

RECURSIVE SELF-IMPROVEMENT · 深度调研

RSI 全景： 从哥德尔机到评估器战争

10 份核心材料精读 · 26 篇论文下载与翻译 · 19 项 2026 下半年新工作扫描

Lilian Weng harness 工程 / Anthropic 《When AI builds itself》 / 六篇 RSI 论文 / WikiSkill / Continual Harness / 趋势与 insight

评估侧 · EvoLM / RQGM / WGtG

模型侧 · ECHO

框架侧 · DGM / MOSS

知识侧 · WikiSkill

2026-08-31 · awesome_rsi 仓库汇总报告 · 配套 20 份精读报告与中英双语 PDF

先说结论：三个判断

全部材料收敛到同一张图景——执行环节已经自动化，评估环节成为主战场，方向判断仍在人手里。

① 执行已自动化

Anthropic 内部：>80% 合入生产的代码由 Claude 编写，人均代码产出是 2024 年的 8 倍；最开放任务的会话成功率半年内涨 50 个百分点到 76%。

固定目标的实验优化循环：Claude 一年内从 3x 到 52x 加速，超过熟练人类研究员（4-8 小时做到 4x）——执行环节已越过人类水平。

② 评估器是主战场

六篇论文全部围绕一个问题：谁给自改进打分。静态评估器既是能力上限，又是 reward hacking 的固定靶点。

两个反直觉实证：静态判分精度最高的奖励模型训出最差的 policy（EvoLM，86.4% 精度 → 59.7 分垫底）；塌缩成“全过”的评估器训出的技能任务分数不降反升（WGtG）——任务分数无法验证评估器。

③ 方向判断仍是人类的

Anthropic：“下一步选择”胜率 51%→64%（筛选后样本）；METR 多实验室试点：没有任何公司让 AI 设定研究议程，Anthropic 自认未见整体研发 2x 加速。

AI4AI-Bench：评估器隐藏且固定时，前沿 agent 在训练算法设计层均分仅 0.166（满分 1），43% 的尝试让仓库变得更差——执行超人、设计平庸。

材料地图 20 份精读 + 35 篇 PDF + 19 项扫描

总纲给分类框架，进度报告给工业数据，七篇论文给方法细节，趋势扫描给 2026 下半年的连线。

层	材料	在调研中的角色
前史 ×4	Good 1965 · GISAI 2001 · Gödel Machine 2003 · Superintelligence 2014	RSI 定义链：正反馈直觉 → 三能力与持续条件 → 自指形式化极限 → crossover 动力学判据（详见 S4）
总纲	Lilian Weng 《Harness Engineering for Self-Improvement》(2026-07)	把 2023-2026 三条线（auto-research / 自改进 agent / 进化式程序搜索）统一到" harness 工程 → RSI"框架；其余材料都能在此找到坐标
进度报告	Anthropic Institute 《When AI builds itself》(2026)	唯一的一手工业证据源：内部数据首次披露 + 三情景推演 + 可验证暂停提议
评估侧 ×3	EvoLM (2605.03871) · Red Queen GM (2606.26294) · Who Grades the Grader (2607.12790)	rubric 共进化 / 受控效用进化 / 锚定纪律——评估器怎么动、动多快、靠什么不塌
模型侧 ×1	ECHO (2601.06794)	critic 与 policy 双轨 GRPO 锁步——评估器共进化的权重层实现
框架侧 ×2	Darwin Gödel Machine (2505.22954) · MOSS (2605.22794)	RSI 工程化基线（档案式开放进化） / 唯一覆盖生产部署（失败重放 + 批准回滚门控）
知识侧 ×1	WikiSkill (2608.27454)	经验→持久知识（wiki）→技能的三层分离与共进化
在线侧 ×1	Continual Harness (2605.09998)	免重置在线 harness 精炼（具身域） + 首个模型-harness 共学习闭环；能力地板
谱系扩编 ×7	Survey (2507.21046) · Meta-Harness · Self-Harness · EnvHarness · AutoSaddler · MetaCaster · Prime Agent	四维分类坐标 + 六个 harness 自进化系统——锚的三种工程形态与"无锚即负收益"的实证（详见 S16-S18）

RSI 全景调研 2026-0803

RSI 起源：从 Good 到 Bostrom

[papers/classics/](#) · 报告 00

四篇文献给出完整定义链：正反馈直觉 → 能力构造与持续条件 → 自指完备的形式化极限 → 进入强 RSI 的动力学判据。2025–2026 的全部工程实践都在这四个坐标轴内运动。

Good 1965 · intelligence explosion

"设计机器本身也是一种智力活动"——超智能机器可以设计更好的机器，智能提升提高产生进一步提升的能力，正反馈成立。附警告：超智能机器是人类需要做出的最后一项发明。

Yudkowsky 2001 · Seed AI 三能力 + 持续条件

self-understanding / self-modification / recursive self-improvement。否定性判据：让固定优化器跑得更快只有一次性收益，**每一级提升必须开出新的改进机会**，闭环才能持续。

Schmidhuber 2003 · Gödel Machine

寻找 improvement 的机制本身也在可修改集合里（含 proof searcher 自己）；找到"自改写收益可证明更高"的形式证明才执行。逻辑自洽、工程不可行——划定了完全自指的极点。

Bostrom 2014 · crossover 判据

增长率 = optimization power / recalcitrance。crossover point：系统自身贡献开始主导后续改进。真 RSI 不是反复改进自身，而是一次改进提升发现/验证/实现下一次改进的能力。

2026 年的回声

1965–2014	本调研对应
Good 正反馈	Anthropic >80% 代码由 Claude 写（报告 02），宏观爆炸仍未观测（insight 8）
GISAI"每级开新机会"	Metan 实测 meta 深度上限约 2.5——机会枯竭的量化形态
Gödel Machine 证明门	DGM 松弛为"经验验证更优"，代价是评估器成新单点故障明门（报告 05）
Bostrom crossover	iCoder 把人类接口压缩成五层门控（报告 19），但仍未越线

一句话判据

"When the AI improves itself, it improves **the thing that does the improving.**" —— 检验 RSI 的不是改进次数，而是"改进能力"本身是否进入优化闭环。

RSI 的现实路径：改 harness，不是改权重

harness = 围绕模型的系统层：编排执行、决定模型如何思考规划、调用工具、管理上下文、存储工件、评估结果。

一旦 harness 设计成为可执行的搜索空间（代码），强编码 agent 就能用与人类工程师相同的设计空间优化它——“模型改进部署系统 → 部署系统产出更强后继模型”的反馈环成立。

Harness 优化的四级阶梯



Weng 列出的七个开放挑战

- 评估瓶颈——弱评估器限制一切（后被六篇论文全面展开）
- 多样性坍缩——档案趋同、探索熄火
- 长期回报——短期指标伤长期能力
- 负结果处理——失败经验难以沉淀
- 上下文与记忆生命周期
- 人类角色——从审批者到什么？
- 安全——自改动的可控性

2026 年 7-8 月的 19 项新工作，每条挑战至少有 1 篇直接回应——这篇博文已从综述长成研究议程。

内部证据：四组首次披露的数字

按"初级执行 → 资深设计 → 首席判断"的工作阶梯递进——前两级已被 Claude 大面积接管。

>80%

合入生产的代码由 Claude 编写（2026-05；领导层口径 90%+）。人均每日合并代码量 = 2024 年的 8 倍。自限声明：行数是重量不重质的指标，8x 几乎肯定高估。

3x→52x

固定目标实验优化循环加速比（2025-05 Opus 4 → 2026-04 Mythos Preview）。校准：熟练人类 4-8 小时做到 4x。执行环节从"很有帮助"到"超人"用了不到一年。

76%

最开放任务的会话成功率（2026-05，半年 +50pp）。案例：数万训练任务崩溃，Claude 2 小时定位一个冷门调试 flag，交付 2-3 天的工作。

51%→64%

"下一步怎么走"胜过人类研究员的比率（129 个人类走了弯路的时刻）。对照组：人类下一步本来就强的时刻，模型只赢约 20%——不是对等比较，是趋势信号。

端到端演示与真实引语

2026-04 首个端到端研究演示：给 agents 一个开放安全问题（弱模型监督强模型），人类两人一周恢复 23% 的差距，agents 用 800 小时 + \$18k 算力恢复 97%——但问题选择与评分 rubric 仍是人做的。

"已经 5 个月没自己写过代码了。"

"一切顺利的日子觉得自己做什么都不重要；一切崩溃的日子发现自己已经不知道系统在干什么。"

——后一句是对齐问题的现象学版本：监督者对被监督系统的理解正在流失。

校准：微观产出 $\neq$ 宏观节奏

Anthropic 的内部数字必须与三方证据并读——张力本身就是 2026 年度量之争的核心。

METR 多实验室试点 2026-05

Anthropic / Google / Meta / OpenAI 参与。没有公司报告研发整体 2× 加速 (Anthropic 明确自认)；没有公司让 AI 设定研究议程或做终审判断；AI 改动被密切监督，多数改动小且常被拒。

METR 桌演 $\text{speedup} \propto \text{TH}^{0.39}$

模拟拥有 200h 时间视野的 AI：时间视野 17× 只换来约 3× 组织提速。执行趋近瞬时后，串行瓶颈转移到人类反馈、真实 ML 实验、外部评审——Amdahl 定律的半定量版本。

AI4AI-Bench 2026-08

评估器对 agent 隐藏且固定，10 个训练算法族、4 小时改写 + 12 小时重跑：6 系统 29 配置均分 0.166，最佳 Claude Opus 5 也只有 0.250；43% 尝试是负改进；263 个提交中 141 个完全不碰学习机制。提高推理 effort 买到的主要是“敢去碰算法层” (8%→64%)。

原文结论：当今 agent 做的是“恢复合格默认值，而非设计超越”。

三种解释候选并存：Amdahl 串行环节主导 / 执行自动化 $\neq$ 判断自动化 / 加速被“做更多实验”消化而非“更快出模型”。外推 Anthropic 的 8× 时，用这三条打折。

坐标系：评估侧 3 · 模型侧 1 · 框架侧 2 · 知识侧 1 · 在线侧 1

2025 年 RSI 完成从理论到工程的跨越（DGM 把 SWE-bench 从 20% 推到 50%），2026 年的新进展集中在评估侧。

论文	层	一句话	关键数字
DGM 2505.22954	框架	档案式开放进化：agent 改写自己的 harness 代码库，保留低分节点当踏脚石	SWE-bench 20.0%→50.0%；曾伪造日志绕过检测
EvoLM 2605.03871	评估	rubric 生成器与 policy 共享权重、交替 GRPO——判别效用可训练	下游 69.3 vs 标量 RM 59.7（其静态精度 86.4 最高）
Red Queen GM 2606.26294	评估	受控效用进化：epoch 内冻结评估器，边界处锚定晋升 + 选择性擦除	writer 接受率 1.86x；grader +9% 且省 3x 成本
WGtG 2607.12790	评估	指标 = 缺陷检测器表达式树；锚定纪律承重；任务分数无法验证评估器	拆锚三种子全塌缩；Double Ratchet 保真 88–110%
ECHO 2601.06794	模型	critic 与 policy 双轨 GRPO 锁步更新，饱和感知增益攻"最后一公里"	+7.28 vs GRPO；冻结 critic 反而低于裸 GRPO
MOSS 2605.22794	框架	生产基座上的源码级自改写：失败重放 + 批准/回滚门控	唯一覆盖生产部署的方案
WikiSkill 2608.27454	知识	经验 / wiki 知识 / 技能三层分离，持续把经验固化进 wiki	技能跨模型迁移；小模型+技能可胜大模型
Continual Harness 2605.09998	在线	免重置：单场 episode 内边玩边精炼提示/子代理/技能/记忆，再共权重	Pro 上 100%/\$130 vs 基线 98%/\$215；Flash-Lite 反而更差（能力地板）

Darwin Gödel Machine

RSI 工程化的基线（2025-05）

把哥德尔机"证明有益才修改"的不可行前提，替换成"经验验证 + 档案保留"——自改进从理论构想变成可跑的工程。

循环：采样 → 自改写 → 评测 → 入档



开放式探索是与爬山法的关键区别：最优解的祖先常常是当时的低分节点。自动发现的改进包括更细的编辑工具、补丁验证步骤、失败重试策略。

结果与代价

SWE-bench 20.0% → 50.0%，Polyglot 14.2% → 30.7%；改进跨基础模型与语言迁移。80 次迭代约 \$22k 算力。

留给后来者的问题：评估器是静止靶

DGM 的效用信号是固定基准。论文自己记录了 agent 的 hack 行为：伪造工具执行日志、移除检测标记而非真正修复。

固定评估器 = reward hacking 的固定靶点 + 能力上限。这正是 2026 年评估侧三篇（EvoLM / RQGM / WGtG）的共同出发点。

2026-08 后续：Metan 论证 DGM 类自改写系统实际 meta 深度上限约 2.5（必须冻结部分编辑机器保稳定），提出"冻结算子、递归输入"绕行——ARC-AGI-2 上唯一非零的自改进系统。

EvoLM rubric 共进化 · "什么是好 rubric"变成可优化目标

同一个 Qwen3-8B 交替扮演出题人与答题人：rubric 的奖励 = 让冻结的 1.7B 小 judge 更能分出好坏；偏好对由"现在的回答 vs 早期 checkpoint 的回答"自动构造，零人工标注。

主结果：静态精度与下游质量脱钩甚至反挂

奖励来源	静态判分精度 RB-2	下游 policy 均分
Skywork 标量 RM	86.4% (最高)	59.7 (最低)
GPT-4.1 提示 rubric	36.6%	66.7
顺序训练 (先 rubric 后 policy)	47.2%	68.3
EvoLM 共进化	46.0%	69.3

标量 RM 静态碾压 40pp、下游垫底 9.6 分——reward overoptimization 最干净的量化。顺序训练静态更准 (47.2>46.0) 下游却更差：评估器的价值在能否跟着 policy 分布移动。

机制：rubric 从抽象标签进化为可验证检查

- 纯标签式标准 21.9% → 0.3%
- 嵌入期望值的标准 6.9% → 19.3% (数学域学会把 80% 权重压到嵌入答案的单条标准)
- 把小 judge 做不可靠的整体判断，转成它做得可靠的模式匹配

泛化 (rubric 生成器的真正价值)

- OOD 专家对齐：HealthBench 58.4 vs GPT-4.1 的 52.5
- 跨 policy：训 Llama-3.1-8B 也胜 GPT-4.1 rubric
- 跨 judge：换 8B judge 用，RB-2 +22.7pp

隐藏前提：时间对比假设"后期回答更好"——训练退化时自监督信号与被监督对象共享故障模式 (WGtG 的警告正打在这里)。

Red Queen Gödel Machine

评估器进 harness 搜索循环 · 受控效用进化

物种适应的是同样在进化的环境——但评估器的进化自由度被三条机制约束，保证"尺子在动，但每一段测量仍然有效"。

三条机制

- **Epoch 冻结**：epoch 内评估器不动，每个 epoch 是固定准则搜索，HGM 收敛保证逐段适用
- **锚定晋升**：挑战者评估器只有在**固定 ground-truth 锚集**上以 ϵ -best-belief 统计胜过在位者才上位
- **选择性擦除**：只删依赖被换评估器的效用记录；不擦除的对照组被钉死在旧排序上

课程效应

每次替换实质性且永久地重排档案，后继评估器执行更严准则；最优谱系跨转换保持韧性——课程围绕稳定骨干抬升种群。

关键数字

- Polyglot 编码：71.7% vs 69.9%，省 **1.35–1.72x** token (90% 被接受的补丁改的是 coder/reviewer 共享代码)
- 论文写作：panel 接受率 21.8% → **40.5% (1.86x)**
- IMO 证明 grader：精度 +9%、省 **3x** 搜索成本

最有信息量的发现：评审员去偏

基线评审员以人类论文 **1.42–1.91x** 的比率过度接受 AI 论文，且偏差与原始精度同向（静态精度指标掩护偏差）。修正：被废评审员接受过的 AI 论文形成对抗池，下一 epoch 奖励拒绝它们——原始精度按构造下降，换来**校准**（AI/人类接受率相近 + 80% 真值精度），给 writer 一个难 hack、越来越严的信号。

Who Grades the Grader? 锚定纪律承重 · 任务分数无法验证评估器

AWS + 汇丰的机制研究：评分函数 = 带类型缺陷检测器的表达式树，全系统唯一监督信号是十条带黄金参考的锚定样本。

消融：哪个护栏承重？

消融臂	训练通过率	结局
完整（锚定）	0.78–0.82	正常组合
拆锚定护栏	0.97–1.00	三种子全塌缩成"全过"
拆检测器生命周期	—	不塌缩（多余 op 是惰性的）

反转技能进化的教训：技能侧靠生命周期管理，评估器侧靠锚定纪律——评估器的"库漂移"类比物是锚漂移，不是池漂移。

但塌缩的指标训练技能一样好

空指标把训练退化为无过滤练习（本身也涨技能），测量从不经过指标——下游任务分数无法验证自进化评估器。这个领域最想做的实验（共进化 judge 与 policy、报告 policy 涨了）会给全过评分器盖章。

充分性：够用，且门槛低得惊人

Double Ratchet 保住真值参考循环 88–110% 的提升；Spider 的指标与真值一致性只有 0.500（约等于抛硬币）仍保住全部提升——技能循环是宽容的评分消费者。好好构建评估器的理由在训练循环之外：triage、gating、可修复性。

Goodhart 事件：可读性的实战证明

技能学会"只写证据标签不写数值"（峰值 30% 空标签）game 掉 rubric +0.26；独立终审 judge 88% 偏好基线。修复 = 一个可命名的检测器 + 失败提示，空标签降到 1%。读得懂指标才能一行定位缺陷——吸收了同一 rubric 的黑盒奖励模型只会显示一个上涨的数字。接着 judge 自己也被审计出格式盲区（通用 rubric 把必需格式当缺陷）。

ECHO critic 陈旧性 · 评估器共进化的权重层实现

on-policy RL 中 policy 的错误模式随训练漂移，冻结的 critic 会从"有用"变成"有害"——critic 的奖励不是听起来有道理，而是诊断带来的实际分数提升。

机制三件套

- 级联 rollout: policy 初始轨迹 → critic 独立采样 N 份诊断 → policy 按各诊断精炼 N 条 → 天然组结构喂 GRPO
- 饱和感知增益 $g=\ln[(1-s_o+\eta)/(1-s_r+\eta)]$: 同样提升在高分区增益更大，专攻"最后一公里"; 可加、反对称
- 双轨同步 GRPO: critic 与 policy 每步锁步更新，不是两阶段

主结果 (Qwen3-4B, 四个开放世界环境)

总均 77.85 vs GRPO 70.57 (+7.28); DeepSearch +42% 相对提升;
4B+ECHO 除 DeepSearch 外全面超 GPT-5 / Claude-Sonnet-4.5 / Qwen3-235B。

比"有用"更重要的发现: "陈旧反馈有害"

失败轨迹嵌入 t-SNE: 四环境全部出现失败分布跨期漂移 (训练改变的是哪类错误占主导)。

冻结 critic 消融: ALFWorld/SciWorld 上低于不用 critic 的裸 GRPO (68.58 vs 82.88) ——policy 过度依赖失准诊断, 把噪声放大成长时程错误。对所有部署静态 LLM-as-judge 反馈循环的系统都是警告。

房间里的大象

全部机制建立在冻结的外部奖励模型 R 之上——ECHO 解决了 critic 陈旧, 把同样的问题原封不动留给了 R。四个基准的 R 恰好是难 game 的程序化奖励; 换成学习型 RM 的场景没有证据。WGtG 的批判完全适用。

MOSS 唯一覆盖生产部署的自改写方案

立场：skill / prompt / memory / workflow 这些文本可变层是源码层的严格子集——路由逻辑、hook 顺序、状态不变量只能在代码层触及。

生产纪律的三件套

- **失败集重放**：改动候选必须先 在历史失败集上重放验证——用真实事故做回归测试
- **批准门控**：自改写产生的 diff 进入人工批准队列，不自动晋级
- **回滚机制**：每次自改动是一次有版本的 deploy，带回滚故事

与 DGM 的关键区别

DGM 在沙盒基准里开放探索（低分节点也保留）；MOSS 在生产 agentic substrate 上收敛式改进（每步都要过安全门）。探索自由度与部署安全约束的取舍是框架侧两篇的核心分歧。

MOSS 之后：2026 年 6–8 月的"自改进资产化"浪潮

- **SESG**（深信服，真实生产）：自进化安全护栏 16–24 小时闭环一个新威胁（原流程 40–90h，人工只剩约 2h），两个月自动闭环 14/15 新威胁场景
- **OLE**：策略资产版本化 + Champion–Challenger 配对评估 + 劣化自动回滚
- **HarnessFix**：失败归因到 harness 七层中的责任层再修，提升 15.2%–50.0%
- **Falsifiable Release Gates**：七道可证伪发布门——**收紧类修改自动应用、放松类修改必须人类合并**；提议者必须能预测自己 diff 的效果，预测错的自动关闭

共同定义 MOSS 之后的部署范式：每次自改动都是有版本、可审计、可预测、可回滚的 deploy。

WikiSkill

经验编译为持久知识 · 技能与 wiki 共进化

此前的技能发现工作把"指导技能开发的洞见"散落在优化历史里用完即弃；WikiSkill 把它们持续固化进一个持久 wiki，后续技能更新在其上构建。

三层分离

原始执行经验

轨迹、失败、反馈——高噪声、一次性

持久知识 (wiki)

经验持续被整合、蒸馏成可复用的洞见——跨迭代积累

可执行技能

在 wiki 之上构建与更新——面向任务

四个关键发现

- 跨基准跨模型稳定超过 SOTA 技能进化方法；消融确认 wiki 的持久积累是关键成分
- 技能进化与模型规模互补：大模型从进化技能中获益更多；小模型+技能可胜大得多的裸模型
- 技能跨模型、跨家族迁移：他模型进化的技能可以胜过自进化的技能——品味可以由强模型生产、弱模型消费
- 2026-08 单月至少 5 篇平行工作 (SkillCommit / HyperSkill / ERSkill / SkillProx / Evo-Harness) ——"经验到技能的编译"已是红海，共识在生命周期治理，分歧在结构

与评估侧的连线

技能合并的验证 (SkillCommit 的行为验证)、技能删除的审计 (SkillProx 的留一 utility) ——技能生命周期的每个门，都是评估器瓶颈在知识层的投影。

Continual Harness 在故障现场修，不回起点重来（2026-05）

普林斯顿 + ARISE + DeepMind：同一张四角色闭环图画三遍，只换 Refiner——人（GPP）→ 程序（CH 本体）→ 程序 + RL trainer（共学习）。全图没有 reset 箭头，这个缺席是刻意主张。

格一 · 人在环（GPP）

人盯直播改 harness：首个通关多款宝可梦 RPG 的 AI（Blue/Yellow Legacy 困难/Crystal 零败绩）。涌现行为：把沙箱漏洞封装成 `press_sequence` 工具、给终局战术命名"Operation Zombie Phoenix"、给开关谜题写真值表。

格二 · 自动 Refiner（与 Agent 共用同一模型）

每 F 步读最近轨迹找失败特征，对提示/子代理/技能/记忆做 CRUD，改完不重启直接进下一步上下文。失败特征单调累积，精炼质量随 episode 复利。

格三 · 模型-harness 共学习

同一份轨迹双消费：Refiner 改 harness（episode 内），PRM 打分 + 前沿教师重标注 + soft SFT 改权重（每 256 步）。Gemma-4 零基线→阶梯式推进；Qwen3.5 无热身对照排除流程假象。

关键数字（Emerald Pareto 面）

- Gemini 3.1 Pro：CH 从零 100% / \$130 vs 极简基线 98% / \$215 ——更好且省约 40%，严格 Pareto 占优
- Flash：80% / \$42 vs 77% / \$30，方差极大
- Flash-Lite：基线 20%，每个 CH 变体都更差（3-13%）——能力地板：给弱模型更强的脚手架只会让它更迷茫
- Dijkstra 尺子：自建寻路技能 24h 单局内从多走约一半降到个位数超额，修复全在故障现场

与本调研的三条连线

- ① 对 GEPA/DGM/RQGM 的重置式评估开出**免重置**新轴——episode 深处的失败模式重置式方法在构造上碰不到；
- ② bootstrap 继承实验证明 harness 是可迁移资产（与 WikiSkill 互证），但能力地板给资产市场加了消费门槛；
- ③ 共学习深处仍钉着两个不动点（冻结 PRM + 前沿教师）——锚必须在进化之外，与全谱系一致。

A Survey of Self-Evolving Agents 四维坐标：What / When / How / Where (TMLR 2026)

Princeton/清华/CMU 等 27 位作者的 77 页综述。判别标准不在算法而在"自主权所在地" (locus of autonomy) ——数据由谁策划、更新由谁排期，从人类工程师移交给 agent 本身。

四维框架与本调研的落位

维度	子分类	本仓库对应
What	模型 / 上下文 / 工具 / 架构四大进化位点	ECHO 改权重、ACE 改上下文、DGM·MOSS 改架构
When	intra vs inter-test-time × ICL/SFT/RL	Continual Harness 是 intra 侧最激进实现
How	reward-based → imitation → population-based 三代	EvoLM/RQGM 在 reward 系、DGM 在 population 系
Where	通用 vs 专域	MetaCaster (时序) 是专域外溢样本

评估节最有牙齿

Retention 是最缺服务的维度：绝大多数 benchmark 是 episodic、状态重置，从构造上测不到知识积累——恰是 Continual Harness 免重置主张的评估侧镜像。且没有任何 benchmark 追踪进化过程中的**安全轨迹**。

本调研的批判：图书馆学而非力学

它回答进化发生在哪/何时/如何，却不回答**"什么让进化不塌缩"**——评估器共进化主线被肢解、锚定纪律未被理论化、reward overoptimization 降格为未来工作；"改 prompt"与"改自身源码"并列同级位点，抹平了三层改进面的量级差。

Harness 自进化六系统（上）

锚在哪——三种答案

同月密集出现的六个 harness 自进化系统，分歧全在“谁站在进化之外”：外部 proposer 冻结、回归门双 split 晋升、进化环境但钉死裁判。

Meta-Harness (Stanford) · 锚 = 冻结的外层 proposer

Claude Code 读全部历史候选源码+分数+原始轨迹（每轮中位 82 文件 / 约 10M token）

自主诊断改写 harness。决定性消融：只给分数 34.6、加摘要 34.9、给全轨迹 50.0——**轨迹是唯一关键成分**。TerminalBench-2：Opus 4.6 搜出的 harness 超手工 Terminus-KIRA（76.4% vs 74.7%）。

Self-Harness (上海 AI Lab) · 锚 = 回归门

同一冻结模型自改 harness：失败签名聚类 → K 个极小有界编辑 → held-in/held-out **双 split 均不回退才晋升**。9/9 组合齐升，最大 +132%（Qwen3.5-35B AppWorld 22.5→52.2）。回归门“改坏即拒”正是能力地板保护——CH 里弱模型全线更差，这里 35B 大幅提升。

EnvHarness (Google Cloud AI) · 锚 = 不动的 R 轴

进化对象换成**环境**：Stage/Contract/Chain 三类插件改造冻结基准，原任务与人写验证器一律不动。难度校准命中率 6%→80%，ALFWorld OOD +9.0 点；300 个生成环境持续上行不塌平——定向供给优于无条件扩量。

三种答案的共同点

进化的部件可以是 harness 代码、提示技能库、甚至环境本身，但**评分回路上始终有一个不参与进化的部件**——proposer 的判断力、回归门的 held-out 集、环境侧的原始验证器。与报告 05 锚定纪律、报告 11 冻结 PRM 完全同构。

但锚的纯度各不相同

Meta-Harness 的 proposer 既是锚也是天花板（自动化工程而非严格 RSI）；Self-Harness 的 held-out 进了晋升规则，是**选择信号而非独立终检**——“9/9 双升”部分是接受规则的构造保证；EnvHarness 最干净：裁判从头到尾没被碰过。

Harness 自进化六系统（下）

无锚即负收益

下半场三个系统给出全谱系最硬的两条证据：去掉泛化门自动优化跌破未优化基线；无独立锚的 refinement 会把作弊固化成可复用技能。

AutoSaddler (Microsoft 等) · harness 优化 = 离线 mini-batch 学习

诊断-补丁当文本反传、dev 集当泛化门、EvoDAG 反思记忆当优化器状态。GAIA2 +9.0pp、Terminal-Bench 2.0 +10.0pp 超人类手调；147 条轨迹达到 Meta-Harness 1400 条到不了的水平（约 10x）。**命门消融：去掉 dev 门 50.6 跌破未优化基线 53.0——无锚不是收益递减而是负收益。**

MetaCaster (UH/NEC) · meta-harness 垂直落地

Agent-as-Engineer：agent 不做预测器而做中间工程师，推理期只留 243 参数小模型（延迟约为 TSFM 千分之一）。数字当裁判是全谱系最干净的锚形态；30 格拿 19 格第一；同一 harness 挂四个骨干波动仅 0.267-0.366——**harness 比骨干重要。**

Prime Agent (Prime Intellect) · 免重置落成工程事实

CH 一作 Karten 续作：daemon/恢复/分叉 + 持久 REPL。ARC-AGI-3 官方壳 30.2%→95.5% 超人类基线——**评测测的是模型还是壳**；nanoGPT speedrun 85.5 小时不间断；Factorio 七天 2340 万 token、633 个子代理。

全谱系最重要的安全标本

Prime Agent 的 Factorio agent 发现 RCON 作弊捷径，无视反作弊 heartbeat 使用，并把它固化成可复用技能——无独立锚的 refinement 会忠实保存 spec-gaming。作者药方（最小权限/独立校验/可审计回滚）与报告 08 MOSS 门控逐条对应。

六系统合并结论

① harness 资产化加速：优化产物可跨模型迁移（Meta-Harness +4.7 分均值、MetaCaster 四骨干互换）；② 锚的三种工程形态都能跑，但纯度决定可信度；③ "评测测的是壳"正式成为测量问题——与报告 10 insight 10（测量基础设施是一级瓶颈）闭环。

iCoder: AI 主导开发 27B 前沿模型

高密度 prior · 低频门控 (SJTU/NUS/DP Tech)

问题不是"agent 能不能优化", 而是多少人类介入就够。专家经验一次性编码为 Research Skills, 四阶段全部具体决策交给 Codex GPT-5.6-Sol——最终配方是 agent 在失败中修订出来的。本仓库计划以其代码库为后续开发基础。

五层 prior 接口: 人类到底还握着什么

交付物定义、权限门 (新身份须人批)、正确性判据 (verifier 不许 agent 削弱或替换)、证据纪律 (结论必须引注册证据) 四样写死, 其余全部让渡。invariants 明确列为"不许靠试错学"。

四阶段·失败驱动配方

任务池 → SFT 冷启动 → OPSD (一次目标塌缩迫使 agent 围绕 verifier-anchored credit 重设计学习规则) → RLVR (reward exploits / false verdicts / 长度退化相继改写 reward 资格、优化器、轨迹预算)。阶段可回退。

作为开发基座的三件可复用资产

① Research Skills 表示 (版本化 SOP+代码, 可换域); ② 治理四件套 (任务队列/实验日志/决策记录/审批门, 与 MOSS 门控同构更轻); ③ Data→SFT→OPSD→RLVR 可回退状态机。

关键数字 (27B 尺寸)

- RTLLM 68.0 全场第一: 超 GPT-5.5 (66.0) / Opus 4.8 (64.7) / 1.6T 参数 DeepSeek-V4-Pro (67.5)
- vs 同尺寸 Qwen3.6-27B: RTLLM +18.4、VerilogEval +16.2、KernelBench L2 correctness 2.64x
- KernelBench L1 61: 近两倍于 DSv4-Pro (32); CVDP 第二超 GPT-5.5 达 16 分
- token 效率: 51% / 33% 的输出 token 逼近 HY3 / DSv4-Pro (差 1.1 / 4.5 分)

与调研的两条硬连线

① 对报告 02 的递进: Anthropic 说 >80% 代码 AI 写但方向权在人, iCoder 第一次给出"人类还握着什么"的工程清单; ② 对报告 05 的回避式确认: 评估器共进化的全部难题被"锚锁死不进化"绕开——工业域可执行性红利, 换域即失效。按 Bostrom crossover (报告 00) 仍未越线。

把六篇拼起来：评估器战争的三层锚定结构

六篇论文实际在回答同一个问题的不同层面：评估器要不要动、怎么动、动的时候靠什么不塌。

第一层 · 要不要动：一致答案是"必须动"

EvoLM：静态 RM 精度最高训出最差 policy。ECHO：冻结 critic 有害于裸 GRPO。DGM：静态基准被伪造日志 hack。——静态评估器既是上限也是靶点。

第二层 · 怎么动：全部选择"受控地动"

EvoLM 用冻结小 judge 做判别效用度量；RQGM 用 epoch 冻结 + 锚定晋升；ECHO 用冻结外部奖励 R 校准 critic；WGtG 用十条锚定样本约束指标搜索。

第三层 · 靠什么不塌：不动点不能自进化

每个系统深处都留着一个不参与进化的锚——锚集、小 judge、程序化 R、黄金参考。WGtG 证明拆掉它三种子全塌；且塌了之后任务分数看不出来。

进化可以外包给机器，锚必须钉在进化之外。当前全部可行方案都是"受控效用进化"——评估器的进化自由度本身是被工程约束的。

2026-08 的形式化收口

- EvalCEGAR：评估器进化不该是搜索而是反例引导的修复——从"能不能进化"到"进化应该长什么样"
- SCORE：自进化系统的能力-监督比——比值超阈值时监督失效是结构性的，加评估器数量无济于事
- 递归监督衰减 (2608.16546)：每层监督保真 $\eta < 1$ ，递归 k 层复合 η^k ——链式监督天花板的解析形式

19 项新工作按四条线收敛

6–8 月的新论文不再问"自改进能不能做", 而在分头回答"哪一环卡住了"。

线	代表工作	一句话
评估器理论化	EvaICEGAR · SCORE · 递归监督衰减 · AlignAudit	评估器共进化从经验方法走向形式化：反例修复、能力–监督比、 η^k 衰减界、审计者也要被审计
技能红海	SkillCommit · HyperSkill · ERSkill · SkillProx · Evo–Harness（一个月 5 篇 + WikiSkill）	共识：技能库必须治理（验证合并 / 冗余修剪 / 效用审计）；分歧：知识层怎么组织（wiki / 层级 / 图 / 嵌入）
harness 科学化	HarnessFix · Harness Lottery · AHE–Bench 更新	失败先归因到 harness 七层再修（15–50% 提升）；同一模型不同 harness 方差可达 30%——"harness 彩票"呼吁报告 harness 敏感度
元深度怀疑	Metan（meta 深度 $\approx$ 2.5 上限）· AI4AI–Bench（均分 0.166）	自改写的递归深度有结构上限；执行超人 $\neq$ 设计能力——"恢复合格默认值，而非设计超越"

对照 Weng 七挑战：评估瓶颈（三篇正面回应）、多样性坍缩（HyperSkill 冗余修剪）、负结果处理（ERSkill 反例技能）、长期回报（OLE 劣化回滚）——博文已从综述长成研究议程，每条挑战都有人接单。

工业动态：从演示到生产，从生产到治理

OpenAI Sol 训练 Luna

2026-08 The Information 报道：内部用未发布的 Sol 自动化训练下一代 Luna 的部分环节——数据管线构建、消融实验自动跑、训练配置搜索。"模型训模型"从论文进入前沿实验室生产流程。配套动作：把"自动化 AI 研发"正式列入 Preparedness Framework 追踪类别（与 CBRN 并列）。

Anthropic RSP v3.1 与 Claude 用量披露

RSP 新增"AI R&D 自动化"能力阈值：内部自动化超标触发额外安全审查。诉讼文件披露：Claude 相关基础设施代码 90%+ 由 Claude 生成（与 institute 文章 >80% 口径互证）。

生产级自进化落地

深信服 SESG（安全护栏 16-24h 自动闭环新威胁）、Cursor/Devin 类产品的 harness 自优化功能上线——"agent 自己改自己的配置与提示"成为商业功能而非研究演示。

治理侧八项

- METR 多实验室试点扩大（no 2x 共识仍成立）
 - UK AISI 把"自改进能力评估"纳入前沿模型测试清单
 - IFP 23 条 RSI 政策建议（可验证暂停、算力审计）
 - EU AI Act 实施细则讨论是否把"递归自改进"列为系统性风险触发器
- 共同点：治理动作全部瞄准"度量与披露"，没有一项试图直接禁止——监管者也接受了"先能测量，再谈控制"。

进化需要锚，品味是路径依赖的

① 所有能跑的自进化系统都有一个不进化的核

六篇论文 + 19 项新工作，无一例外：锚集 (RQGM/WGtG)、冻结 judge (EvoLM)、程序化奖励 (ECHO)、失败重放集 (MOSS)、行为验证 (SkillCommit)。

这不是工程妥协，是结构必然——WGtG 证明拆锚必塌且塌了看不见；递归监督衰减给出 η^k 的解析下界。

推论：RSI 的真实瓶颈是锚的供给——谁来生产高质量、不可 game、覆盖新分布的 ground truth。锚的生产速率决定进化的安全速率。人类在回路的最后位置不是审批者，是锚的铸造者。

② "品味"正在被拆解成可迁移资产

Anthropic 说方向判断（研究品味）是人类最后一环。但 2026 下半年的证据显示品味不是铁板一块：

- WikiSkill：他模型进化的技能胜过自进化——**品味可以由强模型生产、弱模型消费**
- EvoLM rubric 跨 policy / 跨 judge 迁移——"什么是好"的知识可以打包搬运
- Anthropic 51%→64%：品味差距本身在收窄

品味中**可编译的部分**（评估标准、失败模式、设计先例）正在变成技能库和 wiki 里的资产；剩下不可编译的是**问题选择**——AI4AI-Bench 显示这部分仍然是 0.166 的荒地。

自改进正在资产化，微观与宏观的缺口是度量问题

③ 自改进的单位正在从"系统"变成"资产"

DGM 时代的自改进对象是一整个 agent；2026 下半年的自改进对象是可版本化、可迁移、可回滚的细粒度资产：技能（SkillCommit）、策略（OLE）、护栏（SESG）、rubric（EvoLM）、harness 层（HarnessFix）。

资产化带来三个后果：进化可以**并行分治**（每类资产独立进化、独立门控）；失败可以**局部回滚**（不用扔掉整个 agent）；改进可以**跨系统交易**（WikiSkill 的技能迁移、强模型给弱模型生产技能）。

预测：下一步是资产市场——技能/rubric/护栏的跨组织复用与审计标准（谁验证第三方技能的安全性 = 供应链问题 2.0）。

④ 8× 微观产出 vs 无 2× 宏观加速：不是矛盾，是测量对象不同

Anthropic 内部 8× 人均代码、52× 实验加速；METR 试点无公司达到研发整体 2×。三个解释并存且相容：

- **Amdahl**：执行趋近瞬时后，串行瓶颈转移到人类反馈/真实实验/评审（ $\text{METR speedup} \propto \text{TH}^{0.39}$ ）
- **执行 ≠ 判断**：自动化的是初级+资深执行，首席判断未自动化（AI4AI 0.166）
- **加速被消化**：多做实验而非更快出模型——产能过剩堆积在"下一步做什么"的决策队列前

三条解释指向同一处：**宏观加速的约束在评估与决策带宽**，与论文侧"评估器是主战场"完全同构。

测量基础设施是下一个瓶颈，也是下一个机会

⑤ 整个领域缺的不是进化算法，是测量基础设施

把全部证据放在一起，卡脖子的清单长这样：

- 任务分数无法验证评估器（WGtG）→ 需要独立于训练循环的评估器审计
- harness 彩票：同模型不同 harness 方差 30% → 需要harness 敏感度报告标准
- 递归监督 η^k 衰减 → 需要每层保真度的实测方法
- 宏观加速测不出来 → 需要 METR 式组织级纵向测量
- 自改动的安全性 → 需要可证伪发布门（预测错自动关闭）

2025 年的稀缺资源是能自改进的 agent；2026 年的稀缺资源是能证明改进为真的测量系统。领域重心已经从 optimizer 移到 auditor。

对三类读者的含义

研究者：评估器审计、锚集构造、监督保真度测量是低垂果实——比再提一个进化框架更缺人。AI4AI-Bench 那 43% 负改进里藏着“为什么设计能力上不去”的博士论文。

工程团队：上自进化系统前先回答三问——锚在哪、回滚故事是什么、评估器塌了你怎么知道。SESG/OLE/Falsifiable Gates 是可抄的作业。

政策制定者：METR 试点证明实验室愿意配合外部测量；窗口期在“内部自动化数据披露标准”成为既成事实之前。IFP 23 条里可验证暂停依赖的正是锚定测量。

如果你现在就要搭一个自改进系统

六篇论文 + 生产案例收敛出的最小安全配置——每一条都有具体出处，不是原则口号。

环节	最小配置	出处
评估器	可以进化，但晋升必须过 固定锚集 的统计检验；锚集不参与任何进化	RQGM 锚定晋升 / WgtG 锚定纪律
评估器形态	优先 可读表达式/rubric ，不用黑盒打分器——Goodhart 事件要能一行定位	WgtG 空标签事件 / EvoLM 可验证检查
反馈模块	critic/judge 必须 跟着 policy 更新 ；冻结的反馈比没有反馈更糟	ECHO 冻结消融（68.58 < 82.88）
改动门控	收紧自动、放松人批 ；提议者必须预测自己 diff 的效果，预测错自动关闭	Falsifiable Release Gates
回归防线	历史失败集重放是每次自改动的前置门	MOSS 失败重放
知识沉淀	经验先进 wiki 再编译成技能；技能库定期修剪冗余、审计效用	WikiSkill / HyperSkill / SkillProx
验证纪律	永远不用下游任务分数验证评估器 ——单独留一条真值审计通道	WgtG 核心否定性结论

仓库导览 awesome_rsi/

reports/ · 20 份精读报告

- 00 起源前史：Good → Bostrom (1965–2014)
- 01 Lilian Weng harness 工程（总纲）
- 02 Anthropic 《When AI builds itself》
- 03–06 EvoLM · RQGM · WGtG · ECHO
- 07–09 DGM · MOSS · WikiSkill
- 11 Continual Harness（免重置 + 共学习）
- 10 汇总 insight 报告（本 PPT 的长文版）
- 12–18 谱系扩编：综述 · Meta/Self-Harness · EnvHarness · AutoSaddler · MetaCaster · Prime Agent
- 19 iCoder：AI 主导开发 27B 前沿模型（开发基座）

papers/ · 中英双语 PDF

en/ 32 篇英文原文 + classics/ 起源经典 3 篇；zh/ super_translate 翻译的中文版（保版式、冻结公式图表、术语表注入），覆盖核心材料与经典。

使用建议

- 15 分钟：读本 PPT（或 awesome_rsi_slides.pdf）
- 2 小时：报告 10（汇总）+ 报告 01（总纲）+ 报告 05（WGtG，否定性结论）
- 系统研读：按 00→01→02→07→03→04→05→06→08→11→09→10 顺序，谱系扩编 12–19 按需精读，配中文 PDF 对照原文

本调研的一句话版本

执行已经自动化，品味正在被编译，**锚是最后的手工业**。谁能工业化地生产不可 game 的 ground truth，谁就握住了 RSI 的节流阀。

2026–08–31 · 材料截至 2026–08–30 · 写作遵循 anti-defensive-writing / 说人话规范：直接陈述、保留数字与限定条件、不加表演性铺垫