

欢迎使用通用智能与种子人工智能（General Intelligence and Seed AI）2.3 版。本文档旨在阐述构建一个具备通用智能、能够自我理解、自我修改和递归自我增强的完整心智所需的原理、范式、认知架构和认知组件。

多页版本: <http://singinst.org/GISAI/> 单页版本:

<http://singinst.org/GISAI.html> 可打印版本:

<http://singinst.org/printable-GISAI.html>

©2001 by the Singularity Institute for Artificial Intelligence, Inc. All rights reserved.

- Preface
- Executive Summary and Introduction
- 1: Paradigms
 - 1.1: Seed AI
 - 1.1.1: The AI Advantage
 - 1.2: Thinking About AI
- 2: 心智
 - 2.1: World-model
 - Interlude: The Consensus and the Veil of Maya
 - 2.2: Sensory modalities
 - 2.3: Concepts
 - 2.3.1: Modality-level, concept-level, thought-level
 - 2.3.2: Abstraction is information-loss; abstraction is not information-loss
 - 2.3.3: The concept of "three"
 - 2.3.4: Concept combination and application
 - 2.3.5: Thoughts are created by concept structures
 - Interlude: Represent, Notice, Understand, Invent
 - 2.4: Thoughts
 - 2.4.1: Building the world-model
 - 2.4.2: Creativity and invention
 - 2.4.3: Thoughts about thoughts
 - 2.4.4: The legitimate use of the word "I"
- 3: Cognition
 - 3.1: Time and Linearity
 - 3.1.1: The dangers of the system clock
 - 3.1.2: Synchronization
 - 3.1.3: Linear metaphors: Time, quantity, trajectory
 - 3.1.4: Linear intuitions: Reflection, simultaneity, interval, precedence
 - 3.1.5: Quantity in perceptions
 - 3.1.6: Trajectories
- Version History
- Appendix A: Glossary

前言

《通用智能与种子人工智能》由奇点人工智能研究所（Singularity Institute for Artificial Intelligence, Inc.）出版，该研究所是一家非营利公司。您可以通过 institute@singinst.org 联系奇点研究所。如需支持奇点研究所，请访问 <http://singinst.org/donate.html>。奇点研究所是 501(c)(3) 公共慈善机构，您的捐款在法律允许的最大范围内可免税。种子人工智能项目目前处于设计/概念化阶段，尚未编写任何代码；在项目启动之前需要额外资金。《通用智能与种子人工智能》以非正式风格撰写。学术读者、寻求更技术性解释的读者或偏好更正式风格的读者，不妨阅读《通用智能中的组织层次》（Levels of Organization in General Intelligence）。

这是一篇接近书籍长度的阐述。如果您需要对该主题有扎实的了解，我们强烈建议您从头到尾阅读《通用智能与种子人工智能》（GISAI）。然而，如果您需要立即获得答案，请参阅奇点研究所关于人工智能的页面以获取介绍性文章。

《通用智能与种子人工智能》是一项持续进行的工作。截至 2.3 版，“范式”和“心智”部分已完成且自成体系。“认知”部分正在进行中，可能包含对未实现主题的引用。随着更多主题的发布，次要版本号（第二位数字）将增加。

术语表中定义的词看起来像这样：“种子人工智能是一种能够自我理解、自我修改和递归自我增强的人工智能。”

执行摘要与引言

请注意，以下内容仅为引言。其中包含一些必须提前介绍以避免实际解释中出现循环依赖的思想，以及对认知架构的总体概述，以便您了解这些思想在整体中的位置。特别需要说明的是，我并不期望您读完引言后立即惊呼：“啊哈！这就是人工智能的奥秘！”是的，文中描述了一些重要思想，但一个思想是必要的并不意味着它就是充分的。人工智能过去的许多失败都源于追求奖杯的心态，只问代码可以用哪些流行词来描述，而不问代码实际做了什么。本文讨论的是通用智能——它是什么，以及如何构建一个。期望的最终结果是一个自我增强的心智或“种子人工智能”。种子人工智能意味着——与其试图构建一个立即具备人类水平或超人类推理能力的心智——目标是构建一个能够自我增强的心智，然后利用更高的智能再次自我增强，直到达到目标点。“任务不是构建一个具有某种天文数字智能水平的人工智能；任务是构建一个能够自我改进、理解并重写自身源代码的人工智能。任务不是建造一棵参天橡树，而是一颗谦卑的种子。”（摘自 1.1：种子人工智能。）

通用智能本身是极其庞大的。人类大脑经过数百万年的进化，由一千亿个神经元通过一百万亿个突触连接而成，形成了一百多个神经学上可区分的区域。我们不应期望人工智能问题会很简单。认知的子问题包括注意力、记忆、联想、抽象、符号、因果性、虚拟性、期望、目标、行动、内省、缓存和学习，这只是一个不完整的列表。这些特征并非“涌现”的。它们是° 复杂的功能适应，是拥有多个组件和精密内部架构的进化系统，其功能必须在人工心智中被刻意复制。如果做得好，认知可以支持实现分析、设计、理解、发明、自我意识以及其他方面能力的思想，这些方面共同构成了一个智能心智。一个能够访问自身源代码的智能心智可以做各种巧妙的事情，但我们稍后会深入探讨。

不同的人工智能学派以其底层“心智材料”的不同类型而相互区分。经典人工智能由“谓词演算”或“命题逻辑”构成，即被暗示性命名为° LISP 符号的实体，加上旨在模仿人类形式逻辑的直接编码程序。联结主义人工智能由在符号层面实现的神经元构成，输入层和输出层的每个神经元具有程序员确定的解释，中间层通常不赋予直接解释，整个网络通过外部算法训练以执行感知任务。（尽管更具生物学真实性的实现正在涌现。）基于智能体的人工智能由数百段人工编写的代码组成，这些代码执行程序员所期望的任何功能，其交互范围从传递数据结构到相互篡改行为。

种子人工智能继承了联结主义的信念，即容错是有益的。容错导致变异能力。变异能力导致进化。进化导致丰富的复杂性——具有众多触角和相互连接的“心智材料”。然而，联结主义理论呈现出一种二元对立：° 随机的、容错的神经元与代码或汇编语言的晶体般脆弱性之间的对立。这混淆了两个逻辑上不同的概念。可能存在晶体般的神经网络，其中单个错误就会破坏因果链；也可能存在随机代码，例如，一个函数点的多个可变异实现具有可调整的权重。种子人工智能强烈强调认知过程中丰富复杂性的必要性，并对经典人工智能的直接程序化实现持不信任态度。

然而，种子人工智能（Seed AI）同样不信任那种联结主义立场，该立场认为高级认知过程神圣不可侵犯且不透明，人类程序员不得涉足，只能摆弄神经元行为和训练算法，而不能触及实际的网络模式。种子人工智能确实偏爱学习到的概念而非预编程的概念，因为学习到的概念更为丰富。尽管如此，我认为预编程概念以引导人工智能达到能够学习的程度是允许的，尽管存在风险。更关键的是，拥有这样一种架构是可以的：即使较高层级是随机的、自组织的、涌现的、学习的或其他任何情况，程序员仍然能够观察和修改正在发生的事情。而且，设计者有必要了解较高层级上正在发生什么，至少是大致了解，因为认知能力并非涌现的，也不会偶然发生。经典人工智能和联结主义人工智能都提出了一种魔法，以回避实际实现认知较高级别的困难。经典人工智能声称，一个名为“目标”的 LISP 符号就是一个目标。联结主义人工智能宣称，这一切都可以通过神经元和训练算法来完成。种子人工智能承认有必要直接面对这个问题。

在人脑中，至少存在一个多层次系统，其较高级别虽具随机性，却仍有已知的解释：视觉处理系统。视觉皮层及相关区域的特征提取并非按照带有编号层级的严格层级进行（种子人工智能不信任这类结构），但确实存在低层特征（如视网膜像素）、中层特征（如边缘和表面纹理）以及高层特征（如三维形状和运动物体）。像素与附加的解释共同构成了作为视觉描述的认知对象。也可以反向运行特征提取系统，激活一个高层特征，使其引入中层特征，进而引入低层特征。这种“可逆模式”对于记忆召回和定向想象是必要但不充分的。当通过这种方法实现时，记忆和想象能够容纳丰富的概念，这些概念可以有趣地变异并连贯地混合。一根红色香肠的心理图像可以直接变异为一根蓝色香肠的心理图像，而无需将红色的感知存储于单一晶体令牌中，也无需逐像素独立地变异图像。° 大卫·马尔（David Marr）的“二维半世界”范式，即多层次整体描述，被放大并认为不仅适用于感官特征提取，也适用于类别、符号及其他概念。如果种子人工智能拥有“心智质料”，那么这就是它。

种子人工智能（Seed AI）同样强调感官模态（sensory modalities）的问题（例如人类的视觉皮层、听觉皮层和感觉运动皮层），此前这被视为专用机器人人才需考虑的事项。感官模态由适合表示目标领域“像素”和特征的数据结构，以及提取该领域中层级和高级别特征的代码片段（codelets）或处理阶段构成。感官模态在目标领域赋予卓越的直觉和可视化能力，这本身就足以成为赋予自修改人工智能源代码感官模态的理由。感官模态还能对其他领域的抽象推理提供有用的隐喻和具体基础；你可以利用视觉皮层下棋，或想象一个“分支”的如果-那么-否则语句。感官模态提供了概念得以形成的计算“原材料”来源。最后，感官模态为理解训练领域中的具体问题提供了直觉，例如

源代码。这使得人工智能能够学习抽象的艺术——从具体问题出发，到对感官数据进行分类，再到概念化复杂方法，依此类推——而不是被期望一次性吞下高层级思维。

感官模态是智能的基础——这个术语经过精心挑选，以反映必要性而非充分性；在打好基础之后，仍然有大量的“房屋”需要建造。特别是，代码模态并不编写源代码，正如视觉皮层并不设计摩天大楼。当我谈到“代码”感官模态时，我并不是将“感官模态”这一术语扩展为包含自主编写源代码的能力。我是在原始意义上使用“模态”一词，来描述一个几乎与视觉皮层完全类似的系统，只不过它运作于源代码领域而非像素领域。

感官模态——视觉、空间、编码——是人工智能的底层，在这一层中，表征和行为由程序员直接指定。（尽管避免经典人工智能的晶体脆弱性仍然是一个设计目标。）下一层是概念。概念是心智素材的片段，既可以描述心理世界，也可以应用于改变心理世界。（注意，连续的概念可以应用于单一目标，构建出复杂的可视化。）概念包含在长期记忆中。类别、符号以及大多数陈述性记忆都属于概念。如果概念由人工智能学习、训练或以其他方式创建，则它们更加强大，但程序员也可以出于引导目的创建概念。（当然，前提是程序员能够破解修改概念层所需的工具。）概念的底层基质可以是代码、汇编语言或神经网络，以最不脆弱且最易于理解和变异者为准；这个问题将在后面讨论，但我目前倾向于代码。（当然，不是原始代码，而是人工智能所理解的代码。）

概念从长期记忆中检索出来，构建成结构并激活后，便产生思维。思维的典型例子是将词语——符号——构建成合乎语法的句子，并在心智中“说出”它们。思维存在于心智的随机存取存储器中，即由感官模态中可用工作空间创建的“工作记忆”。在思维存在期间，它可以修改工作记忆中当前正在检查的那部分世界模型。（并非心智中说出的每个句子都旨在描述现实；思维还可以创建和修改虚拟（“假设”）假设。）思维被等同于——旨在实现——人类“意识流”的功能。

智能的三层模型是必要的，但并非充分。构建一个“具有感官模态、概念和思维”的人工智能并不能保证智能。人工智能必须拥有正确的感官模态、正确的概念和正确的思维。

进化是人类智能的成因。智能是一种进化优势，因为它使我们能够建模、预测和操纵现实，包括由其他人和我们自己构成的那部分现实。在我们的物理宇宙中，现实倾向于沿着可被称为“整体论”或“还原论”的路线组织自身，这取决于你是向上看还是向下看。“哪些事实可能再次出现？简单的事实。如何识别它们？选择那些看似简单的事实。要么这种简单性是真实的，要么复杂元素是不可区分的。在第一种情况下，我们很可能再次遇到这个简单的事实，无论是单独出现还是作为复杂事实中的一个元素。第二种情况也有很大机会重现，因为自然界不会随机构造这种情况。”（罗伯特·M·波西格，《禅与摩托车维修艺术》，第238页。）

思维发生在一个因果的、目标导向的、“还原整体论”的世界模型之中，并寻求更好地理解世界或为问题发明解决方案。一些方法包括：整体分析：取一个已知高层对象的已知高层特征（“鸟会飞”），并使用启发式方法（从经验中学到的思维层面知识）尝试为该特征构建一个解释；解释由一个低层结构组成，该结构以与关于该高层对象的所有已知事实一致的方式产生了该高层特征（“鸟拍动的翅膀将其向上推”）。因果分析：取一个已知事实（“我的电话在响”），并使用启发式方法构建一个导致该事实的因果序列（“有人想和我说话”）。整体设计：取一个高层特征作为设计目标（“跑得快”），使用启发式方法通过推理可能设计中的约束和机会来缩小搜索空间（“使用轮子”），然后测试试图满足目标的特定低层结构的想法（“自行车”）。

理解与发明在本质上都是混乱的递归过程；自行车能否工作取决于车轮的设计，而车轮能否工作又取决于车轮是由钢铁、橡胶还是木薯布丁制成。因此，需要启发式方法将高层次特征与低层次属性绑定。因此，需要在寻找新启发式方法、更多证据、更好工具、更高智能或更高自我意识的过程中递归，直至最终任务得以解决。解决问题既能带来即时的解决方案，也能促进持久的自我发展。

当足够先进的人工智能能够将“文字处理程序”这一高层次特征，通过多层设计绑定到具体的代码行时，它就能根据“编写一个文字处理程序”的口头指令来编写程序。（当然，遵循口头指令还假设具备语音识别和语言处理能力——更不用说对文字处理程序是什么、做什么、用途何在、人类将如何使用它，以及为什么该程序不应擦除硬盘有非常详细的了解。）当人工智能，或许被赋予对原子和分子的感知模态，能够理解所有现存的分子操控研究时，它就能制定出一系列步骤，从而构建出通用的纳米技术组装器，或构建该组装器所需的工具。当人工智能能够将“有用的智能”这一高层次特征，通过多层设计的认知过程绑定到具体的代码行时，它就能重新设计自身的源代码并提升其智能。

开发这样的种子人工智能（Seed AI）可能需要程序员付出巨大的努力和创造力；种子人工智能完全有可能是历史上最雄心勃勃的软件项目，不仅体现在最终结果上，也体现在内部设计复杂性的纯粹深度上。为了使问题进入人类可解决的范围，开发必须分阶段进行，以便人工智能的早期阶段能够协助后续阶段。常见的格言是10%的代码实现了90%的功能，这提示了一种方法。种子人工智能增加了学习概念与程序员设计概念之间的区别。如果是这样，第一阶段可能是一个具有简化模态、预编程简单概念、低级目标定义，甚至可能由程序员辅助开发连贯思维所需的意识流反射的人工智能。这样的人工智能有望能够以简单的方式操纵代码，从而使概念的源代码（实际上是它自己的源代码）受到灵活且有用的突变的影响，这些突变是学习丰富概念或进化出更优化代码所必需的。骨架人工智能帮助我们填充骨架上的血肉。

...
..
.

你都明白了吗？

很好。

深呼吸。

我们准备开始了。

1：范式

- 1.1: Seed AI
 - 1.1.1: 人工智能的优势
 - 1.2: 思考人工智能
-

1.1：种子人工智能

在每一个领域都立即拥有人类同等能力的人工智能或许是不可能写出来的；超越人类的能力更是如此，因为不存在可参照的工作模型。任务不是构建一个具有某种天文数字般智能水平的人工智能；任务是构建一个能够自我改进、能够理解并重写自身源代码的人工智能。任务不是建造一棵参天橡树，而是一颗谦卑的种子。

随着人工智能重写自身，它沿着智能的轨迹移动。任务不是在轨迹上的某个特定点构建人工智能，而是确保轨迹是开放式的，达到人类同等水平并超越它。越来越聪明的人工智能会越来越擅长重写自己的代码，使自己变得更加聪明。在编写种子人工智能时，重要的不仅是人工智能现在能做什么，而是它将来能做什么。而且问题不仅是编写好的代码，而是编写种子人工智能能够理解的代码，因为最终目标是让它重写自己的汇编语言。(1)。

如果“递归自我增强”要避免失去动力，代码优化或架构变化必须带来实际智能的增量，即聪明程度的提升，而不仅仅是速度。在其自身源代码上运行优化编译器 (2) 可能会产生一个更快的优化编译器。第二次重复该过程不会取得任何成果，只会产生一组相同的二进制文件，因为运行的算法是相同的——只是更快而已。一个在一年内未能解决问题（或解决得不够理想）的人，可能会从额外的十年思考时间中受益；即便如此，一个人最终也可能会耗尽想法。一个在一百年内未能解决问题的人，如果以某种方式转变为爱因斯坦，可能会在一小时内解决它。更快的非智能算法几乎或完全不能取得成果；更快的智能思维可以产生微小的差异；更好的智能思维则会让问题焕然一新。

如果递归自我增强阶梯上的每一级都涉及足够幅度的飞跃，那么每一级都应开辟出足够多的自我改进新视野，以便达到下一级。否则，种子人工智能（Seed AI）将已优化自身，并耗尽所有已感知的改进机会，却未能产生洞见以发现新的机会类型。在这种情况下，种子人工智能将陷入停滞，此时人类程序员需要介入，推动其跨越瓶颈。最终，人工智能不仅必须跨越将神话般的普通人同爱因斯坦分隔开的鸿沟，还必须跨越将尼安德特人同智人分隔开的鸿沟。当真正理解的飞跃发生时，它将至少开辟出与一位能够访问自身神经源代码的人类研究者同样多的可能性。

对自我增强的一个令人惊讶的常见反对意见是，当智能被定义为“提高智能的能力”时，这是一个循环定义——他们认为，这将导致一个贫瘠且无趣的人工智能。即使这是定义（事实并非如此），且该定义是循环的（它不会是），也可以通过将定义建立在弈棋能力或类似的测试能力上来打破循环。然而，智能并未被定义为提高智能的能力；那只是我们最感兴趣的智能行为形式。智能根本没有被定义。如果你观察人类，智能是大脑中一百多个细胞构筑学上不同的区域，它们共同作用以产生智能。简而言之，智能是模块化的，各个模块所执行的任务在性质上不同于整体智能的性质。如果整体智能能够回过头来将某个模块视为一个孤立过程，它就可以做出明确定义的性能改进——这些改进最终累积为整体智能的提升，而无需面对“使自身更智能”的循环问题。从设计角度看，智能是一个拥有许多、许多子目标的目标。一个追求改进智能这一目标的智能体，所面对的不是“改进智能”这一赤裸裸的事实，而是一个极其丰富且复杂的事实，并饰以较不复杂的子目标。

可以推测，在给定的硬件上所能实现的智能存在一个终极极限，但如果种子人工智能（Seed AI）能够设计出更好的硬件，这一循环便会持续下去。具体而言，如果种子人工智能足够聪明，能够规划出一条从现代技术能力通往纳米技术（Nanotechnology）——即 K. 埃里克·德雷克斯勒（K. Eric Drexler）在《纳米系统》（Nanosystems）中所描述的硬件——的路径，那么这将提供相当于人脑原始能力数千倍乃至数百万倍的计算能力。**(3)**。从人类视角来看，超越这一点的认知与技术轨迹究竟是永远持续，还是在某个终极物理极限处达到顶峰，基本上无关紧要；纳米技术加上数千倍于人脑的能力，应当远远足以实现你最初想要一个超人类（Transhuman）去完成的任何事情。

这种设想常常遭到如下反对：一个孤立的人工智能什么也完成不了；技术进步需要整个文明，需要数千名科学家或数百万人类之间的交流。这实际上低估了问题的难度。要思考一个单一的想法，需要复制的远不止单个人脑由基因编程的功能。毕竟，即使完美复制了一个人的功能，人工智能在最初一年里可能除了咿呀学语什么也不做——人类婴儿就是如此。

感知必须凝聚成概念。概念必须串联成思想。足够多的好思想必须足够频繁地重复，使序列成为缓存（Cached），使经常重复的子模式成为反射。必须积累足够多的这类基础反射，才能使一个思想引发另一个思想，形成连贯的链条，构成意识流。除非我们愿意花数年时间听计算机咿呀学语，否则婴儿期的功能必须要么封装在一个以计算机时间运行的虚拟世界中，要么借助一套预编程的概念和思想的骨架集来绕过。（希望随着种子人工智能练习思考，“骨架思想”将被真实的、习得的思想所取代。）

人类的科学思想依赖于数千年积累的知识，以及数百位天才发现的如何思考的启发式方法（Heuristics）。虽然种子人工智能或许能够通过浏览互联网吸收其中部分知识，但还会有其他一些种子人工智能特有的难题，必须由它自行解决。

最后，人类心智的自主过程反映了数百万年的进化优化。除非我们愿意投入等量的编程努力，否则进化本身的功能必须被替代——要么由种子人工智能对这些算法进行自我调整，要么用种子人工智能的刻意决策来替代人类中自主的过程。

这是一项艰巨的工作，但与之匹配的是同样强大的工具。

1.1.1：人工智能的优势

计算机程序的传统优势——不是“人工智能”，而是“计算机程序”——有三重：能够执行重复性任务而不感到厌倦；能够以比我们 200 赫兹的神经元所允许的更高线性速度执行算法任务；以及能够执行复杂的算法任务而不犯错误（或者更确切地说，不犯那些由于分心或短期记忆耗尽而导致的错误类别）。当然，所有这些都与智能无关。

种子人工智能的工具箱尚属未知；没有人建造过。本页更多是关于构建最初阶段，即让种子人工智能说出“你好，世界！”的任务。但是，如果这能够实现，我们期望一个能够访问自身源代码的通用智能会具有哪些优势？

设计新感官模态的能力。从某种意义上说，任何人类程序员都是盲人画家——更糟的是，一个天生没有视觉皮层的画家。我们的程序是逐像素绘制的，因此对单个错误敏感。我们需要有意识地将每一行代码作为一个抽象对象来跟踪。种子人工智能可以拥有一个“代码皮层”，一种专门用于代码的感官模态，具有专门用于代码的直觉和本能，以及从代码中抽象出更高层次概念并直观地可视化代码中详细描述完整模型的能力。人类程序员确实远离其祖先环境，但人工智能总能如鱼得水。（但请记住：代码模态并不编写代码，正如人类视觉皮层并不设计摩天大楼。）

融合意识思维与自主思维的能力。将“深蓝”与“卡斯帕罗夫”结合，并不会产生一个能有意识地每秒审视十亿步棋的存在；它产生的是一个会思考“我怎么能把后放在这里？”的卡斯帕罗夫，并在百万步棋被自动审视的瞬间眨一下眼。在更高层次的整合中，卡斯帕罗夫对每一步有意识审视的棋局意识感知，可能融合了从百万种可能性中筛选出的数据，而卡斯帕罗夫审视的十几步棋可能并非有意识模拟的走法，而是“跳跃”到五步之后最有可能的十几种未来。(5)。

摆脱人类缺陷，尤其是人类政治。为了赢得争论和获得社会地位而向自己合理化站不住脚的立场，这种倾向对我们来说如此自然；以至于很难记住，合理化是一种复杂的适应性功能，在“一般心智”中没有存在的理由。合成心智没有政治本能 (6)；合成心智可以引领人类文明进程，避免政治强加的死胡同，避免观察者偏差，避免合理化的倾向。我们人类本能地认为进步需要多个心智，是因为我们习惯了人类天才，他们做出一两个突破，但随后就固守自己的伟大想法，反对一切进步，直到下一代鲁莽的年轻科学家出现。一个不会衰老、不会合理化的天才级心智，可以将这个循环封装在单一实体中。

超频——投入比原始人类心智中某个模块更多的原始计算能力，或更高效的计算能力；投入更多脑力来解决问题，从而产生更高质量、更大数量、更快速度，甚至种类不同的智能。深蓝最终通过将大量计算能力投入本质上是一个美化的搜索树中击败了卡斯帕罗夫；想象一下，如果人类智能的基本组成过程也能被类似地超频……

自我观察——捕获模块执行过程并以慢动作回放的能力；观察自身思维并追溯因果链的能力；基于细粒度内省形成关于自我的概念的能力。

有意识学习——即有意构建或有意改进概念与记忆的能力，而非将其托付给自主过程；基于有意分析来调整、优化或调试已学技能的能力。

自我改进——将种子人工智能的心智凝聚在一起的普遍粘合剂；人工智能借此从程序员实现的晶体状骨架功能走向丰富而灵活的思维。在人类心智中，随机概念——由许多小答案平均而成的组合答案——带来了容错性；容错性使概念得以在不崩溃的情况下发生变异；变异带来了进化式增长与丰富的复杂性。人工智能通过使用概率元素，可以达到同样的效果；另一条途径是有意观察与操控，从而产生有意“变异”，其错误率大大降低。这些变异或操控是什么？盲目搜索可以变为启发式引导的搜索，从而变得极为有用；自主过程可以变为有意识的，从而变得极为丰富；一个有意识的过程可以

变为自主的，从而变得极快——在有意识学习与调整自身代码之间没有明确的界限。最后，还有高层次的重新设计，根本不是“变异”，而是需要太多同时发生、不向后兼容的改变，以至于进化永远无法实现的改动。

如果这一切都能实现，就会产生自我封装和递归自我增强。当新生的心智完全理解自身的源代码，完全理解创造自身所依据的智能推理——并且能够独立地发明这种推理，使得心智包含自身的设计——循环就闭合了。心智导致设计，设计导致心智。任何智能的提升，无论是由硬件还是软件引发，都会产生更好的心智；由于设计是由心智生成的（或本可以由心智生成），这种提升会传播并导致更好的设计；而更好的设计又会反过来传播并导致更好的心智。（7）。由于种子人工智能不仅封装了人类个体智能的功能，还封装了进化和社会的功能，这些智能的成因也将得到改进。我们可以称之为“盒中文明”，一个拥有比爱因斯坦（8）更多“硬件”智能的实体，能够将抽象思维编码，以现代计算机的线性速度运行。

一个成功的种子人工智能将拥有力量。一个真正的盒中文明，以百万倍于人类的速度思考，可能将几个世纪的技术进步压缩到短短几个小时。我不会反复强调这一点。我在其他著作中已经详细论述过——尤其是《凝视奇点》。关键在于，超人类人工智能的根本目的与传统人工智能不同。

现代前人类人工智能的学术目的是编写程序，展示人类思维的某些方面——为大脑举起一面镜子。前人类人工智能的商业目的是自动化那些对人类来说过于枯燥、过于快速或过于昂贵的任务。对于学术实现是否真正捕捉了人类智能的某个方面，或者商业应用是否执行了值得被称为“智能”的任务，可能存在争议。

在超人类人工智能中，如果成功并非对除受过训练的哲学家之外的所有人都显而易见，那么这项努力就已经失败了。超人类人工智能的最终目的是创建一个“过渡指南”：一个能够安全开发纳米技术以及任何可能出现的后续超技术、利用超人类友好性来预见未来、并利用这些超技术确保人类安全度过奇点另一侧生活的实体。这可能包括协助全人类升级到超级智能力量的水平，或为太阳系中所有夸克创建一个操作系统，或某种完全不可知的事物。我相信，作为创建友好型超级智能的结果，非自愿死亡、痛苦、胁迫和愚蠢将从人类状况中消除；并且人类，或无论我们变成什么，都将尽最大可能实现任何存在的更伟大命运或更高目标，如果有的话。

回到地球：在通往超级智能的道路上，无疑会有许多里程碑、许多临时子目标和临时成功。关键点在于，虽然体现认知的某些方面可能有用或必要，但它本身并不是目的。将认知的各个方面视为目的本身，导致传统人工智能发展出一种“奖杯心态”，即倾向于根据程序是否符合表面描述来评价程序。（给人的印象是，如果你要求某些人工智能研究人员写下一部伟大的英文小说，他们会写一篇关于烤面包机的 20 页论文，然后冲上街头大喊：“尤里卡！这是英文！这是英文！”）我希望种子人工智能的崇高但实用的目标将导致一种习惯，即审视设计的每一部分并说：“当然，这听起来不错，但它如何实质性地促进通用智能？”毕竟，如果认知的某个方面被忠实地复制，却不理解其整体目的，那么期望它做出任何贡献纯粹是信仰问题。

但这将我们带到下一节，“思考人工智能”。

1.2：思考人工智能

人工智能在过去曾屡遭失败。这些失败所投下的阴影笼罩着所有新的人工智能项目提案。人们总是会问：“为什么你的项目不会像其他所有项目那样失败？之前的项目为什么会失败？你的通用智能理论能否解释过去的失败，同时预测你自己的努力会取得成功？”实际上，任何人都可以解释掉过去的失败并预测成功：你只需断言某个特定的新特性就是那个伟大的理念，是智能的必要且充分条件。真正的问题是，一种新的人工智能方法是否能让以往努力的失败显得极其必然，成为历史因素的可预测结果：该方法是否提供了一种对以往失败的物理解释，这种解释在事后看来令人满意地显而易见，使早期的错误看起来像任何成长中的文明都可能犯的自然错误，从而将历史失败“吞没”在一个不留下任何悬而未决焦虑的新理论中。

好吧。我不会说得那么绝对。不过，人工智能有一种令人尴尬的倾向，即在没有成功的地方预测成功，小题大做，并断言某种带有暗示性名称的 LISP 标记的简单模式完全解释了某种极其高层次的思维过程。为什么？

考虑一下你头脑中代表“灯泡”的符号。在你的头脑中，口语“灯泡”的声音在你的听觉皮层中被重建。一幅灯泡的图像被加载到你的视觉皮层中。此外，听觉和视觉皮层比你的计算机用来播放声音和 MPEG 文件的算法要复杂得多，也智能得多。你的听觉皮层已经进化到专门处理传入的语音，其精细度和分辨率比它在其他听觉任务上表现出的更高。你的视觉皮层并不仅仅包含一个二维像素阵列。视觉皮层有专门的过程来提取大卫·马尔（David Marr）所说的“二维半世界”——边缘检测、角点解释、表面、阴影、运动——以及从这个二维半世界中提取三维世界中三维物体模型的过程。“灵长类动物大约 50% 的大脑皮层专门用于视觉处理，人类的估计区域也几乎相当。”（《MITECS》，“中层视觉”。）

在经典人工智能的语义网络或物理符号系统中，灯泡将由名为 light-bulb 的原子 LISP 令牌表示。

NOTE: I say "LISP tokens", not "LISP symbols", despite convention and accepted usage. Calling the lowest level of the system "symbols" is a

horrifically bad habit.

部分问题可以用历史来解释；回溯到人工智能被发明的 20 世纪 50 年代和 60 年代，研究人员拥有的机器小到现代口袋计算器都会嗤之以鼻。这些早期研究者选择相信他们能够用由小型 LISP 结构组成的“符号”取得成功，这些认知“过程”的复杂度相当于现代类库中的一个子程序。他们错了，但这种信念的需要产生了使人工智能沉沦数十年的方法和范式。

以往的人工智能是在物理学家的范式下进行的。过去几个世纪物理学的发展——至少是戏剧性的、刻板的部分——以发现简单方程来巧妙解释复杂现象为特征。在物理学中，任务是找到一个能解释一切的单一绝妙想法。牛顿采用单一假设（质量相互吸引，力等于质量乘积除以距离的平方），并通过一些微积分证明，如果苹果以恒定加速度落向地面，那么这就解释了为什么行星沿椭圆轨道运动。寻找类似的、能印在 T 恤上的统一原理来完全解释拥有数百个细胞构筑学上不同区域的大脑，已经对人工智能造成了严重破坏。

“启发式是编译后的后见之明；它们是判断性规则，如果我们早点拥有它们，就能更快地达到目前的成就水平。”（道格拉斯·莱纳特，1981 年。）从人工智能过去的失败中吸取的启发式可以命名为“必要但不充分”。每当新闻稿中提到神经网络时，简介总是包含“神经网络，它使用与人脑中相同的并行架构”这一短语。当然，神经网络中的“神经元”通常与生物神经元毫无相似之处。但被忽视的主要问题是，说神经网络使用与蚯蚓大脑中相同的并行架构也同样（不太）正确。无论神经网络是否是必要的，它们肯定是不充分的。人脑需要数百万年的进化、数千个模块、数十万种适应，再加上“嘿，让我们构建一个神经网络！”这一简单绝妙的想法。

物理学家的范式很容易满足我们对戏剧性的需求。一个伟大的原理，一个大胆的新想法，推翻了旧宗教的虚假神祇……然后又树立起一批新的虚假神祇。与往常一样，当试图从一个有缺陷的前提推导出期望的结果时，最简单路径涉及相似律和接触律。例如，神经网络中的“神经元”涉及激活的联想链接。因此，人类概念中极其微妙和高层次的联想链接必须由这种低层次属性来解释。同样，任何人类演绎的实例，只要事后能被写成三段论，就必须由十行代码过程的盲目运作来解释——即使人类思维明显涉及对主题的丰富可视化，结果是通过直接检查可视化而非形式演绎推理得出的。

在人工智能领域，那个伟大的简单想法通常按照物理学家的范式在低层次上运作。基于表面属性相似性的推理被用来断言高层次认知现象由低层次现象解释，并声称该低层次现象既是必要的也是充分的。这种认知结构是一个彻头彻尾的谬误：它包含了社会戏剧性（一个辉煌的想法，新对旧）和合理化（基于表面属性相似性的推理，交感巫术），足以承载任何程度的情感重量。这就是人工智能研究出错的方式。

有几种方法可以避免犯这类错误。一种是把“必要但不充分”这几个字纹在额头上。一种是因果分析的直觉，它告诉你“这个原因没有足够的复杂性来解释这个结果”。一种是本能地对在符号层面实现认知的尝试保持警惕。（一种是学习足够的进化心理学，以直接识别和对抗基于意识形态的思维，但这偏离了主题……）

其一是内省。人类内省目前在认知科学中声誉不佳，被视为不可靠、不科学且易被滥用。这完全属实。然而，没有工作模型就无法构建心智。必须直观地认识到，经典人工智能的命题逻辑——三段论、属性继承等——不足以解释你推断将铁砧砸在汽车上会使其损坏的演绎过程。你应该能够内省地看到，其中涉及的内容远不止于此。你可以想象铁砧砸向汽车引擎盖，金属皱缩，挡风玻璃碎裂。**(9)**。清晰可见的是，其中蕴含的心智材料、认知“内容”远比经典人工智能命题逻辑所涉及的要多得多。

对物理学家范式的反叛可以形式化为实用主义定律：

The Law of Pragmatism
Any form of cognition which can be mathematically formalized, or which has a provably correct implementation, is too simple to contribute materially to intelligence.

关键词是“实质性地贡献”。一种架构对于思维可能是必要的，但并未解释思维的实质。实用主义定律指出，如果神经网络的规则简单到可以用数学形式化，那么该网络产生的任何智能答案的实质将归因于特定的权重模式。如果权重模式是由数学上可形式化的学习方法创建的，那么智能的实质将不在于学习方法，而在于训练实例中规律性的复杂模式。

我们无法确定实用主义定律在未来是否仍然成立，但它无疑是勒纳特意义上的启发式方法；如果我们在 20 世纪 50 年代就知道它，就可以避免许多错误。实用主义定律是用于判断一个想法是否“必要但不充分”的工具之一。⁽¹¹⁾。

。GISAI 提出了一种心智，其中包含大致类似于人类感觉模态（听觉皮层、视觉皮层等）的模块。这并不意味着你可以设计任何可以被描述为“包含模块化感觉模态”的旧系统，然后匆忙发布新闻稿，宣称你的公司正在构建包含模块化感觉模态的人工智能。这就是我之前提到的奖杯心态。一个模块化、基于模态的系统是必要但不充分的；还需要在正确的模态中使用正确的模块，采用正确的

表征以及正确的直觉，以处理正确的经验基础，从而产生正确的概念，这些概念在正确的更大架构中支持正确的思想。

当你想到一个灯泡时，“灯泡”的音节和音素被加载到你的听觉皮层中；如果你是一个视觉型的人，一个灯泡的通用图像——默认的示例样本——会出现在你的视觉皮层中。让我们假设某个人工智能拥有相当复杂的听觉皮层和视觉皮层的类似物，能够感知高级特征以及原始二进制数据。这显然是必要的；但这足以像人类一样理解灯泡吗？

不。差得远。当你听到“三角形灯泡”这个短语时，你会想象出一个三角形的灯泡。

NOTE: Please halt, close your eyes, and visualize a triangular light bulb. Please? Pretty please with sugar on top?

这两个符号是如何结合的呢？你知道灯泡是易碎的；你对现实世界的物理有一种内在的理解——有时被称为“朴素”物理学——这使你能够理解易碎性。你明白灯泡和灯丝是由不同的材料制成的；你能够以某种方式将非视觉属性赋予悬挂在你视觉皮层中的三维形状的各个部分。如果你尝试设计一个三角形灯泡，你会设计一个荧光三角形环，或者一个金字塔形的白炽灯泡；无论哪种情况，与“三角形”的默认可视化不同，结果都不会有尖锐的边缘。你知道玻璃上的尖锐边缘会割伤握住它的手。

看看这一切！它需要对灯泡的时间性、四维理解。它需要对因果关系的欣赏，一套直觉。它要求你能够发现问题——与目标的冲突——这需要表示冲突的手段，以及源自目标系统的认知反射。

看看你自己“看着这一切”。它需要内省、反思、自我感知。它需要一整套自我感觉模态的表征、直觉、缓存的反射、期望——专注于进行思考的心智。

阅读本段并加以思考，需要意识流。思考灯泡意味着你将过去对实际灯泡的体验编码为长期记忆所使用的表征。出现在视觉皮层中的灯泡视觉图像，意味着“灯泡”的默认示例样本是从经验中抽象出来的，存储在“灯泡”符号下，并由该符号的听觉标签“灯泡”触发。该示例样本甚至可以与已学习的“三角形”符号相结合。你已形成一个形容词“三角形的”，它由可应用于修改灯泡概念视觉与设计实质的特征组成。想象灯泡破碎并伴随叮当声，需要跨多种感觉模态的回忆与重建同步。

我在前几段中提到了许多特征；它们都不是涌现的。它们不会“只要找到简单的低层方程”就神奇地在高层出现。在人类中，这些特征是复杂的、由数百万年进化产生的功能适应。对于人工智能而言，这意味着你需要坐下来编写代码；改变设计或添加设计元素（直接实现高层案例的专用低层代码通常是坏事），以专门产生所需的结果。

简而言之，作为系统架构，GISAI 中的设计规模远大于以往尝试过的任何设计。其规模足以与《麻省理工学院认知科学百科全书》中 471 篇文章所描述的复杂度系统相媲美。(12)。当然，阅读本文其余部分后你会更好地理解这一点，但届时，我预计种子人工智能将与过去的失败截然不同，以至于无法相互参照。鱼与禽，苹果与橙子，大象与打字机。任何给定的种子人工智能项目仍有可能失败，甚至种子人工智能本身也可能失败——但若如此，失败的原因将有所不同。

2: 心智

- 2.1: World-model
- Interlude: The Consensus and the Veil of Maya
- 2.2: Sensory modalities
- 2.3: Concepts
 - 2.3.1: Modality-level, concept-level, thought-level
 - 2.3.2: Abstraction is information-loss; abstraction is not information-loss
 - 2.3.3: The concept of "three"
 - 2.3.4: Concept combination and application
 - 2.3.5: Thoughts are created by concept structures
- Interlude: Represent, Notice, Understand, Invent
- 2.4: Thoughts
 - 2.4.1: Building the world-model
 - 2.4.2: Creativity and invention
 - 2.4.3: Thoughts about thoughts
 - 2.4.4: The legitimate use of the word "I"

2.1: World-model

智能是一种进化优势，因为它使我们能够建模、预测和操纵现实。这不仅包括乔·穴居人（或者更确切地说，帕特·狩猎采集者）发明弓箭，还包括克里斯·部落首领智胜他的（13）政治对手，以及桑迪·矛制造者意识到她的矛不断折断的原因是她制作时太急躁。也就是说，我们所建模的“现实”不仅包括事物，还包括其他人类和自我。（14）。

推理链之所以重要，是因为它以关于世界如何运作或世界如何被改变的结论告终。就这些目的而言，“世界”包括人工智能的内部世界；在设计自行车时，假设“圆形物体可以在地面上移动而不颠簸”是关于外部世界的陈述。假设“考虑圆形物体是个好主意”，或“关键问题是弄清楚如何与地面接口”，甚至“我感觉想设计一辆自行车”，都是关于内部世界的陈述。

从外部视角来看，认知事件只有在影响外部行为时才重要。同样，从内部视角来看，对世界模型的影响才是关键和实质。这并不是说每一行代码都必须对世界模型做出改变，也不是说世界模型完全由关于现实世界的高层信念组成。构建假设情景——一个“虚拟幻想世界”——的思维序列正在改变一个世界模型，即使它不是世界的模型。“对两幅图片之间存在某种尚未命名的相似性的模糊感觉”是人工智能关于世界的信念内容的一部分。产生这种直觉的代码可能经历多次内部迭代，作用于与世界模型没有明显对应关系的数据结构，然后才产生可理解的输出。

是什么使字节或神经元的模式成为“模型”？又是什么使该模型中的特定陈述为“真”或“假”？（15）。我找到的最佳定义源于对我们智能成因的考察：“智能是一种进化优势，因为它使我们能够建模、预测和操纵现实。”模型之所以有用，是因为它们与外部现实相对应。

我区分了四个层次的绑定：

- A *sensory* binding occurs when there is a mapping between the model's data structures and characteristics of external reality.
- A *predictive* binding occurs when the model can be used to correctly predict future sensory inputs. (This presumes some kind of sensory device targeted on external reality.)
- A *decisive* binding occurs when the model can predict the effects of several possible *actions* on external reality, and choose whichever action gives the best result (according to some goal system). By modeling the future *given* each of several possible actions, it becomes possible to choose between futures - that is, between future sensory inputs. (If the model is sufficiently accurate.)
- A *manipulative* binding occurs when a future can be hypothesized, and a sequence of actions invented which results in that future. Given a desirable future - that is, a high-level property of the model which is defined by the goal system as an end in itself ("supergoal"), or which is a means to an end ("subgoal") - it is possible to invent the actions required to bring the model into correspondence with that future. If the model is correct, taking the specified external actions will actually result in the desired external reality.

定性动作从有限集合中选取。若该集合足够小，使得所有可能动作都能被建模——且确实被建模——那么“决定性绑定”与使用定性动作的操控性绑定之间便不存在根本区别。定量动作具有一个或多个实数（即浮点数）参数。由于这通常会使穷举式“盲目”搜索在理论上或实践上变得不可能——尤其是当拟合必须精确时——必须使用某种有意识的启发式方法，或感官模态的可逆特征，从指定的数值结果推导出所需的数值动作。（注意，给简单的开关型定性动作添加连续时间参数，会使其变为定量动作。）结构动作具有多个元素（定量或定性），可能带有链接或交互（定量或定性）。发出字符串“foobar”便是结构动作的一个例子。要在不进行穷举或不可能搜索的情况下推导出所需的结构动作，需要（A）一条已知的、足够简单且可逆的动作与结果关联规则，或（B）对构成结构的较简单元素进行审慎分析。

这些定义引发了一系列根本性问题——时间、因果性、虚拟性、目标、搜索、发明——但首先，让我们看一个具体例子。想象一个由牛顿台球构成的微观世界——一个由球体（或圆形）组成的世界，每个球体具有位置、半径、质量和速度，在某个无摩擦表面（或在二维真空中运动）上相互作用。（16）。

对于生活在该微观世界的人工智能而言，“世界模型”包含该人工智能对该世界所知晓的一切——台球的位置、速度、半径和质量。更抽象的感知，例如“一组三颗台球”，也属于世界模型的一部分。“台球 A 与台球 B 将发生碰撞”这一预测是世界模型的一部分。如果人工智能想象四颗台球排列成正方形的情形，那么该想象世界拥有其自身的、虚拟的世界模型。如果人工智能相信“想象四颗台球排列成正方形”将有助于解决某个问题，那么该信念属于世界模型。简而言之，世界模型不一定是程序化概念——即具有统一格式和应用程序编程接口（API）的统一数据结构集合。（尽管如果我们能够实现这一点，将会非常方便。）“世界模型”是一个认知概念；它指所有信念的内容，所有心理意象的实质。

回到台球世界，人工智能要拥有该世界的“模型”，需要什么条件？

- 当人工智能的内部数据结构与台球世界的外部属性之间存在协方差时，就发生了感知绑定。例如，表示台球位置的浮点数随台球实际位置的变化而变化。我们还需要要求相同的映射——相同的解释规则——足以在所有其他台球的建模位置与实际位置之间建立绑定。（17）。当模型足够准确，能够预测台球的未来位置时，就发生了预测绑定。假设有一个传感设备向人工智能揭示台球的位置，并且传感设备输出的数据与实际位置之间存在感知绑定（对应关系）。当人工智能能够在预测数据与实际数据之间建立感知绑定（对应关系）时，就发生了预测绑定。
-

● 决定性约束要求人工智能可执行一组有限的动作——例如，在台球每次撞击墙壁时，选择是否减去某个固定的动量增量。（选择该动作是为了不引入任何定量元素。）它需要一个目标状态，如“三个球停在棋盘北侧”。它要求人工智能能够预测动作的结果——基于当前世界模型加上动作事实来预测世界状态。它要求人工智能能够在内部识别某个想象的结果是否满足目标状态的标准。在完美世界中具备这些认知能力（18），对可能动作进行盲目搜索，并结合程序化规则“当想象的情境满足目标标准时，执行导致该情境的动作列表”，将产生决定性约束的“原子”案例。（当然，根据实用主义定律，将设计简化到易于可视化代码的程度，已剥离了所有有用的智能。真实心智要复杂得多。）● 例如，如果人工智能能够控制母球，并知道如何利用该母球“创建两组各三个台球的对称组合”，则会发生操纵性约束。在这个特定例子中，通过一系列定量动作（在特定时间对母球施加力）获得结构性结果（两组各三个球）。

在最后一种情况下，人工智能可能能够将六个台球中的每一个作为独立对象进行操纵，或者每个动作可能同时影响多个球，从而需要更复杂的规划过程。重要的是，“创建两组各三个台球的对称组合”并非偶然发生，也无法通过盲目搜索发现。人工智能要创建台球结构，需要启发式方法——关于规则的知识——不仅将结果与动作联系起来，而且反转过程，将动作与结果联系起来。

假设一个以 4 米/秒向南运动的母球撞上一个以 2 米/秒向南运动的台球，结果是母球和台球都以 3 米/秒向南运动。进一步假设，这些规则包含在人工智能的环境内部模型中，因此如果人工智能可视化一个位于 {8.2, 6}、半径为 1、以 4 米/秒向南运动的母球，以及一个位于 {8.2, 10}、半径为 1、以 2 米/秒向南运动的球，人工智能将可视化一秒后两球在 {8.2, 11} 处相撞，然后两球以 3 米/秒向南运动。从那里到有意识地、陈述性地知道——一般来说，两个以 4 米/秒和 2 米/秒同向运动的球相撞后将以 3 米/秒一起运动，还有很长的路要走。到知道“如果台球 X 撞上台球 Y，那么它们将以它们速度的平均值一起继续运动”甚至更长的路。到反转规则并知道“要让一组两个球以速度 X 一起运动，给定速度为 Y 的台球 A，用速度为 (2X - Y) 的台球 B 撞它”还有更长的路。最后，为了闭环，这最后一条高级规则必须被应用来在世界模型中创建一个特定的假设动作，并且这个假设动作需要被当作外部现实中的真实动作来执行。

在不急于深入探讨的情况下，世界模型需要具备若干特性以支持高层次思维。它需要支持° 时间 - 多帧或时间可视化 - 并伴随提取时间特征。它需要支持预测和期望（并且期望只有在人工智能注意到期望被满足时才是真实的，尤其是当期望被违背时）。世界模型需要支持假设、虚拟可视化帧，这些帧与“真实现实”不同，并且可以被高层思维自由操纵。（所谓“自由操纵”，我指的是直接的操纵性绑定；选择思考一个位于位置 {2, 3} 的台球，应该导致一个台球直接在表示中出现在 {2, 3}，而不需要一系列仔细的动作。）并且，为了使可视化一旦存在就有用，创建台球图像的高层思维必须指向所可视化的特定图像……并且这种指向必须是双向的，一种双向链接。

时间、期望、比较、虚拟语气、可视化、内省和指称。我尚未定义这些术语中的任何一个。（大多数在第三章“认知”中讨论，不过如果你不耐烦，可以跳到附录 A：术语表。）尽管如此，这些是人类世界模型中存在的一些基本属性，对于诸如因果性、意向性、目标、记忆、学习、联想、专注、抽象、范畴化和符号化等高级特征的存在是必要的（但非充分的）。

NOTE: I mention that list of features to illustrate what will probably be one of the major headaches for AI designers: If you design a system and forget to allow for the possibility of expectation, comparison, °subjunctivity, visualization, or whatever, then you'll either have to go back and redesign every single component to open up space for the new possibilities, or start all over from scratch. *Actualities* can always be written in later, but the *potential* has to be there from the beginning, and that means a designer who knows the requirements spec in advance.

插曲：共识与摩耶之幕

在彩虹中，光的物理频率随距离平滑且线性地变化（19）。然而，当你观察彩虹时，你会看到颜色被分成带，边界相对清晰。而且不仅仅是你，每个人都看到这些带。

情况更糟。考虑：光的频率是一个线性的、标量的实数。可见光的频率从红色到蓝色线性上升，以红外线和紫外线为界。但如果你看电脑上的色轮，你会发现它是一个轮子。红色到橙色到黄色到绿色到蓝色到……紫色？……然后又回到红色。紫色从哪里来？它是一种不存在的颜色，似乎是后来添加的，以便将线性光谱变成圆形！

事实证明，紫色和彩虹中的色带都是人类感知颜色空间的方式所产生的工件，这反过来又是我们的视觉皮层在祖先环境中进化以区分物体并在自然光照下保持颜色恒常性的结果。（更多内容，请参阅《适应的心灵》中的“颜色的感知组织”。这绝对是一篇很酷的文章。）

紫色以及彩虹中的色带并非真实存在。但每个人都能看到它们，因此不能简单地称之为幻觉。我倾向于采取一种折中的说法，即紫色和彩虹存在于共识之中。没有人真正生活在外部现实中，即使我们生活在其中，也无法理解它；因为有太多夸克在四处飞舞。当我们穿过大厅，看着地板、墙壁和天花板在我们周围移动时，实际上我们是在穿过自己的视觉皮层。毕竟，那才是我们所看到的东西。我们看不到墙壁反射的光子，当然也看不到墙壁本身；我们感知的每一个细节都是因为视觉系统中某个神经元正在放电。如果错误的神经元放电了，我们就会看到一个并不存在的色点；如果一个神经元未能放电，我们就不会看到一个实际存在的色点。从这个角度来看，

实际的光子几乎无关紧要。此外，由于那个古老的色彩空间问题，你正在穿过的大厅中的所有颜色在技术上都是不正确的。哎呀，你甚至可能走过某个紫色的东西。

这通常是哲学家陷入唯我论深渊的起点。“一切都是任意的！没有什么真实的！一切皆真！我想说什么就说什么，没人能把我怎么样，哇哈哈！”我讨厌这种思路。如果我开始听起来像这样，请检查我的额头是否有脑叶切除手术的疤痕。

共识通常与外部现实有着极其紧密的“感官”、“预测”和“操控”绑定。不，它并非 100% 的时间都有效，但它在 99.99% 的时间里是有效的，因此规则同样严格。仅仅因为你无法直接看到外部现实，并不意味着它不存在。

你所看到的一切都是幻象，是摩耶之幕。东方哲学的错误在于假定摩耶之幕后隐藏着某种宏大而重要的东西。砖块幻象的背后就是实际的砖块。在绝大多数时间里，你甚至可以忘记摩耶之幕的存在。

我们在共识中的存在也不会赋予共识对外部现实的优先权。共识本身只是现实的另一部分。这就是现实约束共识的方式；它只是现实的一部分在物理定律所规定的标准相互作用规则下影响另一部分。外部现实存在于被称为“人类”或“共识”的现实模式之前。那些以“所有真理都是主观的”为由忽视外部现实的人，其组成夸克往往会被我们称为“老虎”的夸克模式所同化。

然而，有时重要的是要记住，老虎只存在于共识之中。假设有人请你给出“老虎”的定义，而你给出了一个在 99.99% 的情况下都成立的定义——“有斑纹的橙色大猫”。然后对方把一只老虎涂成绿色，说：“哈哈！你的定义错了！”在这种情况下，我会基于遗传学、行为模式等给出一个更精确的定义，但接着又会出现半机械老虎和变异老虎。到那时，重要的是要记住，这“只是”共识。你不期望共识中的事物具有完美的数学定义。进化并不选择那些具有哲学上优雅定义的老虎，或感知老虎的心智；进化选择的是大多数时候有效的东西。

那么共识为何有效？因为还原整体论的一个基本规则：忘掉定义。任何“按定义”为真的东西都是同义反复，与外部现实无关——甚至不指涉外部现实。

忘掉定义，如果你发现某种认知感知本质上是主观的或依赖于观察者的——即该感知依赖于仅存在于观察者心智中的性质——那么就放松并接受它在大多数时候对智能有用，不要陷入哲学上的纠结。毕竟它不是真实的，所以何必担心呢？

嘿，这就是共识中的生活。

DEFN: Consensus: The Consensus is the world of shared perceptions that humanity inhabits. Things in the Consensus aren't *really really* real, but they usually correspond tightly to reality - enough to make the rules about what you can and can't say just as strict. What distinguishes the Consensus from actual reality is that there is no *a priori* reason why things should be formalizable, philosophically coherent, or unambiguous.

2.2：感觉模态

人类拥有视觉皮层、听觉皮层、感觉运动皮层——这些是大脑中专门负责特定感觉的区域。每一个这样的“皮层”都由神经模块组成，这些模块从低级数据中提取重要的中级和高级特征，其方式由该领域的“物理定律”决定。视觉皮层及其相关区域（20）是迄今为止大脑中理解得最透彻的部分，因此我们将以此为例。

视觉信息始于光线照射到视网膜；由此产生的信息可以类比为一个二维像素阵列（尽管神经“像素”并非矩形）。“低级”特征提取直接在视网膜中开始，由对边缘、强度变化、光斑、暗斑等作出反应的神经元完成。从这个新的表征——二维像素加上边缘、光斑等特征——外侧膝状体和纹状皮层提取中级特征，如边缘方向、运动、运动特征的方向、纹理、纹理表面的曲率、阴影和双眼感知。这些信息产生了大卫·马尔的二维半世界，它由关于二维特征的三维属性的零散事实组成——这是一个连续表面，这个表面向左弯曲远离，这两个表面相交形成一条边，这三条边相交形成一个角。

最后，从二维半世界构建出运动物体的三维表征。约束传播：如果一个角的三维解释要求一条边是凸的，那么这条边在另一个角中就不能是凹的。物体组装：以相同速度运动的多个表面，或以与旋转一致的方式运动的多个表面，属于同一个物体。一致性：一个物体（或一条边、一个表面）不能同时向两个方向运动。

由此产生的三维表征，仍然与二维半特征和二维像素绑定，被发送到颞叶皮层进行物体识别，并发送到顶叶皮层进行空间可视化。

视觉皮层是七种感官之一的基石。（是的，至少有七种。除了视觉、听觉、味觉、嗅觉和触觉之外，还有本体感觉（告诉我们四肢位置的神经）和前庭感觉（内耳的惯性运动探测器）。（21）。）专门用于处理某一种感官的神经区域占据了人类皮层的很大一部分。在人脑的模块化分区中，最常见的模块类型是感觉模态，或其一部分。这揭示了一个关于心智的基本道理。

经典的人工智能程序，尤其是“专家系统”，通常被划分为微理论。微理论是一个知识体，即一个大型语义网络，例如命题逻辑，也被称为暗示性命名的 LISP 标记。典型的微理论主题是人类专业领域，如“汽车”、“儿童疾病”或“炼油厂”。知识的内容通常由在人类中属于非常高层次的启发式陈述组成：“周六生病的孩子比上学日生病的孩子更可能病情严重。”

经典人工智能中基于微理论的模块与人脑中常见的感觉模块有何不同？“视觉微理论”与“视觉皮层”有何区别？为什么微理论方法失败了？

回顾起来，有两个基本线索本应提醒专家系统理论家（“知识工程师”）某些地方出了问题。首先，微理论试图体现高层次的推理规则——这些启发式规则需要世界模型中大量预先存在的内容。视觉皮层不知道蝴蝶；它知道边缘检测。视觉皮层不包含预先编程的蝴蝶图像；它包含特征提取器，让你能够观察蝴蝶，将其解析为从背景中突出的独立对象，记住该对象与背景分离，并从记忆中重建该对象的图像。我们并非天生具有蝴蝶的经验；我们天生具有视觉皮层，它赋予我们体验和记忆蝴蝶的能力。视觉皮层不是视觉知识；它是视觉知识存在的空间。

第二个更深层次的问题源于第一个问题。专家系统的所有微理论都具有相同的底层数据结构（在此为命题逻辑），并由相同的底层程序（在此为几条贝叶斯推理规则）操作。如果它们都使用相同的数据结构和相同的函数，为什么还要将某些内容分离成不同的模块？一个真正的程序难道不应该拥有不止一个真正的模块吗？

我并不是建议为了神奇地让程序运行得更好而增加数据格式和模块的数量。任何有能力的程序员都知道，在一种数据格式就足够的情况下，不要使用两种数据格式。但是，如果数据和过程不够复杂，不足以迫使程序员采用模块化架构，那么这个程序就太简单了，无法产生真正的智能。

此外，单模块架构肯定不是大脑的工作方式。也许存在某种巧妙的方法，可以使用单一的底层数据结构来表示听觉和视觉信息。如果我们能够做到这一点，那很好。但是，如果解决领域特定表示之间有效交互这一深层问题不需要天才之举，如果问题因为所有思维内容都采用命题逻辑的形式而“解决”了，如果所有行为都能轻松地放入一个单一的程序模块中——那么这个程序就没有足够的复杂性来成为一个像样的视频游戏，更不用说人工智能了。（22）。

我们不应该对经典人工智能研究人员过于苛刻。构建一个基于“纯逻辑”运行的人工智能——没有感觉模态，没有视觉皮层的等价物——是值得尝试的。正如埃德·里吉斯所说，这具有某种傲慢的吸引力。为什么人类思维使用视觉皮层？因为它就在那里！毕竟，如果你已经进化出了视觉皮层，进一步的适应自然会利用它。这并不意味着从头开始工作的工程师必须受限于人类的工作方式。

但这并未奏效。GISAI 提出的智能配方假设人工智能拥有与视觉皮层、听觉皮层等相当的结构。并不一定是这些特定的皮层；毕竟，海伦·凯勒（又盲又聋，用手语交流）学会了智能思考。但即使是海伦·凯勒也有本体感觉，因此拥有用于空间定向的顶叶；她有触觉，可以用触觉来“聆听”手语；她能够利用她所拥有的感觉模态来感知符号，在内部形成符号，并将这些符号串联成句子，进行思考。(23) 某种类型的“皮层”的某种等价物对于 GISAI 设计是必要的。

“皮层”是一个专门的神经学术语，指大脑的表面区域，因此我将使用“感觉模态”或“模态”一词来代替皮层。

DEFN: **Modality:** Modalities in an AI are analogous to human cortices - visual cortex, auditory cortex, *et cetera* - enabling the AI to visualize processes in the target domain. Modalities capture, not high-level *knowledge*, but low-level *behaviors*. A modality has data structures suited to representing the target domain, and °codelets or processing stages which extract higher-level features from raw data.

为什么人工智能需要视觉模态？因为人类视觉皮层及相关的神经解剖结构——我们的视觉模态——使我们关于二维和三维物体的思维变得真实。德鲁·麦克德莫特在《人工智能遇上自然愚蠢》中指出，仅仅因为一个 LISP 令牌被标记为字符串“汉堡包”，并不意味着程序理解汉堡包。程序甚至没有注意到汉堡包。如果符号被称为 G0025 而不是汉堡包，没有人能弄清楚这个令牌本应代表一个汉堡包。

当两个物体碰撞时，我们不仅仅有命题逻辑中的一点内容，比如 collide(car, truck)；我们会想象两个移动的物体。我们建立二维像素和三维特征的模型，并可视化物体碰撞在一起的过程。边缘接触，不是以 触碰（汽车边缘，卡车边缘）的形式，而是两条曲线在边缘上的所有单个点处相遇并变形。你可以成功地观察人脑，并推断出相关神经元正在对边缘和碰撞物体进行建模；事实上，这正是视觉神经解剖学家所做的工作。但如果你对经典人工智能做同样的事情，如果你从命题逻辑中剥离掉方便的英文变量名，你剩下的将是 G0025(Q0423, U0111) 和 H0096(D0103(Q0423), D0103(U0111))。无论进行多少推理，都无法将这些晦涩的数字与现实世界中的汽车或卡车联系起来。

此外，我们的视觉皮层不仅仅用于视觉。《肉身中的哲学》（乔治·莱考夫与马克·约翰逊著）讨论了源-路径-目标模式（24）——一个移动的动体、一个起点、一个目标、一条路线；动体在给定时刻的位置、该时刻的方向、实际最终目的地……《肉身中的哲学》还谈到了“内部空间‘逻辑’与内置推理”：如果你沿一条路线行进，你曾到过路线上的所有位置；如果你从 A 到 B，再从 B 到 C，那么你已经从 A 到了 C；如果 X 和 Y 沿从 A 到 B 的直接路线行进，且 X 超过了 Y，那么 X 比 Y 离 A 更远、离 B 更近。

这些都是空间现实的行为。经典人工智能会试图捕捉这些行为的描述；即“如果旅行 (X, A, B) 且旅行 (X, B, C)，那么旅行 (X, A, C)”。问题在于，构成模型的低层元素（像素、动体、速度）可以产生近乎无限

数量的高层行为，而在经典人工智能方法下，所有这些行为都必须被独立描述。如果 A 包含在 B 中，它就无法出来——除非 B 有一个洞。除非 A 比洞大。除非 A 能侧身或洞是柔性的。试图描述高层特征所表现出的所有可能行为，而不直接模拟底层现实，就像试图设计一个 CPU，用双索引查找表乘以两个 32 位数，该表有 2^{64} （约 180 万亿）个条目。

真正的 CPU 利用了 32 位数由比特组成这一事实。这使得晶体管能够使用婚礼蛋糕法（或现代 CPU 设计所用的任何方法）进行乘法运算。32 位数不是一个整体对象。32 个二进制数字的数值解释不是内在的，而是一种高层特征、一种观察、一种抽象。各个比特相互作用，产生一个 32 位（或 64 位）的结果，然后可以将其解释为结果数。计算机能将 9825 乘以 767 得到 7535775，不是因为有人告诉它 9825 乘以 767 等于 7535775，而是因为有人告诉了它如何将各个比特相乘。

视觉模式赋予观察、预测、决策和操控沿轨迹运动物体的能力，并非因为该模式捕获了高层特征的知识，而是因为该模式包含的元素与外部现实的行为方式相同。具备视觉模式的人工智能有潜力理解“更接近”这一概念，并非因为它拥有关于更接近（A，B）的大量命题逻辑，而是因为 A 和 B 的模型由实际正在变得更接近的实际像素组成。（25）。

源-路径-目标不仅仅是一种视觉模式。它是一种几乎适用于任何努力的隐喻。力和阻力不仅仅是人们推车，而是公司推动产品。源-路径-目标不仅适用于步行到曼哈顿，也适用于程序员努力编写符合需求规格的应用程序。它适用于这些文字本身的进展，在我输入时在屏幕上移动，缩短了到可发布网页目标的距离。此外，视觉隐喻在许多情况下是一种有用的隐喻，一种具有预测约束力的隐喻。（26）。当隐喻不仅涉及高层特征的相似性，还涉及低层元素的相似性或单一根本原因时，它才是有用的。（参见前一脚注。）将编程任务的行为映射到源-路径-目标模式（沿视觉线移动的视觉对象）的视觉隐喻是有用的，如果某种“任务完成”的度量可以映射到轨迹体的定量位置，并且感知到的速度被用来（正确地！）预测任务剩余的时间量。

当然，必须认识到，拥有视觉模式是执行那种特技的必要条件，但并非充分条件。在这种情况下，注意到类比是创造力的百分之九十。这种注意的原子情况将包括随机生成模型，要么通过生成随机数据集，要么通过随机混合先前获得的模型，直到注意到模型与现实之间的某种协方差、某种相似性。然后人工智能说“尤里卡！”

当然，除了非常简单的隐喻之外，搜索空间太大，盲目的构造永远无法与现实相匹配。更常见的情况是，需要刻意构建一个模型——在这种情况下，是一个视觉模型——其行为与现实相对应。关于这种更高层次推理的讨论不属于“感觉模式”部分，但能够“刻意构建”任何东西都需要一种操纵视觉模型的方法。除了采取“在纸上画一个正方形”这一外部动作所需的硬件/代码之外，心智还需要采取“想象一个正方形”这一内部动作所需的硬件/代码。就感觉模式的编程方式而言，其结果是特征提取需要是可逆的。当然，并非所有特征在所有时候都是如此，但为了使可视化的认知行为成为可能，必须存在一种机制，使得检测“线”特征的感知具有一个逆函数，该逆函数构造一条线，或将其他东西转化为一条线。

特征重建比特征提取更难编程，计算量也更大。这就是将“7”和“17”的低级元素相乘，与重建两个可能产生高级特征“119”的低级元素之间的区别。这可能就是为什么丘脑皮层感觉通路总是由同等或更大尺寸的皮层丘脑投射来回报的原因之一；例如，一只猫有 10^6 条神经纤维从外侧膝状体通向视觉皮层，但有 10^7 条纤维沿相反方向行走。（27）。

即使一个完整的感官模式，能够进行感知和可视化，如果没有人工智能的其余部分，也是无用的。“必要，但不充分”，这句话如是说。一个模式提供了概念所由构成的部分原材料——可视化存在的空间，但仅此而已。但是，假设人工智能的其余部分已经正确完成，视觉模式将创造理解“更接近”概念的潜力；利用“更接近”的概念以及从考察“更接近”概念实例中得出的启发式方法，作为其他任务的有用视觉隐喻；并利用在视觉模式中存在的刻意构建的模型，来为关于通过程和交互的思考奠定基础。（换句话说，当考虑国际象棋中的“分叉”或代码中的“如果”语句时，可以将其可视化具有 Y 形轨迹的对象。）

一个完整的视觉模式——像素、边缘检测器、表面纹理解码器等等——真的有必要进行空间推理吗？一个由牛顿台球组成的、具有速度和碰撞检测的世界，是否也能胜任？它显然足以表示诸如“分叉”、“如果语句”、“源-路径-目标”、“更接近”等概念，并为大多数由离散对象组成的通用系统创造隐喻。台球世界的表征能力显著较低；如果你无法在空间中可视化曲线，就更难理解时空中的“弯曲轨迹”。（28）。但是，考虑到编写视觉模式的纯粹程序性困难，由像素组成的台球隐喻是否真的优于直接作为低级元素实现的台球隐喻？

嗯，是的。在视觉模式中，你可以从圆形台球切换到方形台球，可视化它们在接触时的变形，并以其他方式“跳出框框思考”。在这种情况下，跳出框框思考的潜力之所以存在，是因为被建模的系统具有由高级视觉对象表示的元素；这些高级视觉对象又由中级视觉特征组成，而中级视觉特征又由低级视觉元素组成。这为创造力提供了回旋余地。

考虑一个著名的谜题：九个点排列成正方形，要求在不抬起笔的情况下画四条直线连接这些点。（29）。要解开这个谜题，必须“跳出框框思考”——也就是说，画出的线要延伸到正方形的边界之外。为解决这个问题而编写的传统计算机程序，很可能将“框”作为代码中内置的假设，这就是计算机被认为缺乏创造力的原因。（30）。即使假设台球隐喻能够表示线条，也可能遇到同样的问题。

我猜想，许多解开九点问题的人之所以获得洞见，是因为尝试过的线条的某种特定排列暗示了一个不完整的三角形，其角落在框外。“看到”一个“不完整的三角形”是一种视错觉，也就是说，这是高层特征被触发并暗示中层特征的结果——在这个例子中，是一些额外的线条，恰好是问题的解。当然，你可以编造出在台球模态中发生这种情况的方式，但那样台球模态就开始看起来像视觉皮层了。关键在于，对于我们人类特有的创造力风格，拥有一个具有丰富“无关”感知的模态是必要的（但不充分），并且通过心理操纵低层元素，可以使隐喻中的高层对象做出非常规的事情。（即便如此，从开发的角度来看，从台球模态开始并逐步发展到视觉是合理的。）

给种子人工智能赋予感官模态还有两个最终原因：第一，拥有编码模态可能会提高人工智能对源代码的理解，至少在人工智能足够聪明、能够自行决定慢速意识思维和快速自主思维之间的平衡之前是这样。第二，正如后面将要讨论的，思想并非一开始就是抽象的；它们通过攀登思想的层叠蛋糕，达到我们所谓的“抽象”层次。这个层叠蛋糕始于模态所描述的非抽象的、自主的直觉和对世界的感知。模态提供的具体世界使人工智能能够逐步学会处理抽象问题。

NOTE: One of the greatest advantages of seed AI - second only to recursive self-improvement - is going beyond the human sensory modalities. It's possible to create a sensory modality for source code. The converse is also true: Various processes that are autonomic in humans - memory storage, symbol formation - can become sensory modalities subject to deliberate manipulation.

In programmatic terms, *any program module with a coherent set of data structures and an API*, which could benefit from higher-level thinking, is a candidate for transformation into a modality with world-model-capable representations, feature extraction, reversible features to allow mental actions, and the other design characteristics required to support concept formation.

2.3：概念

2.3.1：模态层、概念层、思想层

人类大脑中的模态大多是预先编程的，而非后天习得。（人类模态需要外部刺激才能成长为预先编程的组织，但这与学习不同。）单个神经信号可以具有对窃听器可见且可理解的含义。程序员可以合理地承担通过刻意编程创建模态的风险，使用与数据结构相对应的低级元素，以及人工编写的特征提取过程。

在 GISAI 中，术语“概念”用于指代作为模态中的模式存在的那种心理内容。一个学习到的指令序列，在视觉模态中重建一个通用的、抽象的“灯泡”，就是一个概念。符号、类别和某些记忆都是概念。（尽管通常用法如此，“概念”在技术上可能指非陈述性心理内容，例如人类认知反射或人类运动技能。然而，在种子人工智能中，一切都可以内省，将人类反射或技能的等价物称为“概念”是有意义的。）概念是模式，无论是习得的还是预先编程的，存在于长期存储中并且可以被检索。

概念的结构创造了思想。在人类中，典型的例子是词语组合成句子。思想是可视化的；它们在心灵的随机存取存储器中运作，即由感觉模态中可用内容容量表示的“工作空间”，通常称为“短期记忆”或“工作记忆”。（人工智能中工作记忆的容量不是由可用随机存取存储器决定的，而是由可用于对记忆内容执行特征提取的可用中央处理器容量决定的。如果你有数据结构而没有特征提取，人工智能就不会注意到这些信息。）思想操纵世界模型。

至少在人类中，很难在思想和概念之间划出清晰的界限。（31）。听到单个概念的词语（例如“三角形”）的体验不一定仅仅是一个概念；将其视为由单个概念“三角形”组成的思想可能更为有效。而且，尽管某些概念是通过直接从感官知觉中分类形成的，但更抽象的概念（例如“三”）可能首先作为刻意思想出现。我们将在本节中讨论这两种类型。

2.3.2：抽象是信息丢失；抽象不是信息丢失

在化学中，抽象意味着移除；从分子中“抽象”出一个原子意味着将其取走。使用“抽象”一词来描述概念形成的过程暗示了两个假设：第一，创造概念就是进行概括；第二，概括就是丢失信息。这意味着，要形成“红色”的概念，就必须忽略形状和大小等其他高级特征，只关注颜色。

这是经典人工智能对抽象的看法，因此我们应对其持怀疑态度。另一方面，我们的抽象机制可以学习“红色”的概念。在一个具有视觉模态的存在中，这个概念将由一块心智物质组成，该心智物质已学会区分红色物体和非红色物体。由于红色是作为低级特征被直接检测到的，因此训练一块心智物质来进行这种区分应该不会太难——无论这块心智物质是由可训练的神经元、进化代码还是其他什么构成。神经网络需要学会在“红色”特征出现时激活，否则不激活；一段代码只需要进化出检测红色特征是否存在的功能。至多，“红色”可能还需要检测纯色或同色相分组。在具备视觉模态的情况下，“红色”的概念非常接近表面。

当然，要拥有真正的“红色”概念，仅仅区分红色和非红色是不够的。这个概念必须是可应用的；你必须能够将其应用于可视化，例如“红色的狗”。你还需要一个“红色”的默认示例样本（32）；一个“红色”的极端示例样本；以及对典型红色经历的记忆，例如红绿灯和血液。（据我们所知，缺少其中任何一个都可能足以完全破坏认知流程。）同样，这些特征都接近视觉模态的表面。“红色”将是最容易实现可逆的特征之一，只需很少的额外计算成本；只需将所有颜色的色相设置为红色值。（不过希望这样做能够保留所有检测到的边缘、对比度等。将所有东西都变成完全相同的颜色会破坏非颜色特征。）红色的默认示例样本可以是一个红色斑点或一盏红灯；红色的极端示例样本可能与默认示例样本相同，也可能是一个更

深红色的斑点。而典型的红色物体，如交通信号灯和血液，正是那些红色在其中至关重要且被频繁提及的物体。

(33).

然而，目前让我们专注于范畴形成的问题。传统观点认为，范畴化由泛化构成，而泛化则在于聚焦于特定特征而牺牲其他特征。

我们以字母串这一微域为例。要从实例{"aaa", "bbb", "ccc"}泛化形成范畴“三个相同字母组成的串”，关于具体是哪个字母的信息必须从模型中被抽象掉，或者说丢失掉。实际上，这错误地表述了问题。如果逐字母地丢失该信息，那么"aaa"和"aab"看起来都像"***"。所需的是字母串模态首先提取“相同字母组”的特征，"number=3".和"letter=b",，之后概念可以丢失最后一个特征或聚焦于前两个特征。如果第二个特征“数量”也丢失了，那么结果就是一个更一般的概念，“相同字母组成的串”。当然，这个概念与模态内置的“相同字母组”特征检测器完全相同，这再次表明只有非常简单的概念范畴，即非常接近模态预先设定的关于哪些特征重要的假设表面的范畴，才能通过直接的信息丢失来实现。

为了考察一个更复杂的概念，我们来看“三”这个例子。

2.3.3: “三”的概念

对于受过算术和数学训练的二十一世纪人类来说，“三”的概念具有极大的丰富性。因此必须强调，我们处理的仅仅是“三”的概念，而且一个心智可以理解“三”而不理解“二”、“四”、“数”、“加法”或“乘法”。一个心智可能拥有“三”的概念和“二”的概念，却没有注意到它们之间的任何相似性，更不用说产生那种顿悟：这些概念应该归入“数”这一标题之下。如果一个心智设法获得了三只狗组成的组和三只猫组成的组这些范畴，并不能推出该心智会泛化到“三”这一范畴。

要思考婴儿级或儿童级的人工智能，或者就此而言，教导人类儿童，就必须放慢速度，忘掉那些看似“自然”的事物。必须刻意地在概念之间做出区分——这些概念对人类来说似乎紧密相连，以至于需要刻意努力才能看清它们之间的距离。

人工智能存在于每秒执行数十亿次算术运算的机器上，并不意味着人工智能本身必须理解算术或“三”。（约翰·塞尔，请注意！）即使人工智能拥有一个直接访问数值运算的附加模态，它也不一定理解“三”。如果每个模态都被编程了特征提取器，用来计算每个分组中对象的数量，并将结果输出为（比如）标签“数量：三”，那么人工智能可能仍然无法真正理解“三”，因为这样的人工智能将无法计算那些没有直接在某些模态中表示的对象。一个学习“三”概念的人工智能更有可能不仅注意到三个苹果，而且注意到“vc（该人工智能）当前正在思考三个想法。一个预编程的概念只会注意到程序员在编写程序时所思考的内容。

那么，“三”是什么呢？一个模态不直接涉及数字的人工智能——事实上，其模态是由当时并未思考数字的程序员设计的——如何学习“三”的概念？这样一个简单的概念如何能被分解成更简单的东西？

有一个名为“Copycat”的人工智能，由梅拉妮·米切尔编写，道格拉斯·R·霍夫施塔特构思，它试图解决字母串微域中的类比问题。如果你告诉 Copycat：“‘abc’变成‘abd’；那么‘bcd’变成什么？”，它会回答“bce”。它也能处理更难的问题。（参见术语表中的“Copycat”。）Copycat 是一个真正迷人的人工智能，你可以在《元魔法主题》中读到它，或者阅读源代码（这是一本很好的读物，可以在线以纯文本形式获取——无需解压）。如果你确实查看了源代码，或者甚至只是浏览文件名列表，你就会看到一些非常基本的认知实体的名称。有“键”、“组”和“对应”。有“描述符”（以及“区分描述符”）和“映射”，以及各种有趣的东西。

在不深入探讨模仿者（Copycat）细节的前提下，我认为模仿者中的某些心理对象足够原始，非常接近认知的基础。模仿者直接测量数字（尽管它最多只能数到五），但这并非我们关注的特征。模仿者旨在理解关系并创造类比。它能注意到两个字母在字母串中占据“相同位置”，也能注意到两个字母在更高阶心理结构中占据“相同角色”。它能注意到“abc”中的“c”、“abd”中的“d”以及“bcd”中的“d”都占据相同位置。如果面对一个迫使它这样做的类比问题，它能理解“相同角色”的概念。例如：如果“abc”对应“abd”，那么“pqrs”对应什么？模仿者发现“c”和“s”占据相同角色，尽管它们在字符串中不再占据相同的数值位置，因此回答“pqrt”。

对应关系、角色和映射很可能是模态层面自动检测到的特征（同时也是认知科学中非常高级的概念）。直觉的、直接感知到的对应关系允许同一模态中的两个图像进行比较，这是模态运作的基本组成部分。


这些直觉遵循某些潜在的认知压力（同样由模仿者项目建模）：如果两个高层结构相等，那么低层结构应该相互映射。对称性——非常宽泛地定义——是指每个低层映射都应该相同的想法。如果一个被反射，它们都应该被反射，依此类推。完整性：你不应该将五个元素相互映射，却让第六个元素悬空。

模仿者展示了一个如何利用冲突检测器、相等检测器以及一个称为“计算温度”的特征来实现这类认知直觉的示例。粗略地说，冲突会升高温度，而良好的结构会降低温度。温度越高，认知感知越容易破裂——群体、联结和映射越容易瓦解。较低的温度表明

更好的答案，因此答案更具持久性——认知工作区中感知到的答案片段更难被打破。Copycat 的直觉可能不具备人类有意识地解决“对称性问题”或“完整性问题”时所具有的灵活性或洞见，但它们 *do* 可以说与人类对类比问题的无意识直觉相匹配。每个低层内置认知能力都有其作为高层基于思维的技能的对等物，将两者所遵循的标准混为一谈是危险的。

我们现在回到“三”的概念。暂时假设我们在牛顿台球模式下运作，并且希望人工智能学会识别三个台球。

为“三”学习的第一个概念可能看起来像这样：



左侧的心智图像是一个“示例样本”（或“原型”），附着于三的概念并存储于记忆中。右侧的心智图像是目标，包含实际被计数的对象。当三的示例样本中的每个对象与目标图像中的每个对象之间能够建立对应关系时，“三”的概念即得到满足。如果目标图像包含两个对象，则会在三的示例样本图像中检测到一个悬空对象，概念将不被满足。如果目标图像包含四个对象，则会在目标图像中检测到一个悬空对象。（34）。

当然，这并不是对“三的问题”的完整回答。完整的回答还需考虑以下问题：如何以非脆弱的方式在计算上实现“唯一对应”；如何将每个对象与背景区分开来；如何将三的概念应用于先前包含两个或四个对象的心智图像，以产生包含三个对象的新心智图像；如何从记忆中检索示例样本；如何将“唯一对应”的直觉扩展到不同模态。以及实现这些指令所需的非脆弱方式的心智材料类型；以及示例样本和概念最初是如何被创建或学习的。

事实上，“三”的问题如此复杂，以至于很可能首先由有意识的思维解决，之后再编译为概念。这又增加了弄清思维如何开始的问题：何种任务会迫使心智注意到“三”，并演化出上述定义；以及该技能如何编译为模式。此外，从“三个台球”的概念泛化到“三组三个台球”的概念，意味着要问何种问题会迫使这种泛化。这意味着要问泛化如何在基于思维的技能或基于心智质料的概念内部发生；泛化的需求如何转化为认知压力，该压力如何作用于心智质料代码的某一部分，以及该部分如何在压力下正确转变。然后还有关于迈向成人对“三”的理解的问题，例如注意到哪个特定的台球 A 对应哪个特定的台球 B 并不重要。

然而，上述图表确实在解决该问题上迈出了重大一步。它是对“三”的功能分解，调用了更基本的力量，如唯一对应和示例样本检索。这是一个即使程序员从未听说过数字，或当时未考虑数字的人工智能也能学习的概念。这是一个能以有用方式变异的概念。通过放宽示例样本中无悬空对象的要求，我们得到“小于或等于三”。通过放宽目标图像中无悬空对象的要求，我们得到“大于或等于三”。通过要求目标图像中存在悬空对象，我们得到“多于三”。通过比较两幅图像而非示例样本与图像，我们得到“数量相同”（35），并由此得到“小于”或“小于或等于”。

事实上，审视其中一些突变，可以揭示通往“三”这一概念的现实路径。一般规律是，概念只有在有用时才会被发明。我们世界中的许多物理任务需要等量的某种事物；例如，四个桩对应四个孔。感知特定数量的“孔”并预先选择正确数量的桩，这一任务可能迫使人工智能发展出对应集合的概念，即包含相同数量对象的集合。两个桩不能放入同一个孔，一个桩也不能放入两个孔，这一空间事实将成为一种力量，促使形成唯一（一一）对应的感知。“对应集合”可能是最先形成的概念。此后，如果这样做有用，就会倾向于在有用时将集合分类为对应集合的类别；再之后，就会选择一个三的示例样本，并形成三的概念。

上述图形中对三的分解并不是三这一概念最高效的形式。它只是最容易演化出来的形式。在三的示例样本与比较概念形成之后，会出现一种更高效的程序：计数。

要演化出计数概念，需要发展计数技能，这发生在思维层面，而思维又需要三这一概念在概念层面有更精细的描绘。这要求一和二的概念也已发展出来，并且一、二、三已被推广为数的概念。一旦发生这种情况，并且人工智能已经与数字打交道一段时间，它可能会注意到任何包含三个对象的组都包含一个包含两个对象的组。它可能会设法形成“多一个”的概念，这一洞见很可能是在观察组的数量随着额外对象的添加而变化时被触发的。它甚至可能注意到，每次添加一个对象的物理过程总是产生相同的数值描述序列：“一、二、三、四……”

如果对这种物理过程的多次经验能够被推广，并且选择一个该过程的示例经验并加以应用，结果可能是一种类似于教给人类儿童的计数程序：将一个对象标记为已计数并说出“一”；将另一个对象标记为已计数并说出“二”；将另一个对象标记为已计数并说出在已学会的听觉吟唱序列中“二”之后的那个词；依此类推。不要

重新计数任何已被标记为“已计数”的对象。最后说出的单词就是该组的数量。这种方法比检查唯一一对对应关系更高效，而且这种方法也反映了对数字更深层次的理解。

最后，一旦“三”被使用足够长的时间，人类大脑很可能会演化出某种直接看见“三性”的神经基础。也就是说，人类视觉模态的某个部分——可能是颞叶中的物体识别系统，但这只是一个大胆的猜测——学会对三个一组的物体做出反应。（更大的数字如“五”或“六”更难直接识别——也就是说，不通过计数——除非这些物体排列成固定的五点模式和六点模式，就像骰子面上的点数那样。）对于人工智能来说，类似物可能是一段直接计算物品的代码（或汇编语言，或神经网络——你知道，思维材料）。

然而，即使人工智能最终创建了一种高度优化的、直接实现的计数方法，该概念的先前定义仍然存在。当遇到新情况时，即迫使概念扩展的新情况，思维可以从优化方法切换到反映根本原因和底层基础的方法。如有必要，问题可以一直上升到意识知觉的层面，从而使用深思熟虑的、思维层面的方法——即概念最初产生的那些思想。构成原始定义基础的经验、注意到定义的经验、使用定义的经验——所有这些都可以被回顾。这就是为什么一个概念如果被学习而不是被预编程，就会丰富得多、强大得多。这就是为什么学到的、丰富的概念更加灵活，更有可能变异、进化并衍生出有趣的特化、泛化和变体。这就是为什么当思维遇到特殊情况并不得不诉诸高级推理时，学到的概念更加有用。这就是为什么高级认知对象比经典人工智能中扁平、赤裸的“谓词演算”强大得多、真实得多。

因此，“信息丢失”或“聚焦”这一概念被置于不同的视角之下。诚然，将某物称为三元素组，或将其归入三类别，可以说“丢失”了大量信息——从信息论的角度来看，你已经从指定独特且个别的对象，转变为指定可被“三”所描述的那类事物中的一员。在经典人工智能术语中，你决定聚焦于名为“数量”的特征，而非该对象的其他任何特征。然而，将丰富、复杂、多步骤的感知行为标记为“信息丢失”，近乎于一种曲解。看到一组事物的“三性”并不会破坏信息，反而会增加信息。人们既感知到先前已知的关于该对象的一切，也感知到其三性；而且，在学会感知三性的方法之前，这种三性也无法被“聚焦”。

2.3.4：概念组合与应用

“当你听到‘三角形灯泡’这个短语时，你会想象出一个三角形的灯泡……这两个符号是如何组合的？你知道灯泡是易碎的；你对现实世界的物理有一种内在的理解——有时被称为‘朴素’物理——这使你能够理解易碎性。你明白灯泡和灯丝是由不同材料制成的；你能够以某种方式将非视觉属性赋予悬挂在你视觉皮层中的三维形状的各个部分。如果你尝试设计一个三角形灯泡，你会设计一个荧光三角形环，或者一个金字塔形的白炽灯泡；无论哪种情况，与‘三角形’的默认可视化不同，结果都不会有尖锐的边缘。你知道玻璃上的尖锐边缘会割伤握持它的手。”——1.2：关于人工智能的思考“三角形”和“灯泡”这两个概念是如何组合的？我目前的假设涉及一种可能被称为“还原论能量最小化”或“整体网络松弛”的冲突解决方法，这种方法从化学的“势能面”和 Copycat 的“计算温度”中汲取线索。

神经网络在受到扰动时，会趋向于寻找所谓的“最小能量状态”。概念组合的网络松弛模型在计算上可能是现实的——这是神经元在每秒 200 次操作的时间尺度内能够完成的操作。我目前对概念组合中基本神经操作的假设是共振。一个神经共振回路——也许不是物理的突触回路，而是一个虚拟的消息传递回路，由某种更高层次的神经通信方法（可能是通过神经同步进行绑定）建立——可以正向共振，强化概念组合的那一部分，或者负向共振，产生冲突。我对网络松弛方法的猜测类似于化学中的“势能面”，因为多个叠加的备选方案被同时尝试，因此寻找最小值的过程更像流动的液体，而不是滚动的球。

被组合概念的高层次、显著方面首先被组合。这些高层次特征随后可视化中层特征；如果没有检测到冲突，中层特征再可视化低层特征。如果在任何层次检测到冲突，冲突会传播回导致问题的冲突性高层次或中层特征。谁在冲突中胜出？更显著、更重要或更有用的特征——记住，我们讨论的是组合两个概念，每个概念在多个维度上都有自己的一组特征——被选为主导，然后网络松弛算法继续进行。当一个概念修饰另一个概念时，“更显著”的特征是由进行修饰的概念所指定的。（还要注意，在随意阅读中，并非概念的所有方面都重要，就像你不会完全可视化句子中的每个词一样。只有与讨论主题、与段落产生共振的方面才会被可视化。）

在“三角形灯泡”的例子中，“三角形”是一个形容词。“三角形”或“三角的”概念修饰“灯泡”的概念，而不是相反。“灯泡”的默认示例样本——即通用灯泡的图像——被加载到心理工作区中，包括示例样本的视觉方面被加载到视觉皮层中。接下来，“三角形”的概念被应用于这个心理图像。

“三角形”这一概念，当指涉物理对象时，仅具有单一侧面：它改变目标图像的物理形状。请注意，我说的是“物理形状”，而非“视觉形状”。“灯泡”的默认示例样本是一种心理意象——不是心理图像，而是心理意象；在 GISAI 中，“意象”指任何模态或多种模态下的表征，而不仅限于视觉皮层。“灯泡”示例样本是一个三维灯泡形状物体的意象，由玻璃制成，底部有金属插头，其目的是发光。正是这种多模态心理意象被“三角形”所修改，而不仅仅是意象的视觉成分。特别是，灯泡概念的“形状”侧面，即被修改的侧面，是描述三维物理对象形状的高层特征，而非视觉图像的形状。因此，修改灯泡形状将修改物理形状的心理意象，而不是操纵视觉皮层中的二维视觉形状。

“三角形”概念，当沿“形状”维度应用时，操纵灯泡的心理意象，将三维模型改变为三角形形状。然而，由于扁平灯泡的意象无法引起共鸣，“三角形”自动滑向“金字塔形”。

（我不确定这种冲突是在“扁平灯泡”的中层特征处被检测到，还是在冲突被检测到之前扁平灯泡实际上已经开始可视化。这种滑移发生得太快，我无法确定。我怀疑“三角形”在应用于三维心理意象时，之前就已经滑向“金字塔形”；对于神经实体而言，发生过一次的事情很可能再次发生。神经元会学习，神经思维会在神经元中磨损出通道。可能是灯泡的非扁平性因其球根形状而显著，这种与非扁平性的共鸣导致“三角形”在概念甚至被应用之前就滑向“金字塔形”。）

金字塔是尖锐的。通过内省，我知道“尖锐的金字塔形灯泡”这一概念在冲突被注意到之前，已经一路传递到了视觉层面。（冲突上升到了意识知觉层面，但解决过程或多或少是直觉性的；我不必“停下来思考”。因此，这可能仍然是一个概念层面过程的有效例子。）具体的冲突是：尖锐的玻璃会割伤持握它的人。我们都曾有过尖锐玻璃的视觉经验，以及与之相关的视觉识别和回避需求；因此，尖锐玻璃的心理意象会触发这种识别并产生冲突。这个冲突一旦被检测到，也同样一路可视化到了视觉皮层；我短暂地看到了拇指沿金字塔边缘滑动的心理意象。

尖锐边缘的问题是由尖锐性引起的，可以通过倒圆角来解决，而且我有过圆角玻璃的视觉经验，所以心理意象中的尖锐边缘就滑移成了圆角。结果是一个完整的金字塔形灯泡心理意象，它有四个三角形侧面、圆润的边缘和角落，以及一个带插头的方形底部。（36）

当然，最后五段中的每一句话都只是在回避问题：“为什么？为什么？为什么？”完整的答案实际上超出了“心智”这一节的范围；我只是想提醒读者，通常真正的答案是“因为在你的一生中，它至少以这种方式发生过一次。”人类心智不一定能够同时发明出可视化三角形灯泡所需的所有反射、显著通路和滑移。神经元会学习，思维会在网络中磨损出通道。我第一次必须选择三角形强加应该应用于哪个层面——视觉、空间还是物理——时，可能犯了一个滑稽的错误。种子人工智能或许能够通过使用深思熟虑的、思维层面的推理来避免或缩短这个婴儿期，即思考概念应该如何组合；如果是这样，这就是超越人类所展现的功能。

你会注意到，在整个概念组合的讨论中，我一直在谈论人类，甚至诉诸于基于神经的心智物质的特定属性，而没有讨论在人工智能中的实现问题。大多数时候，生物神经结构的联想性、基于相似性的架构是一个可怕的麻烦。人类进化总是使用神经结构——没有其他类型的计算基底可用——但有些计算任务与这种架构如此不匹配，以至于必须费尽周折才能用神经方式编码它们。（这就是为什么我倾向于本能地怀疑那些说“让我们用神经网络解决这个问题！”的人。当人类心智想出一个解决方案时，它倾向于将其表述为代码，而不是神经网络。“如果你真的理解了这个问题，”我心想，“你就不会使用神经网络。”）

概念组合是神经元真正大放异彩的少数领域之一。这是非常罕见的场合之一，生物神经结构的联想性、基于相似性的、通道磨损的架构如此合适，以至于程序员可能会重新发明赤裸的神经元，不添加或删除任何特征，作为解决问题的正确计算元素。神经结构非常适合于“还原论能量最小化”或“整体网络松弛”或任何你想称呼它的东西。

即便如此，神经网络非常难以理解、调试或合理修改。我相信人类程序员和人工智能都能理解和操纵的心智物质的理想。期望直接的人类可读性可能有点过分；如果从字面上理解这个目标，往往会促进脆弱、结晶、简单的代码，就像经典人工智能的代码一样。尽管如此，即使概念层面的心智物质没有代码的直接语义，我们也可以期望比汇编语言的赤裸不可理解性更好。我们可以期望程序员能够看到和操纵正在发生的事情，至少在一般术语上，也许借助某种“反编译器”。我目前倾向于将代码作为最终的心智物质，同时承认这些代码可能会倾向于以类似神经的模式组织自己，这将需要额外的工具来解码。

2.3.5：思想由概念结构创造

思维由概念层面的模式结构所构建。典型例子是语法句子：大脑语言中枢将线性词序列解析为近似层级结构，其中可定位词语和短语的指称对象（例如形容词需要目标意象）已在句子内部或当前心理意象最显著部分中找到。该过程的逆过程是：注意到事实，将其转化为概念结构，转译为句子，并在心智中清晰表达。（关于意识流现象的可能原因，见 2.4.3 节：关于思维的思维。）

本节将概念视为基于心智素材的感觉模态模式——即假设心智素材关注感觉模态及其特征，或向其发出指令。概念与其他概念相互作用，并受其被调用时更高层语境的影响，这一点在很大程度上被忽略了。这是有意为之。离心智素材层面越远，越“抽象”，就越接近人类内省容易触及的层面。这些是内省感知以词语形式呈现的层面；现代文化将其与超常智力相关联的品质；经典人工智能极度强调的层面。

然而，有些思维如此抽象，以至于似乎远离任何感觉基础。例如，在上一句中，只有“远离”一词具有明显的基础，且由于该句未在空间语境中解释，即使该词也不太可能产生任何直接的视觉化效果。隐喻出现的频率可能比你想象的要高，即使在抽象思维中也是如此（参见“莱考夫和约翰逊，《我们赖以生存的隐喻》或《肉身中的哲学》）。然而，有些概念的定义和基础主要在于它们对其他概念的影响——“抽象概念”。为什么经典人工智能方法不适用于抽象概念？

即使是抽象概念，即完全由指向其他概念的概念所构成的心理意象，也存在于一个还原整体系统之中。抽象概念或许没有直接扎根于感官经验的还原论定义，但它们拥有扎根于其他概念的还原论定义。两个抽象概念之间看似高层的对象间交互，在出现冲突时，可以被建模为两个定义之间的中层结构间交互。

抽象概念仍然具有低层结构、中层交互和高层语境。

然而，用其他概念来定义概念正是经典人工智能的做法。我一时想不起任何（失败的！）经典人工智能具有显式的整体结构——我想不起任何经典人工智能构建了显式的多层模型来基于语义网络进行推理——但很可能有人在某个时候尝试过。（Eurisko 和 Copycat 不算，原因将在后续章节讨论。此外，它们并没有失败。）那么，为什么经典方法对抽象概念不起作用呢？

许多经典人工智能甚至缺乏基本的定量交互（如模糊逻辑），这使得它们无法使用诸如整体网络松弛等方法，并让所有交互都带有更强的刻板感。不过，也有使用模糊逻辑的经典人工智能。

所缺失的是灵活性、可变性，以及最重要的丰富性；所缺失的是学习概念所带来的复杂度。或许在理论上，可以从一个成人人工智能中选取一段抽象推理，其中感官模态的复杂度完全不参与。或许甚至可以在不破坏推理因果过程的前提下，移除某一层级以下的所有基础概念，以及大部分模态层级的复杂度。即便如此——即使心智被剥夺了最终的基础而悬空漂浮——结果也不会是经典人工智能。抽象概念是习得的，是在一个几乎与感官模态同样丰富的世界中成长起来的——因为基础定义由交互丰富的、略微不那么抽象的概念组成，而这些不那么抽象的概念之所以丰富，是因为它们成长于一个由更不抽象概念之间的交互构成的丰富世界，如此层层递进，直至感官模态的层级。丰富性并非自动产生。一旦概念被创造出来，必须对其反复琢磨，才能使其足够丰富以支撑下一层。不能从顶层开始向下构建。

经典人工智能所缺失的另一个因素是：将经验附着于概念的能力、在思考中获得经验的能力、在心中磨出通道的能力。即使是像“三角形灯泡”这样的概念组合，也具有一种动态模式，一种概念层面上的因果流动，这依赖于思考者预先完成了大部分思考。这种复杂度在经典人工智能中同样缺失。（当然，大多数经典人工智能根本不支持认知的所有其他维度——注意力、专注、因果性、目标、虚拟语气等等。）

我认为这为经典人工智能失败的原因提供了充分的解释。这就是为什么经典人工智能无法支持思想层面的推理或意识流；为什么感官模态对于学习抽象思维是必要的；以及为什么概念必须被习得，才能足够丰富以支撑连贯的思维。

插曲：表征、注意、理解、发明

理性推理非常庞大且非常复杂。在试图复制一条理性推理的功能时，很容易贪多嚼不烂，从而陷入绝望——或者更糟，过度简化。补救办法是理解优先级，即一个序列，它告诉你何时超前了，在打好地基之前就盖屋顶；以及启发式方法，它告诉你何时放慢速度，构建工具来构建工具。在你创造一件事物之前，必须存在该事物存在的潜力，有时你必须递归地创造这种潜力。

德鲁·麦克德莫特（Drew McDermott）在经典文章《人工智能遇上天然愚蠢》中指出，在人工智能中，首要任务是让 AI 注意到其主题。不是“理解”。是注意。如果一个经典 AI 有一个名为“汉堡包”的 LISP 标记，这并不意味着该标记是一个符号，也不意味着它有任何汉堡包属性。要让 AI 注意到某事物，其内部行为必须因所注意到的事物而改变。一个名为“汉堡包”的 LISP 标记没有附加的汉堡包属性。经典 AI 的哲学家会说，LISP 标记具有语义，因为它指涉外部现实中的汉堡包，但 AI 无法注意到这种所谓的指涉。这种“指涉”不影响 AI 的行为，既不影响外部行为，也不影响程序因果性的内部流动。

我扩展了麦克德莫特的启发式方法，描述了一个称为 RNUI 的序列，它代表表征（Represent）、注意（Notice）、理解（Understand）和发明（Invent）。表征先于注意；在你能有一种模态编写特征检测器之前，你需要数据结构（或非晶体等价物）来存储被检查的数据和被感知的特征。理解先于发明；在 AI 能设计一辆好的自行车之前，它需要能够区分好自行车和坏自行车——感知目标和子目标的结构，理解人类设计师关于为什么自行车以特定方式设计的解释，能够表征该解释并注意到解释与随机胡言乱语之间的区别。只有这样，AI 才能独立发明一辆自行车并向他人解释。

表征（Represent）是指认知结构的骨架、函数的输入输出或真实思想的平面描述能够在人工智能内部被表示出来。表征关乎静态数据，即减去动态方面和行为之后所剩下的内容。表征无法区分构成思想的数据与由随机数生成器提供的数据。

注意（Notice）提供了强制执行内部关系和内部一致性的行为。注意为数据添加了动态方面。应用于模态层面时，注意描述了特征提取器，这些提取器用关于关系的简单事实、简单的因果联系片段、明显的相似性、时间进程、小的预测和期望以及由该领域“物理定律”产生的其他特征来标注数据。模态层面注意感知的反面是注意操纵，即直接操纵认知表征的选择和行动的可利用性。RNUI 序列也适用于更高层次以及整个人工智能；有可能能够表征和注意“三性”而不理解它，或者无法用它做任何有用的事情。

理解（Understand）关乎^o 意向性和外部关系。理解关乎与其他认知结构的一致性，以及与上层语境和底层实质（^o 还原整体表征的上层和下层）的一致性。理解意味着反映认知结构目标导向方面以及设计特征目的的知识 and 行为。理解反映了能够将高层次特征与低层次特征结合起来的启发式方法的使用。理解意味着能够区分

好的设计和坏的设计。理解是能够完全表征在设计自行车或发明解释过程中会产生认知结构，并验证这些认知结构代表了好的设计或好的解释。

发明（Invent）是设计自行车、发明启发式方法、分析现象、为国际象棋比赛制定计划的能力——简而言之，就是思考。

如果你在让一个人工智能设计自行车时遇到困难，问问自己：“这个人工智能能理解自行车的设计吗？它能区分好的设计和坏的设计吗？”如果你在让人工智能理解自行车设计时遇到困难，问问自己：“这个人工智能能注意到自行车的各个部件吗？它能区分自行车和随机噪声吗？”如果你在让人工智能注意到各个部件时遇到困难，问问自己：“这个人工智能能表示自行车的各个部件吗？它能表示所注意到的关于这些部件的信息吗？”

2.4：思想

NOTE: This section is about what thoughts *do*. For an explanation of what thoughts *are* - how they work, where they come from, and so on - see the previous sections.

2.4.1：构建世界模型

在人工智能能够行动之前，它需要学习。“学习”可以分为知识形成和技能形成。技能形成发生在思维物质、反射或其他无意识过程被修改时。在人类中，这种修改是自主的；在种子人工智能中，它可以是自主的或刻意的；但技能总是自主执行的。（注意，这里使用的“技能”不仅包括运动反射，还包括认知反射，并且“技能”不包括有意识的技能，比如知道（理论上！）如何拆卸摩托车。）技能和知识之间的二分法通常被称为“程序性知识与陈述性知识”，尽管这涉及对底层表示的假设，而这种假设不一定成立。一般来说，“知识”是世界模型，即思维的内容，而“技能”是构成思维的材料。由于技能往往位于概念层面或模态层面，本节重点讨论知识。

世界模型是整体的还是还原的，取决于你是向上看还是向下看。我们生活在一个宇宙中，复杂的物体由更简单的结构构建而成，简单元素之间相互作用的随机规律性变成了可以发展出自身相互作用的复杂元素。

因此，广义上讲，至少存在三类知识问题。你可以寻找一个物体与另一个物体相互作用方式的规律性。你可以取一个物体、一个事件或一次相互作用，并尝试分析它；解释可见的复杂性如何体现在组成元素及其相互作用中。或者，你可以取你已经有所了解的元素和相互作用，并尝试理解系统的高层行为。从你所知道的出发，你可以横向、向下或向上看。

实际上，这种说法过于宽泛。例如，'拿一个你有所了解的物体，突然理解它在更高系统中的作用'，这属于哪一类？我想你可以将其解释为分析的一种变体——当'顿悟'发生时，结果是对系统及其组成部分有了更好的理解。但还有其他知识问题，比如通过采取对系统的意向性立场，并假设对象是为其目的而精心设计的，来猜测元素的属性。这又属于哪一类？我想，其寓意在于，'还原整体论'作为一种范式有其用途，但也存在局限。

也许我们应该推广到通用的因果模型，而不论层级？这样，你可以将活动分为：注意到某种属性或相互作用，推断属性或相互作用的成因，或从已知原因预测预期结果。这个模型更有一些，因为它听起来像是三种问题类型可能对应三种问题解决方法：（A）检查模型以寻找意外的规律性、对应关系、协方差等。（B）生成并检验可能的模型以解释某种效应。（C）利用现有知识填补空白（并且，如果你具有科学头脑，检验由此产生的预测）。

然而，即便是这种观点也有其局限性。例如，追问“为什么”或寻求解释，严格来说并非生成-测试的过程。事实上，生成-测试不过是那个人工智能领域的老难题——搜索算法——在思维层面的一种温和版本。很可能存在某种“温和的搜索算法”——既非“盲目”，也非真正深思熟虑，且带有明确的随机成分——它负责了概念层面上的突发洞见、直觉飞跃以及大量智能的驱动力。然而，在思维层面，退一步思考问题往往更为高效。一种实现“思考问题”的方式是“抽象即信息损失”的经典人工智能式“抽象思维”，即用未知变量替换所有未知信息来推演问题，以观察未知量是否能在某些地方相互抵消，从而得出对所有可能解都成立的部分结果，进而约束搜索空间。更精确的实现方式是“运用基于已有一般信息的启发式方法，逐步构建关于答案的一般性信息”。

思维层面是心智的一个真实层次。没有简单的方法可以刻画它。复杂的方法则是观察人们在出声思考时解决问题的过程（“协议分析”），然后找出一组与底层神经机制或问题解决的功能模块相对应的概括，并将实验观察中的所有个体思维归入这些类别。这个问题规模庞大，但有限；底层能力和心智行为的集合是有限的。尽管如此，这样的项目超出了本节的范围。（在后续主题中，我将尝试充分描述底层能力，使得实现这些能力能够产生可持续的思维。请记住，种子人工智能并非完美描述人类的全部功能，而是要构建具有足够功能的心智以进行工作。）

思维层是心智的一个真实层面，其内部复杂度与模态层或概念层大致相当。区别在于思维对自省开放，因此当我做出笼统概括时，读者能够察觉。尽管如此，我希望这里提供的概括足以传达一个模糊的整体印象，即

在寻求知识的心智中发生着什么。注意到有趣的巧合、协方差和相似性（横向观察），构建、测试并思考某事发生的原因（分析，在整体模型中向下看，在因果模型中向后看），尝试利用已有知识填补空白（预测，在整体模型中向上看，在因果模型中向前看）。目标是拥有良好高层/低层绑定的整体模型，或是一个扰动的后果与前提被充分理解的因果模型，或是一个带有计划、收敛和意向性的目标-子目标模型。目标是一个在所有层面上当你考虑改变它时都能保持一致的模型；一个足够丰富以支持我们所认为的智能思维的模型。

2.4.2：创造力与发明

在理解与创造力之间划出清晰界限实际上是不可能的。有时，一个困难知识问题的解决方案必须被发明出来，几乎是从头开始。有时，新实体的创造并非在可能性中搜索，而是通过更深入地审视已有信息来看那唯一的可能性。但通常，在构建世界模型时，你试图找到单一、唯一的解决方案；即问题的答案。当尝试设计新事物时，你寻找的是问题的任意答案。理解受到更强的约束，但这实际上使问题更容易，因为解决方案存在，问题在于找到它……这些约束或许更应被称为线索。

在发明创造中，每一项约束都会排除一些选项，从而降低解决方案存在的可能性。理解与发明之间的区别，类似于 P 与 NP 之间的差异，即验证一个解与找到这个解之间的区别。回到感觉、预测、决策和操控这四重约束，以及操控的定性、定量和结构三重子约束，发明，或者说高层次操控，增加了第四重约束，即整体约束。这是一种能力，能够从一个期望的高层次特性出发，指定产生该特性的低层次结构。这是一种进行层次化设计的能力，能够从快速移动的目标出发，进而得出自行车的完整物理设计。

发明的方法比理解的方法更不明确。除非问题属于定性操控（从有限数量的备选方案中进行选择），否则设计空间本质上是无限的。智能思维通过拥有一个整体模型来缩小有效的搜索空间，该模型最终建立在能够直接进行反向操控的启发式方法之上。换句话说，如果你可以选择任意实数来指定车轮的宽度，那么就需要一种启发式方法，将其可逆地绑定到一个更高层次的设计特征上，例如转弯时所需的稳定性。如果转弯时所需的稳定性本身就是一个设计变量，那么就需要一种启发式方法将其绑定到一个已知量上，例如骑行者的体重范围。以此类推。

这种推理的作用是将搜索空间从所有可能的低层次设计规格的空间，缩小到构成合理高层次设计的认知对象的空间。如果还有足够的启发式方法进一步约束设计，或者从高层次目标指定设计特征，那么任务就可以在没有特殊灵感的情况下完成。如果存在一个缺口，即某个高层次特征没有直接决定其实现方式的启发式方法，那么有时就会出现一种被称为“洞见”的特殊事件，一种直觉上的飞跃。

有时你试图发明自行车，却不知道轮子的存在。关键的洞见可能在于想起圆木滚下山坡的情景。它可能在于突然之间看到了答案。或者，它可能在于找到正确的启发式方法来攻克问题。关键在于，为了找到那个唯一的正确答案，需要跨越广阔的搜索空间，而这一过程似乎没有任何引导或启发式方法来简化问题。（如果那个“啊哈！”时刻是找到了正确的启发式方法，那么创造性的行为就在于跨越可能启发式方法的搜索空间。）

什么是创造力？创造力是我们赋予一种精神冲击的名称，这种冲击发生在我们感知到大量新颖且高质量的精神材料被传递给我们的时候。我认为，这是对“意外”材料的感知，这里的“意外”并非指传递本身令人惊讶，而是指我们的心智模型无法预测所传递材料的具体内容。我们在两种情况下会将自己或他人的某个想法感知为“有创造性的”：第一，看到某人跳出框架思考；第二，感知到从近乎无限的搜索空间中选出的一个绝佳解决方案。在第一种情况下，一个概念被重新定义，或者原本被认为是约束的东西被打破；答案出乎意料，这给观察者带来了我们称之为“创造力”的精神冲击。第二种情况在于看到“高速旅行”与“自行车”之间巨大的鸿沟被跨越；观察者——除非自己设计过自行车——没有任何单一的启发式方法能够跨越如此大的鸿沟，能够预见所呈现材料的内容。可能的画作空间近乎无限，因此当我们看到任何一幅质量尚可的画作时，大量意外的认知材料被传递到我们眼前，我们便称之为“创造力”。

在我看来，创造性洞见的体验很可能发生在心智决定对搜索问题进行暴力破解，或者更准确地说，智能破解之时。轮子的“啊哈！”时刻之所以出现，是因为在你脑海深处，可能的记忆被随机测试其与问题的适用性，直到滚下山坡的圆木记忆与问题产生共鸣并上升到意识层面。这种无意识的“盲目”搜索可能运用了深思熟虑的一些技巧，例如搜索那些被看到快速移动的物体的记忆。（也可能没有。在我看来，只有刻意的思考才会产生那种约束。）即便如此，它在本质上仍然是一种随机尝试的算法。如果潜意识创造性洞见还有更多内涵，我不知道那是什么。

2.4.3：关于思考的思考

由于思想对人类心智而言相当容易触及，关于其运作方式已有大量研究。具体方法固然重要，但更重要的是构建一个可运作的思想系统，即足够多且行之有效的办法，使人工智能能够继续推进。

思想系统中最重要当属自省。自省是将思想层面维系在一起的粘合剂。连贯的思想并非随机产生。它们之所以出现，是因为我们知道如何思考，并且拥有正确的思维反射。接下来该思考什么这一问题本身就是一个问题领域。为了防止无限递归错误，我们在每时每刻层面上的解决方案完全由反射决定，即我们神经心智中磨损出的通道。即使当我们刻意停下来对自己说：“现在，我接下来该思考什么话题？”，关于思考的思考也是通过反射进行的。这些反射形成于婴儿期，在它们存在之前，连贯的思想不会发生。要跨越这一障碍，你必须是一个种子人工智能，能够观察自己源代码运行的回放，或者暂停并存储高层思想的当前状态，以便递归地审视构成思想的东西。

自我是一个与外部现实中任何领域同样复杂的领域。它不仅包括对自我的感知，还包括对自我的操控。你所记得的内省体验，是由那些问题大到需要意识思考的时刻组成的。在那被记忆的、内省可及的体验之下，隐藏着已经变得如此不可见的感知和反射，以至于我们甚至没有注意到它们。内省的直觉远比哈姆雷特的独白更为根本。内省问题应当以与设计自行车问题相同的尊重和相同的对 RNUI 方法的关注来对待。

内省需要内省感官，甚至可能需要一种内省模式。但内省模式的概念是微妙且可能无用的。显而易见的实现方式是拥有一种内省模式，报告人工智能内部的所有认知元素，但这增加了什么？人工智能已经注意到这些认知元素的存在。“内省模式”与“人工智能内部所有信息的无用且静态的额外副本”有何不同？你能用检测到的“红色特征”的特征做什么，而不能用红色特征本身做什么？

要回答这个问题，有必要退后一步，在上下文中考虑该问题。感官模式并非存在于真空中。它们之所以有用，是因为概念建立在其上。因此，问题不在于如何构建内省感官模式，而在于如何确保关于内省的概念能够形成。这可能涉及创建一种新的内省模式，也可能涉及为旧模式和认知的其他模块附加一个新的维度。

概念操控其指称对象，并从中提取信息。你将如何调整视觉模式，以便能够想象“思考红色”？你如何让 AI 以陈述性方式注意到一个概念已被激活，以及这种感知如何被逆转，从而产生可视化激活一个概念的后果？

这一设计问题或许能在一定程度上解释那种被称为“意识流”的奇特现象。你注意到一个事实，该事实被转化为概念结构，概念结构又被语言中枢转化为句子，随后你在心中“出声地”说出这个句子。有趣之处在于：如果你试图跳过在心中“出声地说出句子”这一步骤，即使你已确切知道将要说出的话语，你也无法继续思考。为什么？这一行为究竟增添了何种新信息？

一种可能的解释是，人类心智通过察觉听觉皮层来察觉概念。人类没有内省的内置模式，因此当概念向听觉皮层添加可识别的内容——词语——时，它们便对我们的心理反射变得“可见”。这闭合了回路。概念激活变得可检测，我们便能形成关于概念的概念。我认为这并非全部解释，但这是一个良好的开端。

那么思想呢？在思想层面，人类的内省相当原始。存在一种将一切归入“我”这一术语之下的倾向。当我们归因因果关系时，我们说“我记起来了”，而不是“长期记忆检索子系统报告……”。或许这是因为，从历史角度看，直到昨天下午我们才对心智内部有所了解。或许是因为细粒度的内省对自我建模不会贡献有用的复杂度，除非你正在撰写关于人工智能的论文之类。关于自我，有大量有用的启发式方法可以通过观察因果来学习，即使所有因果链都始于一个整体的自我对象。种子人工智能可能对更细粒度的自我模型有需求，但由于设计和源代码均可自由获取，这样的自我模型发展起来应该不会太难。

2.4.4: “我”一词的合法使用

人工智能何时可以合法地使用“我”一词？

请理解，我们探讨的是自我意识中一个非常有限且纯粹技术性的方面。我们谈论的不是那种会使伦理系统将你视为人的自我意识。我们谈论的不是“感受质”，不是意识体验的困难问题，不是作为一只蝙蝠意味着什么，或任何此类问题。这些是不同的谜题。

所问的问题是：人工智能何时可以合法地在句子中使用“我”一词，例如“我想要冰淇淋”，而不会让德鲁·麦克德莫特跳出来指责我们使用了一个可能被翻译为“shmeerp”或 G0025 的词？

考虑 SPDM 区分：感知、预测、决策、操纵。模型与现实之间的绑定始于模型以某种方式“映射”到现实（尽管这最终是任意的），当模型能够预测经验时变得可检验，当模型能够用于在备选方案之间做出决策时变得有用，其最终检验是以定量或结构方式操纵现实。还要考虑模式层面、概念层面和思想层面之间的区分。

自我建模始于人工智能——我们称之为 Aisa，意为“AI，自我意识”——开始注意到关于自身的信息时。对感觉的内省感觉很难与感觉本身区分开来，因此直到 Aisa 形成内省概念，这一过程才真正开始。自我模型直到能够做出预测时，才开始产生新颖信息，即能够对内部事件施加连贯观点的信息

——例如：“从一个话题跳到另一个话题，而不是在一个话题上花费大量时间，将导致主要通过联想连接的概念结构。”同样，这些信息直到在目标导向的决策中发挥作用——即决定性绑定——才变得有用。

当 Aisa 能够创建内省概念并制定关于自我的思想层面启发式时，它将能够以与推理其他事物相同的方式推理自身。Aisa 将能够以与操纵外部现实相同的方式操纵内部现实。如果 Aisa 在理解和操纵摩托车方面非常出色，那么在理解和操纵 Aisa 方面也可能同样出色。

但说“爱莎理解爱莎”并不等同于说“爱莎理解自己”。道格拉斯·莱纳特曾这样评价 Cyc：它知道存在 Cyc 这样的东西，也知道 Cyc 是一台计算机，但它不知道它就是 Cyc。这是关键的区别。一个思想层面的自模型 SPDM 绑定，足以让爱莎合理地说出“爱莎想要冰淇淋”——使“爱莎”一词的使用与“shmeerp”或“G0025”一词的使用有实质性的不同。在爱莎能够说出“我想要冰淇淋”之前，还需要一步。但这一步是什么？

有趣的是，假设问题是真实的就足以解决问题。如果在爱莎能够说出“我想要冰淇淋”之前还需要另一步，那么说“爱莎想要冰淇淋”和“我想要冰淇淋”之间必然存在实质性差异。所以答案就是：当通过建模自己所产生的行为——由于自我指涉——与通过建模另一个恰好看起来像自己的 AI 所产生的行为有实质性不同时，你就可以说“我”。

这在任何单个思想中都不会发生——人类不会，AI 也不会——但爱莎指涉性思想的迭代版本可能开始表现出实质性不同的行为。任何单个思想都总是 A 修改 B 的情况，但如果 B 随后继续修改 A，整个系统可能表现出自我意识的基本特征行为。然后爱莎就可以合理地说出关于自己的：“我想要一个冰淇淋蛋筒。”

人类还会往锅里加一些额外的东西。我们有观察者偏见的社会信念，一整套偏向于中心心智的世界观，这往往会锚定对自我的感知。我们将内部因果归因于一个称为“自我”的整体对象，这产生了大量感知到的自我指涉，因为你不会注意到进行修改的思想与被修改的认知对象之间的区别——思想的来源是“自我”，被修改的项目也是“自我”的一部分。

种子 AI 可能最好没有这些特征。我提到它们是因为它们构成了人类所说的“自我”的很大一部分。

3: 认知

- 3.1: 时间与线性
 - 3.1.1: The dangers of the system clock
 - 3.1.2: Synchronization
 - 3.1.3: Linear metaphors: Time, quantity, trajectory
 - 3.1.4: Linear intuitions: Reflection, simultaneity, interval, precedence
 - 3.1.5: Quantity in perceptions
 - 3.1.6: Trajectories

3.1: 时间与线性

- 3.1.1: The dangers of the system clock
- 3.1.2: Synchronization
- 3.1.3: Linear metaphors: Time, quantity, trajectory
- 3.1.4: Linear intuitions: Reflection, simultaneity, interval, precedence
 - 3.1.4.1: Reflection
 - 3.1.4.2: Simultaneity
 - 3.1.4.3: Interval
 - 3.1.4.4: Precedence
- 3.1.5: Quantity in perceptions
 - 3.1.5.1: Zeroth, first, and second derivatives
 - 3.1.5.2: Patterns and broken patterns
 - 3.1.5.3: Salience of noticed changes
 - 3.1.5.4: Feature extractors for general quantities
- 3.1.6: Trajectories
 - 3.1.6.1: 跨时间经验中单个对象的识别
 - 3.1.6.2: 来源、轨迹和目的地的定义属性
 - 3.1.6.3: 来源、路径、目标；冲动、修正、阻力和力度

数字计算机中的时间是离散的，并且具有单一的共时性空间，因此任何玩过康威生命游戏（Conway's Game of Life）的人都知道关于人工智能中时间的真正终极本质所需了解的一切。随着时钟的每一次滴答，每一帧都是根据该本体论的“物理定律”从前一帧推导出来的。（帧序列中的更高层次规律构成了我们所说的因果关系；更多内容见未实现部分：因果关系。）

通用智能需要能够感知和可视化两个事件何时同时发生；一个事件何时先于或后于另一个事件；两个事件序列何时相同或相反对称；以及两个间隔何时相等、更小或更大。其中大部分属于对时间作为数量和轨迹的感觉这一总标题之下，这需要概念层面和模态层面的支持。

3.1.1: 系统时钟的危险

为了支持时间隐喻和时间概念——提供一个具有足够复杂度的应用程序编程接口（API）供心智素材接入——人工智能需要模态层面的支持。最明显的方法是用一个 64 位数字标记所有事件，该数字表示自 1970 年以来的纳秒数——一个普通的老式系统时钟。问题在于，这样一来人工智能就无法思考 1970 年之前发生的任何事情。也无法思考皮秒（picoseconds）。

如果我们人类有一个内置的系统时钟——有几种候选，从心跳到大脑中 40 赫兹的电脉冲——我们并没有有意识的、抽象的途径去感知它。我们记住的是相对时间；事件 A 发生在事件 B 之前，事件 C 介于 A 和 B 之间，A 和 B 之间发生了很多事情，D 似乎花了很长时间，E 似乎过得很快，E 和 F 同时发生，等等。如果我知道某个特定事件发生在 2000 年 7 月 23 日下午 4 点 58 分，那是因为我看了手表，并将视觉或听觉标签“4:58”与该事件关联起来。这就是为什么我能够——至少在抽象层面上——思考宇宙的年龄或皮秒时间框架。我们关于定量时间的抽象概念并非真正建立在我们内部的模态级时钟之上，而是建立在我们所构建的外部时钟之上。或者更确切地说，内部的模态级时钟仅用于即时感知，而抽象概念通过一层抽象来创建模态级，这层抽象能够像处理分钟一样轻松地处理千年。

因为通过比较绝对定量时间来推导所有相对时间感知非常容易，我们几乎肯定会为每个事件标记一个 64 位系统时钟时间（或等效的解释器令牌），并在此基础上构建任何其他模态功能。重要的是要记住，关于时间的真正重要概念不应直接建立在底层的绝对数字之上，因为那样人工智能真的无法思考皮秒或 1970 年之前的事件；构成概念的心智材料将会崩溃。关于时间的概念，如果它们涉及定量数字，应该建立在思考时间问题时发生的认知事件的相对时间之上。因此，人工智能可以想象一个在皮秒时间尺度上发生的过程，并且由于可视化本身发生在纳秒时间尺度上（或人工智能系统时钟运行的任何速度），就不会崩溃。这是一种自动缩放。

换句话说：普遍性要求时间概念与时间模态之间至少存在一层完整的抽象。即使存储的记忆也存储了附加的系统时钟时间，对这些记忆的重放显然不会发生在记录的时间！如果所有被记忆的时间都是纯粹的抽象特征，并且只有具体可视化的时间才会产生时间直觉，那么人工智能就可以自由地操纵可视化过程的时间方面。诸如慢和快（37）这样的符号可以从时间直觉中抽象出来，并应用于任何可视化时间过程的各个方面。

当然，因为我们并非盲目遵循人类的局限性，种子人工智能可能应该拥有某种直接访问系统时钟的模式。我们都曾处于想要确切知道现在几点，或者确切知道我们吃早餐时是几点的情境中。这就是为什么上帝给了我们手表（38）。只要直接访问通过相同的概念过滤器、相同的抽象层进行，这应该是安全的，这样模态级别的系统时钟时间 203840928340 就会以抽象特征“系统时钟时间 203840928340”的形式出现。

3.1.2: 同步

人类时间理解的另一个微妙之处在于，我们的感官是同步的，尽管不同的感官可能具有不同的处理延迟。视觉皮层处理图像需要时间，听觉皮层处理声音也需要时间——所需时间不一定相同。但是，同时到达的物理声音和物理景象应该被感知为同时发生。由于种子人工智能应该能够将感官事件标记为与派生的感知事件不同，这在模态层面上应该相对容易处理……尽管可以想象，如果存在作用于多个模态的派生且可能不同步的高级特征的启发式方法或概念，问题可能会突然出现。

对于某些情况，可以通过仅允许多模态概念作用于已被所有目标模态完全处理的事件来解决此问题。如果一个视觉信号和一个声音信号到达 $t=10$ ，声音在 $t=20$ 完成特征提取，视觉在 $t=30$ 完成提取，那么任何视听概念都不能在 $t=31$ 之前开始作用，此时声音和视觉的感知时间均为 $t=10$ 。换言之，与其从各模态中提取精华，人工智能的感知当下将比实时滞后几秒。

这引入了两个新问题：其一，可能给系统带来严重延迟。模态不仅适用于外部感官信息；模态也是所有内部思维发生之处。在某种程度上，此问题可通过不要求概念激活前完成全部处理来解决，而仅要求达到该概念所需的处理水平。毕竟，概念无法作用于其未拥有的信息。但这仍可能损失一些效率；可能存在概念不需要同步的情况。

第二个问题是主观时间的同步。如果人工智能的当下滞后几秒，那么思维被感知为发生在何时？如果人工智能在它看来是 $t=10$ 的时刻思考“foo！”，但实际时间是 $t=40$ ，那么概念“foo！”被标记为发生在 $t=10$ 还是 $t=40$ ？这有何区别？我看不出使用 $t=40$ 有何区别，因此我强烈倾向于将所有事件标记为其实际发生的时间。尽管如此，人工智能最终可能会发现作用于“主观时间”的有用启发式方法。

所有这些模态层面和概念层面的问题，不过是思想层面变化传播这一远为困难的问题的回声——如何确保“顿悟”体验和“失误”体验传播到心智的各个角落，从而使信念保持在合理一致的状态。一致性问题不属于本节内容。然而，概念层面（以及思想层面）的同步问题似乎并非应由自主过程来解决；概念同步可能需要根据具体情况逐一决定。或许，在学习思想层面的反射并找到有效概念的过程中，人工智能将被迫为每个概念发明所需的任何同步形式。如果一个多模态概念必须作用于“同时”开始处理的模态图像（39），否则就会失败（无法产生有用结果），那么这应该是一个相对简单的调整/变异，即使是^o Eurisko 也能轻松完成。对于程序员在初始阶段指定的任何概念也是如此。

作为一般规则：所有派生感知事件都应标记其真实认知时间以及派生事件的外部世界时间。人类编程的概念应使程序员能够决定应使用哪个时间；学习到的概念只有在使用正确的时间框架时才会被注意到。尽量维持所有智能本应代表的现实中的规律性；弄清楚时间概念所代表的有用规律是感知/外部的还是认知/内部的。

3.1.3: 线性隐喻：时间、数量、轨迹

通用智能需要能够感知和可视化两个事件何时同时发生；一个事件何时先于或后于另一个事件；两个事件序列何时相同或相反对称；以及两个间隔何时相等、较小或较大。大多数

这属于对时间作为数量和轨迹的直觉这一总标题之下……"——上文。认知的几个最基本领域是一维的或单调递增的，因此共享某些线性特征。从某种意义上说，任何对"近"或"远"一词的可能使用都唤起一种线性直觉。"更多"和"更少"这两个词也是如此。时间，因为它既是单调递增的又是一维的（40），属于线性领域之一。线性领域往往彼此密切相关——你可以有"更多"的时间或"更少"的时间，将时间视为数量；你可以"接近"某个给定时间，将时间视为轨迹。我们自由地混用这些词，因为目标领域共享行为和底层属性。从某种意义上说，时间与数量和轨迹之间的关系并非如“莱考夫和约翰逊所称的“隐喻”；它是一种真实的同一性。

当你考虑到时间几乎总是被数学地描述为实数（41）；实数的一个词是“数量”；在大多数轨迹中，到目标的空间距离随时间单调递减；并且时间以恒定速度“向前移动”；那么，这种同一性似乎如此完美，以至于隐喻不会带来任何复杂度。”莱考夫和约翰逊善意地提醒我们，“数量”不仅适用于数学，也适用于砖堆和硬币堆；“轨迹”不仅仅是简单的从源到目标的飞行，而是复杂的空间操作，视觉子系统中有大量部分专门用于其可视化。

通过观察到两堆砖加三堆砖等于五堆砖，可以猜测两小时加三小时将等于五小时。利用 2.3.3 节中描述的基础数值概念：“三”的概念，可以看出这种“隐喻”需要将时间间隔视为独立对象的能力，以便在三个小时中的每一个与三块砖中的每一块之间建立唯一对应关系。要在概念层面学会将时间视为数量，需要人工智能遇到一个具有唯一性约束的任务；一个它无法在同一分钟内做两件事的任务（42）。这导致将时间视为有限资源，进而与时间作为物质实体的类比更加强烈。

莱考夫和约翰逊以观察者的运动来描述时间即运动的隐喻。观察者的“位置”是现在，观察者前方的“空间”是未来，观察者后方的“空间”是过去。“物体”是事件或时间，被“定位”在“线”上的各个“点”处。时间即运动的隐喻有两种（互不相容的）解释：可以认为观察者以恒定速度向前移动，经过事件；或者可以认为事件向观察者移动。（莱考夫和约翰逊指出，这就是“让我们把会议提前一周”这句话有歧义的原因。）莱考夫和约翰逊还指出，我们也将时间映射到身体意象上；在几乎所有语言中，观察者们都“面向”未来——尽管少数语言（大概注意到人们能看到过去，却看不到未来）让观察者面向过去。然而，这偏离了主要话题——将时间描述为轨迹的效用。

时间即空间的一个主要用途是同时可视化多个事件。也就是说，通过将时间概念化为一条线，我们可以同时考虑线上的三个点/事件，而真正的时间可视化会迫使我们按顺序考虑这些事件。但这只适用于人类，因为我们拥有单一且不可分割的意识流。种子人工智能可能能够同时可视化三个不同事件的动态特性；实际上，是在时间线上的三个不同点放置三个不同的移动观察者！同样，将时间可视化为空间使人类更容易感知某些类型的定性关系。将某个量随时间变化绘制成图——你知道，就是普通的二维图——使我们能够感知曲线的性质，而这些性质对于观察一维变量随时间变化的人类观察者来说是不可见的。人类对静态空间属性有一套直觉，使我们能够退后一步观察图形，形成复合感知和连贯思维；我们对动态系统有另一套直觉，在动态系统中，感官图像的变化速率与我们的意识流相同。

对于人工智能而言，空间隐喻的益处或许可以直接通过将空间模式的感知直接改写为时间模式来提供——例如，将视觉曲线检测器改写为在时间模式数据上运行，从而使观察单一量随时间变化的人工智能能够拥有与人类凝视二维图时相同的“平滑曲线”、“尖锐曲线”或“全局最大值”等感知。

结论：时间、数量和轨迹共享某些基本属性。时间与数量之间高层隐喻的主要驱动力是一项将时间视为有限资源的任务。在人类中，时间与轨迹之间隐喻的主要驱动力是我们静态视觉直觉的更高复杂性，但这可能不适用于种子人工智能。

3.1.4：线性直觉：反思、同时性、间隔、先后顺序

霍夫施塔特在论述“Copycat——一个在字母串领域进行类比的人工智能，例如“abc->abd::pqrs->?”——时指出，尽管 Copycat 的领域很简单，但该领域可以包含极其复杂的类比问题，以至于涵盖了人类思维的相当大一部分。几年前，当我刚开始思考人工智能时，我着手头脑风暴列出几百个与类比相关的感知——“之前、下一个、增长、数量、增加、距离、速度、阻塞、对称性、间隔……”——并注意到其中大多数都可以在一条由 X 和 O 组成的线性条带上表示。这些感知我私下统称为线性直觉——即适用于直线的感知。

3.1.4.1：反思

其中一种感知是反思：“XXOX”是“XOXX”的反思，图像“XXOXOXX”是双侧对称的。（请注意，验证“XXOXOXXO”是“OXXOXOXX”的反思，或者“OXOXOXXOXO”是双侧对称的，可能需要更多时间，并且可能需要有意识地而非直觉地进行；我们的感知有“视野，即所消耗处理能力的极限。当然，你的感知正在分析大量的二维像素，而不仅仅是线性图像的开-关“像素”。）编写一个计算程序来验证反思是微不足道的，但这会遗漏一些最重要的设计特征。看到字母串“ooabao”和“xcxcxc”和“rauaabaur”时，字母串“oomemoool”会让人感到相当意外，而“l”会像疼痛的拇指一样突出。即使没有先例来建立期望，图像“WHMMOW”也有某些不对劲的地方（43）。

对反思的感知不仅仅是一个二元的、是或否的验证；一旦部分反思可见，它就会建立对完整反思的期望——一种关于“结构”应该“如何呈现”的心理图像，如果反思是完整的——如果期望被违背。如果实际图像与想象图像冲突，那么违背就会被检测到，违背的对象就会变得更加显著（“像疼痛的拇指一样突出”）。如果存在某种方式来看待违背对象，同时保持完美的反思，它将与期望产生强烈共鸣。（关于期望的更完整讨论，尤其是在概念层面而非模式层面，见未实现部分：因果关系。）

关键在于，对反思的感知，像大多数感知一样，具有复杂的内部结构。特别是，有可能期望反思，并且将"反思"这一属性应用于先前不对称的对象。

通常的注意事项：有可能注意到图像内部的反思，或者注意到两个不同图像中两个结构的反思；如果提前寻找反思，则更容易看到反思。

由于对每一组可能的像素进行反射比较在计算上代价高昂，而我们又能在图像中察觉到意外的反射——这意味着检测器始终处于开启状态——人类大脑很可能首先检测反射的先决条件，并且只有在先决条件被触发时，才尝试感知反射本身。如果两个视觉图像通过反射性质相关联，它们很可能具有非常相似的高层属性，因此同时感知一个图像及其反射会在基于神经元的人类大脑中产生感知结构，这些结构会彼此强烈共振，这表明应当对同一性和反射都进行测试。如果物体是可识别的，那么物体及其镜像通常都会被颞叶（44）归为同一类——一只鸟和它的镜像都被归类为“鸟”——因此来自物体和镜像的视觉信号会在该点汇合，并可以回溯到它们的源头，然后应用对称性测试。

无论如何，这就是人类检测视觉对称性的方式。人类大脑有可能利用其底层的电学特性在全局尺度上检测神经同步性，这是一种基于物理的方法，在冯·诺依曼架构的数字计算机上要匹配这种方法在计算上将极其奢侈。蒙特卡洛方法或许也能达到同样的效果；对全局状态的部分进行一百万次随机采样和比较，可能经常会在足够大的相似结构之间发现局部相似性——即使不是总能发现，也足以让感知具有人类般的自发性。一种随机尝试检测一百万种可能共振的蒙特卡洛方法，或许能够复制神经共振的几乎所有功能，而不会遇到完美实现所无法避免的组合爆炸。

但这类问题是一个重大、根本且深层的设计问题，在某种程度上超出了本节乃至第3章“认知”的讨论范围。对一维时间反射的感知，远比对真正的二维或三维空间反射的感知简单。模态层面的设计目标是，人工智能应能独立注意到极其明显的时间反射；而检测任何更细微的反射，则可交由启发式方法、概念以及深思熟虑的智能来承担。人工智能需要能够验证由概念层面或思维层面考量所提示的时间反射，但如前所述，这一过程相对简单。

Scenario 1

A glass drops, and grapes explode in the microwave, and the computer turns itself on - and then, a few minutes later, the computer turns itself on, grapes explode in the microwave, and a glass drops.

对不常使用的“爆炸葡萄”概念（或若其尚不足以构成概念，则为相应的感知结构）的重新激活，应足以提示事件正在重复；足以在每一对不寻常的事件之间建立对应关系。检测反射的计算过程足够简单，以至于可以设想在每一个有意识感知到的事件线上运行，只要这些事件线在事件之间建立了对应关系——至少对于那些显著到足以建立对应关系的事件而言。

或许这个例子略显离奇，但确实很难想出有用的时间反射实例。脑海中唯一浮现的例子是拆卸并重新组装摩托车（45）。一个股票交易人工智能可能会发现时间反射直觉很有用，或者一个观察灯光上下浮动并试图推断模式的人工智能也会如此。“反向运行过程”在多种情境下都是一个极其有用的启发式方法，但如此高层的想法属于思维层面的过程；甚至“反向”这一概念本身，也理应归入未实现章节：对称性。

场景1（爆炸葡萄场景）中仍存在一些微妙之处。首先，所建立的对对应关系是在高层事件之间。“爆炸葡萄”的概念并非直接表征于感觉模态中；至多，爆炸葡萄的声音和视觉被表征，而现实世界中没有任何两次视觉和声音会完全相等。导致第一次和第二次事件都被归类为“爆炸葡萄”的相似性，属于更高层面——要么是低层概念层面，要么是非常高层的模态层面。

然而，模态层面的时间反思直觉可以作用于概念层面的认知事件。以人类为例，想到“爆炸的葡萄”这一念头会在听觉皮层中产生“爆炸的葡萄”这些音节的视觉化表征，理论上这可以附带一个时间标签。在实践中，人工智能架构很可能将概念层面的认知事件定位并标记为对象，这样思想就可以被标记上用于模态层面时间直觉的系统时钟时间。一般来说，对思考的思考——即内省——显然需要某种方式来观察思想的时间序列，知道自己在何时思考了什么。架构要么需要显式地表征概念和思想的激活（这可能是解决方案（46））；要么，如果这一切都是心智物质的混沌体，更高层次是涌现出来的（47），那么思想就需要以某种方式溢出到模态中，使得进化出的概念和思想层面的反射能够完成诸如识别思想时间之类的任务。

第二个微妙之处在于，时间反思不太可能是完美的。玻璃杯掉落和葡萄爆炸之间的间隔不太可能恰好都是20秒。只有比较性的先后顺序——哪个事件先发生——才会被用于反思测试。尽管如此，保留间隔的反思构成了更强的绑定，尽管人类的时间感知过于粗略，没有秒表我们无法注意到这类事情。（我们用于反思的空间直觉 *do* 要求保留距离。）

3.1.4.2: 同时性

同时性是指两个事件在同一时间发生。完美同时性是指两个事件被标记为在模态层面系统时钟分辨率的极限内恰好同时发生。即使在完全避免并行处理的人工智能中，感觉模态也会将传入图像的所有组成部分标记为同时到达，因此任何心智都充满了无意义的同时性。有意义的同时性是指那些出乎意料且发生在高层次、显著对象中的同时性。例如，两个对象同时从感觉输入中消失。

由于种子人工智能的系统时钟运行速度可能远快于我们自身的时钟，因此有必要定义能够检测不完美同时性的直觉。例如，任何在四十分之一秒内的感官巧合，或任何在千分之一秒内的内部巧合（或选择与人工智能意识流速度相匹配的其他时间尺度）。（48）。

除此之外，将我在 3.1.4.1 节“反思”中列出的所有注意事项应用于同时性。例如，如果同时性重复出现的频率足够高，以至于被预期，那么对同时性的预期就会应用于感官输入以形成图像，被违反的预期应被察觉为真实图像与预期之间的冲突，违反预期的刺激应变得显著，等等。（如果刺激 A 出现时没有预期的同时刺激 B……并且在人工智能从震惊中恢复后刺激 B 仍未出现……那么刺激 A 和 B 的缺失都变得显著。）

3.1.4.3: 间隔

人类对间隔的感知是近似的，而非定量的。我们将某事物感觉持续的时间划分为“不到一秒”、“一秒”、“十秒”、“一分钟”、“十分钟”、“一小时”、“几小时”、“一天”、“几天”、“几周”、“几个月”、“几年”、“一生”和“比一生更长”。（这是一个猜测。我不知道实际的类别或它们的边界。如果有人已经做过研究，这将是一个有趣的知识。）

人类对时间间隔的感知也至少部分是主观的，取决于正在进行的思考量。一个相对缺乏事件的过程，其中我们的思维处理传入数据的速度远快于数据变得可用的速度，却矛盾地被感知为更长——它是“无聊的”（49）。一个充满情感意义事件的过程可能显得更长；当它结束时，“感觉比实际时间长得多”。（再次，用时间作为路径的隐喻，经过许多事件可能使间隔显得更长。）还有一句谚语“快乐时光总是短暂的”；如果事件发生得如此之快，以至于“没有时间思考”或注意潜在的间隔，时间可能显得流逝得快得多。（50）。

然而，在我看来，人类的主观时间间隔并未实现任何重要功能。如果人工智能使用系统时钟间隔来控制实际的主观感知，使得感知到的时间间隔是精确的，那么对精确时间间隔的感知更有可能是有用的——也就是说，当两个过程意外地具有相同的时间间隔时，这更有可能表明存在有用的潜在相关性。人工智能确实需要一种对“大致相同的时间量”的感知，因为这是一种有用的人类感知。（这种感知可能既有定量成分，也有定性成分；换句话说，对“大致相同的时间量”的感知可能强烈为真，也可能微弱为真。）

可能我们人类根本没有模态级别的“等间隔检测器”——毕竟，当我们想要验证两个时间间隔是否相等时，我们必须数心跳或看一眼手表。如果是这样，一个具有模态级别时间间隔感知能力的人工智能可能会发现人类会错过的意外情况。

《麻省理工学院认知科学百科全书》中的“时间推理”指出，时间间隔上的比较操作可能比瞬时事件的简单先后或同时关系更为复杂：“一对时间间隔之间存在十三种原始的可能关系：例如，之前（<）、相接（m）（第一个时间间隔的结束对应于第二个时间间隔的开始）、重叠（o）等等。”由于这十三种可能的关系可以从“开始”和“结束”事件的关系中构建出来，我认为它们不需要架构级别的支持。重叠的时间间隔应该被直观地注意到，因为显著的时间间隔应该被感知为实心的，填满两个事件之间的每一个点，并且碰撞应该以与实心物体碰撞相同的方式被检测到。在计算上，这可以通过使用一维碰撞检测算法来实现，或者通过创建一个内部感知的“时间线”，其中包含可以被多个事件占据的时间像素，其计算上可处理的分辨率（系统时钟可能太快）仍然足够精细以检测重叠。（52）。

最后，时间间隔具有与 3.1.4.1 节“反思”相同的注意事项。例如，时间间隔仅针对显著事件被感知；它们不会为思维中的每一对认知事件被计算。（事实上，这是不可能的，因为对时间间隔的感知本身就是一个认知事件。）

3.1.4.4: 先后关系

时间先后是指两个事件——甲或乙——哪个先发生。先后关系是最常用且最有力的时间感知；人类正是通过它来排列现实。我们并不关心以毫秒计的精确间隔（尽管人工智能可能会——见上文）；我们关心的是事件甲还是事件乙先发生。先后关系是最有力的时间直觉，因为它与因果关系交织最深——结果跟随原因。（见未实现部分：因果关系。）

从数学上讲，先后关系的传递性是线性排序的定义特征。如果甲 < 乙且乙 < 丙，则甲 < 丙；如果这一关系对一组中的所有事件甲、乙、丙都成立，那么就定义了该组的线性排序（53）。先后关系的集合定义了一条线性的事件串。大多数时候，我们人类使用的正是这个定义。在没有实际日历的情况下，我们几乎从不会通过试图记住实际的时间标签并执行排序来重建一系列事件。相反，我们试图通过记住乙在甲之后、丙之前，丁在乙之后等等来重建该序列。

同样值得注意的是，我们倾向于记住那些背后有原因的先后关系——例如因果的先后顺序。如果该序列是一条因果链，我们或许能毫不费力地一口气说出整个序列。如果我们试图描述属于多个不同因果序列的事件的顺序，我们常常必须有意识地从我们记住的部分排序中的交叉点来重建完整顺序；从记住某件事是“不久前”还是“很久以前”；等等。我们并不记得一个内在的日历或时间线，也不记得——在模态层面上——事件的时间。我们记住的是先后关系，而我们生活的时序正是由这些先后关系构建起来的。

种子人工智能或许应当使用模态层面的时钟或模态层面的时间线，但它仍然需要理解先后关系。

一般而言，先后关系无处不在；每当我们说“之前”或“之后”时，我们都在调用它。先后关系既可以是时间上的，也可以是空间上的。先后关系也适用于优先级，不仅指必须先做什么，还指首选什么。在这个意义上，每当我们说“更好”时，我们都在调用先后关系。

或者更糟。关于优先级的隐喻适用于所有在线性序上操作的比较器：这就是为什么线性和时间隐喻在人类语言中无处不在。

所有这些隐喻的共同点是，对数量或轨迹的比较操作通常反映了实际的时间先后——第一个选择通常是首先被考虑的那个；与推断该选择相关的认知事件会更早发生。如果一个较简单的定理出现在较复杂的定理之前，那是因为复杂的定理是由简单的定理构建而成的；简单的定理先被学习或先被发明，而该学习或发明的认知事件会有更早的时钟时间。

比较在模态中无处不在，就像在普通源代码中一样。模态层面的时间先后直觉是这一普遍规则的一个特例。

关于期望优先级和期望落空等的常见注意事项。

3.1.5：感知中的数量

“数量”在每一个包含实数的感知中都会被调用，就像浮点数在普通源代码中无处不在一样。当我说“数量”时，我不仅仅指连续可分的物质实体，如水或时间；我将其推广到表示和直觉中浮点数的内部使用——所有可以“更强”或“更弱”的感知。

3.1.5.1：零阶、一阶和二阶导数

给定两个数量，我们可以注意到哪个更多或更少；给定两个数量属性，如高度，我们可以注意到哪个更高或更低；给定两个数量感知，我们可以判断哪个更强或更弱。这种感知可以静态地运作，在没有时间成分的情况下。

正如未实现章节中所讨论的：当提取时，数量和比较器过于普遍，无法直接引发思考，除非这些数量和比较器是极高层级对象的属性；因此，低层级的数量和比较要么作为特征提取的前奏被计算，要么仅在更高层思考的上下文要求时才被计算。为特征提取而计算的比较通常也是局部的。人类视觉像素与邻近像素进行比较以进行边缘检测，而不是与图像中的每一个其他像素进行比较，使用 $O(N)$ 次比较而非 $O(N^2)$ 次比较。种子人工智能应当能够按需比较任意模态中的任意像素——但仅在需要时。关于按需感知与自动计算感知之间的差异、低层级感知与高层级感知之间的差异，以及引发思考的感知与验证猜测的感知之间的差异，详见未实现章节：当提取时。

可以对静态量执行的基本操作列表基本上是有用算术运算的集合：减法（换句话说，区间计算）、比较、相等性测试。也可以包括加法、乘法、除法、位移、按位与和|、余数计算、指数运算，以及所有其他可以对整数和浮点数执行的运算；然而，这些运算不太可能有用——不太可能挑选出现实中某些有趣的方面。

3.1.5.2：模式与破碎的模式

一个量的场，在时间或空间或两者上延伸，可以产生称为模式的中层特征；模式比量更高层，更丰富，并且作为一种感知更罕见（一百个像素产生一个模式）；因此，模式更有意义。模式可以被打破，而构成模式打破的高层特征比模式本身或低层量更罕见，也更有意义得多。（我在这里谈论的是模态层级的模式；看到思想层级模式的问题几乎与智能本身的问题相同。）

模式的一个例子是上升的量——“上升”意味着要么是随时间变化的单个量，要么是随某个空间维度连续变化的量的场。

- A: 27, 28, 29, 30, 31, 32.
- B: 29, 31, 33, 35, 37, 39.
- C: 8, 19, 22, 36, 45, 71.

A 和 B 不仅是单调递增的，而且是稳步递增的。C 中唯一的模式是数字始终在上升；每个数字与前一个数字相比，都大于前一个数字。在每种情况下，较低层次的模式在较高层次上成为恒定特征。一阶导数——“增加 1”、“增加 2”——在 A 和 B 中是常数。在 C 中，特征“前一个数字小于后一个数字”是常数。

观察 D 的模态：8、16、32、64、128、256，应当注意到数字在持续增加，并且增加的速度也在持续增加。人类模态不会注意到这些数字构成了倍增序列——而且，除非该序列被思维层面的过程所审视，否则人工智能的模态很可能也不应注意到。我这样说，是为了强调模态级模式检测的问题是有限的，与一般模式理解的问题形成对比——如果人工智能的模态能够理解一组简单、有限的模式，那就足够了。

注意到一个模式就是形成一个期望。当这个期望被违背时，模式就被打破了。观察单个量的变化，如序列 C 所示，特征“递增”保持不变。如果 C 继续但突然开始递减——8、19、22、36、45、71、62、21、7、6、1——就检测到了一个“边缘”。在更高层次上，观察到的是：“……大于、大于、大于、小于、小于、小于……”因此，低层特征检测器对“大于”或“小于”的存在，使人工智能能够注意到它原本无法注意到的模式。

并检测到它原本无法看到的边缘。这就是模态级特征检测器的功能：使发现现实中原本隐藏的规律成为可能。

作为一般规则，注意数量、一阶导数和二阶导数中的相等、连续相等和断裂相等。我们注意到常量何时变化，以及恒定的变化率何时变化，但我们人类并不直接感知加速度的变化。我们计算数量和一阶导数，但不计算二阶导数的数值。由于二阶导数——对人类而言——不是定量的而是定性的，我们可以注意到它跨越零线，或注意到大的（数量级）变化，但不会注意到小的内部方差。人工智能可能会发现定量地感知二阶导数是有用的，但计算定量的三阶导数（从而得到定性的四阶导数）在专门应用之外可能不会对智能有显著贡献。

(54).

3.1.5.3: 被注意到的变化的显著性

仍然存在显著性的问题。我们希望金融人工智能或人类会计能够注意到并思考，如果一个银行账户通常显示以百美元计的交易，突然开始显示以百万美元计的交易——中层特征“量级”，以前恒定为“百”，突然跃升至“百万”。但我们不希望注意到从中层特征“量级：150-155”到中层特征“量级：153-160”的变化，即使——表面上——两者看起来都是同样尖锐的不等式。（作为“晶体”比较操作，“百”!=“百万”的不平等程度既不比“150-155”!=“153-160”更大也不更小。）类似地，我们不会注意到从中层特征“以 5 结尾的数字频率：20%”到“以 5 结尾的数字频率：25%”的变化；或者，如果我们确实以某种方式注意到了，我们也不会赋予同样的显著性。

我们从经验或文化环境中了解到，金钱极其重要，人们经常试图篡改它，并且货币数量的数量级应该受到关注；我们还没有学到类似的启发式方法来关注几美元的变动，或数字百分比频率的变化，这就是为什么监控这两个量是只有审计师使用的专门技术。

学习关注哪些模式和断裂模式是一个概念层面的问题；这并非易事，但“Eurisko-oid”技术应该足够。

3.1.5.4: 一般数量的特征提取器

这些是能够对一般数量进行操作的特征提取器：

- Identity
 - Equality and inequality
- Comparators
 - Greater-than and less-than
- Perception of qualitative changes
 - Expected change (within range of observed variance)
 - Fractional change (plus or minus a few percentage points)
 - Significant change (plus or minus a few dozen percentage points)
 - Order-of-magnitude change
- Quantitative computation of first derivative, which is then another quantitative perception
 - 计算二阶导数有时可能有效
 - 计算三阶导数可能仅对专门的应用有用

缺乏这些简单的直觉是计算机程序在人类看来如此愚蠢的原因之一。我们总是注意到显著数量的变化；大多数程序除非经过专门编程，否则无法注意到任何事情，而且它们当然没有被编程去注意它们所注意到的事物的一般属性。银行账户不会注意到你每天存一笔款，然后突然在一天内存十笔款，然后又恢复为每天存一笔款；它被编程来处理金融交易，但不会注意到其中的模式。由于知道有一笔存款对人类来说是一种高层次感知——一种上升到有意识注意层面的感知——我们自动计算基本的数量感知，并注意到任何意外的相等或意外的变化。

在概念层面，所有这些特征都应该为所有显著的高层次数量计算，并为所有足够罕见的高层次特征计算，使得计算所有特征在计算上是可行的。弄清楚为一个数量计算哪些特征，以及关注哪些特征，是人工智能的一个主要学习问题；这一领域的学习对定性智能和效率都有显著贡献，因为复合提取器可以导致全新特征的计算。

在模态层面，这些特征提取器可以组合起来产生一些基本的中层特征，例如像素中的边缘检测，尽管除此之外的任何事情可能都是特定领域的问题。例如，像计算速度变化这样简单的问题不会严格属于数量感知的领域，除非速度被特定领域的感知分解为速度和方向的数量分量。

3.1.6: 轨迹

。莱考夫和约翰逊认为我们对轨迹的理解从根本上基于运动功能，他们提供了轨迹基本元素的列表（引自《肉身中的哲学》）：

- A trajector that moves
- A source location (the starting point)
- A target (L&J call it a "goal"), an intended destination of the trajector
- A route from the source to the target
- The actual trajectory of motion
- The position of the trajector at a given time
- The direction of the trajector at that time
- The actual final location of the trajector, which may or may not be the intended destination

“轨迹”也可以推广到对单一对象的任何一系列变化，对状态的任何一系列调制，这些变化随时间发生，并且有明确的开始和结束；任何连续变化的感知，并且足够平滑或单调，以至于被感知为轨迹，而不是一系列无关的变化事件。（55）。轨迹行为——尤其是具有明确开始、结束和方向的轨迹——与规划相交，规划与目标相交，这是另一个主题。然而，我们将讨论具有°意向性方面目标导向特征的直觉——例如力和阻力。

3.1.6.1：跨时间经验中单一对象的识别

轨迹的概念可以在时间 XO 模态中表示。从以下帧缩小，“OOOOOXXOOOOOOOXXOOXXOOOOO”，它可以被描述为“一条线上的三个点”。给定一个时间序列的 XO 帧，线上的点可以“移动”；它们可以有位置、速度、方向和速率。

XO 模态足以表示轨迹的一个例子，例如：“XXOOOX”、“XOXOOX”、“XOOXOX”、“XOOOX”；观察者会说中间的 X 已经从第一个 X 定义的起点移动到了第三个 X 定义的终点。（注意，我还没有使用“目标”这个词。）

为了形式上的严谨，我们应该命名所有产生开始-移动-终点感知的直觉。最大的障碍是将每个中间的 X 感知为同一个连续对象的实例——也就是说，在 t1 中位置 2 的 X、t2 中位置 3 的 X、t3 中位置 4 的 X 以及 t4 中位置 5 的 X，都是具有连续存在的单一对象的实例。人类会立即做出这种解释，因为我们有关于离散对象持续存在的内置假设——在出生后几个月内就变得明显的领域特定本能。

人工智能或许能做出相同的解读，但难度会更大。要建立对每个 X 作为离散对象以及中间 X 作为连续对象的强绑定感知，可能需要持续十帧的轨迹，而非四帧。暂时假设序列扩展为包含十帧，且中间 X 有十个单位步长。在这种情况下，以下事实立即可见：首先，每帧中 X 的数量相同。（我不会说“每帧有三个 X”，因为这意味着对“三”的理解。）其次，每帧在位置 1 有一个 X，在位置 12 有一个 X。对人类而言，“显而易见”的是，X 数量的恒定意味着离散对象数量的恒定；对人类而言，显而易见的是，三个 X 各自是不同的对象；对人类而言，显而易见的是，在每帧中保持相同位置的 X 在每帧中是同一对象；因此，既然首尾两个 X 已得到解释，每帧中剩余的中间 X 必定是第三个对象。事实上，第三个对象的“运动”（或人工智能可能视之为“位置属性的偏移”）是增量且恒定的。

大量的认知过程刚刚一闪而过。让人工智能感知两个经验属于同一对象，几乎与让人工智能感知两个对象属于同一类别一样深奥。一些底层力量在侯世达的 Copycat 源代码中可见；Copycat 能够将两个不同字符串中的两个不同字母视为占据相同角色。（Copycat 还能看到由字母空间中的“运动”形成的联系；它知道“c”跟在“b”后面。）然而，一般规则远比这深刻。

Rules of Identification
1. Equality of attributes across experiences, particularly those attributes that remain constant for constant objects, implies equality of identity. 2. Continuous change in an attribute, particularly those attributes that can change without changing the underlying object - such as "position" or "speed" - implies equality of identity.
Rule of Improbability Binding
When two images are equal or very similar, the probability that there is a shared underlying cause behind the equality is proportional to the improbability of a coincidental equality.

不可能性规则意味着，属性可能值的范围越广，值的相等就越强烈地暗示底层对象的相等。“XOX”与“XOX”的绑定远弱于“roj”与“roj”的绑定。“3”与“3”的绑定远弱于“23,083”与“23,083”的绑定。

因此，即便是判断两次经历是否属于“同一”对象这样基础的任务，也要求人工智能预先习得哪些属性是身份的良好指标，而这又要求人工智能观察过已知相同的对象，以便观察哪些属性保持不变。如果这是一场逻辑学研讨会，我们就会陷入困境，但既然我们是实用主义者，就可以像人类思维那样通过作弊来打破循环——视觉特征相等和位置连续变化很可能被硬连线到大脑中作为身份的信号。类似地，我们可以先确定几个良好的初始属性，提供一些带有预识别对象的样本集，让种子人工智能从中自行推导。

识别一个对象会带来哪些后果？

Rules of Objectification

1. Objects constitute a major source of regularities in reality, and many heuristics - perhaps even modality-level feature extractors - will operate on objects rather than experiences.
2. Objects often continue to exist even when they are not directly experienced, and may require continuous modeling.
3. Objects will often have internal attributes and complex, dynamic internal structure.
4. All nonvisible attributes of an object remain constant across experiences, unless there is a reason to expect them to change. (If the object has intrinsic variability, then the description of the variability remains constant.)

（作者注：关于对象的讨论或许不应放在 3.1.6 节“轨迹”中，而应放在分类一节，并且应有更长的讨论。）

3.1.6.2: 定义源、轨迹体和目的地的属性

将对象标记为“源”、“轨迹体”和“目的地”——我们暂时不使用“目标”一词——与将它们识别为“对象 1”、“对象 2”和“对象 3”有何不同？“路径”与“轨迹”在何种意义上不同？这些标签隐含了哪些期望，使用这些标签需要哪些经验作为前提？

从概念上讲，路径可以独立于穿越它的对象而存在。如果在多个场合观察到单个或多个对象精确地穿越同一条路径——或许以相同的速度——那么就可以进行泛化；可以从单次经验中提取一个观察到的特征，并验证其适用于一组不同的经验。观察路径的存在只有在观察结果反映在外部现实中时才有用——例如，滚动的球沿山坡路径运动的原因是因为有人挖了一条沟渠。种子人工智能不太可能需要处理我们所熟悉的物理轨迹，但“轨迹”的隐喻延伸到了更重要的源代码模式——一段数据可以沿着路径穿过多个函数。

类似地，促使我们将某个物体或位置识别为“源头”的条件是，一个或多个观测到的轨迹源自该源头；促使我们将某个位置识别为“终点”的条件是，一个或多个观测到的轨迹终止于该终点。对“源头”的感知之所以有用，是因为存在某种因果关系，使得该位置成为轨迹的源头，尤其是当该物体或位置实际上正在产生轨迹时——例如，投手投出球；或者，用人工智能的术语来说，如果一个函数输出数据片段，这些数据随后在系统中传播。类似地，对“终点”的感知尤其有用，如果该终点实际上使轨迹停止或将其消耗。

一个表明可能存在真实原因的线索——即对某个位置/物体作为“源头”/“路径”/“终点”的感知是有用的——是多个不同的路径/轨迹具有相同的源头或终点。想象一个随机移动的点在屏幕上快速移动，然后将该影片回放三次；源头和终点相同这一事实可能并不意味着源头和终点具有任何特殊意义；路径的其余部分也是相同的。

Rule of Variance Binding

Multiple, variant experiences sharing a single higher-level characteristic, but not others, means that the shared characteristic is likely to be significant. Multiple identical experiences can have any number of possible sources; only if at least some properties differ is there a reason to focus on a particular shared characteristic as opposed to others.

因此，对“源头”或“终点”的感知在多个轨迹共享起始位置或结束位置时存在，并且当多个不同的轨迹共享源头或终点但不共享其他特征时，这种感知更为强烈。当这种感知反映了轨迹起始或终止的根本原因时，对“源头”和“终点”的感知是有用的。

“源”或“终点”可以是多个起点或终止点共有的任何特征，而不仅仅是位置。如果手榴弹的轨迹总是终止于蓝色汽车的位置，无论蓝色汽车开到哪里，那么有理由猜测有人试图炸毁蓝色汽车——即蓝色汽车是终点。方差越大，协方差是巧合的概率就越小，绑定就越强。对终点的描述越独特——例如，蓝色汽车是唯一与所有终点共享位置的汽车，而绿色汽车和紫色汽车在其他地方——绑定就越强。如果这种绑定可以通过参照所感知的“终点”的位置来预测下一条轨迹终止的位置，那么它就是预测性的；如果移动所感知的“终点”能够改变轨迹——也就是说，如果你能通过观察蓝色汽车来猜测手榴弹将落在哪里，并通过把蓝色汽车开到那里使手榴弹落在特定位置——那么它就是操纵性的。如果绑定足够强，终点或许可以被称为“目标”（见下文）。

最后，值得注意的是，“源”和“终点”并不一定意味着轨迹体进入和退出存在。任何界定轨迹的区间，或界定轨迹的任何条件，或轨迹内的任何急剧变化，都可能使轨迹体在边界变化期间的位置变得显著。（为了执行检查多条轨迹以发现源或终点绑定的计算操作，源和终点必须是显著的——显著到足以执行发现绑定的额外处理。）

3.1.6.3: 源、路径、目标；冲量、修正、阻力与力度

在界定对某一系统采取意向立场（Intentional Stance）的含义时，通常给出的典型例子是恒温器。当温度升至某一阈值以上时，恒温器启动制冷系统；当温度降至某一阈值以下时，恒温器启动制热系统。恒温器的行为表现得仿佛它“希望”温度维持在某一特定范围内；仿佛恒温器具有目标状态，并有意抵制对该目标状态的任何改变。实际上，恒温器并不具备任何关于现实的模型，但我们仍可方便地将恒温器的行为描述为目标导向的或“意向性的”。

若要用源点、路径和目标来描述一条轨迹，则轨迹体抵达目标必须是非偶然的。若轨迹体持续受到推进，则使用“目标”一词通常意味着轨迹体的路径是自校正的——即若施加一个冲量使轨迹体偏离路径，则（来自轨迹体内部或外部的）校正机制将修正轨迹，使轨迹体继续趋近目标状态。轨迹体接近目标的方式通常是：尽管存在干扰冲量，轨迹体与目标之间的距离仍趋于持续减小。（这并非总是成立，尤其是当“轨迹体”实际上是能够绕远路的智能或半智能实体时，但读者应能理解其意。）在“目标”一词的另一种略有不同的用法中，轨迹体以恒定且不可改变的速度运动，但由于轨迹体经过了瞄准，它倾向于击中目标——或至少接近目标。（这就是“瞄准”的定义方式。）（作者注：此部分需扩展。）

阻力是指通往目标或目标状态途中的“障碍”。当我们观察到轨迹体撞上某种屏障并反弹、减速或被推回时，便会产生“阻力”的感知。其启示在于，轨迹体并非仅仅遭遇了某个随机冲量，而是存在特定的力阻止其达成某一特定目标状态或子目标状态。

强力性是指克服阻力的能力。当我们看到轨迹体施加额外的力以克服阻力时，便会产生“强力性”的感知——这种力量对人类而言具有直观的震撼力。

所有这些不仅适用于实际移动的物体，也适用于一般的目标；适用于更高层次的隐喻——相似即接近。“接近”的概念不仅适用于两个°定量属性，也适用于由多个°定性属性构成的两个结构。如果随着时间的推移，第一个结构的定性属性被逐一调整，使其与第二个结构的相应属性相匹配，那么第一个结构就在“接近”第二个结构。

从数学上讲，我们可以说一个点在由定性属性定义的多维°相空间中接近第二个点，但这过于字面化了。当两个物体越相似意味着它们越可能表现出相似的行为时，相似性的感知是有用的。当两个物体“更接近”意味着需要更少的额外工作就能使它们完全匹配时，相似即接近的隐喻是有用且°可操作的——一个物体已经变得更接近另一个物体所代表的目标。

用“接近”来表示“相似”是一个极其普遍的隐喻。“接近”被用来描述几乎任何可以“接近”目标状态的物体、事件或情境。“接近”被用作描述一般目标的隐喻。

在人类中，这个隐喻的最终基础实际上可能是人类的情感紧张状态。当我们看着某物接近目标时，我们会感到紧张；随着目标越来越近，紧张感上升……当我们观察一个射体接近目标时，同样的紧张感也会上升。接近程度越高，我们的注意力就越敏锐，我们就越警惕最后一秒可能出错的事情。空间接近与广义相似之间的隐喻，很可能是接近目标与接近目的之间更强隐喻的影子。

一般来说，用对人类情感的盲目模仿来拖累人工智能是个坏主意。甚至可能没有必要复制这个隐喻；我并不完全确定空间到相似的隐喻对智能有贡献。但似乎很可能，随着事件接近目标状态，人工智能会经历（或学习）某种类型的注意力增强。

对于我们这些生活在物理世界中的人类来说，试图让一个物体达到某个特定位置是最常见的目标状态之一；位置是最常被操控以达到目标状态的属性之一。事实上，可以说我们本能地应用了“状态即位置”的隐喻。也许人工智能会为源代码学习一套类似的广泛隐喻。

可能应该有某种模态层面的支持，来指示接近目标的感觉，这样“接近目标”的概念就非常接近表面，跨任务和模态的泛化就很容易被注意到。“接近”的想法是一个突破口，一种沿着揭示重要规律性的线条来分割现实的方式；在一个任务中朝向目标的“轨迹”行为，通常与其他任务中轨迹的行为有有用的相似之处。

版本历史

2001 年 5 月 18 日：GISAI 2.3.02。将原始文档“编码一个超人类 AI”拆分为《通用智能与种子 AI》和《创造友好 AI》。进行了少量杂项错误修复。GISAI 现在为 349K。

2001 年 4 月 24 日：GISAI 2.3.01。上传了可打印版本。进行了一些建议的小错误修复。删除了大部分提及“Eliezer Yudkowsky”的内容，以更清楚地表明 GISAI 是奇点研究所的出版物。

2001 年 4 月 18 日：GISAI 2.3.0。（此版本号之前反映了《创造友好 AI》的添加，该文档后来成为独立文档。）将版权更改为“2001”和“奇点研究所”，而不是遗留的“2000”和“Eliezer Yudkowsky”。上传了多页版本。

2000 年 9 月 7 日：GISAI 2.2.0。新增 3.1 节：时间与线性以及插曲：共识与玛雅之幕。上传了旧的错误修复。358K。

2000 年 6 月 25 日：GISAI 2.1.0。新增附录 A：术语表和版本历史。进行了大量编辑、重写和文字润色。220K。未发布。

2000 年 5 月 18 日：GISAI 2.0a。《通用智能与种子人工智能》最初名为《编码一个超人类人工智能》。由于当时奇点研究所尚不存在，CaTAI 的版权归 Eliezer S. Yudkowsky 所有。180K。

附录 A: 术语表

NOTE: If a referenced item does not appear in this glossary, it may be defined in *Creating Friendly AI*.

- affector
- API
- atto
- Bayesian binding
- Bayesian Probability Theorem
- cache
- CFAI
- codelet
- computational horizon
- computational temperature
- Consensus
- continuous
- Copycat
- counterfactual
- crystalline
- cytoarchitecture
- declarative
- Deep Blue
- discrete
- e.g.
- Eurisko
- exa
- femto
- GEB
- gender-neutral pronouns
- giga
- GISAI
- granularity horizon
- hertz
- heuristic
- holism
- horizon
- i.e.
- iff
- instantiate
- intelligence
- intentionality
- Kasparov
- kilo
- Lakoff and Johnson
- latency
- Law of Pragmatism
- Life
- LISP tokens
- Marr
- mega
- micro
- microworld
- milli
- mindstuff
- MITECS
- nano
- Necessary, But Not Sufficient
- ontology

- ontotechnology
- orthogonal
- past light cone
- peta
- Physicist's Paradigm
- pico
- predictive horizon
- procedural
- Q.E.D.
- qualia
- qualitative
- quantitative
- reductholism
- reductionism
- reflection
- relevance horizon
- RNUI
- salience
- scalar
- search trees
- seed AI
- sensory modality
- SIAI
- space of simultaneity
- SPDM
- stochastic
- structural
- subjunctive
- tera
- three
- time
- Turing-computability
- ve
- ver
- verself
- vis
- world-model

-
- **影响因素**：将在未实现部分：因果关系中定义。“影响因素”是一个因子，是影响事物的东西，是产生效果的东西。它与将某物描述为原因或因子有细微差别；介于两者之间。这个术语很有用，因为我经常发现没有其他术语具有我想要使用的确切内涵。说 A 导致 B 就是说 A 完全解释了 B。A 可以影响 B 而不完全解释 B。此外，将某物描述为“原因”通常是将其描述为因果链上的一个中间点；也就是说，原因是结果和影响因素的结合；将某物描述为“影响因素”则只向前看，而不是既向前看又向后看。“原因”常常承载着其他含义，没有“影响因素”那样的精确性。最后，“原因”既是名词又是动词，而“影响因素”明确是名词，这种术语上的差异微妙地影响了我们思考因果关系的方式。所以请原谅这个术语。
 - **应用程序编程接口**：应用程序编程接口（Application Programming Interface）。将库与程序员分隔开来的膜。程序员可用来与操作系统、商业代码库、互联网浏览器等进行通信的一组函数、对象、方法、属性、格式和数据结构。本质上，应用程序编程接口是系统输入和输出的结构。
 - **阿托**： 10^{-18} . 一幺分之一；千分之一“飞”。参见《黑客词典》中的完整量词列表。
 - **贝叶斯 绑定**：指一条信息与其推导出的结论之间的关联强度，依据贝叶斯概率定理（**Bayesian Probability Theorem**）。某一模式越不可能出现，该模式由纯粹巧合产生的可能性就越低。假设你将硬币甲抛掷三十次，再将硬币乙抛掷三十次，而正反面的排列完全一致。对于公平且相互独立的硬币而言，这是十亿分之一的极小概率，因此两个模式之间存在极强的贝叶斯绑定，使观察者得出结论：几乎可以肯定有某种原因将两枚硬币联系在一起。在元理性（meta-rationality）的讨论中，贝叶斯概率定理被用来估计你的信念与现实之间的绑定强度——即你相信某命题这一事实在多大程度上允许你推断该命题为真。假设我观察到我自己说：“天空是绿色的。”如果我知道自己对天空之绿的信念如此强烈，以至于即使天空是最纯净的蓝宝石蓝，我也会宣称天空是绿色的，那么根据贝叶斯概率定理，我观察到我自己说“天空是绿色的”这一事实，对天空的实际颜色没有任何说明。

天空是绿色的可能性。这种效应——即我会看到自己相信“天空是绿色的”——在天空是绿色的群体和天空是蓝色的群体中都被预测到；因此，这一观察并不能表明实际天空属于哪个群体。另一方面，如果我不太关心天空的颜色，那么只有当天空实际上是绿色时，我才可能说天空是绿色的，而我观察到自己做出这一陈述则是支持天空绿色性的有力证据。那关于信仰又是怎么回事？

- **贝叶斯 概率定理：**贝叶斯概率定理将观测到的效应与这些效应的先验概率联系起来，以估计潜在原因的概率。例如，假设你知道以下信息：1% 的人口患有癌症。癌症检测中假阴性的概率为 2%。癌症检测中假阳性的概率为 10%。你的检测结果呈阳性。你患癌症的概率是多少？人类的本能反应是恐惧。毕竟，假阳性的概率只有 10%；那么你患癌症的概率难道不是 90% 吗？贝叶斯概率定理证明了这种推理为何有缺陷。在一组 10,000 人中，100 人患有癌症，9,900 人未患癌症。如果对这 10,000 人进行癌症检测，将产生四组结果。第一组，8,910 人未患癌症且检测结果为阴性。第二组，990 人未患癌症且检测结果为阳性。第三组，2 人患有癌症且检测结果为阴性。第四组，98 人患有癌症且检测结果为阳性。在接受检测之前，你可能属于这四组中的任何一组；贝叶斯概率定理表明，你患癌症的概率等于 $(2 + 98)/(8,910 + 990 + 2 + 98)$ ，即 $1/100$ 或 1%。如果你的检测结果呈阳性，现在已知你属于第二组或第四组。你患癌症的概率为 $(98)/(990 + 98)$ ，即 $49/544$ 或约 9%。如果你的检测结果呈阴性，已知你属于第一组或第三组；你患癌症的概率为 $2/8,912$ 或约 0.02%。通俗地说，只要先验概率对问题的结果有重大影响，就会援引好牧师贝叶斯。然而，贝叶斯概率定理的应用范围要广泛得多——在规范推理中，贝叶斯概率定理控制着所有感官信息与所有信念之间的结合。规范推理者因此常被称为“贝叶斯推理者”。贝叶斯概率定理如此普遍且如此精妙，以至于我会将其作为极少数反例之一，来反驳[°]实用主义定律——例如，在 CFAI 3.1.4：贝叶斯强化中，我讨论了痛苦和快乐的部分功能，虽然在人类中由独立的硬连线系统实现，但在规范推理者（即[°]友好人工智能）中可以直接从贝叶斯概率定理中涌现。

- **缓存：**“缓存”一个结果是指将其存储起来以备后用。例如，您的网络浏览器有一个“缓存文件夹”，其中包含您已经从互联网下载的文件；当浏览器遇到一个已经访问过的网址时，它可以从缓存文件夹中检索该文件，而无需再次下载。

- **CFAI：**“创建友好人工智能”的缩写，这是奇点人工智能研究所的一份出版物。位于 <http://singinst.org/CFAI/index.html>

- **代码片段：**一段独立的代码——一段可以被分离或重新附加的代码，或者一段可以独立浮动的代码。霍夫施塔特和米切尔的[°] Copycat 使用基于代码片段的架构来实现感知；形成键的代码片段被投放到工作区中以形成键。如果[°] 计算温度升高，断键代码片段就会被投放到工作区中。代码片段的概念并不意味着“守护进程”的自由浮动状态，也不意味着“智能体”的程序化个体主义（这两个概念来自传统人工智能，是有缺陷的）。代码片段之于函数，就如同对象之于数据结构。代码片段是一个被视为独立事物的函数，具有自身的属性、特征和行为，可以自由移动或被移动。

- **计算 视野：**问题的范围。需要投入到一项任务中的计算能力的大小。在“视野”之外，是所有与任务无关的事实、所有过于精细而无法用可用计算能力处理的细节、所有过于模糊或不重要而无法预测的后果等等。确定计算视野的位置通常会对认知任务的质量和速度产生重大影响。参见[°] 预测视野、[°] 粒度视野和[°] 相关性视野。

- **计算 温度：**霍夫施塔特和米切尔的“模仿猫”（Copycat，一个解决类比问题的人工智能）中用于控制系统随机性和灵活性程度的一种技术。当计算温度高时，联结容易断裂和形成；探索路径的选择更具随机性。当计算温度低时，联结不易断裂，只探索更优的可能性。在模仿猫中，计算温度与当前认知结构的优良程度相关联。优雅的对对应关系会降低温度；冲突则会升高计算温度。因此，例如，模仿猫可能一开始看到一组看似合理的联结。这会降低计算温度。随着更多感知的建立，计算温度持续下降，直到检测到冲突——例如，一个额外的对应关系，或对应关系的缺失，破坏了一对一映射。这会升高计算温度；有问题的感知结构——联结、组、对应关系——溶解；一组新的结构，希望更优雅，有机会形成。一个有趣的副作用——除了模仿猫能成功解决类比问题这一事实之外——是最终的计算温度提供了一个衡量模仿猫答案优雅程度的良好指标。模仿猫中较低的计算温度与人类观察者认为优雅的类比问题答案相当吻合。在某些方面，模仿猫的计算温度可能是第一种真正的人工情感。

- **共识：**定义于间奏：共识与摩耶之幕。该术语指全人类共享但并非与外部现实完全一致的感知。紫色、彩虹中的色带以及社会/政治感知是极端例子，但我们没有任何感知与外部现实完全精确一致。实际上没有人生活在外部现实中，即使生活在其中也无法理解它；夸克太多，四处飞散。当我们走过走廊，看着地板、墙壁和天花板从身旁掠过时，实际上是在自己的视觉皮层内行走。尽管如此，共识通常与外部现实具有极其紧密的[°] 感官、[°] 预测和[°] 操控绑定，因此规则同样严格。如果一个对象或描述属于共识而非外部现实，并不意味着该描述是任意的。这确实意味着你可能难以用数学方式定义该描述，或找到坚实的哲学基础，或发明一个百分之百有效的定义。99.99% 几乎总是足够好的。

- **continuous:**
Can be divided and subdivided indefinitely. Contrast to °discrete.
- **Copycat:** Defined in 2.3: Concepts.
An AI, written by Melanie Mitchell and conceived by Douglas R. Hofstadter, which tries to solve analogy problems in the microdomain of letter-strings.

If	'abc'	goes	to	'abd'	For	what	does	'bcd'	go	to?
If	'abc'	goes	to	'abd'		what	does	'pqrs'	go	to?
If	'abc'	goes	to	'abd'		what	does	'vuts'	go	to?
If	'abc'	goes	to	'bcd'		what	does	'pqrs'	go	to?
If	'abc'	goes	to	'bcd'		what	does	'ace'	go	to?
If	'abc'	goes	to	'bcd'		what	does	'lwmb'	go	to?

If 'abc' goes to 'abd', what does 'xyz' go to? (Bear in mind that Copycat has no concept for "circularity".)
Copycat solves these problems through a *perceptual* architecture. It mentally builds up a structure of bonds, groups, correspondences, concept-mappings, until it has a "rule" for the first transition that can be applied to the second transition. If the rule can't apply, or can't apply well, then new cognitive pressures come into play, breaking down previously perceived perceptions and allowing new groups and correspondences and rules to form.
Note that Copycat doesn't select the correct answer from a list of alternatives; it actually °invents the answer, which is very impressive and very rare. Copycat is a really fascinating AI, and you can read about it in *Metamagical Themas*, or read the source code (it's a good read, and available as plain text online - no decompression required).
- **counterfactual:**
A what-if scenario deliberately contrary to reality; e.g. "What if I *hadn't* dropped that glass of milk?" See also °subjunctive.
- **crystalline:** Defined in 1.1: Seed AI.
Loosely speaking, "crystalline" is the opposite of "rich" or "organic". If vast loads of meaning rest on the shoulders of individual computational tokens, so that a single error can break the system, it's crystalline. "Crystalline" systems are the opposite of "rich" or "organic" error-tolerant systems, such as biological neural networks or seed-AI mindstuff. Error-tolerance leads to the ability to mutate; mutation leads to evolution; evolution leads to rich complexity - networks or mindstuff with lots of tentacles and connections, computational methods with multiple pathways to success.
- **cytoarchitecture:**
"Cytoarchitecture" refers to the general way neurons connect up in a given lump of neuroanatomy - many-to-many, many-to-one, and so on.
- **declarative:**
The distinction between "procedural" and "declarative" knowledge/skill/information is one of the hallowed dichotomies of traditional AI. Although the boundary isn't as sharp as it's usually held to be - especially in seed AI - the distinction is often worth making.
Your knowledge of how to walk is "procedural" and is stored in procedural form. You don't say to yourself: "Right leg, left leg, right leg, left leg." All the knowledge about how to balance and maintain momentum isn't stored as conscious, abstract, *declarative* thought in your frontal lobes; it's stored as unconscious *procedural* thought in your cerebellum and spinal cord. (Neurological stereotyping included for irony.)
Inside source code, the procedural/declarative distinction is even sharper. A piece of code that turns on the heat when the temperature reaches 72 and turns on the air conditioning when the temperature reaches 74, where 72 and 74 are hard-coded constants, has *procedurally* stored the "correct" temperature of 73. The number "73" may not even appear in the program.
A piece of code that looks up the "target temperature" (which happens to be 73) and twiddles heat or A/C to maintain that temperature has *declaratively* stored the number 73, but has still *procedurally* stored the method for maintaining a temperature. It will be easy for the programmer - or for internally generated programs - to refer to, and modify, the "target temperature". However, the program still doesn't necessarily know how it's maintaining the temperature. It may not be able to predict that the heat will go on if the temperature reaches 72. It may not even know that there's such a thing as "heat" or "air conditioning". All that knowledge is stored in procedural form - as code which maintains a temperature.
In general, procedural data is data that's opaque to the program, and declarative data is data that the program can focus on and reason about and modify. Seed AIs blur the boundary by analyzing their own source code, but this doesn't change the basic programmatic truth that declarative=good and procedural=bad.
- **Deep** **Blue:**
The chess-playing device that finally beat the human champion, °Kasparov. A great, glorified search tree that beat Kasparov essentially through brute force, examining two billion moves per second. Built by IBM.
- **discrete:**
Composed of a finite number of parts which cannot be further divided. Contrast to °continuous.
- **e.g.:**
Exempli gratia; Latin, "for example".
- **Eurisko:**
Eurisko was the first truly self-enhancing AI, created by Douglas B. Lenat. Eurisko's mindstuff - in fact, most of the AI - was composed of °heuristics. Heuristics could modify heuristics, including the heuristics which modified heuristics.
I've never been able to find a copy of Eurisko's source code, but, by grace of Jakob Mentor, I have obtained a copy of Lenat's original papers. It turns out that Eurisko's "heuristics" were arbitrary pieces of LISP code. Eurisko could modify heuristics because it possessed "heuristics" which acted by splicing, modifying, or composing - in short, mutating - pieces of LISP code. Many times this would result in a new "heuristic" which caused a LISP exception, but Eurisko would simply discard the failed heuristic and continue. In a sense, Eurisko was the first attempt at a seed AI - although it was far from truly self-swallowing, possessed no general intelligence, and was created from °crystalline components.
Engines of Creation (by K. Eric Drexler) contains some discussion of Eurisko's accomplishments.
- **exa:**
10¹⁸. One billion billion; a thousand "°peta". See the Hacker's Dictionary for the full list of quantifiers.
- **femto:**
10⁻¹⁵. One-quadrillionth; a thousandth of a "°pico". See the Hacker's Dictionary for the full list of quantifiers.
- **GEB:**
Gödel, Escher, Bach: An Eternal Golden Braid by Douglas R. Hofstadter. This book is *mandatory* reading for all members of the human species.

- gender-neutral**

°Ve, °vis, °ver, °verself. I was forced to start using gender-neutral pronouns when referring to intelligent AIs, since to use "he" or "she" would imply cognitive hardware that such an AI would very specifically *not* have.

I realize that these pronouns strike people as annoying the first time around. I'm sorry for that, and I truly regret having to annoy my readers, but "it" is simply inadequate to refer to AIs. Not only is "it" used as a pronoun for inanimate matter, but "it" is also a general anaphor, like "this" or "that". "It" can refer to anything at all in a sentence, not just the AI, so complex sentences - especially ones that use "it" for other purposes - become impossible to parse syntactically. Sometimes a sentence can be rewritten so that no pronoun is necessary, but for sentences with multiple pronoun references, this rapidly becomes either impossible, or too tangled. I would rather use unusual words than tangled syntax. At least "ve" gets easier to parse with time.

At one point I was using "ve" to refer to a human of indefinite gender, but I have since realized that this is just as inaccurate as referring to an AI as "he" or "she". I now keep a coin near my computer that I flip to decide whether a human is "he" or "she". (No, I haven't fallen into the bottomless pit of political correctness. Everyone has the right to use whatever language they like, and I can flip a coin if I want to. Your right to use "he" implies my right to flip a coin. Right?)
- giga:**

10^9 . One billion; a thousand "mega". See the Hacker's Dictionary for the full list of quantifiers.
- GISAI:**

"General Intelligence and Seed AI". An abbreviation for this document. Permanent location: <http://singinst.org/GISAI/index.html>
- granularity**

horizon:

The fineness of the detail that needs to be modeled. How much °reductionism needs to be applied to capture all the relevant details. The tradeoff between expenditure of computing power, and the benefits to be gained from finer modeling.

Every time your eye moves, the amount of processing power being devoted to each part of the visual field changes dramatically. ("The cortical magnification factor in primates is approximately inversely linear, at least for the central twenty degrees of field." "It has been estimated that a constant-resolution version of visual cortex, were it to retain the full human visual field and maximal human visual resolution, would require roughly 10^4 as many cells as our actual cortex (and would weigh, by inference, roughly 15,000 pounds).") °MITECS, "Computational Neuroanatomy".) And yet we can watch an object rotating, so that different parts move all over the visual cortex, and it doesn't appear to distort.

Every time you change scale or the level of detail at the °modality level of representation, the data may wind up going into essentially a different format - at least, from the perspective of someone trying to detect identity by bitwise comparison. Even adding or subtracting pieces of the puzzle, without changing scale, can be a problem if the AI has painstakingly built up a perceptual tower that doesn't take well to tampering with the foundations. Cognitive methods need to be able to take these kinds of random pushes and shoves. "Error-tolerance" isn't just important because of actual *errors*, but because all kinds of little flaws naturally build up in a cognitive task, as the result of cognition.

See °computational horizon.
- hertz:**

A measure of frequency, equal to 1 cycle per second. A neuron that fires 200 times per second is operating at 200 Hz. CPU clock speeds are currently measured in °megahertz (MHz) or °gigahertz (GHz).
- heuristic:**

I use the term to refer to any piece of knowledge which provides a rule of thumb - anything from "Don't rest your hand on a hot stove" to "Try to control the center of the chessboard".

Some other definitions: Douglas Lenat once wrote an AI called °Eurisko in which the mindstuff - in fact, practically the entire AI - was composed of "heuristics" which could modify other heuristics, including the heuristics doing the modifying. For example, "investigate extreme cases" was modified by a heuristic to yield "investigate cases *close* to extremes". (Douglas Lenat went on to state that "Heuristics are compiled hindsight; they are judgemental rules which, if only we'd had them earlier, would have enabled us to reach our present state of achievement more rapidly.") In classical AI, a "heuristic" is usually a function used to prune °search trees by indicating branches which are likely or unlikely to be desirable.
- holism:**

Holism: The attitude that the whole is greater than the sum of the parts. To take the holistic view is to look upward, focus on the high-level properties. See °reductionism and °reductholism. See also Gödel, Escher, Bach: An Eternal Golden Braid, particularly the dialogues "Prelude" and "Ant Fugue".

"No one in his right mind could deny holism." -- °GEB
- horizon:**

See °computational horizon.
- i.e.:**

Id est; Latin for "that is"; usually used to mean "in other words".
- iff:**

"Iff" is shorthand for "if-and-only-if".
- instantiate:**

Loosely, program A "instantiates" program B if it can perfectly simulate program B. An "instantiation" of a program is a running copy of that program.

This issue actually gets waaay more complicated, but I'm not going to inflict that on you now. Maybe later. Nobody has ever come up with a mathematical definition of "instantiation", but it's a useful concept.
- intelligence:**

Defined in 2.1: World-model.

What is intelligence? In the case of humans, intelligence *is* a brain with around 40 billion neurons, and 104 °cytoarchitecturally distinct areas in the cerebral cortex alone. What intelligence *is* is the subject of this whole web page.

The *cause* of intelligence can be more succinctly described: Evolution is the cause of intelligence, and intelligence is an evolutionary advantage because it enables us to model, predict, and manipulate reality. Or rather, it enables us to model, predict, and manipulate *regularities* in reality.
- intentionality:**

Defined in 3.1: Time and Linearity.

Behaving in such a way as to give rise to the appearance of deliberate, goal-oriented behavior. The classic example is the corrective action of a thermostat; by switching on the heat when the temperature drops below a certain point, or switching on the air-conditioning when the temperature rises above a certain point, a thermostat gives the appearance of "wanting" the temperature to stay in a certain range. We can take the *design stance* and talk about cause and effect in sensors and circuits, or take the *physical stance* and talk about

the underlying atoms, but it's usually most convenient to take the *intentional stance* and say that the thermostat maintains a certain temperature.

- **Kasparov:**
Gary Kasparov, the human who finally lost the world chess championship to °Deep Blue.
- **kilo:**
10³. One thousand. See the Hacker's Dictionary for the full list of quantifiers.
- **Lakoff** and **Johnson:**
George Lakoff and Mark Johnson, coauthors of *Metaphors We Live By* and *Philosophy in the Flesh*. George Lakoff is also the author of *Women, Fire, and Dangerous Things*, a book about cognitive categories.
- **latency:**
Latency describes delays, specifically delays introduced by *communication* rather than local processing, and *irreducible* delays rather than delays caused by sending a large amount of data. Most commonly used in discussion of computer networks and hardware systems. The *latency* on a motherboard is, for example, the time it takes a message from the CPU to reach a video card. The *latency* between nodes of a network is the time it takes for a message from node A to reach node B. For a fine explanation of why "latency" is entirely distinct from "bandwidth" - adding an identical second channel doubles bandwidth but does not affect latency at all - see "It's the Latency, Stupid".
Note that our Universe specifies that the minimum latency between two nodes will be at least one second for every 186,000 miles. The latency between two nodes 300 microns apart must be at least one picosecond.
Anders Sandberg, in "The Physics of Information Processing Superobjects: Daily Life Among the Jupiter Brains", suggests the measure *S* of the "diameter" of a single mind, where *S* is the ratio of the clock speed to the latency between computing elements. (*S* = distance / (clock speed * message speed)). Anders goes on to note that the human brain has *S* ~ 1 (56). An oft-voiced conjecture is that the subjective "feel" of having a single, unified mind may require *S* <= 1. (As far as I know, this conjecture is only applied to °superintelligences, and nobody has suggested that *S* played a role in shaping human neurology.)
- **Law of Pragmatism:** Defined in 1.2: Thinking About AI.
Any form of cognition which can be mathematically formalized, or which has a provably correct implementation, is too simple to contribute materially to intelligence.
- **Life:**
So, you want to know the meaning of life, eh?
When capitalized, "Life" usually refers to Conway's Game of Life, a two-dimensional cellular automaton. Cells are laid out in a square grid, and cells can either be alive or dead. Each cell is affected only by the eight cells around it. With each tick, these rules are applied to each cell:
1: A cell with fewer than two living partners becomes or remains dead.
2: A cell with two living partners maintains its current state.
3: A cell with three living partners becomes or remains alive.
4: A cell with four or more living partners becomes or remains dead.
These rules are enough to generate almost endless variance.
As for the age-old controversy among biologists about how to define "life", I suggest the following: "Life is anything designed primarily by evolution, plus anything that counts as a person." Note that this definition includes mules, excludes computer viruses, includes biological viruses, and (by special clause) includes designed minds smart enough to count as people.
- **LISP** tokens:
LISP is a programming language, the traditional language of AI.
"LISP" stands for "List Processor". In LISP, everything is made from lists, including the code. For example, a piece of code that adds 2 and 2 would be (plus 2 2). This code is a list composed of three tokens: plus, 2, and 2. If "num1" was a LISP token that contained the value of 2, the code could be written (plus num1 2) and would return 4.
When I say that classical AI is built from suggestively-named LISP tokens, I mean that the classical AI contains a data structure reading ((is(food hamburger)) (is(eater human)) (can-eat (eater food))); the classical AI then deduces that a "human" can "eat" a "hamburger", and this is supposed to be actual knowledge about hamburgers and eating. What the AI really knows is that a G0122 can H8911 a G8733. Drew McDermott pointed this out in a famous article called "Artificial Intelligence Meets Natural Stupidity".
(LISP does have one real property which is important to AI, however; the code and the data structures follow the same format, making LISP the single premier language for self-modifying code. A true AI would probably read C++ as easily as LISP, since the amount of complexity needed to parse code is comparatively trivial relative to the amount of cognitive complexity needed to *understand* code. Even so, using a language well-suited to self-modification may simplify the initial stages of the AI where self-improvement is mostly blind. Since LISP is getting ancient as programming languages go, and linked lists are awkward by today's standards, I've proposed a replacement for LISP called "Flare", which (among many other improvements) would use XML instead of linked lists. Even so, of course, putting faith in the token level of Flare would be no better than putting faith in the token level of LISP. At most, Flare might be well-suited to programming sensory modalities and mindstuff. It would be nice to have such a language, since none of the existing languages are really suited to AI, but it's more likely that we'll just hack something up out of Python - during the initial stages, at least. For more about Flare, see the obsolete document *The Plan to Singularity*.)
- **Marr:**
David Marr pioneered the field of computational neurology - in particular, the computational theory of vision. It is almost impossible to convey the magnitude of Marr's contribution to AI. Marr was the first person who *did the work* and *wrote the code* necessary to embody a piece of cognition. He was the first person to propose a theory of AI that wasn't oversimplified to the point of caricature - the first theory to correctly identify the token level of processing. Reading a document like *General Intelligence and Seed AI*, which is essentially *built* on top of David Marr's paradigms, it's hard to convey what the field was like before him.
David Marr died of leukemia in 1980, at the age of thirty-five.
- **mega:**
10⁶. One million; a thousand ""kilo". See the Hacker's Dictionary for the full list of quantifiers.
- **micro:**
10⁻⁶. One-millionth; a thousandth of a ""milli". See the Hacker's Dictionary for the full list of quantifiers.
- **microworld:** Defined in 2.1: World-model.
A microworld is a virtual environment in which the AI can learn and grow. Programmatically, such a world would consist of a simulated external environment, plus an AI watching the simulated external environment through a simulated camera or some other kind of simulated sensory system, and possibly altering the simulated external environment through some kind of simulated fingers, simulated cue sticks (for a billiard-ball world), or other simulated manipulators. Henceforth I will leave out the word "simulated" - the AI is living in a

very real external environment, just one that happens to be implemented on transistors instead of quarks. (Actually, "implemented on transistors *as well as* quarks" might be a better way of putting it.) The environment, to us, is "inside the computer", but it is still outside the AI.

- **milli:**
10⁻³. One-thousandth. See the Hacker's Dictionary for the full list of quantifiers.
- **mindstuff:** Defined in Executive Summary and Introduction.
Mindstuff is the basic substrate from which the AI's permanently stored cognitive objects (and particularly the AI's concepts) are constructed. If a cognitive architecture is a structure of pipes, then mindstuff is the liquid flowing through the pipes.
The mindstuff of classical AI is °suggestively named LISP tokens. The mindstuff of connectionist AI is neurons (neuroids, rather) plus the neuroid learning behaviors created by the training algorithms. Of course, the comparison is deceptive, since neither classical nor connectionist AI have a lower modality layer or a higher thought layer.
Insofar as seed AI has a "stuff that concepts are made of", it might be described as °reductholic multilevel descriptions subject to conscious and autonomic manipulation", with the ultimate substrate probably being interpreted source code (in the early stages) or AI-coded assembly language (in the later stages).
- **MITECS:**
The MIT Encyclopedia of the Cognitive Sciences. Wilson and Keil, 1999. A truly excellent book containing 471 short articles about topics in the cognitive sciences. See also my review in the Bookshelf.
- **nano:**
10⁻⁹. One-billionth; a thousandth of a °micro". See the Hacker's Dictionary for the full list of quantifiers.
- **Necessary, But Not Sufficient:** Defined in 1.2: Thinking About AI.
A design feature may be Necessary for intelligence, but that does not mean it is Sufficient. The latest fad AI may use "the same parallel architecture found in the human brain", but it will also use the same parallel architecture found in an earthworm's brain.
- **ontology:**
The basic level of reality. Our ontology involves quarks, spacetime, and probability amplitudes. The ontology of a °Life game consists of dead cells, live cells, and the cellular-automaton rules. The ontology of a Turing machine is the state transition diagram, the read/write head, and an infinitely long tape with ones and zeroes written on it.
- **ontotechnology:**
Ontotechnology is what you move on to when you're bored with nanotechnology and megascale spacetime engineering. "Ontotechnology" is the art of meddling with underlying reality, and refers to technologies that change the laws of physics, create new Universes, or - this is the best part - *change the kind of things that can be real*. Quarks are real, which we understand. If you believe that °qualia are °objectively real - I do, but in my personal capacity, not my °SAI capacity - then thoughts and experiences and perceptions can also apparently be made °objectively real. If we can create qualia, why not make *other* things real too? Why not turn the laws of physics into material substances that can be manipulated directly? Heck, you could even tamper with the First Cause and make the whole of Reality go out like a candle!
I invented the idea of ontotechnology. Did you guess?
- **orthogonal:**
A mathematical term; in geometry, it means perpendicular. Colloquially, two variables that can change independently of each other; not necessarily mutually irrelevant, but decoupled. See also the entry in the Hacker's Dictionary.
- **past light cone:**
The set of all events in causal contact with a given spacetime point. The past light cone is the space of all events from which a ray of light could have reached the current event. The future light cone is the space of all events that can be reached by a ray of light from the current event. Any event occurring outside our past light cone can have no causal impact on this moment.
- **peta:**
10¹⁵. One million billion; a thousand °tera". See the Hacker's Dictionary for the full list of quantifiers.
- **Physicist's Paradigm:** Defined in 1.2: Thinking About AI.
The idea that advances in AI will be characterized by the discovery of a single bright idea that explains everything yet fits on a T-Shirt; e.g. "Physical Symbol Systems", "expert systems", "parallelism", "neural networks". Confusing the task of a physicist, who "explains" a skyscraper by reference to molecular dynamics, with the task of the engineer who must design that skyscraper.
- **pico:**
10⁻¹². One-trillionth; a thousandth of a °nano". See the Hacker's Dictionary for the full list of quantifiers.
- **predictive horizon:**
How far into the future the consequences of an event need to be projected. The amount of computing power devoted to projecting the consequences of an action. In °Friendly AI, the °computational horizon for disaster-checking.
Humans seem to do very well at recognizing the need to check for *global* consequences by perceiving *local* features of an action. It remains to be seen whether this characteristic of 10¹⁴ x 200Hz synapses can be duplicated in N 2GHz CPUs. See CFAI 3.2.2: Layered mistake detection.
- **procedural:**
See °declarative.
- **Q.E.D.:**
Quod erat demonstrandum; Latin for "So there!"
- **qualia:**
The substance of conscious experience. "Qualia" is the technical term that describes the **redness of red**, the mysterious, indescribable, apparently irreducible quality of **redness** that exists above and beyond a particular frequency of light. If a JPEG viewer stores a set of red pixels, pixels with color 0xFF0000, does it see red the way we do? No. Even if a program simulated all the feature-extraction of the human visual °modality, would it actually *see red*?
I first "got" the concept of qualia on reading the sentence "You are not the person who speaks your thoughts; you are the person who hears your thoughts." (57).
See "Facing Up to the Problem of Consciousness" by David Chalmers for a more extensive definition.
- **qualitative:** Defined in 2.1: World-model.
Qualitative properties are selected from a finite set; for example, the binary set of {on, off}, or the eighty-eight member set of "piano keys". A *qualitative match* is when two qualities have identical values. A *qualitative binding* is when the two qualities are hypothesized to be bound together - if, for example, the same item of the 88-member set "piano keys" occurs in two instances. A qualitative binding is the

weakest type of binding, since it can often occur by sheer coincidence. However, the larger the set, the less likely a coincidence. Small integers are usually qualitative properties; large integers should be treated as quantitative. See also °SPDM, °quantitative binding, and °structural binding.

- **quantitative:** Defined in 2.1: World-model.
Quantitative characteristics occupy a continuous range; they are selected from a range of real (i.e., floating-point) numbers. A *quantitative match* is when two quantities are identical. A *quantitative binding* occurs when two or more quantitative variables are equal to sufficient precision that coincidence is effectively impossible. Quantitative bindings can also be established by covariance or other quantitative relations. See also °SPDM, °qualitative, °structural.
- **reductholism:**
A word appearing in Gödel, Escher, Bach. "Reductholism" is a synthesis of °reductionism and °holism; I use it to indicate the general theory of systems with multiple levels, including both the holistic disciplines of looking up and the reductionist disciplines of looking down. See also °reductionism and °holism.
- **reductionism:**
Reductionism: The attitude that the whole is the sum of the parts. To take the reductionist view is to look downward, focus on the low-level elements and the rules governing their interactions. See °holism and °reductholism. See also Gödel, Escher, Bach: An Eternal Golden Braid, particularly the dialogues "Prelude" and "Ant Fugue".
"No one in his left brain could deny reductionism." -- °GEB
- **reflection:** Defined in 2.4: Thoughts.
The ability of a thinking system to think about itself. A reflective mind is one that has an image of itself; a self-model. In °Friendly AI, a reflective goal system is one that can regard its own components and content as desirable or undesirable. In mundane programming, a "reflective" programming language is one in which code can access information about code (for example, obtaining a list of all the methods or properties of an object).
- **relevance** **horizon:**
The Universe goes on forever, and what we can say about it goes on even longer. Outside the "relevance horizon" lie all the knowledge and °heuristics and skills that are not relevant to the task. See °computational horizon.
Humans and AIs probably have *very different* relevance horizons.
- **RNUI:** Defined in Interlude: Represent, Notice, Understand, Invent.
Represent, Notice, Understand, Invent. First your AI has to *represent* something, then it has to *notice* it, then it has to *understand* it, then *invent* it. You can't take these items out of sequence.
Representing means having the static data structures to hold the information.
Noticing means being able to see simple relations, to perceive internal coherence; to tell the difference between a representation that makes sense, and a representation composed of random numbers.
Understanding means being able to see goal-oriented properties, and how the thing understood fits into the larger structure of the Universe - the thing's functionality, the causes of that thing's characteristics, and so on.
Inventing means being able to start with a high-level goal - "rapid transportation" - and design a bicycle.
- **salience:**
How much attention we're paying to something. The salient event/object is the focus of attention (or *a* focus of attention); the salient event/object occupies the foreground of the mind, rather than the background.
Deciding what to pay attention to is often a significant part of the problem.
- **scalar:**
A single number, as opposed to two or more numbers. The *speed* of an airplane is a scalar quantity; it can be described by a single number. The *velocity* of an airplane, which includes the direction as well as the speed, is a vector - it must be described by two numbers. (Three numbers, if it's a three-dimensional airplane.)
There's a timeworn joke about mosquitoes and mountain climbers that is usually mentioned at this point, but forget it.
- **search** **trees:**
One of the most venerable tools of AI. In a game of tic-tac-toe, you can make any of nine possible moves, then I can make any of eight possible moves, then you can make any of seven possible moves... The computational representation of the game - in a classical AI - would look like a tree; a single node representing the start of the game, with nine branches leading to nine first-move nodes; each first-move node would have eight branches leading to a total of seventy-two possible second-move nodes, and so on. By searching through the entire tree, a classical AI could play a perfect game of tic-tac-toe.
It is possible, even likely, that human cognition involves the use of similar (although much messier) search trees. Or not.
- **seed AI:** Defined in 1.1: Seed AI.
An AI designed for self-understanding, self-improvement, and recursive self-improvement. See 1.1: Seed AI, or the introductory article "What is Seed AI?" on the Singularity Institute's website.
- **sensory modality:** Defined in 2.2: Sensory modalities.
A sensory modality, in an AI, is a module analogous to the human visual cortex, the human auditory cortex, or some other chunk of neurology underlying one of the senses. A modality contains the data structures needed to represent the target domain; the active processing which enables the perception of higher-level features and coherence in that domain; and the interface to the concept level which enables the abstraction of, and visualization of, patterns and objects in that domain.
- **SIAI:**
An abbreviation for "Singularity Institute for Artificial Intelligence".
- **space** **of** **simultaneity:**
A cross-section of the Universe consisting of every event that is happening "right now" according to your reference frame. In Special Relativity, everyone has a different space of simultaneity depending on how fast they're going, and there is no "correct" space of simultaneity. °Turing machines and digital computers have a single, correct space of simultaneity. (For a Turing machine, the space of simultaneity is the state of the tape during any given tick.)
- **SPDM:** Defined in 2.1: World-model.
Sensory, Predictive, Decisive, Manipulative.
Intelligence is an evolutionary advantage because it enables us to model, predict, and manipulate reality. This idea can be refined into describing four levels of *binding* between a model and reality.
A *sensory binding* is simply a surface correspondence between data structures in the model and whatever high-level properties of reality are being modeled.
A *predictive binding* is one that can be used to correctly predict future sensory inputs.

A *decisive* binding is one that can be used to decide between limited sets of possible actions based on the utility of the predicted results.

A *manipulative* binding is one that can be used to start from a specified result and plan a sequence of actions that will bring about the desired result.

See also °qualitative, °quantitative, °structural.

- **stochastic:**

Describing a statistical feature of a population. Since stochastic processes use multiple parallel elements or averaged populations of elements to carry information, they are much more tolerant of errors than more °crystalline constructs such as most modern-day software.

Evolution tends to result in systems that are tolerant of errors and mutation; not necessarily because of a °selection pressure for error-tolerance, but because every evolved system is *ipso facto* one that mutated without dying. Systems with redundant low-level elements - stochastic processes - are the simplest way to get error-tolerance, and generally the first method that evolution hits on. This is a reason why evolved organisms tend to use multiply layered stochastic systems for everything, even though each extra layer of stochastic abstraction considerably decreases efficiency.

- **structural:** Defined in 2.1: World-model.
Structural characteristics are made up of multiple °qualitative or °quantitative components. A *structural match* is when two complex patterns are identical. A *structural binding* occurs when two complex patterns are identical, or bound together to such a degree that coincidence is effectively impossible - only a pattern copy of some kind could have generated the identity. A structural binding is usually the strongest form. See also °SPDM, °qualitative, °quantitative.

- **subjunctive:**

A what-if scenario, e.g. "What if you were to drop that glass of milk?" Something imagined or visualized that *isn't* supposed to describe present or past reality, although a sufficiently attractive what-if scenario might later be turned into a plan, and thence into reality. See also °counterfactual.

- **tera:**

10¹². One thousand billion; a thousand °°giga". See the Hacker's Dictionary for the full list of quantifiers.

- **three:** Defined in 2.3: Concepts.
The concept of "three" is decomposed in some detail in 2.3.3: The concept of "three".

- **time:** Defined in 3.1: Time and Linearity.
Time in a digital computer is °discrete and has a single °space of simultaneity, so anyone who's ever played °Conway's Game of Life knows everything they need to know about the True Ultimate Nature of time in the AI. With each tick of the clock, each frame is derived from the preceeding frame by the "laws of physics" of that °ontology. (Higher-level regularities in the sequence of frames form what we call causality; more about this in *Unimplemented section: Causality*.)

- **Turing-computability:**

If you really haven't heard the term "Turing-computable" before, the first thing you need to do is read Douglas R. Hofstadter's Gödel, Escher, Bach: An Eternal Golden Braid. Drop whatever you're doing, get the book, and read it. It's no substitute, but there's also a nice definition of "Turing machine" in the Stanford Encyclopedia of Philosophy; also, I give a sample visualization of a °Turing machine in *Unimplemented section: Causality*.

Any modern digital computer can, in theory, be simulated by a Turing machine. Any modern computer can also simulate a Turing machine, at least until it runs out of memory (Turing machines, as mathematical concepts, have an infinite amount of memory). In essence, Turing demonstrated that a very wide class of computers, including modern Pentiums and PowerPC chips, are all fundamentally equivalent - they can all simulate each other, given enough time and memory.

There is a task known as the *halting problem* - in essence, to determine whether Turing machine X, acting on input Y, will halt or continue forever. Since the actions of a Turing machine are clearly defined and unambiguous, the halting problem obviously has a true, unique, mathematically correct yes-or-no answer for any specific question. Turing, using a diagonalization argument, demonstrated that no Turing machine can solve the general halting problem. Since any modern digital computer can be simulated by a Turing machine, it follows that no digital computer can solve the halting problem. The halting problem is *noncomputable*. (This doesn't necessarily demonstrate a fundamental "inferiority" of computers, since there's no reason to suppose that *humans* can solve the halting problem. In fact, we can't do so simply by virtue of the fact that we have limited memories.)

A controversial question is whether *our Universe* is Turing-computable - that is, can the laws of physics be simulated to arbitrary accuracy by a digital computer with sufficient speed and memory? And if not, do the uncomputabilities carry over to (a) °qualia and (b) °intelligence? I don't wish to speculate here about °qualia; I don't understand them and neither do you. However, I do understand intelligence, so I'm fairly sure that even if qualia are noncomputable, that noncomputability doesn't carry over into human general intelligence.

I happen to believe that our physical Universe is noncomputable, mostly because I don't trust the Turing formalism. The concept of causality involved strikes me as fundamentally subjective; there's no tail-end recursion explaining why anything exists in the first place; I've never seen a good mathematical definition of °°instantiation"; plus a lot of other reasons that are *way* beyond the scope of this document. If the physical Universe is noncomputable, I believe that qualia are probably noncomputable as well. However, this belief is strictly in my personal capacity and is not defended (or attacked, or discussed) in °GISAI. I am in the extreme minority in so believing, and in an even smaller minority (possibly a minority of one) in believing that *qualia* are noncomputable but that this says nothing about the impossibility, or even the difficulty, of achieving *real intelligence* on computable hardware. I don't believe that semantics require special causal powers, that Godel's Theorem is at all difficult to explain to a computable intelligence, that human mathematical ability is noncomputable, that humans are superior to mere computers, or any of the other °memes that customarily go along with the "noncomputability" meme. Anyway, back to GISAI.

- **ve:**

A °gender-neutral pronoun. The equivalent of "he" or "she".

- **ver:**

A °gender-neutral pronoun. The equivalent of "him" or "her".

- **verself:**

A °gender-neutral pronoun. The equivalent of "himself" or "herself".

- **vis:**

A °gender-neutral pronoun. The equivalent of "his" or "her" (or "hers").

- **world-model:** Defined in 2.1: World-model.

The AI's mental image of the world. Includes °declaratively stored memories containing knowledge about the world, and the contents of sensory modalities - whether sensed, or imagined - constituting the mental workspace. The latter includes °subjunctive or even °counterfactual mental imagery, since even a subjunctive chain of reasoning has internal consistency.

- [1](#): Initial versions of the AI will almost certainly run on interpreted code, and self-modification will take place at or above that level. Eventually, however, a sufficiently intelligent AI should be able to dispense with the interpreted code and rewrite itself in assembly language.
- [2](#): This is actually part of the procedure for building gcc, the GNU C Compiler. Given the gcc source, you build the first version of the gcc binaries using the compiler that came with the system, then build the second version of gcc using the first version, then build a third version using the second version. The idea is that any idiosyncrasies in the included compiler might show up in the first gcc binaries, but won't break them; the second version should be fairly true to the original source, and can be safely used to compile a third version.
- [3](#): The nanotechnology described in Nanosystems, which is basically the nanotechnological equivalent of a vacuum tube - acoustic computing, diamondoid rod logics (4) - describes a one-kilogram computer, running on 100 kW of power, which performs 10^{21} ops/sec using 10^{12} CPUs running at 10^9 ops/sec. The human brain is composed of approximately 100 billion neurons and 100 trillion synapses, firing 200 times per second, for approximately 10^{17} ops/sec total. Thus a seed AI on a nanocomputer would run at ten thousand times the raw power and a million times the linear speed of a human, even before superior software was taken into account. (And if an AI with that much brainpower can't write awesomely superior software, the project has failed.)
- [4](#): That is, the transistor-equivalents consist of kiloatom structures physically moving at the speed of sound in diamond, rather than photons or electrons moving at an appreciable fraction of the speed of light
- [5](#): It might be interesting to learn, just for the record, whether a chess master using a chess program could beat (a) Deep Blue and (b) Kasparov.
- [6](#): Note that I say "instincts". It doesn't mean that AIs are automatically socially stupid. AIs might run human instincts in emulation, or they might develop cognitively-informed rules that make them far savvier than humans. What I mean is that the social heuristics they learn will be matters of conscious thought, not self-delusion and built-in reflexes. They will not make politically-caused *mistakes*.
- [7](#): Whether this process continues indefinitely or dies out will depend on the behavior of the power/intelligence/efficiency curve. That is, what is the software efficiency as a function of the intelligence of the programmer-AI? What is the intelligence of the programmer-AI, as a function of the efficiency of the software on a given amount of hardware?

由于这条曲线自身折叠，大多数关于智力和效率的局部曲线的“合理”图像，在结合时，很可能在全球层面产生一系列突破与瓶颈。至少，在曲线的前人类区域很可能发生这种情况。一旦突破使种子人工智能超越人类水平，我预计“纳米技术到”过渡指南的“曲线”将接管。

- [8](#): “硬件”智能不一定指原始计算能力本身。我使用“硬件”智能来指代由遗传决定、特别是物种间差异而非人类间差异所决定的智能成分。（参见“复杂功能适应”。）
- [9](#): 同时，实际发生的情况比“朴素”内省可能显示的少。如果被问及为什么金属皱缩而玻璃破碎，你会说金属具有延展性而玻璃易碎。但你并不需要意识到或无意识地执行该推理过程，就能想象铁砧撞击汽车。你在电视和电影中见过车祸，你的可视化“借用”了“缓存结果”。你不需要知道铁砧是沉重的金属物体，重力使其以足够的力量向下加速以损坏汽车；你在卡通片中见过铁砧坠落。

内省，如同进化推理，是一种极其强大的工具。与进化推理一样，要在专业层面上运用它，需要练习、天赋和自我意识——以便可靠地区分事后推理与“事前”推理，或区分原创思想与缓存思想。

有些人，甚至可能是大多数读者，可能不需要先想象汽车被砸碎的场景，就能推断出它会损坏；或者更确切地说，接受“将铁砧砸在汽车上会使其损坏”这句话为真；或者更确切地说，继续阅读而没有注意到这句话是假的。

- [10](#): Carl Feynman points out that the correct term is "ante facto", which surprises me, because I didn't think there'd be a term for it at all.
- [11](#): Every rule has an exception. The exception to the "Law of Pragmatism" is the "Bayesian Probability Theorem."
- [12](#): It's actually rather surprising that the vast body of knowledge about human neuroscience and cognition has not yet been reflected in proposed designs for AIs. It makes you wonder if there's some kind of rule that says that AI researchers don't study cognitive science. This wouldn't make any sense, and is almost certainly false, but you do get that impression.
- [13](#): After some soul-searching, I decided to use "his" instead of "vis", since (a) hunter-gatherer societies are often blatantly sexist; (b1) I'd have no qualms about using "his" or "her" if we were talking about Alice and Bob in cryptography; (b2) from a cosmic perspective, one occupation has no greater significance than the other.
- [14](#): It is very likely that human intelligence derives not from the need to outwit tigers, but the need to outwit other humans. (See "conspecifics, and "sexual selection in the glossary.) Hopefully, none of this will hold true of AIs. It's just an important thing to know about humans.
- [15](#): Philosophers have been wrestling with this problem, "the meaning of meaning", for ages. Attempts to create a mathematical definition are probably doomed; there are no selection pressures in favor of reasoning processes which are precisely definable and provably correct. Evolution favors the creation of *useful* models - that is, models whose use promotes inclusive reproductive fitness. In some cases, such as tribal politics, selection pressures may have favored inaccurate, observer-biased models, with consequent problems for modern-day humanity. See also Interlude: The Consensus and the Veil of Maya.
- [16](#): This may sound like the setup for one of those jokes that ends with the physicist saying "First, assume a spherical chicken...", but the billiard-ball domain is complex enough to pose nearly every problem that would be faced by a real-world AI, including uncertainty. Even if sensory information is perfect and complete, the *internal* model is still uncertain - will spending 30 CPU-seconds on a problem-solving strategy yield results, or just another blind alley?

- [17](#): Since a mapping inherently requires a mapper, I do not believe that there is any way to mathematically define a sensory binding in an "observer-independent fashion. In fact, I do not believe there is any way to define any binding in an observer-independent way. I do not believe there is any mathematical way to define when "Turing-computable process A "instantiates Turing-computable process B. I've tried.
- [18](#): In an uncertain world, the AI would need to be able to recognize if a plan had worked, and re-plan if the actions did not have the predicted results. Smart minds design plans that bear in mind the possibility of error.
- [19](#): I could be wrong about this. Ask your local physicist.
- [20](#): Vision in the brain involves an enormous amount of cortex, not just the occipital lobe. In neuroanatomical terms, the processes I'll be talking about take place in the retina, the lateral geniculate nucleus, the striate cortex, and the higher cortical visual areas.
- [21](#): Proprioception and the sense of touch are sometimes lumped together as the "haptic" modality. However, proprioception is served by a separate set of nerves - position sensors embedded in muscle tissue and bone. I think that proprioceptive sensory information is routed to a distinct parietal area (not just sensorimotor cortex), but I can't find a reference that says so one way or the other. (I do know that there's a separate spinal pathway.)

如果本体感觉确实拥有独立的大脑皮层区域（具有独特的表征和可提取的特征），那么它就是一种独立的感觉模态，应当被如此认识。

- [22](#): 此时，一些读者可能会想到，提出“可扩展标记语言（XML）”或“表处理语言（LISP）标记”甚至“零和一”代表了一种通用的底层数据格式。但请记住实用主义定律。万物皆由可扩展标记语言构成的层面，对智能并无实质性贡献。正是可扩展标记语言/标记/二进制数字的特定内容，甚至可能是其上层的内容，在产生有趣的行为。如果你能选取像素可被视为二维阵列中颜色的层面，或听觉“像素”可被视为一维阵列中音高的层面（这两个层面都远高于“零和一”，甚至高于“可扩展标记语言”），并提取所有高层特征，从“边缘”到“下行音调”，使所有这些都遵循一种通用格式——创建一种通用格式，允许在需要领域特定表征的层面上直接交换——那么，你就做出了真正了不起的事情。

否则，这就好比建议在微软文字处理软件（Microsoft Word）和超文本标记语言（HTML）之间进行转换在程序上应当是轻而易举的，因为这两种文件实际上都只是硬盘原子中的磁性模式。重要的是它们不同的层面——实用主义定律指出，智能就在那里。如果它们在任何地方都没有差异——那么，很可能就没有智能。

- [23](#): There's even a dramatic play, "Helen Keller", about the necessity of symbol tags to intelligent cognition.
- [24](#): Lakoff and Johnson call it a 'schema'.
- [25](#): And don't tell me that they're just simulations. How do you know that all the quarks in this Universe aren't being simulated on some big honkin' computer somewhere? Unless the fact that it's a simulation makes an observable, experimentally detectable difference, who cares? I don't believe in zombies.
- [26](#): The necessity for a strongly bound metaphor was something that Plato, for example, never understood. If you make a metaphor between, say, human death and the setting of the sun, it doesn't prove that "Because the sun rises tomorrow, death is impermanent." For a metaphor to bind predictively, it is necessary that the metaphor result from a single underlying cause which produces both sets of effects. It is not enough to say that there is a shared high-level characteristic. Mere similarity, on a high level, is not enough to produce high-level predictions. However, similarity on a low level - a metaphor which analogizes between the *elements* of A and the *elements* of B - is often enough to predict high-level similarities.
- [27](#): "MITECS, "Thalamus":

它（丘脑）在整体架构中占据简单的位置：几乎所有到达大脑皮层的信息都来自丘脑，而丘脑从皮层下结构接收这些信息……特别是，所有视觉、听觉、触觉和本体感觉信息在通往皮层的途中都经过丘脑……

这些事实引出了一个经典观点：丘脑是一个被动的中继站，几乎产生所有传递到皮层的信息输入……

但上述图景忽略了一个基本事实：所有从丘脑到皮层的投射，都受到从皮层到丘脑的同等甚至更大规模反馈投射的相互支配。例如，谢尔曼和科赫（1986）估计，在猫脑中，从丘脑外侧膝状体核到视觉皮层的纤维大约有 10^6 条，而反向的纤维却有 10^7 条！（原文为斜体。）

最流行的假设是，这些纤维扮演着门控角色，协助注意力的集中（为什么需要更多纤维来完成这个任务？）；或者更合理地说，它们在特征提取中提供自上而下的约束。由于这个统计数据是针对猫的，后一种假设可能大体正确。可视化——想象——通常与由通用智能引导的心智相关联。猫可能需要记忆，从而具备从记忆中的高层特征重建图像的能力，但它们可能不需要人类那种细致入微的想象。因此，如果在人类身上发现更大的差异，我也不会感到惊讶！

或者，即使对猫而言，从皮层到丘脑的纤维多于反向纤维，也可能是因为即使是记忆性的感觉操作，在计算上也比感觉知觉更难。

- [28](#): “弯曲轨迹”只存在于时空中；在任何给定参考系、任何时刻，轨迹都恰好位于一个位置。我们通过将四维轨迹映射到三维（或二维）空间曲线来理解“弯曲轨迹”的概念，这使我们能够利用视觉特征提取器来判断曲线是否紧密弯曲、边缘是否锐利等。台球模型可以表示四维轨迹，但不能表示三维空间曲线。[29](#): 也可以不抬笔地用三条直线连接九个点。但你必须跳出更远的框框去思考。

-

- [30](#): As I've said elsewhere, a real AI isn't a computer program any more than a human is an amoeba. To say it more formally (which I can do, now that we're in *this* Webpage), an AI's useful complexity is as far from the program level as a human's useful complexity is distant from the cellular level. A frustrated Windows user assuming that AIs would make the same kind of mistakes as Windows applications is being as foolish as an extraterrestrial assuming that humans would have characteristics stereotypical of amoebas.
- [31](#): Also, some of the things that I'm lumping together as "concepts" in the AI are probably stored and retrieved by distinct subsystems in humans.
- [32](#): See George Lakoff, "Women, Fire, and Dangerous Things".
- [33](#): Also, "red" is a *basic-level category*. (See George Lakoff, in "Women, Fire, and Dangerous Things".) The basic level includes categories such as "red", "dog", and "chair", but not "color", "animal", or "furniture", nor "scarlet", "Irish setter", and "rocker". The basic level is the highest level at which you can summon up a mental image for the category. The basic level is cognitively privileged in a number of ways. For example, basic-level words are the lexically short, the first words learned by children, and the first words to enter a language. Since basic-level categories are more salient, a cognitive scientist looking for an example of a "category" will almost always select a basic-level category. But what holds true of basic-level categories may not hold of higher or lower categories. It's important to bear this in mind whenever you see a discussion of categories that offers a basic-level category as an example.
- [34](#): Note that, for this to work, each correspondence has to be unique. Each object must have only one slot for a unique correspondence in each particular mapping, and once that slot is detected as being filled, it must be impossible to form a correspondence. It's noteworthy that, in spatial modalities modeled on macroscopic physics, the same object cannot occupy two positions, and two objects cannot occupy the same position. In other words, "unique correspondence" involves not so much counting to one, or vetoing an object with "two" correspondences, but simply noticing when objects are bumping into each other, or when the *correspondence* slot is "full" or "empty".
- [35](#): Or rather, "one-to-one correspondence between group membership". "Same number as" implies counting, then comparing the numerical descriptions. The object-by-object implementation described would directly compare objects within the two images. "Same number as" is a much more powerful concept requiring much deeper prerequisites.
- [36](#): "Triangle" slipped to "pyramid" instead of "tetrahedron", even though I know in theory that a tetrahedron is more triangular. I suppose that I've seen more pyramids, or that pyramids are easier to visualize, or that I learned about pyramids at an earlier age, or that I've seen more pyramidal physical objects, or that pyramids resonate more strongly with the bulbish shape. If I'd been constructing a "triangular light bulb" via a deliberate thought-level reasoning process, it probably would have come out as a tetrahedron.
- [37](#): *Slow* and *fast* are not the first concepts abstracted. First comes *slower* and *faster*. Then comes *slower-than-expected* and *faster-than-expected*. Finally comes the concept of *slow* in the absolute sense of a process that occurs slowly relative to the general stream of consciousness (with lots of extra space for thought) and *fast* as describing a process that flits by almost too quickly to be noticed. Since a seed AI should be able to replay cognitive events at will, slowly or quickly to taste, such observer-relative speeds are likely to be a far less important feature of life than for us environmentally-bound humans.
- [38](#): Haven't you ever heard the phrase "The blind watchmaker"?
- [39](#): Say, "within 20000 ticks of each other", or a fuzzy-boundaries ("within 10 ticks is even better") equivalent thereof.
- [40](#): In digital computers! I'm not talking about Relativity!
- [41](#): Again, ducking the question of whether we're considering the "t" dimension or the Minkowskian interval that describes subjective time.
- [42](#): "Deciding what to think about" is an example of such a task!
- [43](#): I'm forced to use colors to create an immediately visible symmetry without overflowing your visual memory. Not only do colors leap more easily to the eye, but they also establish a much stronger binding - one that's much less likely to be a coincidence than a match between Xs and Os. For the bilateral symmetry in XO strings to be visible beyond doubt, the string would have to go on for such a length that it would overflow your visual memory, and your perception of the reflection would perform be conscious rather than intuitive.
- [44](#): In the human brain, the temporal lobe handles object recognition.
- [45](#): Or similar mechanical systems; I mention motorcycles because I have recently been rereading Zen and the Art of Motorcycle Maintenance.
- [46](#): But dangerous - explicit representation of higher levels needs to be handled very carefully, or the °crystalline limits of the representation become the limits of the AI.
- [47](#): Bleah! How do you talk to the AI if you can't identify the stream of consciousness?
- [48](#): Because a seed AI should be able to replay observed events at different speeds, and because a seed AI's stream of consciousness is likely to run either much faster or much slower than the external environment, the seed AI's concept of "simultaneity" may also apply to, for example, observing three supernovas in three weeks. These stellar events may appear "simultaneous" when viewed on a galactic timescale, but no watching human would actually describe them as "simultaneous", since a week is an intrinsically long time to us. A seed AI would be able to actually stretch or slow time to appreciate the galactic scale, and might describe the events as "simultaneous" not metaphorically but literally - actually *perceiving* them as simultaneous on an automatically adjusted subjective timescale.
- [49](#): Why does an uneventful process appear to take longer? (A): Consider the time-as-pathway metaphor; if events are spaced far apart, so that they are passed infrequently, then the time-is-movement metaphor would lead one to think that the observer was moving "slowly". (B): Boredom is unpleasant (because wasting time is an evolutionary disadvantage), and unpleasant processes appear to take longer. Why? Either because it's hardwired in, or because (C): We spend our time wishing that boring events were over, which makes the process appear to take longer. Why? Either because it's hardwired in, or because (D): We pay a lot of attention to how much time is passing. The long intervals move upwards in salience, occupying our immediate minds; and afterwards, we remember all the long intervals as part of the event, which may either stretch out the subjective length of the actual memory, or simply result in the memory being labeled with "took a long time".
- [50](#): The key difference (51) is probably that processes packed full of memorable events will be remembered as being longer, while processes full of immediate, subjective events will occupy all the immediate attention when they occur, while afterwards seeming to have flashed by.
- [51](#): "Key difference" = key variable.
- [52](#): One must be careful to ensure that the maximum resolution of this timeline does not become the new system clock; ideally, the resolution should be finer than the time it takes to process a concept or notice an event, while still enough faster than the system clock that the modality doesn't take up too much overhead.
- [53](#): Actually, there are more requirements: One, for all A and B, one and only one of these relations holds: $A < B$, $A = B$, or $B < A$. Two, if $A = B$, then $A < C$ implies $B < C$, and $C < A$ implies $C < B$. Three, if $A = B$, and $B = C$, $A = C$. Four, if $A = B$, then $B = A$. But that's just legalese to make sure you're using "<" and "=" properly.

- **54:** 神经元非常擅长适应模式；一旦适应了某个模式，它就成为预期，模式的变化就能被注意到。这是神经元的普遍特性，适用于所有经过它们的信息。只要对任何足够强的低层模式进行足够长时间的暴露，并且没有干扰，我们最终会注意到这个模式——即使它是我们从未见过的模式类型。

这可能是一个真实的实例，体现了底层神经元的某种物理特性。这种特性很难作为外部启发式方法复制，除非创建一层额外的类神经元解释代码。然而，我认为程序化模式检测器，加上学习关于应用哪些模式检测器以及何时应用的启发式方法的能力，应该能够在形成期望和检测模式方面达到与生物神经元相当的有效性。

我们适应意外新模式的能力，或许可以通过偶尔尝试在数千个完全随机的量中检测同一性或协方差来模拟。

- 55: 轨迹作为一种视觉-时间体验，物体在空间中移动，从人类视角来看显然是一个无处不在的主题。对于生活在源代码世界中的 AI 来说，这样的轨迹是一个更为深奥的主题。56: 200Hz 的神经元、100m/s 的轴突以及 0.1m 的直径。57: 我不记得最初是在哪里听到这个的，但我猜是雷蒙德·斯穆里安。
-
-