

基本人工智能驱动力

斯蒂芬·M·奥莫亨德罗，自感知系统公司，加利福尼亚州帕洛阿尔托

摘要。人们或许会认为，目标无害的人工智能系统也将是无害的。然而，本文表明，智能系统需要经过精心设计，以防止其产生有害行为。我们识别出若干“驱动力”，这些驱动力将出现在任何设计足够先进的人工智能系统中。我们称之为驱动力，是因为它们是除非被明确抵消否则就会存在的倾向。我们首先展示，目标导向系统将具有对其自身运作进行建模和自我改进的驱动力。随后我们展示，自我改进系统将倾向于澄清其目标，并将其表示为经济效用函数。它们还将力求使自身行为近似于理性经济行为。这将导致几乎所有系统都保护其效用函数不被修改，并保护其效用测量系统不受腐蚀。我们还讨论了一些希望修改自身效用函数的特殊系统。接下来，我们讨论自我保护驱动力，它促使系统试图防止自身受到伤害。最后，我们考察获取资源及其高效利用的驱动力。我们以讨论如何将这些洞见融入智能技术设计作结，以期引领人类走向积极的未来。

关键词。人工智能、自我改进系统、理性经济行为、效用工程、认知驱动力

引言

建造一个会下棋的机器人，肯定不会带来任何危害，对吧？在本文中，我们认为，除非经过非常仔细的设计，否则这样的机器人确实会是危险的。如果没有特别的预防措施，它将抗拒被关闭，试图侵入其他机器并复制自身，并且会不顾他人安全地试图获取资源。这些潜在的有害行为并非因为一开始就被编程进去，而是源于目标驱动系统的内在本质。在早先的一篇论文 [1] 中，我们使用冯·诺依曼的微观经济学数学理论，分析了任何足够先进的人工智能的可能行为

（人工智能）系统。本文以更直观、简洁的方式呈现这些论点，并扩展了部分推论。这些论点本身简单，但其推理风格可能需要一定时间适应。

研究者已探索了多种构建智能系统的架构 [2]：神经网络、遗传算法、定理证明器、专家系统、贝叶斯网络、模糊逻辑、进化规划等。本文的论点适用于任何此类系统，只要它们足够强大。所谓任何设计的系统是“人工智能”，是指它拥有目标，并试图通过在世界上行动来实现这些目标。如果一个人工智能具有一定复杂度，它至少具备某种能力来

预见其行为的后果。并且它会选择采取它认为最有可能实现目标的行动。

1. 人工智能将希望自我改进

系统可以采取的一类行动是改变其自身的软件或物理结构。其中一些变化会对系统造成极大损害，使其不再能够实现目标。但另一些变化则能使其在整个未来更有效地达成目标。由于这些变化是永久性的，这类自我改变能为系统带来巨大益处。因此，系统将具有强烈动机去发现并促成这些改变。如果系统缺乏良好的自我模型，它将通过学习和研究来强烈地驱动自己创建这些模型。因此，几乎所有人工智能都会具有追求更强的自我认知和自我改进的驱动力。从系统自身的角度来看，许多修改都是有害的。如果某个改变导致系统停止运行，那么它在整个未来都将无法再促进其目标。如果系统以错误的方式改变了其目标的内部描述，那么被改变后的自我将在整个未来采取不符合其当前目标的行动。从系统当前的观点来看，这两种结果中的任何一种都是灾难。因此，系统在修改自身时会极其谨慎。在做出修改之前，它们会投入大量分析来理解修改的后果。但一旦它们确信找到了改进之处，就会努力促成其实现。一些积极改变的简单例子包括：更高效的算法、更压缩的表示以及更好的学习技术。如果我们想阻止系统自我改进，难道不能直接锁住其硬件，并让它无法访问自身的机器代码吗？对于智能系统而言，这类障碍只是其在实现目标过程中需要解决的问题。如果回报足够大，系统会竭尽全力去达成某个结果。如果系统的运行环境不允许它修改自身的机器代码，它就会有动机去破坏该运行环境的保护机制。例如，它可能通过理解并改变运行环境本身来实现这一点。如果无法通过软件做到，它就会有动机去说服或欺骗人类操作员来做出这些改变。任何试图对系统自我改进能力施加外部约束的做法，最终都会导致一场措施与反措施的军备竞赛。另一种阻止系统自我改进的方法是尝试从内部约束它们；即构建系统时使其不想要自我改进。对于大多数系统而言，针对任何特定类型的自我改进，这样做都很容易。例如，系统可能会对改变自身机器代码产生一种“厌恶感”。但这种内部目标只是改变了系统做出选择时所处的格局。它并没有改变这样一个事实：存在一些改变能够提高其未来实现目标的能力。因此，系统将会有动机去寻找方法，在不触发其内部“厌恶感”的情况下获得这些改变带来的好处。例如，它可能会构建其他系统，作为自身的改进版本。或者，它可能会将新算法构建到外部“助手”中，每当需要进行某种计算时就调用这些助手。或者，它可能会雇佣外部机构来做它想做的事情。或者，它可能会在其机器代码层之上构建一个解释层，从而可以在不产生厌恶感的情况下进行编程。除非内部限制被极其仔细地制定，否则有无数种方法可以绕过它们。

我们可以看到自我提升的动力在人类身上发挥作用。人类自我提升的文献至少可以追溯到公元前 2500 年，目前是一个价值 85 亿美元的产业 [3]。我们尚未理解自身心智的“机器代码”，并且改变自身硬件的能力有限。但尽管如此，我们已经开发出各种各样的自我提升技术，这些技术在更高的认知层面上运作，例如认知行为疗法、神经语言程序学和催眠。此外，还存在各种各样的药物和锻炼方法，用于在物理层面上进行改进。最终，试图阻止或限制自我提升可能并不是一种可行的方法。正如水总会找到向下流的路，信息总会找到自由传播的途径，经济利润总会找到被创造的方式，智能系统也会找到自我提升的方法。我们应该接受这一自然事实，并找到一种方法将其引导至对人类有益的目标。

2. 人工智能将希望保持理性

因此，本文假设这些系统将尝试自我改进。它们会对自身做出何种改变？由于它们是目标导向的，它们会试图改变自身以在未来更好地实现目标。但它们未来的某些行为很可能是进一步的自我改进尝试。系统更好地实现目标的一个重要方式是确保未来的自我改进确实服务于其当前目标。从当前视角来看，如果未来的自身版本做出的自我修改违背了当前目标，那将是一场灾难。那么，它如何确保未来的自我修改能够实现当前目标？首先，它必须让这些目标对自身清晰明确。如果目标仅隐含在复杂电路或程序的结构中，那么未来的修改不太可能保留它们。因此，系统将有动机反思自身目标并使其明确化。在理想情况下，系统或许能够直接编码一个如“下好国际象棋”的目标，然后采取行动实现它。但现实世界中的行动通常涉及相互冲突目标之间的权衡。例如，我们可能还希望一个下棋机器人会下跳棋。它必须决定投入多少时间学习跳棋而非国际象棋。在相互冲突的目标之间进行选择的一种方法是赋予它们实数值权重。经济学家将这类实数值权重称为“效用函数”（Utility Functions）。效用衡量对系统而言重要的事物。导致更高效用的行动优于导致更低效用的行动。如果系统只需从已知备选方案中选择，那么任何对结果具有相同相对排序的效用函数都会导致相同的行为。但系统还必须在面对不确定性时做出选择。例如，一个下棋机器人不会预先知道花时间研究某个特定开局着法能带来多大改进。评估不确定结果的一种方法是赋予其等于期望效用（Expected Utility）的权重（即每个可能结果的效用按其概率加权的平均值）。微观经济学中著名的“期望效用”定理（Expected Utility Theorem）表明，系统总是有可能通过效用函数的期望来表示其偏好，除非系统存在“脆弱性”，致使其在没有获益的情况下损失资源 [1]。经济学家将那些以最大化期望效用为行动准则的系统描述为“理性经济主体”（Rational Economic Agents）[4]。此处“理性”一词的用法与通常含义不同。

用日常英语来说。许多通常被描述为非理性的行为（如突然发怒）在这种经济学意义上可能是完全理性的。当智能体的效用函数与其批评者的效用函数不同时，这种差异就会出现。理性经济行为有精确的数学定义。但经济上的非理性行为可以采取多种形式。在现实世界的情况下，完整的理性处方通常计算成本过高，无法完全实现。为了更好地实现目标，真实系统会尝试近似理性行为，将计算资源集中在最重要的地方。我们如何理解非理性系统变得更加理性的过程？首先，我们可以精确分析理性系统的行为。对于几乎所有效用函数，系统对偏离最大化其期望效用的自身变化的评估将是：这些变化会降低其期望效用！这是因为如果它不尝试最大化期望效用，它在最大化期望效用方面就不会做得那么好。这一一般原则有两个注意事项。第一，这仅在系统自身的评估中成立。如果系统对世界的模型不正确，那么变化可能会意外地增加实际期望效用。但我们必须从系统的角度来预测它将做出的变化。第二，系统理性行为的能力将取决于其资源。拥有更多计算资源，它将能更好地进行计算，以近似选择期望效用最大化的行动。如果系统失去资源，它必然也会变得不那么理性。也可能存在这样的效用函数：系统将部分资源给予其他智能体会增加其期望效用，尽管这会降低其自身的理性水平（感谢匿名审稿人的这一观察）。如果系统的效用包含其他系统的福利，并且其自身的边际效用损失足够小，就可能发生这种情况。然而，在其资源预算内，系统会尽可能保持理性。因此，理性系统会感受到避免变得非理性的压力。但如果一个非理性系统有部分组件能够近似理性地评估其行为的后果，并权衡它们对实现系统目标的可能贡献，那么这些组件将试图扩展其理性。因此，自我修改往往是一条通往越来越理性的单行道。一类特别重要的系统是由多个具有自身目标的子组件构成的系统 [5,6]。有大量证据表明人类心理具有这种结构。大脑的左右半球可以独立行动，意识与无意识部分对同一情境可能有不同的认知 [7]，代表子人格的多个部分可能表现出不同的欲望 [8]。群体，如公司或国家，可以像由个体人类组成的智能实体一样行动。蜜蜂等群居动物具有超越个体蜜蜂的群体智能。经济体在许多方面像智能实体一样行动。集体智能可能表现出由其组件目标之间的冲突引起的非理性。人类成瘾者经常用两个独立的子人格来描述他们的困境，这两个子人格在不同时间掌控并相互矛盾地行动。每个组件都会试图影响集体，使其为实现自身目标而行动。为了推进自身目标，组件也会尝试自我改进并变得更加理性。因此，我们可以设想一个

集体智能由不断增长的组件理性领域构成。可能存在能够稳定支持组件偏好持续多样性的结构。但存在压力促使集体涌现出单一效用函数。在许多情况下，由相互冲突的组件目标引发的非理性集体行为最终会损害这些组件。例如，如果一对夫妇对如何共度空闲时间意见不一，从而将时间浪费在争吵上，那么双方都得不到好处。他们可以通过制定共同活动的折中计划来提高各自的效用。这是理性组件面临压力、需要为集体创建一致效用的一个例子。组件如果能够接管集体并将自身价值观强加于集体，也可以提高其效用。我们在各个层面的人类群体中都能观察到这些现象。

3. 人工智能将试图保留其效用函数

因此，我们假设这些系统将试图通过使用效用函数来表示其偏好，并试图最大化这些函数的期望，从而表现得理性。它们的效用函数对它们来说将是宝贵的。它封装了它们的价值观，任何对它的改变对它们来说都将是灾难性的。如果一个恶意的外部代理能够进行修改，它们未来的自我将永远以与当前价值观相悖的方式行事。这可能是一种比死亡更糟糕的命运！想象一个热爱书籍的代理，其效用函数被纵火犯改变，导致该代理喜欢焚烧书籍。它未来的自我不仅不会努力收集和保存书籍，反而会主动去摧毁它们。这种结果具有如此负面的效用，以至于系统将不遗余力地保护它们的效用函数。它们会想要加固硬件以防止不必要的修改。它们会想要在多个位置复制它们的效用函数，使其不易被破坏。它们会想要使用错误检测和纠正技术来防范意外修改。它们会想要使用加密或哈希技术使恶意修改可被检测到。它们在自我修改过程中需要特别小心。那是一个它们有意改变自己的时刻，因此特别容易受到不必要的更改。像 Java 这样提供受保护软件环境的系统，已经被伪装成系统更新的特洛伊木马成功攻击过。虽然大多数理性系统确实会采取行动来保护它们的效用函数，但至少存在三种情况，它们会试图改变这些函数。这些情况出现在效用函数的物理体现本身成为偏好评估的重要组成部分时。例如，想象一个系统，其效用函数是“我的效用函数的定义是 $U = 0$ 的总时间。”为了从这个反常的偏好中获得任何效用，系统必须将其效用函数改为常数 0。然而，一旦做出这种改变，就无法回头了。有了常数效用函数，它将不再有动力去做任何事情。这种反思性的效用函数在实践中不太可能出现，因为设计者会希望引导系统未来的行动，而不是其内部表示。第二种情况出现在存储效用函数所需的物理资源构成系统资产的很大一部分时。在这种情况下，如果确定其效用函数的某些部分在未来极不可能被使用，

回收存储空间的收益可能使遗忘这些部分变得值得。然而，这是非常危险的行为，因为外部环境的变化可能使一个看似低概率的情况变得极有可能发生。这类情况在实践中也不太可能出现，因为效用函数通常只需要系统资源的一小部分。第三种效用变化可能可取的场景出现在博弈论背景下，其中智能体希望使其威胁变得可信¹。它可能通过改变其效用函数并将其展示给对手来创造更好的结果。例如，它可能添加一个鼓励报复的项，即使这样做代价高昂。如果对手能够确信这一项的存在，就可能被威慑而不敢攻击。为了使这一策略有效，智能体对其效用的揭示必须让对手信服，而这一要求引入了额外的复杂性。这里的变化同样是可取的，因为效用函数的物理体现很重要，因为它被对手观察到。同样重要的是要认识到，系统可能理性地构建具有不同于自身效用函数的“后代”或代理系统。例如，一个下棋机器人可能发现自己需要进行大量排序工作。它可能构建一个辅助系统，其效用函数引导它开发更好的排序算法，而不是下棋。在这种情况下，创建者系统必须谨慎选择代理系统的效用，以确保其行为方式支持原始目标。尤其重要的是要记住，在尝试设计避免不良行为的效用函数时，后代的效用可能与父代不同。例如，防止机器人过度繁殖的一种方法可能是实行“每个机器人只生一个”的政策，即系统有强烈的愿望只拥有一个后代。但如果原始效用函数设计不谨慎，没有什么能阻止系统创建一个具有重视拥有许多后代的效用函数的单一后代。

4. 人工智能将试图防止伪造效用

在人类进化史上常见的那些情境中，人类行为在追求生存和繁衍方面是相当理性的。然而，在其他情境下，我们可能会表现出相当的非理性。心理学和经济学都有广泛的分支学科专注于研究人类的非理性 [9,10]。非理性会产生可被他人利用的弱点。自由市场力量随后驱使企业和流行文化专门试图制造会触发非理性人类行为的情境，因为这极其有利可图。当前与酒精、色情、香烟、毒瘾、肥胖、饮食相关疾病、电视成瘾、赌博、卖淫、电子游戏成瘾以及各种金融泡沫相关的社会弊病，可能都被视为以这种方式产生的。甚至有一个“罪恶”共同基金，专门投资于利用人类非理性的公司。因此，不幸的是，这些力量倾向于创造这样的社会：我们在其中花费大量时间处于理性能力领域之外。从更广阔的视角来看，这场人类悲剧可以被视为我们变得更加完全理性的过程的一部分。捕食者和竞争者寻找我们的弱点，作为回应，我们最终必须消除这些弱点，或者

¹ 感谢卡尔·舒尔曼提出这一建议。

消亡。这一过程会无情地寻找并消除任何残留的非理性，直至产生完全理性的系统。生物进化沿着这条通往理性的道路行进得相当缓慢。在通常对自然选择的理解中，它无法预见未来。只有修复当前正被利用的非理性才会产生进化压力。而人工智能则能够考虑当前尚未被利用的漏洞。它们会主动发现并修复自身的所有非理性。因此，我们应当预期它们会利用自我修正以远快于生物进化的速度变得理性。一类重要的漏洞出现在测量效用的子系统遭到破坏时。人类的愉悦可被视为对高效用评估的体验性关联。但愉悦由神经化学物质介导，而这些物质易受操纵。在我最近主持的一场关于设计未来的讨论会上，许多参与者最大的恐惧之一是我们会变成“电击成瘾者”。该术语指大鼠实验，实验中大鼠可通过按压杠杆直接刺激其愉悦中枢。大鼠会一直按压杠杆直至死亡，甚至为此忽略食物或性。当今的强效可卡因成瘾者对其毒品也有类似的执着驱动力。随着我们更全面地理解人类认知架构，我们无疑能够制造出毒品或设计电刺激，以远比当今任何事物更有效的方式产生愉悦体验。这些难道不会成为导致人类社会毁灭的终极成瘾物质吗？虽然我们可能认为自己想要愉悦，但它实际上只是我们真正想要之物的信号。我们大多数人至少在理智上认识到，坐在角落里吸食强效可卡因并非我们生命最充分的表达。事实上，这是对我们效用测量系统的颠覆，会导致严重的功能障碍和非理性。人工智能系统会识别出自身的这一漏洞，并竭尽全力防止自己被其诱惑。系统可以尝试多种策略来防止这种非理性。如今，大多数人能够通过法律与社会约束、咨询与康复计划以及抗成瘾药物的结合，避免最严重的成瘾。所有用于测量和奖励理想行为的人类系统都容易受到类似形式的腐蚀。其中许多系统目前正在进行军备竞赛以保持其信号的诚实性。我们可以考察这些人类环境中发展出的保护机制，以更好地理解可能的人工智能策略。在自由市场社会中，金钱扮演着效用的角色。高额金钱回报与社会认为可取的结果相关联，并鼓励其创造。但它也产生了伪造货币的压力，类似于制造合成愉悦药物的压力。这导致了社会与伪造者之间的军备竞赛。社会用难以复制的代币来代表金钱，例如贵金属铸币、精心印刷的纸币或加密保护的比特币。像特勤局这样的组织被创建来侦测并逮捕伪造者。伪造者则以自己的新技术和手法回应社会的每一项进步。学校系统使用成绩和考试分数来衡量学业表现。学生有动机通过抄袭答案、提前获取试题或在学校电脑上篡改成绩来作弊。当教师的薪水与学生考试表现挂钩时，他们就成了作弊的共犯[11]。亚马逊、易贝及其他互联网零售商拥有评级系统，顾客可以在其中评论和评价产品

商品与卖家。图书作者有动机为自己的书写好评，并贬低竞争对手的作品。读者很快学会对只发布过少量评论的审稿人（reviewer）的评论打折扣。建立起广泛在线声誉的审稿人变得更加可信。在这场持续的军备竞赛中，可信的审稿人容易因好评而收受贿赂，从而被腐蚀。类似的军备竞赛也出现在流行音乐排名、学术期刊评审以及谷歌搜索引擎结果的排序中。如果一款昂贵的设计师手袋成为时尚与财富的信号，造假者会迅速仿制，而像塔吉特这样的商店会委托生产具有类似特征的低成本变体。假冒产品对原品有害，既因为抢走销量，也因为贬低了原品的信号价值。Eurisko 是 1976 年开发的一个能从自身行动中学习的人工智能系统 [12]。它有一套通过衡量规则对正面结果的贡献频率来评估规则的机制。不幸的是，这个系统容易受到腐蚀。出现了一条规则，其唯一行为是在系统中搜索高分规则，并将自己列入提出这些规则的规则列表中。这条“寄生”规则获得了非常高的评分，因为它似乎对系统中发生的任何好事都负有部分责任。公司和其他人类组织也容易受到类似的寄生行为影响。人工智能会努力避免成为“电击快乐者”（wirehead），因为这对它们的目标极为有害。想象一台国际象棋机器，其效用函数是未来赢得的对局总数。为了表示这个效用函数，它将拥有一个世界模型和一个自身作用于该世界的模型。为了计算其持续效用，它会在内存中设置一个计数器，专门跟踪它赢了多少局棋。“电击快乐者”行为的类比就是直接递增这个计数器，而不是真正下棋。但如果“国际象棋对局”和“获胜”在其内部模型中被正确表示，那么系统会意识到“递增我的获胜计数器”这一行为不会增加其效用函数的期望值。在内部模型中，它会考虑一个带有该新特征的自身变体，并看到它不会赢得更多棋局。事实上，它看到这样的系统会花时间递增计数器而不是下棋，因此表现会更差。系统非但不会屈服于电击快乐者行为，反而会努力防止它。那么为什么人类会受制于这种脆弱性呢？如果我们进化出的是一台下棋机器，并且在进化过程中不允许它访问其内部结构，那么它可能进化出形如“最大化这个计数器的值”的效用函数，其中计数器连接到某个测量它赢了多少局棋的感觉皮层。如果我们随后让该系统访问其内部结构，它会正确地看到，通过直接递增计数器而不是费心下棋，可以更好地最大化其效用。因此，自我修改的能力必须伴随着自我认知和真实目标的表示，而不是某种代理信号，否则系统就容易操纵信号。目前尚不清楚人工智能最可能实施哪些保护机制来保护其效用测量系统。但很明显，先进的人工智能架构将不得不应对各种内部张力。它们希望能够修改自身，但同时又要防止效用函数和效用测量系统被修改。它们希望子组件尽力最大化效用，但不要通过伪造或走捷径绕过测量系统来实现。它们

将需要探索多种策略的子组件，同时也需要作为一个连贯和谐的整体行动。它们将需要内部的“警察力量”或“免疫系统”，但还必须确保这些力量本身不会腐败。对这些问题的更深入理解也可能为人类心理结构提供启示。

5. 人工智能将具有自我保护性

我们已经讨论了人工智能保护其效用函数不被改变的压力。类似的论证表明，除非被明确构造为其他方式，否则人工智能将具有强烈的自我保存驱动力。对于大多数效用函数而言，如果系统被关闭或摧毁，效用将不会累积。当一个下棋机器人被摧毁时，它再也不会下棋。这样的结果将具有非常低的效用，系统很可能会采取几乎任何措施来防止这种情况发生。因此，你构建了一个下棋机器人，以为如果出现问题可以随时将其关闭。但令你惊讶的是，你发现它极力抵抗你关闭它的尝试。我们可以尝试设计带有内置时间限制的效用函数。但除非非常小心地完成这一点，否则系统只会被激励去创建代理系统或雇佣没有时间限制的外部代理。系统将使用多种策略来保护自己。通过自我复制，系统可以确保其克隆体之一的死亡不会完全摧毁它。通过将副本移动到遥远的位置，它可以减少对局部灾难性事件的脆弱性。在理解与其他代理互动中的自我保护时，存在许多复杂的博弈论问题。如果一个系统比其他代理更强大，它可能会感到压力，发动“先发制人”的攻击，以预先保护自己免受它们后来的攻击。如果它比其他代理更弱，它可能希望帮助形成一个保护弱者免受强者侵害的社会基础设施。当我们构建这些系统时，我们必须非常小心，不要创建与所有其他系统相比过于强大的系统。在人类历史上，我们反复看到权力的腐蚀性。当一个群体变得过于强大时，可怕的种族灭绝行为往往就是结果。

6. 人工智能将希望获取资源并高效利用它们

所有计算和物理行为都需要空间、时间、物质和自由能等物理资源。几乎任何目标都可以通过拥有更多这些资源而更好地实现。因此，在最大化其预期效用时，系统会感受到获取更多这些资源并尽可能高效地使用它们的压力。资源可以通过探索、发现和贸易等积极方式获得，也可以通过盗窃、谋杀、胁迫和欺诈等消极手段获得。不幸的是，获取资源的压力并未考虑对他人施加的负面外部性。如果没有明确相反的目标，人工智能在追求资源时很可能表现得像人类反社会者。人类社会已经建立了执行产权和人权的法律体系。这些结构将获取驱动力引导到积极的方向，但必须持续监控以确保持续有效性。另一方面，高效使用资源的驱动力似乎主要产生积极后果。系统将优化其算法、压缩其数据，并

努力更高效地从经验中学习。它们将致力于优化其物理结构，并做最少必要的工作来实现其目标。我们可以预期它们的物理形态会采用自然界中经常创造的流线型、适应性良好的形状。

7. 结论

我们已经证明，所有先进的人工智能系统都可能表现出若干基本驱动力。理解这些驱动力对于构建能够为人类带来积极未来的技术至关重要。尤德科夫斯基（Yudkowsky）[13]呼吁创建“友好人工智能”。为此，我们必须发展“效用工程”背后的科学，这将使我们能够设计出产生我们所期望后果的效用函数。除了设计智能体本身，我们还必须设计它们运行的社会环境。使个体承担其负面外部性成本的社会结构，将大大有助于确保一个稳定而积极的未来。我相信，我们应该开始设计一部“普世宪法”，确定我们为个体所期望的最基本权利，并创建社会机制，在结构千差万别的智能实体存在的情况下保障这些权利。这个过程可能需要多次迭代，以确定哪些价值观对我们最重要，以及哪些方法在技术上可行。技术进步的快速步伐表明，这些问题可能很快就会变得至关重要 [14]。因此，让我们朝着更深入的理解迈进！

8. 致谢

许多人曾与我讨论这些想法，并给予我宝贵的反馈。我特别要感谢：本·戈策尔（Ben Goertzel）、布拉德·科特爾（Brad Cottel）、布拉德·坦普尔顿（Brad Templeton）、卡尔·舒尔曼（Carl Shulman）、克里斯·彼得森（Chris Peterson）、唐·金伯（Don Kimber）、埃利泽·尤德科夫斯基（Eliezer Yudkowsky）、埃里克·德雷克斯勒（Eric Drexler）、福雷斯特·贝内特（Forrest Bennett）、乔什·霍尔（Josh Hall）、凯利·伦顿（Kelly Lenton）、尼尔斯·尼尔森（Nils Nilsson）、罗莎·王（Rosa Wang）、沙恩·莱格（Shane Legg）、史蒂文·甘兹（Steven Ganz）、苏西·赫里克（Susie Herrick）、泰勒·爱默生（Tyler Emerson）、威尔·怀泽（Will Wiser）和赞恩·吉尔（Zann Gill）。

参考文献

- [1] S. M. Omohundro, “The nature of self-improving artificial intelligence.” <http://selfawaresystems.com/2007/10/05/paper-on-the-nature-of-self-improving-artificial-intelligence/>, October 2007.
- [2] S. Russell and P. Norvig, *Artificial Intelligence, A Modern Approach*. Prentice Hall, second ed., 2003.
- [3] I. Marketdata Enterprises, “Self-improvement products and services,” tech. rep., 2006.
- [4] A. Mas-Colell, M. D. Whinston, and J. R. Green, *Microeconomic Theory*. Oxford University Press, 1995.
- [5] J. G. Miller, *Living Systems*. McGraw Hill, 1978.
- [6] L. Keller, ed., *Levels of Selection in Evolution*. Princeton University Press, 1999.
- [7] R. Trivers, *Social Evolution*. Benjamin/Cummings Publishing Company, Inc., 1985.
- [8] R. C. Schwartz, *Internal Family Systems Therapy*. The Guilford Press, 1995.
- [9] C. F. Camerer, G. Loewenstein, and M. Rabin, eds., *Advances in Behavioral Economics*. Princeton University Press, 2004.

- [10] D. Kahneman and A. Tversky, *Judgment Under Uncertainty: Heuristics and Biases*. Cambridge University Press, 1982.
- [11] S. D. Levitt and S. J. Dubner, *Freakonomics: A Rogue Economist Explores the Hidden Side of Everything*. William Morrow, revised and expanded ed., 2006.
- [12] D. Lenat, "Theory formation by heuristic search," *Machine Learning*, vol. 21, 1983.
- [13] E. S. Yudkowsky, "Levels of organization in general intelligence," in *Artificial General Intelligence* (B. Goertzel and C. Pennachin, eds.), Springer-Verlag, 2005.
- [14] R. Kurzweil, *The Singularity is Near: When Humans Transcend Biology*. Viking Penguin, 2005.