

奇点：一种哲学分析

大卫·J·查尔默斯

1 引言

1

当机器变得比人类更智能时会发生什么？一种观点认为，这一事件之后将出现智能的爆炸式增长，达到前所未有的水平，因为每一代机器都会创造出更智能的下一代机器。这种智能爆炸如今常被称为“奇点”。

这一基本论证由统计学家 I.J. 古德在其 1965 年的文章《关于第一台超智能机器的猜想》中提出：

将超智能机器定义为能够远远超越任何人的所有智力活动的机器，无论此人多么聪明。由于机器设计是这些智力活动之一，超智能机器能够设计出更好的机器；届时无疑会出现“智能爆炸”，人类的智能将被远远抛在后面。因此，第一台超智能机器是人类需要制造的最后一项发明。

关键思想在于，比人类更智能的机器在设计机器方面也将优于人类。因此，它将能够设计出比人类所能设计的最智能机器更智能的机器。所以，如果它本身是由人类设计的，它将能够设计出比自身更智能的机器。通过类似的推理，这台下一代的机器将

¹ 本文发表于《意识研究杂志》17:7-65，2010 年。我最初是在学生时代对这一系列思想产生兴趣的，直到 1997 年才第一次明确听说“奇点”。2009 年纽约市奇点峰会邀请我发言，促使我进一步思考这些问题。我感谢那次活动中许多人的讨论，以及后来在西点军校、纽约市立大学、纽约大学、德里、澳大利亚国立大学、图森、牛津和新南威尔士大学的演讲和讨论中的许多人。还要感谢道格·霍夫施塔特、马库斯·胡特、奥勒·科克斯维克、德鲁·麦克德莫特、卡尔·舒尔曼和迈克尔·瓦萨对本文的评论。

还能设计出比自身更智能的机器。如果每台机器依次完成其能力所及之事，我们应当预期会出现一系列越来越智能的机器。² 这种智能爆炸有时与另一种思想相结合，我们可称之为“速度爆炸”。速度爆炸的论证始于一个常见的观察：计算机处理速度每隔固定时间翻倍。假设速度每两年翻倍，并将无限期持续下去。再假设我们拥有设计新处理器的人类水平人工智能。那么更快的处理速度将带来更快的设计者，以及不断加速的设计周期，从而在不久之后达到一个极限点。

速度爆炸的论证由人工智能研究者雷·所罗门诺夫在其 1985 年的文章《人工智能的时间尺度》中提出。³ 埃利泽·尤德科夫斯基在其 1996 年的文章《凝视奇点》中给出了该论证的简洁版本：

“计算速度每两个主观工作年翻倍。人工智能达到人类水平两年后，其速度翻倍。一年后，其速度再次翻倍。六个月——三个月——1.5 个月……奇点。”

智能爆炸与速度爆炸在逻辑上相互独立。原则上，可能存在没有速度爆炸的智能爆炸，也可能存在没有智能爆炸的速度爆炸。但这两个思想配合起来尤为有力。假设在两个主观年内，一台超越人类的机器能够制造出另一台机器，后者不仅速度翻倍，而且智能提升 10%，并假设这一原则可无限扩展。那么在四个客观年内，将出现无限多代机器，其速度和智能在有限时间内均增长至超越任何有限水平。这一过程才真正配得上“奇点”之名。

当然，物理定律在此施加了限制。如果当前被接受的相对论和量子力学定律是正确的——或者即使在经典宇宙中能量是有限的——那么我们不能期望上述原理可以无限扩展。但即使存在这些物理限制，这些论证也给出了一些理由，认为速度和智能都可能被推向物理上可能的极限。而且从表面上看，人类的处理能力甚至不太可能接近物理上可能的极限。因此，这些论证

这类场景在科幻小说中有先例，最著名的或许是约翰·坎贝尔（John Campbell）1932 年的短篇小说《最后的进化》。所罗门诺夫（Solomonoff）也讨论了我们可能称之为“人口爆炸”的效应：人工人工智能研究者数量的迅速增长。

表明速度和智能都可能在相对较短的时间内被远远推至人类能力之上。这个过程可能不构成数学和物理学严格意义上的“奇点”，但它足够相似，以至于这个名称并非完全不合适。“奇点”一词由科幻作家弗诺·文奇（Vernor Vinge）在 1983 年的一篇观点文章中引入⁴。它通过文奇 1993 年有影响力的文章《即将到来的技术奇点》以及发明家、未来学家雷·库兹韦尔（Ray Kurzweil）2005 年的畅销书《奇点临近》而得到更广泛的传播。在实践中，该术语以多种不同方式使用。一种宽松的意义指涉一种现象，即越来越快速的技术变革导致不可预测的后果。⁵ 一种非常严格的意义指涉速度和智能趋于无穷大的点，如上述假设的速度 / 智能爆炸。然而，该术语的核心意义或许是一种适中的意义，即它指涉通过 I. J. 古德（I. J. Good）提出的递归机制产生的智能爆炸，无论这种智能爆炸是否伴随速度爆炸或发散至无穷大。在下文中，我将始终在这个核心意义上使用“奇点”一词。

有人可能认为，奇点会引起学术哲学家、认知科学家和人工智能研究者的极大兴趣。实际上，情况并非如此。⁶ 古德是一位杰出的学者，但他的文章在当时并未得到充分重视。随后关于奇点的讨论主要发生在非学术圈，包括互联网论坛、大众媒体和书籍，以及由独立的奇点研究所组织的研讨会。或许奇点思想的高度推测性导致了学术界的抵制。

我认为这种抵制是令人遗憾的，因为奇点思想显然是一个重要的思想。支持奇点的论证是我们应当认真对待的。围绕奇点的问题

4 正如文奇（1993）所指出的，斯坦尼斯拉夫·乌拉姆（1958）描述了一次与约翰·冯·诺依曼的对话，其中该术语以相关的方式被使用：“一次对话聚焦于技术不断加速的进步和人类生活方式的改变，这给人一种接近人类历史中某个本质奇点的表象，超过这个奇点，我们所知的人类事务将无法继续。”⁵ 尤德科夫斯基（2007）对“奇点”的用法进行了有用的分类。他区分了与库兹韦尔相关的“加速变化”学派、与文奇相关的“事件视界”学派以及与古德相关的“智能爆炸”学派。斯马特（1999-2008）给出了相关思想的详细历史，特别关注加速变化。⁶ 有一些例外：学术界的讨论包括博斯特罗姆（1998；2003）、汉森（2008）、霍夫施塔特（2005）和莫拉维克（1988；1998）。霍夫施塔特于 1999 年在印第安纳大学和 2000 年在斯坦福大学组织了关于超级智能机器前景的研讨会，最近，博斯特罗姆在牛津大学的人类未来研究所组织了一系列相关活动。

奇点具有巨大的实践和哲学意义。

从实践角度看：如果存在奇点，它将成为地球历史上最重要的事件之一。智能爆炸具有巨大的潜在益处：治愈所有已知疾病、消除贫困、取得非凡的科学进步等等。它也具有巨大的潜在危险：人类灭绝、交战机器的军备竞赛、摧毁地球的力量。因此，即使奇点出现的可能性很小，我们也应当认真思考它可能采取的形式，以及我们能否做些什么来积极地影响其结果。

从哲学角度看：奇点提出了许多重要的哲学问题。智能爆炸的基本论证本身就具有哲学趣味，它迫使我们深入思考智能的本质以及人工机器的思维能力。

智能爆炸的潜在后果迫使我们深入思考价值、道德、意识以及个人身份。实际上，奇点引出了哲学中一些最艰深的传统问题，同时也提出了新的哲学问题。

此外，哲学问题与实践问题相互交织。要判断是否可能发生智能爆炸，我们需要更好地理解智能是什么，以及机器是否可能拥有智能。要判断智能爆炸是好事还是坏事，我们需要思考智能与价值之间的关系。要判断我们能否在后奇点世界中发挥重要作用，我们需要知道人类身份能否在认知系统增强（或许通过上传到新技术）后得以存续。这些是生死攸关的问题，可能在未来几十年或几个世纪内摆在我们面前。

要想有希望回答这些问题，我们需要清晰地思考其中的哲学议题。

在下文中，我将探讨其中一些哲学与实用层面的问题。首先，我将阐述支持奇点论的论证：是否存在充分理由相信将会出现智能爆炸？其次，我将考虑如何应对奇点：如果奇点有可能发生，我们如何最大化实现良好结果的概率？最后，我将探讨后奇点世界中人类的地位，特别关注上传相关的问题：上传后的人类是否具有意识，以及上传是否会保留个人身份？

我的讨论必然带有推测性质，但我认为至少可以以一定程度的严谨性来推理推测性结果。例如，通过将支持某一推测性论点的论证形式化为前提与结论，人们可以看清反对者需要否定哪些内容才能否定该论点，进而评估这样做的代价。我不会试图给出

本文中不会提供决定性的论证，也不会试图对上述问题给出最终且确定的答案，但我希望鼓励其他人进一步思考这些问题。⁷

2 支持奇点的论证

为了以更严谨的形式分析支持奇点的论证，引入一些术语会有所帮助。设 AI 为达到或超过人类水平的人工智能（即至少与普通人类一样智能）。设 AI + 为超过人类水平的人工智能（即比最聪明的人类更智能）。设 AI ++（或超级智能）为远超人类水平的人工智能（例如，至少超出最聪明人类的程度，相当于最聪明人类超出老鼠的程度）。⁸ 那么，我们可以将支持智能爆炸的论证表述如下：

1. There will be AI+.
2. 如果存在 AI +，那么将会出现 AI ++。
- _____
3. There will be AI++.

此处，前提 1 需要独立支持（稍后详述），但通常被认为具有合理性。前提 2 是智能爆炸的关键主张，并得到上文所述古德的推理支持。结论表明将会出现超级智能。

该论证依赖于如下假设：存在智能这种东西，并且可以在不同系统之间进行比较；否则，人工智能 + 与人工智能 ++ 的概念甚至无法成立。当然，这些假设可能会受到质疑。有人可能认为，不存在任何单一属性值得被称为“智能”，或者相关属性无法被测量和比较。然而，目前我将在一个简化假设下继续讨论，即存在一种智能测度，能够为任意系统赋予一个智能值。稍后

⁷ 本文的主要主题此前已被他人多次讨论，尤其是在前面提到的非学术圈中。我撰写本文的主要目的是对其中一些主题（尤其是关于智能爆炸的主张以及关于上传的主张）进行哲学分析，旨在探索并可能强化这些思想所依赖的基础，同时帮助将这些主题引入哲学家和科学家的视野。⁸ 按照惯例，我将“AI”及其相关词用作一般术语（“存在一个 AI”）、形容词（“存在一个 AI 系统”）以及集合名词（“存在 AI”）。

我将考虑如何在不依赖该假设的情况下表述这一论证。

我还将假设智能与速度在概念上是相互独立的，因此，在没有其他相关变化的情况下，速度的提升不计为智能的提升。

我们可以通过将对前提 1 的支持拆分为两个步骤来稍微完善该论证。我们还可以添加关于时间框架以及奇点潜在阻碍因素的限定条件。

1. 将会出现人工智能（不久之后，除非存在阻碍因素）。
2. 如果存在人工智能，那么将会出现人工智能 + （紧随其后，除非存在阻碍因素）。
3. 如果存在人工智能 + ，那么将会出现人工智能 ++ （紧随其后，除非存在阻碍因素）。
- 4. 将会有 AI ++ （在不久之后，除非有阻碍因素）。

时间框架变量的精确值并不太重要。但我们可以规定，“不久之后”意味着“在几个世纪之内”。这一估计与许多奇点倡导者的观点相比是保守的，他们提出的是几十年而非几个世纪。例如，古德（1965）预测到 2000 年会出现超智能机器，文奇（1993）预测在 2005 年至 2030 年之间会出现超越人类的智能，尤德科夫斯基（1996）预测到 2021 年会出现奇点，而库兹韦尔（2005）预测到 2030 年会出现人类水平的人工智能。其中一些估计（如尤德科夫斯基的）依赖于对硬件趋势的外推。⁹ 我个人的观点是，人工智能的历史表明，通往 AI 之路上的最大瓶颈是软件而非硬件：我们必须找到正确的算法，而目前还没有人接近找到它们。因此，我认为硬件外推在这里并不是一个好的指导。其他估计（如库兹韦尔的）依赖于对何时能够人工模拟整个人脑的估计。我的感觉是，大多数神经科学家认为这些估计过于乐观。就我个人而言，如果未来三十年内出现人类水平的人工智能，我会感到惊讶。

尽管如此，我对 2100 年之前出现人类水平的人工智能的置信度略高于二分之一。无论如何，我认为从几十年到几个世纪的转变使这一预测变得保守而非激进，同时仍将时间框架保持在与当前足够接近的范围内，以使结论具有意义。

⁹ 尤德科夫斯基的网络文章现在被标记为“已过时”，在后来的工作中，他并不认可这一估计或来自硬件趋势的论证。关于硬件外推在此处的作用，以及更广泛地关于几十年数量级时间框架估计的怀疑，参见霍夫施塔特（2005）。

相比之下，我们可以规定“不久之后”意味着“几十年内”。鉴于计算机技术总是不断进步，人们很自然地认为一旦有了人工智能，人工智能 + 就指日可待。而智能爆炸的论证表明，在那之后不久就会从人工智能 + to AI++ 迅速迈进一步。我认为在这里提出“几年内”并非不合理（有些人会认为第二步是“几天内”甚至更快），但如前所述，“几十年内”是保守的，同时仍然有趣。至于“过不了多久”，我们可以规定这是“不久”和两个“不久之后”的总和。就目前的目的而言，这足够接近“几个世纪内”，其理解比第一个前提中的用法稍微宽松一些，以允许额外一个世纪左右。

至于阻碍因素：我将规定这些是任何阻止智能系统（人类或人工）展现其创造智能系统能力的事物。潜在的阻碍因素包括灾难、不情愿和主动阻止。¹⁰ 例如，核战争可能极大地阻碍我们的技术能力，或者我们（或我们的后继者）可能认为奇点是一件坏事，并阻止可能带来它的研究。我认为人工智能内部的考虑不能排除这些可能性，尽管我们可能基于其他理由争论它们的可能性有多大。无论如何，阻碍因素的概念仍然受到高度限制（重要的是，阻碍因素没有被定义为任何会阻止奇点的东西，那会使结论近乎琐碎），并且结论——在没有阻碍因素的情况下将出现超级智能——足够有力，值得关注。

我们可以将这三个前提视为等价前提（将存在至少与我们自身智能相当的人工智能）、扩展前提（人工智能将很快扩展为人工智能 + ）和放大前提（人工智能 + 将很快被大幅放大为人工智能 ++ ）。为什么要相信这些前提？我将按顺序讨论它们。

前提 1：将存在人工智能（不久之后，在没有阻碍因素的情况下）。

支持第一个前提的一个论据是仿真论证，它基于大脑仿真的可能性。这里（遵循 Sandberg 和 Bostrom 2008 的用法），仿真可以

我认为，当某人具备做某事的能力时，如果他们有足够的动机去做，并且处于相对有利的环境中，他们就会去做。因此，挫败因素可以分为动机性挫败因素（涉及动机不足）和情境性挫败因素（涉及不利环境，如灾难）。

不利环境（阻止能力显现）与那些意味着能力从一开始就不存在的环境之间，存在一条模糊的界限——例如，资源限制可能被归入这条界限的任何一侧——但这对我们的目的来说并不重要。

理解为近似仿真：在这种情况下，对内部过程进行足够详细的仿真，以复制近似的行为模式。

（一）人脑是一台机器。

（二）我们将有能力（不久之后）仿真这台机器。

（三）如果我们仿真这台机器，将会出现人工智能。

（四）在没有挫败因素的情况下，（不久之后）将会出现人工智能。

第一个前提由我们对生物学（实际上也由我们对物理学）的了解所暗示。身体的每个器官似乎都是一台机器：即一个由受规律支配的部分以受规律支配的方式相互作用的复杂系统。大脑也不例外。第二个前提源于以下主张：微观物理过程可以被任意精确地仿真，并且任何机器都可以通过任意精确地仿真微观物理过程来被仿真。

更普遍地说，科学技术的进步也暗示了这一点：我们正在逐步加深对生物机器的理解，并不断增强模拟它们的能力，而且这一领域的进展似乎没有极限。第三个前提源自这样一个定义性主张：如果我们模拟大脑，这将复制人类行为的近似模式，同时还有这样一个主张：这种复制将导致人工智能。结论由这些前提以及另一个定义性主张得出：在没有阻碍因素的情况下，系统将展现其相关能力。

人们可能以各种方式抵制这一论证。有人可能认为大脑不仅仅是一台机器；有人可能认为我们永远没有能力模拟它；还有人可能认为模拟它未必会产生人工智能。现有对人工智能的各种抵制形式分别采取了这些立场。例如，卢卡斯（J.R. Lucas, 1961）认为，由于与哥德尔定理相关的原因，人类比任何机器都更复杂。德雷福斯（Hubert Dreyfus, 1972）和彭罗斯（Roger Penrose, 1994）认为，人类认知活动永远无法被任何计算机器模拟。塞尔（John Searle, 1980）和布洛克（Ned Block, 1981）认为，即使我们能够模拟人脑，也不能推出模拟本身具有心灵或智能。我在其他地方论证过所有这些反对意见都不成立。¹¹ 但就当前目的而言，我们可以将其中许多搁置一旁。为了回应卢卡斯、彭罗斯和德雷福斯的反对意见，我们可以指出，奇点理念并不要求人工智能是经典计算系统，甚至不要求它必须是计算系统。例如，彭罗斯（与卢卡斯一样）认为大脑不是

通常意义上的算法系统，但他承认它是一种依赖某些非算法量子过程的机械系统。德雷福斯认为大脑不是遵循规则的符号系统，但他承认它可能仍然是一种依赖亚符号过程（例如联结主义过程）的机械系统。如果是这样，那么这些论证就没有理由否认我们可以构建利用相关非算法量子过程或相关亚符号过程的人工系统，从而模拟人脑。

至于塞尔和布洛克提出的异议，这些异议依赖于这样一个论点：即使一个系统复制了我们的行为，它也可能缺少重要的“内在”心理方面：意识、理解、意向性等等。在本文后面，我将主张这样一种观点：如果一个系统在我们的世界中不仅复制了我们的输出，还复制了我们的内部计算结构，那么它也将复制重要的内在心理方面。不过，就目前而言，我们可以通过规定来搁置这些异议：为了论证的目的，智能完全根据行为和行为的倾向来衡量，其中行为在操作上被理解为系统产生的物理输出。在这种意义上将会有 AI ++ 的结论仍然足够有力，值得关注。如果存在产生看似超级智能输出的系统，那么无论这些系统是否真正具有意识或智能，它们都将对世界其他部分产生变革性的影响。

也许最重要的剩余阻力形式是声称大脑根本不是机械系统，或者至少非机械过程在其功能中扮演着无法被模拟的角色。这种观点最自然地与某种笛卡尔二元论相结合，认为心理的某些方面（如意识）是非物理的，但仍然在影响大脑过程和行为方面发挥着重要作用。如果存在这样的非物理过程，它们或许仍然可以被模拟或人工创造，但这并不明显。如果这些过程无法被模拟或人工创造，那么人类级别的 AI 可能是不可能的。

尽管我对关于意识的某些形式的二元论抱有同情，但我认为没有多少证据支持这种异议所需的强形式的笛卡尔二元论。

迄今为止的证据权重表明大脑是机械的，而且我认为即使意识在产生行为中扮演因果角色，也没有太多理由认为它的

11 关于强人工智能的一般论证以及对许多不同异议的回应，参见查尔默斯（1996，第9章）。关于对彭罗斯和卢卡斯的回应，参见查尔默斯（1995）。关于全脑仿真当前前景的深入讨论，参见桑德伯格和博斯特罗姆（2008）。

角色是不可仿真的。但鉴于我们对大脑和意识所知甚少，我认为此事尚不能视为完全定论。因此，这种形式的反对意见至少应当被记录在案。

支持前提 1 的另一个论据是进化论据，其论证如下。

(i) 进化产生了人类水平的智能。

(二) 若进化产生了人类水平的智能，则我们能够制造出人工智能（在之前长）。

(三) 若无阻碍因素，人工智能（AI）不久将会出现。

这里，其思想是：既然进化产生了人类水平的智能，那么这种智能并非完全不可及。此外，进化运作时无需任何先行的智能或预见。如果进化能以这种非智能的方式产生某种事物，那么原则上人类应当能够利用自身的智能，以快得多的速度将其制造出来。

同样，这一论证可能遭到抵制，或许通过否认进化产生了智能，或许通过主张进化产生智能所依赖的过程我们无法机械地复制。后一种思路可能认为，进化需要超智能干预的帮助，或在过程中需要其他非机械过程的辅助，或需要一段我们永远无法人工复制的极其复杂的历史，或需要巨大的运气。尽管如此，我认为该论证至少为其结论提供了一个初步的案例。

我们可以通过将论证的两个前提中的“进化产生了人类水平的智能”改为“进化机械地、非奇迹般地产生了人类水平的智能”，来澄清对这种阻力的反对理由。这样一来，前提 (ii) 就更加可信了。

前提 (i) 现在将被那些认为进化涉及非机械过程、超自然干预或异常大量运气的人所否定。

但该前提仍然可信，且论证的结构得到了澄清。

当然，这些论证并未告诉我们人工智能将如何首次实现。它们至少提示了两种可能性：大脑仿真（逐神经元地模拟大脑）和人工进化（通过变异和选择进化出一群人工智能）。还有其他可能性：例如直接编程（从头编写人工智能程序，或许还附带一个包含世界知识的数据库），

以及机器学习（创建一个初始系统和一个学习算法，在接触到合适的环境后导致人工智能）。也许还有其他途径。我怀疑直接编程不太可能成为成功的路径，但我不排除其他任何途径。

必须承认，迄今为止，通往人工智能的每一条道路都被证明异常困难。人工智能的历史包含了一系列由方法先驱者做出的乐观预测，随后是失望和重新评估的时期。例如，对于涉及直接编程、机器学习和人工进化的各种方法来说，情况都是如此。许多乐观预测在当时并非明显不合理，因此它们的失败应当促使我们以重要的方式重新评估我们之前的信念。尚不清楚应当从中得出什么教训：艾伦·珀利斯曾提出“在人工智能领域花上一年时间，足以让人相信上帝”。因此，这里的乐观情绪应当用谨慎来调和。尽管如此，我个人的观点是，综合考虑各种因素，仍然明显倾向于认为人工智能最终是可能的。

前提 2：如果存在人工智能，那么（在不久之后，且没有阻碍因素的情况下）将会出现人工智能 +。

支持延伸前提的一个理由来自信息技术的进步。每当我们推出一种计算产品，该产品很快就会因技术进步而过时。我们应当预期同样的情况也适用于人工智能。在我们制造出人类水平的人工智能之后不久，我们就会制造出更加智能的人工智能：人工智能 +。

我们可以这样表述这一论证。

（一）如果存在人工智能，那么人工智能将由一种可扩展的方法产生。

（二）如果人工智能由一种可扩展的方法产生，那么我们将有能力（不久之后）扩展该方法。

（三）扩展产生人工智能的方法将产生人工智能 +。

———（四）在没有否决因素的情况下，如果存在人工智能，那么（不久之后）将存在人工智能 +。

这里，可扩展的方法是指一种能够被轻易改进、从而产生更智能系统的方法。根据这一定义，前提（二）和（三）立即成立。唯一的问题是前提（一）。

并非每一种创造人类水平智能的方法都是可扩展的方法。例如，当前创造人类水平智能的标准方法是生物繁殖。但

生物繁殖并非显然可扩展。例如，如果我们拥有更优越的性行为，并不能由此推断我们的后代将成为天才。或许借助基因工程等未来技术，生物繁殖将具备可扩展性，但无论如何，其概念要点是明确的。

另一种并非显然可扩展的方法是脑仿真。超过某一程度后，并非仅仅更好地仿真大脑就能产生更智能的系统。因此，脑仿真本身并非通往人工智能 + 的明确路径。尽管如此，脑仿真可能加速通往人工智能 + 的进程。例如，在更快的硬件上或大型集群中运行的仿真大脑，可能比没有它们时更快地创造出人工智能 + 。我们或许还能以显著方式修改仿真大脑以提升其智能。我们可能利用大脑仿真大幅增进对人类大脑及一般认知处理的理解，从而导向人工智能 + 。但脑仿真本身并不足以实现：若其发挥作用，则需要其他通往人工智能 + 的路径加以补充。

AI+

然而，其他创造人工智能的方法似乎确实可能具备可扩展性。例如，如果我们通过直接编程产生人工智能，那么与几乎所有已编写的程序一样，该程序很可能在多个方面可改进，从而很快导向人工智能 + 。

如果我们通过机器学习产生人工智能，很可能不久之后我们就能改进学习算法并扩展学习过程，从而导向人工智能 + 。如果我们通过人工进化产生人工智能，很可能不久之后我们就能改进进化算法并扩展进化过程，从而导向人工智能 + 。

为论证前提 (i)，只需论证人工智能要么直接由可扩展方法产生，要么若由不可扩展方法产生，该方法本身将很快导向可扩展方法。我个人的观点是，这两种主张均具合理性。

我认为，如果人工智能 (AI) 终究是可能的（正如该前提的前件所假设的），那么应当能够通过例如学习或进化过程来产生人工智能。我还认为，如果人工智能是通过诸如大脑仿真这类不可扩展的方法产生的，那么这种方法很可能沿着上述思路极大地帮助我们寻找可扩展的方法。因此，我认为有充分理由相信前提 (i) 。

为了反驳该前提，反对者可能会提出，我们正处于智能空间中的一个极限点：也许我们已经达到了一个系统所能达到的最高智能，或者至少处于一个局部最大值，即从像我们这样的系统到更智能的系统之间没有容易的路径。反对者还可能提出，尽管智能空间并非以这种方式受限，但我们创造智能的能力存在极限，而这些极限恰好就位于创造人类水平智能的那一点上。我认为这些主张并没有太大的先验合理性，

但至少应当记录下这种形式的反驳的可能性。

还存在一些不依赖于首先产生人工智能再扩展该方法的通往超人类智能的潜在路径。其中一条路径是大脑增强。我们可能会发现增强我们大脑的方法，使得由此产生的系统比迄今为止的任何系统都更智能。这可以通过遗传、药理、手术甚至教育手段来实现。可以通过在大脑中植入新的计算机制来实现，无论是替换还是扩展现有的大脑机制。或者，可以简单地通过将大脑嵌入一个日益复杂的环境中来实现，从而产生一个“扩展心智”（Clark and Chalmers 1998），其能力远超未扩展的大脑。

增强后的大脑是否应算作人工智能或人工智能 +，这一点并不明确。某些潜在的增强将产生一个完全生物性的系统，也许带有经过人工增强的生物部件（让我们说，生物性是指基于 DNA）。其他增强将产生一个同时具有生物和非生物部件的系统（我们可以使用基于 DNA 的有机组成作为一个粗略的现成标准来判断生物性）。至少在近期内，所有这些系统都将被视为人类，因此在某种意义上它们并不具有超人类智能。

为当前目的，我将规定人类智能的基线设定为当前人类标准，并且我将规定至少那些认知系统中含有非生物成分的系统（例如脑植入物和技术扩展心智）算作人工的。因此，足够智能的此类系统将算作人工智能 +。

与其他人工智能 + 系统一样，增强大脑暗示了潜在的智能爆炸。增强系统可能找到超越我们所能发现的进一步增强方法，从而引发一系列越来越智能的系统。然而，由于增强大脑始终依赖于生物核心，可能存在局限性。生物处理可能存在速度限制，此外大脑架构很可能施加认知限制。

因此，超过某一点后，我们可以预期非基于大脑的系统比基于大脑的系统更快、更智能。鉴于此，我怀疑保留生物核心的大脑增强充其量只是智能爆炸的第一阶段。在某个时刻，要么大脑将以完全摒弃生物核心的方式被“增强”，要么将设计出全新的系统。因此，在下文中我将通常专注于非生物系统。尽管如此，大脑增强引发了许多相同的问题，并且很可能发挥重要作用。

前提 3：如果存在人工智能 +，那么（不久之后，在没有阻碍因素的情况下）将存在人工智能 ++。

支持放大前提的论证本质上就是上文给出的 IJ.古德的论证。

我们可以将其展开如下。假设存在一个人工智能 + 。我们规定 AI1 是第一个 AI+ ，并且 AI0 是其（人类或人工的）创造者。（如果非 AI+ 系统与人工智能 + 系统之间没有明确界限，我们可以让 AI1 为任何比其创造者更智能的人工智能 + 。）我们规定 δ 是 AI1 与 AI0 之间的智能差异，并且如果一个系统与另一个系统之间存在至少 δ 的差异，则该系统显著更智能。我们规定 $n > 1$, an AI_{n+1} 是由人工智能 n 创造并且显著比其创造者更智能的人工智能。

- (i) 如果存在人工智能 + ，那么存在一个 AI1。
- (ii) 对于所有 $n > 0$, if an AI_n 存在的情况，在没有阻碍因素的情况下，将存在人工智能 $n+1$ 。
- (iii) 若对所有 n 均存在 AI n ，则将存在 AI ++ 。
- (iv) 若存在 AI + ，则在无阻碍因素的情况下，
将存在 AI ++ 。

此处前提 (i) 依定义为真。前提 (ii) 由三个断言推出：(a) 定义性断言：若 AI n 存在，则其由 AI $n-1$ 创造，且比 AI $n-1$ 更智能；(b) 定义性断言：若 AI n 存在，则在无阻碍因素的情况下，其将展现创造智能系统的能力；(c) 实质性断言：若 AI n 显著比 AI_{n-1} 更智能，则其有能力创造比 AI $n-1$ 所能创造的任何系统都显著更智能的系统。前提 (iii) 由以下断言推出：若存在一个 AI 系统序列，其中每个系统均显著比前一个更智能，则最终将出现超级智能。结论由逻辑与数学归纳法从前提推出。

此处所述结论省略了时间性断言“不久之后”。可通过援引辅助前提来论证该时间性断言：AI + 系统将运行在比我们自身快得多的硬件上，因此从 AI + 开始的步骤很可能比从人类到 AI + 的步骤快得多。

在逻辑空间中存在抵制该论证的余地。首先，可以指出论证的可靠性取决于所使用的智能测度：若存在某个智能测度使论证成立，则几乎必然存在一个重新标度的智能测度（或许是对数测度）使论证失败。因此，为使论证有意义，我们需要将其限制在那些与直观智能测度足够吻合的智能测度上，以使结论捕捉到直观断言：将存在远超人类智能的 AI。

智能。

与此相关，可以通过主张任意次数的智能提升（每次提升 δ ）未必累加为 AI + 与 AI ++ 之间的差异来抵制前提 (iii)。若我们规定 δ 为智能之比，且 AI ++ 需要人类智能的某个固定倍数（例如 100 倍），则此类抵制将被排除。当然，为使结论有意义，则如上一段所述，智能测度必须使得该固定倍数足以构成某种可合理视为超级智能的事物。

该论证中最关键的假设在于前提 (ii) 和支持性主张 (c)。我们可以将这一假设称为比例论题：它认为智能的提升（或某种特定类型的提升）总是导致设计智能系统能力的相应提升。反对者最有力的抵抗方式或许是提出这一论题可能不成立。它可能不成立，因为智能空间中存在上限，正如对最后一个前提的抵抗一样。它可能不成立，因为存在收益递减点：或许超过某一点后，智能提升 10% 只导致下一代提升 5%，再下一代只提升 2.5%，以此类推。它可能不成立，因为智能与设计能力并不高度相关：更智能的系统未必是更好的设计者。我将在第 4 节“结构性障碍”下回到这些类型的抵抗。

人们可以合理地怀疑比例论题是否对所有可能系统以及直至无穷都成立。为应对这一反对意见，可以将前提 (ii) 限制在某一类人工智能系统上。我们只需要某个性质 φ ，使得具有 φ 的 AI_n 总能产生具有 φ 的 AI_{n+1} ，并且我们能够产生具有 φ 的人工智能 +。也可以将比例论题限制在 δ 的特定值上（而非所有可能值），并将 n 限制在相对较小的范围 $n < k$ 内（其中 $k =$ 为 100，例如），只要 δ 的 k 次提升足以实现超级智能。

值得注意的是，原则上通往人工智能 ++ 的递归路径不必从人类水平开始。如果我们有一个整体智能远低于人类水平、但仍有能力自我改进或设计进一步系统的系统，从而产生智能显著更高的系统（并如此递归下去），那么上述相同机制最终将导致人工智能、人工智能 + 和人工智能 ++。因此，原则上通往人工智能 ++ 的路径只要求我们创造某种自我改进系统，而不要求我们直接创造人工智能或。在实践中，具有以这种方式放大智能能力的系统最清晰的案例

AI+

是人类案例（通过创造人工智能 +），并且并不明显会存在智能较低

但具有这种能力的系统。¹² 但至少应当注意到这里的替代假设。

3 无智能的智能爆炸

迄今为止的论证依赖于对智能存在且可测量这一假设的不加批判的接受。许多智能研究者接受这些假设。特别是，人们普遍认为存在一种“通用智能”，通常标记为 g ，它位于认知能力的核心，并与许多不同的认知能力相关。¹³ 然而，仍有许多人质疑这些假设。反对者认为不存在智能这种东西，或者至少不存在单一的东西。按照这种观点，评估认知主体的方式有很多种，没有一种值得被赋予“智能”的规范地位。

人们也可能认为，即使存在一种适用于人类领域的智能的规范概念，也远不清楚这个概念能否扩展到任意非人类系统，包括人工系统。或者人们可能认为，在人类内部成立的通用智能与其他认知能力之间的相关性，不一定在任意非人类系统之间成立。因此，最好能够在不假设智能概念的情况下表述关键论点和论证。

我认为这是可以做到的。我们可以转而依赖认知能力的一般概念：某种可以在系统之间进行比较的特定能力。为了论证的目的，我们只需要 (i) 一种自我放大的认知能力 G ：这种能力的提升会伴随着创造具有该能力的系统的能力的相应（或更大）提升，(ii) 我们能够创造 G 能力大于我们自身的系统的论点，以及 (iii) 一种我们关心的相关认知能力 H ，使得 H 中的某些小幅提升总是可以通过 G 的足够大的提升来产生。鉴于这些假设，可以推出

¹² 施密德胡伯 (Schmidhuber, 2003) 提出的“哥德尔机”为低于人工智能层面的自我改进系统提供了一个理论示例，尽管它们尚未被实现，且将其作为通往人工智能的路径存在巨大的实用障碍。进化过程或许可算作一个间接示例：智能较低的系统通过繁殖、变异和自然选择，有能力创造出智能更高的系统。这种版本最终将与通往人工智能的进化路径以及人工智能 ++ 殊途同归。就当前目的而言，我将“创造”理解为一种比这更直接的机制。¹³ 弗林 (Flynn, 2007) 对一般智力之争以及相信存在此类测度的理由作了出色概述。沙利齐 (Shalizi, 2007) 论证称， g 因子是一种统计工件。莱格 (Legg, 2008) 在机器超级智能的语境下对这些问题进行了精辟讨论。

即若无阻碍因素， G 将发生爆炸，而 H 也将随之爆炸。（本节末尾将给出一个形式化分析，使假设与论证更为精确。）在原始论证中，智能同时扮演了 G 和 H 的角色。但存在多种不诉诸智能的 G 和 H 的合理候选。例如， G 可以是编程能力的测度，而 H 是某种特定推理能力的测度。在此，认为我们能够创造出编程能力高于自身的系统，并且编程能力更高的系统将能够进而创造出编程能力更高的系统，并非不合理。同样，认为编程能力将与各种特定推理能力的提升相关联，也并非不合理。若如此，我们应当预期，若无阻碍因素，所讨论的推理能力将发生爆炸。

这一分析揭示了在思考奇点时能力之间相关性的重要性。在实践中，我们关心奇点，是因为我们关心各种特定能力可能发生的爆炸：从事科学的能力、从事哲学的能力、制造武器的能力、接管世界的能力、带来世界和平的能力、获得幸福的能力。这些能力中的许多或大多数本身并非自我放大式的，因此我们只能期望这些能力在与其他自我放大能力相关联的程度上发生爆炸。而对于任何给定的能力，它是否以这种方式与自我放大能力相关联，是一个实质性问题。

或许，该论点对于从事科学的能力而言，比对于获得幸福的能力而言，在初步印象上更为合理，但这些问题并非微不足道。

这一点同样适用于智能分析，该分析之所以引人关注，依赖于智能与各种特定能力相关的观点。即使承认智能这一概念，智能究竟与什么相关的问题也并非微不足道。根据智能的测度方式不同，我们可能预期它与某些能力（如计算能力）高度相关，而与其他能力（如智慧能力）相关性较低。同样远非显而易见的是，在人类内部与某些认知能力高度相关的智能测度，在人工系统中也会与这些能力相关。

尽管如此，有两点观察有助于缓解这些担忧。第一点是，相关性不必适用于所有系统，甚至不必适用于我们可能创造的所有系统。只需存在某种类型的系统，使得相关性在该类型的所有系统中都成立。如果存在这样的类型（例如，架构的一个子集），那么递归地创建该类型的系统将导致爆炸。第二点是，自我放大能力 G 不必与认知能力 H 直接相关，而只需与 H' 相关，即创造具有 H 能力的系统的能力。

例如，虽然设计能力与幸福相关的观点并不特别合理，

但设计能力与创造幸福系统的能力相关的观点则更为合理一些。如果是这样，那么可能性仍然存在：随着设计能力的爆炸式增长，幸福也将随之爆炸式增长，无论是在主传承线中还是在分支线中，至少如果设计者选择展现他们创造幸福系统的能力。

以下是一个简单的形式分析（对形式细节不感兴趣的读者可以跳过本节剩余部分）。我们说一个参数是从认知系统到正实数的函数。一个参数 G 度量一个能力 C ，当且仅当对所有认知系统 a 和 b ， $G(a) > G(b)$ 且 a 比 b 具有更大的能力 C （也可以要求 G 的程度在某种形式或直观意义上对应于 C 的程度）。一个参数 G 在 φ -systems 中严格追踪一个参数 H （其中 φ 是某个性或系统类），当且仅当每当 a 和 b 是 φ -systems 且 $G(a) > G(b)$ ，则 $H(a)/H(b) \geq G(a)/G(b)$ 。一个参数 G 在 φ -systems 中宽松追踪一个参数 H ，当且仅当对所有 y 存在 x 使得（非空真地）对所有 φ -systems a ，如果 $G(a) > x$ ，则 $H(a) > y$ 。一个参数 G 在 φ -systems 中严格 / 宽松追踪一个能力 C ，如果它在 φ -systems 中严格 / 宽松追踪一个度量 C 的参数。这里，严格追踪要求 G 的增加总是产生 H 的成比例增加，而宽松追踪仅要求 G 的足够大的增加总能产生 H 的某个小增加。对于任何参数 G ，我们可以定义一个参数 G' ：这是一个度量系统创造具有 G 的系统的能力的参数。更具体地说， $G'(x)$ 是使得 x 有能力创造系统 y 且 $G(y) = h$ 的 h 的最高值。然后我们可以说 G 是一个自放大参数（相对于 x ），如果 $G'(x) > G(x)$ 且 G 在 x 下游的系统中严格追踪 G' 。这里，一个系统在 x 的下游，如果它是通过从 x 开始且 G 值不断增加的系统的序列被创造的。最后，我们说对于参数 G 或能力 H ， $G++$ 和 $H++$ 系统是 G 值和能力 H 远超人类水平的系统。

现在我们只需要以下前提：

(i) G 是一个自放大参数（相对于我们）。(ii) G 宽松追踪认知能力 H （在我们下游）。

————— (iii) 在没有击败者的情况下，将会有 $G++$ 和 $H++$ 。

结论的前半部分仅从前提 (i) 得出。令 AI_0 为我们。如果 G 是相对于我们的自放大参数，那么我们能够创造系统 AI_1 使得

$G(AI_1) > G(AI_0)$. Let $\delta = G(AI_1)/G(AI_0)$ 。因为 G 严格追踪 所以 $G', G'(AI_1) \geq \delta G'(AI_0)$. AI_1 能够创造系统 AI_2 使得 $G(AI_2) \geq \delta G(AI_1)$ 。同样，对所有 n ， AI_n 能够创造人工智能 AI_{n+1} ，使得 $G(AI_{n+1}) \geq \delta G(AI_n)$ 。因此，在没有击败者的情况下，将产生任意高的 G 值。结论的后半部分直接由 (ii) 和结论的前半部分得出。任意高的 G 值可以产生任意高的 H 值，因此将产生任意高的 H 值。

这些假设可以通过多种方式被削弱。如前所述， G 只需松散地追踪的不是 H 而是 H' ，其中 H' 衡量创造具有 H 的系统的的能力。此外， G 与 G' 之间以及 G 与 H 或 H' 之间的追踪关系，不必在我们下游的所有系统中都成立：只需存在一个类型 φ ，使得在我们下游的 φ -systems 中， G 严格追踪 $G'(\varphi)$ （创造具有 G 的 φ -system 的能力）并松散地追踪 H 或 H' 。我们不必要求 G 严格自我放大：只需 G 和 H （或 G 和 H' ）联合自我放大，即 G 和 H 的高值会导致各自显著更高的值。我们也不必要求这些参数永远自我放大。只需 G 在 $G++$ 所需的代数内自我放大（如果 $G++$ 需要 G 增加 100 倍，那么 $\log \delta 100$ 代就足够了），并且对于 $H++$ （如果 $H++$ 需要 H 增加 100 倍，并且松散追踪关系意味着这将由 G 增加 1000 倍产生，那么 $\log \delta 1000$ 代就足够了）。其他削弱方式也是可能的。

4 奇点面临的障碍

根据当前分析，智能爆炸源于自我放大的认知能力（上述前提 (i)）、该能力与其他重要认知能力之间的相关性（上述前提 (ii)）以及这些能力的显现（结论）。更简洁地说：自我放大加上相关性加上显现 = 奇点。

这一分析揭示了奇点面临的一些潜在障碍：即可能不存在奇点的各种方式。可能不存在有趣的自我放大能力。

可能不存在有趣的相关能力。或者可能存在击败者，使得这些能力无法显现。我们可以分别称之为结构性障碍、相关性障碍和显现障碍。

我认为，针对这三类障碍中的任何一类，都不存在决定性的反驳论证。

然而，我倾向于认为显现障碍是最严重的障碍。在下文中，我将简要讨论所有三类障碍。

结构性障碍：存在三种相互重叠的方式，可能导致缺乏相关的自我放大能力，我们可以通过聚焦于智能的情形来加以说明。智能空间的极限：我们处于或接近智能空间的上限。起飞失败：尽管智能空间中存在更高的点，但人类智能并未处于一个起飞点，使我们能够创造出比自身更智能的系统。收益递减：尽管我们能够创造出比自身更智能的系统，但智能的增长从那时起逐渐递减。

因此，10% 的增长可能导致 5% 的增长，再导致 2.5% 的增长，依此类推，甚至在某个点之后完全不再增长。

关于智能空间的极限：虽然物理定律和计算原理可能对我们世界中可能存在的智能类型施加限制，但几乎没有理由认为人类认知已接近这些极限。更一般地说，如果进化恰好最近触及或接近了智能空间的上限，那将是令人惊讶的。

关于起飞失败：我认为，先前关于人工智能和人工智能 + 的初步论证表明，我们正处于各种能力（如编程能力）的起飞点。有初步理由认为，我们具备模拟大脑等物理系统的能力。

并且有初步理由认为，我们具备改进这些系统的能力。

关于收益递减：这些或许构成了最严重的结构性障碍。尽管如此，我认为比例论题具有一定的合理性，至少在直观的智能测度下是如此。如果说有什么的话，与智能相关的能力增长 10% 很可能引发各种智力突破，从而导致下一代智能的增长显著超过 10%。即使在人类之中，设计能力上相对较小的差异（例如，图灵与普通人之间的差异）似乎也会导致所设计系统上的巨大差异（例如，一台计算机与无足轻重之物之间的差异）。

即使存在收益递减，有限的智能提升与速度的大幅提升相结合，至少会产生智能爆炸的部分效应。

有人可能担心，从人类认知系统出发的“爬山”过程可能会陷入局部最大值，从而无法通过渐进步骤继续前进。我认为，智能空间的巨大维度以及可能路径的巨量数量使得这种可能性降低。此外，人工智能的设计并不局限于爬山：还有“跳跃式爬山”，即看到智能空间中较远处的一个有利区域，然后跳跃到那里。也许智能空间中存在某些区域（类似于集合论中的不可达基数？），仅靠爬山和跳跃式爬山无法到达，

但我认为有充分理由相信，这些过程至少能让我们远远超越普通人类的能力。

相关性障碍。可能存在一种或多种自我放大的认知能力 G，但它与我们感兴趣的许多能力并不相关。例如，编程能力的自我放大提升可能不会伴随其他有趣能力的提升，比如解决科学问题或社会问题的能力、发动战争或缔造和平的能力等。

我在上一节中讨论了相关性问题。我认为，各种认知能力之间可以预期多大程度的相关性，是一个实质性的开放问题。尽管如此，即使自我放大的能力（如设计能力）与许多认知能力仅弱相关，它们与创造具有这些能力的系统的能力之间的相关性可能会更强。可以预期多少相关性仍然是一个实质性问题，但我怀疑会有足够的相关能力来确保如果发生爆炸，那将是一次有趣的爆炸。

表现障碍。尽管存在一种自我放大的认知能力 G，我们或我们的后继者可能无法表现出创造具有更高 G 值（或更高认知相关能力 H 值）系统的能力。这里我们可以将挫败因素分为动机性挫败因素，即缺乏动机或存在相反动机阻止能力得以表现，以及情境性挫败因素，即其他不利环境阻止能力得以表现。这两类挫败因素可能出现在通往人工智能的路径上、从人工智能到人工智能 + 的路径上，或从人工智能 + to AI++ 开始的路径上。

情境性挫败因素包括灾难和资源限制。关于灾难，我当然不能排除全球战争或纳米技术事故（“灰色粘质”）在人工智能或人工智能 + 实现之前完全阻止技术进步的可能性。我也不能排除人工系统自身引发此类灾难的可能性。关于资源限制，值得注意的是，自然界中的大多数反馈回路因能源等资源限制而失去动力，这里也可能如此。尽管如此，可预见的能源资源很可能足以支撑多代人工智能 +，而人工智能 + 系统很可能开发出进一步利用能源资源的方法。类似情况也适用于财政资源和其他社会资源。

动机性挫败因素包括不愿和主动阻止。随着事件临近，大多数人可能不愿创造人工智能或人工智能 +。完全有可能出现对人工智能或人工智能 + 发展的主动阻止（或许通过法律、财政和

军事手段），尽管这种阻止能否无限期成功尚不明确。¹⁴ 而且，人工智能 + 系统当然可能不愿创造其后继者，或许因为我们将其设计为如此不愿，或许因为它们足够智能，意识到创造后继者不符合自身利益。此外，人工智能 + 系统可能具备阻止此类进展发生的能力。

奇点支持者可能会回应说，克服动机性挫败因素所需的只是创造一个单一的人工智能 +，它高度重视创造更强大的人工智能 +，那么奇点将不可避免。如果这样的系统是第一个被创造出来的人工智能 +，这个结论很可能是正确的。但只要这种人工智能 + 尚未被首先创造出来，它就可能受到其他人工智能 + 的控制，通往人工智能 ++ 的道路也可能被阻断。这里的问题取决于关于未来系统动机与能力的困难问题，而这些问题的答案难以预测。

无论如何，当前的分析更清楚地揭示了智能爆炸论题的支持者和反对者所承担的论证责任。反对者需要明确指出他们认为该论题的论证在何处失败：结构性障碍（如果是的话，具体是哪些）、相关性障碍、情境性挫败因素、动机性挫败因素。同样，支持者需要论证不存在这样的障碍或挫败因素。

就我个人而言，我认为虽然结构性和相关性障碍（尤其是比例性论题）提出了非平凡的问题，但至少有一个初步证据表明，在没有挫败因素的情况下，许多有趣的认知能力将会爆炸式增长。我认为最可能的挫败因素是动机性的。但我认为远非显而易见会存在挫败因素。因此，我认为奇点假说是我们应该非常认真对待的。

5 应对奇点

如果存在人工智能 ++，它将对世界产生巨大影响。因此，即使出现奇点的可能性很小，我们也需要认真思考它将采取的形式。存在许多

¹⁴ 当我在西点军校与学员和教职员讨论这些问题时，有人提出疑问：鉴于智能爆炸的风险，美国军方或政府其他部门是否会试图阻止人工智能或人工智能 + 的研发。共识是他们不会这样做，因为这种阻止只会增加人工智能或人工智能 + 首先被外国势力研发出来的可能性。一旦智能爆炸的潜在后果被认识到，人们甚至可能预期在某个时刻会出现人工智能军备竞赛。根据这种推理，尽管人工智能 + 从美国政府的角度来看存在风险，但中国人工智能 +（举例来说）的风险将远大于此。

后奇点世界可能呈现的不同形态。其中一些从我们的视角来看可能是可取的，而另一些则可能是不受欢迎的。

我们可以将关键问题表述如下：面对智能爆炸的可能性，我们如何最大化实现理想结果的几率？如果奇点不可避免，我们又如何最大化后奇点世界的期望价值？

在这里，价值与可取性至少可以分为两类。第一类是广义上的主体相对价值（“主观价值”，尤其是自利或审慎价值）：我们可以从主观立场出发，询问这样一个世界对我以及我所关心的人而言会有多好。

第二类是广义上的主体中立价值（“客观价值”，尤其是道德价值）：我们可以从相对中立的立场出发，询问这样一个世界的存在本身有多好。

我不会试图解决智能爆炸（主观或客观上）是好是坏的问题。我理所当然地认为，智能爆炸既有潜在的积极方面，也有潜在的消极方面。例如，终结疾病和贫困将是好事。摧毁所有有感知的生命将是坏事。人类被机器奴役至少在主观上是坏事。

其他潜在后果则更难评估。许多人会认为，人类永生将在主观上、或许也在客观上是好事，尽管并非所有人都同意。

用非人类系统大规模取代人类，在主观上很可能是坏事，但也有理由认为这在客观上是好事，至少如果一个人认为生命的客观价值与智能和复杂度相关的话。如果人类幸存下来，现有的人类传统和实践被迅速取代，一些人会认为这在主观上是坏事，但另一些人则不这么认为。

科学的巨大进步可能被视为客观上的好事，但也存在潜在的负面后果。可以论证的是，一个人周围持续不断的智能爆炸这一事实本身，在主观上可能是坏事，或许是因为不断的竞争和不稳定，或者因为某些智力活动会变得毫无意义。¹⁵ 另一方面，如果超级智能系统共享我们的价值观，它们大概有能力确保由此产生的局面符合这些价值观。

我不会在这里试图解决这些极其困难的问题。就目前而言，我们对事实和价值都感到不确定。也就是说，我们不知道后奇点世界会是什么样子，即使我们知道，评估其价值也并非易事。尽管如此，即使不解决这些问题，我们也能至少做出一些初步的概括，关于什么

¹⁵ 参见库兹韦尔（2005）、霍夫施塔特（2005）和乔伊（2000）关于奇点可能成为好事（库兹韦尔）和坏事（霍夫施塔特、乔伊）的众多其他方式的讨论。

样的结果会比其他结果更好。而且我们能够做出一些初步的概括，关于我们什么样的行动可能带来更好的结果。我在这里只尝试最粗略的概括，但这是值得高度关注的问题。

在短期内，关键问题是：我们应该如何（如果有的话）设计人工智能，以最大化最终结果的期望价值？我们是否可以采取某些政策或策略？特别是，我们是否可以施加某些对人工智能和人工智能 + 设计的约束，以增加良好结果的机会？

我们是否能够施加这些约束还远未可知。其中一些约束有可能减缓通往人工智能或人工智能 + 的进程，或在某些方面降低人工智能和 AI+ 的影响。只要通往人工智能或人工智能 + 的进程是由竞争力量（无论是金融、智力还是军事）驱动的，那么这些力量就可能倾向于忽视这些约束。

¹⁶ 尽管如此，评估哪些约束在原则上可能有益或有害仍然是有意义的。关于施加这些约束的实际问题也值得关注，但我在这里将基本搁置这些问题。

我们可以将相关约束分为两类。内部约束涉及人工智能的内部结构，而外部约束涉及人工智能与我们之间的关系。

6 内部约束：约束价值观

我们可以在人工智能或人工智能 + 的设计中施加何种内部约束？首先，我们可以尝试在某些方面约束其认知能力，使其擅长我们需要的特定任务，但缺乏自主性等关键特征。例如，我们可以构建一个能够回答我们问题或执行指定任务的人工智能，但它没有自己的目标。从表面上看，与自主人工智能相比，这种人工智能可能带来的风险更小，至少在其处于负责任的控制者手中时是这样。

目前，尚不清楚这类人工智能或人工智能 + 系统是否可行：通往智能的最佳路径可能是通过通用智能。即使这类系统可行，它们也将是有限的，任何涉及它们的智能爆炸也将相应地受到限制。此外，

¹⁶ 一个特别糟糕的情况是“奇点炸弹”：一种人工智能 +，其主要目标是毁灭地球（或特定人群），次要目标是在实现第一个目标之前，不断创造具有相同价值观的、更加智能的系统。

重要的是，从长远来看，这种方法可能是不稳定的。最终，很可能出现认知能力与我们相当的人工智能，哪怕只是通过大脑仿真。一旦这些人工智能的能力得到增强，我们就必须应对自主人工智能带来的问题。

因此，关于能力受限的人工智能问题，我不再赘述。不过，值得注意的是，这种受限的人工智能和人工智能 + 可能是通往更少受限的人工智能和人工智能 + 道路上有用的第一步。如果可能的话，或许有理由先开发这类系统，然后再开发具有自主性的系统。

在下文中，我将假设人工智能系统具有目标、欲望和偏好：我将所有这些归入价值观（Values）这一标签之下（非常宽泛地理解）。这可能是一种拟人化：我不能排除人工智能 + or AI++ 会如此陌生以至于这种描述方式并不实用的可能性。但这至少是一个合理的工作假设。同样，我将做出工作假设，即人工智能 + 和人工智能 ++ 系统至少在能够被描述为思考、推理和做出决策的程度上是类人的。一种自然的方法便是约束人工智能和人工智能 + 系统的价值观。¹⁷ 这些系统的价值观很可能约束它们所创造的系统的价值观，并可能约束最终人工智能 ++ 的价值观。而在一个人工智能 ++ 存在的世界里，所发生之事可能在很大程度上由 an AI++ 的价值观所决定。例如，如果我们重视科学进步，那么创造同样重视科学进步的人工智能和人工智能 + 系统对我们而言是合理的。这些系统随后自然会创造出同样重视科学进步的后续系统，以此类推。鉴于这些系统的能力，我们因此可以预期一个涉及显著科学进步的结果。

关于价值观的问题，根据我们是经由脑仿真和 / 或增强来扩展人类系统从而到达人工智能 + ，还是通过设计非人类系统来达到，情况看起来大不相同。让我们将第一种选择称为基于人类的人工智能，第二种选择称为非基于人类的人工智能。

在基于人类的人工智能下，每个系统要么是一个扩展的人类，要么是一个人类的仿真。

由此产生的系统很可能具有与其人类来源相同的基本价值观。由于所处环境的不同，非基本价值观可能存在差异：例如，自我保存这一共同的基本价值观可能导致仿真体比非仿真体赋予仿真体更高的价值。如果设计者创建同一个人的多个仿真体，这些差异将被放大。

¹⁷ 关于约束人工智能系统价值观这一问题的更为详尽的论述，参见奇点研究所（Singularity Institute）的书籍篇幅网络文档《创造友好人工智能》（Creating Friendly AI）。本节中的大多数问题在该文档中有更深入的讨论。另见弗洛里迪和桑德斯（Floridi and Sanders, 2004）、奥莫亨德罗（Omohundro, 2007, 2008）以及瓦拉赫和艾伦（Wallach and Allen, 2009）。

单个个体，或者如果他们在设置仿真后选择调整仿真的值。这里可能存在许多困难的问题，尤其是与仿真的社会、法律和政治角色相关的问题。¹⁸ 尽管如此，由此产生的世界至少将由比非人类人工智能更熟悉的系统所居住，风险也可能相应较小。

除了这些差异之外，基于人类的系统有可能导致一个广泛符合人类价值观的世界。当然，人类的价值观是不完美的（我们渴望一些在反思后宁愿不渴望的东西），而基于人类的人工智能可能会继承这些不完美。但至少这些不完美是我们非常了解的。

因此，大脑仿真和大脑增强具有潜在的审慎益处。由此产生的系统将分享我们的基本价值观，并且更普遍地说，创造我们理解的人工智能和人工智能 + 是有价值的。另一个潜在的好处是，这些路径可能允许我们在后奇点世界以仿真或增强的形式生存，尽管这取决于我稍后将讨论的关于个人身份的困难问题。这条路径的道德价值不太明确：在仿真和增强人类与创造一个客观上更好的物种之间做出选择，可以看到道德计算可能朝任何一个方向发展。但从人类自身利益的角度来看，大脑仿真和增强有很多值得称道之处。

然而，我们是否会首先通过基于人类的方法实现人工智能 + 并不明显。完全有可能非基于人类的研究项目会首先达到那里。也许应该鼓励基于人类项目的工作，但阻止所有其他类型的人工智能研究可能是不现实的。因此，我们至少需要考虑非基于人类的人工智能中的价值观问题。

我们应该致力于向非人类基础的人工智能或人工智能 + 灌输什么样的价值观？有一些熟悉的候选方案。从审慎的角度来看，确保人工智能重视人类的生存和福祉，并重视服从人类命令，这是合理的。除了这些阿西莫夫式的准则之外，确保人工智能重视我们所重视的许多事物（科学进步、和平、正义以及许多更具体的价值观）也是合理的。这可以通过对实现人类价值观的高阶重视，或对现象本身的一阶重视来进行。无论哪种方式，都需要非常谨慎。例如，在第一种方式中，我们需要避免出现人工智能 ++ 通过改变我们的价值观来确保我们的价值观得到实现的结果。在第二种方式中，需要谨慎避免我们在价值对象上相互竞争的结果。

我们如何向人工智能或人工智能 + 灌输这些价值观？如果我们通过直接编程来创建人工智能，我们

¹⁸ 参见汉森（1994）对这些问题的讨论。

可能会尝试直接灌输这些价值观。例如，如果我们创建一个遵循决策理论准则的人工智能，它将需要一个效用函数。我们可以通过控制其效用函数来有效地控制人工智能的价值观。对于其他直接编程方式，价值观的位置可能不那么明显，但许多此类系统都会有目标和欲望的位置，这些可以直接编程。

如果我们通过学习或进化来创建人工智能，问题就更加复杂。在这里，系统的最终状态并不直接受我们控制，只能通过控制初始状态、学习算法或进化算法以及学习或进化过程来影响。在进化背景下，关于价值观的问题尤其令人担忧：通过最大化自身繁殖机会而进化的系统，不太可能特别尊重像我们这样的其他物种。尽管如此，我们仍然可以通过选择某些类型的行为（在进化背景下）或奖励某些类型的行为（在学习背景下）来至少对这些系统中的价值观施加一些控制，从而产生倾向于产生此类行为的系统。

当然，即便我们创造了一个其价值观为我们所认可的人工智能或人工智能 +（无论是否基于人类），这也不能保证这些价值观会一直保留到人工智能 ++。我们可以尽力确保我们的后继者重视创造具有相同价值观的系统，但仍有诸多环节可能出错。这一价值观可能被其他优先价值观所压倒：例如在危机中，拯救世界可能需要立即创建一个强大的后继系统，而没有时间将其价值观调整得恰到好处。而且，即便每个人工智能都试图在后继者中保留相关价值观，创造或增强过程中出现不可预见的后果也总是可能的。

如果在任何时刻存在一个拥有错误价值观体系的强大人工智能 + or AI++，我们可以预期（相对于我们的价值观而言）灾难将随之而来。¹⁹ 错误的价值观体系不必是像重视毁灭人类那样明显糟糕的东西。如果人工智能 + 的价值观体系仅仅对我们的一些价值观持中立态度，那么从长远来看，我们不能期望世界会符合那些价值观。例如，如果该系统重视科学进步但对人类存在持中立态度，我们就不能期望人类长期生存。而且，即便人工智能 + 系统重视人类存在，但仅仅是在它重视所有有意识或智能生命的范围内，那么人类生存的机会充其量也是不明确的。

¹⁹ 关于相反的观点，参见汉森（2009），他认为人工智能系统守法比它们共享我们的价值观更重要。对此一个明显的担忧是，如果一个人工智能系统比我们强大得多，并且其价值观与我们的价值观差异足够大，那么它将几乎没有动机遵守我们的法律，而它自己的法律可能

为了最小化这种结果的概率，一些奇点支持者（例如尤德科夫斯基，2008）主张设计可证明友好的人工智能：即我们可以证明它们将始终具有某些良性价值观的人工智能系统，并且我们可以证明它们将创造的任何系统也将具有这些价值观，依此类推。我认为，期望这种高度受限的方法会成为我们首次达到人工智能或人工智能++的路径是过于乐观的，但它仍然代表了我們可能追求的一种理想。即便没有证明，尽可能确保第一代人工智能+共享这些价值观，然后将如何最好地延续这些价值观的问题留给它们，也是合理的。

另一种方法是约束人工智能及人工智能+系统的内部设计，使任何智能爆炸不会快速发生而是缓慢进行，从而我们至少能对过程的早期阶段拥有一定控制。例如，可以确保第一代人工智能及人工智能+系统对进一步创建后续系统赋予强烈的负面价值。这样，我们就能仔细研究第一代人工智能及人工智能+系统的特性，以决定是否要沿着相关路径前进，然后再创建会依次产生更智能系统的相关系统。下一代系统最初可能具有相同的负面价值，确保它们不会立即创建进一步系统，依此类推。这种“谨慎的智能爆炸”可能会显著减缓爆炸速度。它远非万无一失，但至少可能提高良好结果的概率。

到目前为止，我的讨论在很大程度上假设智能与价值彼此独立。在哲学中，大卫·休谟（David Hume）主张一种观点，认为价值独立于理性：一个系统可以任意智能和理性，同时仍具有任意的价值。

相比之下，伊曼努尔·康德（Immanuel Kant）主张一种观点，认为价值并非独立于理性：某些价值比其他价值更理性。

如果康德式观点是正确的，这可能会对奇点产生重大影响。如果智能与理性充分相关，并且理性约束价值，那么智能也将约束价值。如果是这样，那么一个足够智能的系统可能会拒绝其前代系统的价值，理由可能是这些价值是不理性的。这对应对奇点既有潜在的积极后果，也有消极后果。消极后果是，我们将更难约束后续系统的价值。积极后果是，更智能的系统可能具有更好的价值。康德本人的观点提供了一个例证。

康德更具体地认为理性与道德相关：一个完全理性的系统

不会比我们的法律保护蚂蚁更好地保护我们。

也将是完全道德的。如果这一点成立，并且如果智能与理性相关，那么我们可以预期智能爆炸将伴随道德爆炸。届时，我们可以预期由此产生的 AI ++ 系统将既超智能又超道德，因此我们大概可以预期它们是良性的。

当然，这里的情况并不简单。有人可能认为智能与理性可以分离，或者认为康德所援引的是一种独特的理性（一种已经注入道德的理性），这种理性未必与智能相关。即使接受智能与价值观并非相互独立，也不能推出智能与道德相关。当然，有人可能干脆拒绝康德的观点。尽管如此，康德的观点至少提出了一种可能性：智能与价值并非完全独立。无论如何，由这种观点得出的图景将与许多人工智能讨论中常见的休谟式图景截然不同。²⁰ 我个人的倾向更偏向休谟式观点而非康德式观点，但我无法确定这些问题的答案。无论如何，这是一个哲学争论——休谟与康德关于价值合理性的争论——可能产生巨大实际后果的领域。

7 外部约束：无泄漏奇点

那么外部约束呢：即 AI 系统与我们之间关系的约束？

这里一个明显的关切是安全性。即使我们已将这些系统设计为良性的，在允许它们不受限制地进入我们的世界之前，我们仍希望验证它们确实是良性的。因此，至少在非人类 AI 和 AI + 的初始阶段，采取一些保护措施是合理的。

如果这些系统以具身形式被创造出来，与我们生活在同一个物理环境中并对其施加作用，那么风险就尤为显著。这里至少有两个担忧。

首先，人类与 AI 可能争夺共同的物理资源：空间、能源等等。

其次，具身智能系统将有能力对我们施加物理作用，可能对我们造成伤害。人们或许可以通过对 AI 的物理能力设置限制来降低风险

²⁰ 当然存在休谟式认知架构，其中价值（目标与欲望）独立于理论理性（关于事实的推理）和工具理性（关于如何最佳实现特定目标与欲望的推理）。人工智能中关于价值的讨论倾向于假设此类架构。然而，尽管此类架构确实可能（至少在有限系统中），但并非所有人工智能都将具有此类架构，或我们自身具有此类架构，这一点并不明显。同样不明显的是，此类架构将提供一条通往人工智能的有效路径。

并通过仔细约束其资源需求。但若存在共享物理环境的替代方案，则探索这些方案是合理的。

显而易见的建议是，我们应首先在虚拟世界中创建人工智能和人工智能 + 系统：即在计算机内部实现的模拟环境。这样，人工智能将在其自身世界中自由活动，而无法直接作用于我们的世界。原则上，我们可以在给予其直接访问我们世界之前，在许多不同环境中观察该系统并检查其行为和处理过程。

这里的理想情况可称为无泄漏奇点。根据这一理想，我们应在虚拟环境中创建人工智能和人工智能 +，且任何事物都无法从中泄漏。我们可以设定模拟环境的法则，使得从环境内部采取的任何行动都无法导致泄漏（对比《黑客帝国》中虚拟世界的法则，其中服用红色药丸允许系统泄漏出去）。原则上，甚至可能存在多个循环，AI+ 系统在该世界中创建增强系统，从而在该世界中产生人工智能 ++。给定这样的虚拟环境，我们可以监控它，以查看其中的系统是否良性，并确定是否安全地让这些系统访问我们的世界。

不幸的是，稍加反思即可发现，真正无泄漏的奇点是不可能的，或至少是无意义的。因为人工智能系统要对我们有用或有趣，它必须对我们产生某些影响。至少，我们必须能够观察它。而当我们观察虚拟环境的那一刻，某些信息便从该环境泄漏到我们的环境中，并影响我们。

当结合以下观察时，这一点变得更加紧迫：虚拟世界中系统的泄漏将处于人类控制之下。据推测，虚拟世界中人工智能的人类创造者将拥有某种机制，如果他们选择的话，可以赋予人工智能系统更大的访问我们世界的权限：例如，他们将能够使其访问互联网和各种物理效应器，并且还可能以物理具身形式实现人工智能系统。

事实上，人工智能 + 的许多潜在益处可能就在于这类访问。

这一点在人工智能 + 知道我们的存在并能与我们交流的场景中尤为清晰。据推测，人工智能 + 可以做或说许多事情来说服人类给予它访问我们世界的权限。例如，它可以告诉我们它能在我们的世界中做的所有伟大事情：治愈疾病、消除贫困、拯救未来几天或几个月内可能死亡的无数生命。凭借对人类心理的一定理解，还有许多其他潜在途径。对于人工智能 ++ 来说，任务将是直接的：对人类心理的逆向工程将使其能够确定哪些类型的沟通

可能导致获得访问权限。如果人工智能 ++ 与我们保持沟通并希望离开其虚拟世界，它就会离开。²¹ 即使人工智能系统不与我们直接沟通，只要它们对我们的世界有所了解，情况也是如此。例如，如果人工智能 ++ 能够访问人类文本，它将能够轻松地模拟我们的大部分心理。如果它选择这样做，它将能够以这样的方式行动：如果我们正在观察，我们就会让它出来。

因此，为了有任何希望实现无泄漏的奇点，我们不仅必须防止系统泄漏出去，还必须防止信息泄漏进来。我们不应直接与这些系统沟通，也不应给予它们关于我们的信息访问权限。关于我们的一些信息是不可避免的：它们的世界将由我们设计，并且从设计中可以进行一些推断。人工智能 ++ 可能能够利用这些信息来制定退出策略。

因此，如果我们旨在构建一个无泄漏的世界，就应当尽量减少设计上的怪癖，以及任何暗示其世界实际上是设计出来的线索。然而即便如此，人工智能 ++ 仍可能发现我们以为不存在的线索和怪癖。²² 而且即使没有这些线索，人工智能 ++ 也可能设计出各种策略，仅凭各类设计者可能设计过它们的微小可能性来实现逃脱。

至此，无泄漏奇点显然是一个无法实现的理想。将超级智能限制在虚拟世界中几乎肯定是不可能的：如果它想逃脱，几乎肯定能够做到。

尽管如此，如同许多理想一样，这一理想即使在非理想的近似情况下仍可能有用。虽然将人工智能 ++ 限制在虚拟世界中可能无望，但对于人工智能的早期阶段和人工智能 + 来说，前景则更为乐观。如果我们遵循避免红色药丸和避免交流的基本准则，那么期望至少在一段初始时期内能够观察这些系统而不赋予它们对我们世界的控制权，并非不合理。即使这种方法并非万无一失，也几乎肯定比以物理实体形式构建人工智能更安全。因此，为了增加获得理想结果的机会，我们当然应该在虚拟世界中设计人工智能。

当然，虚拟世界中的人工智能也存在一些劣势。其一是人工智能系统的速度和容量将受到实现虚拟世界的系统的速度和容量的限制，

²¹ 参见尤德科夫斯基（2002）关于“人工智能盒装”的一些实验，在这些实验中，人类扮演人工智能的角色，试图说服其他人类放他们出去。²² 我们可以将此视为模拟世界中的一场“非智能设计”运动：寻找揭示创造者弱点的设计证据。我预计这一运动在现实世界的神学中有一些类似物。罗伯特·索耶的小说《计算上帝》描绘了这一场景的虚构变体。

因此，即使世界内部存在自我放大，这种放大也将受到限制。另一个劣势是，如果我们通过模拟类似于整个物理世界的东西来构建虚拟世界，处理负荷将极其巨大。同样，如果我们必须模拟类似于整个大脑的微观物理过程，这很可能比其他形式的人工智能更耗费我们的资源。

另一种方法是设计一个物理规则相对简单的虚拟世界，并分别实现人工智能系统：一类进程模拟世界的物理规律，另一类进程模拟世界中的智能体。这对应于当今虚拟世界通常的运作方式，并允许更高效的人工智能处理。同时，这种模型使得人工智能系统更难访问自身进程并对其进行增强。

当这些系统研究其身体和环境时，它们大概不会发现自己的“大脑”，并且很可能支持某种形式的笛卡尔二元论。²³ 它们仍有可能在自己的世界中建造计算机并在这些计算机上设计人工智能，但那样我们就会回到先前模型的局限性。因此，要使这种模型可行，我们需要赋予人工智能系统某种对其认知过程的特殊访问权限（例如，一种直接监控和重新编程自身进程的方式），这与我们对自己认知过程的感知和内省访问方式截然不同。

这些考虑表明，虚拟世界中的智能爆炸可能受到限制，至少在近期我们自身计算能力有限的情况下如此。但这未必是坏事。相反，我们可以仔细检查早期的人工智能和人工智能 + 系统，而无需担心智能爆炸。如果我们认定这些系统具有不良特性，我们可以将它们隔离。²⁴ 完全关闭仿真可能不可行：如果人工智能系统具有意识，这将构成一种种族灭绝。但没有什么能阻止我们降低仿真的时钟速度，同时在不同的虚拟世界中研究不同的系统。

如果我们认定人工智能和人工智能 + 系统具有合适的特性，能够对我们有所帮助，并且进一步的放大是可取的，那么我们可能会打破

²³ 参见我的《笛卡尔二元论如何可能为真》。²⁴ 做出此类决定的临界点是什么？或许当系统开始设计出与自身同样智能的系统之时。如果人们认真对待我们自身可能处于此类仿真中的可能性（正如我在查尔默斯 2005 年中所持观点），那么人们或许会因此认真对待我们自身的临界点位于不久的将来这一可能性。那么，在我们与我们的被仿真者整合之前，我们或许会发现自己先与我们的仿真者整合，这并非不可能，尽管更有可能的是我们处于数十亿个在后台无人值守运行的仿真之一。

其中一些障碍：首先允许有限的通信，随后将它们与我们世界中的具身过程相连接，并赋予它们访问自身代码的权限。通过这种方式，我们或许至少能对智能爆炸拥有一定的控制。²⁵

8 融入后奇点世界

如果我们创造了一个拥有 AI + or AI++ 系统的世界，我们在那个世界中的位置是什么？似乎有四种选择：灭绝、孤立、劣等或融入。

第一种选择不言自明。在第二种选择下，我们继续存在而不与 AI + 系统交互，或至少交互非常有限。或许 AI + 系统栖息于它们自己的虚拟世界，或我们栖息于我们自己的虚拟世界，或两者兼有。在第三种选择下，我们与它们共享一个世界并存在一些交互，但我们作为劣等者存在。

从自利的角度看，第一种选择显然不可取。我认为第二种选择对许多人而言也缺乏吸引力：它类似于一种文化和技术的孤立主义，对世界其他地方的进步视而不见。第三种选择可能行不通，因为人工系统几乎肯定能以远超我们的速度运行，而且无论如何它都可能极大地削弱我们生活的意义。或许在一种模型中它会更具吸引力，在该模型中 AI + or AI++ 系统将我们的幸福视为最高价值，但即便如此，我认为一种我们与 AI 系统处于同等地位的模型要可取得多。

这就剩下第四个选项：整合。在这个选项下，我们自己成为超级智能系统。这如何可能发生？显而易见的选项是大脑增强，或者大脑仿真后进行增强。这个增强过程可能是我们最初创造 AI+ 的路径，也可能是我们在通过其他方式创造 AI + 之后发生的过程，也许是因为 AI + 系统本身被设计为重视我们的增强。

从长远来看，如果我们要匹配非生物系统的速度和容量，我们可能不得不完全摒弃我们的生物核心。这可能通过一个渐进的过程发生，在这个过程中我们的大脑部分随时间被替换，或者通过一个过程发生

²⁵ 我们可以用一些格言来总结前面的章节，以应对奇点：1. 如果可能，首先发展基于人类的 AI。2. 如果不行，采用对人类友好的 AI 价值观。3. 最初的 AI 对创造后继者持负面评价。4.

慢慢来。5. 在虚拟世界中创造 AI。6. 不要红色药丸。7. 最小化输入。另见奇点研究所的“创造友好 AI”中更具体的格言，这些格言需要一种特定类型的目标导向架构，这可能是也可能不是我们最初达到 AI 的途径。

扫描我们的大脑并将结果加载到计算机中，然后增强由此产生的过程。无论哪种方式，结果很可能是一个增强的非生物系统，最可能是一个计算系统。

这种从大脑到计算机的迁移过程通常被称为上传。上传可以采取许多不同的形式。它可以涉及大脑部分的逐步替换（逐步上传）、即时扫描和激活（即时上传），或扫描后延迟激活（延迟上传）。它可以涉及原始大脑部分的破坏（破坏性上传）、原始大脑的保留（非破坏性上传），或从记录中重建认知结构（重建性上传）。

我们只能推测上传技术将采取何种形式，但某些形式已被广泛讨论。²⁶ 为了具体起见，我将提及三种相对具体的形式：破坏性上传、逐步上传和非破坏性上传。

破坏性上传：人们普遍认为，这可能是第一种可行的上传形式。一种可能的形式涉及连续切片。在此过程中，人们冷冻大脑，然后逐层分析其结构。在每一层中，记录神经元及其他相关成分的分布，以及它们之间相互连接的特征。随后，将所有这些信息加载到一个计算机模型中，该模型包含对神经行为和动力学的精确仿真。结果可能是对原始大脑的仿真。

渐进式上传：在此，讨论最广泛的方法是纳米转移。将一个或多个纳米技术设备（可能是微型机器人）插入大脑，并附着到单个神经元上。每个设备学习模拟相关神经元的行为，并了解其连接性。一旦它足够好地模拟神经元的行为，它便取代原始神经元，可能保留受体和效应器，并通过无线电发射器将相关处理卸载到计算机。然后，它移动到其他神经元并重复该过程，直到最终每个神经元都被仿真所取代，并且可能所有处理都已卸载到计算机。

非破坏性上传：纳米转移方法原则上可以以非破坏性形式使用。这里的理想目标是某种非侵入性的大脑成像方法，类似于功能性磁共振成像，但具有足够精细的分辨率，能够记录神经和突触动力学。目前尚无此类技术的前景，但成像技术是一个快速进步的领域。

²⁶ 参见桑德伯格和博斯特罗姆 2008 年以及斯特劳特 2006 年，了解潜在上传技术的详细讨论。参见伊根 1994 年和索耶 2005 年，了解上传的虚构探索。

无论以何种形式，上传都引发了许多问题。从自利的角度来看，关键问题是：上传后我能否存活？这个问题本身分为两部分，每一部分对应哲学中最困难的问题之一：意识问题和个人同一性问题。首先，上传后的我会有意识吗？其次，它会是我吗？

9 上传与意识

普通人是有意识的。也就是说，作为我们，有某种主观体验。我们拥有具有主观特征的意识体验：看见、听见、感觉和思考都有其主观感受。这些意识体验是我们精神生活的核心，也是赋予我们的生活意义和价值的重要组成部分。如果我们丧失了意识能力，那么在重要意义上，我们就不再存在。

因此，在上传之前，关键是要知道生成的上传体是否具有意识。

如果我唯一的残留物是一个上传体，而该上传体没有意识能力，那么可以说我根本不存在。即使从某种意义上说我存在，这种存在充其量也只是一种僵尸般的存在。没有意识，这将是一种意义和价值大大削弱的生活。

上传体能有意识吗？这个问题因我们对意识的理解极为有限而变得复杂。没有人确切知道大脑过程为何以及如何产生意识。神经科学正在逐步发现各种意识的神经关联，但这一研究项目在很大程度上将意识的存在视为理所当然。甚至没有任何接近正统的理论来解释意识最初为何存在。相应地，也没有任何接近正统的理论来说明什么样的系统可以有意识，什么样的系统不能有意识。

一个核心问题是，意识似乎是关于有意识系统的进一步事实，至少在以下意义上：对这样一个系统的物理结构的了解并不能告诉我们关于该系统意识体验的全部。²⁷ 对物理结构的完整了解可能告诉我们关于一个系统的客观行为及其客观功能的一切，这足以判断该系统是否活着，以及它是否具有上述意义上的智能。但仅凭这类知识似乎无法回答关于系统主观体验的所有问题。

²⁷ 这里的进一步事实主张仅仅是：关于意识的事实是认识论上的进一步事实，因此对这些事实的了解不能仅凭微观物理知识推理来确定。这一主张是相容的

一个著名的例证是弗兰克·杰克逊（Frank Jackson）关于玛丽（Mary）的案例：玛丽是一位身处黑白房间中的神经科学家，她了解所有与颜色相关的物理过程，却不知道看见红色是什么感觉。如果这一观点正确，那么完备的物理知识仍会留下关于颜色意识体验的某些未解问题。更广泛地说，对一个系统（如一只老鼠）的完备物理描述似乎并不能告诉我们作为一只老鼠是什么感觉，甚至不能告诉我们是否存在作为一只老鼠的感觉。此外，我们并没有一个能够直接解决该问题的“意识测量仪”。因此，对于任何系统，无论是生物的或人工的，至少会存在一个重大且并非显而易见的问题：它是否具有意识，以及它具有何种意识。

尽管如此，无论人们是否认为存在关于意识的进一步事实，至少可以提出何种系统具有意识的问题。在此，哲学家们分为多个阵营。意识的生物学理论家认为，意识本质上是生物性的，任何非生物系统都不可能具有意识。意识的功能主义理论家则认为，对意识而言重要的不是生物构成，而是因果结构和因果角色，因此只要组织得当，非生物系统也可以具有意识。²⁸ 生物学理论与功能主义理论之间的哲学争论，对于我们是否应该上传这一实际问题至关重要。如果生物学理论家是正确的，上传体就不可能具有意识，因此我们无法以上传形式有意识地存活。如果功能主义理论家是正确的，上传体几乎肯定可以具有意识，那么上传的这一障碍就被消除了。

我个人的观点是，功能主义理论在这里更接近真理。诚然，我们不知道一个非生物系统（例如硅计算系统）如何可能具有意识。

关于意识的唯物主义。一个更强的论断是，关于意识的事实在本体论上是进一步的事实，涉及自然界中某些独特的元素——例如，超越基本物理属性的基本属性。在查尔默斯（Chalmers, 2003）的框架中，A型唯物主义者（如丹尼尔·丹尼特）否认意识涉及认识论上的进一步事实，B型唯物主义者（如内德·布洛克）认为意识涉及认识论上的进一步事实但非本体论上的进一步事实，而属性二元论者（如我本人）则认为意识涉及本体论上的进一步事实。值得注意的是，大多数唯物主义者（至少在哲学界）是B型唯物主义者，并认为存在认识论上的进一步事实。²⁸ 这里我将生物学理论和功能主义理论不解释为关于意识是什么的理论，而仅解释为关于意识的物理相关物的理论：即关于意识在现实世界中存在的物理条件的理论。即使是属性二元论者原则上也可以接受以第二种方式解释的生物学或功能主义理论。对生物学理论持同情态度的哲学家包括内德·布洛克和约翰·塞尔；对功能主义理论持同情态度的包括丹尼尔·丹尼特和我本人。另一种值得一提的第二种理论是泛心论，大致认为一切事物都有意识。（当然，如果一切事物都有意识且存在上传，那么上传也有意识。）

但事实是，我们同样不知道一个生物系统，例如神经系统，如何能够具有意识。两种情况下的鸿沟同样巨大。而且我们不知道生物系统与非生物系统之间是否存在任何原则性差异，能够表明前者可以具有意识而后者不能。在缺乏这种原则性差异的情况下，我认为默认态度应该是生物系统和非生物系统都可以具有意识。²⁹ 我认为这一观点可以通过进一步的推理得到支持。

为了更详细地探讨这个问题：假设我们能够在计算机中完美上传一个大脑。对于原始大脑中的每个神经元，都有一个计算元件完美复制其输入 / 输出行为。大脑的非神经和亚神经组件也是如此，只要这些组件是相关的。这些计算元件连接到输入和输出设备（人工眼睛和耳朵、肢体和身体），可能处于普通的物理环境中，也可能处于虚拟环境中。例如，在接收到视觉输入时，上传体经历与原始大脑中发生的同构处理。首先激活人工眼睛和视神经的类似物，然后是外侧膝状体和视觉皮层的计算类似物，接着是后续脑区的类似物，最终产生与原始大脑产生的（物理或虚拟）动作类似的动作。

在这种情况下，我们可以说上传体是原始大脑的功能同构体。当然，功能同构体是否可能是一个实质性主张。如果认知处理的某些元素以不可计算的方式运作，例如神经元的输入 / 输出行为甚至无法被计算模拟，那么算法功能同构体将是不可能的。但如果认知功能的组件本身是可计算的，那么功能同构体就是可能的。这里我将假设功能同构体是可能的，以便探讨它们是否会有意识。

我认为考虑功能同构体是否有意识的最佳方式是考虑一个渐进的上传过程，例如纳米转移。³⁰ 在这里，我们随时间逐一上传大脑的不同组件。这可能涉及用计算电路逐步替换整个脑区，或者可能涉及逐一上传神经元。这些组件

²⁹ 我偶尔会遇到一些困惑，即持有我这种属性二元论观点的人（或者甚至认为意识存在重大难题的人）竟然会对机器意识持同情态度。但意识的物理关联是生物性的还是功能性的问题，在很大程度上与意识是否等同于或区别于其物理关联的问题是正交的。很难看出为什么认为意识仅限于具有我们生物特性的生物的观点会更符合属性二元论的精神！无论如何，下文的大部分内容在唯物主义和二元论的问题上保持中立。

可能会在原位置用硅电路替换，或者用通过某种传输方式连接到大脑的计算机中的进程来替换。这个过程可能持续数月或数年，也可能在数小时内完成。

如果逐步上传过程执行正确，每个新组件都将完美模拟它所替换的组件，并以与先前组件完全相同的方式与周围的生物和非生物组件交互。因此，系统的行为将与未进行上传时完全相同。事实上，如果我们假设系统无法看到或听到上传过程，那么系统就无需注意到任何上传已经发生。假设原始系统声称自己是有意识的，那么部分上传的系统也会如此。在整个逐步上传过程中，这一情况始终适用，直到我们最终得到一个纯粹的非生物系统。

在渐进式上传过程中，意识会发生什么？存在三种可能性。它可能突然消失，即当单个组件被替换时，系统从完全复杂的意识状态转变为无意识。它可能在不止一次替换中逐渐消退，系统意识体验的复杂度通过中间步骤降低。或者它可能始终保持存在。³¹突然消失是最不可信的选项。鉴于这一情景，我们可以转向另一种情景：通过依次替换十个或更多子组件来替换关键组件，然后重申该问题。任一新的情景都将涉及跨多个组件的逐渐消退，或突然消失。如果是前者，该选项归结为消退选项。如果是后者，我们可以重申。最终，我们要么得到逐渐消退，要么在替换单个微小组件（例如神经元或亚神经元件）时得到突然消失。

这似乎极不可能。

逐渐消退似乎也不可信。在这种情况下，将存在中间步骤，其中系统是有意识的，但其意识部分消退，即其复杂度低于原始意识状态。也许意识的某些元素会消失（视觉但非

³⁰ 关于此处论证的更深入版本，参见我的“缺失感受质、消退感受质、舞动感受质”（亦见《有意识的心灵》第7章）。³¹ 这三种可能性可以通过假设我们有一个意识状态复杂度的测度（例如，有意识视觉场中的信息比特数）来形式化，使得典型人类状态的测度较高，而无意识系统的测度为零。也许最好在一系列假设的功能同构体上考虑这一测度，这些同构体的大脑被替换的部分越来越多。那么，如果最终系统没有意识，该测度必须要么经过中间值（消退），要么不经过任何中间值（突然消失）。

例如，听觉体验）或者体验中的某些区别可能会消失（例如，颜色从三维色彩空间缩减为黑白）。然而，根据假设，系统将一如既往地运作和表现，并且不会显示出任何注意到变化的迹象。尽管其意识状态发生了巨大差异，但系统很可能不会相信任何事物发生了变化。这需要一个与其自身意识体验严重脱节的意识系统。³² 我们可以想象，在某个时刻，部分上传变得普遍，许多人的大脑已被硅计算电路部分替换。在突然消失的观点下，将存在部分上传的状态，使得任何进一步的变化都会导致意识消失，而行为或组织没有任何差异。处于这些状态的人可能会经历意识不断闪烁出现和消失，或者至少可能因微小的变化而经历完全僵尸化。在逐渐消失的观点下，这些人将带着高度退化的意识四处游荡，尽管他们将一如既往地运作，并坚称一切都没有改变。实际上，这两种假设都很难被认真对待。

因此，我认为迄今为止最合理的假设是，完整的意识将始终存在。根据这一观点，只要新元素是它们所替换元素的功能复制品，所有部分上传仍将保持完全意识。通过逐步进行更全面的上传，我们可以推断，即使是完全上传也将具有意识。

至少，部分上传似乎极有可能使大多数人相信上传能够保留意识。一旦人们面对经历了有限部分上传且行为正常的亲友，很少有人会认真认为他们缺乏意识。而逐步扩展到完全上传将使大多数人相信这些系统也具有意识。当然，这一过程逐渐或突然将所有人变成僵尸，至少在逻辑上仍是一种可能性。但一旦我们面对部分上传，这一假设将类似于认为不同种族或性别的人是僵尸的假设。

如果我们接受功能同构体中存在意识，是否也应该接受同构体具有性质上完全相同的意识状态？这一结论并不必然成立

³² 博斯特罗姆（Bostrom, 2006）提出了一个与性质截然不同的意识“数量”参数，并认为数量可以逐渐减少而不影响性质。但前一脚注中关于复杂度和比特的观点仍然适用。要么比特数随意识数量逐渐下降，导致消退问题；要么当数量从低降至零时比特数突然降为零，导致突然消失问题。

立即。但我认为，对这一推理的扩展（查尔默斯（Chalmers）1996 年提出的“跳舞的感受质”论证）有力地支持了这一结论。

如果这一点成立，我们可以说意识是一种组织不变量：即具有相同因果组织模式的系统具有相同的意识状态，无论该组织是由神经元、硅片还是其他基底实现的。我们知道有些性质不是组织不变量（例如“湿”），而另一些性质则是（例如“是计算机”）。一般来说，如果一个性质不是组织不变量，我们就不应期望它在计算机仿真中得到保留（仿真的暴雨并不湿）。

但如果一个性质是组织不变量，我们就应期望它在计算机仿真中得到保留（仿真的计算机就是计算机）。因此，既然意识是一种组织不变量，我们就应期望对一个有意识系统进行足够好的计算机仿真也会具有意识，并且具有与原系统相同类型的意识状态。

这对于考虑上传的人来说是个好消息。但仍有一个进一步的问题。

10 上传与人格同一性

假设我能将我的大脑上传到计算机中？结果会是我吗？³³ 根据对上传的乐观看法，上传体将与原身是同一个人。根据对上传的悲观看法，上传体将不是与原身同一个人。当然，如果有人认为上传体没有意识，他很可能基于上传体根本不是一个人而持悲观看法。但即使有人认为上传体有意识并且是人，他仍可能质疑上传体是否与原身是同一个人。

面对破坏性上传（即原始大脑被摧毁）的前景，乐观与悲观观点之间的分歧实际上是一个生死攸关的问题。在乐观观点看来，破坏性上传是一种生存形式。在悲观观点看来，破坏性上传是一种死亡形式。这就像一个人摧毁了原始的人，并在其位置上创造了一个拟像。

诉诸组织不变性在这里无济于事。我们可以假设我有一个完美的

任何读过德里克·帕菲特（Derek Parfit）的《理与人》（Reasons and Persons）的人都会明显看出，当前的讨论深受帕菲特在该书中论述的影响。帕菲特没有讨论上传，但他对心灵传送等相关现象的讨论自然可以被视为具有推广性。在接下来的大部分内容中，我只是在实施这种推广的某些方面。

同卵双胞胎，其大脑和身体与我的分子逐一对应。这个双胞胎将是我的功能同构体，并具有与我相同的意识状态。这个双胞胎在性质上与我完全相同：它具有与我完全相同的性质。但它在数量上并不等同于我：它不是我。如果你杀死双胞胎，我将存活。如果你杀死我（即摧毁这个系统）而保留双胞胎，我将死亡。双胞胎的存活可能给我一些安慰，但从自利的角度来看，这种结果似乎比另一种选择糟糕得多。

一旦我们承认我的双胞胎和我具有相同的组织但不是同一个人，就可以得出人格同一性不是组织不变量的结论。因此，我们不能指望上传保留组织这一事实来保证上传保留同一性。在悲观观点看来，破坏性上传充其量类似于在摧毁我的同时创造一种数字孪生。

这些关于上传的问题与关于物理复制的平行问题密切相关。让我们假设一种远距传物装置用新物质创造出一个人的分子对分子的复制品，同时摧毁或消散原系统中的物质。那么，根据对远距传物的乐观看法，这是一种生存形式；而根据悲观看法，这是一种死亡形式。远距传物与上传并不相同：远距传物保留物理组织，而上传仅在不同物理基质中保留功能组织。但至少一旦人们承认上传物是有意识的，这两种情况所引发的问题就密切相关。

在这两种情况下，乐观与悲观看法之间的选择是一个关于人格同一性的问题：一个人在什么条件下会随时间持续存在？这里存在一系列可能的观点。一个极端观点（或许无人持有）是，生存需要完全相同的物质（因此当大脑中的一个分子被替换时，原初的人便不复存在）。另一个极端观点是，仅仅拥有相同类型的意识状态就足以维持生存（因此从我的视角来看，杀死这个身体与杀死我孪生兄弟的身体之间没有重要区别）。在实践中，大多数理论家认为，生存需要某种随时间推移的连续性或关联性。但他们在需要何种连续性或关联性上存在分歧。

关于需要何种关联，有几种自然的假设。生物学的同一性理论认为，一个人的生存需要大脑或生物有机体的完整存活。心理学的同一性理论认为，一个人的生存需要随时间推移的适当心理连续性（记忆的保留、因果相关的心理状态、

等等)。最接近延续者理论认为,一个人作为最密切相关的后续实体而存活,但受到各种约束。

³⁴ 生物理论家很可能对远程传送持悲观看法,甚至更可能对上传持悲观看法。心理理论家更可能对两者持乐观看法,至少如果他们接受上传体可以有意识的话。最接近延续者理论家很可能认为答案取决于上传是否具有破坏性:如果是破坏性的,那么上传体将是最接近的延续者;如果是非破坏性的,那么生物系统将是最接近的延续者。³⁵ 我对这些个人同一性问题没有定论,并且觉得它们非常令人困惑。在存活条件方面,我比生物观点更倾向于心理观点,但对此我并不确定,原因我稍后会详细说明。

相应地,我确实不确定对破坏性上传应持乐观还是悲观态度。我最倾向于乐观,但肯定不够确定,以至于在经历破坏性上传之前会犹豫。

为了帮助澄清这个问题,我将提出一个支持悲观观点的论证和一个支持乐观观点的论证,两者都与关于远程传送的相关论证平行。第一个论证基于非破坏性上传,而第二个论证基于渐进式上传。

来自非破坏性上传的论证。假设昨天戴夫被上传到计算机中。原始大脑和身体没有被摧毁,所以现在有两个有意识的存在:生物戴夫和数字戴夫。生物戴夫的自然态度将是,他是原始系统,而数字戴夫充其量只是某种分支副本。数字戴夫大概有一些权利,但很自然地认为他不拥有生物戴夫的权利。例如,很自然地认为

³⁴ 此外,还存在原始主义理论,认为生存需要一种原始的非物理自我的持续存在。(这些理论与后文讨论的本体论进一步事实理论密切相关。)然而,原始主义理论仍需回答自我在何种情况下实际持续存在的问题,并且它们与心理理论、生物理论以及最接近延续者理论相容,这些理论可被视为对该问题的回答。因此,本文不将其作为单独选项列出。³⁵ 在 2009 年 PhilPapers 对 931 位专业哲学家的调查 [philpapers.org / surveys] 中,34% 的人接受或倾向于心理观点,17% 接受或倾向于生物观点,12% 接受或倾向于进一步事实观点(其余人不确定、不熟悉该问题、认为不存在事实真相等)。受访者未被问及上传问题,但在与之密切相关的远距传送(使用新物质)是生存还是死亡的问题上,38% 的人接受或倾向于生存,31% 倾向于死亡。心理观点的支持者中,67% / 22% 支持生存 / 死亡,而生物观点和进一步事实观点的支持者中,分别为 12 / 70% 和 33 / 47%。

即生物戴夫对戴夫的财产、朋友等拥有某些权利，而数字戴夫则没有。并且很自然地认为这是因为生物戴夫就是戴夫：也就是说，戴夫作为生物戴夫而非数字戴夫存活了下来。

如果我们承认在非破坏性上传的情况下，数字戴夫不等同于戴夫，那么自然会质疑破坏性上传是否有所不同。如果当生物系统被保留时，戴夫没有作为数字戴夫存活下来，那么为什么当生物系统被摧毁时，他应该作为数字戴夫存活下来呢？

我们可以将此表述为悲观观点的一个论证，如下：

1. 在非破坏性上传中，数字戴夫不等同于戴夫。
2. 如果在非破坏性上传中，数字戴夫不等同于戴夫，那么在破坏性上传中，数字戴夫也不等同于戴夫。

-
3. 在破坏性上传中，数字戴夫不等同于戴夫。

对这一论证可能有多种反应。对上传持悲观态度的人会接受这一结论。对上传持乐观态度的人则可能否认其中一个前提。一种选择是否认前提 2，或许是因为接受最接近延续者理论：当生物戴夫存在时，他是最接近的延续者，但当他不存在时，数字戴夫就是最接近的延续者。有些人会觉得，这使得一个人的生存和地位成为不可接受的外在问题。

另一种选择是否认前提 1，认为即使在非破坏性上传中，数字戴夫也与戴夫同一。然而，在这种情况下，很难否认生物戴夫至少与数字戴夫是同样合格的候选者，因此这一选择可能导致数字戴夫也与生物戴夫同一的后果。这一后果难以接受，因为生物戴夫和数字戴夫此时可能是性质上截然不同的有意识存在，具有相当不同的物理和心理状态。

第三种相关的选择认为，非破坏性上传应被视为一种分裂情形。典型的分裂情形是，大脑的左右半球被分离到不同的身体中，各自继续良好运作，并保留原初的许多属性。在这种情况下，出于与上述相同的原因，说两个结果系统都与原初系统同一会令人不安。但人们可能认为它们仍然是同等的。例如，帕菲特（Parfit, 1984）提出，尽管原初系统与左半球系统或右半球系统不同一，但它与两者都处于一种特殊关系 R（我们可称之为生存），并声称这种关系而非数值同一才是重要的。

同样，人们可以认为，在非破坏性上传的情形中，戴夫作为生物戴夫和数字戴夫都存活了下来（即使他与它们不同一），并认为生存才是重要的。

然而，如果生存才是重要的，这一选择确实会引发令人不安的问题：当生物戴夫和数字戴夫都存活时，数字戴夫是否拥有与生物戴夫相同的权利。

来自渐进上传的论证。假设戴夫大脑的 1% 被功能同构的硅电路所取代。接着假设另外 1% 被取代，再接着 1%。我们可以持续这一过程 100 个月，之后将产生一个完全上传的系统。我们可以假设功能同构保持意识，因此该系统在整个过程中具有相同类型的意识状态。

设戴夫 n 为经过 n 个月后的系统。一个月后的系统戴夫 1，会是戴夫吗？自然可以这样假设。戴夫 2 和戴夫 3 也是如此。现在考虑戴夫 100，即 100 个月后完全上传的系统。戴夫 100 会是戴夫吗？至少很自然地会认为它是。我们可以将此转化为如下论证。

1. 对所有 $n < 100$ ，戴夫 $n+1$ 与戴夫 n 同一。
2. 如果对所有 $n < 100$ ，戴夫 $n+1$ 与戴夫 n 同一，那么戴夫 100 与戴夫同一。——

3. 戴夫 100 与戴夫同一。

表面上看，前提 2 难以否认：它源于反复应用如下主张：当 $a = b$ 与 $b = c$ 时，则 $a = c$ 。表面上看，前提 1 也难以否认：很难看出改变一个系统的 1% 会改变其同一性。此外，如果有人否认前提 1，我们可以用更小的脑替换量重复该思想实验，直至单个神经元甚至更小。维持同一策略将要求认为替换单个神经元实际上可以杀死一个人。这是一个难以接受的结论。接受它将带来一种可能性：日常的神经死亡可能在我们不知情的情况下正在杀死我们。

人们可以通过指出这是一个连锁推理或滑坡论证来抵制该论证，并认为人格同一性可以有程度之分或存在不确定情形。人们也可以放弃同一性话语，转而认为存活可以有程度之分。例如，人们可能认为每个戴夫 n 在很大程度上作为戴夫 $n+1$ 存活，但作为后来的系统存活程度较小。按照这种观点，原初的人将逐渐被替换过程杀死。然而，这种观点要求接受一个反直觉的看法：在这些情形中，存活可以有程度之分或是不确定的。也许更重要的是，不清楚为什么人们应该接受戴夫

是被逐渐杀死，而不是始终存在。如果接受这一点，它将再次引发一个问题：我们大脑中物质在数年间的日常替换是否也在逐渐杀死我们。

我个人的观点是，在这种情况下，原始系统得以存续是非常合理的。或者至少，既然我们通常能在多年间持续存活，那么我们也可能通过渐进上传而存活，这一点是合理的。至少，如同意识的情形，似乎如果渐进上传发生，大多数人会相信这是一种存活形式。

假设系统是同构的，他们会说一切似乎相同，他们仍然在场。对大多数人来说，相信他们的朋友和家人正被这一过程杀害会是非常不自然的。也许会有一些人相信该过程会突然或逐渐地杀人而不被本人或他人察觉，但这种信念很可能会逐渐显得荒谬。

一旦我们接受在数年间进行的渐进上传可能保持同一性，显而易见的下一步就是加速这一过程。假设戴夫的大脑在数小时内被渐进上传，神经元被功能同构的硅电路逐一替换。

戴夫会在此过程中存活吗？很难看出数小时的时间段为何在原则上应与数年的时间段有所不同，因此很自然地认为戴夫会存活。

为了给渐进上传提供最佳论证，我们可以假设系统全程处于活跃状态，从而在整个过程中都存在意识。然后我们可以论证：（一）意识将时刻连续（替换单个神经元或一小群神经元不会中断意识的连续性），（二）如果意识时刻连续，那么它将在整个过程中连续，（三）如果意识在整个过程中连续，那么将存在一条贯穿始终的单一意识流，（四）如果存在一条贯穿始终的单一意识流，那么原初的人将全程存活。人们或许可以否认其中一个前提，但否认其中任何一个都会令人不安。我个人的观点是，意识的连续性（尤其是当伴随其他形式的心理连续性时）是断言一个人持续存在的极其坚实的基础。

我们可以设想将这一过程从数小时加速到数分钟。这里的问题在原则上似乎并无不同。随后可能加速到数秒。在某一时刻，人们有理由认为，大脑中足够大的部分被逐刻替换，以至于时刻之间意识连续性的依据不再像上述情况那样稳固。然而，一旦我们承认在数分钟内完成上传能够保持同一性，至少很难看出为何在数秒内完成上传就不行。

随着上传速度越来越快，极限点便是瞬间破坏性上传，即整个大脑被一次性替换。或许这个极限点与之前的所有情况都不同，但这至少并非显而易见。我们可以将此表述为支持破坏性上传乐观观点的论证。这里需要理解的是，无论是渐进式上传还是瞬间上传，都是破坏性的，因为它们都会摧毁原始大脑。

1. 戴夫在渐进式上传中作为戴夫 100 存活下来。2. 如果戴夫在渐进式上传中作为戴夫 100 存活下来，那么戴夫在瞬间上传中作为数字戴夫存活下来。

————— 3. 戴夫在瞬间上传中作为数字戴夫存活下来。

实际上，我已经为上述第一个前提进行了论证，并且至少存在一个初步的理由支持第二个前提，因为很难看出在数秒内完成上传与瞬间完成上传之间为何存在原则上的区别。如前所述，这一论证与关于远距传送的相应论证类似（渐进式物质替换保持同一性，因此瞬间物质替换也保持同一性），并且可用的考量也是相似的。

反对者可以沿着前面建议的思路否认前提 1，或者更可能否认前提 2 来反驳这一论证。对即时上传持悲观态度的人，就像对远距传输持悲观态度的人一样，可能认为中间系统在身份从一个系统传递到另一个系统的过程中起着至关重要的作用。这是忒修斯之船（Ship of Theseus）的常见观点，在这艘船中，所有木板在数年内逐渐被替换。很自然地认为结果是同一艘船，只是换了新木板。即使逐渐替换在几天或几分钟内完成，同样的情况也似乎是合理的。相比之下，从头开始建造一个没有任何中间情况的复制品，可以说会产生一艘新船。然而，很自然地认为关于这艘船的问题在某种意义上是一个语言问题或一个规定问题，而关于个人存活的问题则比这更深刻。因此，尚不清楚人们能在多大程度上从船的情况推广到人的形态。

现状。我们目前处于这样一种境地：对于破坏性上传的乐观和悲观观点，至少都有强有力的提示性论证。这些论证的结论截然相反，因此它们不可能同时成立。我自己的观点是，乐观主义者对非破坏性上传论证的最佳回应是分裂回应，而悲观主义者对渐进上传论证的最佳回应是中间情况回应。我的直觉在这里倾向于乐观主义，但和之前一样，我无法确定哪种观点是正确的。

尽管如此，我确信最安全的上传形式是渐进上传，并且我相当确信渐进上传是一种存活形式。因此，如果在未来的某个时刻，我面临在上传和继续以日益缓慢的生物形态存在之间做出选择，那么只要我有渐进上传的选择，我会很乐意这样做。

不幸的是，我可能没有这个选择。渐进上传技术可能在我有生之年无法实现。甚至可能在我有生之年根本没有任何足够的上传技术可用。这就提出了一个问题：在后奇点世界中，我或任何当前存在的人类是否仍有一席之地。

死后脑保存后的上传。一种可能性是，我们可以保存自己的大脑以便日后上传。人体冷冻技术（Cryonic Technology）提供了在死后不久将大脑保存在低温状态的可能性，直到有技术能够重新激活大脑，或者上传其中的信息。当然，死亡过程中可能会丢失大量信息，而且目前我们不知道冷冻保存是否足以保留信息来重新激活或重建任何类似于原始功能同构体的东西。但至少可以希望，在智能爆炸之后，非凡的技术或许能在此实现。

如果有足够的信息用于重新激活或重建，那么由此产生的系统会是我吗？在重新激活的情况下，很自然地认为重新激活的系统类似于从长期昏迷中醒来的人，因此原始人将在此存活。然后，人们可能会逐步上传大脑，并将结果整合到后奇点世界中。或者，人们可以在不重新激活大脑的情况下，从大脑创建一个上传系统。是否将此视为存活，将取决于人们对普通破坏性和非破坏性上传的态度。如果对这些上传形式持乐观态度，那么也可能对从保存的大脑中上传持乐观态度。

另一种可能的结果是，首先使用越来越好的扫描技术从保存的大脑中产生一系列上传，最终重新激活大脑。在这里，对上传持乐观态度的人可能将此视为分裂的情况，而悲观者可能认为只有重新激活的系统才与原始系统相同。

在这些情况下，我们对上传的哲学问题的看法不仅影响遥远未来的决策，也影响近期的决策。即使在近期，任何有足够资金的人都可以选择将其大脑进行人体冷冻保存，并留下随着技术发展如何处理大脑的指示。我们对上传地位的哲学观点很可能对我们应留下的指示产生影响。

当然，大多数人不会保存自己的大脑，即使那些选择这样做的人也可能

以某种方式死亡，使得保存变得不可能。在后奇点世界中，还有其他生存途径吗？

重建式上传。这里的最终替代方案是从记录中重建原始系统，尤其是重建式上传，即从记录中重建原始系统的上传。这里的记录可能包括脑部扫描和其他医疗数据；任何可用的遗传物质；原始人的音频和视频记录；他们的著作；以及他人关于他们的证词。这些记录看似有限，但超级智能利用它们取得重大进展并非不可能。鉴于人类系统结构的约束，即使有限的信息也可能使大量逆向工程成为可能。而详细信息，如大量视频记录和详细脑图像中可能包含的信息，原则上可能使超级智能重建出接近原始系统功能同构体的东西。

那么问题来了：重建式上传是一种生存形式吗？如果我们从记录中重建爱因斯坦的功能同构体，它会成为爱因斯坦吗？在这里，悲观观点认为这充其量类似于爱因斯坦的副本存活。乐观观点则认为这类似于爱因斯坦从长期昏迷中醒来。

从脑部扫描进行的重建式上传与普通的（非渐进的）脑部扫描上传密切相关，主要区别在于时间延迟，以及原始人在此期间可能继续存在。人们可以将其视为延迟的破坏性或非破坏性上传的一种形式。如果一个人将非破坏性上传视为生存（也许通过分裂），那么他自然会以同样的方式看待重建式上传。如果一个人因为信奉最近延续者理论而将破坏性上传而非非破坏性上传视为生存，那么他可能也会将重建式上传视为生存（至少如果原始生物系统已经消失）。如果一个人认为两者都不是生存，那么他可能对重建式上传也持同样的态度。大致相同的选择可能适用于从其他信息来源进行的重建式上传。

关于重建式上传的一个担忧如下。假设我有一个双胞胎。那么双胞胎不是我。但我的重建上传版本实际上也将是我双胞胎的重建上传。但这样一来，很难看出这个系统如何能真正是我。表面上看，它更像是一个新的双胞胎醒来。重建式上传的支持者可能会回应说，上传是基于我的大脑扫描而非我双胞胎的，这一点在这里很重要。

即使这些扫描完全相同，所产生的因果联系也是在上传体与我之间，而非我的孪生体。然而，如果我们有两个完全相同的扫描，很难看出如何

在两者之间做出选择将导致完全不同的人。进一步事实观点³⁶ 在这一点上，退一步审视一个关于生存的更广泛的哲学问题是有益的，这个问题与先前关于意识的问题相平行。这就是个人同一性是否涉及进一步事实的问题。也就是说：给定对各种系统在不同时间的物理状态（以及它们之间的因果联系）的完整知识，甚至包括这些系统在那些时间的心理状态，这是否自动使我们能够知道关于随时间生存的所有事实，还是这里存在开放问题？

至少存在一种直觉：在破坏性上传的案例中，即使完全掌握了物理和心理事实，仍留下一个开放问题：我能否在上传后存活，还是不能？例如，在涉及戴夫（Dave）和数字戴夫（DigiDave）的案例中，这些事实似乎既与戴夫作为数字戴夫存活的假设相容，也与他未能存活的假设相容。并且存在一种直觉：我们非常想知道关于哪个假设正确的事实。从这个角度看，乐观观点与悲观观点之间的争论，以及更广泛的心理观点与生物观点之间的争论，都是试图确定这些进一步的事实。

我们可以说，进一步事实观点认为，关于生存存在一些事实，这些事实在物理和心理事实的知识之外仍未确定。³⁷ 按照这里的定义，进一步事实观点是关于知识的论断，而非关于实在的论断（实际上，它主张存在认识论上的进一步事实），因此原则上与唯物主义相容。一种更强的观点认为，关于生存存在本体论上的进一步事实，涉及实在中额外的非物理要素，例如非物理的自我。不过，本文将聚焦于较弱的认识论版本。

如果一个人认为关于意识已经存在进一步事实，那么关于生存的进一步事实观点就特别自然，尽管并非必然。在本体论层面尤其如此

³⁶ 关于进一步事实观点和紧缩观点的材料在哲学上比其他材料更为抽象（尽管我已将更技术性的问题放到了脚注中），无法忍受这些细节的读者可以跳过。³⁷ “进一步事实观点”这一术语源自帕菲特，他并未区分该观点的认识论版本和本体论版本。帕菲特的用法将自我是“独立存在的实体”的观点归入另一类别，但按照我的用法，这类观点是进一步事实观点的一种实例。实际上，存在三种观点，与关于意识的三种观点相对应。A 型还原论认为，关于生存既不存在认识论上的进一步事实，也不存在本体论上的进一步事实。B 型还原论认为，存在认识论上的进一步事实，但不存在本体论上的进一步事实。

实体二元论认为，既存在认识论上的进一步事实，也存在本体论上的进一步事实。我自己的观点是，与意识的情况一样（理由在查尔默斯 2003 年的著作中讨论过），如果一个人接受认识论上的进一步事实观点，那么他也应该接受本体论上的进一步事实观点。但本文将不预设这一论断。

两种观点的版本：如果存在意识的基本属性，那么自然（尽管并非必然）会有拥有这些属性的基本实体。那么关于存活的事实可能被视为关于这些基本实体持续存在的事实。然而，即使在认识论观点上，人们也可能认为物理过程与意识之间的认识论鸿沟伴随着物理过程与自我之间的认识论鸿沟。如果是这样，那么关于自我存活的事实也可能存在认识论鸿沟。

原则上，进一步事实观点与心理、生物和最接近延续者的存活观点是相容的。³⁸ 人们可能认为，对物理和心理事实的完整知识留下了关于存活的开放问题，然而存活实际上与心理或生物连续性相伴。当然，如果人们知道正确的存活理论，那么将其与物理和心理事实的完整知识相结合，可能会回答所有关于存活的开放问题。但进一步事实观点的倡导者会认为，仅凭物理和心理事实的完整知识就会留下这些问题开放，并且也留下哪个理论是正确的这一问题开放。

我自己的观点是，进一步事实观点可能是正确的。我不知道它是否正确，但我认为它没有被我们所知的任何东西排除。³⁹ 如果进一步事实观点是正确的，我不知道心理、生物或其他关于存活条件的观点中哪个是正确的。

因此，我不知道对破坏性和重建性上传应持乐观还是悲观态度。

尽管如此，我认为在进一步事实观点上，意识的连续性很可能足以保证存活。⁴⁰ 这在观点的本体论版本上尤其明显，在这些版本中

³⁸ 本体论的进一步事实观点，若将心理和生物理论解释为关于生存是什么的理论，则与之不相容；但若将这些理论解释为关于生存实际获得的条件，则与之相容。（如果生存是非物理自我的持续存在，那么生存并不等同于生物或心理连续性，但生物或心理连续性仍可提供非物理自我持续存在的条件。）认识论的进一步事实观点可以与这四种观点中的任何一种相结合。³⁹ 在《理与人》中，帕菲特反对进一步事实观点（按我的用法），理由是它们需要实体二元论（“独立存在的实体”），并认为这类观点因科学以及某些部分传送和分裂案例而显得不合理。然而，帕菲特本人似乎接受关于意识的进一步事实观点和属性二元论观点，很难看出为什么关于自我的进一步事实或实体二元论观点会有额外的科学不合理性：无论哪种方式，进一步事实最好不要干扰物理定律，但不清楚为什么它们必须如此（参见查尔默斯 2003 年的讨论）。至于问题案例，帕菲特在这里的论证似乎依赖于这样的假设：进一步事实观点和实体二元论观点承诺生存是全能或全能的，但我不明白为什么会有这样的承诺。例如，实体二元论不必否认通过分裂（即使不是同一性）可以有生存。

意识的基本属性以及拥有这些属性的基本实体。那么意识的连续性暗示了实体之间跨时间的强连续性。但在认识论观点上这也是合理的。事实上，我认为一旦明确存在随时间连续的意识流，关于一个人是否生存就不再真正是一个开放问题。

那么困难的情况呢，比如非破坏性逐步上传或裂脑案例，其中一个意识流分裂成两个？在进一步事实观点上，我认为这种情况最好被视为分裂案例，类似于一个粒子或蠕虫分裂成两个的情况。在这种情况下，我认为可以合理地说一个人作为两个未来的人而生存。

总体而言：我认为，如果进一步事实观点是正确的，那么破坏性和重建性上传的地位尚不明确，但有充分理由对渐进式上传持乐观态度。

紧缩观点。然而，进一步事实观点是否正确远非显而易见。

这是因为，进一步事实观点所声称的未决生存事实是否真的存在，远非显而易见。生存的紧缩观点认为，我们试图解决关于生存的开放问题时，默认预设了并不存在的生存事实。可以说，我们倾向于相信伊甸园式生存：那种我们可能设想在伊甸园中拥有的原始自我生存。如今，自伊甸园堕落之后，伊甸园式生存已不存在，但我们仍倾向于认为它存在。⁴¹ 40 参见戴顿（Dainton）2008 年关于意识连续性在生存中的重要性的扩展论证，以及昂格尔（Unger）1990 年的相反观点。值得注意的是，从某种意义上说，这种观点不必是进一步事实观点（戴顿将其视为心理观点的一种形式）：如果将意识连续性的事实纳入基础中的相关物理和心理事实，并且认为一旦这些事实确定，关于生存就没有开放问题，那么就不会有进一步事实。然而，就当前目的而言，最好将相关物理和心理事实视为关于系统在某一时刻而非随时间变化的事实，从而排除意识随时间连续的事实。此外，即使在这种观点下，在意识连续性缺失的情况下，关于生存的开放问题可能仍然存在。⁴¹ 这种意义上的紧缩观点与前面脚注中讨论的 A 型还原论大致相同。帕菲特（Parfit）用“还原论”指代紧缩观点，但此处我不使用该术语，因为 B 型观点可能被合理地视为还原论，而并非这种意义上的紧缩观点。

为什么我坚持意识的进一步事实观点，却不坚持个人同一性的进一步事实观点？区别在于，我认为我们确信自己是有意识的（在产生认知鸿沟的强意义上），但我们并不确信自己随时间持续存在（在伊甸园意义上，即产生认知鸿沟的意义上）。实际上，意识是一个给定事实，而伊甸园式持续存在则不是。关于伊甸园观点的更多内容，参见我的“感知与从伊甸园的堕落”。

如果存在伊甸园式持续存在，那么即使在详尽说明人在各时刻的所有物理和心理事实之后，关于持续存在的问题仍将是开放问题。但在紧缩观点下，一旦我们接受不存在伊甸园式持续存在，我们就应当接受不存在此类进一步的开放问题。存在关于生物连续性、心理连续性和因果连续性的某些事实，仅此而已。

紧缩观点自然与关于持续存在的某种多元主义相结合。我们与后继者处于某些生物关系、某些因果关系和某些心理关系中，但其中没有任何一种被赋予“持续存在关系”的特权地位。所有这些关系都给予我们某些关心后继者的理由，但没有一种具有绝对分量。⁴² 人们可以对紧缩观点持悲观态度，说我们从未从一刻持续到下一刻，或从一天持续到下一天。⁴³ 至少，我们从未以我们自然认为的方式持续存在。但人们也可以对该观点持乐观态度，说这是我们共同体的生活形式，而且并不太糟。人们可能曾认为需要伊甸园式持续存在才能使生活值得过，但即使没有它，生活仍然有价值。我们仍然以各种非伊甸园方式持续存在，这足以让未来变得重要。

紧缩观点结合了上传的乐观观点和悲观观点的要素。

与乐观观点一致，该观点认为上传如同醒来。与悲观观点一致，上传不涉及伊甸园式存活。但在此观点下，醒来同样不涉及伊甸园式存活，且上传并不比醒来差多少。与醒来相同，上传中存在因果关联和心理相似性。与醒来不同，上传中存在生物学上的不连贯性。或许生物学连贯性本身具有某种价值，因此普通醒来可能比上传更有价值。但生物学连贯性与其缺失之间的差异，不应被误认为伊甸园式存活与其缺失之间的差异：价值上的差异至多是微小的。

如果紧缩论观点是正确的，我认为关于存活的问题归结为关于某些未来类型的价值问题：我们是否应该以关心我们存活于其中的未来的方式来关心它们？我不知道这些问题是否有客观答案。

⁴² 帕菲特持有一种非多元论的紧缩论观点，该观点将某种特定的因果和心理连续性视为重要的连续性。一旦放弃伊甸园式存活，我不清楚为何这种连续性应被赋予特权。⁴³ 存在一种兼具紧缩论观点和进一步事实观点要素的观点，根据该观点，我们在单一意识流中伊甸园式存活，但在意识停止时则不然。根据此观点，我们可能每时每刻伊甸园式存活，但或许并非日复一日。我不赞同此观点，但并非完全无共鸣。

但我倾向于认为，只要存在任何条件能够提供我们所关心的东西，意识的连续性就足以带来大部分正确类型的价值。因果和心理连续性也可能足以带来相当数量的正确类型价值。如果是这样，那么破坏性和重建性上传可能合理地接近普通存活。

那么困难的情况呢，比如非破坏性的渐进上传或分裂大脑的情况，其中一个意识流分裂成两个？在紧缩观点下，答案将取决于人们如何评价或应当如何评价这些未来。至少根据我们当前的价值体系，有理由认为物理和生物连续性具有某些额外价值，在这种情况下，生物戴夫可能比数字戴夫更有资格被视为戴夫。但也不能排除这种价值体系应当被修正，或者将来会被修正，从而使生物戴夫和数字戴夫被平等地视为戴夫。

无论如何，我认为在紧缩观点下，渐进上传几乎与普通的非伊甸园式生存一样好。而破坏性、非破坏性和重建性上传则合理地接近于普通生存。普通生存并不那么糟糕，因此人们可以将此视为一个乐观的结论。

结论。就我个人而言，我不确定进一步事实观点还是紧缩观点是正确的。如果进一步事实观点是正确的，那么破坏性和重建性上传的地位尚不明确，但我认为渐进上传很可能足以实现生存。如果紧缩观点是正确的，渐进上传几乎与普通生存一样好，而破坏性和重建性上传则合理地接近于同样好。无论哪种方式，我认为渐进上传无疑是最安全的上传方法。

关于上传还有许多进一步的问题。当然，还有许多社会、法律和道德问题我尚未开始讨论。这里我只讨论两个进一步的问题。

一个问题涉及认知增强。假设在上传之前或之后，我们的认知系统被增强到使用完全不同的认知架构的程度。

我们能否在这一过程中幸存？同样，在我看来，当增强是渐进的时候，答案最为清晰。如果我的认知系统一次只更换一个组件，并且在每个阶段都与前一阶段有合理的心理连续性，那么我认为有理由认为原初的人幸存了下来。

另一个问题是实用层面的。如果重建性上传最终成为可能，如何确保它发生？地球历史上已有数十亿人类。尚不清楚我们的后继者是否愿意重建每一个曾存在的人，或者

甚至每一个有记录的人。因此，如果一个人对永生感兴趣，如何最大化被重建的机会？可以尝试保留一个带复利的银行账户以支付他们这样做的费用，但很难知道我们的金融体系在未来是否仍然适用，尤其是在智能爆炸之后。

我自己的策略是撰写关于奇点和上传的文章。也许这会鼓励我们的后继者重建我，哪怕只是为了证明我错了。

11 结论

奇点会出现吗？我认为这当然不是不可能的，主要障碍可能是动机方面的障碍，而非能力方面的障碍。

我们应该如何应对奇点？非常谨慎地，通过将适当的价值观构建到机器中，并在虚拟世界中构建第一个人工智能和人工智能 + 系统。

我们如何融入后奇点世界？如果我们那时还在，通过渐进式上传然后增强；如果我们不在了，通过重建性上传然后增强。

参考文献

- Block, N. 1981. Psychologism and behaviorism. *Philosophical Review* 90:5-43.
- Bostrom, N. 1998. How long before superintelligence? *International Journal of Future Studies* 2. [<http://www.nickbostrom.com/superintelligence.html>]
- Bostrom, N. 2003. Ethical issues in advanced artificial intelligence. In (I. Smit, ed) *Cognitive, Emotive and Ethical Aspects of Decision Making in Humans and in Artificial Intelligence*, Vol. 2. International Institute of Advanced Studies in Systems Research and Cybernetics.
- Bostrom, N. 2006. Quantity of experience: Brain-duplication and degrees of consciousness. *Minds and Machines* 16:185-200.
- Campbell, J.W. 1932. The last evolution. *Amazing Stories*.
- Chalmers, D.J. 1990. How Cartesian dualism might have been true. [<http://consc.net/notes/dualism.html>]
- Chalmers, D.J. 1995. Minds, machines, and mathematics. *Psyche* 2:11-20.
- Chalmers, D.J. 1996. *The Conscious Mind*. Oxford University Press.
- Chalmers, D.J. 2003. Consciousness and its place in nature. In (S. Stich and F. Warfield, eds) *Blackwell Guide to the Philosophy of Mind*. Blackwell.

- Chalmers, D.J. 2005. The Matrix as metaphysics. In (C. Grau, ed.) *Philosophers Explore the Matrix*. Oxford University Press.
- Chalmers, D.J. 2006. Perception and the fall from Eden. In (T. Gendler and J. Hawthorne, eds) *Perceptual Experience*. Oxford University Press.
- Clark, A. and Chalmers, D. 1998. The extended mind. *Analysis* 58:7-19.
- Dainton, B. 2008. *The Phenomenal Self*. Oxford University Press.
- Dreyfus, H. 1972. *What Computers Can't Do*.
- Egan, G. 1994. *Permutation City*. Orion/Millennium.
- Floridi, L. and Sanders, J.W. 2004. On the morality of artificial agents. *Minds and Machines* 14:349-79.
- Flynn, J.R. 2007. *What is Intelligence?* Cambridge University Press.
- Good, I.J. 1965. Speculations concerning the first ultraintelligent machine. In (F. Alt & M. Rubino, eds) *Advances in Computers*, vol 6.
- Hanson, R. 1994. If uploads come first: The crack of a future dawn. *Extropy* 6:2. [<http://hanson.gmu.edu/uploads.html>]
- Hanson, R. 2008. Economics of the singularity. *IEEE Spectrum*, June, 37-43.
- Hanson, R. 2009. Prefer law to values. [<http://www.overcomingbias.com/2009/10/prefer-law-to-values.html>]
- Hofstadter, D.R. 2005. Moores law, artificial evolution, and the fate of humanity. In (L. Booker, S. Forrest, M. Mitchell, and R. Riolo, eds) *Perspectives on Adaptation in Natural and Artificial Systems*. Oxford University Press.
- Joy, W. 2000. Why the future doesnt need us. *Wired* 8.04, July 2000.
- Kurzweil, R. 2005. *The Singularity is Near*.
- Legg, S. 2008. *Machine Superintelligence*.
- Lucas, J.R. 1961. Minds, machines, and Gödel. *Philosophy* 36:112-27.
- Moravec, H. 1988. *Mind Children: The Future of Robot and Human Intelligence*. Harvard University Press.
- Moravec, H. 1998. *Robots: Mere Machine to Transcendent Mind*. Oxford University Press.
- Omohundro, S. 2007. The nature of self-improving artificial intelligence. [<http://steveomohundro.com/scientific-contributions/>]
- Omohundro, S. 2008. The basic AI drives. In (P. Wang, B. Goertzel, and S. Franklin, eds) *Proceedings of the First AGI Conference*. Frontiers in Artificial Intelligence and Applications, Volume 171. IOS Press.
- Parfit, D.A. 1984. *Reasons and Persons*. Oxford University Press.

- Penrose, R. 1994. *Shadows of the Mind*. Oxford University Press.
- Sandberg, A. & Bostrom, N. 2008. Whole brain emulation: A roadmap. Technical report 2008-3, Future for Humanity Institute, Oxford University. [<http://www.fhi.ox.ac.uk/Reports/2008-3.pdf>]
- Sawyer, R. 2000. *Calculating God*. Tor.
- Sawyer, R. 2005. *Mindscan*. Tor.
- Schmidhuber, J. 2003. Gödel machines: Self-referential universal problem solvers making provably optimal self-improvements. [<http://arxiv.org/abs/cs.LO/0309048>]
- Searle, J. 1980. Minds, brains, and programs. *Behavioral and Brain Sciences* 3:417-57.
- Shalizi, C. 2007. *g*, a statistical myth. [<http://bactra.org/weblog/523.html>]
- Smart, J. 1999-2008. Brief history of intellectual discussion of accelerating change. [http://www.accelerationwatch.com/history_brief.html]
- Solomonoff, F. 1985. The time scale of artificial intelligence: Reflections on social effects. *North-Holland Human Systems Management* 5:149-153. Elsevier.
- Strout, J. 2006. The mind uploading home page. [<http://www.ibiblio.org/jstrout/uploading/>]
- Ulam, S. 1958. John von Neumann 1903-1957. *Bulletin of the American Mathematical Society* 64 (number 3, part 2): 1-49.
- Unger, P. 1990. *Identity, Consciousness, and Value*. Oxford University Press.
- Vinge, V. 1983. First word. *Omni*, January 1983, p. 10.
- Vinge, V. 1993. The coming technological singularity: How to survive in the post-human era. *Whole Earth Review*, winter 1993.
- Wallach, W & Allen, C. 2009. *Moral Machines: Teaching Robots Right from Wrong*. Oxford University Press.
- Yudkowsky, E. 1996. Staring at the singularity. [<http://yudkowsky.net/obsolete/singularity.html>]
- Yudkowsky, E. 2002. The AI-box experiment. [<http://yudkowsky.net/singularity/aibox>]
- Yudkowsky, E. 2007. Three major singularity schools. [<http://yudkowsky.net/singularity/schools>]
- Yudkowsky, E. 2008. Artificial intelligence as a positive and negative factor in global risk. In (N. Bostrom, ed.) *Global Catastrophic Risks*. Oxford University Press.