
智能爆炸微观经济学

埃利泽·尤德科夫斯基 (Eliezer
Yudkowsky) 机器智能研究所

摘要

I.J. 古德的“智能爆炸”论点指出，足够先进的机器智能能够构建出更智能的自身版本，而后者又能构建出更加智能的版本，这一过程可能持续到远远超越人类智能的程度。正如桑德伯格（2010）正确指出的那样，已有若干尝试提出旨在表示经济或技术增长急剧加速的投资回报公式，但几乎没有人尝试正式处理古德的智能爆炸论点本身。

我将关键问题界定为认知再投资的回报——即投入更多算力、更快的计算机或改进的认知算法，以产生认知劳动，从而造就更大的大脑、更快的思维或更优的心智设计。世界上有许多现象被认为与这一问题具有证据相关性，从观察到的古人类演化历程，到摩尔定律，再到机器国际象棋系统随时间推移的能力提升，不一而足。我深入探讨了由此引发的关于如何解读此类证据的若干争论。我提出，分析智能爆炸相关立场的下一步，是将投资回报曲线形式化，以便每种立场都能正式声明其认为哪些可能的微观基础已被历史观察所证伪。更一般地，

本文提出多个关于“认知再投资回报”或“智能爆炸微观经济学”的开放问题。尽管这些问题迄今受到的关注甚少，但它们似乎与影响地球起源智能生命结局的政策选择高度相关。

目录

1 智能爆炸：认知再投资的增长率 1 1.1 关于（外延式）定义术语
.7 1.2 需要排除的问题 11 1.3 人工智能偏好：核心论
点简述 12

2 增长的微观基础 14 2.1 外部视角与卢卡斯批判 19

3 硬起飞模型的若干辩护 28 3.1 脑容量的回报 35 3.2
一次性收益 39 3.3 速度的回报
..... 43 3.4 人口的回报 50 3.5 人类文明的净效率
..... 53 3.6 累积进化选择压力的回报
56 3.7 关联进化难度曲线与工程难度曲线 61 3.8 我们观察进化人科
动物时的人类偏差 64 3.9 局部与分布式智能爆炸
..... 66

3.10 引发智能爆炸的最低条件 72

3.11 未知的未知的回报 75

4 迈向形式化的三个步骤 77

5 期望信息价值：我们想知道的与能知道的
推测图 82

6 智能爆炸微观经济学：一个开放问题 86

参考文献 89

1. 智能爆炸：认知再投资的增长率

1965 年，I.J. 古德¹ 发表了一篇题为《关于第一台超智能机器的猜想》（古德，1965 年）的论文，其中包含以下段落：

将超智能机器定义为一种能在所有智力活动上远超任何人的机器，无论此人多么聪明。由于机器设计属于这类智力活动之一，超智能机器能够设计出更优秀的机器；届时无疑将出现一场“智能爆炸”，人类的智能将被远远抛在后面。因此，第一台超智能机器是人类所需做出的最后一项发明。

此后，许多人开始质疑古德的不可置疑性，自 1965 年以来，争论的状态已有了相当大的发展。在等待尼克·博斯特罗姆即将出版的关于智能爆炸的著作期间，我同时推荐综述论文《智能爆炸：证据与意义》（Muehlhauser and Salamon 2012）作为紧凑的概述。另见大卫·查尔默斯（2010）的论文、相关回应以及查尔默斯（2012）的答复。

请注意，智能爆炸与通常被称为“奇点”的普遍经济或技术加速并非同一命题。经济加速出现在许多未来模型中，其中一些已经得到了很好的形式化。

例如，罗宾·汉森（Robin Hanson）1998 年的论文《机器智能下的经济增长》探讨了扫描人脑的仿真（即仿真）：汉森提出方程来模拟当资本（计算机）可以自由转换为与人类相当的熟练劳动力（通过运行仿真软件）时的经济行为。汉森得出结论，其结果应是一个倍增时间约为数月的全球经济。

这听起来可能已经令人震惊，但汉森的论文并未试图建模一个比任何现存人类都更聪明的智能体，也未探讨该智能体是否能够发明出更聪明的智能体。当超越人类的智能体² 推动科技进步时会发生什么，这一问题极为困难，以至于先前的形式化尝试

1. 伊萨多·雅各布·古达克（Isadore Jacob Gudak），他将自己的名字英国化为欧文·约翰·古德（Irving John Good），并以 I.J. Good 的名义发表作品。他是统计学贝叶斯方法的最早倡导者之一，并与艾伦·图灵（Alan Turing）合作进行早期计算机设计。在计算机科学领域，他的名字因古德-图灵频率估计器而永垂不朽。

2. 我使用“能动性”（agency）而非“智能体”（agent）这一术语，以涵盖协调良好的智能体群体，而非假定单一智能。

未来学建模完全忽略了这一点，尽管它经常被非正式地讨论；同样，更聪明的能动性产生更聪明的能动性的前景也尚未被正式建模。桑德伯格（Sandberg，2010）在其概述技术加速的形式化和半形式化模型的论文中总结道：

关于智能爆炸如何发生的模型显著缺乏。这可能是最重要且最难攻克的问题……

最重要，因为超级智能的出现最有可能从根本上改变人类的游戏规则（无论好坏）。最难，因为它似乎需要理解超人思维的一般性质，或至少需要一种方法来界定其能力和增长率。

针对一些认为智能爆炸在性质上被禁止的论点——例如，由于哥德尔定理（Gödel's Theorem）禁止构建人工思维³——的回应，请再次参见查尔默斯（Chalmers，2010）或穆尔豪瑟和萨拉蒙（Muehlhauser and Salamon，2012）。这里提出的开放问题是定量问题：是否有可能通过将认知改进再投资于进一步改进认知来获得持续回报。正如查尔默斯（Chalmers，2012）所说：

关键问题是“比例性论点”，即认为在某一类系统中，智能增加 δ 将导致这些系统所能设计的系统的智能增加 δ 。

为了阐明核心问题，让我们考虑一个正在进行裂变反应的核反应堆。⁴ 人类首次人工临界裂变反应于1942年12月2日在芝加哥大学的一个壁球场内实现，反应堆是一个巨大的门把手形状的铀砖和石墨砖堆。反应堆的关键参数是有效中子倍增因子 k ——即由一个中子引发的平均裂变次数所发射的平均中子数。（可以将 k 视为中子的“投资回报率”。）具有 $k > 1$ 的反应堆将处于“临界”状态，中子数量呈指数增长。增加更多铀砖会提高 k ，因为这使中子在离开反应堆之前有更多机会撞击更多铀原子。费米曾计算出反应堆应在第56层和第57层铀砖之间达到临界，但当添加第57层时，覆盖有中子吸收材料的木棒

3. 又称通用人工智能，又称强人工智能，又称人工通用智能。参见 Pennachin 和 Goertzel（2007）。

4. 铀原子不具有智能，因此这并不意味着智能爆炸应当类似于核反应堆。此处无意进行类比论证——只是从一个简单过程开始，逐步过渡到更复杂的过程。

镉箔被插入以防止反应堆达到临界状态。实际的临界反应是通过以六英寸的间隔缓慢抽出中子吸收棒而发生的。随着棒被逐次抽出且 k 增加，反应堆的整体中子水平上升，然后每次都在新的稳态下趋于平稳。下午 3 点 25 分，费米下令将棒再抽出十二英寸，并说道：“现在它将变得自持。迹线将上升并持续上升。它不会趋于平稳”（Rhodes 1986）。这一预测得到了证实：盖革计数器的计数增加到无法分辨的轰鸣声，其他在纸上记录中子水平的仪器持续攀升，每两分钟翻一番，直到二十八分钟后反应被关闭。对于这个反应堆， k 为 1.0006。平均而言，铀原子裂变发射的中子中有 0.6% 是“缓发的”——它们是由短寿命裂变产物的进一步衰变发射的，而不是由初始裂变（“瞬发中子”）发射的。因此，上述反应堆在仅考虑瞬发中子时具有 $k = 0.9946$ ，并且由于缓发中子的贡献，其发射量沿缓慢的指数曲线增加。一个瞬发中子 $k = 1.0006$ 的反应堆，其中子强度每十分之一秒就会翻一番。如果费米不了解构成他的反应堆的原子，而仅仅依靠其整体中子强度图来继续像以前那样表现——或者如果他只是堆上铀砖，好奇地凭经验观察会发生什么——那么那一年对芝加哥大学的学生来说就不是一个好年头。

核武器使用常规炸药将核材料压缩成具有瞬发 $k \gg 1$ 的构型；在核爆炸中， k 可能在 2.3 的数量级上，这对于核工程而言“远大于 1”。

在人类首次人工引发的临界反应启动之时，费米已经理解了中子与铀原子——理解得足够充分，能够以谨慎的增量抽出镉棒，仔细监测不断增长的反应，并在二十八分钟后将其关闭。我们目前对认知算法的状态空间尚无牢固的把握。我们对于通过增加资源或尝试改进底层算法来提升通用人工智能的认知问题解决能力，其难度或容易程度应如何，也缺乏牢固的把握。我们或许不应期望能够进行精确计算；我们关于认知算法空间的不确定知识状态，或许不应产生费米式的判断，即迹何时将开始攀升而不趋于平稳，具体到某根镉棒被抽出十二英寸。

但我们仍可寄望于解决更大、不那么精确的问题，例如一个试图自我改进的人工智能，或一个试图自我改进的全球人工智能群体，能否达到“临界”（ $k \approx 1^+$ ）或“超临界”（提示 $k \gg 1$ ）。我们不应

期望精确预测隐喻中的反应堆在两分钟后将输出多少中子。但或许我们可以提前预测，不断堆叠更多的铀砖最终将导致反应堆的中子产量开始以相对于此前上升速度而言迅速增长的速率翻倍……或者，另一种结论是，自我修改的人工智能不应被期望以爆炸性的速率改进。

为使这一问题不至于过于抽象，让我们立即考虑在智能爆炸辩论中已出现的几种截然不同的立场。

这并非一份详尽的清单。与任何具体例证或“详细叙事”一样，每种情形都会引入大量辅助假设。我还要提醒，不要将任何特定情形标记为“好”或“坏”——无论未观测变量的真实值如何，我们都应尽力从中获益。

在陈述了这些免责声明之后，考虑以下具体情景，分别对应隐喻中的“ k 远小于一”、“ k 略大于一”以及“提示 k 显著大于一”，就认知投资回报而言。

$k < 1$ ，“智能哑火”：

论点：对于计算机科学已知的大多数有趣任务，要获得性能的线性回报，需要指数级增加计算能力的投入。

大多数搜索空间呈指数级广阔，低垂的果实很快被耗尽。因此，一个试图投入认知工作量 w 来提升自身性能的人工智能，其回报将按 $\log(w)$ 增长，或者如果进一步再投资，序列 $\log(w))$ 将很快收敛。

$\log(w + \log(w))$ $\log(w), \log(w + \log(w)), \log(w + \log(w +$

情景：我们或许可以假设硅基智能与碳基智能并无显著差异，并且可以构建出约翰·冯·诺依曼水平的人工智能，因为冯·诺依曼本人是物理上可实现的。但构建出的冯·诺依曼所做的工作远不如历史上的冯·诺依曼有趣，因为科学的低垂果实已经被耗尽。数百万个冯·诺依曼只能比一个冯·诺依曼多完成对数级的工作量，而构建这样的人工智能并不值得其成本。人工智能在经济上无法替代大多数认知技能型人类劳动，因为即使能构建出更聪明的人工智能，人类的制造成本也更低。人们尝试通过基因工程、神经药物、脑机接口或克隆爱因斯坦等方式来提升人类智能；但这些尝试都因发现大多数“智能”要么不可复制，要么复制的成本不值得而受挫。摩尔定律决定性地失效，不仅因为微型化日益增加的技术困难，还因为更快的计算机芯片并不比上一代芯片多完成多少工作，

因此英特尔没有足够的经济动力去建设新工厂。生活基本如常继续，无论还有多少个世纪。

$k \approx 1^+$ ，“智能燃烧”：

论点：在过去几十年里，世界经济增长大致呈指数级——增长既没有跌破指数级，也没有爆发超过指数级，这意味着隐喻性的 k 大致等于一（且略偏正）。

这是一个充满智能认知主体的世界所表现出的典型行为：这些主体不断做出新的科学发现，发明新技术，并将资源再投资以获取更多资源。没有理由认为从碳基转变为硅基会产生任何不同。此外，任何单一的人工智能主体与经济总量超过七十亿的人类相比，都不太可能具有显著意义。因此，在相当长的一段时间内，人工智能的进步将主要由世界经济对人工智能研究的贡献所主导，而非由任何单个人工智能的内部自我改进所主导。

没有任何一个智能体能够贡献超过计算机科学总进展的极小部分，即使人类等效人工智能出现，这一点也不会改变

被发明出来。⁵

情景：将人工智能引入全球经济的效果是整体经济增长率的逐步、持续提升，因为最初且最昂贵的人工智能仅承担全球经济认知劳动的一小部分。随着时间推移，人工智能的认知劳动成本降低，并在整体经济中占据更大份额。指数增长的时间尺度从仅有人类经济的水平开始，逐步、持续地转向更高的增长率——例如，汉森（1998b）预测世界经济倍增时间介于一个月至一年之间。经济错位前所未有，但其发生的时间尺度为人类提供了一定的应对机会。

提示 $k \gg 1$ ，“智能爆炸”：

论点：迄今为止，人科动物进化的历史表明，它并不需要指数级增长的进化优化量来产生认知性能上的实质性现实收益——从直立人到智人的进化间隔并不需要是从南方古猿到直立人的十倍。⁶ 所有发现（如发明）所带来的复利回报

5. 我将这一粗略观点归功于罗宾·汉森（Robin Hanson），尽管他尚未确认这是否为公正的表述。

6. 这过于简化了。参见第 3.6 节，其中给出了一个略微不那么简化的分析，最终得出大致相同的结论。

农业的发明、科学的发明或计算机的发明，都没有发生在人类能够将技术红利再投资以增大脑容量、加速神经元或改进其神经回路所使用的底层算法的能力之上。由于人工智能可以将智能成果再投资于更大的大脑、更快的处理速度和改进的底层算法，我们应当预期人工智能的增长曲线会显著高于人类的增长曲线。

情景：第一个在认知再投资上实现可持续回报的机器智能系统，能够相对迅速地大幅提升其智能——例如，通过重写自身软件，或通过购买（或窃取）集群服务器上数量级更大的硬件访问权限。这样的人工智能是“瞬发临界”的——它可以在短时间内将认知投资的成果再投资，而无需先建造新的芯片工厂。当这些立即可用的改进耗尽时，人工智能已经足够聪明，例如能够破解蛋白质结构预测问题。人工智能将 DNA 序列通过电子邮件发送给在线肽合成实验室（其中一些声称有七十二小时周转时间），并利用所得定制蛋白质构建更先进的核糖体等价物（分子工厂）。不久之后，人工智能拥有了自己的分子纳米技术，可以开始建造更快的处理器和其他快速部署的先进技术基础设施。这种粗略的情景有时被通俗地称为“硬起飞”或“人工智能爆发”。⁷

关于这些立场，我们可以继续提出许多问题，它们实际上是沿着一个谱系分布的点，该谱系压缩了几个可能独立变化的维度等。从论证到情景的推论也存在争议。后续章节将更详细地讨论其中一些内容。

更广泛的理念是，关于“认知再投资的回报有多大？”的不同立场会产生截然不同的后果，并具有重大的政策启示。

投资资源以获取更多资源的问题是经济学中的基本问题。一个（近似）理性的主体会考虑多种改进途径，在最便宜的地方购买资源，在预期回报最高的地方投资，并试图绕过其偏好未明确禁止的任何困难。

7. 我必须迅速指出，在我看来，一个获得巨大力量的人工智能是好事还是坏事，将严格取决于该人工智能的目标系统。而这又可能取决于程序员是否能够解决“友好人工智能”（Friendly AI）的问题（参见尤德科夫斯基 [2008a]）。上述观点引出了另一个不同且宏大的讨论，这远远超出了本文的范围，尽管我已在第 1.3 节中非常简要地概述了一些核心思想。然而，提出这一点似乎很重要：硬起飞/人工智能走向爆发（AI-go-FOOM）的情景不一定是坏事，也不必然是好事。

绕过。这是使人工智能不同于一堆铀砖的一个因素：如果你将一根镉箔棒插入一堆铀砖中，这些砖块不会试图将棒推出来，也不会重新配置自身以使棒吸收更少的有价值中子。在经济学中，通常认为理性主体会尽力克服、绕过或智能地围绕障碍重新配置其活动。根据人工智能的偏好和能力，以及周围的社会环境，窃取防护薄弱的计算资源可能是合理的；非法投资的回报在现代经济理论中经常被分析。

因此，描述人工智能再投资增长曲线的问题似乎更类似于现有经济学，而非物理学或计算机科学中的现有问题。由于“微观经济学”是研究理性主体（如个人、企业、机器智能以及协调良好的机器智能群体）试图最大化其投资回报的学科，⁸ 所提出的关于认知投资与再投资下增长曲线的开放问题被命名为“智能爆炸微观经济学”。本文第 2 节讨论了谈论智能爆炸的基本语言，并主张我们应通过寻找潜在的微观基础来推进这一项目，而不是通过类比所谓相似的历史事件。第 3 节试图展示一些关于认知投资回报的具体非正式推理，展示作者在解释其对智能爆炸立场时出现的论证类型。

第 4 节提出了一种初步的方法论，用于形式化智能爆炸的理论——这是一个描述可能的微观基础并明确陈述其与历史经验之间所谓关系的项目，从而使某些可能性可以被证伪。

第 5 节探讨了哪些子问题既具有高价值又可能得到解答。

在领域存在合理不确定性的情况下，有许多我们想知道但可能无法知道的事情——例如，智能爆炸何时会发生？

第 6 节进行总结并提出开放性问题，同时讨论了机器智能研究所（MIRI）若要资助该领域的进一步工作所需满足的条件。

1.1. 关于（外延式）定义术语

人们自然会提出诸如“你说的‘智能’是什么意思？”或“什么样的 AI 系统算作‘认知再投资’？”之类的问题。我将尝试回答这些问题，但我所提供的任何定义都应被视为我个人关于智能爆炸理论的一部分。考虑早期科学家的隐喻立场

8. 在学术上，“宏观经济学”研究的是通货膨胀、失业、货币政策等。

他们刚刚提出了“火为什么是热的？”这个问题。接着有人问：“你说的‘火’到底是什么意思？”回答“火是燃素的释放”是自以为是的，更明智的回答是：“嗯，就提出这个问题而言，火就是从那一堆木柴中冒出来的明亮的橙红色热物质——我认为它实际上是燃素的释放——但这个定义是我答案的一部分，而不是问题本身的一部分。”我认为，当我们为了分析智能爆炸而试图定义“智能”时，明智的做法是牢记这种实用主义。⁹ 为了不完全回避这个问题，我通常使用“智能 $\equiv$ 高效跨领域优化”的概念，其构造如下：

1. 将优化能力视为将未来引导至在偏好排序中排名较高的可能性区域的能力。例如，深蓝（Deep Blue）有能力将棋盘的未来引导至其标记为“获胜”的可能性子空间，尽管加里·卡斯帕罗夫（Garry Kasparov）试图将未来引导至别处。

自然选择能够产生比随机 DNA 字符串所构建的“典型”生物体更善于自我复制的生物体——进化产生的 DNA 字符串在适应度上，在所有 DNA 字符串空间中排名异常靠前。¹⁰

2. 人类认知与蜜蜂认知或海狸认知的区别在于，人类认知在跨领域方面具有显著更强的普适性：蜜蜂筑巢，海狸筑坝，但人类工程师观察两者后，设计出具有蜂窝结构的堤坝。这也正是仅会下棋的深蓝与能够在许多不同领域运作并学习新领域的人类之间的区别。

9. 有一次我与杰伦·拉尼尔（Jaron Lanier）辩论，他长篇大论地论证称，将计算机称为“智能”是不好的，因为这会鼓励人类表现得更加机械，因此人工智能是不可能的；最后我说：“你的意思是，如果我编写一个程序，它又编写一个程序，那个程序又编写另一个程序，而那个程序构建了自己的分子纳米技术，飞往半人马座阿尔法星并开始建造戴森球，那个程序就不算智能吗？”

10. “优化”可以被描述为这样一个概念：当我们预期一个过程会经历不可预测的中间状态，而这些状态最终将适合接近一个可预测的目的地时，我们会援引这一概念——例如，如果你有一位朋友在陌生的城市开车送你去机场，你可以预测最终目的地是机场，即使你无法预测沿途的任何具体转弯。同样，深蓝的程序员通过检查其代码，保留了预测深蓝最终胜利的能力，尽管他们无法预测深蓝沿途的任何具体走法——如果他们确切知道深蓝会在棋盘上如何走子，那么他们自己的棋艺必然至少同样高超。

3. 人类工程学与自然选择不同，后者也是一种强大的跨领域结果主义优化器，区别在于人类工程学更快且计算效率更高。（例如，因为人类能够对搜索空间进行抽象，但这是关于人类智能的假设，而非我定义的一部分。）

综合起来，这些产生了一个“智能 $\equiv$ 高效跨领域优化”的定义。这试图将“改进的认知”描述为产生在偏好排序中更高解决方案的能力，包括例如，比随机棋局获胜概率更高的棋局，比随机论证更可能说服人类目标的论证，比先前中央处理器每秒执行更多浮点运算的晶体管连接图，或对应于特别适合构建分子工厂的蛋白质的脱氧核糖核酸字符串。优化的特征在于能够在搜索空间中击中狭窄目标，其中要求在偏好排序中更高排名会自动缩小同等或更优结果的测度。改进的智能则是在搜索空间中击中更狭窄的目标，以更高的计算效率，通过跨更广泛领域运作的策略。这个定义是我为其他目的（我关于机器智能本身的工作）而发明的，可能不适合用于推理智能爆炸。

为了讨论智能爆炸，更明智的做法可能是推理与我们可以观察到的量更直接相关的增长形式。搜索过程所达到的良好可能性空间的狭窄程度与大多数历史可观察量并不直接对应。

为了提出智能爆炸的问题，我们或许更适合采用这样的定义：“智能是源自大脑的那种聪明玩意儿，它能下棋、为债券定价、说服人们购买债券、发明枪支，并通过观察天空中游移的光点来发现万有引力；而且，如果机器智能大量拥有这种能力，它或许能发明分子纳米技术；等等。”换个角度说，如果某样东西强大到足以建造戴森球，那么我们是否称其为“智能”其实并不重要。而这正是我们所关注的那种“智能”——强大到无论我们是否将其定义为“智能”都无关紧要。这并不是说禁止下定义——只是说进一步的定义会进一步主张那些特定定义适合用来精确划分现实，以便准确预测智能爆炸。

定义的选择无法影响物理现实。如果你设法将“人工智能自我改进”定义为排除某个聪明的计算机玩意儿，而它对自己的代码进行了一周的神秘内部活动，然后

然后提出了一个蛋白质结构预测的解决方案，并利用它构建自己的分子纳米技术……那么显然选错了“自我改进”的定义。例如，参见马奥尼（Mahoney, 2010）倡导的定义，其中“自我改进”要求孤立系统的柯尔莫哥洛夫复杂度增加，或布林斯约德（Bringsjord, 2012）的定义，其中图灵机只有在能够将自己提升到超计算机类别时才被称为自我改进。这两种定义在我看来都不适合推理智能爆炸，因为并不明显（事实上我认为显然错误）这种“自我改进”是发明强大技术所必需的。人们可以将自我改进定义为孤立确定性系统的柯尔莫哥洛夫复杂度增加，并进而证明这只能以时间的对数增长。但证明现实世界智能爆炸因此不可能的全部负担，都依赖于这样一个论点：在现实世界中做出有影响力的事情需要孤立的机器智能增加其柯尔莫哥洛夫复杂度。我们不应忽视这显然是错误的。¹¹ 这并不意味着我们永远不应提出更复杂的自我改进定义。这意味着我们不应忽视无言的实际背景概念，即一个 AI 或 AI 群体重写自己的代码，或编写自己的后继版本，或编写一个全新的 AI，或建造更好的芯片工厂，或赚钱购买更多服务器时间，或以其他方式增加系统中实际考虑的认知问题解决能力。此外，“自我改进”可以描述基因工程人类，或具有脑机接口的人类，或上传分支，或其他几种可能的认知再投资场景，尽管这里我将专注于机器智能的情况。¹² 正是本着这种精神，我提出了形式化 I. J. 古德（I. J. Good）智能爆炸概念这一开放问题。为所提问题中出现的非正式术语（如“认知再投资”）提出良好定义，可以被视为该问题的一部分。在进一步讨论中，我提出了各种定义、类别和

11. 由于任何具有柯尔莫哥洛夫复杂度（Kolmogorov complexity） k 的系统都无法预测规模大于 k 的机器的忙碌河狸序列，因此，若要在能够预测更多忙碌河狸序列的意义上提升智能，就需要提高柯尔莫哥洛夫复杂度。然而，即便是卡尔达肖夫三级（Kardashev Level III）的银河文明，恐怕也无法预测很长的忙碌河狸序列，因此这种形式的“智能”所受的限制并不具有很强的约束性。更多讨论参见我在此处的非正式论述。

12. 这是传统观点，但也是合理的，因为完全基于计算机、经过刻意设计的智能似乎比生物大脑更适合进一步的刻意改进。生物大脑由大量无文档的意大利面条式代码组成，运行在微小且充满噪声的细丝上，读取这些代码尚且需要医学上的巨大巧思，更不用说编辑了。这一点已被广泛认可，但当然并非毫无争议。

然而，任何认为另一组定义更适合“在关节处切分现实”——即更适合预测当某种智能体试图投资于变得更智能时，我们实际上会观察到什么——的人，都可以合理地对此类建议提出异议。

1.2. 需要排除的问题

尽管我们最终只关心现实世界的结果，但我认为，如果我们将这些问题在其自然关节处进行剖析，将某些议题分离出来单独考虑，在理论上将是富有成效的。例如，是否存在一种有效的监控机制能够阻止智能爆炸，或者全球经济是否会在此之前因全球变暖而崩溃，以及许多其他似乎与认知投资作为认知投资的回报没有强烈交互作用的问题。¹³ 特别地，我建议明确排除所有关于“如果智能体的偏好使其不希望以最快可实现的速度提升能力，那会怎样？”的考虑。正如奥莫亨德罗（Omohundro，2008）和博斯特罗姆（Bostrom，2012）所指出的，大多数可能的偏好都意味着能力提升是一种工具性动机。如果你想建立一个充满有感知能力、生活美好的生命的星际文明，你将需要获取能量和物质。如果你想用两百米高的巨型芝士蛋糕填满太空，情况也是如此。在任何一种情况下，你都会有一个变得更聪明的工具性目标。正如通过获取更多物质资源可以更好地实现大多数目标一样，通过更好地解决认知问题——能够在搜索空间中击中更窄的目标——你也可以完成更多事情。

所有可能的心智设计空间是巨大的（米尔豪瑟和萨拉蒙，2012），并且总会有某个智能体选择不执行任何给定行为的特殊情况（阿姆斯特朗，即将出版）。因此，在具备足够设计能力的情况下，应该有可能设计出一个不偏好以最大可能速度提升的智能体——尽管在其自身偏好中表达这一点，我预计在结构上并非易事。即便如此，我们仍需要单独考虑一个问题：如果一个理性智能体试图尽可能快地自我改进，它能够以多快的速度发生智能爆炸。如果最大提升速度本身就很慢，那么构建一个特殊的 AI 设计，使其偏好不比自己程序员能够验证的速度更快地改进，就没有什么意义了。

13. 特别地，我希望避免循环论证，例如“智能爆炸是否可能并不重要，因为会有监控机制来阻止它”，以及“监控机制是否失效并不重要，因为智能爆炸是不可能的”，这样你永远无法在转向循环的另一边之前充分讨论任何问题。

政策是由期望效用的差异所驱动的；除非我们预测在假设不采取行动 X 的情况下 Y 可能会随之发生，否则没有动机去采取任何旨在防止 Y 的行动 X。这要求我们暂时搁置所提出的减缓因素，讨论一个理性主体在未被减缓的情况下可能会做什么。

因此，我建议对智能爆炸的初步研究应考虑一个理性主体在当今世界已存在的障碍之外，试图尽可能快地自我改进时，认知再投资的可实现回报率。¹⁴ 这也反映了一种希望，即尝试解决所提出的开放问题不应需要友好人工智能或国际政治方面的专业知识，就能讨论认知投资作为投资的回报，即使预测实际现实世界的结果可能（或可能不）需要将其中一些问题重新纳入考虑。

1.3. 人工智能偏好：核心论点简述

尽管有上述情况，似乎不可能不至少简要总结一下关于人工智能偏好的讨论现状——如果有人相信一个足够强大的人工智能，或者一个以远高于人类其他部分的速度增长从而获得不可超越优势的人工智能，不可避免地注定要杀死所有人，那么他们可能很难冷静地考虑和分析潜在的增长曲线。

我曾提出，原则上以及在困难的实践中，应当有可能设计出一种“友好人工智能”，由程序员选择人工智能的偏好，并让人工智能以足够高的保真度进行自我改进，从而可知地保持这些偏好稳定。我还认为，原则上以及在困难的实践中，应当有可能将人类偏好中固有的复杂信息传递给人工智能，然后应用进一步的理想化，如反思平衡和理想顾问理论（Muehlhauser and Williamson 2013），以得出一个在直觉上对应于人工智能“做正确的事”的输出。另见 Yudkowsky (2008a)。

在更大的范围内，围绕这些问题的讨论现状似乎围绕四个主要论点展开：智能爆炸论点认为，由于递归自我改进，人工智能的能力有可能在相对于人类经验而言显得快速的时间尺度上增长。这反过来意味着，那些依赖于人类对

14. 也就是说，我们可能假设人们继续用防火墙保护自己的家用电脑，无论其价值如何。我们不应假设存在一个庞大而有效的全球监控组织，致力于消除人工智能中任何自我改进的迹象，就像威廉·吉布森（1984）的《神经漫游者》中的图灵警察那样。另见罗伯特·弗雷塔斯（2000）的《全球生态吞噬的一些限制》中所使用的那种假设，其中提出的关于生物圈转化为纳米机器速度的限制，围绕着一个假设，即存在一个全球监控机构寻找无法解释的热量爆发，并且这将限制纳米机器允许的热量耗散。

长期来看，约束或惩罚人工智能不太可能成功，而且第一个强烈自我改进的人工智能所偏好的内容，最终可能大体上决定源自地球的智能生命的最终结局。（这一子论题是本文的全部主题。可以观察到，围绕该论题的论证远比上述简单总结所暗示的要复杂得多。下面其他三个论题也是如此。）正交性论题认为，心智设计空间足够广阔，能够容纳几乎任何类型偏好的心智。存在工具理性主体，它们追求几乎任何效用函数，并且在反思下大多保持稳定。参见阿姆斯特朗（即将出版）以及穆尔豪瑟和萨拉蒙（2012）。支持正交性论题的有力论证很多，但最强有力的论证之一是通过构造进行的：如果能够回答纯粹认识论的问题，即哪些行动会导致多少回形针存在，那么通过将该答案连接到运动输出，就构造出一个追求回形针的主体。如果它非常擅长回答哪些行动会导致大量回形针这一认识论问题，那么它将是一个非常具有工具性力量的主体。¹⁵ 价值复杂性论题认为，人类价值是复杂的，即具有高算法（柯尔莫哥洛夫）复杂度（尤德科夫斯基 2011；穆尔豪瑟和赫尔姆 2012）。即使是人类价值的理想化形式，如反思平衡（罗尔斯 1971）或理想顾问理论（罗萨蒂 1995）——即我们在无限世界知识、无限思考速度和完美自我理解等极限下所想要的东西——也被预测仍然具有高算法复杂度。这往往源于自然主义的元伦理学理论，根据这些理论，人类对幸福、自由、成长、审美、正义等的偏好（参见弗兰克纳 [1973，第 5 章] 中列出的常见终极价值清单）没有特权理由可以轻易地相互还原或还原为其他任何东西。价值复杂性论题认为，要实现有价值的结果，人工智能的效用函数中必须包含复杂信息；它也将

15. 这样的智能体不会修改自身以追求其他目标，因为这将导致世界上回形针数量的减少，而它对于所有行动（包括内部行动）的评判标准是预期回形针的数量。它不会修改其效用函数以使其具有人类更喜欢的属性，因为它本身并不关心这类元属性，也不承诺相信回形针占据这类属性的最大值；它是一个预期回形针最大化器，而非预期效用最大化器。对称地，那些在初始状态就被成功构建为具有“友好”偏好的人工智能，不会仅仅为了赋予其效用函数某种特定的逻辑属性而抛弃这些友好偏好，除非它们原本就被构建为关心该属性。

仅仅告诉它“让人类快乐”或任何其他简化、压缩的

原则，是不够的。¹⁶

工具性收敛论题指出，对于大多数效用函数的选择，工具理性智能体将可预测地希望获得某些通用资源，例如物质和能量，并追求某些通用策略，例如不进行会改变其未来有效偏好的代码修改（Omohundro 2008; Bostrom 2012）。工具性收敛意味着，人工智能并不需要具有伤害人类的特定终极价值，人类才会受到伤害。人工智能不恨你，但也不爱你，而你由原子构成，它可以利用这些原子做其他事情。综合来看，智能爆炸论题、正交性论题、价值复杂性论题和工具性收敛论题，意味着在能否解决以下设计问题方面存在巨大的效用差异：（1）与具有稳定可指定偏好的自我改进型人工智能相关的问题，以及（2）与人类价值的成功转移（以及通过例如反思平衡或理想顾问理论对其进行进一步理想化）相关的问题，而这些问题都关系到第一个经历智能爆炸的人工智能。

在关于智能爆炸的更大讨论中，与微观经济学相比，这完全是另一个截然不同的主题。在此我只想指出，认知投资的高回报并不必然对应那些痛苦到我们不得不反对的、不可避免的恐怖场景，也不对应那些有德之人应当认同的、支持科技的良性场景。就我个人而言，我倾向于认为认知再投资的更高回报对应着更大的政策依赖型方差。无论那些不可见变量的真实值是什么，问题不在于它们听起来是“好消息”还是“坏消息”；问题在于，在那些背景设定下，我们如何尽可能改善结果。

2. 增长的微观基础

考虑对智能爆炸论点的这一立场：“我认为我们应该预期，指数级增加的投资——无论是计算硬件、软件编程努力等——在现实世界的认知任务表现上只会产生线性收益，因为大多数搜索空间都是指数级庞大的。因此，机器的成果

16. 支持价值复杂性的进一步论证表明，即使是“世界主义”或“非人类自私”的结果，也隐含着高柯尔莫哥洛夫复杂度的规格说明。也许你会认为自己会满足于一个充满有感知能力的存在、以你无法理解的方式快乐互动的未来星际文明，即使其中没有一个是人类或源自人类。但一个预期的回形针最大化器会用回形针填满星系。这就是为什么预期的回形针最大化器令人恐惧。

将智能再投资于人工智能，每一步只会获得对数收益，而“智能爆炸”将很快消退。”这种情景是合理还是不合理？我们在现实世界中是否见过任何东西——做过任何观察——应该影响我们对其概率的估计？

（在这一点上，我建议认真的读者先停下来，花点时间自己思考这个问题，然后再继续。）一些可能相关的事实可能是：

- 将指数级更多的计算能力投入到一个恒定的国际象棋对弈程序中

国际象棋博弈树可搜索深度的线性增长，似乎对应着国际象棋等级分（Elo Rating）的线性提升（其中，两个相对等级分差距固定的对手，无论绝对等级分如何，理论上彼此胜负概率恒定）。

- 国际象棋算法的改进速度近期远超国际象棋硬件，

尤其是在国际象棋程序开始开源之后。深蓝（Deep Blue）以每秒 118 亿次浮点运算运行，等级分约为 2700；深里布卡 3（Deep Rybka 3）在英特尔酷睿 2 四核 6600 处理器上以每秒 24 亿次浮点运算运行，等级分达到 3202。¹⁷

- 似乎在许多重要意义上，人类从自身智能中获得的现实世界回报是黑猩猩近亲的四倍以上。

这一成就的取得，是在智人（Homo sapiens）拥有约四倍的大脑皮层体积和六倍的前额叶皮层的情况下实现的。¹⁸

- 在当前人类物种内部，测得的智商与大脑尺寸存在关联；

这种关联在方差上约为 0.3 的相关性，而非每提升十个智商点就需要大脑尺寸翻倍。¹⁹

- 衡量计算技术、每秒操作数的各种类摩尔定律

其次，每美元运算次数、每美元磁盘空间等指标，通常被认为具有从十二个月到三年不等的特征倍增时间；这些指标被表述为随时间呈指数增长。人们已经撰写了相关论文

17. 得分由瑞典国际象棋计算机协会根据在锦标赛级别进行的 1,251 局比赛确定（正负 ~ 23 分）。

18. 关于硬件扩展，你可能试图得出的明显结论过于简化，并且会存在相关错误。参见第 3.1 节。

19. 对于不熟悉现代心理学文献的参赛者：是的，几乎所有认知能力测度之间都存在强相关性 g ，而智商测试又与这一 g 因子高度相关，并与许多可测量的生活结果和性能指标有良好相关性。参见《剑桥智力手册》（Sternberg 和 Kaufman 2011）。

质疑摩尔定律的有效性（参见，例如，图奥米 [2002]）；以及串行处理器速度的类摩尔定律在 2004 年失效。戈登·摩尔最初观察到的关于每平方厘米晶体管数量的原始定律，至今仍保持其轨迹。

- 英特尔投入的研究人员工时和经通胀调整的资金呈指数级增长

关键在于发明技术并为连续几代中央处理器（CPU）建设制造工厂。但中央处理器本身的晶体管每秒运算次数呈指数增长，而非线性增长；且计算机算力翻倍时间比投资增长翻倍时间更短（即指数更高）。

cost.²⁰

- 进化时间量（累积选择压力的代理测度）

以及进化优化）在人类和原始人类进化过程中产生了显著的变化，似乎并未显示出投入的时间呈指数级增长。从直立人到智人的进化所需时间，并非是从南方古猿到直立人所需时间的十倍。²¹

- 世界经济产出大致呈指数增长，且增速快于人口增长，这与投资呈指数增长的趋势大致相符

产生指数级增长的回报。也就是说，投资回报大致呈线性（但带有乘法因子 $k > 1$ ）。在更长的时间尺度上，世界历史经济产出可以被描述为一系列指数模式（Hanson 1998b）。公元 1600 年或公元前 2000 年，人类总经济产出也呈指数增长，但指数较小，倍增时间更长。

- 科学产出以“论文总数”衡量，往往在短期内呈指数增长

翻倍时间，无论是全球范围（约二十七年 [NSB 2012, 第 5 章]）还是任何给定领域内。但声称从 1970 年到 2010 年的全球变化多于从 1930 年到 1970 年，似乎极其可疑。（对于相对更常听到“加速变革”而非“大停滞”的读者：该主张是，例如美国的总要素生产率增长从 1970 年代前的每年 0.75% 降至之后的 0.25% [考恩（Cowen）2011]。）一个真正的怀疑论者可能会声称，在许多领域，指数级更大的

20. 正如卡尔·舒尔曼（Carl Shulman）所观察到的，英特尔并未雇佣 3.43 亿名员工。

21. 有人可能会反问，直立人（Homo erectus）是否仅仅因为时间上足够遥远而拥有独立的物种名称，而非基于任何先验的认知能力测度（measure）而被单独挑出。这一问题将在第 3.6 节中更详细地讨论。

科学投资带来的年度进展大致恒定——呈次对数回报！²²

- 该图（Silver 2012）展示了欧洲作为作者的书籍数量

时间的函数；印刷机发明后，该图以快于指数的急剧上升趋势跃升。

- 已知历史中的所有技术进步，本质上都是由

恒定的人类大脑结构。有关于过去一万年人类持续进化的论点，但所有这些变化都远未达到改变“你拥有一个大约 1250 立方厘米的树突和轴突组成的大脑，连接着前额叶皮层、视觉皮层、丘脑等”的规模。在人类统治时期，支持持续产生更复杂技术和科学并不需要更大的大脑，也不需要更大的总累积选择压力。

- 人类工程师在单位时间内创建的复杂订单数量是 com-

与物种内部自然选择在单位时间内创造的复杂有序性相比，这一数量级完全不在同一尺度上。一个传递 3% 适应度优势的单一突变，预计需要 768 代才能在拥有十万成员的有性繁殖种群中达到固定。计算机程序员可以在一天或一小时内设计出具有数百个相互协作部件的新复杂机制。反过来，自然选择在单位时间内创造的复杂有序性，对于生命出现之前的地球而言，也完全不在同一尺度上。地球历史上“单位时间内创造的有序性”的图表将包含两个不连续点，代表着根本不同的优化过程的出现。

上述观察列表可能会让你觉得结果可能朝任一方向发展——有些事物呈指数增长，有些则不然。更糟的是，这看起来像是在邀请你根据情感诉求或转瞬即逝的直觉来决定你对人工智能自我改进的偏好信念，然后认定上述案例中任何与你认为人工智能自我改进应有的行为方式相似的案例，都是我们应当参考的自然历史范例，用以确定人工智能的结局。例如，自我改进型人工智能的出现显然最类似于其他经济

22. 事实上，我正是这样一位真正的犬儒主义者，我怀疑社会因素稀释平均贡献的速度，大约与新研究者加入的速度一样快。一个不那么犬儒的假设是，早期的科学更容易，而后期的科学变得更困难，其难度增长速率与科研产出随研究者数量增加而扩展的速率大致相同。

诸如农业发明之类的加速。²³ 或者显然，它类似于复杂秩序生产中其他基础性变革，例如人类智能或自我复制生命。²⁴ 或者不言而喻，整个喧嚣类似于 2012 年对玛雅历法终结的恐慌，因为它属于“尚未被观察到的所谓未来大事件”这一参考类。²⁵ 关于“参考类网球”问题的更多讨论，见第 2.1 节。在我看来，从上述列表的长度中得出的真正教训是，我们不应期望存在某种单一的大定律，规定认知投资是否获得超指数、指数、线性、对数或恒定回报。上述案例表现出不同的行为；它们并非都遵循单一的大增长法则。

同样，现实也并非通过从桶中随机抽取一种曲线类型来分配给每个场景，而“人工智能自我改进”的曲线类型将从同一个桶中独立有放回地抽样。因此，通过鼓吹某种曲线类型的历史案例来论证某人偏好的曲线类型被抽中的可能性，从而证明该类型在曲线类型桶中更常见、更可能被随机抽中，这似乎同样不成立。上述引用的大多数过程随时间表现出相当规律的行为。这意味着所附曲线实际上是该过程因果机制的特征，并且是这些机制的可预测特征，而非随机分配和再分配。任何举手投降并说“这一切都不可知！”的人，其预测得分也可能低于他们本可以达到的水平。

这些表现各异的情形并非关于同一条宏大认知投资曲线以往如何运作的相互竞争的论点。它们同时为真，因此必然在告诉我们关于增长曲线的不同事实——告诉我们多元增长函数的不同领域——提示我们关于智能与现实世界力量如何随不同种类的认知投资而变化的诸多相容真理。²⁶

23. 参见汉森（2008a）。

24. 参见尤德科夫斯基（2008b, 2008c, 2008d）。

25. 参见，例如，在线讨论中的这篇帖子。

26. 现实本身始终完全一致——只有地图可能相互冲突，而非领土。在贝叶斯证据定义下，“强证据”正是那种我们几乎从不在争论的一方以上看到的证据。除非你在某处犯了错误，否则你几乎不应看到指向不同方向的极端似然比。因此，所列事实不可能都是关于同一变量、指向不同方向的“强”论点。

与其选择某一条特定的历史曲线来认定为智能爆炸的特征，或许可以构建一个潜在的因果模型，该模型将与所有这些独立事实相容。我提议，我们应尝试构建一个微观基础模型，该模型不仅概括表面规律，而且试图描述潜在的因果过程以及特定类型认知投资的回报。例如，与其仅仅谈论国际象棋程序如何随时间改进，我们或许可以尝试描述国际象棋程序如何作为计算资源加上人类工程师累积花费在调整算法上的时间的函数而改进。进而我们可以说，人类工程师具有某种特定的智能或优化能力，这与黑猩猩的优化能力或自然选择过程不同。构建这些因果模型的过程有望让我们得出一个更现实的图景——一个与不同历史情境中观察到的许多不同增长曲线相容的图景。

2.1. 外部观点与卢卡斯批判

迄今为止关于智能爆炸的非正式辩论中的一个根本张力，是在对这些未来事件进行建模时，可信且有用的抽象程度大致如何。

我第一次碰巧与雷·库兹韦尔（Ray Kurzweil）同处一室时，问他为什么他的摩尔定律（Moore's Law）图表显示，“一台价值 1000 美元的计算机与人脑一样强大”、“一台价值 1000 美元的计算机比人脑强大一千倍”以及“一台价值 1000 美元的计算机比人脑强大十亿倍”这些事件都遵循摩尔定律的同一历史趋势。²⁷ 我问道，在假定存在计算能力高出十亿倍的智能体之后，继续外推人类观察到的摩尔定律版本是否真的合理？

库兹韦尔 2001 回应称，机器超级智能的存在恰恰是为摩尔定律持续提供动力并使其能够继续开发所需技术的因素。换言之，库兹韦尔 2001 将摩尔定律视为首要现象，而将机器超级智能视为次要因素。

27. 同一张图表将所谓的“人类水平计算能力”作为预测人工智能的阈值，这是一种我强烈反对的方法论，但当时我不想就这一部分进行争论。我在谷歌图片中搜索了确切的图表，但没有找到；维基百科确实引用了《灵魂机器的时代》（Kurzweil 1999）中做出的类似预测，但维基百科引用的时间线比我记忆中的要短。

一种现象，它应当呈现任何所需的形态，以保持主要现象按轨道运行。²⁸ 你甚至可以想象论证（尽管库兹韦尔 2001 并未提及这部分），我们已经见证了摩尔定律历经多代、跨越多种不同类型的硬件而持续有效，而我们对于机器超级智能却毫无实际经验。因此，对摩尔定律的外推应在认识论上优先于关于超级智能的更具推测性的预测，因为它基于更多的经验和更确凿的观察。

我对同一段历史的个人解读是，存在一条潜在的难度曲线，表明更复杂的中央处理器（CPU）需要更多知识和更先进的制造技术才能制造出来，而随着时间的推移，人类研究人员运用他们的智慧提出了各种发明、制造更多发明的工具、物理理论、检验这些理论的实验、辅助设计中央处理器的程序，²⁹ 等等。每十八个月在给定面积内封装更多晶体管的过程，不应被视为地球绕太阳运行 1.5 圈频率的外生因素；它应当是工程师能力的函数。因此，如果我们拥有更快的工程师，我们应当预期摩尔定律会以更快的速度发展。（关于快速操纵技术和传感器带宽同样必需的要点与反论点，参见第 3.3 节。）库兹韦尔 2001 年给出了一个即兴回应，似乎暗示摩尔定律的难度可能以与超级智能解决问题能力增长相同的速率增加，从而在时间维度上维持了对摩尔定律的预测。但为什么这应当成立呢？我们并不确切了解历史上内在难度曲线的形态；它难以直接观测。我们的主要数据是更为人熟知的摩尔定律轨迹，它描述了人类工程师在外部时间中穿越难度曲线的速度。³⁰ 但我们仍然可以合理地预期，如果我们的旧外推是基于人类工程师而预测摩尔定律遵循某种曲线，那么更快的工程师应当突破这一外推向上发展。

28. 我按年份附加下标，因为（1）库兹韦尔是即兴回答，因此将其临场回应视为其个性的永久特征并不公平，并且（2）桑德伯格（2010）指出库兹韦尔此后已改变立场。

29. 最大的酷睿 i7 处理器中有超过二十亿个晶体管。在这一点上，人类工程需要计算机辅助。

30. 可以想象，英特尔可能已平衡其研究投资的增长率，以跟随行业对摩尔定律的预期，即使一条更不规则的潜在难度曲线变得更陡或更缓。这一假设本身似乎并非不可检验——英特尔内部确实有人必须做出这类决策——但如何利用先前收集的、易于获取的数据来检验它，对我来说并不显而易见。

或者更直白地说，完全天真的向另一个方向的外推会是：“给定恒定速度的人类研究者，计算速度每 18 个月翻一番。因此，如果研究者本身就在计算机上运行，我们应该预期计算速度在 18 个月内翻一番，然后在 9 个物理月（或对于 2 倍速度的研究者来说是 18 个主观月）内再次翻一番，然后在 4.5 个物理月内再次翻一番，最终在总共 36 个月后就达到无穷大。”如果人类以恒定速率积累主观时间 $x = t$ ，并且我们观察到计算机速度作为主观时间的摩尔定律指数函数而增加 $y = e^x$ ，那么当主观时间以当前计算机速度的速率增加时，我们得到微分方程 $y' = e^y$ ，其解使计算机速度呈双曲线增长，在有限时间后趋于无穷大。³¹（例如，参见莫拉维克的模型 [1999]。）在现实生活中，我们可能不相信这是一个定量估计。我们可能不相信在现实生活中，这样的曲线在开始触及（很高的）物理界限之前，会大致具有双曲线形状。但与此同时，在现实生活中，我们可能相信，如果研究者能够将他们的劳动成果再投资于自身的认知速度，研究应该会显著加快——我们在这个论证中看到了一个重要的暗示，即使其细节是错误的。我们可以相信一个定性预测：“如果计算机芯片现在遵循摩尔定律，而人类研究者以恒定的神经处理速度运行，那么在研究者运行在计算机上的假设情景中，我们应该看到一个新的摩尔定律，其下界远低于之前的摩尔定律。”你可能会说：“给我一个合理的模型，说明制造芯片的难度如何作为知识的函数，以及知识如何随主观时间积累，一旦研究者运行在计算机上，你就会从摩尔定律中得到一个超指数爆炸。相反，如果你给我一条规则的增长难度曲线来避免智能爆炸，它将错误地回溯预测人类工程师只能从计算机技术中获得次指数级的改进。当然，如果制造芯片突然变得困难得多，恰好与人工智能开始做研究的时间巧合，那将是不合理的——曲线的一种特定的、无根据的奇迹般的不规则性。”

难度曲线可能会在之后的某个随机时间点向上移动，但在那之前，任何可获得的改进仍会带来丰厚的收益。”反过来，这个回答将我们引向一个相当棘手的元层次问题：

A：你为什么要引入这些奇怪的新不可观测抽象？我们可以看到芯片随时间推移变得越来越快。这是我们可以测量的，也是我们有经验的东西。谁测量你所说的这种难度

31. 的解 $dy/dt = e^y$ is $y = -\log(c - t)$ 和 $dy/dt = 1/(c - t)$.

？谁测量知识？这些都是凭空捏造的量，在现实中没有任何严格的基础。我们确实拥有的坚实观察是计算机芯片上晶体管的数量，按年计算。所以我打算把那条极其规律的曲线投射到未来，并从那里进行外推。其余的都是纯粹的、松散的猜测。谁知道除了这个“知识”和“难度”之外，还有多少其他可能的所谓“底层”曲线会给出完全不同的答案？

对此，有人可能会回答：

B：说真的？让我们考虑一个极端情况。神经元每秒大约发放 2 – 200 次，轴突和树突以每秒 1 – 100 米的速度传递神经信号，不到光速的百万分之一。即使每次神经操作散发的热量也比室温下的热力学最小值高出大约六个数量级。³² 因此，在不借助更小、更冷、可逆或量子计算机的情况下，将“内部”思维（不需要“等待外部世界”）加速至少六个数量级在物理上应该是可能的。假设我们面对的是运行速度比人类快一百万倍的思维，以这种速度，它们可以在三十一秒内完成一年的内部思考，这样从苏格拉底出生到图灵去世的总主观时间将在 20.9 小时内过去。你还认为对它们生产下一代计算硬件所需时间的最佳估计会是地球绕太阳公转 1.5 圈吗？

两种著名的认识论立场，即外部观点和卢卡斯批判，各自的支持者可以用它们来标识自己的论点。

32. 大脑作为一个整体器官，每秒耗散约 20 焦耳，即 20 瓦。在温度 T 下，单比特不可逆操作所需的最小能量为 $kT \ln(2)$ ，其中 $k = 1.38 \cdot 10^{23}$ 焦耳/开尔文为玻尔兹曼常数， $\ln(2)$ 为 2 的自然对数（约 0.7）。三百开尔文为 27°C or 80° 华氏度。因此，在理想情况下，室温下 20 瓦的热耗散对应每秒 $7 \cdot 10^{21}$ 次不可逆二进制操作。大脑可近似为具有 10^{14} 个突触。我发现关于平均每秒突触激活次数的数据难以获取，不同来源给出的数值从每秒 10 次激活到 0.003 次激活不等（并非所有树突都必须激活才能触发脉冲，且并非所有神经元在任何时刻都高度活跃）。若我们近似认为大脑具有 10^{14} 个突触，平均每秒激活一次，则在 10^6 倍加速后，每次突触激活可允许 $\sim 10^2$ 次不可逆操作。（注意，由于每个电化学激活的行进脉冲之后需要许多化学离子被泵回神经元膜以重置，神经脉冲行进的总距离是比总激活次数更自然的生物能量消耗测度。对于通过光纤行进的光子，不存在类似的规则。）

“外部视角”（卡尼曼和洛瓦洛，1993 年）是实验心理学中启发式与偏差研究项目中的一个术语。多项实验表明，如果你要求被试估计例如他们何时完成圣诞购物，正确的问题是“你去年何时完成圣诞购物？”而不是“你认为你需要多长时间完成圣诞购物？”后一种估计往往过于乐观，而前一种则更为现实。事实上，当被试被要求使用更多细节进行估计——想象他们将在何时、何地以及如何完成圣诞购物——他们的估计变得更加乐观，且更不准确。类似的结果表明，项目的实际规划者和实施者，尽管完全了解内部细节，但与具有类似项目相关经验但不了解内部细节的经验丰富的外部人士相比，往往更加乐观且估计更不准确。

这有时被称为内部视角与外部视角的二分法。“内部视角”是考虑到所有细节的估计，而“外部视角”是通过将你的项目与其他大致相似的项目进行比较而做出的非常粗略的估计，不考虑任何可能使这个项目不同的特殊原因。

经济学中的卢卡斯批判（Lucas 1976）写于 1976 年，当时“滞胀”——高通胀与高失业率同时出现——正在美国成为一个问题。罗伯特·卢卡斯的具体观点是，在美联储试图缓和通胀的时期，观察到菲利普斯曲线在失业与通胀之间进行权衡。当美联储放弃缓和通胀以将失业率降至更低水平时，雇主和雇员调整了他们的长期预期以考虑持续的通胀，菲利普斯曲线发生了移动。

卢卡斯更大且元层面的观点是，先前观察到的菲利普斯曲线不够根本，无法在结构上对美联储政策保持不变——通胀和失业的概念不够深刻，无法描述即使在美联储政策转变时仍保持稳定的基本事物。维基百科（2013）中有一个非常简洁的总结：

卢卡斯批判表明，如果我们想预测政策实验的效果，我们应该对假定支配个体行为的“深层参数”（与偏好、技术和资源约束相关）进行建模；即所谓的“微观基础”。如果这些模型能够解释观察到的经验规律，那么我们就可以预测个体在考虑政策变化的情况下会做什么，然后汇总个体决策以计算政策变化的宏观经济效应。

在智能爆炸辩论中，外部视角的主要明确支持者是罗宾·汉森，他还提出，将“奇点”——这个术语并非特指智能爆炸，但有时包含它——放入的适当参考类应是导致指数增长指数显著提高的重大经济转型的参考类。摘自汉森（2008a）的博客文章“奇点的外部视角”：

关于未来可能出现的奇点，几乎所有论述都采用内部视角，想象其可能发生的细节。然而，人们严重偏向内部视角，忘记了在推演细节时错误会迅速累积。那么，我们采用外部视角审视下一次奇点，能走多远？从长远的历史视角来看，我们看到稳定的总增长率，其间穿插着罕见的转变，新的更快增长模式几乎毫无预警地出现。我们已知大约有四次这样的“奇点”：动物大脑（~600 百万年前）、人类（~2 百万年前）、农业（~10 千年前）和工业（~0.2 千年前）。以往转变的统计数据显示，我们或许已经逾期未遇另一次转变，而一个世纪后将大幅逾期。下一次转变将直接改变增长率而非能力，至多历时数年，新的倍增时间将为一周至一个月。

关于此分析的更多内容，可参见汉森（1998b）。原始博客文章总结道：

即使在人们被告知外部视角效果更佳之后，过度的内部视角通常仍会持续；毕竟，内部视角更能展示内部知识与能力。人们通常以当前案例为例外来为此辩解。（还记得所有旧规则都不适用于新互联网经济吗？）因此，可以预期会听到借口，声称下一次奇点也是例外，外部视角的估计具有误导性。让我们保持开放心态，但保持警惕的开放心态。

汉森（2008c）的另一篇博文，后来被称为尤德科夫斯基-汉森人工智能爆发辩论，其中说道：

生成新的机制、解释、理论和抽象，这太容易了，简直过于容易。要判断这些东西是否有用，我们需要对其进行审查，而这在“近处”最容易，因为我们对近处了解很多。当我们想要处理或理解“远处”的事物时，我们对远处了解甚少，除了依赖在近处行之有效的机制、理论和概念之外，几乎没有其他选择。远处恰恰是尝试新事物的错误之地。

我们可以应用于世界的可能抽象多如牛毛。

对于每一种抽象，问题不在于能否以那种方式划分世界，而在于它是否“在自然的关节处切割”，提供其他抽象难以轻易获得的有用洞见。我们应当警惕仅为理解远处事物而发明新抽象；应当坚持它们首先在近处展现其价值。

外部视角的教训促使我们使用那些清晰可经验测量的抽象与曲线，并警惕发明那些无法直接观察的新抽象。卢卡斯批判的教训则推动我们寻找足够深刻的抽象，以描述在思维速度、规模和软件质量不断提升的情况下仍能保持稳定的增长曲线。

你可以看到这种张力如何体现在两种观点之间：“让我们用这条测量得非常精确的摩尔定律随时间变化的曲线来预测计算机速度——其他这些乱七八糟的东西到底是从哪里冒出来的？”与“但几乎所有描述人类思维和工程在制造更好计算机芯片中作用的合理因果模型，都应该预测一旦基于计算机的人工智能承担了所有研究，摩尔定律就会加速！”用我与库兹韦尔的一次简短交流来代表我与汉森之间的辩论是不公平的。不过，我确实感到基本分歧归结为类似的张力——汉森对我那些狂野的、未经经验验证的、复杂的抽象持续投以怀疑且不为所动的目光，而从我的角度看，这些抽象正是我试图为那些不可能保持稳定的表面曲线建立任何微观基础的尝试。

汉森（Hanson）对未来可视化的总体原型是一个由仿真人（*ems*）组成的经济社会，即扫描人类大脑的软件仿真。这样就有可能几乎立即将资本投入（计算机硬件）转化为熟练劳动力（复制的仿真人）。这就是汉森对仿真人经济如何能够遵循与过去经济加速“相同趋势”的解释，即世界经济每年或每月翻一番（而目前翻倍时间约为十五年 [汉森（Hanson）1998b]）。

我认为复制人类等效思维的想法几乎错过了智能爆炸中几乎所有潜在有趣的方面，例如更快的大脑、更大的大脑，尤其是设计得更好的大脑，所有这些似乎都可能比增加工人数量产生更大的影响。

为什么？也就是说，如果你可以将给定量的计算能力投入到更多的大脑、更快的大脑、更大的大脑或改进大脑算法中，为什么认为后三种情况之一的投资回报会显著更高？更详细的回答在第3节中给出，但简要总结如下：

软件开发领域有句俗语：“九个女人一个月也生不出一个孩子”，意思是说，你无法通过雇佣一百个人工作一年来获得十个人工作十年的产出，更一般地说，在其他条件不变的情况下，工作时间的扩展性优于人数的扩展性。计算机科学中也有一个普遍真理：快速处理器可以模拟并行处理器，但反过来往往不行。因此，我们预期速度的回报高于数量的回报。关于人类智能如何随神经元增加和固定软件而扩展，我们几乎没有可靠的数据。人类大脑体积确实存在差异，这种差异与 g 的相关性约为 0.3 (McDaniel 2005)，但存在大量可能的混杂因素，如儿童期营养。人类的大脑体积大约是黑猩猩的四倍，但我们之间的差异可能主要在于大脑层面的认知算法。³³ 计算机科学的一个普遍真理是，如果你将一个处理单元拆分成十个部分，且各部分之间的通信带宽有限，那么在任何问题上它们都不可能比原始单元做得更好，而且在许多问题上会差得多。类似地，我们可能预期，对于大多数智力问题，让十倍数量的研究人员运行缩减到五分之一大脑体积的人类软件，可能不会带来净收益；而对于许多智力问题，拥有四倍大脑体积的研究人员可能比增加四倍数量的研究人员带来显著更大的收益。³⁴ 试图说明智力和问题解决能力如何随改进的认知算法而扩展，更难与观察结果联系起来。在任何表面能力可见提升的计算机领域，通常确实如此：使用现代算法和十年前的计算机，比使用现代计算机和十年前的算法更好。这在计算机国际象棋中绝对成立，尽管国际象棋程序爱好者为创建更好程序所投入的净努力，与英特尔每年为制造更好计算机芯片所投入的巨大努力相比微不足道。但这一观察只传达了很小一部分思想：你无法用任何数量的黑猩猩来匹配人类的智力产出。

非正式地说，在我看来

$$\text{quantity} < (\text{size, speed}) < \text{quality}$$

当涉及到心智时。汉森的情景中，所有投资都用于增加仿真脑的纯粹数量——这是对智能爆炸总影响的一个良好估计——

33. 如果仅仅通过将南方古猿放大四倍就能创造出人类，那么从南方古猿到我们的进化路径将会短得多。

34. 这种说法带有相当的含糊其辞。但你真的认为那是错误的吗？

似乎暗示着来自更大脑容量、更快思维和改进大脑设计的投资回报都可以被忽略，这意味着这些投资的回报相对较低。³⁵ 而在我看来，任何与先前观察相容的合理微观基础——即不会反推出一个人类在智力上应可被十只黑猩猩替代——都应该意味着劳动力数量不会是主导因素。未被证伪的增长曲线应当表明，给定一定量的计算能力，你可以将其投资于更多的心智、更快的心智、更大的心智或设计更优的心智，你会投资于后三者之一。

我们不投资于更大的人类大脑，因为这在当前技术下是不可能的——我们不能雇佣一个颅腔体积大三倍的研究人员，只能投入更多人力来解决问题。如果这条投资途径突然变得可行……从实用角度讲，它很可能会产生相当大的差异。我很乐意承认我的模型只做出了模糊的定性预测——我认为我没有足够的数据来做出像汉森对未来经济倍增时间估计那样的定量预测。但从定性角度看，我认为很明显，所有这些难以估计的来自更快大脑、更大脑容量和改进底层认知算法的贡献，都指向大致相同的方向，即“大幅上升”。这意味着汉森的估计，由于坚持对观测良好的量进行外推曲线，将可预见地偏向大幅低估。

而从汉森的角度看，这一切都是异想天开的未经证实的猜测，他坚持分析仿真脑，是因为我们对人类心智如何运作有大量数据，而无法为我所假设的这些新抽象提供坚实的基础。

除了卢卡斯批判之外，我对“外部视角”的另一个主要问题是，似乎每个使用它的人都会得出不同的参照类和不同的答案。对雷·库兹韦尔来说，“奇点”的明显参照类是近历史中运作的摩尔定律，而不是汉森与农业的比较。在这篇文章中，一位在线讨论者将这些话题中的“奇点”归入参照类“新世界来临的信念”，该参照类“成功率为 0%”……并明确称这是使用“参照类预测”的正确“外部视角”，同时斥责任何试图给出不同答案的人使用了“内部视角”。关于我对这一切更详细的回应，请参见“外部视角！”。

35. 罗宾·汉森 (Robin Hanson) 在回复本文草稿时表示：“我构建了一个排除这些因素的形式化模型，这并不意味着我认为这些效应小到可以忽略不计。构建忽略重要因素的模型不仅是合理的，而且通常不可能不这样做。”这无疑是正确的；然而，我认为在这种情况下，结果是一种可预见的方向性偏差。

作为“对话终止者”（Yudkowsky 2010）。我回复的要点是，外部视角已被实验证明在软件项目上优于内部视角，这些项目与以往的软件项目相似，并且对于今年的圣诞购物也是如此，这与去年的圣诞购物高度相似。外部视角预计在一个新事物上效果较差，该新事物与旧事物的相似程度低于所有旧事物彼此之间的相似程度——尤其是当你试图从一种因果系统外推到一种截然不同的因果系统时。而试图跨越过大差距进行外推的一个主要标志是，每个人都提出了一个不同的“显而易见”的参考类别。

当然，也常常发生这样的情况：争论者认为不同的微观基础——不同的现实因果模型——是“显然”合适的。但那样的话，我对于如何聚焦于假设的原因、评估其简单性和规律性，并找出如何用现有证据来检验它们，有一些想法。我不知道在两个人采用不同的参照类并得出不同的外部观点、而这两种观点我们都应该接受之后，该做什么。我的经验是，人们最终会做出相当于说“我带着我的参照类回家了”的事情。我对许多“参照类预测”案例的最后一个问题是——除了每个人都得出不同的参照类之外——他们的最终答案往往比我认为我们的知识状态所允许的更为具体。我认为你不应该能够告诉我，下一个主要增长模式将有一个月到一年之间的倍增时间。所谓的外部观察者一旦把全部赌注押在单一偏好的参照类上，就声称知道得太多了。但那样的话，我刚才所说的就是一个强制谦逊的论点——“我不知道，所以你也可能不知道！”——并且因此自动受到怀疑。

必须完全承认并建议，复杂模型很难拟合有限的数据，而且当假设难以直接观察或精确确定的曲线时，出错的空间很大。但这并不意味着“参照类预测”是一个好的解决方案，甚至不是仅仅最好的解决方案。

3. 硬起飞模型的一些辩护

哪怕只是为了具体性，总结我自己关于智能爆炸的立场似乎是合适的，而不仅仅是抽象地讨论如何一般地形式化这类立场。³⁶ 用非常具体的术语来说——抛开所有抽象原则、微观基础——

36. 彼得·奇斯曼曾经给我讲过一个轶事，关于一位在机器人学会议上发言的人，他来自学术界更偏理论的一方，向一群注重实操的工程师听众演讲。这次演讲

以及“你认为你知道什么，以及你认为你是如何知道的？”这一根本问题——一个由埃利泽·尤德科夫斯基设想的“典型”智能爆炸事件可能会这样展开：某个由对冲基金、学术界、谷歌、³⁷ 或政府运营的人工智能项目，发展到足够先进的水平（见第 3.10 节），开始了一连串持续且不平息的自我改进。这种自我改进的级联可能始于研究人员的根本性突破，使人工智能能够理解并重新设计更多自身的认知算法。或者，一个由适应度评估器管理的自我修改系统集合，在经历了一些较小的自我改进级联之后，最终可能开始一个不平息的级联。或者，某个拥有资金的人可能会向并未完全无法扩展的人工智能算法投入前所未有的计算能力。

一旦这个人工智能开始走上持续的智能爆炸之路，将会有一段时期，人工智能在积极自我改进，或许还在获取额外资源，但尚未达到值得被称为“超级智能”的认知水平。这段时间可能是数月或数年，³⁸ 或数天或数秒。³⁹ 我极不确定在这段时间内人工智能可能表现出何种能力迹象，或其构建者或其他各方可能对此作何反应；但就智能爆炸微观经济学而言，我们应暂时搁置这些问题，并假设人工智能的增长并未受到任何特定机构的蓄意阻碍。

在某个时刻，人工智能将达到能够解决蛋白质结构预测问题并构建纳米技术的程度——或者找出如何控制原子-

完全围绕着由大写希腊字母组成的方程。在问答环节，有人礼貌地问演讲者能否给出一个具体例子。演讲者思考片刻，写下了一组新方程，只是这次所有希腊字母都是小写。我尽量不做那样的人。

37. 拉里·佩奇曾公开表示，他特别感兴趣的是“真正的人工智能”（通用人工智能），该领域的一些研究人员由谷歌资助。据我所知，这仍处于基础算法的蓝天研究层面，并非试图在未来五年内催生谷歌，但似乎仍值得特别提及谷歌。

38. 任何特定人工智能的特征性成长路径可能需要数百年才能达到超级智能——这甚至可能适用于某些现代人工智能，它们并未展现出令人瞩目的进展——但这类人工智能最终无关紧要；某个起步较晚的其他项目将率先达到超级智能。除非所有人工智能发展路径都需要数百年，否则周围文明将继续翻阅人工智能开发项目的牌堆，直到翻出一个发展更快的人工智能。

39. 考虑到当前中央处理器（CPU）以每秒数十亿次操作的串行速度运行，而人类神经元在发放脉冲后至少需要一毫秒才能恢复，秒对于机器智能而言可能是相当长的时间跨度——一秒具有极大的串行深度，允许许多因果事件按顺序发生。参见第 3.3 节。

力显微镜来制造新的工具尖端，这些尖端可用于构建小型纳米结构，而这些纳米结构又能构建更多的纳米结构——或者也许遵循某种更智能、更快速的路线来实现快速基础设施。一个超越这一点的 AI 可以被认为已经达到了巨大物质能力的门槛。由此很可能随之而来的是认知超级智能（如果尚未出现的话）；可以迅速获取庞大的计算资源，以进一步扩展认知算法。超越分子纳米技术之后的进一步增长轨迹，对当今政策而言似乎大多无关紧要。一个拥有分子纳米技术的 AI 将拥有足够的技术优势、足够的独立性以及相对于人类足够的认知速度，以至于之后发生的事情将主要取决于 AI 的偏好。我们可以尝试通过明智地选择 AI 设计来影响这些偏好。但这会引出一个完全不同的讨论（如 1.3 节所述），而后者似乎并不太依赖于这样一个问题：在超级智能已经比世界其他经济更强大的场景中，它究竟会变得多强大。

这种“硬起飞”的具体情景对认知再投资的回报意味着哪些一般性信念？

该方法假设：

- 人工智能通过改进计算机技术可以获得重大收益，而非微小收益
比其人类发明者更科学。
- 更普遍地，人们认为人工智能可以通过更好地利用其已有的计算能力，或仅使用其处理能力来实现巨大收益
可以在短时间内租用或以其他方式获得——特别是，无需建立新的芯片工厂或采取任何其他会涉及长期、不可避免延迟的行动。⁴⁰
- 人工智能可以持续将这些收益再投资，直至在认知问题解决能力上对人类形成巨大优势。

40. 给定投资选择，理性机构将选择利率最高的投资——即单位时间内最大的倍增因子。在收益可反复再投资的情境下，一年回报百倍的投资远不如一小时回报 1.001 倍的投资。在某个时点，人工智能内部代码的改进将触及上限，但存在巨大激励去通过改进代码而非建造芯片工厂来逼近例如蛋白质结构预测阈值。购买更多中央处理器时间是中间情形，但需注意增加硬件也会提高算法改进的回报（见 3.1 节）。（这也是我为何不遗余力地将自身信念与对摩尔定律在近期或远期持续的任何依赖相分离的另一原因。等待数年以获取下一代芯片不应成为进行中智能爆炸的首选方式。）

- 这种认知超智能能够回响到巨大的现实世界能力

通过解决蛋白质折叠问题，或从当时的人类技术基础出发，采取其他更为巧妙的方法（见第 3.11 节），实现这些能力。

更抽象地说，这表明人工智能的自我改进可以在 $k \gg 1$ 和快速再投资时间尺度下运行：“提示超临界”。但为何要相信这一点？

（这类问题在对话中难以回答，因为不同的人可能认为场景中最可疑的部分各不相同。此外，尽管我认为核心有一个简单的想法，但当人们提出探究性问题时，由此产生的对话往往复杂得多。⁴¹ 如果我的回答没有立即解决您优先考虑的首要问题，请见谅；不同的人有不同的优先顺序。）我首先要说的是，人科动物智力的进化史没有显示出任何收益递减的迹象——没有迹象表明进化花费了十倍的时间才产生人科动物大脑的每一次边际改进。

（是的，这很难量化，但即便如此，如果存在显著递减的回报，人类学记录也不应该呈现出它现在的样子。参见第 3.6 节。）我们对进化过程有相当好的数学理解，并且能够很好地近似其中涉及的一些优化压力；我们可以权威地说，在许多重要意义上，进化是极其低效的（尤德科夫斯基，2007 年）。

然而，进化却能够通过点突变、随机重组以及对基因编码的大脑结构进行无远见的爬山式搜索，获得显著的认知回报。此外，进化作为一种优化过程的特征在哺乳动物进化过程中基本保持不变——在相关时间跨度内，没有出现真正根本性的创新，比如性和有性重组的进化发明。

因此，如果自然选择的稳定压力通过优化原始人类的智能实现了显著的适应性回报，那么研究人员在优化自身方面变得更加聪明，就应该会迅速爆发。基于摩尔定律的“完全天真”论证自我折叠后问道：“如果计算能力每十八个月翻一番，那么当计算机在做研究时会发生什么？”我认为这种情况在实践中并不重要，主要是因为

41. “基本思想很简单，但反驳反对意见可能需要复杂得多的对话”对于奥卡姆剃刀来说并不是一个令人担忧的状态；即使对于正确的理论，这也是常见的。例如，自然选择的核心思想比反驳那些听起来简单的反对意见所需的对话要简单得多。增加的对话复杂性通常是由反对意见中隐含的预设所带入的。

我预期认知算法的回报将主导速度的回报。（地球上的优势物种并不是神经元进化最快的物种。）尽管如此，如果摩尔定律的难度曲线使得人类能够以稳定的速度攀登，那么加速的研究人员——其速度本身与摩尔定律挂钩——从我们的角度来看，应该可以预期会迅速爆发。

纯粹速度的回报可能相对较小——加速的人类不会构成超级智能。（关于纯粹速度回报的更多内容，见第 3.3 节。）然而，更快的思维比更聪明的思维更容易想象，这使得“折叠的摩尔定律”成为折叠这一总体思想的一个更简单的例证。

自然选择似乎沿着一条线性或适度超线性的增长曲线攀升，该曲线以累积优化压力为输入，以智能为输出。为了“折叠”这条曲线，我们考虑一种场景：问题的固有难度与之前相同，但思维不再由自然选择的稳定压力从外部改进，而是由思维当前的优化能力决定“累积优化压力输入”曲线被穿越的速度。鉴于之前描述的非折叠曲线的特征，任何特定的自我改进主体，在没有外部帮助的情况下，要么在曲线的较低部分遇到瓶颈（如果它不够聪明，无法做出与长期累积进化相比显著的改进），要么发生智能爆发（如果其初始智能足够高以开始攀升），然后以更快的速度攀升。

我们应该看到一种“瓶颈或突破”的二分法：任何特定的自我改进思维，要么在没有外部帮助的情况下“遇到瓶颈”，就像当前所有的人工智能一样，要么“突破”进入快速的智能爆炸。⁴² 在这些替代方案之间存在一个边界，其中包含看似在自我改进方面取得稳定、缓慢、显著进展的思维；但这个边界不必很宽，任何这样的思维都会稳步向曲线的智能爆发区域移动。见第 3.10 节。我对“人工智能走向智能爆发”场景的部分信心也来自认知科学（例如，对启发式和偏差的研究），这表明人类在实践中远未达到最优设计。认知心理学的广泛状况表明，“大多数人无法在头脑中计算两个三位数的乘法”并不是一个不公平的指责——我们在许多维度上确实设计得如此糟糕。⁴³

42. 至少这一预测的第一部分似乎正在成为现实。

43. 诚然，这是长期涉足该领域后所获得的印象。没有任何单一研究能够传达，或理应传达，人类心智设计在多个维度上极其糟糕这一有力结论。存在代表性的单个例子，例如一个拥有 10^{14} 个处理元件的心智在首次尝试时未能解决抽象的沃森选择任务。但除非你了解其背后的更长故事，以及有多少其他结果与之相似，否则它不会产生同样的影响。

在更高的抽象层次上，这意味着相对于人类智能水平，存在巨大的可见改进空间。人类能够使用为在草原上辨别老虎而进化出的视觉识别系统来下棋，这非同寻常；我们能够使用为制造弓箭而进化出的大脑来为计算机编程，这令人惊叹；而使用主要适应于建模和智胜其他人类的大脑来发明新的计算机科学和新的认知算法，则简直难以置信。但按照能够根据需要重新设计自身并运行具有十亿步串行深度的无错误算法的计算机心智的标准，我们的思维可能并不十分高效。（参见第 3.5 节。）因此，我们有具体理由怀疑认知算法可以改进到超越人类水平——人类大脑算法并不比人类神经元更接近最优软件，正如人类神经元并不比硬件物理极限更接近。即使没有来自实验心理学的令人尴尬的消息，我们仍然可以观察到，构建智能的固有难度曲线没有已知理由具有在刚达到人类等效水平后急剧上升这一特定不规则性。

但我们也有具体理由怀疑，心智设计可以大幅改进到超越人类水平。

这是对我所认为的认知再投资回报可能很大的核心观点的粗略总结。你可以将这个总结称为关于改进认知算法回报的“朴素”观点，类比于如何融入摩尔定律的朴素理论。我们可以深入探讨并提出更复杂的问题，但值得记住的是，当正确进行时，更复杂的分析往往表明朴素答案是正确的。一个从未将广义相对论作为正式引力理论来研究的人，可能会朴素地预期从高崖跳下会坠落并摔得粉碎；在这种情况下，复杂的预测与朴素的预测一致。因此，记住我们没有义务得出任何令人印象深刻的非显而易见的“结论”，让我们考虑一些论证中非显而易见的微妙之处。

在接下来的小节中，我们将考虑：

1. 化石记录实际上告诉我们关于大脑尺寸回报的什么，鉴于智人与南方古猿之间的大部分差异可能是改进的算法。
2. 如何将人类与黑猩猩表现差距的功劳在“人类个体比黑猩猩更聪明”和“人科转变涉及从能够积累知识中获得的一次性质变收益”之间进行划分。更一般地说，如何分析所谓的一次性收益，这些收益据称应从预测的未来增长中剔除。

3. 速度（串行因果深度）的回报与并行性的回报如何对比；更快的思维似乎与更多的思维如何对比。感知和操纵技术是否可能对更快的思考者构成瓶颈，如果是，瓶颈有多大。
4. 人类群体在解决问题能力上似乎如何扩展；一些理由相信我们比机器智能扩展效率更低。加里·卡斯帕罗夫与国际象棋世界队的比赛，卡斯帕罗夫获胜。
5. 在估计人类在认知问题上的净计算效率时可能积累的一些低效率。
6. 人类学记录实际上告诉我们关于累积选择压力下认知回报的什么，鉴于选择压力在人科历史过程中可能不断增加。如果认知或进化存在收益递减，观察到的历史将如何不同。
7. 如何关联进化难度、人类工程难度和人工智能工程难度的曲线，考虑到它们几乎肯定不同。
8. 在尝试通过观察地球上智能的进化来估计类人级智能的内在“难度”时，对人为选择偏差进行修正。（问题在于，在智能未进化的行星上，没有人能观察到它的缺失。）
9. 关于预期“局部”（单一项目）还是“全局”（整个经济）的问题

omy) FOOM，以及认知再投资的量化回报如何与之相互作用。

10. 关于启动智能爆炸（FOOM）所需最低条件的重大未决不确定性；为何 I. J. 古德最初提出的从“超智能”出发的假设显得过强（充分，但远高于必要水平）。
11. 在智能爆炸情景中，未知的未知因素的重要性增强，因为超越人类的智能将选择性地寻找并利用我们当前知识中的缺陷或空白所隐含的有用可能性。

最后需要指出的是，深入探讨支持快速爆发论（FOOM）的立场不应使读者对其他立场产生偏见。仅对一种立场进行长篇辩护，可能会使其看起来像一座可能倒塌的巨大论证大厦，而其他观点，例如“一个由相互作用的智能体组成的集体将 $k \approx 1^+$ 并以可控的、类似人类的指数速度增长，就像世界经济一样”，听起来可能“更简单”，因为它们的论点和反论点尚未被探讨。

但当然（就作者所信而言），其他此类结果在深入辩护时甚至会更加困难。⁴⁴ 每一个支持智能爆炸的论点，其否定形式都是支持智能非爆炸的论点。就本文中每个论点的否定形式可能听起来并非完全合理而言，其他可能的结果在如此深入的论点与反论点交锋中也不会显得更合理。

3.1. 大脑尺寸的回报

许多情况下，我们希望从认知投资的历史回报中进行推理，但不幸的是，数据范围狭窄，使这一过程变得复杂。所有最令人印象深刻的认知回报都来自单一物种，即智人（*Homo sapiens*）。

人类的大脑大约是黑猩猩的四倍……但这几乎不能说明什么，因为人类与黑猩猩之间的大多数差异几乎肯定是算法性的。如果仅仅将南方古猿（*Australopithecus*）的大脑放大四倍就能产生人类，那么从南方古猿到智人的进化之路可能会短得多；像器官大小这样的简单因素在强大的进化压力下可以迅速改变。

基于历史观察，我们可以有把握地说，从南方古猿到智人的进化实际上并不需要大脑体积增加一百倍再加上算法的改进——我们可以反驳这样一种断言：即使考虑到五百万年来认知算法的进化，也需要硬件增加一百倍才能容纳新算法。这听起来可能不算什么，但它确实反驳了那些通过要求硬件呈指数增长来获得线性认知收益，从而阻止智能爆炸的模型。⁴⁵

观察到的历史还有一个非显而易见的启示：在通往智人的过程中，认知算法的改进一定是增加了而不是减少了

44. 罗宾·汉森（Robin Hanson）在尤德科夫斯基-汉森（Yudkowsky-Hanson）人工智能爆发辩论以及多篇论文中，以中等篇幅为“全球经济指数加速”论点进行了辩护，读者可以自行探索这些内容。据我所知，还没有人认真且长篇地辩护过“智能失败”的观点，但这当然可能反映了一种选择效应。如果你认为不会发生任何有趣的事情，你就不认为有什么值得写论文的。

45. 我相当确信自己曾多次听到过这一论点，但遗憾的是我未能保存相关参考文献；如果您有，请提供一篇。显然，我记忆中那些发言者正是利用这一论点来信心十足地否定超人类机器智能的可能性，而他们未曾想到，同样的论点或许也适用于原始人类的人类学记录。如果这听起来荒谬到让人怀疑是否真有人相信，那么请考虑，“智能爆炸不可能发生，因为图灵机无法自我提升为超计算机”这一说法更为糟糕，并参见布利斯约德（Bringsjord, 2012）中一位杰出科学家的恰当引用。我们可以相当有把握地确信，人类智能并未利用量子计算（Tegmark 2000）。大脑的计算元件过大且温度过高。

更大脑容量和进一步提高的智力所带来的边际适应度收益，因为新的均衡脑容量是原来的四倍。为了详细阐述这一推理：一个理性主体会进行投资，使得其所有可替代投资的边际收益大致相等。如果投资 X 的边际收益高于投资 Y，那么将资源从 Y 转移到 X 是合理的。但随后收益递减会降低对 X 进一步投资的收益，并提高对 Y 进一步投资的收益；因此，在将一些资源从 Y 转移到 X 之后，会找到一个新的均衡，其中各项投资的边际收益再次大致相等。

因此，我们可以合理地预期，对于处于粗略进化平衡状态的任何物种，每增加一个单位的 ATP（大致为代谢能量），无论投资于生物体的免疫系统还是大脑，都将产生大致相同的广义适合度增量。如果系统性地存在这样的情况：增加一个边际单位的 ATP 在免疫系统中产生的回报远高于大脑，那么该物种将面临强大的选择压力，倾向于将 ATP 从生物体的大脑转移到免疫系统。进化以广义遗传适合度这一通用货币来衡量所有回报，而 ATP 是一种可替代资源，可以轻松地在身体任何部位消耗。人类大脑消耗了人体所用 ATP 的大约 20%，这是一项巨大的代谢投资。假设一个正突变使得仅用身体 19% 的 ATP 就能完成相同的认知工作——借助这种新的、更高效的神经算法，相同的认知工作可以由更小的大脑完成。如果我们处于认知适合度回报急剧递减⁴⁶或增加更多神经元带来的认知回报急剧递减⁴⁷的状态，那么我们应该预期

46. 假设你的房间已经亮到你喜欢的程度，然后有人给你更便宜、更节能的灯泡。你会保持房间亮度不变，并减少照明总支出。类似地，如果你已经足够聪明，能智胜普通鹿，而增加更多脑力并不能让你更好地智胜鹿，因为你已经比鹿聪明（进一步认知的适应度收益递减），那么进化出更高效的大脑算法将导致进化出更小的大脑来完成同样的工作。

47. 假设每餐需要一个热狗和一个面包；生产每个面包需要 1 单位劳动；而每个连续的热狗需要比前一个多 1 单位劳动来生产，从第一个热狗的 1 单位开始。因此生产 3 个热狗需要 6 单位，生产 9 个热狗需要 45 单位。假设我们目前基于 $45 + 9 = 54$ 总劳动单位享用 9 餐。那么即使有一个神奇的面包工厂消除了生产面包的所有劳动，也无法实现 10 餐的生产，因为热狗的成本递增。类似地，如果我们能通过提高大脑某一部分的效率获得巨大收益，但限制因素是另一个扩展性很差的大脑部分，那么即使我们改进了大脑算法，足以显著缩小大脑的总成本，也不一定意味着我们处于可以通过重新投入节省的神经元来显著增加总认知能力的阶段。

大脑因这一创新而缩小，以更低的价格完成同样的总工作量。但在观察到的历史中，原始人类的大脑反而变大了，付出更高的代谢代价来完成更多的认知工作。由此可见，在原始人类进化过程中，改进的认知既带来了显著的边际适应度回报，更大的大脑也带来了显著的边际认知回报。

在经济学中，这被称为杰文斯悖论——一个反直觉的结果，即提高照明的电效率或使电力更便宜会增加花在照明上的总金额。购买照明的回报上升，所以人们购买更多，总支出增加。类似地，原始人类大脑算法在进化过程中的一些改进，必然增加了在大脑上花费更多 ATP 的边际适应度回报。随着认知算法的改进，大脑的均衡规模及其总资源成本向上移动。

由于人类大脑的体积大约是黑猩猩大脑的四倍，我们可以推断，我们提高效率（在可互换的生物资源上的认知产出）增加了大脑的边际回报，使得新的均衡大脑体积大约是其四倍。不幸的是，这几乎没有告诉我们关于更大体积大脑和恒定算法的投资回报曲线的定量信息——只有定性的真相，即改进的算法确实增加了大脑体积的边际认知回报，并且增加认知劳动量并没有在适应性上产生急剧递减的回报。

我不清楚我们应该从大脑体积仅增加四倍这一事实中得出多少结论——我们能否以此方式对硬件的回报设定上限。据我理解，人类大小的头部导致分娩困难，因为婴儿的头部难以通过产道。这充分解释了为什么我们不会看到具有三倍大小头部的超级智能突变体，即使三倍大小的头部可能产生超级智能。另一方面，尚不清楚人类头部大小是否已经逼近这种限制——有些人的头部尺寸高于平均水平，而他们的母亲并未因此死亡。此外，尼安德特人的大脑可能比现代人类更大（Ponce de León et al. 2008）。⁴⁸ 因此，我们或许可以得出结论：在非常近期的进化历史中，并没有对更大体积大脑本身产生强烈的选择压力。⁴⁹

48. 尼安德特人并非我们的直系祖先（尽管可能发生过一些杂交），但他们与我们亲缘关系足够近，因此他们更大的颅容量是相关的证据。

49. 很可能认知的边际适应性回报已经急剧趋于平缓，以至于在非常近期的历史中，认知效率的提高使大脑的总资源成本向下而非向上移动。如果这是真的，这并不等同于智人（*Homo sapiens sapiens*）变得更笨或甚至保持相同的智力。但这确实意味着，要么认知的边际适应性回报，要么

从脑容量增大推导适应性回报有两个步骤：脑容量的认知回报和认知的适应性回报。例如，约翰·冯·诺依曼（John von Neumann）⁵⁰ 只有一个孩子，因此认知回报向适应性回报的传递可能并非完全高效。我们可以通过观察到智人并未逼近头部尺寸的极限，以及尼安德特人可能拥有更大的脑容量，来为更大脑容量的适应性回报设定上限。这并未说明该回报上限中有多少涉及认知的适应性回报，又有多少涉及脑容量的认知回报。

智人内部的脑容量差异能否让我们对认知回报得出很多结论？脑容量的方差与测得智商的方差相关性约为 0.3，但存在许多可能的混杂因素，如儿童期营养或儿童期对寄生虫的抵抗力。我们最多只能说，约翰·冯·诺依曼似乎并不需要比普通人数指数级更大的大脑，甚至不需要两倍于普通人的大脑，却展现出远超其时代普通人两倍的科学产出。但这大概并非告诉我们脑容量小幅增加会带来巨大回报；更可能的是，其他因素可以在无需脑容量大幅增加的情况下带来科学产出的巨大提升。我们还可以说，脑容量增大 25% 不可能自动产生超级智能，因为这处于现有方差范围之内。

我最终得出的主要教训是，智能的提升并不需要计算能力的指数级增长，并且在人类进化过程中，脑容量增大的边际适应性回报是显著的。这对应于人工智能增长模型，其中人工智能的大幅认知提升可以通过获取已建成的计算资源来实现，而无需构建新的基础芯片技术。

正如改进的算法可以增加添加更多硬件的边际回报（因为它运行的是更好的算法），额外的硬件也可以增加改进认知算法的边际回报（因为它们运行在更多硬件上）。⁵¹ 在日常生活中，我们通常预期这类反馈循环会逐渐减弱，但在人类进化中实际上存在强劲的持续增长，因此

大脑规模扩张的边际认知回报相较于早期进化历史已显著趋于平缓。

50. 我常以约翰·冯·诺依曼（John von Neumann）为例来说明人类智力分布的最远端，因为他被广泛认为是史上最聪明的人，同时代的其他伟大天才都对他心存畏惧。汉斯·贝特（Hans Bethe）曾这样评价他：“我有时会想，像冯·诺依曼这样的大脑是否表明存在一种优于人类的物种”（布莱尔，1957 年）。

51. 对于一家一千万美元的公司而言，花费一百万美元购买一项能使所有流程提升 1% 的创新是一笔糟糕的投资；而对于一家十亿美元的公司来说，这却是一笔极佳的投资。

这类反馈回路可能发挥了重要作用。类似地，人工智能设计或许仅凭大幅增加计算能力就能实现智能爆发（FOOM），就像核反应堆仅靠添加更多相同的铀砖就能达到临界状态一样；新增的硬件可能使所有认知投资的回报倍增，从而将系统从 $k < 1$ 推向 $k > 1$ 。遗憾的是，除了指出这种定性可能性之外，我几乎找不到任何方法来定量把握这一概率。⁵² 总体而言，增加的“规模”是一种我自认为了解相对较少的认知投资类型。在人工智能领域，硬件改进带来的收益通常低于软件改进——但改进的硬件仍然至关重要，因为如果计算机过于孱弱，初始算法的表现可能极差，以至于逐步改进它们并不划算。⁵³ 即便如此，人工智能的发展历程主要仍由软件而非硬件驱动；而在五百万年间，原始人类的大脑体积仅增加了四倍，这表明原始人类的进化似乎也是如此。鉴于目前的知识状况，试图通过绘制摩尔定律曲线并仅考虑计算能力的增加来预测人工智能的到来，在我看来毫无意义。硬件的认知回报始终随着算法的改进而变化；并不存在一个可计算的恒定阈值可供跨越。

3.2. 一次性收益

从直觉层面来看，人类物种积累的认知回报显然远超黑猩猩物种；我们登上了月球，而它们没有。试图定量把握“人类的认知回报”，以及它们究竟超出黑猩猩认知回报多少，因以下事实而变得极为复杂：

- 人类的数量远多于黑猩猩。

52. 这一情景不应与大型超级计算机自发产生意识相混淆，帕特·卡迪根（Pat Cadigan）曾准确指出，后者类似于旧理论中脏衬衫和稻草会自发产生老鼠的说法。相反，这里的担忧在于，你已经拥有一种在性质上能够进行显著自我改进的人工智能设计，而某个拥有大量计算资源的不谨慎团队，因对早期出色成果感到兴奋，试图以十万倍的计算能力运行该人工智能，使其进入临界状态。

53. 如果原始人类的大脑被限制在蜘蛛大小，那么发展出人类水平的智能将困难得多，因为改进算法所带来的增量适应度回报会更低（因为每个算法运行的硬件更少）。一般而言，一个传递一半优势的正向突变需要两倍的时间才能达到固定，并且达到固定的机会也只有一半。因此，如果将适应路径上每一步的适应度回报降低三个数量级，进化结果并非“这种适应需要更长时间才能进化出来”，而是“这种适应根本不会进化出来”。

- 人类之间的交流能力远优于黑猩猩。

这意味着，改进的大脑算法（人类与黑猩猩相比）所带来的认知回报可能比登月所暗示的要小。来自更优累积优化的认知回报，由一个数量更多、能够使用语言跨大脑传递知识的物种实现，不应与单个人类大脑的任何固有能力相混淆。我们知道人类拥有核武器而黑猩猩没有。但若我们将此归因于更大的人类种群，就不能将其归因于人类拥有书写；若将其归因于人类拥有书写，就不能将其归因于人类拥有更大的大脑和改进的认知算法。⁵⁴ “这很愚蠢，”你回答。“显然，你需要书写和人类通用智能，才能发明科学并让技术积累到核武器的水平。即使黑猩猩有某种方式传递它们所拥有的知识并进行累积性思考——比如说，如果你使用脑机接口直接将技能从一只黑猩猩转移到另一只——它们可能仍然永远无法理解线性代数，即使在一百万年内。这不是沟通与个体智能的问题，而是存在联合因果依赖。”即便如此（反驳的反驳继续），发现和使用电力显然不是单个人类大脑的纯粹属性。言语和书写，作为由原始人类智能促成的发明，诱导了认知智能作为优化过程的特性变化：思考时间在种群和世纪之间更强烈地累积。在我们怀疑是否存在任何此类进一步创新的程度上，我们可能预期人类智能的巨大回报主要是一次性事件，而不是随更大大脑或进一步改进的认知算法按比例扩展的可重复事件。如果能够累积知识是一个已经跨越的绝对阈值，我们就不能期望通过一次又一次地跨越它来看到可重复的认知回报。

但随后（反反反方观点认为）我们可能并未完全跨越沟通门槛。假设人类不仅能相互交谈，还能完美转移完整的认知技能，不仅能大体上复制人类，还能复制成千上万个心灵相通的爱因斯坦，就像人工智能可以自我复制并转移思想那样。即使沟通是一次性门槛，我们可能更像是跨越了门槛的 1%，而非 99%。

54. 假设我知道你的投资组合去年回报率为 20%。你投资组合中股票的回报率越高，我就越不期望其中债券的回报率也高，反之亦然。

然而（反 4 方观点回应道）如果人类之间累积知识的能力在质上仍然存在，那么更高效地累积知识所带来的边际回报可能并不与跨越初始门槛成比例。假设存在一亿人口的恒定规模，文明的回报由累积最多的认知劳动决定。实体间累积率从 0% 提升到 1%，对总回报的倍增效应可能远大于从 1% 累积率进一步提升到 99% 累积率所带来的额外倍增因子。在这种情况下，一千个 1% 累积率的实体可以胜过一亿个 0% 累积率的实体，但一千个完美累积率的实体却无法胜过一亿个 1% 累积率的实体，具体取决于你的假设细节。一个反 5 方观点认为，这并非对有中子吸收杂质的铀砖堆的良好模型；任何程度的噪声或低效都会干扰上述结论的清晰性。进一步的反 5 方观点则追问印刷术的发明及随后的工业革命——如果一次性门槛模型成立，为何印刷术带来的文明回报似乎远高于书写或言语？

另一个引发类似论证的一次性阈值围绕人类通用性展开——即我们能够掌握黑猩猩完全无法表征的某些概念，例如数字三十七。格雷格·伊根（Greg Egan, 2002）的科幻小说《希尔德之梯》假设了一个“通用智能定理”，其大意是：一旦达到人类水平，便已完备——你可以思考任何可思考的事物。因此，进一步的通用性不会带来更多增益；这正是伊根所描绘的未来中，尽管有众多人类水平的心智在高速计算机上运行，却不存在超级智能的原因。

“通用智能定理”的明显启发来自丘奇-图灵论题：任何能够模拟通用图灵机的计算机，都能模拟一个非常庞大的系统类别中的任意成员，该类别似乎包含物理定律，因而包含现实宇宙中的一切。一旦证明能够在康威生命游戏中编码单个通用图灵机，那么生命游戏便被称为“图灵完备”，因为我们可以已在构建的通用机器内部编码任何其他图灵机。

在我看来，关于通用性一次性阈值的论证远弱于基于通信的论证。许多人类曾尝试理解线性代数却未能成功。有些人（无论我们世界的这一特征多么不公）可能根本无法理解线性代数，句号。⁵⁵ 原则上，如果这些人能够永生

55. 直到技术进步到能够直接对人类进行认知增强。我认为在这类事情上不应放弃。

并且从不感到厌倦，取一条无限长的纸带，用手模拟一台巨大的图灵机来模拟约翰·冯·诺依曼。但他们仍然不会理解线性代数；他们自己的大脑，与纸带不同，不会包含任何适合处理线性代数的表征。⁵⁶ 因此，超过丘奇-图灵阈值并不意味着大脑拥有适合处理每一种可能概念的先天表征。一只永生的小鼠也会超过这个阈值——大多数复杂系统都是如此——但在相关时间尺度上，其认知回报仍低于人类。人类水平之上也存在明显的提升空间；一个显而易见的未来认知通用性阈值是能够操纵自己的源代码，以便为遇到的任何问题组合新的底层认知表征。如果真正的认知通用性阈值存在——如果存在任何一种心智，能够迅速为几乎任何可解问题赋予自身合适的表征——那么我们处于该阈值之下，而非之上。我通常说，人类与黑猩猩的区别在于“显著更广泛适用的智能”，而非“通用智能”。或许可以将人类视为超过可思考事物阈值的百分之一；但相对于交流的情况，似乎更难写出一个论证，说明超过通用性阈值百分之一就能提供大部分边际回报。这种论证的主要合理来源可能是“科学终结”情景，即物理宇宙提供的大多数有趣且可利用的可能性都能被某个通用性阈值水平所理解，因此超过这一点后，通用性不再带来显著回报。人类尚未开发出许多在某种意义上可预见的技术（例如，我们还没有分子纳米技术），但令人惊讶的是，从当前水平所能想象的所有未来技术，似乎都能用人类水平的抽象能力来把握。

然而，这并非强有力的证据，表明更强的抽象能力无助于实现所有重要的技术可能性。

综上所述，并考虑到上述三个论点，我们得到一个综合论证如下：人类相对于黑猩猩的巨大边际回报主要在于大量人类在高于抽象阈值之上共享知识，这比一只无法与其他黑猩猩交流且在本质上无法掌握代数的黑猩猩所能进行的思考更为令人印象深刻。因此，既然巨大边际回报中很少真正涉及改进认知算法或增加大脑尺寸，我们没有理由相信存在任何

56. 注意这与对塞尔中文房间论证的标准回应（Cole 2013）的相似之处。

此类可重复的收益。黑猩猩与人类的大部分差异来自累积总能力，而非个体人类更聪明；你无法仅凭拥有比单个人类更大的大脑就获得人类相对于黑猩猩的收益。就人类在本质上比黑猩猩更聪明而言，那是因为我们跨越了一个质的阈值，使（异常聪明的）人类能够学习线性代数。但既然现在我们中有些人能够学习线性代数，就不再有那样的阈值了。当考虑到所有这些因素时，它解释了人类大部分的红利，并且几乎没有留下什么可以仅仅归因于进化优化认知算法本身以及原始人类大脑尺寸增加四倍。因此，我们没有理由认为更大的大脑或更好的算法能让 AI 经历相对于人类的认知回报增长，就像人类相对于黑猩猩所经历的那样。

上述论证假设了一次性收益，这些收益全部位于我们的过去，未来没有类似的收益。从某种意义上说，所有来自优化的收益都是一次性的——你不可能两次发明蒸汽机，或重复相同的有利突变——然而，期望这种持续的一次性收益流在某个特定点停止似乎缺乏依据。一般来说，假设的一次性收益——无论是来自单一的沟通门槛、单一的通用性/抽象门槛等——似乎很难通过审视原始增长记录来证伪或证实。总的来说，我的回答是，我非常愿意相信人类已经跨越了质的门槛，但不太愿意相信像我们这样年轻的物种已经跨越了某个门槛的 99%，而不是 10% 或 0.03%，并且极度怀疑所有重大门槛都已经在我们的过去，而未来没有任何门槛。尤其是当人类似乎缺乏各种精巧的特征，例如无限扩展到新硬件的能力、重写自身源代码的能力、运行无错误且具有极长串行深度的认知过程的能力等。⁵⁷ 设计景观的一个特征当然是它包含巨大的一次性收益——只能跨越一次的重大门槛。不太可信的是，人类进化跨越了所有这些门槛并达到了心智的质的极限——尤其是当许多看似合理的进一步门槛即使从这里也能清晰可见时。

3.3. 速度的回报

按照十一世纪的标准，二十一世纪初能够做到的事情在十一世纪的人看来就像是“魔法”，因为他们从未想象过这些事情，更不用说断定它们是可能的了。⁵⁸ 是什么将二十一世纪初与十一世纪区分开来？

57. 更不用说人类作者甚至还没有想到的一切。参见第 3.11 节。

58. 再次参见第 3.11 节。

格雷戈里·克拉克（Gregory Clark，2007）基于英国商人和店主的人口统计数据提出，更尽责的个体在财务上更成功且拥有更多子女，而在尽责性可遗传的范围内，这必然意味着自然选择；因此克拉克认为，可能存在某种程度的遗传变化支持了工业革命。

但这似乎只是对更明显解释的一个小补充，即区分十一世纪和二十一世纪的是时间。

什么是时间？撇开基础物理学中一些有趣但并非压倒性相关的答案不谈，⁵⁹ 当被视为一种经济资源时，“时间”是事件能够一个接一个发生的能力。你不可能在发明内燃机的同时发明喷气式飞机；要发明晶体管，必须有人已经完成了电的发现并告诉你。二十一世纪与十一世纪之间隔着一系列发现和技术发展，这些发现和发展确实是一个接一个发生的，并且如果并行进行会显著更加困难。

对于这种性质，一个比“时间”更具描述性的名称可能是“串行因果深度”。软件行业有句俗语：“九个女人不可能在一个月内生出一个孩子”，这表明你不能仅仅通过增加人手来加快项目进度；一个项目需要时间，需要连续的钟点，而不仅仅是总人时数的劳动。

英特尔并没有雇佣两倍于现有数量的研究人员，并以两倍的速度生产新一代芯片。⁶⁰ 这意味着英特尔认为其未来最大的回报将来自必须在当前发现之后做出的发现（而不是大部分未来回报来自在一个平坦搜索空间中一步可达的发现，因此可以通过两倍的研究人员以两倍的速度达到）。⁶¹ 类似地，神经科学中的“百步规则”（费尔德曼和巴拉德，1982 年）指出，由于人类神经元每秒只能放电约一百次，人类似乎能实时完成的任何计算过程最多只能有一百个串行步骤——即一百个必须一个接一个发生的步骤。

59. 参见，例如，巴伯（1999 年）。

60. 由于英特尔的研发成本约占其销售额的 17%，这并不容易，但却是可能的。

61. 如果英特尔认为其当前的研究人员将耗尽整个搜索空间，或在平坦的搜索空间中耗尽所有边际价值较低的低垂果实，那么英特尔将计划在再推进一代之后终止或缩减其研发支出。以一定的并行度开展研究，该并行度既非你所能管理的最大值也非最小值，意味着相对于你当前和未来的技术回报，存在一个预期均衡：在搜索空间的直接下一层你能找到多少果实，与在能够基于先前发现进行构建之后稍后搜索的改进回报之间的均衡。（卡尔·舒尔曼在本文草稿中评论说，英特尔也可能理性地等待，因为它期望在英特尔之外做出的发现基础上进行构建。）

视觉皮层中有数十亿个神经元，因此有理由假设视觉过程涉及数十亿个计算步骤。但你不能假设 A 发生，依赖于 A 的 B 发生，依赖于 B 的 C 发生，如此进行十亿步。人脑内部不可能有这样一系列事件；这一系列事件的因果深度太大，而人脑的串行深度太浅。现代工厂内部甚至不可能有百万步的串行过程；制造任何需要百万个制造步骤依次发生的产品都将耗时过长且成本过高。这种串行因果深度只能发生在计算机内部。

这是计算机之所以有用的一个重要部分，连同它们精确执行形式化过程的能力：计算机包含着巨量的时间，即包含着极其深的因果事件串行深度。自寒武纪大爆发和距今 2×10^{11} 天的解剖学多细胞生物兴起以来，你的直系后代谱系深度可能约为 10^8 或 10^{11} 代。如果人类自 15 万年前起持续相互交谈，每五秒说一句话，那么最长的连续对话可能包含 $\sim 10^{12}$ 条依次相接的语句。一台 2013 年的中央处理器（CPU）运行一天可包含 $\sim 10^{14}$ 个依次发生的可编程事件，若运行一年则为 $\sim 10^{16}$ 个事件。⁶² 当然，如果我们谈论的是六核中央处理器，那么同一时间最多只能发生六件事，而浮点乘法是一个相当简单的事件。尽管如此，当我思考上述统计数据时，一种令人眩晕的感觉油然而生：我们对计算机的利用是多么糟糕。虽然我过去常问：“如果摩尔定律说计算速度每十八个月翻一番，那么当计算机自己进行科研时会发生什么？”⁶³ 但我不再认为摩尔定律将在智能爆炸中发挥多大作用，部分原因是我预期算法带来的回报将占主导地位，部分原因是我预期人工智能会倾向于将自身扩展到更多现有硬件上，而不是等待英特尔式工厂生产新一代芯片。后一种投资形式的时间尺度如此之慢，因而利率如此之低，以至于我只会在所有其他自我改进替代方案在达到解决蛋白质结构预测或以其他方式绕过大型人类式工厂之前都已遇到瓶颈的情况下，才会预期它被采用。

62. 对于 2008 年的中央处理器来说，情况几乎同样如此，因为串行深度的类摩尔定律几乎已完全失效。不过中央处理器也没有变得更慢，而且我们已经创造出的工件在绝对意义上似乎相当强大。

63. 那时我十七岁。

由于计算机以速度快而闻名，一种非常普遍的猜测是，强人工智能会思考得非常快，因为计算机速度极快，因此这类人工智能会迅速获得我们通常与更古老的人类文明相关联的优势，通常是改进的科学和技术。⁶⁴ 针对这一观点提出的两个反对意见是：(a) 第一个足够先进的人工智能可能非常慢，而它已经运行在全部可用计算能力的很大一部分上，因此很难在不等待摩尔定律的情况下加速，⁶⁵ 以及 (b) 如果没有快速的传感器和快速的马达操纵器，快速思考可能毫无用处。⁶⁶ 让我们首先考虑一个先进的人工智能已经运行在如此多的计算能力上以至于难以加速的前景。我发现这种情况有些难以分析，因为我预计人工智能主要是关于算法而不是大量硬件，但我不能排除人工智能是由某个大型机构开发的情况，该机构从一开始就在大量硬件上运行其人工智能项目。这不应该使人工智能在所有方面都变慢；任何具有一定自我重编程能力的人工智能都应该能够非常快速地执行许多特定类型的认知——举一个极端的例子，它在算术上不应该比人类慢，甚至是有意识的算术。但人工智能的整体思维过程可能仍然比人类慢，尽管大概不会慢到让程序员和研究人员感到太无聊而无法有效地进行项目工作或尝试训练和培养人工智能。因此，我不能说整体情况是不合理的。我确实注意到，在其他条件相同的情况下，人工智能运行的硬件越多、算法越差，改进算法带来的收益就越大。试图故意创建一个已经运行在大量硬件上的慢速人工智能，以期保证有足够的反应时间，实际上可能并不能减缓整体增长曲线——这可能被证明等同于让人工智能一开始就拥有比原本更多的硬件，从而在改进其算法时获得更大的回报。我对这一点普遍不确定。

在输入输出方面，传感和操纵存在各种类似摩尔定律的曲线，但它们的指数往往低于纯计算机技术的曲线。如果你在没有进一步变化的情况下外推这一趋势，那么纯粹的

64. 正如四世纪的中国哲学家李小龙 (Xiaoguang Li) 曾经指出的那样，我们倾向于认为早期文明更为可敬，就像一位见多识广的智慧老祖先；但实际上，后来的文明比早期的文明更古老，因为未来比过去拥有更长的历史。因此，如果我现在告诉您，实际上李小龙“迈克” (Mike) 是我的朋友，他在 2002 年提出了这一观点，我希望这能增加而不是减少您对他智慧的评价。

65. 这主要是在与朋友的私人交谈中出现的；我不确定是否见过印刷来源。

66. 作者相当确信自己在印刷品中见过这一反对意见，但当时又未能收集到参考文献。

“基于计算机研究者的摩尔定律”这一情景很快会在思维敏捷的研究者等待他们通过笨拙的机械手进行实验并实际观察结果的缓慢过程中遇到瓶颈。

例如，高能物理学领域似乎受到建造粒子加速器的费用和延迟的限制。同样，天文学的各个子领域也围绕着昂贵的太空望远镜展开。相对于研究者的典型智力水平，这些领域似乎更受感官限制，而非思维限制。有可能足够聪明的科学家能从已收集的信息中获得更多成果，或提出更好的问题。但至少可以说，目前没有人类显而易见的方法能通过思维更快的人类物理学家来加速高能物理学的发展，而且很容易想象，如果将所有人类天文学家的速度提高一倍，而其他方面保持不变，只会使他们对望远镜时间的沮丧程度增加一倍。

在相反的极端，理论数学是一个仅受其人类研究者思维速度限制的领域（目前计算机辅助是罕见的例外，而非规则）。有趣的是，我们应该将数学的进步描述为（1）以与人类其他活动大致相同的速度持续进行，还是（2）远远超过其他所有人类事业的进步，以至于没有任何非数学的人类成就能在深度上与安德鲁·怀尔斯（Andrew Wiles）对费马大定理的证明（Wiles 1995）相媲美。

针对传感器与执行器技术遵循较慢的类摩尔定律这一论点，主要反驳是：由于目前人类大脑无法加速，且人类仍承担大部分体力劳动，因此尚未出现强烈动机去生产越来越快的操作装置——缓慢的人类大脑仍将是限制因素。然而，若未来传感器或操作装置成为限制因素，理性机构的大部分投资将倾向于改善该因素。若缓慢的操作装置制约全局，这将大幅提升更快操作装置的回报，并降低其他方面的回报。但以现有技术，无法投资于加速研究人员的大脑，因此研究人员思维速度常成为限制资源也就不足为奇。任何夜间关闭以便研究人员睡眠的实验室，必然受制于研究人员大脑中的串行因果而非仪器中的串行因果——能够不眠工作的研究人员将相应加速实验室运转。相比之下，天文学和高能物理学中仪器时间的每一分钟都被排满，夜间关闭仪器是不可想象的。大多数人类研究实验室夜间停止运转这一事实，意味着大多数研究领域并非受限于传感器与执行器。

然而，理性地将投资重新分配至改进传感器与操作装置，并不意味着由此产生的新均衡就是快速进步的均衡。

反驳的反驳是：即便如此，与仅重写算法以更快完成认知工作相比，改进传感器与操作装置的构建速度仍然缓慢。因此，传感器与执行器带宽可能最终成为人工智能在短时间尺度内爆发式增长的限制因素；构建新传感器与操作装置的问题可能充当隐喻性的缓发中子，阻止瞬发临界。只要在缺乏经验数据和影响世界的能力时，思考的实用性存在实际限制，这种延迟就会持续存在。

一个反-反-反论点是，如果例如蛋白质结构预测可以作为一个纯粹的认知问题来解决，⁶⁷ 那么分子纳米技术很可能紧随其后。即使一个超级智能被投放到十三世纪，且没有其他物理或化学知识，它也可能需要一段时间来构建先进工具，这是合理的。⁶⁸ 不那么合理的是（反-反-反论点认为），超级智能在现代时代会受到类似的限制，因为蛋白质合成和皮秒相机已经存在，并且有大量预先收集的数据可用。⁶⁹ 与其将感觉运动限制想象为相当于某个被锁在盒子里的可怜盲灵，我们应该想象一个被锁在盒子里的整个人类文明，做着相当于密码学的事情，从每一点感官数据中提取出最后一丝推理，利用其当前保守的运动带宽仔细规划通往更大能力的最快路径，利用影响世界的每一种可能途径，以尽可能快地获得影响世界的更快方式。参见此处了解非正式阐述。⁷⁰ 我会这样总结我对“速度”或“因果深度”的看法：与十六年前与我现在的自我分离的过去 Eliezer Yudkowsky 的观点相反

67. 注意，在某些情况下，现代蛋白质结构预测和蛋白质设计的前沿是众包的人类猜测，例如 Foldit 项目。这表明将更好的认知算法应用于蛋白质折叠会带来收益。

68. 不确定超级智能做任何事情都需要很长时间，因为假定的超级智能比你聪明得多，因此你无法穷尽地想象或搜索它可能拥有的选项。参见第 3.11 节。

69. 计算机科学中的一些基本形式主义表明，学习率从根本上取决于你是能提出自己的问题，还是只能观察大量预先提出的问题的答案。另一方面，也有强有力的理由认为，人类在利用已收集的证据来约束概率分布方面效率极低。

70. 一场对人类而言看似极快的情报爆炸，可能发生在漫长的并行努力序列深度中，其中大部分尝试失败，从经验中学习，更新策略，等待遥远实验的结果等，这对于必须执行类似工作的人类来说，会显得令人沮丧地缓慢。或者用难以置信的拟人化说法：“当然，从你的角度来看，我只用了四天就接管了世界，但你知道那对我来说有多长吗？我不得不等待两万主观年，我定制的蛋白质才到达！”

年的“时间”，⁷¹ 硬件速度的回报似乎不太可能成为情报爆炸中持续的关键因素。即使是英特尔建造新的芯片工厂，自 2004 年以来，至少截至 2013 年，也并未大幅提升串行速度。更好的算法或硬件扩展可以降低一次思考的串行负担，并允许更多思考以串行而非并行的方式发生；一个人类设计的人工智能在开始时极有可能存在巨大的串行难度过剩负担，因此改进认知算法或硬件扩展将导致有效认知速度可能逐渐、也可能一次性的巨大提升。认知速度在某种根本意义上超越感觉运动带宽，对于纳米技术之前的增长阶段也非常合理。与政策相关的主要问题似乎是：

1. 在增长的哪个阶段（如果有的话），人工智能将能够产生人类文明似乎“随时间”发明的那种新技术能力，以及速度有多快？
2. 在持续情报爆炸的哪个阶段（如果有的话），从哪些起始状态出发，人工智能产生的哪些事件将在速度上超过（1）拥有巨大权力的人类官僚机构和政府（数周或数月）以及（2）权力相对较小的个体人类（数分钟或数秒）的反应？

我预期某种极其快速的思维很可能在某个时刻出现，因为当前的中央处理器（CPU）与人类大脑相比，其串行速度已经非常快；这对应哪个增长阶段很难猜测。我还论证过，“困在雕像中的高速灵魂”这一可视化是不恰当的，而“困在盒子中、互联网接入缓慢的高速人类文明”似乎是更好的看待方式。我们可以可视化一些从认知能力到快速基础设施的清晰路径，例如破解蛋白质结构预测问题。我将对这个问题总结我的观点：尽管高认知速度确实可能导致时间花在感觉运动受限上，但从外部看，这段时间的总量可能并不显得很大——当然，一个困在盒子中、拥有互联网接入的高速人类文明会尽快尝试升级到更快的操纵器。

71. 不过，按照人类效率低得令人尴尬这一总体主题，将尤德科夫斯基 1997 与尤德科夫斯基 2013 分开的实际思维过程，可能相当于二十天的串行思维或类似的东西。也许更少。肯定不是十六年不间断的串行思维。

3.4. 人口回报

如第 3.3 节所述，人工智能与全球人类人口竞争的程度，除其他因素外，取决于大规模人类群体是否以接近理想并行效率的方式扩展。

1999 年，一场名为“卡斯帕罗夫对战全世界”的国际象棋比赛在互联网上进行，由加里·卡斯帕罗夫对阵一支世界团队，该团队有五万余人至少参与过一次，由四位年轻棋星协调，第五位大师提供建议，走法由多数票决定，典型一步棋有五千名投票者。卡斯帕罗夫在四个月、六十二步棋后获胜，称自己一生中从未付出过如此多的努力，后来写了一本关于这场比赛的书（卡斯帕罗夫与金，2000 年），书中说：“这是国际象棋史上最伟大的对局。其思想数量之庞大、复杂度之高、对国际象棋的贡献之大，使其成为有史以来最重要的对局。”世界团队的贡献者显然实现了非平凡的规模扩展——他们的棋力远超其最聪明的个体棋手。但最终卡斯帕罗夫确实获胜了，这意味着五千个人类大脑（集体代表，比如说， $\sim 10^{18}$ 个突触）未能击败卡斯帕罗夫的 $\sim 10^{14}$ 个突触。如果这看起来像是一个不公平的估计，那么它的不公平可能属于一种普遍存在于人类文明扩展尝试中的类型。当然，卡斯帕罗夫的许多对手棋力不足，不太可能对任何给定走法的建议或分析做出显著贡献；他面对的不是五千位大师。但如果世界团队拥有人工智能可能具备的优势，他们本可以将棋艺从一名成员复制到另一名成员，从而更高效地扩展。人类无法做到这一点，我们必须为每一个希望为认知前沿做出贡献的个体费力且昂贵地重复教育过程，而我们一些最杰出的范例无法通过任何已知的训练方法复制，这是人类群体扩展不够优化的方式之一。⁷² 在更微观的层面上，计算机科学的一个常识和编程的一个重要实用事实是，通过稀疏通信带宽分离的处理器有时难以良好扩展。当你缺乏复制整个内部认知表征的带宽时，必须消耗（浪费）计算能力在消息接收者内部重建这些表征。卡斯帕罗夫的一位对手不可能仔细分析局面的某个方面，然后将那种心理状态复制并分发给一百位能够分析略有变体的其他人。

72. 更新：显然卡斯帕罗夫在对局期间阅读了“世界”的论坛；换言之，他能够了解他们的思维过程，但反之则不然。这大大削弱了证据的力度。

思考，然后将各自的发现整合为单一的心智状态。他们只能通过言语交流。从这个意义上说， 10^{14} 个具有高局部通信带宽和高局部技能水平的突触能够击败 10^{18} 个被言语和争论的鸿沟所分隔的突触，这并不太令人惊讶。

尽管我预计我的分析这一部分不会没有争议，但在作者看来，人类科学和工程似乎随时间推移比随人口增长扩展得更好——多十年似乎比增加人手更有价值，这也是一个需要解释的重要数据。

事实上，在作者看来，人类科学随着科学家数量的增加而扩展得极其糟糕，这是 1970 – 2010 年相对于 1930 – 1970 年没有更多相对变化的一个主要原因，尽管科学家数量大幅增加。真实进展的速度似乎相对于时间基本恒定，乘以一个或大或小的因子。我承认，在试图做出这一判断时，我是在尝试总结对我自己少数领域之外的所有领域的极其遥远的把握。即便如此，科学的完全停滞或真实进展的真正指数级（甚至二次方）加速似乎都很难被忽视，而已发表论文的指数级增长是可测量的。真实的科学进展随时间持续，所以我们还没有耗尽可研究的事物；然而不知何故，真实的科学进展的扩展速度远不及专业科学家增加的速度。

对这一现象最宽容的解释是，科学问题正变得越来越困难，而各领域增加科学家的综合速度恰好使进展大致保持恒定。例如，英特尔（Intel）似乎以维持其惯常指数增长所需的速度增加新研究人员，这似乎是合理的。另一方面，英特尔实际上公布了其未来路线图，并且是一个集中协调的半理性机构。科学领域通常希望从各种不愿提供更多资金的资助来源获得尽可能多的资金，而政治博弈决定了任何给定年份的增长或缩减速度。很难看出这种均衡是如何协调的。

一种较为宽容的解释是，科学本质上受限于串行因果深度，且难以并行化——科学进步最重要的影响来自于发现建立在发现之上，一旦局部搜索领域的最佳部分饱和，就很难更快地到达目标。这种解释略显不宽容，因为它意味着大量资金可能被浪费在那些“无事可做”的科学家身上，而最有前景的人已经在研究最重要的问题。从某种意义上说，这仍然是一种宽容的解释，因为它意味着全球进步的速度大约与人类科学家所能取得进展的速度一样快。

这两种宽容的解释都意味着，扩展到新硬件上的人工智能将无法比试图并行工作的人类科学家扩展得快多少，因为人类科学家已经在以群体形式尽可能高效地工作。

此外，还有一些不那么宽容的解读——这些解读以不太讨喜的方式描绘人类的表现。例如，如果我们认可马克斯·普朗克（Max Planck）的说法：“一个新的科学真理并不是通过说服其反对者并让他们看到光明而取得胜利，而是因为其反对者最终死去，而熟悉它的新一代成长起来”（库恩，1962），那么我们可以预期，等待上一代人消亡（或者说退休）的过程是一个串行瓶颈，不受并行度增加的影响。但这将是人类固执和生物大脑衰老的瓶颈，而不是问题空间的固有特征，也不是一般理性主体所必需的性质。我也曾思考过，为什么一个十人初创公司平均而言往往看起来与一个万人公司一样具有创新性。我想到了一种解释，我内部称之为“英雄理论”。这个想法是，一个人类组织只能容纳一到五个被允许重要的“英雄”，而其他潜在的英雄会以某种方式看到所有英雄位置都已被占据，于是他们头脑中的某种本能部分告诉他们，英雄行为不会带来名声或地位。⁷³ 这一理论的优势在于，它以一种统一的方式解释了为什么无论是学术领域还是公司，似乎都无法通过投入更多人力来扩大“真正的创新”，却仍然能够随着时间推移而扩展。其劣势在于其机制并非十分可信。类似的现象或许可以由其他研究者的注意力跨度通过少数领导者形成瓶颈，或者对资助优先事项或问题的关注宽度有限而产生。这类社会学并非我的专业领域。

进一步深入愤世嫉俗的层面，我们可能会问，“科学”是否或许是一个不同于“在期刊上发表论文”的过程，而我们的文明懂得如何复制后一种技能，却对复制前一种技能没有系统性的把握。人们观察到，尽管中国培养的博士数量超过任何其他国家，但技术进步（目前）并非由中国主导。如果人类文明明确知道如何培养博士，但科学家的生产却并非如此，这似乎是可以理解的。

73. 我有时担心，通过成为那个“友好人工智能倡导者”，我已经占据了“友好人工智能倡导者”的位置，因此那些正在考虑人生方向的年轻头脑会看到已经有一个“友好人工智能倡导者”存在，从而不会尝试自己去“做这件事”。这在我看来是一个非常令人担忧的前景，因为我认为自己不足以填补整个位置。

由稀有的隐性专家谱系主导，这些专家大多生活在具有悠久科学传统的国家——此外，政治家或其他资助机构不善于区分传统的隐藏守护者，也无法选择性地向他们提供一百万美元以迁往中国。从某种意义上说，这种可能性并不能说明在更多科学家的情况下适用的真实规模因子，但它表明，在通过估计出版物规模来估计人类科学规模时，可能适用一个很大的惩罚因子。

归根结底，这类科学社会学并非作者的专业领域。尽管如此，人们必须对猜测赋予概率分布，而且得出听起来尊重而非愤世嫉俗的估计并无特别的美德。因此，作者将指出，他大体上认为需要解释的数据是“人类科学在向一个领域投入更多人力时规模扩展极差”；并且作者大体上认为最合理的解释围绕着人类科学官僚体系和流程的问题，这些问题不一定适用于一般心智，尤其是一个扩展到更多硬件上的人工智能。

3.5. 人类文明的净效率

人们可能会试图计算 7,000,000,000 个人类，拥有 100,000,000,000 个神经元和 1,000 倍的突触，每秒放电约 100 次，并得出结论：任何理性主体若使用的计算操作远少于每秒 10^{26} 次，就无法与人类物种竞争。但就个体人类或人类群体规模扩展中存在的低效而言，每秒 10^{26} 次操作并不能很好地表征人类物种整体的认知能力，因为这种能力可用于聚焦于科学或技术问题，即使相对于人类认知算法的特征效率也是如此。

一个初步观察是，约翰·冯·诺依曼的大脑体积与普通人相比并无明显增大，这表明每秒 10^{26} 次运算的真正潜力必然以 70 亿个心灵相通的冯·诺依曼的潜力为下界。这似乎并不能很好地刻画我们当前文明的力量。因此，我们的文明在科学和技术领域必然以低于完美的效率运行。

具体而言，本文建议关注以下低效之处：

- 人类必须通过语音及其他低带宽方式进行交流

而非直接迁移认知表征，这意味着认知劳动的大量重复。

- 可能存在某些专业人士系统性地未能产出重要成果

在其领域取得进展，且真正有效参与者的数量必须按某个显著因子向下调整。

- 人类在获准工作之前必须接受多年的学校教育

关于科学问题，这再次主要反映了重复的认知劳动，相较于复印另一份爱因斯坦的副本。

- 人类科学家并非每天二十四小时都在从事科学研究（这代表效率降低的一个小整数因子）。

- 职业科学家并未将所有工作时间直接用于解决他们的科学问题。

- 在思考科学问题的任何单个人类个体中，并非其大脑的所有部分都可视为在致力于该问题。

- 人类科学官僚体系的低效可能导致潜在有益的贡

献被丢弃，或将潜在有用的人才引导至可预见重要性较低的问题上，等等。

进一步指出，大多数人根本不是科学家或工程师，而大多数科学家和工程师并未专注于智能爆炸过程中的 AI 可能被期望关注的问题，例如改进机器认知算法，或在某个阶段末端的蛋白质结构预测。然而，汉森式批判方法⁷⁴显然会引出这样的问题：“你为什么认为 AI 不必像人类文明无法将所有时间用于 AI 研究那样，将大部分时间和脑力用于支持自身的辅助性经济任务？”一种可能的回答是，人类在从事相对重复的体力或认知劳动时，必须使用整个人类大脑来支持其身体，而 AI 则能够利用仅需直接认知的赚钱机会，使用相应更少的计算能力。汉森式方法随后会追问，为什么没有许多 AI 竞标此类工作并压低回报。⁷⁵但在具有局部 FOOM 的模型中

74. 我将这一通用规则描述如下：“对于人工智能（AI）所有被宣称的能力，追问为何人类不具备同样的能力。对于人类版本能力的所有被宣称的障碍，追问为何类似的障碍不会适用于人工智能。”我时常与汉森（Hanson）就此类问题的案例能否给出令人满意的答案存在分歧，但这一问题本身显然是明智且正确的。

75. 我将这一规则描述如下：“每当有人基于局部快速起飞（FOOM）的背景假设进行工作时，检查该假设，并考虑一个基于众多人工智能大致

因此，一个人工智能相对其他项目领先，即使假设该人工智能并非简单地窃取计算时间，其‘进行科学研究的计算操作’与‘赚取金钱的计算操作’之比很可能高得多。更一般地，全体人类并非主要由专业科学家组成，这些科学家致力于解决人工智能在快速起飞过程中将面临的最重要问题，这一事实必然在降低我们对匹配人类对人工智能进步投入所需净计算能力的估计中发挥作用，前提是算法具有大致人类水平的效率。

上述所有因素综合起来，可能仍仅触及人类计算低效的表层。我们在整数乘法问题上的表现，与每秒 10^{16} 次运算的粗略估计可能让你预期的并不相符。换言之，我们的大脑并未将其底层计算能力高效地传递到整数乘法任务上。

我们在整数乘法上极其糟糕的表现，显然并未为人类在所有问题上的计算效率设定上限——甚至包括非祖先环境中的问题。

加里·卡斯帕罗夫（Garry Kasparov）能够与深蓝（Deep Blue）进行竞争性对弈，当时卡斯帕罗夫每秒分析两步棋，而深蓝每秒分析二十亿步棋，这意味着卡斯帕罗夫确实能够有效地调动其视觉皮层、颞叶、前额叶皮层、小脑等，以并行模式识别和规划的形式有效贡献大量计算能力。事实上，卡斯帕罗夫展现了惊人的计算效率；他能够与深蓝匹敌，这种表现是事先仅凭推理的旁观者可能难以想象的，因为一个每秒串行深度仅有一百步的思维竟能达到如此水平。然而，现代国际象棋程序深里布卡 3.0（Deep Rybka 3.0）在每秒二十八亿次运算的速度下已远超卡斯帕罗夫，因此卡斯帕罗夫的脑力仍未完美转化为国际象棋能力。归根结底，这种低效是意料之中的，因为卡斯帕罗夫的基因构成并非经过漫长岁月为下国际象棋而筛选。

我们或许同样会发现，人类科学家虽然能够将更多脑力用于科学研究而非整数乘法，但他们仍未像专为科学研究设计的思维那样高效地利用其计算操作——即使在他们专注于该问题并处于灵感巅峰的时刻也是如此。

所有这些因素综合起来，描绘出一幅截然不同的图景：若要在发明更优人工智能算法或破解蛋白质折叠的任务中超越人类文明，人工智能所需做的并非与七十亿人类竞争，其中每个人拥有 10^{11} 个神经元和 10^{14} 个突触，每秒放电 10^2 次。

同等能力。”在此，我更倾向于质疑这个问题是否真正有用，因为我实际上确实预期会出现局部快速爆发（FOOM）。

当我们逐一审视以下事实：并非所有人类都是科学家，并非所有科学家都富有成果，并非所有富有成果的科学家每时每刻都在钻研问题，并非所有专业劳动都直接适用于认知问题，认知劳动（尤其是学习，或理解通过言语传递的思想）常常在个体之间重复进行，非重复性贡献的成果被周围官僚体系以远非完美的效率处理，人类由于大脑运行的特征时间尺度至多为每秒 10^2 步而经历显著的串行瓶颈，人类不具备心灵感应能力，以及最终，在巅峰洞见时刻应用于科学问题核心认知部分的实际认知劳动，其低效程度介于“卡斯帕罗夫在国际象棋中输给深莱布卡每秒 28 亿次运算”与“卡斯帕罗夫在整数乘法中输给袖珍计算器”之间……

……人类文明应用于相关问题的有效计算能力，很可能在一个资金适度的项目仅为其人工智能购买即可轻松达到的范围内，而该人工智能本身无需明显地去争取更多资金。

坦率地说，我怀疑当你把所有人类低效因素加总起来时，即便没有多少根本性的新颖且更优的算法——仅仅是将我们已用算法所需的实际认知步骤提炼出来——嗯，我怀疑这个数值实际上相当低。⁷⁶ 而这很可能与一个事实有很大关系，即在实践中，我认为一个设计得当的人工智能可以盖过人类文明的力量。这不仅仅是关于未来增长的抽象期望，而是一种感觉：一旦将所有低效因素计入，人类文明的净认知能力并不那么令人印象深刻。那些认为每秒 10^{26} 次运算实际上是衡量人类文明宏伟力量的恰当代理指标的人，可能会有不同看法。

3.6. 累积进化选择压力的回报

我此前曾声称，我们尚未看到累积自然选择带来的认知回报递减的迹象。也就是说，从南方古猿到直立人的进化时间，并非是从直立人到智人所需时间的十分之一。细心的读者可能会提出异议：“当然，直立人—智人之间的间隔并非南方古猿—直立人之间间隔的十倍。

76. 尽管并非低到如同人类科学家的所有言语思维都能被翻译成一阶逻辑，并由一个简单得可笑的 AI 引擎作为定理背诵出来——这在早期曾被短暂地相信过。如果 BACON (Langley, Bradshaw, and Zytkow 1987) 或结构映射引擎 (Falkenhainer and Forbus 1990) 的制造者所提出的主张是人类认知推理的准确模型，那么截至 1900 年的科学革命总共需要的认知操作数量级或许仅为 10^6 。然而，我们同意 Chalmers、French 和 Hofstadter (1992) 的观点，即这不是一个好的模型。所以并非低到那种程度。

间隔，你只是从化石记录中挑选了三个恰好不具有那些相对间隔的命名标记。”或者，更宽容地说：“好吧，你向我展示了某些命名化石 A、B、C，从 A 到 B 有 320 万年，然后从 B 到 C 有 180 万年。

你真正主张的是，从 A 到 B 的认知改进并非是从 B 到 C 的十倍。你怎么知道这一点？”对此，我可以朝着神经人类学的细节方向挥手示意，⁷⁷ 并声称，关于喉部形状（用于语言使用）、保存下来的工具和篝火等可观测特征，看起来大致呈线性——或者适度超线性，但无论如何不是次线性。脑容量随时间变化的图表可在此处找到（Calvin 2004, chap. 5）。尽管从“脑容量”到“脑容量边际适应度收益递增”再到“脑算法改进”之间存在推理距离——然而，该图表看起来要么是线性的，要么是适度超线性的。

更广泛地说，另一种表述方式是问：如果对原始人类进化优化的回报强烈递减，世界应该是什么样子。⁷⁸ 我的回答是，首先，看到一个认知生态位仅由一种智能物种主导的世界会非常令人惊讶。鉴于认知能力累积选择的回报是次线性的，应该还有其他物种大致赶上领先者。例如，从原始语言进化出复杂的组合句法，由于回报递减，应该是一个比仅仅产生原始语言在进化上昂贵得多的命题。⁷⁹ 然后，在原始人类从原始语言进化出复杂句法的漫长时期里，黑猩猩应该已经赶上并开始使用原始语言。当然，进化并不总是重现相同的结果，即使在高度相似的物种中也是如此。但总的来说，进化对认知的次线性回报意味着，看到一个物种远远领先于所有其他物种会令人惊讶；在追赶过程中应该存在几乎势均力敌的竞争者。

77. 特伦斯·迪肯（Terrence Deacon）1997 年的《符号物种》名义上提出了一种关于人类通用智能的理论，我认为该理论相当错误，但同一本书顺便对原始人类进化过程中的认知改进做了极好的通俗概述，尤其是与语言和抽象推理相关的部分。

78. 在应用理性中心，训练经验主义的一种方式是通过周一周二游戏。例如，你声称相信手机通过“无线电波”而非“魔法”工作。假设周一手机通过无线电波工作，周二通过魔法工作。你能看到或测试到什么在周一和周二之间不同？类似地，这里我们在问：“周一，对更好认知算法的累积选择存在线性或超线性回报。周二，回报强烈次线性。周一和周二的世界看起来有何不同？”换句话说：如果你强烈地得出了结论 X，你应该能够轻松描述如果非 X 世界会看起来非常不同，否则你最初是如何得出 X 的？

79. 关于“原始语言”的解释，参见比克顿（Bickerton，2009）。

向上。（例如，我们看到数百万种有毒物种，但没有一个物种通过拥有远超其最近竞争者的更优良毒素而占据整个“毒素生态位”。）但是，如果在人类进化过程中，与黑猩猩进化相比，对智力的选择压力大幅增加呢？如果在过去 180 万年自直立人以来，对大脑的选择压力增加了千倍，以至于从直立人到智人所需的累积优化实际上与自多细胞生命开始以来大脑的所有进化相当呢？

一个物种内部的总选择压力存在数学极限。然而，与其说总选择压力增加，不如说选择压力突然集中于某一特征而非另一特征更为合理。此外，这在人类进化中几乎肯定是如此。与蝎子相比，人类之间的竞争更可能围绕谁的大脑更好，而不是谁有更好的甲壳。与适合度共变的特征方差更大，自动意味着对该特征的选择压力增加。⁸⁰ 直观地说，人类用大脑做的有趣事情越多，他们的竞争就越会围绕认知而非其他方面。然而，人类大脑实际上看起来确实很像放大的黑猩猩大脑——前额叶皮层更大，无疑有许多神经调整，但总体大脑解剖结构几乎没有变化。

就纯粹的先天进化理论而言——如果我们进行纸上谈兵的理论推演，从未见过智能物种进化，可能会想象一种征服行星的生物从零开始发展出一个新的复杂大脑，远比其他最近竞争者复杂，在该器官突然成为持续数百万年的强烈选择焦点之后。但事实上我们并没有看到这一点。人类大脑看起来像放大的黑猩猩大脑，而不是大部分新颖的器官。

鉴于先前听起来有说服力的论证，即与之前的漫长时期相比，每代对大脑的选择压力可能增加了数千倍，为什么会这样呢？

进化受到串行深度的强烈限制，尽管许多正突变可以并行地被选择。如果你有一个等位基因 B，它仅在等位基因 A 存在时才有优势，那么在有利于 B 的显著选择压力出现之前，A 必须在基因库中达到普遍性，或至少是流行性。如果

80. 数学量化参见普赖斯方程。

C 依赖于 A 和 B 两者，那么在有利于 C 的显著压力出现之前，A 和 B 都必须高度流行。⁸¹ 在有性繁殖的物种中，任何遗传变异都被反复打乱，复杂机器将主要由一个深层的、静止的复杂度池构成，表面浮着一层在任何给定时刻被选择的非相互依赖的改进泡沫。强化的选择压力可能会提高单个正等位基因在基因库中达到普遍性的速度，或允许并行选择更多非相互依赖的变异。但复杂机制的进化仍在一个重要意义上受到串行深度的强烈限制。

因此，尽管极有可能的是，与其他生物体特征相比，原始人类的大脑经历了大大强化的选择，但当只有几十万代将我们分开时，人类大脑看起来大多像黑猩猩大脑仍然不足为奇。

尽管如此，原始人类大脑尺寸随时间的中等超线性增长可以轻松容纳累积选择压力上的严格线性回报，而随时间看似加速的现象仅仅是由于对智力的选择压力增加所致。如果认知的“累积选择压力回报”不位于“累积时间回报”曲线之下，那将是令人惊讶的。我最近震惊地听到关于分子证据的声称，即自农业开始以来，人类的遗传变化速率可能增加了一百倍（霍克斯等人，2007 年）。其中大部分可能与乳糖耐受性、不同纬度的黑色素、消化小麦等有关，而不是对新智力相关等位基因的正选择。这仍然为将人类在过去一万年中的某些进步归因于字面意义上的进化，而不仅仅是文明知识的积累，留下了一些潜在空间。

但即使遗传变化速率真的提高了一百倍，也不意味着在人类进化过程中，单个突变带来的认知回报会显著下降。进化生物学的数学原理表明，一个赋予适应度优势为 s 的单一突变事件，即其携带者的平均适应度为 $1 + s$ ，而种群平均适应度为 1，该突变扩散至整个种群并达到固定的概率为 $2s$ ；预期固定时间为 $2\ln(N)/s$ 代，其中 N 为总种群规模。因此，如果每个正突变的适应度优势降到足够低，该突变不仅需要极长的时间

81. 随后出现了依赖于 B 和 C 的 A*，现在我们拥有了一台复杂的相互依赖机器，移除 A*、B 或 C 中的任何一个都会导致其失效。自然选择自然而然地、自动地沿着一条渐进的、盲目的、局部爬山的路径产生了“不可简化”的复杂机器。

代才能扩散至整个种群，而且很可能根本无法扩散（即使该突变独立地多次重现）。选择压力增加的可能性主要应使我们怀疑，人类与黑猩猩之间存在巨大的认知差距，这源于累积优化带来的线性回报——即进行了更多的优化，而非少量优化产生了巨大回报。但我们不能同时拥有黑猩猩与人类之间较小的认知差距、大量的累积选择，以及单个突变的适应度回报急剧递减，因为在这种情况下，我们根本不会获得多少进化。遗传变化速率增加的可能性实际上并不意味着，随着基础水平变得更加复杂，认知算法会变得“更难设计”或“更难改进”。

单个正突变的回报受到自然选择逻辑的下限约束。

如果你认为未来的分子遗传学可能会在历史记录中揭示出这类巨大的选择压力，那么你应该始终认为人类比黑猩猩聪明得多是合理的（尽管可能不是确定的），这与第 3.2 节中考虑的一些相反方向的论点相悖。从直立人到智人的心智设计距离，与从老鼠到南方古猿的心智设计距离相比，有足够的空间是显著的，这与化石记录中相对时间间隔所暗示的相反。

为了将进化中递减的认知回报纳入这个模型——同时不与基本的进化观点相矛盾，即足够小的适应度优势需要大量时间才能固定，或者更可能根本无法固定——我们必须假设小的认知优势以某种方式提供了超大的适应度优势（这种方式与试图自我改进的人工智能在认知再投资上的回报无关）。在某种程度上，“夸大的适应度优势”出现在失控的性选择理论中（每个人都试图与看起来哪怕只是名义上最聪明的人交配）。无论这种性选择在多大程度上发生，我们都应该降低对那种由认知产生的适应度优势的估计，这种优势会延续到试图解决蛋白质折叠问题的机器智能上（在那里，仅仅稍微好一点并不会获得超额的奖励）。尽管如此，我仍然要说，归根结底，在你能从观察到的生物人类学中得到累积自然选择的递减回报之前，需要对大脑尺寸随时间变化的图表进行一种巴洛克式的解释，更不用说人类和黑猩猩之间观察到的认知差距了。有一些空间让最近的短时间间隔扩展成大量的累积选择压力，但这主要意味着我们不需要假设每个正突变都有递增的回报，

来解释表面上超线性的历史进步。⁸² 总的来说，没有太多空间假设进化历史告诉我们累积自然选择的认知回报在递减。

3.7. 关联进化难度曲线与工程难度曲线

如果创造人类智能对自然选择来说很容易，但对人类工程师来说却很难，那会怎样？

自然选择的力量常被浪漫化——例如，由于美国文化对试图错误地贬低自然选择力量的宗教的反向压力。甚至一些早期生物学家也犯过此类错误，尽管大多是在乔治·C·威廉姆斯（George C. Williams, 1966）和 20 世纪 60 年代革命之前，那场革命催生了对自然选择能力和特征设计过程的非常清晰、往往数学上精确的图景。如今，我们可以在许多方面用简单的方程量化自然选择是缓慢、愚蠢和盲目的这一陈述：一个适应度 $1 + s$ 的正突变需要 $2 \ln(\text{种群})/s$ 代才能固定，并且只有 $2s$ 的概率能够做到。⁸³ 在观测到的生物学中，进化仅在极少数场合发明了自由旋转的轮子。自由旋转的轮子实际上效率极高——这就是它们出现在三磷酸腺苷合酶（ATP synthase）中的原因，该分子可能比生物学中几乎任何其他东西都更受近乎完美效率的强烈选择。但（尤其是当我们从自组装分子转向必须由组织生长的器官时）在通往自由旋转轮子的道路上，很难找到中间进化形式。

进化无法发展出以自由旋转轮子为目标的中间形式，而且它几乎从不局部爬山进入该设计。这是人类工程师能够轻松进入进化几乎从不进入的设计空间的一个例子，因为人类工程师能够在想象中持有整个设计，并根据想象的问题进行调整。

我们应当强烈预期，点突变、随机重组和统计选择会在增长曲线的某些部分遇到瓶颈，而深思熟虑的预见、结果导向的反向链推理和习得的抽象则会稳步前进——而不是相反。智能工程师的难度曲线

82. 需要明确的是，每个正突变带来的递增回报意味着随着基础设计变得更加复杂，改进认知算法变得更容易，这将意味着对恒定优化的回报加速。这可能是从黑猩猩到人类看似巨大收益的一种可能解释，但选择压力几乎肯定增加了，而且可能增加了很多，这一事实意味着我们不能强烈得出这一结论。

83. 试想，如果自 T 型车时代以来，汽车发动机的每一次 2% 改进都需要历经千代才能被采纳，且仅有 4% 的概率被采纳。

应当以自然选择过程的难度曲线为上界（其中更高的难度代表累积投资的更低回报）。进化确实拥有显著的先发优势。然而，尽管追赶数百万年的累积进化优化乍看之下令人望而生畏，但一旦计算出携带 3% 适应度优势的基因需要 875 代才能在五十万个个体中扩散开来，这种畏惧感便会减轻。我们不能期望智能工程与自然选择的难度曲线完全相同。但我们可以合理地将其关联起来，即智能工程的难度曲线应保持在自然选择相应曲线之下，而自然选择在穿越这条曲线上拥有显著的先发优势。假设我们接受这一关联。或许在实践中，我们仍无法对人工智能发展时间得出太多结论。让我们假设人类工程师需要八十年才能让人工智能达到直立人的水平。可以合理地认为，直立人水平的智能仍不足以让人工智能对其自身发展做出显著贡献（尽管参见第 3.10 节）。⁸⁴ 那么，如果让人工智能达到直立人水平需要八十年，再花九十年工程努力达到智人水平，这难道会令人惊讶吗？

我会回答：“是的，我会感到惊讶，因为即使考虑到近期选择压力可能增加，从零开始进化到直立人所花的时间仍远多于从直立人进化到智人所花的时间。”如果自然选择在达到直立人水平后并未经历急剧上升的难度梯度，那么发现人类工程能够达到直立人水平的人工智能（克服了自然选择在此之前数亿年的累积领先优势），但人类工程随后需要更多努力才能从那里达到智人等价物，这将是令人惊讶的。

但请注意：人类工程学的增长曲线可能以进化曲线为下界，同时整体形状仍有所不同。例如，可能所有通向直立人（*Homo erectus*）的步骤对人类工程师而言远比进化容易——即该区域内人类难度曲线远低于进化曲线——而从直立人到智人（*Homo sapiens*）的步骤对人类工程师仅略微容易。也就是说，该区域内人类难度曲线略低于进化曲线。换言之，我们可以设想直立人

84. 这一陈述并非显而易见，原因在于：具有大致相当于直立人水平的通用智能的人工智能，仍可能在计算机编程方面拥有超常能力——正如现代人工智能跨领域智能较差，却仍存在专门的国际象棋人工智能。考虑到盲目进化能够构建出人类，一个加速的、具有专门编程能力的直立人级人工智能能否自我提升至智人水平，并非显而易见。

对自然选择而言“困难”，而从该阶段发展到智人（Homo sapiens）则“容易”，同时这两个过程对人类工程师而言都将“容易”，因此每一步都将在八十年内完成。于是，“创造智能对人类工程师来说将远比进化容易”这一陈述，在一个“达到直立人级人工智能需八十年，再达到智人级人工智能需九十年”同样成立的世界里，是可以想象的。但必须区分可能性与概率。从概率角度看，如果这种情况真的发生，我会感到震惊，因为我们没有观测理由认为相对难度曲线实际上呈现这种形态；缺乏观测支持的具体复杂不规则性具有较低的先前概率。当我具体想象时，同样感到震惊：如果你能造出直立人，你就能造出大脑皮层、小脑皮层、边缘系统、负责物体识别的颞叶等等。人类与黑猩猩共享绝大部分神经架构——这些特征自人类与黑猩猩的最后共同祖先以来未曾分化。我们有某种程度的直接观测证据表明，人类智能是黑猩猩智能这块蛋糕上的糖霜。能造出那么大一块蛋糕，却发现自己做不出相对少量的糖霜，这令人惊讶。80 – 90 假设还要求自然选择在构建更复杂智能时更容易——等价地，在构建较不复杂智能时更困难——其理由不会推广到人类工程师，这进一步增加了具体且无支持证据的复杂不规则性。⁸⁵ 总体而言，我认为我们有具体理由怀疑自然选择的难度曲线位于人类工程师难度曲线之上，并且人类将能够进入自然选择无法触及的设计空间区域。我预期早期人工智能在这一意义上介于人类与自然选择之间，而足够先进的人工智能将沿同一谱系比人类走得更远。那些需要具体且无支持证据的关系不规则性的推测

85. 通过想象更新的方法，假设你告诉我：“抱歉，我来自未来，事实是，达到直立人水平确实花了 X 年，然后又花了另一个 X 年才达到智人水平。”当我从震惊中恢复过来后，我会说：“嗯。我猜一定存在某种方式，能够获得相当于直立人的性能，而无需构建任何真正类似直立人的东西，并且这种方式不会泛化到智人所能做的事情上。”（我们已经拥有在国际象棋上超越人类性能的人工智能，但其方式与人类解决问题的方式完全不同，且不会泛化到其他人类能力。我推测，大多数问题上直立人水平的性能也是以类似方式获得的。）我仍然会感到过于惊讶，以至于无法相信你真的能构建出一个直立人，然后在通往智人的道路上遇到如此大的困难。

这些曲线之间的结果应被视为不太可能；另一方面，许多可能的不规则性所产生的结果则更有可能，因为关系必然在某些地方是不规则的。对该领域的进一步分析可能会得出关于人类工程难度与进化难度之间预期关系的更具体陈述，这些陈述与人工智能时间线和增长曲线相关。

3.8. 我们对进化出的人科动物观察中的人类偏差

“智能进化了”这一观察可能因人类原因而产生误导：也许进化出智能极其困难，但在所有没有进化出智能的行星上，没有人能观察到智能的缺失。

舒尔曼和博斯特罗姆（2012）分析了这个问题及其在当前关于如何推理人类概率的争议状态下可能给出的几种答案。去除一些限定条件并简化后，结果表明——在产生任何人类偏差调整的假设下——我们能得出的主要结论是汉森（1998c）结论的一个变体：如果智能进化中存在几个“困难步骤”，那么进化出智能生命的行星应该预期看到这些困难步骤在其历史中大致均匀分布，无论每一步的相对难度如何。

假设一大群开锁者试图在五小时内解开一系列五把锁，但每把锁的平均解开时间都超过五小时——在平均情况下需要十小时或一百小时。那么，少数足够幸运解开所有锁的开锁者，很可能会看到这五把锁随机分布在记录中。

以开锁者足够幸运解开全部五把锁这一事实为条件，平均解开时间为十小时的困难锁和平均解开时间为一百小时的困难锁，在筛选出所有锁都被解开的情形下，将具有相同的期望解开时间。⁸⁶ 这反过来意味着，“自我复制的生命出现”或“多细胞生物产生”是地球上智能生命演化中合理的困难步骤，但从南方古猿到智人的时间间隔太短，不足以构成一个合理的困难步骤。

在首次达到南方古猿智能的过程中可能存在一个困难步骤，

86. 我认为对这一结果的一个合理的简化说明是：假设锁 A 的解开时间均匀分布在 0 小时到 200 小时之间，锁 B 的解开时间均匀分布在 0 小时到 20 小时之间，那么以 A 和 B 在总共 2 小时内都被成功解开这一事实为条件，我们得到“A 在 1.5 - 1.6 小时内解开且 B 在 0.4 - 0.5 小时内解开的联合概率”与“A 在 0.4 - 0.5 小时内解开且 B 在 1.5 - 1.6 小时内解开的联合概率”相等，尽管在这两种情况下，A 被如此快速解开的概率都是 B 被如此快速解开的概率的十分之一。

但从黑猩猩同等智能到人类，自然选择显然一帆风顺（或者至少，在人类学调整之前，“朴素”视角所指示的航行可能大致同样平稳或同样颠簸）。几乎相同的说法也适用于从老鼠同等祖先到人类的间隔，因为五千万年足够短，使得困难步骤不太可能发生，尽管并非完全不可能。另一方面，从蜘蛛到蜥蜴的间隔可能更合理地包含一个困难步骤，其难度因人类学偏差而对我们隐藏。

这对智能爆炸模型说明了什么？

进化与人类工程的难度曲线不能合理地期望同步变化。对进化而言困难的步骤，对人类工程师而言未必困难（回想自由旋转轮子的例子）。即使在通往老鼠的进化道路上存在一个进化上的困难步骤——这个困难步骤将拥有老鼠的行星数量减少了 10^{50} 倍，使大多数星系超星系团中不再有老鼠，并解释了我们夜空中观察到的“大寂静”——它仍然可能是人类工程师可以轻松完成的事情。⁸⁷ 如果自然选择需要 10^{100} 次尝试才能完成某件事但最终成功了，那么这个问题在绝对意义上仍然不能算太难，因为进化仍然相当愚蠢。

还存在一种可能性，即我们可以逆向工程真实的老鼠。我认为在人工智能领域，逆向工程生物学的作用常常被高估，但如果这个问题由于神秘原因而变得极其困难，我们手头确实有老鼠。

因此，一个进化上的困难步骤相对不太可能成为人类工程师的永久障碍。

所有这些只涉及通往制造老鼠道路上的障碍。我不太修改我的智能爆炸模型以补偿可能的人择偏差的一个原因是，低于老鼠水平的人类困难障碍从外部看起来像是：“天哪，我们已经拥有蜥蜴级别的人工智能二十年了，仍然无法达到老鼠水平，我们可能不得不逆向工程真实的老鼠，而不是自己解决这个问题。”⁸⁸ 但人择原理的建议是，从老鼠到人类的道路

87. 有趣的是，人类工程师尚未构建完全自我复制的系统，而自我复制的初始出现是一个合理的困难步骤。另一方面，复杂细胞（真核生物）的出现以及随后多细胞生命的出现都是合理的困难步骤，各自需要大约十亿年的进化时间，而人类工程师在制造具有复杂部件的复杂事物方面似乎没有遇到任何类似的困难。

88. 这类事情很难凭肉眼判断，但我并未看到任何特别迹象表明，人工智能在通往小鼠水平的道路上迄今已在某个特定节点陷入停滞。对于领域外的观察者而言，人工智能可能看似遭遇瓶颈，因为在普通人的经验中，智能的尺度从“村中愚者”一直延伸到“爱因斯坦”，因此直觉上会认为人工智能停滞不前，停留在“村中愚者水平”之下。如果

并不比看起来更难，那么一个减缓进行中智能爆炸的“困难步骤”想必必须在智能爆炸达到小鼠水平之前出现。⁸⁹ 假设智能爆炸确实可能在小鼠水平之下启动——也许一个具有亚小鼠通用智能和高串行速度的专用编程人工智能能够实现显著的自我改进。那么从外部来看，我们会看到类似这样的情形：“嗯，我们可以构建这些相对愚笨的专用人工智能，它们似乎能从递归自我改进中获得显著收益，但随后我们构建的一切都在相同的亚小鼠水平附近遇到瓶颈。”如果我们试图从这个人类学视角中提炼出政策建议，它可能会说：“如果未来的人工智能研究人员能够构建相对愚笨的自我修改系统，这些系统常常能够经历由再投资收益驱动的长链显著自我改进，并且它们都在小鼠级通用智能之下的某个大致相同的点停滞不前，那么这个点可能就是进化史上的‘困难步骤’，而非难度曲线永久上升之处。你应当对第一个被推过这一大障碍的人工智能保持警惕，因为一旦达到小鼠水平，之后的旅程可能就一帆风顺了。”我不确定自己会对这一建议抱有多大信心——它似乎是通过一个复杂的论证得出的，而且我看不到简化其核心思想的好方法。但既然我原本不会预期这种瓶颈会在许多不同的人工智能系统中均匀出现，那么这一部分可以说是困难步骤模型的一个独特预测：某个被忽视的小锁实际上包含了平均所需解决时间的一千个宇宙小时。不过，总体而言，在我看来，人类学论证并未就智能爆炸提供非常详细的建议（这在很大程度上也是意料之中的）。

3.9. 局部智能爆炸与分布式智能爆炸

罗宾·汉森（Robin Hanson）与我之间辩论的一个关键组成部分是局部性（locality）问题。试想：如果在人类恒定的情况下，知识存在递增回报

如果你恰当地理解从零的“岩石”到“细菌”到“蜘蛛”到“蜥蜴”到“老鼠”到“黑猩猩”再到“人类”的尺度，那么人工智能似乎正以缓慢而稳定的步伐前进。（至少在人类研发的尺度上是缓慢而稳定的。在进化的时间尺度上，过去六十年这一瞬间，人工智能的进步速度之快令人难以想象、令人目眩。）“困难步骤”理论确实指出，我们可能会预期在老鼠之前存在某种进一步的神秘瓶颈，其程度比没有大寂静（Great Silence）时我们所预期的更大。但这样的瓶颈可能仍然不对应于人类工程师的大量时间。

89. 一个更复杂的可能例外是，如果我们能在某些方面远远领先于蜥蜴，但缺少老鼠所做的一件至关重要的事情。比如说，我们已经拥有比蜥蜴更快找到大素数的算法，但仍然不会吃奶酪。

大脑——这是许多非智能爆炸、一般技术超增长模型所依赖的主要假设，该假设似乎得到了指数⁹⁰技术驱动的生产率增长⁹¹的有力支持——那么为什么领先的人类国家没有远远领先于第二名的经济体呢？拥有最多知识经济体难道不应该随着其递增回报的复利而进一步领先于其下一个领先的竞争对手吗？显而易见的答案是，知识并不局限于一个国家的边界之内：一个国家内部的改进很快就会跨越边界传播。中国每年的增长幅度大于澳大利亚，实际国内生产总值（RGDP）增长率约为 8% 对 3%。⁹²这并不是因为总体技术发展具有边际回报递减。而是因为中国在追赶已经生产出来的、可以廉价进口的知识时，正在经历非常快速的知识驱动型增长。

相反地，原始人类（hominids）与黑猩猩的差距越拉越大，黑猩猩不仅未能迎头赶上，反而愈发落后，因为原始人类的基因创新并未进入黑猩猩的基因库。我们可以推测，大脑的改进如何可能为进一步的改进带来更高的认知回报，或者认知的改进如何可能加大围绕智力的选择压力，从而在原始人类进化中形成正反馈效应。但这仍然不会

90. “指数”一词并不意味着“快速”；它指的是微分方程 $y' =$ 的解。“大停滞”论点的核心主张是，发达国家在二十世纪的全要素生产率增长约为每年 0.75%，直到二十世纪七十年代中期降至每年 0.25%（Cowen 2011）。这并不快，但确实是指数级的。

91. 我怀疑，关于人类能以多快的速度复合技术进步的不确定性，并非主导智能爆炸中增长率不确定性的问题，因此我不太谈论人类技术进步曲线的这样或那样的细节，只是指出确实存在一些。对于那些只试图处理恒定人类大脑的技术超增长模型，这些细节显然更受关注。就我个人而言，对于不依赖认知再投资的技术超增长模型，我持不可知论态度，倾向于怀疑。我怀疑，如果你以某种方式拥有恒定的人类大脑——没有人类基因工程，没有使用脑机接口的六十四节点集群人类，没有更快的研究人员，没有来自超级智能人工智能的超常认知回报，没有分子纳米技术，也没有任何其他允许认知再投资的东西——那么由此产生的情景在一个世纪内实际上可能看起来相当正常；在我看来，2000 年至 2100 年由技术驱动的变化量与 1900 年至 2000 年大致相同是合理的。（我愿意听取为什么这是荒谬的。）

92. 日本可能是人均技术最先进的国家，但其经济增长可能受到日本货币政策的阻碍。斯科特·萨姆纳（Scott Sumner）喜欢澳大利亚的货币政策，因此我将中国与澳大利亚进行比较，以比较发展中国家与发达国家的增长率。

如果人科动物的进步通过水平基因传播扩散到其他灵长类动物，那么导致人科动物远远领先于其他灵长类动物的原因。⁹³ 因此，我们可以勾勒出两种截然不同的智能爆炸可能情景，它们在多个维度上处于相反的极端，如下所示：⁹⁴

极局部起飞：

- 与当今情况类似，先进人工智能架构的多样性如此之大，以至于存在项目之间几乎不存在认知内容的交换。下载一个大型数据集，并让您的的人工智能在其自身的认知表征中重新学习该数据集的经验，比在不同人工智能之间交换认知内容更为容易。
除了最先进的项目之外，其他人工智能（AI）即便能够产生自我改进，也只会生成对特有代码的修改，而这些修改无法以低成本与其他任何人工智能共享。

领先项目并未公开其全部甚至大部分研究成果——无论是出于对冲基金保守其配方秘密的相同原因，还是出于与莱昂纳多相同的原因

西拉德并未立即向世界公布裂变链式反应。

- 领先项目的数量相对较少。
- 首个触及智能爆炸的人工智能因一项未与其他任何项目共享的基础算法改进而达到 $k > 1$ 。
- 人工智能具有足够清晰的架构，能够扩展到不断增加的数量上

同时保持硬件作为一个统一的优化过程，能够追求连贯的整体目标。

- 人工智能的自我改进，以及最终向快速基础设施的过渡，涉及在曲线后期阶段能力的大幅激增（因为超级智能正在
已实现，或蛋白质结构预测被充分破解以构建纳米技术的后续阶段）。这极大地放大了该人工智能相对于其最接近竞争对手的认知与技术领先时间。若最接近的竞争对手此前仅落后七天，这七天如今已被放大为一道技术鸿沟，使领先的人工智能能够关闭、隔离或限制其增长

93. 理论上，基因有时可以通过病毒感染一个物种、获取一些基因，然后再感染另一个物种的成员，从而跨越这种鸿沟。从定量和实际的角度来看，就目前所知，人科动物与黑猩猩之间的基因转移量几乎为零。

94. 同样，这两种可能性都不应被贴上“好”或“坏”的标签；无论我们最终生活在何种现实中，无论隐藏变量的设定如何，我们都应充分利用现实。

对任何它希望束缚的竞争者进行限制。最终结果是一个博斯特罗姆（Bostrom, 2006）式的“单一体”。

极度全局起飞：

- 优秀且成功的机器智能技术的涌现极大地赢-
如今我们所见的大量前瞻性原型（Hanson 2008b）。人工智能彼此足够相似，可以自由交换认知内容、代码调整和算法改进。
- 此类人工智能项目数量众多。
- 对任何单一机器智能而言，绝大多数“改进”压力
源于机器智能的全球经济总量或发表其成果的学术人工智能研究人员，而非该人工智能的内部自我修改。
尽管机器智能的全球经济在认知投资上获得了高回报，但该经济中的任何单一组成部分都无法独自实现爆发式增长。
- 任何足够庞大的机器智能都会因内部带宽不足而被迫
分裂成多个部分，各部分拥有各自的局部目标，无法作为一个协调一致的整体行动。
- 人工智能从创新的本地使用中获得的益处非常小
相较于将创新出售给众多不同人工智能所能获得的收益，保留创新秘密的收益微乎其微。因此，很少有创新被保密。（同理，斯蒂芬·金（Stephen King）创作小说时，会将小说卖给成千上万的读者，并用所得收益购买更多书籍，而不是仅仅将小说留给自己。）
- 落后机器智能的投资回报自动下降
随着机器能够“追赶”更廉价的知识（正如中国比澳大利亚增长更快），其增长速度也会提升。此外，领先机构并不会消灭或吞并落后机构（不像强国过去征服弱国那样）。
- 此前无人知晓如何解决九成蛋白质结构预测问题
其他人知道如何以 88% 的准确率解决蛋白质结构预测问题；相对领先优势很小。即便是分子纳米技术等科技，也是逐渐出现，并在许多不同地方同时涌现，伴随着大量的创新共享与交易，落后者迎头赶上；相对领先优势并未因这一转变而显著扩大。
- 最终结果是大量贸易且缺乏全球协调。（这并不一定
一件好事。参见汉森（Hanson）[2008d] 中贪婪的硬壳边疆居民。

这两个极端在许多维度上存在差异，而这些维度可能并不相关。特别要注意的是，足够高的认知再投资回报将产生赢家通吃模型和局部爆发式增长（FOOM），而与其他变量无关。为了使这一点极端到连我都认为不合理，如果存在一个简单的技巧，让你在发现它五秒后就能获得分子纳米技术和超级智能，⁹⁵ 那么下一个竞争者不太可能恰好在这五秒窗口内也发现它。⁹⁶ 将五秒视为字面时间而非隐喻，显然足够高的再投资回报几乎无论其他变量如何都会产生单一主导者。（除非可能持有“足够大的心智必然分裂为争吵的组成部分”这一立场，即使在这种情况下也可能成立。⁹⁷）还应注意，“全球”场景不必将先前文明的全部包含在其球体内。具体而言，以 200 赫兹神经元运行、没有读写端口的生物人类往往会被排除在爆发式增长之外，除非某些人工智能出于最终偏好而专门有动机帮助人类。新发现的认知算法不容易转移到没有通用串行总线（USB）端口的人类大脑中。在这种场景下，人类将相当于那些法律极其严格、阻止资本流入的新兴国家，可能永远保持贫穷。

即使有可能使认知改进跨越“人类障碍”，与投资于同类机器智能相比，这似乎不太可能提供最高的自然投资回报。原则上，你可以避开守卫、偷越朝鲜边境，开一家便利店，让朝鲜人买到其他地方同样的商品。但这不会是你投资资金的最佳方式——除非你出于对最终结果的最终偏好而关心朝鲜人。⁹⁸

95. 类似罗杰·威廉姆斯（Roger Williams）的《素数智力的变形》（The Metamorphosis of Prime Intellect, 2002 年）。

96. 一个理性主体没有趋同的工具性动机，将一个足够强大、可快速再投资的发现出售给另一个目标不同的主体，因为即使另一个主体会在一秒内为这个发现支付十亿美元，你也可以通过保持沉默五秒钟，自己充分利用这个发现并接管宇宙，从而获得更大比例的宇宙，进而获得更高的总回报。

97. 这一立场深入探讨了超出本文范围的 AI 动机问题。我将简要指出，正交性论点反对任何“心智”必须发展出索引性自私偏好从而阻碍协调的断言，即使承认“心智”具有最大的个体规模。我主要倾向于认为这种观点是拟人化的——人类出于明确的进化原因具有索引性自私偏好和群体冲突，但具有统一遗传命运的昆虫群体和整个人类大脑（同样由单一基因组控制所有神经元）似乎没有类似的协调问题。

98. 我们在决策理论方面的工作还表明，基于计算机的心智的最佳协调解决方案将涉及对彼此源代码的了解，或明确采用特定的明确决策

高度局部化的场景显然也带来了自身的挑战。在这种情况下，我们主要希望在任何给定时间点，领先项目都能在“友好 AI”上投入足够大的努力。⁹⁹ 在高度全球化的场景中，我们通过仅让部分 AI 对人类友好来获得渐进式改进，¹⁰⁰ 而局部场景则是赢家通吃。

（但要让众多人工智能中的一个保持友好，确实仍需要某人在全球人工智能生态爆发之前解决相关的技术问题；而认知再投资相对更高的回报会缩短解决该问题可用的时间。）我个人的期望倾向于情景（1）——例如，在谈论那个会爆发的事物时，我通常使用单数而非复数。这主要是因为，我预期认知再投资的回报足够大，足以主导我对其他变量的大部分不确定性。在较小程度上，现代机器智能方法的多样性和不兼容性给我留下了深刻印象，但在这一点上，我尊重汉森关于为何这可能预期会改变的论证。开源国际象棋程序的出现，无疑因算法改进的更多共享而带来了更快的进步，这一点与汉森的论证相结合，使我显著地转向认为生态情景并非完全不可想象。局部趋势与全局趋势结果之间的差异也可能小到取决于政策决策。也就是说，隐藏变量的设定可能最终是这样的：如果我们希望看到一个“友好的单一体”，而不是汉森式的竞争性人工智能的“贪婪硬渣边疆”，那么创建一个“友好”的项目是可行的，该项目在研究优势（资金、计算资源、聪明的研究人员）上足以超过下一个非“友好”的竞争者。

理论。在这里，要验证一个人是否值得信赖并会遵守其协议要困难得多，这意味着人类可能“自然地”倾向于被排除在机器心智之间发展出的任何协调均衡之外，除非存在特定的最终偏好将人类纳入其中。

99. 价值复杂性（Complexity of Value）子论题中的价值脆弱性（Fragility of Value）意味着，解决友好性问题主要是一个具有尖锐阈值的满意化问题，正如拨对我电话号码的十分之九并不能让你联系到某个与埃利泽·尤德科夫斯基（Eliezer Yudkowsky）90% 相似的人。如果脆弱性论题是正确的，我们并没有强烈的动机让领先项目在友好人工智能（Friendly AI）方面比第二名项目好 1%；相反，我们有强烈的动机让它做得“足够好”（尽管这最好包括一些误差余量）。不幸的是，价值复杂性论题意味着“足够好”的友好性涉及巨大的（尽管是有限的）困难。

100. 假设在一百万个合作的机器智能中有一个友好人工智能，这意味着宇宙的百万分之一将被用于人类认为有价值的目的。这实际上是相当多的物质和能量，任何对人口或寿命感到边际效用递减的人可能会认为这种情景承载了大部分效用。

竞争者后来成为单一体。¹⁰¹ 即使在一个全球情景是默认结果的世界中（例如，来自开源人工智能项目），只要隐藏变量没有过于偏向那个方向，这也可能是真的。

3.10. 引发智能爆炸的最低条件

I.J. 古德 (I.J. Good) 谈到智能爆炸始于一个“超智能……

一台能在所有智力活动上远超任何人的机器，无论多么聪明。”这个条件似乎是充分的，但远非必要。

自然选择并没有远超任何人的每一项智力能力——它无法撰写关于计算机科学和认知算法的学术论文——然而它还是孕育出了人类水平的智能。¹⁰² 事实上，自然选择通过点突变、随机重组和统计选择的优化过程构建了人类——没有预见性、显式世界建模或认知抽象。这在原理上强有力地界定了输出人类水平智能设计所需的算法复杂度的上限。

自然选择确实运用了海量的计算蛮力来构建人类。“朴素”的估计是，自然选择在偶然产生人类之前，搜索了 10^{30} 到 10^{40} 个生物体 (Baum 2004)。人择考虑（其他行星是否有生命但没有智能生命？）意味着真实数字可能几乎任意地更高（见 3.8 节）。

机器学习有一个重要的子领域，部署进化计算（受突变/重组/选择启发的优化算法）来尝试解决现实世界的问题。该领域的工具箱包括“改进的”遗传算法，至少在某些情况下，这些算法似乎比你可能想写的第一种“进化”算法快几个数量级地演化出解决方案（例如，Pelikan、Goldberg 和 Cantú-Paz 的贝叶斯优化算法 [2000]）。然而，如果你期望能够采用进化计算并让它输出一个例如蜘蛛级别的生物体，你将大失所望。生命开始后，复杂细胞的出现大约花了十亿年。遗传算法可以设计有趣的无线电天线，或许类似于某种化学酶。但即使有百倍的加速，现代遗传算法似乎使用的蛮力仍然太少，无法走出 RNA 世界，更不用说达到

101. 如果智能爆炸微观经济学告诉我们，算法优势相对于硬件来说是巨大的，那么我们最关心的是“好”项目拥有最聪明的研究人员。如果硬件优势相对于研究人员智力中合理的方差来说是巨大的，这使我们更关心“好”项目拥有最多的计算资源访问权。

102. 人类算作人类等效智能。

寒武纪大爆发。设计一个蜘蛛等效的大脑将远远超出当前进化算法在当前硬件上运行合理时间所能达到的累积优化能力。

在光谱的另一端，人类工程师在特定能力上经常胜过自然选择，尽管人类工程师存在的时间只是极小的一部分。（轮子胜过猎豹，摩天大楼胜过红杉树，土星五号胜过猎鹰等。）似乎相当合理的是，人类工程师在相对于进化总代数而言较短的时间（甚至串行因果深度）内工作，就能成功创造出人类水平的智能。

然而，当前的 AI 算法远未达到这种……我们称之为“利用搜索空间规律性”的水平，尽管这只是关于人类智能的一种可能解释。即使扩展到所有试图自动设计小型系统的 AI 领域，很明显，自动设计目前仍远不及人类设计。无论是当前硬件上运行的 AI 算法，还是从事 AI 研究约六十年的人类工程师，都尚未引发智能爆发。我们知道两种“算法智能 + 搜索量”的组合，它们尚未输出足够的累积优化能力来引发智能爆发。但这留下了很大的可能性空间：一种比自然选择显著更“高效”的 AI，同时比人类计算机科学家显著更不“智能”，却可能开始智能爆发。也许 AI 做出的优化不如人类计算机科学家智能，但它会做出更多这样的优化。而且，AI 在搜索设计空间中的单个点数量上会比自然选择搜索生物体少得多，但会比自然选择更高效地穿越搜索空间。

而且，与自然选择或人类不同，AI 发现的每一项改进都可以立即再投资于其未来的搜索。自然选择构建了直立人之后，并没有使用直立人水平的智能来考虑未来的 DNA 修改。因此，AI 可能不需要比自然选择多太多的智能，就能首先构建出显著优于自身的东西，然后部署更多智能来构建未来的后继者。

以我目前的知识状态，我缺乏强有力的信息来不担心随机的人工智能设计跨越“比任何过去同等或更高智能的算法（包括人类计算机科学家）搜索过更多点，并且比任何过去搜索过同等数量案例的算法（包括自然选择）更智能”的前沿上的任何一点。这一前沿一直在推进，而至今尚未发生快速智能爆发，因此，根据拉普拉斯继承法则或类似的未知先验，我们应当赋予下一次跨越引发快速智能爆发的概率远低于 50%。另一方面，

我们应当赋予在“效率跨越计算”或“智能跨越蛮力”的前沿上的某次跨越，在未来的 N 十年内某个时刻引发智能爆炸的概率高得多。

我们目前的知识也保留了这样一种可能性：在没有难以承受的巨量计算的情况下，半智能优化无法再投资并累积到与人类相当的智能——正如你无法通过反复对自身运行优化编译器来实现智能爆发（FOOM）一样。这里的理论是，小鼠在修改小鼠方面很难做得比随机更好。在这类情景中，对于研究项目能够负担的任何合理计算量（即使考虑到摩尔定律），你都无法制造出一个能比任何人类计算机科学家更好地构建人工智能的人工智能，直到该人工智能足够聪明，能够真正从事计算机科学。在这种可能性范围内，人类计算机科学家必须继续开发自己对人工智能的改进，直到该人工智能达到能够进行与人类竞争的计算机科学的水平，因为在那之前，该人工智能自身无法进行太多推动。¹⁰³ 相反，为了给智能爆发起始水平设定上限，考虑人工智能版的约翰·冯·诺依曼，以比以往人工智能设计者更大的串行深度和并行宽度探索计算机科学。人们会期望这个人工智能如果可能的话，会引发智能爆炸。在这种情况下，我们超越了人类优化数量和优化质量的前沿，所以如果这个人工智能不能构建比自身更好的东西，人类也不能。“快速并行冯·诺依曼”似乎是一个合理的实用上限，用于衡量机器智能在不具备引发智能爆炸能力的情况下能有多聪明，或者在智能爆炸进入瞬发超临界模式之前能有多聪明，假设这完全可能。由于真实值不太可能恰好达到上限，我猜测智能爆炸会在此之前很久就开始。相对于我目前极大的不确定性，我的中位数估计会在中间某处：它需要的远不止改进的优化编译器或改进的遗传算法，但显著少于快速并行冯·诺依曼，

103. “友好”人工智能提案很可能故意呈现出这种情形，因为在友好人工智能中，我们可能希望让人工智能依据行动准则证明自我修改的正确性——让人工智能以高标准的自我理解为约束，从而在改变自身时保留其设计中的重要品质。这可能意味着“友好”项目在允许其人工智能进行某些自我改进之前，会额外增加大量延迟，即使该项目在其他方面拥有更多硬件或更聪明的研究人员，这相对于约束较少的竞争者也是一个显著劣势。（不过，在能够“净化”建议或证明某类改进不会引发灾难性错误的前提下，正在开发中的友好人工智能或许无需具备计算机科学能力，也能实施重要的自我改进。）

（在非友好人工智能项目中）引发智能爆炸；友好人工智能项目则刻意要求人工智能在被允许自我修改之前具备额外的计算机科学能力。这一分布主要基于先验无知，但范围似乎很宽，因此靠近端点的子范围应当相对较窄。

这一范围远未达到 I. J. 古德所定义的“超级智能”。一个仅在构建人工智能方面与快速并行冯·诺依曼机相当的人工智能，未必需要在所有类型的智力活动中都远超人类。例如，它可能非常擅长计算机科学，却尚不擅长对人类进行魅力操控。I. J. 古德所关注的假设，似乎远超过足以得出其智能爆炸结论所需的程度，而遗憾的是，这可能会分散人们对那些可能就足够的、弱得多的假设的注意力。

3.11. 未知未知数的回报

分子纳米技术是一个相当新的概念，十九世纪的人类并没有预见到它的到来。有一个重要但危险的类比：二十一世纪相对于十一世纪可以施展魔法，然而一千年并不是很长的时间；对于黑猩猩来说，人类简直是不可理解的，但我们的大脑设计甚至并没有那么大的不同；因此，我们应该赋予显著的概率，认为在提高速度（串行时间、因果深度、更多那种将人类历史的二十一世纪与十一世纪分开的距离）或改进大脑算法（更多那种将原始人类与黑猩猩分开的东西）方面的回报，最终将带来几乎任何能力。

这甚至可能包括违反我们目前认为的物理定律的能力，因为我们可能并不知道所有相关的定律。当然，仅仅因为我们的标准物理模型可能在某些地方是错误的，我们不能得出任何特定错误是可能的结论。而且新发现不一定带来积极的消息；现代物理学暗示了许多十九世纪不知道的限制，比如光速极限。尽管如此，一个理性的机构将选择性地寻找我们不知道的有用物理可能性；它将故意利用我们不知道的任何定律。在完全普遍的意义上怀疑未来能力可能在某处超过二十一世纪标准模型所暗示的上限，这并不是超自然主义。

一个重要的警告是，如果超光速旅行以任何方式成为可能，那么大寂静/费米悖论（“它们在哪里？”）将变得更加难以解释。这给了我们一些理由相信，没有人会永远发现任何形式的“魔法”来实现超光速旅行（除非它需要一个本身必须以亚光速旅行的超光速接收器）。更一般地说，这给了我们一个进一步的理由去怀疑任何未来的魔法，其形式是“你们的物理学家不知道 X，因此它”

“可能做到 Y”这一可能性，将为许多机构提供以可观测方式实现 Y 的机遇。除了对现代物理学的信心之外，我们还有进一步的理由相信时间旅行是不可能的（至少不存在任何形式的时间旅行，能让你回到时间机器建成之前），并且现实中不存在任何微小的漏洞，即使是超级智能也无法利用它来实现这一点，因为我们的现实世界并没有充满时间旅行者。更一般地说，一个理性机构会系统性地、有选择地寻找先前未知的、异常高投资回报的机会，这一事实表明，在与比我们更聪明的存在打交道时，对未知的未知的期望通常应推动预期回报上升。真实的物理定律也可能意味着异常糟糕的投资可能性——甚至可能是十一世纪无法想象的更糟糕的投资，比如一种仅需一分钱却可能损失千万亿美元的衍生品合约——但超级智能不会对这些特别感兴趣。未知的未知增加了普遍的方差，但理性机构会在这个方差上朝正方向进行选择。

从我的角度来看，“未知的未知的回报”、“魔法的回报”或“超级智能比我更聪明并想到我未曾预见到的可能性的回报”的可能性主要告诉我：(1) 智能爆炸可能比我预期的更快地发生；(2) 试图约束一个比你更聪明的机构在现实世界中的能力，从根本上说是不可靠的；(3) 我们可能只有一次机会来构建一个比我们更聪明、且不会对我们所关心的未来属性漠不关心的存在。但我已经相信了所有这些；因此，从我的角度来看，考虑未知的未知回报的可能性几乎没有增加进一步的边际建议。

其他持有不同背景信念的人可能会提出一个完全不同的政策，其可取性（鉴于他们的其他信念）主要取决于此类未知未知因素的缺失——换言之，该政策的可行性依赖于政策提出者能否成功界定某个比人类更聪明的智能体的机会空间。这将导致一种理性上令人不快的局面，因为“未知未知回报的论证”似乎应当是无法被驳倒的，而一个无法被驳倒的论证意味着它对现实不敏感。¹⁰⁴ 此时我忍不住想说：“谢天谢地，这

104. 事实上，我写下这些话时，正疲惫地预感到有人会声称，整个 AI 走向 FOOM 的论点，既然可以由未知未知回报来支撑，实际上就是不可驳倒的，因为魔法论证不可驳倒，因此硬起飞论点无法被任何论证驳倒，因此对它的信念对现实不敏感，因此它是错误的。我悲观地预言，指出整个论证本应承载

不是我所关心的，因为我的政策提案本来就旨在成为超级智能能想到我所未想之事时的最优回应。”然而，尽管有这种诱惑，这种轻描淡写的回应似乎对辩论的另一方缺乏足够的同情。而且我并不确定应该建立什么样的程序来论证“未知未知回报”的可能性，以便在一个实际上不存在显著未知未知回报的世界里，你能够以高概率推断出不存在未知未知回报，并据此制定计划。

我确实认为，依赖于界定比人类更聪明的能力的提案，可能反映出对真正比你聪明的事物这一概念缺乏适当的认识和尊重。但同样不正确的是，未知未知的前景意味着我们应该给一个比人类稍微聪明一点的存在在五秒内接管宇宙分配概率一，而且我们对于较小的“不可能性”的实际概率分布应该是什么也不清楚。我选择我的政策提案使其对该估计不高度敏感，这并非巧合。

4. 迈向形式化的三个步骤

卢西奥·鲁索（Lucio Russo，2004 年）在一本主张科学早在两千年前就已发明而后被遗忘的书中，将精确科学定义为一组理论公设，其推论可通过无歧义的演绎得出，而这些演绎推论又能进一步与现实世界中的对象相关联。例如，按照这一定义，欧几里得几何可被视为最早的精确科学之一，因为它从公设出发，同时也告诉我们测量现实三角形三个内角时应预期什么。

广义而言，一个理论在多大程度上是形式化的，我们就能在多大程度上无需争论地说出该理论预测了什么，即使我们仍在争论该理论是否真的为真。在某些情况下，一个理论可能以看似形式化的公理呈现，然而它与经验——与可直接观察的事实——的关系可能具有足够的弹性，以至于人们仍在争论一个公认的形式化预测是否真的已经实现。¹⁰⁵ 这在经济学中常常如此：存在许多正式设定的宏观经济学模型，但它们与经验的关系足够模糊，以至于很难判断哪些模型（如果有的话）近似为真。

没有未知的未知，因此它出现在最后一小节，不会对这个精彩的反驳的重复产生任何影响。

105. 另一个边缘情况是形式精确的理论，其精确预测我们缺乏计算能力来计算，导致人们争论该理论的演绎推论，即使该理论的公理已被完全指定。

形式化的意义何在？一种回答是，通过使理论形式化，我们可以计算出仅凭脑海中的直觉无法计算的精确预测。在顺利的日子里，这些精确预测可能无歧义地与经验相关联，而在真正美妙的日子里，这些预测实际上会成真。

但这并非形式化有益的唯一可能原因。为了使理论的推论能够接受无歧义的演绎——即便随后还需进一步论证如何将这推论与经验相联系——我们必须使理论的机制明确化；必须将其从我们思维的幕后移至纸面，以便接受更严格的审视。这或许是我们尝试更形式化地分析智能爆炸所能获得的主要益处——它将揭示先前非形式化论证所必需的内部机制。它还可能揭示我们先前认为高度合理的命题所蕴含的惊人推论，而若将整个理论置于直觉思维之中，这些推论便会被忽视。基于此，我建议按如下方式处理将先前关于智能爆炸的非形式化立场形式化这一总体问题：

1. 将立场转化为关于增长曲线的微观基础假设——即关联累积投资与产出的定量函数。不同立场可能对“投资”与“产出”有不同的概念，对增长曲线如何相互影响也有不同的理解。我们希望以足够的严谨性来规定基本可能性，使其推论成为形式演绎而非人为判断：在 X 随 Y 呈指数增长的可能性中，若 Y 已被量化，则所声称的 X 量应通过计算而非判断得出。
2. 明确说明任何特定立场如何声称（组合的）增长曲线应与历史观测或其他已知事实相关联。以可直接与理论的形式可能性相比较的格式量化相关历史观测，从而能够形式化某一立场关于某范围内某些可能性已被证伪的主张。
3. 明确立场关于基本可能性的规律性或不规律性（或先验概率）的任何进一步假设。明确立场关于不同可能性如何可能相互约束的一致性假设（曲线 A 应位于曲线 B 之下，或应与曲线具有相同形状

C).¹⁰⁶

106. 在贝叶斯意义上，这对应于对多条曲线赋予非独立的联合或条件先验概率。

在将历史经验与理论可能性相关联的步骤中，允许证伪或更新与曲线拟合有着重要区别——这并非试图找出一条“最佳”拟合人类进化历程之类的单一曲线。假设我们知晓一条单一、精确的曲线，在许多情况下似乎超出了我们知识的现状；例如，我们不应假装确切知道自然选择从直立人（*Homo erectus*）演化到智人（*Homo sapiens*）的难度。为了得到具有适当宽可信区间的预测——一种准确反映不确定状态的预测——模型空间中应存在一些规则曲线的空间，这些曲线的组合与特定的历史现象相关。原则上，我们将证伪那些与观测历史不符的组合，并对剩余部分进行积分（或采样）以得出预测。

关于智能爆炸的一些广为人知的立场确实依赖于紧密拟合一条曲线（例如，摩尔定律（*Moore's Law*））。这并非完全荒谬，因为一些历史曲线实际上高度规则（例如，摩尔定律）。通过转向贝叶斯更新而非仅仅证伪，我们可以提升模型空间中那些能狭窄预测观测曲线的部分——即那些将更多概率质量集中于预测该确切结果的部分。这将暴露关于似然函数的假设，并使判断假设曲线精确是否合理变得更加明显；如果我们对过去进行贝叶斯更新，我们能否得到对未来的狭窄预测？为了得到对未来的狭窄预测，我们需要假设什么？摩尔定律在过去实际上有多稳定？——因为如果我们的建模技术甚至无法产生那种程度的稳定性，并且产生向各个方向发散的可信区间，那么我们的更新力度不够，或者我们的先验过于无知。

第一步是分别对一个或多个当前立场和发言者执行这一过程，以揭示并量化其论证背后的形式假设。在第一步结束时，你将能够说：“这是一个模型空间，看起来像发言者 X 所谈论的内容；这些是 X 认为被这些历史经验所证伪的增长曲线或增长曲线组合，或者 X 基于其对历史经验的狭窄预测给出强贝叶斯更新；这是 X 关于这些可能性如何被约束以相互一致的想法；这是 X 认为由模型空间中未被证伪且一致的部分对智能爆炸做出的最终预测。”形式化的第一步大致相当于查看是否存在任何一组曲线，使得发言者的论证能够成立；明确他人曾论证可能性被过去经验排除的场合；并揭示所假设曲线中的任何可疑不规则性。第一步不会得出

关于智能爆炸的确定性答案，但应迫使假设被更清晰地陈述，可能暴露一些荒谬之处，展示一组假设还意味着什么，等等。大多数情况下，第一步是关于明确对智能爆炸的立场，每个立场被单独且孤立地考虑。

第二步是尝试建立一个共同的、整合的多立场模型，该模型将第一步中形式化的多种立场纳入其中——这个模型包含许多不同种类的增长曲线，其中一些可能（在某些观点看来）已经被历史观察所证伪——一个共同的构建模块池，可以被选择和组合，以产生第一步中的各个形式化表述。第二步的主要成果将是（a）一个用于讨论合理增长曲线的系统性共同格式，以及（b）一个大型表格，列出哪些假设产生哪些结果（据表格编制者所称），以及各种论证声称哪些历史观察对这些假设构成问题。我认为这一步旨在明确理论之间的比较：揭示存在于一种立场而非另一种立场中的可争议的不规则之处，并使读者能够更好地评估所谓更优匹配与更简单假设之间的优劣。第二步还不应试图对论证的相对合理性采取强硬立场，也不应产生关于智能爆炸的确定性预测。相反，其目标是使立场之间的比较更加形式化和模块化，同时不遗漏非正式论证的任何重要方面——在统一的表示中形式化立场之间的冲突。

第三步将是一个更为宏大的项目，即提出一个据称唯一正确的描述，描述我们对智能爆炸的不确定信念状态：

- 形式化一个足够宽广的模型空间，使其很可能包含类似现实的东西，并可信地期望在其空间中包含一个点假设，该假设能够很好地拟合，

即使不能精确表示，也能拟合实际构成智能爆炸基础的任何因果过程。也就是说，模型空间不会狭窄到这样的程度：如果现实世界的增长曲线实际上是双曲线型直至其上限，我们事后将不得不自责，因为模型中没有假设组合可能产生双曲线。¹⁰⁷

- 在这个模型空间上，根据简单性和规律性对先验概率进行加权。

107. 换句话说，目标是避免“你的假设空间中完全没有类似现实的东西”这类错误。贝叶斯概率的许多重要定理在假设空间中没有任何类似现实的东西时并不适用。

- 将因果假设的组合与观测历史相关联，并进行贝叶斯分析更新。

- 对更新后的模型空间进行采样，以获得答案上的概率分布关于智能爆炸的任何问题。

- 微调模型的比特位，以获得答案倾向程度的敏感性分析

当您对事物进行略微不同的建模时，结果会有所变化；删除模型的某些部分，以检验一致性假设在多大程度上能够根据剩余部分预测被删除的部分，等等。

如果第三步做得明智——先验反映了适当的不确定性广度——并且在数据稀缺时没有完全陷入形式统计学习的基本困难，那么我预期任何这样的形式化都会主要产生关于少数可回答问题的定性是或否答案，而不是产生关于智能爆炸内部过程将如何运行的狭窄可信区间。少数是或否答案大约是我认为对该主题合理可实现的把握所应允许的提前预测水平——我们不应该在观察到智能爆炸之前就提前知道关于它的大部分事情——我们应该只有少数罕见的情况，其中问题具有高度可能但粗略的答案。

我认为其中一个答案是“人工智能会迅速爆发吗？是的！人工智能会迅速爆发！”但我并不假装能够断言它会以每秒 120,000 纳爆发（nanofooms）的速度进行。

即便在这一层面，覆盖模型空间、给出合理的简单性权重、正确关联历史经验以允许证伪与更新，并得出理性预测，都将是一项相当宏大的工作，且极易出错。尽管如此，我认为第三步原则上描述了在我们当前观测集合下，理想的贝叶斯答案会是什么。换言之，我之所以支持人工智能走向快速爆发（AI-go-FOOM）的答案，是因为我认为我们的历史经验证伪了大多数不会产生快速爆发的认知投资常规增长曲线。

学术争论通常不会在某人推进到产生仿真阶段后就得到最终解决。值得注意的是，宏观经济学家仍在争论，例如，应该稳定通货膨胀还是名义国内生产总值（NGDP）以最大化实际增长。另一方面，宏观经济学家通常希望得到比我们对智能爆炸预测所能合理要求的更精确的答案。如果你满足于诸如“呃，在其他条件不变的情况下，当银行明显增加贷款时，通货膨胀或许应该上升而不是下降？”这样的模型预测，那么与询问通货膨胀是否会高于或低于 2.3% 相比，期望得到确定性的答案可能更为合理。但即便你试图构建第三步的模型，它

可能仍然有些天真地认为你真的能取回答案，更不用说期望其他人都信任你的模型了。就我而言，我认为我对第三步模型的信任程度，很大程度上取决于其论证在简化后是否依然有效，同时还能得出相同的净预测，并且没有被历史证伪。当复杂论证存在能给出大致相同答案的简单版本时，我会更加信任它们；如果没有“聪明的头脑会造出更聪明的头脑”这个更简单的版本，我对增长曲线的论证就不会那么有信心。如果模型告诉我一些出乎意料的事情，但我能将同样的论证翻译回更简单的语言，并且模型在几次交叉验证的推动下仍能产生相似的结果，我可能会相信它。无论如何，我们可以合理地希望，完成第一步、继续第二步、并向第三步推进，将会产生有趣的结果，即使第三步从未完成，或者以几种不同的方式完成。¹⁰⁸ 形式化的主要意义不在于它给出最终且权威的答案，而在于它有时能揭示出那些若不尝试将事情明确化就发现不了的要点。

5. 期望信息价值：我们想知道什么与 我们可能弄清楚什么

关于智能爆炸，我们想知道的事情与我们能够合理期望弄清楚的事情之间往往存在不匹配。

例如，机器智能研究所（Machine Intelligence Research Institute, MIRI）的每个人都想知道，距离人工智能领域的普遍进展可能引发智能爆炸还有多少时间。从政策角度来看，这将是极其有用的知识，如果你能精确到具体年份，你可以在那之前刷爆信用卡。¹⁰⁹ 但是——与许多其他未来学家不同——我们看不出如何能合理地获得关于这个问题的强信息。

汉斯·莫拉维克（Hans Moravec）是最早使用摩尔定律预测强人工智能的主要人物之一，他在其 1988 年的著作《心智儿童》（Mind Children）中花费了大量篇幅，试图让读者相信一个令人难以置信的命题：摩尔定律实际上可以持续不断地延续下去，直到产生能够执行——天哪！——一百万亿次浮点运算的超级计算机。

这足以“与人类大脑的计算能力相媲美”，正如莫拉维克（Moravec）利用当时对视觉皮层及其模拟难度的了解，对这一等价关系进行了相当详细的推算。我们获得的超级计算机

108. “戴一块表的人知道时间；戴两块表的人永远无法确定。”

109. 是的，这是个笑话。

莫拉维克认为 2008 年所需的超级计算机，比他预测的时间提前了几年；但事实证明，现实运作的方式并非宇宙会检查你的超级计算机是否足够大，然后开启其意识。¹¹⁰ 即使这主要是硬件而非软件的问题，“所需硬件”的阈值水平也会比摩尔定律（Moore's Law）更加不确定，而一个可预测的数乘以一个不可预测的数，结果仍是不可预测的数。因此，尽管关于默认人工智能时间线的信息价值极高，但我们预期正式建模能够更新我们对这一数量的信念的可能性很低。我们大多会预期建模正式地告诉我们：“由于这一数量取决于许多你不确定的变量的合取，你对这一数量非常不确定。”对模型进行试探和推敲，看它是否有出人意料之处，是有一定意义的——但我大多预期，鉴于我们的知识状态，我们实际上无法对默认人工智能到来时间线产生紧密的置信区间，因为这个数字敏感地依赖于许多我们不知道的不同因素。因此，我强烈地表达规范性不确定性：“我不知道是哪个十年，你也不知道！”（即使是这种“不知道”，仍必须对应某个关于十年的概率分布，只是不是紧密分布。我目前正与卡尔·舒尔曼（Carl Shulman）探讨为何我的中位数比他的中位数提前了四十五年。我们都不认为能精确到十年——两种情况下的置信区间都非常宽——但我们“不知道”之间的差异大到不容忽视。）一些政策所依赖的重要问题——我希望获得信息、且似乎有合理机会产生新信息、并与政策直接相关的问题——如下：

- 智能爆炸由相对较笨的

比我们更容易自我修改的人类人工智能？（这与政策相关，因为它告诉我们何时开始担忧。我并不特别清楚如何获得这一信息，但我也未看到有力论证表明我们必须对此保持无知。）

- 在接近大致附近的自改进曲线的斜率是多少

人类水平的智能？我们是否有信心届时它会“突飞猛进”，而不是直到后来才放缓？或者是否存在一些合理且可能的情景，即人类水平的智能本身就是作为一次

110. 另见《严厉的月亮》（Heinlein 1966）以及众多其他科幻故事，它们都做了同样的假设（大型计算机 = 智能，或复杂计算机 = 意识），以此作为将人工智能引入故事的廉价方式。另一部科幻小说《应许之地的死亡》（Cadigan 1995）将此比作古代理论，即脏衬衫和稻草会自发产生老鼠。

自我改进曲线是否已经耗尽了所有容易取得的成果？还是人类研究者将人工智能推到了那个水平，而它尚未进行多少自我改进？（这具有政策相关性，因为它决定了在通用人工智能以如此明显的形式出现、以至于人们真正注意到之后，世界是否有任何实质性的机会做出反应。）

- 早期我们更可能看到相对平滑还是相对“颠簸”的增长曲线

智能爆炸的阶段？（政策相关性在于，足够平滑的增长意味着我们可以对当前增长缓慢的有前景的系统不那么紧张，同时需牢记，一堆铀砖尽管在物理上具有连续行为，但对于政策目的而言其平滑性不足。）

另一类在实用实践中值得分析的问题，是那些更形式化的论证可能对外部学者更易理解的问题。例如，我希望通过对认知再投资回报进行形式化建模，并用历史观察约束这些曲线，能够以一种对该领域新手更易接近的方式预测“人工智能迅速爆发”。¹¹¹但即使被正式告知“人工智能迅速爆发”，我也几乎不会获得个人收益，即使置信度很高，因为这是我基于“非正式”论证已经赋予高概率的事情，所以我不会改变政策。只有承诺产生政策转变的预期信念更新才能产生信息的预期价值。

（在正式建模向我揭示的理由表明我对快速爆发式增长（FOOM）完全判断错误的情况下，这将导致剧烈的政策转向，因此信息价值极高。但这一结果至少对我来说会是令人惊讶的；我多半预期得到的答案是“人工智能会快速爆发式增长”，或者更可能的是早期建模尝试给出的“不知道”。）但从实用角度讲，如果我们能够良好地形式化模型空间，并且它确实产生预测，那么将其妥善撰写成文将是一件非常有益的事情。

因此，从实用角度而言，这个特定问题值得花时间解决。

其他一些问题，我承认已形成初步观点，但更正式的论证将具有价值，而其中出人意料的薄弱之处自然更具价值：

111. 当然，我会尝试运用安娜·萨拉蒙（Anna Salamon）的纪律，如果一项先验上看似可信的建模尝试得出结论说“人工智能绝对不会走向爆发式增长（FOOM）”，我会变得好奇。现实地说，我可能无法阻止自己预期在模型中找到问题。但我也尽量不施加更高的证明标准，尽量以同样怀疑的眼光看待那些似乎与我先前信念一致的部分，并且通常不会把新证据抛诸脑后，也不会成为那种对任何事情都无法改变想法的人。而机器智能研究所（MIRI）的其他人以及感兴趣的外部人士，其先前信念则不会那么强烈。

- 人类智能是否是可能性的极限？是否存在“通用智能”
定理”如格雷格·伊根（Greg Egan）所言，即不存在任何在质上比人类更聪明的存在？
- 古德（I. J. Good）关于智能爆炸的原始论证是否成立？
是否会出现一次历史上前所未有的智能激增，在势头耗尽之前达到强超级智能的水平？
- 智能爆炸将是相对局部的还是相对全球的？这是发生在单一智能内部的事情，还是整个世界经济的一个宏大功能？我们应当预期看到一个由许多相互交换数据的人工智能项目发展而来的文明，其中没有单一的人工智能变得比其他更强大；还是应当预期看到一个人工智能单一体（AI Singleton）？ 112

我希望能够获得相关数据的政策相关问题，但我认为不太可能获得强有力的数据，或者微观经济学方法论对此似乎没有太多可说的：

- 距离人工智能领域取得普遍进展可能还需要多长时间
生成一个成功的通用人工智能项目？
- 对一个人工智能项目而言，更聪明的研究者与千倍算力相比，价值几何？
- 单个 AI 项目即将失控的首要警示信号是什么？

人工智能在走向爆发式增长前是什么样子？

更一般地，对于每一个听起来有趣的命题 X，我们都应关注某项研究声称得出的任何有力结论，例如：

- 绝对不是 X，因为带有 X 的模型强烈暗示了看起来像这样的增长曲线
仿佛它们会违背我们以往的历史经验，或者曲线一旦超出我们已观测部分所对应的区间，就必须经历某些特定的、无法解释的不规则变化。（对于有时被提出的“人工智能将发展到人类水平然后停滞”的情景，你可能会预期这类判断。）
- 肯定是 X，因为几乎所有我们发明并拟合历史数据的因果模型
经验，随后被调整以探究自我改进型人工智能可能引发的情形，

112. 在此我对事件的“自然”进程有些不确定，但我个人好奇心较少，因为即使这是一个适度“非自然”的结果，我仍将尝试构建一个能够实现局部快速爆发（FOOM）的友好人工智能（Friendly AI）。

在几乎所有可信区间内，无需进一步调整即可得到 X。

（我认为我们应该这样形式化那个非正式论证，即为什么我们应该预期人工智能会经历智能爆炸，鉴于自然选择在人类演化过程中似乎并未遇到硬件或软件障碍等。）

- 我们确实不知道是 X 还是非 X，而且其他任何人也不可能知道

要么。所有合理的模型都表明，X 随 Y 和 Z 强烈变化，而且没有任何合理的方式能让任何人知道 Y，即使他们知道，他们仍然不会知道 Z。¹¹³（我们可能合理期待的那种针对“没有人知道强人工智能的时间线”的形式化分析）。因此，一个理性的主体应该使用这种高度无知的先验，在广泛的可靠区间上分配概率，并据此行动，为多种可能的结果进行规划和准备。（注意，在某些情况下，这本身就等同于一种反预测，即强烈排除一个只占据可能性空间狭窄范围的“特权”可能性。如果你肯定无法在宽对数尺度上预测某事物，那么作为主观概率，它不太可能处于某个最佳点的三倍因子范围内，而需要该最佳点的情景在先验上就是不可能的。）

6. 智能爆炸微观经济学：一个开放问题

我提出的智能爆炸微观经济学项目可以总结如下：

将关于智能爆炸的立场形式化为微观基础增长曲线及其相互作用，明确过去的观察据称如何约束这些可能性，并基于此类更新正式预测未来结果。

这反映了一种关于方法论的具体想法，更一般地，这个开放问题可以这样提出：

系统地回答这个问题：“关于认知再投资的增长率，我们认为我们知道什么，以及我们认为我们是如何知道的？”

胜任地完成整个项目直至第三步，可能是一个博士论文规模的项目，甚至是一个需要大量资金的多研究者项目。第一步的调查可能可以作为较小规模的项目进行，但仍然会很困难。

113. 卡特娅·格雷斯科抽象地观察到，X 可能仍然（已知）与某个可观测的 W 强相关，这是一个合理的观点。

机器智能研究所（MIRI）对在此问题上取得可信进展抱有浓厚兴趣，这类进展有望化解我们内部的实际争论与政策分歧，但这要求极高的工作标准（形式化模型须与高度成熟的非形式化模型相抗衡），并需充分信任研究者未带有任何特定方向的强烈偏差（动机性认知），包括偏向于使结果呈现中立（动机性中立）或不确定（动机性不确定）的偏差。唯有当预期“获得我们尚未知晓的真实答案的希望与项目资助成本之比”足够高时，我们才会资助此项目。潜在的研究者应具备：

- 具备一定的数理经济学（Mathematical Economics）先修经验。若不具备，至少至少具备一些标准数理经济学知识，并且能够建立和求解微分方程。
- 具备足够的统计预测/机器学习经验，以了解会发生什么
当你试图拟合一个包含大量参数的模型，却没有进行正则化和交叉验证时。
- 对所有那些复杂方程含义具有可证明的强烈直觉：
做一个会问出“但如果总是需要指数级增大的大脑才能换来线性的智力提升，那你怎么解释人类大脑尺寸与黑猩猩大脑尺寸的对比？”的人
- 对认知科学文献和/或基本认识论有足够的熟悉度
您明确知晓并警惕的技能包括：动机性轻信、动机性怀疑、打包与拆解、专家过度自信、合取谬误、密立根油滴实验的历史等。理想情况下（尽管并非必需），您还应熟悉一些本地发展的概念，如动机性停止与继续、动机性中立、动机性不确定性等。
- 能够以可证明的方式撰写结果以供发表。我们非常重视使结果易于公众理解，同时也重视了解
这些结果本身。
- 事先熟悉关于智能爆炸的文献（包括我们自己的文献）并不在此列表中。此类了解可以在之后获得
通过浏览（少数）先前的非正式辩论，并直接与（少数）主要参与者交谈，以确认您对其立场的解读。

这听起来可能标准很高，且工作量巨大——但我们讨论的是对一种假想的未来现象进行规范增长率分析所需的条件，即 I. J. 古德智能爆炸，如果它确实存在，很可能是地球起源的智能生命历史上最重要的现象。如果事实上在我们的望远镜范围内没有

外星人，那么智能爆炸将合理地成为决定可见宇宙未来的最重要事件。关于智能爆炸任何可预测方面的可信信息都是极有价值且重要的。

为了促进关于智能爆炸微观经济学的高质量研究，MIRI 为合格的研究人员设立了一个私人邮件列表。MIRI 将首先在该邮件列表上发布其关于该主题的研究，其他研究人员也可以这样做。如果您想申请加入此邮件列表，请联系 MIRI 获取说明 (admin@intelligence.org)。

致谢

感谢卡佳·格蕾丝 (Katja Grace) 在研究方面提供的协助, 以及卡尔·舒尔曼 (Carl Shulman)、保罗·克里斯蒂亚诺 (Paul Christiano)、卢克·穆尔豪瑟 (Luke Muehlhauser)、卡佳·格蕾丝 (Katja Grace)、卡伊·索塔拉 (Kaj Sotala)、罗宾·汉森 (Robin Hanson)、尼克·博斯特罗姆 (Nick Bostrom)、摩西·卢克斯 (Moshe Looks) 和本杰明·诺布尔 (Benjamin Noble) 提出的宝贵反馈。

参考文献

- Armstrong, Stuart. Forthcoming. "General Purpose Intelligence: Arguing the Orthogonality Thesis." *Analysis and Metaphysics*. Preprint at http://lesswrong.com/lw/cej/general_purpose_intelligence_arguing_the/.
- Barbour, Julian. 1999. *The End of Time: The Next Revolution in Physics*. 1st ed. New York: Oxford University Press.
- Baum, Eric B. 2004. *What Is Thought?* Bradford Books. Cambridge, MA: MIT Press.
- Bickerton, Derek. 2009. *Adam's Tongue: How Humans Made Language, How Language Made Humans*. New York: Hill & Wang.
- Blair, Clay, Jr. 1957. "Passing of a Great Mind: John von Neumann, a Brilliant, Jovial Mathematician, was a Prodigious Servant of Science and His Country." *Life*, February 25, 89–104. <http://books.google.ca/books?id=rEEAAAAMBAJ&pg=PA89>.
- Bostrom, Nick. 2006. "What is a Singleton?" *Linguistic and Philosophical Investigations* 5 (2): 48–54.
- . 2012. "The Superintelligent Will: Motivation and Instrumental Rationality in Advanced Artificial Agents." In "Theory and Philosophy of AI," edited by Vincent C. Müller. Special issue, *Minds and Machines* 22 (2): 71–85. doi:10.1007/s11023-012-9281-3.
- Bringsjord, Selmer. 2012. "Belief in the Singularity is Logically Brittle." *Journal of Consciousness Studies* 19 (7-8): 14–20. <http://ingentaconnect.com/content/imp/jcs/2012/00000019/F0020007/art00002>.
- Cadigan, Pat. 1995. "Death in the Promised Land." *Omni Online*, March.
- Calvin, William H. 2004. *A Brief History of the Mind: From Apes to Intellect and Beyond*. New York: Oxford University Press.
- Chalmers, David John. 2010. "The Singularity: A Philosophical Analysis." *Journal of Consciousness Studies* 17 (9–10): 7–65. <http://www.ingentaconnect.com/content/imp/jcs/2010/00000017/f0020009/art00001>.
- . 2012. "The Singularity: A Reply to Commentators." *Journal of Consciousness Studies* 19 (7-8): 141–167. <http://ingentaconnect.com/content/imp/jcs/2012/00000019/F0020007/art00014>.
- Chalmers, David John, Robert M. French, and Douglas R. Hofstadter. 1992. "High-Level Perception, Representation, and Analogy: A Critique of Artificial Intelligence Methodology." *Journal of Experimental and Theoretical Artificial Intelligence* 4 (3): 185–211. doi:10.1080/09528139208953747.
- Clark, Gregory. 2007. *A Farewell to Alms: A Brief Economic History of the World*. 1st ed. Princeton, NJ: Princeton University Press.

- Cole, David. 2013. "The Chinese Room Argument." In *The Stanford Encyclopedia of Philosophy*, Spring 2013, edited by Edward N. Zalta. Stanford University. <http://plato.stanford.edu/archives/spr2013/entries/chinese-room/>.
- Cowen, Tyler. 2011. *The Great Stagnation: How America Ate All the Low-Hanging Fruit of Modern History, Got Sick, and Will (Eventually) Feel Better*. New York: Dutton.
- Deacon, Terrence W. 1997. *The Symbolic Species: The Co-evolution of Language and the Brain*. New York: W. W. Norton.
- Eden, Amnon, Johnny Søraker, James H. Moor, and Eric Steinhart, eds. 2012. *Singularity Hypotheses: A Scientific and Philosophical Assessment*. The Frontiers Collection. Berlin: Springer.
- Egan, Greg. 2002. *Schild's Ladder*. New York: Eos.
- Falkenhainer, Brian, and Kenneth D. Forbus. 1990. "The Structure-Mapping Engine: Algorithm and Examples." *Artificial Intelligence* 41 (1): 1–63. doi:10.1016/0004-3702(89)90077-5.
- Feldman, J. A., and Dana H. Ballard. 1982. "Connectionist Models and Their Properties." *Cognitive Science* 6 (3): 205–254. doi:10.1207/s15516709cog0603_1.
- Frankena, William K. 1973. *Ethics*. 2nd ed. Foundations of Philosophy Series. Englewood Cliffs, NJ: Prentice-Hall.
- Freitas, Robert A., Jr. 2000. "Some Limits to Global Ecophagy by Biovorous Nanoreplicators, with Public Policy Recommendations." Foresight Institute. April. Accessed July 28, 2013. <http://www.foresight.org/nano/Ecophagy.html>.
- Gibson, William. 1984. *Neuromancer*. 1st ed. New York: Ace.
- Good, Irving John. 1965. "Speculations Concerning the First Ultraintelligent Machine." In *Advances in Computers*, edited by Franz L. Alt and Morris Rubinoﬀ, 31–88. Vol. 6. New York: Academic Press. doi:10.1016/S0065-2458(08)60418-0.
- Hanson, Robin. 1998a. "Economic Growth Given Machine Intelligence." Unpublished manuscript. Accessed May 15, 2013. <http://hanson.gmu.edu/aigrow.pdf>.
- . 1998b. "Long-Term Growth as a Sequence of Exponential Modes." Unpublished manuscript. Last revised December 2000. <http://hanson.gmu.edu/longgrow.pdf>.
- . 1998c. "Must Early Life Be Easy? The Rhythm of Major Evolutionary Transitions." Unpublished manuscript, September 23. Accessed August 12, 2012. <http://hanson.gmu.edu/hardstep.pdf>.
- . 2008a. "Outside View of the Singularity." *Overcoming Bias* (blog), June 20. <http://www.overcomingbias.com/2008/06/singularity-out.html>.
- . 2008b. "Shared AI Wins." *Overcoming Bias* (blog), December 6. <http://www.overcomingbias.com/2008/12/shared-ai-wins.html>.
- . 2008c. "Test Near, Apply Far." *Overcoming Bias* (blog), December 3. <http://www.overcomingbias.com/2008/12/test-near-apply.html>.
- . 2008d. "The Rapacious Hardscrapple Frontier." In *Year Million: Science at the Far Edge of Knowledge*, edited by Damien Broderick, 168–189. New York: Atlas. <http://hanson.gmu.edu/hardscra.pdf>.
- Hawks, John, Eric T. Wang, Gregory M. Cochran, Henry C. Harpending, and Robert K. Moyzis. 2007. "Recent Acceleration of Human Adaptive Evolution." *Proceedings of the National Academy of Sciences of the United States of America* 104 (52): 20753–20758. doi:10.1073/pnas.0707650104.

- Heinlein, Robert A. 1966. *The Moon is a Harsh Mistress*. New York: Putnam.
- Kahneman, Daniel, and Dan Lovallo. 1993. "Timid Choices and Bold Forecasts: A Cognitive Perspective on Risk Taking." *Management Science* 39 (1): 17–31. doi:10.1287/mnsc.39.1.17.
- Kasparov, Garry, and Daniel King. 2000. *Kasparov Against the World: The Story of the Greatest Online Challenge*. New York: KasparovChess Online.
- Kuhn, Thomas S. 1962. *The Structure of Scientific Revolutions*. 1st ed. Chicago: University of Chicago Press.
- Kurzweil, Ray. 1999. *The Age of Spiritual Machines: When Computers Exceed Human Intelligence*. New York: Viking.
- Langley, Patrick, Gary Bradshaw, and Jan Zytkow. 1987. *Scientific Discovery: Computational Explorations of the Creative Process*. Cambridge, MA: MIT Press.
- Lucas, Robert E., Jr. 1976. "Econometric Policy Evaluations: A Critique." *Carnegie-Rochester Conference Series on Public Policy* 1:19–46. doi:10.1016/S0167-2231(76)80003-6.
- Mahoney, Matt. 2010. "A Model for Recursively Self Improving Programs v.3." Unpublished manuscript, December 17. Accessed March 27, 2012. <http://mattmahoney.net/rsi.pdf>.
- McDaniel, Michael A. 2005. "Big-Brained People are Smarter: A Meta-Analysis of the Relationship between In Vivo Brain Volume and Intelligence." *Intelligence* 33 (4): 337–346. doi:10.1016/j.intell.2004.11.005.
- Moravec, Hans P. 1988. *Mind Children: The Future of Robot and Human Intelligence*. Cambridge, MA: Harvard University Press.
- . 1999. "Simple Equations for Vinge's Technological Singularity." Unpublished manuscript, February. <http://www.frc.ri.cmu.edu/~hpm/project.archive/robot.papers/1999/singularity.html>.
- Muehlhauser, Luke, and Louie Helm. 2012. "The Singularity and Machine Ethics." In Eden, Søraker, Moor, and Steinhart 2012.
- Muehlhauser, Luke, and Anna Salamon. 2012. "Intelligence Explosion: Evidence and Import." In Eden, Søraker, Moor, and Steinhart 2012.
- Muehlhauser, Luke, and Chris Williamson. 2013. *Ideal Advisor Theories and Personal CEV*. Berkeley, CA: Machine Intelligence Research Institute. <http://intelligence.org/files/IdealAdvisorTheories.pdf>.
- NSB (National Science Board). 2012. *Science and Engineering Indicators 2012*. NSB 12-01. Arlington, VA: National Science Foundation. <http://www.nsf.gov/statistics/seind12/start.htm>.
- Omohundro, Stephen M. 2008. "The Basic AI Drives." In *Artificial General Intelligence 2008: Proceedings of the First AGI Conference*, edited by Pei Wang, Ben Goertzel, and Stan Franklin, 483–492. Frontiers in Artificial Intelligence and Applications 171. Amsterdam: IOS.
- Pelikan, Martin, David E. Goldberg, and Erick Cantú-Paz. 2000. "Linkage Problem, Distribution Estimation, and Bayesian Networks." *Evolutionary Computation* 8 (3): 311–340. doi:10.1162/106365600750078808.
- Pennachin, Cassio, and Ben Goertzel. 2007. "Contemporary Approaches to Artificial General Intelligence." In *Artificial General Intelligence*, edited by Ben Goertzel and Cassio Pennachin, 1–30. Cognitive Technologies. Berlin: Springer. doi:10.1007/978-3-540-68677-4_1.

- Ponce de León, Marcia S., Lubov Golovanova, Vladimir Doronichev, Galina Romanova, Takeru Akazawa, Osamu Kondo, Hajime Ishida, and Christoph P. E. Zollikofer. 2008. "Neanderthal Brain Size at Birth Provides Insights into the Evolution of Human Life History." *Proceedings of the National Academy of Sciences of the United States of America* 105 (37): 13764–13768. doi:10.1073/pnas.0803917105.
- Rawls, John. 1971. *A Theory of Justice*. Cambridge, MA: Belknap.
- Rhodes, Richard. 1986. *The Making of the Atomic Bomb*. New York: Simon & Schuster.
- Rosati, Connie S. 1995. "Persons, Perspectives, and Full Information Accounts of the Good." *Ethics* 105 (2): 296–325. doi:10.1086/293702.
- Russo, Lucio. 2004. *The Forgotten Revolution: How Science Was Born in 300 BC and Why It Had to Be Reborn*. Translated by Silvio Levy. New York: Springer.
- Sandberg, Anders. 2010. "An Overview of Models of Technological Singularity." Paper presented at the Roadmaps to AGI and the Future of AGI Workshop, Lugano, Switzerland, March 8. <http://agi-conf.org/2010/wp-content/uploads/2009/06/agi10singmodels2.pdf>.
- Shulman, Carl, and Nick Bostrom. 2012. "How Hard is Artificial Intelligence? Evolutionary Arguments and Selection Effects." *Journal of Consciousness Studies* 19 (7–8): 103–130. <http://ingentaconnect.com/content/imp/jcs/2012/00000019/F0020007/art00011>.
- Silver, Nate. 2012. *The Signal and the Noise: Why So Many Predictions Fail—but Some Don't*. New York: Penguin.
- Sternberg, Robert J., and Scott Barry Kaufman, eds. 2011. *The Cambridge Handbook of Intelligence*. Cambridge Handbooks in Psychology. New York: Cambridge University Press.
- Tegmark, Max. 2000. "Importance of Quantum Decoherence in Brain Processes." *Physical Review E* 61 (4): 4194–4206. doi:10.1103/PhysRevE.61.4194.
- Tuomi, Ilkka. 2002. "The Lives and the Death of Moore's Law." *First Monday* 7 (11). <http://firstmonday.org/ojs/index.php/fm/article/view/1000/921>.
- Wikipedia. 2013, s.v. "Lucas Critique." Accessed April 11. http://en.wikipedia.org/w/index.php?title=Lucas_critique&oldid=549911736.
- Wiles, Andrew. 1995. "Modular Elliptic Curves and Fermat's Last Theorem." *Annals of Mathematics* 142 (3): 443–551. doi:10.2307/2118559.
- Williams, George C. 1966. *Adaptation and Natural Selection: A Critique of Some Current Evolutionary Thought*. Princeton Science Library. Princeton, NJ: Princeton University Press.
- Williams, Roger. 2002. *The Metamorphosis of Prime Intellect*. <http://localroger.com/prime-intellect/mopiidx.html>.
- Yudkowsky, Eliezer. 2007. "Evolutions Are Stupid (But Work Anyway)." *Less Wrong* (blog), November 3. http://lesswrong.com/lw/kt/evolutions_are_stupid_but_work_anyway/.
- . 2008a. "Artificial Intelligence as a Positive and Negative Factor in Global Risk." In *Global Catastrophic Risks*, edited by Nick Bostrom and Milan M. Ćirković, 308–345. New York: Oxford University Press.
- . 2008b. "Optimization and the Singularity." *Less Wrong* (blog), June 23. http://lesswrong.com/lw/rk/optimization_and_the_singularity/.

- . 2008c. “Surprised by Brains.” *Less Wrong* (blog), November 23. http://lesswrong.com/lw/w4/surprised_by_brains/.
- . 2008d. “The First World Takeover.” *Less Wrong* (blog), November 19. http://lesswrong.com/lw/w0/the_first_world_takeover/.
- . 2010. “‘Outside View!’ as Conversation-Halter.” *Less Wrong* (blog), February 24. http://lesswrong.com/lw/1p5/outside_view_as_conversationhalter/.
- . 2011. “Complex Value Systems in Friendly AI.” In *Artificial General Intelligence: 4th International Conference, AGI 2011, Mountain View, CA, USA, August 3–6, 2011. Proceedings*, edited by Jürgen Schmidhuber, Kristinn R. Thórisson, and Moshe Looks, 388–393. Lecture Notes in Computer Science 6830. Berlin: Springer. doi:10.1007/978-3-642-22887-2_48.