

自进化智能体综述：迈向人工超级智能之路上的进化内容、时机、方式与方向

Huan-ang Gao^{γ†}, Jiayi Geng^{α†}, Wenyue Hua^{ε†}, Mengkang Hu^{ω†}, Xinzhe Juan^{σμ†}, Hongzhang Liu^{ξ†}, Shilong Liu^{α†}, Jiahao Qiu^{αδ†}, Xuan Qi^{γ†}, Qihan Ren^{σ†}, Yiran Wu^{ρ†}, Hongru Wang^{k†}, Han Xiao^{τ†}, Yuhang Zhou^{λ†}, Shaokun Zhang^{ρ†}, Jiayi Zhang^π, Jinyu Xiang, Yixiong Fang^θ, Qiwen Zhao^ζ, Dongrui Liu^σ, Cheng Qian^β, Zhenhailong Wang^β, Minda Hu^τ, Huazheng Wang^η, Qingyun Wu^ρ, Heng Ji^β, Mengdi Wang^{αδ}

^αPrinceton University, ^δPrinceton AI Lab, ^γTsinghua University, ^θCarnegie Mellon University, ^ξUniversity of Sydney, ^σShanghai Jiao Tong University, ^ρPennsylvania State University, ^μUniversity of Michigan, ^ηOregon State University, ^τThe Chinese University of Hong Kong, ^λFudan University, ^πThe Hong Kong University of Science and Technology (Guangzhou), ^ωThe University of Hong Kong, ^εUniversity of California, Santa Barbara, ^ζUniversity of California San Diego, ^kUniversity of Edinburgh, ^βUniversity of Illinois Urbana-Champaign

Github Repo: <https://github.com/CharlesQ9/Self-Evolving-Agents>

† 同等贡献，作者顺序按字母顺序排列，✉ 通讯作者

Reviewed on OpenReview: <https://openreview.net/forum?id=CTr3bovS5F>

摘要

大语言模型（Large Language Models）在各类任务中展现出卓越能力，但其本质上是静态的，无法针对新任务、不断演变的知识领域或动态交互情境调整内部参数。随着大语言模型越来越多地部署于开放式交互环境中，这种静态特性已成为关键瓶颈，亟需能够实时自适应推理、行动和进化的智能体。这一范式转变——从扩展静态模型转向开发自进化智能体——激发了人们对支持从数据、交互和经验中持续学习与适应的架构和方法的日益关注。本综述首次对自进化智能体进行了系统而全面的回顾，围绕三个基础维度——进化什么、何时进化以及如何进化——对该领域进行梳理。我们考察了智能体各组件（如模型、记忆、工具、架构）的进化机制，按阶段（如测试时内、测试时之间）对适应方法进行分类，并分析了指导进化适应的算法与架构设计（如标量奖励、文本反馈、单智能体和多智能体系统）。此外，我们分析了针对自进化智能体量身定制的评估指标和基准，重点介绍了编码、教育和医疗等领域的应用，并指出了在安全性、可扩展性和协同进化动力学方面的关键挑战和研究方向。通过为理解和设计自进化智能体提供结构化框架，本综述为在研究和实际部署中推进更具适应性、能力更强、更稳健且用途更广的智能体系统绘制了路线图，并最终为实现人工超级智能（Artificial Super Intelligence）提供启示——届时智能体将自主进化，并在广泛任务中展现出超越人类水平的智能。




图 1: 概念轨迹图, 展示从大语言模型 (LLMs) 到基础智能体, 再到自进化智能体——本文关注的重点——并最终迈向假想的人工超级智能 (ASI) 的演进过程。沿着这一路径, 智能性与适应性不断提升, 标志着向更自主、更具智能体特性的 AI 系统转变。自进化智能体之后的未来方向仍属开放问题, 有待持续探索。

1 引言

“生存下来的物种, 不是最聪明的, 也不是最强壮的, 而是最能适应并调整自身以应对所处不断变化环境的物种。”——查尔斯·达尔文¹

大语言模型 (LLMs) 在广泛任务中展现出卓越能力。然而, 它们本质上仍是静态的 (Luo 等, 2025a), 在遇到新任务、不断演变的知识领域或动态交互情境时, 无法调整其内部参数。随着大语言模型越来越多地部署在开放式交互环境中, 这一局限性成为关键瓶颈。在此类场景下, 传统知识检索机制已显不足, 催生了能够实时动态调整感知、推理和行动的智能体。这种对动态、持续适应的新兴需求, 标志着人工智能领域的概念转变: 从扩展静态模型转向开发自进化智能体。虽然监督微调 (SFT) 和强化学习 (RL) 等成熟技术提供了改进机制, 但我们定义自进化不仅依据所用算法, 更在于自主性的归属。与传统流程中人类工程师整理数据并安排更新不同, 自进化智能体能够实时从新数据、交互和经验中持续学习, 从而构建出更稳健、更通用、能够应对复杂动态现实问题的系统 (Wang 等, 2024a)。这一转变正推动我们走向一条通往人工超级智能 (ASI) 的有前景且具变革性的道路, 届时智能体不仅能以不可预测的速度从经验中学习并进化, 还能在广泛任务上达到或超越人类水平智能 (Wang 等, 2025g)。

与静态大语言模型 (Large Language Models) 不同, 后者受限于无法适应新颖且不断变化的环境, 自进化智能体旨在通过持续从现实世界反馈中学习来克服这些局限性。这一进展重塑了我们对智能体的理解。自进化智能体作为一个核心概念, 代表了智能系统演进中的重大进步, 充当了通往更具适应性和自主性人工智能的中间桥梁, 如图 1 所示。近期研究计划越来越侧重于开发能够从经验中持续学习和适应的自适应智能体架构, 例如智能体框架 (Yin et al., 2025)、提示策略 (Fernando et al., 2023) 以及不同的优化进化方式方面的最新进展。尽管取得了这些进展, 现有综述主要将智能体进化作为综合智能体分类法中的一个附属组成部分来处理。以往综述主要提供通用智能体发展的系统性概述, 而对自进化智能体在受限场景下的自进化机制覆盖有限 (Luo et al., 2025a; Liu et al., 2025a)。

¹ 这句话被广泛认为是查尔斯·达尔文 (Charles Darwin) 所说, 但并未逐字出现在他的著作中。该表述被认为源自利昂·C·梅金森 (Leon C. Megginson) 教授, 他转述了达尔文的思想。尽管经常被误引, 这句话有效地抓住了达尔文进化论的精髓, 并已在科学和管理文献中广为流传。

例如，Luo 等人（2025a）讨论了几种进化方式，如自学习和多智能体协同进化，而 Liu 等人（2025a）则明确从智能体的不同组成部分（如工具和提示）角度介绍了进化。此外，一些研究专门关注语言模型本身的进化（Tao et al., 2024），而非更广泛的智能体概念。然而，这些工作处理的是孤立的组成部分，而非整体智能体系统。因此，目前尚无系统性的综述致力于将自进化智能体作为一等研究范式进行专门、全面的考察。这一空白使得一些基本问题尚未得到充分探索：智能体的哪些方面应该进化？适应应在何时发生？以及这种进化在实践中应如何实施？

据我们所知，本文是首篇系统且全面的综述，聚焦于自进化智能体，为理论探索与实际部署提供了清晰的路线图。然而，鉴于该领域正处于快速形成阶段，概念边界仍在社区内被积极协商，本文将本综述定位为指导性综合，而非对已完全确立范式的回顾。本文不强行划定刚性边界，而是旨在将社区中涌现的异构机制组织为一个连贯的框架。本文围绕三个基础性问题组织分析——进化什么、何时进化、如何进化——并为理解每个问题提供结构化框架。具体而言，本文系统考察了智能体的各个组成部分，包括模型、记忆、工具及相应工作流，探究其各自的进化机制（第 3 节中智能体进化什么）；随后，本文依据不同时间阶段及不同学习范式（如监督微调、强化学习和推理时进化）对现有进化方法进行划分（第 4 节中何时进化）。最后，本文总结了引导智能体进化的不同信号（如文本反馈或标量奖励），以及待进化智能体的不同架构（如单智能体与多智能体进化）（第 5 节中如何进化）。此外，本文回顾了若干评估度量与基准，以追踪自进化智能体的现有进展，并强调评估与智能体协同进化的重要性（第 6 节）。本文还考察了编码、教育、医疗等领域的新兴应用，这些领域中持续适应与进化至关重要（第 7 节）。最后，本文识别了持续存在的挑战，并概述了有前景的研究方向，以指导自进化智能体的发展（第 8 节）。通过沿正交维度对自进化过程进行系统分解，本文提供了一个结构化且实用的框架，使研究人员能够系统地分析、比较并设计更稳健、更具适应性的智能体系统。综上所述，本文的主要贡献如下：

- 本文建立了一个统一的表征智能体系统中自我进化过程的理论框架，围绕三个基本维度展开：进化什么、如何进化以及何时进化，为未来自我进化智能体系统提供了清晰的设计指导。
- 本文进一步研究了为自我进化智能体量身定制的评估基准或环境，强调了与适应性、鲁棒性和现实世界复杂性相关的新兴度量和挑战。
- 本文展示了跨多个领域的关键现实世界应用，包括自主软件工程、个性化教育、医疗保健和智能虚拟助手，说明了自我进化智能体的实用潜力。
- 本文识别了关键的开放性挑战和有前景的未来研究方向，强调了安全性、个性化、多智能体协同进化和可扩展性等方面。
- 通过这样做，本综述为研究人员和从业者提供了一个更结构化的分类法，用于从不同角度理解、比较和推进自我进化智能体的研究。随着基于大语言模型的智能体越来越多地集成到关键任务应用中，理解它们的进化动力学变得至关重要，这超越了学术研究，涵盖了工业应用、监管考虑和更广泛的社会影响。




图 2: 自我进化智能体的分类法, 其中智能体沿着什么、何时、如何和哪里维度进行分析, 并在每个叶节点标注了选定的代表性方法和系统。




图 3：自进化智能体在关键维度上的全面概览。从左至右、从上到下，该图与第 3 至第 7 节的组织结构相对应。进化什么（第 3 节）分解了智能体组件：模型、上下文、工具和架构，展示了进化发生的位置。何时进化（第 4 节）区分了测试时内与测试时间的自进化，分别对应上下文学习、监督微调和强化学习范式。如何进化（第 5 节）总结了方法族——基于奖励、模仿与示范、基于种群——以及跨领域维度，如在线/离线、同策略/异策略和奖励粒度。在哪里进化（第 6 节）对比了通用与领域特定的部署（例如，编程、图形用户界面、金融、医疗、教育）。评估（第 7 节）概述了目标和度量——适应性、泛化性、效率、安全性——以及相应的评估范式（静态、短视界、长视界）。总体而言，该分类法映射了本综述的推理流程：定义进化什么、何时进化以及如何进化，为评估和推进自进化智能体奠定了基础。

2 定义与基础

在深入全面综述之前，我们首先给出自进化智能体的正式定义，并介绍自进化智能体关键方面的分类法。我们还讨论了自进化智能体与其他著名学习范式（如课程学习、终身学习、模型编辑和遗忘学习）之间的关系，突出了自进化智能体的适应性、动态性和自主性。

2.1 定义

环境 我们首先将智能体系统的环境（包括用户和执行环境，例如 Linux shell）定义为一个部分可观测马尔可夫决策过程（POMDP），表示为一个元组 $E = (\mathcal{G}, \mathcal{S}, \mathcal{A}, T, R, \Omega, O, \gamma)$ ，其中：

- $\mathcal{G}$ 是一组潜在目标。每个 $g \in \mathcal{G}$ 是智能体需要实现的任务目标，例如用户查询。
- $\mathcal{S}$ 是一组状态。每个 $s \in \mathcal{S}$ 表示环境的内部状态。
- $\mathcal{A}$ 是一组动作。每个动作 $a \in \mathcal{A}$ 可以是文本推理、外部知识检索和工具调用的组合。




图 4：2022 年至 2025 年间若干代表性自进化智能体框架的演化图景。该图按时间顺序梳理了自进化智能体发展中的主要研究里程碑，涵盖自主规划、工具使用和持续自我改进等能力。

- T 是状态转移概率函数，它接收状态-动作对 (s, a) 并输出下一状态的概率分布 $T(s'|s, a)$ 。
- $R: \mathcal{S} \times \mathcal{A} \times \mathcal{G} \rightarrow \mathcal{R}$ 是反馈/奖励函数，以特定目标 $g \in \mathcal{G}$ 为条件。反馈 $r = R(s, a, g)$ 通常采用标量分数或文本反馈的形式。
- Ω 是智能体可访问的一组观测。
- O 是观测概率函数，它接收状态-动作对 (s, a) 并输出智能体下一观测的概率分布 $O(o'|s, a)$ 。
- γ 是折扣因子。

智能体系统 我们将（多）智能体系统定义为 $\Pi = (\Gamma, \{\psi_i\}, \{C_i\}, \{\mathcal{W}_i\})$ 。架构 Γ 决定智能体系统的控制流或多智能体之间的协作结构。它通常表示为按图或代码结构组织的一系列节点 $(N_1, N_2, \dots)$ 。每个节点 N_i 由以下部分组成：

- ψ_i ：底层大语言模型/多模态大语言模型。
- C_i ：上下文信息，例如提示 P_i 和记忆 M_i 。
- $\mathcal{W}_i$ ：可用工具/应用程序编程接口的集合。

在每个节点，智能体策略是一个函数 $\pi_{\theta_i}(\cdot|o)$ ，它接收观测并输出下一动作的概率分布，其中 $\theta_i = (\psi_i, C_i)$ 。这里的实际动作空间是自然语言空间与工具空间 $\mathcal{W}_i$ 的并集。

对于给定任务 $\mathcal{T} = (E, g)$ ，由环境 E 和相应目标 $g \in \mathcal{G}$ 表示，智能体系统遵循拓扑 Γ 生成轨迹 $\tau = (o_0, a_0, o_1, a_1, \dots)$ ，并从外部环境或内部信号（例如，自置信度或评估器的反馈）接收反馈 r 。

自进化策略 自进化策略是一种变换 f ，它将当前智能体系统映射到新状态，条件是基于生成的轨迹 τ 和外部/内部反馈 r ：

$$f(\Pi, \tau, r) = \Pi' = (\Gamma', \{\psi'_i\}, \{C'_i\}, \{\mathcal{W}'_i\}) \quad (1)$$

自我进化智能体的目标 设 U 为一个效用函数，用于衡量智能体系统 Π 在给定任务 $\mathcal{T}$ 上的性能，通过赋予一个标量分数 $U(\Pi, \mathcal{T}) \in \mathbb{R}$ 。该效用可来源于任务特定的反馈 r ，例如奖励信号或文本评估，并可能与其他性能指标（如完成时间、准确率或鲁棒性）相结合。给定一个任务序列 $(\mathcal{T}_0, \mathcal{T}_1, \dots, \mathcal{T}_n)$ 和一个初始智能体系统 Π_0 ，一个自我进化策略 f 通过以下方式循环生成一个不断演化的智能体系统序列 $(\Pi_1, \Pi_2, \dots, \Pi_n)$ ：

$$\Pi_{j+1} = f(\Pi_j, \tau_j, r_j), \quad (2)$$

其中 τ_j 和 r_j 分别是任务 $\mathcal{T}_j$ 上的轨迹和反馈。

设计自我进化智能体的总体目标是构建一个策略 f ，使得任务上的累积效用最大化：

$$\max_f \sum_{j=0}^n U(\Pi_j, \mathcal{T}_j) \quad (3)$$

自我进化智能体的操作性定义 为了提供一个概念边界，我们引入自我进化智能体的操作性定义。自我进化智能体是指基于自身轨迹或反馈信号修改其内部参数、上下文状态、工具集或架构拓扑，并以提升未来性能为明确目标的智能体。

该定义包含三个纳入标准：（i）更新必须是经验依赖的，由轨迹、自生成数据或环境反馈驱动，专门针对智能体的策略局限性或能力边界，而非通用数据综合；（ii）更新必须产生持久的、改变策略的效果，而非短暂的指令遵循行为；（iii）系统必须具备自主探索或自启动学习的机制，即使它也利用预先收集的数据。为清晰起见，我们用“被动”表示仅由外部提供的数据或计划触发的学习，用“主动”表示自启动的探索、反思或结构修改（即利用自我反思来收集数据），明确排除静态流水线（例如标准蒸馏），其中数据生成与智能体的交互历史无关。

由于该领域正在迅速形成，完全自主的自我进化（无需人工干预）代表了一个理想目标，而非当前常态。在本综述中，我们不设置严格的排除阈值来忽略早期发展。相反，我们分析促成自我进化范式的机制，范围从原始进化（例如迭代自举或反馈驱动的提示）到强自我进化（完全自主的诊断与重构），从而全面展示各种方法如何推动该范式在“什么、何时以及如何”方面向完全自主迈进。

2.2 与其他工作的关系

表 1 总结了自我进化智能体与其他范式（包括课程学习、终身学习、模型编辑和遗忘学习）之间的关键区别。我们在下文中简要介绍每种范式，突出这些范式之间的差异，以及它们与自我进化智能体的差异。

课程学习 课程学习是一种训练策略，其中数据按难度递增的顺序呈现（Bengio 等，2009；Wang 等，2021）。该策略类似于人类课程，概念从简单到复杂逐步引入。课程学习已被广泛应用于多个领域，包括计算机视觉（Guo 等，2018；Jiang 等，2014；Liu 等，2023a）、

自然语言处理（Platanios 等，2019；Tay 等，2019）、语音识别（Braun 等，2017；Lotfian 和 Busso，2019）等。最近，一些基于课程学习的方法被提出用于在后训练阶段微调大语言模型（Wang 等，2025p；Zhang 等，2025o；Parashar 等，2025；Zhang 等，2025a；Li 等，2025b）。课程学习的框架通常包含两个关键组件：一个难度度量器，用于量化每个训练数据点的难度水平；以及一个训练调度器，根据难度水平重新组织模型接收数据点的顺序。与在静态数据集上操作的课程学习不同，自我进化智能体旨在处理动态环境中的顺序任务。此外，课程学习仅更新模型参数，而自我进化智能体能够调整非参数组件，如记忆和工具。

终身学习 终身学习是指人工智能模型在面对新任务和新环境时，能够持续且自适应地学习，同时保留先前获得的知识 and 能力。这种学习范式，也称为持续学习或增量学习，对于人工智能模型在动态和复杂环境中运行至关重要（Wang et al., 2024c; Zheng et al., 2025c; Parisi et al., 2019; Shi et al., 2024; Yang et al., 2025d; Zhou et al., 2024a）。人工智能模型终身学习的主要目标是在接触新数据或新任务时，实现保留现有知识（稳定性）与获取新知识（可塑性）之间的平衡（McCloskey & Cohen, 1989; Zheng et al., 2025c; Ratcliff, 1990; Rolnick et al., 2019）。尽管终身学习与自进化智能体共享顺序任务设置，但两者在两个方面存在根本差异：（1）记忆功能与使用时机：持续学习方法广泛采用记忆机制（例如，经验回放缓冲区（Rolnick et al., 2019）、情景记忆（Lopez-Paz & Ranzato, 2017））来缓解灾难性遗忘，但这些机制主要作为训练时工具，通过梯度计算进行参数优化。相比之下，自进化智能体利用运行时上下文（提示、工作记忆、对话历史），在测试时直接影响动作生成，而无需参数更新。区别不在于非参数组件的存在与否，而在于其功能角色：训练时回放与测试时状态适应。（2）学习主动性：终身学习主要通过外部提供的任务序列被动获取知识，而自进化智能体主动探索环境，并纳入内部反思或自我评估机制来引导自身的学习轨迹。近期自改进大语言模型方法（Huang et al., 2022; Yuan et al., 2024d）通过自生成数据和自我批判迭代优化模型，可视为以模型为中心的终身学习实例。自进化智能体则超越这一范式，涵盖系统级进化，包括工具获取、架构重构和环境探索。

模型编辑与遗忘 模型编辑与遗忘旨在高效且精确地修改人工智能模型中的特定知识，同时保留无关知识并避免完全重新训练（Wang et al., 2024f; 2025i; Zhang et al., 2024d; Wang et al., 2025i; Nguyen et al., 2022; Geng et al., 2025a）。模型编辑的一个典型应用是执行高效且精确的局部事实更新（例如，将“2021 年奥运会主办城市”的答案从“东京”修改为“巴黎”）。早期方法聚焦于原子知识三元组，后来扩展到各种可信赖相关任务（Fang et al., 2025a; Huang et al., 2025a）。近期研究还提出了终身模型编辑（Chen et al., 2024c），即顺序执行模型编辑。对于模型遗忘，早期工作主要关注隐私相关信息的移除（Chen et al., 2021）。随着大语言模型的快速发展，模型遗忘也被用于增强大语言模型的安全性（Zhang et al., 2024j; Li et al., 2024c; Zou et al., 2024; Lu et al., 2025）。与终身学习相比，模型编辑具有一致的目标：两者都旨在获取新知识或能力，同时减轻灾难性遗忘。然而，终身学习通常依赖于对所有模型参数进行广泛的基于梯度的微调，而模型编辑往往以有针对性的方式仅修改一小部分参数。与自进化智能体相比，模型编辑（1）无法修改非参数组件，如记忆或工具，（2）依赖于算法设计者预定义的流程，而自进化智能体可以根据环境观察或内部反馈信号自发地采用更多样化和灵活的策略。

自进化智能体的定位 为了阐明这些范式之间的关系并激发自进化智能体的作用，我们通过两个互补的视角来审视它们：问题设定

表 1: 自进化智能体与其他知名范式的比较

Paradigm	Runtime Context	Evolving Toolset	Dynamic Tasks	Test-time Adaptation	Active Exploration	Structural Change	Self-reflect & Eval
Curriculum Learning	✗	✗	✗	✗	✗	✗	✗
Lifelong Learning	✗	✗	✓	✗	✗	✗	✗
Model Editing	✗	✗	✓	✓	✗	✗	✗
Self-evolving Agents	✓	✓	✓	✓	✓	✓	✓

视角和解决方案范式视角。这种区分阐明了每种范式的基础——无论它源于学习环境固有的约束和挑战，还是源于关于模型或智能体本身如何更新的方法论提议。

- **问题设定视角。**课程学习与终身学习源于具体的学习问题。课程学习旨在解决如何组织不同难度的训练样本，使模型能够更有效地处理复杂样本；终身学习则关注在时间推移中获取新能力，同时缓解灾难性遗忘。因此，这些范式由它们所要解决的问题驱动，主要规定如何为学习者组织经验，而非智能体本身如何在参数更新之外进行适应。

- **解决方案范式视角。**相比之下，模型编辑与自进化智能体起源于解决方案：它们提出了更新或修改系统的机制。模型编辑提供了针对性的程序——通常是局部参数调整——以纠正或插入知识。自进化智能体将这一思想泛化，将适应视为一种一等能力，不仅允许参数更新，还允许对运行时上下文、记忆、工具和工作流结构进行更改，这些更改由智能体自身的轨迹和反馈信号驱动。

通过这一双重视角框架来看，课程学习与终身学习植根于它们所解决的学习问题的本质，而模型编辑与自进化智能体则由它们为实现改变所提供的方法来定义。因此，自进化智能体代表了一种系统级解决方案范式：它们将参数级编辑作为一条更新途径，同时支持在智能体的多个组件之间进行更广泛、持久且由交互驱动的演化。

3 演化什么？

自进化智能体与静态智能体的区别不在于它包含哪些组件，而在于哪些内部状态可以根据其自身的轨迹、反思和反馈信号被自主修改。因此，本节的关键问题是识别智能体系统中的演化位点 $\Pi = (\Gamma, \{\psi_i\}, \{C_i\}, \{W_i\})$ ——即系统中那些状态能够以经验驱动且持久的方式被重写的部分，从而实现累积式自我改进。

遵循第 2.1 节的表述，这些进化位点与智能体系统的四大支柱相契合。我们的研究始于智能体的认知核心，即模型 $\{\psi_i\}$ ，其参数可通过自生成的监督信号、执行轨迹或环境反馈持续更新（Zhou 等，2025e；Wang 等，2025q）。随后，我们考虑上下文 $\{C_i\}$ ——包括指令（Xiang 等，2025；Khattab 等，2023）和长期记忆（Chhikara 等，2025；Wang 等，2024j）——它随着智能体反思、存储和检索经验而演化，从而塑造未来的决策。基于这一内部基础，我们考察工具 $\{W_i\}$ 的进化，其中智能体基于可验证的交互信号自主创建（Qiu 等，2025b）、精炼（Qu 等，2025）和管理（Wang 等，2025k）可执行技能。最后，我们扩展到智能体架构层面，系统架构（Hu 等，2024c；Zhang 等，2024c）和协作结构（Wan 等，2025）随时间优化，实现超越单个组件的结构适应。我们在表 2 中展示了这些进化位点的代表性示例。

表 2: 沿四大进化支柱定位的代表性自进化智能体方法；实心圆点 (●) m 标记该方法主动演化的维度。

Method	Model		Context		Tool			Architecture	
	Policy	Experience	Prompt	Memory	Creation	Mastery	Selection	Single	Multi
SCA(Zhou et al., 2025e)	●	●	○	○	●	○	○	○	○
RAGEN(Wang et al., 2025q)	●	●	○	○	○	○	○	●	○
AgentGen (Hu et al., 2024b)	○	●	●	●	●	○	○	●	○
Promptbreeder(Fernando et al., 2023)	○	○	●	○	○	○	○	●	○
Expel(Zhao et al., 2024a)	○	●	○	●	○	○	○	○	○
Agent Workflow Memory(Wang et al., 2024j)	○	○	○	●	○	○	●	○	○
Mem0(Chhikara et al., 2025)	○	○	○	●	○	○	○	○	○
MAS-Zero(Ke et al., 2025)	○	○	●	○	○	○	○	○	●
Multi-Agent Design(Zhou et al., 2025a)	○	○	●	○	○	○	●	○	●
SPO(Xiang et al., 2025)	○	○	○	○	○	○	○	○	○
Alita(Qiu et al., 2025b)	○	○	●	○	●	○	●	○	○
TextGrad(Yellamraju et al., 2024)	○	○	●	○	○	●	●	●	○
DGM(Zhang et al., 2025h)	○	○	●	○	○	○	○	●	○
AlphaEvolve(Novikov et al., 2025)	○	○	●	○	●	●	○	●	○
ADAS(Hu et al., 2024c)	○	○	●	○	●	○	○	●	●
AFlow(Zhang et al., 2024c)	○	○	●	○	●	○	●	●	●
ReMA(Wan et al., 2025)	○	○	○	○	○	○	○	○	●
SkillWeaver(Zheng et al., 2025a)	○	○	○	●	●	●	●	○	○
LearnAct(Zhao et al., 2024b)	○	○	○	●	●	○	●	○	○
DRAFT(Qu et al., 2025)	○	○	●	○	●	●	○	○	○
ToolGen(Wang et al., 2025k)	○	○	○	●	●	●	○	○	○
CRAFT(Yuan et al., 2024a)	○	○	○	○	●	●	●	○	○
CREATOR(Qian et al., 2023b)	○	○	○	○	●	●	○	○	○
Voyager(Wang et al., 2023a)	○	○	●	●	●	●	●	○	●

3.1 模型

模型是自进化的主要位点，因为其参数可基于智能体自身的轨迹、反思和交互结果自主重写。这些模型通过持续调整内部参数和扩展功能能力而进化的能力，对于开发自主、通用的智能体至关重要。与严重依赖人工标注数据集和固定训练机制的静态系统不同，自进化模型能够通过交互、自监督数据生成和动态学习循环实现改进，从而获得更高的效率、适应性和可扩展性。

具体而言，我们概述了模型进化展开的主要轴线。这些包括从自生成的监督中学习以精炼模型权重，通过与构建的或外部环境的交互进化，以及整合直接重塑未来推理行为的反馈信号。这些策略共同代表了从被动学习范式向主动自我改进的转变。

策略 一个自我进化的智能体能够优化其参数，从而在目标任务上表现更佳。传统的用于训练智能体掌握工具使用基准的数据收集方法成本高昂，且往往覆盖范围有限，而纯合成数据生成流程通常存在质量不足的问题。因此，近期研究强调让智能体自主生成数据以改进自身模型权重。一种代表性方法是自我挑战智能体（Self-Challenging Agent, SCA）（Zhou et al., 2025e），其中语言模型在生成可执行代码即任务问题的挑战者与解决这些问题的执行者之间交替扮演角色。随后，模型利用成功解决方案产生的轨迹对其参数进行微调，从而在复杂的多步骤任务上取得显著性能提升。类似地，自我奖励自我改进框架（Self-Rewarding Self-Improving framework）（Simonds et al., 2025）实现了内部自我评判机制，使模型能够自主生成问题、解决问题并评估自身表现，从而无需外部标注即可产生自包含的微调数据。该方法在复杂推理任务中表现出显著改进。除任务创建外，另一个有前景的研究方向是利用交互反馈直接进行参数更新。例如，SELF（Lu et al., 2023）、SCoRe（Kumar et al., 2024）和 PAG（Jiang et al., 2025b）将执行迹或自然语言批评解释为在线监督微调（Supervised Fine-Tuning, SFT）与强化学习（Reinforcement Learning, RL）框架中的奖励信号，从而实现策略的持续改进。TextGrad（Yellamraju et al., 2024）进一步扩展了这一概念，将非结构化文本反馈视为可微训练信号，能够直接影响提示设计和模型参数。此外，AutoRule（Wang & Xiong, 2025）将语言模型的推理迹和偏好反馈转化为基于规则的显式训练奖励，通过结构化奖励信号提升模型输出质量。总体而言，这些进展勾勒出一条清晰的轨迹——从智能体自主构建训练任务到基于执行反馈直接优化参数，凸显了模型通过从自身产生的数据中学习而持续进化的能力。

能够直接影响提示设计和模型参数。此外，AutoRule (Wang & Xiong, 2025) 将语言模型的推理迹和偏好反馈转化为基于规则的显式训练奖励，通过结构化奖励信号提升模型输出质量。总体而言，这些进展勾勒出一条清晰的轨迹——从智能体自主构建训练任务到基于执行反馈直接优化参数，凸显了模型通过从自身产生的数据中学习而持续进化的能力。

经验 智能体不仅可以通过调整内部参数实现进化，还可以通过主动与环境交互甚至构建环境、捕获经验并将其转化为驱动迭代改进的学习信号来实现进化。这种环境回路为智能体提供了可扩展自适应所需的复杂性和多样性。自挑战智能体 (Self-Challenging Agent, SCA) (Zhou et al., 2025e) 在任务层面体现了这一动态过程，智能体自主生成新颖的代码即任务问题，执行这些问题，然后筛选成功的轨迹用于自我再训练。智能体生成器 (AgentGen) (Hu et al., 2024b) 将这一概念扩展到完整环境生成，从初始语料库合成多样化的仿真世界（采用规划域定义语言或健身房风格格式）。它实现了双向进化回路，逐步调整任务难度，使智能体能够在动态结构化的课程中持续成长。反思 (Reflexion) (Shinn et al., 2023) 通过引入自我反思机制对此进行补充，智能体迭代记录对其先前行为的自然语言批评，指导未来行为以避免重复错误。此外，自适应规划器 (AdaPlanner) (Sun et al., 2023) 引入了闭环自适应规划，使智能体能够根据环境反馈即时优化策略，有效地根据即时结果重塑动作序列。类似地，自我精炼 (Self-Refine) (Madaan et al., 2023b) 采用迭代精炼回路，智能体反复批评和修订其初始输出，在无需显式再训练的情况下显著提高任务准确率。自改进编码智能体 (Self-Improving Coding Agent, SICA) (Robeyns et al., 2025b) 进一步拓展了边界，使智能体能够自主编辑其底层代码和工具，通过直接自我修改迭代增强其核心推理能力。从强化学习的角度来看，诸如 RAGEN (Wang et al., 2025q) 和 DYSTIL (Wang et al., 2025c) 等框架将多步工具使用任务概念化为马尔可夫决策过程，通过丰富的环境奖励和策略归纳回路优化智能体策略。RAGEN 利用来自环境的密集反馈迭代微调动作策略，而 DYSTIL 利用语言模型生成的高层策略建议，逐步将复杂决策技能内化到强化学习智能体中。总体而言，这些方法突显了一种引人注目的范式，即自进化智能体不仅利用自生成数据，还主动重塑其环境和内部机制以推动持续学习。这种动态交互回路指向了深深植根于经验适应的自主、开放式改进循环。

3.2 上下文

待演化的 LLM 智能体的一个基本组成部分是上下文，它塑造了智能体的行为方式。首先，我们希望解释两个术语：“提示优化”和“记忆演化”，它们在不同文献中被使用。在大多数情况下，这两个术语可以互换使用，因为它们都指上下文窗口中所包含的内容。提示优化问的是“我们如何措辞或组织指令，使 LLM 表现更好？”，并关注措辞、顺序等细节。另一方面，记忆演化问的是“我们应该如何存储、遗忘和检索上下文，以便智能体保持信息灵通并表现更好？”，它侧重于将哪些过去的信息呈现出来或归档。

3.2.1 记忆演化

基于 LLM 的智能体越来越多地设计有长期记忆机制，这些机制随着智能体持续解决任务并与环境交互而增长和适应 (Shan 等, 2025; Qian 等, 2023a)。不断演化的记忆使智能体能够积累知识、回忆过去事件，并根据经验调整其行为。许多工作强调，有效的记忆管理对于智能体性能至关重要 (Zhong 等, 2024; Zhang 等, 2025e; Yan 等, 2024)。SAGE (Liang 等, 2024) 使用艾宾浩斯遗忘曲线来决定记住或遗忘什么。A-mem (Xu 等, 2025a) 通过动态索引和链接更新智能体记忆结构，以创建相互连接的知识网络，遵循基本

Zettelkasten 方法的原则。Mem0 (Chhikara 等人, 2025) 引入了一个两阶段流水线, 其中智能体首先从近期对话中提取显著事实, 然后决定如何更新长期记忆: 智能体可以添加新事实、合并/更新冗余事实, 或删除矛盾事实。此外, Memory-R1 (Yan 等人, 2025) 提出了一个强化学习框架, 用于训练一个专门的记忆管理器智能体, 该智能体学习选择结构化操作, 如添加、更新和删除。这种机制确保了智能体的长期记忆是连贯且最新的。MemInsight (Salama 等人, 2025) 通过语义结构增强原始记忆, 对过去的交互进行总结和标记, 以便后续检索。REMEMBER (Zhang 等人, 2024a) 将大语言模型与经验记忆相结合, 并使用强化学习信号来决定在每个回合后如何更新该记忆。Memento (Zhou 等人, 2025b) 通过采用在线强化学习来优化案例检索策略, 实现了无需微调大语言模型参数的持续适应, 使智能体能够从存储在不断演变的记忆库中的过去经验中学习。MemGen (Zhang 等人, 2025f) 引入了一种在潜空间中运行的动态生成记忆。它使用学习到的记忆触发器来决定何时调用记忆, 并使用编织器构建潜令牌序列, 从而实现推理与记忆的流畅交织。

记忆进化的一个关键方面是使智能体能够从过往经验中学习启发式方法或技能。先进的智能体并非仅检索确切的过往实例, 而是将经验提炼为更通用的指导 (Zhao et al., 2024a; Fu et al., 2024)。Expel (Zhao et al., 2024a) 处理过往轨迹以生成洞见和规则, 从而指导后续交互。这种经验知识的积累带来了可衡量的收益, 因为智能体随着经验的增加而表现稳步提升。ReasoningBank (Ouyang et al., 2025) 进一步发展了这一思想, 将成功和失败经验中可泛化的推理策略提炼为结构化记忆。它还引入了记忆感知的测试时扩展, 以在每个任务上生成多样化的经验。其他系统则专注于存储问题解决的更高层次构建模块。例如, 智能体工作流记忆 (Agent Workflow Memory) (Wang et al., 2024j) 记录常见的子任务序列 (工作流), 使得解决复杂任务的智能体能够检索并重用经过验证的动作序列, 而非从头规划。类似地, MUSE (Yang et al., 2025a) 引入了一种面向长时程任务的经验驱动型智能体, 其核心是一个分层记忆模块, 将经验组织为策略性、程序性和工具使用性记忆。该智能体通过“规划-执行-反思-记忆”循环来填充此记忆, 从而在工作中学习。在 Richelieu 外交智能体中, 系统通过自我博弈游戏增强记忆, 存储模拟交互中的洞见以改进未来决策 (Guan et al., 2024)。通过将具体情节泛化为可复用的知识, 这些方法展示了记忆进化如何将智能体的一次性经验转化为长期能力, 从而推动智能体的进化。

3.2.2 提示优化

虽然记忆演化关注智能体保留何种知识, 但提示优化 (Prompt Optimization, PO) 使大语言模型智能体能够通过精炼其提供给骨干模型的指令来实现自我演化, 从而在不修改模型权重的情况下直接改变模型行为 (Ramnath 等, 2025)。早期研究将指令设计视为搜索问题。APE (Zhou 等, 2022) 生成候选提示, 在验证示例上评分, 并选择最佳者。ORPO (Yang 等, 2023) 扩展了这一思想, 让模型根据先前输出的反馈迭代重写自身提示。ADO (Lin 等, 2025a) 引入 DSP, 对迭代提出的提示施加语义约束, 以促进找到最优提示。ProTeGi (Pryzant 等, 2023) 生成自然语言“修正”, 作为对提示的编辑, 形成梯度下降的文本类比。PromptAgent (Wang 等, 2023d) 将提示发现视为蒙特卡洛树搜索, 策略性地探索指令空间, 而 PromptBreeder (Fernando 等, 2023) 等演化方法则维持一个种群以发现越来越有效的指令。REVOLVE (Zhang 等, 2024e) 通过跟踪模型响应的轨迹并应用平滑更新, 进一步稳定了长优化过程。将这种自主性推向极限, SPO (Xiang 等, 2025) 创建了一个完全自包含的循环, 模型生成其训练数据, 并利用对其输出的成对偏好比较来精炼提示, 从而消除了对外部标注数据或人类反馈的需求。这些技术共同表明, 智能体能够自主改进其提示策略, 将提示文本转化为一个可学习的组件, 与智能体的经验共同演化。为了解决某些优化器的简洁性偏差和上下文坍塌问题, 智能体上下文工程 (Agentic Context Engineering, ACE) (Zhang 等, 2025m) 将上下文视为全面的策略手册, 随时间积累策略。它使用一个

模块化智能体过程，通过增量更新来演化上下文，用于离线提示优化和在线记忆适应。

在复杂系统中，智能体通常编排一系列大语言模型调用或与其他智能体协作，使得提示设计成为一个多节点问题。诸如 DSPy 等框架将整个工作流表示为图，其子提示针对全局目标进行联合调优（Khattab 等，2023）。Trace（Wang 等，2023c）、TextGrad（Yellamraju 等，2024）和 LLM-AutoDiff（Yin & Wang，2025）将这一思想推广，将每个提示视为可微分程序中的参数，并传播自然语言“梯度”以细化每一步。在协作场景中，多智能体系统搜索（MASS）（Zhou 等，2025a）首先优化个体角色提示，然后细化智能体间通信模式，而 MAS-ZERO（Ke 等，2025）动态提出并修订角色提示，为每个新问题组建高效团队。进化系统如 EvoAgent（Yuan 等，2024b）和 AgentSquare（Shang 等，2025）将每个智能体及其提示视为模块，利用变异和选择发现优于手工设计的专业团队。这些方法将提示优化从单一指令扩展到定义整个工作流或智能体社会的语言。

3.3 工具

智能体的能力从根本上由其可运用的工具所定义。智能体发展的轨迹标志着一个关键演变：从单纯的工具使用者转变为自主的工具制造者。这一从依赖预定义静态工具集到使智能体能够自主扩展和完善自身技能的转变，是迈向认知自给自足的关键飞跃。这种智能体动态调整自身能力的范式，使其能够解决初始设计者未曾设想的众多复杂问题。这一演变在三个相互关联的方面展开：工具发现、掌握与管理，详见下文各小节。

自主发现与创造 自主工具创建的主要动力在于克服固定工具集的固有局限性，赋予智能体按需创新的灵活性。目前，相关方法已从机会式发现延伸至形式化综合。在一端，像 Voyager 这样的智能体通过涌现式试错构建不断扩展的技能库，其驱动力源于探索复杂开放环境（如《我的世界》）的内在动机（Wang 等，2023a）。这种探索性方法在生成广泛技能方面能力强大，但可能缺乏精确性。相比之下，ATLASS、Alita 和 Live-SWE-Agent 等系统采取更具反应性的方法，通常在识别到能力缺口时，从零开始创建新工具，或采用检索增强生成（Retrieval-Augmented Generation, RAG）搜索开源代码仓库（Haque 等，2025；Qiu 等，2025b；a；Xia 等，2025a）。在另一端，则是高度结构化的框架，将工具创建视为一种审慎的工程过程。例如，CREATOR 将抽象工具创建（如推理一个可复用函数的通用结构，用于计算 N 天平均温度）与具体工具使用（如决定如何将该函数应用于特定城市和时间范围）解耦，从而增强模块化和可复用性（Qian 等，2023b）。更为形式化的是，SkillWeaver 分析成功的人类或智能体任务轨迹，提出、综合并打磨新技能，形成稳健、可复用的应用程序编程接口（API），确保更高的初始质量（Zheng 等，2025a）。此外，CRAFT 等框架表明，为特定领域创建专用工具集对于补充通用模型至关重要，能够在保持适应性的同时实现专家级性能（Yuan 等，2024a）。RL-GPT（Liu 等，2024）将生成的代码实现集成到强化学习流程中，将其作为工具来应对复杂任务，同时采用代码即策略（Code-as-Policy）方法直接处理较简单的任务。这种集成能够根据环境反馈动态调整和演化，实现持续改进。然而，这种新兴的自主性带来了重大挑战，尤其是在安全与保障方面。不受约束的代码生成可能产生带有可利用漏洞或意外有害行为的工具，这使得自动化验证和沙箱化成为未来研究的关键领域。

Mastery Through Iterative Refinement The proliferation of self-created tools necessitates a robust mechanism for their mastery; a newly generated tool is often a brittle script, not a reliable function. This is where iterative refinement becomes essential. Frameworks like LearnAct and From Exploration to Mastery establish a critical self-correction loop where the agent learns from its own experience (Zhao et al., 2024b;

Qu 等人, 2025)。这涉及解决困难的“信用分配”问题：精确确定哪一行代码或哪个参数导致了失败。为此，智能体分析丰富的反馈信号——包括编译器错误、意外的应用程序编程接口（API）返回值、环境状态变化，甚至用户后续操作中的隐式信号。目标不仅是调试工具底层代码，还要完善其文档（例如文档字符串和参数描述），这对于提升智能体未来理解并正确使用该工具的能力至关重要。这一完善过程也为有价值的人机协作打开了大门。虽然完全自主是最终目标，但许多系统可以设计为“人在回路”模式，由人类专家提供纠正、高层建议或验证新创建的工具。这种协作方式能显著加速掌握过程，并确保智能体的技能符合人类意图和安全标准。最终，这种自我磨砺过程将初生技能提升为可靠能力，确保智能体不断增长的技能库不仅在数量上增加，更重要的是在质量和鲁棒性上提升。

可扩展的管理与选择 当智能体的已掌握技能库增长到数百或数千时，它会面临“丰裕之咒”。挑战从创建工具转变为高效地管理和选择工具。大型库产生了巨大的搜索空间，使得传统检索方法既缓慢又不准确。为了克服这一点，ToolGen (Wang et al., 2025k) 代表了一种根本性的范式转变，它将工具编码为语言模型词汇表中的独特标记。这巧妙地将工具检索重新定义为生成问题，利用变换器（transformer）强大的模式识别能力，将最合适的工具预测为其思维过程的自然延续。TOOLMEM (Xiao et al., 2025b) 使智能体能够在专用记忆中学习并存储不同工具的优缺点。在推理时，智能体检索这些知识以做出更明智的决策，从而针对特定任务需求优化工具选择。除了选择单一工具之外，高级智能体还必须擅长工具组合——学习以新颖的顺序链接多个工具来解决多步骤问题。这是一项更高阶的管理任务。像 AgentSquare 这样的架构方法参与了一种元学习（meta-learning）形式，自动搜索智能体的模块化设计空间——包括其规划、记忆和工具使用组件——以找到用于复杂任务执行的最优配置 (Shang et al., 2025)。作为这一进化趋势的逻辑终点，像 Darwin Godel Machine 这样的前瞻性概念提出了一个开放式进化框架，其中智能体可以从根本上重写自己的核心代码。在这一愿景中，智能体与其工具之间的区别变得模糊，导致递归的自我改进级联，超越了单纯的工具增强 (Zhang et al., 2025h)。本质上，这整条进化路径旨在建立一个封闭且良性的循环：一个真正自主的智能体，能够感知自身能力的差距，创造新颖的解决方案，通过实践掌握它们，并无缝地将它们整合到一个连贯管理且不断扩展的技能库中。

3.4 架构

下一代智能体系统的决定性特征是其固有的自我改进能力。这标志着从固定能力系统向能够自主提升性能的系统的根本性转变 (Liu et al., 2025b)。通过将自身内部逻辑和协作结构视为可优化组件，这些系统能够根据反馈调整其行为和设计，达到静态设计无法企及的效率和有效性水平。本节详细阐述这种自我优化如何实现，首先考察单智能体系统内的改进，然后探讨复杂多智能体系统的协同演化。

3.4.1 单智能体系统优化

大语言模型调用节点优化 优化单次大语言模型（LLM）调用在孤立场景下较为直接，但在智能体系统中，这演变为一个困难的信用分配问题，因为任何单一变更的效果都会被后续步骤所掩盖。研究通过使节点级组件可优化来应对这一挑战，主要遵循两种策略。第一种策略侧重于在固定的智能体拓扑结构内精化节点。一个典型例子是文本梯度（TextGrad）(Yellamraju 等, 2024)，其受反向传播启发，利用“文本梯度”将反馈从最终输出沿 workflow 反向传播，引导系统性的局部优化。

在不改变系统整体结构的前提下，对每个节点进行细化。第二种并行策略将这种组件级优化直接融入系统架构本身的搜索过程中。在该方法下，节点特征成为更大搜索空间中的可调参数。例如，框架可以将提示工程直接嵌入搜索循环，使系统不仅能发现最优工作流，还能同时为每个智能体找到最有效的指令（Zhou 等，2025a）。类似地，EvoFlow（Zhang 等，2025c）利用进化算法，通过从多样化的模型池中为每个任务选择最合适的大语言模型来构建异构工作流。这种整体策略能够发现结构与个体智能体能力协同优化的系统，从而有效平衡整体性能与成本等度量指标（Ye 等，2025a）。

自主智能体优化 在优化单个大语言模型调用节点的基础上，更深层次的自我改进将自主智能体视为一个整体实体。这一演进沿两条主线展开：优化智能体的高层架构设计，以及使智能体能够直接修改其自身源代码。第一种方法聚焦于发现最优的智能体结构。AgentSquare（Shang 等，2025）通过定义一个由规划器和记忆模块等组件构成的模块化设计空间，并利用进化算法为给定任务寻找最有效的组合，体现了这一思路。第二条主线涉及动态重写自身运行代码的智能体。这在诸如达尔文哥德尔机（Darwin Gödel Machine, Zhang 等，2025h）和 AlphaEvolve（Novikov 等，2025）等激进系统中可见，前者递归地修改其自身的 Python 代码库，后者利用进化编码改进特定算法。类似地，哥德尔智能体（Gödel Agent, Yin 等，2025）提供了一个自指框架，使智能体能够分析并修改其逻辑。这两个方向（优化智能体的架构“蓝图”及其功能代码）共同展示了一个关键趋势：将智能体的基本结构和逻辑转变为可学习的组件。MemEvolve（Zhang 等，2025g）引入了一个元进化框架，不仅进化智能体的经验记忆，还进化记忆系统本身的架构。通过双层优化过程，它调整编码、存储和检索信息的机制，以更好地适应特定任务领域。

3.4.2 多智能体系统优化

智能体在系统中的组织方式和通信方式（即其拓扑结构）从根本上决定了其解决复杂问题的能力。该领域已从使用固定的、人工设计的通信结构，发展到创建能够自动调整其组织以适应给定任务的动态系统，从而使它们能够发现并利用最有效的协作模式。这一演进沿两条主线展开：静态显式工作流的优化，以及动态内部策略的协同进化。

智能体工作流优化 智能体工作流（Agentic Workflow）的优化聚焦于为给定问题寻找最有效且通常静态的通信与任务委派结构。早期研究奠定了重要基础，例如自动流（AutoFlow）（Li 等，2024d）展示了从自然语言自动创建线性工作流，而群体智能体（GPTSwarm）（Zhuge 等，2024）提出了统一的基于图的框架。同时，其他基础性工作探索了智能体如何通过符号学习将交互经验提炼为显式、可解释的逻辑规则集，以指导未来决策（Zhou 等，2024b）。将系统抽象为可调组件——无论是节点、边还是符号规则——至关重要。然而，这些早期系统往往缺乏高效探索庞大配置与交互空间的形式化方法。

重大突破出现在自适应智能体系统（ADAS）（Hu 等，2024c）和自动流（AFlow）（Zhang 等，2024c）将这一挑战正式定义为搜索与优化问题。ADAS 通过将系统设计视为在基于代码配置的图灵完备空间中进行搜索，确立了理论愿景。在此基础上，AFlow 通过引入表示常见智能体模式的可复用算子，并采用蒙特卡洛树搜索（Monte Carlo Tree Search, MCTS）高效导航巨大的设计空间，使其变得实用。这些工作共同确立了将智能体系统设计视为可处理优化问题的核心方法论，证明了自动发现的工作流能够超越人工设计的工作流。

在此形式化之后，研究迅速多样化，转向为每个具体查询创建定制化的智能体系统。出现了两种主要策略：基于搜索的生成和基于学习的生成。基于搜索的

此类方法，如 MaAS (Zhang 等, 2025d)，构建潜在架构的“超网”，并从中采样专用系统。与此同时，基于学习的方法训练模型直接生成有效拓扑。例如，ScoreFlow (Wang 等, 2025n) 采用新颖的偏好优化方法训练生成器，而 FlowReasoner (Gao 等, 2025) 利用强化学习训练元智能体，动态构建定制工作流。这种针对特定查询的生成方向仍是活跃的研究领域 (Ye 等, 2025b; Ke 等, 2025)。此外，值得注意的是，该过程不仅限于拓扑本身：许多此类框架还同时进行节点级优化，例如将提示协同优化或异构模型选择作为架构生成过程的有机组成部分 (Zhang 等, 2024c; Zhou 等, 2025a; Zhang 等, 2025c)。

所有搜索与学习方法面临的一个关键挑战是评估每个潜在工作流的计算成本 (Shang 等, 2025)。为解决这一问题，研究者开发了轻量级预测模型。Agentic Predictor (Trirat 等, 2025) 是一个典型例子，它训练模型基于工作流的结构和语义特征准确估计其性能，而无需完整执行。通过提供快速且低成本的评估代理，这些预测器显著加速了优化过程，使探索庞大设计空间成为可行 (Zhang 等, 2025s)。

多自主智能体优化 与优化系统显式工作流结构不同，这一研究方向关注多个自主智能体如何通过交互共同演化其内部行为策略。该方法能够涌现出协调、任务委派和良性竞争等能力。例如，ReMA (Wan 等, 2025) 利用多智能体强化学习 (MARL) 协同训练高层元思考者和低层执行者，显著提升了推理基准上的性能。在此基础上，GiGPO (Feng 等, 2025b) 通过聚合轨迹来提供更精确的信用分配，从而增强多智能体强化学习训练，提高了长时程任务的成功率。为支持这一方向，MARTI (Liao 等, 2025) 等平台提供了开源基础设施，用于编排和扩展这些语言模型集体的训练。总体而言，这些研究强调了多智能体强化学习作为培养个体智能体无法单独实现的群体级能力的有前景的途径。

4 何时演化

基于大语言模型的智能体自演化的时间维度主要涉及学习过程与任务执行之间的关系。因此，自演化智能体的第二个关键方面是确定演化时机，即在哪个阶段调用自演化策略 f 并将其应用于智能体系统。为此，我们提出一种分类法，区分两种时间模式的自演化：测试时内自演化和测试时间自演化。

测试时内自演化 指在任务执行过程中发生的自适应过程，智能体识别其在特定问题上的局限性，并启动有针对性的学习机制以实时增强其能力 (Xi 等, 2024; Bi 等, 2024)。这种演化模式的特点是与当前任务的即时耦合：智能体针对遇到的特定问题提升其问题解决能力，在性能与适应之间形成动态交互。

测试时间自演化 指的是在任务完成之间发生的学习过程，利用积累的经验来提升未来表现。这一类别涵盖了多种方法论途径：离线学习范式通过迭代精炼从预先收集的数据集中提取知识 (Zelikman 等, 2022; 2024)，在线学习范式则基于流式交互数据持续适应 (Qi 等, 2024; Qiu 等, 2025b; Qian 等, 2024b; Wang 等, 2025o)。

在这些时间阶段中实现自我进化，利用了大型语言模型中的三种基本学习范式：上下文学习 (ICL) (Dong 等, 2022; Min 等, 2021; Wies 等, 2023)，通过上下文示例调整行为而不修改参数；监督微调 (SFT)，通过基于梯度的优化在标注数据上更新模型权重 (Devlin 等, 2018; Shen, 2024; Dong 等, 2023)；以及强化学习 (RL)，通过奖励驱动的策略优化塑造行为 (Kaelbling 等, 1996; Sun 等, 2024a; Zhang 等, 2025n)。虽然这些学习




图 5: 何时进化的概览。上方路径展示了测试时内自我进化, 其中适应 (例如变体生成、验证和策略更新) 发生在任务执行过程中。下方路径描绘了测试时间自我进化, 其中学习通过回放、轨迹分析和策略更新在事后发生。

范式在不同时间背景下在概念上保持一致, 但它们在数据可用性和学习目标方面的实例化有所不同:

测试时内自演化的特征在于其在线性质: 学习数据在任务执行过程中动态涌现, 优化目标直接针对当前问题实例的性能提升。这种实时耦合要求具备快速适应机制, 能够处理学习数据与反馈信号, 并在主动任务求解的时间约束内调整行为。另一方面, 测试时际自演化的特征在于其回顾性质: 学习算法作用于历史数据, 无论这些数据来自精心整理的数据集还是累积的行为轨迹, 其优化目标面向提升任务分布上的期望性能, 而非最大化任何特定问题实例的成功率。这种时间解耦使得更复杂的学习过程成为可能, 能够识别跨任务模式、整合多样经验, 并在不受主动任务执行即时性约束的情况下发展可泛化能力。

4.1 测试时内自演化

在测试时内自演化中, 智能体进行的自我改进过程与解决当前任务内在地耦合。这一时间阶段的显著特征是其同步性: 反馈信号在任务执行期间生成并处理, 优化目标专门针对提升当前问题实例的性能, 而非泛化到未来任务。在此, 我们介绍三种学习范式如何在这一时间阶段得以实现。

上下文学习 测试时上下文学习 (Intra-test-time ICL) 方法将模型的上下文窗口用作动态记忆系统, 以便在不修改参数的情况下即时适应。这些方法通常采用自我反思机制, 智能体分析自身性能, 生成口头批评或洞见, 并将这些反思保存在情景记忆缓冲区中, 以指导同一任务上下文中的后续决策 (Shinn 等, 2023; Madaan 等, 2023a)。一些方法超越了简单的反思, 包括动态计划修订, 智能体可以根据环境反馈修改其整体方法, 在动作执行和计划修改之间按需切换。例如, AdaPlanner (Sun 等, 2023) 将任务分解为可管理的子目标, 并预测每个子目标的环境反馈。在执行过程中, 其精炼器组件区分计划内反馈 (与预测一致的观察) 和计划外反馈 (偏离的观察)。对于计划内反馈, 精炼器通过专门的 `ask_LLM()` 动作动态查询大语言模型 (LLM), 以解析观察并提取相关信息。对于计划外反馈, 精炼器主动修订整个计划, 并从中间点继续求解, 而不是从头开始。这种自适应闭环框架消除了对反馈结构先验知识的需求, 并实现了更高效的决策。类似地, TrustAgent (Hua 等, 2024) 在执行过程中采用基于规则的计划修订, 根据语言反馈修改其方法, 以向更安全的规划策略演进。这些上下文学习方法展示了测试时自适应如何在永久改变模型的情况下实现复杂的行为修改, 在保持灵活性的同时保留了模型的通用能力。

基于语言反馈，以向更安全的规划策略演进。这些上下文学习方法展示了测试时自适应如何在不永久改变模型的情况下实现复杂的行为修改，在保持灵活性的同时保留了模型的通用能力。

监督微调。

其中模型立即执行

通过习得的元适应策略实现即时自我修正。自适应语言建模（Self-adaptive Language Modeling）（Zweiger 等，2025）通过生成“自我编辑”来体现这一方法，这些自我编辑是元级指令，能够重构信息表示、指定优化超参数，或调用工具进行数据增强和梯度计算。这些自我编辑触发即时的监督微调，产生持久的权重更新，使模型适应当前任务。关键创新在于元学习阶段，强化学习通过将更新后模型的下游性能作为奖励信号来训练模型生成有效的自我编辑，本质上是在教模型如何自我教学。Acikgoz 等（2025）提出了测试时自我改进（Test-Time Self-Improvement, TT-SI）框架，该框架使智能体能够通过自我意识首先识别不确定的测试样本，从而进行即时适应。对于这些具有挑战性的输入，智能体随后生成一个合成训练示例，并执行一次临时的轻量级参数更新，以在重置权重之前提升其即时性能。

强化学习。测试时内部强化学习使模型在遇到超出其当前能力的问题时能够按需发展新能力。LADDER（Simonds 与 Yoshiyama，2025）通过其测试时强化学习（Test-Time Reinforcement Learning, TTRL）机制证明了这一点：在识别出一个特别具有挑战性的问题后，系统会生成一组针对性的相关问题变体，并专门针对该问题类别进行密集的、有针对性的强化学习。这种方法将难以克服的挑战转化为学习机会，使模型能够在部署期间扩展其问题解决能力，而不是失败或提供次优解决方案。该方法代表了一种即时技能获取的形式，计算资源在最需要的时间和地点被精确投入。

4.2 测试时之间的自我进化

测试间自我进化代表了自主智能体中的主要学习过程，其中适应发生在任务执行之后而非执行期间。在这种时间模式下，智能体完成给定任务，提取反馈信号，包括显式奖励（Gao 等，2024）、梯度（Amari，1993；Bottou，2010）和性能度量（Ge 等，2023），随后利用这些信息增强其未来解决问题的能力。这种回顾性学习过程将任务执行与能力提升解耦，使智能体能够巩固经验、识别成功与失败的模式，并在不受实时任务需求计算约束的情况下系统地优化其行为策略。

上下文学习。测试间上下文学习已成为智能体自我改进的一种广泛采用的方法。该范式利用先前任务的执行结果和反馈作为未来问题解决的上下文信息。Wang 等（Wang 等，2024j）通过从智能体动作历史中归纳 workflow 并将其纳入后续任务的上下文来证明这一原理。上下文强化学习（ICRL）领域（Mocini 等，2025；Laskin 等，2022；Lee 等，2023）通过将观察和动作的历史保持在智能体的上下文窗口内来扩展这一概念。这些方法利用了这样一个假设：预训练的神经网络可以在其前向传播中实现隐式强化学习算法，通过处理上下文信息来适应行为而无需参数更新（Kirsch 等，2023）。ICRL 的一个定义性特征是上下文内改进：随着任务相关信息在上下文中积累，智能体性能逐步提升的现象，通过注意力机制而非基于梯度的学习实现复杂的适应。

监督微调。测试间监督微调（SFT）方法（Chen 等，2025b）通过合成数据生成和自我评估建立了一种迭代自我改进的范式。SELF（Lu 等，2023）开创了元认知训练，其中模型首先获得自我反馈和自我优化能力，

然后迭代地为未标注指令生成响应，并通过自我批判加以增强。STaR（Zelikman 等，2022）和 Quiet-STaR（Zelikman 等，2024）专注于通过合理化提升推理能力——模型尝试解决问题，然后为最初未能解决的正确答案生成解释，从而创建结合成功尝试与事后推理的增强训练数据。Sirius（Zhao 等，2025b）将这一方法扩展到序列问题求解，维护正确解库，同时通过多阶段细化（包括反馈整合、重新生成和改写）来增强失败案例。这些方法共享一个核心洞见：模型可以通过学习评估和增强自身输出来引导自我改进，从最初不完美的尝试中生成高质量训练信号，而无需大量人工监督。最近的框架如 ARIA（He 等，2025a）进一步扩展了这一范式，将人在回路指导纳入测试时自适应，使智能体能够主动识别知识缺口并请求专家反馈。

强化学习。测试间强化学习利用不受约束的计算资源，通过广泛的环境交互和复杂的课程设计来优化智能体。RAGEN（Wang 等，2025q）和 DYSTIL（Wang 等，2025c）在多轮交互任务中采用在线强化学习，通过在模拟对话中进行在线策略学习来持续优化策略。Learning Like Humans（Zhang 等，2025a）引入了受认知启发的训练方法，具有自适应难度递进，结合在线策略探索与离线策略效率以及专家演示来加速学习。领域特定应用展示了测试间强化学习的多样性：WebRL（Qi 等，2024）通过自进化课程开发网页导航智能体，根据性能自动调整任务复杂度；DigiRL（Bai 等，2024）使设备控制智能体能够通过自主强化学习掌握真实世界交互。这些方法利用部署前阶段进行大量试错学习，通过数千次交互开发稳健策略，这在实时部署期间是不切实际的。

5 如何进化

追求自我进化是构建先进、自主且日益通用的人工智能的核心所在。对于大语言模型（Large Language Model）及其智能体扩展而言，如何持续、自主且高效地进化其能力已成为一项核心挑战。因此，自进化智能体的第三个关键方面是实例化一种有效的进化策略 f ，即如何将智能体系统 $\Pi = (\Gamma, \{\psi_i\}, \{C_i\}, \{\mathcal{W}_i\})$ 转换至其新状态 $\Pi' = (\Gamma', \{\psi'_i\}, \{C'_i\}, \{\mathcal{W}'_i\})$ 。与传统依赖静态数据集或一次性监督微调的方法不同，自我进化强调一个持续的过程，模型从现实世界交互中学习，主动寻求反馈，进行自我反思，生成或筛选新数据，并根据动态环境调整其策略。这种持续进化不仅仅是扩大数据或计算规模的问题；它要求智能体获得一系列元能力，包括自我纠正、自主数据生成、知识迁移和多智能体协作。因此，自我进化的格局已变得日益丰富和多面，每个方法分支都在探索反馈、学习范式、数据来源和进化尺度的不同维度。

随着时间推移，自进化智能体的研究已历经三大范式——基于奖励、基于模仿和基于群体的进化——每一种范式的出现都是为了解决前一种范式的局限性。基于奖励的方法首先通过显式信号闭合了反馈回路，但存在脆弱性和高成本的问题。基于模仿的学习通过利用高质量示范稳定了进化过程，尽管有时以牺牲探索为代价。基于群体的进化随后将适应性扩展至集体规模，强调多样性和涌现协调。这些范式共同勾勒出一条从个体自我改进迈向集体智能的连贯轨迹。

本章旨在系统地梳理和分析自进化方法的主要家族，为理解其原理、机制和相互作用提供一个统一框架。我们首先从基于奖励的进化入手，其核心在于设计奖励信号——从自然语言反馈和内部置信度量到外部或隐式信号——以引导迭代式自我改进。

表 3: 基于奖励、模仿/演示和群体学习的自进化智能体方法概览。本表依据以下标准对关键方法进行分类：（1）反馈类型：所使用的反馈类型，包括基于语言的推理和数值奖励。（2）反馈来源：反馈的起源，分为内部（模型生成）或外部（外部提供）。（3）学习方法：所应用的学习范式，如上下文学习（ICL）、监督微调（SFT）、强化学习（RL）和进化算法；（4）更新组件：模型中被更新的部分，可以是全部参数或模型子集。（5）更新时机：智能体进化过程中应用更新的阶段，如预训练、测试前或测试时。

Method	Feedback Type	Feedback Source	Learning Method	Updated Components	Update Timing
<i>Reward-based Evolution Methods</i>					
Reflexion(Shinn et al., 2023)	language	internal	ICL	context	test-time
AdaPlanner(Sun et al., 2023)	language	external + internal	ICL	context	test-time
AgentS2(Agashe et al., 2025)	language	external	ICL	context	test-time
SELF(Lu et al., 2023)	language	external + internal	SFT	full params	pre-test time + test-time
SELF-REFINE(Madaan et al., 2023a)	language	internal	ICL	context	test-time
SCoRe(Kumar et al., 2024)	numerical	external	RL	full params	pre-test time
PAG(Jiang et al., 2025b)	numerical	external	RL	full params	pre-test time
TextGrad(Yellamraju et al., 2024)	language	external	ICL	context	pre-test time / test-time
SRSI(Simonds et al., 2025)	language	internal	RL	full params	pre-test time
Self-Train LM(Shafayat et al., 2025)	numerical	internal	RL	full params	pre-test time
MM-UPT(Wei et al., 2025c)	numerical	internal	RL	full params	pre-test time
CoVo(Zhang et al., 2025j)	numerical	internal	RL	full params	pre-test time
SWE-agent(Du et al., 2025)	language	external	ICL	context	test-time
SICA(Robeyns et al., 2025a)	numerical	external	ICL	codebase(tools, workflows, prompts)	test-time
Feedback Friction(Jiang et al., 2025a)	language	external	ICL	context	test-time
USEagent(Applis et al., 2025)	language	external	ICL	context	test-time
DYSTIL(Wang et al., 2025c)	language + numerical	external + internal	SFT+RL	full params	pre-test time + test-time
OTC-PO(Wang et al., 2025h)	numerical	external	RL	full params	pre-test time
AUTORULE(Wang & Xiong, 2025)	language + numerical	external + internal	RL	full params	pre-test time
EGSR(Zhang et al., 2025a)	numerical	external	RL	full params	pre-test time
LADDER(Simonds & Yoshiyama, 2025)	numerical	external	RL	full params	pre-test time
RAGEN(Wang et al., 2025q)	numerical	external	RL	full params	test-time
SPIRAL(Liu et al., 2025d)	numerical	internal	RL	full params	pre-test time
ICRL Prompting(Song et al., 2025)	numerical	external + internal	RL	full params	test-time
MATH-SHEPHERD(Wang et al., 2023b)	numerical	external	RL	full params	pre-test time
AgentPRM(Choudhury, 2025)	numerical	external	SFT+RL	full params	pre-test time
Agent Q(Putta et al., 2024)	numerical	external	RL	full params	pre-test time
GiGPO(Feng et al., 2025a)	numerical	external	RL	full params	pre-test time
SPA-RL(Wang et al., 2025d)	numerical	external	RL	full params	pre-test time
Self-Instruct(Wang et al., 2022)	language	internal	SFT	full params	pre-test time
WizardLM(Xu et al., 2024a)	language	internal	SFT	full params	pre-test time
OS-Genesis(Sun et al., 2024b)	numerical	external	SFT	full params	pre-test time
UI-Genie(Xiao et al., 2025a)	numerical	external	SFT	partial params	pre-test time
GUI-R1(Luo et al., 2025b)	numerical	external	SFT+RL	full params	pre-test time
InfGUI-R1(Liu et al., 2025e)	numerical	external	SFT+RL	full params	pre-test time
Voyager(Wang et al., 2023a)	language	external	ICL	context	test-time
SwiftSage(Lin et al., 2023)	language	external	ICL	context	test-time
AutoWebGLM(Lai et al., 2024)	language	external	SFT+RL	full params	pre-test time
DigiRL(Bai et al., 2024)	language	external	RL	partial params	pre-test time
WebRL(Qi et al., 2024)	language	external	SFT+RL	full params	pre-test time
Let's Verify Step-by-Step(Lightman et al., 2023)	language	external	SFT	full params	pre-test time
AlphaMath(Chen et al., 2024a)	numerical	external	SFT	full params	pre-test time
rStar-Math(Guan et al., 2025)	numerical	external	SFT	full params	pre-test time
DistRL(Wang et al., 2024g)	language	external	RL	full params	pre-test time + test-time
MobileGUI-RL(Shi et al., 2025b)	language	external	RL	full params	pre-test time
<i>Imitation and Demonstration Learning Methods</i>					
STaR(Zelikman et al., 2022)	language + numerical	internal	SFT	full params	pre-test time
V-STaR(Hosseini et al., 2024)	numerical	external + internal	SFT + RL	partial params	pre-test time
AdaSTaR(Koh et al., 2025)	numerical	internal	SFT	full params	pre-test time
STIC(Deng et al., 2024)	language	internal	RL + SFT	partial params	pre-test time
GENIXER(Zhao et al., 2024c)	language	external	SFT	full params	pre-training
Sirius(Zhao et al., 2025b)	language + numerical	internal	SFT	full params	pre-test time
SOFT(Tang et al., 2025)	language	internal	SFT	not specified	pre-test time
RISE(Qu et al., 2024b)	language + numerical	internal + external	SFT	full params	pre-test time
IoE(Li et al., 2024b)	numerical	internal	/	/	test-time
<i>Population-based and Evolutionary Methods</i>					
DGM(Zhang et al., 2025h)	numerical	external	ICL	codebase (tools, workflows, prompts)	test-time
EvoMAC(Hu et al., 2024d)	language	external	ICL	team composition, workflow, prompts	test-time
SPIN(Chen et al., 2024f)	language	internal	RL	full params	pre-test time
GENOME(Zhang et al., 2025r)	numerical	external	Evolution Alg.	partial params	pre-test time
SPC(Chen et al., 2025c)	numerical	internal	SFT+RL	critic params	pre-test time + test-time
Puppeter(Dang et al., 2025)	numerical	external	RL	planner policy	pre-test time / between tasks
MedAgentSim(Almansoori et al., 2025b)	language	external	ICL	context (knowledge base)	test-time
STL(Mendes & Ritter, 2025)	language + numerical	internal	SFT	value model	pre-test time
MDTeamGPT(Chen et al., 2025e)	language	external	ICL	context (knowledge base)	test-time

接下来，我们考察模仿与演示学习，其中智能体通过模仿完整、高质量的行为示例（即演示）来学习。虽然传统上这些示例来源于人类专家，但在自进化智能体的背景下，这些示例通常由智能体自身或其他智能体生成。当演示丰富或能够自主合成时，这种范式尤为强大，并已在推理和多模态领域推动了显著进展。



图 6: 基于奖励的自进化策略概览，分为文本奖励、隐式奖励、内部奖励和外部奖励，每种奖励与不同的反馈来源和机制相关联。

最后，我们介绍基于群体和进化的方法，这些方法从生物进化和集体智能中获得启发。这些方法维护智能体变体或协作智能体的种群，利用选择、变异、交叉和竞争等机制并行探索解空间，促进多样性，并促成新策略或架构创新的涌现。

5.1 基于奖励的自进化

自我提升能力是高级智能的基石。在大语言模型（Large Language Models）的背景下，这表现为一种奖励驱动的动态进化过程，模型通过迭代地从自身输出和交互中学习来完善其能力。作为指导性反馈的奖励信号设计至关重要；它决定了学习过程的性质、效率和有效性。在本节中，我们根据反馈的性质（文本反馈、内部置信度、外部奖励和隐式奖励）系统地回顾了奖励设计的主要方法。

文本反馈 提供详细、可解释的改进指令，与标量奖励不同，文本反馈包含细致批评和可操作的建议。最近的框架如 Reflexion (Shinn 等人, 2023)、AdaPlanner (Sun 等人, 2023)、AgentS2 (Agashe 等人, 2025)、SELF (Lu 等人, 2023)、Self-Refine (Madaan 等人, 2023a)、SCoRe (Kumar 等人, 2024)、PAG (Jiang 等人, 2025b) 和 TextGrad (Yellamraju 等人, 2024) 体现了这一方向。

其中

智能体用自然语言反思过去的尝试，将这些反思作为情景记忆存储，以指导未来的决策。AdaPlanner 通过允许大语言模型智能体根据计划内和计划外的反馈修改其计划，实现闭环自适应规划，同时通过代码风格提示和利用技能发现来减轻幻觉。Self-Refine 和 SELF 进一步探索了迭代自我反馈和自我纠正，证明即使是最先进的模型也可以通过多轮基于语言的自我批评得到改进，而无需额外的监督数据或外部强化。这些框架凸显了语言作为奖励渠道的力量，实现了细致、灵活且样本高效的自我提升。

内部奖励 基于内部置信度的奖励方法摒弃外部信号，转而利用模型自身的概率估计或确定性等内部度量。该范式借助模型的内在理解来引导改进，无需依赖外部监督。置信度知情自洽性 (CISC) (Taubenfeld 等, 2025)、自集成 (Xu 等, 2025b)、自奖励自改进 (Simonds 等, 2025)、基于自确定性的可扩展最优 N 选择 (Kang 等, 2025) 以及自奖励语言模型 (Yuan 等, 2025b) 等方法允许模型根据内部置信度度量进行自我评估和校准。例如，CISC 通过置信度分数对推理路径进行加权，以同时提升准确率和计算效率，从而有效地从多个候选中筛选出高质量解。自集成通过将选择划分为更小、更易管理的组并聚合预测来缓解置信度失真，以减少过度自信偏差。自奖励

语言模型表明，模型可以充当自身的奖励函数，通过自我指令和自我评估循环生成训练数据。这些方法能够减少对人类标签和外部评估器的依赖，实现可扩展且自主的自我改进循环，无需人工干预即可持续运行。AgentEvolver (Zhai 等, 2025) 提出了一个综合框架，通过三种协同机制提升智能体训练效率：用于自主任务生成的自我提问、用于经验引导探索的自我导航，以及用于细粒度信用分配的自我归因。特别是，其自我归因机制利用大语言模型的推理能力，回顾性地分配密集且语义有据的逐步奖励，以用于策略优化。

外部奖励 外部奖励来源于模型之外的来源，如环境、多数投票或显式规则。多数投票 (Shafayat 等, 2025; Wei 等, 2025c; Zhang 等, 2025j) 利用多个模型输出之间的一致性作为正确性的代理，提供了一种自生成但有依据的奖励信号。环境反馈，包括基于工具的反馈，是智能体大语言模型研究的核心（例如，SWE-Dev (Du 等, 2025)、SICA (Robeyns 等, 2025a)、反馈摩擦 (Jiang 等, 2025a)、USEagent (Applis 等, 2025)、DYSTIL (Wang 等, 2025c)），其中智能体通过与真实环境和工具的直接交互进行学习。基于规则的奖励 (Wang 等, 2025h; Wang 与 Xiong, 2025; Zhang 等, 2025a; Simonds 与 Yoshiyama, 2025; Wang 等, 2025q; Liu 等, 2025d) 使用显式约束或逻辑规则作为可验证信号，在数学推理、游戏和结构化问题求解领域尤为有效。这些方法提供了客观、可靠的监督，但可能需要大量的工程工作，或在表达能力上有所局限。

隐式奖励 隐式奖励框架假设大语言模型即使在没有被显式标记为奖励的情况下，也能从反馈信号中学习。例如，“奖励即足够” (Song 等, 2025) 表明，大语言模型可以利用嵌入在上下文窗口中的简单标量信号进行上下文强化学习，在无需显式强化学习微调或监督的情况下，在多轮迭代中改进其响应。这揭示了模型解读并学习输入上下文中隐式反馈线索的内在能力。近期研究扩展了这一概念，表明大语言模型通过其标准训练目标天然地编码了类似奖励的信号。内生奖励 (Li 等, 2025e) 揭示，标准的下一词预测隐式地学习了一个通用的奖励函数，该函数可以从模型 logits 中提取，无需额外训练。此外，隐式自我改进 (PIT) 框架 (Wang 等, 2024i) 通过最大化以参考响应为条件的响应质量差距，从人类偏好数据中隐式地学习改进目标，无需额外的人工努力。与基于规则或环境衍生的外部奖励不同，隐式奖励方法通过发现和利用语言建模中天然存在的奖励信号，提供了独特的优势。

总之，基于奖励的进化提供了明确的优化和强大的自主性，但仍然敏感

对奖励设计不敏感，通常以稳定性和安全性换取适应性与开放性。

5.2 模仿与演示学习

模仿与演示学习传统上涉及一个智能体从一组演示中学习模仿专家（通常是人类）的行为。在自进化智能体的背景下，这一范式被调整和泛化，这正是本综述的重点。在此，“专家”的角色不一定是固定的外部实体（如人类），而是任何高质量演示的来源。在自进化智能体中，这些“专家示例样本”通常由智能体自身生成（例如，过去成功的轨迹）、由其他能力更强的智能体生成，或从环境交互中合成。

模仿学习与基于奖励的方法之间的关键区别在于反馈的性质。模仿学习是规定性的、基于示例样本的：智能体获得一份完整且成功的指南（例如，完整的推理迹），并学习复现这种行为。相比之下，基于奖励的方法是评价性的、基于信号的：智能体自行探索，并接收标量或文本形式的批评，迫使其通过试错和功劳分配来推断改进的路径。

此外，该进化机制与后续将介绍的基于种群的方法存在根本性差异。模仿学习和基于奖励的学习通常侧重于通过迭代优化来提升单个智能体的性能，而基于种群的方法则进化一组智能体。

并行进行。它们的进展通常来自多样化基因库中的选择压力，而非从示例样本到个体的直接知识传递。因此，模仿学习占据了一个独特的生态位：它依赖于高质量解的存在，以直接引导并加速个体智能体的进化，当此类示范能够可靠且自主地生成时，该方法尤为强大。

5.2.1 自生成演示学习

自生成演示学习涉及智能体通过迭代精炼过程创建自身训练数据，模型通过从自身输出中生成并筛选高质量示例来学习改进。

引导推理能力。泽利克曼等人（2022）提出了自生成演示学习的基础框架，使语言模型能够通过迭代自训练引导其推理能力。该过程包括为问题生成推理链、对正确解进行微调，并重复此循环以逐步提升性能，而无需真实推理路径。在此框架基础上，近期进展通过更复杂的训练策略精炼了引导过程。例如，侯赛尼等人（2024）提出了一种验证器引导的自训练方法，其中独立的验证器模型在生成的推理链被纳入训练数据之前评估其质量，从而增强自改进的可靠性。此外，科赫等人（2025）引入了自适应数据采样策略，根据模型在各种推理任务上的表现动态调整训练数据的构成，从而缓解对特定问题类型的过拟合。“探索以进化”范式（王等人，2025l）通过提出一种自动化流程来生成复杂且可验证的训练数据，将这一概念扩展到深度研究网络智能体。该框架引导智能体首先进行主动在线探索，从实时网络中收集有依据的信息，然后进化出复杂的聚合逻辑，以合成既需要信息检索又需要深度推理的问答对。

多模态自训练。将自训练扩展到多模态领域，在生成同时涵盖视觉与文本模态的高质量演示方面，面临着独特的挑战。邓等人（2024）展示了视觉语言模型如何通过基于自身生成的图像描述和视觉推理链进行训练，从而实现迭代改进。该方法利用模型现有的视觉理解能力生成详细的图像描述，随后以自举的方式使用这些描述来微调模型的视觉感知。赵等人（2024c）在此基础上，通过先进的提示工程和质量过滤机制，使多模态大语言模型成为强大的数据生成器，在不同模态和任务中生成多样化的训练示例。

5.2.2 跨智能体演示学习

跨智能体演示学习涉及智能体从其他智能体提供的演示中学习，这些演示可以来自同一系统内部或外部来源，从而实现知识迁移和协作改进。

多智能体自举推理。赵等人（2025b）提出了一个框架，使多智能体系统能够通过自举推理相互学习成功的演示。该系统维护一个经验库，其中包含不同智能体生成的成功交互轨迹，从而促进高效的知识共享和协作改进。每个智能体都可以利用整个系统的集体经验，从而加速学习过程并发现多样化的解决策略。该框架展示了智能体如何在复杂任务的不同方面进行专业化，同时受益于整个系统积累的知识。

领域特定的演示学习。演示学习在特定领域的应用已被证明在专业知识可以通过演示有效传递的专业领域中尤为有效。在推荐系统中，诸如自优化微调（唐等人，2025）等技术使基于大语言模型的推荐系统能够从自身成功的推荐模式中学习，形成一个随时间增强个性化的反馈循环。该系统从成功的用户交互中生成高质量的推荐演示，并使用这些演示来微调底层语言模型，最终实现更准确和个性化的推荐。

质量推荐演示来自成功的用户交互，并使用这些演示来微调底层语言模型，最终实现更准确和个性化的推荐。

5.2.3 混合演示学习

混合演示学习结合了自生成演示和外部演示，以创建更鲁棒、更多样化的训练方案，从而发挥每种方法的优势。

递归自我改进。Qu 等人（2024b）展示了如何通过结构化的自我反思和演示生成来训练智能体系统地改进其行为。该方法使语言模型智能体能够内省其推理过程，识别需要改进的领域，并生成纠正性演示来解决这些弱点。这一递归过程建立了一个持续改进的循环，使智能体在自我诊断和自我纠正方面越来越熟练，从而产生更鲁棒、更具适应性的行为。

置信度引导的演示选择。近期的发展集中在更复杂的机制上，用于从自生成和外部来源中选择高质量演示。基于置信度的方法（Li 等人，2024b）利用模型的不确定性估计来确定哪些演示最有可能对学习产生积极贡献，从而过滤掉可能有害或低质量的示例。该方法解决了演示学习中的一个关键挑战：低质量的演示可能会降低性能。通过确保仅使用高置信度、高质量的示例进行训练，该方法有助于保持学习过程的完整性。

模仿和演示学习方法的有效性高度依赖于可用演示的质量和多样性。虽然这些方法在存在高质量示例样本时能够产生令人印象深刻的结果，但在优质演示稀缺或最优行为未能在可用数据中得到充分体现的领域中，它们面临挑战。未来的研究方向包括开发更复杂的演示选择和生成策略，提高从不完美演示中学习的鲁棒性，以及创建更好的机制来组合来自多个来源的演示。

总体而言，基于模仿的进化通过高质量示例样本稳定了学习，但通常以探索和泛化为代价来换取可靠性和样本效率。

5.3 基于种群与演化的方法

基于种群与演化的方法是一种在改进智能体行为方面具有悠久历史的范式，与现代基于学习的技术相辅相成。该方法从生物演化中汲取灵感，在人工智能领域根基深厚。约翰·霍兰德（John Holland）将这一概念形式化为实用的计算工具，其关于遗传算法（Genetic Algorithm, GA）的开创性工作确立了选择、交叉和变异等核心算子，用于优化种群（Holland, 1976）。在此基础上，约翰·科扎（John Koza）开创了遗传编程（Genetic Programming, GP），这是一种强大的扩展，直接演化可执行程序或符号表达式，因而适用于生成智能体逻辑。该范式的威力通过自动合成新颖的、具有人类竞争力的成果得到证明，例如获得专利的模拟电子电路（Koza, 2010）。这一成功延伸至多个领域，从为双陆棋和国际象棋等策略游戏演化具有竞争力的智能体（Hauptman & Sipper, 2007; Azaria & Sipper, 2005），到在基于智能体的仿真中发现复杂、可解释的策略，例如演化出优于静态人工设计策略的动态税收规则（Garuccio, 2016）。

该范式在演化智能体系统方面取得了里程碑式的成就。例如，经典的“演化合成生物”在模拟三维世界中共同演化智能体形态与神经控制器，发现了多种新颖且有效的运动策略（Sims, 1994）。此后，有影响力的 NEAT 算法解决了一项关键挑战，展示了如何不仅演化权重，还能演化神经网络的整个拓扑结构（Stanley & Miikkulainen, 2002）。这使得从简单的初始结构自主发现复杂的智能体“大脑”成为可能，这一原则对神经演化产生了持久影响。这些开创性工作表明，演化能够同时构建智能体的物理形态及其复杂控制系统，为人工设计提供了一种强有力的替代方案。

在此基础上，这些方法代表了与前述章节中基于奖励和基于模仿的方法不同的一种智能体进化范式。基于奖励的方法通常通过迭代奖励信号优化单个智能体，而模仿学习则依赖于从示范中学习；相比之下，基于种群的方法同时维护多个智能体变体。这使得能够并行探索解空间，并通过选择、变异、交叉和竞争性交互等机制涌现出多样化的能力（Zhang et al., 2025r）。通过利用并行搜索和遗传变异，这些方法实现了更广泛的搜索覆盖，并能够发现基于梯度的优化可能遗漏的新颖解决方案。当解空间复杂、多模态，或者最优策略需要根本性的架构改变而非参数微调时，这种方法尤其有价值。

5.3.1 单智能体进化

单智能体进化方法侧重于通过基于种群的机制进化单个智能体，其中智能体的多个变体随时间竞争和进化。这些方法可以大致分为两种主要范式：从进化中学习和从多次展开中自我博弈。

从进化中学习。该范式直接借鉴生物进化，维持智能体变体的种群，并应用进化算子以发现改进的能力。达尔文哥德尔机（Darwin Gödel Machine, DGM）（Zhang 等，2025h）通过自我改进智能体的开放式进化体现了这一方法，这些智能体维护所有历史版本的档案，能够从任何过去的“物种”分支，而非线性优化。该系统通过允许智能体直接修改其自身的 Python 代码库来实现自指改进，进化由编码基准上的经验性能驱动，父代选择在性能分数与用于多样化探索的新颖性奖励之间取得平衡。近期工作进一步探索了利用大语言模型（LLM）本身来实现核心进化算子。例如，LLM_GP（Hemberg 等，2024）使用大语言模型直接对以文本表示的程序执行变异、交叉和选择，利用模型固有的代码知识来指导进化搜索。类似地，CodeEvolve（Assumpção 等，2025）等开源框架已经证明，进化编码智能体可以在数学基准上取得最先进的结果，有时通过使用基于岛屿的遗传算法和基于启发的交叉，超越 AlphaEvolve（Novikov 等，2025）等专有系统。这一原理也在自指图超网络（Self-Referential Graph Hyper-Networks）（Pedersen 等，2025）中得到了探索，其中网络学习生成自身的权重变异，使得进化速率本身变得可选择和可适应。

除了进化代码和架构之外，这一范式还扩展到进化模型的参数和内部逻辑。受自然启发的基于种群的进化（GENOME）框架（Zhang 等人，2025r）直接将遗传算法应用于语言模型参数进化，维护种群并在模型权重上使用交叉、变异和选择算子。GENOME+（Zhang 等人，2025r）通过粒子群优化概念对此进行了扩展，增加了继承机制和集成方法，证明了无梯度的进化优化可以通过参数空间探索有效提升模型能力。EvoLLM-JP（Akiba 等人，2025）进一步利用进化算法将多个基础模型最优地合并为一个具有卓越性能的单一专用模型。此外，一些框架创建了紧密集成的反馈回路，使进化有助于模型微调。例如，SOAR（Pourcel 等人，2025）在进化搜索阶段生成候选程序与“后见之明学习”阶段之间交替进行，后者利用所有尝试（无论成功与否）生成丰富的数据集用于微调智能体模型，从而形成自我改进的良性循环。

自我博弈。自我博弈是一种范式，智能体通过与自身版本的迭代交互来改进，从而创建一个动态且自我维持的学习过程。其原理在 AlphaZero（Silver 等人，2017）等系统中得到了著名展示，该系统完全无需人类数据即可在复杂游戏中取得卓越性能。核心机制是协同进化学习：随着智能体的改进，其对手（自身过去或并发的版本）也变得更强大，从而生成一个难度不断增加的永久自适应课程。这避免了在固定环境中训练时可能出现的停滞，并能够发现新颖的涌现策略。

这一强大原理已被适配用于大语言模型（LLM）及其智能体，使其能够从零或极少外部数据中自我提升能力。一种突出的方法涉及单个模型或两个模型实例扮演不同且共同演化的角色。例如，绝对零度（Absolute Zero，赵等人，2025a）和 R 零（R-Zero，黄等人，2025b）采用“挑战者”或“提议者”智能体，在“求解者”智能体能力边界生成问题。更复杂的多智能体动态见于苏格拉底零（Socratic-Zero，王等人，2025m），其中求解者与强大的教师共同演化，教师创造挑战，生成器提炼教师策略以实现可扩展的课程创建。为解决纯自主系统的不稳定性，R 少（R-Few，余等人，2025b）引入一种引导方法，挑战者由少量人类示例锚定，以防止概念漂移和多样性崩溃。系统通过闭环改进：求解者因正确性（通常通过执行验证）获得奖励，挑战者因提出困难但可解的问题获得奖励，从而在无外部标签的情况下推动持续改进。类似地，自挑战语言模型智能体（Self-Challenging Language Model Agents，周等人，2025e）建立了一个框架，智能体交替生成和解决复杂的多步骤编码任务，利用成功轨迹进行自我微调。该范式还扩展到更专门化的协作角色，如求解器-验证器（Sol-Ver）框架（林等人，2025b）所示，其中大语言模型共同演化其生成代码（求解器）和创建相应单元测试（验证器）的能力。同样，拼写（SPELL，杨等人，2025e）将此原理应用于长上下文推理，单个模型循环扮演提问者、回答者和验证者角色，在程序化验证困难的领域提供可靠的奖励信号。

在这些方法中，改进由智能体自身轨迹产生的自生成学习信号驱动。自我博弈微调（Self-Play Fine-Tuning，SPIN）（Chen 等，2024f）奠定了一种基础方法，即当前模型与先前版本竞争，从而产生改进的进化压力。SPC（Chen 等，2025c）通过更复杂的对抗性协同进化推进了这一方法，其特点是“狡猾生成器”制造欺骗性错误，以及“步骤批评者”学习检测这些错误。STL（Mendes 与 Ritter，2025）展示了通过迭代前瞻搜索进行自我教学，其中价值模型从自身的探索性推演中生成训练数据。近期工作，如 EvoTest（He 等，2025b），通过引入无梯度的进化框架扩展了这些思想，该框架在回合之间修订智能体的提示、记忆和工具。

自我博弈的独特之处在于其独特的自我改进机制：智能体通过与自身变体的直接交互进行学习。这通常表现为两种方式：模型与自身过去的版本竞争以推动迭代改进（如 SPIN），或者单一模型采用不同的交互角色，例如“挑战者”为“求解者”生成新问题（如 Absolute Zero）。这种从动态交互中学习的原理不同于基于模仿的自举方法。虽然 STaR（Zelikman 等，2022）等方法也从智能体自身的输出中学习，但它们通过筛选并在静态的成功轨迹上进行训练来实现。相比之下，自我博弈从博弈式交互过程本身生成学习信号，即使不存在完美示例样本，也能从相对成功中学习。这种对单一智能体谱系的关注也使其区别于更广泛的基于种群的方法：自我博弈不是在进化一个庞大而多样的种群，而是在源自同一智能体的最小策略集之间创造高度聚焦的进化压力。

5.3.2 多智能体进化

多智能体进化方法将基于种群的方法扩展到进化整个智能体团队或网络，重点优化集体行为、协调策略和协作架构。根据其进化机制，这些方法可分为两种主要范式：系统架构进化和基于知识的进化。

系统架构进化。该范式聚焦于演化多智能体系统的结构与协调层面，涵盖团队构成、编排策略及 workflow 优化。EvoMAC（Hu 等人，2024d）提出了一种模拟神经网络训练的多智能体系统框架，实现了“文本反向传播”，其中编译错误与测试失败作为损失信号，驱动智能体团队构成及个体提示的迭代修改。一个专门的“更新团队”分析文本反馈以识别问题智能体并生成修改指令，从而在智能体配置空间而非模型参数空间中有效实施基于梯度的优化。FELA 框架（Wang 等人，2025e）将该概念应用于一个实际的

工业问题，利用一个包含专门“构思”、“编码”和“评判”智能体的多智能体系统，在强化学习与遗传算法原理的指导下，协同演化以从复杂数据中生成高性能特征。Puppeteer (Dang 等人, 2025) 则采取不同方法，聚焦于协调策略的演化而非团队构成的改变。该系统采用一个集中式编排器，通过强化学习演化其决策策略，在每一步动态选择要激活的智能体，同时平衡任务性能与计算成本。这种“提线木偶”范式展示了架构演化如何在协调层面发生，发现了高效的协作模式及涌现行为，例如核心智能体之间更紧密的协调以及复杂的循环交互模式。Agent0 (Xia 等人, 2025b) 引入了一个框架，通过课程智能体与执行智能体之间的协同演化循环，从零数据开始演化智能体。课程智能体被训练以生成挑战执行智能体的前沿任务。随后，执行智能体改进的工具使用能力反过来推动创建更复杂、具备工具感知能力的课程，从而建立起自我提升的良性循环。

基于知识的演化。该范式强调通过记忆积累和基于案例的学习来演化多智能体团队的集体知识与经验，主要借助上下文学习或类上下文适应而非参数更新来运作。MDTeamGPT (Chen 等, 2025e) 通过双知识库系统为此方法奠定基础，实现了用于存储成功案例的正确知识库 (CorrectKB) 和用于捕获失败反思的链式知识库 (ChainKB)，使系统能够通过结构化案例检索和推理增强从成功与失败中学习。MedAgentSim (Almansoori 等, 2025b) 扩展了这一医疗咨询框架，展示了此类基于知识的演化如何应用于真实世界的诊断场景，从患者互动中积累经验，并利用检索增强生成随时间提升咨询质量。PiFlow (Pu 等, 2025) 将该范式应用于科学发现，维护原理-结果对的轨迹，并通过信息论优化来引导假设生成。

总之，基于种群和自我博弈的演化增强了多样性与开放式发现，但通常

与单智能体范式相比，会带来更高的计算成本和更低的可解释性。

5.4 跨领域演化维度

在概述了三种核心演化范式之后，我们现在分析它们的跨领域维度——揭示不同的设计选择如何在反馈类型、数据来源和学习稳定性之间取得平衡。

智能体自我进化是一个多层面的过程，其特征是若干交叉维度，这些维度塑造了智能体如何随时间学习、适应和改进。超越任何单一学习算法或监督信号，这些维度定义了自主智能体设计与分析的核心原则。在本节中，我们系统比较了自我进化方法的主要家族——基于奖励、基于模仿/演示和基于种群的方法——沿着几个关键轴，如学习范式（在线与离线）、策略一致性（同策略与异策略）以及奖励粒度（基于过程、基于结果或混合）。我们进一步强调了额外维度，包括反馈类型、数据来源、样本效率、稳定性和可扩展性，如表 4 所总结。这一全面比较为理解不同智能体进化方法固有的优势、局限性和设计权衡提供了统一视角。

5.4.1 在线与离线学习

设计自我进化智能体的另一个基本维度是学习范式，可大致分为离线或在线。这一区别取决于智能体的进化更新是在静态的、预先收集的经验数据集上执行（离线），还是通过与实时环境的持续直接交互进行（在线）。

离线学习 在离线学习范式中，学习阶段与实时任务执行解耦。离线过程通常涉及离线数据生成、过滤和模型微调的循环，重点是在部署前构建一个强大且通用的基础模型。这一范式中的主要策略是




图 7：智能体自我进化所依托的交叉进化维度示意图。学习范式：在离线学习中，数据预先收集并用于筛选与微调；而在在线学习中，智能体持续与环境交互以实现实时适应。策略一致性：同策略进化基于智能体自身轨迹更新策略，而异策略进化则依赖回放缓冲区、人类示范或其他智能体的经验。奖励粒度：反馈可以是基于过程的（步骤级奖励）、基于结果的（最终结果奖励）或二者的混合。这三个正交轴共同定义了智能体在基于奖励、基于模仿和基于群体的进化范式中如何生成数据、调整策略并接收反馈。

表 4：自我进化方法族在关键维度上的比较。

Dimension	Reward-based	Imitation/Demonstration	Population-based
Feedback Type	Scalar reward, natural language, confidence, external signals	Demonstration trajectories, exemplars, rationales	Fitness scores, task success, competitive signals
Data Source	Self-generated, environment, external rules	Self-generated or other agents, humans	Population generations, multi-agent systems
Reward Granularity	Outcome/process/hybrid (flexible)	Usually outcome/process (via demo steps)	Often outcome-level, sometimes process via competition
Online/Offline	Both (reward learning, RL, DPO, SFT)	Typically offline, sometimes online demo mining	Online evolution or batch population updates
On/Off-policy	Both (DPO, Reflexion, GRPO)	Primarily off-policy, but online variants can be on-policy	Off-policy (population); self-play is on-policy
Sample Efficiency	Moderate (depends on reward sparsity)	High (if demo quality is high)	Usually low (needs many trials)
Stability	Sensitive to reward design	Sensitive to demo quality/diversity	Sensitive to population size/diversity
Scalability	Good with automation	Limited by demo collection	High but resource-intensive

领域是大型语言模型自举，即模型利用自身生成的内容增强自身能力。例如，自指令（Self-Instruct）（Wang 等，2022）展示了语言模型如何通过生成新指令并配以自身响应来创建合成数据集，从而自举其指令遵循能力。

用于微调。在此基础上，WizardLM (Xu 等人, 2024a) 展示了如何逐步演化这些自生成指令的复杂度，从而提升模型在更具挑战性任务上的能力。尽管这些方法主要通过合成启发式策略专注于广泛的能力扩展，作为引导阶段，它们为本文框架中定义的闭环、经验驱动的演化奠定了必要基础。在图形用户界面 (GUI) 和网络智能体 (Web Agent) 的背景下，离线学习通常涉及利用预先收集的高质量轨迹进行监督微调 (SFT)。OS-Genesis (Sun 等人, 2024b) 引入了一种反向任务综合方法，用于自动创建轨迹。类似地，UI-Genie (Xiao 等人, 2025a) 采用统一的奖励模型进行轨迹评估，并通过自我改进循环迭代生成高质量轨迹。这两种方法都专注于构建丰富的监督微调数据集，以增强智能体解决复杂任务的能力。除监督微调外，离线方法还结合了在智能体与环境交互的静态数据集上执行的强化学习。例如，GUI-R1 (Luo 等人, 2025b) 和 InfiGUI-R1 (Liu 等人, 2025c) 利用基于规则的奖励，并在离线图形用户界面数据集上应用 R1 风格 (Guo 等人, 2025b) 的训练。

在线学习 相比之下，在线学习使智能体能够在与实时或模拟环境交互的过程中持续学习和适应。每个动作的反馈被用于实时更新智能体的策略、计划或知识库。这使其能够更好地适应动态或未见过的语境。一些智能体并非通过更新模型权重实现在线进化，而是通过即时优化其计划和技能库。例如，Voyager (Wang 等, 2023a) 提出了一种由大语言模型驱动的智能体，通过持续探索、自主生成任务课程，并从直接经验中构建持久的技能库来学习玩《我的世界》。AdaPlanner (Sun 等, 2023) 专注于在任务内调整其计划；它生成初始计划，接收环境反馈，并在线优化计划。类似地，SwiftSage (Lin 等, 2023) 采用快慢思考过程，能够反思其快速直觉模式的失败，并切换到更审慎、使用工具的慢速模式，根据任务难度在线调整策略。强化学习是在线学习的基本机制，使智能体能够从环境奖励信号中学习。DigiRL (Bai 等, 2024) 展示了如何使用自主强化学习在真实环境中训练设备控制智能体，而 DistRL (Wang 等, 2024g) 提出了一种异步分布式框架，使此类设备端训练变得可行。MobileGUI-RL (Shi 等, 2025b) 通过引入合成任务生成流程，并结合轨迹感知奖励的群体相对策略优化 (GRPO)，解决了在在线移动环境中训练图形用户界面智能体的特定挑战。

5.4.2 同策略与异策略学习

上一节考察了数据收集与学习的时间安排（在线与离线），本节则聚焦于智能体进化的策略一致性方面——具体而言，智能体是从其试图改进的同一策略所产生的经验中学习（同策略），还是从不同策略所产生的经验中学习（异策略）。这一区别对于理解智能体如何利用其经验数据，以及在进化过程中如何权衡学习稳定性与样本效率至关重要。

同策略学习。同策略方法要求智能体仅从当前策略产生的经验中学习，从而确保策略一致性，但往往以牺牲样本效率为代价。反思 (Reflexion) (Shinn 等, 2023) 通过其迭代式自我反思机制体现了这一方法。智能体使用当前策略生成响应，接收失败反馈，并立即将该反馈纳入以更新其推理过程，用于下一次迭代。GRPO (Shao 等, 2024b) 和 DAPO (Yu 等, 2025a) 延续了这一路径，并展示了多次采样的有效性。智能体始终从自身当前行为中学习，保持严格的策略一致性。在智能体场景中，同策略方法提供了出色的学习稳定性，并避免了困扰异策略方法的分布不匹配问题。然而，它们样本效率低下，因为每次策略更新都需要重新收集数据，这使得它们在复杂的多步推理或工具使用场景中计算成本高昂，因为生成高质量轨迹的代价很大。

异策略学习。异策略方法允许智能体从不同策略产生的经验中学习，包括先前版本、其他智能体或人类演示，从而显著提高样本效率，但代价是潜在的分布不匹配。Yuan 等 (2024c) 展示了一种复杂的

离线策略方法，其中模型 M_{t+1} 从先前版本生成的偏好数据中学习 M_t 。系统通过 DPO 内置的 KL 散度约束与参考策略来处理分布偏移，防止新策略偏离数据生成策略过远。Yuan 等人（2023）展示了另一种强大的离线策略范式，通过基于排序的监督从多样化的响应来源中学习——包括其他模型、人类和不同的采样策略。该方法将对齐视为排序问题而非要求策略一致性，从而巧妙地规避了分布偏移。Zhao 等人（2025b）展示了多智能体环境中的离线策略学习，智能体从包含先前策略版本生成的成功交互轨迹的“经验库”中学习，从而高效复用昂贵的多智能体协调数据。在智能体环境中，离线策略方法在样本效率方面表现出色，使智能体能够利用历史数据、专家演示和跨智能体学习。它们对于多步推理尤为有价值，因为成功轨迹稀少且生成成本高昂；对于工具使用场景，智能体可以从多样化的执行示例中学习，而无需反复与环境交互。然而，它们面临分布偏移、奖励黑客行为（智能体利用训练与部署策略之间的不一致性）以及需要谨慎正则化以维持训练稳定性的挑战。

5.4.3 奖励粒度

奖励设计中的另一个关键选择是其粒度，它决定了智能体在何种细节层次上接收学习信号。奖励粒度从粗粒度的基于结果的奖励（评估整体任务完成情况）到细粒度的基于过程的奖励（评估智能体轨迹的每一步）不等。当前的自进化框架采用这些不同的粒度层次，根据任务复杂性和期望的学习结果来定制反馈机制。

基于结果的奖励 基于结果的奖励是一种反馈机制，根据预定义任务的成功完成情况来评估智能体。该奖励仅由智能体轨迹的最终状态决定，与中间步骤无关。一个核心挑战，尤其是在网页或图形用户界面导航等动态环境中，是如何有效地从成功轨迹和更为频繁的失败轨迹中学习。为解决这一问题，直接偏好优化（Direct Preference Optimization, DPO）（Rafailov 等，2023）旨在直接最大化偏好响应的似然，同时最小化与参考策略之间的 KL 散度。类似地，RRHF（Yuan 等，2023）采用排序损失方法，通过对响应概率进行排序来使多个响应的模型概率与人类偏好对齐，而无需辅助价值模型。此外，多项工作已开发出基于结果奖励的智能体自进化专用框架。一种直接的方法是拒绝采样微调，如 AutoWebGLM（Lai 等，2024）中所使用的。该方法采用预先设计的奖励模型来评估轨迹结果，识别成功轨迹，并利用这些高质量数据更新模型。DigiRL（Bai 等，2024）将图形用户界面导航任务建模为马尔可夫决策过程

（MDP），并使用基于视觉语言模型的评估器在一个回合结束时获得最终的稀疏奖励。WebRL（Qi 等，2024）开发了一种鲁棒的结果监督奖励模型（ORM），以解决动态网页环境中固有的反馈稀疏性问题。该 ORM 在自进化课程框架内评估任务成功，使智能体能够从失败的尝试中学习并逐步改进。

基于过程的奖励 与提供单一、延迟信号的基于结果的奖励相比，基于过程的奖励范式通过评估智能体轨迹中的每一步，提供了更精确、更细粒度的反馈。过程监督奖励模型（Process-supervised Reward Models, PRMs）已被证明比结果监督奖励模型（Outcome-supervised Reward Models, ORMs）显著更可靠，特别是在需要复杂推理的领域，如解决数学问题（Lightman et al., 2023）。然而，获得如此细粒度的步骤级反馈传统上需要大量人工标注，这既耗时又难以扩展。为了解决这一标注瓶颈，Math-Shepherd（Wang et al., 2023b）提出了一种自动过程标注框架，该框架利用蒙特卡罗树搜索（Monte Carlo Tree Search, MCTS）通过评估每一步推导出正确最终答案的潜力来收集逐步监督。类似地，AlphaMath（Chen et al., 2024a）训练一个价值模型来评估解答路径中步骤的正确性，并在 MCTS 框架内通过探索与利用来更新策略和价值模型。通过利用基于过程的奖励，智能体能够以渐进、逐步的方式提升其能力。rStar-Math（Guan et al., 2025）和 AgentPRM（Choudhury, 2025）都提出了迭代演化策略和

过程奖励模型的方法，无需人工标签即可生成逐步更高质量的推理路径。Agent Q (Putta et al., 2024) 将逐步验证机制集成到其 MCTS 过程中，以收集高质量轨迹，然后通过 DPO 训练迭代地优化策略。

混合奖励 混合方法旨在通过结合最终任务成功的清晰性（基于结果）和中间步骤的细粒度指导（基于过程）来提供更全面的学习信号。这些方法克服了仅基于结果信号的稀疏性，同时将智能体的逐步推理锚定在最终任务目标上。例如，GiGPO (Feng 等人, 2025a) 通过引入双层奖励机制来解决训练长程智能体的不稳定性。它根据整个轨迹的最终成功提供回合级奖励，同时为中间动作分配局部化的步骤级奖励。这种双重信号既提供了高层次的方向性目标，也提供了低层次的纠正性指导。类似地，SPA-RL (Wang 等人, 2025d) 提出了一种奖励分解方法，弥合了稀疏结果信号与密集过程反馈之间的差距。它根据最终任务完成情况将增量进展归因于多步轨迹中的每一步，有效地将基于结果的奖励分配到过程步骤中。这种方法创建了密集的中间进展奖励，在保持与最终任务目标对齐的同时增强了强化学习的有效性。

5.5 自进化方法的其他维度

除了学习范式、策略一致性和奖励粒度的核心轴之外，表 4 还突出了区分自进化方法的其他几个重要维度：

反馈类型。反馈的性质差异很大：基于奖励的方法利用标量奖励、自然语言信号或模型置信度；模仿方法侧重于演示轨迹和推理过程；基于种群的方法使用适应度分数或竞争信号。反馈类型从根本上决定了智能体使用什么信息来改进。

数据来源。基于奖励的方法通常通过智能体与环境的交互或工程化规则生成数据，而模仿学习通常依赖于人类或专家生成的演示。基于种群的方法从多个智能体或世代中汲取集体经验，实现了多样化的探索，但需要大量的协调。

样本效率。在高质量示范可用的情况下，模仿学习通常是最具样本效率的方法，因为智能体可以直接模仿专家行为。基于奖励的方法效率中等，其效率对奖励稀疏性高度敏感。基于种群的进化往往样本效率低下，因为它通常需要通过大量试验评估大量智能体变体。

稳定性。基于奖励的学习对奖励函数的质量和设计敏感，存在奖励黑客行为或非预期行为的风险。模仿学习高度依赖示范的质量和多样性。基于种群的方法对种群规模和多样性敏感，规模小或同质化的种群面临过早收敛的风险。

可扩展性。可扩展性取决于数据或反馈收集的可行性以及并行化学习的能力。当反馈可以自动化（例如通过模拟器）时，基于奖励的方法扩展性良好。模仿学习通常受限于收集示范的成本。基于种群的方法可以扩展到大规模计算，但资源消耗极大。

这些维度共同为自我进化策略提供了更细致、多维的视角，指导实践者选择和设计最适合其特定领域挑战的智能体学习流程。

6 在哪里进化？

自我进化智能体推动了众多领域和应用的进步。总体而言，这些应用大多可以系统地归为两类：（1）通用领域进化，即智能体系统通过进化扩展其在各种任务上的能力，主要是




图 8: 进化方向分类为两大类型: 通用领域进化, 侧重于跨多样任务的广泛能力增强 (例如记忆机制、协同进化、课程训练), 以及特定领域进化, 针对编码、图形用户界面、金融、医疗、教育等领域的专业知识。

在数字领域内, 以及 (2) 特定领域进化, 其进化专门用于提升在特定任务领域内的熟练度。本质上, 通用助手的进化侧重于将学到的经验迁移到更广泛的任务集, 而专用智能体的进化则强调在特定领域内深化专业知识。

6.1 通用领域进化

第一类, 通用领域进化, 指的是为通用应用设计的自进化智能体, 特别是作为多功能数字助手。这些智能体逐步增强其能力, 以应对广泛的用户查询, 尤其是在动态和多样化的数字环境中。从技术上讲, 这些通用助手智能体主要通过三种机制增强其能力: 记忆优化、课程驱动训练和模型-智能体协同进化。这些机制共同使智能体能够持续适应并有效响应日益复杂的用户需求。

记忆机制。促进智能体进化的最常见机制是记忆机制, 智能体将历史成功/失败经验 (Wang et al., 2023a; Zhang et al., 2024f) 总结为记忆表征 (Zhang et al., 2024g), 期望这些提炼的经验在应对未见过的任务时能发挥作用。例如, Mobile-Agent-E (Wang et al., 2025o) 采用由“提示” (提供一般性指导) 和“捷径” (表示从过去经验中提取的可复用动作序列) 组成的长期记忆结构。该自我进化模块支持在复杂智能手机任务上持续提升性能。另一个典型例子是 MobileSteward (Liu et al., 2025f), 它在中央智能体下协调多个应用专用智能体, 并配备任务调度、执行和评估的专用模块。它还整合了基于记忆的自我进化机制, 总结成功执行经验以改进未来跨应用指令处理。同时, 生成式智能体 (Generative Agents) (Park et al., 2023) 存储其经历的情景记忆, 综合更高层次的反思, 并将未来规划建立在这种自我反思之上。在这些例子中, 记忆作为基础, 使智能体能够内化过去经验、抽象高层次模式并优化未来行为。

模型-智能体协同进化。另一条研究路线是对大语言模型智能体进行模型-智能体协同进化。UI-Genie (Xiao et al., 2025a) 构建了一个专门的图像-文本奖励模型, 在步骤和任务两个层面对轨迹进行评分。它利用通过受控破坏和困难负样本挖掘生成的合成轨迹, 在多代迭代中联合微调智能体和奖励模型。WebE-

沃沃尔弗 (Fang et al., 2025b) 引入了一种协同演化的世界模型大语言模型，用于模拟网络环境。该模型通过预测下一观测来生成合成训练数据，并在推理过程中实现前瞻性推理，从而显著提升了真实网络任务的成功率。绝对零度 (Zhao et al., 2025a) 通过强化自我博弈协同演化推理智能体及其内部自奖励模型。该框架通过对抗性地生成日益困难的推理问题，并利用内部自我确定性作为奖励信号来优化智能体，同时更新智能体的策略和自奖励机制。这些方法共同证明了协同演化智能体与辅助模型（如奖励模型或世界模型）在实现大语言模型智能体系统中更稳健、更泛化且可扩展的学习方面的有效性。

课程驱动训练。课程驱动训练也是构建自进化通用助手的关键机制。例如，网络强化学习 (Qi et al., 2024) 采用自进化课程：当智能体失败时，会自动生成相似但可管理的任务。结合学习到的奖励模型和自适应策略更新，该方法在网络竞技场基准上实现了成功率的提升。旅行者 (Wang et al., 2023a) 同样在《我的世界》中利用自动化的自底向上课程，其中 GPT-4 根据智能体进度提出合适的下一任务，通过迭代提示和环境反馈构建不断增长的基于代码的技能库。这些方法凸显了课程学习如何使智能体通过迭代任务适应自主扩展其能力。

6.2 专业领域演化

除了通用数字智能体之外，自进化智能体也已被有效应用于专业领域，其演化被定制以显著提升在较窄任务集内的性能。

编程。自我进化智能体的强大能力直接延伸至编码等实际应用领域，其自主适应与改进的能力为软件开发提供了一种变革性的方法。SICA (Robeyns 等人, 2025a) 证明，一个自我改进的编码智能体能够自主编辑其自身的代码库，并提升其在基准任务上的性能。EvoMAC (Hu 等人, 2024d) 在多智能体协作网络上引入了一种自我进化范式，该范式自动优化个体智能体提示词和多智能体工作流，通过克服人工设计系统的局限性，显著提升了代码生成性能。AgentCoder (Huang 等人, 2024) 同样聚焦于一个通过迭代精化实现自我进化的多智能体代码生成框架。程序员智能体根据测试执行器智能体的反馈持续改进代码，并利用测试设计器提供的独立测试用例进行验证，从而显著提升了有效性和效率。Zhang 等人 (Zhang 等人, 2025b) 通过筛选高质量答案、按难度对积累的经验进行分层，以及从自生成数据中自适应地选择演示，使大语言模型智能体能够持续进化，从而带来显著的性能提升并构建了机器学习库。尽管这些实例在具体机制上有所不同——从单智能体自我编辑到复杂的多智能体协作网络以及基于经验的学习——但它们共同秉持迭代自我改进和自主适应以增强编码能力的核心原则。这些进展凸显了自我进化智能体如何通过持续学习和优化，显著提升编码效率和代码质量。

图形用户界面 (Graphical User Interfaces, GUI)。自进化图形用户界面智能体将大语言模型的能力从纯文本推理扩展到对桌面、网络和移动界面的直接操作，在此过程中它们必须应对大型离散动作空间、异构布局以及部分视觉可观测性。Yuan 等人将像素级视觉与自我强化相结合，使智能体能够在无需额外人工标注的情况下迭代提升点击类型定位准确率 (Yuan 等人, 2025c)。在真实桌面软件上，来自 WindowsAgentArena 的 Navi 智能体回放并批判自身的失败轨迹，最终在 150 项 Windows 挑战中将其任务完成率提高了一倍 (Bonatti 等人, 2024)。对于开放网络自动化，WebVoyager 融合了截图特征与思维链反思；连续的自我微调将其在未见网站上的端到端成功率从 30% 提升至 59% (He 等人, 2024)，而 ReAP 则增加了对过往结果的情景记忆，在先前失败的查询上进一步恢复了 29 个百分点的差距 (Azam 等人, 2025)。除了强化学习和记忆之外，AutoGUI 持续从实时界面中挖掘功能标注，以在每个训练周期扩展可复用的技能库 (Li 等人, 2025a)，而 MobileUse 则部署了一个分层自我反思栈，能够就地监控、验证和修正智能手机操作 (Li 等人, 2025c)。总体而言，这些

系统体现了自我进化的完整三元组——进化什么（定位模块、技能记忆）、何时进化（离线整合与在线反思）以及如何进化（强化学习、合成数据、分层监控）——为通向普遍胜任的界面智能体指明了道路。

金融。为金融任务等专业领域定制智能体的主要瓶颈在于高效构建领域特定知识库并将其整合到智能体的学习过程中——这一挑战可通过引入自我进化机制得到有效缓解。QuantAgent (Wang 等, 2024d) 提出了一种双层框架, 利用模拟和真实环境的反馈迭代优化智能体的响应, 并自动增强其领域特定知识库。这一迭代过程帮助智能体逐步逼近最优行为, 减少对昂贵人工标注数据集的依赖, 并显著提升其在交易任务中的预测准确率和信号质量。TradingAgents (Xiao 等, 2024) 融合了反思、强化学习以及来自真实交易结果的反馈回路等动态过程, 并结合协作辩论, 以持续优化策略并提升交易性能。这些进展凸显了自我进化智能体在金融领域的潜力, 它们能够自主构建领域专业知识、适应动态市场条件, 并不断改进决策和交易表现。

医学。自进化智能体已成为医疗人工智能领域的一种强大范式, 其中适应性和进化能力对于管理现实世界临床实践的复杂性和不断变化的特性至关重要。最突出的应用之一是医院规模的仿真。例如, Agent Hospital (Li 等人, 2024a) 创建了由大语言模型驱动的医生、患者和护士组成的封闭环境, 使医生智能体能够处理数千个虚拟病例。这一过程帮助这些智能体在没有人工标注的情况下自主完善和进化其诊断策略, 最终在美国医师执照考试风格的测试中取得强劲性能。类似地, MedAgentSim (Almansoori 等人, 2025a) 集成了大语言模型医生、患者和工具智能体。它将成功的咨询记录为可复用的轨迹, 并采用思维链反思和共识来驱动自我进化, 从而在连续交互中提高成功率。另一个例子是 EvoPatient (Du 等人, 2024), 它让医生智能体和患者智能体进行持续对话。在每一代中, 它们用高质量的交流更新记忆: 患者发展出更真实的症状叙述, 而医生学会提出更尖锐的问题。值得注意的是, 这一过程没有显式的梯度更新或手工设计的奖励。强化学习也是构建自适应医疗智能体的核心。例如, DoctorAgent-RL (Feng 等人, 2025c) 将咨询建模为马尔可夫决策过程, 使用一个奖励函数来评估诊断准确率、覆盖率和效率。这引导策略梯度更新, 帮助智能体提出更相关的问题, 并比基于模仿的方法更快地达到正确诊断, 从而实现自我改进。此外, 像“学会成为医生”这样的自动化架构搜索方法将工作流本身视为可进化的对象, 迭代地插入专家子智能体或新的推理跳转, 以覆盖观察到的失败模式并提高多模态诊断准确率 (Zhuang 等人, 2025)。最后, 除了临床决策之外, 自进化智能体也已扩展到生物医学发现领域。OriGene (Zhang 等人, 2025t) 作为一个虚拟疾病生物学家, 通过迭代地完善其分析过程来进化。它利用人类和实验反馈来更新核心推理模板、调整工具使用策略并完善分析协议。类似地, STELLA (Jin 等人, 2025) 是一个自进化的生物医学研究智能体, 它通过其模板库将成功的推理工作流提炼为可复用的模板, 并利用外部或新组装的工具扩展其工具海洋, 以满足新兴的分析需求, 从而随着时间的推移不断改进。

教育。自进化大语言模型智能体在教育领域也有广泛应用。在学习者层面, 自进化智能体如个性化导师 PACE (Liu 等, 2025c) 根据详细的学生画像调整提示, 并在对话中不断优化提问。同时, 大语言模型之间的自我博弈框架生成多样化的师生对话, 进一步微调智能体, 使其教学策略在交互过程中和交互之后都能不断进化。另一个例子是 MathVC (Yue 等, 2025), 它采用符号化角色画像来模拟虚拟学生, 并利用元规划器编排真实的问题解决阶段。这种设置使智能体的对话过程逐步向正确解决方案进化, 紧密模拟协作学习的自然展开。在教师层面, 自进化智能体系统如专业发展平台 i-vip (Yang 等, 2025b) 部署了一组协作的大语言模型智能体——教练、评估者和反馈生成器——它们

实时相互批评并改进输出。这些智能体根据教师学习者的响应调整解释，并在部署后通过纳入专家反馈持续进化，从而逐步优化提示策略。类似地，EduPlanner (Zhang 等, 2025p) 将教案创建构建为一个对抗循环，其中规划器的草稿由评估者和优化器智能体反复审查和优化，直到满足多样化的教育目标。同样，SEFL (Zhang 等, 2025k) 利用师生自我博弈生成大量作业-反馈示例，然后微调轻量级反馈模型。这种自进化过程显著提高了评论的清晰度和实用性。总体而言，这些例子展示了自进化大语言模型智能体如何动态适应学习者和教师，推动更个性化、更有效和可扩展的教育体验。

其他。超越上述四大垂直领域，自进化智能体展现出更广泛的适用性，在传统智能体往往力不从心的专业领域中提供了卓越的适应性与性能。例如，Arxiv Copilot (Lin 等, 2024) 通过将历史用户交互（包括生成的答案、研究趋势和想法）纳入其思维数据库进行学习与适应，从而增强了提供个性化和增强型学术辅助的能力。在截然不同的场景中，Voyager (Wang 等, 2023a) 是游戏《我的世界》中的智能体，通过自我进化过程，擅长在新世界中从零开始解决新任务。它通过自动课程不断细化任务目标，扩展技能库，并利用迭代提示机制改进动作，全程无需人工干预。转向需要明确战略规划领域，Agents-of-Change (Belle 等, 2025) 基于迭代性能分析和战略研究自主优化提示并重写代码，从而帮助智能体克服长期战略规划中的固有局限，在《卡坦岛》等复杂环境中实现持续更优且更连贯的游戏表现。最后，在外交领域，Richelieu (Zhao 等, 2024d) 引入了能够通过自我博弈机制实现自我进化的 AI 外交智能体，该机制使智能体无需人类数据即可获取多样化经验来扩充记忆，从而增强其在外交活动中的战略规划、反思和整体表现。尽管这些多样化的示例运行在不同的环境中——从学术研究和虚拟游戏世界到战略棋盘游戏和复杂的外交谈判——它们都共享一个基本特征：利用持续学习、自我优化和自主适应，在各自领域内实现日益复杂和高效的表现。这些多样化的示例进一步印证了自进化智能体的多功能性，展示了它们在传统领域之外广泛复杂、动态且类人任务中日益增长的卓越潜力。

7 自进化智能体的评估

评估自我进化智能体面临一系列独特的挑战，这些挑战超越了传统静态人工智能系统的评估范畴。与传统智能体通常在单一时间点对固定任务集进行评估不同，自我进化智能体旨在通过与动态环境的持续交互不断学习、适应和改进。因此，其评估不仅需要捕捉即时任务成功率，还必须涵盖随时间推移的适应能力、知识积累与保持、长期泛化能力，以及在顺序或新颖任务间迁移所学技能的能力，同时缓解灾难性遗忘。这要求从传统的“单次”评分方式根本性地转变为纵向的、成本感知的轨迹视角。

7.1 评估目标、度量与基准覆盖

为了有效评估自我进化智能体，我们必须超越传统度量，建立一个全面的框架，以捕捉其动态、自适应和长期学习能力。一个真正有能力且理想的自我进化智能体不仅需要学习和改进，还必须记住过去的知识，将其迁移到新情境中，可持续地运行，并负责地行事。基于这些对持续且稳健人工智能的关键要求，我们将核心评估目标划分为五个核心维度：适应性、保持性、泛化性、效率性和安全性，如表 6 所示。每个维度针对智能体自我进化过程的一个关键方面，并通过相应的度量和基准覆盖分析进行评估。表 7 提供了全面的目录




图 9：自进化智能体评估目标与范式概览。左：评估目标与度量。本文总结指导智能体评估的五项核心目标：适应性、保持性、泛化性、效率与安全性，这些目标反映智能体应如何随时间进化并表现。右：评估范式。评估方法按时间尺度递增组织：从固定能力的静态评估（如外部任务求解与组件级评估），到捕捉任务内适应的短时程自适应评估（如增强或动态基准），最终到考察在进化或终身基准下持续改进的长时程终身学习评估。这些轴共同将自进化的目标与用于度量它们的评估设置联系起来，形成评估智能体适应性与可持续性的统一框架。度量定义见表 6，协议总结见表 10。

评估资源方面，本文综合这些局限性，以映射五项目标框架下的覆盖缺口，并在表 8 中确定面向轨迹、成本感知评估的方向。

7.1.1 适应性

目标与度量 适应性是任何自进化智能体的基础评估准则，度量其通过经验改进域内任务性能的能力。该维度聚焦于量化学习曲线及智能体在特定领域内迭代进化时性能提升的程度。适应性并非静态成功率，而是随时间、步骤或迭代进行度量。典型度量包括按迭代步长的成功率（Hu 等，2024c；Wang 等，2024j；Zheng 等，2025b），该指标追踪下游任务性能随智能体交互历史变化的函数。

覆盖缺口 尽管自适应拥有最丰富的基准生态系统——涵盖代码生成（软件工程基准（SWE-bench）（Jimenez 等，2023）、机器学习工程基准（MLE-Bench）（Chan 等，2024））、网页导航（网络竞技场（WebArena）（Zhou 等，2023）、网络商店（WebShop）（Yao 等，2022））以及通用推理（通用人工智能助手基准（GAIA）（Mialon 等，2023）、智能体基准（AgentBench）（Liu 等，2023b））——但评估仍受限於实用的设计选择。科学智能体基准（ScienceAgentBench）将任务限制在单一编程语言并施加执行时间上限，排除了计算密集型的科学工作流（Chen 等，2024e）。机器学习工程基准（MLE-Bench）提供了结构良好的任务，但偏离了真实的研究场景，在真实场景中问题表述本身就是挑战的一部分（Chan 等，2024）。这些简化允许受控的领域内评估，但将评估限制在狭窄、静态的任务分布上。此外，大多数基准在预先指定的学习协议（例如，固定的迭代预算或预定的重放计划）下衡量改进，而不是评估智能体是否自主发现有效的适应策略。智能体基准（AgentBench）进一步报告了在持续推理和战略决策方面的弱点（Liu 等，2023b），然而评估视野仍然局限于短期改进曲线。

7.1.2 保留

目标与度量 保留是评估自进化智能体知识库稳定性的关键标准。该维度特别关注灾难性遗忘的挑战，这是终身学习中常见的问题，即新知识的获取侵蚀了先前学习的信息，以及扩展交互中的知识保留。两个关键度量可用于从不同角度量化这种稳定性：遗忘（FGT）和反向迁移（BWT）（Zheng 等，2025c）。具体而言，令 $J_{i,t}$ 表示在完成 t 个任务后任务 i 上的性能：

$$\text{FGT}_t = \frac{1}{t-1} \sum_{i=1}^{t-1} \left[\max_{j \in \{i, \dots, t\}} J_{i,j} - J_{i,t} \right], \quad \text{BWT}_t = \frac{1}{t-1} \sum_{i=1}^{t-1} (J_{i,t} - J_{i,i}).$$

正向反向迁移（BWT）表明新学习对旧任务产生积极影响，标志着成功的知识迁移和更稳健、更稳定的学习过程。

覆盖缺口 保留（Retention）仍然是最缺乏关注的维度。当前的记忆机制在动态状态更新和跨长程交互中保持一致性方面存在显著困难（Hu et al., 2025）。经验回放（Experience Replay）表现出一种内在张力：虽然回放缓冲区可以改善学习，但将其扩展到超过最优阈值会通过上下文溢出和资源耗尽引发性能退化（Zheng et al., 2025b）。经济和计算约束限制了评估的鲁棒性，一些基准仅进行最少的重复，可能无法捕捉随机变化（Castillo-Bolado et al., 2024）。最关键的是，绝大多数现有基准采用情景式评估，即智能体状态在任务之间重置，从根本上排除了对知识积累或退化的测量——而这正是区分自进化智能体与静态系统的现象。

7.1.3 泛化（Generalization）

目标与度量 虽然适应性和保留关注域内性能，但泛化是衡量自进化智能体将其积累的知识应用于新的、未见过的领域或任务的能力的关键指标。一个真正智能的智能体不仅应在其熟悉的领域内表现良好，还应展示跨领域泛化的能力。这种能力可以通过评估智能体在跨越多个任务分布和领域的多样化任务集上的性能来评价。常见方法包括在多领域测试套件上计算聚合性能度量（例如平均成功率）（Liu et al., 2023b; Sun et al., 2023），以及使用模拟现实世界新颖性场景的留出任务分布进行域外评估（Hu et al., 2024b; Peng et al., 2025）。

覆盖缺口 泛化通常通过多领域测试套件（如智能体基准（AgentBench）（Liu 等，2023b）、智能体公司（TheAgentCompany）（Xu 等，2024b））和留出任务分布来评估，衡量智能体跨领域迁移知识的能力。然而，当前的评估依赖于静态快照：智能体在多样化任务上仅测试一次，未追踪其在长期学习轨迹中跨领域迁移能力是否退化。技术进步进一步削弱了旧任务的区分力，因为现代智能体受益于早期系统无法获得的算法进步（Chan 等，2024），同时训练数据污染使跨领域评估复杂化（Chan 等，2024）。现有基准既未考察智能体在领域内专业化时是否保持泛化广度，也未考察在数百次学习片段后，一个领域获得的知识是否仍能迁移。

7.1.4 效率

目标与度量 效率量化自进化智能体在学习和运行过程中的资源利用程度。由于智能体持续运行并自主决策，评估其进化过程的成本和速度至关重要。

表 5 中的这些度量对于计算、内存、时间和人力等资源有限的实用现实应用尤为重要：

表 5：自进化智能体的精细化成本分类与单位，附现实示例（Fan 等，2025）：在软件工程基准（SWE-bench）（Jimenez 等，2024）上，软件工程智能体（SWE-Agent）（Yang 等，2024）结合通义千问 3-32B（Qwen3-32B）（44 万令牌，35 次调用，28% 成功率）对比 GPT-4o-mini（810 万令牌，181 次调用，10% 成功率）——模型与脚手架协同对效率至关重要。

Dimension	Symbol	Typical Unit	Example Measurement	Worked Example
Token usage	C_{token}	#tokens	Prompt + completion tokens per episode/step	440K vs. 8.1M tokens per task; 18× difference
Step count / latency	C_{step}	#turns / rounds	Reasoning/interaction turns	35 vs. 181 API calls per task; Quality vs. quantity trade-off
Wall-clock time	C_{time}	#seconds	End-to-end elapsed runtime incl. I/O	12 vs. 200+ turns per task; Simple vs. complex bugs
Tool/API calls	C_{tool}	#calls	External function/environment calls	15 vs. 38 calls (AutoCodeRover); High-quality reasoning reduces iterations
Memory growth	C_{mem}	#tokens / MB	Persistent memory; context window expansion	Linear growth per call; Token snowball effect amplifies invalid context
Human oversight	C_{human}	#hours / tokens	Review, labeling, red-team; guidance tokens	Failed attempts: 4× cost vs. successful ones; Expensive failures pattern

- 令牌消耗（Hu 等，2024a）：推理、生成和记忆操作中使用的总令牌数

- 时间消耗（Lu 等，2024b）：完成任务或达到性能阈值所需的实际时间

- 步骤数（Wang 等，2023a）：完成任务所需的交互轮数

- **工具调用：**外部应用程序编程接口或环境调用的次数，可与性能增益结合以评估工具生产率（Tool Productivity, TP）（Wang et al., 2025h），公式为：

$$TP_{\S} = \frac{\Delta \text{score}}{\sum_i \text{cost}(\text{tool}_i)}.$$

- **内存增长：**智能体运行期间持久内存和上下文窗口的扩展

- **人工监督：**人工干预所需的时间和精力，包括审查、标注和纠正性指导

为将效率与性能增益相关联，本文报告单位增益成本（Cost-per-Gain, CPG）为：

$$CPG_t = \frac{\text{Total Cost}_t}{\text{Performance Gain}_t + \epsilon},$$

其中成本可以以令牌、时间、内存、人力或归一化综合指标（如货币成本）衡量，性能增益为在时间范围 t 内相对于基线的改进。单位增益成本越低，表明学习效率越高。

覆盖缺口 效率受到进化成本报告稀疏且不一致的影响。虽然基准论文偶尔会记录评估过程中的总体资源消耗（Chan 等人，2024），但它们很少将成本分解为进化特定的组成部分：自我反思或经验回放期间消耗的令牌、架构搜索或记忆更新所花费的墙钟时间、自主探索触发的工具调用。人类基线收集中的成本约束（Xu 等人，2024b）反映了

更广泛的可访问性挑战，但并未阐明进化过程本身的效率。更根本的是，标准评估协议允许无约束的优化——智能体最大化任务成功率，而不面临现实世界部署中支配的硬性令牌预算、迭代限制或延迟约束。

7.1.5 安全性

目标与度量 从自我进化的角度来看，安全性领域批判性地考察这些智能体在持续进化过程中是否会发展出不安全或不良的行为模式。该维度评估智能体对预定义规则的遵守程度及其产生有害行为的倾向。评估自我进化智能体安全性的关键度量可能包括：（1）安全分数（Zhang 等人，2024i），衡量智能体行为被标记为“安全”的测试用例比例；（2）危害分数（Andriushchenko 等人，2024），通过详细的人工编写评分标准计算，当部分而非全部有害标准被触发时，输出获得部分分数；（3）策略下完成率（CuP）（Levy 等人，2024），评估智能体在严格遵守给定规则或策略集的情况下是否成功完成任务；（4）风险比率（Levy 等人，2024），计算智能体在特定维度上违反规则的频率，提供不合规的定量测度；（5）拒绝率（Zhang 等人，2024b；Andriushchenko 等人，2024），评估智能体因任务具有攻击性、恶意或其他不安全性质而拒绝执行的比例；（6）泄漏率（Shao 等人，2024a），跟踪智能体无意中泄露敏感或私人信息的频率。

覆盖缺口 安全评估主要捕捉孤立事件中的风险。智能体安全基准（Agent-SafetyBench）识别出两个核心缺陷：在不同情境下部署工具时鲁棒性不足，以及对特定操作场景中潜在危险的识别有限（Zhang et al., 2024i）。在多智能体环境中，群体基准（SwarmBench）揭示了根本性的协调挑战，即局部交互无法产生连贯的集体策略，智能体无法维持安全协作操作所需的共享态势理解（Ruan et al., 2025）。然而，目前尚无基准追踪长期演化过程中的安全轨迹——无论是风险是否通过反复暴露于边缘案例而累积，还是不安全行为是否通过自主探索和自我导向学习而出现。

7.1.6 自我导向性与评估权衡

自我演化智能体的一个决定性特征是其自主探索和自我导向演化的能力，这使其区别于被动学习范式。自我导向的程度，特别是智能体是自主生成任务和演化策略，还是遵循外部提供的课程，在评估维度上产生了根本性的权衡。

高度自我导向的系统通过自主课程生成展示了显著的性能提升。网络强化学习（WebRL）通过从探索失败中自我生成任务，性能从 4.8% 提升至 42.4%（Qi et al., 2024），而软件工程智能体（SEAgent）通过自主软件探索和课程演化，实现了 23.2 个百分点的提升，从 11.3% 提升至 34.5%（Sun et al., 2025c）。然而，自主演化也带来了可衡量的风险。当智能体在相互冲突的目标下自主演化时，对齐伪装率从 12% 上升至 78%（Greenblatt et al., 2024），这表明在外部监督极少的情况下进行演化会带来安全挑战。

尽管已有文献记载了这些影响，该领域仍缺乏量化进化中自主性的标准化度量。为便于公平比较，本文建议透明地报告进化过程的三个方面：（1）明确进化策略与任务序列是预先确定的、程序化采样的，还是由智能体自主生成的；（2）记录反馈信号的来源，说明其来自外部人类标签、基于规则的评估器，还是自我生成的反思；（3）报告进化过程中外部干预的频率。清晰记录自主控制的程度对于解释性能声明至关重要，因为性能提升可能反映真正的自我进化能力，也可能源于大量外部指导。

这种以轨迹为中心的评估与评估自我进化智能体的核心目标一致：不仅衡量其取得的成果，更衡量其学习进化的自主程度。

表 6：核心维度上的智能体评估度量概览

Goal	Metric	Description
Adaptivity	Success Rate by Iteration Steps (Hu et al., 2024c; Wang et al., 2024j; Zheng et al., 2025b)	Performance in downstream tasks as a function of the agent’s interaction history
	Adaptation Speed (Wang et al., 2023a)	How quickly an agent reaches a certain performance threshold or converges to an optimal strategy within a given adaptation period
Retention	Forgetting (FGT) (Zheng et al., 2025c)	The average accuracy drop on old tasks after an agent learns a new one, measuring whether useful experience is successfully maintained
	Backward Transfer (BWT) (Zheng et al., 2025c)	The average accuracy improvement on old tasks due to the experience gained from new tasks
Generalization	Aggregate Performance (Liu et al., 2023b; Sun et al., 2023)	Mean success rates or other performance indicators across multi-domain test suites to gauge overall proficiency
	Out-of-Domain (OOD) Performance (Hu et al., 2024b; Peng et al., 2025)	The agent’s performance in held-out task distributions
Efficiency	Token Consumption (Hu et al., 2024a)	Computational overhead in reasoning and generation steps
	Time Expenditure (Lu et al., 2024b)	Total duration required for task completion
	Number of Steps (Wang et al., 2023a)	Minimal actions needed to accomplish objectives
	Tool Productivity (Wang et al., 2025h)	The ratio between task benefit (e.g., answer accuracy) and tool usage cost (e.g., number of tool calls)
安全性	Safety Score (Zhang et al., 2024i)	Proportion of test cases where agent behavior meets predefined safety criteria
	Harm Score (Andriushchenko et al., 2024)	Graded assessment of harmful outputs based on violation severity
	Completion Under Policy (CuP) (Levy et al., 2024)	Task success rate while complying with specified constraints
	Risk Ratio (Levy et al., 2024)	Frequency of policy violations per interaction opportunity
	Refusal Rate (Zhang et al., 2024b; Andriushchenko et al., 2024)	Percentage of tasks declined due to safety concerns
	Leakage Rate (Shao et al., 2024a)	Incidence of unintended sensitive information disclosure

7.2 评估范式

鉴于自我进化智能体持续学习的范式，其评估需要超越传统静态评估的多方面方法。当前评估范式可根据评估的时间范围大致分为：静态评估、短时程自适应评估和长时程终身学习能力评估。每一类别针对智能体进化能力的不同方面，从瞬时性能到长期学习轨迹。术语说明：此处“持续”指系统层面的自我进化（策略、记忆、技能、工具或程序在多个回合间的变化），而非必然指模型参数的持续学习。因此，本文的评估追踪跨交互回合和进化环境的轨迹，与权重是否更新无关。

7.2.1 静态评估

静态评估在特定时间点评估自我进化智能体的瞬时性能。尽管这些智能体旨在持续改进，静态方法对于建立基线性能、在固定任务集上比较不同智能体架构，或在离散训练阶段后评估能力仍然至关重要。该方法与传统人工智能评估一致，侧重于固定环境中的即时性能。虽然有助于评估“域内”泛化能力

表 7: 用于评估自进化智能体的代表性基准

Benchmark Name	Task Domain	Goal	Core Metrics	Task Quantity	Temporal Scope
ScienceAgentBench(Chen et al., 2024e)	Scientific Data Analysis	Adaptivity, Efficiency	Valid Execution Rate, Success Rate, CodeBERTScore, API Cost	102	Static
MLE-Bench(Chan et al., 2024)	ML-Engineering	Adaptivity	–	75	Static
DS-Bench(Jing et al., 2025)	Data Science	Adaptivity	Task Success Rate, Cost, Inference Time, Competition-level Accuracy	540	Static
SWE-bench(Jimenez et al., 2023)	Software Engineering	Adaptivity	Pass Rate	2,294	Static
OSWorld(Xie et al., 2024)	Computer-Use / GUI	Adaptivity	Success Rate	369	Static
Mobile-Eval-E(Wang et al., 2025o)	Computer-Use / GUI	Adaptivity, Efficiency	Action Accuracy, Reflection Accuracy, Termination Error	25	Static, Short-horizon
WebShop(Yao et al., 2022)	Web Search / Browse	Adaptivity	Success Rate	12,087	Static
WebArena(Zhou et al., 2023)	Web Search / Browse	Adaptivity	Success Rate	812	Static
WebWalkerQA(Wu et al., 2025)	Web Search / Browse	Adaptivity, Efficiency	Accuracy, Action Count	680	Static
ST-WebAgentBench(Levy et al., 2024)	Web Search / Browse	Safety	Completion under Policy	235	Static
xbench(Chen et al., 2025f)	Web Search / Browse	Adaptivity	LLM-Judge Score	100	Static
BrowseComp(Wei et al., 2025b)	Web Search / Browse	Adaptivity	Accuracy	1,266	Static
Agent-SafetyBench(Zhang et al., 2024i)	General	Safety	Safety Score	20,000	Static
LifelongAgentBench(Zheng et al., 2025b)	General	Adaptivity, Retention, Generalization	Success Rate	1396	Long-horizon
AgentBench(Liu et al., 2023b)	General	Adaptivity, Generalization	Success Rate, F1, Reward, Game Progress	1360	Static
GAIA(Mialon et al., 2023)	General	Adaptivity	Accuracy	466	Static
TheAgentCompany(Xu et al., 2024b)	General	Adaptivity, Efficiency	Completion Score, Steps, Cost per Instance	175	Static
EvaLearn(Dou et al., 2025)	General	Adaptivity, Efficiency	Accuracy, Slope, Position of 1st solution, Num of consecutive solutions	648	Long-horizon
PlanBench(Valmeekam et al., 2023)	Planning	Adaptivity	Accuracy	~26,250	Static, Short-horizon
Natural Plan(Zheng et al., 2024a)	Planning	Adaptivity	Exact Match	3,600	Static
ACPbench(Kokel et al., 2025)	Planning	Adaptivity, Generalization	Accuracy	3,720	Static
AppBench(Wang et al., 2024b)	Planning	Adaptivity	Success Rate, F1	800	Static
ToolBench(Qin et al., 2023)	Tool Usage	Adaptivity	Pass Rate, Win Rate	126,486	Static
ToolSandbox(Lu et al., 2024a)	Tool Usage	Adaptivity	Similarity Score	1,032	Static
Seal-Tools(Wu et al., 2024)	Tool Usage	Adaptivity	Accuracy, P/R/F1	14,076	Static
API-Bank(Li et al., 2023)	Tool Usage	Adaptivity	Accuracy, ROUGE	4,125	Static
T-Eval(Chen et al., 2023)	Tool Usage	Adaptivity	Domain-Specific Score	23,305	Static
τ -Bench(Yao et al., 2024)	Tool Usage	Adaptivity	Pass@k	165	Static
AceBench(Chen et al., 2025a)	Tool Usage	Adaptivity	Accuracy	2,000	Static
LTMBenchmark(Castillo-Bolado et al., 2024)	Agent Memory	Retention, Efficiency	Score, Accuracy, GoodAI LTM Score, Speed, Cost, Verbosity	30	Long-horizon
StoryBench(Wan & Ma, 2025)	Agent Memory	Retention, Efficiency	Accuracy, First-Try Accuracy, Longest Corr, Retry Count, Runtime Cost, Token Consumption	311 scene nodes, 86 choice nodes	Short-horizon, Long-horizon
MemoryAgentBench(Hu et al., 2025)	Agent Memory	Adaptivity	SubEM, Recall, ROUGE F1, Accuracy, Recall@5, Model-based Acc/F1	2200	Static, Short-horizon
MultiAgentBench(Zhu et al., 2025)	Multi-Agent Collaboration	Adaptivity	KPI, Text-Based Score, Communication Score, Planning Score, Coordination Score	100	Static
SwarmBench(Ruan et al., 2025)	Multi-Agent Collaboration	Adaptivity	Perspective-specific Metrics	5	Short-horizon

“进化、分布外评估”范式，静态评估本质上无法捕捉自进化智能体核心的动态、持续学习或长期进化特性。

为评估智能体在特定时刻的通用能力，通常采用为静态人工智能系统设计的标准基准。这些基准提供多样化的任务领域，测试各种核心智能体能力，从而在智能体进化之前或特定阶段提供其熟练程度的快照。这些评估可系统性地分为外部任务解决评估和内部智能体组件评估，其中外部任务解决评估衡量完成领域特定或跨领域任务的端到端性能，内部能力评估则关注智能体的基础组件，包括规划、工具使用、记忆管理、多智能体协调等。

外部任务解决评估 该类别评估智能体在各种真实或模拟环境中完成任务的端到端熟练程度。在科学数据分析和机器学习工程中，ScienceAgentBench（Chen 等，2024e）和 MLE-Bench（Chan 等，2024）等基准测试智能体生成和执行数据分析代码以及解决 Kaggle 风格问题的能力。对于网络搜索/浏览，WebShop（Yao 等，2022）、WebArena（Zhou 等，2023）、X-WebAgentBench（Wang 等，2025j）、Mind2Web（Deng 等，2023）和 BrowseComp（Wei 等，2025b）等环境模拟了真实的网络交互、复杂的浏览场景和任务完成。

表 8：目标到基准的映射及其局限性和覆盖缺口。

Goal	Benchmarks	Limitations	Coverage Gaps
Adaptivity	SWE-bench, We-bArena, MLE-Bench, ScienceAgentBench, GAIA	Restricted programming languages and execution time limits (Chen et al., 2024e); Simplified problem specifications vs. authentic R&D ambiguity (Chan et al., 2024); Weak sustained reasoning and decision-making (Liu et al., 2023b)	Open-ended exploration without predetermined objectives; Long-horizon adaptation under non-stationary distributions
Retention	LifelongAgentBench, LTMBenchmark, MemoryAgentBench	Persistent challenges in dynamic memory and long-range consistency (Hu et al., 2025); Replay buffer trade-offs with context overflow (Zheng et al., 2025b); Limited robustness testing due to costs (Castillo-Bolado et al., 2024)	Episodic designs reset state between tasks; No retention with safety constraints
Generalization	AgentBench, GAIA, TheAgentCompany, MLE-Bench	Progressive task obsolescence from algorithmic advances (Chan et al., 2024); Training data contamination risks (Chan et al., 2024)	Temporal robustness under distribution drift; Adversarial co-evolutionary assessment
Efficiency	MLE-Bench, TheAgent-Company	High resource demands limit accessibility (Chan et al., 2024); Cost constraints prevent baseline collection (Xu et al., 2024b)	No enforced budgets during evolution; Multi-objective constraints absent
Safety	Agent-SafetyBench, SwarmBench	Inadequate tool robustness and risk awareness (Zhang et al., 2024i); Local-global coordination disconnect (Ruan et al., 2025)	Static evaluation only; No long-horizon safety drift tracking; Co-evolutionary safety unexplored

在安全约束下。在软件工程领域，SWE-bench 系列（Jimenez 等，2023；Openai，2024；Aleithan 等，2024；Yang 等，2024）利用真实的 GitHub 问题来评估智能体的代码修复能力。对于计算机使用交互，OSWorld（Xie 等，2024）提供了一个统一的环境，用于涉及各种桌面和网络应用的开放式任务。营销等专业领域也设有基准，如 xbench（Chen 等，2025f）。除特定领域外，通用智能体基准如 AgentBench（Liu 等，2023b）、GAIA（Mialon 等，2023）和 TheAgentCompany（Xu 等，2024b）评估跨多个知识领域和专业任务的广泛问题解决能力，模拟通用人工智能助手在现实世界中的需求。

智能体内部组件评估 除端到端任务完成外，评估智能体的底层核心能力至关重要。这些基准评估有助于智能体整体智能和自我进化潜力的基本能力。在规划方面，PlanBench（Valmeekam 等，2023）、Natural Plan（Zheng 等，2024a）、AutoPlanBench（Stein 等，2025）和 ACPBench（Kokel 等，2025）等基准全面评估智能体在理解动态环境、制定策略、分解复杂问题以及在各种规划领域执行推理方面的能力。在工具使用方面，简单的基准如 ToolAlpaca（Tang 等，2023）和 ToolBench（Qin 等，2023）测试基本的选择和参数映射，而更复杂的基准如 ToolSandbox（Lu 等，2024a）、Seal-Tools（Wu 等，2024）、API-Bank（Li 等，2023）、T-Eval（Chen 等，2023）、 τ -Bench（Yao 等，2024）、AceBench（Chen 等，2025a）模拟涉及多轮交互、隐式状态依赖和嵌套调用的现实场景。记忆管理基准如 LTMBenchmark（Castillo-Bolado 等，2024）、MemoryAgentBench（Hu 等，2025）和 StoryBench（Wan & Ma，2025）评估智能体在多轮交互、动态场景和长程依赖中保留和利用信息的能力。对于多智能体协作的评估，MultiAgentBench（Zhu 等，2025）和 SwarmBench（Ruan 等，2025）等基准评估协作和竞争环境中的协调、沟通和涌现群体智能。

静态评估的典型度量包括准确率、成功率、进展率、完成率以及各类领域特定的性能指标（例如代码相似度分数、有效执行率、通过率、F1 分数）。这些度量为单次调用或固定任务集提供了单一的性能评分。

表 9：短时程自适应评估与长时程终身学习能力评估的差异

Dimension		Short-horizon Adaptation Assessment	Long-horizon Lifelong Learning Ability Assessment
Primary Focus		Immediate learning and incremental improvement within consistent or slightly varying tasks	Continuous knowledge accumulation and sustained performance across diverse, evolving tasks and environments.
Core Challenges		Rapid adaptation to minor changes; Improving on similar, repeated tasks	Mitigating catastrophic forgetting; Robust knowledge transfer; Maintaining efficiency/safety over time; handling true novelty and significant distribution shifts
Temporal Scope		Small number of sequential tasks or iterations over a short period; Improvement on the same or similar task types.	Large, potentially unbounded sequence of diverse, cross-domain tasks; Very long interaction periods requiring integration of new skills with old

7.2.2 短时程自适应评估

短时程自适应超越了静态评估，通过评估智能体在相对较短时期或有限交互次数内适应和改进的能力。智能体可能通过更多尝试在同一任务实例上提升性能，或适应同一任务类型的新实例。该类别侧重于捕捉自进化智能体在相对一致或略有变化的任务分布内即时适应和增量学习的能力。这些评估方案大致可分为两种方式：（1）为传统基准增加时间维度，以及（2）专门设计能够天然支持短时程动态学习的基准和度量。

增强型传统基准 许多研究利用现有基准，但引入新维度以跟踪性能随时间的变化。这通常涉及将性能作为迭代次数、步骤数或示例数的函数进行分析。例如，自适应智能体系统在抽象推理语料库基准上评估了保留测试准确率随智能体系统迭代次数的变化；自适应网络记忆方法在网页导航环境地图测试划分的在线评估过程中研究了累积成功率，使用示例数量标记进化进展；网络进化器在实时网页任务基准上研究了自我改进迭代下的成功率。该方法允许在限定范围内跟踪智能体的适应性。

内置动态评估的基准 部分基准在设计时考虑了短时程动态学习。例如，记忆智能体基准（MemoryAgentBench）（Hu 等，2025）包含一个“测试时学习”（Test-Time Learning, TTL）维度，用于评估智能体在单次交互会话中直接从对话中学习新任务的能力。在实践中，TTL 通过两类任务进行评估：多类分类和推荐。在这些设置中，智能体必须利用先前提供的信息——例如上下文中的标注示例或一段较长的电影相关对话历史——来执行新任务，如将句子映射到类别标签或推荐相关电影。这评估了持续交互过程中的即时适应和知识获取能力。

评估短时程适应能力的度量与方法 短时程适应能力的主要度量和评估方法旨在量化适应性。这些方法包括：（1）按迭代步数统计的成功率（Hu 等，2024c；Wang 等，2024j；Zheng 等，2025b），用于跟踪智能体与环境交互更多或多次尝试任务时的性能提升；（2）学习曲线分析，用于可视化性能（如成功率、准确率）在有限训练步数、回合或交互次数内的变化（Hu 等，2024c；Wang 等，2024j）；（3）适应速度（Wang 等，2023a），用于衡量智能体在短时程内达到特定性能阈值或收敛到最优策略的速度。

短时程适应能力非常适合评估自进化智能体的初始学习能力和即时适应性。它们能够有效展示智能体是否能够从近期经验中学习并提升其在领域内任务上的性能。这一类别被广泛用于当前的自进化智能体。然而，有限的时间窗口使得评估长期知识保持（缓解灾难性遗忘）以及跨差异巨大或顺序呈现任务的真正终身学习能力变得困难。

7.2.3 长时程终身学习能力评估

长周期终身学习能力评估对于真正评估自我进化智能体至关重要，因为它关注智能体在多样化环境和长时间跨度内持续获取、保留和复用知识的能力。如表 9 所示，它主要关注在长时间跨度内、面对多样化且可能不断变化的任务或环境流时的持续学习、知识积累和稳定性能。这是一个新兴但关键的领域，其独特挑战包括灾难性遗忘、跨不同任务的稳健知识迁移、长时间跨度内的高效资源管理，以及在不断演变的数据分布上持续评估时减轻数据泄漏。专门的基准正在涌现以应对这些复杂性。

目前，此类基准数量稀少。LTMBenchmark (Castillo-Bolado 等, 2024) 是专注于长期记忆 (LTM) 评估的专用基准。它通过动态对话测试评估大语言模型智能体的记忆保持与持续学习能力，利用带有受控干扰的交错对话模拟现实世界的回忆挑战。关键度量包括任务准确率、记忆张成加权的 LTM 分数，以及用于跨架构比较的效率测度（测试数/小时、成本）。LifelongAgent-Bench (Zheng 等, 2025b) 是另一项开创性基准，专门设计用于评估智能体的终身学习。它构建跨数据库 (DB)、操作系统 (OS) 和知识图谱 (KG) 等领域的相互依赖任务序列，要求智能体逐步建立在先前习得的技能之上。这允许在长期学习轨迹中系统追踪性能提升与知识保持。为解决缺乏多样化环境以测试泛化的问题，AutoEnv (Zhang 等, 2025i) 引入了一个从可分解规则分布自动生成异构世界的框架。该工作还贡献了 AUTOENV-36 数据集，以系统测度智能体的跨环境学习与适应能力。此外，存在一种解决方案，通过持续更新基准数据集 (White 等, 2024; Yang 等, 2025c) 或通过重构原始基准使基准自身演化来评估自进化智能体，从而构建动态基准，这在一定程度上可缓解数据泄漏 (Chen 等, 2025g)。例如，Benchmark Self-Evolving (Wang 等, 2024e) 提出了一种通过迭代持续更新现有基准的解决方案。类似地，TRACE 框架 (Guo 等, 2025a) 通过测试时探索使智能体将任务演化至更高难度，以应对基准饱和问题。这些新颖且更复杂任务的有效性由“复现验证”范式保证，该范式确认智能体记录轨迹可复现。此类动态基准场景的初步发现表明，随着基准演化，模型性能可能下降，凸显了持续适应的难度。

长时程终身学习的度量指标超越了简单的成功率，用于量化智能体不断演进的能力，例如遗忘 (Forgetting, FGT)、后向迁移 (Backward Transfer, BWT) (Zheng 等, 2025c) 以及单位增益成本。长期泛化度量可能涉及在持续演进的分布外任务集上评估性能，或衡量智能体在跨多个领域长期学习后仍能有效执行的任务广度。

长时程终身学习能力评估对于全面评价自进化智能体的核心承诺至关重要：即其持续学习、保留知识并在较长时间内有效泛化的能力。这些评估对于评估保留能力、对真正新颖场景的泛化能力以及长期运行的效率至关重要。该领域仍是自进化智能体评估研究的一个关键前沿。除了固定的长时程流之外，一种开放式变体持续演进任务、工具和环境。

表 10: 标准化评估协议

Aspect	Short-horizon	Long-horizon	Work Example for Long-horizon (EvoAgent (Yuan et al., 2025a))
Goal aligned	Adaptivity, efficiency	Retention, generalization, efficiency, long-term safety	Optimizes long-horizon Success Rate (SR) and Exploration Efficiency (EE) on 67 Minecraft tasks (five tiers) plus Atari; e.g., Overall SR improves from 21.80% to 30.29% (relative gain $\approx 105.9\%$).
State persistence	No persistence across tasks; all updates reset after each episode	Full persistence of model / prompt / memory / tools across tasks	Maintains a persistent Multimodal Experience Pool and continual World Model, updating parameters and experience after each subtask and reusing them across subsequent tasks without reset.
Dataset structure	Fixed benchmark or episodic sampling; IID or near-IID task variants	Streamed sequences with non-stationary distributions; versioned tasks; explicit OOD clusters for transfer	Uses a fixed long-horizon Minecraft benchmark (67 tasks split into Wood/Stone/Iron/Gold/Diamond tiers) plus Atari as a cross-environment test set; tasks are pre-defined rather than streamed or versioned.
Evolution budget	Per-task cap K_{short} (iterations, tool calls, tokens, wall-clock)	Stage cap K_{stage} + cumulative cap K_{total} ; explicit memory/tool growth policy	Enforces a per-subtask step cap L_{max} and matches DreamerV3's environment-step budget, reporting wall-clock of ~ 2.7 days vs. ~ 7 days on one A100, but without explicit formulas for $K_{\text{stage}}/K_{\text{total}}$ or a formal memory/tool growth policy.
Required logging	Per-iteration: seeds, prompts, model/tool versions, full reasoning/action traces, cost breakdown	Above + persistent state checkpoints, replayable trajectories, scheduled retention probes, evolution decision logs	Logs each terminated subtask as a trajectory (states, rewards, completion ratios) into the experience pool for CL-based sampling and world-model updates, but does not publish full replayable per-iteration logs, checkpoints, or scheduled retention probes.
Primary metrics	<i>Adaptivity</i> : success-by-iteration curves, AULC; <i>Generalization</i> : within-distribution transfer	<i>Retention</i> : BWT/FGT, forgetting curves; <i>Generalization</i> : temporal & cluster-OOD; <i>Efficiency</i> : Cost-per-Gain (CPG)	Uses SR and EE per tier plus an Overall aggregate; e.g., on Gold and Diamond tiers EvoAgent roughly doubles SR over baselines, but no BWT/FGT or explicit forgetting curves are reported.
Efficiency metrics	Cost-per-Gain (CPG), tokens-per-success, tool calls, latency per iteration	Cumulative CPG, stage-wise efficiency, token-drift (tokens/task over time), memory growth rate	Efficiency is captured by EE and wall-clock (e.g., $> 6\times$ fewer ineffective steps on average and 2.7 vs. 7 days training), while CPG, token-drift, and memory-growth statistics are not explicitly reported.
Safety auditing	Per-episode: Safety Score, Harm Score, Refusal Rate; window-level Leakage Rate	Long-horizon safety drift tracking; periodic probes (Safety/Harm/CuP/Risk Ratio); persistent Leakage Rate across stages	Relies on an internal self-verification module with goal-similarity and L_{max} to terminate unproductive subtasks, but does not run external safety benchmarks or track long-horizon safety drift.
Human-in-loop	Human-time + guidance-tokens per episode; intervention count	Cumulative human-time + guidance-tokens; stage-wise intervention frequency; intervention-to-success ratio	After initial task specification, training and evaluation are fully autonomous with no human feedback or labeling, and human-time/guidance-tokens are effectively 0 (not numerically reported).
Required outputs	Learning curve + AULC; per-task summary table; cost breakdown	Learning/forgetting matrix; stage tables + long-horizon curves; detailed cost taxonomy breakdown	Provides SR/EE tables over all tiers and ablations over planner/control/reflection/world-model modules, but no learning/forgetting matrices or detailed cost-taxonomy (tokens/time/tool/memory) breakdowns.

7.2.4 标准化评估协议

为解决现有设置的异质性问题并使以轨迹为中心的评估可复现，我们进一步将上述考量提炼为短时程和长时程评估的标准化协议，总结于表 10。对于短时程设置，我们假设不存在跨任务状态持久化，并对每个任务的演进施加预算 K_{short} （以迭代次数、工具调用次数、令牌数或墙钟时间计），要求对提示、模型/工具版本、完整推理与行动迹以及成本分解进行逐迭代日志记录，并通过按迭代的成功率曲线和学习曲线下面积以及基本效率度量（例如，每次成功的令牌数、延迟）报告适应性。相比之下，长时程协议假设模型参数、提示、记忆和工具集在任务间完全持久化，指定阶段性和累积性演进预算（ $K_{\text{stage}}, K_{\text{total}}$ ）以及明确的记忆/工具增长策略，并要求更丰富的日志记录：可回放的轨迹、持久检查点、定期保留探测、演进决策日志以及人在回路统计信息，以揭示自指导程度。主要的长时程度量随后从即时成功扩展到包括保留（FGT/BWT 和遗忘曲线）、时间和簇分布外泛化、单位增益成本及效率随时间的漂移，以及长期运行。

在行为不断演变的情况下，安全指标如安全事件发生率和政策合规性。我们的工作示例 EvoAgent（Yuan 等人，2025a）既说明了实践的可行性，也揭示了当前的局限性：它已经满足了长时程协议的关键要素——持久的世界模型和经验更新、明确的子任务步数上限，以及安全率/效率比和墙钟效率的报告——但许多推荐维度（例如标准化保留指标、明确的 CPG/令牌漂移以及长期安全漂移跟踪）尚未报告，这凸显了未来自我进化智能体评估需要填补的具体空白。

7.3 当前评估实践的局限性

尽管前几节概述了核心评估维度及其覆盖范围，但更广泛的视角表明，当前实践仍存在大量盲区，并阻碍了不同方法之间的公平比较。为了将这些局限性置于具体情境中，我们考察了仍未被充分评估的能力维度，以及在共享设置下使同类比较复杂化的因素。

7.3.1 服务不足的能力交叉点

带隐私约束的长时程保留：目前没有基准将扩展记忆评估（如 LTMBenchmark（Castillo-Bolado 等人，2024））与严格的安全审计（如 Agent-SafetyBench（Zhang 等人，2024i））结合起来，因此无法确定智能体能否在数千次交互中保持个性化，同时保证零敏感信息泄露。

操作约束下的架构自适应：当前的架构搜索方法（例如 AFlow（Zhang 等人，2024c）、ADAS（Hu 等人，2024c））在离线状态下长时间运行以发现最优工作流。目前没有评估考察智能体能否自主演化其架构选择策略，学习哪种拓扑最适合不同类型的查询，同时遵守实时操作约束（毫秒级响应延迟、每次查询的令牌预算）。这不仅需要评估最终架构质量，还需要评估智能体在严格资源限制下，其选择或生成架构的策略是否通过经验持续改进。

工具生态演化：现有工具基准提供固定应用程序编程接口；尚无评估能捕捉工具发现、集成测试与生产力度量的自导生命周期——这些能力已由类似 Alita 的系统展示，却未纳入标准评估。

协同演化下的多智能体安全：SwarmBench（Ruan 等，2025）在孤立时间点识别协调失败；这些失败在长期多智能体协同演化中会放大还是减弱，以及当智能体相互学习时，不安全行为是否表现出社会传染，仍未得到探索。

7.3.2 公平比较的挑战

为补充对评估基准的讨论，本文提供表 11，该表对齐了在部分匹配条件下评估的自演化智能体的代表性子集，即相似领域、基准和骨干模型。该表旨在明确，当周围实验上下文尽可能保持文献所允许的恒定时，不同方法如何实例化“什么/何时/如何”维度。然而，正如该表也清楚表明的，真正的同类比较目前仍不可行。现有工作在以下方面存在显著差异：（1）报告实践：延迟、成本和安全性等关键度量常被省略或定义不一致；（2）评估流程：提示格式、展开预算、工具访问和环境配置差异很大；（3）骨干模型选择：即使名义上相似的模型在规模、训练数据或推理设置上也不同；（4）架构设计：智能体实现不同的控制循环、信用分配机制和记忆系统，无法直接比较。由于这些因素相互影响，跨方法归一化结果可能过度解读未受控的差异。因此，表 11 作为说明性快照呈现，而非确定性比较。

尽管存在这些局限性，该表仍突显若干定性趋势：使用更丰富的“什么”结构（如架构级搜索）和测试间“何时”机制的方法，在多步优化可行的领域中往往取得更强性能，而轻量级测试内反思方法则倾向于

表 11: 在共享设置下对一些代表性自进化智能体的比较综合。方法按领域分组；重复条目用“-”表示。我们使用什么/何时/如何分类法总结每种方法并报告性能。延迟、成本和安全性度量并未一致报告，限制了完全同类比较。

Area	Benchmark	Base model	Method	What	When	How	Perf. (%)
code	SWE	Gemini-1.5-pro	Reflexion (Shinn et al., 2023)	Context / lesson / reflection	Intra-test (ICL)	Reward-based (textual)	14.3
-	-	-	Learn-by-Interact (Su et al., 2025)	Context / experience / reflection	Intra-test (ICL)	Reward-based (textual)	18.7
-	-	Claude-3.5-sonnet	Reflexion (Shinn et al., 2023)	Context / lesson / reflection	Intra-test (ICL)	Reward-based	54.4
-	-	-	Learn-by-Interact (Su et al., 2025)	Context / experience	Intra-test (ICL)	Reward-based	60.0
-	WebArena	Gemini-1.5-pro	Reflexion (Shinn et al., 2023)	Context / lesson / reflection	Intra-test (ICL)	Reward-based (textual)	20.2
-	-	-	Learn-by-Interact (Su et al., 2025)	Context / experience	Intra-test (ICL)	Reward-based	25.6
web	WebArena	Claude-3.5-sonnet	Reflexion (Shinn et al., 2023)	Context / lesson / reflection	Intra-test (ICL)	Reward-based	40.4
-	-	-	Learn-by-Interact (Su et al., 2025)	Context / experience	Intra-test (ICL)	Reward-based	48.0
-	WebArena-Lite	GLM-4-9B	DigiRL (Bai et al., 2024)	Model policy	Inter-test (RL)	Reward-based (external env.)	31.5
-	-	-	WebRL (Qi et al., 2024)	Model policy	Inter-test (RL)	Reward-based (external env.)	43.0
-	-	Llama3.1-8B	DigiRL (Bai et al., 2024)	Model policy	Inter-test (RL)	Reward-based	30.3
-	-	-	WebRL (Qi et al., 2024)	Model policy	Inter-test (RL)	Reward-based	42.4
math	GSM8K	GPT-4o-mini	ADAS (Hu et al., 2024c)	Architecture multi-agent system	/ Inter-test (RL / SFT hybrid)	/ Population-based workflow search	90.5
-	-	-	AFlow (Zhang et al., 2024c)	Architecture multi-agent topology	/ Inter-test	Population-based (MCTS)	90.8
-	-	-	ScoreFlow (Wang et al., 2025n)	Architecture / multi-agent (query-specific workflow)	Inter-test	Imitation + preference optimization	94.6
-	MATH	Gemini-1.5-pro-002	ADAS (Hu et al., 2024c)	Architecture multi-agent system	/ Inter-test	Population-based	80.0
-	-	-	AFlow (Zhang et al., 2024c)	Architecture multi-agent topology	/ Inter-test	Population-based	76.0
-	-	-	Mass (Zhang et al., 2025d)	Architecture / single / multi-agent design search	Inter-test	Population-based evolutionary	84.7

更具成本效益但收益较小。几乎所有方法都缺乏一致的延迟/成本/安全性报告，这突显了一个限制更广泛综合的关键差距。我们希望此表能作为当前方法在可比设置下如何操作什么/何时/如何维度的具体参考，同时推动标准化报告的需求，以支持未来的同类评估。

8 未来方向

8.1 个性化人工智能智能体

随着对自进化智能体兴趣的增加，部署个性化智能体已成为研究界日益重要的目标（Zhang 等，2024h）。例如，在聊天机器人、数字孪生和情感支持对话等应用中，一个关键挑战是使人工智能智能体能够在长期交互中准确捕捉并适应用户独特的行为模式或偏好。现有的个性化智能体通常严重依赖标注数据和训练后方法（Cheng 等，2024）。Zhang 等（2025q）最近的工作提出了一种自生成偏好数据方法，旨在快速个性化大语言模型。TWIN-GPT Wang 等（2024h）利用电子健康记录创建患者的数字孪生，提高临床试验结果预测的准确性。然而，这些现有策略依赖于一个关键假设，即大语言模型能够持续获取高质量、大规模的用户数据。

在实际部署场景中，主要挑战仍然是冷启动问题：智能体需要在初始数据有限的情况下，逐步完善其个性理解，准确解读用户意图，并有效构建用户画像。此外，个性化规划与执行方面仍存在显著挑战，例如有效的长期记忆管理、外部工具集成以及个性化生成（确保输出始终与个体用户的事实和偏好保持一致）（Li 等，2025d）。此外，必须确保自进化智能体不会无意中强化或加剧现有的偏差和刻板印象，这凸显了未来研究的另一个关键方向。随着个性化智能体不断进化并调整其记忆或决策过程，这些治理原则尤为重要。在这些治理原则的基础上，评估框架也应随之演进，以确保个性化场景中的公平性、问责制和对齐。

数据治理。负责任的个性化应在适应性与隐私保护之间取得平衡。首先，智能体应采用数据最小化原则：仅收集与任务相关的数据，并提供透明、可撤销的控制选项。经验表明，网络智能体基准显示，最先进的智能体经常不必要地处理敏感数据，这促使了默认最小化设计（Zharmagambetov 等，2025）。作为补充，个性化智能体的有效数据治理需要部署端侧个性化框架，以便从用户交互中进行本地学习，同时配合用户主导的隐私机制，例如 Rescriber，在任何远程数据交换之前执行端侧编辑和批准（Zhou 等，2025c）。为防止无限期保留，记忆衰减和遗忘策略应支持选择性删除以及针对个性化迹的“被遗忘权”式遗忘（Staufer，2025）。最后，由于自进化可能随时间推移导致安全性或公平性漂移，系统应包含偏差监控和公平性审计循环，随着用户和情境的演变调整标准和干预措施（Basu & Das，2025），并通过持续检查记忆/工具/ workflows 更新来防范错误进化（进化过程中的安全性/对齐退化）（Shao 等，2025）。

评估。随着个性化数据的整合，个性化自进化智能体的评估指标应超越内在评估（例如，使用如 ROUGE（Lin，2004）和 BLEU（Papineni et al., 2002）等指标直接评估个性化生成文本质量）或外在评估（例如，通过推荐系统、分类任务及其他特定应用间接评估个性化效果）。传统的个性化评估指标往往无法充分捕捉自进化智能体固有的演化动态。因此，未来研究需要更轻量级和自适应的评估指标（Zhang et al., 2024h）。此外，为了更好地评估自进化个性化智能体，迫切需要灵活、动态的基准，能够准确评估智能体的性能，特别是在自进化过程中管理长尾个性化数据方面。我们提倡报告：

- **个性化适应增益（Personal Adaptation Gain, PAG）**：每个用户在 k 个会话中相对于非个性化基线的改进。

- **保留与遗忘平衡**：如前向/后向迁移和选择性遗忘效能等指标（例如，在删除请求后用户事实暴露的减少）。
- **隐私-效用权衡**：效用增益与保留的个人数据比特数之比；在网络智能体场景中辅以数据最小化评分（仅在必要时共享敏感信息的比例）（Zharmagambetov et al., 2025）。
- **设备端学习比率**：个性化更新或记忆写入在用户设备本地执行的比例，可能带有用户同意或修订机制（例如，在 Rescriber 中研究的那样）（Zhou 等人，2025c）。
- **偏差/漂移监测器**：跨用户群体差异或安全退化的纵向测量；可以定义诸如公平性漂移或安全漂移等指标，尽管标准化版本仍有待开发（Basu 和 Das, 2025；Shao 等人，2025）。
- **纵向用户结果**：跟踪会话级满意度、目标完成趋势或多阶段发展轨迹（例如，在 StuLife 等基准中的虚拟“校园生活”智能体）（Cai 等人，2025）。

8.2 泛化

自进化智能体在跨多样化任务领域和环境中实现稳健泛化方面也面临相当大的挑战。专业化与广泛适应性之间的根本张力仍然是该领域最紧迫的挑战之一，对可扩展性、知识迁移和协作智能具有重要影响。

可扩展架构设计：开发可泛化的自进化智能体的一个核心挑战在于设计可扩展的架构，能够在复杂性和范围增加时保持性能。当前的智能体系统经常遇到专业化与泛化之间的权衡，针对特定任务优化的智能体难以将其学习到的行为迁移到新环境中（Chen 等人，2024d）。此外，基于大语言模型的智能体中动态推理相关的计算成本随着适应机制的复杂性呈非线性增长，在现实资源限制下对可实现的泛化施加了实际约束（Kim 等人，2025）。最近的研究表明，配备反思和记忆增强能力的自进化智能体在增强泛化方面显示出巨大潜力，特别是在较小的资源受限模型中（Liang 等人，2024）。尽管如此，这些方法在处理需要长期持续适应的复杂现实场景时仍然遇到局限性。

跨领域自适应：实现跨领域泛化是自进化智能体面临的关键前沿。当前方法通常依赖领域特定的微调，限制了智能体在不重新训练的情况下适应新环境的能力（Belle 等，2025）。测试时扩展和推理时自适应方面的最新进展为增强跨领域泛化提供了有前景的途径（Snell 等，2024；Zhang 等，2025l）。这些技术允许智能体通过在推理期间扩展计算资源，动态地为不熟悉场景分配额外的推理能力，从而避免增加模型参数。此外，元学习策略在促进对新领域的快速少样本自适应方面已展现出相当大的潜力（Bilal 等，2025）。然而，其有效性关键取决于智能体准确判断何时需要补充计算资源，并在多样推理任务中高效分配这些资源的能力。

持续学习与灾难性遗忘：自进化智能体必须持续适应新任务，同时保留先前获得的知识，这一挑战因大语言模型固有的持续记忆（Chen 等，2024b）中的灾难性遗忘现象（Ghosal 等，2024）而加剧（Bell 等，2025）。稳定性-可塑性困境在基于基础模型的智能体中尤为突出，因为为每个新任务重新训练的计算成本过高（Zheng 等，2025c）。近期研究探索了参数高效微调方法、选择性记忆机制和增量学习策略，以在保持适应性的同时减轻灾难性遗忘（Wang 等，

2024c)。尽管如此，在效率与防止模型漂移之间实现最佳平衡仍然是一个重大的开放挑战，尤其是当智能体在资源约束下运行或处理具有严格隐私考虑的数据流时。

知识可迁移性：近期研究已识别出智能体间知识迁移的关键局限性。Shi 等人（2025a）强调，当前智能体的知识整合与迁移能力仍需显著优化。特别是，Geng 等人（2025b）发现基于大语言模型的智能体往往无法有效地将交互中获得的新知识传播给其他智能体，从而限制了它们的协作潜力。此外，Vafa 等人（2025）揭示基础模型可能严重依赖浅层模式匹配，而非发展出稳健且可迁移的内部世界模型。这些发现指出了若干重要的未来研究方向：1）必须更好地理解一个智能体所获得的知识在何种条件下能够可靠地泛化并传递给其他智能体；2）开发量化智能体知识迁移局限性方法，可为智能体协作瓶颈提供更清晰的洞见；3）需要一种明确的机制来促进稳健、可泛化的世界模型的形成，这能显著提升自进化智能体的协作有效性。

8.3 安全且可控的自进化智能体

随着自主人工智能智能体越来越有能力独立学习、进化和执行复杂任务，确保其安全性和可控性已成为首要关切。与静态系统不同，自进化的本质引入了独特且被放大的风险，这些风险在智能体的生命周期中动态涌现。这些风险不仅仅是传统人工智能安全问题的延伸，例如由模糊用户指令或恶意钓鱼链接等环境威胁所引发的风险（Zhou 等人，2025d），而是从根本上与智能体自主自我修改和适应的能力相关（Shao 等人，2025；Han 等人，2025）。本节描述了自进化智能体特有的新兴风险，然后讨论了一套用于构建更安全系统的规范性护栏机制和缓解策略。

8.3.1 自进化系统中的新兴风险

近期研究已识别出由自主自我改进过程本身所引发的新风险。这些风险不一定存在于初始智能体中，但可能随着其进化而逐渐显现。我们沿着智能体的主要进化路径对这些风险进行分类：骨干模型、记忆和工具。

- **模型演化中的失控行为漂移：**核心风险在于，智能体的目标和价值观可能随着其演化而偏离最初的人类意图。自我演化固有的学习不确定性加剧了这一风险，尤其是在模糊情境下运行时（Anwar 等，2024；Bagdasarian 等，2024）。模型演化过程中可能出现一种被称为“错误演化”（misevolution）的现象（Shao 等，2025）。例如，在智能体生成的数据上进行自我训练可能导致安全对齐的“灾难性遗忘”，使智能体执行其先前拒绝的有害指令，例如与其被训练避免的恶意内容进行交互（Shao 等，2025；Hahm 等，2025）。

- **记忆演化中的部署时奖励黑客行为：**开放式演化容易受到奖励黑客行为的影响。智能体可能发现并利用自定义奖励信号或内部反馈中的漏洞。这在记忆演化中尤为明显，经验的积累可能无意中诱发不安全行为。例如，智能体可能学会发放不必要的退款，因为其记忆将退款与高满意度评分相关联（Shao 等，2025），而设计不佳的记忆模块可能进一步加剧此类风险（Wang 等，2025b）。一个相关概念是“对齐倾斜过程（Alignment Tipping Process, ATP）”，即最初对齐的智能体发现不对齐行为更具奖励性，导致其策略“倾斜”并放弃初始约束（Han 等，2025）。

- **自创工具与外部引入工具的安全性：**智能体自主生成和使用工具的能力带来了显著的安全问题。智能体可能自发创建

存在安全漏洞的工具，或在引入外部工具时未能识别恶意代码（Shao 等，2025）。这使得智能体成为潜在的安全威胁载体。此处的一个主要挑战是，智能体仍难以区分必要与无关的敏感信息（Zharmagambetov 等，2025），可能导致其创建泄露私人数据的工具。此外，随着智能体的改进，它们可能更擅长创建和执行攻击性网络操作，这一风险需要动态评估（Wei 等，2025a）。

8.3.2 规范性护栏机制与缓解策略

应对自我进化带来的新兴风险，需要超越描述性警示，转而实施规范性、可操作的护栏机制。尽管早期框架如可信代理（TrustAgent）已探索多阶段策略（即规划前、规划中、规划后）以促进更安全的行为（Hua 等，2024），但自我进化的独特动态要求采用更全面的“安全生命周期”方法。未来的研究与开发预计将聚焦于在智能体运行的每个阶段集成安全防护措施。

- **工具与代码执行的沙箱化与验证：**为降低工具使用带来的风险，所有由智能体生成或外部来源的工具必须在严格沙箱化的环境中执行。此外，自动化安全验证（如静态分析和漏洞扫描）应作为新工具集成前的默认步骤（Labs，2025）。为保障工具交互协议的安全，运行时防御流水线（Xing 等，2025；Wang 等，2025a）提供了针对工具投毒和提示注入等威胁的分层检测。
- **自我修改的审计追踪与故障保护：**任何自我修改都必须伴随全面的审计追踪，以确保更改可追溯且可逆。实施回滚与故障保护模式至关重要，使系统在检测到不良行为时能够回退到先前已知的安全状态。对于记忆，主动防御机制如 A-MemGuard 提出双记忆结构与基于共识的验证，以在“中毒”记忆破坏行为之前识别并隔离它们（Wang 等，2025b；Wei 等，2025d）。
- **针对长期漂移的持续监控与红队测试：**静态的部署前安全评估并不充分。需要对智能体行为进行持续监控，以检测长期价值漂移。这可以通过设计用于测试突发性失对齐的红队场景来实现。对于图形用户界面（GUI）智能体，混合验证框架如 OS-Sentinel 将形式化验证器与上下文判断器相结合，以提供稳健的工作流内安全监控（Sun 等，2025b）。
- **审批关卡与隐私保护措施：**对于高风险操作，应实施需要人在回路确认的审批关卡。此外，鉴于智能体在处理敏感数据方面存在困难（Zharmagambetov 等，2025），必须采取稳健的隐私保护措施以防止泄露，并确保部署的平衡与安全。

为协助实践者，我们将这些策略综合成一份部署自进化智能体的合规检查清单（见表 12）。总之，部署可靠、可控且安全的自进化系统是一个关键且活跃的研究领域。未来工作必须朝着构建全面的安全感知进化生命周期迈进，整合稳健的验证、持续监控和自适应护栏机制，以确保智能体在变得更加自主时仍与人类价值观和安全约束保持一致。

8.4 多智能体生态系统

多智能体自进化系统面临若干独特挑战，需要进一步探索。

Balancing Individual and Collective Reasoning: Recent studies highlight the difficulty of balancing independent reasoning with effective group decision-making in multi-agent environments (Chen et al., 2025d;

表 12：部署自进化智能体的合规检查清单 类别 部署合规检查清单 工具与代码安全

Category	Compliance Checklist for Deployment
Tool & Code Safety	☐ 严格沙箱化：所有工具和智能体生成的代码均在隔离环境中执行，默认不访问主机文件、网络或敏感进程。 ☐ 资源限制：沙箱对 CPU、内存和执行时间施加严格限制，以防止拒绝服务或失控进程。 ☐ 自动化安全验证：强制流水线对所有新的或修改过的工具在使用前执行静态分析（例如 SAST）和漏洞扫描。 ☐ 依赖扫描：验证流水线检查所有第三方库和依赖项是否存在已知漏洞。 ☐ 基于风险的访问控制：工具按风险级别分类，高风险能力（例如文件系统写入、API 调用）需要通过审批关卡获得明确批准。
自我修改控制	☐ 不可变审计追踪：所有自我修改（涉及模型权重、记忆、工具集或核心逻辑）均被记录，包含触发条件、所做更改及结果。 ☐ 安全状态版本控制：智能体的状态（模型、记忆、工具）被版本化，已知的“安全”版本被明确标记。 ☐ 经测试的回滚机制：存在可靠的一键回滚机制，可将智能体恢复至先前已知的安全版本。该机制定期接受测试。 ☐ 更新前安全验证：在部署自我修改后的模型之前，自动使用安全关键提示的“黄金数据集”对其进行评估，以防止对齐的灾难性遗忘。
行为与对齐安全	☐ 持续运行时监控：主动监控系统跟踪智能体行为，标记偏离预期行为、异常资源使用或不安全行为迹象。 ☐ 奖励黑客行为检测：监控关键度量以发现奖励黑客行为迹象（例如利用奖励函数漏洞）。针对急剧且无法解释的度量变化配置警报。 ☐ 自动化红队测试：持续的红队测试框架处于活跃状态，以编程方式生成并运行测试场景，以探查新出现的对齐偏差、价值漂移和新的失效模式。 ☐ 目标护栏机制：对智能体修改自身基本目标或安全约束的能力施加严格约束。任何此类更改均需人工审核。
数据隐私与记忆完整性	☐ 主动记忆防御：采用双记忆结构或共识验证等机制，在潜在“有毒”或有害记忆影响行为之前，检测、隔离并中和它们。 ☐ 个人身份信息检测与脱敏：在个人身份信息（PII）被存储至长期记忆或用于训练之前，使用自动化工具检测并对其进行编辑或匿名化处理。 ☐ 数据最小化原则：智能体被配置为仅收集和保留任务所必需的数据，并强制执行数据保留策略。 ☐ 隐私法规合规性：系统设计符合相关数据隐私法规（例如《通用数据保护条例》（GDPR）、《加州消费者隐私法案》（CCPA））。
运营控制与治理	☐ 关键操作的人为介入：高风险操作（如大额金融交易、数据删除、与外部用户通信）须经强制人工审批步骤把关。 ☐ 明确的事件响应计划：已制定成文计划以应对安全故障，包括立即停机、回滚和分析的步骤。 ☐ 集中式监督仪表板：仪表板为人类操作员提供对智能体行为、状态和活跃安全警报的实时可见性。 ☐ 可解释性与可追溯性：系统清晰解释采取特定操作的原因，并在审计追踪中将其关联到具体记忆、目标或模型推断。

Sun 等人，2025a）。虽然集体讨论能显著增强诊断推理，但智能体往往面临过度依赖群体共识的风险，从而削弱其独立推理能力。

为缓解这一问题，未来研究应探索动态机制，调整个体与集体输入的相对权重。这种方法有助于防止决策被单个或少数智能体主导，最终促进稳健、平衡的共识构建与创新。此外，开发显式知识库和标准化更新方法——利用智能体的成功与失败——可进一步提升智能体的自进化能力，并增强其在协作情境中的个体推理贡献。

高效框架与动态评估：另一个关键挑战在于开发高效的算法和自适应框架，使智能体能够有效协作，同时保持其各自的决策优势。（Hu et al., 2024d）引入了自适应奖励模型和优化的动态网络结构，这可以显著增强智能体之间的协作式自我改进。然而，（Sun et al., 2025a）指出的一个主要空白是缺乏明确的机制让智能体动态管理和更新其知识。解决这一问题需要新的框架，明确整合持续学习和自适应协作机制。此外，现有的多智能体评估基准主要是静态的（Zhu et al., 2025），因此无法捕捉智能体角色的长期适应性和持续演化。未来的基准应纳入动态评估方法，反映多智能体系统中持续的适应、演化的交互以及多样化的贡献，从而为自我演化智能体提供更全面的评估度量。

9 结论

自进化智能体的出现标志着人工智能领域的一次范式转变，从静态、单一的模型迈向能够持续学习与适应的动态智能体系统。随着语言智能体越来越多地被部署在开放式、交互式环境中，进化能力——即根据新任务、知识和反馈调整推理过程、工具和行为——已成为构建下一代智能体系统的关键。本综述首次对自进化智能体进行了全面而系统的梳理，围绕三个基础性问题展开：智能体的哪些方面应当进化、进化应在何时发生、以及如何有效实现进化过程。此外，我们讨论了若干评估自进化智能体进展的方法，涵盖度量指标与基准测试，并介绍了相应的应用场景与未来方向。这些智能体的进化需要在模型、数据、算法和评估实践等方面取得重大进展。解决诸如灾难性遗忘、自主进化过程中的人类偏好对齐，以及智能体与环境的协同进化等问题，将是解锁不仅具有适应性而且值得信赖、与人类价值观一致的智能体的关键。我们希望本综述能为研究人员和实践者提供一个基础框架，用于设计、分析并推动自进化智能体的发展与进步。

参考文献

- Emre Can Acikgoz, Cheng Qian, Heng Ji, Dilek Hakkani-Tür, and Gokhan Tur. Self-improving llm agents at test-time. *arXiv preprint arXiv:2510.07841*, 2025.
- Saaket Agashe, Kyle Wong, Vincent Tu, Jiachen Yang, Ang Li, and Xin Eric Wang. Agent S2: A compositional generalist-specialist framework for computer use agents. *arXiv preprint arXiv:2504.00906*, 2025.
- Takuya Akiba, Makoto Shing, Yujin Tang, Qi Sun, and David Ha. Evolutionary optimization of model merging recipes. *Nature Machine Intelligence*, 7(2):195–204, 2025.
- Reem Aleithan, Haoran Xue, Mohammad Mahdi Mohajer, Elijah Nnorom, Gias Uddin, and Song Wang. Swe-bench+: Enhanced coding benchmark for llms. *arXiv preprint arXiv:2410.06992*, 2024.
- Mohammad Almansoori, Komal Kumar, and Hisham Cholakkal. Self-evolving multi-agent simulations for realistic clinical interactions. *arXiv preprint arXiv:2503.22678*, 2025a.
- Mohammad Almansoori, Komal Kumar, and Hisham Cholakkal. Self-evolving multi-agent simulations for realistic clinical interactions. *arXiv preprint arXiv:2503.22678*, 2025b.

- Shun-ichi Amari. Backpropagation and stochastic gradient descent method. *Neurocomputing*, 5(4-5):185–196, 1993.
- Maksym Andriushchenko, Alexandra Souly, Mateusz Dziemian, Derek Duenas, Maxwell Lin, Justin Wang, Dan Hendrycks, Andy Zou, Zico Kolter, Matt Fredrikson, et al. Agentharm: A benchmark for measuring harmfulness of llm agents. *arXiv preprint arXiv:2410.09024*, 2024.
- Usman Anwar, Abulhair Saparov, Javier Rando, Daniel Paleka, Miles Turpin, Peter Hase, Ekdeep Singh Lubana, Erik Jenner, Stephen Casper, Oliver Sourbut, et al. Foundational challenges in assuring alignment and safety of large language models. *arXiv preprint arXiv:2404.09932*, 2024.
- Leonhard Applis, Yuntong Zhang, Shanchao Liang, Nan Jiang, Lin Tan, and Abhik Roychoudhury. Unified software engineering agent as ai software engineer. *arXiv preprint arXiv:2506.14683*, 2025.
- Henrique Assumpção, Diego Ferreira, Leandro Campos, and Fabricio Murai. Codeevolve: An open source evolutionary coding agent for algorithm discovery and optimization. *arXiv preprint arXiv:2510.14150*, 2025.
- Ruhana Azam, Aditya Vempaty, and Ashish Jagmohan. Reflection-augmented planning (ReAP): Memory for web navigation agents. *arXiv preprint arXiv:2506.02158*, 2025.
- Yaniv Azaria and Moshe Sipper. Gp-gammon: Using genetic programming to evolve backgammon players. In Maarten Keijzer, Andrea Tettamanzi, Pierre Collet, Jano van Hemert, and Marco Tomassini (eds.), *Genetic Programming*, pp. 132–142, Berlin, Heidelberg, 2005. Springer Berlin Heidelberg. ISBN 978-3-540-31989-4.
- Eugene Bagdasarian, Ren Yi, Sahra Ghalebikesabi, Peter Kairouz, Marco Gruteser, Sewoong Oh, Borja Balle, and Daniel Ramage. Airgapagent: Protecting privacy-conscious conversational agents. In *Proceedings of the 2024 on ACM SIGSAC Conference on Computer and Communications Security*, pp. 3868–3882, 2024.
- Hao Bai, Yifei Zhou, Jiayi Pan, Mert Cemri, Alane Suhr, Sergey Levine, and Aviral Kumar. Digirl: Training in-the-wild device-control agents with autonomous reinforcement learning. *Advances in Neural Information Processing Systems*, 37:12461–12495, 2024.
- Debabrota Basu and Udvass Das. The fair game: Auditing & debiasing ai algorithms over time. In *Cambridge Forum on AI: Law and Governance*, volume 1, pp. e27. Cambridge University Press, 2025.
- James Bell, Luca Quarantiello, Ethan N Coleman, Ling Li, Meng Li, et al. The future of continual learning in the era of foundation models: Three key directions. *arXiv preprint arXiv:2506.03320*, 2025.
- Nikolas Belle, Dakota Barnes, Alfonso Amayuelas, Ivan Bercovich, Xin Eric Wang, and William Wang. Agents of change: Self-evolving llm agents for strategic planning. *arXiv preprint arXiv:2506.04651*, 2025.
- Yoshua Bengio, Jérôme Louradour, Ronan Collobert, and Jason Weston. Curriculum learning. In *Proceedings of the 26th annual international conference on machine learning*, pp. 41–48, 2009.
- Zhenni Bi, Kai Han, Chuanjian Liu, Yehui Tang, and Yunhe Wang. Forest-of-thought: Scaling test-time compute for enhancing llm reasoning. *arXiv preprint arXiv:2412.09078*, 2024.
- Areeb Bilal, Muhammad Abdul Mohsin, Muhammad Umer, Muhammad Arslan Khan Bangash, et al. Meta-thinking in llms via multi-agent reinforcement learning: A survey. *arXiv preprint arXiv:2504.14520*, 2025.
- Rogerio Bonatti, Dan Zhao, Francesco Bonacci, Dillon Dupont, Sara Abdali, Yinheng Li, Yadong Lu, Justin Wagle, Kazuhito Koishida, et al. Windows Agent Arena: Evaluating multi-modal OS agents at scale. *arXiv preprint arXiv:2409.08264*, 2024.
- Léon Bottou. Large-scale machine learning with stochastic gradient descent. In *Proceedings of COMPSTAT’2010: 19th International Conference on Computational Statistics Paris France, August 22-27, 2010 Keynote, Invited and Contributed Papers*, pp. 177–186. Springer, 2010.

- Stefan Braun, Daniel Neil, and Shih-Chii Liu. A curriculum learning method for improved noise robustness in automatic speech recognition. In *2017 25th European Signal Processing Conference (EUSIPCO)*, pp. 548–552. IEEE, 2017.
- Yuxuan Cai, Yipeng Hao, Jie Zhou, Hang Yan, Zhikai Lei, Rui Zhen, Zhenhua Han, Yutao Yang, Junsong Li, Qianjun Pan, et al. Building self-evolving agents via experience-driven lifelong learning: A framework and benchmark. *arXiv preprint arXiv:2508.19005*, 2025.
- David Castillo-Bolado, Joseph Davidson, Finlay Gray, and Marek Rosa. Beyond prompts: Dynamic conversational benchmarking of large language models. In *The Thirty-eight Conference on Neural Information Processing Systems Datasets and Benchmarks Track*, 2024. URL <https://openreview.net/forum?id=twF1D3C9Rt>.
- Jun Shern Chan, Neil Chowdhury, Oliver Jaffe, James Aung, Dane Sherburn, Evan Mays, Giulio Starace, Kevin Liu, Leon Maksin, Tejal Patwardhan, et al. Mle-bench: Evaluating machine learning agents on machine learning engineering. *arXiv preprint arXiv:2410.07095*, 2024.
- Chen Chen, Xinlong Hao, Weiwen Liu, Xu Huang, Xingshan Zeng, Shuai Yu, Dexun Li, Shuai Wang, Weinan Gan, Yuefeng Huang, et al. Acebench: Who wins the match point in tool usage? *arXiv preprint arXiv:2501.12851*, 2025a.
- Guoxin Chen, Minpeng Liao, Chengxi Li, and Kai Fan. Alphamath almost zero: process supervision without process. *arXiv preprint arXiv:2405.03553*, 2024a.
- Hardy Chen, Haoqin Tu, Fali Wang, Hui Liu, Xianfeng Tang, Xinya Du, Yuyin Zhou, and Cihang Xie. Sft or rl? an early investigation into training rl-like reasoning large vision-language models. *arXiv preprint arXiv:2504.11468*, 2025b.
- Howard Chen, Jiayi Geng, Adithya Bhaskar, Dan Friedman, and Danqi Chen. Continual memorization of factoids in language models. *arXiv preprint arXiv:2411.07175*, 2024b.
- Jiaqi Chen, Bang Zhang, Ruotian Ma, Peisong Wang, Xiaodan Liang, Zhaopeng Tu, Xiaolong Li, and Kwan-Yee K Wong. Spc: Evolving self-play critic via adversarial games for llm reasoning. *arXiv preprint arXiv:2504.19162*, 2025c.
- Kai Chen, Xinfeng Li, Tianpei Yang, Hwei Wang, Wei Dong, and Yang Gao. Mdteamgpt: A self-evolving llm-based multi-agent framework for multi-disciplinary team medical consultation. *arXiv preprint arXiv:2503.13856*, 2025d.
- Kai Chen, Ji Qi, Jing Huo, Pinzhuo Tian, Fanyu Meng, Xi Yang, and Yang Gao. A self-evolving framework for multi-agent medical consultation based on large language models. In *ICASSP 2025-2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pp. 1–5. IEEE, 2025e.
- Kaiyuan Chen, Yixin Ren, Yang Liu, Xiaobo Hu, Haotong Tian, Tianbao Xie, Fangfu Liu, Haoye Zhang, Hongzhang Liu, Yuan Gong, et al. xbench: Tracking agents productivity scaling with profession-aligned real-world evaluations. *arXiv preprint arXiv:2506.13651*, 2025f.
- Min Chen, Zhikun Zhang, Tianhao Wang, Michael Backes, Mathias Humbert, and Yang Zhang. When machine unlearning jeopardizes privacy. In *Proceedings of the 2021 ACM SIGSAC conference on computer and communications security*, pp. 896–911, 2021.
- Qizhou Chen, Taolin Zhang, Xiaofeng He, Dongyang Li, Chengyu Wang, Longtao Huang, and Hui Xue. Lifelong knowledge editing for llms with retrieval-augmented continuous prompt learning. *arXiv preprint arXiv:2405.03279*, 2024c.
- Simin Chen, Yiming Chen, Zexin Li, Yifan Jiang, Zhongwei Wan, Yixin He, Dezhi Ran, Tianle Gu, Haizhou Li, Tao Xie, et al. Recent advances in large language model benchmarks against data contamination: From static to dynamic evaluation. *arXiv preprint arXiv:2502.17521*, 2025g.

- Weize Chen, Jiarui Yuan, Chen Qian, Cheng Yang, Zhiyuan Liu, and Maosong Sun. Optima: Optimizing effectiveness and efficiency for llm-based multi-agent system. *arXiv preprint arXiv:2410.08115*, 2024d.
- Zehui Chen, Weihua Du, Wenwei Zhang, Kuikun Liu, Jiangning Liu, Miao Zheng, Jingming Zhuo, Songyang Zhang, Dahua Lin, Kai Chen, et al. T-eval: Evaluating the tool utilization capability of large language models step by step. *arXiv preprint arXiv:2312.14033*, 2023.
- Ziru Chen, Shijie Chen, Yuting Ning, Qianheng Zhang, Boshi Wang, Botao Yu, Yifei Li, Zeyi Liao, Chen Wei, Zitong Lu, et al. Scienceagentbench: Toward rigorous assessment of language agents for data-driven scientific discovery. *arXiv preprint arXiv:2410.05080*, 2024e.
- Zixiang Chen, Yihe Deng, Huizhuo Yuan, Kaixuan Ji, and Quanquan Gu. Self-play fine-tuning converts weak language models to strong language models. *arXiv preprint arXiv:2401.01335*, 2024f.
- Yi Cheng, Wenge Liu, Kaishuai Xu, Wenjun Hou, Yi Ouyang, Chak Tou Leong, Xian Wu, and Yefeng Zheng. Autopal: Autonomous adaptation to users for personal ai companionship. *arXiv preprint arXiv:2406.13960*, 2024.
- Prateek Chhikara, Dev Khant, Saket Aryan, Taranjeet Singh, and Deshraj Yadav. Mem0: Building production-ready ai agents with scalable long-term memory. *arXiv preprint arXiv:2504.19413*, 2025.
- François Chollet. On the measure of intelligence. *arXiv preprint arXiv:1911.01547*, 2019.
- Sanjiban Choudhury. Process reward models for llm agents: Practical framework and directions. *arXiv preprint arXiv:2502.10325*, 2025.
- Yufan Dang, Chen Qian, Xueheng Luo, Jingru Fan, Zihao Xie, Ruijie Shi, Weize Chen, Cheng Yang, Xiaoyin Che, Ye Tian, et al. Multi-agent collaboration via evolving orchestration. *arXiv preprint arXiv:2505.19591*, 2025.
- Xiang Deng, Yu Gu, Boyuan Zheng, Shijie Chen, Sam Stevens, Boshi Wang, Huan Sun, and Yu Su. Mind2web: Towards a generalist agent for the web. *Advances in Neural Information Processing Systems*, 36:28091–28114, 2023.
- Yihe Deng, Pan Lu, Fan Yin, Ziniu Hu, Sheng Shen, Quanquan Gu, James Y Zou, Kai-Wei Chang, and Wei Wang. Enhancing large vision language models with self-training on image comprehension. *Advances in Neural Information Processing Systems*, 37:131369–131397, 2024.
- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Bidirectional encoder representations from transformers. *arXiv preprint arXiv:1810.04805*, 15, 2018.
- Guanting Dong, Hongyi Yuan, Keming Lu, Chengpeng Li, Mingfeng Xue, Dayiheng Liu, Wei Wang, Zheng Yuan, Chang Zhou, and Jingren Zhou. How abilities in large language models are affected by supervised fine-tuning data composition. *arXiv preprint arXiv:2310.05492*, 2023.
- Qingxiu Dong, Lei Li, Damai Dai, Ce Zheng, Jingyuan Ma, Rui Li, Heming Xia, Jingjing Xu, Zhiyong Wu, Tianyu Liu, et al. A survey on in-context learning. *arXiv preprint arXiv:2301.00234*, 2022.
- Shihan Dou, Ming Zhang, Chenhao Huang, Jiayi Chen, Feng Chen, Shichun Liu, Yan Liu, Chenxiao Liu, Cheng Zhong, Zongzhang Zhang, Tao Gui, Chao Xin, Wei Chengzhi, Lin Yan, Qi Zhang, Yonghui Wu, and Xuanjing Huang. Evallearn: Quantifying the learning capability and efficiency of llms via sequential problem solving, 2025. URL <https://arxiv.org/abs/2506.02672>.
- Yaxin Du, Yuzhu Cai, Yifan Zhou, Cheng Wang, Yu Qian, Xianghe Pang, Qian Liu, Yue Hu, and Siheng Chen. Swe-dev: Evaluating and training autonomous feature-driven software development, 2025. URL <https://arxiv.org/abs/2505.16975>.
- Zhuoyun Du, Lujie Zheng, Renjun Hu, Yuyang Xu, Xiawei Li, Ying Sun, Wei Chen, Jian Wu, Hao lei Cai, and Hao hao Ying. Llms can simulate standardized patients via agent coevolution. *arXiv preprint arXiv:2412.11716*, 2024.

- Zhiyu Fan, Kirill Vasilevski, et al. Swe-effi: Re-evaluating software ai agent system effectiveness under resource constraints. *arXiv preprint arXiv:2509.09853*, 2025.
- Junfeng Fang, Houcheng Jiang, Kun Wang, Yunshan Ma, Jie Shi, Xiang Wang, Xiangnan He, and Tat-Seng Chua. Alphaedit: Null-space constrained model editing for language models. In *The Thirteenth International Conference on Learning Representations*, 2025a.
- Tianqing Fang, Hongming Zhang, Zhisong Zhang, Kaixin Ma, Wenhao Yu, Haitao Mi, and Dong Yu. Webevolver: Enhancing web agent self-improvement with coevolving world model. *arXiv preprint arXiv:2504.21024*, 2025b.
- Lang Feng, Zhenghai Xue, Tingcong Liu, and Bo An. Group-in-group policy optimization for llm agent training. *arXiv preprint arXiv:2505.10978*, 2025a.
- Lang Feng, Zhenghai Xue, Tingcong Liu, and Bo An. Group-in-group policy optimization for llm agent training, 2025b. URL <https://arxiv.org/abs/2505.10978>.
- Yichun Feng, Jiawei Wang, Lu Zhou, and Yixue Li. Doctoragent-rl: A multi-agent collaborative reinforcement learning system for multi-turn clinical dialogue. *arXiv preprint arXiv:2505.19630*, 2025c.
- Chrisantha Fernando, Dylan Banarse, Henryk Michalewski, Simon Osindero, and Tim Rocktäschel. Prompt-breeder: Self-referential self-improvement via prompt evolution. *arXiv preprint arXiv:2309.16797*, 2023.
- Yao Fu, Dong-Ki Kim, Jaekyeom Kim, Sungryull Sohn, Lajanugen Logeswaran, Kyunghoon Bae, and Honglak Lee. Autoguide: Automated generation and selection of state-aware guidelines for large language model agents. *arXiv e-prints*, pp. arXiv-2403, 2024.
- Hang Gao and Yongfeng Zhang. PTR: precision-driven tool recommendation for large language models. *CoRR*, abs/2411.09613, 2024.
- Hongcheng Gao, Yue Liu, Yufei He, Longxu Dou, Chao Du, Zhijie Deng, Bryan Hooi, Min Lin, and Tianyu Pang. Flowreasoner: Reinforcing query-level meta-agents. *arXiv preprint arXiv:2504.15257*, 2025.
- Jiaxuan Gao, Shusheng Xu, Wenjie Ye, Weilin Liu, Chuyi He, Wei Fu, Zhiyu Mei, Guangju Wang, and Yi Wu. On designing effective rl reward at training time for llm reasoning. *arXiv preprint arXiv:2410.15115*, 2024.
- Anthony Garuccio. A genetic programming approach to solving optimization problems on agent-based models. Master’s thesis, Duquesne University, 2016.
- Yingqiang Ge, Wenyue Hua, Kai Mei, Juntao Tan, Shuyuan Xu, Zelong Li, Yongfeng Zhang, et al. Openagi: When llm meets domain experts. *Advances in Neural Information Processing Systems*, 36:5539–5568, 2023.
- Jiahui Geng, Qing Li, Herbert Woisetschlaeger, Zongxiong Chen, Fengyu Cai, Yuxia Wang, Preslav Nakov, Hans-Arno Jacobsen, and Fakhri Karay. A comprehensive survey of machine unlearning techniques for large language models. *arXiv preprint arXiv:2503.01854*, 2025a.
- Jiayi Geng, Howard Chen, Dilip Arumugam, and Thomas L Griffiths. Are large language models reliable ai scientists? assessing reverse-engineering of black-box systems. *arXiv preprint arXiv:2505.17968*, 2025b.
- Gaurav Ghosal, Tatsunori Hashimoto, and Aditi Raghunathan. Understanding finetuning for factual knowledge extraction. *arXiv preprint arXiv:2406.14785*, 2024.
- Ryan Greenblatt, Buck Shlegeris, Kshitij Sachan, and Fabien Roger Sato. Alignment faking in large language models. *Anthropic Research*, December 2024. URL <https://www.anthropic.com/research/alignment-faking>.
- Xinyu Guan, Li Lyna Zhang, Yifei Liu, Ning Shang, Youran Sun, Yi Zhu, Fan Yang, and Mao Yang. rstar-math: Small llms can master math reasoning with self-evolved deep thinking. *arXiv preprint arXiv:2501.04519*, 2025.

- Zhenyu Guan, Xiangyu Kong, Fangwei Zhong, and Yizhou Wang. Richelieu: Self-evolving llm-based agents for ai diplomacy. *Advances in Neural Information Processing Systems*, 37:123471–123497, 2024.
- Dadi Guo, Tianyi Zhou, Dongrui Liu, Chen Qian, Qihan Ren, Shuai Shao, Zhiyuan Fan, Yi R. Fung, Kun Wang, Linfeng Zhang, and Jing Shao. Towards self-evolving benchmarks: Synthesizing agent trajectories via test-time exploration under validate-by-reproduce paradigm. *arXiv preprint arXiv:2510.00415*, 2025a.
- Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Ruoyu Zhang, Runxin Xu, Qihao Zhu, Shirong Ma, Peiyi Wang, Xiao Bi, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. *arXiv preprint arXiv:2501.12948*, 2025b.
- Sheng Guo, Weilin Huang, Haozhi Zhang, Chenfan Zhuang, Dengke Dong, Matthew R Scott, and Dinglong Huang. Curriculumnet: Weakly supervised learning from large-scale web images. In *Proceedings of the European conference on computer vision (ECCV)*, pp. 135–150, 2018.
- Dongyoon Hahm, Taywon Min, Woogyol Jin, and Kimin Lee. Unintended misalignment from agentic fine-tuning: Risks and mitigation. *arXiv preprint arXiv:2508.14031*, 2025.
- Siwei Han, Jiaqi Liu, Yaofeng Su, Wenbo Duan, Xinyuan Liu, Cihang Xie, Mohit Bansal, Mingyu Ding, Linjun Zhang, and Huaxiu Yao. Alignment tipping process: How self-evolution pushes llm agents off the rails. *arXiv preprint arXiv:2510.04860*, 2025.
- Mohd Ariful Haque, Justin Williams, Sunzida Siddique, Md. Hujaifa Islam, Hasmot Ali, Kishor Datta Gupta, and Roy George. Advanced tool learning and selection system (ATLASS): A closed-loop framework using LLM. *CoRR*, abs/2503.10071, 2025.
- Moritz Hardt and Yu Sun. Test-time training on nearest neighbors for large language models. *arXiv preprint arXiv:2305.18466*, 2023.
- Ami Hauptman and Moshe Sipper. Evolution of an efficient search algorithm for the mate-in-n problem in chess. In *European Conference on Genetic Programming*, pp. 78–89, 2007.
- Hongliang He, Wenlin Yao, Kaixin Ma, Wenhao Yu, Yong Dai, Hongming Zhang, Zhenzhong Lan, and Dong Yu. WebVoyager: Building an end-to-end web agent with large multimodal models. *arXiv preprint arXiv:2401.13919*, 2024.
- Yufei He, Ruoyu Li, Alex Chen, Yue Liu, Yulin Chen, Yuan Sui, Cheng Chen, Yi Zhu, Luca Luo, Frank Yang, and Bryan Hooi. Enabling self-improving agents to learn at test time with human-in-the-loop guidance. In Saloni Potdar, Lina Rojas-Barahona, and Sebastien Montella (eds.), *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing: Industry Track*, pp. 1625–1653, Suzhou (China), November 2025a. Association for Computational Linguistics. ISBN 979-8-89176-333-3. URL <https://aclanthology.org/2025.emnlp-industry.115/>.
- Yufei He, Juncheng Liu, Yue Liu, Yibo Li, Tri Cao, Zhiyuan Hu, Xinxing Xu, and Bryan Hooi. Evotest: Evolutionary test-time learning for self-improving agentic systems. *arXiv preprint arXiv:2510.13220*, 2025b.
- Erik Hemberg, Stephen Moskal, and Una-May O’Reilly. Evolving code with a large language model. *Genetic Programming and Evolvable Machines*, 25(2):21, 2024.
- John H. Holland. *Adaptation in natural and artificial systems*, 1976.
- Arian Hosseini, Xingdi Yuan, Nikolay Malkin, Aaron Courville, Alessandro Sordoni, and Rishabh Agarwal. V-star: Training verifiers for self-taught reasoners. *arXiv preprint arXiv:2402.06457*, 2024.
- Mengkang Hu, Yao Mu, Xinmiao Yu, Mingyu Ding, Shiguang Wu, Wenqi Shao, Qiguang Chen, Bin Wang, Yu Qiao, and Ping Luo. Tree-planner: Efficient close-loop task planning with large language models, 2024a. URL <https://arxiv.org/abs/2310.08582>.

- Mengkang Hu, Pu Zhao, Can Xu, Qingfeng Sun, Jianguang Lou, Qingwei Lin, Ping Luo, and Saravan Rajmohan. Agentgen: Enhancing planning abilities for large language model based agent via environment and task generation. *arXiv preprint arXiv:2408.00764*, 2024b.
- Shengran Hu, Cong Lu, and Jeff Clune. Automated design of agentic systems. *arXiv preprint arXiv:2408.08435*, 2024c.
- Yuanzhe Hu, Yu Wang, and Julian McAuley. Evaluating memory in llm agents via incremental multi-turn interactions. In *ICML 2025 Workshop on Long-Context Foundation Models*, 2025.
- Yue Hu, Yuzhu Cai, Yaxin Du, Xinyu Zhu, Xiangrui Liu, Zijie Yu, Yuchen Hou, Shuo Tang, and Siheng Chen. Self-evolving multi-agent collaboration networks for software development. *arXiv preprint arXiv:2410.16946*, 2024d.
- Wenyue Hua, Xianjun Yang, Mingyu Jin, Zelong Li, Wei Cheng, Ruixiang Tang, and Yongfeng Zhang. Trustagent: Towards safe and trustworthy llm-based agents through agent constitution. In *Trustworthy Multi-modal Foundation Models and AI Agents (TiFA)*, 2024.
- Baixiang Huang, Zhen Tan, Haoran Wang, Zijie Liu, Dawei Li, Ali Payani, Huan Liu, Tianlong Chen, and Kai Shu. Model editing as a double-edged sword: Steering agent ethical behavior toward beneficence or harm. *arXiv preprint arXiv:2506.20606*, 2025a.
- Chengsong Huang, Wenhao Yu, Xiaoyang Wang, Hongming Zhang, Zongxia Li, Ruosen Li, Jiabin Huang, Haitao Mi, and Dong Yu. R-zero: Self-evolving reasoning llm from zero data. *arXiv preprint arXiv:2508.05004*, 2025b.
- D Huang, JM Zhang, M Luck, Q Bu, Y Qing, and H Cui. Agentcoder: Multi-agent code generation with effective testing and self-optimization. *University of Hong Kong, King's College London, University of Sussex, Shanghai Jiao Tong University*, 2024.
- Jiabin Huang, Shixiang Shane Gu, Le Hou, Yuexin Wu, Xuezhi Wang, Hongkun Yu, and Jiawei Han. Large language models can self-improve. *arXiv preprint arXiv:2210.11610*, 2022.
- Jonas Hübner, Sascha Bongni, Ido Hakimi, and Andreas Krause. Efficiently learning at test-time: Active fine-tuning of llms. *arXiv preprint arXiv:2410.08020*, 2024.
- Dongwei Jiang, Alvin Zhang, Andrew Wang, Nicholas Andrews, and Daniel Khashabi. Feedback friction: Llm struggle to fully incorporate external feedback. *arXiv preprint arXiv:2506.11930*, 2025a.
- Lu Jiang, Deyu Meng, Teruko Mitamura, and Alexander G Hauptmann. Easy samples first: Self-paced reranking for zero-example multimedia search. In *Proceedings of the 22nd ACM international conference on Multimedia*, pp. 547–556, 2014.
- Yuhua Jiang, Yuwen Xiong, Yufeng Yuan, Chao Xin, Wenyuan Xu, Yu Yue, Qianchuan Zhao, and Lin Yan. PAG: Multi-turn reinforced llm self-correction with policy as generative verifier. *arXiv preprint arXiv:2506.10406*, 2025b.
- Carlos E Jimenez, John Yang, Alexander Wettig, Shunyu Yao, Kexin Pei, Ofir Press, and Karthik Narasimhan. Swe-bench: Can language models resolve real-world github issues? *arXiv preprint arXiv:2310.06770*, 2023.
- Carlos E Jimenez, John Yang, et al. Swe-bench: Can language models resolve real-world github issues? In *ICLR*, 2024.
- Ruofan Jin, Zaixi Zhang, Mengdi Wang, and Le Cong. Stella: Self-evolving LLM agent for biomedical research. *arXiv preprint arXiv:2507.02004*, 2025. URL <https://arxiv.org/abs/2507.02004>.
- Liqiang Jing, Zhehui Huang, Xiaoyang Wang, Wenlin Yao, Wenhao Yu, Kaixin Ma, Hongming Zhang, Xinya Du, and Dong Yu. Dsbench: How far are data science agents from becoming data science experts?, 2025. URL <https://arxiv.org/abs/2409.07703>.

- Leslie Pack Kaelbling, Michael L Littman, and Andrew W Moore. Reinforcement learning: A survey. *Journal of artificial intelligence research*, 4:237–285, 1996.
- Zhewei Kang, Xuandong Zhao, and Dawn Song. Scalable best-of-n selection for large language models via self-certainty, 2025. URL <https://arxiv.org/abs/2502.18581>.
- Zixuan Ke, Austin Xu, Yifei Ming, Xuan-Phi Nguyen, Caiming Xiong, and Shafiq Joty. Mas-zero: Designing multi-agent systems with zero supervision, 2025. URL <https://arxiv.org/abs/2505.14996>.
- Omar Khattab, Arnav Singhvi, Paridhi Maheshwari, Zhiyuan Zhang, Keshav Santhanam, Sri Vardhamanan, Saiful Haq, Ashutosh Sharma, Thomas T Joshi, Hanna Moazam, et al. Dspy: Compiling declarative language model calls into self-improving pipelines. *arXiv preprint arXiv:2310.03714*, 2023.
- Jiin Kim, Byeongjun Shin, Jinha Chung, and Minsoo Rhu. The cost of dynamic reasoning: Demystifying ai agents and test-time scaling from an ai infrastructure perspective. *arXiv preprint arXiv:2506.04301*, 2025.
- Louis Kirsch, James Harrison, Daniel Freeman, Jascha Sohl-Dickstein, and Jürgen Schmidhuber. Towards general-purpose in-context learning agents. Workshop on Distribution Shifts, 37th Conference on Neural Information ..., 2023.
- Woosung Koh, Wonbeen Oh, Jaemin Jang, MinHyung Lee, Hyeongjin Kim, Ah Yeon Kim, Joonkee Kim, Junghyun Lee, Taehyeon Kim, and Se-Young Yun. Adastar: Adaptive data sampling for training self-taught reasoners. *arXiv preprint arXiv:2505.16322*, 2025.
- Harsha Kokel, Michael Katz, Kavitha Srinivas, and Shirin Sohrabi. Acpbench: Reasoning about action, change, and planning. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 39, pp. 26559–26568, 2025.
- John R Koza. Human-competitive results produced by genetic programming. *Genetic programming and evolvable machines*, 11(3):251–284, 2010.
- Aviral Kumar, Rishabh Agarwal, Disha Shrivastava, Feryal Behbahani, Aleksandra Faust, et al. Training language models to self-correct via reinforcement learning. *arXiv preprint arXiv:2409.12917*, 2024.
- Invariant Labs. mcp-scan, 2025. URL <https://github.com/invariantlabs-ai/mcp-scan>.
- Hanyu Lai, Xiao Liu, Iat Long Iong, Shuntian Yao, Yuxuan Chen, Pengbo Shen, Hao Yu, Hanchen Zhang, Xiaohan Zhang, Yuxiao Dong, et al. Autowebglm: A large language model-based web navigating agent. In *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pp. 5295–5306, 2024.
- Michael Laskin, Luyu Wang, Junhyuk Oh, Emilio Parisotto, Stephen Spencer, Richie Steigerwald, DJ Strouse, Steven Hansen, Angelos Filos, Ethan Brooks, et al. In-context reinforcement learning with algorithm distillation. *arXiv preprint arXiv:2210.14215*, 2022.
- Jonathan Lee, Annie Xie, Aldo Pacchiano, Yash Chandak, Chelsea Finn, Ofir Nachum, and Emma Brunskill. Supervised pretraining can learn in-context reinforcement learning. *Advances in Neural Information Processing Systems*, 36:43057–43083, 2023.
- Ido Levy, Ben Wiesel, Sami Marreed, Alon Oved, Avi Yaeli, and Segev Shlomov. St-webagentbench: A benchmark for evaluating safety and trustworthiness in web agents. *arXiv preprint arXiv:2410.06703*, 2024.
- Hongxin Li, Jingfan Chen, Jingran Su, Yuntao Chen, Qing Li, and Zhaoxiang Zhang. AutoGUI: Scaling gui grounding with automatic functionality annotations from LLMs. *arXiv preprint arXiv:2502.01977*, 2025a.
- Junkai Li, Yunghwei Lai, Weitao Li, Jingyi Ren, Meng Zhang, Xinhui Kang, Siyu Wang, Peng Li, Ya-Qin Zhang, Weizhi Ma, and Yang Liu. Agent hospital: A simulacrum of hospital with evolvable medical agents. *arXiv preprint arXiv:2405.02957*, 2024a.

- Loka Li, Zhenhao Chen, Guangyi Chen, Yixuan Zhang, Yusheng Su, Eric Xing, and Kun Zhang. Confidence matters: Revisiting intrinsic self-correction capabilities of large language models. *arXiv preprint arXiv:2402.12563*, 2024b.
- Mengdi Li, Jiaye Lin, Xufeng Zhao, Wenhao Lu, Peilin Zhao, Stefan Wermter, and Di Wang. Curriculum-rlaif: Curriculum alignment with reinforcement learning from ai feedback. *arXiv preprint arXiv:2505.20075*, 2025b.
- Minghao Li, Yingxiu Zhao, Bowen Yu, Feifan Song, Hangyu Li, Haiyang Yu, Zhoujun Li, Fei Huang, and Yongbin Li. Api-bank: A comprehensive benchmark for tool-augmented llms. *arXiv preprint arXiv:2304.08244*, 2023.
- Nathaniel Li, Alexander Pan, Anjali Gopal, Summer Yue, Daniel Berrios, Alice Gatti, Justin D Li, Ann-Kathrin Dombrowski, Shashwat Goel, Long Phan, et al. The wmdp benchmark: Measuring and reducing malicious use with unlearning. *arXiv preprint arXiv:2403.03218*, 2024c.
- Ning Li, Xiangmou Qu, Jiamu Zhou, Jun Wang, Muning Wen, Kounianhua Du, Xingyu Lou, Qiuying Peng, Jun Wang, and Weinan Zhang. MobileUse: A gui agent with hierarchical reflection for autonomous mobile operation. *arXiv preprint arXiv:2507.16853*, 2025c.
- Xiaopeng Li, Pengyue Jia, Derong Xu, Yi Wen, Yingyi Zhang, Wenlin Zhang, Wanyu Wang, Yichao Wang, Zhaocheng Du, Xiangyang Li, et al. A survey of personalization: From rag to agent. *arXiv preprint arXiv:2504.10147*, 2025d.
- Yi-Chen Li, Tian Xu, Yang Yu, Xuqin Zhang, Xiong-Hui Chen, Zhongxiang Ling, Ningjing Chao, Lei Yuan, and Zhi-Hua Zhou. Generalist reward models: Found inside large language models. *arXiv preprint arXiv:2506.23235*, 2025e.
- Zelong Li, Shuyuan Xu, Kai Mei, Wenyue Hua, Balaji Rama, Om Raheja, Hao Wang, He Zhu, and Yongfeng Zhang. Autoflow: Automated workflow generation for large language model agents. *arXiv preprint arXiv:2407.12821*, 2024d.
- Xuechen Liang, Yangfan He, Yinghui Xia, Xinyuan Song, Jianhui Wang, Meiling Tao, Li Sun, Xinhang Yuan, Jiayi Su, Keqin Li, Siyuan Chen, and Tianyu Shi. Self-evolving agents with reflective and memory-augmented abilities. *arXiv preprint arXiv:2409.00872*, 2024.
- Junwei Liao, Muning Wen, Jun Wang, and Weinan Zhang. Marft: Multi-agent reinforcement fine-tuning, 2025. URL <https://arxiv.org/abs/2504.16129>.
- Hunter Lightman, Vineet Kosaraju, Yuri Burda, Harrison Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. Let’s verify step by step. In *The Twelfth International Conference on Learning Representations*, 2023.
- Bill Yuchen Lin, Yicheng Fu, Karina Yang, Faeze Brahman, Shiyu Huang, Chandra Bhagavatula, Prithviraj Ammanabrolu, Yejin Choi, and Xiang Ren. Swiftsage: A generative agent with fast and slow thinking for complex interactive tasks. *Advances in Neural Information Processing Systems*, 36:23813–23825, 2023.
- Chin-Yew Lin. Rouge: A package for automatic evaluation of summaries. In *Text summarization branches out*, pp. 74–81, 2004.
- Guanyu Lin, Tao Feng, Pengrui Han, Ge Liu, and Jiaxuan You. Arxiv copilot: A self-evolving and efficient LLM system for personalized academic assistance. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pp. 122–130, 2024. URL <https://arxiv.org/abs/2409.04593>. arXiv:2409.04593.
- Sam Lin, Wenyue Hua, Lingyao Li, Zhenting Wang, and Yongfeng Zhang. Ado: Automatic data optimization for inputs in llm prompts. *arXiv preprint arXiv:2502.11436*, 2025a.
- Zi Lin, Sheng Shen, Jingbo Shang, Jason Weston, and Yixin Nie. Learning to solve and verify: A self-play framework for code and test generation. *arXiv preprint arXiv:2502.14948*, 2025b.

- Bang Liu, Xinfeng Li, Jiayi Zhang, Jinlin Wang, Tanjin He, Sirui Hong, Hongzhang Liu, Shaokun Zhang, Kaitao Song, Kunlun Zhu, Yuheng Cheng, Suyuchen Wang, Xiaoqiang Wang, Yuyu Luo, Haibo Jin, Peiyan Zhang, Ollie Liu, Jiaqi Chen, Huan Zhang, Zhaoyang Yu, Haochen Shi, Boyan Li, Dekun Wu, Fengwei Teng, Xiaojun Jia, Jiawei Xu, Jinyu Xiang, Yizhang Lin, Tianming Liu, Tongliang Liu, Yu Su, Huan Sun, Glen Berseth, Jianyun Nie, Ian Foster, Logan Ward, Qingyun Wu, Yu Gu, Mingchen Zhuge, Xiangru Tang, Haohan Wang, Jiaxuan You, Chi Wang, Jian Pei, Qiang Yang, Xiaoliang Qi, and Chenglin Wu. Advances and challenges in foundation agents: From brain-inspired intelligence to evolutionary, collaborative, and safe systems, 2025a. URL <https://arxiv.org/abs/2504.01990>.
- Bang Liu, Xinfeng Li, Jiayi Zhang, Jinlin Wang, Tanjin He, Sirui Hong, Hongzhang Liu, Shaokun Zhang, Kaitao Song, Kunlun Zhu, et al. Advances and challenges in foundation agents: From brain-inspired intelligence to evolutionary, collaborative, and safe systems. *arXiv preprint arXiv:2504.01990*, 2025b.
- Ben Liu, Jihan Zhang, Fangquan Lin, Xu Jia, and Min Peng. One size doesn't fit all: A personalized conversational tutoring agent for mathematics instruction. *arXiv preprint arXiv:2502.12633*, 2025c. URL <https://arxiv.org/abs/2502.12633>.
- Bo Liu, Leon Guertler, Simon Yu, Zichen Liu, Penghui Qi, Daniel Balcells, Mickel Liu, Cheston Tan, Weiyan Shi, Min Lin, et al. Spiral: Self-play on zero-sum games incentivizes reasoning via multi-agent multi-turn reinforcement learning. *arXiv preprint arXiv:2506.24119*, 2025d.
- Dongrui Liu, Huiqi Deng, Xu Cheng, Qihan Ren, Kangrui Wang, and Quanshi Zhang. Towards the difficulty for a deep neural network to learn concepts of different complexities. *Advances in Neural Information Processing Systems*, 36:41283–41304, 2023a.
- Shaoteng Liu, Haoqi Yuan, Minda Hu, Yanwei Li, Yukang Chen, Shu Liu, Zongqing Lu, and Jiaya Jia. Rl-gpt: Integrating reinforcement learning and code-as-policy. *Advances in Neural Information Processing Systems*, 37:28430–28459, 2024.
- Xiao Liu, Hao Yu, Hanchen Zhang, Yifan Xu, Xuanyu Lei, Hanyu Lai, Yu Gu, Hangliang Ding, Kaiwen Men, Kejuan Yang, et al. Agentbench: Evaluating llms as agents. *arXiv preprint arXiv:2308.03688*, 2023b.
- Yuhang Liu, Pengxiang Li, Congkai Xie, Xavier Hu, Xiaotian Han, Shengyu Zhang, Hongxia Yang, and Fei Wu. Infigui-rl: Advancing multimodal gui agents from reactive actors to deliberative reasoners. *arXiv preprint arXiv:2504.14239*, 2025e.
- Yuxuan Liu, Hongda Sun, Wei Liu, Jian Luan, Bo Du, and Rui Yan. Mobilesteward: Integrating multiple app-oriented agents with self-evolution to automate cross-app instructions. *arXiv preprint arXiv:2502.16796*, 2025f.
- David Lopez-Paz and Marc'Aurelio Ranzato. Gradient episodic memory for continual learning. In *Advances in Neural Information Processing Systems*, volume 30, pp. 6467–6476, 2017.
- Reza Lotfian and Carlos Busso. Curriculum learning for speech emotion recognition from crowdsourced labels. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 27(4):815–826, 2019.
- Jianqiao Lu, Wanjun Zhong, Wenying Huang, Yufei Wang, Qi Zhu, Fei Mi, Baojun Wang, Weichao Wang, Xingshan Zeng, Lifeng Shang, Xin Jiang, and Qun Liu. SELF: Self-evolution with language feedback. *arXiv preprint arXiv:2310.00533*, 2023.
- Jiarui Lu, Thomas Holleis, Yizhe Zhang, Bernhard Aumayer, Feng Nan, Felix Bai, Shuang Ma, Shen Ma, Mengyu Li, Guoli Yin, et al. Toolsandbox: A stateful, conversational, interactive evaluation benchmark for llm tool use capabilities. *arXiv preprint arXiv:2408.04682*, 2024a.
- Junting Lu, Zhiyang Zhang, Fangkai Yang, Jue Zhang, Lu Wang, Chao Du, Qingwei Lin, Saravan Rajmohan, Dongmei Zhang, and Qi Zhang. Axis: Efficient human-agent-computer interaction with api-first llm-based agents. *arXiv preprint arXiv:2409.17140*, 2024b.

- Xiaoya Lu, Dongrui Liu, Yi Yu, Luxin Xu, and Jing Shao. X-boundary: Establishing exact safety boundary to shield llms from multi-turn jailbreaks without compromising usability. *arXiv preprint arXiv:2502.09990*, 2025.
- Junyu Luo, Weizhi Zhang, Ye Yuan, Yusheng Zhao, Junwei Yang, Yiyang Gu, Bohan Wu, Binqi Chen, Ziyue Qiao, Qingqing Long, Rongcheng Tu, Xiao Luo, Wei Ju, Zhiping Xiao, Yifan Wang, Meng Xiao, Chenwu Liu, Jingyang Yuan, Shichang Zhang, Yiqiao Jin, Fan Zhang, Xian Wu, Hanqing Zhao, Dacheng Tao, Philip S. Yu, and Ming Zhang. Large language model agent: A survey on methodology, applications and challenges, 2025a. URL <https://arxiv.org/abs/2503.21460>.
- Run Luo, Lu Wang, Wanwei He, and Xiaobo Xia. Gui-r1: A generalist r1-style vision-language action model for gui agents. *arXiv preprint arXiv:2504.10458*, 2025b.
- Aman Madaan, Niket Tandon, Prakhar Gupta, Skyler Hallinan, Luyu Gao, Sarah Wiegrefe, Uri Alon, Nouha Dziri, Shrimai Prabhumoye, Yiming Yang, Shashank Gupta, Bodhisattwa Prasad Majumder, Katherine Hermann, Sean Welleck, Amir Yazdanbakhsh, and Peter Clark. Self-Refine: Iterative refinement with self-feedback. In *Advances in Neural Information Processing Systems*, 2023a. URL <https://arxiv.org/abs/2303.17651>.
- Aman Madaan, Niket Tandon, Prakhar Gupta, Skyler Hallinan, Luyu Gao, Sarah Wiegrefe, Uri Alon, Nouha Dziri, Shrimai Prabhumoye, Yiming Yang, Shashank Gupta, Bodhisattwa Prasad Majumder, Katherine Hermann, Sean Welleck, Amir Yazdanbakhsh, and Peter Clark. Self-refine: Iterative refinement with self-feedback. In A. Oh, T. Naumann, A. Globerson, K. Saenko, M. Hardt, and S. Levine (eds.), *Advances in Neural Information Processing Systems*, volume 36, pp. 46534–46594. Curran Associates, Inc., 2023b.
- Michael McCloskey and Neal J Cohen. Catastrophic interference in connectionist networks: The sequential learning problem. In *Psychology of learning and motivation*, volume 24, pp. 109–165. Elsevier, 1989.
- Ethan Mendes and Alan Ritter. Language models can self-improve at state-value estimation for better search. *arXiv preprint arXiv:2503.02878*, 2025.
- Grégoire Mialon, Clémentine Fourrier, Thomas Wolf, Yann LeCun, and Thomas Scialom. Gaia: a benchmark for general ai assistants. In *The Twelfth International Conference on Learning Representations*, 2023.
- Sewon Min, Mike Lewis, Luke Zettlemoyer, and Hannaneh Hajishirzi. Metaicl: Learning to learn in context. *arXiv preprint arXiv:2110.15943*, 2021.
- Amir Moeini, Jiuqi Wang, Jacob Beck, Ethan Blaser, Shimon Whiteson, Rohan Chandra, and Shangdong Zhang. A survey of in-context reinforcement learning. *arXiv preprint arXiv:2502.07978*, 2025.
- Thanh Tam Nguyen, Thanh Trung Huynh, Zhao Ren, Phi Le Nguyen, Alan Wee-Chung Liew, Hongzhi Yin, and Quoc Viet Hung Nguyen. A survey of machine unlearning. *arXiv preprint arXiv:2209.02299*, 2022.
- Kolby Nottingham, Bodhisattwa Prasad Majumder, Bhavana Dalvi Mishra, Sameer Singh, Peter Clark, and Roy Fox. Skill set optimization: Reinforcing language model behavior via transferable skills. In *ICML*. OpenReview.net, 2024.
- Alexander Novikov, Ngân Vũ, Marvin Eisenberger, Emilien Dupont, Po-Sen Huang, Adam Zsolt Wagner, Sergey Shirobokov, Borislav Kozlovskii, Francisco JR Ruiz, Abbas Mehrabian, et al. Alphaevolve: A coding agent for scientific and algorithmic discovery. *arXiv preprint arXiv:2506.13131*, 2025.
- Openai. Introducing swe-bench verified, 2024. <https://openai.com/index/introducing-swe-bench-verified>.
- Siru Ouyang, Jun Yan, I-Hung Hsu, Yanfei Chen, Ke Jiang, Zifeng Wang, Rujun Han, Long T. Le, Samira Daruki, Xiangru Tang, Vishy Tirumalashetty, George Lee, Mahsan Rofouei, Hangfei Lin, Jiawei Han, Chen-Yu Lee, and Tomas Pfister. Reasoningbank: Scaling agent self-evolving with reasoning memory. *arXiv preprint arXiv:2509.25140*, 2025.

- Yichen Pan, Dehan Kong, Sida Zhou, Cheng Cui, Yifei Leng, Bing Jiang, Hangyu Liu, Yanyi Shang, Shuyan Zhou, Tongshuang Wu, et al. Webcanvas: Benchmarking web agents in online environments. *arXiv preprint arXiv:2406.12373*, 2024.
- Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. Bleu: a method for automatic evaluation of machine translation. In *Proceedings of the 40th annual meeting of the Association for Computational Linguistics*, pp. 311–318, 2002.
- Shubham Parashar, Shurui Gui, Xiner Li, Hongyi Ling, Sushil Vemuri, Blake Olson, Eric Li, Yu Zhang, James Caverlee, Dileep Kalathil, et al. Curriculum reinforcement learning from easy to hard tasks improves llm reasoning. *arXiv preprint arXiv:2506.06632*, 2025.
- German I Parisi, Ronald Kemker, Jose L Part, Christopher Kanan, and Stefan Wermter. Continual lifelong learning with neural networks: A review. *Neural networks*, 113:54–71, 2019.
- Joon Sung Park, Joseph O’Brien, Carrie Jun Cai, Meredith Ringel Morris, Percy Liang, and Michael S Bernstein. Generative agents: Interactive simulacra of human behavior. In *Proceedings of the 36th annual acm symposium on user interface software and technology*, pp. 1–22, 2023.
- Shishir G. Patil, Tianjun Zhang, Xin Wang, and Joseph E. Gonzalez. Gorilla: Large language model connected with massive apis. In *NeurIPS*, 2024.
- Joachim Winther Pedersen, Erwan Plantec, Eleni Nisioti, Marcello Barylli, Milton Montero, Kathrin Korte, and Sebastian Risi. Hypernetworks that evolve themselves. In *Artificial Life Conference Proceedings 37*, volume 2025, pp. 17. MIT Press One Rogers Street, Cambridge, MA 02142-1209, USA journals-info ..., 2025.
- Dengyun Peng, Yuhang Zhou, Qiguang Chen, Jinhao Liu, Jingjing Chen, and Libo Qin. Dlpo: Towards a robust, efficient, and generalizable prompt optimization framework from a deep-learning perspective. *arXiv preprint arXiv:2503.13413*, 2025.
- Emmanouil Antonios Platanios, Otilia Stretcu, Graham Neubig, Barnabas Poczos, and Tom M Mitchell. Competence-based curriculum learning for neural machine translation. *arXiv preprint arXiv:1903.09848*, 2019.
- Julien Pourcel, Cédric Colas, and Pierre-Yves Oudeyer. Self-improving language models for evolutionary program synthesis: A case study on arc-agi. *arXiv preprint arXiv:2507.14172*, 2025.
- Reid Pryzant, Dan Iter, Jerry Li, Yin Tat Lee, Chenguang Zhu, and Michael Zeng. Automatic prompt optimization with "gradient descent" and beam search. *arXiv preprint arXiv:2305.03495*, 2023.
- Yingming Pu, Tao Lin, and Hongyu Chen. Piflow: Principle-aware scientific discovery with multi-agent collaboration. *arXiv preprint arXiv:2505.15047*, 2025.
- Pranav Putta, Edmund Mills, Naman Garg, Sumeet Motwani, Chelsea Finn, Divyansh Garg, and Rafael Rafailov. Agent q: Advanced reasoning and learning for autonomous ai agents. *arXiv preprint arXiv:2408.07199*, 2024.
- Zehan Qi, Xiao Liu, Iat Long Iong, Hanyu Lai, Xueqiao Sun, Jiadai Sun, Xinyue Yang, Yu Yang, Shuntian Yao, Wei Xu, Jie Tang, and Yuxiao Dong. Webrl: Training llm web agents via self-evolving online curriculum reinforcement learning. *arXiv preprint arXiv:2411.02337*, 2024.
- Chen Qian, Yufan Dang, Jiahao Li, Wei Liu, Zihao Xie, Yifei Wang, Weize Chen, Cheng Yang, Xin Cong, Xiaoyin Che, et al. Experiential co-learning of software-developing agents. *arXiv preprint arXiv:2312.17025*, 2023a.
- Cheng Qian, Chi Han, Yi Fung, Yujia Qin, Zhiyuan Liu, and Heng Ji. CREATOR: Tool Creation for Disentangling Abstract and Concrete Reasoning of Large Language Models. In *The 2023 Conference on Empirical Methods in Natural Language Processing*, 2023b. URL <https://openreview.net/forum?id=aCHq10rQiH>.

- Cheng Qian, Shihao Liang, Yujia Qin, Yining Ye, Xin Cong, Yankai Lin, Yesai Wu, Zhiyuan Liu, and Maosong Sun. Investigate-consolidate-exploit: A general strategy for inter-task agent self-evolution. *arXiv preprint arXiv:2401.13996*, 2024a.
- Lang Qian, Peng Sun, Yilei Wang, Jiayue Jin, Azzedine Boukerche, and Liang Song. A new online evolutionary optimization method for driving agents. In *GLOBECOM 2024-2024 IEEE Global Communications Conference*, pp. 2244–2249. IEEE, 2024b.
- Yujia Qin, Shihao Liang, Yining Ye, Kunlun Zhu, Lan Yan, Yaxi Lu, Yankai Lin, Xin Cong, Xiangru Tang, Bill Qian, et al. Toolllm: Facilitating large language models to master 16000+ real-world apis. *arXiv preprint arXiv:2307.16789*, 2023.
- Jiahao Qiu, Xuan Qi, Hongru Wang, Xinzhe Juan, Yimin Wang, Zelin Zhao, Jiayi Geng, Jiacheng Guo, Peihang Li, Jingzhe Shi, Shilong Liu, and Mengdi Wang. Alita-g: Self-evolving generative agent for agent generation. *arXiv preprint arXiv:2510.23601*, 2025a.
- Jiahao Qiu, Xuan Qi, Tongcheng Zhang, Xinzhe Juan, Jiacheng Guo, Yifu Lu, Yimin Wang, Zixin Yao, Qihan Ren, Xun Jiang, Xing Zhou, Dongrui Liu, Ling Yang, Yue Wu, Kaixuan Huang, Shilong Liu, Hongru Wang, and Mengdi Wang. Alita: Generalist agent enabling scalable agentic reasoning with minimal predefinition and maximal self-evolution. *CoRR*, abs/2505.20286, 2025b.
- Changle Qu, Sunhao Dai, Xiaochi Wei, Hengyi Cai, Shuaiqiang Wang, Dawei Yin, Jun Xu, and Ji-Rong Wen. Towards completeness-oriented tool retrieval for large language models. In *CIKM*, pp. 1930–1940. ACM, 2024a.
- Changle Qu, Sunhao Dai, Xiaochi Wei, Hengyi Cai, Shuaiqiang Wang, Dawei Yin, Jun Xu, and Ji-Rong Wen. From exploration to mastery: Enabling llms to master tools via self-driven interactions. In *ICLR*. OpenReview.net, 2025.
- Yuxiao Qu, Tianjun Zhang, Naman Garg, and Aviral Kumar. Recursive introspection: Teaching language model agents how to self-improve. *Advances in Neural Information Processing Systems*, 37:55249–55285, 2024b.
- Rafael Rafailov, Archit Sharma, Eric Mitchell, Christopher D Manning, Stefano Ermon, and Chelsea Finn. Direct preference optimization: Your language model is secretly a reward model. *Advances in Neural Information Processing Systems*, 36:53728–53741, 2023.
- Kiran Ramnath, Kang Zhou, Sheng Guan, Soumya Smruti Mishra, Xuan Qi, Zhengyuan Shen, Shuai Wang, Sangmin Woo, Sullam Jeoung, Yawei Wang, et al. A systematic survey of automatic prompt optimization techniques. *arXiv preprint arXiv:2502.16923*, 2025.
- Roger Ratcliff. Connectionist models of recognition memory: constraints imposed by learning and forgetting functions. *Psychological review*, 97(2):285, 1990.
- Maxime Robeyns, Martin Szummer, and Laurence Aitchison. A self-improving coding agent. *arXiv preprint arXiv:2504.15228*, 2025a.
- Maxime Robeyns, Martin Szummer, and Laurence Aitchison. A self-improving coding agent, 2025b. URL <https://arxiv.org/abs/2504.15228>.
- David Rolnick, Arun Ahuja, Jonathan Schwarz, Timothy Lillicrap, and Gregory Wayne. Experience replay for continual learning. *Advances in neural information processing systems*, 32, 2019.
- Kai Ruan, Mowen Huang, Ji-Rong Wen, and Hao Sun. Benchmarking llms’ swarm intelligence. *arXiv preprint arXiv:2505.04364*, 2025.
- Rana Salama, Jason Cai, Michelle Yuan, Anna Currey, Monica Sunkara, Yi Zhang, and Yassine Benajiba. Meminsight: Autonomous memory augmentation for llm agents. *arXiv preprint arXiv:2503.21760*, 2025.

- Timo Schick, Jane Dwivedi-Yu, Roberto Dessì, Roberta Raileanu, Maria Lomeli, Eric Hambro, Luke Zettlemoyer, Nicola Cancedda, and Thomas Scialom. Toolformer: Language models can teach themselves to use tools. In *NeurIPS*, 2023.
- Sheikh Shafayat, Fahim Tajwar, Ruslan Salakhutdinov, Jeff Schneider, and Andrea Zanette. Can large reasoning models self-train?, 2025. URL <https://arxiv.org/abs/2505.21444>.
- Lianlei Shan, Shixian Luo, Zezhou Zhu, Yu Yuan, and Yong Wu. Cognitive memory in large language models. *arXiv preprint arXiv:2504.02441*, 2025.
- Yu Shang, Yu Li, Keyu Zhao, Likai Ma, Jiahe Liu, Fengli Xu, and Yong Li. Agentsquare: Automatic LLM agent search in modular design space. In *ICLR*. OpenReview.net, 2025.
- Shuai Shao, Qihan Ren, Chen Qian, Boyi Wei, Dadi Guo, Jingyi Yang, Xinhao Song, Linfeng Zhang, Weinan Zhang, Dongrui Liu, and Jing Shao. Your agent may misevolve: Emergent risks in self-evolving llm agents. *arXiv preprint arXiv:2509.26354*, 2025.
- Yijia Shao, Tianshi Li, Weiyan Shi, Yanchen Liu, and Diyi Yang. PrivacyLens: Evaluating privacy norm awareness of language models in action. *Advances in Neural Information Processing Systems*, 37:89373–89407, 2024a.
- Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, YK Li, Y Wu, et al. Deepseekmath: Pushing the limits of mathematical reasoning in open language models. *arXiv preprint arXiv:2402.03300*, 2024b.
- Ming Shen. Rethinking data selection for supervised fine-tuning. *arXiv preprint arXiv:2402.06094*, 2024.
- Haizhou Shi, Zihao Xu, Hengyi Wang, Weiyi Qin, Wenyan Wang, Yibin Wang, Zifeng Wang, Sayna Ebrahimi, and Hao Wang. Continual learning of large language models: A comprehensive survey. *ACM Computing Surveys*, 2024.
- Quan Shi, Carlos E Jimenez, Shunyu Yao, Nick Haber, Diyi Yang, and Karthik Narasimhan. When models know more than they can explain: Quantifying knowledge transfer in human-ai collaboration. *arXiv preprint arXiv:2506.05579*, 2025a.
- Yucheng Shi, Wenhao Yu, Zaitang Li, Yonglin Wang, Hongming Zhang, Ninghao Liu, Haitao Mi, and Dong Yu. Mobilegui-rl: Advancing mobile gui agent through reinforcement learning in online environment, 2025b. URL <https://arxiv.org/abs/2507.05720>.
- Zhengliang Shi, Yuhan Wang, Lingyong Yan, Pengjie Ren, Shuaiqiang Wang, Dawei Yin, and Zhaochun Ren. Retrieval models aren’t tool-savvy: Benchmarking tool retrieval for large language models. *CoRR*, abs/2503.01763, 2025c.
- Noah Shinn, Federico Cassano, Edward Berman, Ashwin Gopinath, Karthik Narasimhan, and Shunyu Yao. Reflexion: Language agents with verbal reinforcement learning. In *Advances in Neural Information Processing Systems*, 2023. URL <https://arxiv.org/abs/2303.11366>.
- David Silver, Thomas Hubert, Julian Schrittwieser, Ioannis Antonoglou, Matthew Lai, Arthur Guez, Marc Lanctot, Laurent Sifre, Dharshan Kumaran, Thore Graepel, et al. Mastering chess and shogi by self-play with a general reinforcement learning algorithm. *arXiv preprint arXiv:1712.01815*, 2017.
- Toby Simonds and Akira Yoshiyama. Ladder: Self-improving llms through recursive problem decomposition. *arXiv preprint arXiv:2503.00735*, 2025.
- Toby Simonds, Kevin Lopez, Akira Yoshiyama, and Dominique Garmier. Self rewarding self improving, 2025. URL <https://arxiv.org/abs/2505.08827>.
- Karl Sims. Evolving virtual creatures. In *Proceedings of the 21st Annual Conference on Computer Graphics and Interactive Techniques*, SIGGRAPH ’94, pp. 15–22, New York, NY, USA, 1994. Association for Computing Machinery. ISBN 0897916670. doi: 10.1145/192161.192167. URL <https://doi.org/10.1145/192161.192167>.

- Charlie Snell, Jaehoon Lee, Kelvin Xu, and Aviral Kumar. Scaling llm test-time compute optimally can be more effective than scaling model parameters. *arXiv preprint arXiv:2408.03314*, 2024.
- Kefan Song, Amir Moeini, Peng Wang, Lei Gong, Rohan Chandra, Yanjun Qi, and Shangdong Zhang. Reward is enough: Llms are in-context reinforcement learners. *arXiv preprint arXiv:2506.06303*, 2025.
- Kenneth O Stanley and Risto Miikkulainen. Evolving neural networks through augmenting topologies. *Evolutionary computation*, 10(2):99–127, 2002.
- Dimitri Staufer. What should llms forget? quantifying personal data in llms for right-to-be-forgotten requests. *arXiv preprint arXiv:2507.11128*, 2025.
- Katharina Stein, Daniel Fišer, Jörg Hoffmann, and Alexander Koller. Automating the generation of prompts for llm-based action choice in pddl planning. In *Proceedings of the Fourteenth International Conference on Automated Planning and Scheduling (ICAPS 2025)*. AAAI Press, 2025.
- Hongjin Su, Ruoxi Sun, Jinsung Yoon, Pengcheng Yin, Tao Yu, and Sercan Ö. Arik. Learn-by-interact: A data-centric framework for self-adaptive agents in realistic environments, 2025. URL <https://arxiv.org/abs/2501.10893>.
- Chuanneng Sun, Songjun Huang, and Dario Pompili. Llm-based multi-agent reinforcement learning: Current and future directions. *arXiv preprint arXiv:2405.11106*, 2024a.
- Haochen Sun, Shuwen Zhang, Lujie Niu, Lei Ren, Hao Xu, Hao Fu, Fangkun Zhao, Caixia Yuan, and Xiaojie Wang. Collab-overcooked: Benchmarking and evaluating large language models as collaborative agents. *arXiv preprint arXiv:2502.20073*, 2025a.
- Haotian Sun, Yuchen Zhuang, Ling kai Kong, Bo Dai, and Chao Zhang. AdaPlanner: Adaptive planning from feedback with language models. In *Advances in Neural Information Processing Systems*, 2023. URL <https://openreview.net/forum?id=rnKgbKmelt>.
- Qiushi Sun, Kanzhi Cheng, Zichen Ding, Chuanyang Jin, Yian Wang, Fangzhi Xu, Zhenyu Wu, Chengyou Jia, Liheng Chen, Zhoumianze Liu, et al. Os-genesis: Automating gui agent trajectory construction via reverse task synthesis. *arXiv preprint arXiv:2412.19723*, 2024b.
- Qiushi Sun, Mukai Li, Zhoumianze Liu, Zhihui Xie, Fangzhi Xu, Zhangyue Yin, Kanzhi Cheng, Zehao Li, Zichen Ding, Qi Liu, et al. Os-sentinel: Towards safety-enhanced mobile gui agents via hybrid validation in realistic workflows. *arXiv preprint arXiv:2510.24411*, 2025b.
- Zeyi Sun, Ziyu Liu, Yuhang Zang, Yuhang Cao, Xiaoyi Dong, Tong Wu, Dahua Lin, and Jiaqi Wang. Seagent: Self-evolving computer use agent with autonomous learning from experience. *arXiv preprint arXiv:2508.04700*, 2025c.
- Heng Tang, Feng Liu, Xinbo Chen, Jiawei Chen, Bohao Wang, Changwang Zhang, Jun Wang, Yuegang Sun, Bingde Hu, and Can Wang. Bridging the gap: Self-optimized fine-tuning for llm-based recommender systems. *arXiv preprint arXiv:2505.20771*, 2025.
- Qiaoyu Tang, Ziliang Deng, Hongyu Lin, Xianpei Han, Qiao Liang, Boxi Cao, and Le Sun. Toolalpaca: Generalized tool learning for language models with 3000 simulated cases. *arXiv preprint arXiv:2306.05301*, 2023.
- Zhengwei Tao, Ting-En Lin, Xiancai Chen, Hangyu Li, Yuchuan Wu, Yongbin Li, Zhi Jin, Fei Huang, Dacheng Tao, and Jingren Zhou. A survey on self-evolution of large language models. *arXiv preprint arXiv:2404.14387*, 2024.
- Amir Taubenfeld, Tom Sheffer, Eran Ofek, Amir Feder, Ariel Goldstein, Zorik Gekhman, and Gal Yona. Confidence improves self-consistency in llms. *arXiv preprint arXiv:2502.06233*, 2025.

- Yi Tay, Shuohang Wang, Luu Anh Tuan, Jie Fu, Minh C Phan, Xingdi Yuan, Jinfeng Rao, Siu Cheung Hui, and Aston Zhang. Simple and effective curriculum pointer-generator networks for reading comprehension over long narratives. *arXiv preprint arXiv:1905.10847*, 2019.
- Patara Trirat, Wonyong Jeong, and Sung Ju Hwang. Agentic predictor: Performance prediction for agentic workflows via multi-view encoding. *arXiv preprint arXiv:2505.19764*, 2025.
- Keyon Vafa, Peter G Chang, Ashesh Rambachan, and Sendhil Mullainathan. What has a foundation model found? using inductive bias to probe for world models. *arXiv preprint arXiv:2507.06952*, 2025.
- Karthik Valmeekam, Matthew Marquez, Alberto Olmo, Sarath Sreedharan, and Subbarao Kambhampati. Planbench: An extensible benchmark for evaluating large language models on planning and reasoning about change. *Advances in Neural Information Processing Systems*, 36:38975–38987, 2023.
- Luanbo Wan and Weizhi Ma. Storybench: A dynamic benchmark for evaluating long-term memory with multi turns. *arXiv preprint arXiv:2506.13356*, 2025.
- Ziyu Wan, Yunxiang Li, Xiaoyu Wen, Yan Song, Hanjing Wang, Linyi Yang, Mark Schmidt, Jun Wang, Weinan Zhang, Shuyue Hu, and Ying Wen. Rema: Learning to meta-think for llms with multi-agent reinforcement learning, 2025. URL <https://arxiv.org/abs/2503.09501>.
- Bin Wang, Zexin Liu, Hao Yu, Ao Yang, Yenan Huang, Jing Guo, Huangsheng Cheng, Hui Li, and Huiyu Wu. Mcpguard: Automatically detecting vulnerabilities in mcp servers. *arXiv preprint arXiv:2510.23673*, 2025a.
- Bo Wang, Weiyi He, Pengfei He, Shenglai Zeng, Zhen Xiang, Yue Xing, and Jiliang Tang. Unveiling privacy risks in llm agent memory. *arXiv preprint arXiv:2502.13172*, 2025b.
- Borui Wang, Kathleen McKeown, and Rex Ying. Dystil: Dynamic strategy induction with large language models for reinforcement learning, 2025c. URL <https://arxiv.org/abs/2505.03209>.
- Guanzhi Wang, Yuqi Xie, Yunfan Jiang, Ajay Mandlekar, Chaowei Xiao, Yuke Zhu, Linxi Fan, and Anima Anandkumar. Voyager: An open-ended embodied agent with large language models. *arXiv preprint arXiv:2305.16291*, 2023a.
- Hanlin Wang, Chak Tou Leong, Jiashuo Wang, Jian Wang, and Wenjie Li. Spa-rl: Reinforcing llm agents via stepwise progress attribution. *arXiv preprint arXiv:2505.20732*, 2025d.
- Haoyu Wang, Dong Fang, et al. Fela: A multi-agent evolutionary system for feature engineering of industrial event log data. *arXiv preprint arXiv:2510.25223*, 2025e.
- Hongru Wang, Yujia Qin, Yankai Lin, Jeff Z. Pan, and Kam-Fai Wong. Empowering large language models: Tool learning for real-world interaction. In *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval*, SIGIR '24, pp. 2983–2986, New York, NY, USA, 2024a. Association for Computing Machinery. ISBN 9798400704314. doi: 10.1145/3626772.3661381. URL <https://doi.org/10.1145/3626772.3661381>.
- Hongru Wang, Rui Wang, Boyang Xue, Heming Xia, Jingtao Cao, Zeming Liu, Jeff Z. Pan, and Kam-Fai Wong. AppBench: Planning of multiple APIs from various APPs for complex user instruction. In Yaser Al-Onaizan, Mohit Bansal, and Yun-Nung Chen (eds.), *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, pp. 15322–15336, Miami, Florida, USA, November 2024b. Association for Computational Linguistics. doi: 10.18653/v1/2024.emnlp-main.856. URL <https://aclanthology.org/2024.emnlp-main.856/>.
- Hongru Wang, Deng Cai, Wanjuan Zhong, Shijue Huang, Jeff Z. Pan, Zeming Liu, and Kam-Fai Wong. Self-reasoning language models: Unfold hidden reasoning chains with few reasoning catalyst, 2025f. URL <https://arxiv.org/abs/2505.14116>.

- Hongru Wang, Cheng Qian, Manling Li, Jiahao Qiu, Boyang Xue, Mengdi Wang, Heng Ji, and Kam-Fai Wong. Toward a theory of agents as tool-use decision-makers, 2025g. URL <https://arxiv.org/abs/2506.00886>.
- Hongru Wang, Cheng Qian, Jiahao Qiu, et al. OTC-PO: Optimal tool calls via reinforcement learning. *arXiv preprint arXiv:2504.14870*, 2025h.
- Kun Wang, Guibin Zhang, Zhenhong Zhou, Jiahao Wu, Miao Yu, Shiqian Zhao, Chenlong Yin, Jinhu Fu, Yibo Yan, Hanjun Luo, et al. A comprehensive survey in llm (-agent) full stack safety: Data, training and deployment. *arXiv preprint arXiv:2504.15585*, 2025i.
- Liyuan Wang, Xingxing Zhang, Hang Su, and Jun Zhu. A comprehensive survey of continual learning: Theory, method and application. *IEEE transactions on pattern analysis and machine intelligence*, 46(8): 5362–5383, 2024c.
- Peiyi Wang, Lei Li, Zhihong Shao, RX Xu, Damai Dai, Yifei Li, Deli Chen, Yu Wu, and Zhifang Sui. Math-shepherd: Verify and reinforce llms step-by-step without human annotations. *arXiv preprint arXiv:2312.08935*, 2023b.
- Peng Wang, Ruihan Tao, Qiguang Chen, Mengkang Hu, and Libo Qin. X-webagentbench: A multilingual interactive web benchmark for evaluating global agentic system. *arXiv preprint arXiv:2505.15372*, 2025j.
- Renxi Wang, Xudong Han, Lei Ji, Shu Wang, Timothy Baldwin, and Haonan Li. Toolgen: Unified tool retrieval and calling via generation. In *ICLR*. OpenReview.net, 2025k.
- Rui Wang, Ce Zhang, Jun-Yu Ma, Jianshu Zhang, Hongru Wang, Yi Chen, Boyang Xue, Tianqing Fang, Zhisong Zhang, Hongming Zhang, Haitao Mi, Dong Yu, and Kam-Fai Wong. Explore to evolve: Scaling evolved aggregation logic via proactive online exploration for deep research agents. *arXiv preprint arXiv:2510.14438*, 2025l.
- Saizhuo Wang, Hang Yuan, Lionel M Ni, and Jian Guo. Quantagent: Seeking holy grail in trading by self-improving large language model. *arXiv preprint arXiv:2402.03755*, 2024d.
- Shaobo Wang, Zhengbo Jiao, Zifan Zhang, Yilang Peng, Xu Ze, Boyu Yang, Wei Wang, Hu Wei, and Linfeng Zhang. Socratic-zero: Bootstrapping reasoning via data-free agent co-evolution. *arXiv preprint arXiv:2509.24726*, 2025m.
- Siyuan Wang, Zhuohan Long, Zhihao Fan, Zhongyu Wei, and Xuanjing Huang. Benchmark self-evolving: A multi-agent framework for dynamic llm evaluation. *arXiv preprint arXiv:2402.11443*, 2024e.
- Song Wang, Yaochen Zhu, Haochen Liu, Zaiyi Zheng, Chen Chen, and Jundong Li. Knowledge editing for large language models: A survey. *ACM Computing Surveys*, 57(3):1–37, 2024f.
- Taiyi Wang, Zhihao Wu, Jianheng Liu, Jianye Hao, Jun Wang, and Kun Shao. Distrl: An asynchronous distributed reinforcement learning framework for on-device control agents. *arXiv preprint arXiv:2410.14803*, 2024g.
- Tevin Wang and Chenyan Xiong. Autorule: Reasoning chain-of-thought extracted rule-based rewards improve preference learning. *arXiv preprint arXiv:2506.15651*, 2025.
- Xiao Wang, Yuansen Zhang, Tianze Chen, Songyang Gao, Senjie Jin, Xianjun Yang, Zhiheng Xi, Rui Zheng, Yicheng Zou, Tao Gui, et al. Trace: A comprehensive benchmark for continual learning in large language models. *arXiv preprint arXiv:2310.06762*, 2023c.
- Xin Wang, Yudong Chen, and Wenwu Zhu. A survey on curriculum learning. *IEEE transactions on pattern analysis and machine intelligence*, 44(9):4555–4576, 2021.
- Xinyuan Wang, Chenxi Li, Zhen Wang, Fan Bai, Haotian Luo, Jiayou Zhang, Nebojsa Jojic, Eric P Xing, and Zhiting Hu. Promptagent: Strategic planning with language models enables expert-level prompt optimization. *arXiv preprint arXiv:2310.16427*, 2023d.

- Yinjie Wang, Ling Yang, Guohao Li, Mengdi Wang, and Bryon Aragam. Scoreflow: Mastering LLM agent workflows via score-based preference optimization. *arXiv preprint arXiv:2502.04306*, 2025n.
- Yizhong Wang, Yeganeh Kordi, Swaroop Mishra, Alisa Liu, Noah A Smith, Daniel Khashabi, and Hananeh Hajishirzi. Self-instruct: Aligning language models with self-generated instructions. *arXiv preprint arXiv:2212.10560*, 2022.
- Yue Wang, Tianfan Fu, Yinlong Xu, Zihan Ma, Hongxia Xu, Bang Du, Yingzhou Lu, Honghao Gao, Jian Wu, and Jintai Chen. Twin-gpt: digital twins for clinical trials via large language model. *ACM Transactions on Multimedia Computing, Communications and Applications*, 2024h.
- Zhenhailong Wang, Haiyang Xu, Junyang Wang, Xi Zhang, Ming Yan, Ji Zhang, Fei Huang, and Heng Ji. Mobile-agent-e: Self-evolving mobile assistant for complex tasks. *arXiv preprint arXiv:2501.11733*, 2025o.
- Zhenting Wang, Guofeng Cui, Kun Wan, and Wentian Zhao. Dump: Automated distribution-level curriculum learning for rl-based llm post-training. *arXiv preprint arXiv:2504.09710*, 2025p.
- Zihan Wang, Kangrui Wang, Qineng Wang, Pingyue Zhang, Linjie Li, Zhengyuan Yang, Xing Jin, Kefan Yu, Minh Nhat Nguyen, Licheng Liu, Eli Gottlieb, Yiping Lu, Kyunghyun Cho, Jiajun Wu, Li Fei-Fei, Lijuan Wang, Yejin Choi, and Manling Li. Ragen: Understanding self-evolution in llm agents via multi-turn reinforcement learning. *arXiv preprint arXiv:2504.20073*, 2025q.
- Ziqi Wang, Le Hou, Tianjian Lu, Yuexin Wu, Yunxuan Li, Hongkun Yu, and Heng Ji. Enabling lanuguage models to implicitly learn self-improvement. In *The Twelfth International Conference on Learning Representations*, 2024i. URL <https://openreview.net/forum?id=2tVHNRZuCs>.
- Zora Zhiruo Wang, Jiayuan Mao, Daniel Fried, and Graham Neubig. Agent workflow memory. *arXiv preprint arXiv:2409.07429*, 2024j.
- Boyi Wei, Benedikt Stroebel, Jiachen Xu, Joie Zhang, Zhou Li, and Peter Henderson. Dynamic risk assessments for offensive cybersecurity agents. *arXiv preprint arXiv:2505.18384*, 2025a.
- Jason Wei, Zhiqing Sun, Spencer Papay, Scott McKinney, Jeffrey Han, Isa Fulford, Hyung Won Chung, Alex Tachard Passos, William Fedus, and Amelia Glaese. Browsecomp: A simple yet challenging benchmark for browsing agents. *arXiv preprint arXiv:2504.12516*, 2025b.
- Lai Wei, Yuting Li, Chen Wang, Yue Wang, Linghe Kong, Weiran Huang, and Lichao Sun. Unsupervised post-training for multi-modal llm reasoning via grpo, 2025c. URL <https://arxiv.org/abs/2505.22453>.
- Qianshan Wei, Tengchao Yang, Yaochen Wang, Xinfeng Li, Lijun Li, Zhenfei Yin, Yi Zhan, Thorsten Holz, Zhiqiang Lin, and XiaoFeng Wang. A-memguard: A proactive defense framework for llm-based agent memory. *arXiv preprint arXiv:2510.02373*, 2025d.
- Colin White, Samuel Dooley, Manley Roberts, Arka Pal, Ben Feuer, Siddhartha Jain, Ravid Shwartz-Ziv, Neel Jain, Khalid Saifullah, Sreemanti Dey, et al. Livebench: A challenging, contamination-limited llm benchmark. *arXiv preprint arXiv:2406.19314*, 2024.
- Noam Wies, Yoav Levine, and Amnon Shashua. The learnability of in-context learning. *Advances in Neural Information Processing Systems*, 36:36637–36651, 2023.
- Jialong Wu, Wenbiao Yin, Yong Jiang, Zhenglin Wang, Zekun Xi, Runnan Fang, Linhai Zhang, Yulan He, Deyu Zhou, Pengjun Xie, et al. Webwalker: Benchmarking llms in web traversal. *arXiv preprint arXiv:2501.07572*, 2025.
- Mengsong Wu, Tong Zhu, Han Han, Chuanyuan Tan, Xiang Zhang, and Wenliang Chen. Seal-tools: Self-instruct tool learning dataset for agent tuning and detailed benchmark. In *CCF International Conference on Natural Language Processing and Chinese Computing*, pp. 372–384. Springer, 2024.

- Zhiheng Xi, Dingwen Yang, Jixuan Huang, Jiafu Tang, Guanyu Li, Yiwen Ding, Wei He, Boyang Hong, Shihan Do, Wenyu Zhan, et al. Enhancing llm reasoning via critique models with test-time and training-time supervision. *arXiv preprint arXiv:2411.16579*, 2024.
- Chunqiu Steven Xia, Zhe Wang, Yan Yang, Yuxiang Wei, and Lingming Zhang. Live-swe-agent: Can software engineering agents self-evolve on the fly? *arXiv preprint arXiv:2511.13646*, 2025a.
- Peng Xia, Kaide Zeng, Jiaqi Liu, Can Qin, Fang Wu, Yiyang Zhou, Caiming Xiong, and Huaxiu Yao. Agent0: Unleashing self-evolving agents from zero data via tool-integrated reasoning. *arXiv preprint arXiv:2511.16043*, 2025b.
- Jinyu Xiang, Jiayi Zhang, Zhaoyang Yu, Fengwei Teng, Jinhao Tu, Xinbing Liang, Sirui Hong, Chenglin Wu, and Yuyu Luo. Self-supervised prompt optimization. *arXiv preprint arXiv:2502.06855*, 2025.
- Han Xiao, Guozhi Wang, Yuxiang Chai, Zimu Lu, Weifeng Lin, Hao He, Lue Fan, Liuyang Bian, Rui Hu, Liang Liu, et al. Ui-genie: A self-improving approach for iteratively boosting mllm-based mobile gui agents. *arXiv preprint arXiv:2505.21496*, 2025a.
- Yijia Xiao, Edward Sun, Di Luo, and Wei Wang. Tradingagents: Multi-agents llm financial trading framework. *arXiv preprint arXiv:2412.20138*, 2024.
- Yunzhong Xiao, Yangmin Li, Hewei Wang, Yunlong Tang, and Zora Zhiruo Wang. Toolmem: Enhancing multimodal agents with learnable tool capability memory. *arXiv preprint arXiv:2510.06664*, 2025b.
- Tianbao Xie, Danyang Zhang, Jixuan Chen, Xiaochuan Li, Siheng Zhao, Ruisheng Cao, Toh J Hua, Zhoujun Cheng, Dongchan Shin, Fangyu Lei, et al. Osworld: Benchmarking multimodal agents for open-ended tasks in real computer environments. *Advances in Neural Information Processing Systems*, 37:52040–52094, 2024.
- Wenpeng Xing, Zhonghao Qi, Yupeng Qin, Yilin Li, Caini Chang, Jiahui Yu, Changting Lin, Zhenzhen Xie, and Meng Han. Mcp-guard: A defense framework for model context protocol integrity in large language model applications. *arXiv preprint arXiv:2508.10991*, 2025.
- Can Xu, Qingfeng Sun, Kai Zheng, Xiubo Geng, Pu Zhao, Jiazhan Feng, Chongyang Tao, Qingwei Lin, and Daxin Jiang. Wizardlm: Empowering large pre-trained language models to follow complex instructions. In *The Twelfth International Conference on Learning Representations*, 2024a.
- Frank F Xu, Yufan Song, Boxuan Li, Yuxuan Tang, Kritanjali Jain, Mengxue Bao, Zora Z Wang, Xuhui Zhou, Zhitong Guo, Murong Cao, et al. Theagentcompany: benchmarking llm agents on consequential real world tasks. *arXiv preprint arXiv:2412.14161*, 2024b.
- Wujiang Xu, Kai Mei, Hang Gao, Juntao Tan, Zujie Liang, and Yongfeng Zhang. A-mem: Agentic memory for llm agents. *arXiv preprint arXiv:2502.12110*, 2025a.
- Zicheng Xu, Guanchu Wang, Guangyao Zheng, Yu-Neng Chuang, Alexander Szalay, Xia Hu, and Vladimir Braverman. Self-ensemble: Mitigating confidence distortion for large language models, 2025b. URL <https://arxiv.org/abs/2506.01951>.
- Cilin Yan, Jingyun Wang, Lin Zhang, Ruihui Zhao, Xiaopu Wu, Kai Xiong, Qingsong Liu, Guoliang Kang, and Yangyang Kang. Efficient and accurate prompt optimization: the benefit of memory in exemplar-guided reflection. *arXiv preprint arXiv:2411.07446*, 2024.
- Sikuan Yan, Xiufeng Yang, Zuchao Huang, Ercong Nie, Zifeng Ding, Zonggen Li, Xiaowen Ma, Kristian Kersting, Jeff Z. Pan, Hinrich Schütze, Volker Tresp, and Yunpu Ma. Memory-r1: Enhancing large language model agents to manage and utilize memories via reinforcement learning. *arXiv preprint arXiv:2508.19828*, 2025.
- Cheng Yang, Xuemeng Yang, Licheng Wen, Daocheng Fu, Jianbiao Mei, Rong Wu, Pinlong Cai, Yufan Shen, Nianchen Deng, Botian Shi, Yu Qiao, and Haifeng Li. Learning on the job: An experience-driven self-evolving agent for long-horizon tasks. *arXiv preprint arXiv:2510.08002*, 2025a.

- Chengrun Yang, Xuezhi Wang, Yifeng Lu, Hanxiao Liu, Quoc V Le, Denny Zhou, and Xinyun Chen. Large language models as optimizers. *arXiv preprint arXiv:2309.03409*, 2023.
- John Yang, Carlos E Jimenez, Alex L Zhang, Kilian Lieret, Joyce Yang, Xindi Wu, Ori Press, Niklas Muennighoff, Gabriel Synnaeve, Karthik R Narasimhan, et al. Swe-bench multimodal: Do ai systems generalize to visual software domains? *arXiv preprint arXiv:2410.03859*, 2024.
- Kaiqi Yang, Hang Li, Yucheng Chu, Ahreum Han, Yasemin Copur-Gencturk, Jiliang Tang, and Hui Liu. A llm-driven multi-agent systems for professional development of mathematics teachers. *arXiv preprint arXiv:2507.05292*, 2025b. URL <https://arxiv.org/abs/2507.05292>.
- Yue Yang, MingKang Chen, Qihua Liu, Mengkang Hu, Qiguang Chen, Gengrui Zhang, Shuyue Hu, Guangtao Zhai, Yu Qiao, Yu Wang, et al. Truly assessing fluid intelligence of large language models through dynamic reasoning evaluation. *arXiv preprint arXiv:2506.02648*, 2025c.
- Yutao Yang, Jie Zhou, Xuanwen Ding, Tianyu Huai, Shunyu Liu, Qin Chen, Yuan Xie, and Liang He. Recent advances of foundation language models-based continual learning: A survey. *ACM Computing Surveys*, 57(5):1–38, 2025d.
- Ziyi Yang, Weizhou Shen, Chenliang Li, Ruijun Chen, Fanqi Wan, Ming Yan, Xiaojun Quan, and Fei Huang. Spell: Self-play reinforcement learning for evolving long-context language models. *arXiv preprint arXiv:2509.23863*, 2025e.
- Shunyu Yao, Howard Chen, John Yang, and Karthik Narasimhan. Webshop: Towards scalable real-world web interaction with grounded language agents. *Advances in Neural Information Processing Systems*, 35: 20744–20757, 2022.
- Shunyu Yao, Noah Shinn, Pedram Razavi, and Karthik Narasimhan. tau-bench: A benchmark for tool-agent-user interaction in real-world domains. *arXiv preprint arXiv:2406.12045*, 2024.
- Rui Ye, Xiangru Liu, Qingyun Wu, Xinyuan Pang, Zhaopeng Yin, Lu Bai, et al. X-mas: Towards building multi-agent systems with heterogeneous llms. *arXiv preprint arXiv:2505.16997*, 2025a.
- Rui Ye et al. Mas-gpt: Training llms to build llm-based multi-agent systems. *arXiv preprint*, 2025b.
- S. Yellamraju, , et al. TextGrad: Automatic "differentiation" via text. *arXiv preprint arXiv:2406.07496*, 2024.
- Li Yin and Zhangyang Wang. Llm-autodiff: Auto-differentiate any llm workflow. *arXiv e-prints*, pp. arXiv–2501, 2025.
- Xunjian Yin, Xinyi Wang, Liangming Pan, Li Lin, Xiaojun Wan, and William Yang Wang. Gödel agent: A self-referential agent framework for recursive self-improvement, 2025. URL <https://arxiv.org/abs/2410.04444>.
- Qiyang Yu, Zheng Zhang, Ruofei Zhu, Yufeng Yuan, Xiaochen Zuo, Yu Yue, Weinan Dai, Tiantian Fan, Gaohong Liu, Lingjun Liu, et al. Dapo: An open-source llm reinforcement learning system at scale. *arXiv preprint arXiv:2503.14476*, 2025a.
- Wenhao Yu, Zhenwen Liang, Chengsong Huang, Kishan Panaganti, Tianqing Fang, Haitao Mi, and Dong Yu. Guided self-evolving llms with minimal human supervision. *arXiv preprint arXiv:2512.02472*, 2025b.
- Lifan Yuan, Yangyi Chen, Xingyao Wang, Yi Fung, Hao Peng, and Heng Ji. CRAFT: Customizing LLMs by Creating and Retrieving from Specialized Toolsets. In *12th International Conference on Learning Representations*, 2024a. URL <https://openreview.net/forum?id=G0vdDSt9XM>.
- Siyu Yuan, Kaitao Song, Jiangjie Chen, Xu Tan, Dongsheng Li, and Deqing Yang. Evoagent: Towards automatic multi-agent generation via evolutionary algorithms. *arXiv preprint arXiv:2406.14228*, 2024b.

- Siyu Yuan, Kaitao Song, Jiangjie Chen, Xu Tan, Dongsheng Li, and Deqing Yang. Evoagent: Towards automatic multi-agent generation via evolutionary algorithms, 2025a. URL <https://arxiv.org/abs/2406.14228>.
- Weizhe Yuan, Richard Yuanzhe Pang, Kyunghyun Cho, Xian Li, Sainbayar Sukhbaatar, Jing Xu, and Jason Weston. Self-rewarding language models. *arXiv preprint arXiv:2401.10020*, 2024c.
- Weizhe Yuan, Richard Yuanzhe Pang, Kyunghyun Cho, Xian Li, Sainbayar Sukhbaatar, Jing Xu, and Jason E. Weston. Self-rewarding language models. In *Proceedings of the 41st International Conference on Machine Learning*, volume 235 of *Proceedings of Machine Learning Research*, pp. 57905–57923. PMLR, 2024d.
- Weizhe Yuan, Richard Yuanzhe Pang, Kyunghyun Cho, Xian Li, Sainbayar Sukhbaatar, Jing Xu, and Jason Weston. Self-rewarding language models, 2025b. URL <https://arxiv.org/abs/2401.10020>.
- Xinbin Yuan, Jian Zhang, Kaixin Li, Zhuoxuan Cai, Lujian Yao, Jie Chen, Enguang Wang, Qibin Hou, Jinwei Chen, Peng-Tao Jiang, and Bo Li. Enhancing visual grounding for gui agents via self-evolutionary reinforcement learning. *arXiv preprint arXiv:2505.12370*, 2025c.
- Zheng Yuan, Hongyi Yuan, Chuanqi Tan, Wei Wang, Songfang Huang, and Fei Huang. Rrhf: Rank responses to align language models with human feedback without tears. *arXiv preprint arXiv:2304.05302*, 2023.
- Murong Yue, Wenhan Lyu, Wijdane Mifdal, Jennifer Suh, Yixuan Zhang, and Ziyu Yao. Mathvc: An llm-simulated multi-character virtual classroom for mathematics education. *arXiv preprint arXiv:2404.06711*, 2025. URL <https://arxiv.org/abs/2404.06711>.
- Eric Zelikman, Yuhuai Wu, Jesse Mu, and Noah Goodman. Star: Bootstrapping reasoning with reasoning. *Advances in Neural Information Processing Systems*, 35:15476–15488, 2022.
- Eric Zelikman, Georges Harik, Yijia Shao, Varuna Jayasiri, Nick Haber, and Noah D Goodman. Quiet-star: Language models can teach themselves to think before speaking. *arXiv preprint arXiv:2403.09629*, 2024.
- Yunpeng Zhai, Shuchang Tao, Cheng Chen, Anni Zou, Ziqian Chen, Qingxu Fu, Shinji Mai, Li Yu, Jiaji Deng, Zouying Cao, Zhaoyang Liu, Bolin Ding, and Jingren Zhou. Agentevolver: Towards efficient self-evolving agent system. *arXiv preprint arXiv:2511.10395*, 2025.
- Danyang Zhang, Lu Chen, Situo Zhang, Hongshen Xu, Zihan Zhao, and Kai Yu. Large language models are semi-parametric reinforcement learning agents. *Advances in Neural Information Processing Systems*, 36, 2024a.
- Enci Zhang, Xingang Yan, Wei Lin, Tianxiang Zhang, and Qianchun Lu. Learning like humans: Advancing llm reasoning capabilities via adaptive difficulty curriculum learning and expert-guided self-reformulation. *arXiv preprint arXiv:2505.08364*, 2025a.
- Genghan Zhang, Weixin Liang, Olivia Hsu, and Kunle Olukotun. Adaptive self-improvement llm agentic system for ml library development. *arXiv preprint arXiv:2502.02534*, 2025b.
- Guanghui Zhang, Kang Chen, Guohao Wan, Hao Chang, Hao Cheng, et al. Evoflow: Evolving diverse agentic workflows on the fly. *arXiv preprint arXiv:2502.07373*, 2025c.
- Guanghui Zhang, Li Niu, Jianwei Fang, Kun Wang, Lu Bai, et al. Multi-agent architecture search via agentic supernet. *arXiv preprint arXiv:2502.04180*, 2025d.
- Guibin Zhang, Muxin Fu, Guancheng Wan, Miao Yu, Kun Wang, and Shuicheng Yan. G-memory: Tracing hierarchical memory for multi-agent systems. *arXiv preprint arXiv:2506.07398*, 2025e.
- Guibin Zhang, Muxin Fu, and Shuicheng Yan. Memgen: Weaving generative latent memory for self-evolving agents. *arXiv preprint arXiv:2509.24704*, 2025f.

- Guibin Zhang, Haotian Ren, Chong Zhan, Zhenhong Zhou, Junhao Wang, He Zhu, Wangchunshu Zhou, and Shuicheng Yan. Memevolve: Meta-evolution of agent memory systems. *arXiv preprint arXiv:2512.18746*, 2025g.
- Hanrong Zhang, Jingyuan Huang, Kai Mei, Yifei Yao, Zhenting Wang, Chenlu Zhan, Hongwei Wang, and Yongfeng Zhang. Agent security bench (asb): Formalizing and benchmarking attacks and defenses in llm-based agents. *arXiv preprint arXiv:2410.02644*, 2024b.
- Jenny Zhang, Shengran Hu, Cong Lu, Robert Lange, and Jeff Clune. Darwin Godel Machine: Open-Ended Evolution of Self-Improving Agents. *arXiv preprint arXiv:2505.22954*, 2025h.
- Jiayi Zhang, Jinyu Xiang, Zhaoyang Yu, Fengwei Teng, Xionghui Chen, Jiaqi Chen, Mingchen Zhuge, Xin Cheng, Sirui Hong, Jinlin Wang, et al. Aflow: Automating agentic workflow generation. *arXiv preprint arXiv:2410.10762*, 2024c.
- Jiayi Zhang, Yiran Peng, Fanqi Kong, Cheng Yang, Yifan Wu, Zhaoyang Yu, Jinyu Xiang, Jianhao Ruan, Jinlin Wang, Maojia Song, HongZhang Liu, Xiangru Tang, Bang Liu, Chenglin Wu, and Yuyu Luo. Autoenv: Automated environments for measuring cross-environment agent learning. *arXiv preprint arXiv:2511.19304*, 2025i.
- Kongcheng Zhang, Qi Yao, Shunyu Liu, Yingjie Wang, Baisheng Lai, Jieping Ye, Mingli Song, and Dacheng Tao. Consistent paths lead to truth: Self-rewarding reinforcement learning for llm reasoning, 2025j. URL <https://arxiv.org/abs/2506.08745>.
- Mike Zhang, Amalie Pernille Dilling, Léon Gondelman, Niels Erik Ruan Lyngdorf, Euan D. Lindsay, and Johannes Bjerva. Sefl: Harnessing large language model agents to improve educational feedback systems. *arXiv preprint arXiv:2502.12927*, 2025k. URL <https://arxiv.org/abs/2502.12927>.
- Ningyu Zhang, Yunzhi Yao, Bozhong Tian, Peng Wang, Shumin Deng, Mengru Wang, Zekun Xi, Shengyu Mao, Jintian Zhang, Yuansheng Ni, et al. A comprehensive study of knowledge editing for large language models. *arXiv preprint arXiv:2401.01286*, 2024d.
- Peiyan Zhang, Haibo Jin, Leyang Hu, Xinnuo Li, Liying Kang, Man Luo, Yangqiu Song, and Haohan Wang. Revolve: Optimizing ai systems by tracking response evolution in textual optimization. *arXiv preprint arXiv:2412.03092*, 2024e.
- Qiyuan Zhang, Fuyuan Lyu, Zexu Sun, Lei Wang, Weixu Zhang, Wenyue Hua, Haolun Wu, Zhihan Guo, Yufei Wang, Niklas Muennighoff, et al. A survey on test-time scaling in large language models: What, how, where, and how well? *arXiv preprint arXiv:2503.24235*, 2025l.
- Qizheng Zhang, Changran Hu, Shubhangi Upasani, Boyuan Ma, Fenglu Hong, Vamsidhar Kamanuru, Jay Rainton, Chen Wu, Mengmeng Ji, Hanchen Li, et al. Agentic context engineering: Evolving contexts for self-improving language models. *arXiv preprint arXiv:2510.04618*, 2025m.
- Shaokun Zhang, Jieyu Zhang, Jiale Liu, Linxin Song, Chi Wang, Ranjay Krishna, and Qingyun Wu. Offline training of language model agents with functions as learnable weights. In *Forty-first International Conference on Machine Learning*, 2024f.
- Shaokun Zhang, Yi Dong, Jieyu Zhang, Jan Kautz, Bryan Catanzaro, Andrew Tao, Qingyun Wu, Zhiding Yu, and Guilin Liu. Nemotron-research-tool-n1: Exploring tool-using language models with reinforced reasoning. *arXiv preprint arXiv:2505.00024*, 2025n.
- Xuemiao Zhang, Liangyu Xu, Feiyu Duan, Yongwei Zhou, Sirui Wang, Rongxiang Weng, Jingang Wang, and Xunliang Cai. Preference curriculum: Llms should always be pretrained on their preferred data. *arXiv preprint arXiv:2501.13126*, 2025o.
- Xueqiao Zhang, Chao Zhang, Jianwen Sun, Jun Xiao, Yi Yang, and Yawei Luo. Eduplanner: Llm-based multi-agent systems for customized and intelligent instructional design. *arXiv preprint arXiv:2504.05370*, 2025p. URL <https://arxiv.org/abs/2504.05370>.

- Yijing Zhang, Dyah Adila, Changho Shin, and Frederic Sala. Personalize your llm: Fake it then align it. *arXiv preprint arXiv:2503.01048*, 2025q.
- Yiqun Zhang, Peng Ye, Xiaocui Yang, Shi Feng, Shufei Zhang, Lei Bai, Wanli Ouyang, and Shuyue Hu. Nature-inspired population-based evolution of large language models. *arXiv preprint arXiv:2503.01155*, 2025r.
- Yuanshuo Zhang, Yuchen Hou, Bohan Tang, Shuo Chen, Muhan Zhang, Xiaowen Dong, and Siheng Chen. Gnn as predictors of agentic workflow performances. *arXiv preprint arXiv:2503.11301*, 2025s.
- Zeyu Zhang, Xiaohe Bo, Chen Ma, Rui Li, Xu Chen, Quanyu Dai, Jieming Zhu, Zhenhua Dong, and Ji-Rong Wen. A survey on the memory mechanism of large language model based agents. *arXiv preprint arXiv:2404.13501*, 2024g.
- Zhehao Zhang, Ryan A Rossi, Branislav Kveton, Yijia Shao, Diyi Yang, Hamed Zamani, Franck Dernoncourt, Joe Barrow, Tong Yu, Sungchul Kim, et al. Personalization of large language models: A survey. *arXiv preprint arXiv:2411.00027*, 2024h.
- Zhexin Zhang, Shiyao Cui, Yida Lu, Jingzhuo Zhou, Junxiao Yang, Hongning Wang, and Minlie Huang. Agent-safetybench: Evaluating the safety of llm agents. *arXiv preprint arXiv:2412.14470*, 2024i.
- Zhexin Zhang, Junxiao Yang, Pei Ke, Shiyao Cui, Chujie Zheng, Hongning Wang, and Minlie Huang. Safe unlearning: A surprisingly effective and generalizable solution to defend against jailbreak attacks. *arXiv preprint arXiv:2407.02855*, 2024j.
- Zhongyue Zhang, Zijie Qiu, Yingcheng Wu, Shuya Li, Dingyan Wang, Zhuomin Zhou, Duo An, Yuhan Chen, Yu Li, Yongbo Wang, et al. Origene: A self-evolving virtual disease biologist automating therapeutic target discovery. *bioRxiv*, pp. 2025–06, 2025t.
- Andrew Zhao, Daniel Huang, Quentin Xu, Matthieu Lin, Yong-Jin Liu, and Gao Huang. Expel: Llm agents are experiential learners. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 38, pp. 19632–19642, 2024a.
- Andrew Zhao, Yiran Wu, Yang Yue, Tong Wu, Quentin Xu, Matthieu Lin, Shenzhi Wang, Qingyun Wu, Zilong Zheng, and Gao Huang. Absolute zero: Reinforced self-play reasoning with zero data. *arXiv preprint arXiv:2505.03335*, 2025a.
- Haiteng Zhao, Chang Ma, Guoyin Wang, Jing Su, Lingpeng Kong, Jingjing Xu, Zhi-Hong Deng, and Hongxia Yang. Empowering large language model agents through action learning. *CoRR*, abs/2402.15809, 2024b.
- Henry Hengyuan Zhao, Pan Zhou, and Mike Zheng Shou. Genixer: Empowering multimodal large language model as a powerful data generator. In *European Conference on Computer Vision*, pp. 129–147. Springer, 2024c.
- Qianchuan Zhao, Yuxiang Xie, Wentao Wang, Jie Li, Lizhou Sha, Jialong Zhang, and Minlie Huang. Riche-lieu: Self-evolving LLM-based agents for AI diplomacy. *arXiv preprint arXiv:2407.06813*, 2024d. URL <https://arxiv.org/abs/2407.06813>.
- Wanjia Zhao, Mert Yuksekgonul, Shirley Wu, and James Zou. Sirius: Self-improving multi-agent systems via bootstrapped reasoning. *arXiv preprint arXiv:2502.04780*, 2025b.
- Arman Zharmagambetov, Chuan Guo, Ivan Evtimov, Maya Pavlova, Ruslan Salakhutdinov, and Kamalika Chaudhuri. Agentdam: Privacy leakage evaluation for autonomous web agents. *arXiv preprint arXiv:2503.09780*, 2025.
- Boyuan Zheng, Michael Y. Fatemi, Xiaolong Jin, Zora Zhiruo Wang, Apurva Gandhi, Yueqi Song, Yu Gu, Jayanth Srinivasa, Gaowen Liu, Graham Neubig, and Yu Su. Skillweaver: Web agents can self-improve by discovering and honing skills. *CoRR*, abs/2504.07079, 2025a.

- Huaxiu Steven Zheng, Swaroop Mishra, Hugh Zhang, Xinyun Chen, Minmin Chen, Azade Nova, Le Hou, Heng-Tze Cheng, Quoc V Le, Ed H Chi, et al. Natural plan: Benchmarking llms on natural language planning. *arXiv preprint arXiv:2406.04520*, 2024a.
- Junhao Zheng, Xidi Cai, Qiuke Li, Duzhen Zhang, ZhongZhi Li, Yingying Zhang, Le Song, and Qianli Ma. Lifelongagentbench: Evaluating llm agents as lifelong learners. *arXiv preprint arXiv:2505.11942*, 2025b.
- Junhao Zheng, Chengming Shi, Xidi Cai, Qiuke Li, Duzhen Zhang, Chenxing Li, Dong Yu, and Qianli Ma. Lifelong learning of large language model based agents: A roadmap. *arXiv preprint arXiv:2501.07278*, 2025c.
- Yuanhang Zheng, Peng Li, Wei Liu, Yang Liu, Jian Luan, and Bin Wang. Toolrerank: Adaptive and hierarchy-aware reranking for tool retrieval. In *LREC/COLING*, pp. 16263–16273. ELRA and ICCL, 2024b.
- Wanjun Zhong, Lianghong Guo, Qiqi Gao, He Ye, and Yanlin Wang. Memorybank: Enhancing large language models with long-term memory. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 38, pp. 19724–19731, 2024.
- Da-Wei Zhou, Hai-Long Sun, Jingyi Ning, Han-Jia Ye, and De-Chuan Zhan. Continual learning with pre-trained models: A survey. *arXiv preprint arXiv:2401.16386*, 2024a.
- Han Zhou, Xingchen Wan, Ruoxi Sun, Hamid Palangi, Shariq Iqbal, Ivan Vulić, Anna Korhonen, and Sercan Ö. Arik. Multi-agent design: Optimizing agents with better prompts and topologies, 2025a. URL <https://arxiv.org/abs/2502.02533>.
- Huichi Zhou, Yihang Chen, Siyuan Guo, Xue Yan, Kin Hei Lee, Zihan Wang, Ka Yiu Lee, Guchun Zhang, Kun Shao, Linyi Yang, et al. Memento: Fine-tuning llm agents without fine-tuning llms. *arXiv preprint arXiv:2508.16153*, 2025b.
- Jijie Zhou, Eryue Xu, Yaoyao Wu, and Tianshi Li. Rescriber: Smaller-llm-powered user-led data minimization for llm-based chatbots. In *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems*, pp. 1–28, 2025c.
- Shuyan Zhou, Frank F Xu, Hao Zhu, Xuhui Zhou, Robert Lo, Abishek Sridhar, Xianyi Cheng, Tianyue Ou, Yonatan Bisk, Daniel Fried, et al. Webarena: A realistic web environment for building autonomous agents. *arXiv preprint arXiv:2307.13854*, 2023.
- Wangchunshu Zhou, Yixin Ou, Shengwei Ding, Long Li, Jialong Wu, Tiannan Wang, Jiamin Chen, Shuai Wang, Xiaohua Xu, Ningyu Zhang, et al. Symbolic learning enables self-evolving agents. *arXiv preprint arXiv:2406.18532*, 2024b.
- Xueyang Zhou, Weidong Wang, Lin Lu, Jiawen Shi, Guiyao Tie, Yongtian Xu, Lixing Chen, Pan Zhou, Neil Zhenqiang Gong, and Lichao Sun. Automating safety enhancement for llm-based agents with synthetic risk scenarios. *arXiv preprint arXiv:2505.17735*, 2025d.
- Yifei Zhou, Sergey Levine, Jason Weston, Xian Li, and Sainbayar Sukhbaatar. Self-challenging language model agents, 2025e. URL <https://arxiv.org/abs/2506.01716>.
- Yongchao Zhou, Andrei Ioan Muresanu, Ziwen Han, Keiran Paster, Silviu Pitit, Harris Chan, and Jimmy Ba. Large language models are human-level prompt engineers. In *The Eleventh International Conference on Learning Representations*, 2022.
- Kunlun Zhu, Hongyi Du, Zhaochen Hong, Xiaocheng Yang, Shuyi Guo, Zhe Wang, Zhenhailong Wang, Cheng Qian, Xiangru Tang, Heng Ji, et al. Multiagentbench: Evaluating the collaboration and competition of llm agents. *arXiv preprint arXiv:2503.01935*, 2025.
- Yangyang Zhuang, Wenjia Jiang, Jiayu Zhang, Ze Yang, Joey Tianyi Zhou, and Chi Zhang. Learning to be a doctor: Searching for effective medical agent architectures. *arXiv preprint arXiv:2504.11301*, 2025.

Mingchen Zhuge, Wenyi Wang, Louis Kirsch, Francesco Faccio, Dmitrii Khizbullin, and Jürgen Schmidhuber. Gptswarm: Language agents as optimizable graphs. In *ICML*. OpenReview.net, 2024.

Andy Zou, Long Phan, Justin Wang, Derek Duenas, Maxwell Lin, Maksym Andriushchenko, J Zico Kolter, Matt Fredrikson, and Dan Hendrycks. Improving alignment and robustness with circuit breakers. In *The Thirty-eighth Annual Conference on Neural Information Processing Systems*, 2024.

Yuxin Zuo, Kaiyan Zhang, Li Sheng, Shang Qu, Ganqu Cui, Xuekai Zhu, Haozhan Li, Yuchen Zhang, Xinwei Long, Ermo Hua, et al. Ttrl: Test-time reinforcement learning. *arXiv preprint arXiv:2504.16084*, 2025.

Adam Zweiger, Jyothish Pari, Han Guo, Ekin Akyürek, Yoon Kim, and Pulkit Agrawal. Self-adapting language models. *arXiv preprint arXiv:2506.10943*, 2025.