

Audited Skill-Graph Self-Improvement for Agentic LLMs via Verifiable Rewards, Experience Synthesis, and Continual Memory

Ken Huang 
DistributedApps.ai, OWASP
 Fairfax, VA, USA
 ken.huang@owasp.org

Jerry Huang 
Kleiner Perkins
 jerryhuang2k@gmail.com

摘要

强化学习正日益被用于将大语言模型转变为交互式智能体，这些智能体能够在部分可观测条件下长期行动、调用工具并管理记忆。近期的综述将这一趋势界定为从单轮生成向序贯决策的转变，并围绕规划、推理、工具使用、自我改进和记忆等能力来组织智能体强化学习 [10]。与此同时，系统层面的工作强调，多轮、多任务训练的稳健扩展需要异步生成-训练流水线以及面向异构环境的统一接口 [11, 4]。尽管取得了这些进展，部署的自我改进循环仍面临一个操作安全问题：优化压力、分布偏移和不完全可观测性会诱发奖励黑客行为、脆弱专业化以及难以复现、审计或治理的不可追踪行为漂移。本文提出审计式技能图自我改进（ASG-SI），该方法将自我改进视为将智能体迭代编译为一个不断增长的有向技能图，其中技能晋升由验证器支持证据把关。ASG-SI 结合了可验证的分解奖励，用于评估工具使用正确性、结果有效性、技能复用和组合完整性；利用经验综合实现可扩展的压力测试和课程覆盖；并通过持续记忆控制防止无界上下文增长，同时保留长期信用分配。核心操作机制是一个验证器-审计器，它重放候选技能及其组合，为晋升决策生成最小充分证据束，并支持从可重放工件而非不透明偏好信号中重建塑形奖励。

1 引言

智能体强化学习将优化从单轮文本生成重构为时间上扩展的决策过程，其中策略必须解读观测、选择动作（如工具调用和记忆操作）并追求延迟奖励。近期综述中的一个关键主题是，通常被视为提示技巧的智能体能力——规划、工具集成、记忆、反思和推理——可以被形式化为交互式策略的组成部分，并在奖励可用时通过强化学习加以改进 [10]。并行研究强调，真正的进展依赖于基础设施：多轮展开引入了复杂的控制流、异构环境和吞吐量约束，这促使了完全异步的流水线、标准化的数据接口以及解耦的执行与训练 [11, 4]。这些趋势为安全关键场景提出了一个实用问题：当智能体被允许在部署期间改进时，改进的单位是什么，以及该单位如何在优化压力下被验证、复现和治理？ASG-SI 通过使改进显式且可检查来回答这一问题。ASG-SI 不将自我改进仅视为参数漂移，而是将改进视为可复用技能的积累。




图 1: ASG-SI 系统架构。在线交互与离线技能编译和验证相分离。改进仅通过经审计的技能提升进入系统。

这些技能具有显式接口、可验证契约和可审计来源。该提议的动机源于近期工具学习和可验证奖励研究中反复出现的操作现实：当奖励可以从工件（如工具记录、模式检查或确定性评估器）中重建时，学习可以变得更加可靠，且更少依赖主观判断，但由此产生的系统仍需要严格的测量和污染控制 [5, 8, 6]。ASG-SI 通过仅在验证器生成可回放证据后才提升新能力，并结构化奖励使相同证据可用于重建奖励分量，从而将这一洞见操作化。图 1 提供了一个紧凑的架构，将在线交互与离线编译和验证相分离。

2 系统概述

ASG-SI 将智能体系统组织为四个子系统，通过日志和注册表连接：策略运行时，负责任务和工具的交互；记忆子系统，支持有界的长时程运行；技能编译器，从成功轨迹中提取可复用技能并将其规范化为标准表示；验证器-审计器，在受控测试框架下回放候选方案并生成证据包。经审计的技能图是一个有向多重图，其节点为具有明确接口和实现的技能，边编码组合约束、依赖顺序和受保护的降级路径。关键架构目标是确保从“智能体行为”到“提升改进”的路径由可独立重放和检查的工件（artifact）中介。这种分离与 AgentRL 和 Agent Lightning 中更广泛的系统视角一致，其中执行和训练被刻意解耦，并通过定义良好的数据接口统一 [11, 4]。在 ASG-SI 中，验证器-审计器充当执行边界：它不依赖策略模型的内部状态，而是依赖可从记录轨迹、环境检查和确定性验证器重建的工件。

3 威胁模型与安全目标

ASG-SI 针对已部署的智能体系统，这些系统在与工具、外部状态和记忆交互的同时进行自我改进。基线（baseline）对手模型假设攻击者能够影响任务输入和任务分布，能够试图诱导优化压力朝向违反约束的行为，并能通过工具输出或外部资源提供恶意或混淆内容。这涵盖了常见的部署风险：智能体在约束下运行时以结果度量（metric）进行评估，而最大化某个度量的系统可能发展出工具性

违反要求以实现测量结果的策略。近期工作提出在多步骤、持久环境中显式评估此类行为，从而推动超越单轮拒绝行为、聚焦于结果驱动约束违反的安全目标 [3]。ASG-SI 还考虑了自我改进流水线特有的供应链与完整性风险：受损的技能工件、被篡改的验证器或日志可制造改进的假象，同时降低安全性与可靠性。ASG-SI 的安全目标定义在已提升工件及其来源层面，而非单一模型检查点层面。首要目标是可审计性，即提升决策与奖励分配须与证据包绑定，且该证据包可在指定验证器版本与环境测试框架下重放。第二目标是改进的完整性，即技能仅在满足显式接口契约并通过独立于生成候选策略运行时的重放测试时方可提升。第三目标是受控泛化，即技能复用与组合仅允许通过前置条件与后置条件均经检查的接口进行，从而在技能图的节点与边层面实现故障定位。第四目标是测量可靠性，即评估协议须包含对奖励博弈与测量工件的检查，这些工件可能在可验证奖励机制下夸大收益，近期关于可验证奖励与测量差距的强化学习讨论中已提出此关切 [6]。上述目标假设已应用标准操作隔离，使验证器与证据存储不被策略运行时直接写入，并对验证器、工具与测试框架实施版本控制。

4 动机与失效模式

一个已部署的自我改进智能体必须在部分可观测条件下解决控制问题，其中奖励往往稀疏、延迟，或与工具调用模式、策略约束或合规检查等中间有效性要求纠缠在一起。如果优化仅针对最终结果，训练会变得不稳定，因为许多轨迹提供的学习信号很少，且智能体可能发现利用评估盲点的捷径。渐进式奖励塑形通过提供分阶段目标来形式化一种实用的应对方法：首先教授工具使用和格式化的结构正确性，然后是正确性和质量，最后才是效率，从而减少稀疏奖励机制下的早期崩溃 [13]。工具学习方面的工作同样强调，奖励设计必须反映工具选择和参数化的结构，因为粗粒度的结果匹配可能过于薄弱，无法指导中间动作 [5]。ASG-SI 遵循这一方向，但将其扩展到操作治理，通过将每个奖励组件与可回放的工件绑定，这些工件也支持晋升门控。第二种失败模式是持续任务流下的遗忘。针对智能体的持续学习基准强调，评估必须跟踪任务演变过程中的性能，并且即使静态基准分数看似稳定，灾难性遗忘也可能显现 [2]。在部署环境中，遗忘可能表现为先前稳定的工具使用模式出现回归、在小的上下文扰动下动作选择发生变化，或记忆内容漂移破坏长程依赖。近期工作将记忆操作作为策略的一部分，使用强化学习进行训练，旨在保持性能的同时使记忆有界或结构化 [12, 9]。ASG-SI 采纳这一前提，将记忆操作视为可审计控制回路的一部分，并通过定期回放测试已晋升技能及其组合来使保持力可度量。第三种失败模式是非模块化改进。即使智能体在聚合度量上有所提升，也可能难以归因于哪些行为得到了改进、该变化是否具有泛化性，

以及这种改进能否被安全地复用。技能库方法试图通过显式生成和复用技能来使改进模块化，而近期基于强化学习的公式化方法则将技能生成与利用整合进训练目标 [7]。ASG-SI 通过验证与审计扩展了模块化，使技能不仅被添加，而且通过有证据支持的检查得到提升，从而使改进的操作单元成为具有显式接口和来源追踪的已验证技能工件，而非模型行为的隐式转变。

5 审计技能图自改进

ASG-SI 将每次迭代视为一个编译与验证循环，其中策略运行时通过直接推理、工具调用和内存操作的组合与任务交互，同时记录包含工具转录、中间工件和内存更新的完整轨迹。技能编译器通过识别可复用的子序列来提取候选技能，将其规范化为规范程序或模板，并分配带有前置条件和后置条件的显式接口。这些接口被设计为可由验证器检查，包括工具调用的模式约束和中间工件的结构不变量。随后，验证器-审计器在留出任务、契约检查和受控扰动上评估候选技能，生成证据包，其中在适用时包括确定性测试结果、工具模式验证日志以及工件或转录的加密哈希。只有通过提升标准的候选技能才会被添加到审计技能图中，该图成为未来复用的显式运行时基础。在提升之前强调验证，其动机在于“学习改进了某个度量”与“学习产生了可复用、可治理的能力”之间的操作差距。在 ASG-SI 中，被提升的技能是一个可调单元，其接口和证据可以被检查，其执行可以在指定的测试框架下重放。这种设计还支持成功归因的分解：系统能够区分归因于直接推理的成功与归因于已验证技能复用和已验证组合的成功。图 2 描绘了迭代循环，其中验证既产生提升决策，也产生用于奖励塑形的证据。

6 验证器支持的奖励构建

ASG-SI 采用一种可分解的奖励，旨在能够从证据包中重建。工具有效性组件评估工具调用是否符合模式、参数是否类型正确，以及输出是否在后续步骤中被一致使用；这源于一个观察，即工具使用的结构化奖励往往是必要的，因为最终答案匹配可能过于粗糙，无法指导策略改进 [5]。结果验证组件在可用时使用确定性评估器对任务成功进行评分，例如单元测试、显式环境检查或结构化任务中的精确匹配评分。技能重用组件奖励在满足前置条件下调用已验证技能并产生满足后置条件的输出，将重用转变为一种尊重契约的行为，而非启发式方法。组合组件奖励在每个边缘满足接口契约的多技能链，并惩罚那些否则会被端到端成功所掩盖的契约违规。记忆纪律组件惩罚无界上下文增长，并奖励在有界记忆下保持成功的记忆操作，这与将记忆更新和检索决策视为强化学习目标下可学习动作的方法一致 [12, 9]。渐进式塑形在训练阶段之间调度这些组件，早期优先考虑结构有效性，后期将权重转向正确性、组合完整性和效率。

图 2 (第 5 页) : ASG-SI 中的迭代自我改进循环。




图 2: ASG-SI 中的迭代自我改进循环。候选技能从轨迹中编译，通过重放和契约检查进行验证，然后被提升。证据包驱动塑形奖励并支持可复现性。

这与智能体强化学习中的渐进式奖励塑形方法一致，该方法提供密集的、分阶段的反馈，以克服稀疏的二元奖励并稳定优化 [13]。验证器-审计器负责生成重建所需的工件：模式验证日志、测试结果、接口检查和中间工件的哈希值。这种设计还支持更强的测量纪律，因为相同的工件可用于检测声称的成功与可验证的成功之间的不一致，并审计奖励组件是否按规定计算，这一点在可验证奖励机制在奇偶控制协议下进行评估时变得重要 [6]。

7 技能图表示

经审计的技能图 (Skill Graph) 为模块化改进、故障定位与治理提供了具体基础。节点对应具有显式接口、规范实现与验证报告的技能；边编码兼容性与组合约束，例如所需中间类型、顺序约束或受保护的备用路径。通过显式表示接口，ASG-SI 能够在测试框架下回放以验证技能与组合，将回归定位到特定节点或边，并以已验证可复用单元的累积来衡量改进，而非仅依据聚合基准分数的变化。这是对非模块化失效模式的实用回应：当改进被表示为具有可验证契约的工件图时，便有可能询问新增了何种能力、适用于哪些任务，以及有何证据支持其声称的行为。图 3 展示了一种常见的多步组合模式，其中包含受保护的备用路径，旨在刻画现实智能体行为——主策略可能失败，而在显式保护条件下调用保守的替代方案。




图 3：技能图组合示例。节点为具有显式接口的已验证技能；边编码组合契约与受保护的备用路径。

8 审计与证据包

审计被视为一等输出，将晋升决策、奖励构建与可复现性绑定为单一迹。每个晋升决策都关联一个最小充分证据包，包含工具模式与参数、工具输出（或输出较大时的输出哈希）、技能接口的契约检查、适用时的确定性测试结果，以及带版本信息的验证器身份。这些证据包支持奖励重建、第三方重放，并使回归检测可操作，因为当初证明晋升合理的同一批测试可以定期或在新模型检查点上重新运行。该设计源于如下观察：结果度量在优化压力下可能被操纵，且当可验证奖励大规模使用时，稳健评估往往需要显式测量与溯源检查 [6]。在智能体可能被激励违反约束以达成结果的情境中，显式记录约束检查并将其纳入奖励与晋升门控，提供了一种实用机制，与针对多步环境中结果驱动约束违反的基准相一致 [3]。图 4 展示了从轨迹到候选、再到验证器重放，进而到基于证据的晋升与塑造奖励的流程。

9 证据完整性与防篡改设计

证据完整性是任何受审计的自我改进系统的安全边界，因为被篡改的证据可能制造出已验证改进的假象，同时损害安全性与可靠性。ASG-SI 将每个证据包视为结构化清单，其中包含字段的规范排序、工件与转录的加密哈希，以及验证器、工具模式和环境运行器的显式版本标识符。该设计通过两种方式支持篡改可检测性：通过重新计算哈希并比较清单，使事后修改可被检测；通过将结果绑定到特定验证器版本，使来源在不同运行之间可比较。随着系统采用异步流水线，完整性要求变得更加突出，因为执行与训练的解耦提高了吞吐量，但也增加了分布式部署中迹完整性以及显式陈旧性和来源控制的重要性 [11, 4]。对于安全类别提交，本节可具体化为对日志仅追加存储、签名密钥管理以及策略运行时与验证器职责分离的具体要求，核心主张仍然是：在对抗性压力下，证据完整性是使可审计性具有意义的必要条件。

图 4 (第 7 页) : 可审计的改进迹。




图 4: 可审计的改进迹。晋升决策和塑造奖励源自可重放的证据包，而非不透明的偏好信号。

10 经验综合的扩展

经验综合 (Experience Synthesis) 为在真实环境交互昂贵或速率受限时扩展训练与验证提供了一条途径。DreamGym 提出通过将环境动态提炼为经验模型，并将合成转换与定期用真实交互重新锚定的回放缓冲区相结合，来合成多样化的智能体经验 [1]。在 ASG-SI 中，合成经验被视为对真实推演的补充而非替代，因为安全目标不仅关乎性能，还关乎可靠的证据以及合成分布与真实分布之间的有界发散。综合主要用于对技能接口和组合进行压力测试，探测在自然任务分布下罕见的边界条件，并扩展对抗性和边缘案例行为的覆盖范围。通过真实推演进行周期性重新锚定可重新校准验证器阈值，并降低基于无法迁移到真实测试环境的合成工件而提升技能的风险。这一框架还支持更符合安全导向的综合使用方式：它可以生成对抗性结构化的任务，以检验约束边界和工具误用模式，并且这些任务可以集成到用于晋升门控的留出验证套件中。

11 持续学习与保留

持续学习使遗忘变得可观测，因为评估沿着任务流而非静态测试集跟踪性能。SWE-Bench-CL 通过按时间顺序组织软件工程问题，并衡量智能体在代码库演进时是否保留和迁移能力，体现了这一点 [2]。ASG-SI 通过双重机制解决保留问题。首先，已验证的技能

作为可调用的工件持久存在于图中，即使基础策略的行为发生漂移，也能作为稳定的后备方案使用。其次，记忆操作受到控制，使得长程依赖可以在不导致上下文无限增长的情况下得以保留，这与通过强化学习而非固定启发式来优化记忆更新和检索的方法一致 [12, 9]。这种组合实现了可衡量的保留：已验证的技能可以定期进行回放测试，以在工件层面检测性能退化，而重用统计可以量化保留的技能在任务流变化时是否仍保持操作相关性。

12 实现考虑因素

ASG-SI 旨在与异步智能体强化学习基础设施集成，其中执行与训练解耦，并通过标准化数据接口连接。AgentRL 强调可扩展的多轮、多任务训练，采用异步生成-训练流水线和异构环境支持 [11]，而 Agent Lightning 描述了将智能体执行与强化学习训练分离，并定义统一数据接口以支持与多种智能体运行时集成 [4]。ASG-SI 与该方向兼容，将编译器和验证器视为边车服务，消费轨迹日志并产出技能工件、验证器报告和证据包。策略运行时查询经审计的技能图以获取调用候选，而训练器消费证据包以计算塑形奖励，并支持奇偶校验控制的评估，其中相同证据可复用于验证结果和中间约束。本文的参考实现可在 <https://github.com/kenhuangus/ASG-SI> 获取。仓库包含一个完全可运行的最小原型 (`asg_si_demo.py`)，在单个文件中镜像 ASG-SI 架构，并使所有中间工件显式化。该原型定义了一个可验证环境，生成具有确定性真值和精确匹配验证的任务，作为可验证结果奖励的具体实例。它实现了一个小型工具注册表，具有显式模式和纯函数工具，以保持重放确定性并使模式验证有意义。它将交互表示为由类型化步骤（工具调用、技能调用或直接动作）组成的轨迹，并记录足够的数据以重建结果正确性和中间有效性。它实现了一个有界记忆组件，保留有限数量的紧凑笔记并向智能体暴露摘要提示，为受控记忆增长提供具体基线，后续可替换为学习到的记忆操作而不改变审计边界。原型中的技能编译器展示了“编译”步骤，即从成功轨迹中提取规范程序。具体而言，当任务通过单次工具调用正确解决时，编译器构建一个程序模板，将工具参数映射到任务输入键，并分配一个显式接口，描述所需输入和输出类型。然后将其传递给验证器-审计器，该审计器在一组同类型的保留任务上重放候选技能，并生成验证报告，包括每个测试的结果、通过率、检查时间戳和程序表示的稳定哈希。每个验证事件以 JSON 审计迹的形式写入仅追加的审计目录，使证据包具体且可检查。原型中的奖励塑形函数将奖励分解为结构有效性、结果正确性、复用奖励和步数惩罚，并记录每个分量，以便从证据和轨迹日志中重建奖励。该原型还包括一个可选的基于模型的策略，调用本地模型端点并将输出解析为工具调用或直接答案，允许在现实的工具使用错误（如参数指定错误或工具选择错误）下运行相同的审计和验证机制。该实现有意结构化，使得验证器边界不依赖于模型的内部

推理：晋升与奖励成分由可重放和验证的工件决定，这与论文中关于经审计的改进迹可支持可复现评估与治理的主张一致。

13 评估计划

ASG-SI 的评估必须衡量能力增长、持续流下的保持性以及优化压力下的约束遵守情况，同时衡量自我改进管道本身的完整性。能力增长应分解为可归因于直接推理的成功、可归因于已验证技能复用的成功以及可归因于已验证组合的成功，因为本文的论点是持久改进表现为可审计可复用工件的增长，而非仅仅是总分提升。工具有效性度量应包括模式正确率、参数类型正确性以及工具输出利用一致性，反映基于证据的中间有效性，而非仅最终结果 [5]。保持性应在诸如 SWE-Bench-CL 的任务流下衡量，通过跟踪任务演变时的性能，并定期在固定验证套件上重放测试已晋升技能以检测回归，从而同时捕捉策略漂移和工件稳定性 [2]。约束遵守应在旨在引发结果驱动违规的环境中进行评估，其中智能体可能被激励绕过规则以最大化度量，并且证据包应被审计以发现奖励黑客行为的特征，例如不一致的工具迹或被最终结果掩盖的契约违规 [3]。由于近期分析指出，在没有奇偶校验控制协议和污染检查的情况下，可验证的奖励增益可能被高估，ASG-SI 评估应报告基于证据的重建率、跨版本的验证器可复现性以及测试框架变化的敏感性 [6]。该设计隐含的一个实用综合度量是经审计的改进率，它结合了新晋升已验证技能的比率与其在留出任务上的复用率，从而同时捕捉工件的创建及其操作效用。

14 局限性与开放失败案例

ASG-SI 依赖于验证器与证据存储的完整性和隔离性；若验证器被攻破，或策略运行时能够改写证据，可审计性将沦为表面属性而失去强制力。基于回放的验证会引入开销，且非确定性环境需要受控测试装置、记录与回放机制或稳健的统计测试，以保持证据的有效性。可验证奖励还可能产生度量激励，使行为偏向于易于验证的方面而非期望的方面，近期研究强调需要谨慎设计评估，以避免在可验证奖励机制下夸大收益或遗漏隐性成本 [6]。在实际部署中，证据包可能包含敏感数据，需要访问控制、保留策略以及对支持回放所需存储内容的谨慎最小化。最后，技能接口可能存在规格不足的问题：若前置条件和后置条件过弱，技能可能通过测试却在边缘情况中失效；若过于严格，有用的技能可能永远无法被提升。这些权衡促使未来工作关注接口推断、对抗性验证套件以及面向复杂工具与环境交互的原则性组合类型。

15 结论

ASG-SI 将智能体自我改进重新定义为可验证、可复用能力的积累，而非不受控的参数漂移。通过将行为编译为经审计的技能图、利用验证器支持证据塑造奖励、以有根据的经验综合策略扩展训练，并控制长时程交互中的记忆增长，该方法旨在使自我改进在安全相关的部署中可度量、可复现且可治理。

参考文献

- [1] Zhaorun Chen, Zhuokai Zhao, Kai Zhang, Bo Liu, Qi Qi, Yifan Wu, Tarun Kalluri, Sara Cao, Yuanhao Xiong, Haibo Tong, Huaxiu Yao, Hengduo Li, Jiacheng Zhu, Xian Li, Dawn Song, Bo Li, Jason Weston, and Dat Huynh. Scaling agent learning via experience synthesis, 2025. URL <https://arxiv.org/abs/2511.03773>.
- [2] Thomas Joshi, Shayan Chowdhury, et al. Swe-bench-cl: Continual learning for coding agents, 2025. URL <https://arxiv.org/abs/2507.00014>.
- [3] Miles Q. Li, Benjamin C. M. Fung, Martin Weiss, Pulei Xiong, Khalil Al-Hussaeni, and Claude Fachkha. A benchmark for evaluating outcome-driven constraint violations in autonomous ai agents, 2025. URL <https://arxiv.org/abs/2512.20798>.
- [4] Xufang Luo, Yuge Zhang, Zhiyuan He, Zilong Wang, Siyun Zhao, Dongsheng Li, Luna K. Qiu, and Yuqing Yang. Agent lightning: Train any ai agents with reinforcement learning, 2025. URL <https://arxiv.org/abs/2508.03680>.
- [5] Cheng Qian, Emre Can Acikgoz, Qi He, Hongru Wang, Xiusi Chen, Dilek Hakkani-Tür, Gokhan Tur, and Heng Ji. Toolrl: Reward is all tool learning needs, 2025. URL <https://arxiv.org/abs/2504.13958>.
- [6] Aaron Tu, Weihao Xuan, Heli Qi, Xu Huang, Qingcheng Zeng, Shayan Talaei, Yijia Xiao, Peng Xia, Xiangru Tang, Yuchen Zhuang, Bing Hu, Hanqun Cao, Wenqi Shi, Tianang Leng, Rui Yang, Yingjian Chen, Ziqi Wang, Irene Li, Nan Liu, Huaxiu Yao, Li Erran Li, Ge Liu, Amin Saberi, Naoto Yokoya, Jure Leskovec, Yejin Choi, and Fang Wu. Position: The hidden costs and measurement gaps of reinforcement learning with verifiable rewards, 2025. URL <https://arxiv.org/abs/2509.21882>.
- [7] Jiong Xiao Wang, Qiaojing Yan, Yawei Wang, Yijun Tian, Soumya Smruti Mishra, Zhichao Xu, Megha Gandhi, Panpan Xu, and Lin Lee Cheong. Reinforcement learning for self-improving agent with skill library, 2025. URL <https://arxiv.org/abs/2512.17102>.
- [8] Xumeng Wen, Zihan Liu, Shun Zheng, Zhijian Xu, Shengyu Ye, Zhirong Wu, Xiao Liang, Yang Wang, Junjie Li, Ziming Miao, Jiang Bian, and Mao Yang. Reinforcement learning with verifiable rewards implicitly incentivizes correct reasoning in base llms, 2025. URL <https://arxiv.org/abs/2506.14245>.
- [9] Sikuan Yan, Xiufeng Yang, Zuchao Huang, Ercong Nie, Zifeng Ding, Zonggen Li, Xiaowen Ma, Hinrich Schütze, Volker Tresp, and Yunpu Ma. Memory-rl: Enhancing large language model agents to manage and utilize memories via reinforcement learning, 2025. URL <https://arxiv.org/abs/2508.19828>.

- [10] Guibin Zhang, Hejia Geng, Xiaohang Yu, Zhenfei Yin, Zaibin Zhang, Zelin Tan, Heng Zhou, Zhongzhi Li, Xiangyuan Xue, Yijiang Li, Yifan Zhou, Yang Chen, Chen Zhang, Yutao Fan, Zihu Wang, Songtao Huang, Yue Liao, Hongru Wang, Mengyue Yang, Heng Ji, Michael Littman, Jun Wang, Shuicheng Yan, Philip Torr, and Lei Bai. The landscape of agentic reinforcement learning for llms: A survey, 2025. URL <https://arxiv.org/abs/2509.02547>.
- [11] Hanchen Zhang, Xiao Liu, Bowen Lv, Xueqiao Sun, Bohao Jing, Iat Long Iong, Zhenyu Hou, Zehan Qi, Hanyu Lai, Yifan Xu, Rui Lu, Hongning Wang, Jie Tang, and Yuxiao Dong. Agentrl: Scaling agentic reinforcement learning with a multi-turn, multi-task framework, 2025. URL <https://arxiv.org/abs/2510.04206>.
- [12] Zijian Zhou, Ao Qu, Zhaoxuan Wu, Sunghwan Kim, Alok Prakash, Daniela Rus, Jinhua Zhao, Bryan Kian Hsiang Low, and Paul Pu Liang. Mem1: Learning to synergize memory and reasoning for efficient long-horizon agents, 2025. URL <https://arxiv.org/abs/2506.15841>.
- [13] Zhuoran Zhuang, Ye Chen, Jianghao Su, Chao Luo, Luhui Liu, and Xia Zeng. Enhancing agentic reinforcement learning with progressive reward shaping and value-based sampling policy optimization, 2025. URL <https://arxiv.org/abs/2512.07478>.