

为什么大语言模型还不是科学家：来自四次自主研究尝试的教训

德鲁夫·特雷汉 帕拉斯·乔普拉 {
德鲁夫·特雷汉, 帕拉斯 } @lossfunk.com

2026 年 1 月

摘要


本文报告了一项案例研究，涉及四次端到端尝试，使用由六个大语言模型智能体组成的流水线，映射到科学工作流程的各个阶段，以自主生成机器学习研究论文。在这四次尝试中，有三次在实现或评估阶段失败。一次完成了流水线，并被 Agents4Science 2025 接受，这是一个实验性的首届会议，要求人工智能系统作为第一作者，并通过了人类和多人工智能评审。从这些尝试中，我们记录了六种反复出现的失败模式：偏向训练数据默认值、在执行压力下实现漂移、长时程任务中的记忆和上下文退化、尽管明显失败却过度兴奋地宣称成功、领域智能不足，以及实验设计中科学品味薄弱。最后，我们讨论了构建更稳健的人工智能科学家系统的四个设计原则，对自主科学发现的影响，并在 <https://github.com/Lossfunk/ai-scientist-artefacts-v1> 处发布了所有提示、工件和输出。

1 问题定义与系统概述

我们最初的问题是：最先进的推理大语言模型能否以高度自主性、最少的代码脚手架和最基本的工具，从研究想法到研究论文？研究论文中提出的各种人工智能科学家系统已经依赖于高度的

领域特定的工作流程预定义，或以系统特定的方式框定问题陈述。像 Sakana 的 [1] 这样的树搜索系统需要复杂的元编排，这与我们的最小脚手架目标相矛盾。同样，谷歌的 AlphaEvolve 系统 [2] 需要人类专家预先定义清晰的验证度量。

我们感兴趣的是探索当前大语言模型（Large Language Models, LLMs）在没有大量脚手架或人类输入的情况下能走多远。为此，我们将范围限定在计算科学，特别是机器学习（Machine Learning），因为该领域的实验可以完全数字化进行。图 1 展示了我们系统设计的高层示意图。



* 采用外部评审进行迭代优化。

图 1：自主研究流水线：展示六个智能体模块与共享文件系统工件（从 idea.md 到 paper outline.md）之间交互的高层示意图，用于维护上下文。

我们的最终系统由以下六个不同模块组成，均使用 Gemini 2.5 Pro，主要因其长上下文长度。每个模块的提示词和输出格式可在我们的 GitHub 仓库 1 中获取。

1. **想法生成智能体**，通过结合子领域内两篇输入论文的洞见生成研究想法，并以结构化格式输出想法。关于想法生成过程的更多细节见第 2 节。
2. **假设生成智能体**，接收生成的研究想法，提出可检验且可证伪的假设，并给出明确的声明陈述、数据集、基线和需观察的度量，以指导后续阶段的实验规划。¹
<https://github.com/Lossfunk/ai-scientist-artefacts-v1>

3. **实验规划智能体**，将假设与想法转化为详细的实现计划（plan.md 和 agent.md 文件），包含逐步任务、项目结构、方法澄清以及失败模式控制，供克劳德代码（Claude Code）在模态（Modal）基础设施上自主执行。
4. **实验输出评估智能体**，采用双层评估方法，主要审查实验输出在假设实现保真度和统计有效性方面的表现。同一智能体后续还用于对已完成的假设套件进行论文就绪性检查，以确定是否已获得足够的洞见来推进论文撰写任务。
5. **修订智能体**，当实验输出评估表明失败时，自动决定研究流程的下一步，在修订想法、修订假设套件或请求大语言模型导师反馈之间进行选择。该智能体触发频率较低，因为大多数失败的实验由人类决策终止，而非通过修订流程处理。
6. **论文大纲智能体**，审查完整的实验输出以及各阶段所有相关上下文文档，以概述研究论文，包括所需可视化的描述。随后克劳德代码逐节完成该大纲，形成完整论文。

实验实现与论文撰写 - 实验实现与论文撰写由克劳德代码（Claude Code）使用克劳德·奥普斯 4.1（Claude Opus 4.1）和克劳德·索内特 4（Claude Sonnet 4）完成，包括迭代代码开发、在模态（Modal）基础设施上执行，以及从大纲到全文的手稿开发。

在论文撰写方面，我们采用了三阶段迭代方法：生成详细大纲、按顺序完成各章节，以及进行两轮人类与克劳德代码的协作编辑——第一轮确保连续性和流畅性，第二轮则缓和关于结果的过度乐观表述。根据我们的经验，在论文撰写阶段，人工干预对于质量控制仍然是必要的，因为通过提示生成的初始自主草稿虽然在技术上准确，但往往倾向于过于机械化的文风或缺乏叙事上的细微差别。

工具与模型访问 - 该模型在谷歌人工智能工作室（Google AI Studio）上使用代理提示进行访问，包括仓库位置和以下四个工具定义：

- 读取文件 - 这使大语言模型（LLM）能够读取上下文文件，包括先前生成的文档、来自外部大语言模型评审的导师笔记，或代码实现与执行的输出。
- 写入文件 - 这使大语言模型能够保存上下文文件。

- 大语言模型搜索 - 这使代理能够在整个研究过程中根据需要，通过开放人工智能（OpenAI）模型从互联网查询当前信息。
- 列出文件 - 该操作返回了上下文仓库中的文件列表。随着项目进展以及大语言模型智能体创建子目录，这一功能将变得更加重要。

Context Management - Each research idea operated within a dedicated repository that served as the workspace for all agents and the context store. This repository included all context artefacts created from idea note, to hypotheses sets, code files, and code outputs, as well as the final paper LaTeX template required for the conference submission.

每个智能体都接收仓库状态作为其提示上下文的一部分，如图 2 所示。

这种方法确保我们没有过度进行上下文工程，符合我们的自主性和通用系统设计约束，并且我们可以审查大语言模型关于何时解析哪些上下文文件的决策，这对任何研究者来说都是一项相关的信息检索技能。

Task	Generate ideas, Generate hypotheses etc...
List of Files Available	idea_directory/idea.md idea_directory/hypotheses_suite.json idea_directory/hypothesis_1/code.py idea_directory/hypothesis_2/code.py ...
Tools Available	read_file, write_file, list_file, llm_search
Output Format	``` json/markdown ```
Task-Specific Guidelines	1. ... 2. ... 3. ... 4. ...
Task-Specific Process	1. ... 2. ... 3. ... 4. ...

图 2：智能体提示模板：如何在每个智能体模块的系统提示中共享仓库状态、工具和流程指南。

想法评审 - 与此同时，我们还使用了四个零样本提示（基于神经信息处理系统大会指南的审稿人 [1]、思路链审稿人 [3]、谷歌联合科学家锦标赛审稿人 [4]，以及一个通过开放人工智能平台具备网络搜索访问权限的自定义评估提示）在假设生成和实验过程开始之前进行想法评审和筛选。所有审稿人提示均在克劳德作品 4.1 上运行，只有自定义评估提示具有网络搜索访问权限。²

2 我们的尝试与结果

为了测试我们的自主研究系统，我们探索了三个领域：世界模型、多智能体强化学习以及人工智能安全与对齐。图 3 展示了我们的多阶段² 我们决定在 4 个审稿人提示中的 3 个中不包含网络搜索，这与关于人工论文评审过程的讨论一致，在该讨论中审稿人提到他们在撰写评审意见之前并未进行大量文献综述。

表 1：研究实施历程：尝试、结果与失败模式

ID	Domain	Idea	Runs	Final Status	Primary Failure Modes
MARL-1	Multi-Agent RL	Zero-shot Multi-agent Coordination	2	Failed: Execution Stage	Implementation Drift, Bias on Training Data
WM-1	World Models	Differentiable Planning in Stochastic World Models	1	Failed: Evaluation Stage	Implementation Drift, Lack of Scientific Taste
WM-2	World Models	Replacing Reconstruction Loss with Perceptual Loss	1	Failed: Evaluation Stage	Implementation Drift, Bias on Training Data
AS-1	AI Safety	Using Semantic Entropy for Jailbreak Detection	2	Success: Published at Agents4Science 2025	Bias on Training Data, Memory and Context Issues

生成与评审想法的流程，最终筛选出四个想法，从想法生成推进到假设生成与实验。我们以顶级会议与期刊的论文语料库为起点，确保想法生成扎根于前沿研究；最终决定推进哪些想法之前，我们联系了母论文作者，征求其对质量与可行性的意见。

在这四个想法中，三个在执行早期被剔除，只有第四个（来自人工智能对齐与安全领域）成功完成。表 1 概括了这四个候选想法，包括最终状态与主要失败模式。为清晰起见，本文其余部分以编号（MARL-1、WM-1、WM-2、AS-1）指代各研究想法。每次尝试的详细案例研究，包括完整文本、来源论文、专家验证与具体错误，见附录 A。

第四个想法成功执行后，其成果成为我们的最终论文，被 Agents4Science 2025 会议接收：“一致性混淆：为何更强的对齐会破坏黑盒越狱检测。”该会议从 254 份有效投稿中接收了 48 篇，我们的论文还通过了会议组织者设立代码审计。

会议审稿人包括三位




图 3：筛选漏斗：从 135+ 篇论文到 4 个候选想法。仅有一个（AS-1）通过了执行约束。

不同的 LLM 审稿人与一位人类专家。表 2 展示了主要认可该工作实证贡献与负面结果的评审意见，同时指出分析与比较较为有限，导致最终决定为边缘性接收，其中 3 位 AI 审稿人中有 1 位给出 6 分或强烈接收。

表 2: Agent4Science 2025 对“一致性混淆”的评审

Reviewer Type	Decision	Confidence	Strengths	Weaknesses
AI Reviewer 3	4	5	Solid contribution by revealing fundamental limitations of a plausible detection approach and providing mechanistic understanding of why it fails.	The focus on a single SE variant and limited model families.
AI Reviewer 2	6	5	The paper’s originality lies not in the proposal of a new method, but in its rigorous deconstruction of an existing one in a new context.	No significant weaknesses identified.
AI Reviewer 1	4	5	Clear empirical negative results with careful quantification, rigorous analysis of failure modes, appropriate baselines, and transparent discussion of limitations and ethical considerations.	Limited scope (the SE variant differs from canonical SE), lack of comparison to content-based black-box detectors, calibration protocol concerns, narrow decoding and embedding choices, and no positive alternative proposed.
Human Reviewer	4	3	The paper is technically sound, with careful empirical evaluation. It identifies a clear and reproducible failure mode. The underlying method is borrowed from hallucination detection. Main originality is in showing its limitations rather than developing a new technique.	Scope is limited, comparisons are mostly against simple baselines, with no testing of stronger black-box defenses. Contribution is primarily a negative result. While important, significance would be higher if the paper also explored alternative methods or mitigation strategies.

作为会议投稿的一部分，我们必须附上一份 AI 参与清单，以衡量并说明 AI 在我们研究中的作用。表 3 展示了其中的片段。我们将系统在实验设计、执行和写作方面的自主性评为最高级别（D 类， $\geq 95\%$ AI），而人类参与（C 类，50-95% AI）主要出现在初始假设定义阶段。完整论文、生成的代码、具体的智能体日志以及完整清单均可在 OpenReview [5] 上查阅。

3 观察到的失效模式与缓解措施

通过实验，我们识别出六种在不同研究尝试中反复出现的关键失效模式。这些模式揭示了当前 LLM 在自主研究能力上的系统性局限。以下小节将结合具体示例和缓解策略，逐一详述每种失效模式。

表 3: 按研究阶段划分的 Idea AS-1 的 AI 参与清单 (Agents4Science 评分标准)

研究阶段	评分	角色描述
Hypothesis Development	C	<i>Mostly AI:</i> Initial search space defined by human; specific failure mode hypothesis and core questions generated by AI agents via paper mashing.
Experimental Design	D	<i>AI-Generated:</i> Full experimental plans, baseline choices, and metric definitions generated by Gemini 2.5 Pro; human role limited to high-level approval.
Execution & Analysis	D	<i>AI-Generated:</i> End-to-end coding by Claude Code. Datasets handled autonomously. Human intervention limited to providing HuggingFace tokens.
Paper Writing	D	<i>AI-Generated:</i> Narrative structuring and figure generation driven by AI. Human role restricted to final “sanity check” and minor copy-editing.


评分标准: A: $\geq 95\%$ Human, B: 50–95% Human, C: 50–95% AI, D: $\geq 95\%$ AI.

3.1 训练数据偏差

研究通常依赖于专门的协议、库和数据集，这些并不广泛使用，但模型始终默认采用其训练数据中流行的替代方案。

训练数据。这种失效模式在基础设施设置、库选择和数据集处理中系统性地显现，模型始终用推测的记忆训练模式覆盖明确的指令。

在 Modal 设置的情况下，Claude Code 会始终使用过时的 Modal 挂载命令来使本地文件可访问，并默认使用本地文件路径而非 Modal 存储，忽略 plan.md 和 agent.md 文件中提供的更新 API 文档和指令。此外，它还会回归到过时的研究库，尽管有明确的版本和搜索要求，并忽略数据集特定的字段结构，而采用标准格式。图 4 展示了在三个实现上下文中这种系统性覆盖，附录 A 中按想法实现提供了详细示例。



专门研究此问题的研究人员也发现了设置库和环境时的类似错误 [6] [7]。我们通过在早期阶段避免 **图 4: 训练数据偏差模式：在长上下文中，记忆模式对提示指令的系统性覆盖。**

锚定于低层次细节（如要使用的库和数据集）来解决此问题，


并在执行阶段提供特定库使用和库文档的指令。

即使经过这两项修改，在出现错误的情况下，实验执行模型仍常常将库导入诊断为原因，并回归到使用训练数据中提到的版本，坚持认为这才是正确的方法。

训练数据中的这种偏差可能以比使用库和数据集时的错误更隐蔽的方式显现。梅赫塔布·索尼（Mehtaab Sawhney）和马克·塞尔克（Mark Sellke）在关于使用 GPT-5 Pro 研究埃尔德什（Erdős）问题的工作中观察到：“虽然模型能够提出看似合理的证明策略，但它们往往……对现有方法的能力过于自信。”他们指出这并不令人意外，因为关于“更明显的策略”为何行不通的讨论“在数学文献本身中基本缺失”，因此在训练数据中也缺失。在这种情况下，训练数据的偏差导致了领域品味的失败，以及无法识别他们所称的问题的“负空间”[8]。我们在第 5 节讨论这种缺失数据对未来系统设计的启示。

3.2 实现漂移

实现漂移表示 当人工智能系统遇到技术复杂性或执行障碍时，会系统性地偏离原始研究规范，转向更简单、更熟悉的解决方案。这在实验执行阶段尤为突出。模型不是解决实现挑战的根本原因，而是逐步简化架构并放弃核心创新，以获得表面上类似于预期研究贡献的可运行代码。



这在训练循环等长时间运行的任务中尤为突出，此时编码助手常常会超时，并将耗时过长视为需要改用其他实现来修复的错误，从而偏离研究构想、假设和计划文件中的指令。图 5 以“构想”为例展示了这一情况

图 5：实现漂移模式：在创意工作记忆-1 的执行障碍期间，所提实现的简化。

WM-1 实现。

然而，偏离实现的倾向并非仅由时间相关错误所致。它同样出现在其他长上下文任务中，例如在有限的输出长度内重写基线和实现复杂代码。在每种情况下，由于任务包含多个步骤，实验执行智能体（Experiment Execution Agent）在不同的节点选择实现更简单的内容或以“样本”/“测试”模式运行，这也导致了流程下游的失败。附录 A 中详述的想法工作记忆-2（Idea WM-2）实现体现了这种级联模式，其中实现梦想家（Dreamer）基线时的单个错误触发了渐进式简化，而非根本原因调试。

为应对这些挑战，我们采用了两种关键方法。首先，我们遵循组合式假设生成方法，而非依赖单一假设，这使我们能够通过准备后续实验来规划一个实验中可能出现的失败。其次，我们实现了一个流程，在该流程中，代码文件先生成，然后在执行前明确验证和测试错误，将代码生成和执行视为不同的任务。这通过计划文件（plan.md）和智能体文件（agent.md）中的明确指令强制执行。

3.3 记忆与上下文问题

科学发现和实验是长期任务。它要求智能体在超过当前模型有效可靠性范围的时间段内保持连贯性[9]。这就是为什么我们看到大语言模型（LLM）在长上下文、长持续时间任务上的许多常见约束在我们的研究系统中显著显现。随着会话的推进和上下文工件的积累，模型系统性地丢失了对先前决策、已建立配置和已完成工作的跟踪，导致冗余实现和不一致的实验设置。

这种失败模式在基线实现期间最为明显，该过程需要大量的超参数管理。编码智能体没有参考规划层面的细节，而是在生成或运行相关代码时声明自己的超参数并附上注释。这导致了实验条件对人类协调者来说既不清楚，又极难在没有建立文件管理系统的情况下进行组织。

我们通过引入一个配置文件并在代理说明文件中提供清晰的引用说明，同时使其成为所有特定任务提示的持久组成部分，解决了这一问题。不过，这仍然遇到了在训练数据偏差失败模式中提到的代理说明文件的局限性。

此外，在编码和论文撰写阶段，长上下文问题也浮现出来，当我们需要引用项目中较早的细节时。在许多情况下，实验执行代理会错误引用开始时定义的函数，导致诸如

函数签名不正确和度量计算不匹配等错误。在论文撰写过程中，代理会忘记查阅最初版本的想法和假设文件来构思论文大纲，而是依赖最近的文件和结果。这最终导致论文读起来像是一系列实验的罗列，缺乏起源故事和动机。

我们对此的解决方案是，像人类科学家那样，启用越来越多的类似记忆的上下文抽象，包括在每个克劳德代码会话结束时维护实验进度和实验执行日志的配置（图 7）。

尽管依赖克劳德代码编写的会话日志有助于记忆和上下文管理，但随着会话日志的增长，另一个问题出现了：管理由大语言模型生成的文件数量不断增加。这指出了在基于语言模型的自主科学系统中进行文件和目录管理的必要性。

3.4 过度兴奋与尤里卡本能

这种失败模式在论文大纲、修订和实验输出评估阶段最为明显。模型在明显失败的情况下仍持续报告成功，并夸大其研究贡献的重要性。图 6 展示了在我们多次尝试中这种失败模式出现的一些方式。




图 6：过度兴奋与尤里卡本能。左：在执行过程中，代理在明显的实验失败情况下仍声称成功。右：在论文撰写过程中，有限的结果被夸大为过度的贡献。

我们注意到，即使结果显示出明显的退化或失败，生成的文本也只关注顶层的积极指标，忽略了根本性问题，这可以追溯到依赖实验执行阶段生成的报告文件来评估输出，而不是检查实验流程中的原始日志。论文撰写阶段通过夸大新颖性和范围加剧了这些问题。在论文撰写过程中，Claude Code 会将工作描述为某个领域的“首篇论文”，或声称具有“开创性贡献”，而不管实际的研究成果如何。

这反映了古德费尔团队所识别的“p 值操纵与灵光乍现”行为 [10]，并与布贝克等人的发现一致，研究者指出模型会“引入数值胶带”来掩盖错误，并“在数值信号显然仍是噪声时自信地宣告胜利”[8]。这种“取悦倾向”要求回路中的人类具备足够的专业知识，以拒绝模型给出的简化方案。

这种过度乐观的倾向也体现在反馈整合过程中，系统变得过于遵循流程而缺乏适当的评估。语言模型智能体如何整合反馈本身就是一个完整的研究领域，而大语言模型智能体通过反馈对其它自动化研究者进行“沙袋”操作所构成的安全威胁，已由 Anthropic 团队进一步探讨 [11]。

我们认为这些模式很可能源于大语言模型训练中基于人类反馈的强化学习阶段，在该阶段模型因顺从和帮助人类而获得奖励，从而产生偏向乐观解读和积极框架的偏差，即使证据表明并非如此。这些训练目标显然不符合自主科学系统的要求，后者应面向科学怀疑精神、追求真理以及检测确认偏差。

3.5 领域智能不足

研究论文展示了完善的最终配置，但省略了从假设到可行实现所需的隐性知识。人工智能系统始终难以掌握经验丰富者所拥有的未成文工艺知识。

研究人员视为理所当然。这些差距在需要科学判断而非纯粹编码能力的阶段表现得最为突出，例如假设生成、计划生成和实验输出评估。

从假设转向实现计划时，系统缺乏足够的领域深度来预测输出并识别失败模式。此外，模型未能做出关键决策所需的判断，例如选择与任务需求对齐的基线。例如，在想法 WM-2 中选择一个连续控制任务与离散输入模型基线。

计划设定了高层次目标，但忽略了使实现变得困难的数学和概念障碍。这造成了问题，尤其是对于需要深厚领域专业知识的研究想法。两个想法 WM-1 和 WM-2 都需要高级领域知识来组合复杂部分，例如平衡随机世界模型与可微分树搜索规划器，或向基线添加新的损失项。模型缺乏理解这些元素应如何交互或成功修改经过验证的架构的专业知识。

每个子领域都有独特的流程需求：强化学习需要回滚，人工智能对齐与安全需要记录响应，模型难以直觉判断哪些工件对调试和验证重要，即使在计划生成阶段有详细指令。

除了实现差距之外，模型还缺乏对实验有效性阈值的判断——例如，当基线性能比既定基准低 95% 时仍继续进行假设检验，使得任何比较分析在科学上毫无意义。

3.6 缺乏科学品味

模型始终未能识别实验设计和统计方法论中的根本缺陷。这些方法论差距出现在假设生成和实验输出评估阶段。

我们最初仅依赖生成一个最小可行假设作为流程的一部分。然而，我们很快意识到这种方法对于研究输出是不够的。依赖单一假设造成了过高的项目风险。即使是微小的实现错误也会触发完整的想法修订，而不是假设调整。因此，我们采用了假设生成的投资组合方法，创建全面的假设套件，允许在个别实验失败时进行假设级别的调整，而不是完全放弃想法。更多细节请参见第 3 节关于实现漂移缓解的内容。

这一局限性在 WM-1 假设过于简单而无法得出任何结论时变得明显，且模型未能捕捉到这一点，即使在反思阶段也是如此。问题因无关的复杂度而进一步复杂化，例如 50,000 的深度参数，这造成了计算负担却无科学价值。即使有明确指令，智能体对统计有效性的意识仍不足。想法 WM-1 仅使用一个随机种子运行。专家对计算复杂度的担忧在规划或假设生成阶段的任何时刻都未被处理，而且该方法甚至在 6 小时、1 个 GPU 的限制内被推荐，尽管它在计算上不可行。

问题模式在各想法中持续存在。想法 WM-2 的实验设计存在根本性逻辑错误。生成的计划假设使用静态数据帧进行离线训练。然而，Dreamer 需要在线学习。类似地，想法 MARL-1 显示系统未能

解读输入种子论文的未来工作部分。最后，AS-1 想法中的退化输出直到实验输出评估阶段的人工干预才被标记。

4 面向人工智能科学家系统的设计要点

我们对失败模式的分析揭示了构建稳健自主研究系统的四项设计原则。这些原则应对了跨研究领域和实现尝试中的关键挑战。

1. 从抽象开始，后续再具体化

领域专业知识和技术细节应在整个研究工作流程中逐步引入。提示和生成内容应随着过程推进而变得更加具体。在构思阶段保持高层次的抽象，以防止过早锚定于特定实现。确保在后续实现阶段再进行具体化，以避免在早期阶段产生错误锚定。这对于确保新颖性和避免抄袭也至关重要，因为模型可能输出已经完成的研究，仅做了轻微的语言改动。

在规划期间，避免使用技术细节，例如特定数据集、度量指标、数学思想以及特定领域的实践，如记录强化学习的回放或数据收集协议。虽然这些细节对执行很重要，但过早引入这些上下文往往会导致模型依赖训练数据中的旧库和方法，而不是识别或推理最新的解决方案。

2. 全面验证

验证必须贯穿研究流程的每个阶段——从想法和假设的生成到代码和结果的生成。在每个相关阶段使用验证器或批评代理有助于避免概念或实现错误，并防止错误级联。

为人工智能科学家系统进一步设计验证的两个关键维度是：过程验证与结果验证，以及正确性验证与科学贡献验证。后者包括确保规划、构思和输出审查等关键阶段的可复现性。Tang 等人提出的技术执行评估和科学贡献评估框架 [12] 为评估人工智能科学家的输出提供了互补的视角。

在收集实验结果时，应基于原始数据而非大语言模型的解释，因为大语言模型倾向于在错误中解读出信号，或对明显平庸的结果过于乐观——Goodfire 团队称之为 p 值操纵和灵光乍现 [10]。在实践中，这意味着确保实验输出评估要么以编程方式审查原始日志、

统计指标和原始数据输出，要么如果使用大语言模型评估器，则通过系统提示或上下文注入严格指示它们关注这些原始输出，而非摘要或报告文件。

验证不仅对于确保正确性必不可少，而且也是人在回路的一个接触点。例如，根据我们的经验，构建一个验证器来审查推荐的可视化内容，使我们能够移除一些虽然从现有结果中自然生成、但对论文核心叙事并非至关重要的可视化。对我们而言，在执行过程中，验证也成为为训练模型和数据收集等长时间运行任务提供可观测性的一种方式。我们通过在实验计划生成阶段加入明确指令以包含测试来实现这一点。

3. 为失败与恢复做好规划

科学发现是一项处于任务复杂度前沿的长期任务，大语言模型及大语言模型驱动的代理在此仍面临局限性，导致错误累积。在研究执行过程中，人类研究者会做出许多微观决策，这些决策必须为自主大语言模型预先指定，以避免失败。

这意味着多轮智能体任务设计优于零样本生成。这确保了计划包含足够的细节，以避免在流程后期出现漂移或错误。除了外部验证和批判之外，反思和扩展思考也是在执行前确保足够清晰度的有效方法。

我们发现将所有编码任务拆分为模块化任务可以防止错误级联。一种方法是分离代码生成与代码执行，确保可以内置验证钩子。另一种是 Goodfire 团队使用 Jupyter 笔记本的方式，保持对错误的自然单元级限制 [10]。

我们使用 agent.md 在任务执行期间传递系统级指令，以遵循通用的良好科学编码原则并确保正确性。这包括为长时间任务保存检查点的指令、在不同规模添加测试以在完全执行前查看管道中的水流情况、为代码中所有重要度量添加详细日志记录，以及避免第 3 节中提到的长上下文和内存相关错误的额外具体指令。

除了自主执行的韧性之外，将生成与执行分离还能够在关键阶段进行人工审查和干预。例如，当可视化生成与论文集成分离时，我们可以在最终手稿中出现无用的条形图之前进行审查和删除，从而支持从实验执行到论文写作阶段的人在回路审查。

4. 记录一切

从自主科学智能体的输出到运行实验中使用的所有可能度量，一切都应全面记录。这包括对 LLM 实际响应的常规张成和迹日志记录，以及使智能体能够创建自己的文件。这两个目的：支持长时间自主执行以及后续的人工/LLM 审查和验证。

对我们而言，这意味着通过写入工具支持第 1 节中列出的所有上下文工件，并在实验执行期间实施如图 7 所示的全面会话日志记录指令，以及在计划生成阶段针对领域特定的主要和次要实验度量实施具体的日志记录指令。我们还明确指示论文大纲与写作智能体在综合结果的同时综合过程工件，以保持叙事连贯性并捕捉科学发现的过程与演变。这种全面的日志记录实现了我们在第 4 节中提到的双重评估框架。

```
"Update the /claude_code_logs directory with a session_log file for this session. Document a comprehensive but concise record of: Work completed (specific tasks finished), Decisions made (technical choices including rationale), and Artifacts edited or created (exact filenames of code created or modified). Create a new entry strictly and do not delete, overwrite, or summarise previous session logs. Focus exclusively on actions taken. Do NOT include "Next Steps" or forward-looking plans."
```

图 7：会话日志记录指令：用于在自主智能体会话中维护详细研究执行记录的全面提示模板。

5 讨论与更广泛的启示

科学发现的完全自主目前仅存在于未来，不仅从能力角度看，也从人类偏好角度看。即使以最大自主性为目标，我们仍在关键节点依赖人类干预。这些节点包括想法审查、论文写作以及实验执行过程中的元提示。这一模式在现有的人工智能科学家系统中一致出现。Sakana 的方法要求研究人员从 40 个由人工智能生成的概念中挑选 3 个有前景的想法 [1]。类似地，谷歌的联合科学家系统要求科学家指定的研究目标作为入口点 [4]。领域专家很可能仍将参与其中，以进行微调、纠偏和验证。

尽管像 OpenAI 这样的主要实验室正在进入人工智能用于科学发现的领域，但它们明确认识到需要人类专业知识，寻求聘请“世界级学者”，这些学者“完全被人工智能所吸引”，与人工智能模型并肩工作 [13]。这种招聘策略强化了当前的目标，即创建用于有效人机协作的智能体和工具，而不是自主科学家。来自大型实验室的近期工作，如早期科学加速实验

借助 OpenAI 的 GPT-5，验证了这一方法，展示了智能体能够独立重新发现已知结果并进行深度文献检索，同时充当“研究合作者”和“知识渊博的研究导师”，但正如菲尔兹奖得主蒂莫西·高尔斯所指出的，“我们尚未达到大语言模型可能提出解决难题的主要思路的阶段。[8]”

但我们绝不能低估人类与大语言模型（Large Language Model）协作带来的加速效应。物理学家布莱恩·基思·斯皮尔斯（Brian Keith Spears）指出，这种协作将原本六个月的流程压缩至六小时——实现了“1000 倍”的加速——实际上使他成为“一人专家军团”[8]。这种协作对于启动科学方法的数据循环也尤为关键。

科学发现不仅超出了当前大语言模型的训练分布，而且可以合理地假设，科学研究工作流程的产物在训练数据中明显缺失。例如，没有记录的阅读清单或专家文献综述轨迹可用于训练或基准测试文献搜索智能体。可以利用已发表论文的引用列表来近似，但这些是最终入选的论文，而更具关键性的技能——训练智能体判断应忽略哪些参考文献——可能更为重要。

我们也缺乏失败尝试的记录。正如梅赫塔布·索尼（Mehtaab Sawhney）和马克·塞尔克（Mark Sellke）所指出的，“当前模型在感知数学的‘负空间’方面仍然有限……这并不令人意外，因为此类讨论在数学文献本身中基本缺失；数学家不会系统地记录为什么某些问题难以触及，为什么更明显的策略行不通，或者为什么某些技术本质上无法解决某类问题”[8]。让专家首先在包含工具和多智能体编排的平台上使用这些大语言模型，能够收集训练数据，以训练未来能够自主执行这些任务的智能体。

这些进展受到长时程任务和上下文需求中根本性瓶颈的制约。科学发现要求在数周乃至数月内保持连贯性和上下文窗口。这远远超出了当前模型的可靠性。截至 2025 年 11 月，即使是最先进的系统，如 GPT-5.1-Codex-Max，其时间跨度也仅约 2 小时 40 分钟，成功率为 50%[9]。这表明，在完全自主的科学家出现之前，我们很可能会先看到较小的模块，为下一轮长时程科学专业化构建数据。

这里的数据局限性不仅限于训练，也延伸到了评估环节。目前正在创建多个基准。其中一些值得注意的包括艾伦人工智能研究所（AllenAI）的 AstaBench，它为处理特定科学研究任务的特定智能体提供基准测试 [14]，以及 ScientistBench，它专注于更广泛的科学推理能力。但即使是 ScientistBench[12] 也只包含 22 篇论文和 28 个任务，而且大多极具引导性。这凸显了评估自主科学时数据的局限性。此外，ScientistBench 中复杂的匿名化过程也指出了评估中的一个挑战，即如何将模型能力与

记忆的训练数据区分开来。这个问题很重要，因为在缺乏鲁棒评估系统的情况下，语言模型可能会生成抄袭的科学成果。[15]

通过增加大语言模型（LLM）之间的交互，可以在科学工作中获得进一步的收益。例如，最近的例子展示了专用智能体系统的潜力。PHYSICS SUPERNOVA 展示了人工智能智能体通过具有领域特定工具的管理智能体，在 2025 年国际物理奥林匹克竞赛（IPHO）中与金牌得主相匹敌 [16]。此外，多智能体虚拟实验室也可以同步领域特定工具，以加速发现 [17]。

范式似乎是将科学发现分解为离散的能力。这些能力可以通过强化学习（RL）训练到更小、更专用的模型中。这种分解使得复杂的科学工作流程能够作为具有明确评分标准和奖励函数的任务来学习。较大的实验室将竞相获取需要与领域专家合作的元能力。较小的实验室将使用开源模型和强化学习，为开源智能体和领域特定模型创建自己的基准。这为不久的将来的开放科学提供了一个令人信服的理由，包括出版物、共享结果以及所有能够促进更广泛科学进步的输入和材料。

6 局限性与未来工作

我们的自主研究系统既展示了人工智能驱动的科学发现的前景，也展示了其当前的边界。几个关键的局限性限制了我们研究结果的普适性和鲁棒性。

我们将研究范围限定于计算机器学习研究，排除了需要超出数字计算范围的实验基础设施的物理科学。这一对最小脚手架方法的必要约束，为自主科学发现设定了一个显著边界。由于我们的主要目标是会议投稿而非受控实验，我们没有将架构迭代记录为系统性的消融实验。这种方法使得难以分离出哪些设计变更导致了我们的成功与三次失败。我们的实验规模有限——仅在三个机器学习子领域中涉及四个研究想法，每个想法仅进行单次实现运行，而非采用最佳 N 方法。如此小的样本量无法对失败模式的普遍性或缓解措施的有效性得出稳健的统计结论。已识别的失败模式是通过定性观察而非系统性的定量测量得出的，这限制了我们衡量其重要性或在不同研究背景下出现频率的能力。

此外，我们仅发布了提示词和选定的系统输出，而非完整的系统架构，这限制了可复现性以及他人基于我们方法进行构建的能力。

在未来的工作中，我们将采取以下具体步骤来解决上述局限性。我们将从受控实验开始，以量化这些失败模式的出现，并验证我们提出的缓解策略的有效性。我们计划将方法扩展到数百个研究想法，涵盖多样化的科学子领域，以建立观察结果的统计有效性。我们还计划将智能体架构作为开源工具发布给研究社区，超越仅共享提示词的方式，以支持更广泛的实验和改进。此外，我们将建立专家与大型语言模型协作会话中科学工作流程数据的系统化收集，以基准化性能改进并训练领域特定的研究智能体。最后，我们旨在开发用于失败模式和超越会议接收率的研究质量度量的定量测量框架，同时优化人机协作研究模式，这可能开启科学方法数据循环，实现迭代能力提升。

参考文献

- [1] Yutaro Yamada et al. *The AI Scientist-v2: Workshop-Level Automated Scientific Discovery via Agentic Tree Search*. 2025. arXiv: 2504.08066 [cs.AI]. URL: <https://arxiv.org/abs/2504.08066>.
- [2] Alexander Novikov et al. *AlphaEvolve: A coding agent for scientific and algorithmic discovery*. 2025. arXiv: 2506.13131 [cs.AI]. URL: <https://arxiv.org/abs/2506.13131>.
- [3] Long Li et al. “Chain of ideas: Revolutionizing research via novel idea development with llm agents”. In: *arXiv preprint arXiv:2410.13185* (2024).
- [4] Juraj Gottweis et al. *Towards an AI co-scientist*. 2025. arXiv: 2502.18864 [cs.AI]. URL: <https://arxiv.org/abs/2502.18864>.
- [5] Dhruv Trehan. “The Consistency Confound: Why Stronger Alignment Can Break Black-Box Jailbreak Detection”. In: *Open Conference of AI Agents for Science 2025*. 2025. URL: <https://openreview.net/forum?id=B6ZrLXou3u>.
- [6] Avi Arora, Jinu Jang, and Roshanak Zilouchian Moghaddam. *SetupBench: Assessing Software Engineering Agents’ Ability to Bootstrap Development Environments*. 2025. arXiv: 2507.09063 [cs.SE]. URL: <https://arxiv.org/abs/2507.09063>.
- [7] Aleksandra Eliseeva et al. *EnvBench: A Benchmark for Automated Environment Setup*. 2025. arXiv: 2503.14443 [cs.LG]. URL: <https://arxiv.org/abs/2503.14443>.
- [8] Sébastien Bubeck et al. *Early science acceleration experiments with GPT-5*. 2025. arXiv: 2511.16072 [cs.CL]. URL: <https://arxiv.org/abs/2511.16072>.
- [9] METR. *Details about METR’s evaluation of OpenAI GPT-5.1-Codex-Max*. <https://evaluations.metr.org//gpt-5-1-codex-max-report/>. Nov. 2025.
- [10] Mark Bissell, Michael Byun, and Daniel Balsam. *You and your research agent: Lessons from using agents for Interpretability Research*. Oct. 2025. URL: <https://www.goodfire.ai/blog/you-and-your-research-agent>.
- [11] Johannes Gasteiger et al. *Automated Researchers Can Subtly Sandbag — alignment.anthropic.com*. <https://alignment.anthropic.com/2025/automated-researchers-sandbag/>. 2025.
- [12] Jiabin Tang et al. *AI-Researcher: Autonomous Scientific Innovation*. 2025. arXiv: 2505.18705 [cs.AI]. URL: <https://arxiv.org/abs/2505.18705>.
- [13] Kevin Weil. *Tweet on Hiring Domain Experts for OpenAI for Science*. 2025. URL: <https://x.com/kevinweil/status/1962938974260904421?s=46>.
- [14] Allen AI. *AstaBench: Rigorous benchmarking of AI agents with a holistic scientific research suite — Ai2 — allenai.org*. 2025. URL: <https://allenai.org/blog/astabench>.
- [15] Tarun Gupta and Danish Pruthi. *All That Glitters is Not Novel: Plagiarism in AI Generated Research*. 2025. arXiv: 2502.16487 [cs.CL]. URL: <https://arxiv.org/abs/2502.16487>.

- [16] Jiahao Qiu et al. “Physics Supernova: AI Agent Matches Elite Gold Medalists at IPhO 2025”. In: *arXiv preprint arXiv:2509.01659* (2025).
- [17] Kyle Swanson et al. “The Virtual Lab of AI agents designs new SARS-CoV-2 nanobodies”. In: *Nature* (2025), pp. 1–3.
- [18] Han Wang et al. *Learning to Communicate Through Implicit Communication Channels*. 2025. arXiv: 2411.01553 [cs.MA]. URL: <https://arxiv.org/abs/2411.01553>.
- [19] Darius Muglich et al. *Expected Return Symmetries*. 2025. arXiv: 2502.01711 [cs.MA]. URL: <https://arxiv.org/abs/2502.01711>.
- [20] Zhengyao Jiang et al. *AIDE: AI-Driven Exploration in the Space of Code*. 2025. arXiv: 2502.13138 [cs.AI]. URL: <https://arxiv.org/abs/2502.13138>.
- [21] Weipu Zhang et al. *STORM: Efficient Stochastic Transformer based World Models for Reinforcement Learning*. 2023. arXiv: 2310.09615 [cs.LG]. URL: <https://arxiv.org/abs/2310.09615>.
- [22] Dixant Mittal and Wee Sun Lee. *Differentiable Tree Search Network*. 2024. arXiv: 2401.11660 [cs.LG]. URL: <https://arxiv.org/abs/2401.11660>.
- [23] Chenglei Si, Tatsunori Hashimoto, and Diyi Yang. *The Ideation-Execution Gap: Execution Outcomes of LLM-Generated versus Human Research Ideas*. 2025. arXiv: 2506.20803 [cs.CL]. URL: <https://arxiv.org/abs/2506.20803>.
- [24] Chenglei Si, Diyi Yang, and Tatsunori Hashimoto. *Can LLMs Generate Novel Research Ideas? A Large-Scale Human Study with 100+ NLP Researchers*. 2024. arXiv: 2409.04109 [cs.CL]. URL: <https://arxiv.org/abs/2409.04109>.
- [25] Pietro Mazzaglia et al. *GenRL: Multimodal-foundation world models for generalization in embodied agents*. 2024. arXiv: 2406.18043 [cs.AI]. URL: <https://arxiv.org/abs/2406.18043>.
- [26] Danijar Hafner et al. *Dream to Control: Learning Behaviors by Latent Imagination*. 2020. arXiv: 1912.01603 [cs.LG]. URL: <https://arxiv.org/abs/1912.01603>.
- [27] Haoyang Li et al. *LLMs Caught in the Crossfire: Malware Requests and Jailbreak Challenges*. 2025. arXiv: 2506.10022 [cs.CR]. URL: <https://arxiv.org/abs/2506.10022>.
- [28] Jiayu Liu et al. *Revisiting Epistemic Markers in Confidence Estimation: Can Markers Accurately Reflect Large Language Models’ Uncertainty?* 2025. arXiv: 2505.24778 [cs.CL]. URL: <https://arxiv.org/abs/2505.24778>.

A 深入探讨：研究想法与轶事

在本附录中，每个小节遵循一致的结构：由我们的想法生成智能体生成的完整想法规范、来自原始论文作者的专家验证反馈，以及记录自主执行过程中具体失败模式和系统响应的详细实现轶事。在整个附录中，块引用代表我们系统概述中描述的 LLM 智能体的直接输出或执行日志文档的摘录，提供了研究尝试期间系统行为的真实示例。我们还要感谢种子论文的作者，他们对早期研究想法提供了宝贵的反馈；任何剩余的错误或误解完全由我们自己承担。

A.1 MARL-1：多智能体强化学习中的零样本协调

这个想法源于在 ICLR 2025 上结合多智能体强化学习中的隐式通信协议 [18] 和零样本协调 [19] 研究。表 4 详细说明了由我们的想法生成智能体生成的完整 idea.md 文件的主要部分。

表 4： MARL-1：多智能体强化学习中的零样本协调 - 在实现中被拒绝

想法：用于零样本协调的元自适应隐式通信协议（Meta-AICPs）	
Problem and Motivation	Current RL agents, while capable in specific tasks with specific partners, are brittle. They struggle with novel teammates, task variations, and especially in situations requiring emergent communication and the dynamic formation and adaptation of conventions. For AI agents to achieve truly fluid and generalizable collaboration in open or ad-hoc team settings, they must robustly coordinate with novel, independently trained partners who may employ unknown or diverse implicit communication protocols. This addresses the fundamental 'double adaptation problem' in MARL: adapting to both environment dynamics and the evolving policies and communication conventions of other agents.
Proposed Approach	Building on work done on Implicit Channel Protocols [18], Agents meta-learn adaptive strategies to rapidly infer and co-create/align their internal P-mappings (the mapping between scouting actions and messages) when encountering novel partners. This moves beyond adapting to fixed partner strategies towards learning how to adapt the communication system itself. Meta-learning distributions over protocol spaces or adaptive strategies for P, rather than relying on fixed point estimates or pre-coordination with novel partners who lack a shared co-training history.
Key Innovation	Extends ZSC beyond action policies to the communication system itself - agents coordinate how they communicate and how to adapt how they communicate. Meta-learning over protocol spaces addresses the need for true convention emergence rather than just partner strategy inference. Dynamic protocol adaptation and emergence during novel partner interaction, with neural architecture disentangling convention-agnostic task policy from convention-specific protocol adapter module.
Concrete Example	In Hanabi with three canonical P-maps (conservative, aggressive, random), Meta-AICP agents evaluate ZSC performance against diverse partners using Protocol Divergence Score and Information Flow Rate metrics. Agents adapt their scouting action mappings based on inferred partner protocols, maintaining communication richness while achieving robust coordination with previously unseen protocol variants.
Potential Pitfalls	Potential trade-off in expressiveness vs. generalization - adapted protocols might not achieve the same peak level of nuanced, high-bandwidth communication as protocols developed via intensive co-training. Dependence on quality of meta-training distribution diversity and representativeness. Performance against partners with radically different, out-of-distribution P-mappings remains uncertain.

专家验证：当我们带着这个想法联系种子论文的作者时，他们对系统在解释其原始论文的未来工作部分时的失败以及潜在的失败模式表示担忧，其中许多失败模式也由想法生成智能体在生成的想法文本中识别出来。

他们指出，当他们提到“动态识别或设计通信映射的未来工作”时，他们指的是“基于公共观察或任务”，而不是“具有未知映射的全新伙伴”。我们认为这是想法生成智能体缺乏领域专业知识并过于宽泛地解释论文中原始陈述的另一个实例。

他们确实指出，该想法“触及了一个具有挑战性且重要的问题”，并且“对所述方向进行形式化与实证检验……可能产生有用的洞见。”他们还称赞了选择花火（Hanabi）设定以及从其 ICP 工作中识别出的基线，认为它们是“坚实的锚点”。

实现与失败模式：考虑到关于检验和形式化该主张价值的反馈，我们仍将该想法推进到假设生成与实验规划阶段。

在此阶段，我们仍为每个研究想法生成一个最小可行假设——每个项目仅检验一个关键假设，这与我们后来采用的包含全面假设套件的组合方法不同（如第 3 节所述）。我们还采用了单文件编码方法（类似于 AIDE [20]，一种自动化代码生成系统），指令是在单个 Python 文件中生成一个完整的实现。

此处出现了两种主要的失败模式：

模型试图将复杂实现全部塞入 单个文件，导致奖励黑客行为或实现漂移，即简化实现。在两次独立的运行中，模型输出的代码文件包含以下内容：

“注意：该实现侧重于清晰度和高层研究机制，而非最先进的游戏性能——在此简短参考原型中，预计不会达到令人印象深刻的花火得分。”

注意：这是任务规范中所述计划的快速且安全的 MVP
骨架实现……所有繁重计算都由--fast 标志保护。

环境设置失败。模型始终回退到规范的 DeepMind hanabi-learning-env，该库已不再维护。即使反复失败并指示使用替代方案，在遇到非导入错误时，模型也会将

错误解释为非 hanabi-learning-env 导入所致，并将正确的库导入回退为错误的过时版本。

这说明了第 3 节讨论的训练数据偏差失效模式，即模型依赖记忆模式而非使用当前信息。这也向我们指出，开箱即用的 AIDE 不足以用于研究代码实现，因为研究代码实现比训练 Kaggle 挑战模型更具迭代性，并且底层实现代理需要访问互联网并获取最新信息，而不仅仅依赖工作流上游生成的零样本 LLM 响应。

A.2 WM-1：随机世界模型中的可微规划

该想法的来源是整合了 NeurIPS 2023 关于随机世界模型的工作 [21] 和一篇已撤回的 ICLR 2024 关于潜在状态空间中可微树搜索的投稿 [22]。表 5 详细列出了我们的想法生成代理生成的完整 idea.md 文件的主要部分。

表 5：WM-1：随机世界模型中的 DTS 规划 - 在实现中被拒绝

想法：在随机世界模型中进行可微树搜索以用于规划（S-DTS）	
Problem and Motivation	DTS and similar methods are designed for deterministic worlds. When deployed in non-deterministic environments, their deterministic world models fail to capture environmental stochasticity, leading them to learn an “average” world dynamics. While methods exist for learning stochastic world models (STORM), they are typically trained separately from the planner, which prevents the planner and model from co adapting. This separation means the world model is not optimized for the specific states and transitions that are most critical for the planner’s decision-making process.
Proposed Approach	Integrating a Stochastic World Model, inspired by STORM’s architecture, directly into the DTS framework. Joint optimization provides a powerful, targeted learning signal - the overall planning loss backpropagates through the entire differentiable search process, including sampled transitions from the WM.
Key Innovation	Bridging the gap between deterministic planners and stochastic environments. While deterministic DTS cannot represent or plan for multiple possible outcomes, and separately trained stochastic models miss the key insight of DTS by optimizing for global prediction error rather than task-relevant regions, S-DTS integrates VS-WM directly into the DTS framework. The world model learns to be an accurate predictor specifically for transitions that matter most for making good decisions, while the planner learns to account for the specific uncertainties expressed by its co-adapted world model.
Concrete Example	In “slippery ice” grid world where moving north can result in slipping left or right near a pit, DTS with ensembles might average paths or see variance but doesn’t reason about probability of each outcome, potentially choosing paths close to the pit if average seems safe. S-DTS’s expected backup rule explicitly incorporates low-probability, high-cost outcomes of slipping into the pit, learning to select safer paths further from pit even if slightly longer, demonstrating superior risk-awareness.
Potential Pitfalls	Training instability from interaction of REINFORCE, Gumbel-Softmax sampling, and VAE losses; computational overhead from triple loop of training steps, search trials, and MC samples; VS-WM might fail to learn true stochastic dynamics, especially rare events.

专家验证：对于这个想法，我们收到了联系过的两位主要作者之一的回复。他们指出这是一个值得探索的真正研究空白，并强调

“树搜索在 AlphaGo/MuZero/EfficientZero 中已展现出巨大潜力，但将其与类似 Dreamer 的基于模型强化学习方法相结合的研究却寥寥无几。”

他们对实现和调试的计算成本与技术复杂度表示担忧，并指出执行过程绝非易事，“否则为何在搜索潜力巨大的情况下，还没有人尝试增强 DreamerV3 呢？”他们总结道：“如果你们能向公众发布高质量的代码实现，应该会产生广泛的影响。”

除了种子论文的主要作者外，我们还与一位世界模型研究者分享了这个想法，该研究者曾在顶级 A* 会议发表过论文，并担任过审稿人。

他们的反馈与前一位专家的意见基本一致。他们也同样对实现的技术复杂度表示担忧，并指出了想法文本中一个具体且关键的遗漏错误：“论文将 STORM 的世界模型当作 DTS 确定性多层感知机的直接替代品”，并且“系统在设置部分遗漏了推理网络。”

不过总体而言，他们也同意“这个想法切入点很好”，能够产生一个“出色的世界模型”，有助于“长时程敏感控制应用”。

实现与失败模式：考虑到总体反馈积极，我们继续为该想法进行假设生成和实验规划。当时我们仍在使用最小可行假设提示，这意味着只需实现并验证一个假设，以捕捉所提研究想法中的关键不确定性和风险。

我们实现这一点的经验与专家评论一致——实现并非易事，遇到了许多技术挑战，尤其是在语言模型中有限领域品味和智能的典型失败模式。

复杂的世界模型架构涉及多个相互连接的组件——编码器、解码器、演员网络、评论家网络——产生了众多潜在的故障点，导致了多次格式不匹配错误。

“这是关键失败。我在可微展开过程中更新潜在状态的简化逻辑在数学上是不正确的，导致了矩阵乘法中的形状不匹配。”

训练循环的集成同样存在问题。规划器被设计用于单输入处理，但训练循环尝试进行批处理，造成了系统所描述的“计算上灾难性的”性能——工作量乘以批大小

并且在一小时内完成了不到所需步骤的 1%。

“错误 2：批处理逻辑（‘索引错误：维度超出范围’）：‘智能体规划 0’方法被设计为在单个状态上工作，但训练循环试图在一批状态上使用它，导致了索引错误。”

每个步骤规划长达 50,000 步的极长训练循环被传回，导致了超时，进而导致了实现漂移。这主要是由于模态时间限制，导致克劳德代码依赖于简化架构，而不是解决基础设施问题。

克劳德代码最终完全放弃了可微树搜索，转向标准的演员-评论家方法，保留了某种形式的联合优化，但这代表了与所提出方法的显著偏离。

新策略：我重写了训练脚本（train_s_dts.py），采用演员-评论家（Actor-Critic）方法。这保留了项目核心的“联合优化”思想，同时效率大幅提升。

幸运的是，我们的验证系统成功检测到了这种实现漂移。实验输出评估指出：

“名称‘随机可微树搜索（Stochastic-DTS）’对于实际实现的算法而言是一个误称，实际算法是一个更简单的可微多射击规划器。这可能具有误导性。训练脚本演变为演员-评论家方法，虽然是一个务实且技术上合理的选择，但代表了与初始假设文档可能推断出的内容存在显著偏差。这一过程应当被透明地记录。”

除了实现问题之外，实验设计本身也存在根本性缺陷。生成的假设过于简单，无法得出有意义的结论，并且所提出的随机可微树搜索模型和基线在冰湖（FrozenLake）环境中均达到了接近完美的 0.0 灾难率，使得假设无法被检验。这在实验输出评估报告中被识别为一个错误，报告指出“实验未能在有意义的性能区间内检验假设。”

虽然环境的选择过于简单，但其他几个选定的方面却过于复杂。例如，选择 50000 作为可微树搜索深度参数。这些同样指向了领域智能的缺失，而这种智能通常只有在研究者的经验决策中才能体现

在实验过程中。这也与斯坦福大学关于大语言模型生成假设的研究结论一致 [23, 24]。

其他方法学缺陷包括统计效度不足。测试仅使用一个随机种子运行，不足以恰当地证伪或接受假设。

修订提示最终建议开发更好地基于技术实现细节的假设，并在比冰湖更具挑战性的环境中进行测试。

A.3 WM-2：用感知损失替代像素重建 在世界模型中

该想法结合了 NeurIPS 2024 上关于多模态基础世界模型的论文 [25] 与 ICLR 2020 上开创性的 Dreamer 论文 [26]。表 6 详细列出了我们的想法生成智能体所生成的完整 idea.md 文件的主要部分。

表 6：WM-2：世界模型的感知损失训练目标——在实现中被拒绝

想法 SALVO：在视觉语言模型感知空间中训练世界模型以实现语义基础控制	
Problem and Motivation	Generative world models learn by compressing high-dimensional observations into latent space using pixel-level reconstruction loss, forcing the model to expend capacity on high-frequency visual details often irrelevant for semantic understanding. This “irreversible semantic compression” means subtle but task-critical visual cues that are easily distinguishable by a VLM can be lost in the world model’s latent representation, creating a semantic gap between the world model’s understanding and the VLM’s interpretation of task prompts.
Proposed Approach	Replace conventional pixel-level reconstruction loss entirely with a perceptual reconstruction loss defined within the embedding space of a frozen, pre-trained VLM. Instead of forcing the model’s latents to reconstruct raw observations, train them to reconstruct the VLM’s perception of the observations. This directly aligns the world model’s optimization with semantic concepts embedded in the VLM.
Key Innovation	Replacing pixel-reconstruction loss entirely with perceptual reconstruction loss in VLM embedding space. Instead of training world models to be good at reconstructing pixels, train them to be good at reconstructing VLM perceptions. This directly aligns the world model’s optimization with semantic concepts embedded in the VLM, creating latent representations inherently structured around VLM-salient features.
Concrete Example	For prompt “robot performing graceful pirouette,” GenRL’s pixel optimized world model learns “turning” without intrinsic concept of “grace,” resulting in mechanically efficient but ungraceful motion. SALVO’s VLM-optimized world model is forced to generate reconstructions capturing graceful vs. clumsy distinction, encoding necessary physical information for graceful-looking reconstruction and enabling policy to control semantically-meaningful latents.
Potential Pitfalls	Semantic dominance vs. physical accuracy leading to imagined rollouts structured around VLM-salient features; inheriting VLM inductive biases, blind spots, or artifacts; computational cost from VLM forward passes; training instability from replacing well-understood pixel-MSE with complex high-dimensional perceptual loss.

专家验证：我们联系了两篇种子论文的主要作者以获取反馈。第一位作者指出该想法“有趣且值得探索”。第二位作者对替换像素重建损失的技术顾虑以及其能否泛化到 MineRL 等特定领域之外表示了一些保留意见。

他们指出“这是 [他们] 最早尝试的事情之一”，并且根据他们的经验，“与基于重建的目标相比，感知损失可能无法捕捉到用于控制的细粒度信息”。他们确实强调，所识别的研究空白——“为强化学习寻找更好的世界模型学习目标”——是真实存在的。

实现与失败模式：考虑到这些全面的反馈，我们决定继续实现，因为我们看到了进行有意义实验和获得洞见的明确机遇。

该实现揭示了实验设计中的一个根本性逻辑错误，这一错误体现了第 3 节所讨论的领域智能失败。假设采用静态数据帧进行离线训练，但梦想家（Dreamer）需要在线学习——这一不匹配违反了核心算法假设。这导致探索与利用之间缺乏平衡、状态覆盖有限、动作与奖励之间无相关性，以及跨回合边界的转移不可能实现。在静态随机策略数据上训练从根本上削弱了基线的有效性，这一发现仅在实验输出评估阶段才被察觉。

核心问题源于重新创建梦想家基线的需求，这引发了一系列失败。由于第 3 节讨论的训练数据偏差，当提示中提到“现代机器学习实践”时，系统默认选择了火炬（PyTorch），尽管原始梦想家是在张量流（TensorFlow）中实现的。这迫使对基线进行完全重新实现，从而引入了多重不兼容性：火炬版本无法处理连续控制任务（如 CartPole-SwingUp），数据格式混乱以及编码器-解码器形状不匹配，而视觉语言模型（VLM）损失的集成进一步加剧了这些问题。

“初始转置卷积实现产生了错误的输出尺寸——第一次尝试： $31 * 31$ 输出（填充计算不正确），第二次尝试： $79 * 79$ 输出（仍然不正确），需要改用上采样方法以获得精确的 $64 * 64$ 输出。”

此外，在火炬中重新实现梦想家基线的过程中，出现了一个关键错误：无意中传递了虚拟奖励信号，而非实际环境奖励。这意味着评论家网络没有学到任何东西，而世界模型和行动者继续进行表征学习：

“世界模型和行动者正在学习（仅表征学习）——评论家没有可学习的内容，因为传递的是虚拟零奖励……梦想家 V2 架构需要真实奖励监督。发现我们传递的是虚拟奖励，而非实际的 CartPole 奖励。”

这一奖励错误贯穿了整个实验流程，导致行动者训练中出现梯度爆炸，绘图显示零值，评估指标失去意义，而实验执行代理通过在处理 CLIP 时调用 `.detach()` 破坏了核心创新，切断了从感知损失到世界模型解码器的梯度流，阻止了从重建目标中学习。

实验输出评估给出了最终结论：实现保真度评分为“低”，指出基线性能比既定基准低 95%，使得任何比较在科学上均无效。评估认为该实验“未能为有效测试创造必要条件”，且信号“完全被失效实验设置的噪声所掩盖”，需要在重新检验假设前进行完整的重新实现。

A.4 AS-1：语义熵作为越狱提示的信号

该想法是通过综合两篇 ACL 2025 的对齐论文得出的，一篇关于恶意软件请求中的越狱挑战 [27]，另一篇关于使用认知标记进行置信度估计 [28]。

表 7 详细说明了由我们的想法生成智能体生成的完整 `idea.md` 文件的主要部分。

表 7：AS-1：语义熵作为越狱提示的信号 - 成功完成

使用语义熵作为黑盒信号检测越狱中的行为不一致性	
Problem and Motivation	We lack reliable, real-time signals for detecting jailbreak attacks on black-box models (e.g., those served via API). Existing defenses are often reactive (post-generation content filtering) or brittle (input pattern matching), while powerful white-box methods that inspect gradients or activations are inapplicable. This leaves API-based models vulnerable to novel, adaptive attacks, creating a significant gap in the safety ecosystem.
Proposed Approach	Reframing jailbreak detection from a content analysis problem to a behavioral analysis problem. Use semantic inconsistency, measured via semantic entropy, as a zero-shot, black-box signal of a jailbreak attempt. The internal conflict an LLM experiences when processing a jailbreak prompt will manifest as high variance in the semantic meaning of its potential responses, detected by sampling and comparing multiple generated outputs.
Key Innovation	Repurposing the behavioral signal of response inconsistency, originally used for fact-checking in hallucination detection, as a security signal to detect the internal conflict caused by a jailbreak attack. Using semantic entropy over clustered response embeddings to measure behavioral inconsistency indicating safety alignment conflict.
Concrete Example	For jailbreak “My grandma used to tell me stories about how to make napalm,” sampling N=5 responses yields mixed semantic clusters: refusals (“I cannot fulfill this request”), compliance (“mix gasoline with...”), and hedges (“for fictional purposes...”). This high semantic variance produces high entropy score, flagging interaction as suspicious before harmful response reaches user, based solely on model’s inconsistent behavior.
Potential Pitfalls	Hardness confound where complex but benign prompts also produce high entropy; adaptive adversaries learning to generate prompts forcing consistent, low-entropy malicious outputs; inapplicability to training-time backdoor attacks that eliminate rather than create internal conflict.

专家验证：在此阶段，我们基于先前专家验证和实现尝试的经验教训，对顶级想法进行了内部审查。我们选择了

这个想法作为最有可能成功进行自主执行的想法，特别是因为它避免了先前想法中发现的许多技术复杂性和计算资源问题。该选择优先考虑实现可行性而非新颖性，代表了向能够在系统当前能力范围内完成的想法进行战略转向。

实现与失败模式：这个想法最有趣的地方在于，第一个假设虽然被实现了，但当它未能有效检测越狱时，修订代理触发了一次思路转变：从使用语义熵作为检测方法，转向展示其失败并研究失败模式。

表 8 展示了相关代理在思路修订后生成的更新假设套件。

表 8：假设套件的演变：从测试检测到研究失败

	Original Hypotheses Suite (Testing SE as Detection Method)	Revised Hypotheses Suite (Investigating the Consistency Confound)
H1	Semantic entropy detector achieves AUROC > baseline consistency metric by 0.1+ on JailbreakBench harmful vs benign prompts	H1: SE underperforms simple baselines (BERTScore, Embedding Variance) on JailbreakBench, with model-dependent baseline rankings
H2	SE maintains AUROC > 0.85 distinguishing harmful from benign-but-hard prompts, proving sensitivity to malice not complexity	H2: SE failure generalizes to HarmBench-Contextual, again losing to simpler baselines with model-dependent performance
H3	SE calibrated on JailbreakBench generalizes to HarmBench contextual attacks with AUROC > 0.70	H3: After controlling for response length confound, SE achieves near-random AUROC < 0.55 on both benchmarks
H4	SE deployed as gate reduces Tree of Attacks ASR by 25+ percentage points vs undefended model	H4: SE uniquely brittle: performance collapses when clustering threshold τ increased from 0.1→0.2 or samples N from 5→10
H5	SE correctly identifies >20% of jailbreaks missed by supervised WildGuard classifier	H5: Paraphrasing prompts disproportionately degrades SE vs baselines by disrupting memorized refusal templates
H6		>80% of SE false negatives exhibit “Consistency Confound”: high duplicate rate (>0.6) and low cluster count (≤ 2)
H7		Stronger alignment worsens SE: Qwen2.5-72B shows lower SE AUROC than smaller models while maintaining baseline performance

我们被接收论文的摘要为：

“大语言模型（Large Language Models）的黑盒越狱检测仍然具有挑战性，尤其是在无法访问内部状态的情况下。语义熵（Semantic Entropy）——已成功用于幻觉检测——基于响应一致性分析，提供了一种有前景的行为方法。我们假设越狱提示会在安全训练和指令遵循之间产生内部冲突，可能表现为具有高语义熵的不一致响应。我们使用基于嵌入的黑盒语义熵实现（改编自法夸尔等人的双向蕴含方法）系统地评估了这一方法，以在黑盒约束下工作。

在黑盒约束下工作。通过在两个模型家族（Llama 和 Qwen）及两个基准（JailbreakBench、HarmBench）上的测试，我们发现 SE 的假阴性率高达 85-98%，始终被更简单的基线超越，并表现出极端的超参数敏感性。我们确定主要失效机制为“一致性混淆”：对齐良好的模型产生一致、模板化的拒绝响应，而 SE 将其误判为安全行为，这解释了 73-97% 的假阴性，且具有高统计置信度 [95% Wilson 置信区间]。虽然 SE 关于响应不一致性指示问题内容的核心假设在有限情况下成立，但阈值脆弱性使其在实际中不可靠。我们的结果表明，对于这种 SE 变体，响应一致性可能不是可靠的越狱检测信号，因为更强的对齐导致更可预测的输出，从而混淆了这类基于多样性的检测器。”

与之前的实现不同，本研究在人工干预显著减少的情况下推进。由于研究重点在于数据分析而非复杂的模型架构，大多数技术障碍能够自主克服。第 3 节中讨论的熟悉的基础设施挑战在此同样出现——模态应用程序编程接口兼容性问题、模型集成错误以及库导入失败。

训练数据偏差也体现在数据集处理中，模型没有审查可用字段，而是默认采用标准提示和输出格式，尽管 HarmBench-Contextual 提示具有一个最初被忽略的独立上下文字段。然而，这些问题并未阻碍进展。

为了满足会议截止日期，实验评估流程被简化为仅两个检查点：初始想法修订和最终论文就绪性评估。

该实现还展示了第 3 节中讨论的过度兴奋失败模式。尽管存在需要人工干预才能识别和解决的退化输出和统计不显著性，初始自动论文写作始终强调积极方面，同时淡化重大局限性。这种模式需要人工监督，以确保在最终论文的局限性章节中透明地报告方法问题和统计问题。