

No More Stale Feedback: Co-Evolving Critics for Open-World Agent Learning

Zhicong Li^{1,2*}, Lingjie Jiang^{3*}, Yulan Hu², Xingchen Zeng⁴,
Yixia Li⁵, Xiangwen Zhang², Guanhua Chen⁵,
Zheng Pan², Xin Li², Yong Liu^{1†}

¹ 中国人民大学高瓴人工智能学院, ² 阿里巴巴集团高德地图, ³ 北京大学, ⁴ 香港科技大学 (广州), ⁵ 南方科技大学 {zhicongli, liuyonggsai}@ruc.edu.cn, lingjiejiang@stu.pku.edu.cn {huyulan, zhangxiangwen.zxw, panzheng.pan, beilai.bl}@alibaba-inc.com xzeng159@connect.hkust-gz.edu.cn, liyixia@me.com, ghchen08@gmail.com

摘要

批评引导的强化学习 (RL) 已成为训练大语言模型智能体的强大范式, 通过自然语言反馈增强稀疏的结果奖励。然而, 当前方法通常依赖静态或离线批评模型, 无法随着策略的演化而适应。在在线策略强化学习中, 智能体的错误模式随时间变化, 导致静态批评者变得过时, 提供的反馈效用递减。为解决这一问题, 本文提出 **ECHO** (用于事后引导优化的演化批评者), 一个通过同步协同演化循环联合优化策略与批评者的框架。**ECHO** 利用级联展开机制, 批评者为初始轨迹生成多个诊断, 随后进行策略细化以实现群体结构化的优势估计。本文通过饱和和感知的增益塑造目标应对学习平台期的挑战, 该目标奖励批评者在高性能轨迹中诱导增量改进。通过采用双轨 **GRPO** 更新, **ECHO** 确保批评者的反馈与演化的策略保持同步。实验结果表明, **ECHO** 在开放世界环境中产生更稳定的训练和更高的长期任务成功率。

政策优化的指南针。然而, 这些信号往往缺乏可操作性, 因为它们仅反映最终结果, 而未提供有效改进所需的诊断性洞见, 最终导致显著的数据低效 (Gao et al., 2025; Yang et al., 2025b)。为弥合这一差距, 近期研究引入了语言批评者以提供诊断性反馈 (Dhuliawala et al., 2024)。一类常见工作使用基于模板的批评 (Wang et al., 2025; Liu et al., 2025; Huang et al., 2025), 其计算成本低, 但缺乏适应性, 无法针对智能体的具体行为提供定制反馈。为提供更具针对性的指导, 另一类工作采用独立微调的分离批评模型来优化策略输出 (McAleese et al., 2024)。这些模型通常被设计为外部监督者, 旨在提供解决复杂失败所需的诊断性反馈。尽管这些方法通过提供更详细的反馈克服了静态模板的局限性, 但它们仍与策略的学习过程脱节, 隐含假设最优批评策略是静态的。然而, 在在线策略强化学习中, 策略持续演化, 导致轨迹分布不断变化, 并伴随失败模式的相应漂移: 早期阶段的轨迹可能由粗粒度错误主导, 受益于高层提示; 而后期阶段的策略更常受制于细微且难以定位的缺陷。因此, 在早期分布上训练 (并随后冻结) 的批评者可能变得过时, 产生冗余、粒度校准不当甚至对当前策略具有误导性的反馈, 导致其边际效用随训练推进而衰减。这种批评者过时——

1 引言

强化学习 (Sutton et al., 1998) 已成为训练基于大语言模型 (LLM) 智能体的有前景的范式 (Anthropic, 2024; Team et al., 2025), 使其能够通过环境交互完成复杂任务。在该范式中, 奖励信号 (Wen et al., 2025) 作为基础 * 同等贡献。

†通讯作者。

这种固有局限从根本上限制了样本效率，并阻碍了基于批评的强化学习在长程精炼中持续改进。受此观察启发，我们认为批评者应被视为一个共同演化的模块，而非静态的监督者，与策略同步适应（图 1）。具体而言，我们提出 **ECHO**（用于事后引导优化的演化批评者），这是一个促进策略与批评者之间共生优化循环的框架。我们不再奖励批评者听起来合理，而是直接优化其促进策略改进的能力：批评根据精炼后引发的性能增益进行评估，并与策略同步更新以跟踪其不断变化的失败模式。为了使这种共同演化稳定且样本高效，**ECHO** 采用级联式诊断与纠正展开，生成组结构轨迹以进行相对优势估计，并引入饱和感知增益整形，即使在改进变得渐进时也能提供信息丰富的学习信号。我们的主要贡献如下：（1）我们识别并实证证明了基于批评的强化学习中的批评者过时问题，冻结批评者会导致批评效用随策略改进而明显衰减。（2）我们引入 **ECHO**，一种同步的共同演化优化范式，通过双轨 **GRPO** 联合对齐批评者与策略。（3）我们提出饱和感知奖励设计和组相对优化方案，共同提升训练稳定性并增强跨任务性能。

2 相关工作

在基于大语言模型（LLM）的智能体的长程决策中，标量结果奖励往往缺乏诊断性，这促使基于语言的批评成为可操作的监督信号（Gao 等，2025；Yang 等，2025b；Zhao 等，2025）。先前的工作通常将语言批评者实现为静态的、基于模板或离线生成的反馈，或者作为单独训练的批评模型。

基于模板的批评者。一类轻量级工作通过注入预定义提示作为批评信号，避免了训练单独的批评模型。HINT（Wang 等，2025）通过附加通用的人工提示来触发重新生成，引导无效的展开走向有效。Tang 等（2025）进一步采用一小组基于错误条件的提示模板，路由不同的

失败案例与不同的预定义指导模式。超越通用指导，LUFFY（Yan 等，2025）通过注入教师模型的正确答案作为展开结果来缓解低效探索。为了更好地控制指导的粒度，还探索了更结构化的提示。GHPO（Liu 等，2025）和 ADHint（Zhang 等，2025a）通过注入掩码的部分参考解作为提示来提供更强的监督，有效地揭示部分答案以稳定和加速学习。

StepHint（Zhang 等，2025b）使用教师模型生成完整的思维链，将其拆分为 N 个推理步骤，并通过连接不同数量的前缀步骤来形成提示。相比之下，Scaf-GRPO（Zhang 等，2025c）设计了从抽象到具体指导的批评模板，根据模型当前性能提供由粗到细的指导。

基于训练的批评者。另一条工作线训练专门的批评模型以生成更具信息性和诊断性的反馈。早期尝试（Saunders 等，2022；Ke 等，2024；Xi 等，2024；Tang 等）主要依赖单阶段微调，通常通过整理批评数据集并训练模型生成用于评估和验证的自然语言反馈。Yu 等（2025）提出了面向精炼的批评优化（RCO），通过在批评-精炼循环中根据行动者精炼输出的效用奖励批评来训练批评者。还研究了多阶段训练以稳定不同训练目标下的学习。CGI（Yang 等，2025b）通过分阶段更新利用批评引导的迭代改进来训练智能体，通常将批评者视为固定监督者。CTRL（Xie 等，2025）引入了一个两阶段训练流程，首先通过监督微调蒸馏批评，然后应用 GRPO 直接优化批评生成以提升下游精炼成功率。

尽管取得了这些进展，大多数基于训练的批评者都是离线训练的，然后被冻结或异步更新，与在线策略学习保持解耦。随着策略的轨迹分布和失败模式随时间变化，批评者变得过时，其提供有用批评的能力逐渐衰减。




图 1：评论家范式比较。（a）传统静态范式：采用解耦且冻结的评论家模块，这些模块从现成模板初始化或由独立模型微调而来，导致评估静态且反馈僵化。（b）本文提出的 ECHO 范式：策略与评论家有机协同进化。策略首先生成初始推演 τ_o ，借助评论家的诊断指导 c 将其精炼为 τ_r 。两个模型联合更新，确保评论家的诊断精确率与策略不断演化的失败模式保持同步。

3 方法论

为解决在策略失败模式漂移下解耦训练导致的评论家滞后问题，本文提出回声（ECHO）机制，即策略 P_θ 与评论家 C_ψ 之间的协同进化交互，而非静态监督任务。在该范式下，本文将精化过程视为动态同步问题，使两个模型在共享的策略轨迹空间中协同进化：• P_θ （行动者）学习将诊断反馈转化为纠正动作。它不依赖无引导探索，而是以评论家当前的诊断结果为条件，生成直接提升任务奖励的精化方案。

- C_ψ （诊断进化器）因能最大化策略性能增益的反馈而获得奖励，从而学会精准定位导致策略失败的缺陷。

这种联合演化确保了评论家（Critic）的诊断深度能够持续校准，以适应策略不断变化的失败模式。通过双轨 GRPO 机制同时优化两个模型，我们将精炼过程转化为一个自我改进的系统，其中评估精确率与执行能力协同演化。图 2 总结了整体训练循环，并展示了一个具体的精炼示例。

3.1 级联进化展开

为促进两种模型的共生优化，ECHO 采用级联展开机制

通过诊断与纠正循环生成群组结构轨迹的机制。

阶段一：多视角诊断。给定查询 q ，策略 P_θ 首先生成初始轨迹 $\tau_o \sim P_\theta(\cdot | q)$ 。为提供客观的诊断依据，外部奖励模型 R 对提议进行评估，得到基线分数 $s_o = R(q, \tau_o)$ 。以轨迹及其对应分数为条件，评论家 C_ψ 被独立调用 N 次，产生一组多样化的诊断反馈 $\mathcal{G}_C = \{c_o^{(j)}\}_{j=1}^N$ ：

$$c_o^{(j)} \sim C_\psi(\cdot | q, \tau_o, s_o), \quad j = 1, 2, \dots, N. \quad (1)$$

通过将 s_o 纳入提示，评论家能够提供“分数感知”的解释，识别阻碍轨迹获得更高奖励的具体差距。

阶段二：条件精化。在诊断之后，策略 P_θ 需要将这些批评内化为精确的纠正行动。以增强输入 $\tilde{q}^{(j)} = (q, c_o^{(j)})$ 为条件，策略采样一组相应的精化轨迹：

$$\tau_r^{(j)} \sim P_\theta(\cdot | \tilde{q}^{(j)}), \quad j = 1, 2, \dots, N. \quad (2)$$

奖励模型评估每个精化结果，得到修正后分数 $s_r^{(j)} = R(q, \tau_r^{(j)})$ 。这种级联展开产生基线分数 s_o 、批评组 $\mathcal{G}_C$ 和精化组 $\mathcal{G}_P = \{\tau_r^{(j)}\}_{j=1}^N$ ，作为协同进化优化的经验信号。




图 2: 具有饱和感知 (SA) 评论家奖励的 ECHO 训练概览。在第 t 步, 策略 π_{θ_t} 产生展开 τ_o , 由奖励模型评分得到 s_o 。评论家 π_{ψ_t} 生成批评, 附加到原始查询以引出精化展开 τ_r , 评分为 s_r 。我们计算 SA 评论家奖励 r_c 以强调接近饱和时的最后一公里改进, 并同步更新评论家和策略以获得 $\pi_{\psi_{t+1}}$ 和 $\pi_{\theta_{t+1}}$ 。

3.2 饱和感知的奖励设计

量化批评效用的直接方法是衡量奖励的线性改进, 即 $\Delta s = s_r - s_o$ 。然而, 这种线性度量未能考虑模型优化中的饱和效应: 当初始分数 s_o 接近性能上限 (例如 $s \rightarrow 1$) 时, 实现进一步增量所需的边际努力和信息急剧增加。将 0.9 到 0.95 的改进等同于 0.1 到 0.15 的改进, 会造成“等距谬误”, 从而阻碍批评者诊断高质量提案中细微但关键的缺陷, 并导致优化停滞。为解决这一问题, 我们假设奖励空间是非线性的, 并受难度加权函数 $\omega(s)$ 支配。我们将 $\omega(s)$ 定义为软障碍函数, 用于捕捉接近完美时熵减难度不断增加的特性:

$$\omega(s) = \frac{1}{1 - s + \eta}, \quad (3)$$

其中 $\eta > 0$ 是平滑超参数。我们将一次改进的内在增益定义为 $\omega(s)$ 从 s_o 到 s_r 的路径积分:

$$g(s_o, s_r) = \int_{s_o}^{s_r} \omega(s) ds = \ln \left(\frac{1 - s_o + \eta}{1 - s_r + \eta} \right). \quad (4)$$

这一选择产生了一个有原则的塑形信号 (Ng 等人, 1999), 具有三个理想特性。首先, 它是饱和感知的: 对于相同的 Δs , 当改进发生在更高分数区域时,

增益 g 更大, 从而鼓励批评者关注近乎正确提案中细微但有影响的缺陷。其次, 它是可加的 (路径一致的):

$$g(s_o, s_m) + g(s_m, s_r) = g(s_o, s_r), \quad (5)$$

这使得训练信号不受改进是通过一步完成还是通过多个中间编辑完成的影响。第三, 增益是反对称的, $g(s_o, s_r) = -g(s_r, s_o)$, 提供了一个统一的度量, 在相同尺度下奖励改进并惩罚退化。最后, 我们直接使用这一内在增益作为批评者奖励:

$$r_c = g(s_o, s_r) = \ln \left(\frac{1 - s_o + \eta}{1 - s_r + \eta} \right). \quad (6)$$

3.3 同步协同进化

优化 我们不将批评者视为静态预言机, 而是将协同进化操作化为同步双轨对齐问题。我们构建了一个闭环优化, 其中 P_θ 和 C_ψ 探索共享的轨迹空间, 相互锚定彼此的学习进度。这是通过构建两个相互依赖的群体结构来实现的:

$$\mathcal{G}_P(q) = \{\tau_r^{(1)}, \tau_r^{(2)}, \dots, \tau_r^{(N)}\}, \quad (7)$$

$$\mathcal{G}_C(q, \tau_o) = \{c_o^{(1)}, c_o^{(2)}, \dots, c_o^{(N)}\}. \quad (8)$$

此处, $\mathcal{G}_C$ 表示诊断假设空间, 其中包含 N 种不同的解释

提案的缺陷，而 $\mathcal{G}_F$ 表示以这些假设为条件的纠正行动空间。

双轨优势估计。为最大化样本效率，本文计算组相对优势以捕捉每个模型输出的边际效用。对于策略 P_θ ，优势 $A_P^{(j)}$ 通过对 $\mathcal{G}_F$ 内的分数 $s_r^{(j)}$ 进行归一化计算得到。这使得策略能够从多样化的诊断样本中高效识别最有效的改进路径（Wang et al., 2022b; Cobbe et al., 2021）。对于评论家 C_ψ ，优势 $A_C^{(j)}$ 通过对第 3.2 节定义的饱和感知奖励 $r_c^{(j)}$ 进行组相对归一化得到。通过 λ 放大高分增益并平衡惩罚，该机制使评论家模型能够快速收敛到有效反馈。同步更新。遵循组相对策略优化（GRPO）目标（Shao et al., 2024）， P_θ 和 C_ψ 均通过最大化包含优势加权似然和 KL 发散约束的替代目标进行更新：

$$\mathcal{J}(\phi) = \mathbb{E}_{q \sim \mathcal{D}, \{o_i\}_{i=1}^N \sim M_{\phi_{\text{old}}}} \left[\frac{1}{N} \sum_{i=1}^N \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \min \left(\rho_{i,t}(\phi) A_i, \text{clip}(\rho_{i,t}(\phi), 1 - \epsilon, 1 + \epsilon) A_i \right) \right] - \beta D_{\text{KL}}(M_\phi \| M_{\text{ref}}), \quad (9)$$

其中 $\phi \in \{\theta, \psi\}$ 表示策略或评论家的参数， o_i 表示生成的序列。重要性采样比率定义为 $\rho_{i,t}(\phi) = \frac{M_\phi(o_{i,t} | \text{ctx}, o_{i,<t})}{M_{\phi_{\text{old}}}(o_{i,t} | \text{ctx}, o_{i,<t})}$ ，其中 $M_\phi(o_{i,t} | \text{ctx}, o_{i,<t})$ 是每个模型对应的输入上下文。 $A_i \in \{A_P, A_C\}$ 是各自的组相对优势。这种同步优化确保评论家的诊断焦点持续校准到策略不断演变的失败模式上，从而形成自我强化的课程以促进持续改进。为完整起见，ECHO 的完整伪代码见附录 D。

4 实验设置

场景与任务。为了在广泛的认知挑战范围内评估 ECHO，我们在四个不同的环境中进行了实验。具体而言，对于网页导航，我们使用 WebShop（Yao 等人，2022 年），要求智能体在电子商务平台上导航并做出购买决策；对于具身任务，ALFWorld（Shridhar 等人，2020 年）要求智能体在家庭环境中进行长时程规划和物体操作；

对于科学任务，SciWorld（Wang 等人，2022 年 a）提供了一个用于复杂实验推理和假设验证的模拟器；对于深度搜索，我们采用了 Xi 等人（2025 年）提出的基于 RAG 的 DeepSearch 环境，该环境需要多轮信息综合以完成开放域问答。更多细节见附录 A。

基线与骨干模型。

我们使用 Qwen3-4B-Instruct-2507（Yang 等人，2025 年 a）（下文简称为 Qwen3-4B）和 Qwen2.5-7B（Team 等人，2024 年）作为主要骨干模型。默认情况下，评论家 C_ψ 使用与策略 P_θ 相同的骨干模型。为了确保严格且全面的评估，我们将我们的方法与涵盖专有和开源大语言模型的多种强基线进行了比较。具体而言，对于专有模型，我们纳入了 GPT 系列（Achiam 等人，2023 年）、Gemini-2.5-pro（Comanici 等人，2025 年）和 Claude-Sonnet-4.5。此外，我们还将开源模型作为竞争基线，包括 Qwen3-235B-A22B（Yang 等人，2025 年 a）和 DeepSeek-R1-0528（Guo 等人，2025 年）。实现细节见附录 B。

5 结果

表 1 展示了主要结果。我们围绕三个研究问题组织分析：**RQ1** 评估 ECHO 在开放世界智能体基准上的整体有效性；**RQ2** 研究在策略学习过程中失败模式是否发生漂移，以及这种漂移是否导致冻结的评论家变得过时；**RQ3** 研究为什么所提出的饱和感知奖励是有益的，尤其是在接近奖励上限的最后阶段改进中。更详细的实验结果和分析见附录 C。

5.1 RQ1: ECHO 在开放世界智能体学习中的有效性如何？

ECHO 始终优于标准方法

分组相对策略优化（Group Relative Policy Optimization, GRPO）及其他强基线。如表 1 所示，在相同训练预算下，ECHO 始终优于 GRPO，这支持了我们的假设：同步的在线策略批评减少了无效探索，从而提高了数据效率。最显著的提升出现在 Qwen3-4B 的长时程搜索和网页交互任务上：在 DeepSearch 上，ECHO 从 33.25 提升至 47.25，相对提升约 42%；在 Web-

表 1: 四个开放世界智能体基准上的主要结果。粗体表示每个基准内的最佳结果。

Models	WebShop	ALFWorld	SciWorld	DeepSearch	Overall
<i>Proprietary Models</i>					
GPT-4o-mini	56.59	45.20	40.68	31.43	43.48
GPT-4o	58.20	44.45	45.78	26.19	43.66
GPT-4-turbo	52.45	42.64	34.14	61.90	47.78
GPT-4.1	58.07	43.56	35.65	61.46	49.67
GPT-5	46.12	35.09	13.06	72.19	41.62
Gemini-2.5-pro	65.58	68.04	12.50	36.50	45.66
Claude-Sonnet-4.5	58.80	64.73	56.83	65.00	61.34
<i>Open-sourced Models $\geq 100B$</i>					
Qwen3-235B-A22B	25.26	26.60	23.50	28.25	25.90
DeepSeek-R1-0528	44.81	72.50	4.50	40.25	40.52
<i>Open-sourced Models $< 100B$ & RL</i>					
Qwen3-4B	6.12	0.32	4.50	20.25	7.80
Qwen3-4B + GRPO	82.37	87.50	79.14	33.25	70.57
Qwen3-4B + ECHO	90.03	91.25	82.88	47.25	77.85
Qwen2.5-7B	13.98	2.00	1.50	15.50	8.25
Qwen2.5-7B + GRPO	83.55	89.50	81.24	42.25	74.14
Qwen2.5-7B + ECHO	89.97	93.75	85.63	46.75	79.03

Shop 上, 从 82.37 提升至 90.03, 相对提升约 9%。这些提升表明, 当成功依赖于跨多个步骤诊断和修复特定失败原因时, ECHO 尤其有效。重要的是, 在更复杂的具身和科学环境中, 失败更加多样且更难定位, ECHO 在 Qwen3-4B 上也带来了持续提升, 将 ALFWorld 从 87.50 提升至 91.25, SciWorld 从 79.14 提升至 82.88。总体而言, ECHO 在所有四个基准上都提升了性能, 相比 GRPO 平均提升 7.28 分, 并且相对于更强的基线也取得了极具竞争力的结果: 除了 DeepSearch 上 GPT-5 获得最佳分数外, ECHO 在其他基准上均以明显优势达到或超过所有列出的强模型。

ECHO 在不同骨干规模上具有泛化性。为了测试 ECHO 是否适用于不同骨干规模, 我们还在 Qwen2.5-7B 上进行了评估。结果表明, ECHO 并不局限于特定的容量范围。相反, 它在两种骨干上都持续优于 GRPO, 并在各种环境中表现出强劲的性能。这表明同步的批评者-策略协同进化的优势可以跨模型规模迁移, 凸显了 ECHO 在开放世界智能体学习中的通用性和泛化

能力。

5.2 研究问题 2: 在线策略学习过程中是否会发生失败模式漂移?

5.2.1 失败模式如何随训练变化

为了进一步检验在策略训练下失败模式是否发生漂移, 我们分析了 Qwen3-4B 的训练轨迹, 并将其划分为三个阶段: 早期、中期和晚期。在每个阶段, 我们选择三个相邻的策略检查点, 并对每个检查点在相同的留出测试集上执行 rollout。我们收集每个阶段产生的所有不成功轨迹, 并将它们视为该阶段特定失败分布的样本。对于每条不成功轨迹, 我们使用 Gemini-2.5pro 生成简洁的诊断, 描述潜在的错误原因。然后, 我们使用 Qwen3-8B-Embedding 对这些诊断进行嵌入, 并使用 t-分布随机邻域嵌入 (t-SNE) 可视化得到的表示 (Maaten and Hinton, 2008)。

主导失败模式的阶段性漂移。图 3 显示了所有四个环境中明显的分布漂移。在 WebShop 和 DeepSearch 中, 每个阶段的失败形成相对紧凑的簇, 高密度中心从早期到晚期显著移动。这表明训练

表 2: ECHO 的消融结果。“w/o”表示移除指定组件。由于 SA 塑造依赖于有意义的奖励幅度，我们专注于 WebShop 和 SciWorld，这两个具有非二元奖励的基准。

Methods	WebShop	ALFWorld	SciWorld	DeepSearch	Avg(↓)
<i>Qwen3-4B</i>					
GRPO	82.37	87.50	79.14	33.25	-
ECHO	90.03	91.25	82.88	47.25	-
ECHO w/o evloving	83.60	85.75	68.58	40.25	9.25
ECHO w/o SA-aware	86.69	-	78.55	-	3.84
<i>Qwen2.5-7B</i>					
GRPO	83.55	89.50	81.24	42.25	-
ECHO	89.97	93.75	85.63	46.75	-
ECHO w/o evloving	84.99	92.50	72.19	42.50	5.98
ECHO w/o SA-aware	86.78	-	83.65	-	2.59




图 3: 跨训练阶段的失败模式漂移。我们使用 t-SNE 在诊断嵌入空间中可视化来自早期、中期和晚期检查点的失败轨迹，轮廓表示密度区域。

改变了哪些错误原因占主导地位，而不是简单地缩小一组固定的错误。

更高的多样性和部分持续性在 com-

复杂环境。在更复杂的环境阿尔弗雷德世界（ALFWorld）和科学世界（SciWorld）中，失败分布更为分散，且在不同阶段间部分重叠，反映出更高的失败模式多样性以及某些反复出现错误的持续性。即便在这些场景下，密度质量仍会随着训练阶段迁移，证实了主导失败模式依然是非平稳的。

5.2.2 冻结评论家的局限性

失效模式漂移为进一步验证在故障模式漂移下进行评论家自适应的必要性，本文冻结评论家并重新运行实验，保持 ECHO 其余组件不变。结果见表 2，训练曲线如图 5 所示。

冻结评论家会导致最终性能下降。我们发现这一简单改动导致所有环境中的性能下降，表明保持批评与

不断演进的策略对于维持其有效性至关重要。与此同时，在 ALFWorld 和 SciWorld 上的性能退化最为严重，甚至不及标准 GRPO。我们推测，在这些更复杂的环境中，过时的评论家更频繁地产生冗余或偏离目标的诊断，而策略在细化过程中可能过度依赖这些诊断，从而将评论转化为噪声，并放大长时程误差。

训练动态揭示了阶段依赖效应。图 5 进一步表明，协同进化的收益取决于训练阶段和环境。在 WebShop 上，冻结评论家变体在早期可能表现强劲，但其改进速度随后放缓并被 ECHO 超越，这与后期错误变得更加细粒度一致，此时过时的评论日益失准，成为降低采样效率的噪声。在 ALFWorld 和 SciWorld 中，ECHO 在开始时与 GRPO 接近，主要在中后期拉开差距，这表明存在一个短暂的校准期，在此期间评论家学会生成环境特定的、可操作的诊断。




图 4: 饱和感知增益塑造对最后一英里细化的影响。我们绘制了使用 Qwen3-4B 在 WebShop 和 SciWorld 上细化前与细化后奖励的密度散点图 (s_o, s_r)。绿色区域中的点满足 $s_r > s_o$ ，对应于奖励改进的细化，密度越高表示评论越有效。高亮的高分方块标记了接近上限的区域。




图 5: 四个环境中的训练奖励曲线 (Qwen3-4B)。

对于长时程失败，其优势在显现之前需要时间。相比之下，在 DeepSearch 上，ECHO 在早期阶段提升更为陡峭；我们推测这是因为评估器对输出格式和交互协议高度敏感，因此评论家能够快速纠正系统性的、易于描述的早期失败。总体而言，这些曲线支持了我们的观点：在策略训练下，评论策略是非平稳的；随着失败模式漂移，冻结的评论家变得越来越不匹配，而同步的协同进化有助于在整个训练过程中保持评论的效用。

5.3 研究问题 3: 为什么饱和感知 (SA) 奖励设计有效?

为了检验 SA 增益塑造是否比线性改进奖励提供更具信息量的学习信号，我们比较了两种奖励设计

在 WebShop 和 SciWorld 上针对 Qwen3-4B 的消融结果：线性奖励 $\Delta s = s_r - s_o$ ，以及本文提出的饱和感知增益 $g(s_o, s_r)$ （见公式 6）。如表 2 所示，在保持 ECHO 其余部分不变的情况下禁用饱和感知塑造，会导致两个数据集上的性能一致下降。值得注意的是，WebShop 上的性能下降更为显著。本文将这一现象归因于策略所达到的不同状态：SciWorld 更具挑战性，学习到的智能体距离饱和状态更远，因此训练较少受最后阶段微调的主导，而饱和感知塑造正是为这一阶段提供额外信号而设计的；相比之下，WebShop 更频繁地进入接近上限的状态，使得饱和感知塑造的影响更大。为了进一步理解饱和感知塑造在微调过程中的作用位置，本文在图 4 中可视化了微调前与微调后奖励的联合分布 (s_o, s_r)。由于饱和效应在轨迹奖励已经较高时最为显著，本文聚焦于训练的中后期阶段。具体而言，本文提取了连续 10 个 rollout 批次的窗口，移除满足 $s_o = 1$ 的轨迹，并将 (s_o, s_r) 的联合分布以密度散点图的形式展示在图 4 中。

整体微调有效性。在 WebShop 和 SciWorld 两个数据集上，饱和感知塑造将显著更多的概率质量集中在改进区域，即图 4 中绿色左上三角所示的 $s_r > s_o$ 区域。该区域密度越高，表明批评意见更可靠地转化为奖励提升的微调，说明饱和感知设计相比线性替代方案具有更强的整体微调有效性。

接近奖励上限时的最后阶段改进。在黄色方框突出显示的高分区域中，最理想的结果位于其左上角区域，即轨迹从接近满分开始，并在微调后仍有所改进。对于两个数据集，饱和感知塑造在该区域表现出更高的密度，表明其能更好地将接近正确的轨迹转化为满分解决方案。相比之下，线性奖励在该区域显示许多样本仍接近对角线，尤其是在 SciWorld 上，表明微调倾向于保持原始分数，难以实现接近上限时所需的小幅但关键的提升。

6 结论

我们提出了 ECHO，一个面向开放世界大语言模型智能体的协同进化框架。通过同步评论家与策略的更新，ECHO 缓解了策略失效漂移下的评论家滞后问题。所提出的级联式展开为群体相对优化提供了群体结构化样本，而饱和度感知的增益塑造则提升了最后阶段的改进效果。这些设计共同使评论家的诊断粒度与策略不断演化的失效模式保持一致，从而支持更稳定的训练和持续的优化。

局限性

我们的框架使用从同一外部奖励模型计算出的改进信号来同时更新策略和评论家。因此，其有效性取决于奖励的质量和校准：如果奖励存在噪声、偏差或定义不充分，评论家可能会优化到评估器工件上，而非真正具有诊断性的反馈，策略也可能继承同样的错位。此外，在当前实现中，奖励评估和评论生成由不同的模型处理。一个自然的下一步是将它们统一到一个模型中，既能对轨迹进行评分，又能生成可操作的评论，这可以简化训练流程，并提高“被奖励的内容”与“被建议的内容”之间的一致性。我们将这一整合留给未来工作。

参考文献

Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altenschmidt, Sam Altman,

Shyamal Anadkat, and 1 others. 2023. Gpt-4 technical report. *arXiv preprint arXiv:2303.08774*.

AI Anthropic. 2024. The claude 3 model family: Opus, sonnet, haiku. claude-3 model card. In *Conference on Natural Language Processing*, volume 1.

Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, and 1 others. 2021. Training verifiers to solve math word problems. *arXiv preprint arXiv:2110.14168*.

Gheorghe Comanici, Eric Bieber, Mike Schaekermann, Ice Pasupat, Noveen Sachdeva, Inderjit Dhillon, Marcel Blistein, Ori Ram, Dan Zhang, Evan Rosen, and 1 others. 2025. Gemini 2.5: Pushing the frontier with advanced reasoning, multimodality, long context, and next generation agentic capabilities. *arXiv preprint arXiv:2507.06261*.

Shehzaad Dhuliawala, Mojtaba Komeili, Jing Xu, Roberta Raileanu, Xian Li, Asli Celikyilmaz, and Jason Weston. 2024. Chain-of-verification reduces hallucination in large language models. In *Findings of the association for computational linguistics: ACL 2024*, pages 3563–3578.

Bofei Gao, Zefan Cai, Runxin Xu, Peiyi Wang, Ce Zheng, Runji Lin, Keming Lu, Dayiheng Liu, Chang Zhou, Wen Xiao, and 1 others. 2025. Llm critics help catch bugs in mathematics: Towards a better mathematical verifier with natural language feedback. In *Findings of the Association for Computational Linguistics: ACL 2025*, pages 14588–14604.

Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Ruoyu Zhang, Runxin Xu, Qihao Zhu, Shitong Ma, Peiyi Wang, Xiao Bi, and 1 others. 2025. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. *arXiv preprint arXiv:2501.12948*.

Qihan Huang, Weilong Dai, Jinlong Liu, Wangui He, Hao Jiang, Mingli Song, Jingyuan Chen, Chang Yao, and Jie Song. 2025. Boosting mllm reasoning with text-debiased hint-grpo. *arXiv preprint arXiv:2503.23905*.

Pei Ke, Bosi Wen, Andrew Feng, Xiao Liu, Xuanyu Lei, Jiale Cheng, Shengyuan Wang, Aohan Zeng, Yuxiao Dong, Hongning Wang, and 1 others. 2024. Critiquellm: Towards an informative critique generation model for evaluation of large language model generation. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 13034–13054.

Ziru Liu, Cheng Gong, Xinyu Fu, Yaofang Liu, Ran Chen, Shoubo Hu, Suiyun Zhang, Rui Liu, Qingfu Zhang, and Dandan Tu. 2025. **GHPO: Adaptive Guidance for Stable and Efficient LLM Reinforcement Learning**. *arXiv preprint*. ArXiv:2507.10628 [cs].

- Laurens van der Maaten and Geoffrey Hinton. 2008. Visualizing data using t-sne. *Journal of machine learning research*, 9(Nov):2579–2605.
- Nat McAleese, Rai Michael Pokorny, Juan Felipe Ceron Uribe, Evgenia Nitishinskaya, Maja Trebacz, and Jan Leike. 2024. Llm critics help catch llm bugs. *arXiv preprint arXiv:2407.00215*.
- Andrew Y Ng, Daishi Harada, and Stuart Russell. 1999. Policy invariance under reward transformations: Theory and application to reward shaping. In *Icml*, volume 99, pages 278–287. Citeseer.
- William Saunders, Catherine Yeh, Jeff Wu, Steven Bills, Long Ouyang, Jonathan Ward, and Jan Leike. 2022. Self-critiquing models for assisting human evaluators. *arXiv preprint arXiv:2206.05802*.
- Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, YK Li, Yang Wu, and 1 others. 2024. Deepseekmath: Pushing the limits of mathematical reasoning in open language models. *arXiv preprint arXiv:2402.03300*.
- Mohit Shridhar, Xingdi Yuan, Marc-Alexandre Côté, Yonatan Bisk, Adam Trischler, and Matthew Hausknecht. 2020. Alfworld: Aligning text and embodied environments for interactive learning. *arXiv preprint arXiv:2010.03768*.
- Richard S Sutton, Andrew G Barto, and 1 others. 1998. *Reinforcement learning: An introduction*, volume 1. MIT press Cambridge.
- Chenming Tang, Hsiu-Yuan Huang, Weijie Liu, Saiyong Yang, and Yunfang Wu. 2025. Do not step into the same river twice: Learning to reason from trial and error. *arXiv preprint arXiv:2510.26109*.
- Zhengyang Tang, Ziniu Li, Zhenyang Xiao, Tian Ding, Ruoyu Sun, Benyou Wang, Dayiheng Liu, Fei Huang, Tianyu Liu, Bowen Yu, and 1 others. Self-evolving critique abilities in large language models. In *Second Conference on Language Modeling*.
- Kimi Team, Yifan Bai, Yiping Bao, Guanduo Chen, Jiahao Chen, Ningxin Chen, Ruijue Chen, Yanru Chen, Yuankun Chen, Yutian Chen, and 1 others. 2025. Kimi k2: Open agentic intelligence. *arXiv preprint arXiv:2507.20534*.
- Qwen Team and 1 others. 2024. Qwen2 technical report. *arXiv preprint arXiv:2407.10671*, 2(3).
- Ruoyao Wang, Peter Jansen, Marc-Alexandre Côté, and Prithviraj Ammanabrolu. 2022a. Scienceworld: Is your agent smarter than a 5th grader? *arXiv preprint arXiv:2203.07540*.
- Xinyi Wang, Jinyi Han, Zishang Jiang, Tingyun Li, Jiaqing Liang, Sihang Jiang, Zhaoqian Dai, Shuguang Ma, Fei Yu, and Yanghua Xiao. 2025. Hint: Helping ineffective rollouts navigate towards effectiveness. *arXiv preprint arXiv:2510.09388*.
- Xuezhi Wang, Jason Wei, Dale Schuurmans, Quoc Le, Ed Chi, Sharan Narang, Aakanksha Chowdhery, and Denny Zhou. 2022b. Self-consistency improves chain of thought reasoning in language models. *arXiv preprint arXiv:2203.11171*.
- Xumeng Wen, Zihan Liu, Shun Zheng, Shengyu Ye, Zhirong Wu, Yang Wang, Zhijian Xu, Xiao Liang, Junjie Li, Ziming Miao, and 1 others. 2025. Reinforcement learning with verifiable rewards implicitly incentivizes correct reasoning in base llms. *arXiv preprint arXiv:2506.14245*.
- Zhiheng Xi, Jixuan Huang, Chenyang Liao, Baodai Huang, Honglin Guo, Jiaqi Liu, Rui Zheng, Junjie Ye, Jiazheng Zhang, Wenxiang Chen, and 1 others. 2025. Agentgym-rl: Training llm agents for long-horizon decision making through multi-turn reinforcement learning. *arXiv preprint arXiv:2509.08755*.
- Zhiheng Xi, Dingwen Yang, Jixuan Huang, Jiafu Tang, Guanyu Li, Yiwen Ding, Wei He, Boyang Hong, Shihan Do, Wenyu Zhan, and 1 others. 2024. Enhancing llm reasoning via critique models with test-time and training-time supervision. *arXiv preprint arXiv:2411.16579*.
- Zhihui Xie, Jie Chen, Liyu Chen, Weichao Mao, Jingjing Xu, and Lingpeng Kong. 2025. Teaching language models to critique via reinforcement learning. *arXiv preprint arXiv:2502.03492*.
- Jianhao Yan, Yafu Li, Zican Hu, Zhi Wang, Ganqu Cui, Xiaoye Qu, Yu Cheng, and Yue Zhang. 2025. Learning to reason under off-policy guidance. *arXiv preprint arXiv:2504.14945*.
- An Yang, Anfeng Li, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Gao, Chengen Huang, Chenxu Lv, and 1 others. 2025a. Qwen3 technical report. *arXiv preprint arXiv:2505.09388*.
- Ruihan Yang, Fanghua Ye, Jian Li, Siyu Yuan, Yikai Zhang, Zhaopeng Tu, Xiaolong Li, and Deqing Yang. 2025b. The lighthouse of language: Enhancing llm agents via critique-guided improvement. *arXiv preprint arXiv:2503.16024*.
- Shunyu Yao, Howard Chen, John Yang, and Karthik Narasimhan. 2022. Webshop: Towards scalable real-world web interaction with grounded language agents. *Advances in Neural Information Processing Systems*, 35:20744–20757.
- Tianshu Yu, Chao Xiang, Mingchuan Yang, Pei Ke, Bosi Wen, Cunxiang Wang, Jiale Cheng, Li Zhang, Xinyu Mu, Chuxiong Sun, and 1 others. 2025. Training language model to critique for better refinement. *arXiv preprint arXiv:2506.22157*.
- Feng Zhang, Zezhong Tan, Xinhong Ma, Ziqiang Dong, Xi Leng, Jianfei Zhao, Xin Sun, and Yang Yang. 2025a. Adhint: Adaptive hints with difficulty priors for reinforcement learning. *arXiv preprint arXiv:2512.13095*.

Kaiyi Zhang, Ang Lv, Jinpeng Li, Yongbo Wang, Feng Wang, Haoyuan Hu, and Rui Yan. 2025b. Stephint: Multi-level stepwise hints enhance reinforcement learning to reason. *arXiv preprint arXiv:2507.02841*.

Xichen Zhang, Sitong Wu, Yinghao Zhu, Haoru Tan, Shaozuo Yu, Ziyi He, and Jiaya Jia. 2025c. Scaff-grpo: Scaffolded group relative policy optimization for enhancing llm reasoning. *arXiv preprint arXiv:2510.19807*.

Pengxiang Zhao, Guangyi Liu, Yaozhen Liang, Weiqing He, Zhengxi Lu, Yuehao Huang, Yaxuan Guo, Kexin Zhang, Hao Wang, Liang Liu, and 1 others. 2025. Mas-bench: A unified benchmark for shortcut-augmented hybrid mobile gui agents. *arXiv preprint arXiv:2509.06477*.

A 环境与评分标准

我们实验中使用的评估环境总结在表 3 中，包括其任务设置、对智能体所需的核心能力以及官方评分标准。

表 3: 评估环境概览。我们总结了每个环境的设置、对智能体所需的核心能力以及官方评估器使用的评分标准。

Environments	Description	Required Agent Ability	Score Criterion
WebShop (Yao et al., 2022)	An interactive e-commerce website simulator where the agent navigates product pages and selects an item that satisfies a natural-language shopping goal.	Goal parsing, web navigation, information retrieval, constraint tracking, reasoning over semi-structured fields.	Purchase-based success, rewarding buys that match the requested product type and constraints (attributes/options/price).
ALFWorld (Shridhar et al., 2020)	A text-based embodied household environment derived from ALFRED, requiring multi-step manipulation (<i>e.g.</i> , pick, place, clean, heat) to accomplish instructions.	Subgoal decomposition, spatial and physical commonsense, hierarchical planning, multi-step action execution, instrument operation.	Binary episode success judged by completion of the specified household task.
SciWorld (Wang et al., 2022a)	A simulated scientific discovery environment where the agent performs experiments, uses instruments, and reasons over observations to satisfy a scientific objective.	Scientific skills, experimental design, instrument operation, causal and mechanistic reasoning.	Progress-based scoring that rewards completing required main subgoals in order (with optional bonus goals), while any out-of-order main step triggers a failure score.
DeepSearch (Xi et al., 2025)	A retrieval-augmented multi-turn QA environment where the agent must search, read, and synthesize evidence to answer open-domain questions.	Query decomposition, iterative retrieval, evidence aggregation, faithful synthesis, termination control.	Answer-level correctness judged by the official QA evaluator (exact-match style).

表 4: 与已建立的基于评论引导的基线在四个环境中的性能比较。

Method	WebShop	ALFWorld	SciWorld	DeepSearch	Overall
RCO	35.64	3.00	16.50	25.75	20.22
LUFFY	80.34	80.92	70.44	31.00	65.18
ECHO	90.03	91.25	82.88	47.25	77.85

B 更多实现细节

所有实验均在十六块 H20-100GB 图形处理器 (GPU) 上进行。策略 P_θ 与评论家 C_ψ 使用相同的学习率, 设定为 $\text{lr}_\theta = \text{lr}_\psi = 1 \times 10^{-6}$ 。默认将展开组大小设为 $N = 8$, 即对于每个查询, 从评论家采样 8 条独立评论, 并基于这些评论生成 8 个相应的改进。对于策略模型, 遵循奖励设计与评估协议的官方设置, 以确保公平一致的比较。对于评论家模型, 使用式 (6) 中的奖励函数, 并在所有实验中将 η 设为 0.1。

C 补充实验分析

本文提供补充实验分析, 以完善正文中的主要结果。具体而言, 首先纳入标准组相对策略优化 (GRPO) 设置之外的额外评论引导基线比较。随后分析评论引导改进的有效性, 验证改进是否真正遵循评论家的诊断反馈, 并研究评论粒度在训练过程中的演变。最后报告详细的训练时间分析, 以量化 ECHO 引入的计算开销。除非另有说明, 本附录中的所有实验均使用 Qwen3-4B 模型进行。

C.1 与额外评论引导基线的比较

为了进一步加强对 ECHO 的实证评估, 我们在标准 GRPO 基线之外, 增加了与两种具有代表性的批评引导方法的比较。具体而言, 我们考虑了 RCO, 这是一种基于训练的批评优化框架, 通过学习的批评迭代地改进轨迹; 以及 LUFFY, 这是一种强大的改进方法, 在轨迹改进过程中利用教师提供的解决方案。这些方法代表了批评引导学习的两种常见范式: 基于训练的和基于模板的批评。表 4 展示了在四个环境中的性能比较。ECHO 在所有任务上均一致地优于两种基线。值得注意的是, 尽管 LUFFY 受益于来自真实解的强教师提示, ECHO 在没有获得此类特权监督的情况下仍取得了更高的性能。这一结果表明, ECHO 的改进并非源于更强的外部指导, 而是源于共同演化的批评所提供的自适应诊断反馈, 该批评与策略不断演化的失败模式保持一致。我们注意到, RCO 在我们的设置中表现相对较差, 主要是因为它不更新策略模型本身, 而是依赖于固定策略的迭代改进-评估过程。这种设计在长时程交互环境中效果较差, 因为策略适应至关重要。总体而言, 这些结果进一步支持了我们的结论: 批评的共同演化, 而非仅靠 RL 优化器的选择, 在推动 ECHO 的性能提升中发挥了关键作用。

C.2 批评引导精炼的有效性

我们首先探究由 ECHO 带来的性能提升是否真正源于评论家引导的细化, 而非仅仅来自额外的轨迹采样。为此, 我们设计了一个受控比较, 以隔离评论家诊断反馈的影响。对于每个查询, 我们首先使用当前策略生成一条初始轨迹。然后在两种条件下生成第二轮轨迹: (1) 评论家引导的细化, 即基于评论家的诊断反馈对轨迹进行细化; (2) 无评论家重新生成, 即在不提供任何评论的情况下简单地重新采样轨迹。对于这两种条件, 我们生成 $N = 8$ 条轨迹并计算

表 5: 训练阶段中二次精化带来的奖励增益。数值表示相对于初始展开的平均奖励增益。在相同解码预算下，将评论家引导的精化与无评论家的重新生成进行比较。

Dataset	Phase	No-Critic Regen	Critic-Guided Refine	Relative Gain
WebShop	Early	+0.81	+6.54	+5.73
	Mid	+0.59	+5.42	+4.83
	Late	+0.23	+7.54	+7.31
SciWorld	Early	+0.32	+2.82	+2.50
	Mid	+0.43	+3.65	+3.22
	Late	+0.34	+3.78	+3.44

组平均奖励。随后，我们减去原始轨迹的奖励，以获得该查询的奖励增益。表 5 报告了在 WebShop 和 SciWorld 上早期、中期和晚期训练检查点的平均奖励增益。无批评者再生列衡量了纯粹通过额外采样获得的改进，提供了轨迹自然变异性的细粒度估计。批评者引导精炼列报告了在批评者引导下进行精炼所实现的增益。最后，相对增益衡量了批评者在此基线方差之外带来的额外改进。在两个数据集和所有训练阶段中，批评者引导的精炼始终产生比无批评者再生显著更高的奖励增益，表明批评者提供了超越简单轨迹重采样的可操作指导。值得注意的是，相对增益在训练后期变得更大，表明随着策略和批评者共同进化，批评者变得越来越有效。

C.3 批判-精炼对齐与粒度演化

接下来，本文探究由批评引导的改进是否因果性地归因于批评者的诊断性反馈，并进一步考察此类反馈的性质在训练过程中如何演变。

批判-精炼对齐。为验证改进是否真正解决了批评中指出的问题，本文采用固定的外部评估器（Gemini-2.5-pro）来评估批评与改进轨迹之间的对齐程度。对于每个实例，评估器会获得原始轨迹、批评和改进后的轨迹。评估器不判断整体正确性，而是进行针对性审计，以确定改进是否明确解决了批评中指出的问题。评估器给出三种标签之一：是（问题已解决）、*NO*（问题未解决）或不清楚。本文剔除不清楚的案例，并报告“是”标签的百分比作为问题解决率。如表 6 所示，对齐程度在训练过程中显著提升。在早期阶段，问题解决率约为 75%，表明策略尚未学会可靠地遵循批评。相比之下，在中期和后期阶段，各数据集上的问题解决率均超过 90%，表明策略越来越能够根据批评者的诊断反馈采取行动。

批评粒度的演变。上述结果虽然表明改进越来越遵循批评，但并未解释为何批评在后期阶段变得更加有效。为此，本文分析了训练过程中批评粒度的演变。本文使用固定的外部评估器，根据批评的主要意图将其分为三类：粗粒度、中粒度和细粒度。粗粒度批评提供一般性指导，中粒度批评侧重于结构化推理或子任务级别的纠正，细粒度批评则识别精确的错误或决策点。如表 6 所示，训练阶段之间出现了明显的转变：早期阶段的批评以粗粒度指导为主，而中粒度和细粒度批评在后期阶段变得越来越普遍。特别是，细粒度批评在后期阶段大幅增长，表明批评者越来越注重精确的错误定位。

表 6: 不同训练阶段的批评-改进对齐与批评粒度 (%)。

Dataset	Phase	Issue Addressed	Coarse-level	Mid-level	Fine-grained
<i>Critique-Refinement Alignment</i>					
WebShop	Early	74.56	62.42	24.12	13.46
	Intermediate	93.87	34.70	41.89	23.41
	Late	95.30	8.61	49.34	42.05
SciWorld	Early	75.15	68.90	20.66	10.44
	Intermediate	92.48	39.23	37.58	23.19
	Late	90.02	11.78	41.50	46.72

为了更好地理解这一转变，我们人工检查了具有代表性的执行轨迹。在训练早期，策略往往难以完成基本的环境交互，此时批评主要提供程序性指导。随着策略的改进，错误逐渐转向次优规划和长程推理，批评也随之演变为针对更高层次的决策或细微的推理缺陷。

总体而言，这些结果表明，对齐的改善并非仅仅是训练的副产品，而是由批评粒度的系统性转变所驱动。随着失败模式变得更加细粒度和抽象化，批评者能够适应性地提供越来越精确且可操作的反馈，从而在训练后期实现持续的性能提升。

C.4 训练时间分析

我们分析了回声（ECHO）的计算开销，以评估性能提升是否以显著增加训练成本为代价。特别地，我们提供了详细的挂钟训练时间分解，以识别开销的主要来源。

表 7 报告了 Qwen3-4B 在多个环境中的训练时间分解。对于回声，我们将总时间分解为三个部分：策略执行、批评执行和精炼。对于基线 GRPO，我们在相同的实验设置下报告了执行时间和总训练时间。

回声额外阶段（包括初始轨迹生成、批评评估和更新）引入的开销是微乎其微的。与基线 GRPO 的总训练时间相比，这些成本可以忽略不计，证明协同演化机制本身并非瓶颈。

相反，大部分额外计算来自精炼阶段。这是一个合理的权衡：由于精炼处理更长的上下文，解码自然需要更多时间。即使包含这一精炼步骤，对总挂钟时间的影响仍然可控。我们观察到相对于 GRPO 平均增加约 15%，考虑到主要实验中报告的性能大幅提升，这是一个适度的权衡。需要注意的是，在像 ALFWorld 和 DeepSearch 这样要求更高的环境中，回声和 GRPO 的训练时间确实都会上升。这是由任务复杂性驱动的，而非协同演化逻辑本身。

最终，这些结果表明，ECHO 的成功并非仅仅源于庞大的计算预算。通过在明确界定的适度时间增加下提供显著更强的性能，ECHO 实现了极为有利的效率权衡。

D ECHO 伪代码

算法 1 给出了 ECHO 的完整训练流程。它概括了级联式展开流程（在线策略提议 τ_o 、多视角批评 $\{c_o^{(j)}\}$ 以及基于批评条件的改进 $\{\tau_r^{(j)}\}$ ），式 (6) 中的饱和度感知批评奖励计算，以及同步双轨 GRPO 更新

表 7: 训练墙钟时间分解 (秒)。我们报告了 ECHO 的训练时间分解, 并与相同设置下的基线 GRPO 进行了比较。

组件	WebShop	ALFWorld	SciWorld	DeepSearch
Policy Rollout (ECHO)	10	14	10	17
Critic Rollout	10	8	9	10
Refinement	272	541	192	581
Total ECHO	327	592	231	649
GRPO Rollout	259	502	168	552
Total GRPO	273	519	184	581
Overhead (%)	+19	+14	+25	+11

针对策略和批评器在同一在线策略批次上执行。

Algorithm 1: ECHO: Evolving Critic for Hindsight-Guided Optimization

Input : Dataset $\mathcal{D}$; reward model R ; policy P_θ ; critic C_ψ ; group size N ; GRPO hyperparams (ϵ, β) ; smoothing $\eta > 0$.

Output : Updated parameters (θ, ψ) .

```

1 foreach training step do
2   Sample a batch of queries  $q \sim \mathcal{D}$ 
   // Stage 0: On-policy proposal and baseline score
3   Sample initial trajectory  $\pi_o \sim P_\theta(\cdot | q)$ 
4   Compute baseline score  $s_o \leftarrow R(q, \tau_o)$ 
   // Stage 1: Multi-view diagnosis (critic group)
5   for  $j \leftarrow 1$  to  $N$  do
6     Sample critique  $c_o^{(j)} \sim C_\psi(\cdot | q, \tau_o, s_o)$ 
7    $\mathcal{C} \leftarrow \{c_o^{(j)}\}_{j=1}^N$ 
   // Stage 2: Conditional refinement (policy group)
8   for  $j \leftarrow 1$  to  $N$  do
9     Form augmented input  $\tilde{q}^{(j)} \leftarrow (q, c_o^{(j)})$ 
10    Sample refinement  $\tau_r^{(j)} \sim P_\theta(\cdot | \tilde{q}^{(j)})$ 
11    Evaluate post-correction scores  $s_r^{(j)} \leftarrow R(q, \tau_r^{(j)})$ 
12   $\mathcal{G}_P(q) \leftarrow \{\tau_r^{(j)}\}_{j=1}^N$ 
   // Saturation-aware critic reward for each critique
13  for  $j \leftarrow 1$  to  $N$  do
14     $r_E^{(j)} \leftarrow \ln\left(\frac{1-s_o+\eta}{1-s_r^{(j)}+\eta}\right)$  // Eq. 6
   // Dual-track group-relative advantage estimation
15  Compute policy advantages  $\{A_P^{(j)}\}_{j=1}^N$  by group-relative normalization of  $\{s_r^{(j)}\}_{j=1}^N$ 
16  Compute critic advantages  $\{A_C^{(j)}\}_{j=1}^N$  by group-relative normalization of  $\{r_c^{(j)}\}_{j=1}^N$ 
   // Synchronized GRPO updates (same batch, two tracks)
17  Update  $\theta$  by maximizing the GRPO surrogate objective  $\mathcal{U}(\theta)$  using sequences  $\{\tau_r^{(j)}\}$  with
    advantages  $\{A_P^{(j)}\}$ 
18  Update  $\psi$  by maximizing the GRPO surrogate objective  $\mathcal{U}(\psi)$  using sequences  $\{\tau_o^{(j)}\}$  with
    advantages  $\{A_C^{(j)}\}$ 

```

E 批评模型提示词

我们在框 A.1 中提供了用于从批评模型引出批评的确切提示模板。该提示约束批评模型将其反馈基于官方评分信息，并以固定格式输出最多 1-2 条高层次、可操作的建议，这稳定了训练过程并保持了各次展开之间批评的一致性。

Box A.1 : The prompt for critique generation.

你是一个**批评模型**，用于针对模型在给定任务上的整体表现提供指导。

系统将为你提供：

- 用户的任务描述；
- 模型在尝试完成任务过程中与环境交互的若干轮记录；
- 官方最终评分。

你的任务：**严格依据官方评分信息**，在 `<critic>` 标签内输出清晰的改进建议和行为指导。只指出问题和改进方向。不要提及优点，不要给予表扬或鼓励。

输入说明 模型的每一轮动作在 `<model_response>...</model_response>` 内提供 环境反馈在 `<env_feedback>...</env_feedback>` 内提供

Official Scoring Criteria (for your understanding; do not modify or question)

{Detail scoring criteria on specific task.}

You must:

- 将官方评分结果视为绝对正确且最终有效。
- 不重新解读、质疑或调整官方评分。

Original Question

{original_prompt}

Response to be Evaluated

{initial_response}

Official Scoring Information

{score_info_text}

输出格式 你必须**仅**输出以下两个标签及其内容。不得添加或删除标签，也不得在这些标签之外输出任何内容：`` `<reason>` 你的详细推理过程：

- 基于官方评分信息，分析模型在每个评分维度上的表现；
- 严格遵循官方评分信息；不得质疑、修改或补充；

- 当你对任何评估维度存在疑问或主观判断时，始终以官方评分结论作为最终依据。</reason>
<critic> 你的最终指导：- 如果模型得分为满分（1 分），直接返回“none”。- 给出**最多 1 – 2 条**简短、高层次的建议；只提及最关键的问题。- **不要**引用具体的回复文本或对话细节；只描述模型应如何改变其一般行为或策略。- 不要给予任何表扬或鼓励；只指出问题以及你应如何改进。- 始终以**“你”**（第二人称）称呼模型，而不是“该模型”、“它”或类似称呼。</critic> ``基于上述标准，对给定模型的行为提供指导，并按指定格式输出。

Output

Now, begin your reasoning!