

SKILLRL: 通过递归技能增强强化学习进化智能体

Peng Xia^{1*} Jianwen Chen^{1*} Hanyang Wang^{1,2*} Jiaqi Liu¹ Kaide Zeng¹ Yu Wang³ Siwei Han¹
Yiyang Zhou¹ Xujiang Zhao⁴ Haifeng Chen⁴ Zeyu Zheng⁵ Cihang Xie⁶ Huaxiu Yao¹

摘要

大语言模型 (LLM) 智能体在复杂任务中展现出惊人的成果，但它们往往孤立运行，未能从过往经验中学习。现有的基于记忆的方法主要存储原始轨迹，这些轨迹通常冗余且噪声较多。这阻碍了智能体提取对泛化至关重要的高层次、可复用的行为模式。本文提出 SKILLRL 框架，通过自动技能发现与递归进化，弥合原始经验与策略改进之间的鸿沟。该方法引入基于经验蒸馏的机制来构建分层技能库 SKILL-BANK，一种针对通用与任务特定启发式策略的自适应检索策略，以及一种递归进化机制，使技能库能够在强化学习过程中与智能体策略协同进化。这些创新显著降低了令牌占用，同时增强了推理效用。在 ALF-World、WebShop 及七个搜索增强任务上的实验结果表明，SKILLRL 达到了最先进的性能，超越强基线 15.3% 以上，并在任务复杂度增加时保持鲁棒性。代码可在

<https://github.com/aiming-lab/SkillRL> 获取。




图 1. (a) SKILLRL 流程概览。与存储原始轨迹并丢弃失败经验的先前方法（灰色虚线）不同，SKILLRL 采用基于经验蒸馏的机制，将多样化经验转化为结构化技能。(b) 在 ALFWorld 验证集 (Shridhar et al.) 上的性能。与普通 GRPO 和记忆增强强化学习相比，SKILLRL 实现了更快的收敛和更高的成功率。

通过自然语言与复杂环境进行交互。尽管取得了这些进展，每次任务执行在很大程度上仍然是孤立的。当前的大语言模型智能体在孤立状态下运行，无法从过去的成功或失败中学习 (Zhang 等人, 2025b)，这严重阻碍了它们的进化。因此，一个根本性的挑战仍然存在：智能体如何高效地从经验中学习，并将这些知识迁移到其他任务？

1. 引言

大语言模型 (LLM) 智能体 (Yao et al., 2022b; Shinn et al., 2023) 在各类复杂任务中展现出卓越能力，如网页导航 (Google, 2025; OpenAI, 2025c) 和深度研究 (OpenAI, 2025b; Google, 2024; Team et al., 2025)。¹ 北卡罗来纳大学教堂山分校 ² 芝加哥大学 ³ 加利福尼亚大学圣迭戈分校 ⁴ NEC 美国实验室 ⁵ 加利福尼亚大学伯克利分校 ⁶ 加利福尼亚大学圣克鲁兹分校。通讯作者：Peng Xia <pxia@cs.unc.edu>，Huaxiu Yao <huaxiu@cs.unc.edu>。

现有基于记忆的大语言模型智能体方法主要涉及在采样过程中将原始轨迹直接保存到外部数据库中，以作为未来类似任务的参考 (Shinn 等人, 2023; Zhao 等人, 2024)。虽然直观，但这些原始轨迹通常冗长且包含大量冗余和噪声 (Chhikara 等人, 2025)，使得模型难以提取关键信息。最近的工作尝试压缩轨迹并通过在线训练更新记忆库 (Zhang 等人, 2025b; 2026)，提高了记忆效率。然而，这些方法仅仅模仿过去的解决方案，未能提炼核心原则或调整智能体的内部策略以利用记忆进行引导式决策。如图 1(a) 中的虚线流程所示，这类方法往往在信息密度与噪声之间难以权衡，导致性能次优甚至下降，如图 1(b) 所示。

如图 1(b) 所示, 导致性能次优甚至下降。

我们认为这些方法忽略了一个关键洞见: 有效的经验迁移需要抽象。人类专家不会记住每种情况下的每个动作; 相反, 他们发展技能 (Anthropic, 2024), 即紧凑且可复用的策略, 捕捉完成特定任务的本质。受此观察启发, 我们提出了 SKILLRL 框架, 通过自动技能发现和递归技能进化, 弥合原始经验与高效策略改进之间的鸿沟。

SKILLRL 首先引入了一种基于经验的技能蒸馏机制, 该机制从环境交互中收集多样化的轨迹, 并采用差异化处理: 成功的回合被保留为示范, 而失败的回合则被合成为简洁的失败教训, 以减轻上下文噪声。其次, 我们将这些经验转化为一个分层的技能库 SKILLBANK, 区分用于通用策略指导的通用技能和用于任务级启发式的任务特定技能。这种抽象使智能体能够在决策过程中自适应地检索相关技能, 显著减少了令牌占用, 同时增强了推理效用。最后, SKILLRL 在强化学习 (RL) 过程中融入了递归技能进化机制, 将技能库视为动态组件而非静态知识源。通过在每个验证轮次后分析失败模式来生成新技能或优化现有技能, 我们的方法确保技能库与智能体策略共同进化, 在任务复杂度增加时保持鲁棒性。如图 1(b) 所示, SKILLRL 实现了显著更快的收敛速度和更高的渐近性能。

主要贡献是 SKILLRL, 一个使 LLM 智能体能够通过自动技能发现和递归进化弥合原始经验与策略改进之间差距的框架。通过将冗余轨迹蒸馏为分层 SKILLBANK, 我们的方法抽象出通用和任务特定技能, 以高效指导决策。此外, 我们引入了一种递归进化机制, 确保技能库和智能体策略在强化学习过程中共同进化。在 ALFWorld、WebShop 和七个搜索增强基准上的实证结果表明, SKILLRL 以 15.3% 的提升达到了最先进的性能, 在任务成功率和推理效用方面显著优于当前基于记忆的智能体调优基线。

2. 预备知识

LLM 智能体。 我们考虑一个在交互式环境中运行的智能体 $\mathcal{E}$ 。在每个时间步 t , 智能体观察到

一个状态 $o_t \in \mathcal{O}$, 选择一个动作 $a_t \in \mathcal{A}$, 并获得一个奖励 r_t 和下一个观测 o_{t+1} 。一条轨迹 $\tau = (o_0, a_0, r_0, \dots, o_T, a_T, r_T)$ 捕捉了一次交互的回合。任务由自然语言描述指定 d 。一个基于大语言模型的智能体由 θ 参数化, 实现策略 $\pi_\theta(a_t|o_{\leq t}, d, c)$, 其中 c 表示额外上下文 (例如, 技能、演示)。我们的目标是学习一个策略, 在上下文长度约束 $|c| \leq L_{\max}$ 下最大化期望回报 $\max_\theta \mathbb{E}_{\tau \sim \pi_\theta} [\sum_{t=0}^T \gamma^t r_t]$ 。

分组相对策略优化 (GRPO)。 GRPO (Shao 等, 2024) 是一种强化学习方法, 通过使用组内相对奖励来优化策略, 从而避免训练评论家。对于每个查询 x , 模型采样 G 个响应 $\{y^{(1)}, \dots, y^{(G)}\}$, 这些响应被评分以获得奖励 $\{R_1, \dots, R_G\}$ 。GRPO 计算归一化优势, 并使用 PPO 风格的裁剪目标更新策略 (Schulman 等, 2017):

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E}_{x, \{y_i\}} \left[\frac{1}{G} \sum_{i=1}^G \min \left(r_i A_i, \text{clip}(r_i, 1 - \epsilon, 1 + \epsilon) A_i \right) - \beta D_{\text{KL}}(\pi_\theta \| \pi_{\text{ref}}) \right], \quad (1)$$

其中 $r_i = \frac{\pi_\theta(y_i|x)}{\pi_{\text{old}}(y_i|x)}$ 是重要性比率, $A_i = \frac{R_i - \text{mean}(\{R_j\}_{j=1}^G)}{\text{std}(\{R_j\}_{j=1}^G)}$ 是归一化优势, ϵ, β 是超参数, π_{old} 是当前更新前的策略。

3. SKILLRL

在本节中, 如图 2 所示, 我们提出 SKILLRL, 这是一个旨在通过自动技能发现和递归演化来弥合原始交互经验与策略改进之间差距的框架。SKILLRL 包含三个核心组件。首先, 我们开发了一种基于经验的技能蒸馏机制, 将冗余的轨迹转化为简洁、可操作的知识。其次, 我们将这些蒸馏后的经验组织成一个分层技能库 $\mathcal{S}$, 从而能够高效地检索通用和任务特定的专业知识。最后, 我们引入了一种递归技能演化机制, 利用强化学习动态地完善技能库, 并与智能体的策略同步。我们详细描述这些组件如下:

3.1. 基于经验的技能蒸馏

从环境交互中收集的原始轨迹 τ 是冗长的, 包含探索性动作、回溯和冗余步骤, 这些掩盖了导致成功或失败的关键决策。为了将这些经验转化为可操作的知识, 我们采用一个教师模型 $\mathcal{M}_T$ 将轨迹蒸馏为紧凑、可复用的技能。

具体而言, 本文首先部署一个基础大语言模型智能体 π_{base} 于




图 2. SKILLRL 框架概览。我们使用基础模型收集轨迹，将其蒸馏为分层技能库，执行冷启动监督微调以启用技能利用，然后基于验证失败进行动态技能演化的强化学习训练。

目标环境 $\mathcal{E}$ 以收集多样化的轨迹。与以往仅保留成功回合的方法不同，本文有意同时保留成功轨迹 $\mathcal{T}^+ = \{\tau_i : r(\tau_i) = 1\}$ 和失败轨迹 $\mathcal{T}^- = \{\tau_i : r(\tau_i) = 0\}$ ，其中 $r(\tau)$ 表示二值任务成功指示符。失败轨迹揭示了失败模式和边界条件，即仅从成功中难以推断的信息。

我们根据轨迹结果进行差异化处理。对于成功轨迹 $\tau^+ \in \mathcal{T}^+$ ，我们提取导致任务完成的策略模式：

$$s^+ = \mathcal{M}_T(\tau^+, d). \quad (2)$$

教师模型识别关键决策点、正确行动背后的推理以及可迁移到特定任务实例之外的可泛化模式。

对于失败轨迹 $\tau^- \in \mathcal{T}^-$ ，由于其长度和噪声，直接纳入上下文不可行。相反，我们合成简洁的失败教训：

$$s^- = \mathcal{M}_T(\tau^-, d). \quad (3)$$

分析识别：(1) 失败点，(2) 有缺陷的推理或行动，(3) 本应采取的措施，以及 (4) 防止类似失败的一般原则。这将冗长的失败回合转化为反事实。

3.2. 分层技能库 (SKILLBANK) 构建

遵循智能体技能 (Agent Skills) 的设计原则 (Anthropic, 2024)，我们将提炼的知识组织为分层技能库 SKILLBANK，以便在决策过程中高效检索相关专业知识。

技能组织。我们将 SKILLBANK 分为两个层级：1) 通用技能 $\mathcal{S}_g$ 捕捉适用于环境内所有任务类型的通用策略原

则。这些通常包括探索策略（例如，系统性搜索模式、优先访问未探索位置）、状态管理原则（例如，在行动前验证前置条件）以及目标跟踪启发式方法（例如，维护进度计数器、仅在验证完成后终止）。通用技能提供了可跨不同任务类别迁移的基础指导。2) 任务特定技能 $\mathcal{S}_k$ 编码针对任务类别 k 的专业知识。这些技能捕捉特定领域的动作序列、任务特有的前置条件和约束、该任务类型独有的常见失败模式，以及利用任务结构的优化流程。通过在收集过程中按任务类型组织轨迹，我们能够提取细粒度、类别特定的策略，以补充更广泛的通用技能。

完整的技能库 SKILLBANK 为 $\mathcal{S}_g \cup \bigcup_{k=1}^K \mathcal{S}_k$ 。每个技能 $s \in \text{SKILLBANK}$ 的结构包括：简洁的名称（例如，系统性探索）、描述策略的原则，以及指定适用条件的应用时机。这种格式在提供清晰应用指导的同时，实现了高效检索。

技能检索。在推理时，给定任务描述 d ，智能体检索相关技能以增强其上下文。通用技能 $\mathcal{S}_g$ 始终作为基础指导被包含。任务特定技能通过语义相似度进行检索：

$$\mathcal{S}_{\text{ret}} = \text{TopK}(\{s \in \mathcal{S}_k : \text{sim}(e_d, e_s) > \delta\}, K), \quad (4)$$

其中 e_d, e_s 分别是任务描述和技能的嵌入， δ 是相似度阈值， K 控制检索到的技能数量。策略随后以检索到的技能为条件：

Algorithm 1 SKILLRL: Recursive Skill-Augmented RL

Require: Base model π_{base} , teacher $\mathcal{M}_T$, environment $\mathcal{E}$
Ensure: Trained policy π_{θ^*} , evolved skill library SKILLBANK*

```

1:  $\triangleright$  Experience-based Skill Distillation
2:  $\mathcal{T}^+, \mathcal{T}^- \leftarrow \text{Rollout}(\pi_{\text{base}}, \mathcal{E})$ 
3: for all  $\tau^+ \in \mathcal{T}^+$  do
4:    $s^+ \leftarrow \mathcal{M}_T(\tau^+)$ 
5: end for
6: for all  $\tau^- \in \mathcal{T}^-$  do
7:    $s^- \leftarrow \mathcal{M}_T(\tau^-)$ 
8: end for
9:  $\triangleright$  Hierarchical Skill Library Construction
10:  $\mathcal{S}_g \leftarrow$  general skills from distilled experiences
11: for all task type  $k$  do
12:    $\mathcal{S}_k \leftarrow$  task-specific skills for category  $k$ 
13: end for
14: SKILLBANK  $\leftarrow \mathcal{S}_g \cup \bigcup_k \mathcal{S}_k$ 
15:  $\triangleright$  Recursive Skill Evolution via RL
16: // Cold-start initialization
17:  $\mathcal{D}_{\text{SFT}} \leftarrow \mathcal{M}_T(\mathcal{E}, \text{SKILLBANK})$ 
18:  $\theta \leftarrow \text{SFT}(\pi_{\text{base}}, \mathcal{D}_{\text{SFT}})$ ;  $\pi_{\text{ref}} \leftarrow \pi_{\theta}$ 
19: // RL with recursive evolution
20: for epoch = 1 to  $N$  do
21:   for all task  $d$  do
22:      $\mathcal{S}_{\text{ret}} \leftarrow \text{Retrieve}(d, \text{SKILLBANK})$ 
23:     Sample  $\{\tau^{(i)}\}_{i=1}^G \sim \pi_{\theta}(\cdot | d, \mathcal{S}_g, \mathcal{S}_{\text{ret}})$ 
24:     Compute  $\{R_i\}_{i=1}^G$  and update  $\theta$  via GRPO
25:   end for
26:   if validation epoch then
27:      $\mathcal{T}_{\text{val}}^- \leftarrow$  failed validation trajectories
28:      $\mathcal{S}_{\text{new}} \leftarrow \mathcal{M}_T(\mathcal{T}_{\text{val}}^-, \text{SKILLBANK})$ 
29:     SKILLBANK  $\leftarrow \text{SKILLBANK} \cup \mathcal{S}_{\text{new}}$ 
30:   end if
31: end for
32: return  $\pi_{\theta}, \text{SKILLBANK}$ 

```

检索到的技能:

$$a_t \sim \pi_{\theta}(a_t | o_{\leq t}, d, \mathcal{S}_g, \mathcal{S}_{\text{ret}}). \quad (5)$$

值得注意的是, 与原始轨迹相比, 技能蒸馏实现了 10–20 $\times$ 的令牌压缩, 同时增强而非降低了原始经验的效用。这种压缩使智能体能够在有限的上下文窗口内利用丰富的经验知识。

3.3. 递归技能演化

静态技能库无法预见智能体将遇到的所有场景。随着策略的改进和对新状态区域的探索, 智能体会面临现有技能提供指导不足的情况。我们引入强化学习过程中的递归技能演化来解决这一局限性, 使技能库和智能体策略能够共同演化。

冷启动初始化。在强化学习训练之前, 我们解决一个关键挑战: 基础智能体尚未学会如何有效利用技能。简单地向未修改的模型提供技能收益有限 (Guo et al., 2025)。因此, 我们执行一个冷启动监督微调

(SFT) 阶段 (Ouyang et al., 2022), 其中教师模型 $\mathcal{M}_T$ 生成 N 技能增强的推理轨迹 $\mathcal{D}_{\text{SFT}} = \{(d_i, \mathcal{S}_i, \tau_i^*)\}_{i=1}^N$, 展示如何在决策过程中检索、解释和应用技能。然后在这些演示上对基础模型进行微调:

$$\theta_{\text{sft}} = \arg \min_{\theta} \mathcal{L}_{\text{CE}}(\mathcal{D}_{\text{SFT}}; \theta), \quad (6)$$

其中 $\mathcal{L}_{\text{CE}}$ 表示交叉熵损失。所得模型 $\pi_{\theta_{\text{sft}}}$ 既作为强化学习训练的起点, 也作为 KL 正则化的参考策略 π_{ref} 。

递归技能演化。静态技能库无法预见智能体将遇到的所有场景。随着策略改进并探索新的状态区域, 智能体会面临现有技能指导不足的情况。本文引入递归技能演化以解决这一局限性。该过程始于包含基线任务-行动原则的初始技能库。

每个验证轮次后, 本文监测每个任务类别的成功率 $\text{Acc}(C)$ 。为确保针对性增长, 仅对 $\text{Acc}(C) < \delta$ 的类别触发演化。随后, 本文采用多样性感知的分层采样策略收集失败轨迹 $\mathcal{T}_{\text{val}}^- = \{\tau_j : r(\tau_j) = 0\}_{j=1}^M$: 轨迹按类别分组, 按失败严重程度 (负奖励) 排序, 并通过轮转采样选择以保持类别熵。然后分析这些样本以识别差距:

$$\mathcal{S}_{\text{new}} = \mathcal{M}_T(\mathcal{T}_{\text{val}}^-, \text{SKILLBANK}). \quad (7)$$

教师模型被提示: (1) 识别当前技能未解决的失败模式, (2) 提出新技能以覆盖这些差距, (3) 建议对已证明无效的现有技能进行改进。随后更新技能库:

$$\text{SKILLBANK} \leftarrow \text{SKILLBANK} \cup \mathcal{S}_{\text{new}}.$$

这形成了一个良性循环: 随着智能体改进, 它会遇到新挑战, 从而推动技能库扩展, 进而实现进一步改进。

基于强化学习的策略优化。本文使用 GRPO 优化技能增强策略。对于每个具有描述 d 的任务, 智能体首先检索相关技能, 然后从当前策略 π_{θ} 采样 G 条完整轨迹 $\{\tau^{(1)}, \dots, \tau^{(G)}\}$ 。每条轨迹 $\tau^{(i)}$ 获得一个二元奖励 $R_i = r(\tau^{(i)}) \in \{0, 1\}$, 表示任务是否成功。每条轨迹的归一化优势计算如下:

$$A_i = \frac{R_i - \text{mean}(\{R_j\}_{j=1}^G)}{\text{std}(\{R_j\}_{j=1}^G)}. \quad (8)$$

策略根据以下公式更新:

$$\mathcal{J}(\theta) = \mathbb{E}_{d, \{\tau^{(i)}\}} \left[\frac{1}{G} \sum_{i=1}^G \min \left(\rho_i A_i, \text{clip}(\rho_i, 1 - \epsilon, 1 + \epsilon) A_i \right) - \beta D_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{ref}}) \right], \quad (9)$$

其中 $\rho_i = \frac{\pi_{\theta}(\tau^{(i)} | d, \mathcal{S}_g, \mathcal{S}_{\text{rel}})}{\pi_{\text{old}}(\tau^{(i)} | d, \mathcal{S}_g, \mathcal{S}_{\text{rel}})}$ 是在技能增强上下文上计算的重要性比率。锚定于 $\pi_{\text{ref}} = \pi_{\theta_{\text{st}}}$ 的 KL 惩罚确保强化学习优化在提升任务性能的同时, 保留已学习的技能利用能力。完整的训练流程总结于算法 1。

4. 实验

我们在九个具有挑战性的大语言模型智能体基准上评估 SKILLRL: ALFWorld、WebShop 以及七个搜索增强问答任务。我们的实验旨在回答以下问题: 1) SKILLRL 与最先进的方法相比如何? 2) 每个组件的贡献是什么? 3) 技能库在训练过程中如何演变? 4) 技能是否加速模型收敛?

4.1. 实验设置

环境。ALFWorld (Shridhar 等人) 是一个与 ALFRED 具身智能基准对齐的基于文本的游戏。智能体必须通过文本命令导航并与物体交互来完成家务任务。WebShop (Yao 等人, 2022a) 模拟网上购物。智能体在逼真的网页界面中导航, 以查找并购买符合用户规格的产品。此外, 我们还评估了 SKILLRL 在搜索增强问答任务上的性能, 包括单跳问答数据集 (NQ (Kwiatkowski 等人, 2019)、TriviaQA (Joshi 等人, 2017) 和 PopQA (Mallen 等人, 2023)) 以及多跳问答数据集 (HotpotQA (Yang 等人, 2018)、2Wiki (Ho 等人, 2020)、MuSiQue (Trivedi 等人, 2022) 和 Bamboogle (Press 等人, 2023))。

基线。我们将技能强化学习 (SKILLRL) 与四类具有竞争力的方法进行比较。首先, 我们纳入了闭源大语言模型 (LLM), 具体为 GPT-4o (OpenAI, 2024) 和 Gemini-2.5-Pro (Comanici 等人, 2025), 它们代表了通用推理和指令遵循领域的最先进水平。其次, 我们评估了基于提示的智能体或基于记忆的方法, 包括 ReAct (Yao 等人, 2022b) 和 Reflexion (Shinn 等人, 2023), 它们依赖上下文提示进行多步推理, 以及 Mem0 (Chhikara 等人, 2025)、ExpeL (Zhao 等人, 2024) 和 MemP (Fang 等人, 2025), 它们利用外部记忆或经验池来引导行为, 而无需更新参数。第三, 我们考虑了基于强化学习 (RL) 的方法, 包括基于群体的在线强化学习算法, 如 RLOO (Ahmadian 等人, 2024)

和 GRPO (Shao 等人, 2024), 它们通过轨迹组上的优势估计来优化策略。最后, 我们与记忆增强的强化学习方法进行比较, 如 EvolveR (Wu 等人, 2025)、MemRL (Zhang 等人, 2026), 以及 Mem0+GRPO 和 SimpleMem (Liu 等人, 2026)+GRPO 的组合, 这些方法将持久记忆机制直接集成到强化学习优化过程中, 以处理长期依赖关系。对于搜索增强的问答任务, 我们将 SKILLRL 与 R1-Instruct、Search-o1 (Li 等人, 2025)、Search-R1 (Jin 等人, 2025)、ZeroSearch (Sun 等人, 2025) 和 StepSearch (Zheng 等人, 2025) 进行比较。

实现 细节。我们使用 Qwen2.5-7B-Instruct (Bai 等人, 2023) 作为基础模型, 并使用 OpenAI o3 (OpenAI, 2025a) 作为教师模型, 用于技能蒸馏和监督微调 (SFT) 数据生成。对于强化学习训练, 我们使用 GRPO, 学习率为 1×10^{-6} , 批大小为 16, 组大小为 8, 梯度累积步数为 4。我们设置 $K=6$ 用于任务特定技能检索, 设置 $\delta=0.4$ 用于收集失败轨迹。有关训练超参数的更多详细信息, 请参见附录 B.1。

4.2. 主要结果

与基线的比较。我们将 SKILLRL 与基线方法在两个基准上进行比较, 如表 1 所示。我们的方法一致地优于所有基线, 关键观察如下:

1) 相对于基于提示的方法的显著提升。SKILLRL 在 ALFWorld 上达到了 89.9% 的成功率, 在 WebShop 上达到了 72.7%, 大幅超越了最佳的基于提示的基线。这一差距表明, 虽然上下文学习可以利用过去的经验, 但它往往无法从冗长的轨迹中提炼出可操作的知识, 或从根本上调整智能体的策略。

2) 相较于普通强化学习的优势。强化学习训练带来了显著增益, 然而技能强化学习始终超越标准强化学习基线。与近端策略优化、强化学习目标优化和群体相对策略优化相比, 技能强化学习取得了最佳整体性能。值得注意的是, 由于技能强化学习以群体相对策略优化为基础优化器, 在虚拟家庭环境中相较于群体相对策略优化取得的 12.3% 绝对提升 (从 77.6% 到 89.9%) 直接归因于我们的技能增强机制, 而非算法方差。在冷却和拾取二等复杂子任务中, 技能强化学习分别比群体相对策略优化高出 23.0% 和 22.8%, 证明结构化技能先验在稀疏奖励环境中有效加速并增强了策略学习。

3) 相较于记忆增强强化学习的优势。技能强化学习大幅超越了现有的记忆增强强化学习框架, 这些框架在管理和更新经验的方式上有所不同。记忆强化学习仅使用强化学习更新其记忆库而保持策略冻结, 无法适应

表 1. 在虚拟家庭环境和网上购物平台上的性能。对于虚拟家庭环境，我们报告每个子任务的平均成功率（%）以及总体结果。对于网上购物平台，我们报告平均得分和平均成功率（%）。* 表示从（冯等人，2025）复现的结果。最佳结果和次佳结果分别以红色和蓝色高亮显示。

Method	ALFWorld							WebShop	
	Pick	Look	Clean	Heat	Cool	Pick2	All	Score	Succ.
<i>Closed-source LLMs</i>									
GPT-4o	75.3	60.8	31.2	56.7	21.6	49.8	48.0	31.8	23.7
Gemini-2.5-Pro	92.8	63.3	62.1	69.0	26.6	58.7	60.3	42.5	35.9
<i>Qwen2.5-7B-Instruct</i>									
Qwen2.5	33.4	21.6	19.3	6.90	2.80	3.20	14.8	26.4	7.80
<i>Prompt-based Agentic or Memory-based Methods</i>									
ReAct*	48.5	35.4	34.3	13.2	18.2	17.6	31.2	46.2	19.5
Reflexion*	62.0	41.6	44.9	30.9	36.3	23.8	42.7	58.1	28.8
Mem0	54.0	55.0	26.9	36.4	20.8	7.69	33.6	23.9	2.00
ExpeL	21.0	67.0	55.0	52.0	71.0	6.00	46.3	30.9	11.2
MemP	54.3	38.5	48.1	56.2	32.0	16.7	41.4	25.3	6.40
SimpleMem	64.5	33.3	20.0	12.5	33.3	3.84	29.7	33.2	8.59
<i>RL-based Methods</i>									
RLOO*	87.6	78.2	87.3	81.3	71.9	48.9	75.5	80.3	65.7
GRPO*	90.8	66.1	89.3	74.7	72.5	64.7	77.6	79.3	66.1
<i>Memory-Augmented RL-based Methods</i>									
MemRL	62.8	38.5	22.2	12.5	8.00	0.00	21.4	29.5	9.20
EvolveR	64.9	33.3	46.4	13.3	33.3	33.3	43.8	42.5	17.6
Mem0+GRPO	78.1	54.8	56.1	31.0	65.0	26.9	54.7	58.1	37.5
SimpleMem+GRPO	89.5	36.3	60.0	50.0	64.9	26.3	62.5	67.8	46.9
SKILLRL	97.9	71.4	90.0	90.0	95.5	87.5	89.9	85.2	72.7

复杂环境，在虚拟家庭环境上仅取得 21.4%。进化强化学习联合更新策略和记忆库，显示出改进（43.8%），但仍受限于对粗略轨迹存储的依赖。为了提供更具竞争力的基线，我们实现了记忆零加群体相对策略优化，将最先进的基于提示的记忆机制与优化后的策略模型相结合。虽然这种混合方法将虚拟家庭环境上的性能提升至 54.7%，网上购物平台上的性能提升至 37.5%，但仍大幅落后于技能强化学习（绝对成功率差距约 35.2%）。这些结果验证了我们的核心假设：有效的经验迁移需要高级技能抽象和共同演化的库，而非简单的轨迹压缩或基于提示的记忆检索。

与闭源模型的比较。值得注意的是，如表 1 所示，采用 Qwen2.5-7B-Instruct 的 SKILLRL 显著优于规模大得多的闭源模型。在 ALFWorld 上，本文方法比 GPT-4o（OpenAI，2024）高出 41.9%，比 Gemini-2.5-Pro（Comanici 等，2025）高出 29.6%。这表明有效的技能学习可以弥补模型规模的不足，使较小的开源模型能够通过结构化的经验知识实现更优的任务性能。

搜索增强问答的性能。如

表 2 所示，SKILLRL 达到了最先进的平均得分 47.1%，显著优于 Search-R1（38.5%）和 EvolveR（43.1%）。主要观察结果包括：1）优越的多跳推理：SKILLRL 在 Bamboogle 等复杂任务中表现出色，比 EvolveR 高出 19.4%。这表明分层技能能够有效指导多步信息综合。2）强大的泛化能力：尽管仅在有限数据集（NQ、HotpotQA）上训练，SKILLRL 在 TriviaQA 和 2Wiki 等分布外任务上仍保持有竞争力的性能，证实了蒸馏出的搜索策略是任务无关的。

4.3. 分析

本节详细分析各模块的有效性以及技能演化动态。

消融研究。我们进行了消融实验以评估各组件的贡献，结果见表 3。根据结果：（1）移除分层结构（即仅保留任务特定技能）使 ALFWorld 上的性能下降 13.1%，WebShop 上的性能下降 11.3%，表明通用策略原则提供了必要的基础指导。（2）用原始轨迹替换技能库导致性能下降最大（高达 25%），这

表 2. 搜索增强问答任务的性能。SKILLRL 在 NQ 和 HotpotQA 上训练。† 和 * 分别表示域内和域外数据集。* 表示从 (Sun 等, 2025) 复现的结果。

Method	Single-Hop QA			Multi-Hop QA				Avg.
	NQ [†]	TriviaQA [*]	PopQA [*]	HotpotQA [†]	2Wiki [*]	MuSiQue [*]	Bamboogle [*]	
Qwen2.5-7B-Instruct								
Qwen2.5 [*]	11.6	35.6	1.20	16.4	22.2	4.80	14.4	15.2
CoT [*]	12.8	35.6	3.80	16.2	22.6	6.60	24.0	17.4
RAG [*]	27.4	58.2	17.8	25.8	23.2	9.40	16.8	25.5
Search-o1 [*]	19.4	40.6	11.4	17.0	27.0	8.60	30.4	22.1
R1-Instruct	21.0	44.9	17.1	20.8	27.5	6.00	19.2	22.4
Search-R1	39.3	61.0	39.7	37.0	40.1	14.6	36.8	38.5
ZeroSearch	43.6	61.8	51.5	34.6	35.2	18.4	27.8	39.1
StepSearch	-	-	-	38.6	36.6	22.6	40.0	-
EvolveR	43.5	63.4	44.6	38.2	42.0	15.6	54.4	43.1
SKILLRL	45.9	63.3	45.9	43.2	40.3	20.2	73.8	47.1

表 3. 消融实验结果。我们报告在 ALFWorld 和 WebShop 上的平均成功率 (%)。

Method	ALFWorld	WebShop
SKILLRL	89.9	72.7
<i>Skill Library Ablations</i>		
w/o Hierarchical Structure	76.8	61.4
w/o Skill Library (Raw Trajectories)	61.7	50.2
<i>Training Pipeline Ablations</i>		
w/o Cold-Start SFT	65.2	46.5
w/o Dynamic Evolution	84.4	70.3

直接支持了我们的动机：抽象优于记忆。原始经验引入了显著的冗余和噪声，阻碍了有效的知识迁移。

(3) 冷启动监督微调被证明至关重要（没有它性能下降 20%），这证实了基础模型在进入强化学习阶段之前，需要一个初始的显式演示阶段来学习如何自适应地检索和利用抽象技能。

(4) 动态演化通过确保技能库是一个动态组件而非静态数据库，带来了 5.5% 的提升。这种协同演化使智能体能够通过解决初始技能集未涵盖的新出现的失败模式，迭代地优化其内部策略。

ALFWorld 上的逐任务分析。表 1 按任务类型分解了 ALFWorld 的性能。最大的提升出现在 PickTwo (+23%)、Cool (+22%) 和 Heat (+15%) 上，这些任务属于最具挑战性的任务，需要多步规划和状态跟踪。任务特定技能在这里特别有价值，它们捕捉了诸如“当拾取两个物体时，在寻找第二个之前先确认第一个已固定”等策略，以解决常见的失败模式。

技能库增长。图 3 展示了技能库在训练过程中的演化。初始技能库包含 55 项技能（12 项通用，43 项任务特定）。通过动态演化，到训练结束时（步骤 150）增长到 100 项技能。增长主要由任务特定技能驱动（从 43 项增加到 80 项），而通用技能




图 3. 强化学习训练期间技能库规模的演变。动态技能演化在验证检查点处添加技能。

技能数量呈现更稳定的增长（从 12 增至 20）。值得注意的是，我们观察到跨不同任务类别的均衡扩展，确保智能体为每次环境展开发展出专门化的专长。这种整体扩展反映了智能体在特定任务类型中不断完善其技能库并应对多样化场景的能力日益增强。

上下文效率。为评估技能抽象对推理开销的影响，我们将 SKILLRL 的平均提示长度与使用原始轨迹的记忆增强基线（Qwen2.5-7B with Raw Memory）进行比较，见

图 4。结果表明，原始记忆方法承受着较高且波动的令牌占用（平均 ~ 1,450 个令牌），而 SKILLRL 保持显著更精简的提示（平均 < 1,300 个令牌），实现了约 10.3% 的上下文长度缩减。这种效率源于我们的蒸馏机制，它将冗长的环境交互压缩为高密度、可操作的技能。值得注意的是，SKILLRL 在实现更优性能的同时所需上下文少于基于记忆的基线，表明技能抽象有效缓解了传统基于记忆的智能体中常见的上下文膨胀问题。




图 4. 原始记忆检索与我们的蒸馏技能抽象之间的提示长度（令牌数）比较。SKILLRL 在保持推理效用的同时持续降低上下文开销。




图 5. ALFWorld 验证集上的成功率。递归技能演化显著加速收敛并提升整体性能上限。

演化动态。图 5 展示了有无递归技能演化机制的强化学习训练曲线。我们观察到，虽然无演化的 SKILLRL 表现出稳步提升，但具备技能演化的 SKILLRL 展现出显著更高的学习率和更优的渐近性能。具体而言，SKILLRL 在 60 个训练步内达到超过 80% 的成功率，而基线方法需要约 90 步才能达到较低的峰值。这种收敛加速表明，动态引入新技能和精炼现有技能有效地为智能体提供了及时的策略指导，以克服局部最优。此外，更高的性能上限验证了技能库与策略的协同演化使智能体能够适应静态记忆方法无法解决的日益复杂的任务场景。

定性分析。为了进一步研究 SKILLRL 如何利用所学知识，我们在图 6 中可视化了 ALFWorld 和 WebShop 上的推理过程。案例研究表明，我们训练的智能体能够有效地从技能库中检索并执行相关技能来指导其决策。例如，在 WebShop 任务中，智能体调用通用策略，如“优先核心关键词”，并结合任务特定的启发式方法“聚焦关键查询”，以确保产品在有限预算内满足所有约束。类似地，在 ALFWorld 中，智能体协调分层技能，即使用“渐进式目标分解”进行高层规划，并使用“无器具先于对象”来避免常见的逻辑陷阱。这种通用技能与特定技能的无缝集成证实了智能体并非仅仅记忆轨迹，而是发展了对任务逻辑的结构化理解，从而实现更稳健、更高效的问题解决。

5. 相关工作

大语言模型智能体。能力强大的大语言模型的出现催化了自主智能体系统的快速发展 (Wei 等人, 2026)。ReAct (Yao 等人, 2022b) 将推理与行动交织在一起，实现了思维链风格的规划

交互过程中的学习，而反思 (Reflexion) (Shinn 等, 2023) 通过对过往失败的自我反思引入言语强化。AutoGen (Wu 等, 2024) 和 CAMEL (Li 等, 2023) 等框架展示了通用多智能体能力，具备自动化编排和多样化工具集成。虽然早期工作聚焦于编码或基础算术等受限任务，但这些方法主要依赖上下文学习 (In-Context Learning, ICL) (Dong 等, 2024)。然而，随着任务复杂度增加，这些智能体难以扩展，因为它们将每次交互视为孤立事件，且必须在没有任何先验知识的情况下从头开始每个新任务。

智能体中的记忆机制。为克服有限上下文窗口的限制以及智能体无法从经验中学习的缺陷，外部记忆架构已成为智能体设计的基石 (Hu 等, 2025; Wang, 2025)。早期系统主要采用静态检索增强生成 (RAG) 范式，或将原始轨迹存储为少样本示例 (Wang 等; Chhikara 等, 2025; Zhang 等, 2025a; Wang 等, 2024)。然而，原始轨迹通常占用大量令牌，且包含显著冗余和噪声，可能导致性能下降。当前研究已转向自改进记忆，将交互提炼为更高层次的洞见或程序性提示 (Wang 和 Chen, 2025; Tang 等, 2025; Fang 等, 2025; Zhao 等, 2024; Ouyang 等, 2025; Wei 等, 2025)。虽然近期一些工作探索通过在线训练更新记忆库以提高效率 (Zhang 等, 2025b; 2026)，但许多现有方法仍难以区分高价值经验与噪声，或未能提炼出可指导内部决策的核心原则。

智能体技能与强化学习的演进。智能体技能 (Anthropic, 2024) 作为紧凑、可复用的策略，捕捉子任务的本质，其发展日益通过持续学习 (Continual Learning, CL) 和强化学习 (RL) 的视角来审视。传统持续学习 (Parisi 等, 2019) 侧重于预定义任务中的知识保留，而自进化智能体 (Gao 等, 2025; Xia 等, 2025; Liu 等, 2025) 旨在开放环境中主动获取技能 (Fang 等, 2025; Wang 等,

WebShop

Task: I need a women's long sleeve button-down shirt in navy blue, size large, machine washable, price lower than \$40.00

--- Retrieved Skills ---

Detected Task Type: apparel

[General Skills] ... [Task-Specific Skills]

Step 1

Observation: WebShop homepage. Search bar available.

<think>Following skill [gen_001] 'Prioritize Core Keywords' and [app_001] 'Focus Key

Query': I should include product type + must-have attributes. My query should be ...</think>

<action>search[women long sleeve button down shirt navy blue machine ...]</action>

Step 9

Observation: Product page updated: Color = Navy Blue, Size = L. Price: \$29.99

<think>Applying skill [app_004] 'Check Variant Price': price for Navy Blue / L is \$29.99, which is under the \$40 budget. Also per [app_005] 'Confirm Hidden Specs': ... \$29.99 < \$40. Per skill [gen_013] 'Purchase Decisively', I should buy now.</think>

<action>click[Buy Now]</action> ✓

ALFWorld

Task: heat some egg and put it in countertop.

--- Retrieved Skills ---

Detected Task Type: heat

[General Skills] ... [Task-Specific Skills]

Step 1

Observation: You are in the middle of a room. Looking quickly around you...

<think>Per [gen_010] 'Progressive Goal Decomposition': sub-goals are ... Per [hea_004]

'No Appliance Before Object': I must NOT go to microwave first. Per [hea_001]

'Secure Exact Target First': find the egg. It's food — check fridge and

countertops.</think>

<action>go to countertop 1</action>

Step 8

Observation: You arrive at countertop 1

<think>Per [hea_005]: place the heated egg directly.</think>

<action>put egg 1 in/on countertop 1</action> ✓

图 6. SKILLRL 在 WebShop 和 ALFWorld 上的案例研究。示例展示了智能体如何在推理过程中自适应地检索并整合通用技能与任务特定技能，以实现精确高效的执行。

2025)。虽然强化学习被广泛用于对齐大语言模型 (Schulman 等, 2017; Ouyang 等, 2022), 或通过基于规则的验证器改进推理 (Shao 等, 2024), 但将其应用于智能体技能仍因奖励稀疏和长时程而具有挑战性。与以往将记忆视为静态或辅助来源的记忆增强强化学习不同, 近期趋势表明高效经验迁移的关键在于抽象 (Wu 等, 2025)。我们的工作在此基础上, 将技能库视为与智能体策略共同演化的动态组件, 利用强化学习通过递归失败分析来精炼结构化技能。

6. 结论

我们提出了 SKILLRL, 一个用于大语言模型智能体的技能增强强化学习框架。通过将原始轨迹提炼为紧凑、可复用的技能, 并在训练过程中实现技能的动态演化, SKILLRL 在 ALFWorld 和 WebShop 上达到了最先进的性能, 同时使用的上下文远少于基于记忆的方法。我们的工作表明, 从经验到技能的抽象是构建能力强、样本高效智能体的有力原则。

致谢

本工作部分得到了亚马逊研究奖、思科教师研究奖、NEC Laboratories America 研究基金以及 Coefficient Giving 的支持。

参考文献

Ahmadian, A., Cremer, C., Gallé, M., Fadaee, M., Kreutzer, J., Pietquin, O., Üstün, A., and Hooker, S. Back to basics: Revisiting reinforce-style optimization for learning from human feedback in llms. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 12248–12267,

2024.

Anthropic. The claude 3 model family: Opus, sonnet, haiku, 2024. URL <https://www.anthropic.com/news/claude-3-family>.

Bai, J., Bai, S., Chu, Y., Cui, Z., Dang, K., Deng, X., Fan, Y., Ge, W., Han, Y., Huang, F., et al. Qwen technical report. *arXiv preprint arXiv:2309.16609*, 2023.

Chhikara, P., Khant, D., Aryan, S., Singh, T., and Yadav, D. Mem0: Building production-ready ai agents with scalable long-term memory. *arXiv preprint arXiv:2504.19413*, 2025.

Comanici, G., Bieber, E., Schaekermann, M., Pasupat, I., Sachdeva, N., Dhillon, I., Blistein, M., Ram, O., Zhang, D., Rosen, E., et al. Gemini 2.5: Pushing the frontier with advanced reasoning, multimodality, long context, and next generation agentic capabilities. *arXiv preprint arXiv:2507.06261*, 2025.

Dong, Q., Li, L., Dai, D., Zheng, C., Ma, J., Li, R., Xia, H., Xu, J., Wu, Z., Chang, B., et al. A survey on in-context learning. In *Proceedings of the 2024 conference on empirical methods in natural language processing*, pp. 1107–1128, 2024.

Fang, R., Liang, Y., Wang, X., Wu, J., Qiao, S., Xie, P., Huang, F., Chen, H., and Zhang, N. Memp: Exploring agent procedural memory. *arXiv preprint arXiv:2508.06433*, 2025.

Feng, L., Xue, Z., Liu, T., and An, B. Group-in-group policy optimization for llm agent training. *arXiv preprint arXiv:2505.10978*, 2025.

Gao, H.-a., Geng, J., Hua, W., Hu, M., Juan, X., Liu, H., Liu, S., Qiu, J., Qi, X., Wu, Y., et al. A survey of self-evolving agents: On path to artificial super intelligence. *arXiv preprint arXiv:2507.21046*, 2025.

- Google. Try deep research and our new experimental model in gemini, your ai assistant, 2024. URL <https://blog.google/products/gemini/google-gemini-deep-research/>.
- Google. Introducing the gemini 2.5 computer use model, 2025. URL <https://blog.google/technology/google-deepmind/gemini-computer-use-model/>.
- Guo, D., Yang, D., Zhang, H., Song, J., Zhang, R., Xu, R., Zhu, Q., Ma, S., Wang, P., Bi, X., et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. *arXiv preprint arXiv:2501.12948*, 2025.
- Ho, X., Nguyen, A.-K. D., Sugawara, S., and Aizawa, A. Constructing a multi-hop qa dataset for comprehensive evaluation of reasoning steps. In *Proceedings of the 28th International Conference on Computational Linguistics*, pp. 6609–6625, 2020.
- Hu, Y., Liu, S., Yue, Y., Zhang, G., Liu, B., Zhu, F., Lin, J., Guo, H., Dou, S., Xi, Z., et al. Memory in the age of ai agents. *arXiv preprint arXiv:2512.13564*, 2025.
- Jin, B., Zeng, H., Yue, Z., Yoon, J., Arik, S., Wang, D., Zamani, H., and Han, J. Search-r1: Training llms to reason and leverage search engines with reinforcement learning. *arXiv preprint arXiv:2503.09516*, 2025.
- Joshi, M., Choi, E., Weld, D. S., and Zettlemoyer, L. Triviaqa: A large scale distantly supervised challenge dataset for reading comprehension. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 1601–1611, 2017.
- Kwiatkowski, T., Palomaki, J., Redfield, O., Collins, M., Parikh, A., Alberti, C., Epstein, D., Polosukhin, I., Devlin, J., Lee, K., et al. Natural questions: a benchmark for question answering research. *Transactions of the Association for Computational Linguistics*, 7:453–466, 2019.
- Li, G., Hammoud, H., Itani, H., Khizbullin, D., and Ghanem, B. Camel: Communicative agents for” mind” exploration of large language model society. *Advances in Neural Information Processing Systems*, 36:51991–52008, 2023.
- Li, X., Dong, G., Jin, J., Zhang, Y., Zhou, Y., Zhu, Y., Zhang, P., and Dou, Z. Search-o1: Agentic search-enhanced large reasoning models. *arXiv preprint arXiv:2501.05366*, 2025.
- Liu, J., Xiong, K., Xia, P., Zhou, Y., Ji, H., Feng, L., Han, S., Ding, M., and Yao, H. Agent0-vl: Exploring self-evolving agent for tool-integrated vision-language reasoning. *arXiv preprint arXiv:2511.19900*, 2025.
- Liu, J., Su, Y., Xia, P., Han, S., Zheng, Z., Xie, C., Ding, M., and Yao, H. Simplemem: Efficient lifelong memory for llm agents. *arXiv preprint arXiv:2601.02553*, 2026.
- Mallen, A., Asai, A., Zhong, V., Das, R., Khashabi, D., and Hajishirzi, H. When not to trust language models: Investigating effectiveness of parametric and non-parametric memories. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 9802–9822, 2023.
- OpenAI. Gpt-4o system card, 2024. <https://openai.com/index/gpt-4o-system-card/>.
- OpenAI. Introducing o3 and o4-mini, 2025a. <https://openai.com/index/introducing-o3-and-o4-mini/>.
- OpenAI. Openai deep research system card, 2025b. URL <https://openai.com/index/introducing-deep-research/>.
- OpenAI. Openai computer-using agent, 2025c. URL <https://openai.com/index/computer-using-agent/>.
- Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C., Mishkin, P., Zhang, C., Agarwal, S., Slama, K., Ray, A., et al. Training language models to follow instructions with human feedback. *Advances in neural information processing systems*, 35:27730–27744, 2022.
- Ouyang, S., Yan, J., Hsu, I., Chen, Y., Jiang, K., Wang, Z., Han, R., Le, L. T., Daruki, S., Tang, X., et al. Reasoningbank: Scaling agent self-evolving with reasoning memory. *arXiv preprint arXiv:2509.25140*, 2025.
- Parisi, G. I., Kemker, R., Part, J. L., Kanan, C., and Wermter, S. Continual lifelong learning with neural networks: A review. *Neural networks*, 113:54–71, 2019.
- Press, O., Zhang, M., Min, S., Schmidt, L., Smith, N. A., and Lewis, M. Measuring and narrowing the compositionality gap in language models. In *Findings of the Association for Computational Linguistics: EMNLP 2023*, pp. 5687–5711, 2023.
- Schulman, J., Wolski, F., Dhariwal, P., Radford, A., and Klimov, O. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- Shao, Z., Wang, P., Zhu, Q., Xu, R., Song, J., Bi, X., Zhang, H., Zhang, M., Li, Y., Wu, Y., et al. Deepseekmath: Pushing the limits of mathematical reasoning in open language models. *arXiv preprint arXiv:2402.03300*, 2024.
- Shinn, N., Cassano, F., Gopinath, A., Narasimhan, K., and Yao, S. Reflexion: Language agents with verbal reinforcement learning. *Advances in Neural Information Processing Systems*, 36:8634–8652, 2023.

- Shridhar, M., Yuan, X., Cote, M.-A., Bisk, Y., Trischler, A., and Hausknecht, M. Alfworld: Aligning text and embodied environments for interactive learning. In *International Conference on Learning Representations*.
- Sun, H., Qiao, Z., Guo, J., Fan, X., Hou, Y., Jiang, Y., Xie, P., Zhang, Y., Huang, F., and Zhou, J. Zeroscore: Incentivize the search capability of llms without searching. *arXiv preprint arXiv:2505.04588*, 2025.
- Tang, X., Qin, T., Peng, T., Zhou, Z., Shao, D., Du, T., Wei, X., Xia, P., Wu, F., Zhu, H., et al. Agent kb: Leveraging cross-domain experience for agentic problem solving. *arXiv preprint arXiv:2507.06229*, 2025.
- Team, T. D., Li, B., Zhang, B., Zhang, D., Huang, F., Li, G., Chen, G., Yin, H., Wu, J., Zhou, J., et al. Tongyi deepsearch technical report. *arXiv preprint arXiv:2510.24701*, 2025.
- Trivedi, H., Balasubramanian, N., Khot, T., and Sabharwal, A. Musique: Multihop questions via single-hop question composition. *Transactions of the Association for Computational Linguistics*, 10:539–554, 2022.
- Wang, G., Xie, Y., Jiang, Y., Mandlkar, A., Xiao, C., Zhu, Y., Fan, L., and Anandkumar, A. Voyager: An open-ended embodied agent with large language models. *Transactions on Machine Learning Research*.
- Wang, Y. *From Static Parameters to Updatable Memory: Enabling Large Language Model Agents to Remember, Adapt, and Learn*. PhD thesis, University of California, San Diego, 2025.
- Wang, Y. and Chen, X. Mirix: Multi-agent memory system for llm-based agents. *arXiv preprint arXiv:2507.07957*, 2025.
- Wang, Y., Takanobu, R., Liang, Z., Mao, Y., Hu, Y., McAuley, J., and Wu, X. Mem- $\{\alpha\}$: Learning memory construction via reinforcement learning. *arXiv preprint arXiv:2509.25911*, 2025.
- Wang, Z. Z., Mao, J., Fried, D., and Neubig, G. Agent workflow memory. *arXiv preprint arXiv:2409.07429*, 2024.
- Wei, T., Sachdeva, N., Coleman, B., He, Z., Bei, Y., Ning, X., Ai, M., Li, Y., He, J., Chi, E. H., et al. Evo-memory: Benchmarking llm agent test-time learning with self-evolving memory. *arXiv preprint arXiv:2511.20857*, 2025.
- Wei, T., Li, T.-W., Liu, Z., Ning, X., Yang, Z., Zou, J., Zeng, Z., Qiu, R., Lin, X., Fu, D., et al. Agentic reasoning for large language models. *arXiv preprint arXiv:2601.12538*, 2026.
- Wu, Q., Bansal, G., Zhang, J., Wu, Y., Li, B., Zhu, E., Jiang, L., Zhang, X., Zhang, S., Liu, J., et al. Autogen: Enabling next-gen llm applications via multi-agent conversations. In *First Conference on Language Modeling*, 2024.
- Wu, R., Wang, X., Mei, J., Cai, P., Fu, D., Yang, C., Wen, L., Yang, X., Shen, Y., Wang, Y., et al. Evolver: Self-evolving llm agents through an experience-driven lifecycle. *arXiv preprint arXiv:2510.16079*, 2025.
- Xia, P., Zeng, K., Liu, J., Qin, C., Wu, F., Zhou, Y., Xiong, C., and Yao, H. Agent0: Unleashing self-evolving agents from zero data via tool-integrated reasoning. *arXiv preprint arXiv:2511.16043*, 2025.
- Yang, Z., Qi, P., Zhang, S., Bengio, Y., Cohen, W., Salakhutdinov, R., and Manning, C. D. Hotpotqa: A dataset for diverse, explainable multi-hop question answering. In *Proceedings of the 2018 conference on empirical methods in natural language processing*, pp. 2369–2380, 2018.
- Yao, S., Chen, H., Yang, J., and Narasimhan, K. Webshop: Towards scalable real-world web interaction with grounded language agents. *Advances in Neural Information Processing Systems*, 35:20744–20757, 2022a.
- Yao, S., Zhao, J., Yu, D., Du, N., Shafraan, I., Narasimhan, K. R., and Cao, Y. React: Synergizing reasoning and acting in language models. In *The eleventh international conference on learning representations*, 2022b.
- Zhang, G., Fu, M., Wan, G., Yu, M., Wang, K., and Yan, S. G-memory: Tracing hierarchical memory for multi-agent systems. *arXiv preprint arXiv:2506.07398*, 2025a.
- Zhang, G., Ren, H., Zhan, C., Zhou, Z., Wang, J., Zhu, H., Zhou, W., and Yan, S. Memevolve: Meta-evolution of agent memory systems. *arXiv preprint arXiv:2512.18746*, 2025b.
- Zhang, S., Wang, J., Zhou, R., Liao, J., Feng, Y., Zhang, W., Wen, Y., Li, Z., Xiong, F., Qi, Y., et al. Memrl: Self-evolving agents via runtime reinforcement learning on episodic memory. *arXiv preprint arXiv:2601.03192*, 2026.
- Zhao, A., Huang, D., Xu, Q., Lin, M., Liu, Y.-J., and Huang, G. Expel: Llm agents are experiential learners. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 38, pp. 19632–19642, 2024.
- Zheng, X., An, K., Wang, Z., Wang, Y., and Wu, Y. Stepsearch: Igniting llms search ability via step-wise proximal policy optimization. In *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, pp. 21816–21841, 2025.

附录

A. 提示词

本节提供框架各阶段使用的完整提示词模板。这些模板旨在确保智能体行为一致，并在不同环境中生成结构化数据。

A.1. 智能体执行提示词

以下提示词用于在线推理阶段。这些模板为智能体提供当前任务描述、历史交互记录以及一组检索到的技能（经验），以指导其决策过程。提示词明确要求在动作选择前进行思维链（Chain-of-Thought, CoT）推理步骤。

提示词 A.1：带技能的 ALFWorld 智能体执行 系统提示词：你是运行在 ALFRED 具身环境中的专家智能体。你的

任务是： { 任务描述 }

检索到的相关经验 { 检索到的记忆 }

当前进度 在此步骤之前，您已经采取了 { 步数 } 步。以下是最近的 { 历史长度 } 条观察记录以及您采取的相应动作： { 动作历史 } 您现在处于第 { 当前步骤 } 步，当前观察为： { 当前观察 } 当前情况下的可采纳动作为： [{ 可采纳动作 }]。

现在轮到您采取一个动作。您应首先逐步推理当前情况。此推理过程必须包含在<think> </think>标签内。完成推理后，您应为当前步骤选择一个可采纳动作，并将其呈现在<action> </action>标签内。

提示 A.2：具备技能的 WebShop 智能体执行 系统提示：您是在 WebShop 电子商务环境中运行的专家自主智能体。您的任务

是： { 任务描述 }。

检索到的相关经验 { 检索到的记忆 }

当前进度 在此步骤之前，您已经采取了 { 步数 } 步。以下是最近的 { 历史长度 } 条观察记录以及您采取的相应动作： { 动作历史 } 您现在处于第 { 当前步骤 } 步，当前观察为： { 当前观察 } 当前情况下的可采纳动作为： [{ 可用动作 }]。

现在轮到您为当前步骤采取一个动作。您应首先逐步推理当前情况，然后仔细思考哪个可采纳动作最能推进购物目标。此推理过程必须包含在<think> </think>标签内。完成推理后，您应为当前步骤选择一个可采纳动作，并将其呈现在<action> </action>标签内。

A.2 技能生成与蒸馏提示

这些提示在技能发现和库初始化阶段使用。它们引导高能力教师模型分析交互轨迹、识别失败模式，并将可复用的、可操作的技能提炼为结构化的 JSON 格式。

提示 B.1: 从失败中动态发现技能 分析这些失败的 `{ 环境描述 }` 智能体轨迹，并建议要添加的新技能。

失败的轨迹: `{failure_examples}`
 现有技能标题: `{existing_titles}`

生成 1-3 个新的可操作技能，以帮助避免这些失败。每个技能必须包含：技能 ID、标题（3-5 个词）、原则（1-2 句话）、何时应用。技能 ID 应唯一，并遵循以下模式：“dyn 001”、“dyn 002”等。

仅返回技能的 JSON 数组，不要包含其他文本。

提示 B.2: 初始技能提炼 (ALFWorld) 您是提炼智能体行为模式为简洁、可操作技能的专家。分析这些来自在家庭环境 (ALFWorld) 中运行的具身智能 (Embodied AI) 智能体的成功与失败轨迹。

成功轨迹: `{success_patterns}`
 失败的轨迹: `{failure_patterns}`

生成 8-12 条适用于所有任务类型的通用技能。这些技能应：1. 简洁；2. 可操作；3. 可迁移；4. 具备失败意识。重点关注：导航、物体操作、状态跟踪、错误恢复以及容器交互规则。

仅返回 JSON 数组，不要包含其他文本。

提示 B.3: 初始技能蒸馏 (WebShop) 您是提炼智能体行为模式为简洁、可操作技能的专家。分析这些来自在线购物环境 (WebShop) 中运行的 AI 智能体的成功与失败轨迹。

成功轨迹: `{success_patterns}`
 失败的轨迹: `{failure_patterns}`

生成 10-15 条通用技能。重点关注：搜索查询构建、产品选择启发式、选项配置（尺寸、颜色等）、约束验证、导航模式以及价格处理。

仅返回 JSON 数组，不要包含其他文本。

A.3. 冷启动轨迹生成提示

为弥合基础模型与目标性能之间的差距，我们使用以下提示生成高质量合成轨迹，用于监督微调 (SFT)。这些提示指示教师模型在解决任务的同时明确展示特定技能的应用，从而为学生模型提供清晰的学习信号。

提示 C.1: 合成轨迹生成 (ALFWorld) 您是 ALFRED 具身环境中的专家智能体。您将获得一个任务和可应用的技能。您的目标是生成一条成功运用这些技能的轨迹。

您应生成一条逐步轨迹，该轨迹应：

1. 恰当地使用所提供的技能；
2. 在环境中采取现实可行的动作；
3. 成功完成任务；
4. 展示良好的规划和系统化探索。

对于每一步，您应：

- 使用 `<think></think>` 标签思考当前情况。
- 使用 `<action></action>` 标签选择合适的动作。
- 动作应为简单命令，如“走到柜子 1”、“打开抽屉 2”、“拿起苹果 1”、“将苹果 1 放在台面 1 上/里”。

生成从起点到终点的完整轨迹。任务完成时停止。

Prompt C.2: Synthetic Trajectory Generation (WebShop)

You are an expert shopping agent in the WebShop e-commerce environment. You will be given a shopping task and relevant skills to apply. Your goal is to generate a successful trajectory that demonstrates proper use of these skills.

You should generate a step-by-step trajectory that:

1. Uses the provided skills appropriately;
2. Takes realistic actions in the WebShop environment;
3. Successfully finds and purchases the requested product;
4. Demonstrates good search strategies and product evaluation.

For each step, you should:

- Think through the current situation using `<think></think>` tags.
- Choose an appropriate action using `<action></action>` tags.
- Actions can be: `search[query]`, `click[element]`, or `buy now`.

Generate a complete trajectory from start to finish. Stop when the purchase is complete.

B. 附加实验细节

B.1. 超参数

表 4. SKILLRL 的超参数。

Hyperparameter	Value
<i>Cold-Start SFT</i>	
Learning rate	1×10^{-4}
Batch size	16
Epochs	3
SFT examples	7,500 (AlfWorld) / 2,400 (WebShop)
<i>RL Training</i>	
Learning rate	1×10^{-6}
Batch size	64
KL loss Coef	0.01
Invalid Action Penalty Coef	0.1
Max Prompt Length	6,000
Max Response Length	1,024
Epoch	150
<i>Skill Retrieval</i>	
Top-K retrieval	6
Validation interval	5 Steps
Update Threshold δ	0.4
Max failures analyzed	10 ($SR < 0.4$) / 5 ($SR > 0.4$)
Max new skills per evolution	3

B.2. 计算资源

所有实验均在配备 8 块 NVIDIA H100 80GB GPU 的集群上进行。训练时间：

- 轨迹收集：3 小时
- 技能蒸馏：0.5 小时
- 冷启动监督微调：2 小时
- 强化学习训练：24 小时

表 5. 从技能库中提取的 ALFWorld 示例蒸馏技能（Shridhar 等人）。本表总结了从原始轨迹中推导出的一般模式和应用逻辑。

ID	Skill Title	Principle (Actionable Pattern)	When to Apply
<i>General Exploration & Acquisition Skills</i>			
gen_001	Systematic Exploration	Search every plausible surface or container exactly once before revisiting; prioritize unseen locations.	Anytime the goal count is not met and unexplored areas remain.
gen_002	Immediate Acquisition	As soon as a required object becomes visible and reachable, take it immediately.	Upon first visual confirmation of a goal-relevant object.
gen_003	Destination First Policy	After picking up a goal object, navigate directly to the known target receptacle and place it.	Holding any goal object while target location is identified.
<i>State-Changing & Spatial Relation Skills</i>			
gen_005	Use State-Changing Tools Early	Acquire the object, then immediately use the nearest suitable appliance (heat/cool/clean) before placement.	After picking up an object requiring temperature or cleanliness change.
gen_006	Establish Spatial Relations	First locate the reference object, adjust its state if needed, then search or place in the specified region.	Tasks containing prepositions like “under”, “inside”, or “on”.
<i>Reliability & Error Recovery</i>			
gen_014	Loop Escape Trigger	If the last 3–5 actions do not change the state, switch to an untried search branch or action type.	After several consecutive no-progress observations.
gen_015	Pre-Action Sanity Check	Confirm prerequisites (hand free, capacity, power) before executing manipulative commands.	Right before issuing any command that could legally fail.

表 6. ALFWorld 常见智能体失败与缓解策略。

ID	Failure Description	Root Cause (Why it happens)	Mitigation (How to avoid)
err_001	Redundant Revisit	Lacks explicit memory of explored areas; strategy degenerates into local loops.	Maintain an exploration map; prioritize unvisited candidates.
err_006	Skipping State Changes	Conflates object presence with goal satisfaction; omits cleanliness/temp checks.	Integrate state precondition checks into the planner before placement.

总墙钟时间：每次实验约 30 小时。

C. 技能库示例

在本节中，我们提供 ALFWorld 和 WebShop 环境的蒸馏技能与错误分类示例目录。表 5 和表 7 分别详细说明了为具身操作和基于网络的购物所蒸馏的一般技能，突出了系统探索和约束满足所需的可操作原则。此外，我们在表 6 和表 8 中提供了失败案例的结构化分析，对常见错误进行了分类，从 ALFWorld 中的空间推理循环到 WebShop 中的价格变动疏忽，并给出了根本原因和拟议的缓解策略。

表 7. WebShop 导航的示例蒸馏技能 (Yao 等人, 2022a)。这些技能代表了智能体处理大规模产品搜索和约束满足所使用的策略模式。

ID	Skill Title	Principle (Actionable Pattern)	When to Apply
<i>Search & Query Engineering</i>			
gen_001	Prioritize Core Keywords	Include product type, 1-2 functional attributes, and hard constraints; omit secondary descriptors.	Before issuing the first search or refining over-specific queries.
gen_002	Iterative Refinement	Adjust keywords or apply site filters instead of repeating the same failed query.	When results are irrelevant or repeat despite multiple searches.
<i>Product Evaluation & Verification</i>			
gen_003	Scan Before You Click	Read titles, thumbnails, and prices in results to ensure plausibility before opening a link.	On search results pages when choosing the next product to inspect.
gen_004	Verify Early, Abort Fast	Immediately check category, attributes, and price on the product page; leave if any constraint is violated.	Within the first observation on every product detail page.
gen_006	Confirm Hidden Attributes	Open Description/Features sections to ensure non-visible specs (e.g., material) meet constraints.	When constraints are not evident from the title or variant list.
<i>Configuration & Transaction</i>			
gen_005	Set Mandatory Variants	Always select required options (size, color, etc.) before evaluating price or purchasing.	After confirming product match but before any purchase action.
gen_007	Check Variant Pricing	For price ranges, select the exact variant combination to verify the specific price is within budget.	Whenever price changes with variant selection or shows as a range.
gen_013	Purchase Decisively	Execute 'Buy Now' immediately once all constraints and prices are confirmed on a variant.	After validating every constraint on the current product variant.

表 8. 网络购物任务中的常见失败。

ID	Failure Description	Root Cause	Mitigation Strategy
err_001	Missing Constraints in Query	Omits size or price caps, leading to overwhelming or irrelevant result sets.	Assemble full requirement list first; ensure every hard constraint is in the query string.
err_004	Price Shift Oversight	Fails to notice price changes after selecting a specific size or color variant.	Re-read the price element after every option change before proceeding to checkout.
err_005	Premature Purchase	Clicks "Buy Now" without setting mandatory variants, leading to errors or wrong items.	Validate that every required dropdown/radio option is explicitly selected before buying.
err_009	Ignoring Stock Status	Attempts to purchase out-of-stock items by ignoring disabled buttons or stock labels.	Verify that the 'Add to Cart' button is enabled and no 'Out of Stock' message is present post-selection.
err_011	Sponsored Link Distraction	Clicks loosely matched ads, diverting the workflow from organic, suitable products.	Implement ad-label detection; prioritize organic listings for higher constraint reliability.

D. 附加案例

Case 1: WebShop Footwear (Functional Constraints)

Task: I want a pair of men's black slip-resistant work shoes, size 10, rubber sole, price lower than \$50.00.

技能 [foo 002] 验证描述中的特性；[foo 004] 选择变体后确认价格。避免 [err 001] 遗漏价格上限；[err 003] 选择错误的商品类别。

Agent Trajectory with Skill-Guided Reasoning

- | | |
|---------------|--|
| Step 1 | Obs: WebShop homepage.
Think: Per [gen_001], I'll include key constraints (type, function, color, price) in the query.
Action: search[men black slip resistant work shoes rubber sole under 50] |
| Step 2 | Obs: Results: [1] Chef Shoes \$38.99; [2] Kitchen Shoes \$42.50; [3] Steel Toe Boots \$55.99.
Think: [gen_003] Item [1] is under budget and matches function. Item [3] is over budget (skip).
Action: click[Item 1] |
| Step 3 | Obs: Product page. Price: \$35.99-\$45.99. Colors: Black, White. Sizes: 7-12.
Think: [foo_002] Description confirms rubber sole. Now selecting Black and Size 10 [foo_003].
Action: click[Black] → click[10] |
| Step 5 | Obs: Selected: Black, Size 10. Price updated to \$38.99.
Think: [foo_004] \$38.99 < \$50. All constraints (color, size, function, price) are satisfied.
Action: click[Buy Now] |

结果: 成功 —— 以 38.99 美元购得。关键技能: [示例 002] (验证), [示例 004] (价格核查)。

Case 2: Electronics (Speaker with Abort-and-Retry)

Task: I need a portable bluetooth speaker, waterproof, black color, price lower than \$30.00.

技能 [元素 001] 约束丰富的搜索；[元素 004] 不匹配时快速退出；[生成 002] 迭代细化。避免 [错误 002] 搜索中过于具体的变体名称；[元素 006] 避免点击循环。

Agent Trajectory: Handling Missing Constraints

- | | |
|---------------|---|
| Step 1 | Obs: WebShop homepage.
Think: [ele_001] Packing all mandatory attributes: portable, bluetooth, waterproof, black, < \$30.
Action: search[portable bluetooth speaker waterproof black under 30] |
| Step 2 | Obs: Results: [1] Waterproof Speaker \$28.99; [2] Mini LED Speaker \$19.99; [3] 20W Speaker \$35.50.
Think: [ele_005] Item [1] matches most keywords and price.
Action: click[Item 1] |
| Step 3 | Obs: Product page (Item 1). Colors: Blue, Red, Green, Army Green. Black unavailable.
思考: [生成 004] 尽早验证, 快速中止: 没有黑色选项! [ele 004] 立即退出以寻找另一个候选。
Action: click[Back to Search] |
| Step 4 | Obs: Back on search results.
Think: [gen_002] Iterative refinement. Item [2] \$19.99 is the next best candidate.
Action: click[Item 2] |
| Step 5 | Obs: Product page (Item 2). Colors: Black, Blue, Red. Specs: IPX5 Waterproof.
Think: [ele_002] Black is available! IPX5 confirms waterproof. Selecting Black.
Action: click[Black] |
| Step 6 | Obs: Black selected. Final price: \$19.99.
Think: [ele_003] \$19.99 < \$30. All specs (black, portable, waterproof) verified.
Action: click[Buy Now] |

结果: 成功 —— 通过提前退出高效处理属性不匹配。应用的关键技能: [第 004 代] (快速中止), [第 004 元素] (不匹配时退出)。

案例 1: ALFWorld 清洁任务 (生菜) → Sink → Countertop)

Task: Clean some lettuce and put it in countertop.

核心技能 [cle 001] 分阶段计划 (定位 → 清洁 → 放置); [cle 006] 使用位置先验 (食物放冰箱)。避免的错误 [err 002] 跳过封闭容器; [err 003] 忽略可见目标物体。

Step 1-3 **Obs:** 冰箱 1 是关闭的。动作: 打开冰箱 1 → 拿生菜 1
Reasoning: Per [cle_006], food is likely in the fridge. [gen_002] Grab lettuce immediately on sight.

Step 4-6 **Obs:** Arrive at sinkbasin 1. **Action:** clean lettuce 1 with sinkbasin 1
Reasoning: Per [cle_001] Phase 2: bring to water source. [cle_003] Go straight to sink.

Step 7 **Obs:** Arrive at countertop 1. **Action:** put lettuce 1 in/on countertop 1
Reasoning: Per [gen_003] Destination First: place cleaned object immediately to finish.

结果: 成功 (7 步) — 使用的技能: [第 010 代] (分解), [第 003 号] (先用水槽)。

案例 2: ALFWorld 加热任务 (鸡蛋) → Microwave → Countertop)

Task: Heat some egg and put it in countertop.

核心技能 [hea 001] 先确保精确目标; [hea 003] 打开-放置-加热顺序; [hea 004] 拿到物品前不使用电器。

Step 1-3 **Obs**
台面 1 (无鸡蛋) → 台面 2 (发现鸡蛋)。动作: 拿起鸡蛋 1 推理: [hea 004] 在持有物品前避免使用微波炉。[hea 002] 系统搜索台面。

Step 4-6 **Obs**
微波炉 1 是关闭的。动作: 打开微波炉 1 → 加热鸡蛋 1 推理: [hea 003] 正确顺序: 先开门, 再启动状态变化。

Step 7-8 **Obs**
鸡蛋已加热。动作: 走到台面 1 → 放下鸡蛋 1 推理: [hea 005] 加热后直接放置: 不绕路直接移动到目标。

结果: 成功 (8 步) — 使用的技能: [hea 001] (目标优先), [hea 004] (顺序控制)。

案例 3: ALFWorld 检查任务 (铅笔) ⊕ Desklamp → Success)

Task: Look at pencil under the desklamp.

核心技能 [loo 001] 寻找台灯表面 (书桌/边桌); [loo 002] 打开台灯; [exa 001] 尽早配对物体 (目标与工具共置)。避免的错误 [err 003] 忽略可及的目标; [loo 005] 防止动作循环 (仅切换一次)。

Agent Trajectory: High-Efficiency Co-location Handling

Step 1 **Obs**
房间中部。可见: 书桌 1/2、抽屉 1-3、边桌 1 等。推理: [loo 001] 台灯通常放在书桌上。优先前往书桌 1, 以便同时找到铅笔和台灯。动作: 前往书桌 1

Step 2 **Obs**
在书桌 1 上: 闹钟 1、台灯 1、铅笔 1。推理: [示例 001] 成功共置! 两个物体均在此处。[示例 002] 先拾取目标物体, 再与工具交互。
Action: take pencil 1 from desk 1

Step 3 **Obs**
持有铅笔 1。推理: [loo 002] 切换台灯状态以满足“光照下”条件。[exa 004] 单次切换规则确保无重复动作。
Action: use desklamp 1

结果: 成功 (最优 3 步) —— 展示了卓越的空间推理能力和零浪费导航。关键技能: [示例 001] (物体配对), [留一法 001] (空间先验)。