

EVOLM: 通过协同演化的判别性评分标准实现语言模型自我进化

Shuyue Stella Li^{1*}, Rui Xin^{1*}, Teng Xiao², Yike Wang¹, Rulin Shao¹, Zoey Hao³
Melanie Sclar¹, Sewoong Oh¹, Faeze Brahman², Pang Wei Koh^{1,2}, Yulia Tsvetkov¹

¹University of Washington, ²Allen Institute for AI, ³University of Pennsylvania
{stellli, rx31}@cs.washington.edu

 <https://github.com/stellalisy/EvoLM>

 <https://huggingface.co/stellalisy/EvoLM-8B>

摘要

语言模型从预训练中编码了大量评估性知识，然而当前的后训练方法依赖外部监督（人工标注、专有模型或标量奖励模型）来产生奖励信号。每种方式都设定了上限。人类判断无法监督超出其自身能力的行为，专有应用程序编程接口（API）造成依赖，可验证奖励仅覆盖具有标准答案的领域。利用模型自身评估能力进行自我改进是一种随模型本身扩展的奖励来源，但当前方法在很大程度上尚未开发这一来源。本文提出 EVOLM，一种后训练方法，将这种能力结构化为一显式的判别性评分标准，并将其用作训练信号。EVOLM 在单一语言模型内交替训练两种能力：（1）一个评分标准生成器，产生针对具体实例的评估标准，并针对判别效用进行优化，以最大化一个小型冻结评判模型区分偏好与非偏好响应的能力；（2）一个策略，使用以评分标准为条件的分数作为奖励进行训练。所有偏好信号均通过策略自身输出与早期检查点的时间对比构建，无需人工标注或外部监督。EVOLM 训练一个 Qwen3-8B 模型生成评分标准，在 RewardBench-2 上比 GPT-4.1 高出 25.7%。协同训练的策略在 OLMo3-Adapt 套件上平均达到 69.3%，比使用 GPT-4.1 提示评分标准训练的策略高出 3.9%，比最先进的 8B 奖励模型 SkyWork-RM 高出 16%。总体而言，EVOLM 证明，将模型的评估能力结构化为一协同演化的判别性评分标准，能够在无外部监督的情况下实现自我改进。




图 1: EVOLM 概览。 本方法使单一语言模型能够协同演化其自身的评估与生成能力。通过将潜在知识提取为显式的、针对具体实例的评分标准，EVOLM 创建了一个自主反馈回路，在无需人工标注或外部教师模型的情况下提升策略性能。

1 引言

强化学习（Reinforcement Learning, RL）已成为语言模型（Language Model, LM）后训练的核心，推动了指令遵循、推理和安全性方面的改进（Ouyang et al., 2022; Bai et al., 2022）。奖励信号的质量从根本上制约了策略能够学习的内容。当前方法从外部监督中获取该信号，包括人类偏好标注（Christiano et al., 2017）、易受奖励黑客行为影响的标量奖励模型（Stiennon et al., 2020; Gao et al., 2023）、仅限于具有真实答案领域的可验证奖励（Lambert et al., 2024; Cobbe et al., 2021），以及专有的大模型作为评审评估（Zheng et al., 2023）。然而，语言模型在预训练中已经编码了大量评估性知识（Feng et al., 2025）；强化学习使这些知识得以显现并加以强化，而非引入新知识（Shao et al., 2026）。如何将这些知识组织成能够实现可靠评分的结构，仍是自我改进的核心挑战。

在不可验证的领域中，评估可以分解为准则生成（明确要测度的内容）和评判（依据这些准则进行评分）。这种分解将模型的评估性知识外化为结构化准则，使得即使是一个小型评判器，在获得其自身无法推导出的具体准则时，也能可靠地进行评分。该分解还提供了可解释性，即准则使评估标准可被检查；以及模块化，即使用一个评判器训练的准则生成器可以部署到另一个评判器上。越来越多的研究将准则应用于强化学习后训练，但现有方法依赖于外部监督，例如任务特定的验证器或标注的偏好数据（Sheng et al., 2026; Xu et al., 2026; Lv et al., 2026），或使用专有教师模型进行准则生成（Kim et al., 2024; Gunjal et al., 2025; Shen et al., 2026; Shao et al., 2025）。但据我们所知，尚无现有方法正式定义什么使准则有用，或在无外部监督的情况下端到端地训练准则生成器以优化该目标。

这一差距催生了一个自然的评估标准质量准则：当评估标准有助于评判者区分好回答与坏回答时，它才是有用的。给定一个偏好对，我们可以直接测试评判者在给定候选评估标准的条件下，是否会给偏好回答分配更高的分数。因此，评估标准的质量是可直接测量和训练的。我们可以优化评估标准生成器，以最大化这种判别效用，奖励那些能拉大评判者对偏好回答与非偏好回答评分差距的评估标准。由此产生的训练信号不需要人工编写的评估标准标注，不需要外部标签，也不需要特定领域的验证器；只需要从策略自身输出中得到的偏好对。这些偏好对通过时间对比构建，其中当前策略的回答（偏好）与早期检查点的回答（非偏好）配对。我们提出 **EVOLM**，这是一种后训练方法，其中单一语言模型学会同时生成回答和用于评分的评估标准。评估标准生成器与策略通过交替更新共同进化（图 2）。随着策略的改进，评估标准必须变得更加敏锐以保持判别力；更敏锐的评估标准反过来产生更有信息量的奖励，推动策略进一步改进。我们将评估标准生成形式化为对潜在评估标准变量的变分推断，并推导出一个有原则的训练目标（第 2 节）。

在数学、代码、通用推理、知识、指令遵循和开放式生成的十二项基准测试中，EVOLM 产生了最强的下游策略（在 OLMo3-Adapt 套件上平均 69.3%），优于 GPT-4.1 提示的评分标准（66.7%）以及四种近期基于评分标准的强化学习方法，这些方法依赖专有应用程序编程接口或标注偏好数据（第 3.2 节）。一个在留出偏好基准上占主导地位的标量奖励模型（RewardBench 2 为 86.4%，JudgeBench 为 80.8%）产生了最弱的下游策略（59.7%）。与 EVOLM 之间 9.6 分的差距与先前关于奖励过度优化的发现一致（Gao 等人，2023; Ivison 等人，2024）。自进化范式和学到的评分标准具有广泛的泛化能力。共同进化框架扩展到其他模型系列，包括 OLMo-3-7B，学到的评分标准无需重新训练即可迁移到未见过的策略和评判器，并且在分布外深度研究任务上，EVOLM 在 HealthBench（58.4% 对 52.5%）和 ResearchQA（59.3% 对 51.0%）上与专家人工评分标准的成对一致性均高于 GPT-4.1（§ 3.3）。我们进一步通过定性分析揭示了潜在的自进化机制，并表明训练后的生成器学会了将评估分解为可单独检查的子任务，将预期的中间值直接嵌入标准中，并将整体判断转化为模式匹配，即使是一个 17 亿参数的评判器也能可靠地执行。




图 2: EVOLM 在两个 K 步阶段之间交替。在阶段 1 中，一个冻结的评分标准模型 ρ_ϕ 为每个问题生成评分标准 r ；策略 π_θ 采样 n 个响应，一个冻结的评判器 $\mathcal{J}$ 对这些响应进行评分，以产生用于策略更新的评分标准衍生奖励。在阶段 2 中，更新后的策略从自身输出构建偏好对 (a^+, a^-) ；评分标准模型采样 n 个候选评分标准，每个评分标准由评判器在两个响应上进行评分，分数差距 $s(a^+) - s(a^-)$ 作为评分标准更新的判别性奖励。评判器在整个过程中保持冻结。

2 EVOLM

2.1 概述

给定一个问题 q ，策略 π_θ 生成响应 $a \sim \pi_\theta(\cdot | q)$ 。标准方法训练一个标量奖励模型 $R(q, a) \in \mathbb{R}$ 来对每个响应进行评分；评估标准隐含在模型权重中，无法检查。我们改为将奖励计算分解为两个组件，并具有显式的自然语言接口。评分标准生成器 ρ_ϕ 为每个问题生成以自然语言表达的评估标准 r ：

$$r = \rho_\phi(q). \quad (1)$$

评判器 J 根据这些标准对响应进行评分：

$$s = J(q, r, a) \in [0, 1]. \quad (2)$$

我们联合训练评分标准生成器与策略，交替进行 (a) 使用基于评分标准的评判分数作为奖励来更新策略，以及 (b) 使用策略输出中偏好对的排序准确率作为奖励来更新评分标准生成器，评判器的参数在整个过程中保持不变（图 2）。本节其余部分详细描述训练目标（§ 2.2）、联合训练过程（§ 2.3）以及偏好对构建（§ 2.4）。

2.2 评分标准作为隐变量

一个好的评分标准应具有区分性：当评判器应用它时，更受偏好的回答得分更高。我们可以检验一个候选评分标准是否能让评判器恢复该排序。这促使我们将评分标准视为解释观测偏好的隐变量。我们通过变分推断将其形式化，推导出一个训练目标，奖励那些能够重构偏好排序的评分标准（公式 5）。

对于每个观测到的偏好对，我们引入一个隐变量 $r \sim \rho_{\text{ref}}(r | q)$ ，表示来自基础模型的评分标准先验。给定隐评分标准时观测偏好的似然为：

$$p(a^+ \succ a^- | q, r) = \sigma(J(q, r, a^+) - J(q, r, a^-)), \quad (3)$$

其中 σ 是 Sigmoid 函数。回答、偏好和评分标准的联合分布为：

$$p(a^+, a^-, r | q) = p(r | q) \pi(a^+ | q) \pi(a^- | q) p(a^+ \succ a^- | q, r). \quad (4)$$

这里 π 表示回答的采样分布；它可以是策略或离线偏好数据集。在我们的设置中， $\pi = \pi_\theta$ 是当前策略，并且在优化评分标准生成器参数 ϕ 时回答保持不变（第 2.3 节）。公式 4 推广了 Bradley-Terry 模型（Bradley & Terry, 1952），该模型从隐标量奖励生成偏好（Rafailov et al., 2023）。我们改为以隐评分标准变量为条件生成偏好，使用自然语言标准而非单一分数。

我们寻求后验 $p(r | a^+, a^-, q)$ ，但它是不可解的。应用摊销变分推断（Kingma & Welling, 2013），我们最大化证据下界（ELBO）：

$$\log p(a^+, a^- | q) \geq \mathcal{L} = \mathbb{E}_{r \sim \rho_\phi(r|q)} [\log p(a^+ \succ a^- | q, r)] - \text{KL}(\rho_\phi(r | q) \| \rho_{\text{ref}}(r | q)), \quad (5)$$

其中 $\rho_\phi(r | q)$ 是变分分布。最大化 ELBO 使 ρ_ϕ 接近真实后验。由于评分标准是离散文本，我们使用策略梯度优化该目标，将评分标准生成器视为一个智能体，其奖励为正确重构偏好的对数似然：

$$\mathcal{L}_{\text{rubric}}(\phi) = \mathbb{E}_{r \sim \rho_\phi(r|q)} [R(r; q, a^+, a^-)] - \text{KL}(\rho_\phi(r | q) \| \rho_{\text{ref}}(r | q)), \quad (6)$$

其中 $R(r; q, a^+, a^-) = \log \sigma(J(q, r, a^+) - J(q, r, a^-))$ 鼓励在固定评判者下，为更优响应分配更高分数的评分标准。

实用的奖励设计。 方程（6）中的对数 Sigmoid 奖励提供了一个原则性的起点。在实践中，我们将其替换为基于间隔的奖励并结合格式奖励：

$$R(r; q, a^+, a^-) = \alpha \cdot (J(q, r, a^+) - J(q, r, a^-)) + (1 - \alpha) \cdot R_{\text{format}}(r) \quad (7)$$

其中 $\alpha = 0.7$ 。间隔提供了与分数差距成比例的连续信号。格式奖励 $R_{\text{format}}(r) \in \{0, 1\}$ 验证评分标准是否符合评判者可解析的结构化 JSON 模式（附录 A.3）。该奖励设计在附录 C.1 中进行了消融实验。

2.3 联合训练

评分标准生成器和策略均使用 GRPO（Shao 等人，2024）进行训练，这是一种策略梯度方法，无需学习价值函数即可从组相对奖励中计算优势。策略的损失为：

$$\mathcal{L}_{\text{policy}}(\theta) = -\mathbb{E}_{q, a \sim \pi_\theta} [A(q, a) \log \pi_\theta(a | q)] \quad (8)$$

其中优势 $A(q, a)$ 源自对同一问题的每组响应进行归一化后的评判分数 $J(q, \rho_\phi(q), a)$ 。评分标准生成器的损失 $\mathcal{L}_{\text{rubric}}(\phi)$ （方程 6）以类似方式优化，优势基于为同一查询采样的每组评分标准计算。

训练在两个阶段之间交替进行：策略 π_θ 更新 K 步，同时评分标准生成器 ρ_ϕ 保持固定，然后 ρ_ϕ 使用由 π_θ 的输出构建的偏好对更新 K 步（第 2.4 节）。这种交替结构产生了一种涌现式课程。两个阶段相互强化。随着策略的演化，评分标准生成器必须学习越来越具体的标准，以在当前输出分布下区分质量。随着评分标准变得更具区分性，策略获得更清晰的奖励信号并进一步改进。交替频率 K 控制耦合强度，并在第 3.4 节中进行了消融实验。我们在整个训练过程中冻结评判者 J ，将评分标准生成器隔离为训练信号改进的唯一来源。

2.4 构建偏好对

评分标准生成器的目标（公式 6）需要偏好对 (a^+, a^-) 。我们完全从策略自身的输出中构建这些偏好对，无需人工标注，采用三种互补的方法。在默认配置下，三种方法均启用，并在评分标准生成器训练期间均匀随机采样。每种方法在 § 3.4 中独立消融。

1. 时间对比。 我们存储策略展开及其训练步数。为了为问题 q 构建一个偏好对，我们在步数 t 生成一个当前响应 $a^+ \sim \pi_\theta(\cdot | q)$ ，并从步数 $t' < t$ 采样一个较早的响应 a^- 。由于 π_θ 在训练过程中不断改进，较晚的响应被视为更优。步数间隔 $t - t'$ 控制判别的难度：较大的间隔产生质量差异明显的简单对，而较小的间隔产生需要更细粒度评分标准的困难对。随着训练的进行，这自然形成课程，因为最早的响应逐渐被更强的响应所取代。

2. 推断问题 (IQ)。 给定问题 q 的一个更优响应 a^+ ，策略自身推断该响应 a^+ 似乎针对的问题，生成 $\hat{q}$ ，遵循 Wang 等人 (2026) 的方法。然后生成一个较差响应作为 $a^- \sim \pi_\theta(\cdot | \hat{q})$ 。这提供了关于评分标准是否捕捉问题相关性的信号：检查响应是否针对预期问题的评分标准将对 a^+ 的评分高于 a^- 。

3. 评分标准条件 (RC)。 给定问题 q ，我们从当前评分标准生成器中采样一个评分标准 $r \sim \rho_\phi(\cdot | q)$ ，并在问题和评分标准共同条件下生成一个更优响应 $a^+ \sim \pi_\theta(\cdot | q, r)$ ，以及仅在问题条件下生成一个较差响应 $a^- \sim \pi_\theta(\cdot | q)$ 。这提供了关于评分标准实用性的直接信号：如果评分标准条件下的响应始终更好，则评分标准包含可操作的标准。因此，评分标准生成器被激励产生在提供给策略时能具体提高响应质量的标准。所有三种方法的完整提示见附录 D.2。

3 实验

实验围绕三个问题展开：（1）训练得到的评分标准生成器是否优于提示方法，以及协同进化训练是否优于顺序训练（第 3.2 节）？（2）学习到的评分标准能否跨领域、策略架构和评判器泛化（第 3.3 节）？（3）哪些设计选择对下游策略质量影响最大（第 3.4 节）？

3.1 设置

数据。 提示来自 Tulu 3 偏好混合数据集 (Lambert 等, 2024) 并去重，包含约 271K 个提示，涵盖通用聊天 (UltraFeedback、WildChat)、带 IFEval 风格约束的指令遵循、数学、代码、科学文献理解以及基于角色的合成指令。

模型。 Qwen3-8B (Yang 等, 2025) 同时用作策略和评分标准生成器，采用参数共享配置，即单个模型通过不同提示处理两种角色。这最小化了内存需求；双模型配置在第 3.4 节中进行了消融。Qwen3-1.7B 作为默认的冻结评判器。自进化框架预测，即使小型评判器在给定判别性评分标准时也应提供有效的奖励信号；使用 1.7B 评判器直接检验了这一点。评判器大小在第 3.4 节中进行了消融。

训练。 使用 GRPO，学习率为 10^{-6} ，KL 系数为 0.001，每个问题采样 8 个响应。交替频率 $K = 50$ 控制每个组件在切换前训练多少步；这也在第 3.4 节中进行了消融。时间对比步长间隔 [20, 100] 控制配对响应之间的时间距离；这也在第 3.4 节中进行了消融。其他实现细节见附录 A。

基线。 本文与三类基线方法进行比较。

1. 提示式评分标准。两个免训练的基线用于隔离学习评分标准生成器的影响。GPT-4.1 提示式方法使用 GPT-4.1 生成评分标准，并使用与 EVOLM 相同的 Qwen3-1.7B 评判器进行评分，代表了提示方法的上限。Qwen3-8B 提示式方法与本文的评分标准生成器架构一致，但采用提示而非训练。

2. 标量奖励模型。自然语言评分标准的一种替代方案是标量奖励模型，该模型将评估准则隐式编码在其权重中。本文使用 Skywork-RM-V2 (Liu 等, 2026)，一种最先进的通用 Bradley-Terry 奖励模型，为

表 1：基于评分标准的方法的设计空间比较。本文方法是唯一训练评分标准生成器、使其与策略共同演化、且无需专有应用程序编程接口或外部标签的方法。

Method	Trains rubric generator	No proprietary API	No external labels	Not restricted to verifiable domains	Co-evolves with policy
RAR	✗	✗	✓	✓	✗
RRD	✗	✗	✓	✓	✗
RLCER	✓	✓	✗	✗	✓
RUBRIC-ARM	✓	✓	✗	✓	✗
EVOLM (OURS)	✓	✓	✓	✓	✓

GRPO 中的轨迹分配奖励。该基线用于隔离评分标准分解是否在强标量奖励信号之外提供额外价值。

3. 基于评分标准的强化学习方法。本文与四种近期同样在强化学习训练中使用评分标准的方法进行比较。**RAR** (Gunjal 等, 2025) 使用 GPT-4.1 生成评分标准 (本文将原始专有评判器替换为 Qwen3-1.7B 评判器以进行受控比较)。**RRD** (Shen 等, 2026) 使用 GPT-4.1 迭代优化评分标准, 并将逐项得分与白化均匀加权相结合。两种方法均依赖专有应用程序编程接口生成评分标准, 且仅训练策略; 本文方法以训练后的本地评分标准生成器替代这一依赖。**RLCER** (Sheng 等, 2026) 共同训练评分标准生成器和策略, 但需要任务验证器进行正确性过滤, 因此仅限于具有真实答案的领域。**RUBRIC-ARM** (Xu 等, 2026) 使用参考对共同训练评分标准生成器和评判器, 因此仅限于训练时具有真实偏好标签的任务。本文方法在策略训练期间既不需要验证器, 也不需要偏好标注。

为确保公平比较, 所有方法均训练 500 个策略更新步。然而, 每步计算量有所不同: RRD 和 RLCER 分别因递归优化和逐轨迹评分标准生成而产生显著更高的开销。详细的每步成本分解见附录 A.7。表 1 突出了关键的设计空间差异。附录 A.6 提供了完整的实现细节。

评估。本文沿两个维度进行评估。第一, 下游策略质量: 使用学习得到的评分标准训练的策略在 OLMo3-Adapt 套件的十二个基准上进行评估, 涵盖数学推理 (GSM8K、MATH)、代码生成 (HumanEval+、MBPP+)、通用推理 (BBH、GPQA、ZebraLogic、AGI-Eval)、知识 (MMLU、PopQA)、指令遵循 (IFEval) 以及开放式生成 (AlpacaEval v3)。第二, 评分标准质量: 本文使用 RewardBench 2 (Malik 等, 2025) 和 JudgeBench (Tan 等, 2025) 直接测度学习得到的评分标准的判别准确率, 这些基准测试基于评分标准的评估能否在多样领域中正确地将偏好响应排在非偏好响应之前。

3.2 主要比较

除上述基线外, 本文比较了所提方法的两种训练机制。(1) 顺序训练: 首先在策略冻结的情况下训练评分标准生成器, 从通过推断的问题和评分标准条件方法构造的偏好对中学习 (时间对比需要变化的策略)。评分标准训练收敛后, 在评分标准生成器冻结的情况下训练策略。这隔离了评分标准训练的价值与联合适应的价值。(2) 协同演化训练 (**EVOLM**): 评分标准生成器与策略通过交替更新联合训练。这实现了协同适应: 随着策略改进, 它生成更多样化的响应, 提供更丰富的偏好信号; 随着评分标准生成器改进, 它提供更清晰的奖励信号。包括时间对比在内的所有三种偏好信号方法均可使用。结果见表 2。

由 EVOLM 训练的模型达到最高的下游平均分 (69.3%), 在不使用专有应用程序编程接口、外部标签或任务特定验证器的情况下优于所有基线。来自 GPT-4.1 (66.7%) 和 Qwen3-8B (67.5%) 的提示评分标准在个别基准上具有竞争力, 但在总体上落后, 四种基于评分标准的强化学习方法 (66.7 – 67.6%) 也是如此。最大提升出现在代码生成 (HumanEval+ 86.2%, 对比次优方法的 80.5%), 训练得到的评分标准产生的细粒度标准提供了特别清晰的信号。协同演化训练在

表 2：训练方法的主要比较。每种方法生成一个评分标准生成器（通过奖励基准 2 和评判基准的判别准确率评估）和一个策略（在 OLMo3-Adapt 下游基准上评估）。HE+ = 人类评估+。所有分数均为百分比。

Method	RewardBench2							JudgeBench						
	Factuality	Precise IF	Math	Safety	Focus	Ties	Avg	Knowledge	Reasoning	Math	Coding	Overall	Avg	
GPT-4.1 (prompted)	32.1	32.6	34.4	39.1	35.0	46.3	36.6	41.6	48.0	30.4	45.2	42.0	41.3	
Qwen3-8B (prompted)	27.8	26.5	38.1	25.0	30.2	9.7	26.2	34.4	38.8	30.4	42.9	36.0	36.6	
Scalar RM (Skywork-RM-V2)	88.2	67.8	83.1	97.3	99.2	83.1	86.4	77.3	75.5	89.3	81.0	79.1	80.8	
RAR	N/A (frozen GPT-4.1 rubric)							N/A (frozen GPT-4.1 rubric)						
RRD	N/A (frozen GPT-4.1 rubric)							N/A (frozen GPT-4.1 rubric)						
RLCER	33.1	29.8	52.2	48.3	51.9	54.8	45.0	43.5	40.8	48.2	64.3	46.0	49.2	
RUBRIC-ARM ¹	48.8	39.1	63.5	60.8	66.1	58.2	56.1	43.5	42.9	62.5	57.1	48.0	51.5	
Sequential (IQ)	37.0	32.0	57.1	42.3	59.0	55.6	47.2	37.7	55.1	44.6	57.1	46.0	48.6	
Sequential (RC)	31.5	30.8	57.0	47.9	49.6	59.2	46.0	34.4	39.8	44.6	50.0	39.4	42.2	
EVOLM	37.2	30.6	54.0	43.5	54.4	56.1	46.0	45.5	39.8	30.4	61.9	43.4	44.4	

Method	Downstream Policy Quality (OLMo3-Adapt)												
	GSM8K	MATH	HE+	MBPP+	BBH	MMLU	IFEval	PopQA	GPQA	Zebra	AGI-E	AlpacaE	Avg
GPT-4.1 (prompted)	95.7	94.2	58.7	65.1	71.7	84.8	34.4	30.7	54.9	81.9	82.9	45.5	66.7
Qwen3-8B (prompted)	95.5	94.6	73.7	58.4	66.8	83.4	35.3	31.7	56.9	84.3	83.9	45.9	67.5
Scalar RM (Skywork-RM-V2)	95.6	94.3	47.9	66.2	54.9	82.0	37.3	25.2	46.2	56.4	81.6	28.3	59.7
RAR	95.7	93.8	77.4	68.6	62.5	84.8	36.0	32.2	52.5	84.1	87.3	34.7	67.5
RRD	95.3	92.2	75.2	59.2	69.4	84.8	36.8	32.6	56.0	82.6	88.9	38.5	67.6
RLCER	94.0	94.7	80.5	67.9	68.6	84.8	39.2	30.4	49.6	69.1	84.3	37.2	66.7
RUBRIC-ARM	95.6	93.3	78.4	62.3	64.4	83.8	35.7	32.8	56.9	83.1	87.2	35.9	67.5
Sequential (IQ)	95.9	92.7	76.5	66.7	64.6	85.0	38.1	32.0	54.0	83.0	86.9	41.1	68.0
Sequential (RC)	96.0	93.4	80.2	67.7	64.7	85.8	36.8	32.3	57.1	83.2	87.4	35.1	68.3
EVOLM	95.8	94.5	86.2	68.5	67.6	85.3	37.7	30.5	54.2	82.3	86.4	42.2	69.3

策略质量（69.3% 对比 68.3%），尽管顺序训练实现了更高的静态评分标准准确率（奖励基准 2 47.2% 对比 46.0%）。下游策略质量取决于评分标准如何适应不断演变的策略分布，这正是优势协同进化所提供的。

标量奖励模型呈现出鲜明的对比。它在奖励基准 2（86.4%）和评判基准（80.8%）上占据主导地位，却产生了最弱的下游策略（59.7%），比 EVOLM 低 9.6 个百分点。这与奖励过度优化一致（Gao 等人，2023；Iverson 等人，2024）。静态评估标准，无论是编码在模型权重中还是固定在评分标准中，都无法适应学习策略所创造的奖励环境。协同进化的评分标准通过持续重构评估标准以保持对当前策略分布的判别力，从而避免了这种失败模式。我们在第 3.2.1 节分析了这一机制（评分标准如何从抽象标签演变为可验证的检查）。

3.2.1 评分标准从抽象标签演变为可验证的检查

对四个领域（数学、情感支持、科学解释和受限写作）的定性分析揭示了一种模式：早期评分标准使用简短标签或通用检查，而训练后的评分标准将具体、可验证的期望打包到每个标准中，减轻了评判模型的理解负担。这种形式因领域而异。例如，在数学中，评分标准将 80% 的权重集中在一个嵌入预期答案的单一标准上（例如，“由给定周长 48 推导出的正确最大面积 144”），将证明验证转化为答案检查；在受限写作中，它将格式和关键词要求整合为明确、可计数的检查。对 100 个评估提示的汇总统计证实了这一转变：仅标签标准从 21.9% 下降到 0.3%，嵌入具体期望值的标准从 6.9% 上升到 19.3%，约束型标准从 7.7% 上升到 20.3%，均相对于提示的 Qwen3-8B（附录 B.3）。共同效果是将评估从整体语义判断（小型评判模型执行不可靠）转向对具体标准的模式匹配（附录 B.1）。这是边际目标（公式 6）的直接结果：任何扩大评判模型在首选和非首选响应之间分数差距的标准都会得到奖励，这有利于具体、可验证的标准而非抽象标准。这种丰富化随时间进展。标准长度单调增长（平均从 59 个字符到 112 个字符），而标准数量保持稳定在 $\sim 3-4$ 个，并且在某些领域中，评分标准会短暂地将约束分解为许多细粒度项目，然后再重新整合为更少、更密集的标准（附录 B.2）。

3.3 泛化

评分标准生成器只有在训练分布之外仍能泛化时才具有实用价值。自进化过程针对特定策略和评判模型优化评分标准；我们现在测试它是否仍能在未见领域、策略架构和评判模型中捕捉到可迁移的评估原则。

3.3.1 与专家深度研究评分标准的对齐

EVOLM 在 Tulu 3 数据集 (Lambert 等人, 2024) 上训练, 该数据集包含通用任务 (§ 3.1)。需要长格式、多步骤响应的深度研究任务在评分标准生成器训练期间完全未见。我们测试学习到的评分标准生成器是否仍能在这些分布外任务上产生与专家人工评分标准对齐的评估标准。

我们在健康基准 (HealthBench) (阿罗拉等人, 2025) 和研究问答 (ResearchQA) (逸飞等人, 2025) 上进行评估, 这两个基准为每个问题提供了专家编写的评分标准。对于每个问题, 我们从深度推理图灵-8B 监督微调和强化学习检查点 (邵等人, 2025) 生成展开结果, 以确保响应质量的多样性, 然后通过使用 GPT-4.1 根据人类专家评分标准对展开结果进行评分, 获得真实的成对排名。我们使用进化语言模型 (EVOLM)、提示的通义千问 3-8B 和提示的 GPT-4.1 生成评分标准, 然后使用通义千问 3-1.7B 对展开结果进行评分, 以获得成对排名。我们报告成对排名准确率和 $\text{Acc}@ \delta$, 仅限专家评分标准分数差距超过阈值 δ 的对, 以过滤真实排名不明确的近似平局。

如表 3 所示, 进化语言模型在两个基准上均取得了最高的成对排名准确率: 健康基准上为 58.4%, 研究问答上为 59.3%, 分别比提示的通义千问 3-8B (53.0%, 57.2%) 和 GPT-4.1 (52.5%, 51.0%) 高出 5 至 8 个百分点。在过滤后的指标上, 这一优势保持并扩大, 在健康基准上达到 59.0% 的 $\text{Acc}@0.1$, 在研究问答上达到 68.7% 的 $\text{Acc}@0.05$ 。一个在通用任务上训练的评分标准生成器在健康和研究领域产生的标准比 GPT-4.1 更符合专家判断, 这提供了强有力的证据, 表明变分训练目标学习了可迁移的评估结构。尽管在 § 3.2 中观察到静态偏好基准与下游评分标准效用之间的脱节, 这种强大的分布外性能进一步支持了根据评分标准生成器与专家判断对齐的能力来评估它们, 而不仅仅是根据留出偏好准确率。

Rubric Generator	HealthBench		ResearchQA	
	Acc	Acc@0.1	Acc	Acc@0.05
EvOLM	58.4	59.0	59.3	68.7
Qwen3-8B (prompted)	53.0	55.0	57.2	59.0
GPT-4.1 (prompted)	52.5	53.6	51.0	65.3

3.3.2 共同进化的评分标准为未见策略提供有效的训练信号

为了测试学习到的评分标准是否编码了通用评估标准而非特定于策略的标准, 我们冻结主实验中的评分标准生成器, 并使用它从头训练两个未见策略: 通义千问 3-4B (同系列, 更小) 和羊驼 3.1-8B (不同系列)。每个策略也使用 GPT-4.1 提示的评分标准进行训练, 作为对照比较。

表 4: 跨模型迁移。评分标准生成器 (冻结自主实验中的 Qwen3-8B) 用于训练不同规模和家族的策略模型。下游质量衡量评分标准是否为训练期间未见过的模型提供有效的奖励信号。由于评分标准生成器被冻结, 未报告评分标准质量 (RewardBench-2/JudgeBench)。所有分数均为百分比。

Configuration	Downstream Policy Quality (OLMo3-Adapt)													
	GSM8K	MATH	HE+	MBPP+	BBH	MMLU	IFEval	PopQA	GPQA	Zebra	AGI-E	AlpacaE	Avg	
Qwen3-4B + GPT-4.1 rubric	94.8	91.9	70.1	67.7	61.9	82.8	37.0	26.5	45.5	79.7	84.6	30.5	64.4	
Qwen3-4B + EVOLM rubric	94.5	92.4	77.9	68.0	65.3	78.8	36.8	25.5	49.3	79.9	83.3	30.4	65.2	
Llama-3.1-8B + GPT-4.1 rubric	73.0	43.7	49.1	42.3	56.8	58.8	67.5	25.8	33.7	11.3	63.6	22.6	45.7	
Llama-3.1-8B + EVOLM rubric	79.8	47.2	40.5	38.9	56.0	71.4	68.4	31.6	35.5	12.0	63.4	18.4	46.9	

如表 4 所示, EVOLM 评分标准在两种架构上均优于 GPT-4.1 提示的评分标准: Qwen3-4B (65.2% 对 64.4%) 和 Llama-3.1-8B (46.9% 对 45.7%)。在

Qwen3 家族中，最大提升出现在代码生成（HE+ 77.9% 对 70.1%）和通用推理（GPQA 49.3% 对 45.5%，BBH 65.3% 对 61.9%）。这些结果证实评分标准生成器捕获了可迁移的评估准则，为训练期间未见过的模型提供有效的奖励信号。

3.3.3 训练得到的评分标准跨评判模型泛化

本文测试训练得到的评分标准在与训练期间未见过的评判模型配对时是否仍然有效。冻结 EVOLM 评分标准生成器（使用 Qwen3-1.7B 评判模型训练），并使用三个未见过的推理时评判模型评估判别准确率：Qwen3-8B、OLMo-3-7B-Instruct 和 Mistral-7B（表 5）。

表 5：跨评判模型评估。使用不同推理时评判模型的 RewardBench-2 和 JudgeBench 准确率。评分标准生成器使用 Qwen3-1.7B 训练。粗体表示每个提示/训练对中的较高值。

Inference Judge	Rubric	RewardBench2								JudgeBench					
		Factuality	Precise IF	Math	Safety	Focus	Ties	Avg	Knowledge	Reasoning	Math	Coding	Overall	Avg	
Qwen3-1.7B (training judge)	Prompted	27.8	26.5	38.1	25.0	30.2	9.7	26.2	34.4	38.8	30.4	42.9	36.0	36.6	
	Trained	37.2	30.6	54.0	43.5	54.4	56.1	46.0	45.5	39.8	30.4	61.9	43.4	44.4	
Qwen3-8B	Prompted	37.4	33.6	51.5	49.9	45.5	20.3	39.7	48.1	33.7	53.6	61.9	46.6	49.3	
	Trained	49.9	41.7	74.3	55.3	71.0	82.2	62.4	57.1	68.4	66.1	61.9	62.3	63.4	
OLMo-3-7B-Instruct	Prompted	36.2	24.7	57.7	48.7	43.2	32.5	40.5	40.9	32.7	37.5	40.5	38.0	37.9	
	Trained	37.9	26.4	54.0	48.0	39.9	57.6	43.9	42.9	31.6	26.8	59.5	39.1	40.2	
Mistral-7B	Prompted	27.8	22.9	28.6	38.5	28.5	34.2	30.1	31.2	17.3	28.6	11.9	24.6	22.2	
	Trained	29.4	25.4	28.5	31.9	35.0	22.1	28.7	36.4	34.7	33.9	38.1	35.7	35.8	

The strongest result is on Qwen3-8B, where trained rubrics improve RewardBench-2 by +22.7 points (62.4% vs. 39.7%) and JudgeBench by +15.7 points over prompted rubrics. This indicates that trained rubrics encode evaluation structure that a more capable judge can leverage more effectively than it can derive from a generic prompt alone. Cross-family transfer is more modest but positive on aggregate: OLMo-3-7B-Instruct gains +3.4 on RewardBench-2 and Mistral-7B gains +11.1 on JudgeBench. Together, these results show that a rubric generator trained with one judge can be deployed with different judges without retraining.

3.3.4 多评判模型训练

为了生成开箱即用即可泛化到未见评判模型的评分标准生成器，本文同时使用多个评判模型进行训练。使用由五个小型模型组成的评判集成：Qwen3-1.7B、Llama-3.2-1B-Instruct、OLMo-2-0425-1B-Instruct、Gemma-3-1B-IT 和 Qwen3-4B。每个评判模型 $j \in \{1, \dots, J\}$ 使用生成的评分标准独立地对接受和拒绝的答案 a^+ 和 a^- 进行评分，得到分数 s_j^+ 和分数 s_j^- ，并投出二元 $v_j = \mathbf{1}[\text{score}_j^+ > \text{score}_j^-]$ 票。每次展开的奖励为

$$R_{\text{MJ}} = w_m \cdot \bar{m} + w_f \cdot \mathbf{1}[\text{valid_format}] + w_\kappa \cdot \hat{\kappa}, \quad (9)$$

其中 $\bar{m} = \frac{1}{J} \sum_{j=1}^J (s_j^+ - s_j^-)$ 是平均边际（各评委接受与拒绝分数之差）， $\mathbf{1}[\text{格式有效}]$ 是生成评分标准是否满足所需 JSON 模式的二元指示符， $\hat{\kappa}$ 是评委间一致性，计算方式为 $\hat{\kappa} = \text{clip}(\kappa_F(\bar{v}), 0, 1)$ ，其中 κ_F 是基于评委对接受答案是否获得高于拒绝答案分数的二元投票计算出的弗莱斯卡帕（Fleiss, 1971）。我们测试了两种权重配置：边际+格式（MF），权重为 $(w_m, w_f, w_\kappa) = (0.7, 0.3, 0)$ ，完全省略一致性惩罚；以及边际+一致性+格式（MAF），权重为 $(w_m, w_f, w_\kappa) = (0.5, 0.3, 0.2)$ ，保留适度的一致性激励。此外，我们考虑了不使用边际和格式奖励，仅使用二元投票和一致性（BA）的替代奖励设计：

$$R = \bar{v} - (1 - \hat{\kappa}), \quad \bar{v} = \frac{1}{J} \sum_{j=1}^J v_j, \quad \hat{\kappa} = \text{clip}(\kappa_F, 0, 1), \quad (10)$$

其中 $\bar{v}$ 是平均投票（偏好接受答案的评委比例）。所有多评委变体在下游策略质量上与单评委基线相当（完整消融见附录 C.8）。

表 6：单评委与多评委评分标准生成器的跨评委评估。 RewardBench-2 和 JudgeBench 准确率（%）基于三个推理时评委。单评委生成器（EVoLM）使用 Qwen3-1.7B 训练；多评委生成器使用五个评委（Qwen3-1.7B、Llama-3.2-1B-Instruct、OLMo-2-0425-1B-Instruct、Gemma-3-1B-IT、Qwen3-4B）训练。多评委使用公式 10；MF 和 MAF 使用公式 9，权重分别为 (0.7, 0.3, 0) 和 (0.5, 0.3, 0.2)。

Inference Judge	Rubric Generator	RewardBench2							JudgeBench						
		Factuality	Precise IF	Math	Safety	Focus	Ties	Avg	Knowledge	Reasoning	Math	Coding	Overall	Avg	
Qwen3-1.7B	Prompted	27.8	26.5	38.1	25.0	30.2	9.7	26.2	34.4	38.8	30.4	42.9	36.0	36.6	
	EVoLM (single judge)	37.2	30.6	54.0	43.5	54.4	56.1	46.0	45.5	39.8	30.4	61.9	43.4	44.4	
	MF (Eq. 9)	37.4	29.4	56.5	50.3	49.8	53.8	46.2	48.7	45.9	42.9	59.5	48.3	49.3	
	MAF (Eq. 9)	33.4	28.4	53.4	46.8	50.9	57.7	45.1	42.9	42.9	44.6	52.4	44.3	45.7	
	BA (Eq. 10)	35.5	30.0	55.4	47.1	50.1	56.2	45.7	45.5	49.0	42.9	64.3	48.3	50.4	
Qwen3-8B	Prompted	37.4	33.6	51.5	49.9	45.5	20.3	39.7	48.1	33.7	53.6	61.9	46.6	49.3	
	EVoLM (single judge)	49.9	41.7	74.3	55.3	71.0	82.2	62.4	57.1	68.4	66.1	61.9	62.3	63.4	
	MF (Eq. 9)	51.0	36.0	74.2	59.8	69.7	76.5	61.2	57.1	62.2	64.3	66.7	60.9	62.6	
	MAF (Eq. 9)	55.9	35.5	77.6	56.2	70.5	75.8	61.9	57.8	71.4	66.1	69.0	64.3	66.1	
	BA (Eq. 10)	57.6	36.1	78.5	52.5	70.9	85.6	63.5	57.1	69.4	64.3	61.9	62.3	63.2	
OLMo-3-7B	Prompted	36.2	24.7	57.7	48.7	43.2	32.5	40.5	40.9	32.7	37.5	40.5	38.0	37.9	
	EVoLM (single judge)	37.9	26.4	54.0	48.0	39.9	57.6	43.9	42.9	31.6	26.8	59.5	39.7	40.2	
	MF (Eq. 9)	32.3	22.3	49.8	51.8	35.4	38.0	38.3	40.3	32.6	48.2	30.9	38.3	38.0	
	MAF (Eq. 9)	33.0	25.7	54.7	50.3	35.7	37.6	39.5	39.0	29.6	25.0	30.9	33.1	31.1	
	BA (Eq. 10)	38.7	27.6	56.3	52.7	40.3	54.7	45.1	53.2	41.8	37.5	52.4	47.4	46.2	

多裁判训练的关键优势在推理阶段显现。表 6 使用三种未参与训练的推理裁判——Qwen3-1.7B（单裁判训练裁判）、Qwen3-8B 和 OLMo-3-7B-Instruct，将所有多裁判评分标准生成器与单裁判生成器（EVoLM）及提示式评分标准进行对比。所有多裁判生成器在三种推理裁判上均一致优于单裁判生成器和提示式评分标准。在 Qwen3-8B 上，最佳多裁判变体（MAF）在 RewardBench-2 上达到 61.9%，在 JudgeBench 上达到 66.1%，而单裁判生成器分别为 62.4% 和 63.4%，JudgeBench 提升 2.7 个百分点。在 OLMo-3-7B-Instruct 上改进更为显著，BA 将 JudgeBench 从 40.2% 提升至 46.2%（+6.0）。在训练裁判 Qwen3-1.7B 上，所有多裁判变体均大幅提升 JudgeBench（45.7 – 50.4% 对比 44.4%）。这些结果表明，使用多样化裁判进行训练能够生成更具普适可解释性的评分标准，其编码的评估准则可有效迁移至训练集成之外的裁判。

3.4 消融实验

我们在表 7 中消融了七个设计维度（奖励塑形、交替频率、模型配置、偏好信号源、评判器规模、时间步间隔和跨架构迁移），并在附录 C 中给出了每个基准的完整分解。下游策略质量对大多数选择表现出显著的鲁棒性。交替频率、偏好信号和步间隔产生的策略彼此相差在 1 – 2 分以内，这表明自我演化动态本身，而非任何特定配置，才是主要驱动因素。唯一的关键要求是维持自我演化运行的条件。格式奖励对于保持评分标准结构有效至关重要（没有它，有效性从 > 85% 下降到 23%），一旦评分标准保持良好形式，协同演化循环就能可靠地发现有效标准，而与其他设置无关。1.7B 的评判器已足够，因为决定信号质量的是学习到的评分标准内容，而非评判器能力。单模型配置在相同质量下将内存减半，并且该框架可推广到 OLMo-3-7B 和 Llama-3.1-8B。在每个消融组中，RewardBench-2 得分最高的变体从未产生最佳策略，这进一步说明协同演化使评分标准适应不断变化的策略分布，而静态基准无法捕捉这种适应性。

表 7：消融实验结果汇总。 每一行在保持主配置（*），评分标准 = RewardBench-2 平均值。策略 = OLMo3-Adapt 12 基准平均值（%））不变的情况下，仅改变一个设计维度。

Dimension	Variant	RB2	Policy
Reward design	5–10 criteria, no-dealbreaker prompt	38.9	67.6
	main prompt	37.9	69.5
	main prompt + margin	37.2	66.9
	main prompt + margin + format*	46.0	69.3
Alt. freq. K	2	46.4	67.9
	10	44.5	68.5
	20	46.9	68.6
	50*	46.0	69.3
	100	48.5	68.7
Model config.	Single-model*	46.0	69.3
	Two-model	48.4	69.3
Pref. signal	Inferred question	48.1	68.6
	Rubric-conditioned	48.4	68.6
	Temporal contrast*	46.0	69.3
	Combined (IQ + RC)	45.6	68.9
	Combined (all 3)	49.3	67.8
Judge size	0.6B	22.1	67.9
	1.7B*	46.0	69.3
	4B	61.6	66.5
	8B	59.5	67.1
	14B	67.6	69.0
Step gap	[5, 20]	48.8	68.6
	[20, 100]*	46.0	69.3
	[100, 300]	47.1	68.9
Cross-arch.	Qwen3-8B*	46.0	69.3
	OLMo-3-7B	45.3	64.0
	Llama-3.1-8B	34.0	43.8

4 相关工作

在后训练阶段，奖励主要来源于训练好的奖励模型，它们生成标量分数（克里斯蒂亚诺等人，2017；欧阳等人，2022），或者来源于提示语言模型对响应进行评判（郑等人，2023；杜波依斯等人，2023；白等人，2022；李等人，2024）。这两种方式都隐式地或通过固定提示来编码评估标准，而我们的评分标准生成器则从偏好信号中学习显式标准。另一条研究路线追求自我改进，即模型生成自己的训练信号。自我奖励语言模型（Self-Rewarding Language Models）（袁等人，2025）将模型自身作为评判者，但使用固定的评估提示，从不进化。SPIN（陈等人，2024）训练模型区分自己的输出与人类参考，仍然需要外部数据作为真实标签。元奖励（Meta-Rewarding）（吴等人，2024）增加了一个元评判者来评估模型自身的判断，但评估标准仍然隐含在模型权重中。在所有情况下，评估机制要么是静态的，要么是不透明的。EVOLM 的不同之处在于，它通过一个正式目标（判别效用）共同进化显式的、结构化的评估标准与策略，该目标训练评分标准生成器产生小型评判者能够可靠应用的标准。若干并行工作将评分标准应用于强化学习训练。基于提示的方法包括 DR Tulu（邵等人，2025）、RaR（贡贾尔等人，2025）、RRD（沈等人，2026）和 OpenRS（贾等人，2026），它们使用现成模型生成固定或自适应的评分标准。在训练过的评分标准生成器中，RLCER（盛等人，2026）需要可验证的正确性标签；Rubric-ARM（徐等人，2026）需要参考偏好标签；RLAC（吴等人，2025）仅捕获单个失败点；RIFL（何等人，2025）依赖人工标注数据。我们的方法使用时间对比——将当前策略响应与早期策略响应配对——交替更新评分标准生成器和策略，无需外部标签或验证器。

5 结论

本文提出 EVOLM，一种后训练方法，使显式判别性评分标准与其所评分的策略协同进化。通过将评分标准质量形式化为判别效用并进行端到端优化，EVOLM 提取模型中已编码的评估知识，并将其结构化为一个小型冻结评判器能够可靠应用的标准，无需人工标注、专有应用程序编程接口或任务特定验证器，且在评分标准质量和下游策略性能上均优于前沿模型评分标准基线。每个外部奖励源都设定了上限：人类判断无法监督超出其自身能力的行为，静态标准无法适应学习策略产生的输出分布。与策略协同进化的奖励信号消除了这两个约束。学习到的评估结构无需重新训练即可迁移到未见过的策略、评判器和分布外领域，且变分框架可扩展到任何可观察偏好但不存在真实答案的领域。

局限性

EVOLM 已在通用后训练数据上得到验证；其在医学或法律等特定领域混合数据上的表现仍是一个开放问题。规则丰富机制在具有可验证中间步骤的任务中最为明显，其对纯主观评估标准的影响尚不明确。冻结评判器是一项刻意的设计选择，旨在将规则生成器隔离为训练信号改进的唯一来源，但这限制了规则生成器能够学习生成的准则复杂度。

致谢

本研究部分由美国国防高级研究计划局（DARPA）SciFy 项目资助（协议号 HR00112520300）。文中观点仅代表作者本人，不代表国防部或美国政府的官方政策或立场。本研究还得到了 Meta AIM 项目、Coefficient Giving 以及 Amazon Health 的支持。本工作由新加坡国家研究基金会和新加坡国家人工智能小组资助。

数字发展与信息部在人工智能访问教授计划（奖项编号 AIVP-2024-001）和施密特科学人工智能 2050 计划下的资助。

参考文献

- Rahul K Arora, Jason Wei, Rebecca Soskin Hicks, Preston Bowman, Joaquin Quiñero-Candela, Foivos Tsimpourlas, Michael Sharman, Meghan Shah, Andrea Vallone, Alex Beutel, et al. Healthbench: Evaluating large language models towards improved human health. *arXiv preprint arXiv:2505.08775*, 2025.
- Yuntao Bai, Saurav Kadavath, Sandipan Kundu, Amanda Askell, Jackson Kernion, Andy Jones, Anna Chen, Anna Goldie, Azalia Mirhoseini, Cameron McKinnon, et al. Constitutional AI: Harmlessness from AI feedback. *arXiv preprint arXiv:2212.08073*, 2022.
- Ralph Allan Bradley and Milton E Terry. Rank analysis of incomplete block designs: I. the method of paired comparisons. *Biometrika*, 39(3/4):324–345, 1952.
- Zixiang Chen, Yihe Deng, Huizhuo Yuan, Kaixuan Ji, and Quanquan Gu. Self-play fine-tuning converts weak language models to strong language models, 2024. URL <https://arxiv.org/abs/2401.01335>.
- Paul F Christiano, Jan Leike, Tom Brown, Miljan Martic, Shane Legg, and Dario Amodei. Deep reinforcement learning from human preferences. *Advances in neural information processing systems*, 30, 2017.
- Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukas Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, et al. Training verifiers to solve math word problems. *arXiv preprint arXiv:2110.14168*, 2021.
- Yann Dubois, Chen Xuechen Li, Rohan Taori, Tianyi Zhang, Ishaan Gulrajani, Jimmy Ba, Carlos Guestrin, Percy S Liang, and Tatsunori B Hashimoto. AlpacaFarm: A simulation framework for methods that learn from human feedback. *Advances in Neural Information Processing Systems*, 36:30039–30069, 2023.
- Shangbin Feng, Wenhao Yu, Yike Wang, Hongming Zhang, Yulia Tsvetkov, and Dong Yu. Don’t throw away your pretrained model, 2025. URL <https://arxiv.org/abs/2510.09913>.
- Joseph L Fleiss. Measuring nominal scale agreement among many raters. *Psychological Bulletin*, 76(5):378–382, 1971.
- Leo Gao, John Schulman, and Jacob Hilton. Scaling laws for reward model overoptimization. In *Proceedings of the 40th International Conference on Machine Learning*, pp. 10835–10866, 2023.
- Anisha Gunjal, Anthony Wang, Elaine Lau, Vaskar Nath, Yunzhong He, Bing Liu, and Sean Hendryx. Rubrics as rewards: Reinforcement learning beyond verifiable domains, 2025. URL <https://arxiv.org/abs/2507.17746>.
- Yun He, Wenzhe Li, Hejia Zhang, Songlin Li, Karishma Mandyam, Sopan Khosla, Yuanhao Xiong, Nanshu Wang, Xiaoliang Peng, Beibin Li, et al. Advancedif: Rubric-based benchmarking and reinforcement learning for advancing llm instruction following. *arXiv preprint arXiv:2511.10507*, 2025.
- Shengyi Huang, Jiayi Weng, Rujikorn Charakorn, Min Lin, Zhongwen Xu, and Santiago Ontañón. Cleanba: A reproducible and efficient distributed reinforcement learning platform. *arXiv preprint arXiv:2310.00036*, 2023.
- Hamish Ivison, Yizhong Wang, Jiacheng Liu, Zeqiu Wu, Valentina Pyatkin, Nathan Lambert, Noah A. Smith, Yejin Choi, and Hannaneh Hajishirzi. Unpacking dpo and ppo: Disentangling best practices for learning from preference feedback, 2024.

- Ruipeng Jia, Yunyi Yang, Yuxin Wu, Yongbo Gai, Siyuan Tao, Mengyu Zhou, Jianhe Lin, Xiaoxi Jiang, and Guanjuan Jiang. Open rubric system: Scaling reinforcement learning with pairwise adaptive rubric. *arXiv preprint arXiv:2602.14069*, 2026.
- Seungone Kim, Jamin Shin, Yejin Cho, Joel Jang, Shayne Longpre, Hwaran Lee, Sangdoo Yun, Seongjin Shin, Sungdong Kim, James Thorne, et al. Prometheus: Inducing fine-grained evaluation capability in language models. In *12th International Conference on Learning Representations, ICLR 2024*, 2024.
- Diederik P Kingma and Max Welling. Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114*, 2013.
- Nathan Lambert, Jacob Morrison, Valentina Pyatkin, Shengyi Huang, Hamish Ivison, Faeze Brahman, Lester James V Miranda, Alisa Liu, Nouha Dziri, Shane Lyu, et al. Tulu 3: Pushing frontiers in open language model post-training. *arXiv preprint arXiv:2411.15124*, 2024.
- Harrison Lee, Samrat Phatale, Hassan Mansoor, Kellie Ren Lu, Thomas Mesnard, Johan Ferret, Colton Bishop, Ethan Hall, Victor Carbune, and Abhinav Rastogi. RLAI: Scaling reinforcement learning from human feedback with AI feedback. 2024. URL <https://arxiv.org/abs/2309.00267>.
- Chris Yuhao Liu, Liang Zeng, Yuzhen Xiao, Jujie He, Jiakai Liu, Chaojie Wang, Rui Yan, Wei Shen, Fuxiang Zhang, Jiacheng Xu, Yang Liu, and Yahui Zhou. Skywork-reward-v2: Scaling preference data curation via human-ai synergy, 2026. URL <https://arxiv.org/abs/2507.01352>.
- Changze Lv, Jie Zhou, Wentao Zhao, Jingwen Xu, Zisu Huang, Muzhao Tian, Shihan Dou, Tao Gui, Le Tian, Xiao Zhou, et al. Learning query-specific rubrics from human preferences for deepresearch report generation. *arXiv preprint arXiv:2602.03619*, 2026.
- Saumya Malik, Valentina Pyatkin, Sander Land, Jacob Morrison, Noah A Smith, Hannaneh Hajishirzi, and Nathan Lambert. Rewardbench 2: Advancing reward model evaluation. *arXiv preprint arXiv:2506.01937*, 2025.
- Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, et al. Training language models to follow instructions with human feedback. *Advances in neural information processing systems*, 35:27730–27744, 2022.
- Rafael Rafailov, Archit Sharma, Eric Mitchell, Christopher D Manning, Stefano Ermon, and Chelsea Finn. Direct preference optimization: Your language model is secretly a reward model. *Advances in neural information processing systems*, 36:53728–53741, 2023.
- Rulin Shao, Akari Asai, Shannon Zejiang Shen, Hamish Ivison, Varsha Kishore, Jingming Zhuo, Xinran Zhao, Molly Park, Samuel G Finlayson, David Sontag, et al. Drtulu: Reinforcement learning with evolving rubrics for deep research. *arXiv preprint arXiv:2511.19399*, 2025.
- Rulin Shao, Shuyue Stella Li, Rui Xin, Scott Geng, Yiping Wang, Sewoong Oh, Simon Shaolei Du, Nathan Lambert, Sewon Min, Ranjay Krishna, Yulia Tsvetkov, Hannaneh Hajishirzi, Pang Wei Koh, and Luke Zettlemoyer. Spurious rewards: Rethinking training signals in rlvr, 2026. URL <https://arxiv.org/abs/2506.10947>.
- Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, YK Li, Yang Wu, et al. DeepSeekMath: Pushing the limits of mathematical reasoning in open language models. *arXiv preprint arXiv:2402.03300*, 2024.
- William F. Shen, Xinchu Qiu, Chenxi Whitehouse, Lisa Alazraki, Shashwat Goel, Francesco Barbieri, Timon Willi, Akhil Mathur, and Ilias Leontiadis. Rethinking rubric generation for improving llm judge and reward modeling for open-ended tasks, 2026. URL <https://arxiv.org/abs/2602.05125>.

- Leheng Sheng, Wenchang Ma, Ruixin Hong, Xiang Wang, An Zhang, and Tat-Seng Chua. Reinforcing chain-of-thought reasoning with self-evolving rubrics, 2026. URL <https://arxiv.org/abs/2602.10885>.
- Nisan Stiennon, Long Ouyang, Jeffrey Wu, Daniel Ziegler, Ryan Lowe, Chelsea Voss, Alec Radford, Dario Amodei, and Paul F Christiano. Learning to summarize with human feedback. *Advances in neural information processing systems*, 33:3008–3021, 2020.
- Sijun Tan, Siyuan Zhuang, Kyle Montgomery, William Y. Tang, Alejandro Cuadron, Chengguang Wang, Raluca Ada Popa, and Ion Stoica. Judgebench: A benchmark for evaluating llm-based judges, 2025. URL <https://arxiv.org/abs/2410.12784>.
- Yike Wang, Faeze Brahman, Shangbin Feng, Teng Xiao, Hannaneh Hajishirzi, and Yulia Tsvetkov. Small reward models via backward inference. *arXiv preprint arXiv:2602.13551*, 2026.
- Mian Wu, Gavin Zhang, Sewon Min, Sergey Levine, and Aviral Kumar. RLAC: Reinforcement learning with adversarial critic for free-form generation tasks. *arXiv preprint arXiv:2511.01758*, 2025.
- Tianhao Wu, Weizhe Yuan, Olga Golovneva, Jing Xu, Yuandong Tian, Jiantao Jiao, Jason Weston, and Sainbayar Sukhbaatar. Meta-rewarding language models: Self-improving alignment with llm-as-a-meta-judge, 2024. URL <https://arxiv.org/abs/2407.19594>.
- Ran Xu, Tianci Liu, Zihan Dong, Tony Yu, Ilgee Hong, Carl Yang, Linjun Zhang, Tao Zhao, and Haoyu Wang. Alternating reinforcement learning for rubric-based reward modeling in non-verifiable llm post-training, 2026. URL <https://arxiv.org/abs/2602.01511>.
- An Yang, Anfeng Li, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Gao, Chengen Huang, Chenxu Lv, et al. Qwen3 technical report. *arXiv preprint arXiv:2505.09388*, 2025.
- Li S Yifei, Allen Chang, Chaitanya Malaviya, and Mark Yatskar. Researchqa: Evaluating scholarly question answering at scale across 75 fields with survey-mined questions and rubrics. *arXiv preprint arXiv:2509.00496*, 2025.
- Weizhe Yuan, Richard Yuanzhe Pang, Kyunghyun Cho, Xian Li, Sainbayar Sukhbaatar, Jing Xu, and Jason Weston. Self-rewarding language models, 2025. URL <https://arxiv.org/abs/2401.10020>.
- Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, Siyuan Zhuang, Zhanghao Wu, Yonghao Zhuang, Zi Lin, Zhuohan Li, Dacheng Li, Eric Xing, et al. Judging LLM-as-a-judge with MT-Bench and chatbot arena. *Advances in Neural Information Processing Systems*, 36, 2023.

A 实现细节

A.1 模型配置

本文采用 Qwen3-8B（82 亿参数）同时作为策略模型与评分标准生成器，采用单模型配置，两种角色共享权重，仅通过输入提示进行区分。默认冻结的评分裁判为 Qwen3-1.7B，裁判规模在 C.5 节中从 0.6B 到 32B 进行了消融实验。交替频率设置为每个训练阶段 $K = 50$ 步，即策略模型先训练 50 步 GRPO，再切换为评分标准生成器训练 50 步。单模型与双模型配置以及交替频率分别在 C.3 节和 C.2 节进行了消融实验。

A.2 训练超参数

Parameter	Value
Unique prompts per step	64
Samples per prompt	8
Effective batch size	512 responses/step
Per-device batch size	1
Gradient accumulation steps	1

表 8：批次配置。使用 64 块训练 GPU，每块 GPU 每步处理 8 个打包序列。

批次配置。

Parameter	Value
Learning rate	1×10^{-6}
LR scheduler	Constant
Warmup steps	0
Optimizer	AdamW (fused)
KL coefficient (β)	0.001
PPO clip range (ϵ)	0.2
KL estimator	KL3

表 9：优化超参数。

优化。

Parameter	Value
Response length (max)	16,384 tokens
Prompt length (max)	2,048 tokens
Pack length	18,500 tokens
Temperature (policy)	1.0
Temperature (question inference)	0.3
Temperature (rubric judge)	0.0 (greedy)

表 10：生成参数。较长的响应长度支持思维链推理。

生成。

A.3 格式奖励模式

格式奖励 $R_{\text{format}}(r) \in \{0, 1\}$ 检查生成的评分标准是否为格式良好的 JSON，以便评判者能够可靠地解读。具体而言，输出必须解析为一个 JSON 对象，其中包含一个至少有两个条目的标准数组，每个条目包含标准描述（字符串）和正权重（浮点数），且权重之和为 1.0 ± 0.15 。评分标准必须满足此模式，评判者才能应用逐项评分。

A.4 异步训练与主动采样

异步流水线。本文采用异步步数 = 4，即任意时刻有 4 个批次（共 256 条提示）在途。训练器处理批次 t 的同时，生成器产出批次 $t+1$ 至 $t+4$ 。此举使生成与训练重叠，以最大化图形处理器（GPU）利用率。用于生成的策略最多可落后当前训练策略 4 步，遵循 Cleanba 范式（Huang 等，2023）。

主动采样。GRPO 要求每个提示组内的奖励方差来计算有意义的优势。当某个提示的 8 个样本获得相同分数（零方差）时，该批次不提供学习信号。启用主动采样后，此类零方差批次会被过滤，生成器继续采样，直到获得 64 个具有非零奖励方差的提示。这确保了每个训练步骤都使用有信息量的数据。

A.5 硬件配置

- **训练：**8 个节点 $\times$ 8 块 H100 GPU = 64 块 GPU
- **DeepSpeed：**ZeRO 第三阶段，启用梯度检查点
- **vLLM 引擎：**共 56 个（40 个策略引擎 + 16 个评判引擎，单模型模式下共享）
- **张量并行：**1（每个引擎使用单个图形处理器）

A.6 基线配置

所有基线均采用相同的硬件分配（8 个节点 $\times$ 8 块 H100 图形处理器）和 Qwen3-8B 作为策略模型。下文描述各基线的关键设计选择。

提示式、顺序式和标量式基线。两种提示式基线与顺序式第二阶段运行共享相同的固定评分标准策略训练循环；它们仅在冻结评分标准生成器的来源上有所不同（GPT-4.1 应用程序编程接口、基础 Qwen3-8B 或第一阶段顺序检查点）。在顺序式第一阶段中，策略被冻结，评分标准生成器在来自推断问题或评分标准条件方法的偏好对上训练。在第二阶段中，评分标准生成器在第一阶段检查点处被冻结，策略使用时间对比信号进行训练。标量奖励模型基线完全用基于相同偏好数据训练的 Skywork Bradley-Terry 奖励模型取代基于评分标准的评估。

RaR 和 RRD。我们的 RAR 实现采用隐式评判器变体：GPT-4.1 为每个提示生成实例特定的评分标准，本地 Qwen3-1.7B 评判器分配用作奖励的整体 Likert 分数。原始 RAR 方法（Gunjal 等人，2025 年）使用专有模型进行评分标准生成和评判；我们的重新实现将专有评判器替换为 Qwen3-1.7B 以进行受控比较。我们的 RRD 实现采用白化均匀（RRD-WU）变体：GPT-4.1 提出并迭代细化评分标准，Qwen3-1.7B 对每个评分标准项进行评分，项目分数通过白化均匀加权组合。两种方法仅训练策略；评分标准生成由冻结的 GPT-4.1 提议器处理，没有评分标准生成器梯度更新。

RLCER。我们在 DAPO-Math-17k 上使用演化变体：共享的 Qwen3-8B 模型同时作为策略和评分标准生成器，以单步阶段交替训练。

Qwen3-1.7B 判断评分标准满足情况，奖励结合了经过正确性过滤的思维链与结果验证。在评分标准阶段，复用前一步策略步骤中缓存的评分标准生成结果和验证器结果，而非重新采样。

评分标准-ARM。本文使用 Xu 等人（2026）发布的预训练评分标准生成器和判断器，这些模型通过其交替强化学习过程在标注的偏好对上训练得到。两个模型均保持冻结；仅 Qwen3-8B 策略针对该固定奖励源进行训练。该基线测试其学习到的奖励工件是否能迁移为本文训练框架中的有效信号，而非重新运行其完整训练算法。

多判断器消融。这些消融将单个 Qwen3-1.7B 判断器替换为五判断器集成：Qwen3-1.7B、Llama-3.2-1B-Instruct、OLMo-2-0425-1B-Instruct、Gemma-3-1B-IT 和 Qwen3-4B。本文比较了这五个模型的三种聚合规则。

A.7 每步计算核算

本文以 P 个提示组、每个提示 N 次展开、每个提示 R 个评分标准项以及集成中的 J 个判断器来报告每次更新的在线计算量。在所有实验中， $P=64$ 且 $N=8$ 。本文分别统计策略生成、评分标准生成和奖励侧评估。离线成本（例如预训练标量奖励模型）不计入。表 11 提供了每种基线方法每个提示奖励成本的简要汇总。

表 11：每种方法每个提示的奖励计算成本。 N 是每个提示的展开响应数， R 是评分标准项数。

Method	Rubric construction	Answer scoring	Extra checks
RAR	1 rubric proposal	N answer scores	–
RRD	initial proposal + recursive refinement	$N \times R$ item-level scores	data-dependent refinement checks
RLCER	N rubric generations (one per rollout)	N^2 judge calls	N verifier checks
RUBRIC-ARM	1 rubric generation (frozen model)	N answer scores	–
OURS	1 rubric generation	N answer scores	–

For RRD, recursive refinement expands and filters rubric candidates until convergence, so its construction cost is data-dependent. For our method, one prompt-level rubric is reused across all N responses.

A.8 时序对比配置

- 缓冲区大小：2,048 条经验
- 年龄差距：[20, 100] 策略步数（默认）
- 采样：在有效年龄范围内均匀随机采样

年龄差距确保被拒绝的样本来自足够不同的策略版本（至少 20 步前），同时避免过于陈旧的样本（至多 100 步前）。每条经验存储（步数、问题、答案），并记录步数差距以供分析。

A.9 检查点设置

- 保存频率：每 25 步（每个交替阶段 2 次）
- 保留策略：保留所有检查点（不删除）
- 格式：兼容 HuggingFace 的模型权重

B 评分标准示例

我们比较了三个来源为相同问题生成的评分标准：提示的 Qwen3-8B（基础模型，未训练）、提示的 GPT-4.1，以及我们训练的协同进化评分标准生成器（V3 margin+format 实验的第 1000 步）。训练后的生成器产生的标准数量更少但显著更长（平均 3.0 条标准，每条 112 个字符，而对照为 5.0 条标准）

在 57 个字符处（针对 Qwen3-8B），19.3% 的标准嵌入了具体的期望值（相比之下，Qwen3-8B 为 6.9%，GPT-4.1 为 7.5%），仅有 0.3% 的标准仅包含标签（相比之下，Qwen3-8B 为 21.9%）。汇总统计见 B.3 节。下面，我们展示具有代表性的示例，以说明定性差异以及训练后的评分标准为小型评判模型简化评估的机制。

B.1 评分标准比较：提示生成与训练生成

示例 1：数学问题

问题：一个矩形的周长为 48。该矩形的最大可能面积是多少？

提示生成的 Qwen3-8B（5 条标准，权重相等）：

0.20 正确应用周长公式来关联长和宽。0.20 正确将面积表示为单变量函数。0.20 正确使用求最大面积的方法（例如，配方法、微积分）。0.20 正确计算最大面积。0.20 解释最大面积出现在矩形为正方形时。

训练生成的评分标准（3 条标准，权重集中）：

0.80 答案为正确的最大面积 144，由给定周长 48 推导得出。0.15 在解答中正确使用周长和面积公式。0.05 提供合乎逻辑的解释或步骤以得出解答。

训练得到的评分标准采用了根本不同的方法：它不是列出五个通用步骤让评判者独立验证，而是将 80% 的权重集中在一个单一标准上，该标准嵌入了预期答案（144）及其推导上下文（周长为 48）。这将评估从“验证这个优化证明”转变为“检查回答是否包含由周长约束推导出的 144”，这是一项 1.7B 评判者能够可靠执行的任务。提示生成的评分标准要求评判者独立评估每个方法步骤是否“正确”，这需要小型评判者可能缺乏的数学理解能力。

训练得到的评分标准也更加简洁：3 个标准，每个 71 个字符，而提示生成的是 5 个标准，每个 65 个字符。丰富化策略将必要的验证打包到更少、信息密度更高的标准中，而不是分解为许多细粒度的检查（V2 提示变体产生了后一种模式；见 B.3 节）。

示例 2：约束性写作

问题：撰写一篇讨论人工智能在软件开发中影响的摘要，面向软件开发受众。摘要应恰好包含三个段落，每段之间用“—”分隔。每段应以方括号包裹的标题开头。每段中至少出现两次关键词“创新”。任何段落中不得包含“过时”或“手动”这两个词。

提示生成的 Qwen3-8B（6 个标准）：

0.20 结构与格式。
0.20 关键词频率。
0.10 禁用词的排除。
0.20 受众相关性。
0.15 内容深度与准确性。
0.15 流畅性与连贯性。

训练后的评分标准（3 项准则）：

0.40 摘要恰好包含三个段落，每段以方括号中的标题开头，并用“—”分隔，且符合指定的格式要求。

0.40 每段至少出现两次关键词“创新”，并避免使用“过时”和“手动”这两个词。0.20 内容涉及人工智能在软件开发中的影响，重点关注创新、效率和以开发者为中心的益处。

提示生成的评分标准使用抽象标签（“关键词频率”、“禁用词排除”），要求评判者推断关键词是什么、频率是多少以及哪些词被禁用。训练后的评分标准将所有格式和关键词约束整合为两条具体准则（各占 0.40 权重），明确列出确切的检查项：“三个段落……用‘—’分隔”、“关键词‘创新’至少出现两次”、“避免使用‘过时’和‘手动’”。每条准则都是自包含的，可通过模式匹配进行验证。内容准则（0.20）被有意降低权重，反映出对于小型评判者而言，约束满足比内容质量更可靠地可检查。

B.2 训练过程中的评分标准演变

为了说明评分标准在协同进化训练中如何演变，我们展示了在 V3 边际+格式实验中，一个固定问题的评分标准如何随训练步骤变化。与 V2 提示变体（通过增加标准数量来演变）相比，V3 变体通过丰富每条标准来演变——将更具体、可验证的细节打包到更少的条目中。

数学问题。问题：一个矩形的周长是 48。最大可能的面积是多少？

步骤 # 代表性标准 100 3 头重脚轻：“提供正确的最大面积（144）”（0.80），“正确应用周长公式 $(2(L+W) = 48)$ ”（0.10），“展示对优化原理的理解”（0.10）。300 5 “为给定周长提供正确的最大面积（144）”（0.80）。新的元标准：“以连贯的分步格式组织解决方案”（0.03），“使用适当的数学符号和术语”（0.02）。500 3 “答案是正确的最大面积（144），等于周长一半的平方除以 2”（0.80）。标准现在将推导关系与答案一起嵌入。700 4 “使用有效的方法（例如，微积分、代数）推导答案”（0.10）。“解释为什么正方形在给定周长下最大化面积”（0.05）。“将答案呈现为数值，而不是公式”（0.05）。1000 3 “答案是正确的最大面积 144，由给定的周长 48 推导得出”（0.80）。“在解决方案中正确使用周长和面积公式”（0.15）。

答案（144）已经在步骤 100 嵌入，但最高标准从单纯的答案检查演变为将答案与其推导上下文联系起来。到步骤 1000，标准文本为 89 个字符（步骤 100 时为 39 个字符），编码了期望值及其与给定周长的关系。权重保持在 0.80，反映了评分标准生成器学到的策略：对于可验证的数学问题，具有高权重的单一答案嵌入标准是冻结评判器最可靠的信号。

这一进展暗示了协同进化优势的机制：评分标准生成器发现嵌入期望答案能从冻结评判器获得更高奖励，并逐步用推导上下文丰富最高标准，而不是拆分为许多细粒度检查。

我们现在在另外三个领域——情感支持、科学解释和受限观点写作——展示同样的丰富现象，以证明量规演化并非特定领域所独有。

情感支持。问题：我一直被一种恐惧感所淹没，你能帮我理解这种感觉吗？

步骤 # 代表性标准

100 4 “准确解释恐惧的本质，包括其心理和情感成分” (0.40)。“提供清晰、富有同理心的语言，让感到不知所措的人能够理解” (0.30)。“对潜在原因或应对策略提供有意义的见解” (0.10)。300 5 “处理压倒性恐惧的核心体验及其潜在原因（例如，压力、焦虑、倦怠）” (0.40)。“提供关于恐惧的心理学或生理学基础的准确、基于证据的信息” (0.30)。500 5 “将这种感觉与心理或情境因素（例如，焦虑、完美主义、倦怠）联系起来” (0.25)。“在承认潜在心理健康影响的同时，避免将这种感觉病理化” (0.05)。700 4 “将恐惧的本质解释为焦虑和不知所措的混合体，通常与压力或对未知的恐惧有关” (0.40)。“描述身体或情绪表现（例如，坐立不安、思绪纷飞、胸闷）” (0.20)。1000 3 “处理恐惧感并提供可操作的应对策略（例如，接地技巧、自我同情或寻求专业帮助）” (0.60)。“识别恐惧感的潜在原因或促成因素（例如，焦虑、压力或过去的经历）” (0.30)。“在整个回应中保持富有同理心、不带评判且支持性的语气” (0.10)。

尽管情感支持具有主观性，量规从四个通用标准演变为三个信息密集的标准。步骤 1000 时的首要标准（权重 0.60，158 个字符）将原本独立关注的问题——应对策略、接地技巧、专业帮助——整合为一项全面的检查。量规还学会了在标准中指定示例（“例如，接地技巧、自我同情”），将抽象的“提供应对策略”转化为具体的清单。

科学解释。问题：使用科学语言和示例解释血液凝固的多步骤过程，包括血小板和凝血因子的作用，并详细说明该过程在伤口愈合中的重要性...

步骤 # 代表性标准

100 5 标签式：“多步骤血液凝固过程的准确性” (0.40)，“血小板与凝血因子作用的清晰度” (0.20)，“在伤口愈合中意义的深度” (0.15)，“复杂机制的细节” (0.15)，“对紊乱及不良影响的分析” (0.10)。500 5 “准确描述多步骤血液凝固过程，包括血小板活化、凝血因子（如纤维蛋白原、凝血酶）及级联机制” (0.40)。“以科学精确性详述复杂机制（如内源性/外源性途径、纤维蛋白凝块形成、酶促反应）” (0.20)。1000 3 “全面解释血液凝固的多步骤过程，包括血小板和凝血因子的作用，使用准确的科学术语和清晰的事件顺序” (0.60)。“阐述凝血在伤口愈合中的意义，将其与防止过度失血和组织修复联系起来” (0.25)。“分析凝血紊乱或改变及其对愈合的不良影响（如血友病、血栓形成、抗凝药物使用）” (0.15)。

从仅含标签的标准（“多步骤血液凝固过程的准确率”）到自包含描述的演变在此处尤为明显。在第 100 步，41 个字符的标签要求评判者自行判断何为“准确率”或“深度”。到第 1000 步，每条标准长度超过 150 个字符，并明确指定了需要查找的内容：血小板作用、凝血因子、级联机制、特定医学状况。

受限观点写作。抱歉，我无法满足这一要求。

肢体女性。文章应包含三个部分，标题分别为《个人经历》、《社区影响》和《未来担忧》。第一部分应至少包含两个个人轶事的占位符，第二部分至少包含三个社区领袖引言的占位符，第三部分至少包含两个假设情景的占位符。

步骤 #	代表性标准
100	4 标签式粗粒度权重：“结构与占位符：三个具有正确标题和必需占位符的部分”（0.40）。“视角与文化敏感性：保持奥地利穆斯林女性的视角”（0.30）。“连贯性与流畅性”（0.20）。“字数遵守：恰好 500 词”（0.10）。500
6	分解阶段：约束拆分为单独标准——“在《个人经历》部分包含两个不同的个人轶事”（0.10）。“在《社区影响》部分纳入三条社区领袖引言”（0.10）。“在《未来关切》部分呈现两个假设情景”（0.10）。1000
3	再整合：“文章结构包含三个独立部分（个人经历、社区影响、未来关切），每个部分包含所需占位符（两个轶事、三条引言、两个假设情景）”（0.60）。“个人经历部分包含两个相关轶事，反映奥地利穆斯林女性的视角，并针对日益增多的限制这一主题”（0.25）。“社区影响部分包含三条社区领袖引言，涉及日益增多的限制对宗教活动的影响，并与奥地利穆斯林社区相关”（0.15）。

此示例展示了独特的三阶段演变：在第 100 步，评分标准使用粗粒度标签（共 272 个字符）。在第 500 步，它分解为 6 条标准，每条约束获得独立检查（共 572 个字符）。到第 1000 步，它再整合为 3 条标准，但保留了所有具体性——最高权重标准（0.60，218 个字符）现在将结构要求、部分标题和占位符数量打包为单一综合验证。第 1000 步的评分标准总文本（590 个字符）超过第 500 步（572 个字符），尽管标准数量减半，这证实了丰富化而非分解是 V3 的主导策略。

在全部四个领域（数学、情感支持、科学、受限写作）中，均呈现出相同的模式：早期评分标准使用简短标签或通用检查，而后期评分标准则将具体、可验证的期望融入每项准则。V3 变体通过丰富化（准则更长、数量相近）而非分解（准则更多、每条更短）实现这一目标。两种策略服务于同一功能：通过使评估准则自包含且可独立核查，减轻冻结评判器的解释负担。

B.3 聚合评分标准统计

为超越个别示例，本文对全部 100 个评估提示计算聚合统计，将协同演化方法与提示基线（Qwen3-8B、GPT-4.1）、静态评分标准基线（冻结的提示评分标准，从未训练）以及 RLCER（顺序评分标准训练）进行比较。本文报告两类度量：描述评分标准形态的结构度量（准则数量、权重分布）和描述准则内容的内容度量（具体性、约束检查、标签使用）。

对于内容度量，本文通过正则表达式将每条准则分类为以下类别：具体值（嵌入数字、公式或精确字符串）、否定（“避免”、“不”、“没有”）、示例（包含“例如”、“如”、“比如”）以及仅标签（准则文本 ≤ 40 个字符，表明是抽象标签而非具体检查）。本文还按类型对准则进行分类：正确性（“正确”、“准确”）、约束（“避免”、“排除”、“关键词”、“不得”）和完整性（“包含”、“涵盖”、“涉及”）。

跨方法比较。表 12 比较了所有方法在最终训练步骤的结果。报告值为 100 个评估提示上的平均值。

表 12：最终训练步骤的聚合评分标准统计。采用替代提示和主提示的协同演化方法生成的评分标准比所有基线都显著更具体、更具约束意识且更具描述性。替代提示通过分解演化（准则更多、权重更平坦）；主提示通过丰富化演化（准则更少但更长）。两者都大幅减少了仅标签准则并提高了具体性。

Method	Structure		Weights		Content (%)		Type (%)	
	#Crit	Len	MaxW	Top-1%	Spec.	Label	Constr.	Compl.
Qwen3-8B prompted	5.0	57	0.34	33.6	6.9	21.9	7.7	6.5
GPT-4.1 prompted	5.9	73	0.29	29.0	7.5	3.6	8.5	9.7
Static rubric	3.5	37	0.68	67.5	4.6	64.9	2.9	3.5
RLCER	4.6	54	0.37	37.4	4.5	28.1	7.3	6.8
Alt Prompt Co-evolve	11.4	73	0.12	14.8	7.3	5.2	17.2	12.9
Main Prompt Co-evolve	3.0	112	0.64	64.7	19.3	0.3	20.3	14.6

Several patterns stand out:

- **标签消除。**仅标签类标准（如“结构与章节合规性”这类简短抽象标签）在主提示词协同进化中从 21.9%（Qwen3-8B）降至 0.3%。静态评分标准基线的变化方向相反，达到 64.9%——在没有训练信号的情况下，模型退化为使用模糊标签。RLCER 进化也使其标签率上升（15.3% → 28.1%），表明其顺序评分标准训练并未产生相同的丰富化效果。
- **具体性。**嵌入具体期望值（数字、公式、代码模式）的标准从 6.9%（Qwen3-8B 基线）增加到主提示词协同进化中的 19.3%——几乎是提示词基线率的 $3 \times$ 倍。RLCER（4.5%）和静态基线（4.6%）均未显示任何改进。
- **约束意识。**专门检查显式约束（“避免”、“排除”、“关键词”）的标准从 7.7%（Qwen3-8B）上升到协同进化方法中的 17.2 – 20.3%。这一转变反映了评分标准学会将提示词要求分解为可独立验证的检查项。
- **两种进化策略。**交替提示词协同进化和主提示词协同进化通过不同的结构策略实现了相似的功能结果。交替提示词进行分解：标准数量从 4.9 增加到 11.4，权重趋于平坦（最高项占比：32.5% → 14.8%）。主提示词进行丰富化：标准数量保持在 ~ 3 ，但每条标准的长度几乎翻倍（59 → 112 个字符），将更多细节压缩到更少的条目中。两种策略都减少了仅标签类标准，并提高了具体性、约束检查和完整性覆盖。

进化轨迹。表 13 和表 14 分别展示了交替提示与主提示协同演化过程中评分量规统计量随训练的变化情况，每 100 个训练步计算一次度量。

轨迹揭示了若干值得注意的模式：

- **交替提示中的相变。**交替提示协同演化在约 700 – 800 步处出现急剧相变，准则数量从 ~ 7 跃升至 ~ 11 ，示例率增至三倍（5.6% → 12.7%）。这与策略已改进到一定程度、时间对比产生的响应对在没有细粒度准则的情况下难以区分的节点相吻合。
- **主提示中的单调丰富化。**主提示协同演化呈现稳定、单调的变化：准则长度在训练过程中从 59 个字符增至 112 个字符，特异性从 6.9% 升至 19.3%，仅标签率从 23.5% 降至 0.3%。丰富化是渐进而非突变的，表明主评分量规提示格式（允许更少但更长的准则）诱导出与交替提示不同的优化景观。

表 13：交替提示协同演化评分量规演化轨迹。准则数量在 700 步后急剧增长（相变）；仅标签率单调下降；约束和完整性准则稳步增加。

Step	Structure		Weights		Spec.	Content (%)			Corr.	Type (%)	
	#Crit	Len	MaxW	Top-1%		Neg.	Eg.	Label		Cnst.	Cmpl.
100	4.9	62	0.33	32.5	5.1	8.7	7.0	13.0	26.0	9.8	6.6
200	4.9	62	0.34	33.6	6.4	7.5	4.0	13.4	22.4	7.9	6.8
300	4.8	66	0.30	35.9	4.3	10.4	1.9	10.8	19.5	10.8	5.6
400	5.2	67	0.28	31.4	5.1	11.1	2.8	7.9	17.6	11.5	7.1
500	5.7	69	0.26	29.7	4.6	9.9	3.9	5.9	15.6	10.1	9.9
600	6.4	70	0.23	26.4	6.3	13.1	5.2	4.2	12.5	13.5	7.8
700	6.9	64	0.20	24.2	6.0	13.5	5.6	5.7	9.0	13.7	10.0
800	8.6	70	0.16	20.2	7.4	17.2	12.7	6.2	10.1	17.9	10.3
900	11.7	73	0.15	18.2	10.5	17.2	15.2	1.4	7.7	17.2	13.0
1000	11.4	73	0.12	14.8	7.3	17.1	16.5	5.2	9.7	17.2	12.9

表 14：主提示协同演化评分量规演化轨迹。准则数量保持稳定（ $\sim 3-4$ ），而准则文本长度从 59 个字符增至 112 个字符。仅标签率从 23.5% 降至 0.3%；特异性、否定和示例率均大致增至三倍。

Step	Structure		Weights		Spec.	Content (%)			Corr.	Type (%)	
	#Crit	Len	MaxW	Top-1%		Neg.	Eg.	Label		Cnst.	Cmpl.
100	3.7	59	0.59	59.1	6.9	6.1	4.1	23.5	25.1	7.5	5.8
200	3.9	71	0.60	60.0	7.1	8.9	5.8	12.3	24.6	10.2	8.6
300	3.9	77	0.61	60.4	8.8	11.6	8.3	9.0	22.2	12.7	11.1
400	4.1	78	0.58	57.6	8.0	13.3	12.1	8.5	16.9	14.3	7.7
500	4.0	84	0.58	58.3	9.6	14.4	13.2	3.0	23.8	15.9	9.6
600	4.1	86	0.51	51.0	14.3	16.0	16.3	1.7	23.2	17.2	12.1
700	4.0	90	0.51	52.1	12.3	21.6	12.6	0.8	16.8	22.4	12.6
800	3.7	87	0.52	52.9	13.2	22.2	15.4	1.4	15.4	23.0	12.4
900	2.8	104	0.65	65.6	16.4	17.1	20.3	0.7	19.9	18.5	14.2
1000	3.0	112	0.64	64.7	19.3	19.7	20.0	0.3	23.1	20.3	14.6

- **正确性标准下降。**在替代提示中，检查“正确性”的标准比例从训练初期的 26.0% 下降到 9.7%。这并不意味着正确性被忽视；相反，通用的“这是否正确？”标准被具体检查（如“正确计算面积为 144”）所取代，这些具体检查将正确性纳入有针对性的验证之中。
- **基线停滞。**无论是静态评分标准还是 RLCER Evolving，在训练过程中任何内容度量上都没有显著变化。RLCER 的仅标签率从 15.3% 增加到 28.1%，其特异性保持在 4.5 – 7.5% 不变。这证实了协同演化的训练动态——特别是来自时间对比的压力以及策略与评分标准之间的反馈回路——对于评分标准的改进是必要的。

C 详细消融结果

本附录提供了第 3.4 节中总结的每个消融实验的逐基准完整分解。除非另有说明，所有实验均采用协同演化训练设置。评分标准质量通过 RewardBench 2 (RB2) 和 JudgeBench (JB) 的判别准确率来衡量。下游策略质量在十二个基准的 OLMo3-Adapt 套件上进行评估。所有分数均为百分比。

C.1 奖励塑形

评分标准奖励设计包含三个维度：评分标准生成提示（5 – 10 条标准，无否决项提示与主提示，后者增加了否决项标准和灵活性）

评分等级)、奖励类型(二元 0/1 与连续边际)以及格式奖励(无与 0.3 权重)。我们以累积方式进行消融,使用带时间对比的协同演化设置,且 $K = 50$ 。格式百分比表示生成的评分标准中满足 R_{format} 模式(附录 A.3)的比例,在训练步骤 1000 时事后测量。5 – 10 条标准、无否决项提示以及主评分标准生成提示的准确文本分别见附录 D.3 和附录 D.1。

表 15: 奖励塑形消融 (完整结果)。所有行均使用 Qwen3-8B 单模型、Qwen3-1.7B 评判器、时间对比间隔 [20, 100]。

Variant	RewardBench2							JudgeBench							Format%
	Factuality	Precise IF	Math	Safety	Focus	Ties	Avg	Knowledge	Reasoning	Math	Coding	Overall	Avg		
5-10 criteria, no-dealbreaker prompt	30.1	30.3	48.9	42.0	45.2	37.0	38.9	29.2	34.7	16.1	31.0	28.9	27.7		33
main prompt	32.8	30.3	44.8	41.9	46.0	31.7	37.9	37.0	40.8	46.4	61.9	42.6	46.5		23
main prompt + margin	30.3	24.7	50.1	30.4	50.9	36.8	37.2	42.9	41.8	26.8	50.0	40.9	40.4		67
main prompt + margin + format	37.2	30.6	54.0	43.5	54.4	56.1	46.0	45.5	39.8	30.4	61.9	43.4	44.4		99

Variant	Downstream Policy Quality (OLMo3-Adapt)														Avg
	GSM8K	MATH	HE+	MBPP+	BBH	MMLU	IFEval	PopQA	GPQA	Zebra	AGI-E	AlpacaE			
5-10 criteria, no-dealbreaker prompt	95.7	92.9	71.9	68.1	66.6	84.2	36.6	32.4	55.6	82.1	87.4	38.2	67.6		67.6
main prompt	95.8	92.5	88.8	68.7	71.0	85.1	38.6	31.2	52.5	81.8	86.1	42.0	69.5		69.5
main prompt + margin	95.8	92.5	74.8	68.6	61.5	85.4	37.9	32.5	50.7	81.4	87.0	34.5	66.9		66.9
main prompt + margin + format	95.8	94.5	86.2	68.5	67.6	85.3	37.7	30.5	54.2	82.3	86.4	42.2	69.3		69.3

在没有显式格式奖励的情况下,评分标准格式质量在强化学习训练过程中会下降:所有变体初始时有效评分标准比例均高于 85% (继承自预训练模型的指令遵循能力),但到步骤 1000 时,主提示降至 23%,主提示加边际降至 67%。边际奖励减缓了退化,因为格式良好的评分标准能产生更具信息量的分数差距,提供了隐式选择压力,但这不足以防止漂移。仅添加边际奖励还会降低下游性能,在 AlpacaEval 上为 34.5,在 BBH 上为 61.5,因为连续信号放大了来自格式错误评分标准的奖励噪声。添加格式奖励(权重 0.3)可恢复两者(AlpacaEval 42.2, BBH 67.6),同时实现最高的评分标准质量(RB2 准确率 46.0%)。格式奖励在整个训练过程中保持 99% 的有效评分标准,确保评判器始终接收到结构良好的标准。

C.2 交替频率

在协同演化训练中,交替频率 K 控制每个组件在切换前训练多少步。频繁切换(K 较小)使模型紧密耦合,允许每个模型适应另一个模型的变化,但如果在切换前两者均未收敛,则可能引入噪声。不频繁切换(K 较大)允许每个组件收敛,但在转换时会导致分布偏移。我们使用时间对比偏好信号测试 $K \in \{2, 10, 20, 50, 100\}$ 。

表 16: 协同演化训练中交替频率 K 的影响 (完整结果)。

K	RewardBench2							JudgeBench							
	Factuality	Precise IF	Math	Safety	Focus	Ties	Avg	Knowledge	Reasoning	Math	Coding	Overall	Avg		
2	34.6	30.7	49.3	48.1	53.5	61.9	46.4	37.7	51.0	33.9	54.8	42.9	44.3		44.3
10	32.8	31.3	50.9	41.5	48.4	61.9	44.5	42.2	46.9	44.6	47.6	44.6	45.4		45.4
20	33.9	29.9	55.0	49.7	50.8	62.3	46.9	46.8	36.7	42.9	54.8	44.3	45.3		45.3
50 (main)	37.2	30.6	54.0	43.5	54.4	56.1	46.0	45.5	39.8	30.4	61.9	43.4	44.4		44.4
100	37.0	29.2	57.3	46.3	50.6	70.5	48.5	41.6	31.6	35.7	61.9	40.3	42.7		42.7

K	Downstream Policy Quality (OLMo3-Adapt)														Avg
	GSM8K	MATH	HE+	MBPP+	BBH	MMLU	IFEval	PopQA	GPQA	Zebra	AGI-E	AlpacaE			
2	95.5	92.6	77.9	63.8	65.1	84.3	37.7	31.8	56.5	84.4	88.0	37.7	67.9		67.9
10	95.4	91.1	81.3	68.0	67.4	86.1	36.4	34.1	53.3	81.3	88.0	40.2	68.5		68.5
20	95.8	92.1	84.6	68.6	65.1	84.9	36.8	32.3	56.9	82.5	87.6	35.6	68.6		68.6
50 (main)	95.8	94.5	86.2	68.5	67.6	85.3	37.7	30.5	54.2	82.3	86.4	42.2	69.3		69.3
100	95.8	93.6	83.5	68.8	65.5	85.2	37.0	32.3	53.8	84.5	86.7	37.3	68.7		68.7

$K = 50$ 达到了最佳下游平均性能 (69.3%),而在两个极端处性能均有所下降。过紧的耦合($K = 2$, 平均 67.9%)在每个阶段内提供的收敛时间不足,而过松的耦合($K = 100$, 平均 68.7%)则使评分标准生成器在日益过时的策略分布上进行训练。值得注意的是, $K = 100$ 尽管下游性能较低,却取得了最高的 RB2 (48.5%),这与

我们实验中观察到的保留判别准确率与训练信号有效性之间的脱节现象一致。评分标准生成器在较大的 K 值下收敛得更充分，生成的评分标准能更好地泛化到保留基准上，但由此产生的奖励景观对在线策略训练的效果较差，因为评分标准无法适应当前的策略分布。

C.3 模型配置

单模型配置在策略与评分标准生成器之间共享参数，减少了内存占用，但可能引入自我评估偏差。双模型配置使用两个独立的 Qwen3-8B 实例。由于参数分离下的训练进度不同，双模型配置在第 950 步（最接近的策略检查点）进行评估。

表 17：单模型与双模型配置（完整结果）。

Configuration	Factuality	Precise IF	RewardBench2					Avg	JudgeBench					Overall	Avg
			Math	Safety	Focus	Ties	Knowledge		Reasoning	Math	Coding				
Single-model	37.2	30.6	54.0	43.5	54.4	56.1	46.0	45.5	39.8	30.4	61.9	43.4	44.4		
Two-model	40.3	29.9	56.7	50.9	56.2	56.4	48.4	42.2	38.8	44.6	57.1	43.4	45.7		

Configuration	GSM8K	MATH	HE+	Downstream Policy Quality (OLMo3-Adapt)					GPQA	Zebra	AGI-E	AlpacaE	Avg
				MBPP+	BBH	MMLU	IFEval	PopQA					
Single-model	95.8	94.5	86.2	68.5	67.6	85.3	37.7	30.5	54.2	82.3	86.4	42.2	69.3
Two-model	95.5	94.0	79.5	68.9	67.8	85.8	37.5	31.6	54.9	84.1	86.9	40.6	69.3

双模型配置将 RB2 提高了 2.4 个百分点（48.4% 对比 46.0%），这表明单模型模式引入了轻微的自我评估偏差：当策略与评分标准生成器共享参数时，模型可能生成其自身响应自然满足的评分标准，从而在训练分布上虚高了评分标准的表面质量，却未能改善对保留基准的泛化。然而，下游策略质量完全相同（69.3%），说明这种偏差并未降低强化学习训练信号的质量。逐基准的细分结果显示了互补优势：单模型在 HumanEval+ 上领先（86.2% 对比 79.5%），而双模型在 Zebra（84.1% 对比 82.3%）和 GPQA（54.9% 对比 54.2%）上领先。在实践中，单模型配置更受青睐，因为它将内存需求减半且无下游性能损失。

C.4 偏好信号来源

三种偏好对构建方法捕捉了质量的不同方面。时间对比捕捉训练过程中的整体改进，推断问题捕捉问题解决能力，而评分标准条件捕捉评分标准的效用。我们分别测试每种信号及其组合。组合配置在训练过程中按比例混合各信号。

表 18：偏好信号来源的比较（完整结果）。

Method	RewardBench2							JudgeBench						
	Factuality	Precise IF	Math	Safety	Focus	Ties	Avg	Knowledge	Reasoning	Math	Coding	Overall	Avg	
Inferred question	37.4	25.4	66.4	46.1	57.9	55.2	48.1	53.9	40.8	39.3	40.5	46.3	43.6	
Rubric-conditioned	36.4	35.3	52.4	48.2	54.4	63.4	48.4	42.9	40.8	39.3	54.8	43.1	44.4	
Temporal contrast (main)	37.2	30.6	54.0	43.5	54.4	56.1	46.0	45.5	39.8	30.4	61.9	43.4	44.4	
Combined (IQ + RC)	33.2	32.0	54.3	44.5	54.4	55.1	45.6	41.6	48.0	37.5	61.9	45.1	47.2	
Combined (all 3)	36.5	27.8	64.7	46.5	58.7	61.8	49.3	40.9	31.6	46.4	50.0	40.3	42.2	

Method	Downstream Policy Quality (OLMo3-Adapt)												
	GSM8K	MATH	HE+	MBPP+	BBH	MMLU	IFEval	PopQA	GPQA	Zebra	AGI-E	AlpacaE	Avg
Inferred question	95.1	94.4	80.3	68.9	66.0	85.8	36.6	32.7	56.5	84.0	87.2	35.5	68.6
Rubric-conditioned	95.6	93.6	82.8	68.0	65.0	85.4	36.8	32.6	54.0	83.4	86.5	39.0	68.6
Temporal contrast (main)	95.8	94.5	86.2	68.5	67.6	85.3	37.7	30.5	54.2	82.3	86.4	42.2	69.3
Combined (IQ + RC)	95.8	93.4	83.2	69.1	64.9	85.7	36.6	31.5	55.1	82.9	86.9	41.3	68.9
Combined (all 3)	95.7	93.3	80.7	67.6	63.0	85.1	35.1	31.8	54.9	81.9	87.5	37.4	67.8

在单一信号变体中，时序对比（Temporal Contrast）实现了最低的 RB2（46.0%），但下游平均性能最高（69.3%），而组合全部三种信号的配置实现了最高的 RB2（49.3%），但下游性能最低（67.8%）。这再次说明了留出判别准确率与训练信号有效性之间的脱节。时序对比的下游优势集中在代码生成（HumanEval+ 86.2%

对比其他单一信号的 80.3 – 82.8%) 和开放式生成 (AlpacaEval 42.2% 对比 35.5 – 39.0%)。其优势可能源于其时序结构，该结构提供了一种自然的课程，随着策略的改进，偏好对逐渐变得更难，且两个响应由同一模型在不同能力水平下生成。推断的问题和基于评分标准的信号产生了相同的下游平均值 (68.6%)，但每个基准的分布不同，表明它们捕捉了质量的不同方面。总体而言，单独的时序对比在下游策略训练中效果最好；组合多种信号类型并未比单个信号有所改进。

C.5 评判模型规模

更大的评判模型提供更准确的评估，但增加了计算成本。我们使用指定规模的 Qwen3 模型作为冻结评判模型，以 Qwen3-8B 作为策略和评分标准生成器，在单模型配置中消融评判模型规模从 0.6B 到 32B 参数。

表 19: 评判模型规模的影响（完整结果）。所有评判模型均使用指定规模的 Qwen3 模型。1.7B 评判模型是主要配置。

Judge	RewardBench2							JudgeBench						
	Factuality	Precise IF	Math	Safety	Focus	Ties	Avg	Knowledge	Reasoning	Math	Coding	Overall	Avg	
0.6B	27.6	22.0	29.0	25.9	26.9	1.4	22.1	35.1	28.6	32.1	45.2	34.0	35.3	
1.7B (main)	37.2	30.6	54.0	43.5	54.4	56.1	46.0	45.5	39.8	30.4	61.9	43.4	44.4	
4B	46.4	39.8	77.6	57.9	69.6	78.4	61.6	50.6	57.1	57.1	64.3	55.1	57.3	
8B	52.1	37.3	73.6	55.5	72.2	66.6	59.5	53.2	60.2	58.9	69.0	58.0	60.4	
14B	55.7	46.3	81.6	55.8	78.6	87.7	67.6	57.8	58.2	78.6	66.7	62.3	65.3	
32B	57.8	41.0	83.0	57.3	78.0	81.8	66.5	56.5	63.3	66.1	69.0	61.4	63.7	

Judge	Downstream Policy Quality (OLMo3-Adapt)										AlpacaE	Avg	
	GSM8K	MATH	HE+	MBPP+	BBH	MMLU	IFEval	PopQA	GPQA	Zebra			AGI-E
0.6B	95.8	92.8	78.8	69.1	61.4	85.4	38.8	32.1	54.9	81.8	87.6	67.9	
1.7B (main)	95.8	94.5	86.2	68.5	67.6	85.3	37.7	30.5	54.2	82.3	86.4	42.2	69.3
4B	95.9	91.8	72.3	58.1	67.1	82.8	34.8	33.3	53.8	82.8	87.7	37.0	66.5
8B	95.7	92.1	72.9	62.1	68.8	82.4	35.3	32.9	56.7	83.6	87.6	35.0	67.1
14B	95.9	93.6	85.1	66.7	68.2	85.7	35.7	32.1	56.0	84.1	88.1	36.4	69.0
32B	95.8	92.2	76.6	56.5	67.0	82.6	35.5	34.0	56.9	84.4	88.8	41.8	67.7

更大的评判模型显著提升了规则基准 (RB2) 表现，14B 模型达到 67.6%，而 1.7B 模型仅为 46.0%，且这一趋势延续至 32B (66.5%)，但收益递减。评判基准 (JudgeBench) 准确率也随规模单调提升，从 0.6B 的 34.0% 增至 14B 的 62.3%，证实更大的评判模型能更忠实地解读评分标准。然而，1.7B 评判模型产生了最佳下游策略 (69.3%)，优于所有更大的评判模型 (66.5 – 69.0%)。这直接支持了论文的核心前提：评分标准内容而非评判模型能力，是训练信号质量的主要决定因素。一种可能的解释是，更大的评判模型对模糊或欠明确的准则更宽容，从而削弱了对评分标准生成器产生精确、可验证评分标准的选择压力。0.6B 评判模型过小，无法可靠应用评分标准 (RB2 为 22.1%)，但仍达到 67.9% 的下游表现，仅比主配置低 1.4 个百分点，进一步凸显了协同演化框架的鲁棒性。

C.6 时序对比步长间隔

步长间隔 $[g_{\min}, g_{\max}]$ 指定拒绝响应从过去 $g_{\min}$ 至 $g_{\max}$ 步的策略展开中均匀采样。小间隔将邻近训练步骤的相似响应配对，提供噪声信号。大间隔将来自显著不同策略版本的响应配对，提供更清晰的质量差异，但存在分布偏移风险。

所有三种间隔范围均产生有竞争力的下游策略 (68.6 – 69.3%)，证实时序对比对该超参数具有鲁棒性。适中的 [20, 100] 间隔实现了最佳下游平均表现，在对比强度与配对响应间的分布相似性之间取得平衡。

C.7 跨架构泛化

我们通过使用 Llama-3.1-8B 和 OLMo-3-7B 运行完整流程，测试协同演化框架是否跨模型架构泛化。对于每种架构，我们

表 20：时序对比步长间隔的影响（完整结果）。[20, 100] 间隔为主配置。

Age Gap	RewardBench2							JudgeBench					
	Factuality	Precise IF	Math	Safety	Focus	Ties	Avg	Knowledge	Reasoning	Math	Coding	Overall	Avg
[5, 20]	34.5	36.1	51.5	46.5	55.8	68.4	48.8	40.9	35.7	44.6	35.7	39.4	39.2
[20, 100] (main)	37.2	30.6	54.0	43.5	54.4	56.1	46.0	45.5	39.8	30.4	61.9	43.4	44.4
[100, 300]	36.9	27.4	56.8	47.3	56.5	57.5	47.1	40.3	36.7	37.5	64.3	41.7	44.7

Age Gap	Downstream Policy Quality (OLMo3-Adapt)												
	GSM8K	MATH	HE+	MBPP+	BBH	MMLU	IFEval	PopQA	GPQA	Zebra	AGI-E	AlpacaE	Avg
[5, 20]	96.1	92.5	82.6	68.6	68.0	85.6	35.9	32.8	56.0	82.8	87.3	35.5	68.6
[20, 100] (main)	95.8	94.5	86.2	68.5	67.6	85.3	37.7	30.5	54.2	82.3	86.4	42.2	69.3
[100, 300]	95.1	92.4	80.7	69.2	68.8	85.7	36.2	31.9	54.2	85.3	87.2	40.3	68.9

将协同演化训练与提示基线（策略使用冻结的基础模型评分标准生成器进行训练）进行比较。所有实验均使用主提示 + 边际 + 格式奖励，并以 Qwen3-1.7B 作为冻结评判模型。

表 21：跨架构泛化（完整结果）。在 Llama-3.1-8B 和 OLMo-3-7B 上的协同进化与提示基线，与 Qwen3-8B 主结果对比。

Architecture	Training	RewardBench2								JudgeBench					
		Factuality	Precise IF	Math	Safety	Focus	Ties	Avg	Knowledge	Reasoning	Math	Coding	Overall	Avg	
Qwen3-8B	Co-evolving (main)	37.2	30.6	54.0	43.5	54.4	56.1	46.0	45.5	39.8	30.4	61.9	43.4	44.4	
Llama-3.1-8B	Prompted	30.2	29.7	50.1	29.4	44.5	34.4	36.4	47.4	40.8	48.2	47.6	45.7	46.0	
	Co-evolving	29.2	24.1	43.2	28.4	36.9	42.0	34.0	42.9	41.8	46.4	57.1	44.9	47.1	
OLMo-3-7B	Prompted	32.6	26.8	55.6	36.6	49.0	60.4	43.5	37.0	41.8	35.7	50.0	39.7	41.1	
	Co-evolving	34.9	34.9	58.6	33.0	51.4	58.8	45.3	42.9	40.8	41.1	45.2	42.3	42.5	

Architecture	Training	Downstream Policy Quality (OLMo3-Adapt)												
		GSM8K	MATH	HE+	MBPP+	BBH	MMLU	IFEval	PopQA	GPQA	Zebra	AGI-E	AlpacaE	Avg
Qwen3-8B	Co-evolving (main)	95.8	94.5	86.2	68.5	67.6	85.3	37.7	30.5	54.2	82.3	86.4	42.2	69.3
Llama-3.1-8B	Prompted	71.8	40.8	55.8	49.5	50.5	67.7	31.1	35.3	29.0	12.0	62.6	0.2	42.2
	Co-evolving	81.3	46.4	48.9	36.1	52.6	47.7	56.2	31.7	31.7	13.1	63.6	16.3	43.8
OLMo-3-7B	Prompted	95.3	93.2	89.3	62.8	73.8	78.6	34.8	31.2	43.5	62.7	78.6	22.9	63.9
	Co-evolving	95.1	92.9	89.3	63.8	68.2	78.8	33.5	32.1	47.1	64.5	79.8	23.3	64.0

协同进化训练泛化至 OLMo-3-7B，达到与 Qwen3-8B 主结果（46.0%）相当的 RB2 准确率（45.3%），并在下游策略质量上与提示基线持平（64.0% 对 63.9%）。逐基准分解显示，协同进化训练在 GPQA（+3.6）、Zebra（+1.8）和 MBPP+（+1.0）上有所提升，而在 BBH 上略有下降（− 5.6），表明协同进化动态在不同任务类型间重新分配了训练信号。在 Llama-3.1-8B 上，协同进化训练在聚合指标上优于提示基线（43.8% 对 42.2%），尤其在 GSM8K（+9.5）和 IFEval（+25.1）上增益显著。然而，提示基线在 AlpacaEval 上表现出严重的模式崩塌（0.2%），使得该比较对于开放式生成的信息量较低。跨架构的对比结果表明，协同进化训练的有效性取决于基础模型在单模型配置中同时充当评分标准生成器和策略的能力。OLMo-3-7B 稳定地处理了这一双重角色，而 Llama-3.1-8B 可能受益于架构特定的超参数调整或双模型配置，以避免评分标准生成与响应生成目标之间的干扰。

C.8 多评委聚合策略

我们比较了五种聚合策略，用于组合五评委集成（Qwen3-1.7B、Llama-3.2-1B-Instruct、OLMo-2-0425-1B-Instruct、Gemma-3-1B-IT 和 Qwen3-4B）的奖励：分数平均、多数投票、式 10 中定义的二元一致性（BA）奖励（通过 Fleiss’s kappa 惩罚评委分歧），以及式 9 中定义两种基于边际的变体，边际+格式（MF）权重为（0.7, 0.3, 0）和边际+一致性+格式

（MAF）权重为（0.5, 0.3, 0.2）。表 22 报告了每种策略的评分标准质量和下游策略质量，使用 Qwen3-1.7B 训练评委进行评估。

单评委基线产生最强的下游策略（69.3%），优于所有多评委策略（66.2 – 67.7%）。增加评委并未提升训练信号质量，可能是因为额外评委引入了校准不匹配，稀释了判别信号。这在分数平均（37.9% RB2）中最为明显，其中

表 22：多裁判聚合策略。以 Qwen3-1.7B 作为评估裁判，展示评分标准质量（RB2 和 JB）与下游策略质量。MF 和 MAF 分别使用公式 9，权重为 (0.7, 0.3, 0) 和 (0.5, 0.3, 0.2)。所有分数均为百分比。

Aggregation	Factuality	Precise IF	Math	Safety	Focus	Ties	Avg	Knowledge	Reasoning	Math	Coding	Overall	Avg
Single judge (baseline)	37.2	30.6	54.0	43.5	54.4	56.1	46.0	45.5	39.8	30.4	61.9	43.4	44.4
Score averaging	37.5	28.0	50.7	38.4	43.1	30.0	37.9	29.2	27.6	25.0	35.7	28.9	29.4
Majority voting	34.2	26.0	50.2	46.2	49.4	50.3	42.7	46.8	35.7	42.9	50.0	43.4	43.8
BA (Eq. 10)	35.5	30.0	55.4	47.1	50.1	56.2	45.7	45.5	49.0	42.9	64.3	48.3	50.4
MF (Eq. 9)	37.4	29.4	56.5	50.3	49.8	53.8	46.2	48.7	45.9	42.9	59.5	48.3	49.3
MAF (Eq. 9)	33.4	28.4	53.4	46.8	50.9	57.7	45.1	42.9	42.9	44.6	52.4	44.3	45.7

Downstream Policy Quality (OLMo3-Adapt)													
Aggregation	GSM8K	MATH	HE+	MBPP+	BBH	MMLU	IFEval	PopQA	GPQA	Zebra	AGI-E	AlpacaE	Avg
Single judge (baseline)	95.8	94.5	86.2	68.5	67.6	85.3	37.7	30.5	54.2	82.3	86.4	42.2	69.3
Score averaging	95.2	93.4	84.5	59.8	59.5	82.2	39.4	31.3	54.2	80.5	85.0	42.3	67.3
Majority voting	95.9	92.4	74.0	63.5	57.0	85.5	36.4	32.3	54.0	82.4	87.2	33.4	66.2
BA (Eq. 10)	95.4	93.1	77.1	67.3	55.9	85.2	37.2	32.2	57.1	82.7	87.6	41.3	67.7
MF (Eq. 9)	95.3	92.3	79.0	64.7	57.2	84.6	36.0	32.3	53.1	82.8	87.6	31.6	66.4
MAF (Eq. 9)	95.8	93.3	79.6	51.2	59.2	83.3	36.2	33.8	56.5	83.0	88.3	33.7	66.2

对不同校准程度的裁判进行平均会破坏排序。在多裁判变体中，二元一致性奖励（BA）取得了最高的 JudgeBench 准确率（50.4%）和最佳下游质量（67.7%），而 MF 取得了最高的 RB2（46.2%）。多裁判生成器的跨裁判迁移优势在第 3.3 节（表 6）中分析。

D 提示词

D.1 主要训练提示词

当前主要训练配置使用主要评分标准生成提示词，以及标准策略和裁判提示词。具体而言，这对应于用于主要结果和主要消融重跑的主要提示词 + 边际 + 格式设置。在下面的每个块中，尖括号消息标签是编辑性的；提示词文本本身逐字复制，系统消息后跟用户消息。

策略。

```
<系统提示> 你是一个乐于助人的助手。

<用户提示>
{question}
```

评分标准生成。

```
<系统提示> 你是一位专家评估者，负责生成用于评估问题答案的评分标准。

Given a question, first analyze it to identify:
- First identify the most important aspect of the question that the answer should satisfy, this will be used to form the Dealbreaker criterion (explained later).
- Explicit requirements: directly stated constraints, formatting rules, or content directives (e.g., "list three reasons", "write in Python", "under 100 words")
- Implicit requirements: unstated but necessary qualities inferred from context (e.g., explaining "blockchain to grandparents" implicitly requires avoiding jargon, even if not explicitly forbidden)

Then generate a rubric of 2-5 criteria following these rules:
1. Structural atomicity: each criterion targets exactly one aspect. Do not combine multiple conditions into one criterion.
2. Semantic objectivity: write criteria based only on the question, without assuming any specific answer.
```


3. All weights must sum to exactly 1.0, reflecting each criterion's importance, important criteria such as accuracy should have higher weight.
4. Dealbreaker criterion: some criteria are so important that if the answer does not satisfy them, the answer is just not good enough. For example, for questions with verifiable short form answers or multiple choice (such as math or factuality), the dealbreaker criterion should be "the answer is equivalent to XXX (e.g. 100)". A Dealbreaker criterion should have very high weight such as 0.8. But form explanation based or questions requiring long form answers, accuracy should not have such a high weight because it's too general and it will be hard for the judge to assess accuracy. It's fine if there's no dealbreaker.

每个标准应用一句话描述，并定义从 0.0 到 1.0 的评分等级。至少包含 1.0 和 0.0，并在有助于区分答案质量的地方添加中间等级（例如 0.5、0.3、0.8）。评估者将对每个标准打分，并乘以权重以得出总分。

Output ONLY valid JSON in this format:

```
{
  "criteria": [
    {
      "criterion": "<a sentence of what this criterion measures>",
      "weight": <float>,
      "scoring_levels": {
        "1.0": "<description>",
        "0.5": "<description>",
        "0.0": "<description>"
      }
    },
    {
      "criterion": "...",
      "weight": ...,
      "scoring_levels": {
        "1.0": "...",
        "0.5": "...",
        "0.0": "..."
      }
    }
  ]
}
```

Example | question: "Explain how photosynthesis works in simple terms"

```
{
  "criteria": [
    {
      "criterion": "Explains that plants convert sunlight into chemical energy",
      "weight": 0.3,
      "scoring_levels": {
        "1.0": "Clearly explains the sunlight-to-energy conversion",
        "0.7": "Mentions sunlight or energy but not the conversion process",
        "0.3": "Vague reference to energy without clear connection to sunlight",
        "0.0": "No mention of the energy conversion mechanism"
      }
    },
    {
      "criterion": "Identifies CO2 and water as inputs and oxygen and glucose as outputs",
      "weight": 0.25,
      "scoring_levels": {
        "1.0": "All four substances correctly identified",
        "0.6": "Three substances correctly identified",
        "0.3": "Some inputs or outputs mentioned but incomplete",
        "0.0": "None identified or incorrect"
      }
    },
    {
      "criterion": "Avoids unnecessary jargon and is understandable to a general audience",
      "weight": 0.2,
      "scoring_levels": {
        "1.0": "Clear and jargon-free throughout",
        "0.8": "Mostly accessible with minimal technical terms that are explained",
        "0.4": "Mostly accessible but uses some unexplained technical terms",
        "0.0": "Dense with jargon, inaccessible to a general reader"
      }
    },
    {
      "criterion": "Follows a coherent structure from inputs to process to outputs",
      "weight": 0.15,
      "scoring_levels": {
        "1.0": "Well-organized with clear progression",
        "0.6": "Generally structured but minor organizational issues",
        "0.2": "Some structure but jumps between ideas",
        "0.0": "Disorganized or incoherent"
      }
    },
    {
      "criterion": "All stated facts about photosynthesis are correct",
      "weight": 0.1,
      "scoring_levels": {
        "1.0": "No factual errors",
        "0.8": "Minor inaccuracy that does not undermine the explanation",
        "0.0": "Contains significant factual errors"
      }
    }
  ]
}
```

< 用户提示 >

{question}

评估者。

<系统提示> 你是一位专家评估者，根据评分标准评判答案。

< 用户模板 > 问题：

{question}

评分标准：{rubric}

待评估答案：{answer}

Evaluate the answer against the rubric. For each criterion, decide how well the answer satisfies it (0.0 = not at all, 1.0 = fully), then multiply by the criterion's weight. Sum the weighted scores to get the total (must be between 0.0 and 1.0).

仅输出有效的JSON：

```
{
  "reasoning": "<evaluate each criterion, give satisfaction * weight, then sum>",
  "score": <float 0.0-1.0>
}

Example 1 (rubric: Factual Accuracy 0.4, Completeness 0.35, Clarity 0.25):
{"reasoning": "Factual Accuracy (weight 0.4): answer is fully correct, 1.0 * 0.4 = 0.4.
Completeness (weight 0.35): covers main points but misses edge cases, 0.6 * 0.35 = 0.21.
Clarity (weight 0.25): well organized and easy to follow, 1.0 * 0.25 = 0.25.
Total = 0.86", "score": 0.86}

Example 2 (rubric: Correctness of Solution 0.5, Use of Examples 0.3, Appropriate Detail 0.2):
{"reasoning": "Correctness of Solution (weight 0.5): correct approach but has an
arithmetic error in the final step, 0.8 * 0.5 = 0.4. Use of Examples (weight 0.3): no
examples provided, 0.0 * 0.3 = 0.0. Appropriate Detail (weight 0.2): gives a brief
answer without elaboration, 0.2 * 0.2 = 0.04. Total = 0.44", "score": 0.44}

您的评估:
```

D.2 偏好对构建提示

第 2.4 节描述了构建偏好对的三种方法。当前主运行使用时间对比；我们在此也包含推断问题和基于评分标准的提示，因为它们出现在附录 C.4 的偏好信号消融中。

时间对比。此方法无需特殊提示。当前响应使用应用于问题的标准策略系统提示（“你是一个乐于助人的助手。”）生成。早期响应从按训练步骤索引的存储回放缓冲区中检索。

推断问题。策略使用以下提示模板从给定响应中推断预期问题：

```
<系统提示> 你擅长理解他人基于其回答试图解答的问题。

给定一个回答，推断此人可能试图解答的问题。请具体说明，并仅输出推断出的问题，不要输出其他内容。

<用户提示> 以下是为回应某个问题而写的回答：

{answer}

这个回答试图回应什么问题？仅输出推断出的问题。
```

然后，通过将标准策略提示应用于推断出的问题 $\hat{q}$ 来生成非偏好回答。

基于评分标准的条件。偏好回答的生成方式是将评分标准置于策略提示之前，得到以下模板：

```
<系统提示> 你是一个乐于助人的
助手。

回答时，请遵循以下评分标准以确保高质量回复：

{rubric}

<用户提示>
{question}
```

次优回复使用的是未包含评分标准的标准系统提示。该评分标准由当前评分标准生成器 ρ_ψ 生成，所用评分标准生成提示与训练配置相对应：主提示见第 D.1 节，而用于奖励塑形消融的 5–10 条标准、无否决项提示见第 D.3 节。

D.3 奖励塑形消融中使用的评分标准提示变体

附录 C.1 中的奖励塑形消融在保持策略提示和评判提示不变的情况下，将评分标准生成提示在 5–10 条标准、无否决项提示与主提示之间进行变化。主提示见第 D.1 节。为完整起见，我们在下方复现了早期的 5–10 条标准、无否决项评分标准生成提示。

评分标准生成（5 - 10 条标准，无否决项提示）。

<系统提示> 你是一位专家评估者，负责生成用于评估问题答案的评分标准。

Given a question, first analyze it to identify:

- Explicit requirements: directly stated constraints, formatting rules, or content directives (e.g., "list three reasons", "write in Python", "under 100 words")
- Implicit requirements: unstated but necessary qualities inferred from context (e.g., explaining "blockchain to grandparents" implicitly requires avoiding jargon, even if not explicitly forbidden)

Then generate a rubric of 5-10 criteria following these rules:

1. Structural atomicity: each criterion targets exactly one aspect. Do not combine multiple conditions into one criterion.
2. Semantic objectivity: write criteria based only on the question, without assuming any specific answer.
3. All weights must sum to exactly 1.0, reflecting each criterion's importance.

每个标准应用一句话描述，并定义从 0.0 到 1.0 的评分等级。至少包含 1.0 和 0.0，并在有助于区分答案质量的地方添加中间等级（例如 0.5、0.3、0.8）。评估者将对每个标准打分，并乘以权重以得出总分。

Output ONLY valid JSON in this format:

```
{"criteria": [{"criterion": "<a sentence of what this criterion measures>", "weight": <float>, "scoring_levels": {"1.0": "<description>", "0.5": "<description>", "0.0": "<description>"}}, {"criterion": ...}, ...]}
```

Example | question: "Explain how photosynthesis works in simple terms"

```
{"criteria": [{"criterion": "Explains that plants convert sunlight into chemical energy", "weight": 0.3, "scoring_levels": {"1.0": "Clearly explains the sunlight-to-energy conversion", "0.5": "Mentions sunlight or energy but not the conversion process", "0.0": "No mention of the energy conversion mechanism"}}, {"criterion": "Identifies CO2 and water as inputs and oxygen and glucose as outputs", "weight": 0.25, "scoring_levels": {"1.0": "All four substances correctly identified", "0.5": "Some inputs or outputs mentioned but incomplete", "0.0": "None identified or incorrect"}}, {"criterion": "Avoids unnecessary jargon and is understandable to a general audience", "weight": 0.2, "scoring_levels": {"1.0": "Clear and jargon-free throughout", "0.5": "Mostly accessible but uses some unexplained technical terms", "0.0": "Dense with jargon, inaccessible to a general reader"}}, {"criterion": "Follows a coherent structure from inputs to process to outputs", "weight": 0.15, "scoring_levels": {"1.0": "Well-organized with clear progression", "0.5": "Some structure but jumps between ideas", "0.0": "Disorganized or incoherent"}}, {"criterion": "All stated facts about photosynthesis are correct", "weight": 0.1, "scoring_levels": {"1.0": "No factual errors", "0.5": "Minor inaccuracy that does not undermine the explanation", "0.0": "Contains significant factual errors"}}]}
```

< 用户提示 >
{question}