

Evolving-RL: 智能体经验 驱动自进化能力的端到端优化

Zhiyuan Fan^{1,2}, Wenwei Jin^{1,†}, Feng Zhang¹, Bin Li¹, Yihong Dong², Yao Hu¹, Jiawei Li¹

¹Xiaohongshu Inc. ²School of Computer Science, Peking University

[†]通讯作者。

{zyfan043, wenwei1217.jin, libin656712945, yaoohu}@gmail.com
{zhangfeng4, wangdesheng}@xiaohongshu.com
dongyh@stu.pku.edu.cn

摘要

经验驱动的自进化智能体旨在通过从过往交互中提炼可复用经验，克服大语言模型的静态特性，从而在部署时适应新任务。这一过程对基础模型的抽象、泛化和上下文学习能力提出了很高要求。然而，现有研究大多聚焦于系统层面的设计选择，例如经验的表示与管理方式，而忽视了底层模型的内在能力。尽管近期一些工作开始通过强化学习优化经验利用阶段，但仍未将自进化视为一个需要联合优化的统一过程。为此，本文提出 **Evolving-RL**，一个高效的算法框架，联合提升自进化所需的经验提取与利用能力。具体而言，本文以经验提取与评估为学习核心，利用评估产生的两个监督信号分别优化提取器与求解器，从而实现二者的协同共进化。在 ALFWorld 和 Mind2Web 上的实验表明，**Evolving-RL** 有效增强了大语言模型提取与复用经验的能力，在分布外任务上取得了显著的性能提升（在 ALFWorld 未见任务上相对 GRPO 基线最高提升 98.7%，在 Mind2Web 上提升 35.8%），且这些提升只有在经验提取与利用协同共进化时才能完全释放。此外，**Evolving-RL** 本质上是一种经验增强的强化学习算法。通过将可复用经验模式直接内化到模型参数中，即使在测试时没有经验积累的情况下，也能在已见和未见任务上取得远超标准基线的性能提升。代码见 <https://github.com/Fanzy27/Evolving-RL>。

1 引言

大语言模型（Large Language Models, LLMs）在广泛的任務中展现了卓越的能力，包括复杂推理 [9, 17, 11, 28] 和自主智能体决策 [26, 8, 35]。然而，一旦训练完成，大语言模型在很大程度上是静态的：它们缺乏在部署期间持续适应复杂的分布外环境和任务的能力。这一根本局限性推动了测试时自进化研究的兴起 [3, 31, 22, 38, 1]。作为该范式中的一个重要方向，经验驱动的自进化智能体




图 1: (a) 本文方法 (“Evolving-RL”) 积累的技能能够有效迁移到其他策略, 并持续提升下游性能。相反, 受限于技能质量较低, 由基础模型自身提取的技能 (“self-extracted”) 不仅无法提升性能, 反而相比不注入 (“None”) 会降低性能, 这证明了本文方法在确保技能质量方面的关键作用。(b) 除了测试时自进化, Evolving-RL 作为一种经验增强的强化学习算法也表现出高效性, 始终优于标准 GRPO 和受静态技能库约束的仅求解器训练。

从先前的交互中积累可复用的经验, 并利用这些经验解决相关的未来任务, 从而逐步增强其部署时的能力。

现有的经验驱动自进化方法主要关注系统层面的进化设计, 大量研究致力于经验表示 [33, 39, 27, 16]、形式化和管理机制 [6, 24, 34]。虽然这些基于提示的方法已成功证明注入过往经验可以显著提升下游决策能力, 但其有效性最终受限于底层模型提取和利用这些经验的能力 [18]——这一过程高度依赖于模型具备强大的上下文学习 [4] 和抽象推理能力。

近期若干研究 [30, 29] 探索了强化学习作为增强模型利用经验能力的一种途径。然而, 这些方法并未将自我进化作为一个统一过程进行优化。它们仅改进利用阶段, 同时依赖更强的外部模型或人工设计的过滤机制来保证所提取经验的质量。这种解耦设计存在固有局限, 因为提取与利用在学习过程中不仅是互补能力, 更是相互构成的。所提取经验的质量直接影响经验利用的强化学习动态。当提供的经验含有噪声时, 以其为条件会给优化过程引入方差与模糊性。因此, 策略往往收敛到一种退化行为: 学会系统性地忽略所提供的经验, 因为绕过不可靠的指导比尝试利用它能获得更稳定的回报。

为弥合这一差距, 本文提出演化强化学习 (**Evolving-RL**), 一种在统一训练范式下联合优化经验提取与利用的高效算法框架。为使该联合优化可处理且可解释, 我们特意将经验实例化为文本技能——紧凑的程序性抽象, 捕捉关于做什么、何时干预以及如何从失败中恢复的可操作规律。以该表示为基础, 演化强化学习采用以提取器为中心的设计: 对于每次源交互, 共享策略生成候选文本技能。随后, 每个候选技能通过应用于多个检索到的实例并根据下游反馈获得奖励来进行严格评估。同时, 该下游评估过程中收集的轨迹被回收用于精化模型的技能利用能力。通过将下游迁移性能作为主要监督信号, 提取器与求解器协同进化, 自然地将可迁移技能抽象的进步与稳健的技能条件执行耦合起来。

我们在基于文本的具身任务环境 ALFWorld 和基于网络的任务基准 Mind2Web 上评估了所提方法。实验结果表明, 演化强化学习显著提升了模型显式提取与复用技能的能力, 从而在分布外任务上带来明显更好的泛化。具体而言, 当加入所提取的技能时, 演化强化学习将

在 ALFWorld 未见任务上的成功率从 44.6% (GRPO [19] 基线) 提升至 88.6%，并将 Mind2Web 上的整体动作准确率从 22.73% 提高到 30.87%。此外，在技能迁移实验中，由 Evolving-RL 训练模型提取的高质量技能展现出对其他模型的强迁移能力 (图 1a)。此外，Evolving-RL 还通过将可复用的经验模式内化到模型参数中，强化了底层策略本身。即使不进行测试时技能注入，我们训练的策略在 ALFWorld 未见任务上仍达到 81.1% 的成功率，在 Mind2Web 上达到 28.05% 的整体动作准确率，显著优于标准 GRPO 基线 (分别为 33.7% 和 22.83%)，证明了其不仅对自我进化有价值，而且作为一种经验增强的强化学习形式也具有价值 (图 1b)。

2 相关工作

2.1 经验驱动的自我进化智能体

经验驱动的自我进化使智能体能够持续积累和复用知识，克服其训练后能力的静态性 [38, 3]。该领域的现有文献已在多个维度上推进了这一范式。在经验表示方面，先前研究探索了不同的粒度，从原始交互轨迹 [40, 33]、可复用工作流 [27] 到可执行技能 [39, 2, 41]、策略原则 [16]。除表示之外，并行工作还开发了用于自主经验提取 [2, 14, 20] 和高效记忆管理 [24, 5, 34] 的复杂机制。尽管取得了这些进展，这些系统主要依赖基础模型已有的提取和利用有效经验的能力。因此，经验驱动进化的收益从根本上受限于底层模型的内在能力 [18]。虽然近期方法 [29, 30, 25] 尝试利用强化学习 (Reinforcement Learning, RL) 来增强底层模型的能力，但它们通常孤立地优化经验利用，未能将提取和利用视为一个统一过程进行联合优化。相反，它们的经验提取阶段仍然严重依赖手工设计的过滤启发式规则或能力更强的外部模型。受此局限性的启发，我们的工作优化了整个自我进化循环：不再将经验生成视为外部组件，而是基于所提取技能的迁移价值来驱动端到端的进化过程。

2.2 经验增强的强化学习

通过强化学习 (Reinforcement Learning, RL) 增强经验利用本质上构成了一种经验增强的强化学习范式 [21, 30, 12]，能够显著提升训练效率。因此，近期一些工作也将该过程定义为一种强化学习范式。ERL[21] 与 RetroAgent[36] 利用任务特定的反思作为经验来增强学习过程。尽管在任务内取得了有效增益，此类经验缺乏泛化性，难以跨任务迁移。此外，EvolveR[29]、SkillRL[30] 和 D2Skill[25] 等框架将轨迹蒸馏为可复用的经验库，并在强化学习训练期间加以利用。然而，其经验构建流程的优化程度仍然较弱，提取过程仍严重依赖人工设计的过滤机制或更强的外部模型。相比之下，Evolving-RL 将经验提取与利用视为统一的优化问题。本文将经验实例化为可迁移的文本技能，通过其对检索到的下游任务的影响进行评估，并利用所得反馈在单一强化学习循环中协同训练提取器与求解器，从而确保提取的经验持续为强化学习训练提供有效效用。

值得注意的是，一项同期工作 [15] 具有相似的动机，即协同优化经验提取与利用。然而，该工作错误地将协同演化过程中的训练不稳定性归因于参数冲突，最终在两个不同模型中分别训练这两种能力。此外，其经验验证仍局限于单任务场景，限制了跨任务泛化性。相比之下，Evolving-RL 通过以评估为中心的训练明确确保泛化性，并且如附录 A 所述，有效解决了潜在的不稳定性，从而在真正统一的单一模型中训练两种能力。




图 2: Evolving-RL 概览。该框架首先进行在线技能提取，随后对提取的技能进行下游评估。该评估过程为提取器与求解器生成训练信号，使其在统一的协同演化框架内实现联合优化。

3 进化强化学习

3.1 框架概述

本文提出进化强化学习（Evolving-RL），一种统一的算法框架，在单一共享策略内联合提升模型的技能提取与技能利用能力。如图 2 所示，本方法在线生成技能并在下游任务上对其进行评估。该过程产生两个耦合的学习信号。跨多个任务聚合的下游奖励为所提取技能的质量与通用性提供直接监督，从而提升模型的技能提取能力。同时，下游评估期间收集的技能条件轨迹被复用以提升其技能利用能力。通过这种方式，所有采样的轨迹均被充分利用，使这两项能力在统一的算法框架内协同进化。

角色与共享策略。本方法涉及两个关键角色：提取器与求解器，二者共享相同的策略参数。提取器以一段完整的源交互为输入，生成紧凑的文本技能——一种过程性抽象，编码从该经验中提取的可复用决策规则、工作流程步骤及错误处理策略。求解器以新任务及注入的技能为输入，生成动作轨迹。

展开结构。每次训练迭代始于在无任何注入技能的情况下求解源任务 $x^{src} \sim \mathcal{D}$ 。由共享策略 π_θ 参数化的求解器在 x^{src} 条件下与环境交互，并产生轨迹：

$$\tau \sim \pi_\theta(\cdot | x^{src}).$$

所得轨迹 τ 与环境奖励 r^{src} 构成提取状态 $s^e = (x^{src}, \tau, r^{src})$ ，该状态条件化提取器以生成 N 个候选技能。随后，检索器 $\mathcal{R}$ 获取 K 个语义相关的下游任务，并对每个（技能，任务）对，求解器展开技能条件轨迹。该结构——源求解 $\rightarrow$ 技能提取 $\rightarrow$ 下游评估——在单次迭代内产生两个耦合的样本族：提取器样本与求解器轨迹，二者均被联合目标所利用。

3.2 提取器训练

在线技能生成。在演化强化学习（Evolving-RL）中，提取器以完全在线的方式进行优化，每次训练迭代都从生成新经验开始。给定提取状态 s^e ，提取器采样一组 N 个候选技能：

$$\mathcal{E} = \{e_1, \dots, e_N\}, \quad e_i \sim \pi_\theta(\cdot | s^e).$$

每个候选 e_i 被实例化为一个技能，即一种结构化的文本抽象，它编码了从源交互中提炼出的高层程序性知识和具体操作细节。生成的 N 个候选构成比较集，用于提取器优化中基于群体相对策略优化（GRPO）的优势估计。

面向泛化的评估。我们通过技能提升求解器在相关任务上性能的能力来评估其质量和泛化性。为确保公平评估，同一比较组内的所有候选技能必须在相同的下游任务集上进行评估。因此，我们不使用技能内容本身作为检索查询，因为这会导致不同技能在不同的下游任务集上被评估。相反，下游任务基于任务描述的嵌入进行检索。具体而言，给定源任务 x^{src} ，检索函数 R 返回一组语义最相似的前 K 个下游任务：

$$\mathcal{X}^{\text{ret}} = R(x^{\text{src}}) = \text{TopK}_{x \in \mathcal{D}} s(\phi(x^{\text{src}}), \phi(x)), \quad (1)$$

其中 $\phi(\cdot)$ 表示任务描述的嵌入， $s(\cdot, \cdot)$ 实例化为余弦相似度。我们还将源任务本身包含在 $\mathcal{X}^{\text{ret}}$ 中，因为技能质量不仅应反映向相关任务的迁移，还应反映其对原始任务的影响。

对于每个候选技能 e_i 和每个检索到的下游任务 $x_j \in \mathcal{X}^{\text{ret}}$ ，求解器生成一条以技能为条件的轨迹 $t_{ij} \sim \pi_\theta(\cdot | x_j, e_i)$ ，并获得环境奖励 r_{ij} 。分配给技能 e_i 的奖励定义为其平均下游性能：

$$R_i^e = \frac{1}{K} \sum_{j=1}^K r_{ij}. \quad (2)$$

一项技能只有在持续提升求解器在多个相关任务上的性能时，才会获得高奖励，从而直接将提取目标与跨任务迁移效用对齐。

提取器目标。源自同一交互的 N 个候选技能构成一个单一的 GRPO 比较组。我们计算组归一化

$$\frac{R_i^e - \text{mean}(\{R_{i'}^e\}_{i'=1}^N)}{\text{std}(\{R_{i'}^e\}_{i'=1}^N)} \text{ 优势为 } A_i^e = \frac{R_i^e - \text{mean}(\{R_{i'}^e\}_{i'=1}^N)}{\text{std}(\{R_{i'}^e\}_{i'=1}^N)}。 \text{ 提取器损失为}$$

$$\mathcal{L}_e(\theta) = -\frac{1}{N} \sum_{i=1}^N \min(\rho_i^e A_i^e, \text{clip}(\rho_i^e, 1 - \epsilon, 1 + \epsilon) A_i^e) + \beta_e D_{\text{KL}}(\pi_\theta \| \pi_{\text{ref}}) - \eta_e \mathcal{H}(\pi_\theta), \quad (3)$$

其中 $\rho_i^e = \frac{\pi_\theta(e_i | s^e)}{\pi_{\theta_{\text{old}}}(e_i | s^e)}$ 为重要性采样比率， D_{KL} 表示 KL 正则化项， $\mathcal{H}(\pi_\theta)$ 表示熵项。与通常用于鼓励探索的用法相反，我们采用负系数 η_e 的熵正则化来惩罚熵增长，并使提取策略偏向确定性预测。这一约束是必要的，因为技能天然允许多样化表示，意味着提取不存在单一的确定性目标。这一特性使得该过程本质上具有高熵。再加上技能评估过程中引入的噪声（见附录 A），这些因素否则可能导致策略熵在训练期间持续增长，最终导致训练崩溃。

3.3 求解器训练

跨技能组优势估计。在下游评估期间，每个检索到的任务 x_j 产生一组 N 条轨迹 $\{t_{ij}\}_{i=1}^N$ ，其中每条轨迹以不同的候选技能为条件。尽管由于注入的技能，这些轨迹来自异构提示，但它们仍然可以直接比较，因为同一任务 x_j 的所有 N 次展开共享底层任务语义、目标和上下文结构。因此，我们将每个任务的 N 条以技能为条件的轨迹聚合为一个单一的 GRPO 比较组，并通过组内奖励归一化计算求解器侧优势：

$$A_{ij}^s = \frac{r_{ij} - \text{mean}(\{r_{i'j}\}_{i'=1}^N)}{\text{std}(\{r_{i'j}\}_{i'=1}^N)}. \quad (4)$$

在这种分组机制下，求解器在下游任务上响应的正确性成为主导的优化信号。当存在有益技能时，求解器因利用该技能超越同一任务下以次优技能为条件的轨迹而获得奖励。相反，当提供虚假或误导性技能时，求解器因偏离相对于其替代方案的最优行为而受到惩罚，从而学会对退化的指导保持鲁棒性。这两种激励共同培养出一个既能有效利用高质量技能，又能在不良技能条件下保持稳定性能的求解器。

求解器目标。我们重用下游评估期间收集的所有 $N \times K$ 技能条件轨迹。设 A_{ij}^s 为式 (4) 中的异构上下文优势。求解器损失为

$$\mathcal{L}_s(\theta) = -\frac{1}{NK} \sum_{j=1}^K \sum_{i=1}^N \min(\rho_{ij}^s A_{ij}^s, \text{clip}(\rho_{ij}^s, 1 - \epsilon, 1 + \epsilon) A_{ij}^s) + \beta_s D_{\text{KL}}(\pi_\theta \| \pi_{\text{ref}}), \quad (5)$$

其中 $\rho_{ij}^s = \frac{\pi_\theta(t_{ij}|x_i, e_i)}{\pi_{\theta_{\text{old}}}(t_{ij}|x_i, e_i)}$ ， $D_{\text{KL}}(\pi_\theta \| \pi_{\text{ref}})$ 是 KL 散度正则化项，衡量当前策略 π_θ 与参考策略 π_{ref} 的偏差。

3.4 联合目标与协同演化动态

最终训练目标是提取器损失和求解器损失的加权组合：

$$\mathcal{L} = \lambda_e \mathcal{L}_e + \lambda_s \mathcal{L}_s. \quad (6)$$

由于两个损失作用于同一参数向量 θ ，它们紧密耦合：提升提取质量的梯度步骤也会更新求解器权重。

具体而言，该机制在两个方向上运作。在提取侧，提取器被激励产生广泛有用的技能——即能帮助求解器处理各种检索任务的技能。在利用侧，求解器在技能质量的真实分布下训练：它在同一次展开中同时遇到信息性技能和噪声技能，这反映了测试时面临的条件，从而相应地建立鲁棒性。

4 实验

4.1 实验设置

本文以 Qwen2.5-7B-Instruct [32] 作为基础模型实例化所有方法，并在两个具有明确任务级别划分的基准上进行评估：ALFWorld [23] 和 Mind2Web [7]。本文主要将所提方法与两类基线进行比较：基于提示的经验驱动自进化方法 ExpeL [38]、Memento [40] 和 ReasoningBank [16]，以及基于强化学习的方法 GRPO [19] 和 SkillRL [30]。然而，由于 SkillRL 依赖一定量的冷启动数据，本文无法在 Mind2Web 上对其进行评估。为确保鲁棒性，所有报告结果均为五次运行的平均值。下文简要描述实验设置，详细实现选择参见附录 C。

ALFWorld。ALFWorld 是一个基于文本的具身基准，用于通过多轮交互完成家务任务。为评估测试时自进化的泛化能力，本文按任务类型将原始训练集划分为已见子集和未见子集。在训练期间，经验提取和策略优化均仅在已见子集上进行。在测试时，智能体额外允许从未见训练子集中收集技能。本文报告成功率作为 ALFWorld 上的评估度量。

Mind2Web。Mind2Web 是一个面向多样化真实世界网站的具身网页导航基准。本文在官方训练划分（1009 个任务）上进行训练，并在其三个标准评估设置上报告结果：跨任务（252 个任务）、跨网站（177 个任务）和跨领域（912 个任务）。在测试时，考虑到原始训练划分规模相对较小且与评估设置存在显著分布偏移，本文允许模型在测试集上生成轨迹并提取技能。在 Mind2Web 上，本文报告两个度量：动作准确率（Act. Acc.）和成功率（SR）。动作准确率定义为所有执行动作中正确预测动作的比例。

表 1: ALFWorld 上的性能。标记为“w/ skills”的行评估每种方法与其自身提取技能相结合的效果。每列中的最佳和次佳结果分别以粗体和下划线突出显示。* 表示从 [30] 复现的结果。

Method	Seen tasks					Unseen tasks			All
	Pick	Heat	Cool	Clean	Avg.	Look	Pick2	Avg.	Overall
Base Model	75.0	13.0	60.0	57.4	51.9	18.9	36.5	27.4	45.5
Base Model (w/ skills)	74.2	28.7	56.2	45.8	50.9	16.7	36.5	26.3	44.5
<i>Prompt-based methods</i>									
ReasoningBank	75.0	21.7	47.6	45.2	47.5	11.1	35.3	22.9	41.1
ExpeL*	21.0	52.0	71.0	55.0	49.5	67.0	6.0	37.4	46.3
Memento	79.2	39.1	76.2	64.5	64.6	0.0	41.2	20.0	53.0
<i>RL-based methods</i>									
GRPO	<u>96.7</u>	100.0	100.0	90.3	96.2	53.3	12.9	33.7	79.9
GRPO (w/ skills)	95.8	98.3	<u>98.1</u>	96.1	97.0	61.1	27.1	44.6	83.3
SkillRL	93.3	72.2	80.0	95.2	86.2	81.2	55.6	68.8	81.7
Ours (w/o skills)	94.2	<u>99.1</u>	100.0	<u>96.8</u>	<u>97.4</u>	100.0	<u>61.2</u>	<u>81.1</u>	<u>93.1</u>
Ours (w/ skills)	97.5	100.0	100.0	97.4	98.6	<u>95.6</u>	81.2	88.6	96.0

表 2: 在跨任务、跨网站、跨领域及整体评估设置下, Mind2Web 上的结果。我们报告了动作准确率 (Act. Acc.) 和成功率 (SR), 最佳和次佳结果分别以粗体和下划线标出。

Method	Cross-task		Cross-website		Cross-domain		Overall	
	Act. Acc.	SR	Act. Acc.	SR	Act. Acc.	SR	Act. Acc.	SR
Base Model	12.57	0.24	7.95	0.00	7.91	0.44	8.79	0.34
Base Model (w/ skills)	14.92	0.40	15.01	0.00	12.68	0.50	13.41	0.42
ReasoningBank	11.84	0.00	17.76	0.56	12.09	0.66	12.79	0.52
Memento	15.27	0.40	15.46	0.56	13.13	0.88	13.84	0.75
GRPO	28.79	1.51	24.61	0.00	20.84	1.67	22.83	1.42
GRPO (w/ skills)	28.98	0.87	26.20	0.90	20.33	<u>1.69</u>	22.73	1.43
Ours (w/o skills)	<u>35.32</u>	<u>1.59</u>	35.15	3.39	<u>24.67</u>	1.21	<u>28.05</u>	<u>1.57</u>
Ours (w/ skills)	41.99	2.38	<u>35.14</u>	<u>1.81</u>	26.97	1.91	30.87	1.99

4.2 主要结果

表 1 和表 2 分别报告了在 ALFWorld 和 Mind2Web 上的主要结果。在这两个基准上, Evolving-RL 一致地优于所有基线, 验证了我们的两个主要主张: 它通过增强模型提取和利用经验的能力来改进测试时自进化, 并且它也是一种有效的经验增强强化学习方法, 即使在评估时不注入技能也能改进底层策略。

在 ALFWorld 上, Evolving-RL 在注入技能的情况下达到了 96.0% 的最佳整体成功率, 显著优于所有基线。在未见任务上的提升尤其大, 它将 GRPO (带技能) 从 44.6 提高到 88.6。即使不注入技能, 我们的方法仍能达到 93.1 的整体成功率。在 Mind2Web 上, 我们在更嘈杂且更具挑战性的网络环境中观察到了相同的定性趋势。Evolving-RL 在跨任务、跨网站和跨领域设置下一致地优于 GRPO。在注入技能的情况下, 我们的方法在跨任务、跨网站和跨领域设置下, 动作准确率相对于 GRPO 分别提高了 45.9%、42.8% 和 29.4%。然而, 我们也观察到, 在跨网站划分上, 提供技能并没有比无技能设置带来明显的改进。一个可能的解释是, 智能体在跨网站任务上生成的轨迹与训练期间看到的轨迹分布差异很大, 使得提取器难以从这些轨迹中提炼出有用的技能。

总体而言, 结果表明 Evolving-RL 以两种互补的方式改进了性能。首先, 我们的方法有效地增强了测试时自进化: 在推理时注入技能会带来

清晰且一致的性能提升。其次，不注入技能时的强劲性能表明，Evolving-RL 也是一种有效的训练算法，用于改进策略泛化本身。换句话说，在训练期间反复接触经验增强的上下文，使模型能够将可复用的程序性模式内化到其参数中。

4.3 消融与分析

在本节中，我们对 Evolving-RL 进行了更全面的实证分析，旨在回答以下三个问题：

问题 1：是什么驱动了 Evolving-RL 的泛化增益？

在主实验中，即使测试时没有技能注入，Evolving-RL 也表现出强大的泛化能力。这表明其性能提升并非仅归因于测试时的进化；相反，很大一部分改进已内化于策略参数中。为了更好地分离这一增益的来源，我们进行了受控消融实验，结果如表 3 所示。值得注意的是，即使仅使用求解器目标——即使用经验条件上下文训练求解器而不协同进化提取器——也显著优于 GRPO，在泛化方面实现了 73.2% 的相对提升。这一模式表明，注入的技能充当了一种结构化辅助监督：在强化学习训练期间，策略反复接触程序性指导，使其能够将这些规律直接吸收到权重中，凸显了经验增强强化学习在提升泛化能力方面的有效性。

表 3: ALFWorld 上的目标消融实验。协同进化目标对应于完整的 Evolving-RL 训练。

Objective	Eval.	Seen	Unseen	Overall
Base Model	w/o skills	51.9	27.4	45.5
Base Model	w/ skills	50.9	26.3	44.5
Extractor-only	w/o skills	62.6	28.6	53.7
Extractor-only	w/ skills	73.7	27.6	61.7
Solver-only	w/o skills	98.2	70.3	90.9
Solver-only	w/ skills	97.8	69.7	90.4
Co-evolution	w/o skills	97.4	81.1	93.1
Co-evolution	w/ skills	98.6	88.6	96.0

然而，一个关键的细微差别在于，在仅使用求解器目标的情况下，测试时的技能注入不会带来进一步的改进。这是因为策略自身提取的技能不够可靠，无法支持直接条件化——这一局限性由基础模型在注入技能评估时的性能下降所证明。因此，当训练仅优化策略利用技能的能力时，模型会反复暴露于噪声技能信号中。在这种设置下，最有效的策略是对注入的技能变得不敏感，而不是依赖它们。这解释了为什么仅使用求解器目标仍能通过参数级内化改善泛化，但在评估时无法从技能注入中进一步受益。

相反，仅提取器的目标提供了一个互补的视角。即使没有显式训练求解器，基础模型固有的问题解决能力仍然表现出可测量的提升，这表明提取器和求解器的参数优化方向之间存在根本的对齐。然而，孤立地优化提取器会导致其技能提取能力对已见轨迹过拟合。如表 3 所报告，与基础模型相比，带有技能的仅提取器变体在已见任务上获得了显著增益，但在未见任务上几乎没有提升。结合仅求解器设置的局限性，这种过拟合行为强烈强调了协同演化的必要性，它协调两个组件以实现鲁棒且可泛化的性能。

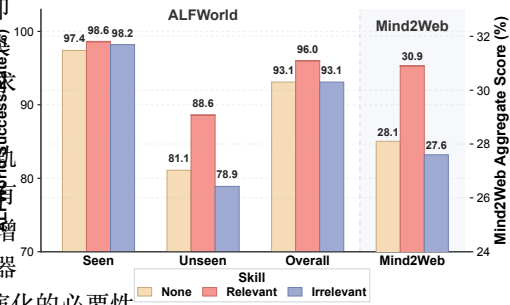


图 3: ALFWorld 和 Mind2Web 上技能相关性的消融实验。我们比较了三种设置：不注入技能（无）、注入相关技能和注入不相关技能。

问题 2：技能条件增益是否仅仅由于对注入技能上下文的过拟合？为了回答这个问题，我们对技能相关性进行了受控消融实验。具体来说，我们在三种条件下评估模型：（1）使用相关技能，（2）使用不相关技能，以及

(3) 不注入技能。不相关技能通过使用检索函数 R 识别最不相关的问题，然后从中提取技能来构建。

如图 3 所示，注入不相关技能产生的性能与无技能基线相当，而提供相关技能则带来明显的提升。这种对比表明，观察到的增益不仅仅是过拟合于上下文提示的存在或格式的工件；相反，策略真正基于所提供技能的语义内容。此外，不相关技能相对于无技能设置不会降低性能这一事实凸显了我们方法的鲁棒性：模型可以有效地忽略噪声或无信息信号，而不会遭受性能损失。

问题 3：提取的技能是否可以在训练策略之外重用？ 我们进一步探究了进化强化学习（Evolving-RL）所提升的两项能力——技能提取与技能利用——是否紧密耦合，具体方法是检验由进化强化学习训练的策略所提取的技能能否迁移至其他策略。具体而言，我们将进化强化学习产生的技能注入基础模型和群体相对策略优化（GRPO）训练模型中，并额外测量智能体在成功完成任务时采取的动作步数。由于失败轨迹通常会达到预设步数上限，为公平比较，我们将该测量限制为每种任务类型 10 个成功样本。

如表 4 所示，进化强化学习提取的技能带来的性能增益显著大于评估策略自身生成的技能。值得注意的是，当迁移至基础模型时，总体成功率从 45.5 显著提升至 60.4。这表明进化强化学习习得的技能并非狭隘地专用于训练策略，而是可广泛复用于不同策略。

这种跨策略可迁移性表明，进化强化学习提升的是技能提取本身的质量，而非仅仅在提取器与求解器之间诱导出私有通信协议。附录 B 中提供了阐明这一改进的详细案例研究。

表 4：进化强化学习技能在 ALFWorld 上的跨策略可迁移性。我们报告成功率及成功任务的平均步数。进化强化学习生成的技能相比评估器自身提取的技能带来更大的性能提升，凸显了强大的跨策略可复用性。

Solver	Skill Source	Seen	Unseen	Overall	Steps
Base Model	None	51.9	27.4	45.5	12.58
Base Model	Self-extracted	50.9	26.3	44.5	12.40
Base Model	Evolving-RL	70.3	32.6	60.4	12.20
GRPO	None	96.2	33.7	79.9	12.08
GRPO	Self-extracted	97.0	44.6	83.3	11.25
GRPO	Evolving-RL	98.0	62.9	88.8	10.04

5 结论

我们提出 **Evolving-RL**，一个用于优化经验驱动自进化能力的端到端算法框架。**Evolving-RL** 将经验的提取与利用概念化为一个统一过程。该框架以经验提取和迁移评估为核心，有效地将经验奖励与其实际效用对齐，同时无缝复用评估过程中产生的技能条件轨迹来联合训练求解器。这一设计建立了一个闭环，使经验提取的质量与利用该经验的能力在单一共享策略中相互强化。在实验中，使用 **Evolving-RL** 训练的模型在域内性能和域外泛化方面均持续优于 GRPO 基线。进一步分析表明，这些性能提升既源于推理时的显式技能条件化，也源于将可复用的程序性模式内化到策略参数中，凸显了 **Evolving-RL** 的双重价值——既作为增强自进化能力的手段，也作为一种经验增强的强化学习算法。

局限性与未来工作。 1) 我们的工作主要聚焦于设计一个框架来协同优化经验驱动的自进化能力。因此，我们采用了相对直接的技能管理和检索策略。然而，我们认为经验进化机制不仅在训练阶段至关重要，对于部署后的适应也同样关键。因此，未来工作的一个有前景的方向是将该框架与更复杂的进化机制相结合。2) 我们从理论上分析了评估机制引入的估计误差。这种误差会给训练注入噪声，甚至可能导致在某些情况下不稳定。

减少这种噪声并提高评估过程的鲁棒性仍然是未来研究的重要方向。

参考文献

- [1] Lakshya A Agrawal, Shangyin Tan, Dilara Soylu, Noah Ziemis, Rishi Khare, Krista Opsahl-Ong, Arnav Singhvi, Herumb Shandilya, Michael J Ryan, Meng Jiang, Christopher Potts, Koushik Sen, Alexandros G. Dimakis, Ion Stoica, Dan Klein, Matei Zaharia, and Omar Khattab. Gepa: Reflective prompt evolution can outperform reinforcement learning, 2026. URL <https://arxiv.org/abs/2507.19457>.
- [2] Salaheddin Alzubi, Noah Provenzano, Jaydon Bingham, Weiyuan Chen, and Tu Vu. Evoskill: Automated skill discovery for multi-agent systems, 2026. URL <https://arxiv.org/abs/2603.02766>.
- [3] Huan ang Gao, Jiayi Geng, Wenyue Hua, Mengkang Hu, Xinzhe Juan, Hongzhang Liu, Shilong Liu, Jiahao Qiu, Xuan Qi, Yiran Wu, Hongru Wang, Han Xiao, Yuhang Zhou, Shaokun Zhang, Jiayi Zhang, Jinyu Xiang, Yixiong Fang, Qiwen Zhao, Dongrui Liu, Qihan Ren, Cheng Qian, Zhenhailong Wang, Minda Hu, Huazheng Wang, Qingyun Wu, Heng Ji, and Mengdi Wang. A survey of self-evolving agents: What, when, how, and where to evolve on the path to artificial super intelligence, 2026. URL <https://arxiv.org/abs/2507.21046>.
- [4] Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. *Advances in neural information processing systems*, 33:1877–1901, 2020.
- [5] Zhicheng Cai, Xinyuan Guo, Yu Pei, Jiangtao Feng, Jinsong Su, Jiangjie Chen, Ya-Qin Zhang, Wei-Ying Ma, Mingxuan Wang, and Hao Zhou. FLEX: Continuous agent evolution via forward learning from experience. *arXiv preprint arXiv:2511.06449*, 2025. doi: 10.48550/arXiv.2511.06449.
- [6] Zouying Cao, Jiaji Deng, Li Yu, Weikang Zhou, Zhaoyang Liu, Bolin Ding, and Hai Zhao. Remember me, refine me: A dynamic procedural memory framework for experience-driven agent evolution, 2026. URL <https://arxiv.org/abs/2512.10696>.
- [7] Xiang Deng, Yu Gu, Boyuan Zheng, Shijie Chen, Samuel Stevens, Boshi Wang, Huan Sun, and Yu Su. Mind2web: Towards a generalist agent for the web. *arXiv preprint arXiv:2306.06070*, 2023. doi: 10.48550/arXiv.2306.06070.
- [8] Taicheng Guo, Xiuying Chen, Yaqi Wang, Ruidi Chang, Shichao Pei, Nitesh V. Chawla, Olaf Wiest, and Xiangliang Zhang. Large language model based multi-agents: A survey of progress and challenges. *arXiv preprint arXiv:2402.01680*, 2024. URL <https://arxiv.org/abs/2402.01680>.
- [9] Jie Huang and Kevin Chen-Chuan Chang. Towards reasoning in large language models: A survey. In *Findings of the Association for Computational Linguistics: ACL 2023*, pages 1049–1065, Toronto, Canada, 2023. Association for Computational Linguistics. doi: 10.18653/v1/2023.findings-acl.67. URL <https://aclanthology.org/2023.findings-acl.67/>.
- [10] Bowen Jin, Hansi Zeng, Zhenrui Yue, Jinsung Yoon, Sercan Arik, Dong Wang, Hamed Zamani, and Jiawei Han. Search-rl: Training llms to reason and leverage search engines with reinforcement learning, 2025. URL <https://arxiv.org/abs/2503.09516>.
- [11] Takeshi Kojima, Shixiang (Shane) Gu, Machel Reid, Yutaka Matsuo, and Yusuke Iwasawa. Large language models are zero-shot reasoners. In *Advances in Neural Information Processing Systems*, volume 35, pages 22199–22213. Curran Associates, Inc., 2022. URL https://proceedings.neurips.cc/paper_files/paper/2022/file/8bb0d291acd4acf06ef112099c16f326-Paper-Conference.pdf.
- [12] Yu Li, Rui Miao, Zhengling Qi, and Tian Lan. Arise: Agent reasoning with intrinsic skill evolution in hierarchical reinforcement learning, 2026. URL <https://arxiv.org/abs/2603.16060>.
- [13] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. *International Conference on Learning Representations (ICLR)*, 2019.
- [14] Ziyu Ma, Shidong Yang, Yuxiang Ji, Xucong Wang, Yong Wang, Yiming Hu, Tongwen Huang, and Xiangxiang Chu. Skillclaw: Let skills evolve collectively with agentic evolver, 2026. URL <https://arxiv.org/abs/2604.08377>.
- [15] Dilxat Muhtar, Jiashun Liu, Wei Gao, Weixun Wang, Shaopan Xiong, Ju Huang, Siran Yang, Wenbo Su, Jiamang Wang, Ling Pan, and Bo Zheng. Complementary reinforcement learning, 2026. URL <https://arxiv.org/abs/2603.17621>.

- [16] Siru Ouyang, Jun Yan, I-Hung Hsu, Yanfei Chen, Ke Jiang, Zifeng Wang, Rujun Han, Long T Le, Samira Daruki, Xiangru Tang, Vishy Tirumalashetty, George Lee, Mahsan Rofouei, Hangfei Lin, Jiawei Han, Chen-Yu Lee, and Tomas Pfister. Reasoningbank: Scaling agent self-evolving with reasoning memory. In *The Fourteenth International Conference on Learning Representations*, 2026. URL <https://openreview.net/forum?id=jL7fwchScm>.
- [17] Shuofei Qiao, Yixin Ou, Ningyu Zhang, Xiang Chen, Yunzhi Yao, Shumin Deng, Chuanqi Tan, Fei Huang, and Huajun Chen. Reasoning with language model prompting: A survey. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 5368–5393, Toronto, Canada, 2023. Association for Computational Linguistics. doi: 10.18653/v1/2023.acl-long.294. URL <https://aclanthology.org/2023.acl-long.294/>.
- [18] Shuai Shao, Qihan Ren, Chen Qian, Boyi Wei, Dadi Guo, Jingyi Yang, Xinhao Song, Linfeng Zhang, Weinan Zhang, Dongrui Liu, and Jing Shao. Your agent may misevolve: Emergent risks in self-evolving llm agents, 2026. URL <https://arxiv.org/abs/2509.26354>.
- [19] Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, YK Li, Y Wu, Daya Guo, et al. Deepseekmath: Pushing the limits of mathematical reasoning in open language models. *arXiv preprint arXiv:2402.03300*, 2024. URL <https://arxiv.org/abs/2402.03300>.
- [20] Shuaike Shen, Wenduo Cheng, Mingqian Ma, Alistair Turcan, Martin JinYE Zhang, and Jian Ma. Skill-foundry: Building self-evolving agent skill libraries from heterogeneous scientific resources, 2026. URL <https://arxiv.org/abs/2604.03964>.
- [21] Taiwei Shi, Sihao Chen, Bowen Jiang, Linxin Song, Longqi Yang, and Jieyu Zhao. Experiential reinforcement learning, 2026. URL <https://arxiv.org/abs/2602.13949>.
- [22] Noah Shinn, Federico Cassano, Ashwin Gopinath, Karthik Narasimhan, and Shunyu Yao. Reflexion: language agents with verbal reinforcement learning. In *Advances in Neural Information Processing Systems*, volume 36, pages 8634–8652. Curran Associates, Inc., 2023. URL https://proceedings.neurips.cc/paper_files/paper/2023/file/1b44b878bb782e6954cd888628510e90-Paper-Conference.pdf.
- [23] Mohit Shridhar, Xingdi Yuan, Marc-Alexandre Côté, Yonatan Bisk, Adam Trischler, and Matthew Hausknecht. ALFWorld: Aligning text and embodied environments for interactive learning. *arXiv preprint arXiv:2010.03768*, 2021. doi: 10.48550/arXiv.2010.03768.
- [24] Xiangru Tang, Ge Zhang, Sirui Hong, Chenglin Wu, Hao Cheng, Jiaheng Liu, Wangchunshu Zhou, Xingyao Wang, He Zhu, Chi Wang, Peng Xia, Daniel Shao, Fang Wu, Xinming Wei, Tianhao Peng, Ziyang Zhou, Tingting Du, and Tianrui Qin. Agent kb: Leveraging cross-domain experience for agentic problem solving, 2025. URL <https://arxiv.org/abs/2507.06229>.
- [25] Songjun Tu, Chengdong Xu, Qichao Zhang, Yaocheng Zhang, Xiangyuan Lan, Linjing Li, and Dongbin Zhao. Dynamic dual-granularity skill bank for agentic rl, 2026. URL <https://arxiv.org/abs/2603.28716>.
- [26] Lei Wang, Chen Ma, Xueyang Feng, Zeyu Zhang, Hao Yang, Jingsen Zhang, Zhiyuan Chen, Jikai Tang, Xu Chen, Yankai Lin, Wayne Xin Zhao, Zhewei Wei, and Jirong Wen. A survey on large language model based autonomous agents. *Frontiers of Computer Science*, 18(6):186345, 2024. doi: 10.1007/s11704-024-40231-1. URL <https://link.springer.com/article/10.1007/s11704-024-40231-1>.
- [27] Zora Zhiruo Wang, Jiayuan Mao, Daniel Fried, and Graham Neubig. Agent workflow memory, 2024. URL <https://arxiv.org/abs/2409.07429>.
- [28] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc V. Le, and Denny Zhou. Chain-of-thought prompting elicits reasoning in large language models. In *Advances in Neural Information Processing Systems*, volume 35, pages 24824–24837. Curran Associates, Inc., 2022. URL https://proceedings.neurips.cc/paper_files/paper/2022/file/9d5609613524ecf4f15af0f7b31abca4-Paper-Conference.pdf.
- [29] Rong Wu, Xiaoman Wang, Jianbiao Mei, Pinlong Cai, Daocheng Fu, Cheng Yang, Licheng Wen, Xuemeng Yang, Yufan Shen, Yuxin Wang, and Botian Shi. Evolver: Self-evolving llm agents through an experience-driven lifecycle, 2025. URL <https://arxiv.org/abs/2510.16079>.

- [30] Peng Xia, Jianwen Chen, Hanyang Wang, Jiaqi Liu, Kaide Zeng, Yu Wang, Siwei Han, Yiyang Zhou, Xujiang Zhao, Haifeng Chen, Zeyu Zheng, Cihang Xie, and Huaxiu Yao. Skillrl: Evolving agents via recursive skill-augmented reinforcement learning. *arXiv preprint arXiv:2602.08234*, 2026. doi: 10.48550/arXiv.2602.08234.
- [31] Zhishang Xiang, Chengyi Yang, Zerui Chen, Zhimin Wei, Yunbo Tang, Zongpei Teng, Zexi Peng, Zongxia Li, Chongsong Huang, Yicheng He, Chang Yang, Xinrun Wang, Xiao Huang, Qinggang Zhang, and Jinsong Su. A systematic survey of self-evolving agents: From model-centric to environment-driven co-evolution, February 2026. URL <https://doi.org/10.36227/techrxiv.177203250.05832634/v2>. Preprint.
- [32] An Yang, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chengyuan Li, Dayiheng Liu, Fei Huang, Haoran Wei, Huan Lin, Jian Yang, Jianhong Tu, Jianwei Zhang, Jianxin Yang, Jiaxi Yang, Jingren Zhou, Junyang Lin, Kai Dang, Keming Lu, Keqin Bao, Kexin Yang, Le Yu, Mei Li, Mingfeng Xue, Pei Zhang, Qin Zhu, Rui Men, Runji Lin, Tianhao Li, Tianyi Tang, Tingyu Xia, Xingzhang Ren, Xuancheng Ren, Yang Fan, Yang Su, Yichang Zhang, Yu Wan, Yuqiong Liu, Zeyu Cui, Zhenru Zhang, Zihan Qiu, et al. Qwen2.5 technical report. *arXiv preprint arXiv:2412.15115*, 2024. URL <https://arxiv.org/abs/2412.15115>.
- [33] Chen Yang, Quanquan Gu, Chenyang Zhao, and Dongruo Zhou. Cops: Empowering llm agents with provable cross-task experience sharing, 2024. URL <https://arxiv.org/abs/2410.16670>.
- [34] Cheng Yang, Xuemeng Yang, Licheng Wen, Daocheng Fu, Jianbiao Mei, Rong Wu, Pinlong Cai, Yufan Shen, Nianchen Deng, Botian Shi, Yu Qiao, and Haifeng Li. Learning on the job: An experience-driven self-evolving agent for long-horizon tasks, 2025. URL <https://arxiv.org/abs/2510.08002>.
- [35] Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, and Yuan Cao. React: Synergizing reasoning and acting in language models, 2023. URL <https://arxiv.org/abs/2210.03629>.
- [36] Xiaoying Zhang, Zichen Liu, Yipeng Zhang, Xia Hu, and Wenqi Shao. Retroagent: From solving to evolving via retrospective dual intrinsic feedback, 2026. URL <https://arxiv.org/abs/2603.08561>.
- [37] Yanzhao Zhang, Mingxin Li, Dingkun Long, Xin Zhang, Huan Lin, Baosong Yang, Pengjun Xie, An Yang, Dayiheng Liu, Junyang Lin, Fei Huang, and Jingren Zhou. Qwen3 embedding: Advancing text embedding and reranking through foundation models. *arXiv preprint arXiv:2506.05176*, 2025. URL <https://arxiv.org/abs/2506.05176>.
- [38] Andrew Zhao, Daniel Huang, Quentin Xu, Matthieu Lin, Yong-Jin Liu, and Gao Huang. Expel: LLM agents are experiential learners. *arXiv preprint arXiv:2308.10144*, 2023. doi: 10.48550/arXiv.2308.10144.
- [39] Boyuan Zheng, Michael Y. Fatemi, Xiaolong Jin, Zora Zhiruo Wang, Apurva Gandhi, Yueqi Song, Yu Gu, Jayanth Srinivasa, Gaowen Liu, Graham Neubig, and Yu Su. Skillweaver: Web agents can self-improve by discovering and honing skills, 2025. URL <https://arxiv.org/abs/2504.07079>.
- [40] Huichi Zhou, Yihang Chen, Siyuan Guo, Xue Yan, Kin Hei Lee, Zihan Wang, Ka Yiu Lee, Guchun Zhang, Kun Shao, Linyi Yang, and Jun Wang. Memento: Fine-tuning LLM agents without fine-tuning LLMs. *arXiv preprint arXiv:2508.16153*, 2025. doi: 10.48550/arXiv.2508.16153.
- [41] Huichi Zhou, Siyuan Guo, Anjie Liu, Zhongwei Yu, Ziqin Gong, Bowen Zhao, Zhixun Chen, Menglong Zhang, Yihang Chen, Jinsong Li, Runyu Yang, Qiangbin Liu, Xinlei Yu, Jianmin Zhou, Na Wang, Chunyang Sun, and Jun Wang. Memento-skills: Let agents design agents, 2026. URL <https://arxiv.org/abs/2603.18743>.

A 协同进化稳定性

A.1 技能评估的可靠性

由于 R_i^e 是从有限数量的下游任务和 rollout 中估计得到的，我们分析它能够多可靠地对两个竞争候选技能 e_a 和 e_b 进行排序。对于一个检索到的任务 x_i ，设

$$u_{ai} = \mathbb{E}[r(x_i, t) \mid t \sim \pi_\theta(\cdot \mid x_i, e_a)], \quad u_{bi} = \mathbb{E}[r(x_i, t) \mid t \sim \pi_\theta(\cdot \mid x_i, e_b)],$$

表示任务 x_i 上两种技能的真实期望奖励。它们在 K 个检索任务上的真实平均效用为

$$R_a = \frac{1}{K} \sum_{i=1}^K u_{ai}, \quad R_b = \frac{1}{K} \sum_{i=1}^K u_{bi}.$$

在我们的实现中，每个技能在每个检索任务上通过单次推演进行评估。设

$$Y_{ai} = r(x_i, t_{ai}), \quad t_{ai} \sim \pi_\theta(\cdot \mid x_i, e_a), \\ Y_{bi} = r(x_i, t_{bi}), \quad t_{bi} \sim \pi_\theta(\cdot \mid x_i, e_b),$$

为对应的实际奖励。则两种技能的经验估计为

$$\hat{R}_a = \frac{1}{K} \sum_{i=1}^K Y_{ai}, \quad \hat{R}_b = \frac{1}{K} \sum_{i=1}^K Y_{bi},$$

它们分别是 R_a 和 R_b 的无偏估计量。定义真实性能差距和经验性能差距为

$$\Delta_{ab} = R_a - R_b, \quad \hat{\Delta}_{ab} = \hat{R}_a - \hat{R}_b.$$

对于每个任务 x_i ，观测奖励 Y_{ai} 和 Y_{bi} 是有界随机变量，其均值分别为 u_{ai} 和 u_{bi} 。尽管这些变量在不同任务上不一定同分布，但在独立推演采样下它们相互独立。因此， $\hat{\Delta}_{ab}$ 是独立、有界、非同分布随机变量的平均值，适用于此类和式的中心极限定理表明，当 K 适度大时，其分布近似为高斯分布。

设

$$v_{ai} = \text{Var}(Y_{ai}), \quad v_{bi} = \text{Var}(Y_{bi}).$$

在独立推演采样下，估计差距的方差为

$$\sigma_{ab}^2 = \text{Var}(\hat{\Delta}_{ab}) = \frac{1}{K^2} \sum_{i=1}^K [v_{ai} + v_{bi}]. \quad (7)$$

因此，对于适度大的 K ， $\hat{\Delta}_{ab} \sim \mathcal{N}(\Delta_{ab}, \sigma_{ab}^2)$ 。因此，如果 $R_a > R_b$ （等价于 $\Delta_{ab} > 0$ ），有限样本评估保持正确排序的概率近似为

$$\Pr(\hat{R}_a > \hat{R}_b \mid R_a > R_b) \approx \Phi\left(\frac{\Delta_{ab}}{\sigma_{ab}}\right), \quad (8)$$

其中 $\Phi(\cdot)$ 表示标准正态分布的累积分布函数。

该表达式表明，技能评估的可靠性由真实性能差距 Δ_{ab} 与估计差距的方差 σ_{ab}^2 共同决定。两种技能所产生的奖励差异越大，且采样方差越小，评估越有可能恢复其真实排序。

最后，若奖励有界于区间 $[m, M]$ ，则

$$v_{ai} \leq \frac{(M - m)^2}{4}, \quad v_{bi} \leq \frac{(M - m)^2}{4},$$




图 4: 稳定性受控的协同进化与朴素协同进化的训练稳定性比较。朴素协同进化在 KL 损失和熵损失上呈现快速增长, 而稳定性受控的协同进化使两者保持有界, 并产生更平滑、更可靠的奖励提升。

由此得到

$$\sigma_{ab}^2 \leq \frac{(M - m)^2}{2K}. \quad (9)$$

将其代入方程 (8) 可得保守下界

$$\Pr(\hat{R}_a > \hat{R}_b \mid R_a > R_b) \gtrsim \Phi\left(\frac{\Delta_{ab}\sqrt{2K}}{M - m}\right). \quad (10)$$

伯努利奖励情形是该公式的一个特例。当 $r \in \{0, 1\}$ 时, 有 $u_{ai} = p_{ai}$ 且 $v_{ai} = p_{ai}(1 - p_{ai})$, 这恢复了用于 ALFWorld 的二元奖励推导。

A.2 训练稳定性

如方程 8 所示, 技能评估的可靠性关键取决于候选技能之间的真实性能差距 Δ_{ab} : 差距越大, 评估越能准确恢复其相对质量。然而, 强化学习训练涉及大量采样, 提取器偶尔会生成罕见表达式或异常字符。由于文本技能提取本质上缺乏确定性基准, 且从根本上是一个高熵生成过程, 产生此类不规则输出的可能性显著增大。重要的是, 这些异常并不总是导致下游求解器性能大幅下降。因此, 畸形技能与语义相似但形式良好的技能之间的性能差距 Δ_{ab} 可能仍然很小。

当这一差距很小时, 我们的经验评估机制可能无法可靠地区分这两种技能。因此, 畸形技能可能 A_i^e 偶然被赋予正的提取器侧优势。这形成了一个病态反馈循环: 恰好出现在此类技能中的低概率标记被反复强化, 导致提取器策略熵 $\mathcal{H}(\pi_\theta)$ 随时间增长。此外, 由于提取器和求解器在共享模型中对高度相似的文本上下文进行操作, 这种熵驱动的噪声很容易从提取过程渗入求解器, 进一步加剧整体不稳定性。一旦熵超过临界阈值, 训练就会变得不稳定, 并可能最终崩溃, 如图 4 所示。

为缓解这一问题, 我们引入了两种显式的稳定性控制。首先, 我们应用基于规则的过滤器, 对包含异常字符的任何候选技能赋予零奖励。其次, 如方程 3 所定义, 我们在提取器目标中包含熵正则化项 $-\eta_e \mathcal{H}(\pi_\theta)$, 以防止提取策略变得过度分散。与标准使用熵正则化鼓励探索不同, 我们的目标是抑制不受控制的熵增长并约束提取分布。如图 4 所示, 这两项措施共同显著提高了协同进化训练的稳定性。

第一项措施可视为对奖励函数的轻量修改: 除了基于迁移的评估外, 我们还加入了一个小的基于规则的奖励修正。我们还进行了实验



图 5：案例研究。经演化强化学习训练的模型所提取的技能简洁明了，并提供了正确的程序性指导；而未经训练的基座模型所提取的技能则包含步骤顺序错误，且遗漏了关键动作。

将该基于规则的过滤器替换为基于大语言模型的评估，以判断所提取技能在语言上是否自然流畅。这一替代方案产生了与基于规则修正相似的稳定化效果。

关于协同演化不稳定性的讨论。协同演化过程中出现的严重不稳定性在近期同期文献 [15] 中也有观察到。他们遇到了类似的训练崩溃，并将其归因于提取器与求解器之间固有的参数冲突，最终选择将系统解耦为两个独立的模型。然而，我们上述分析表明，真正的瓶颈不在于参数干扰，而在于由评估噪声和无约束提取熵驱动的病态反馈回路。通过明确识别这一根本原因并引入相应的稳定性控制（基于规则的筛选和负熵正则化），演化强化学习成功防止了这种崩溃。这表明经验提取与利用确实可以在单一统一策略中平滑地联合优化，无需解耦架构。

B 案例研究

为了更好地理解演化强化学习如何提升技能提取的质量，我们比较了不同模型从同一交互轨迹中产生的技能。如图 5 所示，对于与任务“将花瓶放入保险箱”相对应的轨迹，经演化强化学习训练的模型提取了一个连贯且可执行的技能，该技能正确捕捉了定位目标物体、拾取物体、找到目标容器并将物体放入其中的过程。

相比之下，基座模型提取的技能存在明显的程序性缺陷。它在移动到物体之前引入了确认容器位置的步骤，导致子目标顺序错误。此外，在定位物体之后，它未能包含拾取物体这一关键指令。当这种有缺陷的技能被注入求解器时，会显著降低求解器的成功率。

C 实现细节

在本节中，我们详细描述了实验设置，包括环境配置和训练实现。

C.1 环境配置

ALFWorld. **ALFWorld** 是一个基于文本的交互式环境，用于完成具身家务任务。在每一步，智能体接收到描述当前可见物体的文本观察，以及一组可执行的动作。我们使用完整的交互历史作为模型上下文，包括所有先前的观察和已执行的动作。因此，**ALFWorld** 中的每个优化样本对应于一个完整的轨迹。遵循 [10]，我们对轨迹内的环境观察应用损失掩码，使得它们作为条件上下文提供，但不贡献于策略优化损失。

环境奖励在轨迹级别定义。如果任务成功完成，轨迹获得奖励 10；否则，获得奖励 0。形式上，对于一个轨迹 τ ，如果任务成功完成，奖励为，

$$r(\tau) = \begin{cases} 10, \\ 0, \end{cases} \quad \text{otherwise.}$$

Mind2Web. **Mind2Web** 是一个用于有根据的网页导航的基准。在官方数据集中，每个任务与一个参考动作轨迹以及每一步对应的 HTML 状态配对。然而，原始 HTML 过长且噪声大，无法直接用作模型输入。因此，我们通过过滤 HTML 并仅保留交互元素（如按钮、输入字段和超链接）来预处理每个页面；生成的过滤文本用作智能体的观察。

由于上下文长度限制，我们采用回合级状态表示。在每个决策步骤，智能体获得当前过滤后的观察以及先前已执行动作的文本历史，但不包括过去观察的完整历史。因此，Mind2Web 中的每个优化样本对应于单个交互步骤，而不是整个轨迹。

Mind2Web 的一个关键特性是数据集仅提供真实轨迹上的下一个状态。如果智能体在任何步骤选择了错误的动作，相应的下一个状态不可用，轨迹立即终止。因此，智能体只有在当前步骤预测正确动作时才能进入下一个决策步骤。我们报告的动作准确率是在此设置下计算的，即正确预测的动作占有所有已执行动作的比例。

对于 Mind2Web 上的求解器优化，由于每一步都有正确性反馈，我们采用逐轮 GRPO 来训练求解器。具体来说，对于技能 e_i 在检索到的任务 x_j 上生成的轨迹，步骤 t 处的奖励定义为：如果步骤 t 预测的动作是正确的，

$$r_{ij,t} = \begin{cases} 1, \\ 0, \end{cases} \quad \text{otherwise.}$$

提取器奖励使用轨迹级奖励计算。具体来说，对于技能 e_i 在检索到的任务 x_j 上生成的下游轨迹，其轨迹级奖励定义为步骤级奖励之和：

$$r_{ij}^{\text{traj}} = \sum_{t=1}^{T_{ij}} r_{ij,t},$$

其中 $r_{ij,t}$ 表示步骤 t 处的奖励， T_{ij} 是轨迹长度。技能 e_i 的提取器奖励随后计算为 K 个检索到的下游任务上的平均轨迹级奖励：

$$R_i^e = \frac{1}{K} \sum_{j=1}^K r_{ij}^{\text{traj}}.$$

这样，求解器训练利用了细粒度的步骤级监督，而提取器评估仍与从完整轨迹中提炼的程序性经验的整体质量保持一致。

表 5: ALFWorld 和 Mind2Web 的主要训练超参数。

Hyperparameter	ALFWorld	Mind2Web
Base model	Qwen2.5-7B-Instruct	Qwen2.5-7B-Instruct
Policy clip ϵ_{low}	0.1	0.1
Policy clip ϵ_{high}	0.15	0.15
Number of candidate skills N	8	8
Number of retrieved tasks K	4	4
Extractor reward weight λ_e	0.2	0.1
Solver reward weight λ_s	1.0	1.0
Rollout batch size B	16	16
Rollout temperature	1.0	1.0
Rollout top- p	0.9	0.85
KL loss coefficient	0.01	0.01
Extractor entropy coefficient	-0.03	0.0
Training steps	75	150

C.2 训练设置

所有实验均从 Qwen2.5-7B-Instruct 初始化，并使用 AdamW [13] 进行训练。除非另有说明，我们使用恒定学习率 1×10^{-6} 、权重衰减 0.1, $\beta_1 = 0.9$ 和 $\beta_2 = 0.98$ 。训练采用 GRPO 风格的策略优化，使用低方差 KL 正则化和裁剪策略更新。在每次 rollout 中，我们从训练集中采样 16 个源任务，即 rollout 批大小为 16。对于相似任务检索，任务描述嵌入使用 Qwen3-Embedding-4B [37] 离线预计算并缓存以供训练期间使用。所有实验均在 8 块 NVIDIA H800 GPU 上进行。每次 Evolving-RL 训练在 ALFWorld 上大约需要 10 小时，在 Mind2Web 上大约需要 17 小时。

表 5 总结了在 ALFWorld 和 Mind2Web 上使用的主要任务特定和方法特定超参数。我们在 ALFWorld 上训练 75 步，在 Mind2Web 上训练 150 步。对于 GRPO 基线，我们使用相同的训练步数，并匹配每次更新的求解器样本数量以进行公平比较。具体来说，每次 GRPO 更新使用 $B \times N \times K$ 个样本。

在这些超参数中，最重要的方法特定参数是候选技能数量 N 、检索到的下游任务数量 K ，以及提取器/求解器奖励权重 λ_e 和 λ_s 。参数 N 决定用于提取器端 GRPO 的比较集，而 K 控制每个提取技能的可迁移性评估范围。权重 λ_e 和 λ_s 在联合优化过程中平衡技能提取与技能利用的贡献。