



Hexo Labs

SIA: 通过框架和权重更新实现自我改进的人工智能

Prannay Hebbar^{*1}, Yogendra Manawat^{*1}, Samuel Verboomen², Alesia Ivanova⁴, Selvam Palanimalai³, Kunal Bhatia¹, Vignesh Baskaran¹

^{*}Equal contribution. · ¹Hexo Labs Palo Alto · ²Hexo Labs Brussels · ³Hexo Labs Toronto · ⁴University of Oxford

关键词：自改进智能体、测试时训练、强化学习、脚手架工程、支架生成

摘要

人类是构建和改进人工智能的瓶颈。无论是模型本身还是包裹它们的智能体，都由人来编写、调优和修正。能够自行探索如何改进自身的人工智能这一长远目标仍未实现。两条基本独立的研究路线试图突破这一瓶颈。脚手架更新学派让元智能体重写特定任务智能体的脚手架（其工具、提示、重试逻辑和搜索过程），而模型权重保持不变。测试时训练学派则使用手工编写的强化学习流程，根据任务反馈更新模型自身的权重，而脚手架保持不变。这两个孤岛各自为政。本文提出自改进智能体（Self-Improving Agent, SIA），一个自改进循环，其中语言模型智能体（该

反馈智能体）同时更新任务专用智能体的框架与权重。我们在三个截然不同的领域进行评估：中国法律罪名分类、底层图形处理器核函数优化以及单细胞核糖核酸去噪。结合两种手段在所有三个基准上均优于仅进行框架迭代。SIA-W+H 在 LawBench 上比先前最先进水平高出 **25.1%**，生成的图形处理器核函数比先前最先进水平快 **12.4%**（1,017 vs 1,161 μ s），在去噪任务上比先前最先进水平高出 **20.4%**。框架更新使模型具备智能体特性，塑造其搜索与行动方式，而权重更新则构建了任何提示或框架都无法灌输的领域直觉。

1. 引言

1.1. 人类是瓶颈。

当今人工智能的进展受限于人类。模型由研究人员设计和后训练，构建于其上的智能体由工程师搭建脚手架、编写提示、调试和调优。该领域的长期目标——一个能够自行找出改进方法的人工智能（模型或智能体）——仍未实现。本文将这一目标视为具体的一步：一个系统，仅给定任务规范和验证器（两者均在 §3 中定义），无需进一步人类干预即可改进其脚手架和模型权重。

1.2. 自我改进人工智能的两个孤岛。

自动化自我改进的研究已分化为两个基本不相关的孤岛，如下所述。

孤岛 1：脚手架/框架自我改进。一个元智能体跨体重写任务特定智能体的脚手架——其系统提示、工具调度逻辑、重试策略和答案提取代码，而底层语言模型权重保持不变。近期代表包括达尔文

哥德尔机 (Zhang et al., 2025)、元框架 (Lee et al., 2026)、超智能体 (Zhang et al., 2026)，以及更广泛的自动化智能体系统设计研究 (Hu et al., 2024)。该孤岛中反复出现的经验观察是，脚手架编辑集中于软件工程卫生——解析、重试、调度——而很少提供领域特定的推理，这些推理是基础模型在任何提示下都无法产生的。

孤岛二：测试时后训练。手工编写的强化学习流程在测试时根据任务反馈更新模型自身的权重，通常保持固定的单一提示与评分模板。代表性工作包括测试时强化学习 (TTRL, Zuo 等, 2025)、测试时训练的发现系列 (Yuksekgonul 等, 2026) 以及测试时训练惊人有效性结果 (Akyürek 等, 2024)。此处的增益来自内部策略变化，但实现该变化的流程由人工设计，无法适应脚手架化智能体所揭示的任务结构。

差距。这两个孤岛彼此孤立运作。脚手架工作保持模型固定；测试时训练保持脚手架固定。

1.3. 贡献。

- 本文提出并评估了一种反馈智能体 (Feedback-Agent)，该智能体同时训练任务特定智能体的权重，并结合脚手架更新，以提升任意下游任务的性能。该系统与任务无关：给定任务规范和验证器，它既能生成进化的脚手架，也能生成一组经强化学习适配的低秩适配 (LoRA; Hu 等, 2022) 权重。
- 本文在三个截然不同的领域实证展示了该组合方法——法律 (191 类中文罪名分类; Fei 等, 2023)、系统 (H100 上的 Triton 核函数优化; Novikov 等, 2025) 和生物学 (单细胞 RNA 去噪; van Dijk 等, 2018)——并观察到相对于先前最先进方法的持续增益

：在 LawBench 上提升 25.1% (70.1% 对 45.0%)，GPU 核函数加速 12.4% (1,017 对 1,161 μ s)，去噪任务提升 20.4% (0.289 对 0.240 均方误差范数)。

- 我们分离出仅由脚手架 (harness) 带来的贡献 (跨多次迭代的脚手架更新轨迹)，并将其与完整流程 (脚手架+权重更新) 进行对比，证明权重更新带来的增益超越了脚手架单独所能达到的效果。

1.4. 路线图。

§ 2 阐述本文所回答的研究问题，并将每个问题映射到后续章节。§ 3 定义技术词汇。§ 4 将 SIA 置于自改进与测试时训练工作的背景中。§ 5 描述可配置循环方法。§ 6 给出各任务的结果与消融分析。§ 7 讨论每个调节因素所带来的变化。§ 8 和 § 9 以局限性与未来工作作结。




图 1. SIA 在三个不同任务上的表现。每个面板比较三个操作点：基线（第一代，无 SIA）、SIA-H（仅脚手架更新）和 SIA-W+H（脚手架+权重更新），分别对应 LawBench Top-1 准确率、TriMul CUDA 加速比和 scRNA-seq 去噪均方误差范数。虚线标记先前的最先进水平。SIA-W+H 在所有三个任务上严格优于 SIA-H。

2. 研究问题

本文围绕两个研究问题展开。每个问题由后续特定章节回答。

- RQ1 总体论点。我们首先探究在模型权重固定不变的情况下，仅靠脚手架迭代能在多大程度上改进特定任务的智能体。然后探究同时运行两个调节因素（在单一循环中迭代更新脚手架和模型权重）是否能突破仅靠脚手架的上限。组合方法是否优于仅迭代脚手架，并且这一结论是否在不同领域均成立？
- 研究问题二机制：各杠杆分别改变了什么？权重更新是否浮现出任何脚手架编辑都无法触及的领域知识，以及框架迭代是否产生性质不同的（外部基础设施）变化？

3. 背景与预备知识

3.1. 智能体及其组成部分。

任务特定智能体是一个接收任务实例并产生答案的程序。本文将其分解为：

- **大语言模型**。具有权重 θ 的底层语言模型。本文全程使用 openai/gpt-oss-120b 作为基础模型。
- **系统提示**。每次模型调用前添加的固定文本，用于框定任务。
- **工具调度逻辑**。解析模型工具调用输出并将其路由至处理程序（文件输入输出、代码执行、数据集查找、评分器调用）的 Python 代码。
- **答案抽取**。将模型响应（通常为结构化尾部块）转换为基准格式预测的代码。
- **评分器**。编排器调用以计算每个实例奖励的确定性验证器。

本文将智能体中固定的、非权重组件统称为脚手架（**scaffold**，亦称为 **harness**）。它是系统提示、工具分发逻辑、答案抽取以及所有支持性基础设施的并集，即智能体中所有固定代码而非模型输出的部分。

3.2. 元智能体与任务特定智能体。

元智能体是一种大语言模型调用，其输出本身就是一个智能体。SIA 使用两种元智能体：

- **元智能体（Meta-Agent）** ($\mathcal{M}$)。根据任务规范 $\mathcal{U}$ 以及基准附带的任何参考实现 $\mathcal{R}$ 生成初始脚手架 A_1 ：

$$A_1 = \mathcal{M}(\mathcal{U}, \mathcal{R}).$$

- **反馈智能体（Feedback-Agent）** ($\mathcal{F}$)。读取上一代生成的脚手架 A_g 、其执行轨迹 τ_g 和性能度量 $\mathcal{E}_g$ ，并综合出一个改进的脚手架：

$$A_{g+1} = \mathcal{F}(A_g, \tau_g, \mathcal{E}_g, \mathcal{U}).$$

任务特定智能体是在第 g 代中实际针对评估数据集执行的脚手架 A_g 。

3.3. 轨迹与反馈循环。

与仅以聚合度量作为改进条件的系统不同， $\mathcal{F}$ 接收完整轨迹 τ_g ，即运行 A_g 对 $\mathcal{D}$ （评估数据集）产生的完整结构化执行日志：每个提示、

模型响应、工具调用、工具结果以及每个任务实例提取的答案。这使得 $\mathcal{F}$ 能够诊断具体的失败模式，而不是对汇总统计做出反应。每一代 g 遵循三阶段协议：

1. 执行。

A_g 在 $\mathcal{D}$ 上于沙箱内运行：对数据集目录具有只读访问权限，对工作目录具有读写访问权限。轨迹 τ_g 被捕获。

2. 分析。

$\mathcal{F}$ 接收 A_g 的源代码、 τ_g 、度量 $\mathcal{E}_g$ ，以及可选的用于防止单实例过拟合的样本任务描述。

3. 改进。

$\mathcal{F}$ 生成两个产物：改进报告（文本分析及拟议变更）和下一代智能体 A_{g+1} 。

3.4. 符号表。

Symbol	Meaning
g	Generation index
$G_{\max}$	Maximum number of generations
A_g	Agent scaffold at generation g
$\mathcal{D}$	Evaluation dataset
$\mathcal{U}$	Task specification (benchmark description + sample instances)
$\mathcal{E}_g$	Performance metrics and error logs at generation g
τ_g	Execution trajectory at generation g
$\mathcal{F}$	Feedback agent
G	Number of rollouts per state during RL training
π_θ	Current policy (model with trainable weights θ)
π_{θ_0}	Frozen reference policy (base model)
s	Initial state (task prompt)
a	Action (model-generated response / rollout)
$V(s, a)$	Task reward for action a given state s

4. 相关工作

我们调查了各个孤岛，刻画了自改进智能体（SIA）所解决的具体差距，并在比较表中总结了整体格局。

4.1. 利用/脚手架自改进。

- 达尔文·哥德尔机 (Darwin Godel Machine) (Zhang 等, 2025)。对智能体源代码进行进化搜索：一个智能体种群提出并评估对自身的代码突变，适应度最高的变体得以存活。模型是固定的。
- **元脚手架 (Meta-Harness) (Lee 等, 2026)**。由大语言模型 (LLM) 驱动的手脚手架变异，并对脚手架图进行端到端优化。自改进智能体 (SIA) 的手脚手架更新步骤在精神上与元脚手架最为接近；区别在于我们在脚手架收敛之后进行权重更新，而不是进一步的变异。
- 超智能体 (Hyperagents) (Zhang 等, 2026)。最接近的同期工作。超智能体允许元机制本身——即元智能体编辑任务特定智能体所依据的规则——也是可编辑的，而不仅仅是任务特定智能体。智能体和智能体改进者共同进化。与自改进智能体 (SIA) 的区别在于杠杆：超智能体为脚手架编辑增加了表达力，但保持模型权重固定；自改进智能体 (SIA) 增加了第二个基于权重的杠杆。
- **人工智能科学家 (AI Scientist) (Lu 等, 2024)**。一个完整的研究流程元智能体，提出假设、运行实验、撰写论文。该智能体的输出是研究产物，而非修改后的脚手架；脚手架在多次运行中保持固定。
- **智能体系统的自动化设计 (Hu 等人, 2024)**。对构建模块（子智能体、工具、提示）组合的元搜索。模型固定。

- **自动研究者 (Karpathy, 2026)**。一种用于自主机器学习实验的静态脚手架：智能体提出并运行实验配置，但智能体架构本身在迭代过程中不发生变化。

4.2. 测试时训练与测试时强化学习。

- **测试时发现学习 (Yuksekgonul 等人, 2026)**。我们在训练更新步骤中使用的目标。在熵效用目标下利用轨迹在测试时训练权重；SIA 复用了该损失函数和基于 LoRA 的训练栈。
- **测试时训练 (TTT) 的惊人有效性 (Akyürek 等人, 2024)**。实证表明，测试时逐任务梯度自适应能显著提升少样本性能。确立了测试时训练即自适应的框架。
- **TTRL (Zuo 等人, 2025)**。在无标注测试数据上，利用多数投票衍生的伪奖励进行强化学习。该设定为单提示、单响应；无脚手架，也无逐实例验证器。SIA 的不同之处在于，奖励是确定性的任务验证器，且推理过程是脚手架化的。
- **STaR (Zelikman 等人, 2022)**；**Self-Refine (Madaan 等人, 2023)**；**Reflexion (Shinn 等人, 2023)**。早期的自我改进循环，引导推理轨迹或使用语言批评。STaR 在自生成推理上微调模型（监督式权重更新）；Self-Refine 和 Reflexion 仅在推理时运行，无权重更新。
- **自我博弈微调 (Chen 等人, 2024)**。迭代微调，模型自身输出作为训练信号。训练流程为手工编写；脚手架固定。
- **EUREKA (Ma 等人, 2023)**。大语言模型生成奖励函数（脚手架侧变更），随后用于训练强化学习策略（权重侧变更）。两个组件相互作用，但奖励函数生成器本身不被训练后的策略更新，循环是单向的而非共同进化。SIA 的不同之处在于，反馈智能体在闭环反馈中动态选择脚手架更新或权重更新，每种更新类型都由两个组件当前状态下产生的轨迹所指导。

4.3. 强化学习与智能体训练基础设施。

在所有训练运行中，我们使用 gpt-oss-120b 作为基础模型，并采用秩为 32 的低秩适配 (LoRA) 配置。权重更新通过我们的强化学习训练平台 Modal 在 H100 GPU 上执行，该平台在单一托管流水线中处理轨迹生成、奖励分配和梯度更新。SIA 构建于现有训练框架之上；反馈智能体在其控制下组合这些基础设施组件，将权重更新视为与脚手架重写并列的两种可选动作之一。相关基础设施包括用于灵活 RLHF 的 **verl/HybridFlow** (Sheng 等, 2024)、用于长时程智能体训练的 **SkyRL** (Cao 等, 2025)、用于统一后训练的 **LLaMA-Factory** (Zheng 等, 2024)，以及用于简化微调配置的 **Axolotl**。

4.4. 比较表。

表 1. 自改进/自动化智能体在两个维度上的比较。系统是否编辑测试框架？是否编辑模型权重？

Agent	Edits harness	Edits weights
SIA (ours)	Yes	Yes
Hyperagents (Zhang et al., 2026)	Yes	No
Darwin Gödel Machine (Zhang et al., 2025)	Yes	No
Meta-Harness (Lee et al., 2026)	Yes	No
AI Scientist (Lu et al., 2024)	Partial	No
Automated agentic system design (Hu et al., 2024)	Yes	No
AutoResearcher (Karpathy, 2026)	No	No
TTRL (Zuo et al., 2025)	No	Yes
Discover-TTT (Yuksekgonul et al., 2026; Akyürek et al., 2024)	No	Yes
EUREKA (Ma et al., 2023)	Partial	Yes
FunSearch (Romera-Paredes et al., 2024)	Partial	No
Voyager (Wang et al., 2023)	Yes	No
Self-Refine (Madaan et al., 2023) / Reflexion (Shinn et al., 2023)	Partial	No
STaR (Zelikman et al., 2022)	No	Yes
ReAct (Yao et al., 2022)	No	No

据我们所知，SIA 是唯一在单一自改进循环中同时更新脚手架和权重的系统。

5. 方法

5.1. 概述。

SIA 是一个由三个大语言模型组件驱动的可配置循环：元智能体、任务特定智能体和反馈智能体。元智能体初始化任务特定智能体的脚手架。每次执行后，反馈智能体观察轨迹和性能，然后在每一步动态选择两种互补动作之一：测试框架更新（脚手架演化，权重固定）或训练算法更新（通过反馈智能体选择的强化学习方法进行权重更新，脚手架固定）。动作的选择，以及选择权重更新时训练算法的选择，均以任务类型和观察到的奖励动态为条件。测试框架更新阶段和权重更新阶段是这两种动作类型的软标签，而非严格的顺序阶段。




图 2. 自改进智能体 (SIA) 的概念视图。(a) 两个互补的杠杆 (文本脚手架和低秩适配器)。每次执行后, 反馈智能体 (紫红色) 选择下一步动作: 脚手架更新 (青色) 或权重更新 (琥珀色)。两个杠杆自由交错, 不锁定为顺序阶段。(b) 一个示例的 7 步序列, 展示反馈智能体在脚手架更新和权重更新之间交替。每个 **FB:H**/**FB:W** 标记代表一次决策。度量曲线因两类步骤而上升, 脚手架更新 (青色段) 和权重更新 (琥珀色段) 各自贡献不同的增益。




图 3. 自改进智能体 (SIA) 系统架构。元智能体根据任务规范 $\mathcal{U}$ 和验证器 V 初始化脚手架。任务特定智能体在环境中执行, 产生轨迹; 反馈智能体分析轨迹并选择下一步动作, 要么合成改进的脚手架 (脚手架更新), 要么触发权重更新, 然后将结果反馈给任务特定智能体。循环重复直到步骤预算耗尽。

5.2. 系统组件。

自改进智能体（SIA）的三个组件（元智能体、任务特定智能体、反馈智能体）在 § 3.2 中定义；实现细节如下。在所有实验中，元智能体和反馈智能体使用克劳德·索内特 4.6（Claude Sonnet 4.6）；任务特定智能体使用 gpt-oss-120b（脚手架步骤）或其强化学习适配检查点（训练步骤）。

5.3. 脚手架更新。

当反馈智能体选择脚手架更新时，循环执行一步脚手架演化。每一步遵循逐步协议（执行 → 分析 → 改进）。轨迹由当前模型 π_θ （基础或强化学习适配）产生；模型权重 θ 在此步骤中保持固定，仅脚手架 A_g 发生变化。递推关系为

$$A_{g+1} = \mathcal{F}(A_g, \tau_g(\pi_\theta), \mathcal{E}_g, \mathcal{U}),$$

其中 $\tau_g(\pi_\theta)$ 表示通过执行脚手架 A_g 与模型 π_θ 收集的轨迹。

样本任务正则化。元代理在脚手架生成过程中以多样化的任务规范为条件，这缓解了初始脚手架对单一基准实例的过拟合。

6. 实验

我们在法律、系统和生物学三个对比鲜明的任务上评估了 SIA。这些基准通常用于评估其他自我改进的人工智能系统；我们特意在这些基准上运行，以便与先前工作进行直接比较。

6.1. 设置。

表 2. 各任务评估设置。

Task	Domain	Train / Test	Metric	Previous SOTA	Verifier
LawBench (191-class)	Chinese legal	5,332 / 913	top-1 accuracy	0.450	held-out test-split grader
AlphaEvolve TriMul	Low-level	n/a / fixed input shape	score = 1500/runtime (higher = faster)	1.292	H100 timing
MAGIC scRNA-seq Denoising	Single-cell	n/a / pancreas scRNA-seq	mse_norm ($\in [0, 1]$, higher = better)	0.24	MAGIC reference against ground truth

所有权重更新步骤通过 LoRA（秩 $r = 32$ ，学习率 4×10^{-5} 。）适配 gpt-oss-120b。

6.2. 基线。

由于脚手架更新步骤从围绕 gpt-oss-120b 的元代理初始化脚手架开始，并针对我们报告的同一验证器运行，因此初始分数按构造即为 gpt-oss-120b 经过元代理初始脚手架 A_1 （一个任务特定的系统提示、单工具分发循环和输出解析器，在任何反馈代理迭代开始前根据基准规范生成一次）过滤后的结果。脚手架更新轨迹随后追踪脚手架迭代在该基线上增加的内容，权重更新轨迹则追踪权重更新在仅脚手架最优结果之上增加的内容。我们将此视为主要基线结构。在所有任务中，反馈代理

从脚手架迭代开始，当框架进展停滞时切换到权重更新；我们报告 **SIA-H**（仅框架最佳）和 **SIA-W+H**（框架 + 权重更新最佳），以分离每个杠杆的贡献。

6.3. 逐任务结果。

6.3.1. LawBench: 191 类中文刑事罪名分类。

LawBench (Fei 等人, 2023) 是一个多类法律文档分类基准，源自真实的中国刑事案例描述。给定一个事实性案例摘要，模型必须从中国成文法中的 191 个不同类别中识别正确的刑事罪名。这 191 个类别编码了细粒度的法律区分，即使训练有素的从业者也觉得困难：盗窃类别（普通盗窃、公共财产盗窃、侵占）、袭击类别（简单、加重、严重身体伤害）以及欺诈变体，每个类别在法律上精确的事实要素上有所不同，直接影响量刑。随机猜测基线的正确率不到百分之一。该基准包含 5,332 个训练样本和 913 个测试样本；所有评估均在留出的测试集上进行。框架更新。早期的脚手架迭代建立了一个可用的分类流程；后续几代围绕 TF-IDF + LinearSVC 流程对其进行了重构，迭代调整字符 n -gram 范围和正则化器 C ，稳步提高准确率，直到收益在 **50.0%** 处趋于平稳，比初始运行提高了 36.5 个百分点。此时，反馈代理检测到奖励停滞并切换到权重更新。权重更新。由于奖励信号是一个干净的结果型标量（罪名正确与否），并且 rollout——每个都是针对测试集执行的生成解决方案脚本——可以廉价地并行生成，反馈代理应用了带 GAE 的 PPO：学习到的价值头 V_ϕ 在生成的解决方案脚本上产生逐 token 的优势估计，裁剪代理目标 $\min(r_t \hat{A}_t, \text{clip}(r_t, 1 \pm \epsilon) \hat{A}_t)$ 防止策略偏离有效的基线太远。这对模型编写能够正确处理细粒度罪名区分的分类代码的能力施加了稳定的梯度压力，将准确率推至 **70.1%**，比仅框架最佳结果额外提高了 20.1 个百分点（图 4）。




图 4. LawBench 结果。基线、SIA-H（仅框架）和 SIA-W+H（框架 + 权重更新）的 Top-1 准确率。虚线：先前的最先进水平。

6.3.2. AlphaEvolve TriMul: 用于蛋白质结构预测的 CUDA 核函数优化。

三角乘法更新 (TriMul) 是 AlphaFold2 的 Evoformer 模块中的核心操作，用于在蛋白质结构预测过程中传播成对残基相互作用特征。该任务源自 AlphaEvolve 基准，要求智能体为 H100 GPU 上的此操作编写自定义 CUDA 内核。TriMul 受内存带宽限制而非计算限制：线程访问非连续

内存，因为三角稀疏结构导致线程束发散和缓存未命中，使标准稠密矩阵优化技术失效。实现高吞吐量需要 H100 特定知识、张量核心调度、共享内存分块、寄存器压力管理，而标准库（cuBLAS、cuSPARSE）不适用于此操作。分数定义为 $1500 / \text{运行时间}$ ，因此分数越高表示内核越快。框架更新。智能体在迭代过程中逐步构建并优化可用的 CUDA 内核，最终达到 **12,483**，**a 1.14 $\times$** 加速的最佳运行时间。增量脚手架更改（内存布局提示、编译标志、重试逻辑）继续产生较小增益，直到轨迹趋于平稳，此时反馈智能体切换到权重更新。权重更新。内核优化具有稀疏、结果密集的奖励结构：大多数生成的内核要么编译失败，要么远非最优，使得冷启动的原始梯度信号无信息量。反馈智能体应用熵优势加权，通过自适应温度 β : $w_i \propto \exp(r_i/\beta)$ ，的 Softmax 重分配，上调高奖励轨迹的权重并折扣近零奖励噪声，即使在回滚批次中大多数内核较差时也能实现有效的梯度流。这使模型能够内化 H100 特定设计模式、共享内存分块、fp32 寄存器累加、块大小选择，这些是脚手架编辑无法编码的，将运行时间降至 **1,017**，最终加速 **14.02 $\times$** ，**a**，比仅框架峰值减少 91.9%（图 5）。




图 5. TriMul CUDA 结果。基线、SIA-H（仅框架）和 SIA-W+H（框架+权重更新）相对于基线的加速比。虚线：先前最先进水平。

6.3.3. MAGIC 单细胞 RNA 测序去噪：单细胞 RNA 插补。

单细胞核糖核酸测序（scRNA-seq）能够测量数千个单个细胞的基因表达，但由此产生的计数矩阵高度稀疏：许多真实的非零计数由于技术性丢失而被观测为零。MAGIC（基于马尔可夫亲和图的细胞插补）通过构建细胞间的 k 最近邻图、计算马尔可夫转移概率，并在图邻居之间扩散表达值以插补缺失信号来解决这一问题。该任务要求智能体在胰腺 scRNA-seq 数据（Baron 等人，2016）上调整 MAGIC 的耦合超参数：邻居数量 k 、扩散步数 t 、核带宽 α 以及预处理选择。优化并非易事： k 过小会过度拟合单个细胞噪声；过大则会导致过度平滑，破坏真实的生物信号。评估使用 mse 范数，这是一种针对真实值的归一化重建质量评分（越高越好；1.0 表示完美插补）。工具更新。智能体在多次迭代中扫描了 MAGIC 的耦合超参数空间——邻居数量 k 、扩散步数 t 、带宽 α ——并达到了一个稳定平台，mse 范数稳定在最佳值

0.241。进一步的脚手架迭代没有产生有意义的改进，促使反馈智能体转向权重更新。权重更新。通过使用 GRPO，模型完全超越了参数调整。关键的是，第一个权重更新检查点引入了一种结构变换，这是仅靠脚手架循环在所有工具迭代中从未生成的：一个两行的后处理步骤（`np.clip + np rint`），将插补计数舍入为非负整数，强制实施一个生物学不变量，该不变量虽然平凡正确，但在任何先前的脚手架版本中都不存在。这将 `mse` 范数提升至 **0.289**，比仅使用工具的最佳结果提高了 20%（图 6）。




图 6. 去噪结果。基线、SIA-H（仅工具）和 SIA-W+H（工具+权重更新）的 MSE_{norm} 。虚线：先前的最先进水平。

7. 讨论

7.1. 组合与仅工具（RQ1）

为了分离每个杠杆的贡献，我们将 SIA-H（仅工具更新）与 SIA-W+H（工具+权重更新）进行消融对比。表 3 报告了所有三个任务中的初始得分、先前最先进水平以及两个操作点。

表 3. 消融：SIA-H 与 SIA-W+H。“初始”是 gpt-oss-120b 通过元智能体初始脚手架 A_1 获得的得分。SIA-H 是仅工具的最佳结果；SIA-W+H 增加了权重更新。

Task	Initial	Prev. SOTA	SIA-H (harness only)	SIA-W+H (harness + weights)
LawBench (top-1 acc)	13.5%	45.0%	50.0%	70.1%
AlphaEvolve TriMul (reward)	0.105	1.292	0.120	1.475
Denoising (<code>mse_norm</code>)	0.048	0.240	0.241	0.289

SIA-W+H 在所有任务上均严格优于 SIA-H，证实了研究问题一。增益显著：LawBench 上提升 **+20.1** 个百分点，TriMul 上运行时间减少 **91.9%**（12,483 $\rightarrow$ 1,017 μ 秒），去噪任务上提升 **20%**。每个杠杆占据不同的变化空间——外部脚手架与内部参数——因此两者均不会使对方可获得的增益饱和（见第 7.2 – 7.4 节）。

7.2. 脚手架迭代改变了什么？（研究问题二 a）

脚手架迭代产生外部化变化：新工具、更严格的解析器、搜索过程、重试策略和提示结构，而模型权重保持不变。在三个任务中，观察到反馈智能体构建了日益专门化的脚手架：在 LawBench 上，构建了结构化答案提取层和基于模型候选答案的 SVC 重排序器；在 TriMul 上，构建了编译错误解析器，将 CUDA 诊断信息作为结构化上下文反馈，以及返回中位运行时间的计时脚手架；在 MAGIC 去噪任务上，构建了批量配置驱动器和结果解析工具，将（参数集，得分）对组织起来供模型推理。在所有三个案例中，变化均为软件工程改进：新工具、更严格的输出解析器、更智能的重试逻辑。模型检查点全程未变；所有增益均来自脚手架在模型与任务环境之间的中介方式。

7.3. 反馈智能体如何应用权重更新（研究问题二 b）

反馈智能体不运行固定的强化学习流程。虽然本文报告了三个任务，但我们一直在更广泛的任务集上运行 SIA，这些任务未包含在本文中；以下算法描述反映了在更广泛实验中观察到的常见模式。在报告的两个任务中，LawBench 上观察到使用 GAE 的 PPO；TriMul 上观察到熵优势加权；去噪任务上观察到 GRPO。关于跨任务算法选择的更全面处理将推迟到第二版。

- **使用 GAE 的 PPO。** 观察到的情况：当步级奖励密集且训练稳定性是约束瓶颈时，例如多步工具使用或长代码生成任务，单次灾难性更新会导致策略崩溃。学习到的价值头 V_ϕ 产生逐令牌优势估计 $\hat{A}_t = \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}$ ，裁剪后的替代目标 $\min(r_t \hat{A}_t, \text{clip}(r_t, 1 \pm \varepsilon) \hat{A}_t)$ 防止策略离开信任域。双演员-评论家优化代价高昂，但能提供可用的最低方差梯度信号。
- **组相对策略优化（GRPO）。** 适用情形：采样成本低廉且验证器在回合结束时触发，分类、简答或单元测试任务中单次前向传播即可对数百个补全进行评分。优势在规模为 G 的采样组内进行归一化，从而完全消除价值网络。这将内存占用减半，并支持大规模并行批次。 $\hat{A}_i = (r_i - \bar{r}) / \sigma_r$
- **熵加权优势。** 适用情形：奖励直方图严重右偏，正确解稀少但单个信号强的任务，如困难数学证明或低通过率代码综合。与将低于平均水平的采样梯度置零不同，梯度质量通过带自适应温度的 Softmax 函数 $\beta: w_i \propto \exp(r_i / \beta)$ 进行重新分配（Yuksekgonul 等，2026）。温度在线调节，使有效样本量保持在最低阈值之上，防止坍缩到单一轨迹。
- **带 KL 散度约束的强化估计（REINFORCE + KL-to-base）。** 适用情形：奖励密集且主要风险是能力退化而非梯度方差，基座模型已接近胜任且不希望参数大幅变动的细粒度领域自适应任务。蒙特卡洛回报 $\sum_{t' \geq t} \gamma^{t'-t} r_{t'}$ 直接作为优势，并附加针对冻结参考模型的惩罚项 $-\alpha \text{KL}(\pi_\theta \| \pi_{\theta_0})$ 。无评论家、无分组，最简单的训练循环。
- **前 N 名行为克隆。** 适用情形：奖励极其稀疏，所有采样中 $\mathbb{E}[r] \approx 0$ ，策略梯度信号数值为零。反馈智能体将其作为零阶段冷启动：按验证器得分最高的前 k 个采样通过交叉熵损失蒸馏到模型中，将基线通过率提升到后续近端策略优化（PPO）或组相对策略优化（GRPO）阶段可行的水平。
- **直接偏好优化（DPO）。** 适用情形：验证器能对输出排序但无法给出绝对评分，序数信号可靠而基数奖励不可靠的软性质量标准任务。给定获胜采样 y^+ and a losing rollout y^- , the objective $-\log \sigma \left(\beta \log \frac{\pi_\theta(y^+)}{\pi_{\theta_0}(y^+)} - \beta \log \frac{\pi_\theta(y^-)}{\pi_{\theta_0}(y^-)} \right)$ is minimised directly without a reward model.
每种训练方法均基于轨迹观测进行条件化，而非固定调度。

7.4. 权重更新改变了什么（研究问题 2b）

权重更新产生内化知识：编码进模型参数的领域特定模式，这是任何脚手架编辑都无法触及的。与修改模型周围基础设施的脚手架变更不同，权重更新直接修改模型对解的先验。在 LawBench 上，对 191 类罪名分类法的梯度压力锐化了模型对相邻类别的消歧能力，能够区分盗窃子类型、伤害等级和欺诈变体，且无需任何提示侧线索。在 AlphaEvolve TriMul 上，权重收敛到 H100 特定的核函数设计模式（共享内存分块、fp32 寄存器累加、块大小选择），这些模式无论脚手架质量如何，基础模型都从未产生过。在 MAGIC 去噪上，第一个权重更新检查点引入了一个脚手架从未提出的结构不变量：一个 `np.clip + np rint` 后处理步骤，将插补计数舍入为非负整数，将生物学约束直接编码进策略。在每种情况下，内化知识都是任务特定的且与验证器对齐，它源于直接的梯度压力，而非任何人工编写的指令。脚手架塑造智能体的搜索方式；权重更新改变模型所知的内容。

8. 局限性

耦合协同进化的古德哈特定律。脚手架搜索和强化学习权重更新都针对同一个固定验证器进行优化 V 。每一轮都会塑造另一方所见的分布：脚手架找到当前策略易于利用的支架；权重则在随后会改变的数据收集脚手架上进行训练。该耦合系统的联合不动点是两个对彼此更新历史视而不见的优化器之间的纳什均衡，而非在分布外脚手架或新策略上最大化 V 的点。标准的古德哈特分析假设单一优化器；双杠杆设置产生了一种耦合变体，其不动点可能在训练验证器上表现强劲，但在任一组件的任何扰动下都显得脆弱。

9. 未来工作

基于动作选择策略的元强化学习。反馈代理目前使用冻结的大语言模型先验在工具更新与权重更新之间进行选择。一种更具原则性的方法将选择策略本身视为待学习的对象：在一组任务分布上运行自我改进代理，将每个（轨迹、动作、结果）三元组视为外层马尔可夫决策过程中的一次转移，并通过在该外层马尔可夫决策过程上进行强化学习来训练选择器。随后，选择器通过跨任务的经验改进其杠杆归因能力，而非依赖在来自不同能力区间的轨迹上校准的固定启发式规则。这形成了一种真正的递归结构——一个自改进系统，其改进机制本身也在自改进，并引发了关于此类嵌套循环稳定性的非平凡问题，这些问题不同于单层强化学习或元学习中的任何问题。

更交错的训练与工具切换。当前的自我改进代理循环以离散的粗粒度轮次在工具搜索与权重更新阶段之间交替。一种更细粒度的调度方案——反馈代理可以在工具搜索过程中触发权重更新，或在梯度步骤后立即恢复工具探索——可以减少观察到停滞与采取行动之间的延迟，并可能解锁粗粒度交替所遗漏的改进轨迹。

参考文献

- [1] Ekin Akyürek, Mehul Damani, Adam Zweiger, Linlu Qiu, Han Guo, Jyothish Pari, Yoon Kim, and Jacob Andreas. The surprising effectiveness of test-time training for few-shot learning. *International Conference on Machine Learning*, 2024.

- [2] Maayan Baron, Adrian Veres, Samuel L. Wolock, Abigail L. Faust, Renaud Gaujoux, Amedeo Vetere, Jennifer Hyoje Ryu, Bridget K. Wagner, Shai S. Shen-Orr, Allon M. Klein, et al. A single-cell transcriptomic map of the human and mouse pancreas reveals inter- and intra-cell population structure. *Cell Systems*, 3(4):346–360.e4, 2016.
- [3] Shiyi Cao et al. SkyRL-v0: Train real-world long-horizon agents via reinforcement learning. Technical report, NovaSky, UC Berkeley, 2025.
- [4] Zixiang Chen, Yihe Deng, Huizhuo Yuan, Kaixuan Ji, and Quanquan Gu. Self-play fine-tuning converts weak language models to strong language models. In *International Conference on Machine Learning*, 2024.
- [5] D. V. Dijk, Roshan Sharma, J. Nainys, Kristina M. Yim, Pooja Kathail, Ambrose J. Carr, Cassandra Burdziak, Kevin R. Moon, Christine L. Chaffer, D. Pattabiraman, et al. Recovering gene interactions from single-cell data using data diffusion. *Cell*, 174(3):716–729.e27, 2018.
- [6] Zhiwei Fei, Xiaoyu Shen, D. Zhu, Fengzhe Zhou, Zhuo Han, Songyang Zhang, Kai Chen, Zongwen Shen, and Jidong Ge. LawBench: Benchmarking legal knowledge of large language models. *arXiv.org*, 2023.
- [7] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, and Weizhu Chen. LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations*, 2021.
- [8] Shengran Hu, Cong Lu, and Jeff Clune. Automated design of agentic systems. *International Conference on Learning Representations*, 2024.
- [9] Andrej Karpathy. autoresearch: AI agents running research on single-GPU nanochat training automatically, 2026.
- [10] Yoonho Lee, Roshen Nair, Qizheng Zhang, Kangwook Lee, Omar Khattab, and Chelsea Finn. Meta-harness: End-to-end optimization of model harnesses. *International Conference on Machine Learning*, 2026.
- [11] Chris Lu, Cong Lu, Robert Lange, Jakob Foerster, Jeff Clune, and David Ha. The AI scientist: Towards fully automated open-ended scientific discovery. *arXiv.org*, 2024.
- [12] Yecheng Jason Ma, William Liang, Guanzhi Wang, De-An Huang, Osbert Bastani, Dinesh Jayaraman, Yuke Zhu, Linxi Fan, and Anima Anandkumar. Eureka: Human-level reward design via coding large language models. In *International Conference on Learning Representations*, 2023.
- [13] Aman Madaan, Niket Tandon, Prakhar Gupta, Skyler Hallinan, Luyu Gao, Sarah Wiegrefe, Uri Alon, Nouha Dziri, Shrimai Prabhumoye, Yiming Yang, et al. Self-refine: Iterative refinement with self-feedback. In *Neural Information Processing Systems*, volume 36, pages 46534–46594. Neural Information Processing Systems Foundation, Inc. (NeurIPS), 2023.
- [14] Alexander Novikov, Ngô Ṽu, Marvin Eisenberger, Emilien Dupont, Po-Sen Huang, Adam Zsolt Wagner, S. Shirobokov, B. Kozlovskii, Francisco J. R. Ruiz, Abbas Mehrabian, et al. AlphaEvolve: A coding agent for scientific and algorithmic discovery. *arXiv.org*, 2025.
- [15] B. Romera-Paredes, M. Barekatin, Alexander Novikov, Matej Balog, M. P. Kumar, Emilien Dupont, Francisco J. R. Ruiz, J. Ellenberg, Pengming Wang, Omar Fawzi, et al. Mathematical discoveries from program search with large language models. *Nature*, 625:468–475, 2023.
- [16] Guangming Sheng, Chi Zhang, Zilingfeng Ye, Xibin Wu, Wang Zhang, Ru Zhang, Yanghua Peng, Haibin Lin, and Chuan Wu. HybridFlow: A flexible and efficient RLHF framework. In *European Conference on Computer Systems*, 2024.
- [17] Noah Shinn, Federico Cassano, Beck Labash, Ashwin Gopinath, Karthik Narasimhan, and Shunyu Yao. Reflexion: Language agents with verbal reinforcement learning. In *Neural Information Processing Systems*, volume 36, pages 8634–8652. Neural Information Processing Systems Foundation, Inc. (NeurIPS), 2023.

- [18] Guanzhi Wang, Yuqi Xie, Yunfan Jiang, Ajay Mandlekar, Chaowei Xiao, Yuke Zhu, Linxi Fan, and Anima Anandkumar. Voyager: An open-ended embodied agent with large language models. *Trans. Mach. Learn. Res.*, 2023.
- [19] Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, and Yuan Cao. ReAct: Synergizing reasoning and acting in language models. In *International Conference on Learning Representations*, 2023.
- [20] Mert Yuksekgonul, Daniel Kocejka, Xinhao Li, Federico Bianchi, Jed McCaleb, Xiaolong Wang, Jan Kautz, Yejin Choi, James Zou, Carlos Guestrin, et al. Learning to discover at test time. *arXiv.org*, 2026.
- [21] Eric Zelikman, Yuhuai Wu, and Noah D. Goodman. STaR: Bootstrapping reasoning with reasoning. In *Advances in Neural Information Processing Systems 35*, volume 35, pages 15476–15488. Neural Information Processing Systems Foundation, Inc. (NeurIPS), 2022.
- [22] Jenny Zhang, Shengran Hu, Cong Lu, Robert Lange, and Jeff Clune. Darwin Gödel machine: Open-ended evolution of self-improving agents. *SuperIntelligence - Robotics - Safety & Alignment*, 2(3), 2025.
- [23] Jenny Zhang, Bingchen Zhao, Wannan Yang, Jakob Foerster, Jeff Clune, Minqi Jiang, Sam Devlin, and Tatiana Shavrina. Hyperagents. *arXiv preprint arXiv:2603.19461*, 2026.
- [24] Yaowei Zheng, Richong Zhang, Junhao Zhang, Yanhan Ye, Zheyang Luo, and Yongqiang Ma. LlamaFactory: Unified efficient fine-tuning of 100+ language models. In *Annual Meeting of the Association for Computational Linguistics*, pages 400–410. Association for Computational Linguistics, 2024.
- [25] Yuxin Zuo, Kaiyan Zhang, Shang Qu, Li Sheng, Xuekai Zhu, Yuchen Zhang, Binqing Qi, Youbang Sun, Ganqu Cui, Ning Ding, et al. TTRL: Test-time reinforcement learning. *arXiv.org*, 2025.