

SkillCommit: 通过行为验证的范围扩展实现智能体技能进化

Yu He¹, Weikai Yang^{2*}

¹Nanjing University

²The Hong Kong University of Science and Technology (Guangzhou)
yu_he@smail.nju.edu.cn, weikaiyang@hkust-gz.edu.cn

摘要

大语言模型（Large Language Model）智能体无需更新参数即可持续改进，方法是将历史经验转化为可复用的程序性知识。然而，现有方法通常基于语义相似性或大语言模型判断来整合经验，这可能合并表面相关但行为上不兼容的策略，从而降低性能。为解决该问题，本文提出 SkillCommit，一个在线技能进化框架，持续将经验转化为可复用技能的分层库。每条新经验最初保留为实例特定的补丁，保留在其局部上下文中验证过的行为。随着相关技能积累，SkillCommit 将共享共同行为机制的技能抽象为更高层次的技能。具体而言，对于每条新技能，基于嵌入的检索首先识别候选相关技能。跨实例回放和基于大语言模型的机制检查确定这些技能是否跨案例迁移并共享共同的底层机制。通过两项检查的候选技能被抽象为更高层次的技能，并且仅当该技能保留所有组成技能已验证的行为时才提交。在 RuleArena、OpenExempt 和 KOR-Bench 上的实验表明，SkillCommit 在不同领域持续提升智能体性能。此外，学习到的技能可跨模型规模和系列迁移，实现跨模型经验转移。

引言

大语言模型（Large Language Model）智能体能够使用外部工具并以日益增强的自主性与环境交互（Yao 等，2023；Schick 等，2023；Yang 等，2023；Deng 等，2023；Zhou 等，2024）。然而，在专业领域的可靠部署通常需要领域知识、程序性惯例和操作约束，而基础模型在预训练期间并未获得这些。可复用技能提供了一种模块化方式，将这些程序外化并在不修改模型参数的情况下指导智能体（Wang 等，2025；Ni 等，2026；Ma 等，2026；Shinn 等，2023；Zhao 等，2024；Ouyang 等，2026）。然而，在实践中，此类知识很少以完整的说明文档形式存在，而是分散在从业者的经验、执行历史和任务反馈中。手动提取和形式化此类知识成本高昂，且可能

仍然遗漏了罕见但关键的边界情况。这一差距推动了技能演化，即智能体从累积的轨迹和反馈中自动提取、整合并精炼可复用技能（Ouyang 等，2026；Zhang 等，2026a,b；Chen 等，2026；Suzgun 等，2026）。现有方法通常利用基于大语言模型的抽象，将个体轨迹和反馈提炼为实例特定的补丁，智能体在解决相似任务时可以检索并复用这些补丁（Shinn 等，2023；Zhao 等，2024；Ouyang 等，2026）。然而，由于这些补丁范围狭窄，随着经验积累，单独保留它们会导致记忆和检索成本不断增长（Chen 等，2026；Ni 等，2026；Zhang 等，2026b）。为了构建更紧凑且通用的技能库，后续方法基于语义相似性（Xu 等，2025；Ma 等，2026）或模型判断（Xu 等，2025；Wang 等，2025；Ni 等，2026；Ma 等，2026；Chen 等，2026）将相关的实例特定补丁整合为更高层次的技能。然而，这些方法不能保证行为兼容性，因为语义相似的补丁可能编码相互冲突的策略，而语义不相似的补丁可能共享共同的底层机制。图 1 展示了语义相似性与行为兼容性之间的这种不匹配。因此，可靠的技能演化需要超越表面相似性的标准。认知科学研究表明，具体经验必须首先转化为能够指导未来行动的程序性知识（Kolb，2014）。只有当学习者识别出跨经验共享的关系结构，而不是依赖表面相似性时，这种知识才能超越其原始情境进行迁移（Gentner，1983；Gick 和 Holyoak，1983；Chi、Feltovich 和 Glaser，1981）。此外，新形成的抽象必须在不干扰先前已验证能力的情况下进行整合（McClelland、McNaughton 和 O'Reilly，1995）。这些原则共同表明，技能演化应当确立局部有效性，通过共享底层机制的证据来证明其更广泛复用的合理性，并在知识在更高抽象层次上整合时保留已验证的行为。为了满足这些要求，我们提出了 SkillCommit，一个在线技能演化框架，将技能演化组织为三个阶段。首先，当智能体未能完成任务时，基于反馈的补丁归纳根据失败的轨迹和

*Corresponding 作者。




图 1: 语义相似性可能检索到行为上不兼容的补丁, 同时忽略那些共享共同行为机制的补丁。

反馈并通过重放该任务实例进行局部验证。随着补丁的积累, 行为兼容性分组评估多个补丁是否表现出可迁移的行为并共享共同的底层机制, 从而确定候选高层技能的适当范围。最后, 源保留巩固将行为兼容的补丁抽象为高层技能, 并在其保留每个组成技能已验证行为时提交该技能。这一过程使技能库能够随时间扩展、重组和压缩, 同时保留经验证的行为。我们在规则竞技场 (RuleArena) (Zhou 等人, 2025)、开放豁免 (OpenExempt) (Servantez 等人, 2026) 和知识推理基准 (KOR-Bench) (Ma 等人, 2025) 上评估了技能提交 (SkillCommit), 在所有评估子集上均一致优于无技能设置和强基线。进一步实验表明, 所诱导的技能在不同模型规模间有效迁移, 即使跨模型家族迁移也能保持效用。我们的贡献如下:

- 我们将可靠的技能演化形式化为行为验证的范围扩展, 涵盖技能准入、兼容性分组和高层抽象, 要求对每个更广泛的行为声明提供重放证据。

- 我们提出技能提交 (SkillCommit), 一个在线框架, 用于构建紧凑的技能库, 同时保留先前验证的行为。

- 我们在规则竞技场 (RuleArena)、开放豁免 (OpenExempt) 和知识推理基准 (KOR-Bench) 上评估了技能提交 (SkillCommit), 显示相对于无技能和强基线的一致增益, 并考察了所诱导技能跨模型规模和家族的迁移性。

相关工作

大语言模型智能体与技能系统。智能体技能已成为可复用的程序性工件, 通过任务指令、操作性知识和可执行 workflow 扩展大语言模型智能体, 超越一次性提示和原子化工具使用 (Wang 等, 2023, 2025; Li 等, 2026; Ni 等, 2026; Ma 等, 2026)。先前工作研究了此类外部知识如何组织和关联, 其中 A-MEM (Xu 等, 2025) 动态链接累积的记忆笔记, CA3Mem (Zhang 等, 2026b) 通过结构化记忆图重组相关经验。智能体工作流记忆 (Wang 等, 2025) 则从智能体轨迹中归纳反复出现的工作流, 并有选择地检索以用于后续任务。同时, SkillsBench (Li 等, 2026) 评估精心设计的技能是否提升智能体性能, 而 SkillLearnBench (Zhong 等, 2026) 考察智能体能否从任务经验中持续获取可复用技能。这些研究确立了技能如何被组织、检索和评估, 但未明确何种行为证据应证明演化中的技能所声称的更广泛适用性。

技能获取与自我演化。早期基于经验的方法 (Zhang 等, 2024; Gupta 等, 2024) 将执行反馈转化为可复用的文本知识, 包括 Reflexion (Shinn 等, 2023) 中的言语反思、ExpeL (Zhao 等, 2024) 中的可迁移洞见, 以及 Reasoning-Bank (Ouyang 等, 2026) 中从成功与失败经验提炼的推理策略。近期系统超越保留个体记忆, 在 ACE (Zhang 等, 2026a) 中持续精炼演化的策略手册, 或在 Trace2Skill (Ni 等, 2026) 中分层整合轨迹局部经验。SkillGen (Ma 等, 2026) 评估合成技能的净干预效应, 而 SkillCAT (Chen 等, 2026) 在分层合并前于源任务上重放候选补丁。尽管这些方法在特定阶段引入验证, 但它们并未统一约束从文本候选到经验证补丁、从个体补丁到行为兼容组、从组抽象到活跃模式的连续范围扩展。相比之下, SkillCommit 通过教师参照的源重放、定向跨实例重放和源保留重放分别验证这些决策。

SkillCommit

可靠的技能演化不仅需要从个体经验中提取程序性知识, 还需要确定该知识在多大范围内可以泛化而不损害先前已验证的行为。SkillCommit 通过将技能库构建视为一系列经过行为验证的范围扩展来应对这一挑战。如图 2 所示, 反馈引导的补丁

归纳法 推导出实例特定的补丁，并验证冻结的执行器能够利用该补丁求解源实例。

行为兼容性分组 利用跨实例回放与机制评估来识别能够支撑共享高层技能的补丁。源保留式整合仅在源回放确认该技能在其声明范围内所有实例上均有效时，才提交所归纳的技能。

反馈引导的补丁归纳：该阶段旨在将失败任务执行中的反馈转化为程序性补丁，使冻结的执行器能够利用该补丁改进其行为。它遵循迭代的两步过程：从教师反馈生成候选补丁，并通过源重放验证补丁。

补丁生成。核心思想是将执行器的失败行为与教师为同一任务生成的参考进行对比。具体而言，当执行器在源实例 x_i 上失败并产生轨迹 τ_i^- 时，向教师模型提供 x_i 、已验证的真实答案以及 τ_i^- 。基于这些信息，教师生成一条参考轨迹 τ_i^+ ，该轨迹能够到达正确答案，并诊断失败行为与成功行为之间的差异。基于这种对比，教师生成一个候选补丁 c_i ，其中包含简洁的程序性指导，例如行为约束、决策规则或可检查的中间步骤，旨在解决 τ_i^- 中观察到的失败。注意，教师可能使用与执行器相同的底层模型，但在独立的教师提示下运行，并能够访问在执行过程中从未暴露的特权反馈。为防止解决方案泄露，包含最终答案或 x_i 的实例特定解决方案的候选补丁在验证前被丢弃。

源回放验证。每个候选补丁 c_i 通过使用相同的冻结执行器回放源实例进行验证。在回放过程中，执行器仅接收原始任务上下文 x_i 和候选补丁 c_i 。生成的答案由任务验证器评估，该验证器保留对真实答案的访问权限。如果执行器成功解决 x_i ，则该候选补丁被接纳为源验证的实例特定补丁。否则，被拒绝的补丁、新的回放轨迹以及验证器反馈将返回给技能作者，以指导下一次生成尝试。这种生成-回放循环最多重复 $K = 3$ 次尝试，一旦补丁使冻结执行器能够解决源实例即终止。实际上，88.0% 的失败实例在 3 次尝试内产生验证通过的补丁，91.8% 的成功补丁在前 2 次试验中获得。

行为兼容性分组

此阶段确定本地验证的补丁如何在其原始实例之外被重用。给定传入补丁 q_t 及其源实例 x_t ，技能提交首先检查 q_t 是否与现有的更高层技能行为兼容。如果找到兼容技能，框架尝试扩展该技能以覆盖新补丁。否则，它搜索一组兼容的残差

补丁并使用它们来归纳新的更高层技能。在两种情况下，语义相似性仅用于检索有界数量的合理候选。实际决策基于行为回放和机制评估，因为语义相似的补丁可能实现不兼容的策略，而表达不同的补丁可能遵循相同的底层过程。注意，用于行为兼容性评估和更高层技能归纳的详细提示模板在附录 A 中提供。

扩展现有技能。SkillCommit 首先检索活跃的高层技能，其描述与传入补丁 q_t 最为相似。我们使用同一编码器嵌入 q_t 的修复文本和每个活跃技能的结构化描述，按余弦相似度对活跃技能版本进行排序，并保留前 R 个候选，实验中取 $R = 4$ 。对于每个检索到的技能 p ，框架通过将两个记忆应用于其当前已验证范围之外来收集行为证据。具体而言，现有技能 p 在传入源实例 x_t 上重放，而 q_t 在 p 覆盖的一组任务实例 $\mathcal{W}(p)$ 上重放。令 $\rho(m, x) \in [0, 1]$ 表示冻结执行器在仅由记忆 m 引导时是否解决实例 x 。我们计算 p 与 q_t 之间的行为兼容性如下：

$$C(p, q_t) = \frac{\rho(p, x_t) + \sum_{x_j \in \mathcal{W}(p)} \rho(q_t, x_j)}{1 + |\mathcal{W}(p)|}. \quad (1)$$

当 $C(p, q_t) \geq \gamma$ 时，该对通过行为兼容性筛选，其中 $\gamma \in [0, 1]$ 为预定义阈值。这种交叉重放提供了分级证据，表明两个记忆在相关行为上下文中运作。由于部分行为迁移仍可能源于不同策略，模式作者随后评估 p 和 q_t 是否可由共享的程序机制解释。若兼容性得分和机制评估均支持合并，作者提出 p 的扩展版本，其范围包含传入源。该提案保持为候选，直到下一阶段的完整源重放确认扩展技能在其声明范围内保持已验证的行为。

形成新技能。若现有技能均未通过前述检查，技能提交 (SkillCommit) 则从残差补丁中构建新技能，即那些尚未被纳入任何更高层级技能的、经过源验证的补丁。类似地，技能提交检索一组语义相关的残差补丁 $\mathcal{C}_t$ ，并通过跨实例回放评估其行为兼容性。基于这些回放结果，技能提交搜索一个锚点补丁，其过程能够迁移到候选组中所有其他补丁的源实例。一个合格的组必须包含传入补丁 q_t 且至少包含 m 个成员。默认情况下，要求锚点能够迁移到每个成员，而反向迁移可作为更严格的可选标准。在合格组中，技能提交选择行为覆盖范围最广的一个，仅在并列时使用语义相似性和确定性排序。若未找到合格组， q_t 保持残差状态，不构建新技能。




图 2: 技能提交概览。反馈引导的补丁归纳推导并源验证实例补丁；行为兼容性分组利用跨实例回放扩展现有技能或构建新技能；源保持整合仅在完整范围源回放后提交候选技能。

源保持整合 在识别出行为一致的补丁组或兼容的现有技能后，技能提交在提议范围内归纳候选技能。由于抽象可能省略对个别源实例至关重要的约束，整合由完整源回放控制。候选技能仅当在其提议范围内保留所有先前验证的行为时才被提交；否则，其范围可能缩小到回放支持的子集，或候选被拒绝。

候选技能归纳。 候选技能可通过两种方式产生。若前一阶段识别出一组兼容的残差补丁，模式作者尝试从该组中归纳出一个新的更高层技能。若传入补丁与现有技能兼容，模式作者则生成该技能的扩展版本。在两种情况下，归纳出的技能均指定适用条件、可执行的过程性指导以及排除条件，分别由何时、修复和 avoid_何时表示。为鼓励机制层面的抽象而非实例记忆，模式作者不会获得源问题、答案、教师轨迹或来源信息。对于形成新技能，其仅接收所提议组中的匿名补丁文本。对于扩展，其额外接收当前技能描述。

全范围源重放。 令 S 表示候选技能的提议源集合。为验证抽象保留了先前已验证的行为，技能提交使用冻结的執行器在 S 中的每个源实例上重放该候选技能。若在所有源实例上重放成功，则该候选技能被视为完全支持。否则，模式作者利用其先前版本以及重放轨迹和验证器反馈，逐步细化当前候选技能，同时真实答案和实例身份保持隐藏。每次细化产生一个新的候选技能

版本，该版本在进一步细化之前在同一源集合上重放。此过程最多进行 L 次尝试，所有候选版本及其重放结果均保留以供审计。

源保持提交与拆分。 为确保每个已提交技能在其声明范围内保留每个源实例的已验证行为，技能提交使用源重放作为合并的唯一标准。根据重放结果，每个候选技能遵循三种转换之一。

提交。 若候选技能在其提议范围内的每个源实例上成功重放，则将其提交为更高层技能。当候选技能扩展现有技能时，新版本替换活动版本，同时保留先前版本以供追溯。当候选技能从一组残差补丁中归纳时，它成为一个新的活动技能。

拆分。 如果重放在部分提议来源上成功，技能提交 (SkillCommit) 会选择具有最强重放支持的候选版本。如果该版本支持的来源集合包含至少 m 个实例，将通过将其范围限制在受支持的来源上，并在此缩减后的范围内再次重放来进行拆分。成功重新验证的拆分将作为独立的高层技能提交。通常，根据数据集的不同，我们将 m 设为 2 或 3，详见附录 B。

拒绝。 若无候选版本，则候选被丢弃。现有技能层级保持不变，相应补丁继续作为实例特定技能保留。若无候选版本产生至少 m 个源实例的重放支持子集，或缩小后的候选未能通过重新验证，则候选被拒绝。现有技能层级保持不变，而相应补丁仍作为实例特定技能可用。这些转换共同确保更高层级的技能

仅在重放支持其更广泛适用性时才进行扩展，而不受支持的抽象则被保守地缩小或拒绝。

实验

我们评估技能提交（SkillCommit）是否能在异构推理领域中改进冻结执行器，是否产生一致的任务级正迁移，并产生在不同模型规模和系列中保持有效的技能。我们进一步考察其三个阶段对性能的贡献。

实验设置 数据集与度量。我们将技能承诺（SkillCommit）作为在线技能演化框架，在三个互补的推理基准上对其进行评估。为考察复杂规则推理中的技能演化，我们使用规则竞技场（RuleArena）（周等人，2025）中的航空与篮球子集。具体而言，我们将 200 个航空案例划分为 100 个归纳案例与 100 个留出测试案例，并将 215 个篮球案例划分为 170 个归纳案例与 45 个测试案例。为评估法律领域的泛化能力，我们从开放豁免（OpenExempt）（塞尔万特斯等人，2026）的高级能力套件中选取豁免分类（EC）与豁免估值（EV），每个任务包含 210 个归纳案例与 105 个留出测试案例。最后，我们纳入知识正交基准（KOR-Bench）（马等人，2025）中的逻辑与密码任务，以评估知识正交抽象推理的泛化能力，每个任务使用 175 个归纳案例与 75 个留出测试案例。评估度量反映各基准的输出结构。规则竞技场与知识正交基准要求可验证的最终答案，因此我们报告严格准确率，仅当解析后的答案通过相应基准验证器时才计为正确。开放豁免则要求对豁免引用或估值主张进行结构化预测；因此我们遵循官方评估器，报告宏观 F1 值，该值同时反映适用项的覆盖情况与对无依据预测的避免。

基线。我们将技能承诺与无技能（No Skill）及四种代表性经验学习方法进行比较。经验提炼（ExpeL）（赵等人，2024）从累积经验中提取可复用洞见，而推理银行（ReasoningBank）（欧阳等人，2026）存储并检索源自先前执行的推理记忆。自适应课程演化（ACE）（张等人，2026a）通过反思与筛选迭代演化外部策略手册。轨迹到技能（Trace2Skill）（倪等人，2026）将轨迹级经验分层提炼为可复用技能文档。我们将每种方法适配至相同的基准接口与归纳数据，同时保留其原始技能构建机制。在每个模型配置中，所有方法使用相同的冻结执行器、基础任务提示、输出解析器、验证器及单实例生成极限。

模型配置与实现细节。我们的模型配置将匹配模型的有效性与跨模型规模和系列的迁移区分开来。我们首先考虑两种匹配模型设置，分别使用 DeepSeek-V4-Flash 和 Qwen3.6-35B-A3B 进行技能构建和任务执行。这些设置确立了当技能作者和使用者相同时 SkillCommit 的有效性，




图 3: 在匹配的 DeepSeek-V4-Flash RuleArena 运行中相对于无技能的实例级效果。帮助计数表示无技能未解决但相应方法解决的案例，而损害计数表示无技能解决但该方法破坏的案例。

在不同容量水平的模型之间。然后我们使用较小的 Qwen3.5-9B 模型作为技能使用者，反映一种实用的部署场景，即技能由能力更强的模型构建，但由成本更低的模型反复执行。由 Qwen3.6-35B-A3B 编写的技能评估了同系列、跨规模的迁移，而由 GPT-5.4 编写的技能评估了跨模型系列和规模的迁移。所有模型参数在技能构建和评估过程中保持冻结，生成设置和方法特定的预算在附录 B 中提供。

主要结果

SkillCommit 在每个评估设置中都一致地优于无技能执行和其他基线方法。表 1 总结了在三个互补推理基准上的实验结果。在表 1 的所有 18 个任务配置对中，SkillCommit 均优于无技能，并在每个任务上取得最佳结果，将所报告任务指标的未加权平均值从 50.80% 提高到 78.15%。当 DeepSeek-V4-Flash 和 Qwen3.6-35B-A3B 同时作为技能作者和技能使用者时，六任务平均值分别提高了 19.33 和 30.02 个百分点。相比之下，四种竞争技能方法的 72 个任务级结果中有 31 个低于无技能，另有 6 个仅与之持平。SkillCommit 在三种配置中的平均得分分别比最强的竞争方法高出 14.48、28.08 和 28.01 个百分点。经验衍生的记忆在没有行为验证的情况下并不可靠，可能引入

比它们纠正的更多的错误。图 3 中的实例级分解表明，适度的甚至负面的总体变化并不意味着这些方法未能从经验中学习；相反，它们的收益经常被新引入的错误所抵消。ExpeL 修复了 24 个 Airline 和 14 个 NBA 失败案例——与 SkillCommit 在 Airline 上的 24 个修复相匹配——但也分别推翻了 8 个和 3 个基线正确的预测，将其净收益降至 16 和

Skill Author	Skill User	Method	RuleArena		OpenExempt		KOR-Bench		Avg.↑
			Air.↑	NBA↑	EV↑	EC↑	Logic↑	Cipher↑	
DeepSeek V4-Flash	DeepSeek V4-Flash	No Skill	72.00	28.89	76.86	86.33	72.00	73.33	68.24
		ExpeL	<u>88.00</u>	<u>53.33</u>	50.17	88.36	<u>80.00</u>	<u>78.67</u>	73.09
		ReasoningBank	66.00	31.11	65.54	74.25	68.00	72.00	62.82
		ACE	51.00	6.67	<u>87.32</u>	<u>95.65</u>	72.00	70.67	63.89
		Trace2Skill	50.00	28.89	84.30	75.50	70.67	70.67	63.34
		SKILLCOMMIT (Ours)	96.00	71.11	94.28	96.01	82.67	85.33	87.57
Qwen3.6 35B-A3B	Qwen3.6 35B-A3B	No Skill	51.00	26.67	29.02	47.46	53.33	76.00	47.25
		ExpeL	54.00	<u>31.11</u>	7.76	21.53	65.33	78.67	43.07
		ReasoningBank	44.00	26.67	22.37	27.64	58.67	74.67	42.34
		ACE	32.00	11.11	<u>38.42</u>	45.71	<u>73.33</u>	77.33	46.32
		Trace2Skill	<u>55.00</u>	<u>31.11</u>	35.68	29.34	61.33	<u>82.67</u>	49.19
		SKILLCOMMIT (Ours)	85.00	66.67	72.46	79.46	74.67	85.33	77.27
Qwen3.6 35B-A3B	Qwen3.5 9B	No Skill	<u>55.00</u>	15.56	9.97	15.61	60.00	65.33	36.91
		ExpeL	54.00	26.67	4.18	10.73	<u>62.67</u>	70.67	38.15
		ReasoningBank	53.00	22.22	16.42	22.68	52.00	65.33	38.61
		ACE	14.00	15.56	<u>26.31</u>	<u>34.57</u>	41.33	<u>74.67</u>	34.41
		Trace2Skill	35.00	<u>31.11</u>	24.76	25.43	60.00	73.33	41.61
		SKILLCOMMIT (Ours)	81.00	60.00	54.28	62.41	76.00	84.00	69.62

表 1：三种技能作者/技能用户配置下的主要结果。RuleArena 和 KOR-Bench 报告严格准确率，而 OpenExempt 报告宏观 F1。平均值为六个任务分数的未加权平均值。每个配置中的最佳结果以粗体显示，次佳结果以下划线显示。箭头下标表示与匹配基线相比的变化。

11 个案例。这种模式与提取有用洞见但缺乏执行基础的准入和回放验证的范围控制相一致，允许有效的经验在其适用上下文之外被重用。ReasoningBank 在 Airline 上帮助/损害了 3/9 个案例，在 NBA 上帮助/损害了 2/1 个案例，表明在没有行为兼容性证据的情况下检索相关推理记忆，尽管在 NBA 上有轻微增益，也可能产生负迁移。ACE 在 Airline 和 NBA 上分别帮助/损害了 3/24 和 3/13 个案例，表明在没有回归测试其更新的情况下全局演化剧本，可能覆盖的正确行为远多于其纠正的行为。Trace2Skill 在 Airline 上帮助/损害了 2/24 个案例，在 NBA 上帮助/损害了 7/7 个案例，与轨迹级经验被泛化到其行为支持范围之外相一致。相比之下，SkillCommit 修复了 24 个 Airline 和 21 个 NBA 失败案例，而仅在零个和两个案例上出现回归，分别产生 24 和 19 的净收益。因此，核心区区别不仅在于方法是否能提取有用的记忆，还在于该记忆范围的每次扩展是否得到回放证据的支持。SkillCommit 通过源回放补丁准入、定向跨实例兼容性检查以及提交前的全范围源回放提供了这些保障；下面的组件消融研究检验了它们各自的贡献。

技能可迁移性分析

族内跨尺度迁移。为检验由较大模型编写的技能是否仍可被同系列较小执行器使用，我们部署了由 Qwen3.6-35B-A3B 编写的库，并搭配一个冻结的 Qwen3.5-9B 技能使用者。在图 4 所示的四项任务中，迁移的技能将 Qwen3.5-9B 的平均得分从无技能时的 48.97 提升至 75.25




图 4：匹配模型与跨模型技能复用。图例箭头表示技能作者 → 冻结技能使用者。无技能柱状条显示 Qwen-9B 使用者的匹配基线；Qwen-35B → Qwen-35B 为匹配模型参考。柱状条报告严格准确率。

并在每项任务上提升性能。迁移效果显著但并非无损：匹配的 Qwen3.6-35B-A3B 执行在 Airline（85.00 对 81.00）、NBA（66.67 对 60.00）和 Cipher（85.33 对 84.00）上仍保持更高，而较小用户模型在 Logic 上略优（76.00 对 74.67）。这一模式表明，所学技能在不同模型规模间保留了可复用的程序核心，而其部分有效性仍取决于执行器特定的解释和提示约定。同时，相对于无技能的一致增益以及 Logic 上的反转，反驳了

Condition	Success	Δ (pp)
SKILLCOMMIT (Full)	71.11	0.00
No Skill	28.89	↓ 42.22
w/o Feedback-Guided Patch Induction	53.33	↓ 17.78
w/o Behavioral Compatibility Grouping	66.67	↓ 4.44
w/o Source-Preserving Consolidation	66.67	↓ 4.44
Feedback-Guided Patch Induction <i>only</i>	64.44	↓ 6.67
Behavioral Compatibility Grouping <i>only</i>	60.00	↓ 11.11
Source-Preserving Consolidation <i>only</i>	57.78	↓ 13.33

表 2：规则竞技场（RuleArena）美国职业篮球联赛（NBA）上的消融结果。 Δ denotes 为相对于无消融的绝对百分点下降。

库仅编码针对作者模型定制的指令。这些结果与反馈引导的归纳和源保持的巩固一致，将局部经验转化为显式的、由回放支持的程序。

跨家族 以及跨尺度迁移。为检验当技能作者与使用者在模型家族和规模上均不同时技能是否仍可复用，我们进一步以 GPT-5.4 作为技能作者、以 Qwen3.5-9B 作为技能使用者。在图 4 的四个任务中，GPT-5.4 编写的技能将 Qwen3.5-9B 的平均得分从无技能时的 48.97 提升至 69.75，并在每个任务上均改善了性能，证明了跨模型家族与规模边界的迁移能力。该迁移在 Airline（67.00 对 81.00）、Logic（70.67 对 76.00）和 Cipher（81.33 对 84.00）上仍弱于同家族跨尺度复用，导致平均差距为 5.50 分。这种任务相关的退化与不同模型家族在表达和执行程序性指导时残留的不匹配一致，即使底层机制可复用。尽管如此，两个作者模型在 NBA 上达到了相同的准确率（60.00），且 GPT-5.4 编写的技能在 Logic 和 Cipher 上与匹配的 Qwen3.6-35B-A3B 性能差距保持在 4 分以内。NBA 上的持平并不能确立技能质量的等价性，因为两个技能库最终由同一个较小的使用者执行，可能遇到共同的使用者侧上限；然而，它排除了统一的跨家族惩罚，并表明足够明确的决策程序能够在作者家族变化后存续。总体而言，结果表明行为归纳与整合为异构模型之间提供了可移植的接口，同时并未完全消除家族和执行器特定的惯例。

组件消融 为区分每个阶段在完整流水线中是否必要，以及其单独是否充分，

表 2 将每个 w/o 条件与相应的组件隔离条件配对。w/o 变体衡量在给定其余流水线时某一阶段的边际贡献，而仅执行变体则使用其实际接口所需的上游输入来执行指定阶段。

源重放补丁归纳提供了主要的性能增益。移除反馈引导的补丁内

消融实验显示，去除该模块后性能从 71.11% 降至 53.33%，在三个留一阶段条件中降幅最大。相比之下，直接部署源验证的实例补丁可达到 64.44%。由于前者仍能获得可解析的首轮教师补丁，这一对比表明增益源于对提议补丁的验证与精炼，而非仅仅生成额外的记忆文本。因此，仅补丁归纳的高分表明，大部分即时准确率提升来自将合理提议转化为冻结执行器已证明能够执行的指导。然而，该分数并未衡量不断演进的技能库所提供的更广泛范围控制。

兼容性分组通过筛选提升迁移效果

其中补丁可被复用。移除行为兼容性分组后，性能从 71.11% 降至 66.67%，表明仅靠语义检索无法完全恢复跨实例行为证据所带来的全部收益。兼容性分组在单独使用时，若基于未经源验证或后续合并的初步补丁，其性能达到 60.00%。这些条件之间的差距表明，兼容性筛选在提供可靠局部修复时是有用的，但无法弥补缺乏支撑的上游补丁，也无法独立保持由此产生的抽象。因此，其作用并非生成原始修正，而是确定该修正可以安全复用的行为上下文。

巩固作用更像是一道保存门，而非一个独立的修复机制。移除源保留整合同样将性能降低至 66.67%，表明全范围重放有助于防止已编写的抽象丢弃已验证的行为。与补丁归纳相比，较小的降幅反映了一个不同的作用：兼容性证据可以支持一个组，但不能保证某个抽象保留所有源。全范围重放测试该抽象，并缩小或拒绝支持不完整的候选。仅整合达到 57.78%，这是组件隔离中最弱的结果，因为将重放门应用于未验证补丁的语义组不能替代源验证的修复或用于组形成的行为证据。

结论

本文提出了技能提交（SkillCommit），一种在线技能演化框架，可将智能体积累的经验转化为紧凑的层次化技能库，且不牺牲先前已验证的行为。技能提交并非仅依赖语义相似性或模型判断，而是以行为证据为基础进行整合，仅当更广泛的行为声明通过回放验证后才予以采纳。在规则竞技场（RuleArena）、开放豁免（OpenExempt）和知识导向推理基准（KOR-Bench）上的实验表明，与无技能设置和强技能演化基线相比，该方法均取得了一致的改进。所得技能还能跨模型规模和系列迁移，这表明程序性知识可由能力更强的模型生成，并被更小、更经济的智能体复用。本文认为，这是迈向智能体从经验中持续改进、同时保持累积知识紧凑、可复用且行为可靠的一个实用步骤。

参考文献

- Chen, K.; Zhong, Q.; Liu, J.; and Du, B. 2026. Skill-CAT: Contrastive Assessment and Topology-Aware Skill Self-Evolution for LLM Agents. *arXiv:2606.13317*.
- Chi, M. T. H.; Feltoovich, P. J.; and Glaser, R. 1981. Categorization and representation of physics problems by experts and novices. *Cognitive Science*, 5(2): 121–152.
- Deng, X.; Gu, Y.; Zheng, B.; Chen, S.; Stevens, S.; Wang, B.; Sun, H.; and Su, Y. 2023. Mind2Web: Towards a Generalist Agent for the Web. In *Advances in Neural Information Processing Systems*, volume 36, 28091–28114. Curran Associates, Inc.
- Gentner, D. 1983. Structure-mapping: A theoretical framework for analogy. *Cognitive Science*, 7(2): 155–170.
- Gick, M. L.; and Holyoak, K. J. 1983. Schema induction and analogical transfer. *Cognitive Psychology*, 15(1): 1–38.
- Gupta, P.; Kirtania, S.; Singha, A.; Gulwani, S.; Radhakrishna, A.; Soares, G.; and Shi, S. 2024. MetaReflection: Learning Instructions for Language Agents using Past Reflections. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, 8369–8385. Association for Computational Linguistics.
- Kolb, D. A. 2014. *Experiential learning: Experience as the source of learning and development*. FT press.
- Li, X.; Liu, Y.; Chen, W.; You, B.; Di, Z.; He, Y.; Zheng, S.; et al. 2026. SkillsBench: Benchmarking How Well Agent Skills Work Across Diverse Tasks. *arXiv:2602.12670*.
- Ma, K.; Du, X.; Wang, Y.; Zhang, H.; Wen, Z.; Qu, X.; Yang, J.; Liu, J.; Liu, M.; Yue, X.; Huang, W.; and Zhang, G. 2025. KOR-Bench: Benchmarking Language Models on Knowledge-Orthogonal Reasoning Tasks. In *The Thirteenth International Conference on Learning Representations*.
- Ma, Y.; Huang, Y.; Bao, H.; Zhuang, H.; Shukla, S.; Galley, M.; Zhang, X.; and Feuerriegel, S. 2026. SkillGen: Verified Inference-Time Agent Skill Synthesis. *arXiv:2605.10999*.
- McClelland, J. L.; McNaughton, B. L.; and O'Reilly, R. C. 1995. Why there are complementary learning systems in the hippocampus and neocortex: Insights from the successes and failures of connectionist models of learning and memory. *Psychological Review*, 102(3): 419–457.
- Ni, J.; Liu, Y.; Liu, X.; Sun, Y.; Zhou, M.; Cheng, P.; Wang, D.; Zhao, E.; Jiang, X.; and Jiang, G. 2026. Trace2Skill: Distill Trajectory-Local Lessons into Transferable Agent Skills. *arXiv:2603.25158*.
- Ouyang, S.; Yan, J.; Hsu, I.-H.; Chen, Y.; Jiang, K.; Wang, Z.; Han, R.; Le, L. T.; Daruki, S.; Tang, X.; Tirumalashetty, V.; Lee, G.; Rofouei, M.; Lin, H.; Han, J.; Lee, C.-Y.; and Pfister, T. 2026. ReasoningBank: Scaling Agent Self-Evolving with Reasoning Memory. In *The Fourteenth International Conference on Learning Representations*.
- Schick, T.; Dwivedi-Yu, J.; Dessi, R.; Raileanu, R.; Lomeli, M.; Hambro, E.; Zettlemoyer, L.; Cancedda, N.; and Scialom, T. 2023. Toolformer: Language Models Can Teach Themselves to Use Tools. In *Advances in Neural Information Processing Systems*, volume 36, 68539–68551. Curran Associates, Inc.
- Servantez, S.; Lawskey, S. B.; Jain, R.; Linna, D. W.; and Hammond, K. 2026. OpenExempt: A Diagnostic Benchmark for Legal Reasoning and a Framework for Creating Custom Benchmarks on Demand. *arXiv:2601.13183*.
- Shinn, N.; Cassano, F.; Gopinath, A.; Narasimhan, K.; and Yao, S. 2023. Reflexion: Language Agents with Verbal Reinforcement Learning. In *Advances in Neural Information Processing Systems*, volume 36.
- Suzgun, M.; Yuksekgonul, M.; Bianchi, F.; Jurafsky, D.; and Zou, J. 2026. Dynamic Cheatsheet: Test-Time Learning with Adaptive Memory. In *Proceedings of the 19th Conference of the European Chapter of the Association for Computational Linguistics (Volume 1: Long Papers)*, 7080–7106. Association for Computational Linguistics.
- Wang, G.; Xie, Y.; Jiang, Y.; Mandlekar, A.; Xiao, C.; Zhu, Y.; Fan, L.; and Anandkumar, A. 2023. Voyager: An Open-Ended Embodied Agent with Large Language Models. *arXiv preprint arXiv:2305.16291*.
- Wang, Z. Z.; Mao, J.; Fried, D.; and Neubig, G. 2025. Agent Workflow Memory. In *Proceedings of the 42nd International Conference on Machine Learning*, volume 267 of *Proceedings of Machine Learning Research*, 63897–63911. PMLR.
- Xu, W.; Liang, Z.; Mei, K.; Gao, H.; Tan, J.; and Zhang, Y. 2025. A-MEM: Agentic Memory for LLM Agents. In *Advances in Neural Information Processing Systems*, volume 38.
- Yang, R.; Song, L.; Li, Y.; Zhao, S.; Ge, Y.; Li, X.; and Shan, Y. 2023. GPT4Tools: Teaching Large Language Model to Use Tools via Self-Instruction. In *Advances in Neural Information Processing Systems*, volume 36, 71995–72007. Curran Associates, Inc.
- Yao, S.; Zhao, J.; Yu, D.; Du, N.; Shafran, I.; Narasimhan, K. R.; and Cao, Y. 2023. ReAct: Synergizing Reasoning and Acting in Language Models. In *The Eleventh International Conference on Learning Representations*.
- Zhang, Q.; Hu, C.; Upasani, S.; Ma, B.; Hong, F.; Kamanuru, V.; Rainton, J.; Wu, C.; Ji, M.; Li, H.; Thakker, U.; Zou, J.; and Olukotun, K. 2026a. Agentic Context Engineering: Evolving Contexts for Self-Improving Language Models. In *The Fourteenth International Conference on Learning Representations*.
- Zhang, W.; Tang, K.; Wu, H.; Wang, M.; Shen, Y.; Hou, G.; Tan, Z.; Li, P.; Zhuang, Y.; and Lu, W. 2024. Agent-Pro: Learning to Evolve via Policy-Level Reflection and Optimization. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 5348–5375. Association for Computational Linguistics.
- Zhang, Z.; Bu, W.; Pan, K.; Miao, B.; Zhang, W.; Wang, G.; Ji, W.; Tang, R.; Li, J.; and Tang, S. 2026b. Evolving Generalist Virtual Agents with Generative and Associative Memory. *Proceedings of the AAAI Conference on Artificial Intelligence*, 40(15): 13006–13014.
- Zhao, A.; Huang, D.; Xu, Q.; Lin, M.; Liu, Y.-J.; and Huang, G. 2024. ExpeL: LLM Agents Are Experiential Learners. *Proceedings of the AAAI Conference on Artificial Intelligence*, 38(17): 19632–19642.

Zhong, S.; Lu, Y.; Ning, J.; Wan, Y.; Feng, L.; Ao, Y.; Ribeiro, L. F. R.; Dreyer, M.; Ammirati, S.; and Xiong, C. 2026. SkillLearnBench: Benchmarking Continual Learning Methods for Agent Skill Generation on Real-World Tasks. arXiv:2604.20087.

Zhou, R.; Hua, W.; Pan, L.; Cheng, S.; Wu, X.; Yu, E.; and Wang, W. Y. 2025. RuleArena: A Benchmark for Rule-Guided Reasoning with LLMs in Real-World Scenarios. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 550–572.

Zhou, S.; Xu, F. F.; Zhu, H.; Zhou, X.; Lo, R.; Sridhar, A.; Cheng, X.; Ou, T.; Bisk, Y.; Fried, D.; Alon, U.; and Neubig, G. 2024. WebArena: A Realistic Web Environment for Building Autonomous Agents. In *The Twelfth International Conference on Learning Representations*.