

自我书写的度量：从自身盲点进化出评估器

Xing Zhang Yanwei Cui Guanghui Wang Zhihao Lin Peiyang He*

亚马逊云科技生成式人工智能创新中心

摘要

智能体在可靠的自动度量下能快速改进，没有度量则会停滞，而最需要它们的应用——报告生成便是其中之一——恰恰是无人知晓如何评分的应用。度量能否自我书写？说清什么答案算好很难；指出答案中的某个错误则更容易，因此我们进化的度量是一组小型 Python 算子，每个算子针对一个命名缺陷标记候选答案，或弃权，并投票。直接向模型索要算子行不通：183 个候选算子仅实现了 96 种不同行为，且都来自巨大空间中的一个狭窄区域。EvalCEGAR 转而借鉴程序验证中的反例引导抽象精化。它将算子池视为一种抽象，并搜索冲突——即两个答案被算子给出相同评分，但一个正确一个错误。这一对答案，而非提示词，才是创作请求；当冲突击败所有尝试时，循环会扩大算子可读取的内容，而非重新采样。在 MBPP+ 和 HumanEval+ 上——一个隐藏单元测试提供精确真实标签的沙盒——该循环写出一个 55 行的算子，在 428 个未见任务上，将“不标记任何内容”与完美过滤器之间的差距缩小了 15.4%（ $+0.0065, p=0.0010$ ），且标记数量仅为最佳手写算子的四分之一。在从未见过的基准上，该算子在三分之一的标记上与手写算子的效果完全一致。八次运行中有六次产生了这样的算子，且全部在样本外有所帮助；我们将 15 个手写算子合并为一个过滤器时，准确率反而下降。基于相同信息的 LLM 评判器在几乎不相交的候选集上达到了相同的差距，但每个候选答案永久消耗一次模型调用，而算子则零成本。

1 引言

自我改进系统需要策略之前，首先需要度量。有了可靠的自动度量，LLM 智能体能快速改进：自我精化、自我调试和反思循环都假设存在一个信号，能将更好的答案与更差的答案区分开 [13, 20, 5]。没有度量，进展就会停滞，而替代方案都很薄弱：参考重叠在构造上就忽略了语义 [16, 10]，LLM 评判器则带有位置、冗长和自我偏好偏差，这些偏差属于评判器而非答案 [24, 21]。这在开放式输出上最为棘手，例如报告或计划，既没有参考答案，也没有关于好答案应具备何种特征的定论。

本文探讨度量指标能否自动演化。我们演化的并非分数，而是一组算子：每个算子均为小型 Python 函数，读取一项任务与一个候选答案，并针对某一特定缺陷进行标记、判定为无缺陷或弃权。算子池通过投票形成度量：当足够多的成员标记某候选答案时，该答案即被拒绝。这种形式遵循一种在缺乏参考答案时依然成立的不对称性：评价答案优劣需要无人写下的标准；而指出其错误通常无需此类标准。每个算子陈述一种异议，因此可被独立阅读、运行与证伪，算子池的有效性是一种经测量的属性，而非假设的属性：每个成员在加入前都需在下游决策中证明自身价值。* 通讯作者：

peiyang@amazon.com

我们的初步运行结果。我们首先运行了显而易见的循环：向模型请求一个算子，若门控机制接受则保留，如此反复。该循环以两种方式停滞，我们将两者均视为问题陈述。障碍一：算子空间极为庞大，而模型被要求生成“评估算子”时，仅从该空间中一个微小且固定的区域采样。重复采样无法移动该区域：对研究在该狭窄接口下编写的全部 295 个算子进行评分，未产生任何发现（第 5.2 节）。障碍二：模型实际编写的算子在行为上自我重复，且大部分被拒绝。五次运行产生了 183 个标记一切的算子，仅实现了 96 个不同的标记集合（第 6 节）。一次拒绝同样无法提供任何学习信号：循环只知道候选算子失败了，却不知道它未能区分何种区别。

我们的方法。我们借鉴程序验证中的一项准则：反例引导的抽象精化仅在具体反例证明当前抽象过于粗糙时才对其进行细化 [7]。算子池即该抽象，它将每个候选答案映射为一个签名，即池中算子对该答案返回的判定向量。两个签名相同的答案对于该度量而言不可区分，因此若一对答案签名相同但在真实标签上不一致，则证明该度量无法表达这一区别。EvalCEGAR 将这对答案作为规范交给模型。每次接纳都会重新划分签名空间，因此下一个规范在构造上必然不同：多样性压力来自目标本身，而非采样器（障碍 2）。当一对答案击败所有尝试时，循环会扩大算子可读取的接口范围，而不是再次采样，因为接口无法感知的区别在任何样本量下都不可达（障碍 1）。算子只有在改善该度量所服务的决策时才被接纳，而不是因为它覆盖了更多已知缺陷，且被接纳的算子通过投票发挥作用。

我们为何在代码上验证。动机源于缺乏可用度量的领域，然而本文所有数据均来自具有精确度量的领域：MBPP+ 和 HumanEval+ 中的 Python 问题 [1, 4, 11]，其隐藏的单元测试套件可直接判定正确性。编写度量的方法无法在真值未知的领域进行评估，因此我们在真值已知但被隐藏的领域构建该方法。算子本身具有领域特定性，因此新领域继承的是循环机制，而非此算子池。可迁移的部分虽窄但可验证：算子从不读取预言机，四重筛查确保它们不会重建预言机（附录 A），且预言机标签仅出现在训练划分中，其代价是新领域可以承受的：在我们 75 个训练任务中，仅有 10 个任务同时包含通过可见检查的正确与错误候选答案，而这已足以接纳可迁移的算子（附录 B）。

贡献。

- **EvalCEGAR。**一个从自身盲点演化评估度量的循环，其编写请求即它为自己发现的反例（第 4 节）。
- **在样本外保持有效的算子。**八次运行中有六次接纳了算子，且全部六个在 428 个未见任务上均有帮助；最佳算子仅 55 行 Python 代码，在第二个基准上以三分之一的标记量匹敌我们最佳的手写算子，而在相同信息下，模型评判器虽与其持平，但标记的集合几乎不相交（第 5.1 节）。
- **每种机制的价值所在。**在相同信息上于循环内部进行消融：仅录取问题一项就将录取数从零提升至一，而狭窄接口在 336 次尝试中未录取任何内容（第 5.2 节）。
- **组合被精确求解，而非搜索。**对循环可组合的全部 230 万个子集进行评分，将其用于组合这些子集的目标函数在该空间中排名低至第 5 百分位，而未调参的类别加权目标函数则位于第 91 百分位或更高（第 5.3 节）。

2 相关工作

开放式输出的自动评估。上述两种替代方案均在不改变形式的前提下得到了强化：学习型度量用模型自身的相似性判断取代了重叠计数 [23]，而评判框架则向评判者提供明确的准则以供填写 [12]，并通过分解粗略准则和过滤冗余准则 [19] 加以改进。其输出仍是一个单一标量，读者无法将其各部分区分开来。EvalCEGAR 产生的是不同的对象：一个由小型、可执行、可单独证伪的反对意见组成的池。该池可以增减一条反对意见而无需重新训练，这正是此类度量具有可演化性的原因。我们将与这两类方法进行比较：评判者在终点指标上与我们持平，但在应舍弃哪些候选项上存在分歧（第 5.1 节），因此我们的主张在于可检验度量的生成方式，而非超越标量度量。

基于大语言模型的程序搜索与反例引导抽象精化。FunSearch 针对给定评估器演化程序 [18]，而自动化智能体设计则针对给定基准搜索智能体代码 [9]。本文的工作是其补充：当评估器本身作为产物时，不存在固定的适应度函数，因此设计问题从如何变异候选方案转变为候选方案在被保留之前必须证明什么。在输出上最接近的是利用大语言模型（LLM）诱导可执行检查并将其组合的方法，通过一组紧凑的 Python 验证器，其联合满足近似于带标签的目标 [17] 或对模型生成的二值问题进行无权重投票 [8]。这些方法搜索能够预测标签的检查；而本文搜索的是反例，以证明当前检查无法做到这一点，并据此在部署决策上予以接纳。我们将该方法作为基线运行（第 5.2 节）。CEGAR 是一种验证技术 [7]；据我们所知，将其迁移到度量综合中是新的（第 4 节）。

多样性与测试生成。质量-多样性搜索通过维护显式的行为档案来防止种群崩溃 [15]；本文的多样性压力则来自每次接纳后对目标进行重新划分，第 6 节衡量了这种做法的不足之处。这也不是测试生成：基于属性的测试器需要一个待证伪的属性 [6]，差分测试需要第二个实现 [14]，而本文的设置两者皆不具备。

3 预备知识

任务与数据。每个任务都是来自 MBPP+ 或 HumanEval+ 的 Python 编程问题，由 EvalPlus 分发 [11]，其隐藏测试套件是精确的预言机。它为循环所针对并接纳的训练样本打标签，除评分脚本外没有其他部分读取它。题目陈述还会展示一些示例调用及其预期结果，求解器也能看到这些；我们称之为可见检查，它们不属于留出信息。我们抽取了 150 个 MBPP+ 任务，其中 75 个用于运行循环，75 个留出，并将剩余的 228 个 MBPP+ 任务以及 164 个 HumanEval+ 任务中的 125 个加入留出集。² 结果在这 428 个未见任务上报告，分为 MBPP+ 留出（75 个）、MBPP+ 附加（228 个）和 HumanEval+（125 个），后者是唯一来自不同任务分布的组。

选择准确率。对于每个任务 t ，我们采样多个模型解，并令 $V(t)$ 为通过可见检查的解，包括重复项：这些是部署系统可能接受的候选解，因此重要的故障是那些在它们中幸存下来的故障。度量必须从中选择。它从 $V(t)$ 中丢弃其标记的内容，留下保留集 $K(t)$ ，并从 $K(t)$ 中均匀抽取一个样本，或者如果度量标记了所有内容，则从 $V(t)$ 中抽取。选择准确率是该样本正确的概率，在任务上取平均； Δ always 表示其相对于不标记任何内容的度量的变化。

可判定性与余量。一个任务只有在 $V(t)$ 同时包含一个正确样本和一个错误样本时才才可判定；在任何其他任务上，无论度量做什么，抽取样本的正确性都已确定。在我们的采样深度下，428 个留出任务中只有 58 个是可判定的，因此所有 428 个任务上的选择准确率从 0.7170（当没有标记任何内容时）到 0.7593（对于完美算子）运行。绝对 Δ values 因此很小，所以我们还将每个报告为该可达范围的分数，即余量。端点也由召回率主导：被标记的正确样本仅仅离开保留集，而被捕获的错误样本则改变了剩余可抽取的内容。

我们比较的对象。在构建循环之前，我们手工编写了 15 个算子，其中十个是对候选解语法树的静态检查，五个是运行候选解。它们是循环开始的池子，并且一起作为一个过滤器应用时，构成我们的人工基线。我们最强的手工算子，即贯穿始终的比较器，标记一个行为与其任务其他样本的多数不一致的候选解。第二个基线是一个大语言模型（LLM）评判器，在完全一级算子的信息下，对每个候选解提出一个问题，在两种模型和两种提示的四种配置下（第 1 节）。

编写算子的模型。一个冻结模型（Claude Opus 4.7，本工作中没有微调和梯度更新）输出算子源代码，在 8 轮中 60 次调用上限下每次运行 47-48 次调用。其算子所评判的错误候选解来自较弱的模型（Llama 3.1 8B Instruct 和 Claude Haiku 4.5，以及 Amazon Nova Micro 和 Mistral 7B

² HumanEval+ 不打印断言，因此其可见检查是从文档字符串示例合成的；我们保留 125 个任务，这些任务至少产生一个参考解通过的此类检查。




图 1: EvalCEGAR。编写请求是一个盲点：答案池映射到一个签名，而真实情况不一致（左）。准入重新划分签名，因此下一个请求已经移动，并且一个抵抗级别 1 的盲点会升级（右），而不是被重新采样。

为第 6 节的更深入抽取添加了指令），因此编写糟糕代码的模型从未编写过评判它的操作符。EvalCEGAR 交付的内容，即操作符池及其投票，是纯 Python，带有 *no* 推理时模型调用。

保持循环诚实。四个屏幕在门看到之前拒绝一个编写的操作符，每个都关闭了早期工作轮次意外重建预言机的一种方式：在不运行的情况下根据候选者的语法决定，关注故障生成器恰好发出的常量，在提示关键词上分支，以及在别处执行候选者时通过文本匹配到达标志。这 15 个手写操作符中没有一个是触发，因此它们不是对普通检测器的禁令（A 节）。每个 Δis 都针对大小匹配的洗牌零假设进行测试：每个任务的操作符自己的标志计数从该任务自己的样本中重新抽取，因此零假设固定了它标记多少，只随机化标志落在哪里。这允许“此规则胜过不标记任何东西”，但不允许“规则 A 胜过规则 B”，即第 6 节报告的主张，并且多重比较在相关测试族内带有 Bonferroni 校正，在多个 [2] 的筛选上带有 Benjamini – Hochberg 校正。注册意味着预测在测试它的脚本存在之前就被写下来了。

4 方法

一句话。找到当前池评分相同的两个候选答案，一个正确一个不正确；要求模型提供一个捕获此类故障的操作符；当请求被证明不可达时，扩大操作符可以读取的内容；并根据部署的决策是否改进来准入。

图 1 是循环，算法 1 是其中的一轮。

碰撞目标选择。冲突（collision），或称盲点，是同时包含正确与错误候选者的签名类，池中最大的一个成为下一个目标。冲突对定位了请求但并未陈述它：请求覆盖了所有以相同方式失败的训练样本，因为命名两个样本的规范可由查找表满足（A 节）。一个目标若在两种接口的所有尝试中均存活，则被放弃；一旦所有目标均被放弃，循环便返回算子词汇表的不足性证书：度量语言，而非作者，才是极限。这正是失败运行具有信息价值的原因：它指出了词汇表无法表达的分。

接口升级。第 1 级为操作（任务，代码）。当 $r_{\max}=3$ 个第 1 级尝试在目标上失败时，同一目标升级至第 2 级，即操作（任务，代码，上下文），其中上下文允许操作者查看候选者的同类，并在 600 的硬预算下，在自选输入上运行其中任意一个

Algorithm 1 EvalCEGAR, one round on one target. Δ_D is the change in selection accuracy on the training tasks D . Ground-truth labels y are read on the training split only, at lines 2 and 10; AUTHOR sees the specification and the interface, never y .

Require: operator pool P , training tasks D with candidate sets $V(t)$ and labels y , level-1 retry budget $r_{\max}$, total attempt budget R

```

1:  $\sigma_P(c) \leftarrow (o(t, c))_{o \in P}$  for every  $c \in V(t), t \in D$  ▷ the pool is the abstraction
2:  $C \leftarrow \{ \text{signature classes containing both a } y=1 \text{ and a } y=0 \text{ candidate} \}$  ▷ the blind spots
3: if  $C = \emptyset$  then return  $P$  ▷ the pool already separates every labelled pair
4:  $\kappa \leftarrow \arg \max_{\text{class} \in C} |\text{class}|$  ▷ the target
5:  $\text{spec} \leftarrow$  every incorrect training sample that fails as  $\kappa$ 's do, and every correct one ▷ not just the pair
6:  $\ell \leftarrow 1$  ▷ interface level:  $\text{op}(\text{task}, \text{code})$ 
7: for  $r = 1 \dots R$  do
8:    $o \leftarrow \text{AUTHOR}(\text{spec}, \ell)$  ▷ one LLM call; a stated request, not "write a metric"
9:   if  $o$  fails a leakage screen, does not shrink  $\kappa$ , or is a function of  $\sigma_P$  then continue
10:  if  $\Delta_D(P \cup \{o\}) > 0 \wedge \text{helped} \geq 3 \wedge \text{helped} > \text{hurt}$  then
11:    return  $P \cup \{o\}$  ▷ admission re-partitions  $\sigma_P$ , so the next  $\kappa$  has moved
12:  if  $r = r_{\max}$  then
13:     $\ell \leftarrow 2$  ▷ same  $\kappa$ , wider interface  $\text{op}(\text{task}, \text{code}, \text{ctx})$ 
14: return  $P$  ▷  $\kappa$  abandoned: unreachable at either interface

```

每次操作调用在至多 16 个对等节点上的观测（图 1 右，及 A 节）。这改变了搜索的坐标，而非在坐标内重采样：若有用操作在层级 1 不可表达，则无论采样多少次都无法找到它。

基于已部署决策的准入。最终门槛是对决策的下限约束，在训练划分上评估： $\Delta > 0$ ，至少 3 个任务受益，受益 $>$ 受损。这并非对故障类别召回率的下限约束，而这一点听起来更为重要：一个稀疏且精确的算子从构造上就无法通过召回率下限，而这恰恰是端点所期望的。召回率门槛分支拒绝了我们的最佳算子，因为它未能覆盖池中仍然遗漏的 140 个已知故障中的任何一个（第 D 节）。

按误差独立性进行组合。被采纳的算子通过投票组合而成：当所选子集 S 中至少 m 个算子（共 k 个）标记某个候选时，该候选即被标记，其中 $m=2$ 和 $k = |S| \leq K_{\max}=6$ ，除非另有说明。该子集是仅基于已标注训练样本计算目标函数所得到的最优子集，不使用开发集划分、不调整阈值、不进行平局处理，且采用单位权重而非学习得到的权重，因为在正类稀缺时学习权重难以超越单位权重 [8]。该目标函数最初是对确证标记（即投票触发的标记）计算 $J = \text{TP} - \text{FP}$ ；第 5.3 节表明 J 不利于部署，并将其替换为在训练划分上读取的 $\lambda = n_{\text{TP}}/n_{\text{FP}}$ 处的 $\text{TP} - \lambda \text{FP}$ 。

5 结果与分析

三个问题：该度量在未见任务上是否有效（第 5.1 节），移除每个机制会带来什么贡献（第 5.2 节），以及一旦能够精确评分整个搜索空间，组合步骤的效果如何（第 5.3 节）。

5.1 主要结果

表 1 比较了单个算子。循环算子的代码为 55 行 Python，以四分之一的标记量达到了比较算子 94.2% 的效果。在仅包含 58 个可判定任务时，其 $+0.0065$ 上升至 $+0.0481$ （表 2），并且其标记与最接近的手写算子在 Jaccard 系数 0.245, so it 处重叠，表明并非重新发现。其行为可用一句话概括：保留通过提示可见断言的同类，在扰动输入上运行它们和候选，并标记与幸存多数意见不一致的情况。每个被采纳的二级算子都是该算法的变体，因为循环奖励的是新的区分方式，而非新的划分方法（第 6 节）。同一张表还展示了促使循环设计的对比：在人们认为容易的领域中，15 个手写算子作为一个过滤器反而损失了准确率。

表 1：在 428 个留出任务及其 2592 个样本上，所设计的算子与最强手写算子及大语言模型评判器的对比。余量百分比为 Δ as，即完美算子可增加 0.0424 的一部分（第 3 节）；调用次数为每个候选评分所需的模型请求数。三个正类行在 Δ 上彼此相差在 0.0005 以内，区别在于标记数量和成本。

	Δ	% of headroom	p	flags	calls
hand-written comparator	+0.0069	16.3	0.0130	515	0
all 15 hand-written operators as one filter	-0.0067	-15.8	n/a	1425	0
LLM judge, best of four configurations	+0.0070	16.5	0.0010	158	1
loop-authored operator	+0.0065	15.4	0.0010	126	0

表 2：所设计算子的逐池迁移，每个池均与其自身的随机置换零分布（ $b=1000$ 次重采样）比较。HumanEval+ 在预言模块、提示风格和难度上与测试池不同，且未进行任何重新调整。+/- 统计了受益和受损的任务数；误报率为正确样本被标记的比率，格式为所设计算子/手写算子。各池余量：0.0392, 0.0429, 0.0433。

pool	tasks	decidable	Δ	p	z	+/-	false alarms
MBPP+ held-out	75	6	+0.0047	0.0400	1.74	+2/-1	0.054 / 0.168
MBPP+ additional	228	34	+0.0038	0.0020	3.38	+8/-4	0.041 / 0.129
HumanEval+	125	18	+0.0125	0.0010	6.28	+10/-1	0.027 / 0.071

基于相同信息的模型评判器。在一位一级操作员的精确接口下，对每位候选人提出一个问题，并在相同的端点和零假设上作为度量进行评分，四种评判配置中最佳者达到 +0.0070（表 1），因此我们不声称超越它。这既非相同的判定，也非相同的成本。两组标记的杰卡德相似度为 0.105，即 257 个标记中的 27 个；各方独有的标记仅为零假设（+0.0010 在 $p=0.068$ 处，以及 -0.0007）；而它们达成一致的 27 个标记价值 +13/-1 个任务，并集高于两部分，为 +0.0073。可检查的操作员与模型判断在不同的输入上失败，因此它们的一致性两者单独都无法达到的高精确率区域。成本将它们永久区分：47 次编写调用且每位候选人零调用，对比每位候选人每次调用，此处单次遍历为 1762 次。两种不对称性属于该比较：作者模型在 +0.0040 处进行评判，低于其创作水平，且两个基准均为公开，因此评判者可能已记忆解决方案，而操作员无法如此（第 1 节）。

一个池，而非单一操作员。八次运行仅在模型采样上有所不同，因此它们的分布差异即为 EvalCEGAR 自身的采样分布：8 次中有 6 次接纳了操作员，全部 6 次在样本外均为正（中位数 +0.0029，范围 +0.0009 至 +0.0065，6 次中有 4 次单独显著），全部 6 次均处于第 2 级，且所有四个拟合筛选在全部 6 次上均干净。在整个研究中，门控已接纳 26 个操作员，这是第 5.3 节所组合的两个池中较小的一个：在留出任务上，25 个无害，17 个相对于自身零假设单独显著，而随机预期为 1.3，中位数为 +0.0036。15 个手写操作员并非这样的池：9 个有任何标记，5 个无害，1 个显著。接纳仅基于训练划分，因此这是迁移。

迁移至未见基准。两个事实尤为突出（表 2）。在三个池上测量的 13 条规则中，12 条由循环编写的运算符和比较器，唯有这一条在所有三个池上均为正，并清除了各自池的零假设，而比较器仅在人类评估增强版（HumanEval+）上达到 $p < 0.05$ 。在来自不同任务分布的人类评估增强版池上，它与比较器完全匹配，并在简约性上胜出：相同的 10 个受助任务，相同的单个受损任务，以及相同的 +0.0125，即该池余量的 28.8%，使用 36 个标志对 103 个标志。每个池首先检查是否包含足够的可判定任务，以便完美运算符能够注册，因此零值意味着缺失，而非无能力。迁移在第二个轴上也成立，针对来自三个生成器的 9320 个候选者，这些候选者从未见过该组合规则，达到该抽取余量的 22.1%，而此处为 18.9%（第 G 节）。

5.2 机制消融

移除任一机制都会立即阻止准入（表 3）：每个机制都是必要的，而不仅仅是辅助性的。仅窄臂的失败并非预算伪影，因为第 1 级自身的上限低于随机水平：对研究编写的全部 295 个一级运算符，在 503 个合并任务上评分，无分割且无

表 3：两种机制消融，各自在循环内对其自身候选者运行，使用相同的三个种子和相同的训练分割标签，仅更改指定组件。调用次数是模型每个种子的编写调用次数，因此两种消融均非资源不足的运行。在任一臂或研究的 336 次尝试中，从未有第 1 级尝试被准入（第 D 节）。

arm	what changes	calls	admissions
the loop (reference)	–	47 / 48 / 47	1 / 1 / 1
recall floor at the gate	the admission objective	48 / 48 / 48	0 / 0 / 0
level 1 only, no escalation	the interface	48 / 48 / 48	0 / 0 / 0

选择成本在 $p < 0.05$ 处给出 9，而随机期望为 14.75，因此本杰明尼-霍赫伯格程序在 10% 的错误发现率下未返回任何发现。

独立搜索在墙的位置上达成一致。针对平衡标记样本进行委托检查，并准入它们以预测标签，如第 2 节的归纳方法所做，在第 1 级准入 48 个候选者中的 2 个，其 $+0.0016$ 未被其自身零假设拒绝，在第 2 级准入 16 个候选者中的 6 个，在仅训练组合器下为 $+0.0054$ （第 I 节）。两次搜索除接口外无任何共享，均在第 1 级失败，且均在第 2 级成功，这也界定了召回率下限行所声称的内容：准入目标不得奖励覆盖率，但预测拟合不会像召回率门控那样失败。

门控台账。记录每一次门控咨询都能精确定位该墙。准入需要三个受助任务；窄接口达到两个并在那里停止 55 次且无任务受损，其 124 次咨询中无一达到三个，而宽接口达到三个 6 次且每次均获准入（图 3）。扩展并未买到方向，窄接口能轻易找到方向；它买到的是通用性，即第三个不同的任务。定向本身买到的是候选可行性而非准入：无定向时操作员在 34.5% 的情况下处处弃权，而有定向时为 2.1%（第 C 节）。

5.3 组合，枚举

组合从循环的获准操作员中选择一个大小至多 6 的子集，两个池中均无手写操作员。两个池收集了门控在研究各创作臂和种子上的准入结果，分别为 26 个和 35 个操作员，较大的包含较小的，它们实现了 17 种和 20 种不同的标志行为，产生 313,911 个和 2,007,327 个子集，小到足以枚举。我们通过与其他地方相同的代码在留出端点上对每个子集评分（图 2），因此先前通过推理回答的问题变成了算术，且本小节中不出现 p 值。两个术语反复出现：当子集的投票未标志任何内容时，该子集为空；而预言机最大参数是枚举中留出 Δ_{in} 的最佳值，是任何训练数据规则都不应达到的上界。每个结果跨越四个单元格：每个池在二级操作员读取的同伴集的两个固定设置下。

缺陷。 J 将其自身的最大参数排在其搜索空间的第 4.9 至第 85.7 百分位之间（表 4 中的 C1），而预言机最大参数约为其 $(+0.0300/+0.0314)$ 对 J 的 $(+0.0155/+0.0140)$ 的两倍，且其与端点的 k 内相关性仅在 $k=2$ 处为正，到 $k=6$ 时降至 -0.338 （图 2c）。枚举还表明原因是偏差而非方差：在更多标注数据上重新拟合会收敛（在 $n=210$ 处有 16–18 个不同选择，在 $n=1195$ 处为 3–5 个），且收敛到冻结规则以下，即先前经验法则下固定的子集。因此应冻结选择而非重新拟合。

修复。我们在运行前注册了六项选择标准，每项均仅从训练划分中计算（ $n_{TP}=222$ 真和 $n_{FP}=1183$ 假标志），按未改变的 ≥ 2 -中- k 规则排序，并与精确景观进行评分（表 4）。平衡准确率在四个单元格中均为六项标准中的最佳，缩小了与预言机最大值的差距的 39.8–90.2%，并且在所有四个单元格中也优于标签预测 F_1 ，即归纳基线所承认的标准。

为何有效。我们注册的预测归咎于聚合，即 J 按样本计数而端点按任务平均；但端点自身的公式 C2 从未达到第 85 百分位，




图 2：组合搜索空间，枚举。(a,b) 在 26 和 35 算子池的每个 ≥ 2 -中- k 子集 ($k \leq 6$) 上的留出 Δ of, 以密度表示, 表 4 的 C1 - C7、冻结规则和预言机最大值各自位于其精确百分位。C7 为事后添加。(c) 在较大池中每个子集大小上 J 与端点之间的斯皮尔曼相关性: 仅在 $k=2$ 处为正, 因此错位并非规模假象。

因此那并非缺陷。关键在于类别权重: 平衡准确率对 $TP - 0.188FP$ 单调, 对误报 $5.33\times$ 的惩罚小于 J 的 1:1, 而 C4 降至第 1.5 百分位或更低。这正是第 3 节的召回主导性重新浮现为错误指定的目标, 意味着一旦目标正确, 重新拟合是安全的, 而这正是自进化库所需要的。两项注册检查成立: 半分协议在 4 个单元格中的 4 个中重新选择 C6, 并且在 12 点扫描中, HumanEval+ 的最优 λ -平台在 4 个单元格中的 4 个包含 MBPP 训练比率, 而 $\lambda=1$ 从未如此, 因此权重是选择端点的属性, 而非那些标签的属性 (F 节)。

整个闭包上的安全性。在较大池的 2,007,292 个非平凡子集中, 零个损害端点 (最小 $+0.0007$) : 准入使组合在其整个组合闭包上安全, 精确且无需功效论证。反之在 15 个手写算子上成立, 准入不接受其中任何一个: 同一组合器在那里收敛为不标记任何内容。

6 负面结果与局限性

行为重复。该池在行为上而非文本上重复自身: 在 187 个候选中, 没有任何源文本对达到杰卡德相似度 0.8, 然而 183 个标记了任何内容的候选仅实现了 96 个不同的标记集 (图 5)。两种疗法均无效。定向使其更糟, 定向组是三者中多样性最低的, 并且在准入时的新颖性项仅在它阻止的 11 个候选中恢复了 2 个真正的新算子; 给它重复的现任算子, 模型再次重复它。因此, 限制位于算子先验中, 而非门控处, 这支持显式的行为档案 [15]。

浪费, 而非耗尽。在三个新种子上进行的 14 次准入中, 有 9 次重新发现了已选中的算子, 并且该池上 $+0.0076$ 的组合标题未能通过我们随后添加的重新发现筛选 (第 H 节)。对行为类别的稀疏化 [3] 在第六个种子上仍产生 2.00 个新类别: 是浪费, 而非耗尽。

数字未显示的内容。每个 Δ is 都是与不标记任何内容相比, 而非与另一条规则相比: 在 9 个配对测试中, 没有两条规则被区分开 [22], 它们的差异存在于 2-9 个任务上, 并且三个似乎优于比较器的循环算子是对它的重新发现。二级判定也是同行选民规模的函数: 将其扩大三倍会改变所有 35 个算子的判定, 因此它们的标记需要一个固定的选民群体, 尽管留出的 Δ moves 上升而非下降 (第 G 节)。准入所丢弃的内容未被测量 (第 C 节)。两个基准都来自同一个

分布族，因此样本外任务列表需要第三个预言机端口。并且循环并非获得这种质量算子的唯一途径：一个评判者与其增量持平，因此它购买的是互补的错误分布，而非更高的上限。

7 结论

评估度量可以自动生成，且该产物足够小，便于阅读：55 行 Python 代码，无权重，在 428 个未见任务上，与完美算子之间的距离缩小了 15.4%。它通过反例而非提示进行询问，其背后的三条规则适用于任何可执行检查池：

- **基于决策而非覆盖率进行准入。** 仅此一项改变，就将每个种子的准入数量从零提升至一。
- **当没有任何方法能解决反例时，拓宽接口。** 在窄接口上的 336 次尝试无一准入；而宽接口则准入六个。
- **在选择端点上，对类别进行加权。**，读取训练 $TP - (n_{TP}/n_{FP})FP$

练

标签，达到了一个空间的最高十分位，而该空间中以精确率为导向的目标函数位于最底部的 2%。

在存在单元测试之处，运行单元测试。剩下的便是促使该方法产生的场景：一个未解决的计数器示例是唯一证据，表明某个度量的词汇表，以及它所能支持的声明，已经耗尽。

参考文献

- [1] Jacob Austin, Augustus Odena, Maxwell Nye, Maarten Bosma, et al. Program synthesis with large language models. *arXiv preprint arXiv:2108.07732*, 2021.
- [2] Yoav Benjamini and Yosef Hochberg. Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*, 57(1):289–300, 1995.
- [3] Anne Chao. Estimating the population size for capture-recapture data with unequal catchability. *Biometrics*, 43(4):783–791, 1987.
- [4] Mark Chen, Jerry Tworek, Heewoo Jun, Qiming Yuan, et al. Evaluating large language models trained on code. *arXiv preprint arXiv:2107.03374*, 2021.
- [5] Xinyun Chen, Maxwell Lin, Nathanael Schärli, and Denny Zhou. Teaching large language models to self-debug. In *International Conference on Learning Representations (ICLR)*, 2024.
- [6] Koen Claessen and John Hughes. QuickCheck: A lightweight tool for random testing of Haskell programs. In *International Conference on Functional Programming (ICFP)*, pages 268–279, 2000.
- [7] Edmund Clarke, Orna Grumberg, Somesh Jha, Yuan Lu, and Helmut Veith. Counterexample-guided abstraction refinement. In *Computer Aided Verification (CAV)*, pages 154–169, 2000.
- [8] Ben Griffin, Aaron Ontoyin Yin, Diego Vidaurre, Ugur Koyluoglu, et al. Random Rule Forest (RRF): Interpretable and manageable ensembles of LLM-generated questions for predicting success from unstructured data. *arXiv preprint arXiv:2505.24622*, 2025.
- [9] Shengran Hu, Cong Lu, and Jeff Clune. Automated design of agentic systems. *arXiv preprint arXiv:2408.08435*, 2024.
- [10] Chin-Yew Lin. ROUGE: A package for automatic evaluation of summaries. In *Text Summarization Branches Out*, pages 74–81, 2004.
- [11] Jiawei Liu, Chunqiu Steven Xia, Yuyao Wang, and Lingming Zhang. Is your code generated by ChatGPT really correct? rigorous evaluation of large language models for code generation. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

- [12] Yang Liu, Dan Iter, Yichong Xu, Shuohang Wang, Ruochen Xu, and Chenguang Zhu. G-Eval: NLG evaluation using GPT-4 with better human alignment. In *Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2023.
- [13] Aman Madaan, Niket Tandon, Prakhar Gupta, Skyler Hallinan, et al. Self-refine: Iterative refinement with self-feedback. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
- [14] William M. McKeeman. Differential testing for software. *Digital Technical Journal*, 10(1):100–107, 1998.
- [15] Jean-Baptiste Mouret and Jeff Clune. Illuminating search spaces by mapping elites. *arXiv preprint arXiv:1504.04909*, 2015.
- [16] Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. BLEU: a method for automatic evaluation of machine translation. In *Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 311–318, 2002.
- [17] Pouya Pezeshkpour and Estevam Hruschka. AutoPyVerifier: Learning compact executable verifiers for large language model outputs. *arXiv preprint arXiv:2604.22937*, 2026.
- [18] Bernardino Romera-Paredes, Mohammadamin Barekatain, Alexander Novikov, Matej Balog, et al. Mathematical discoveries from program search with large language models. *Nature*, 625:468–475, 2024.
- [19] William F. Shen, Xinchu Qiu, Chenxi Whitehouse, Lisa Alazraki, et al. Rethinking rubric generation for improving LLM judge and reward modeling for open-ended tasks. *arXiv preprint arXiv:2602.05125*, 2026.
- [20] Noah Shinn, Federico Cassano, Ashwin Gopinath, Karthik Narasimhan, and Shunyu Yao. Reflexion: Language agents with verbal reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
- [21] Peiyi Wang, Lei Li, Liang Chen, Zefan Cai, et al. Large language models are not fair evaluators. *arXiv preprint arXiv:2305.17926*, 2023.
- [22] Frank Wilcoxon. Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83, 1945.
- [23] Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q. Weinberger, and Yoav Artzi. BERTScore: Evaluating text generation with BERT. In *International Conference on Learning Representations (ICLR)*, 2020.
- [24] Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, Siyuan Zhuang, et al. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. In *Advances in Neural Information Processing Systems (NeurIPS) Datasets and Benchmarks Track*, 2023.

A 请求范围、屏幕与空值

交给作者的请求覆盖了整个故障类别，而非两个冲突样本，因为双样本请求可通过查找表满足：本工作的早期一轮测量恰好证实了这一点，操作符在少数训练故障上触发，而在留出类别上完全不触发。这两类故障分别是：已经未通过可见检查的故障，以及通过了可见检查但仅未通过隐藏测试套件的故障，请求覆盖冲突样本所属的任一类别。

第 3 节四个屏幕中最微妙的是提示关键词屏幕：基于关键词分支的操作符根据任务身份而非面前的候选者作答，这相当于通过分派表进行预言机重建。

第 2 级的上下文暴露了候选者的同类项、运行器、提示可见的断言以及输入生成器，但不暴露任何读取隐藏测试套件的内容。输入来自对提示可见断言的参数进行扰动，这些断言求解器同样可见，未扰动的数量也被暴露。

以便操作符能够区分二者。超出观察上限的操作符选择弃权而非停滞。

第 3 节的洗牌空值全程使用 $b=1000$ 重采样，并设置种子以确保重跑时能精确复现。

B 迁移预算

由于预言机标签仅出现在训练划分上，将 EvalCEGAR 迁移至无预言机领域的成本即为该划分的标签成本，且必须以可判定示例来计量：一个示例只有在同时携带一个通过可见检查的良候选与一个坏候选时，才能为循环提供信息。在我们的 75 个训练任务中，有 10 个是可判定的，从而产生 80 个（正确，错误）对以及训练目标的四个可区分层级。这足以证明能够接纳可迁移的算子（ $+0.0065$ ），但显然不足以调整一个标量：一个 ≥ 4 选 26 的投票在留出集上价值 $+0.0087$ ，而无论是训练 Δ_{nor} 还是训练内部的交叉验证都无法将其与并集区分开来。

三项测量完成了预算。(i) 调整聚合的交叉点为 20–30 个可判定任务：低于此值时，选择在 9 个方向中的 9 个上坍塌为并集；高于此值时，轮转一个留出折可恢复 $+0.0077$ ($p \leq 0.0004$ ，在 $m=2, 3, 4$ 处相同)，达到预言机增益的 57%。(ii) 更好的门控消除了这一要求，而非为其付出代价：来自目标专用门控（第 C 节）的三个种子的 9 个算子得分 $+0.0071$ ($p=0.0022$)，与无需设定阈值的普通并集相同，因此门控质量与聚合是替代关系。(iii) 组合彻底改变了计量单位，而这是最便宜的一项：误差独立性需要带标签的标志，而非可判定任务，而同一训练划分中包含 426 个这样的标志。 ≥ 2 选 k 规则以 5 个算子而非 26 个且无需调整的方式匹配了 (i) 的轮转选择，实测代价为 ~ 60 个带标签候选（在样本量减半时退化为 $+0.0065/+0.0033$ ）。因此，新领域的预算线为 ~ 10 个可判定示例用于编写和接纳，加上 ~ 60 个带标签候选用于决定哪些被接纳的算子参与投票，而第二个数字是实践者真正能够产生的，因为它不要求单个示例同时包含正确和错误的候选。

C 定向与接纳

在合成银行上的一项早期消融实验倾向于碰撞，录取比为 4 比 0，36 个无向候选中有 31 个因未定向而被拒绝。这在自然银行上未能复现，我们放弃其许可的主张。后续的单标志实验则厘清了分工：保留碰撞作为目标但不再将其作为验收测试，使每粒种子的不同度量产出从 0.38 提升至 1.67 ($4.4\times$)，峰值质量保持不变 ($+0.0063$ vs $+0.0065$)，并将约束性拒绝阶段移至目标函数（拒绝占比从 28.6% 升至 60.3%）。因此，碰撞承担着两项可分离的任务，只有第一项值得其成本。门控所丢弃的内容在另一方向上同样未被度量：一个因训练中未标记任何内容而被其拒绝的算子，正是我们保留的最可靠算子。

D 机制消融的完整结果

两条分支均在循环自身的候选上运行于循环内部，因此二者都不是对另一分支所编写算子的重新评分。二者读取相同的训练集划分标签，且任一分支中均无门控调用触发其中止保护。召回率门控分支所施加的下限要求算子至少在池中仍遗漏的 140 个故障类别中的 30% 上触发，同时在必须通过的样本上误报率不超过 2%。仅窄分支还获得了每目标双倍的一级尝试次数，即每个种子 48 次，而完整循环为 24 次，将其 144 次与八次完整运行所产生的所有一级尝试合并，得到 336 次。

E 完整的门账本

在表 3 的 336 次一级尝试中，有 124 次通过了所有早期筛选，这些是门控所见并绘制于图 3 的尝试；目标首先在窄接口处尝试，因此升级运行中的大多数咨询都是窄接口的，若将运行记录视为单一接口则会过度归因。八个运行中获准的六个算子，每个在其获准前都有一条记录在案的一级拒绝。该记录同时充当了准入下限的敏感性分析：在受助情况下

≥ 2 窄接口将接纳其 124 次咨询中的 55 次，因此下限是接口必须达到的标准，而这些接纳将转移至何处尚未衡量。




图 3：准入门的每一次咨询，而不仅仅是最终获准进入的那些，按候选者在门所读取的训练划分上帮助完成的任务数量进行统计。获准需要三项任务，且只有更宽的接口能够达到这一要求，无论窄运行是否可能升级。

F 选择准则：注册、鲁棒性与类别权重

在评估景观之前，所有六项准则、其公式及预测排名均已预先记录，因此表 4 报告的是每个选项实际落点，而非刻意寻找的选项。

表 4：六项先验准则及一项事后补充准则，对照图 2 所列举的景观。单元格内容为（26 算子池，35 算子池）在各同行集设置下的表现。C6 为我们采用的规则，且未做任何调优：0.1877 为训练划分的类别比例 n_{TP}/n_{FP} 。C7 为归纳基线自身的准入信号，也是唯一未预先注册的行。

criteria	training split only	landscape percentile, 4 cells	held-out Δ
C1	$J = TP - FP$ (the original)	56.3 / 42.3 / 85.7 / 4.9	+0.0079 ... +0.0220
C2	the endpoint's own formula on training data	76.2 / 66.2 / 78.3 / 82.1	+0.0184 ... +0.0209
C3	per-task capped J	14.5 / 29.5 / 50.4 / 44.1	+0.0098 ... +0.0138
C4	precision-flavoured $(TP - FP) / (TP + FP + 1)$	1.5 / 0.5 / 0.4 / 0.1	+0.0043 ... +0.0062
C5	size-penalised $J - 2k$	40.8 / 29.6 / 32.5 / 2.3	+0.0072 ... +0.0130
C6	balanced accuracy $\equiv TP - (n_{TP}/n_{FP}) FP$	98.7 / 91.1 / 92.7 / 94.1	+0.0236 ... +0.0286
C7	label-prediction F_1 (not registered)	89.2 / 85.7 / 85.0 / 85.8	+0.0218 ... +0.0244

第 5.3 节背后的两项注册鲁棒性检验在此完整报告。（i）分半法。在留出任务的一半 A 上选择准则，并在另一半 B 上报告结果，划分方式在注册时固定，在 B 半自身景观的 85.2 – 98.2 百分位处，4 个单元格中有 4 个重新选择了 C6，而 J 为 9.3 – 82.4 百分位。（ii）逐基线检验，这也使得 HumanEval+ 成为该准则的最佳池。端点可按任务精确分解，因此相同的留出任务可按来源零成本重新划分，重组后达到报告景观的最大值，精确到 6 位小数。在 HumanEval+ 上（其与训练划分仅共享算子池），C6 排名位于 95.9 / 97.6 / 95.9 / 97.5 百分位，为三个池中最佳，在 4 个单元格中有 4 个击败 J ，并在配对检验中于 4 个单元格中有 3 个与其显著分离。以三种方式解读相同的 428 个任务并未为整体比较增加独立证据，但确实排除了增益源于标签所属基准的假象。

扫描（图 4）。 $\lambda = n_{TP}/n_{FP}$ 从 MBPP 训练划分中读取，因此问题在于它是这些标签的特性，还是选择端点的一般特性。在表 4 的四个单元格中，每个单元格对 λ 的十二个值进行了评分。HumanEval+ 的最优平台在 4 个单元格中有 4 个包含训练划分比例， $\lambda=1$ 每次都严格位于其外，而 $\lambda=0$ （完全忽略误报）从未严格更优。

G 同行依赖的判定

二级算子读取 ctx ，而 ctx 由任务的每个原始样本构建，因此其判定是该同行选民群体的函数，而非仅取决于候选者本身。这两种效应已分别测量。

the class weight is a property of the endpoint, not of the MBPP+ label ratio




图 4：在 $TP - \lambda FP$ 中扫描 λ ，每个留出池一行：HumanEval+的最优平台（阴影部分）包含 $\lambda = n_{TP}/n_{FP} = 0.1877$ ，该值从 MBPP+训练划分中读取，并排除 J 的 $\lambda = 1$ 。

面对冻结的选民群体，35 个算子中没有一个改变任何裁决，无论是留出集还是训练集，这是我们检查而非假设的精确恒等性，也是此处每个数字所依赖的基础。面对从 3424 个样本增长到 12744 个样本的选民群体，所有 35 个算子至少改变一个裁决，新增 1996 个标记，移除 440 个标记，其中一个算子在代码从未改变的行上将其自身标记数增加了一倍以上。因此，更宽的接口以牺牲指标稳定性为代价换取了判别能力，而部署的二级算子必须像我们固定我们的选民群体那样固定其选民群体。

变化的方向是一致性异议必须回答的问题，且该方向是有利的。在增长的选民群体下，每个冻结选择从 $+0.0009$ 增加到 $+0.0036$ ，且没有实质性的重新排序，因此算子是从同伴上下文中读取信号，而非为了共识本身而追踪共识。在同一次抽取中，第 5.3 节的五算子规则（在训练划分上选择且从未重新选择）在来自三个从未拟合过的生成器的 9320 个候选项上得分 $+0.0220$ ($z=8.34$, $p=0.0010$, $+79/-12$ 个任务。两次抽取的原始增量不可直接比较，因为更深的抽取空间更大（余量 0.0995 对 0.0424），因此两者均以其自身余量的分数形式引用：22.1% 对 18.9%。算子在那里是样本外的；任务列表则不是。

H 冗余性与多样性否决

图 5 展示了第 6 节背后的冗余性证据。否决本身被实际运行，而不仅仅是提出：在第 B 节的折叠轮换下，它在 $m=2, 3, 4$ 处等于或低于普通并集 ($+0.0065/+0.0057/+0.0047$ ，损害 9/11/11 个任务（相对于并集的 8 个），且开发折叠在 9 个方向中的 5 个方向上禁用了它。在第 6 节的重发现密集池上，冻结规则在 5 个新颖算子上成立 ($+0.0040$)。它换来的是简约性——7 个算子达到 26 个算子的效果——而非质量。它在准入时否决标记集重叠，这使其成为比第 6 节的行为新颖性门控更弱的工具，且两者的失败方式不同。

I 评判器与归纳基线

评判器，四种配置。裁判看到任务陈述、提示可见的断言以及候选源代码，这恰好是第 1 级接口操作（任务，代码），而永远不会看到隐藏测试套件。只有通过可见检查的 1762 个不同的（任务，候选）对才会被评判，因为只有这些是端点评分的对象。配置涉及两个模型：一个生成操作符的模型，以及更便宜的 Claude Haiku 4.5，后者也是第 3 节中的候选生成器之一，因此便宜的裁判会对自己的一些输出进行评分；还有两种提示：一个单词的裁决，以及一个先给出理由再给出裁决的形式，其措辞说明了训练划分本身的类别平衡，因此裁判没有获得操作符被拒绝的任何统计信息。回复按（池，任务，源哈希）缓存，未指明裁决的回复不会标记任何内容，这是保守的解读；对缓存进行两次重新评分会重现字节完全相同的输出。




图 5: (a) 对所有 63 个种子子集和 720 种到达顺序进行精确稀疏化, 而非自助法: 在这六个种子中接纳的 23 个操作符分为 16 个不同的行为类别, 曲线并未饱和。(b) 所示的补救措施, 实时运行: 在接纳时被行为新颖性项阻止的 11 个候选者各自的结果。下方条带从三个层面解读冗余: 文本、行为和策略, 为每个层面给出不同的类别、Jaccard ≥ 0.8 处对所占比例以及最大类别。

表 5: 裁判作为度量, 在表 1 的端点和零假设上。精确率、召回率和准确率将裁判视为对相同对的分类器, 这与端点增量是不同的问题。最后两行与表 1 中的两个参考相同。

model	prompt	Δ	p	+/-	% headroom	precision	recall	accuracy
cheap	reason-then-verdict	+0.0070	0.0010	+21/-8	16.5	0.403	0.161	0.818
cheap	one word	+0.0044	0.0130	+20/-9	10.3	0.369	0.199	0.807
author	reason-then-verdict	+0.0040	0.0040	+14/-8	9.5	0.677	0.154	0.845
author	one word	+0.0036	0.0060	+17/-7	8.6	0.600	0.203	0.844
hand-written comparator		+0.0069	0.0130	+22/-10	16.3			
loop-authored operator		+0.0065	0.0010	+20/-6	15.4			

在表 5 中, 先推理后回答提高了便宜模型的增量并降低了其标记数量, 而两种作者模型配置的增量大约是该值的一半。作为分类器, 作者模型更精确 (0.677 对 0.403) 但用处更小, 这再次体现了第 3 节中的召回率主导地位: 一个精确但在大多数坏候选上保持沉默的裁判无法改变可供抽取的内容。在两种先推理后裁决的配置中, 没有回复未能指明裁决; 单字裁决配置在 1762 个中分别丢失了 1 个和 5 个, 未指明裁决的回复不会标记任何内容。

重叠与成本。

表 6 通过同一代码对两组标志及其布尔组合进行评分。在查看并集增量之前先看重叠部分: 只有当各部分存在分歧时, 优于各部分的并集才值得关注, 而此处它们确实存在分歧。

表 6: 循环生成的运算符与最佳评判配置作为标志集, 在同一点上的表现。两者之间的杰卡德相似系数为 0.105: 27 fl, 共有 257 个标志重合。

flag set	Δ	p	+/-	flags
operator only (set difference)	+0.0010	0.0679	+8/-6	99
judge only (set difference)	-0.0007	0.6563	+9/-9	131
both agree (intersection)	+0.0053	0.0010	+13/-1	27
either (union)	+0.0073	0.0010	+27/-12	257
operator	+0.0065	0.0010	+20/-6	126
judge	+0.0070	0.0010	+21/-8	158

成本来自调用账本而非估算。生成运算符的那次运行进行了 47 次调用, 此后它评分的每个候选都无需额外成本; 全部八次运行共进行了 376 次调用。

评判器对每个候选消耗一次调用且无任何摊销，因此对该端点的一次完整遍历需要 1762 次调用， $37.5 \times$ 生成运算符的那次运行或 $4.7 \times$ 全部八次运行（包括两次未接纳任何候选的运行），且每个未来候选都将再次产生该成本。

验证器归纳。相同的作者模型、相同的系统提示、相同的四个屏幕且顺序一致、相同的训练划分、端点和空假设。有两处有意改变：候选的委托依据是平衡的随机标注样本而非签名冲突，且候选因能预测标签而被接纳，要求至少 3 个真阳性且精确率至少为 0.5，这是已部署门控的三个受助任务和受助 $>$ 受损在标签空间中的对应物。表 7 报告了两种接口在三种组合方式下的结果。

表 7：各接口下的验证器归纳。组合方式包括已接纳检查的简单并集、 ≥ 2 选 k 投票，以及训练 F_1 最佳的单一检查；只有最后一种规则是实践者无需留出标签即可应用的。

	level 1, detect(task, code)	level 2, detect(task, code, ctx)
candidates commissioned	2 runs $\times$ 24	1 run $\times$ 16
admitted	2	6
union of the admitted checks	+0.0016 ($p=0.19$)	+0.0053 ($p=0.0120$)
≥ 2 -of- k vote	+0.0000 ($p=0.52$)	+0.0053 ($p=0.0010$)
best single by training F_1	+0.0016 ($p=0.19$)	+0.0054 ($p=0.0060$)

第 1 级失败的方式与我们自己的第 1 级搜索相同：48 次调用，2 次接纳，一次运行未接纳任何候选，且没有任何组合能与空假设区分开。第 2 级有效。各屏幕在此基线上的触发方式与在我们自己的作者路径上相同，因源模式拟合和提示分发而拒绝候选，因此它未获得我们的方法所不具备的任何豁免。其最佳单一检查达到 +0.0074，高于比较器和我们的运算符，但该检查是通过读取留出增量选出的，并非合法的头条结果。合法的解读是警示：在此端点上，通过更宽接口的预测拟合接纳所能达到的上限至少与我们报告的一样高。

标签预测作为组合准则。同样的准则替换可以在完全没有模型和采样的情况下进行，因为第 5.3 节的枚举将所有子集都放入内存，因此准则是对有限集合的全序，其选择、增量和百分位数是计数而非估计。以 J 作为工具检查，其最大参数在所有四个单元中重现了已发布的结果。

表 8：在表 4 的四个单元中，四种准则的留出 Δ and 精确景观百分位数。C8 是在至少 3 个真阳性的相同下限下的精确率，并且在该下限下是退化的：它在每个单元中都选择相同的两个算子集合，标记了十个任务。

criterion	26 ops, full	35 ops, full	26 ops, frozen	35 ops, frozen
C1, $J = TP - FP$	+0.0155 (56.3)	+0.0140 (42.3)	+0.0220 (85.7)	+0.0079 (4.9)
C6, balanced accuracy	+ 0.0286 (98.7)	+ 0.0253 (91.1)	+ 0.0236 (92.7)	+ 0.0236 (94.1)
C7, label-prediction F_1	+0.0244 (89.2)	+0.0231 (85.7)	+0.0219 (85.0)	+0.0218 (85.8)
C8, precision	+0.0038 (0.0)	+0.0038 (0.0)	+0.0038 (0.3)	+0.0038 (0.1)

表 8 在表 4 的六种准则基础上增加了两种准则，其中一种胜过 J ：C7 在三个单元中击败它，在第四个单元中打平，并且当算子池从 26 个增长到 35 个时不会崩溃，而 J 会。因此，第 5.3 节测量的差距部分可以通过相关工作已经使用的准则来恢复，而 C6 在所有四个单元中恢复了更多。C7 每次选择与 J 不同的子集，与 J 的选择相比，杰卡德系数为 0.22 到 0.67，因此这不是同一排名的两个名称。