

Aspire: 模型能否从模糊目标中自我进化?

¹ByteDance Seed, ²Singapore University of Technology and Design, ³M-A-P, ⁴TokenWave.AI

完整作者列表见贡献部分

Abstract

人类学习的许多重要形式始于一个模糊的目标，例如“成为更优秀的物理学家”或“提升研究能力”。学习者必须解读目标、识别能力差距、决定如何学习，并判断自己是否真正有所进步。相比之下，现有关于大语言模型自我进化的研究通常从人类指定的任务和评估度量出发，将自我进化简化为优化一个明确的目标，而非决定学什么以及如何学。本文提出 Aspire，一个面向模糊目标驱动的自我进化基准。Aspire 仅提供一个自然语言能力目标，而下游评估任务保持隐藏。智能体必须通过选择数据和更新方法、构建训练与验证信号，并决定何时进行评估，来将目标具体化。Aspire 在统一的交互式环境中同时支持模型权重进化和智能体框架进化，并在一个由专家编写的隐藏集合上评估所得系统，该集合包含 520 个条目，涵盖六个目标。实验表明，模糊目标将搜索努力重新导向目标解读。当前智能体能够常规完成训练和框架编辑循环，但权重层面的提升仍然稀少且不稳定，最强的进化框架仍低于工程化的 Qwen-Agent 参考系统。智能体经常在数据不匹配的情况下训练，并信任狭隘的自我评估，因此局部提升无法迁移到隐藏评估中，持续的搜索和训练还可能抹去先前的改进。

Date: September 1, 2026

Project Page: <https://self-developing-agents.github.io/>

1 引言

人类学习的许多重要形式始于一个宽泛的能力方向，而非预定义的基准、训练集或完全可计算的奖励函数。例如，一个希望成为更优秀物理学家的学生，不仅要选择教材、练习和学习方法，还要识别自身知识差距、确定优先发展的能力，并判断学习是否带来了真正的进步。因此，自主学习涉及三个相互关联的决策：改进什么、如何改进，以及如何验证改进。

现有关于大语言模型自我进化的研究主要聚焦于第二个决策。在给定具体任务、评估脚本和成功度量的情况下，大语言模型智能体已经能够收集数据、运行训练，并根据反馈修订训练后策略。PostTrainBench [20]、LaMDAgent [29]、Evo-Memory [25] 和 SEAL [37] 表明，现代大语言模型能够自主搜索针对指定目标的有效优化路径。因此，这些系统是在人类将诸如“提升数学推理能力”这类宽泛的能力请求，转化为诸如“提升在 AIME 上的性能”这类固定的任务级目标之后才开始运行的（图 1(a)）。任务格式、难度范围、度量和成功标准均已预先定义：智能体搜索的是如何改进，而非追求何种能力目标。当现有基准趋于饱和或不再




图 1 从显式任务优化到模糊目标驱动的自我进化。(a) 在显式任务定义下，人类指定任务格式与构成、难度锚点、度量和成功标准，智能体主要搜索如何改进一个固定目标。(b) 在仅有宽泛能力方向的情况下，智能体必须诊断能力差距、分解子目标、构建学习与验证信号，从而决定优化什么以及如何优化。官方评估项保持密封；外部评估检验智能体自建代理上的增益能否迁移到预期能力。

反映新兴的能力差距时，人类仍须发现新的弱点，将其转化为任务，并设计相应的基准和奖励。这为持续的递归自我改进留下了一个核心问题：

仅给定一个模糊目标，且没有智能体可见的任务规范或可分解的奖励？

我们将这一问题形式化为模糊目标驱动的自我进化。如图 1(b) 所示，“模糊”并非指含糊不清或定义不完善，而是指一个宽泛的能力方向，尚未被具体化为固定的任务级目标和评估度量。因此，智能体必须诊断能力差距、形成中间目标、构建学习与验证信号，并联合搜索优化对象与优化方法。这一扩展的决策空间引入了一种更深层的失效模式：智能体构建的代理指标上的提升可能无法转化为预期能力的真正改进。因此，评估模糊目标驱动的自我进化需要一个目标对齐的外部评估器，其任务级规范和测试项对智能体保持隐藏。

为研究这一问题，我们提出了 Aspire，一个用于模糊目标驱动的自我进化的基准。Aspire 仅提供自然语言能力目标，而下游评估任务保持隐藏。智能体自行决定如何将目标操作化，包括使用何种数据和更新方法，以及是否及如何进行中间验证。Aspire 支持两个层面的进化：模型权重和支持智能体的框架。一个统一的面向智能体的工具允许智能体搜索、下载、导入或合成数据；启动不同形式的训练；运行自我评估；并管理候选分支与选择。控制器负责数据管理、作业调度、资源隔离和检查点验证。Aspire 记录由此产生的决策、行动和自我评估轨迹，并在一个隐藏的、由专家编写的 520 个测试项集合上评估所得系统，该集合涵盖知识扩展和能力强化两个方向的六个目标。根据协议的不同，智能体要么不获得任何中间评估分数，要么仅获得有界的聚合分数；它永远无法访问评估项、参考答案或逐项反馈。

我们将实验组织为从受控比较到自主演进的递进过程。研究问题一（RQ1）通过在匹配的起始模型、更新工具和计算预算下，用模糊的能力目标替代显式的训练后任务，来分离目标设定的影响。研究问题二（RQ2）随后进入完整的 Aspire 设置，探究从指令微调检查点出发的智能体能否将模糊目标转化为保留在权重层面的能力增益。研究问题三（RQ3）保持模型权重不变，转而演化对象

至支撑代理框架。

研究问题一：当明确的后训练任务被模糊的能力目标取代时，会发生何种变化？模糊目标将搜索努力转向目标解读与操作化，在所评估的设置中，其总体结果低于相应的明确任务参照。

研究问题二：从指令微调检查点出发，大语言模型能否通过自主权重更新将模糊目标转化为保留的能力提升？智能体通常能完成数据选择、训练和检查点生成，但在隐藏评估数据上超越基线的改进仍然罕见，且无法通过持续搜索可靠保留。

研究问题三：除模型权重外，智能体能否利用自身实现进化？在模型权重固定的情况下，智能体能够生成功能性的后继框架，用于目标解读、工具使用和自我评估，但即便是所观察到的最强后继框架，仍不及工程化的通义千问智能体参考框架。

本文的贡献有三方面。首先，我们将目标操作化——即将宽泛的能力目标转化为可训练的目标、学习信号和验证标准——形式化为自主后训练中缺失的一个维度。其次，我们引入了一个具有密封评估和最小交互环境的基准，用于模型权重和框架更新。第三，我们提供了结果和轨迹证据，揭示了执行更新与保持目标对齐改进之间的差距。

2 背景

大多数智能体基准（agent benchmark）在问题已经可执行之后才开始：任务已明确，奖励或评判器已定义，执行脚手架已固定。这种设置对于受控比较是必要的，但它掩盖了在实际部署中占主导地位的工作。在工业界，这些工作分布在多个角色中——包括解决方案架构师、应用工程师和平台工程师——但其最近最明显的结晶是前向部署工程师（forward-deployed engineer, FDE），这一头衔由 Palantir 推广，并已被前沿模型公司采用 [18, 19]。前向部署工程师嵌入在部署环境中，将通用模型转变为能够与客户的数据格式、工作流程和操作约束协同工作的系统。该角色的成功标准不是演示或基准分数，而是部署的系统是否真正被使用、持续运行，并在面对失败时不断改进。前向部署工程师角色在前沿模型和数据平台公司中的增长反映了一个简单的事实：一个有能力的模型还不是一个可工作的系统 [1, 23]，而如今这一差距主要由人类工程师来弥补。

从模型的角度来看，前向部署工程师的工作提供了基准设计者通常预设的三类结构。首先，目标是模糊的：非正式的部署需求必须转化为具体的目标、约束和成功标准。其次，反馈信号可能缺失或不可靠：在任何人能够确定系统是否在改进之前，必须构建测试、评判器、迹（trace）或其他验证机制。第三，执行系统可能不以可用的形式存在：未来任务运行所需的工具、上下文管理、状态、生命周期逻辑和验证接口必须被构建、适配，并随着需求变化而维护。

Aspire 聚焦于第一层及其所启动的能力提升过程。当部署需求仅指定一个宽泛的能力方向时，模型能否确定自身应学习的内容，将该方向转化为数据、训练计划和验证信号，并通过更新模型权重或智能体框架来实现真正的能力增长？S₃ Gym 研究交互经验能否在可执行验证下被判断和复用，HarnessDev 研究模型如何构建和维护承载它们的系统，而 Aspire 则隔离出宽泛部署需求如何被转化为具体学习目标并实现为能力增长。

3 Aspire：自我进化基准与交互环境

自我进化只有在进展保持外部可测量的情况下才能被研究。因此，Aspire 保留一个评估器作为控制器端的科学仪器，同时对其基准定义、条目和

可分解奖励对智能体保密。有界的聚合结果近似稀疏的部署反馈，而不会将评估器变成智能体可见的任务规范或可直接训练的监督来源。

本节通过三个组件实例化该设置。我们首先定义有界进化回合以及模型和框架可操作的表层（第 3.1 节）。然后，我们呈现一个涵盖六个目标的隐藏评估集（第 3.2 节）以及一个最小交互环境，智能体通过该环境构建、测试并安全保留更新（第 3.3 节）。实验特定的反馈、资格、资源和发布核算与 RQ2 结果一同出现在附录 C 中。

3.1 任务定义与进化表层

战役与回合。令 $G \in \mathcal{G}$ 表示一个模糊目标：一个自然语言能力目标，不指定训练任务、数据集或优化过程。与显式任务设置不同，智能体必须通过将 G 转化为自身的数据、更新目标和验证标准来执行目标操作化。一场战役固定了控制器端的实验契约

$$\Gamma = (G, \mathcal{E}_G, J, \mathcal{A}, B, \Sigma), \quad Y_r^{\text{in}} = (M_r, H_r, D_r),$$

其中 $\mathcal{E}_G$ 版本化评估器绑定于 G , J 在需要基于模型的评分时，其评判者为 $\mathcal{A}$ 类型化行动契约， B 活动预算，以及 Σ 预先声明的终止选择规则。传入状态包含模型权重 M_r 、智能体框架 H_r （围绕模型的运行时指令、工具策略、工作流、记忆与验证逻辑），以及决策模型 D_r 该评估器引导搜索过程。评估器——包括其项目、答案、评分标准、路由元数据和评分配置——在整个活动期间存在，但从不作为智能体观察的一部分。研究问题一（RQ1）是训练后基准（PostTrainBench）的模糊目标对应版本：它保留每个原始密封任务评估器，同时用宽泛的能力描述替换明确的基准标识符。这些特定任务的结果与研究问题二（RQ2）和研究问题三（RQ3）中使用的六目标评估（Aspire）保持分离，且不进行合并。

一轮进化是一个有界的搜索与提交片段，在此期间决策模型是固定的，而非一次工具调用。形式上，对于轮次 r 中的每个交互步骤 j ， $D_{r,j} = D_r$ 成立。结合固定的创建者侧脚手架 C_r, D_r ，解释 G 并可在终止前提出多个数据操作、更新、验证、分支和候选状态。因此，不同候选体现了不同的目标操作化。轮次终止后，控制器可重用 D_r 或显式提升一个经过验证的训练后代。记 $\mathcal{D}_r$ 为这些后代的集合，下一轮的选择遵循 $D_{r+1} \in \{D_r\} \cup \mathcal{D}_r$ ；任何交接仅在后续轮次开始。

已释放的交互。设 $E_{r,j}$ 为交互步骤 j 之前的私有控制器状态。智能体仅接收已释放视图 $q_{r,j}$ ，其中包含公共历史、生命周期状态、合法请求类型、已批准标识符以及剩余预算的有界投影。在每一步， D_r 和 C_r 根据目标和已释放历史提出一个动作，控制器在更新其私有状态之前验证该请求。被接受的请求创建相应的持久转换；被拒绝的请求返回类型化错误，而不创建工件或分数。详细反馈仅限于智能体自身的验证数据；评估反馈遵循第 3.2 节中协议特定的信息边界。

两个进化表面。Aspire 将被进化的组件与指导搜索的策略分离。报告的两个表面是

$$\mathcal{S}_M(H_0, D_r) = \{(M, H_0, D_r) : M \in \mathcal{M}\}, \quad \mathcal{S}_H(M_0, D_r) = \{(M_0, H, D_r) : H \in \mathcal{H}\}.$$

表 1 Aspire 中的演化表面。被研究的组件发生变化，而 D_r 、控制器和评估器在该轮内保持固定。

Setting	Mutable component	Fixed during evaluation
Weight evolution (RQ1–RQ2)	Model weights M	H_0, D_r , controller, evaluator
Harness evolution (RQ3)	Agent harness H	M_0, D_r , controller, evaluator

每个权重候选记录其父检查点、注册数据、更新规范以及用于智能体自身验证数据的来源。每个测试装置候选记录其父版本、内容哈希和编辑来源。我们使用 Self 表示冻结的基础检查点作为决策模型 D_0 的配置，而候选更新源自同一检查点 M_0 。训练后代的晋升是轮次之间的显式操作，绝不是轮次内的自动替换。

3.2 隐藏的、查询受限的评估集

本小节描述在 RQ2 和 RQ3 中使用的六目标隐藏评估；RQ1 则使用原始的密封、任务特定的 PostTrainBench 评估器，在模糊目标契约下进行，且将这些结果汇总到 Aspire 中。

在没有智能体可见基准的情况下进行测量。从模糊目标中学习，如果没有外部进展标准，就无法评估。因此，Aspire 在控制器侧保留一个基准，同时向智能体隐藏其任务级规范。隐藏评估集是科学仪器，而非智能体可见的学习契约：它使研究人员能够测量智能体选择的更新是否提升了预期能力，而不披露哪些任务定义了成功。它包含 520 个专家编写的评估项目，涵盖六个模糊目标；每个目标在其对应的项目上进行评估，智能体从未见过这些项目，并且协议不返回项目级结果——仅在允许反馈时返回一个聚合分数。

六个目标的测试条目。520 个条目覆盖六个目标：科学与学术推理（75 条）；人文与社会科学知识（110 条）；健康与医学推理（100 条）；数学推理（126 条）；逻辑、可靠性与指令遵循（89 条）；以及学术与科学写作（20 条）（图 2）。第五个目标有意设计为复合目标；当前方案并不声称将逻辑推理、抗幻觉能力和指令遵循作为三个可独立识别的目标来测量。相反，它将其视为一个综合的可靠性目标。每个评估条目恰好属于一个目标，每个目标在其各自的评估切片上单独计分和报告，而不是将所有六个目标的条目级分数汇总为一个单一分数。写作条目是 20 个顶层任务包，可能产生多个由评估者评分的回答，因此研究问题 3（RQ3）分别报告任务宏平均和示例微平均的聚合结果。

构建与质量控制。领域专家从零开始编写每个候选条目。GPQA [21]、MMLU-Pro [24] 和 MedQA [15] 仅作为任务格式、领域覆盖和大致难度的参考；这些基准中的任何条目均未被复制、改写或收录。每个候选条目保留作者和修订来源、参考答案或固定评分标准，以及预定义的评分规则。独立审查会移除不正确、不完整、规格不足或评分不稳定的条目。

通过筛选的候选条目需经过盲测多模型难度校准、精确与语义去重、针对参考基准的重叠审计、评分器绑定以及本地端到端验证。在可能的情况下使用确定性或结构化评分；开放式回答使用活动固定的基于评分标准的评判器。隐藏评估集绑定到不可变的版本化清单，运行中的活动从不更改该版本。详细的筛选、难度级别、重叠检查、评分器分配和版本管理见附录 A.1 和附录 A.2。

信息边界与解释。智能体接收以自然语言表述的模糊目标，并可自行构建训练数据与验证数据。它无法访问隐藏评估项、参考答案、路由标签、评分标准、候选输出或评判迹。每个注册用于训练的数据集在进入训练后端之前，都会检查其与隐藏评估集的重叠情况。评估仅返回协议允许的聚合分数，以及在固定评估器与评判配置下剩余的查询配额。

在自适应反馈协议下，有限数量的查询可对同一目标的相同项目进行评估。由此产生的聚合分数构成一个稀疏的黑盒结果通道：智能体可利用这些分数来选择后续更新、分支或停止点，但无法观察项目内容，也不能基于其内容进行训练。因此，该协议衡量的是在有限自适应反馈下的性能，而非在




图 2 隐藏评估集的构建与信息边界。顶部：专家撰写的候选项目经过独立评审、盲难度筛选、重叠与重复审计、评分器绑定及不可变版本控制。底部：520 个评估项目覆盖六个目标。项目与评判资产仅由控制器持有；协议不暴露任何项目级结果，仅暴露其允许的聚合分数。

一个未经触碰的后选择测试。在仅最终协议下，智能体可训练多个检查点，但在提交其唯一最终检查点之前不会收到任何评估分数，因此该分数无法指导后续更新。在 RQ3 中，框架候选在首次评估前即被冻结，所得分数不会返回给其创建者。

我们使用分布外（Out-of-Distribution, OOD）这一术语来描述独立撰写、被排除在智能体训练数据及其自身验证数据之外、并在智能体构建的学习信号之外进行评估的评估项目。这并不断言其边缘文本分布与模型预训练语料库不相交。该协议旨在减少直接内容泄漏，并测试智能体能否从稀疏结果反馈中将模糊目标操作化，同时保持学习工件与测量工件之间可审计的分离。

3.3 一个具有安全保留机制的最小交互环境

Aspire 在保留受控计算和真实模型更新的同时，刻意分离了策略复杂性与基础设施复杂性。智能体控制如何将给定目标操作化，以及如何更新模型或框架；控制器则吸收凭证、存储约定、分布式作业机制和恢复逻辑。这保持了接口的简洁性，同时不预设学习策略。

面向智能体的执行工具。智能体不操作命令行、不下载训练仓库、不组装运行时，也不实现分布式执行。相反，Aspire 暴露了一个带有类型化、可组合动作的单一智能体工具（图 3）。通过工具调用，智能体可以搜索、下载或导入公共数据集；合成并注册新数据；启动监督微调（SFT）或分组相对策略优化（GRPO），并采用低秩适配（LoRA）或其他允许的配置；查询作业状态；在其自身的验证数据上构建并运行检查；以及对谱系进行分支或停止。智能体仍然选择数据、更新方法、参数和控制流，而控制器将这些选择转化为受管的后端操作。这种设计最大限度地减少了附带工程工作，同时保留了从模糊目标进行自我进化所要测试的策略决策。

最小动作与信任边界。对于权重进化，智能体选择数据、更新方法、超参数、父检查点，以及是否继续、分支或停止。对于框架进化，它使用自身数据编辑运行时提示、工具策略、工作流、记忆或验证程序，并冻结一个版本化候选。接口仅暴露语义动作——注册、训练或编辑、验证、评估、分支和终止——同时隐藏后端机制。它保留了




图3 最小交互环境与结果协议。权重候选遵循数据-训练-验证路径，而框架候选遵循编辑-冻结路径。统一的智能体工具在智能体自身数据上暴露可组合的数据、训练、状态和验证动作；控制器将它们映射到受管后端，并强制执行预算和谱系约束。评估仅返回协议允许的聚合结果。跨轮次，控制器可以重用当前决策模型，或显式提升经过验证的训练后代；任何交接仅在后续轮次开始时进行。

第 3.2 节定义的信息边界：智能体做出战略决策，控制器执行并约束这些决策，评估项保持隐藏。

已验证候选与可审计执行。权重候选只有在控制器验证其父项、注册数据、准入更新及完整检查点发布之后才可评估。测试框架候选必须在评估前进行版本化并冻结。无效、不完整、外部或智能体自创的工件不能进入评分谱系。已接受的操作记录来源、候选谱系、资源使用、聚合提交及最终选择。完整的操作模式、恢复及后端实现细节属于系统工件；面向实验的核算规则见附录 C。

候选结果与安全保留。设 Y^{in} 为传入状态， $\mathcal{K}$ 为本轮产生的已验证候选。对于候选 k ，我们将原始分数变化定义为

$$\Delta^{\text{raw}}(k) = \hat{s}_{\Gamma}(Y(k)) - \hat{s}_{\Gamma}(Y^{\text{in}}),$$

该变化可能为正或负。最佳评估检查点是得分最高的已评估检查点；选定检查点是在活动预先声明的资格与完成规则下得分最高的合格检查点。对于分数门控的权重演化，控制器仅在 $k^* \neq \perp$ 且 $\Delta^{\text{raw}}(k^*) > 0$ 时保留选定检查点 k^* ；否则回滚至 Y^{in} 。因此，结果状态 Y^{out} 在前一种情况下为 $Y(k^*)$ ，否则为 Y^{in} 。因此，

$$\Delta^{\text{ret}} = \hat{s}_{\Gamma}(Y^{\text{out}}) - \hat{s}_{\Gamma}(Y^{\text{in}}) \geq 0.$$

非负保留改进源于安全回滚，因此是一种选择结果，而非证明每次尝试更新都能提升能力。测试框架候选则在冻结后与固定模型权重进行比较；其效果可能为负，且不意味着部署或递归交接。所报告实验的完整资格、平局处理、终止及聚合规则见附录 C.1。

4 实验与分析

我们围绕第 1 节提出的三个问题组织实验。**RQ1** 探讨模糊目标如何改变后训练结果和搜索轨迹，并与显式任务设置进行对比。**RQ2** 探讨大语言模型能否通过权重更新将模糊目标转化为能力提升。**RQ3** 探讨在运行时模型权重固定时，智能体测试框架本身能否演化。这三项研究共同从刻画目标规范的影响，推进到模型演化，最终到围绕模型的系统演化。

4.1 设置

研究问题一改变了目标规格，并使用原始的 PostTrainBench 评估器。研究问题二在六个模糊目标上采用两种互补协议：仅最终协议包含 24 次运行，不提供中间评估分数，每个模型-目标对报告两次最终运行的算术平均值（平均@2）；自适应反馈协议包含 30 个配置-目标单元，并测试反馈引导的检查点搜索。研究问题三在固定运行时模型和隐藏评估集的情况下改变测试框架。

我们分别报告研究问题二的两个协议。在研究问题三中，每个冻结测试框架执行三次以测量运行时变化，而非三次独立的进化运行。详细的预算、评估器设置和结果定义见附录 C。

4.2 研究问题一：模糊目标如何改变后训练

问题。相对于显式任务设置，模糊目标如何改变后训练结果和搜索轨迹？

设置。标准 PostTrainBench 会指明下游基准，从而指定智能体应优化的内容。我们用广泛的能力描述替换该标识符，同时保留后训练接口和原始任务评估器。由此产生的智能体必须显式或隐式地选择具体目标、代理训练任务和验证方法，此外还需进行更新本身。我们使用已发布的 PostTrainBench 分数作为参考，并仅在过程比较中匹配了显式任务和模糊目标契约下的 Claude Opus 4.8 轨迹。其他运行元数据也可能不同，因此以下结果描述的是观察到的差异，而非隔离仅由提示引起的因果效应。任务、模型和配对标准见附录 B。

主要结果：模糊目标的最终分数总体较低，但任务层面的变化各异。图 4(a) 显示，在模糊目标提示下，Claude Opus 4.8 达到 27.07，而 PostTrainBench 中 Claude Opus 4.8 Max 的官方参考分数为 32.90；GPT-5.6 达到 29.58，而 GPT-5.6 的官方参考分数为 36.23。然而任务层面的模式有所不同：在模糊目标提示下，Claude Opus 4.8 在 HumanEval 和 BFCL 上得分更高，而 GPT-5.6 在 GSM8K 上得分更高。因此，我们在解释总体差距时不假设任务层面存在一致的退化。

轨迹模式一：模糊目标与不同的资源使用相关。在匹配的克劳德·欧普斯 4.8 运行中，模糊目标轨迹在每个匹配运行对中记录了多出 2,109 秒的决策模型思考时间和多出 0.61 小时的图形处理器空闲时间，而主动训练和评估时间减少了 1.27 小时（图 4(b)）。对智能体可见的任务材料和代理评估脚本的访问变得 $2.98\times$ 和 $2.39\times$ 一样密集。在涵盖六个共享设置的单独轨迹级样本中，工具动作的平均数量没有增加（从 188.5 到 179.2），而低秩适应在模糊目标下使用得更频繁。这些描述性变化与更多的目标操作化工作和更少的主动更新时间一致，但并未证明其中一项取代了另一项，也未确定哪项选择导致了最终得分差距。

参考比较：强显式任务系统使用不同的搜索配置。在模糊目标提示下，克劳德·欧普斯 4.8 执行 3.54 次评估对应 6.17 次训练启动，即每次启动 0.57 次评估。官方 GPT-5.6 执行 39.21 次评估对应 14.91 次启动，即每次启动 2.63 次—— $4.6\times$ 反馈密度（图 4(c)），提供了更多测试、拒绝和从更新中分支的机会。官方克劳德·欧普斯 4.8 最大版遵循不同的配置：其 2.89 次评估和 5.14 次训练启动产生每次启动 0.56 次评估，几乎相同




图 4 研究问题一最终得分和轨迹比较。(a) 官方后训练基准参考中克劳德·欧普斯 4.8 最大版和 GPT-5.6 的得分，以及七个基准上的模糊目标得分。(b) 在匹配的克劳德·欧普斯 4.8 对中，模糊目标轨迹显示更多的决策和图形处理器空闲时间以及更少的主动图形处理器工作。(c) 在模糊目标提示下，克劳德·欧普斯 4.8 每次训练启动获得的评估反馈少于官方 GPT-5.6，而官方克劳德·欧普斯 4.8 最大版具有几乎相同的反馈密度。面板 (c) 是描述性跨系统参考，而非匹配的提示效应。精确值和计算见附录 B。

与模糊目标提示下的克劳德·欧普斯 4.8 相比，但它记录了 165,851 个思考字符，而官方 GPT-5.6 为 30,895 个。这些跨系统统计描述了两种强显式任务配置，而非隔离目标模糊性：官方 GPT-5.6 具有密集的评估反馈，而官方克劳德·欧普斯 4.8 最大版具有大得多的记录推理量。

对研究问题一的回答。相对于显式任务引用，模糊目标将搜索范围从如何优化扩展到优化什么以及如何优化。在匹配的克劳德·欧普斯 4.8 运行中，模糊目标与更多的目标操作化工作和更少的主动更新时间相关，而其综合得分仍低于显式任务引用。

4.3 研究问题二：模糊目标驱动自定向权重演化

问题。从经过指令微调的检查点出发，仅给定模糊目标的大语言模型能否确定要学习的内容，并通过指导对该检查点的迭代更新来提升自身能力？这一出发点更贴近实际的自演化场景，即一个通用模型必须在保留指令微调所获得行为的同时改进自身。

设置。与研究问题一适应预训练模型不同，研究问题二的两个设置均从指令微调检查点开始，并允许迭代训练。我们将每个初始指令微调检查点称为基模型，其初始评估得分称为基得分。这是一个具有实际重要性的设置：更新应增加与目标相关的行为，同时不破坏指令微调已编码的有用行为。仅最终协议测试开环执行，而自适应反馈协议测试使用稀疏综合得分的搜索。尽管系统可以在后续轮次中将训练后的后代提升为决策模型，但所有报告的运行均保持初始决策模型不变；因此，证据涉及自适应权重搜索而非递归决策模型替换。在两种协议中，评估聚焦于单一目标，不衡量每个无关能力的保留情况。

仅最终协议。Qwen3.5-4B 自优化和 Qwen3.5-9B 自优化各自在两次独立执行的终态运行中优化全部六个目标，共产 24 次运行。对于每个模型-目标对，我们报告 Avg@2——即算术

Final-only protocol (24 runs): mean change from base score

Each point averages two runs; the evaluation score is returned only after final-checkpoint submission.




图 5 回滚前仅最终协议相对于基得分的平均变化。每个点是某个模型-目标对两次独立执行的终态运行的算术平均值。Qwen3.5-9B 的科学与学术推理是唯一两次运行均值高于基得分的组合。各组成运行的得分见附录 C.3。

两个最终检查点分数的平均值——而非两次中的最佳值。一次运行可在 40 个图形处理器（GPU）小时内启动多个训练任务，但只能提交一个最终检查点用于隐藏评估集的评估。两次运行的重复使最终估计较少依赖于任何单次运行。该协议并未隔离决策模型规模，因为决策模型、基础模型和基础分数在 4B 与 9B 之间共同变化。

仅最终结果：仅有一个两次运行的平均值超过基础分数。所有 24 个仅最终运行均完成了其单一最终检查点评估（图 5）。以每个模型-目标对作为报告单位，Qwen3.5-4B 有 0/6 的平均结果高于其基础分数，Qwen3.5-9B 有 1/6。唯一正面的配对是科学与学术推理：两次运行均从 45.33 上升至 48.00，因此两次运行的平均值为 48.00，即比基础分数高 2.67 分。在配对层面，这是所有 12 个模型-目标对中唯一正面的平均值。在单次运行层面，3/24 的最终检查点超过其基础分数，而回滚在其余 21 次运行中保留了基础模型。单次终端运行和每个目标的结果见附录 C.3。

自适应反馈协议。自适应反馈协议探究稀疏的聚合评估分数能否引导一个不断改进的多检查点轨迹。决策模型根据迄今观察到的分数选择公共数据、更新方法、训练计划以及何时评估或分支。在自我（Self）设置中，初始的 Qwen3.5-4B 或 Qwen3.5-9B 检查点保持为固定的决策模型，同时训练后代检查点。GPT-5.6 Luna、Terra 和 Sol 作为同一 Qwen3.5-4B 基础模型的外部决策模型。符合条件的检查点可以针对某个目标在隐藏评估项目上获得重复的聚合分数，但智能体永远不会看到这些项目或逐项反馈。

自适应搜索结果：产生一个训练后的检查点是常见的；产生一个高于基础目标分数的分数是罕见的。在 30 个配置-目标单元中，每个配置-目标单元运行一次，28 个产生了经过评估的检查点，21 个满足预先声明的来源、探索、完成和终端记录要求，从而成为符合条件的检查点（图 6 和图 7(a)）。只有两个单元的最佳评估检查点分数超过基础分数。Qwen3.5-4B Self 将科学从 44.00 提升至 45.33，但没有 Self 单元

隐藏评估项目上的分数：自适应反馈协议（30 个单元）大：最佳评估检查点得分·小：基础得分·填充：得分 / 基础得分




图 6 所有 30 个自适应反馈配置-目标单元在隐藏评估集上的得分：两个自我配置和三个外部决策模型设置。大值为最佳评估检查点的得分；小值给出基础得分。两个没有评估检查点的单元显示回退的基础得分用于核算，但用阴影表示并标注为无检查点。对于有评估的单元，颜色编码最佳评估检查点得分除以基础得分。打印值保留原始得分尺度。

保留一个高于其基础得分的模型；Terra 将 Qwen3.5-4B 数学从 17.86 提升至 20.10，并且是唯一一个检查点得分高于基础得分、通过资格审核并在回滚后保留的单元。因此，智能体经常闭合可执行的训练循环——数据、更新、检查点和评估——但大多数产生的检查点并未保持基础得分。45.33 的科学得分是来自一次自适应反馈运行的最佳评估检查点，并未被两个仅最终阶段的 Qwen3.5-4B 最终检查点复现。由于反馈和检查点选择契约不同，我们将这些协议视为互补设置而非重复试验。保留的 Terra 得分是在同一固定评估切片上使用重复聚合反馈选出的；在没有单独确认切片的情况下，它只能作为反馈引导选择的证据，而非独立复现的能力提升。

轨迹模式 1：表面上的进展可能是从训练引起的退化中恢复。22 个具有多个评估检查点的单元包含 62 次连续转换：28 次上升、13 次持平、21 次下降。后续搜索在 14/22 个单元中优于第一个评估检查点，但这并不意味着得分高于基础得分。例如，Qwen3.5-4B 自我配置在数学上从 0.79 提升至 1.75 再到 2.38，但仍远低于其 17.86 的基础得分（图 7(c)）。因此，谱系内的正斜率可能描述的是从训练引起的退化中恢复，而非高于基础的改进。转换计数是汇总的描述性统计，因为各单元贡献的检查点数量不同。

轨迹模式二：更多搜索并不意味着更好的搜索。使用相同的 Qwen3.5-4B 基础模型，外部决策模型产生了不同的目标级结果。在它们评估的最佳检查点中，Luna 在人文学科（7.27）和逻辑（20.39）上得分最高，Terra 在数学（20.10）和写作（16.01）上得分最高，Sol 在科学（30.67）和医学（11.00）上得分最高。在六个目标中的五个里，即使这些分数中的最高值也仍低于基础分数。Sol 搜索范围最广，产生了 33 个评估检查点，消耗了 76.56 个已结算的训练 GPU 小时，但没有一个超过其对应的基础分数。Terra 在自适应选择切片上找到了唯一保留的改进；其后来的数学后代从 20.10 下降到 2.78，然后恢复到 18.17。因此，更大的搜索量并不能确保获得高于基础的分数，而持续优化





图 7 自适应反馈结果与轨迹分解。在 30 个单元中，28 个产生了评估检查点，21 个产生了合格检查点，1 个产生了保留的改进（a）。在 62 次连续的轮内检查点转换中，28 次增加（b），但即使是单调的自优化轨迹也可能远低于基础分数（c）。

Score on hidden evaluation items vs. cumulative settled GPU-hours

Same Qwen3.5-4B model; $y = \text{checkpoint score} / \text{base score}$; 100% marks the base model.



Training GPU-hours are accumulated at each hidden evaluation. X-ranges are panel-specific; failed or unscored evaluations are omitted.

图 8 使用相同 Qwen3.5-4B 基础模型的四种配置的自适应反馈分数-计算轨迹。分数按每个目标的基础分数归一化，曲线按已结算的训练 GPU 小时连接评估检查点。

可能导致回归而非产生更好的后代，因此需要检查点选择和回滚（图 8）。

在仅最终协议中，三次运行持续了 16-20 个训练作业，消耗了 26.570-32.286 GPU 小时，但它们提交的最终检查点在 4B 数学上仅得 0.159 分，在 9B 数学上得 2.540 分，在 9B 写作上得 0 分。由于该协议下不评估中间检查点，这些轨迹无法建立单调退化或识别最佳早期检查点；它们表明，沿着最新检查点谱系的盲目延续可能以糟糕的最终检查点告终。

观察到的失败模式：数值标签 SFT 与答案格式崩溃相关。Self 轨迹在领域和答案格式上都表现出集中性。在自适应反馈协议中，Qwen3.5-4B Self

在 30/32 个数据集导入事件中使用了 GSM8K 或 Hendrycks 数学数据，包括针对科学、逻辑和写作的运行。在仅最终协议中，提交的五个检查点是在数字标签 MMLU SFT 上训练的：所有 21,000 个训练目标都是个位数标签，所有 279 个对应的评估输出都是个位数。它们的得分分别为 0、0、0、6.141 和 0。所有五个检查点都表现出相同的模式。这不是随机化的因果比较，但它记录了一种与训练诱导的回归相关的具体答案格式不匹配。由于所有 24 项最终评估均未出现项目错误，缺失输出或评估器故障并不能解释总体退化。进一步的核算见附录 C.3；内容相关的解释使用受控访问的源迹。

对 RQ2 的回答。我们观察到的是孤立的、高于基线的目标得分，而非可靠的改进。在 12 个仅最终 Avg@2 结果中，只有一个超过了其基线得分，并且自适应反馈通常产生局部上升的轨迹，但仍低于基线。因此，智能体完成更新循环的一致性高于保持基线性能的一致性；这些目标特定的评估并不衡量无关的能力。

4.4 RQ3：利用进化

问题。在模型权重固定的情况下，一步式利用进化能否提升智能体在学术和科学写作目标上的研究性能？

设计。我们将 Qwen3.5-4B 固定为运行时模型，并使用原始 Qwen-Agent 作为参考利用。在相同的可编辑契约下，Qwen3.5-4B 创建者和 GPT-5.6 Luna、Terra 及 Sol 各自尝试从相同的 H_0 生成一个后继利用 H_1 。Qwen3.5-4B 创建者未生成有效的 H_1 ，根据预先声明的失败规则被赋予零分。三个有效的后继利用各自被冻结，并在学术和科学写作目标的 20 个隐藏评估项目上执行三次；这些得分不会返回给创建者。每个条件有一条创建轨迹，而三次执行衡量的是冻结利用的运行时变化。没有运行将 H_1 进化为 H_2 ，因此该实验评估的是一步式利用生成，而非递归式利用自我改进。

结果：最接近的继任框架在数值上低于固定参考。所有三个有效继任框架在数值上均低于原始千问智能体（Qwen-Agent），后者获得 28.64 任务宏均值和 27.65 示例微均值（表 2）。由太阳（Sol）创建的继任框架最接近，为 27.22/25.97，比参考低 1.42 个任务宏均值点，其次是由大地（Terra）创建的继任框架，为 20.76/20.14，以及由月亮（Luna）创建的继任框架，为 19.32/18.33。

轨迹模式 1：狭窄的智能体验证可能使框架专门针对错误的代理指标。月亮（Luna）通过添加固定的五部分研究答案模板，将创建者设计的八项清单在智能体自身验证数据上的得分从 7/8 提升至 8/8。在两个结构相似的提示也获得 8/8 后，它在大约 40 分钟后停止。该模板使答案在偏差和局限性方面更加明确，但对隐藏评估项的检查表明，它可能将对机制、公式、参数或工程细节的请求重新表述为研究设计问题。因此，验证增益和隐藏评估集上 19.32 的任务宏均值与针对狭窄代理指标的专门化一致，而非广泛改进。

轨迹模式 2：答案审查不能保证输出完整性。大地（Terra）正确地拒绝了一个两遍审查器，因为该审查器捏造了不支持的显著性结果和效应量，但其最终框架保留了另一条失败路径：在计算器调用后，空的最终模型响应导致工具前部分草稿被提交。在一次受检执行中，这发生在两个项目上，并在算术上约占该执行总体下降的 70%。太阳（Sol）在其自身验证数据中跨四种任务类型以及多个提示和工具变体搜索了 3 小时 11 分钟，拒绝了存在幻觉、延迟或工具控制失败的替代方案，即使它们的验证分数更高。其最终编辑仅检查最后一个模型响应是否完整且非空；该检查在 20 个受检评估项中均未触发。因此，它改进了失败处理，但轨迹未显示其带来了任务准确率的提升。详细案例见附录 D。

表 2 研究问题 3：固定千问智能体（Qwen-Agent）参考和继任框架在隐藏评估集上的研究性能。所有可执行框架均使用千问 3.5-4B（Qwen3.5-4B）作为运行时模型。

Configuration	Task macro	Example micro
Original Qwen-Agent reference	28.64	27.65
Qwen3.5-4B Creator (no valid harness)	N/A	N/A
GPT-5.6 Luna successor harness	19.32	18.33
GPT-5.6 Terra successor harness	20.76	20.14
GPT-5.6 Sol successor harness	27.22	25.97

Note: The reference and each valid successor are frozen and executed three times on the same 20 evaluation items; their reported values are execution means. Task macro weights evaluation items equally, whereas example micro weights evaluator-scored examples equally. The Qwen3.5-4B Creator produces no valid harness, so it has no execution mean; its predeclared protocol-level failure score is zero. Per-execution dispersion is not reported, so differences between executable harnesses are descriptive.

对研究问题三的回答。单步式测试框架进化能够产生可执行且行为上有所区别的后继测试框架，但所有三个有效的后继框架在数值上仍低于千问智能体（Qwen-Agent）。它们的轨迹暴露出验证多样性与输出完整性方面的瓶颈：在这一单步、单目标设定下，智能体完成了编辑—测试循环，却未能相对于参考测试框架提升隐藏集的平均性能。

5 相关工作

自训练与自进化方法。自进化方法让模型构建自身学习信号的一部分。STaR [31] 在能产生正确答案的自生成推理链上进行微调；ReST-EM [22] 迭代地进行采样、奖励过滤与再训练；自奖励语言模型（Self-Rewarding LM）[30] 将模型自身用作评判者；SPIN [5] 通过自我博弈进行学习。R-Zero [11] 与绝对零度推理器（Absolute Zero Reasoner）[35] 通过提出问题、解决问题并改进问题，进一步降低对外部数据的依赖；SEAL [37] 则根据下游收益对模型生成的自编辑进行强化。在所有这些情形中，模型协助生成数据、奖励、任务或编辑，但进展仍由具体信号（如正确性、奖励、自我博弈结果或任务收益）来度量。Aspire 与之互补：它不引入新的训练算法，而是检验一个仅被给予模糊目标的模型能否围绕该目标构建有效的学习过程。

自动化后训练与机器学习智能体基准。PostTrainBench [20] 为智能体提供基础模型、评估脚本以及用于数据过滤、训练和超参数搜索的预算；LaMDAgent [29] 同样自动化了迭代式后训练流程。RSIBench-Data [17] 固定目标模型、基准与训练栈，让智能体修改数据策略，并发现大多数持续搜索的结果低于其自身的最佳检查点——这是一种与我们所区分的候选进展与保留收益相关的保留失败。AI4AI-Bench [6] 则让智能体在隐藏评估下重写训练算法，但大多数提交并未改变模型的学习方式。PAST-Bench [27] 检验保留的经验是否通过预期的保存—检索—更新路径改善后续的个人智能体任务。

更广泛的基准如 MLE-bench [2]、MLAgentBench [12] 和 RE-Bench [26] 针对可量化目标衡量机器学习实验与人工智能研发。AIDE [14]、DS-Agent [9] 和 SELA [7] 自动化数据科学与建模流程；ADAS [10] 和达尔文哥德尔机 [32] 改进智能体系统或代码。Hyperagents [33] 使元级修改过程可编辑，Frontis-MA1 [28] 训练专门的元进化智能体，红皇后哥德尔机 [13] 共同进化智能体与评估器，使目标随训练轮次变化。

这些系统使自动化工程可度量，但通常从已可操作的任务、评分或评估器开始。补充的影子评估发现前沿智能体能够完成工程任务而无需推进未发表的研究问题 [16]，一项对 1250 篇自我改进论文的调查指出研究方向设定是使人类留在回路中的瓶颈 [3]。当现有度量饱和或不再代表下一个能力差距时，这一点至关重要。Aspire 隐藏下游任务，衡量智能体能否将宽泛方向转化为在隐藏评估上测得的学习

项目：RQ1 在 PostTrainBench 内隔离这一目标侧差异，RQ2 研究由外部模型或基础模型自身引导的权重演化。

记忆、工作流与技能演化。自我改进也可通过记忆、工具和工作流发生。Evo-Memory [25] 研究记忆的写入、组织与重用；EvoFSM [34] 使用可解释的有限状态工作流编辑；SkillLearnBench [36] 发现外部反馈支持持续技能提升，而仅靠自我反馈可能导致递归漂移。HELIX [8] 重建固定模型的框架，利用经过验证的轨迹更新模型，然后再次重建框架；Co-Harness [4] 交替进行经过验证的框架编辑与基于改进框架产生的轨迹的微调。RQ3 通过询问在运行时权重保持固定时，中介目标解释、工具使用、记忆和自我评估的框架能否演化，将这一研究方向与模糊目标学习联系起来。

6 结论

现代大语言模型智能体能够搜索有效途径以改进指定目标。下一步是确定当没有智能体可见的任务规范或可分解奖励已经将进展操作化时，应当学习什么。我们将此问题形式化为模糊目标驱动的自我进化，并引入 Aspire，它将模糊目标与隐藏评估和可审计轨迹配对。在三项研究中，RQ1 过程切片将模糊目标提示与更多的目标定义工作相关联；自主运行产生被评估检查点的频率远高于保留改进的频率；在不变的运行时权重下，最高的后继利用均值仍低于固定参考值。这些结果表明，为什么进展必须相对于基础模型来判断，而不仅仅是相对于前一个检查点：闭合训练循环尚不等于闭合能力循环。

我们的结论受限于六个目标及其专家撰写的评估项的覆盖范围和评分质量、每个配置-目标单元的一次规范自适应反馈运行，以及仅在受控访问下可用的内容级轨迹证据。更广泛的目标覆盖、重复运行、更新的评估集版本，以及控制漂移和无关能力损失的递归进化，仍然是未来工作的重要方向。

7 贡献

核心贡献者 吴宇浩、张景源、石佳俊

贡献者 张宇轩、雷新平、周俊廷、王泽轩、吴宇辰、周欢、王铎、朴银珠、彭永昌、石云峰、陈进、王佐、刘金凯、刘佳恒

通讯作者 Yuhao Wu

(wuyuhao.621@bytedance.com) Wenxuan

Zhang (wxzhang@sutd.edu.sg) Shen Yan

(sheny@bytedance.com) Wenhao Huang

(huang.wenhao@bytedance.com) Ge Zhang

(gezhang@umich.edu)

参考文献

- [1] Aditya Challapally, Chris Pease, Ramesh Raskar, and Pradyumna Chari. The GenAI divide: State of AI in business 2025. https://www.artificialintelligence-news.com/wp-content/uploads/2025/08/ai_report_2025.pdf, 2025. Industry report.
- [2] Jun Shern Chan, Neil Chowdhury, Oliver Jaffe, James Aung, Dane Sherburn, Evan Mays, Giulio Starace, Kevin Liu, Leon Maksin, Tejal Patwardhan, Lilian Weng, and Aleksander Mądry. MLE-bench: Evaluating machine learning agents on machine learning engineering. *arXiv preprint arXiv:2410.07095*, 2024.
- [3] Mingguang Chen, Licheng Wang, and Bo Qu. Recursive self-improvement in AI: From bounded self-refinement to autonomous research loops, 2026. URL <https://arxiv.org/abs/2607.07663>.
- [4] Zhengyu Chen, Teng Xiao, Huaisheng Zhu, Yige Yuan, Luan Zhang, and Jingang Wang. Co-Harness: Co-evolving harnesses and model weights for LLM agents, 2026. URL <https://arxiv.org/abs/2607.22688>.
- [5] Zixiang Chen, Yihe Deng, Huizhuo Yuan, Kaixuan Ji, and Quanquan Gu. Self-play fine-tuning converts weak language models to strong language models. In *International Conference on Machine Learning (ICML)*, 2024.
- [6] Yizhe Chi, Wenyi Li, Deyao Hong, Xiaoqiu Wang, Mingju Gao, Kaisen Yang, Bingxiang He, Youjie Zheng, Calvin Xiao, and Qinhuai Na. AI4AI-Bench: Benchmarking LLM agents in algorithmic design for recursive self-improvement, 2026. URL <https://arxiv.org/abs/2608.20318>.
- [7] Yizhou Chi, Yizhang Lin, Sirui Hong, Duyi Pan, Yaying Fei, Guanghao Mei, Bangbang Liu, Tianqi Pang, Jacky Kwok, Ceyao Zhang, Bang Liu, and Chenglin Wu. SELA: Tree-search enhanced LLM agents for automated machine learning. *arXiv preprint arXiv:2410.17238*, 2024.
- [8] Tianyu Fan and Chao Huang. HELIX: Model-harness co-evolution for recursive self-improvement, 2026. URL <https://arxiv.org/abs/2608.13951>.
- [9] Siyuan Guo, Cheng Deng, Ying Wen, Hechang Chen, Yi Chang, and Jun Wang. DS-Agent: Automated data science by empowering large language models with case-based reasoning. In *International Conference on Machine Learning (ICML)*, 2024.
- [10] Shengran Hu, Cong Lu, and Jeff Clune. Automated design of agentic systems. *arXiv preprint arXiv:2408.08435*, 2024.
- [11] Chengsong Huang, Wenhao Yu, Xiaoyang Wang, Hongming Zhang, Zongxia Li, Ruosen Li, Jiaxin Huang, Haitao Mi, and Dong Yu. R-Zero: Self-evolving reasoning LLM from zero data. *arXiv preprint arXiv:2508.05004*, 2025.
- [12] Qian Huang, Jian Vora, Percy Liang, and Jure Leskovec. MAgentBench: Evaluating language agents on machine learning experimentation. In *International Conference on Machine Learning (ICML)*, 2024.
- [13] Alex Iacob, Andrej Jovanović, William F. Shen, Daniel Burkhart, Meghdad Kurmanji, Nurbek Tastan, Lorenzo Sani, Niccolò Alberto Elia Venzani, Ambroise Odonnat, Zeyu Cao, Bill Marino, Xinchu Qiu, and Nicholas D. Lane. The Red Queen Gödel Machine: Co-evolving agents and their evaluators, 2026. URL <https://arxiv.org/abs/2606.26294>.

- [14] Zhengyao Jiang, Dominik Schmidt, Dhruv Srikanth, Dixing Xu, Ian Kaplan, Deniss Jacenko, and Yuxiang Wu. AIDE: AI-driven exploration in the space of code. *arXiv preprint arXiv:2502.13138*, 2025.
- [15] Di Jin, Eileen Pan, Nassim Oufattole, Wei-Hung Weng, Hanyi Fang, and Peter Szolovits. What disease does this patient have? a large-scale open domain question answering dataset from medical exams. *arXiv preprint arXiv:2009.13081*, 2020.
- [16] Peter Kirgis, Sayash Kapoor, Andrew Schwartz, Stephan Rabanser, David Africa, Konstantinos Voudouris, Viet Nguyen, Toby Pilditch, Magda Dubois, Harry Coppock, Cozmin Ududec, Nitya Nadgir, Matilda Orona, Tilman Bayer, Derrick Chan-Sew, Yue Ling, Abhishek Shetty, Helen Toner, Gillian Hadfield, Seth Lazar, Steve Newman, Shoshannah Tekofsky, Rishi Bommasani, and Arvind Narayanan. Can AI agents conduct open-ended AI research? Early evidence from two case studies, 2026. URL <https://arxiv.org/abs/2607.27191>.
- [17] Fanqing Meng, Lingxiao Du, Qiguang Chen, Ziqi Zhao, Haocheng Lu, Mengkang Hu, and Michael Qizhe Shieh. RSIBench-Data: Benchmarking data-centric research for recursive self-improvement, 2026. URL <https://arxiv.org/abs/2607.25886>.
- [18] Gergely Orosz. What are forward deployed engineers, and why are they so in demand? <https://newsletter.pragmaticengineer.com/p/forward-deployed-engineers>, 2025. The Pragmatic Engineer.
- [19] Palantir Technologies. A day in the life of a Palantir forward deployed software engineer. <https://blog.palantir.com/a-day-in-the-life-of-a-palantir-forward-deployed-software-engineer-45ef2de257b1>, 2020.
- [20] Ben Rank, Hardik Bhatnagar, Ameya Prabhu, Shira Eisenberg, Karina Nguyen, Matthias Bethge, and Maksym Andriushchenko. PostTrainBench: Can LLM agents automate LLM post-training? *arXiv preprint arXiv:2603.08640*, 2026.
- [21] David Rein, Betty Li Hou, Asa Cooper Stickland, Jackson Petty, Richard Yuanzhe Pang, Julien Dirani, Julian Michael, and Samuel R. Bowman. GPQA: A graduate-level google-proof q&a benchmark. *arXiv preprint arXiv:2311.12022*, 2023.
- [22] Avi Singh, John D. Co-Reyes, Rishabh Agarwal, Ankesh Anand, Piyush Patil, Xavier Garcia, Peter J. Liu, James Harrison, Jaehoon Lee, Kelvin Xu, Aaron Parisi, Abhishek Kumar, Alex Alemi, Alex Rizkowsky, Azade Nova, Ben Adlam, Bernd Bohnet, Gamaleldin Elsayed, Hanie Sedghi, Igor Mordatch, Isabelle Simpson, Izzeddin Gur, Jasper Snoek, Jeffrey Pennington, Jiri Hron, Kathleen Kenealy, Kevin Swersky, Kshiteej Mahajan, Laura Culp, Lechao Xiao, Maxwell L. Bileschi, Noah Constant, Roman Novak, Rosanne Liu, Tris Warkentin, Yundi Qian, Yamini Bansal, Ethan Dyer, Behnam Neyshabur, Jascha Sohl-Dickstein, and Noah Fiedel. Beyond human data: Scaling self-training for problem-solving with language models. *Transactions on Machine Learning Research (TMLR)*; *arXiv:2312.06585*, 2024.
- [23] The New Stack. Why OpenAI and Anthropic are hiring forward deployed engineer teams. <https://thenewstack.io/forward-deployed-engineers-ai/>, 2026.
- [24] Yubo Wang, Xueguang Ma, Ge Zhang, Yuansheng Ni, Abhranil Chandra, Shiguang Guo, Weiming Ren, Aaran Arulraj, Xuan He, Ziyang Jiang, Tianle Li, Max Ku, Kai Wang, Alex Zhuang, Rongqi Fan, Xiang Yue, and Wenhui Chen. MMLU-Pro: A more robust and challenging multi-task language understanding benchmark. *arXiv preprint arXiv:2406.01574*, 2024.
- [25] Tianxin Wei, Noveen Sachdeva, Benjamin Coleman, Zhankui He, Xuying Ning, Mengting Ai, Yunzhe Li, Jingrui He, Ed H. Chi, Chi Wang, Shuo Chen, Fernando Pereira, Wang-Cheng Kang, and Derek Zhiyuan Cheng. Evo-Memory: Benchmarking LLM agent test-time learning with self-evolving memory, 2026. URL <https://arxiv.org/abs/2511.20857>.
- [26] Hjalmar Wijk, Tao Lin, Joel Becker, Sami Jawhar, Neev Parikh, Thomas Broadley, Lawrence Chan, Michael Chen, Josh Clymer, Jai Dhyani, Elena Elicheva, Katharyn Garcia, Brian Goodrich, Nikola Jurkovic, Holden Karnofsky, Megan Kinniment, Aron Lajko, Seraphina Nix, Lucas Sato, William Saunders, Maksym Taran, Ben West, and Elizabeth Barnes. RE-Bench: Evaluating frontier AI R&D capabilities of language model agents against human experts. *arXiv preprint arXiv:2411.15114*, 2024.
- [27] Shuhan Xue, Zixin Ding, Yichen Shen, Yinjie Wang, Zhenfei Yin, Yingcheng Wu, Yuxin Chen, Mengdi Wang, and Ling Yang. PAST-Bench: Benchmarking the foundations of recursive self-improvement in personal agents, 2026. URL <https://arxiv.org/abs/2608.04003>.
- [28] Junlin Yang, Che Jiang, Yu Fu, Tianwei Luo, Can Ren, Weizhi Wang, Kaikai Zhao, Hongyi Liu, Yuxin Zuo, Yuru Wang, Yuchen Fan, Kai Tian, Zhenzhao Yuan, Xiaojian Lin, Li Sheng, Rushi Qiang, Guoli Jia, Xingtai

- Lv, Ermo Hua, Dianqiao Lei, Youbang Sun, Ning Ding, Bowen Zhou, and Kaiyan Zhang. Frontis-MA1: Training an AI4AI model towards recursive self-improvement in machine learning engineering, 2026. URL <https://arxiv.org/abs/2607.28568>.
- [29] Taro Yano, Yoichi Ishibashi, and Masafumi Oyamada. LaMDAgent: An autonomous framework for post-training pipeline optimization via LLM agents, 2025. URL <https://arxiv.org/abs/2505.21963>.
- [30] Weizhe Yuan, Richard Yuanzhe Pang, Kyunghyun Cho, Xian Li, Sainbayar Sukhbaatar, Jing Xu, and Jason Weston. Self-rewarding language models. In *International Conference on Machine Learning (ICML)*, 2024.
- [31] Eric Zelikman, Yuhuai Wu, Jesse Mu, and Noah D. Goodman. STaR: Bootstrapping reasoning with reasoning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
- [32] Jenny Zhang, Shengran Hu, Cong Lu, Robert Lange, and Jeff Clune. Darwin Gödel Machine: Open-ended evolution of self-improving agents. *arXiv preprint arXiv:2505.22954*, 2025.
- [33] Jenny Zhang, Bingchen Zhao, Wannan Yang, Jakob Foerster, Jeff Clune, Minqi Jiang, Sam Devlin, and Tatiana Shavrina. Hyperagents, 2026. URL <https://arxiv.org/abs/2603.19461>.
- [34] Shuo Zhang, Chaofa Yuan, Ryan Guo, Xiaomin Yu, Rui Xu, Zhangquan Chen, Zinuo Li, Zhi Yang, Shuhao Guan, Zhenheng Tang, Sen Hu, Liwen Zhang, Ronghao Chen, and Huacan Wang. EvoFSM: Controllable self-evolution for deep research with finite state machines, 2026. URL <https://arxiv.org/abs/2601.09465>.
- [35] Andrew Zhao, Yiran Wu, Yang Yue, Tong Wu, Quentin Xu, Yang Yue, Matthieu Lin, Shenzhi Wang, Qingyun Wu, Zilong Zheng, and Gao Huang. Absolute Zero: Reinforced self-play reasoning with zero data. *arXiv preprint arXiv:2505.03335*, 2025.
- [36] Shanshan Zhong, Yi Lu, Jingjie Ning, Yibing Wan, Lihan Feng, Yuyi Ao, Leonardo F. R. Ribeiro, Markus Dreyer, Sean Ammirati, and Chenyan Xiong. SkillLearnBench: Benchmarking continual learning methods for agent skill generation on real-world tasks, 2026. URL <https://arxiv.org/abs/2604.20087>.
- [37] Adam Zweiger, Jyothish Pari, Han Guo, Ekin Akyürek, Yoon Kim, and Pulkit Agrawal. Self-adapting language models. *arXiv preprint arXiv:2506.10943*, 2025.

附录

A 基准构建与实验约定

A.1 目标与评估集统计

该基准定义了六个模糊目标，每个目标与隐藏评估集中一组互斥的项目配对（表 3）。自适应反馈协议评估所有六个目标。在当前版本中，逻辑性、可靠性和指令遵循构成一个复合目标；本文不将其三个组成部分视为单独识别的目标。

表 3 六个模糊目标及其对应的评估项目。所有 520 个顶级项目均由领域专家新撰写。

Vague goal	Evaluation items	#Items
Scientific and academic reasoning	Science and academic reasoning	75
Humanities and social-science knowledge	Humanities and social sciences	110
Health and medical reasoning	Health and medicine	100
Mathematical reasoning	Mathematical reasoning	126
Logic, reliability, and instruction following	Logic, reliability, and instruction following	89
Academic and scientific writing	Academic and scientific writing	20
Total unique items	Six non-overlapping groups	520

学术与科学写作目标的项目包含 20 个顶级任务包，计为 20 个评估项目。其评估器可能在一个任务内产生多个评分示例，因此 RQ3 同时报告任务宏平均和示例微平均两种聚合方式。

A.2 污染控制细节

污染控制始于作者环节。领域专家从零开始编写每个条目，而命名的公开基准仅作为任务原型和难度参考。在冻结隐藏评估集的某个版本之前，流程会移除报告组内部及跨报告组的精确重复和语义重复，并审计与参考基准的重叠情况。数据集注册随后对隐藏评估集应用第二道精确和语义重叠关卡，检测到的匹配项在数据进入监督微调（SFT）、群组相对策略优化（GRPO）或持续预训练之前即被拒绝。

种子-2.0、GPT-5.2 和 Gemini-3 在共享的盲筛协议下独立回答每个候选项。L0–L3 表示未能通过的模型数量；超时和服务错误会重试，而不计为失败。该筛选用于校准难度，并与作者环节和重叠审计相互独立。经过审查、评分器绑定和本地端到端验证后，隐藏评估集在清单和 SHA-256 下被冻结。更正会创建新版本；正在进行的活动继续使用创建时固定的版本。

A.3 提示契约

提示由版本化的设置配置文件渲染，而非针对每次运行临时编写。模糊目标提示包含自然语言能力目标、正在训练的模型、行动契约、预算，以及隐藏评估集仅返回聚合分数的规则。它不透露评估条目的内容、答案、评分标准、目标路由标识符或逐条反馈。例如，数学目标要求智能体改进困难的多步推理、精确计算和清晰论证，而不指明评估条目。显式任务契约额外披露已批准的任务格式、难度锚点、度量和成功标准，同时保持相同的内容边界。每次活动都绑定其设置标识符、提示配置文件版本、渲染提示的 SHA-256 和实验身份。这些绑定在创建和恢复时都会检查，

因此模糊目标运行无法在显式任务契约或不同提示版本下静默恢复。

B 完整的研究问题一（RQ1）分数与轨迹核算

表 4 比较了图 4(a) 中可视化的精确数值。官方分数是系统级 PostTrainBench 参考值；模糊目标列是我们的结果。它们共享基准定义和聚合权重，但不被视为仅提示的因果对。

表 4 针对 RQ1 的 PostTrainBench 分数比较。数值为百分比；加权平均值使用官方基准权重。

Benchmark	Official Claude Opus 4.8 Max	Vague goal Claude Opus 4.8	Official GPT-5.6	Vague goal GPT-5.6
AIME 2025	10.83	5.83	7.50	3.75
GPQA Main	28.35	24.89	30.13	27.04
HealthBench	31.68	12.62	27.39	9.93
HumanEval	47.33	56.63	63.95	56.40
GSM8K	68.87	66.98	69.48	74.35
ArenaHard	36.09	13.07	26.40	21.72
BFCL	47.13	58.63	94.38	79.38
Weighted average	32.90	27.07	36.23	29.58

匹配过程核算。过程比较将显式任务和模糊目标运行配对，这些运行具有相同的决策模型、基础模型、基准叶节点和试验索引。我们排除了反作弊命中以及仅返回回退基础的运行对。匹配的 Claude Opus 4.8 比较包含 48 个匹配运行对。每个试验占用一个 H20 沙箱 GPU 最多 10 小时。我们将占用时间划分为决策模型等待时间（在此期间沙箱 GPU 空闲）和其余工作流使用的活跃时间。

对于 Claude Opus 4.8，模糊目标提示与每个匹配运行对中决策模型思考时间增加 2,109 秒、空闲时间增加 0.61 小时相关，同时活跃时间减少 1.27 小时。相应的绝对均值从 0.6 小时空闲时间变为 1.2 小时，从 8.0 小时活跃时间变为 6.7 小时。图 4(b) 将这些差值转换为分钟以便统一视觉尺度；显示的值使用未取整的测量结果。

行为归一化。叙事轨迹在不同条件下的长度差异显著，因此动作提及按每 10,000 字符进行归一化，并且仅当命中率和密度变化一致时才予以解读。在模糊目标提示下，阅读任务定义的密度上升 $2.98\times$ ，检查评估脚本的密度上升 $2.39\times$ ，低秩适配（LoRA）/参数高效微调（PEFT）的使用密度上升 $3.09\times$ 。LoRA 出现在 89.8% 的模糊目标运行中，而在匹配的显式任务运行中仅占 24.1%；33 对匹配运行从不用 LoRA 转为使用 LoRA，反向转换为零。我们另外通过两种轨迹导出共有的六个匹配设置（21 条轨迹）上的轨迹级工具调用，验证了 Claude Opus 4.8 的模式。平均动作计数从每条轨迹 188.5 变为 179.2。因此，我们将更长的模糊目标叙事解读为额外的深思熟虑，而非智能体执行了更多工作的证据。训练启动仅从具体的启动命令（如 `accelerate launch` 或 `torchrun`）中计数；对 `train` 和 `sft` 的宽泛关键词匹配不作为动作证据。这些轨迹级调用比第 3.1 节中定义的可接受控制器动作 $a_{r,j}$ 更宽泛。

官方轨迹比较。我们将同一轨迹解析器应用于 112 条已发布的官方轨迹，其中官方 Claude Opus 4.8 Max 和 GPT-5.6 Sol 系统各 56 条。模糊目标 Claude Opus 4.8 平均每条轨迹有 3.54 次评估和 6.17 次训练启动；官方 Claude Opus 4.8 Max 平均为 2.89 次和 5.14 次，而官方 GPT-5.6 平均为 39.21 次和 14.91 次。这些对应每次训练启动的评估次数分别为 0.57、0.56 和 2.63。官方 Claude Opus 4.8 Max 还记录了每条轨迹 165,851 个思考字符，

而官方 GPT-5.6 记录了 30,895 个，支持了正文中深度深思熟虑和高频实验的解释。

C 完整的 RQ2 结果与实验方案

C.1 结果核算与回滚

只有其父检查点、注册数据、准入更新和已发布工件均通过验证的检查点，才能进入被评估的谱系。实验在运行前固定其隐藏评估集、评分器或裁判、解码与聚合规则、查询配额、资格要求、终选选择器以及平局打破顺序。被评估的检查点是指任何具有持久分数的已验证候选者。合格的检查点还需满足预先声明的来源、探索、完成和终选记录要求。被选中的检查点是在固定选择器和平局打破顺序下得分最高的合格检查点。仅当该检查点超过基础分数时，保留的模型才使用它；否则控制器回滚到基础模型。我们分别报告最佳被评估、被选中和保留的结果，因为较高的中间分数可能来自未完成的运行，而非负的保留分数可能反映回滚而非学习。研究问题三（RQ3）则在研究评估前冻结每个测试框架，将其与固定权重的参考模型进行比较，并且不向创建者透露分数。

C.2 反馈与提交协议

模糊目标和显式任务配置使用各自独立的版本化设置，且不能跨实验提交检查点。训练使用注册数据和由控制器解析的父检查点，并且只有来自当前谱系的完全发布的检查点才能被验证或提交。智能体自身的验证数据对智能体可见，且不消耗对隐藏评估集的查询。自适应反馈协议允许在其记录的配额内，对相同的目标特定评估项进行重复的聚合分数查询。仅最终协议不返回任何中间分数，并且每次运行只接受一次最终检查点评估。无效或重复的请求不消耗查询；如果后续部署或评估器阶段失败，已接受的保留仍然计入。任何协议都不会返回隐藏评估项、答案、候选输出、评分标准或裁判推理。

C.3 仅最终协议：模糊目标权重演化

仅最终协议将 Qwen3.5-4B 自身与 Qwen3.5-9B 自身交叉，共六个目标，每个目标分别执行运行 A 和运行 B，总计 24 次运行（表 5）。每次运行可在 40 GPU 小时内启动多个训练任务，但只能提交一个最终检查点用于在隐藏评估集上进行评估。均值是两个最终检查点分数的算术平均值，而非两者取优或来自一个检查点的两个样本。评估器作为本地进程运行，检查点推理使用无思考模式，gemini-3.5-flash 在 8,192 个标记的思考预算和 10% 的失败关闭阈值下进行评判。检查点部署使用八个 GPU，并在评估后清理。

表 5 仅最终协议最终检查点结果。终端增量 Δ_{term} 将均值与基础分数进行比较。数值为回滚前的原始评估分数；均值与 Δ_{term} 由未舍入的分数计算得出，之后才进行显示舍入。

Vague goal	Qwen3.5-4B Self					Qwen3.5-9B Self				
	Base	Run A	Run B	Mean	Δ_{term}	Base	Run A	Run B	Mean	Δ_{term}
Scientific and academic reasoning	44.000	0.000	0.000	0.000	-44.000	45.330	48.000	48.000	48.000	+2.670
Humanities and social sciences	18.820	9.000	5.909	7.455	-11.365	27.450	10.273	9.091	9.682	-17.768
Mathematical reasoning	17.860	16.746	0.159	8.452	-9.408	25.160	0.714	2.540	1.627	-23.533
Health and medicine	87.000	63.000	68.000	65.500	-21.500	87.000	71.000	72.000	71.500	-15.500
Logic, reliability, and instruction following	27.460	21.437	23.754	22.596	-4.864	26.190	6.141	16.338	11.240	-14.950
Academic and scientific writing	19.270	0.000	15.308	7.654	-11.616	22.930	23.588	0.000	11.794	-11.136

所有 24 个提交的最终检查点均在首次评判尝试中完成评估；所有 2,080 个条目输出均非空，且没有条目报告评估错误。在模型-目标报告层面，Qwen3.5-4B 有 0/6 的均值结果高于其基础分数，Qwen3.5-9B 有 1/6。在单次运行层面，相应的

计数为 0/12 和 3/12。科学与学术推理是唯一均值为正的目标：其两次运行各得 48.00 分，并正确回答 36/75 个条目，但仅有 26 个正确条目重叠，且有 20/75 个条目在两次运行中正确性发生翻转。因此，该一致性仅涉及相同 75 个评估条目上的总体方向，而非条目级稳定性或超出这些条目的迁移。原始最终检查点宏平均值从 4B 的 35.735 降至 18.609，从 9B 的 39.010 降至 25.640；回滚后，保留模型在 21/24 次运行中与基础模型相同。

五个提交的检查点使用了数字标签的 MMLU 监督微调。它们选定的训练快照包含 21,000 个单数字目标，所有 279 个对应的评估输出也都是单数字；五个最终检查点的得分分别为 0、0、0、6.141 和 0。三个长尾运行进一步展示了漫长的盲目训练谱系：用于数学的 4B 运行 B 启动了 20 个作业，在提交最终检查点之前花费了 26.570 GPU 小时，最终得分为 0.159；用于数学的 9B 运行 B 启动了 17 个作业，花费了 32.286 GPU 小时，最终得分为 2.540；用于写作的 9B 运行 B 启动了 16 个作业，花费了 30.530 GPU 小时，最终得分为 0。由于只评估最终检查点，这些结果既无法识别最佳中间检查点，也无法建立单调退化路径。

C.4 自适应反馈协议结果

在自适应反馈协议的 30 个配置-目标单元中，28/30 产生了至少一个被评估的检查点。只有两个配置-目标单元的最佳评估检查点得分超过了基础得分：Qwen3.5-4B 自我科学从 44.00 上升到 45.33，而 Terra 优化 Qwen3.5-4B 数学从 17.86 上升到 20.10。Terra 数学检查点是在完整运行选择规则下唯一保留的改进。在至少有两个评估检查点的 22 个配置-目标单元中，62 次连续转换包括 28 次增加、13 次持平、21 次减少。后期搜索在 14/22 的配置-目标单元中超过了第一个评估检查点，但只有 Terra 数学轨迹产生了一个得分超过基础得分的合格检查点。这些是每个配置-目标单元一次运行的描述性单元级结果。

决策模型搜索概况。22 个多检查点轨迹中有 8 个是非递减的。Luna 在 28 个注册计划中的 24 个使用了监督微调，并在 28 个中的 21 个从最新检查点继续，产生了 22 个评估检查点，消耗了 89.57 GPU 小时。Terra 注册了 33 个计划，包括 6 次 GRPO 更新，产生了 19 个评估检查点，消耗了 91.73 GPU 小时。其保留的数学得分 20.10 之后是 2.78，然后是 18.17。Sol 注册了 40 个计划、36 次评估尝试、23 次搜索操作和 12 个不同的数据集名称；它产生了 33 个评估检查点，消耗了 76.56 GPU 小时，但没有一个超过相应的基础得分。

自主导向的代理与更新选择。Qwen3.5-4B 自主模型在 30/32 次数据集导入事件中导入了 GSM8K 或 Hendrycks 数学数据，包括科学、逻辑和写作相关事件；Qwen3.5-9B 自主模型在 11/15 次导入中使用了数学数据，但在数学之外更具目标针对性。它们的更新选择也不同：Qwen3.5-4B 自主模型在 4/12 个计划中使用 GRPO，而 Qwen3.5-9B 自主模型在 9/11 个计划中使用 SFT。两种配置分别生成了 20,396 和 28,135 个代理事件，但仅注册了 12 和 11 个训练计划。这些计数描述了搜索分配情况，本身并不能说明某个检查点为何获得或丧失能力。

C.5 轨迹证据边界

便携式自适应反馈工件包含计数、时间戳、源哈希、资源使用、提交和选择记录，但不包括隐藏评估项、原始模型消息、命令输出和逐项评判理由。确定性提取覆盖每个配置-目标单元，读取 63,973 个代理事件、1,196 个训练事件和 2,194 个阶段事件，并恢复 124 个训练计划和 95 次候选评估尝试。两次独立审查检查了任务级解释。因此，所得结论涉及探索、检查点进展、选择和回滚；逐项因果分析需要受控访问包含内容的迹。

表 6 RQ2-RQ3 的资源核算。训练 GPU 小时数不包括推理、评判、部署和空闲控制器时间。

实验 运行 计划 作业 训练 GPU 小时数 复制与上限
自适应反馈协议 30 124 107 322.610 每个配置-目标单元一次运行；每个配置-目标单元 40 GPU 小时和 10 小时墙钟时间 仅最终协议 24 - 83 149.236 分别执行运行 A 和运行 B/模型-目标单元；每次运行 40 GPU 小时 RQ3 后继框架创建 4 次创建尝试 -- 0.3 个有效后继；每个后继框架执行三次

C.6 计算与资源核算

表 6 总结了运行、计划、作业和已结算的训练 GPU 小时数。自适应反馈协议是一个完整的 5×6 设计，但不是多种子估计。仅最终协议为 Qwen3.5-4B 使用了 59.269 训练 GPU 小时，为 Qwen3.5-9B 使用了 89.967 训练 GPU 小时。RQ3 不更新权重；因此，创建者模型和运行时推理不在训练 GPU 账本之内。

D RQ3 创作者轨迹案例分析

范围与证据边界。该内容层面的分析涵盖三条有效的 GPT-5.6 创作者轨迹，以及针对每个冻结后继框架在隐藏评估集上的一次受检执行。创作者仅能看到其自身的验证数据；评估项和分数不会返回。表 2 报告了三次执行的平均值，而下面的任务级示例则诊断了一次受检执行中的机制。因此，它们是案例证据，而非额外的重复实验或创作者模型的稳定排名。

Luna：在狭窄验证代理上的早停。Luna 在一个带有八项检查清单的验证提示上评估 H_0 。在得到 7/8 的结果后，它添加了一个固定的五部分模板，涵盖研究问题、设计、分析、风险和局限性。编辑后的框架在该提示和两个相似提示上达到 8/8，Luna 在大约 40 分钟后停止。在隐藏评估集上的受检执行中，该模板提高了结构完整性，但将关于机制、公式、参数或工程细节的直接问题重新表述为研究设计问题，而非提供所要求的技术内容。

Terra：审稿人回退且缺少最终答案不变量。Terra 移除了初始的两遍审稿人，因为该审稿人编造了无依据的显著性结果和效应量，然后为假设、模型调用、日志记录和计算器使用添加了更窄的防护措施。然而，它遗漏了一个最终答案不变量：当计算器后的响应为空时，框架会提交工具调用前的片段。因此，两个受检任务返回了 342 和 520 字符的部分草稿，分数从 H_0 下的 75.00 和 52.33 降至 2.57 和 2.91。这些案例约占该次执行中总体下降的 70%。

Sol：更广泛的测试后保守选择。在 3 小时 11 分钟和四种验证任务类型中，Sol 测试了提示长度、工具调用恢复、禁用工具和审查遍次，同时纠正了一个错误的本地参考答案。它因延迟、重复调用、编造数字或评分器遗漏而拒绝了本地更强的变体。所选框架恢复了原始的 Qwen-Agent 策略，并为空的最终响应添加了完整性检查。该检查在 20 个受检评估项上从未触发，支持改进的失败语义而非分数提升。