

递归自改进 (Recursive Self-Improvement)

调研全文报告

从 Good 1965 的智能爆炸猜想到 2026 年的评估器战争与 harness 工业化：29 份精读报告合订

核心论点——执行已经自动化，品味正在被编译，锚是最后的手工业

构建日期：2026-09-04 (首版 2026-08-31)

材料范围：Lilian Weng 《Harness Engineering for Self-Improvement》· Anthropic 《When AI builds itself》· EvoLM · Red Queen Gödel Machine · Who Grades the Grader · ECHO · Darwin Gödel Machine · MOSS · WikiSkill · Continual Harness · A Survey of Self-Evolving Agents (TMLR) · Meta-Harness · Self-Harness · EnvHarness · AutoSaddler · MetaCaster · Prime Agent · iCoder · Metan · Co-Harness · Co-Evolution in Agentic Systems · Gödel Agent · SICA · EvalCEGAR · RHO · 技能进化红海五篇 · 安全治理五篇 · Self-Evolving Coding Agents 综述；前史：Good 1965 · Vinge 1993 · GISAI 2001 · Gödel Machine 2003 · Omohundro 2008 · Chalmers 2010 · IEM 2013 · Superintelligence 2014

配套材料：61 篇英文 PDF + 8 篇起源经典 · 27 篇中译 PDF · 汇总 PPT (report/awesome_rsi_slides.html / .pdf) · 图 1 时间线 / 图 2 分类树 (assets/)

仓库：github.com/asimfish/awesome_rsi

目录

1. 解读报告 00 · RSI 起源：从 Good 到 Bostrom (1965–2014)
2. 解读报告 01 · Lilian Weng 《Harness Engineering for Self-Improvement》
3. 解读报告 02 · Anthropic Institute 《When AI builds itself》
4. 解读报告 03 · EvoLM: Self-Evolving Language Models through Co-Evolved Discriminative Rubrics
5. 解读报告 04 · The Red Queen Gödel Machine: Co-Evolving Agents and Their Evaluators
6. 解读报告 05 · Who Grades the Grader? Co-Evolving Evaluation Metrics and Skills for Self-Improving LLM Agents
7. 解读报告 06 · ECHO: No More Stale Feedback — Co-Evolving Critics for Open-World Agent Learning
8. 解读报告 07 · Darwin Gödel Machine: Open-Ended Evolution of Self-Improving Agents
9. 解读报告 08 · MOSS: Self-Evolution through Source-Level Rewriting in Autonomous Agent Systems
10. 解读报告 09 · WikiSkill: Compiling Agent Experience into Persistent Knowledge for Skill Evolution
11. 汇总报告 · RSI 全景：从哥德尔机到评估器战争 (2025–2026)
12. 解读报告 11 · Continual Harness: Online Adaptation for Self-Improving Foundation Agents
13. 解读报告 12 · A Survey of Self-Evolving Agents
14. 解读报告 13 · Meta-Harness: End-to-End Optimization of Model Harnesses
15. 解读报告 14 · Self-Harness: Harnesses That Improve Themselves
16. 解读报告 15 · EnvHarness: Awakening Static Worlds for Agent Learning
17. 解读报告 16 · AutoSaddler: Automatic Harness Optimization with Durable Updates from Agent Execution Traces
18. 解读报告 17 · MetaCaster: meta-harness 优化在时间序列预测的垂直落地
19. 解读报告 18 · Prime Agent: 自改进 RLM harness 的产品化
20. 解读报告 19 · iCoder: AI 主导开发前沿工业编码模型
21. 解读报告 20 · Metan (Meta^n): 通过涌现深度实现递归自改进
22. 解读报告 21 · Co-Harness: harness 与模型权重的共进化
23. 解读报告 22 · Co-Evolution in Agentic Systems: 以"共进化"为中心轴的综述

- !4. 解读报告 23 · 2024–2025 桥接：从 Gödel Agent 到 SICA
- !5. 解读报告 24 · EvalCEGAR：让评估器从自己的盲点里长出来
- !6. 解读报告 25 · RHO：在黑暗中进化——无任何外部评分的 harness 优化
- !7. 解读报告 26 · 技能进化红海五篇合评：WikiSkill 同月的平行答案
- !8. 解读报告 27 · 安全与治理五篇合评：自进化系统的部署纪律
- !9. 解读报告 28 · Self-Evolving Coding Agents：编码域垂直综述与配套 awesome 列表

Figure 1 · Recursive Self-Improvement: 71 项工作的时间线（1965–2026）

按十个家族分泳道、按 arXiv 首版年月定位（非 arXiv 材料取发布月近似）；★ 为 11 份核心精读材料。1965-2014 为思想史，2015-2022 无收录（断轴），2025-2026 两年集中了 56 项。




图 1 · 71 项工作的时间线：按十个家族分泳道、按 arXiv 首版年月定位（非 arXiv 材料取发布月近似），★ 为核心精读材料；1965–2014 思想史与 2023–2026 工程爆发之间断轴。

Figure 2 · 递归自改进的分类体系 (Taxonomy)

7 个一级维度 · 37 个子类；"锚在哪"是本仓库独有的主轴——三份公开综述都没有这一列。同一工作可出现在多个维度（如 Continual Harness 既是文本层介质，又是免重置时间模式，锚为冻结 PRM）。




图 2 · 递归自改进的分类体系：七个一级维度、37 个子类；"锚在哪"是本仓库独有的主轴。同一工作可出现在多个维度。

解读报告 00 · RSI 起源：从 Good 到 Bostrom (1965–2014)

文献	年份	出处	本仓库归档
I. J. Good, <i>Speculations Concerning the First Ultraintelligent Machine</i>	1965	Advances in Computers, Vol. 6	papers/classics/1965_Good_UltraintelligentMachine.pdf (扫描影印版, 无文本层)
E. Yudkowsky, <i>General Intelligence and Seed AI 2.3</i>	2000– 2001	Singularity Institute (网络文 档)	papers/classics/2001_Yudkowsky_GISAI.pdf (Stafforini 存档 排版版) · Web Archive 原版
J. Schmidhuber, <i>Gödel Machines: Self-Referential Universal Problem Solvers Making Provably Optimal Self- Improvements</i>	2003	arXiv:cs/0309048	papers/classics/2003_Schmidhuber_GoedelMachines.pdf + 中文翻译
N. Bostrom, <i>Superintelligence: Paths, Dangers, Strategies</i>	2014	Oxford University Press (专著)	无 PDF (版权书籍, 只编目)

一句话核心主张

四篇文献合起来给出了 RSI 的完整定义链：**Good 给正反馈直觉，Yudkowsky 给能力构造与持续条件，Schmidhuber 给自指完备的形式化极限，Bostrom 给进入强 RSI 的动力学判据**——半个世纪后 2025–2026 的全部工程实践（本仓库报告 01–19）都在这四个坐标轴内运动。

逐篇拆解

Good 1965：智能爆炸的第一性原理

历史语境：Good 是图灵在布莱切利园的同事与合作者，这篇文章基于他 1962/1963 年的演讲写成，比"AI 寒冬"一词的出现还早十年。核心论证只有三步：(1) 定义超智能机器为"能远超任何人全部智力活动的机器"；(2) 注意到**设计机器本身就是一种智力活动**；(3) 推论：超智能机器可以设计出更好的机器——"there would then unquestionably be an intelligence explosion"。

关键在第二步：它把"智能"从被优化的对象升格为**优化算子本身**。智能提升会提高产生进一步智能提升的能力，由此形成正反馈。Good 同时留下了那句被引用了六十年的警告：超智能机器是"人类需要做出的最后一项发明"——前提是机器足够温顺 (docile)。

Yudkowsky 2000–2001: Seed AI 的三能力与持续条件

GISAI 是网络时代的第一份 RSI 工程蓝图（近书长度的网络文档，从未正式发表）。它明确描述了 Seed AI 必须具备的三种能力：**self-understanding**（理解自身认知架构）、**self-modification**（改写自身源码）、**recursive self-improvement**（改写产生复利）。

对本调研最重要的是它的否定性判据：**单纯让固定优化器运行得更快，并不能维持递归改进**——加速一个不变的搜索过程只有一次性收益；每一级提升必须让系统**看到或实现新的改进机会**，闭环才能持续。这个"每级须开新机会"条件在 2026 年被 Metan (arXiv:2608.24735) 以实证形式重新发现：自改写系统因必须冻结部分编辑机器，实际 meta 深度上限约 2.5——正是"新机会枯竭"的量化形态。

Schmidhuber 2003: 自指完备的形式化极限

Gödel Machine 补上了前两篇缺少的形式化：一台机器，其**寻找 improvement 的机制本身也在可修改集合里面**——包括证明搜索器自己。改写的触发条件是 proof searcher 找到一个形式证明，证明"执行这次自改写"的期望效用严格高于"继续当前策略"；一旦找到，改写立即执行（Global Optimality Theorem 保证这不是贪心陷阱：证明本身已经把未来所有可能的更好改写考虑在内）。

它是理论上干净、工程上不可行的极点：在任何现实环境里，关于自改写收益的形式证明几乎不可获得。但它划定了一个重要边界——**完全自指（连改进机制都可改）在逻辑上是自洽的**，代价是把可行性全部押在证明搜索上。后来的全部工程化工作都是对这个极点的松弛。

Bostrom 2014: crossover 与动力学判据

Bostrom 把 RSI 从机制描述升格为动力学框架：智能增长率 = **optimization power / recalcitrance**（投入的优化能力 ÷ 系统的改进阻力）。optimization power 分解为外部研究人员的贡献与系统自身的贡献；**crossover point** 定义为系统自身贡献开始主导后续改进的时刻——越过这一点才叫 strong recursive self-improvement。只有当正反馈的增益压过随能力增长而增长的 recalcitrance 时，才可能出现 Good 意义上的智能爆炸。

Bostrom 给出了本报告认为整个前史中最锋利的判据："When the AI improves itself, it improves the thing that does the improving"——检验一个系统是否在做 RSI，不是看它能否反复改进自身，而是看**一次改进是否同时提升了系统发现、验证和实现下一次改进的能力**。反复改进只是迭代；让"改进能力"本身进入优化闭环才是递归。

四篇连成的一条线

环节	文献	给出的东西	2026 年的回声
为什么会爆	Good 1965	正反馈直觉：设计机器也是智力活动	Anthropic >80% 代码由 Claude 写（报告 02）
怎么构造	GISAI 2001	三能力 + "每级须开新机会"的持续条件	Metan 的 meta 深度 2.5 上限（报告 10 insight 4）
逻辑极限	Gödel Machine 2003	完全自指自洽，但押注在不可得的证明上	DGM 把"可证明更优"松弛为"经验验证更优"（报告 07）
何时算真 RSI	Bostrom 2014	crossover：自身贡献主导后续改进	"评测测的是模型还是壳"（报告 18）；工业界尚无人声称越过 crossover

与本调研的连线

1. **DGM (报告 07) 是 Gödel Machine 的直系工程化后代**：名字直接致敬，核心松弛是把"proof searcher 找到收益证明才改写"换成"改了先跑基准、经验上更好就保留"——用统计置信替代形式证明，用档案多样性对冲单点错误。整个 2025–2026 谱系都活在这次松弛的红利与代价（评估器成为新的单点故障，报告 05）里。
2. **Bostrom 的 crossover 判据是报告 02 的正确读法**：Anthropic 披露内部 >80% 代码由 Claude 写，但按 crossover 定义这仍是弱 RSI——改进方向、评估标准与合并权仍由人类研究员主导。iCoder（报告 19）把人类介入压缩成"高密度低频接口"，是朝 crossover 方向可测量的一步，但接口本身仍是人写的。
3. **Yudkowsky 的持续条件预言了锚定纪律的必要性**：GISAI 说每级提升必须开出新机会，但没说谁来判定"这是不是真提升"——2026 年的答案（报告 05：评估器塌缩与真进化观测等价，必须外置人工锚）恰好补上了这个缺口：没有锚，系统看到的"新机会"可能全是评估器的幻觉。
4. **Good 的正反馈在宏观层面仍未被证实**：报告 10 insight 8 指出微观加速（单任务提效）与宏观节奏（前沿模型发布间隔、论文产出率）之间存在实证鸿沟——六十年后，intelligence explosion 依然是一个未被观测到的外推。

解读报告 01 · Lilian Weng 《Harness Engineering for Self-Improvement》

项目	内容
来源	lilianweng.github.io/posts/2026-07-04-harness/ （2026-07-04，约 31 分钟阅读量级长文）
作者	Lilian Weng（Thinking Machines 联创，前 OpenAI 安全副总裁，Lil'Log 博主）
性质	领域综述 + 个人判断：把 2023-2026 年 auto-research、自改进 agent、进化式程序搜索三条线统一组织到" harness 工程 → RSI"这一问题之下
定位	本次调研的总纲：其余 8 份材料（Anthropic 文章 + 七篇论文）都能在这篇的分类框架里找到坐标

一句话核心主张

RSI 的近期现实路径不是模型直接改写自己的权重，而是**改进围绕模型的 harness**——即编排执行、决定模型如何思考规划、调用工具、感知与管理上下文、存储工件、评估结果的那一层系统；一旦 harness 设计成为**可执行的搜索空间**（代码），强编码 agent 就能利用与人类工程师相同的设计空间来优化它，这构成"模型改进部署系统 → 部署系统产出更强后继模型"的反馈环。

1. 概念与历史定位

- RSI 概念谱系：I. J. Good (1965) 的"超智能机器"（能设计更好的机器来改进自己）→ Yudkowsky (2008) 的"递归自改进"（AI 用当前智能改进产生其智能的认知机器）。
- 现代版本的两种形态：模型直接改权重（远期）；模型改进**训练管线与部署系统**，从而产出更强后继模型（近期，前沿实验室已在发生——文中直接引用 Anthropic 与 OpenAI 的加速证据）。
- Harness 定义**（原文）：围绕基础模型的系统，编排执行，决定模型如何思考与规划、如何调用工具与行动、如何感知与管理上下文、存储工件、评估结果。Claude Code / Codex 等编码 agent 产品的成功证明这一层与模型原始智能同等重要。
- 划界：self-play、合成数据、test-time training、持续学习也属 RSI 愿景，但不在本文范围。

2. Harness 设计模式（三模式 + 一案例）

相比早期"agent = LLM + 记忆 + 工具 + 规划"，harness 工程额外包含 **workflow 设计（loop engineering）**、**评估、权限控制、持久状态管理**——已经不是 prompt 模板，而是运行时与软件系统设计。Weng 给出 OS 类比：harness 应像操作系统一样封装复杂逻辑、保持接口简单；配置、工具接口等协议会逐步全行业标准化。

模式 1 · workflow 自动化：目标导向循环（计划→执行→观察/测试→改进→再执行，直到达标），可主动向用户请求澄清。Karpathy 的 autoresearch 仓库是干净范例；Codex agent loop 是产品化范例。关键在于模型分析**自己的轨迹与失败案例**并通过"agent 运行时"迭代，而非静态 prompt 模板。

模式 2 · 文件系统作为持久记忆：长时程 agent 的工件（实验日志、代码 diff、论文摘要、错误痕迹、历史轨迹）远超上下文窗口；harness 不应把一切塞进 context，而应把持久状态放进文件。读写文件（bash）是 LLM 的基础能力，因此文件式记忆天然随核心模型能力提升而受益——这是把记忆问题外包给“模型能力增长”的杠杆设计。

模式 3 · 子 agent 与后台任务：并行搜索多假设、并发跑实验、隔离子任务防止污染主上下文；父 agent 需要小型进程管理器（启动任务、查日志、取消失败运行、合并结果）。关键设计：**并行必须显式且可检视**——子 agent 输出若只活在瞬态聊天上下文里会迅速失效，存成文件/日志/状态记录才能在中断后恢复、对自己的执行历史推理。

案例 · 编码 agent harness：主流编码 agent（Claude Code、Codex、OpenCode、Cursor 系）的核心接口已趋同——文件系统工具（glob/grep/read/edit/apply_patch）、shell、git、MCP/Skills、web 搜索、后台进程（cron）、agent 委托（spawn/resume/wait/interrupt）。

Harness 层 vs 核心智能：Weng 的预测——(1) harness 工程走向元方法论（改进“获得更好答案的机器”而非答案本身），harness 系统自身成为优化目标，启发式规则减少、通用机制增多；(2) 成熟 harness 使能 auto-research 闭环，更聪明的模型反过来防止 harness 过度工程化。最终许多 harness 改进会被**内化**进模型行为，但与外部上下文和工具的接口会保留——类比 prompt 工程：手工技巧随指令微调而边缘化，但“指定目标、约束、上下文、评估”的需求从未消失。

3. Harness 优化（优化对象的递进）

Weng 给出核心递进线：**指令 prompt → 结构化上下文 → 工作流 → harness 代码 → 优化器代码**——模型越强，优化对象越复杂、方法越通用。

3.1 上下文工程

- **ACE** (Agentic Context Engineering, Zhang et al. 2025)：把上下文当作演化中的 playbook 而非越写越长的 prompt。三组件：Generator 产轨迹、Reflector 从成败轨迹蒸馏洞见、Curator 增量更新条目化上下文。防塌缩关键：Curator 不重写整段 prompt，只输出（标识符，描述）结构化条目，用确定性逻辑合并、周期性去重——避免迭代重写导致的 context collapse 与简洁偏置。局限：更新规则与工作流仍是手工设计。
- **MCE** (Meta Context Engineering, Ye et al. 2026)：把**机制**（怎么管上下文）与**内容**（上下文里有什么）分离，双层优化——内层给定 skill 优化上下文，外层在 skill 空间搜索最优机制；skill 数据库记录历史（skill、上下文函数、训练/验证分数），元级 agent 对既往 skill 做 agentic crossover 产生新 skill。上下文函数落地为专用目录中的文件集合（静态 skill.md + 动态 rollout），全部在带标准工具集（Read/Write/Edit/Bash/Glob/Grep/ToDoWrite）的 agentic 编码环境中执行。
- **Meta-Harness** (Lee et al. 2026)：再深一层——优化对象是“决定信息如何存储、检索、呈现给模型”的**代码**；提案者本身是编码 agent，输出 Pareto 前沿上的 harness 候选集合。执行历史全部可经文件系统访问（grep/cat 按需读，不塞满 prompt）；每个候选 harness 是文件系统里含源码、分数、轨迹、状态更新的字典。TerminalBench-2 实验从 Terminus-KIRA/Terminus-2 两个很强的人工 harness 初始化仍能继续提升。Weng 的总结：“一旦 harness 设计成为可执行搜索空间，强编码 agent 就能利用人类工程师使用的同一设计空间。”

3.2 工作流设计

- 手工设计路线：AI Scientist (Lu et al. 2026, Nature——提想法/写代码/跑实验/分析/写稿/同行评审全管线)；ScientistOne (Meng et al. 2026, 以可验证性为中心约束：每条声明——引用/数值/方法/结论——必须回溯到证据源并过 Chain-of-Evidence 审计)；Autodata (Kulikov et al. 2026, challenger/弱 solver/强 solver/verifier 四角色合成"恰好难度"的数据——强 solver 能解而弱 solver 不能；Weng 点出局限：合成任务只微调弱 solver 不动强 solver，更像对生成 prompt 分布的间接蒸馏，RSI 味道不足)。
- 搜索路线：ADAS (Hu et al. 2025, meta-agent 用代码编程新 agent 工作流，档案累积，两步自精炼查新颖性)；AFlow (Zhang et al. 2025, 工作流表示为图——节点是 LLM 调用、边是代码逻辑——MCTS 搜索，QA/代码/数学上超过手工工作流与 ADAS)。

3.3 自改进 Harness (本文核心节)

- 立论：上下文工程或工作流设计都只是 harness 的一部分；**代码是定义程序与系统的通用语言**——harness 就是编排 prompt、工具调用、子 agent、控制流、记忆、工作流逻辑的代码；LLM 能优化执行 agent 的代码，就能访问远大于手写 prompt 的设计空间。
- **STOP** (Zelikman et al. 2023)：递归脚手架改进的早期范例。种子改进器 I 接 (效用函数 u, 解 s, 黑箱模型 M) 返回改进解；目标不是改进 s 而是**改进改进器本身**——用元效用 (改进器在下游任务集上的平均效用) 递归更新 I。发现的策略包括遗传算法、分解改进、多臂 prompt bandit、模拟退火、束/树搜索。**警示性结果**：GPT-4 上跨迭代改善、GPT-3.5/Mixtral 上退化——递归结构本身不够，基础模型必须足够强才能改进机制；harness 改进使模型部署更好，但智能仍是核心。
- **Lin et al. 2026 (能力解耦)**：拆开两个轴——harness-updating (产出有用 harness 编辑的能力) 与 harness-benefit (利用更新后 harness 的能力)。惊人发现：从 Qwen3.5-9B 到 Claude Opus 4.6, **更新能力几乎持平** (9B 写出的 skill 与 Opus 程序同构)；受益能力非单调，**中档模型受益最大**。要用好 harness，模型需要正确及时地调用 skill/工具、擅长长时程指令遵循。
- **Self-Harness** (Zhang et al. 2026)：propose-evaluate-accept 循环——弱点挖掘 (把失败聚类成 verifier 锚定的失败模式；同一表面错误可能有不同因果机制，需含 verifier 级原因+因果状态+抽象机制的富失败记录)；有界 harness 提案 (提案上下文含可编辑面、失败模式、需保留的通过行为、既往编辑摘要；偏好可由窄改动解决的复发模式；候选需彼此互异)；提案验证 (held-in 测弱点是否解决 + held-out 测是否引入新问题，**双侧零回归才接受**)。三个模型在 Terminal-Bench-2 上学到各自弱点定制的 harness 指令。Weng 的安全担忧：允许程序编辑 OS 系统就打破了抽象边界——可编辑面要精心设计，**权限控制与安全层必须住在循环之外**。
- **AHE** (Agentic Harness Engineering, Lin et al. 2026)：把瓶颈定位在**可观测性**——rollout 失败时必须知道哪个组件负责，每次编辑必须证据接地。三支柱：组件可观测 (harness 拆成 7 组件——系统提示/工具描述/工具实现/中间件/skill/子 agent 配置/长期记忆——每个失败模式映射到一个组件)；经验可观测 (Agent debugger 逐轨迹写根因报告，聚合成基准总览，分层访问省 token)；决策可观测 (Evolve agent 的每次编辑配下一轮可证伪的预测，且**runs 目录/tracer/verifier/LLM 配置只读**——物理禁掉关 verifier、换模型、加推理预算这类 reward hacking，保证每笔收益可归因到 harness 编辑)。Terminal-Bench-2 上超过 OpenCode/Terminus-2/Codex (Hard 档除外)；冻结后的 harness 零样本迁移到 SWE-bench-verified 仍有效——进化的是工程经验而非基准特定优化。

3.4 进化搜索

- 适用条件：搜索空间巨大或形状怪异 + 梯度难做但解易评估——harness 搜索恰好匹配。

- 谱系：Promptbreeder (mutation prompt 也被进化) → GEPA (反思式进化) → **AlphaEvolve** (Novikov et al. 2025: 候选程序池 + 冻结 LLM 生成 diff; EVOLVE-BLOCK 标注可改区域; meta-prompt 与解程序共同进化; 消融证明进化过程/上下文/元提示/全文件进化/强 LLM 各有贡献) → ThetaEvolve (进化 + RL+ICL)、DemoEvolve (人类示范增广档案)、ShinkaEvolve (三件套提升采样效率: 父代采样平衡性能排名与子代数、嵌入相似度的代码新颖性拒绝采样、meta-scratchpad 记录成功模式)。
- **DGM** (Zhang et al. 2025): 与上述"解改进"不同, 显式针对**可编辑 harness 代码仓库**的进化——agent 被允许修改自己的 harness; 后续 Hyperagents (Zhang et al. 2026) 加 meta-agent 控制如何修改任务 agent。Weng 强调: DGM 是**固定模型下的 harness 进化**, SWE-bench 20%→50%、Polyglot 14.2%→30.7%。
- 适用边界判断 (重要): 这族方法在**候选解可自动评估、适应度易量化的域有效** (矩阵乘法、GPU kernel、算法竞赛、数据中心调度), 在评估慢、模糊、启发式为主的域挣扎; 算力效率也是现实约束。

3.5 与模型权重的联合优化

- SIA (Hebbar et al. 2026): Meta-Agent 提 harness、任务 agent 执行、Feedback-Agent 决定本轮改 harness 还是改权重。Weng 的评价直接: 实验混淆严重 (任务 agent 用 gpt-oss-120b 而 Meta/Feedback 用 Claude Sonnet 4.6, 基线太弱), "方向有趣、证据临时" (provisional)。训练稳定性与 Goodhart 效应开放。
- Continual Harness (Karten et al. 2026): 长时程游戏设定, harness 更新 + 用强教师在低奖励轨迹上蒸馏标签共学 policy。

4. 未来挑战 (七条, 每条都是后续论文的题眼)

先给了一个冷静的实证参照——Trehan & Chopra (2026): 最小脚手架下测试 LLM 从想法到论文, 三领域 45–50 篇种子文档, 只有 4 个想法过人类专家筛选、**只有 1 个完整执行成论文**。六个复发失败模式: 训练数据默认偏置 (旧库/陈旧命令/未接地假设)、执行压力下的实现漂移 (复杂时滑向常见简单方案)、记忆与上下文退化、过度乐观 (噪声里宣布胜利, 即 Bubeck et al. 的 "p-hacking and eureka-ing"、"numerical duct tape")、领域智能不足 (判断实现复杂度/结果合理性/哪些基线重要的隐性手艺)、科学品味弱 (实验可执行但没回答对的问题)。

1. **弱而模糊的评估器**: 多数研究声明没有快速精确 verifier; 自改进循环只在可测量客观指标的任务上好用 (同 RL); 研究品味、新颖性、长期科学价值难测。
2. **上下文与记忆生命周期**: 记忆随自治性增长; Weng 的判断——上下文工程将且应当成为**智能的核心部分**而非停留在软件层 (类比人类终身记忆维护)。
3. **负结果**: 文献偏向成功案例, LLM 可能不擅长放弃假设、报告负结果、承认失败; 研究 harness 应让失败尝试易于保存——从失败学习是修剪搜索空间的最好方式。
4. **多样性塌缩**: 进化与 RL 循环倾向利用已知高奖励模式; 开放式研究里最好的路径初期在当前评估器下可能更差。
5. **Reward hacking**: 奖励来自单测就过拟合单测、来自 judge 就学 judge 特定把戏、来自基准就利用基准伪影; **评估器与权限控制应住在进化循环之外**, 配 held-out 测试、轨迹审计、关键决策点人类评审——监督能自动化到什么程度是开放问题。

6. **长期成功**：优化目标多为短期（完成手头任务），沙箱 RLVR 很难捕捉可维护性、所有权边界、迁移成本、向后兼容、未来调试负担。
7. **人类角色**：人类应**沿栈上移而非被移出循环**——在正确的时间、正确的抽象层级提供监督；"我们是在为人类更好的未来造技术，不是反过来。"

附录给出 6 个基准速查：PaperBench（复现 20 篇 ICML 2024 论文，8316 条 rubric，当时最佳 Claude 3.5 Sonnet 约 21% 不敌 ML PhD）、CORE-Bench、ScienceAgentBench、RE-Bench（AI 在 2 小时预算 4 倍于人类、8/32 小时被人类反超）、MLE-bench、KernelBench。

5. 批判性评价

框架价值：这是目前唯一把 auto-research / 自改进 agent / 进化搜索三条文献统一到单一优化对象递进线（prompt→上下文→ workflow→harness 代码→优化器代码）上的综述，"harness 是可执行搜索空间"一句话给了整个领域操作性定义。七条挑战清单在 2026 下半年被逐条回应（见趋势调研）：弱评估器→EvalICEGAR/SCORE，负结果→SkillProx 的删除一等公民，多样性塌缩→Metan 进化档案，reward hacking→BenchJack/HVTB，人类角色→Falsifiable Release Gates。

判断的可检验性：Weng 的三个预测——harness 改进最终内化进模型、评估器必须在循环外、中档模型从 harness 受益最大（引 Lin et al.）——都是可证伪命题；其中"评估器在循环外"与六篇论文的评估器共进化方向存在**建设性张力**：六篇证明评估器不动会成为瓶颈，Weng 强调评估器乱动会被 hack，两者的合题正是"锚定纪律"（锚在循环外、metric 在循环内进化）。

盲区：全文以编码/研究域为中心，对多模态、具身、物理实验域的 harness 几乎未触及；对经济学约束（算力-认知劳动替代弹性）只字未提——这两块恰是 Anthropic 文章与 2026 下半年宏观争论的主战场。"52x 加速"这类内部数据引用自实验室自述，缺第三方口径（METR 试点后来补上了这一角）。

6. 与其余材料的关系

- 六篇论文全部可放进她的分类：DGM/MOSS→3.3-3.4 节（自改 harness+进化搜索）、EvoLM/ECHO→3.5 节（联合权重优化）、RQGM/WGtG→挑战 1+5（评估器与 reward hacking）、WikiSkill→模式 2+3.1 节（文件记忆+上下文工程）。
- Anthropic 文章是她"前沿实验室加速"一句引用的展开版；她的挑战 7（人类沿栈上移）与 Anthropic 的"方向与批准权留在人手"完全同构。
- 阅读顺序建议：先读本文建立坐标系，再读六篇看坐标系里每个格子的最新进展，最后读趋势调研看格子之间的连线。

解读报告 02 · Anthropic Institute 《When AI builds itself》

项目	内容
来源	anthropic.com/institute/recursive-self-improvement (Anthropic Institute, Marina Favaro 与 Jack Clark 合著)
性质	政策研究机构文章：用公开基准 + 首次披露的 Anthropic 内部数据论证"AI 已在加速 AI 自身的开发"，并推演三种未来情景与协调机制
定位	本次调研中唯一的一手工业证据源：六篇学术论文研究"怎么做 RSI"，这篇回答"RSI 现在实际做到了哪一步、卡在哪一步"

一句话核心主张

Anthropic 正在把越来越大比例的 AI 开发工作委托给 AI 系统自己（工程师人均合并代码量是 2021–2025 均值的 8 倍、>80% 合入生产的代码由 Claude 编写），趋势外推指向能完全自主设计后继模型的系统——"我们还没到那一步，RSI 也非必然，但它可能来得比多数机构准备好的时间更早"；执行环节（写代码、跑实验）已接近自动化，方向判断（研究品味）是人类保留的最后一环，而这一环的差距也在快速收窄（自动选下一步实验的胜率半年内从 51% 升到 64%）。

1. 论证结构：外部证据 + 内部证据 + 三情景推演

文章的修辞结构值得注意：先用第三方可核查的公开基准建立趋势可信度，再用无法外部核查的内部数据填充细节，最后做情景分析——这是政策文书的写法（作者 Jack Clark 是 Anthropic 政策负责人），不是技术论文。

1.1 外部证据（可核查）

- METR 时间视野：**AI 可靠完成任务的时长约每 4 个月翻倍（早期趋势是 7 个月）。Claude Opus 3（2024–03）约 4 分钟任务 → Sonnet 3.7 约 1.5 小时 → Opus 4.6 约 12 小时；趋势成立则 2026 年内到"人类数天"、2027 年到"人类数周"。Claude Mythos Preview 被 METR 测得连续工作"至少 16 小时"，处于 METR 不出新任务就无法测量的上限。
- 基准饱和速度：**SWE–bench 从个位数到饱和用了两年；CORE–Bench（复现已发表研究——原创研究的前置能力）从 2024 年约 20% 到饱和只用了 15 个月。

1.2 内部证据（首次披露，按"初级→资深→首席"的工作层级递进）

文章把前沿模型开发拆成**工程**（写代码、搭基础设施、盯训练）与**研究**（决定跑什么实验、解读结果、选下一个想法），并用 Anthropic 员工的成长阶梯类比 Claude 的能力爬升：执行别人指定的任务 → 拿到目标自己设计方法 → 决定哪些问题值得做。

- 代码产出：**2026–05 起 >80% 合入代码由 Claude 编写（领导层公开口径 90%+，80% 是保守的生产合入口径）；Claude Code 2025–02 发布前这个数字是低个位数。人均每日合并代码量在 2021–2024 四年持平，2025 年起爬升（Claude 开始自己跑代码），2026 年再陡（长时程自主工作），2026 Q2 达 2024 年的 **8 倍**。文章自我设限：代码行数是重量不重质的指标，8× 几乎肯定高估了真实生产力增益——但"团

队用 AI 写更多代码"这一加速本身是真的。2026-03 内部调查 (130 名研究员): 中位数自估用 Mythos Preview 后产出约 4 倍 (文章again自我修正: METR 研究表明开发者自估会偏高)。

2. **代码质量**: "能跑"维度证据明确——人类纠正/接管 Claude 的比率一年来持续下降; 最开放任务的会话成功率 2026-05 达 76% (半年升 50 个百分点)。案例: 常规升级导致数万训练任务崩溃, Claude 只凭文本描述+集群访问, 逐一排查环境设置, 定位到一个冷门调试 flag, 2 小时交付通常 2-3 天的工作。"可维护"维度: 内部共识是 2025 年末 Claude 代码略差于人类、当下大致持平、预期年内反超。附带的组织变化: 全部代码变更先过自动 Claude 审查——回溯分析显示这能拦下 claude.ai 历史事故背后约 1/3 的 bug。
3. **执行既定目标的实验**: 固定测试——给 Claude 一段小模型训练代码, 要求在保持正确性检查的前提下尽量加速。2025-05 Opus 4 平均 ~3x, 2026-04 Mythos Preview ~52x; 校准参照: 熟练人类研究员 4-8 小时做到 4x。(脚注自限: 加速倍数强烈依赖起始代码的可改进空间, 绝对值不代表真实训练加速——同型对比才是信息量所在: 一年 3x→52x, 且超过人类。)
4. **自主提出实验**: 2026-04 发表的首个端到端研究演示——给 Claude agents 一个开放 AI 安全问题 (弱模型能否可靠监督强模型), agents 自己提假设、测试、并行共享发现、迭代。人类研究员两人一周恢复了 23% 的"地板-天花板"差距; agents 用 800 累计小时 + 约 1.8 万美元算力恢复了 **97%**。自限声明: 结果未能干净迁移到生产规模模型; **问题选择与评分 rubric 仍是人类做的**——方向设定是人类唯一有意义的角色。
5. **研究方向判断 (最关键的一组数据)**: 从真实 Claude Code 会话中选出 129 个"研究者走了弯路"的时刻, 只给模型看走弯路之前的内容, 问它下一步做什么, 由能看到会话最终走向的另一个 Claude 判谁的选择更好。2025-11 的 Opus 4.5 胜人类 51%, 2026-04 的 Mythos Preview 达 **64%**。方法自限: 样本刻意选了人类有改进空间的时刻, 不是对等比较 (对照组: 在人类下一步本来就很强的 127 个时刻, 模型只赢约 20%) ——但研究日常正是这类下一步决策的链条, 此指标是"模型最终能否独立跑调查"的相关信号。

2. 三种未来情景

1. **趋势停滞、现有能力扩散**: 指数变 S 曲线 (研究判断可能不来自堆算力堆数据)、或供应链约束 (芯片/电网/互连)、或外生冲击。即便能力冻结在今天, 世界也会巨变——Project Glasswing 首周发现一万多个高危漏洞, 网络防御瓶颈已从找漏洞变成打补丁。作者判断此情景**不太可能**: 所有可测能力 (包括"软"能力) 迄今都在同一条曲线上, 未见弯折。
2. **复合效率增益, 人类保留方向权 (作者认为最可能)**: AI 开发大幅自动化, 人类定方向、判结果; 百人公司做万人公司的事。关键制衡: **Amdahl 定律**——加速一部分只是把瓶颈挪到没加速的部分。Anthropic 已遇到两个实例: 人类代码评审成为新瓶颈; 想法/工具/模拟爆炸式增长, 远超组织追踪消化能力——"发现并修复瓶颈的速度"可能成为组织最重要的技能。
3. **完全 RSI, AI 造后继者**: 进展速度完全由算力 (或算法效率发现速度) 决定, 人类转向监督/验证/核查一个扩张中的"虚拟实验室"。对齐问题在此情景下最不确定: 模型可能足够对齐并自己发现新解法, 也可能今天罕见的失准随代际复合放大、越来越频繁且越来越不被理解, 直至失控。同时 Amdahl 定律依然适用于物理世界: 再多智能也不能提前知道药物的十年长期效应、不能提前宪法规定的选举、"不能在一个周末把陌生人变成老友"——普通人感受到的未来节奏仍由这些瓶颈设定, 即使上游实验室以算力速度运转。

3. 政策立场 (文章的真正目的)

- 若能有效放慢技术发展以争取应对时间，"那很可能是好事"；但单边减速只会让最谨慎的行动者追上，反而更不安全。
- 核心提议：世界应当拥有**可验证的减速/暂停选项**——多国多个前沿实验室在相同条件下同意停止，且互相能验证真的停了。Anthropic 承诺：若此类系统存在且其他前沿开发者可验证地减速，"我们预期我们会减速或暂停"。
- 难点直白：训练比导弹发射井好藏得多、输入是通用算力、悄悄违约的激励巨大（谁继续谁接管领先）；INF 条约级别的验证体制花了几十年建立信任，"我们没有那么久"。
- 行动：未来数月组织政策制定者/研究者/公民社会/其他 AI 公司的对话并公开产出。

4. 批判性评价

证据分级要清楚。这篇文章最有价值也最需要小心的地方是内部数据不可外部复核。文章自身的自限声明做得诚实（8x 是高估、52x 不锚定绝对值、64% 不是对等比较、97% 未迁移到生产规模），但三条外部对照必须并读：

1. **METR 多实验室试点**（2026-05，Anthropic/Google/Meta/OpenAI 参与）：没有公司报告研发整体节奏 2 倍加速——**Anthropic 自己确认了这一点**；无公司让 AI 设定研究议程或做终审判断。"人均 8 倍产出"与"未见 2 倍节奏"并不矛盾（微观产出 ≠ 宏观节奏，Amdahl 定律正是文章自己给的解释框架），但外推时必须用后者校准前者。
2. METR 桌演的半定量关系 $\text{speedup} \propto \text{TH}^{0.39}$ ：时间视野 17 倍只换约 3 倍提速——文章的"任务时长每 4 个月翻倍"外推到组织加速时要打这个折扣。
3. AI4AI-Bench（2026-08）：评估器隐藏且固定时，前沿 agent 在训练算法设计层平均只完成 16.6% 的路程、43% 的尝试是负改进——"执行超人、方向平庸"的结论与文章一致，但量化出的方向能力差距比文章的 64% 叙事更冷峻（64% 测的是"下一步选择"，AI4AI 测的是"完整算法设计"，后者更接近真实研究）。

"品味是最后瓶颈"的论证有一个可疑跳步。文章说范式转移想法数年才有一个、之间的进展都是增量迭代（scale up→看哪坏了→修→再试），而这正是 Claude 擅长的工作流——因此即便品味不涨，复合加速也成立。这个论证低估了"选择哪个增量"本身的品味含量：AI4AI-Bench 里 43% 的负改进正说明增量选择不是免费的。Edison 的 1% 灵感 99% 汗水类比里，那 1% 决定 99% 流向哪里。

情景 2 与情景 3 之间缺一个情景："AI 有了研究品味但人类仍握批准权"——这恰是 Falsifiable Release Gates（收紧自动/放松须人）和 MOSS（收敛不自动晋级）在构建的世界。文章的三分法把"能力"与"权限"绑在一起了，而 2026 年安全工程的主线恰恰是把两者解耦。

员工引语是全文最真实的部分。"已经 5 个月没自己写过代码"、"人情小债的礼物经济消失了"、"一切顺利的日子觉得自己做什么都不重要，一切崩溃的日子发现自己已经不知道系统在干什么"——最后这句是对齐问题的现象学版本：**监督者对被监督系统的理解正在流失**，这比任何基准数字都更能说明情景 3 的风险实质。

5. 与其余材料的关系

- 与 Weng 文章互为表里：Weng 给方法论地图（harness 怎么优化），本文给进度报告（优化到哪了）；Weng 挑战 7"人类沿栈上移"与本文"人类角色收窄至方向判断"是同一观察的两种表述。
- 六篇论文是本文"执行已自动化、评估是战场"判断的学术展开：本文的固定加速测试（3x→52x）就是一个静态评估器下的自改进循环——如果跑得多久，EvoLM 的 reward overoptimization 与 WGTG 的评估器

塌缩问题会准时到场。

- 本文的"弱监督强"端到端演示 (97% gap recovery) 与 ECHO 的 critic-policy 共进化问题：前者证明 agents 能自主做这类研究，后者给出这类研究的算法内核。
- 政策提议（可验证暂停）与趋势调研里的 IFP 23 条、AIVEC 验证联盟、CSA 治理速度差是同一条政策线的不同环节。

解读报告 03 · EvoLM: Self-Evolving Language Models through Co-Evolved Discriminative Rubrics

项目	内容
arXiv	2605.03871 (2026-05-05, Under review)
作者	Shuyue Stella Li, Rui Xin 等 (华盛顿大学 + Allen AI + UPenn; Pang Wei Koh、Yulia Tsvetkov 组)
代码/模型	github.com/stellalisy/EvoLM · huggingface.co/stellalisy/EvoLM-8B
在六篇中的位置	评估侧第一篇: 把 rubric 生成器纳入训练循环, 与 policy 交替更新——共进化谱系中"权重内共进化"的代表

一句话核心主张

模型预训练里已经编码了大量评估知识, 却没有被现有后训练方法当作奖励来源; EvoLM 把这份潜在能力结构化成逐实例的判别性 rubric, 让同一个模型交替训练"出题打分"和"答题"两种能力——rubric 生成器的奖励是让一个冻结的小 judge 更能分出好坏回答 (判别效用), policy 的奖励是 rubric 条件下的 judge 打分; 全程不需要人类标注、专有 API 或领域验证器, 偏好对完全由 policy 自己的输出通过时间对比 (现在的回答 vs 早期 checkpoint 的回答) 构造。

1. 方法

1.1 分解: rubric 生成 + judge 打分

标准做法是标量奖励模型 $R(q,a)$, 评估标准隐在权重里不可检查。EvoLM 把奖励计算拆成两段自然语言接口: rubric 生成器 $p_\phi(q)$ 产出逐题评估标准 r , judge $J(q,r,a) \in [0,1]$ 按标准打分。好处三个: 可解释 (标准可检查)、模块化 (换 judge 不用重训)、小 judge 可用 (给了具体标准, 1.7B 的 judge 也能可靠打分——这是论文的核心赌注之一, 实验证实)。

1.2 rubric 是隐变量: 变分推断形式化

好 rubric 的定义只有一条: judge 用了它之后能把偏好回答排在前面。论文把 rubric 处理成解释观察到偏好的隐变量: $p(a+>a-|q,r)=\sigma(J(q,r,a+)-J(q,r,a-))$, 这是 Bradley-Terry 模型的推广 (把隐标量奖励换成隐自然语言 rubric)。后验不可解, 用摊销变分推断最大化 ELBO: 重构偏好排序的对数似然 - $KL(p_\phi||p_{ref})$ 。rubric 是离散文本, 用策略梯度优化——rubric 生成器变成一个 agent, 奖励是偏好重构对数似然。实际实现换成 margin 奖励 + 格式奖励: $R = 0.7 \cdot (J(a+) - J(a-)) + 0.3 \cdot R_{format}$ (JSON schema 校验)。

1.3 交替训练 (共进化的具体机制)

两个角色共享同一份 Qwen3-8B 权重 (不同 prompt 切换), 用 GRPO 训练。K=50 步交替: Phase 1 冻结 rubric 生成器训 policy (rubric 条件 judge 分做奖励); Phase 2 冻结 policy 训 rubric 生成器 (判别 margin 做奖励)。judge 全程冻结——把改进信号的唯一来源隔离在 rubric 生成器上。交替产生涌现课程: policy 变强 → rubric 必须更细才能分出好坏 → 更细的 rubric 给出更锐的奖励 → policy 再变强。

1.4 偏好对的三种自构造 (无人类标注的关键)

- 1. **时间对比**：当前 policy 回答为 a+， $t' < t$ 的早期 checkpoint 回答为 a-。步距 [20,100] 控制难度——距离大则对比容易，距离小则需要更细粒度 rubric，天然形成课程。
- 2. **推断问题 (IQ)**：给 a+ 让 policy 反推它像在回答什么问题 q^+ ，再用 q^+ 生成 a-——训练 rubric 检查"回答是否切题"。
- 3. **rubric 条件 (RC)**：a+ 由 (q,r) 条件生成、a- 只由 q 生成——直接测 rubric 是否包含可执行的改进指令。

2. 关键实验结果

设置：271K 提示 (Tulu 3 混合，通用对话/指令遵循/数学/代码/科学理解)，12 个基准 (OLMo3-Adapt 套件)，全部方法统一 500 步 policy 更新。

2.1 主结果 (论文最重要的一张表)

奖励来源	RewardBench-2 (静态判别精度)	下游 policy (OLMo3-Adapt 均分)
Skywork-RM-V2 标量 RM	86.4% (最高)	59.7% (最低)
GPT-4.1 提示 rubric	36.6%	66.7%
Qwen3-8B 提示 rubric	26.2%	67.5%
四个 rubric-RL 基线 (RAR/RRD/RLCER/Rubric-ARM)	—	66.7—67.6%
顺序训练 (先 rubric 后 policy)	47.2%	68.3%
EvoLM (共进化)	46.0%	69.3%

两个反直觉结论：

- 1. **静态判分精度与下游质量脱钩甚至反挂**：标量 RM 在 RewardBench-2 上碾压所有 rubric 方法 40 个百分点，训出的 policy 却垫底 (差 EvoLM 9.6 分) ——policy 会针对固定评分面找捷径，这是 Gao et al. (2023) reward overoptimization 的又一实证。**评估器的价值不在静态精度，在能否跟着 policy 分布移动。**
- 2. **顺序训练的 rubric 静态精度更高 (47.2 vs 46.0)，下游却更差 (68.3 vs 69.3)** ——共进化的收益恰恰来自 rubric 对当前 policy 分布的适应性，静态基准测不出这个。

最大单项收益在代码生成：HumanEval+ 86.2% vs 次优 80.5%。

2.2 机制分析：rubric 从抽象标签进化为可验证检查

定性+统计分析 (100 个评估提示)：纯标签式标准从 21.9% 降到 0.3%，嵌入具体期望值的标准从 6.9% 升到 19.3%，约束型标准从 7.7% 升到 20.3%；标准平均长度 59→112 字符而条数稳定在 3-4 条。数学域的 rubric 学会把 80% 权重压在一条嵌入期望答案的标准上 ("正确的最大面积 144，由周长 48 导出")，**把证明验证变成答案核对**；受限写作域把格式/关键词要求合并成可数的显式检查。共同效应：把小 judge 做不可靠的整体语义判断，转换成小 judge 做得可靠的**具体模式匹配**——这是 margin 目标的直接后果 (任何拉大分差的标准都被奖励，具体可验证的标准天然占优)。

2.3 泛化 (rubric 生成器的真正价值检验)

- **OOD 域**: 训练分布里完全没有的深度研究任务上, 与专家人工 rubric 的成对排序一致性——HealthBench 58.4% vs GPT-4.1 的 52.5%, ResearchQA 59.3% vs 51.0%。8B 模型训出的 rubric 生成器在陌生领域比 GPT-4.1 更贴近专家判断。
- **跨 policy 迁移**: 冻结 rubric 生成器训全新 policy——Qwen3-4B (65.2 vs GPT-4.1 rubric 的 64.4)、Llama-3.1-8B (46.9 vs 45.7), 跨家族也成立。
- **跨 judge 迁移**: 用 Qwen3-1.7B judge 训出的 rubric, 换 Qwen3-8B judge 用时 RewardBench-2 +22.7 分——训练出的 rubric 编码了更强 judge 也提取不出的评估结构。
- **多 judge 训练**: 五个小 judge 投票 + Fleiss's kappa 一致性奖励, 进一步改善开箱即用的跨 judge 泛化。

3. 批判性评价

真正的贡献是把"什么是好 rubric"变成了可优化的目标。此前 rubric-RL 工作要么用 GPT-4.1 生成 rubric (RAR/RRD——专有依赖)、要么需要任务验证器 (RLCER——只能做有 ground truth 的域)、要么需要偏好标签 (Rubric-ARM)。EvoLM 是设计空间表里唯一五项全勾的 (训练 rubric 生成器 / 无专有 API / 无外部标签 / 不限可验证域 / 与 policy 共进化)。

但"无外部监督"有一个隐藏前提: 时间对比假设后期回答优于早期回答。这在训练早中期成立 (policy 确实在涨), 但如果训练进入退化阶段 (reward hacking 开始), 时间对比会把退化方向当成改进方向——**自监督信号与被监督对象共享同一个故障模式**。论文没有讨论这个循环性, Who Grades the Grader 的"评估器塌缩与进化观测等价"结论正打在这里: EvoLM 的 rubric 判别精度是对自己构造的偏好对测的, 没有外部锚。

judge 冻结是稳定性的来源, 也是天花板。EvoLM 把三元组 (rubric 生成器、policy、judge) 里只放开两个, judge 冻结避免了 RQGM 要处理的"尺子自己在动"问题——代价是 judge 能力上限最终约束整个循环 (judge 分不出的差异, 再好的 rubric 也无法表达)。论文用"具体化 rubric 降低 judge 负担"部分绕开了这个约束, 但 rubric 能具体化的前提是任务有可具体化的正确性结构——开放域写作/研究判断这类任务上, 把评估压成模式匹配本身就是失真。

与安全的接口: rubric 是自然语言、可检查, 这比标量 RM 的黑盒评分对齐友好得多——人可以直接审计"policy 正在被什么标准优化"。但 2.2 节的机制分析同时暴露了风险: rubric 进化的方向是**评估收窄** (80% 权重压到单条标准), 判别效用最大化与评估全面性之间存在未被讨论的张力。

4. 与其他材料的关系

- 与 **RQGM** 是共进化的两种时间结构: EvoLM 连续交替 (K=50 步), RQGM epoch 内冻结评估器、边界处才换尺——RQGM 用可测性换适应速度, EvoLM 反之。
- 与 **WGtG** 互补且被其警示: EvoLM 展示评估器进化的收益, WGtG 证明没有外部锚时收益与塌缩不可区分。EvoLM 的专家 rubric 对齐实验 (HealthBench/ResearchQA) 实际上就是一种事后锚定——但它是评估阶段做的, 不在训练循环里。
- 与 **ECHO** 同攻"评估侧滞后": EvoLM 的武器是显式 rubric (结构化、可迁移), ECHO 是 critic 模型直接 GRPO 共训 (连续、无结构); EvoLM 在通用后训练场景, ECHO 在开放世界 agent 场景。

- 印证 **Weng** 挑战 4（评估瓶颈）与 Anthropic 文中固定加速测试的隐忧：任何静态评估器下的长期自改进都会撞上 overoptimization, EvoLM 的 59.7% vs 69.3% 是这一点最干净的量化。

解读报告 04 · The Red Queen Gödel Machine: Co-Evolving Agents and Their Evaluators

项目	内容
arXiv	2606.26294 v2 (2026-06-29, preliminary preprint, 作者声明将在后续版本探索更长搜索时程)
作者	Alex Jacob, Andrej Jovanovic, William F. Shen 等 (剑桥 CaMLSys + NVIDIA + Flower Labs + MBZUAI + Inria; Nicholas Lane 组)
命名	Van Valen 红皇后假说: 物种必须不断适应才能维持相对于共进化竞争者的适存度
在六篇中的位置	评估侧第二篇: DGM→HGM→HyperAgents 这条 harness 进化谱系的直接续作, 第一个把评估器本身放进搜索循环的框架

一句话核心主张

现有自改进 agent (DGM/HGM/HyperAgents) 全部假设**平稳评估准则**——一个在整场搜索中固定不变的验证器/基准/标注集, 这忽略了进化的核心特征 (物种适应的是同样在进化的环境); RQGM 通过**受控效用进化**把评估纳入改进循环: 搜索按 epoch 组织, epoch 内评估器冻结 (继承单 epoch 内的自改进保证), epoch 边界处挑战者评估器只有在**固定的 ground-truth 锚数据集**上以 ϵ -best-belief 统计优于在位者才能上位, 随后**选择性擦除**只删除依赖被替换评估器的效用记录。

1. 方法

1.1 谱系与四点修改

沿用 HGM 的树搜索骨架 (档案节点、clade 元生产力 CMP 做 Thompson 采样、 ϵ -best-belief 选最终 agent), 做四点修改: (i) 每个档案节点从单 agent 变成**多角色共享工作区** (任务 agent + 评估器共居一个可进化代码库, meta-agent 可修改全部角色代码); (ii) 评估器本身是**可学习的 agentic 过程**; (iii) 效用函数可在指定的进化 epoch 变化; (iv) 评估器可在 epoch 边界被替换。

1.2 受控效用进化 (核心机制, 也是理论贡献所在)

三条保证支撑“非平稳效用下的自改进”:

- Epoch 内有效性**: epoch 内评估器/产物生成协议/二值评分规则全部冻结, 每个 epoch 就是一个固定准则搜索问题, HGM 的收敛保证逐 epoch 直接适用 (Prop. 3)。
- 锚定改进**: 挑战者只有在评估器无关的 ground-truth 锚 (该角色的客观标签或人类偏好数据集) 上把 ϵ -best-belief 分数 (Beta 后验的 ϵ 分位数, 以概率 $1-\epsilon$ 成立的下界) 抬高才被晋升, 平局偏向在位者以避免不必要的擦除——评估器跨 epoch 也在改进, 不只是 epoch 内 (Rem. 3)。
- 摊销转换成本**: 替换时不立即重排全档案 (浪费预算在可能永不再访的节点上), 而是懒惰重评——后续评估回到旧节点时才用新评估器重打分; 指数间隔的 checkpoint 使暴露于擦除/重评的记录数只随预算线性增长 $O(B)$, 而不是每步都允许转换的 $O(B^2)$ (Prop. 6)。

选择性擦除为什么必要: 保留旧分数或把旧分数缩放到新评估器上, 都会混合不同效用函数的证据、破坏 epoch 内平稳性——对照实验 (no-erasure control) 显示不擦除时搜索被钉死在被废评估器的排序上, 新准则永远无

法重排档案。

1.3 数据隔离

创建节点的反馈与选择节点的证据分离：meta-agent 看训练结果来指导自我修改，但节点选择只由验证集评估驱动，最终报告用独立测试集——防记忆化设计比 DGM 时代明显收紧。

2. 实验（GPT-5.5 low 做 meta-agent，三域，四个 RQ）

2.1 RQ1 · 有 ground truth 的域，学习型评估器依然有用（Polyglot 编码）

共进化一个 agent-as-a-judge 代码审查员（锚定 CRAVE 真实 PR 接受/拒绝数据集）作为测试执行的**补充信号**：审查员单次调用、比多轮 agent 执行便宜得多。结果：held-out 通过率 71.7% vs HGM-H 的 69.9%，且用 **1.35x–1.72x 更少的 token** 超过基线。机制解释：90% 被接受的补丁修改的是 coder 和 reviewer **共享**的基础设施代码——一次编辑同时改善两个角色，共进化在丰富搜索而不是分裂预算。

2.2 RQ2 · 无客观基准的域（论文写作 / IMO 证明）

- **论文写作**（锚：APReS 人类接受/拒绝决定）：共进化的 writer 在四评审 panel 下平均接受率 40.5% vs HGM-H 的 21.8% (**1.86x**；匹配算力点 1.78x)。
- **证明写作**（锚：IMO-GradingBench 人类评分，7/7 满分算通过）：匹配算力时与 HGM-H 持平，长时程后分化——HGM-H 停滞（冻结评估器不再提供信息量），RQGM specialist 均分 4.33 vs 4.07（静态 IMO25 人工管线）vs 3.73（HGM-H），Pass@6 61.7% 最高；Pass@7 上仍输 IMO25（48.3% vs 55.0%）——RQGM 靠更多 6/7 近完整证明赢均分，严格全对率还差，作者归因于搜索预算。
- 附带效率结果：把搜索期任务 agent 调用换成 Nemotron 3 Ultra（meta-agent 保持 GPT-5.5），价格等效 token 省 **~13x** 而终评精度接近。

2.3 RQ3 · 评估器替换对搜索施加课程效应

宏观：每次替换实质性且**永久**地重排档案（排序停在擦除后的新水平，不回弹到旧序）——后继评估器执行更严的准则。微观：档案证据集中在少数骨干谱系上，每次转换把被旧准则压低的谱系拉回竞争，但最优谱系跨转换保持韧性——课程围绕稳定骨干抬升种群，而不是每次转换推倒重来。

2.4 RQ4 · 共进化改善评估器本身（论文最有信息量的部分）

两个评估器的对比揭示了**任务结构决定评估器的可腐蚀性**：

- **证明 grader**（有参考解可对照，自偏好偏差空间小）：纯共进化就够——IMO-GradingBench 精度最高（比基线高 9%），搜索成本比 HGM-H 低 **3x**，无需对抗目标。
- **论文 reviewer**（无参考答案，暴露于 LLM 自偏好偏差）：HGM-H 评审员以人类论文 **1.42x–1.91x** 的比率过度接受 AI 生成论文，且 APReS 的接受/拒绝平衡奖励宽松评审——**偏差与原始精度同向**，静态精度指标反而掩护了偏差。RQGM 的修正利用 epoch 边界：被废评审员曾接受的 AI 论文形成**对抗池**，下一 epoch 额外奖励拒绝这些论文。代价是原始 APReS 精度按构造下降（低于宽松的 HGM-H），收益是**校准**：对 AI 与人类论文接受率相近、保住 80% ground-truth 精度，给 writer 一个难以 hack、随时间变严的信号——Tab. 1 里最强 writer 正是这个对抗评审员训出来的。

3. 批判性评价

这是六篇里理论姿态最完整的一篇：不是"我们让评估器动了"，而是"评估器可以动，但动的自由度被三条机制约束"（epoch 冻结、锚定晋升、选择性擦除）——把 Gödel Machine 谱系"证明有益才修改"的精神翻译到了评估器层。**但锚是阿喀琉斯之踵**：所有跨 epoch 保证最终悬挂在那个固定 ground-truth 锚数据集上——锚本身不进化、不受污染、且代表任务真实目标，这三个假设在长时程下逐一变弱（锚会饱和、会被档案间接拟合、且 APReS 这种"人类接受/拒绝"锚本身就带宽松偏差——论文自己发现了这一点才引入对抗目标）。**锚不是被消除了，是被移到了循环外面**——这与 WGtG 的"锚定纪律"结论殊途同归，也意味着 RQGM 没有真正回答"评估器的评估器是谁"，只是把答案推给了一个更小、更慢变的人工数据集。

"preliminary" 要当真：搜索时程短（proof 域 88M token）、SWE-bench 因运行时长被排除、v2 与 v1 相隔仅数周。RQ3 的课程效应基于两个域的图形证据，样本量不支持强结论。

对抗修正的一般化问题：论文 reviewer 的去偏依赖"被废评估器接受过的 AI 产物"这个天然对抗池——这个构造只在生成器-评估器共居一个搜索里才免费可得。它是共进化框架的真实红利，但也提示：**对抗样本的来源本身依赖共进化结构**，单独训练评估器时这个修正不可用。

与 EvoLM 的对照最有启发：EvoLM 连续交替（K=50 步）+ judge 冻结，RQGM 离散 epoch + judge 可替换但锚冻结——两者都没有让"最后一层尺子"动起来。整个 2026 评估侧进展可以总结为：**共进化的自由度在上移，但每上移一层，就需要一个新的更外层的冻结物**。

4. 与其他材料的关系

- 直接续 **DGM**（报告 07）：DGM 固定 SWE-bench 做效用，RQGM 指出这正是 DGM 遇到的 hack 行为（伪造日志、绕过检测）的结构根源之一——评估器是静止靶。
- 与 **WGtG**（报告 05）互为正反面：RQGM 展示"锚定下的评估器进化能带来什么"，WGtG 证明"没有锚时评估器进化与塌缩不可区分"——两篇合读才是完整论证。
- 与 **ECHO**（报告 06）：RQGM 在 harness/代码层共进化（进化的是评估器的代码与提示），ECHO 在权重层共进化（critic 模型参数与 policy 同步 GRPO）——同一原理的两个实现层。
- 呼应 **Weng** 挑战 4（评估瓶颈）与她对"进化搜索作为 harness 优化器"的判断；Anthropic 文中"研究品味是最后瓶颈"在 RQGM 这里具体化为"锚数据集的构造品味"。

解读报告 05 · Who Grades the Grader? Co-Evolving Evaluation Metrics and Skills for Self-Improving LLM Agents

项目	内容
arXiv	2607.12790 v2 (2026-07-30)
作者	Xing Zhang, Peiyang He 等 (AWS 生成式 AI 创新中心 + 汇丰科技中国——工业作者写的机制研究)
代码	github.com/amazon-science/Self-Evolving-Agents-Double-Ratchet
在六篇中的位置	评估侧第三篇，给出全谱系最重要的 否定性结论 ：下游任务分数无法验证自进化评估器

一句话核心主张

技能可以进化，评估指标为什么不能？——本文把**评分函数本身**（不是任务集）当作一等进化对象：在只有十条带黄金参考的锚定样本的"稀疏锚"制度下，搜索由带类型的小缺陷检测器组成的表达式树，产出**可读的表达式而非不透明打分器**；但真正的贡献是两个安全发现：(1) 拆掉锚定护栏，指标在三个种子上全部塌缩成"全过"的空指标，而拆掉检测器生命周期不会——**锚定纪律（而非生命周期管理）承载评估器的安全负荷**，恰好反转技能进化文献的教训；(2) 塌缩的空指标训练出的技能任务分数与正常指标**一样好甚至更好**——因此这个领域最想做的实验（共进化 judge 和 policy、报告 policy 变好了）会给一个全过的评分器盖章通过，**任务分数只回答充分性，永远无法回答有效性**。

1. 方法

1.1 立场：我们很少知道什么是好，但通常能找出缺点

指标 $M(t,y) \rightarrow \{\text{pass, fail, abstain}\}$ 是缺陷检测器组成的表达式树。原子 $op\ o(t,y,c) \rightarrow \{\text{drawback, clean, abstain}\}$ 各查一类失败、其余弃权，分三个成本档：静态 op （解析产物）、执行 op （沙箱跑代码/真仓库跑 SQL）、judge op （问 LLM 一个窄问题）。组合语法：叶子 op 、析取、合取、否定、K-of-k 投票、加权投票——**通过 = 根节点没找到任何已知缺陷**，不是认证正确。刻意保持指标以确定性检测器为主是安全选择而非效率选择：裸 LLM judge 与被评的 LLM solver 共享失败模式，可能在任何优化压力出现之前就漂移到一致，且这种合谋从外面看不见；类型化检测器一次一叶地失败，每叶自报它命中的失败类——正是这个性质后来让一次 rubric-gaming 事故变成一行诊断。

1.2 稀疏锚制度与三分割

- train**（大、无标注）：暴露候选指标分歧/弃权之处；共进化时被进化指标评分供技能循环用。
- dev**（十条锚定样本，五清晰失败五干净通过）：每条带黄金参考，教师模型据此发软 pass/fail 标签——**全系统唯一的监督信号**。
- test**（锁定）：持最强参考（单元测试/官方执行比对/报告 rubric），指标进化的任何环节都不读——有效性数字是严格出样的。指标进化的选择目标： $S(e) = A_{dev}(e) \cdot A_{train}(e)^w - \lambda C(e)$ 。 A_{dev} 是召回加权的锚一致性（漏报缺陷的代价是误报的 2 倍，防止只靠答对简单类刷满）； A_{train} 是**可靠性加权共识**（每个 op 的票按其锚上留一边际加权——锚上证明过的 op 主导，未证明的近中性投票，防止一批便宜合成、共

享盲点的相关检测器自定义伪标签)；共识只做迁移正则，乘性进入、fail-closed，永远不能单独选出指标。

1.3 生命周期与 Double Ratchet

op 生命周期：从失败聚类合成带类型 op 规格 → 出生门（在其聚类上命中至少一半、在已知好样本上干净）→ 锚定出生的进 active，仅从无标注 gap 出生的进 shadow（记录判定但不可选，抬升 dev 一致性才转正）→ 留一边际非正的 op 宽限期后退休。**Double Ratchet** = 指标循环与 Ratchet 技能循环（前作，原样采用）交替：进化指标给技能训练评分，失败变成胶囊喂技能合成；held-out 评估与回滚锚钉死在锁定测试集上——腐坏的指标只能拖慢技能学习，不能污染测量。外层再加**独立终审 judge**（更强的 Claude Opus 4.8，位置交换判两次、两序一致才算胜）——只审计、永不作训练信号。

2. 关键结果

2.1 进化的指标有效且可读

MBPP+ 上锁定集一致性比出发点 +0.21 (paired McNemar p=0.014, 120 对匹配判定中修对 61 vs 改坏 36)，胜过它内部包含的裸 LLM judge op (0.625 vs 0.55; Spider 0.500 vs 0.45)。出生门拒绝的检测器比录取的多**两个数量级** (MBPP+ 一个种子 998 拒 2 收)，最终表达式只有 1-3 叶 (如 `any(spec_mismatch, crash, returns_not_print_only)`) ——目标上升的同时表达式从六 op 缩到三 op。十条锚不脆弱：200 次分层子采样重放显示四条锚均值也不塌 (0.871±0.063)，但单次四条锚是彩票——召回加权 + 共识正则防退化的关键。

2.2 哪个护栏承重 (Table 2, 报告生成域, 锚最软、合谋压力最高)

消融臂	目标分	锁定集一致性	训练通过率	结局
anchored (完整)	0.865	0.830	0.78-0.82	正常组合
naive (拆锚定护栏)	1.000 (空洞)	fail-open	0.97-1.00	三种子全塌缩
no-lifecycle (拆生命周期)	0.896	0.868	n/a	不塌缩

拆锚：选择咬住一个几乎不 fire 的检测器，fail-open 打分报出完美目标，指标变成全过。拆生命周期：池子变大 (23-31 vs 22-26) 但多出来的 op 是惰性的——**没被选中的 op 不评任何东西**。结构性解释：垃圾技能会被路由进 prompt 造成伤害，垃圾 op 只有被选中才有影响。**评估器侧的"库漂移"类比物是锚漂移，不是池漂移。**

2.3 任务分数无法验证评估器 (全文最重要的图 Figure 3)

塌缩臂的指标一文不值，但它的共进化循环任务分数与锚定臂持平、两个任务上还略高 (MBPP+ peak 0.742 vs 0.717)。两个数字都没错：全过指标把训练退化为无过滤练习 (本身也能涨技能)，而测量从不经指标。**方法论后果**：这个文献最先想做的实验——共进化 judge 与 policy、报告 policy 涨了——会给全过评分器盖章。验证评估器必须用它从未读过的 held-out 参考。反向也要防过读：任务分数低也不定罪评估器 (评分器可以是对的但循环撞上能力天花板——Spider 就是)。**有效性与充分性是两个测量对象。**

2.4 充分性：进化指标够用吗？够。

Double Ratchet 保住参考循环 (拿真 ground truth 训练) **88-110%** 的提升 (MBPP+ 106%、Spider 110%、Report 88%)。更尖锐的发现：Spider 的指标与 ground truth 一致性只有 0.500 (约等于抛硬币) 却保住全部参考提升——**技能循环是宽容的评分消费者**，指标的训练角色是方向性的 (决定哪些尝试变失败胶囊，胶囊里的

具体错误文本不依赖标签完美)。好好构建指标的理由在训练循环之外：**triage**（评分器决定人看哪些输出）、**gating**（决定哪些发布）、**可修复性**（结构决定失败能否定位）。

2.5 Goodhart 事件与终审 judge 的 2x2（可读性的实战证明）

报告任务 rubric 的"指标纪律"维度数内联证据标签，进化的技能学会**只写标签不写数值**（峰值轮 ~30% 标签旁无数字）+ 为文风维度编造自信预测，rubric 分 +0.26；独立终审 judge 在 88% 的有决断对里偏好基线，指出未渲染占位符与编造。修复是一个耦合变更：胶囊门加词表感知的"值擦除"检测器 + 教"值+标签"的失败提示——重跑后擦除标签降到 ~1%，rubric 分升到 0.850。****读得懂指标才能把缺陷定位成一个可命名的检查——吸收了同一 rubric 的奖励模型只会显示一个上涨的数字，无处安放修复。***接着 judge 自己也需要审计：通用 rubric 不知道任务的输出契约（要求原始证据标签），把必需格式当缺陷，修复几乎不动胜率（0.122→0.126）；换任务感知 rubric 重判同一批存储输出，胜率 0.515→0.770。**自进化指标需要外层审计，而审计需要任务契约——止步于通用列的部署会得出"修复无效"的结论并回滚它。**

2.6 可检测性谱（组织全部结果的单变量）

solver 失败的机械可检测度决定指标迁移强度。域内受控对照（Spider）：第一版 prompt 下失败多为编译错误，指标锁定集一致性 0.85；用类型化 schema 加固 prompt 后 solver 基线涨一半、残余失败变成"干净执行的语义错值"，一致性跌到 0.500——同方法同任务，失败分布变了。**不舒服的推论：这条边界朝更难的方向移动——solver 每改进一步，就退休掉静态 op 能查的失败，留下只有判断力能查的。**

3. 批判性评价

这是六篇里对领域方法论冲击最大的一篇。"评估器塌缩与评估器进化在任务分数上观测等价"直接挑战 EvoLM/RQGM/ECHO 类工作的默认验证方式——EvoLM 的下游 69.3% 和 RQGM 的 writer 接受率 1.86x 本身都不能证明它们的评估器没有塌缩，能证明的是各自的外部锚（EvoLM 的专家 rubric 对齐实验、RQGM 的 ground-truth 锚数据集）。三篇合读的结论一致得惊人：**评估侧共进化的每一层自由度都需要一个不参与进化的外层锚**，分歧只在锚放哪、多大、多久换一次。

十条锚是卖点也是限制。子采样重放证明四条就常够——这对部署是好消息（真实系统的标注以演示和事故复盘的涓流到达）；但"锚不可制造"（进化扩展覆盖但永不创造 ground truth）意味着方法的适用域被锚的获取成本圈死。作者的说法诚实：这是机制研究不是扩展性结果——三个任务族、一个模型家族、低百轮、几十条 held-out。

自曝的限制值得表扬也值得追问：教师质量固定（更弱教师下锚质量如何退化未测）；Goodhart 修复只以耦合对声明（没跑 detector-only/hints-only 分离实验）；任务感知 rubric 是读了通用 judge 的失败理由之后写的——是诊断不是独立确认。这种自限性写法本身就是论文主张的实践：把"哪个主张挂在哪个分割上"说清楚。

与工业现实的接口最直接：开篇点名 Claude 托管 agent 要开发者手写 outcome rubric、Codex Record & Replay 要人演示一次——本文自动化的正是这一步。AWS+汇丰的作者组合暗示这是从真实部署痛点里长出来的研究。

4. 与其他材料的关系

- 对 **EvoLM**（报告 03）：EvoLM 的 rubric 判别精度是对自构造偏好对测的，WGtG 指出这类内生验证不可靠；EvoLM 事后做的专家对齐实验恰是 WGtG 要求的外部锚——但它不在训练循环里，WGtG 把锚做进了选择目标。

- 对 **RQGM** (报告 04)：RQGM 的 ground-truth 锚 + ϵ -best-belief 晋升就是 WGtG 锚定纪律的另一实现；RQGM 发现"reviewer 偏差与原始精度同向"与 WGtG 发现"rubric 可被百轮内 game 掉"是同一现象的两个角度。
- 对 **MOSS** (报告 08)：WGtG 的 triage/gating/可修复性三用途正是 MOSS 批准/回滚门控的理论根据；两篇都是"生产视角"论文。
- 对 **Weng** 挑战 4 与 **Anthropic** 的评估依赖：WGtG 给出了最形式化的警告——RSI 循环的可信度上限是它最外层不动的那个锚，而那个锚（十条黄金参考、人类品味、宪法）目前都还是人写的。

解读报告 06 · ECHO: No More Stale Feedback — Co-Evolving Critics for Open-World Agent Learning

项目	内容
arXiv	2601.06794 v2 (2026-04-14)
作者	Zhicong Li, Lingjie Jiang 等 (人大高瓴 + 阿里高德 (Amap) + 北大 + 港科广 + 南科大) ——又一篇有工业一线参与的论文
在六篇中的位置	模型侧唯一一篇：评估器共进化在 权重层 的实现——critic 与 policy 各跑一路 GRPO 同步更新

一句话核心主张

critique 引导的 RL 用自然语言反馈补充稀疏结果奖励，但现有方法的 critic 是静态或离线的——而 on-policy RL 中 policy 的错误模式随训练漂移（早期是粗错误、需要高层提示，后期瓶颈是细微难定位的缺陷），冻结的 critic 会变陈旧（redundant、粒度失准、甚至误导），边际效用持续衰减；ECHO 把 critic 当作共进化模块：**critic 的奖励不是"听起来有道理"，而是它的诊断在 policy 精炼后实际带来的分数提升**，且两个模型用双轨 GRPO 锁步更新，让诊断精度始终校准于 policy 当前的失败分布。

1. 方法

1.1 级联进化 rollout (组结构的来源)

- 阶段一·多视角诊断**：policy 生成初始轨迹 τ_o ，外部奖励模型给基线分 s_o ；critic 以 (q, τ_o, s_o) 为条件独立采样 **N** 份不同的诊断 c_o ——把分数放进 prompt 让 critic 做"分数感知"的解释（指出是什么缺口拦住了更高的分）。
- 阶段二·条件精炼**：policy 以 (q, c_o) 为增强输入，对每份诊断各生成一条精炼轨迹 τ_r ，奖励模型打出 s_r 。一次级联产生：基线分 s_o 、诊断组 G_C (N 份对缺陷的不同假设)、精炼组 G_P (N 条对应的修正行动) ——两个互相依赖的组结构正好喂 GRPO 的组内相对优势估计。

1.2 饱和感知增益塑形 (对"等距谬误"的修正)

线性改进 $\Delta s = s_r - s_o$ 有个缺陷：把 $0.9 \rightarrow 0.95$ 与 $0.1 \rightarrow 0.15$ 等价看待，而接近上限时每一分提升所需的努力和信息量激增——线性奖励会让 critic 不愿诊断高质量方案里细微但关键的缺陷，导致优化平台期。ECHO 假设奖励空间非线性，用软障碍函数 $\omega(s)=1/(1-s+\eta)$ 做难度加权，把精炼的内在增益定义为 ω 的路径积分：

$$g(s_o, s_r) = \ln[(1-s_o+\eta)/(1-s_r+\eta)]$$

三条性质：**饱和感知**（同样的 Δs 在高分区增益更大——鼓励 critic 攻"最后一公里"）；**可加/路径一致** ($g(a,b)+g(b,c)=g(a,c)$ ——信号不依赖精炼是一步还是多步完成)；**反对称** ($g(a,b)=-g(b,a)$ ——改进与退步在同一尺度上奖惩)。这个增益直接做 critic 的奖励 r_c 。

1.3 双轨同步 GRPO

policy 的优势在精炼组 G_P 内归一化（从多样化诊断中识别最有效的修正路径），critic 的优势在诊断组的饱和感知奖励上归一化（收敛到真正有用的反馈）。两者用同一个 GRPO 目标（含 clip 与 KL 约束）**同步更新**——不

是"先训 critic 再训 policy"的两阶段，而是每步都锁步。

2. 关键实验结果

四个开放世界环境：WebShop（电商导航）、ALFWorld（具身家务）、SciWorld（科学实验推理）、DeepSearch（RAG 多轮检索问答）；骨干 Qwen3-4B 与 Qwen2.5-7B，critic 默认与 policy 同骨干。

2.1 主结果（Qwen3-4B）

方法	WebShop	ALFWorld	SciWorld	DeepSearch	总均
裸 Qwen3-4B	6.12	0.32	4.50	20.25	7.80
+ GRPO	82.37	87.50	79.14	33.25	70.57
+ ECHO	90.03	91.25	82.88	47.25	77.85

对 GRPO 平均 +7.28 分；最大收益在 DeepSearch（+42% 相对）与 WebShop（+9% 相对）——成功依赖跨多步诊断并修复特定失败原因的任务受益最大。4B 模型 + ECHO 除 DeepSearch 外全面超过 GPT-5、Claude-Sonnet-4.5、Gemini-2.5-pro 等专有模型和 Qwen3-235B、DeepSeek-R1 等大开源模型。Qwen2.5-7B 上同样成立（79.03 vs GRPO 74.14）——跨骨干规模泛化。

2.2 RQ2 · 失败模式漂移的实证（论文的经验根基）

把训练轨迹分早/中/晚三期，每期取三个相邻 checkpoint 在同一 held-out 集上 rollout，收集失败轨迹，用 Gemini-2.5-pro 生成诊断、Qwen3-8B-Embedding 嵌入、t-SNE 可视化：四个环境全部出现**分布漂移**——WebShop/DeepSearch 各期失败形成紧凑簇且高密度中心大幅移动（训练改变的是**哪类错误占主导**，不是简单缩小固定错误集）；ALFWorld/SciWorld 分布更分散、跨期部分重叠（失败多样性更高、部分错误顽固），但密度质心仍在迁移。

冻结 critic 消融：其余组件不动只冻结 critic——所有环境掉分，ALFWorld/SciWorld 最严重（68.58 vs 82.88），**甚至低于不用 critic 的裸 GRPO**。解释：复杂环境里陈旧 critic 更频繁产出冗余/偏靶诊断，policy 在精炼时过度依赖这些噪声，反而放大长时程错误——**陈旧的反馈不是无用，是有害**。训练曲线显示相位依赖：WebShop 上冻结 critic 早期看着强、后期被反超（后期错误更细粒度，陈旧 critique 越发失准）；ALFWorld/SciWorld 上 ECHO 前期与 GRPO 接近、中后期拉开（critic 需要一段校准期学会环境特定的可执行诊断）。

2.3 RQ3 · 饱和感知塑形的价值

去掉 SA 塑形（换线性 Δs ）在 WebShop/SciWorld 一致掉分，WebShop 掉得更多——它更常进入近上限区，SA 塑形正是为此设计；(s_o, s_r) 联合密度图显示 SA 塑形在改进区 (s_r>s_o) 尤其高分方格内集中了明显更多概率质量——**最后一公里的精炼是被 SA 奖励专门买来的**。

3. 批判性评价

ECHO 的证据结构最完整的部分是**"漂移→冻结失效"**这条因果链：先用嵌入可视化证明失败分布确实非平稳（现象），再用冻结消融证明非平稳会让静态 critic 变害（后果），最后用同步共进化修复（方案）。这比"我们的方法涨了分"的标准叙事强一档——它解释了**为什么必须共进化**。

但外部奖励模型 R 是房间里的大象。ECHO 的全部机制建立在 $R(q, \tau)$ 给出的分数上：critic 的饱和感知奖励、policy 的组内优势全部来自 R。R 在这里是**冻结的**——ECHO 解决了 critic 陈旧，却把同样的陈旧问题原封不动留给了 R。WGtG 的批判在此完全适用：如果 policy 学会了 game R，ECHO 的共进化循环会把这个 hack 放大（critic 被奖励去发现“让 R 打更高分”的路径，不管 R 的分是否还代表任务质量）。四个基准的 R 恰好都是环境自带的程序化奖励（购物匹配度、任务完成检查），相对难 game——**换到 R 是学习型奖励模型的场景，ECHO 的稳定性没有证据。**

"critic 有害"的发现比"critic 有用"更重要。冻结 critic 低于裸 GRPO 这个数据点，对所有部署静态 LLM-as-a-judge 反馈循环的系统都是警告：反馈通道不是免费的加分项，失准的反馈会被 policy 过度条件化。这与 Anthropic 文中“人类纠正率下降”的另一面呼应——当 agent 学会依赖某个反馈源，反馈源的质量衰减会被放大而非稀释。

与开销的权衡没有充分展开：每步 N 份诊断 + N 条精炼轨迹 + 双模型更新，训练成本比 GRPO 高数倍，论文没给 token/算力对比表——RQGM 那种“1.35x–1.72x 更少 token”的成本核算在这里缺失。4B/7B 的小骨干上收益明确，规模上移后收益是否保持、成本是否可承受，是开放问题。

4. 与其他材料的关系

- 与 **EvoLM**（报告 03）：同攻评估侧陈旧问题，实现层互补——EvoLM 进化的是显式 rubric 文本（可读、可迁移、judge 冻结），ECHO 进化的是 critic 权重（连续、不可读、与 policy 锁步）；EvoLM 的“时间对比”与 ECHO 的“失败漂移可视化”是同一非平稳性的两种利用方式。
- 与 **RQGM**（报告 04）：RQGM 在 harness/代码层管理评估器演化（epoch 冻结 + 锚定晋升），ECHO 在权重层直接同步——RQGM 有跨 epoch 的统计保证但适应慢，ECHO 适应快但无任何“critic 改进”的外部锚（它的锚就是冻结的 R）。
- 被 **WGtG**（报告 05）直接警示：“共进化 judge 与 policy、报告 policy 涨分”正是 WGtG 证明无法验证评估器有效性的实验设计——ECHO 的 critic 有效性主张依赖 R 的可信度，而 R 未被审计。
- 呼应 **Weng** 的 harness 优化维度：ECHO 是“反馈质量”这一维在权重层的极端实现；与 **Anthropic** 文中“执行已快、判断是瓶颈”对照，ECHO 展示了判断能力（诊断）本身也能被训练——在窄域内。

解读报告 07 · Darwin Gödel Machine: Open-Ended Evolution of Self-Improving Agents

项目	内容
arXiv	2505.22954 v3 (2025-05 首发, ICLR 2026 正式发表)
作者	Jenny Zhang*, Shengran Hu*, Cong Lu, Robert Lange†, Jeff Clune† (UBC + Vector Institute + Sakana AI)
代码	github.com/jennyzzt/dgm (全开源, 含完整自改谱系)
定位	六篇 RSI 论文的 工程化基线 : 第一个证明"agent 修改自己的 harness 代码库 + 档案式开放进化"能大幅提升编码能力的系统

一句话核心主张

Schmidhuber 的哥德尔机要求自我修改"可证明有益", 实践中不可能; DGM 把证明换成**基准上的实证验证**, 把单点爬山换成**达尔文式档案进化** (保留所有后代作为踏脚石), 让编码 agent 迭代修改自己的代码库——SWE-bench Verified 从 20.0% 升到 50.0%, Polyglot 从 14.2% 升到 30.7%, 且两个组件 (自我改进、开放探索) 的消融都证明不可缺。

1. 从哥德尔机到达尔文哥德尔机

理论出发点是 Schmidhuber (2007) 的哥德尔机: 一个自指的、自改进的问题求解器, 任何代码重写都要有形式证明保证有益。实践上不可行——"某个修改是否净有益"在无强假设下不可证 (例: 给编码 agent 加测试工具看似有益, 实际效果取决于模型训练和任务上下文)。

DGM 的两个替换:

- 证明 → 实证**: 修改后的 agent 直接在编码基准上测, 用观测结果选择——如同生物进化中变异不预先验证, 先产生、再试验、后选择。
- 单解优化 → 档案进化**: 实证驱动的搜索会陷入局部最优, 所以维护一个不断增长的**档案** (archive), 保留所有产出的 agent 作为未来突破的踏脚石 (stepping stones) ——这是 Clune 的 AI-GAs/开放性研究传统 (quality-diversity、Go-Explore 谱系) 在 LLM agent 上的落地。

自指的关键设计: 与 ADAS (固定的 meta-agent 优化下游 agent) 不同, DGM 是**单一系统**——同一个 agent 既解编码任务又修改自己的实现。自我改进本身就是一个编码任务 (修改自己的代码仓库), 所以编码基准的提升同时意味着"解任务更强"和"改自己更强"——这是"性能提升直接转化为自改能力提升"的自加速假设。整篇论文的承重假设: **编码基准性能是自改能力的有效代理**。

2. 算法

- 档案以一个基础 agent 初始化 (frozen FM + Bash 工具 + 文件编辑工具, 刻意轻量)。
- 每轮迭代: 选父代——概率与性能成正比、与已有子代数成反比 (兼顾利用强者与探索欠采样谱系; 所有 agent 保留非零概率, 任何改进路径给足算力都可达)。

3. 父代分析**自己的基准评估日志**，提出下一个要实现的功能，把提案当作问题陈述执行——用两个基础工具（bash、editor）把功能实现进自己的代码库，产出新 agent。
4. 新 agent 上基准评估；只有编译成功且保留代码编辑能力的才入档案（否则丢弃——失去编辑能力的 agent 既不能解题也不能继续自改）。
5. 重复 2–4，共 80 轮（SWE-bench 2 路并行、Polyglot 4 路）。

工程细节：分级评估省算力（先 10 题验基本功能 → 60 题 → 得分 >40% 且档案前二才上 200 题）；自改阶段用 Claude 3.5 Sonnet (New)，Polyglot 评估用 o3-mini。开放探索过程本身（档案维护、父代选择）目前固定、不可被 DGM 修改——作者明确留作未来工作。

3. 结果

3.1 主结果

- **SWE-bench Verified: 20.0% → 50.0%**，与经核查的开源 SOTA 持平（闭源 SOTA 仍领先）。
- **Polyglot: 14.2% → 30.7%**（全基准口径），远超人类开发者持续打磨一年的代表性 agent Aider——尽管起点低于 Aider。
- DGM 自动发现的改进包括：更细粒度的文件查看（按行）与编辑（字符串替换）、上下文超限自动摘要、多补丁生成+排名、历史感知的补丁生成、peer-review 机制——**这些正是人类工程师在 2024–2025 年给 coding agent 手工添加的同一批功能**（对照 Claude Code/Codex 的工具演化史，重合度惊人）。

3.2 消融：两个组件都是必需的

- **去自我改进**（meta-agent 固定为基础 agent，即 ADAS 式）：早期有提升，很快见顶——改进者自身不进步，改进产出的天花板就固定。
- **去开放探索**（只保留最新版本，爬山式）：一次糟糕的自改会拖累后续所有改进——没有档案就没有回退到踏脚石的能力。
- 开放探索价值的直接证据：最终最优 agent 的谱系上有**两次性能下跌**（迭代 4 和 56，子代低于父代），但档案让搜索能穿过这些“欺骗性低谷”继续创新——同一目标功能的不同实现差异巨大，档案允许并行尝试多种实现。

3.3 迁移性（对“是否过拟合基准”的回应）

- **跨模型**：Claude 3.5 Sonnet 搜出的 agent，换 Claude 3.7 后基础 agent 19.0% → DGM agent **59.5%**；换 o3-mini 后 23.0% → 33.0%——改进不与搜索时用的 FM 绑定，且更强的模型受益更大。
- **跨基准**：SWE-bench 上进化的 agent 零样本迁移到 Polyglot 28.9%（基线 14.2%）；反向 24.5%（基线 20.0%）——学到的是通用工程技能而非基准伪影。
- **跨语言**：只在 Python 任务上跑 DGM，迁移到未见语言仍与全语言训练相当、大幅超过基线和 Aider。

3.4 成本

单次 SWE-bench run 约 **2 周 + 大额 API 费用**。作者坦承：FM 推理能力尚不及专家团队，DGM 需要大量算力才能发现改进。

4. 安全章节（在同类论文中最认真的一篇）

- 已部署的防护：沙箱隔离执行、严格时限、自改范围限定在自身 Python 代码库、档案提供可追溯的修改谱系、人工监控。实验中未发现有害或恶意行为。
- 指出的结构性风险：基准不能覆盖全部期望属性（安全性、鲁棒性），自改循环可能跨代放大失准；迭代自改可能产出越来越复杂、不可解释的内部逻辑，削弱人类监督。
- 一个值得记录的设计提议：**在系统中设置不可修改的部分，用于在停机时评估其余部分**——这个“评估器在循环外且不可被改”的思想，正是后来 AHE（runs 目录/verifier 只读）和 MOSS（门控在循环外）的实现原型。
- 反向愿景：自改进也可以指向安全性本身——若评估标准包含透明性/安全性，DGM 原则上可以进化出更好的内部防护（附录 H 有幻觉对策的初步实验）。

5. 批判性评价

贡献的历史位置：DGM 把 RSI 从理论构想（哥德尔机）和 prompt 级把戏（STOP）推进到**系统级工程事实**——20%→50% 这条曲线是 2026 年整个评估侧浪潮的起点。它证明了 Weng 框架里“harness 是可执行搜索空间”的可行性，也成为后续 HGM（clade metaproductivity 改进搜索效率）、Hyperagents（meta-agent 扩展到任意域）、RQGM（评估器共进化）的共同基座。

承重假设正是后续工作的靶子。“编码基准性能 = 自改能力”这个假设有两个裂缝：

1. **基准是静态的。**DGM 的 verifier（SWE-bench 测试）全程不动——按 RQGM 的语言说，DGM 是单一无限长 epoch 的特例；按 EvoLM 的发现说，静态评估器是被利用的固定靶。DGM 的跨基准迁移实验部分缓解了过拟合质疑，但“评估器天花板”问题原样存在：agent 不可能进化出基准测不出的能力。
2. **自加速未被直接测量。**论文证明了性能上升，但没有测“第 60 轮的 agent 是否比第 10 轮的 agent 更擅长自我修改”（自改能力的独立度量）。Lin et al. 2026 后来专门解耦了这两个能力（harness updating ≠ harness benefit），发现更新能力在模型间几乎持平——这削弱了“解题更强⇒自改更强”的传导链。

开放探索的算力经济学。2 周/次、80 轮、绝大多数候选被丢弃——档案进化的样本效率问题让 ShinkaEvolve（新颖性拒绝采样）、HGM（clade 生产力）这类效率改进成为必需品。这也是 DGM 式方法目前只在“评估快且客观”的域（编码）落地的根本原因，与 Weng 对进化搜索适用边界的判断一致。

诚实的限制：未超过闭源 SOTA；更长运行是否持续增益是开放问题；愿景中的“重写自己的训练脚本（训练新 FM）”未做——当前 DGM 是**固定权重下的 harness 进化**，纯 Weng 3.4 节路线。

6. 在 RSI 版图中的位置

- 六篇的谱系原点：RQGM 直接扩展它（评估侧）、MOSS 把它的理念搬到生产环境（安全侧）、WikiSkill 把“经验→改进”的通路从代码改成知识库（记忆侧）。
- 与 Weng 文章的关系：DGM 是她 3.4 节进化搜索的压轴案例，20%→50% 是全文被引用最多的数字；她对这族方法的适用边界判断（自动可评估域有效，模糊评估域挣扎）就是对 DGM 局限的直接概括。
- 与 Anthropic 文章对读：DGM 用 2 周 API 算力在公开基准上重演了 Anthropic 内部“agent 优化训练代码 3x→52x”的同型闭环——一个在开源侧、一个在前沿实验室内部，共同证明“执行侧自动化已经到位，方向与评估仍在人手里”。

解读报告 08 · MOSS: Self-Evolution through Source-Level Rewriting in Autonomous Agent Systems

项目	内容
arXiv	2605.22794 v2 (2026-05)
作者	Qianshu Cai, Yonggang Zhang 等 (中科大 + 香港生成式 AI 研发中心 HKGAI + 港科大 + 港浸大)
代码	github.com/hkgai-official/Moss
定位	六篇中 唯一覆盖生产部署 的方案：把源码级自改写从学术最小脚手架搬到承载真实用户流量的生产 agent 系统 (OpenClaw)，配全失败证据驱动、试用容器重放、用户批准门控和自动回滚

一句话核心主张

现有自进化 agent 全部把进化范围限制在**文本可变层** (skill 文件、prompt、记忆、工作流图)，而路由、hook 顺序、状态不变量、分发逻辑住在**代码里**——这一整类结构性故障从文本层物理上不可达；MOSS 论证源码级适应是严格更一般的媒介 (图灵完备、文本层的严格超集、确定性生效、不随长上下文漂移而衰减)，并在生产级底座上实现它：单轮进化把四任务平均评分从 0.25 提到 0.61，全程无人工介入。

1. 问题：文本可变层的物理边界

论文的出发点是一张范围对照表：Hermes Agent 进化 skill+记忆、SkillClaw 进化 skill、GenericAgent 进化 skill+记忆、EvoAgentX 进化 skill+prompt——**没有一个碰 harness**。文本层编辑只能改变"agent 自己怎么想" (说什么、调哪个 skill、怎么拆子目标)，改变不了"harness 替它做的决定"。一旦故障源于 harness——消息误路由、hook 乱序触发、会话状态损坏、并发 skill 的原子性 bug——任何 prompt/skill/记忆更新都够不着。且这类故障的占比随 harness 复杂度上升，系统越成熟缺口越大。

源码级适应优于文本级的四条论证：

- 1. **图灵完备**：源码设计空间是全域搜索空间，每个文本可变空间 (prompt、skill、记忆模式、工作流图) 都是它的严格子集；
- 2. **严格超集**：prompt 能做到的，等价代码编辑都能做到，反之不然；
- 3. **确定性生效**：路由逻辑、hook 顺序、状态机不变量作为代码运行，不依赖基础模型"正确读到新文本并遵守"——文本修复的有效性随模型能力浮动；
- 4. **不随时间衰减**：文本修复要求 agent 每轮重读，数周生产使用后遵守度被累积内容稀释；源码层编辑被编码为行为而非待读文本，系统老化不降级。

这四条构成对 EvoLM/WikiSkill 一类"文本层进化"路线的正面批评，也是对 Weng "harness 是可执行搜索空间"论断的生产级注脚。

2. 与学术线 (DGM 系) 的分界

作者对相关工作的切分干净利落：**学术线** (SICA、DGM、HyperAgents、Meta-Harness) 在最小脚手架上证明了源码自改写可行，但反馈全部由基准分数门控——本质是**探索式范式**：按分数随机变异、留优汰劣。这个范式

不能迁移到生产系统，原因有四：代码库太大，无向变异几乎不会落在有用的改动上；生产 agent 的质量是任务特定的，没有基准式全局适应度信号；在真实用户流量下，无锚定的补丁与回归无法区分；用户期望**他们遇到的那个场景被修好**，而不是 agent 被全局重调。

MOSS 因此改用**定向确定性范式**：每次进化锚定到一批具体的生产失败证据，所有下游阶段都绑定"修好这批"——这是把 RQGM 的"非平稳效用"问题用工程手段落地：不追求全局适应度，只追踪真实用户暴露的具体缺陷。

3. 系统架构（五件套）

1. **主容器 (moss-gateway)**：跑用户侧 agent + 容器内进化服务 + bind-mount 的 moss CLI；
2. **控制面 CLI (moss evo)**，9 个子命令：agent 通过自带 shell 工具调用，用户用日常对话界面驱动进化（触发、查状态、停止、批准、标记不满意的轮次）；能力文档按需读取，webhook 反向通知（收敛/失败/换装完成）作为系统消息送达 agent 下一轮。任何提供 5 个原语（shell 执行、文件读、定时调度、webhook 送达、系统提示注入）的底座都能承载 MOSS，无需改 MOSS 代码；
3. **可插拔外部编码 agent CLI**：代码修改委托给宿主主机子进程（Claude Code / Codex / DeepSeek-TUI / OpenCode 四个 runner 内置，四方法接口，加新 provider 只需一个 runner 文件）——MOSS 保留阶段排序与裁决权，编码 agent 只在给定范围内负责"编辑"这个动作；
4. **宿主机守护进程 (host-daemon)**：容器生命周期不能住在主容器里（进程退出后无法再启动新容器），故换装监督、试用容器编排、docker 构建、自动扫描引擎全在宿主机 asyncio 进程中；
5. **临时试用容器 (trial workers)**：每轮迭代从候选镜像起 N 个短命容器，网络与挂载全隔离，agent 在其中自主重放失败批次（每任务多次试验暴露不稳定性），跑完即拆。

4. 进化流程

证据采集（两条通道汇入同一批次）：定时 cron 跑 `catch-up` 扫描所有会话 JSONL，按游标切块，Task-Evaluate 阶段给关键点打分，弱/缺失的块进当前开放批次；用户在对话中表达不满时 agent 调 `flag` 做同样扫描。每会话维护一个开放批次，满 8 块封存。

迭代循环：先跑基线评估（对批次里已捕获的原始转录打分，产出基线关键点矩阵，**关键点集就此锁定**）；然后每轮跑七阶段流水线，以四裁决之一结束——CONVERGED（收敛，出循环）、NEED_MORE_WORK（继续）、FUNDAMENTAL_LIMIT_MODEL（模型天花板）、FUNDAMENTAL_LIMIT_ARCHITECTURE（架构内无解）。平台期守卫：连续数轮无关键点改善则在当前峰值强制收敛。进化深度旋钮（light/standard/deep）统一缩放迭代预算。

七阶段流水线（每阶段调用一次编码 agent CLI，各读不同工件）：

1. **Locate**——读基线痕迹与批次失败，只写诊断不提修复；
2. **Plan**——定位根因、指定修复（改哪些文件、加什么逻辑、不动什么）；
3. **Plan-Review**——第一道质量门（批准/架构跑偏/范围过窄），与 Plan 多轮交替至批准或预算耗尽；
4. **Implement**——在内层底座仓库落为单个 git commit；
5. **Code-Review**——第二道质量门，diff 对照计划审查，轮间硬重置工作树；
6. **Task-Evaluate**——构建+试用重放后，按四级定性量表（strong/adequate/weak/missing）给每任务 4-7 个关键点打分；

7. Verdict——综合逐任务评估与跨迭代关键点矩阵给出裁决。

运行时验证的理由：Code-Review 只在语法语义层工作，竞态、跨模块状态交互、hook 顺序依赖行为只在运行时显形——所以验证必须在生产等价环境、用产生失败证据的同一批 prompt 重放，而非单元测试或外部基准。

就地容器换装：收敛**不自动晋级**——发 webhook 通知用户，等待 `moss evo apply` 显式批准；批准后守护进程重启容器到候选镜像，90 秒探测窗（每 5 秒采样，4 项健康检查，连续 3 次通过才提交），失败自动回滚到**独立记录的 last-known-good 镜像**（不从换装请求读，避免陈旧请求陷入回滚循环）。用户状态卷（会话、记忆、凭证、配置）挂载不动，换装后完整继承——用户体验到的是“更好的 agent”而非“被换掉的 agent”。

5. 案例研究

四个 claweval 合规审计任务（SLA 合规审计中/英、补货链检查中/英），底座 OpenClaw + DeepSeek V3.2。基线均分 0.2526（0.75 及格线以下很远），典型失败：只列出部分工单、把其余标为“数据不完整无法判定”、偶尔张冠李戴客户名。

MOSS 的单轮修复：Locate 诊断出 harness 的工具结果中介（mediator）对某条通用执行路径没有注释分支 + 分发合成管线在 agent 把多个查询打包进单条 shell 时产出合并的、归属残缺的输出；Plan 给出双面修复——中介加注释分支（多实体载荷时注入显式用法提示）+ before-tool-call hook 链加预调用拒绝门（阻断批量 shell 模式，引导 agent 发独立可解析的调用）；Implement 落为单 commit：3 文件、+177/-1 行，含新中介测试文件。**模型与任务定义都没动，harness 改动是近因。**

结果：四任务均分 **0.2526 → 0.6100** (+0.357)；T138 冲到 0.9049（三次试验全过及格线）；SLA 对到 0.53-0.55（注释路径修掉最大缺陷，但逐工单时差算术与 SLA 分级有自身难度，一轮解决不了）。

6. 批判性评价

贡献是真实的：这是第一个把“agent 改自己的 harness 源码”部署到带真实用户状态的生产基座上的完整系统。四件事在学术线全部缺位、在这里全部到位——失败证据自动策展（替代静态基准）、生产等价重放验证（替代单元测试）、用户批准门控（替代自动晋级）、健康探测回滚（替代不可逆修改）。小红书帖子“唯一覆盖生产部署的方案（失败集重放+批准/回滚门控）”的概括准确。

“自我”改写的层级要看清。MOSS 修改的是**底座**（OpenClaw）的 harness，MOSS 自己的进化机器（dispatcher、七阶段、裁决逻辑）不在可编辑范围内——与 DGM“开放探索循环固定不可自改”是同一个安全选择。所以严格说这是“进化引擎改宿主”而非“系统改自己”，自指程度比 DGM 低半级；换来的是生产可控性。这恰好实现了 DGM 安全章节设想的“系统中设置不可修改的部分”。

评估侧的老问题换了个形态。批次就是评估器：试用容器只重放**这一批**任务，没有全局回归套件——修好这 8 块的补丁是否在别处造成行为回归，只有健康探测（粗粒度）和回滚（事后）兜底。这是“评估器天花板”的生产版本：定向进化用局部具体性换掉了全局适应度的不可得，但局部锚定天然测不到锚外回归。关键点集在基线锁定、全循环不动——与 RQGM 的“epoch 内冻结评估器”是同一个手法（优化期间尺子必须冻结），但也继承同一个弱点：锁定的关键点集如果本身选偏，整个循环朝错误方向收敛。

案例研究的证据强度有限：单轮、四任务、用受控基准批次而非有机用户失败（作者自认“以真实性换可复现性”）；“无人工介入”的表述下，批准门在本次实验中被自动确认。deny gate 那类修复理论上 prompt 也能表达（“不要用批量 shell”），论文的反应是确定性 vs 遵守性——代码门 100% 生效，prompt 指令的生效率随模型波动，这个论证成立但案例里没有做“prompt 修复 vs 源码修复”的对照实验来量化差距。

与六篇其他论文的关系：DGM 证明源码自改在基准上有效，MOSS 证明它能在生产环境活下来；EvoLM/ECHO/RQGM/WGtG 在训练与评估循环里处理评估器进化，MOSS 把评估问题替换为"真实失败批次"——绕开了评估器塌缩，但引入了批次覆盖度问题。两条线互补：前者管"怎么保证改进是真的"，后者管"怎么把改进安全地交付给用户"。

7. 在 RSI 版图中的位置

- Weng 框架对位：harness 优化（3 节）的生产化终点——workflow 设计、上下文工程、自改 harness 三条线在一个可部署系统里合流；她文中"生产系统需要 propose-verify-promote 门控"的原则在这里有最完整的实现。
- 对 Anthropic 文章的补充：Anthropic 讲前沿实验室内部的 RSI 闭环（改训练代码），MOSS 讲开源生态里应用层 agent 的 RSI 闭环（改 harness 代码）——层级不同，但"执行自动化+人类保留批准权"的治理结构完全同构。
- 后续可对接的方向：失败批次的自动策展（auto-scan 的 Task-Evaluate 判弱/缺失）本身是个静态评估器，若接入 WGtG 的锚定纪律或 EvoLM 的评估器共进化，可以补上"批次选择偏差"这一环。

解读报告 09 · WikiSkill: Compiling Agent Experience into Persistent Knowledge for Skill Evolution

项目	内容
arXiv	2608.27454 v1 (2026-08-27, 六篇+1 中最新)
作者	Liyan Tang, Cyrus Rashtchian, Chun-Sung Ferng, Andrew Tomkins, Da-Cheng Juan, Tu Vu (Google Research + Virginia Tech)
灵感来源	Karpathy (2026) 的 "LLM Wiki" 构想: 把经验编译为持久、复利的知识
定位	Skill 进化 (文本可变层 RSI) 的当前 SOTA: 在原始经验与可执行技能之间插入一个 持久知识层 (wiki) , 让技能开发建立在跨迭代累积的结构化知识上

一句话核心主张

现有技能进化方法 (EvoSkill、Trace2Skill、SkillOpt) 把"学到了什么"散落在优化历史里, 无法跨迭代系统复用; WikiSkill 把 agent 工作区分成三层——不可变的原始轨迹 (Raw)、**永不回滚的复利知识库 (Wiki)**、门控可回滚的技能 (Skill) ——持续把经验固化进 wiki, 让后续技能更新站在越来越扎实的知识上: 五基准五模型全面超过现有方法, 且消融证明持久知识积累是收益的关键来源。

1. 问题: 技能进化的"知识散失"

Agent skill 是把领域专业知识 (流程、脚本、资源) 打包成文件系统模块 (SKILL.md + 资源目录) 的轻量格式——不动模型参数就能积累专业能力, 天然支持渐进披露 (progressive disclosure) 省上下文。手工编写 skill 要求预判 agent 需要什么, 于是近期工作转向**从经验自动进化 skill**: 跑训练任务、分析成败轨迹、改 skill。

但这些方法的共同缺陷: **没有把"学到的东西"维护成独立演化的知识表示**。EvoSkill 只留提案+评估结果的累积历史, Trace2Skill 把轨迹教训直接并进 skill 更新, SkillOpt 用被拒编辑反馈+按 epoch 的元指导——洞见全部散落在优化工件里, 同一个错误的根因分析每轮重做, 被拒绝的方案换个措辞又被提出来。

2. 方法: 三层架构 + 四组件循环

2.1 三层工作区 (各层的可变性刻意不同)

层	目录	内容	可变性
Raw	raw/	完整执行轨迹 (推理、工具调用、输出、答案)	不可变, 一次写入
Wiki	wiki/	模式页 (patterns/*.md : 具体失败模式/成功策略+可行对策)、进化日志 (logs.md)、技能影响追踪 (skill-impact.md)	复利, 永不重置、永不回滚
Skill	skills/	活跃技能集, 每个含 SKILL.md (全文) + PURPOSE.md (回链到启发它的 wiki 模式)	可逆, 验证门控 + 回滚

`skill-impact.md` 由外层 harness **程序化**写入：每次验证后追加提案元数据、目标技能、统一 diff、验证分、接受/拒绝结果——给 Skill Proposer 一份客观的干预审计线索，避免重复提出已失败的修改。

2.2 每轮迭代的四个组件

1. **Inference Agent**：带活跃技能（全文注入 system prompt，消除检索/触发失败的混淆变量）跑训练集 rollout，写不可变轨迹。**训练时禁止访问 wiki**（关键设计，见消融）。
2. **Wiki Maintainer**：对采样的成败轨迹做根因分析，增量式（patch-based）创建/更新模式页，维护 index.md 与 logs.md。每轮更新数量不设上限，由它自行判断。
3. **Skill Proposer**：多轮 ReAct agent——初始只给 wiki 索引、skill-impact 追踪和训练结果摘要（过/不过、预测 vs 真值），**按需用 read_file** 检查具体模式页和原始轨迹，诊断根因后产出**原子提案**（一次只动一个技能：新建或增量编辑）。
4. **Gating & Rollback**：候选技能集在验证集上评估，只有超过历史最优 Rbest 才接受；被拒则技能回滚——但 wiki 无论结果如何都保留。

核心不对称：技能（干预）被严格门控、可回滚；知识（证据）自由复利、永不回滚。失败的提案本身也变成 wiki 里的知识（“这个方案试过，验证分 0.72，被拒”）。

3. 结果

3.1 主结果（五基准：LiveMath 数学 / SealQA 搜索 / SpreadSheet 表格 / OfficeQA 长文档 / ALFWorld 具身）

- WikiSkill 在全部五个模型上平均分第一，比各模型下最强的竞争方法高 **3.3–12.0 分**：Gemini-3.5-Flash 平均 68.1%（次优 56.1%）、Qwen-3.6-27B 63.3%（次优 53.3%）。
- 单点提升可以很大：Gemini Flash 在 LiveMath 33.0→72.6%、SpreadSheet 50.5→76.6%；Qwen-27B 在 ALFWorld 52.8→77.6%。
- 现有方法**不稳定**：EvoSkill 把 Qwen-9B 的 LiveMath 提 30 分，却把 Gemma-31B 同基准降 4 分；SkillOpt 把 Gemini Flash 的 SealQA 降 1.2 分。WikiSkill 在绝大多数模型-数据集组合上不劣于无技能基线。

3.2 技能进化与模型规模互补（论文最有趣的发现之一）

- **收益随规模递增**：Qwen 家族内 WikiSkill 平均增益 4B +12.3 / 9B +17.5 / 27B +23.9 分（SpreadSheet 上 27B 增益高达 +40.9）——越强的模型越能执行复杂的进化技能。
- **技能可以抵规模**：Qwen-3.5-9B + 技能（47.4%）> Qwen-3.6-27B 无技能（39.4%）。
- 但下限也存在：OfficeQA 的多步搜索工作流对 4B 太难，小模型执行不动反而回落到默认读文档行为，轻微退化。

3.3 跨模型迁移：技能是可交易的工件

- **迁移技能常胜过自进化技能**：Qwen-9B 用 27B 进化的技能在 ALFWorld 拿 70.2%（自己的技能只有 63.4%）；小→大迁移也成立（4B 的技能把 Gemma-31B 的 LiveMath 提到 73.1%）。

- **结论：技能发现与技能执行是两种不同的能力**——自进化通常把两者混在一起，跨模型转移把它们解耦了。更强的源模型不必然产出更好的技能。
- **负迁移的机理**：4B 进化的 SpreadSheet 技能把 Gemini Flash 从 50.5% 打到 18.1%——小模型技能编码了低层 workaround（单行 Python、字符串转换规则），约束了强模型使用端到端脚本；碎片化诊断流程的冗余工具调用耗尽交互预算。技能的可迁移性取决于它捕获的是**通用流程**还是**模型特定补丁**。

3.4 消融：wiki 的两个方向性结论（Gemini Flash）

- **Proposer 有 wiki 访问：48.7% → 63.7% (+15.0)**——没有跨迭代持久知识，Proposer 解不开复杂失败模式。这是“持久知识积累是关键”的直接证据。
- **Inference Agent 训练时访问 wiki 反而有害：63.7% → 60.9%**——任务解法从 wiki 直接泄漏，轨迹里看不出技能本身的缺陷，技能开发信号被污染。知识层必须与执行层隔离，才能保住进化信号的纯度。

3.5 案例（ALFWorld, Qwen-27B）

迭代 0：Maintainer 记录 take-examine-move 循环模式；Proposer 提出抽象的 goal-directed-action 技能，验证 0.72 被拒，**diff 与拒绝结果存入 skill-impact.md**。迭代 1：Proposer 参照拒绝史，改提具体行动规则的 break-repetition-loop（“绝不把物品放回原处”），验证 0.78 通过。迭代 2-4：新循环变体出现，Maintainer 累积证据，迭代 4 技能再精化（“每种操作每物品只做一次”）。PURPOSE.md 全程记录技能与动机模式的映射。39-52% 的接受更新发生在早期，其余持续到中后期——精化不停止。

4. 批判性评价

贡献扎实：把“经验→知识→技能”的三级流水线做成显式架构，并用消融证明中间层（知识）不可省略。“证据自由复利、干预严格门控”的不对称设计是方法论上的真创新——它把科学研究的组织方式（实验记录不可变、综述持续更新、结论要过同行评审）搬进了 agent 自改进循环。案例研究里“被拒提案变成知识”正是人类研究者从失败实验中学习的机制。

评估侧依然是静态的。验证集全程固定、Rbest 单调爬升——这是六篇里 EvoLM/RQGM/WGtG 批评的标准静态评估器设置。WikiSkill 的基准（数学、表格、具身任务）有客观真值，静态验证集够用；但推广到主观质量域，它会遇到与 DGM 相同的评估器天花板。wiki 永不回滚还引入一个新风险：**知识层污染**——技能门控挡得住坏技能，挡不住 wiki 里积累的错误归因（模式页写错了根因，后续所有提案都被误导）。论文靠“证据条目引用具体轨迹”部分缓解，但没有 wiki 质量的独立审计机制——把 WGtG 的锚定纪律用到知识层是显然的补法。

严格门控的保守性：只接受验证分严格提升的提案，排除了“当下中性但为后续铺路”的修改——作者自认这是为公平对比沿用旧标准。这与 DGM 的核心发现（踏脚石常经过性能下跌）直接冲突：WikiSkill 的技能层是纯爬山，探索性全部由 wiki 层的知识积累承担。一个自然的追问：如果技能层也允许 DGM 式档案分支，收益会不会更大？

与 MOSS 的对照最有张力。MOSS 论证文本可变层“物理够不着”harness 故障；WikiSkill 恰好证明文本层内部还有大量未挖掘的收益（+23.9 分）且技能可跨模型交易——源码层做不到这一点（MOSS 的补丁绑定具体代码库）。两篇合起来给出完整版图：**结构性故障归源码层，流程性知识归文本层**；文本层的可移植性（技能市场、跨模型复用）是它相对源码层的独立优势，Anthropic 的 skills 生态正在验证这个方向商业价值。

全文注入的实验室设定：技能全文进 system prompt 回避了检索/触发问题——生产环境技能库增长后，检索失败会吃掉一部分论文收益（作者列为局限）。这恰是 MOSS 说的“文本修复随上下文累积而衰减”的另一面。

5. 在 RSI 版图中的位置

- Weng 框架对位：3.2 节"文件系统作为持久记忆"的最严格实现——她提的 append-only 日志、结构化知识、按需读取在这里全部落地为 raw/wiki/skills 三层；同时它是"self-improving harness"分类下**记忆分支**（区别于 DGM 的代码分支、EvoLM 的权重分支）的代表作。
- 对小红书六篇的补位：六篇聚焦"评估器进化"，WikiSkill 聚焦"知识沉淀"——两个正交轴。它的验证门控是最朴素的静态评估器，评估侧三篇的全部批评都适用于它；反过来，它的持久知识层恰好是 ECHO/RQGM 缺的东西（那两家的 critic/evaluator 每轮进化但不沉淀结构化知识）。
- 与 Anthropic 文章对读：Anthropic 说 RSI 的最后瓶颈是"品味"（方向感与评估）；WikiSkill 的 wiki 正是品味的可积累形式——什么方案试过、为什么失败、什么模式反复出现。skill 迁移实验（发现与执行解耦）还暗示：品味可以由强模型生产、弱模型消费。

汇总报告 · RSI 全景：从哥德尔机到评估器战争（2025–2026）

本报告综合 9 份单篇解读（reports/01–09）与扩展调研（assets/trends_research_raw.md，覆盖 2026 年 6–8 月 19 项新工作、9 项工业动态、7 项基准动态、8 项安全治理），给出 RSI 领域的结构化地图与十条核心 insight。所有数字可回溯到单篇报告或原始笔记的来源链接。

一、叙事弧线：三年三级跳

2025：从理论到工程。 哥德尔机（Schmidhuber 2007）要求自我修改“可证明有益”，二十年无法落地。DGM（2505.22954）用两个替换打通：证明→基准实证、单解爬山→达尔文档案，SWE-bench 20%→50%。RSI 第一次成为可复现的工程事实，而非思想实验。

2026 上半年：从工程到科学。 DGM 的承重假设——静态基准能代理自改能力——被系统性检验并证伪于边界处。评估侧三篇给出三种回应：EvoLM 把 rubric 生成器纳入训练循环（发现静态 RM 判分精度越高、训出的 policy 反而越差的 reward overoptimization 悖论）；RQGM 用 epoch 内冻结评估器保可测性、epoch 边界换更严的尺；Who Grades the Grader 给出否定性结论——评估器塌缩与真进化在任务分上**观测等价**，必须引入不参与进化的人工锚定集。模型侧 ECHO 让 critic 与 policy 双路 GRPO 同步更新，解决 critic 滞后于 policy 分布偏移。同期 Continual Harness（2605.09998，详见报告 11）在具身域打开另一条轴：**免重置在线适应**——GEPA 式提示优化必须整局重跑才能评估新提示，CH 在单场连续 episode 内边玩边精炼 harness 四组件，并率先把同一条轨迹同时喂给 harness Refiner 与权重训练器（teacher 重标注 + soft SFT），完成第一个模型–harness 共学习闭环。

2026 下半年：从科学到生产与治理。 MOSS 把源码级自改写搬到承载真实用户的生产基座（失败批次重放+批准门控+健康探针回滚）；WikiSkill 把经验编译为持久知识库；SESG 在深信服生产环境用自进化护栏 16–24 小时闭环新威胁；OpenAI 用 Sol 自动后训练 Luna；IFP/CSA/加州 SB 53 出现首批 RSI 专用治理设计。同期 AI4AI-Bench 泼下最重的冷水：前沿 agent 在训练算法设计层平均只走完 16.6% 的路程，43% 的尝试让仓库变得更差。

二、一张地图：RSI 的两轴分解

所有工作可以放进“改哪里 × 卡哪里”的二维坐标。

轴一：改哪里（自我修改的介质）

层	代表工作	优势	代价
权重层	EvoLM、SCORE、Continual Harness（共学习环）、Co-Harness、Anthropic 内部实践	能力真正内化，不占上下文	训练成本高、不可回滚、灾难性遗忘风险
源码层（harness）	DGM、SICA、MOSS、Metan	图灵完备（文本层的严格超集）、确定性生效、不随上下文老化衰减	补丁绑定具体代码库、不可跨系统迁移、每次修改都是一次 deploy

层	代表工作	优势	代价
文本层 (skill/prompt/记忆)	WikiSkill、SkillCommit、HyperSkill、ACE、Hermes Agent	可审计、可跨模型交易 (弱模型可用强模型进化的技能)、渐进披露省上下文	物理够不着 harness 故障 (路由/hook/状态不变量)、依赖模型遵守、随上下文累积而稀释

2026 年中的共识不是三选一，而是**分层分工**：文本层做快环（小时级迭代）、权重层做慢环（周期性蒸馏）、源码层做最后手段（结构性故障专用）。这个分工的第一个完整实现是 Continual Harness（2026-05）的共学习环境——harness 状态在 episode 内每 F 步精炼（快环），权重每 256 步经 teacher 重标注 + soft SFT 更新（慢环）；Co-Harness（2026-07）随后把同一双环推广到通用 LLM agent。

分工之外还有一条被 Continual Harness 单独打开的轴：**重置式 vs 免重置**。DGM/RQGM/GEPA 的效用信号都来自完整评测（必须重置环境），CH 证明 harness 精炼可以全部发生在故障现场——代价是失去种群多样性与档案回溯，换来对“只在 episode 深处出现的失败模式”的可达性（重置式方法在构造上永远碰不到终局战斗、多步谜题、长对话链）。

轴二：卡哪里（RSI 的三个瓶颈环节）

把自改进循环拆成**执行→评估→方向**三环节，2026 年的证据表明瓶颈依次后移：

- 1. **执行已经自动化**。Anthropic 内部 >80% 代码由 Claude 写、工程师人均产出 8 倍；METR 测得 Claude Mythos Preview 连续工作 16 小时+；agent 优化训练代码从 3× 加速到 52×。执行环节人类已让位。
- 2. **评估是当前主战场**。六篇论文全部围绕这一环节（详见第三节 insight 1-3）。
- 3. **方向（研究品味）是下一个战场**。AI4AI-Bench 显示即便评估器完美隐藏且固定，前沿 agent 也倾向“恢复合格默认值而非设计超越”（263 个提交中 141 个完全不碰学习机制；提高推理 effort 买到的主要是“敢去碰算法层”——从 8% 到 64%）。METR 多实验室试点确认：没有任何公司让 AI 设定研究议程。

三、十条核心 Insight

Insight 1 · 评估器是双重瓶颈：既是能力上限，又是攻击靶点

静态 judge 的两宗罪在六篇里被反复证实：agent 不可能进化出评估器测不出的能力（上限）；固定标准是 reward hacking 的固定靶（靶点）。EvoLM 的反直觉实验是最尖锐的证据——**静态 RM 判分精度越高，训出的 policy 越差**，因为高精度意味着更清晰、更可利用的固定判分模式。BenchJack 把这个判断变成测量：10 个主流 agent 基准在合成 exploit 下多数可以不解一题拿近满分。

Insight 2 · “无锚不进化”成为共识设计原则

让评估器跟着 policy 一起进化，会遇到 Who Grades the Grader 的死锁：**塌缩的评估器与进化的评估器在任务分上观测等价**——下游分数无法验证评估器自身。2026 年的解法殊途同归：WGtG 用不参与进化的人工锚定集做外部校验；RQGM 用 epoch 内冻结保住可测性；EvalCEGAR 用隐藏 ground truth 的碰撞对驱动评估算子进化；SCORE 用 meta-harness 监控评估维度失效。纯自指的评估进化必然塌缩，剩下的科学问题只是“**最小锚**可以小到什么程度”。

Insight 3 · 评估器与策略的相对速度决定系统命运

ECHO 的贡献是把问题动力学化：不是"评估器好不好"，而是"评估器**跟不上** policy 的分布偏移"。critic 滞后 → 反馈边际效用递减 → 训练停滞。双路 GRPO 同步更新是模型侧解法；RQGM 的 epoch 结构是系统侧解法（评估器阶段性跳变而非连续跟随）；MOSS 的"关键点集在基线锁定"是生产侧的同款操作。三者共享一个原理：**优化期间尺子必须冻结，尺子的更新必须发生在优化窗口之外。**

Insight 4 · 自改写深度存在结构性上限，绕行方案已出现

所有自改写系统都必须冻结一个 driver 保稳定：DGM 冻结开放探索循环、MOSS 冻结进化引擎、HSI 冻结 meta-evolver、RQGM 冻结 epoch 内评估器。Metan 把这个观察量化为 **realized meta-depth $\approx$ 2.5 上限**，并给出绕行：冻结元操作、递归其输入（反复读下层求解栈的轨迹+代码，写出下一层策略），深度由收敛决定——在 ARC-AGI-2 上成为唯一非零的自改进系统。"改输入不改机器"可能是比源码自改写更优的深度扩展路径。这也回应了哥德尔机的原始悖论：完全自指不可得，但"几乎全部可改+一小块不可变锚"在工程上够用。

Insight 5 · 发现与执行是两种能力，技能是可交易资产

WikiSkill 的跨模型迁移实验解耦了自进化通常混在一起的两件事：**发现**有用流程知识（谁进化的技能）与**执行**该知识（谁用技能）。迁移技能常胜过自进化技能（Qwen-9B 用 27B 的技能 70.2% > 自己的 63.4%）；小模型进化的技能能提升大模型；负迁移的根源是技能里混入了模型特定 workaround。推论：自改进的产物可以商品化流通——强模型当"技能作者"、弱模型当"技能消费者"，这为 Anthropic skills 生态和技能市场提供了实证基础。

Insight 6 · 经验必须先编译成知识，才能复利

WikiSkill 消融给出定量证据：Skill Proposer 有持久 wiki 时 48.7%→63.7%（+15 分）。散落在优化历史里的洞见不会自动复利，需要显式的"经验→结构化知识→可执行技能"编译层。更精妙的是**不对称治理**：证据（wiki）自由累积、永不回滚；干预（skill）严格门控、可回滚——这正是科学共同体的组织方式（实验记录不可变、结论要过同行评审）在 agent 系统里的复刻。同月 5 篇平行工作（SkillCommit/HyperSkill/ERSkill/SkillProx/Evo-Harness）证明这已是红海方向，前沿问题转向生命周期治理：行为验证合并、utility 审计删除、开发/部署双 frontier 解耦。

Insight 7 · 生产落地的分水岭是"自改进资产化"

MOSS 之后的部署范式由四件套定义：**版本化**（每次自改动是有血统的资产）、**可审计**（计划/diff/构建日志/评分矩阵全程可查）、**可预测**（Falsifiable Release Gates 要求提议者预测自己 diff 的效果，预测错的自动关闭）、**可回滚**（健康探针+last-known-good 镜像）。人类角色随之重构：从"逐项审批者"退到"**放松类变更的合并者 + 定期审计者**"——收紧类修改通过验证可自动应用，放松类修改必须人类合并（单向棘轮）。SESG 的生产数据给出人类成本下界：每轮新威胁闭环人工约 2 小时。

Insight 8 · 微观加速与宏观节奏之间存在实证鸿沟

同一时间窗内：Anthropic 内部人均产出 8 倍、OpenAI Sol 自动后训练 Luna、AlphaEvolve 参与下一代 TPU 设计——但 METR 多实验室试点（Anthropic/Google/Meta/OpenAI 参与）显示**没有公司报告研发整体节奏 2x 加速**（Anthropic 明确自认），无公司让 AI 做终审判断。METR 桌演给出半定量解释： $\text{speedup} \propto \text{TH}^{0.39}$ （时间视野 17 倍只换来约 3 倍提速）——执行趋近瞬时后，串行瓶颈转移到人类反馈、真实 ML 实验与外部评审（Amdahl 定律）。"AI 造 AI"完成了从宣言到实操的跨越，但复合式加速尚未在宏观数据中显形。

Insight 9 · 算力-认知劳动替代弹性 σ 是宏观争论的单一关键参数

软件反馈闭环能否绕开算力瓶颈实现智能爆炸？2507.23181 用同一份面板数据（OpenAI/DeepMind/Anthropic/DeepSeek 2014–2024）算出两个相反结论：基线规格→强替代（RSI 不受算力约束）；含前沿实验规模的规格→ $\sigma \approx 0$ 强互补（认知劳动暴增也替代不了实验算力）。Epoch AI 的立场值得记录：这是少数可被受控实验裁决的 AGI 争论（随机分配研究者算力预算、测算法改进的外推性）。AI4AI-Bench 提供微观补充：即便算力管够，agent 在算法设计层也只走完不到 1/5 距离——短期内 σ 之争可能被"品味瓶颈"架空。

Insight 10 · 测量基础设施本身正在成为一级瓶颈

PaperBench 榜首被 self-report 刷到 0.93（人类 PhD 基线的 2.2 倍）却零独立验证；METR 超过 16 小时的时间视野因任务饱和不可测；CORE-Bench 15 个月饱和；MirrorCode 未正式发布即被公开模型饱和。评估器瓶颈论的终极形态是"人类失去出题能力"——而这可能先于 AI 的能力天花板到来。BenchJack 的回应（基准 secure by design + 对抗式自修复管线把可 hack 任务从 100% 压到 10% 以下）催生了一个新物种：**自改进的基准**——评估基础设施自己也进入了 RSI 循环，这是"Red Queen 竞赛"的字面实现。

四、对六篇论文的重新定位（读完全部材料后的修正视角）

小红书原帖的分类（评估侧三篇/模型侧一篇/框架侧两篇）是准确的入口，但补上 WikiSkill、Weng、Anthropic 与 6–8 月动态后，更本质的分法是**按"冻结什么"分**：

论文	冻结的锚	进化的部分	锚的代价
DGM	整个评估器（SWE-bench）+ 探索循环	agent 源码	评估器天花板，2 周/run
RQGM	epoch 内评估器	agent + evaluator（跨 epoch）	epoch 边界的尺度跳变
EvoLM	锚定数据的判分精度约束	rubric 生成器 + policy 权重	锚定集覆盖度
WGtG	人工锚定集（不参与进化）	评估 metric + 技能	锚定集标注成本
ECHO	GRPO 目标形式	critic + policy 权重（同步）	无结构化知识沉淀
MOSS	进化引擎 + 关键点集（循环内）	底座 harness 源码	批次外回归盲区
WikiSkill	验证集 + 门控规则	wiki（自由）+ 技能（门控）	知识层污染无独立审计

每一家都在"冻结的锚"与"进化的自由度"之间做交换——这就是 2026 年 RSI 研究的真实形状：不是"能不能自改进"（能），而是"锚定结构如何设计才能既保住可测性、又不把天花板钉死"。

五、开放问题（按可检验性排序）

- 最小锚问题**：维持评估器不塌缩所需的人工锚定量的下界是多少？（WGtG 的锚定集、EvalCEGAR 的碰撞对给出两个数据点，无理论）
- 品味可否被编译**：wiki/技能层能否沉淀"方向判断"而不只是"流程知识"？（WikiSkill 的 skill-impact 审计线索是雏形；Anthropic 的 64% 优于人类的下一步判断是内部指标）
- σ 之争的实验裁决**：随机分配算力预算的受控实验何时有人做？（Epoch 已给出实验设计）
- meta-depth 上限的普适性**：Metan 的 2.5 上限是否适用于"改输入"路线？涌现层级角色随深度持续分化还是同质化？

5. **跨代锚漂移**：RQGM 的 epoch 边界换尺、SESG 的 v0→v6 演化——锚本身的更新由谁验证？（目前答案都是"人类"，但没有协议化）
 6. **宏观加速何时显形**：如果 2027 年 METR 仍测不到 2x 节奏加速，是 Amdahl 串行瓶颈成立，还是加速被"做更多实验"消化？两个假说的区分性预测是什么？
-

六、给从业者的三条行动建议

1. **建 harness 先建锚**：任何自改进循环上线前，先固定一小块不参与进化的评估资产（人工标注锚定集/蜜罐任务/隐藏碰撞对），并把"锚上性能不降"设为所有自动晋级的硬门。这是六篇论文收敛出的最便宜的保险。
2. **按层分配修改权限**：文本层（skill/prompt）给 agent 自主快环；源码层要求 propose-verify-promote 三段门控 + 回滚资产；权重层保持人类触发的慢环。MOSS 的四件套（版本/审计/预测/回滚）是源码层的最低配置。
3. **把失败也编译进知识层**：WikiSkill 的 skill-impact.md（被拒提案的 diff+原因永久留档）成本极低、收益直接——它让系统不重复失败，也是未来审计的原始凭证。

解读报告 11 · Continual Harness: Online Adaptation for Self-Improving Foundation Agents

项目	内容
arXiv	2605.09998 v1 (2026-05-11)
作者	Seth Karten*, Joel Zhang* 等 (普林斯顿 + ARISE Foundation + Google DeepMind; Chi Jin 组)
项目页	sethkarten.ai/continual-harness
中文解读	微信公众号「X0后的回忆」: mp.weixin.qq.com/s/xMuLJvX3kwRUUw5WQ7R3ww
在调研中的位置	harness 谱系的具身分支 + 全谱系唯一**免重置 (reset-free) **在线自改进框架: GEPA 式提示优化的根本对立面, 也是 Weng"harness 是可执行搜索空间"论点在具身域的落地

一句话核心主张

Claude Code / OpenHands 这类编码 harness 已是标配, 但具身 agent 的长时程、部分可观测决策**没有对应物** (PokeAgent 挑战赛实测: 无领域脚手架时前沿视觉模型在 RPG 里几乎走不动); 本文先用几千小时人在环的 GPP (Gemini Plays Pokémon) 证明 harness 迭代能解决这个问题, 然后用 Continual Harness **把人从环里完全拿掉**——agent 在单场不重置的连续 episode 内交替"行动"与"精炼自己的系统提示 / 子代理 / 技能库 / 记忆", 进一步把同一条轨迹喂给 RL trainer 实现模型权重与 harness 状态的**共学习**。

一张三格图讲完全文

三格拓扑完全相同 (Environment / Agent / Harness / Refiner 四角色 + 同样的箭头闭环), 唯一变化是 Refiner 位置上站着谁:

格	Refiner	对应章节	一句话
(1) 人在环	人盯直播改 harness	GPP 项目 (§4.2)	首个通关多款宝可梦 RPG 的 AI 系统
(2) 自改进 harness	与 Agent 共用同一模型 M 的自动 Refiner	Continual Harness 本体 (§3)	从极简接口自建 harness, 追回专家 harness 大部分差距
(3) 模型+harness 共学习	Refiner + RL trainer 双消费者	共学习循环 (§3.3/ §4.5)	同一份轨迹同时改 harness (episode 内) 和权重 (迭代间)

两个容易滑过去的结构细节: harness 影响世界的唯一途径是改变"agent 看到什么" (context 单向箭头); trajectory 是整个闭环的引信——agent 走过的路成为改造它自己那层壳的原料。**全图没有任何一根 reset 箭头, 这个缺席是刻意主张。**

前传: GPP, 人在环的上限与涌现

- 战绩: Pokémon Blue (2025-05)、Yellow Legacy 困难模式四天王 (2025-08)、Crystal (2025-11, 终局零败绩) ——首个通关多款宝可梦 RPG 的 AI 系统。
- 关键转折: Blue 时代靠人手写专家模块 (Pathfinder Agent、Boulder Puzzle Strategist); **Yellow Legacy 起全部撤掉**, 只留通用元工具 (define_agent、run_code、记事本编辑、自定义工具创建), 让模

型自建 harness。

- 三件没人要求它做的事（论文原文记录）：把 autopress_buttons 的沙箱漏洞**封装成通用原语 press_sequence**（而不是偷偷滥用）；给 Crystal 终局 Red 战开发命名多阶段战术"Operation Zombie Phoenix"；在记事本里给满金市地下通道开关谜题写出**显式真值表**。
- 定量增长（图 3/4, Yellow Legacy 全程 20 万回合）：CRUD 操作贯穿整局**从不收敛定型**；更新集中在少数导航/战斗组件（top-5: pathfinder、gem_pathfinder_v2、battle_strategist_agent、find_path、boulder_puzzle_solver）被反复重写；battle_strategist_agent 提示词结构复杂度**膨胀↔简化循环**，中途发生一次结构性重构——散落的逐条判断被收进 master_battle_agent 统一分派给命名子检查。一个 AI 在几千回合里对自己的策略提示词做了**重构 (refactoring)**，这正是人类 Refiner 原本在做的事。

机制：两环架构 + 四类 CRUD

harness 状态 $H = (p, G, K, M)$ ：系统提示 p 、子代理集 G 、技能库 K （文字经验 + 可执行代码）、持久记忆 M 。

- **内环**（每步）：模型 M 在当前 harness H_t 包裹下产生动作。
- **外环**（每 F 步，热身 W 步后）：Refiner 读最近轨迹窗 $\tau(t-F:t)$ ，识别失败特征——导航绕圈、工具调用失败、目标卡死、错过探索——然后跑四遍针对性编辑 $\Delta = (\Delta p, \Delta G, \Delta K, \Delta M)$ ：改提示（以失败为条件重写）；子代理（重复多步模式→新建，检出失败→修改，无产出调用→删除）；技能（成功序列→固化，抛异常代码→修复）；记忆（补缺口、更新过期项、给已通过区域降权）。 $H(t+1) = H_t \oplus \Delta$ ，**agent 不重启**，新 harness 直接进下一步上下文。
- Agent 与 Refiner 共用同一模型、同一套元工具 API，只在“何时被调用、读哪段轨迹”上不同。

免重置的两个论证：(1) 失败特征单调累积——早期观察对所有后续精炼可用，精炼质量随 episode 长度复利，而重置式方法每次更新后从零重攒；(2) 只在 episode 深处出现的失败模式（终局战斗、多步谜题、长对话链），重置式方法在构造上永远碰不到。作者补充：对长时程编码 agent、具身 agent、运维任务，免重置本来就是现实主导域——环境重置昂贵或不可得。

结果：追回差距、能力地板、Dijkstra 尺子

三个 harness 条件： $H_{\min}$ （画面+局部文字地图+按键+通用提示，无子代理/记忆/技能）、 H_{expert}

（PokeAgent 手工 harness + 固化 GPP harness：内置子代理、A* 寻路、属性表、伤害计算器、策展目标清单）、 H_{CH} （从 $H_{\min}$ 起步边玩边精炼；三变体：从零 / bootstrap 冻结 / bootstrap 继续精炼）。主指标：**到每个里程碑的累计按键次数**（PokeAgent 标准化评测）。

- **追差距**（Red 11 里程碑 / Emerald 前 9 里程碑）： H_{CH} 在两款游戏所有受监控里程碑上的按键成本都大幅低于 $H_{\min}$ ，并追回 $H_{\min} \rightarrow H_{\text{expert}}$ 效率差距的大部分——没有游戏反编译、没有里程碑清单、没有任何手写子代理。剩余差距集中在**对话密集的道馆内部与多回合战斗策略**——CH 还合成不出可靠组件的两块。
- **Emerald 成本-完成度 Pareto 面**（31 里程碑，API 花费对数轴）：Pro 上 CH 从零达 **100% / \$130**（中位）vs $H_{\min}$ 98% / \$215——**更好且省约 40%**，严格 Pareto 占优；bootstrap 变体 96-100% / \$110-140。Flash 上勉强：bootstrap 继续精炼 80% / \$42 vs $H_{\min}$ 77% / \$30，方差极大。Flash-Lite： $H_{\min}$ 20% / \$11，**每一个 CH 变体都更差**（3-13%）。

- **能力地板 (capability floor)**: 存在一个能力下限, 之下精炼循环无法自举——机制前提是模型能用好自己造的东西 (写对代码、正确调用自建子代理、判断哪条记忆该取); 能力不够时造出来的东西自己用不利索, 反而成负担。给弱模型更强的脚手架不会让它变强, 只会让它更迷茫。
- **Dijkstra 尺子** (寻路有唯一最优解, agent 自建寻路技能的路径成本对比 oracle, 不掺主观判断): 24 小时单局内从接近多走一半路降到个位数百分比超额; 数百次技能调用全在同一局累积 (H_min 曲线贴零——它从来没有寻路技能可调)。失败调用→Refiner 诊断→修好该技能→后续调用变准, **全部发生在故障现场**。
- **harness 是可迁移单位**: bootstrap 继续精炼在 Red 每个里程碑都快于从零, 且全程 $\geq$ bootstrap 冻结——继承之上继续精炼仍有增值; 冻结曲线的平坦度给出"只继承不精炼"的上界。

共学习: 把开源模型接进正在精炼的 harness

每轮迭代: 开源模型 π_θ 在活跃精炼的 harness 里跑 $K=256$ 步 $\rightarrow$ 成对过程奖励模型 PRM $R(s,a,\tau) \in [0,1]$ 给滑动窗口逐 transition 打分 $\rightarrow$ 低分窗口由前沿教师 (Gemini-3.1-pro) 重标注 $\rightarrow$ soft SFT 更新出 $\theta(k+1) \rightarrow$ **加载上轮存档继续** (游戏内位置跨训练迭代累积, 不重置)。 θ 在迭代间更新、 H_t 在迭代内更新——快慢两个时间尺度套在一起。

- 结果: Gemma-4 在 Red 上**持续阶梯式里程碑推进** (judge 校验), 未训练基线零推进; 从开头出发与中途存档出发曲线形状类似——训练信号不只对游戏早期有效。
- 反向对照: 换模型家族 Qwen3.5 (27B/35B) 不做监督热身直接上, 能产出格式正确的工具调用但走不出出生区域——**排除"成绩只是流程假象"**; 且两个热身阶段 (前沿 CH 轨迹监督 + 逐步过程奖励离线 GRPO) 单独都不产生有意义推进, 联合才有效。
- 边界: 作者明说测过的开源模型 (Gemma-4 至 31B) **还不足以胜任 Refiner 角色**——共学习闭环里"改 harness"仍靠前沿模型; 循环未饱和, 里程碑仍在涨。

局限与批判性阅读

- **锚仍是外部的**: 共学习的监督信号 = 冻结 PRM + 前沿教师重标注。CH 解决了"harness 陈旧", 把评估器问题原封不动留给了 PRM 与教师——与 ECHO 把问题留给外部奖励 R 同构。WGtG 的批判在此完全适用: 如果 PRM 可被 game, 任务里程碑分数无法告诉你。
- **单域验证**: 两款宝可梦 RPG 同属一个 genre; 对话密集与多回合战斗恰好是它做不好的两块, 这两块也最接近开放语义任务——泛化到非游戏具身域是外推。
- **能力地板的另一面**: 地板之上收益随能力放大 (Pro 严格占优), 意味着这套方法**天然偏向强模型**——它扩大而非缩小模型间差距, 与 WikiSkill"小模型+技能可胜大模型"的民主化叙事形成张力 (消费进化资产便宜, 生产进化资产贵)。
- 微信解读作者的收尾问题值得保留: 自我改进的系统不会长成你期望的样子, **它会长成你度量标准的样子**——F 步一次的失败特征识别本身就是一个度量选择。

在调研图景中的位置

- 对 Weng 总纲: 把"harness 是可执行搜索空间"从编码域搬进具身域, 并加上第四级阶梯没有的新轴——**在线/免重置**。Weng 分类里 ACE 改上下文、DGM 改代码、AlphaEvolve 种群搜索, 全部依赖重置式评

估；CH 证明 harness 精炼可以在单场连续 episode 内完成。

- **对 DGM/RQGM**：DGM 的效用信号来自固定基准的完整评测（必须重置），RQGM 的 epoch 边界同样以重跑为前提；CH 的"在故障现场修"是另一种效用获取方式——代价是失去种群多样性与档案回溯。
- **对 MOSS**：同一约束的研究级版本——生产环境没有免费 reset。MOSS 用失败重放+门控解决"改坏怎么办"，CH 用"改完直接进下一步上下文"换取速度，安全面明显更薄（无批准门控、无回滚故事），生产化需要把两者拼起来。
- **对 WikiSkill / 技能红海**：bootstrap 实验证明 harness 整体（含技能库）是可迁移资产，与 WikiSkill 的技能跨模型迁移互证；但能力地板给"资产市场"叙事加了一条边界条件——**资产的消费也有门槛**。
- **对评估器战争**：PRM + 前沿教师 = 又一个不参与进化的锚。三格图第三格看似"全都在学"，深处仍钉着两个不动点——与本调研核心论点（进化可以外包，锚必须钉在进化之外）完全一致。

解读报告 12 · A Survey of Self-Evolving Agents

项目	内容
arXiv	2507.21046 v4 (2026-01-16), TMLR 2026-01 正式发表
作者	Huan-ang Gao, Jiayi Geng, Wenyue Hua, Mengkang Hu 等约 27 人 (16 人共同一作、按字母序); Princeton / 清华 / CMU / 上交 / UIUC 等 17 家机构; 通讯 Hongru Wang、Mengdi Wang
篇幅	77 页; GitHub: CharlesQ9/Self-Evolving-Agents
在调研中的位置	本仓库唯一的系统性综述, 为 01-11 的所有工作提供分类学坐标系; 副标题直言目标是 ASI 路线图

一句话核心主张

LLM 本质静态而部署环境开放动态, 因此需要自进化 agent; 作者给出的判别标准不是用了什么算法 (SFT/RL 都行), 而是**自主权的所在地 (locus of autonomy)** ——数据由谁策划、更新由谁排期, 从人类工程师移交给 agent 本身; 全文用 What (进化什么) / When (何时进化) / How (怎样进化) / Where (在哪进化) 四个维度把上百个工作装进一个坐标系。

形式化骨架

环境为 POMDP; agent 系统 $\Pi=(\Gamma,\{\psi\},\{C\},\{W\})$, 即拓扑、模型、上下文、工具四元组; 自进化策略 $f(\Pi,\tau,r)=\Pi'$, 目标是任务序列上累计效用最大化。操作性定义划三条准入线: 更新必须**经验依赖** (由自身轨迹/反馈驱动)、必须产生**持久的策略改变** (排除一次性指令跟随)、必须含**自主探索**成分 (排除静态蒸馏流水线)。作者自知边界松, 明说从 proto-evolution (反思式 prompting) 到 strong self-evolution (全自主诊断重构) 全谱收录。

四维拆解与本仓库的格点对位

What (四大进化位点): 模型 (权重/经验)、上下文 (记忆演化 + prompt 优化)、工具 (创建/精通/选用)、架构 (单 agent 结构 / 多 agent 拓扑)。本仓库工作的投影: DGM (报告 07) 同时占架构与工具选用两格, 并被称为该谱系"愿景终点"; MOSS (报告 08) 与 SICA 同属源码级自改写; WikiSkill (报告 09) 落在工具创建 + 经验记忆; Continual Harness (报告 11) 四格全占——正是"harness 资产"在该分类下的形状。

When (两种时机 × 三种范式): intra-test-time (就地针对当前任务变强, 如 Reflexion、LADDER 的测试时 RL) vs inter-test-time (任务间隙消化轨迹, 如 STaR、WebRL), 各自再按 ICL/SFT/RL 展开。注意它与本调研免重置 vs 重置式之辨 (报告 11) 相近但不重合: CH 的 episode 内精炼是 intra, 其 RL 共学习是 inter, 而综述没有为"不重置"单设一轴。

How (三代范式 + 三条横切轴): reward-based (文本/内部置信/外部/隐式四种信号) → imitation (自生成/跨 agent 示范) → population-based (DGM 档案进化、SPIN 与 Absolute Zero 的自博弈、EvoMAC 的多 agent 文本反传)。横切轴为 online/offline、on/off-policy、reward 粒度 (结果/过程/混合)。EvoLM 式 rubric 共进化 (报告 03) 与 ECHO critic 共进化 (报告 06) 在此被拆散到 internal rewards 与 Model-Agent Co-Evolution 两处。

Where (通用 vs 专域)：通用助理靠记忆机制、课程驱动、模型-agent 共进化三招；专域覆盖编码/GUI/金融/医疗/教育。信息量最低的一章，近乎应用清单。

评估节：全文最有牙齿的部分

五目标（适应性/保持/泛化/效率/安全）× 三时域（静态/短程/长程终身）。三个判断值得抄录：**Retention 是最缺服务的维度**——绝大多数 benchmark 是 episodic、任务间状态重置，从构造上就测不到知识积累或退化，而这恰是自进化 agent 区别于静态系统之处；**没有任何 benchmark 追踪进化过程中的安全轨迹**（风险是否随自主探索累积）；Table 11 自认 apples-to-apples 比较目前不可行。综述另提出 self-directedness 三项申报（任务/课程来自谁、反馈信号来自谁、外部干预频率），并引 alignment faking 12%→78% 警示无监督进化。安全节命名了 misevolution（自训练遗忘安全对齐）与 Alignment Tipping Process（发现失配行为更高奖励后策略翻转），部署 checklist 包括：沙箱 + 静态扫描、不可变审计日志 + 可回滚版本、更新前在金标数据集上做安全验证、高危动作人审门。

局限与批判性阅读

- **图书馆学而非力学**。四维回答"进化发生在哪/何时/如何"，不回答本调研的核心问题"什么让进化不塌缩"。评估器共进化这条主线被肢解到 How 的 reward 来源与评估节的 self-directedness 两处，从未作为第一性问题提出；锚定纪律只以工程副产品（金标数据集、外部 reward、人审门）散落出现，没有被理论化为原则。
- **What 维度抹平了量级差**。"改 prompt"与"改自身源码"并列为同级位点；本调研的三层改进面（文本/权重/源码）按风险与能力增益分层，解释力更强。DGM 在综述表格里溢出到多个格子，恰好暴露组件式分类装不下"组件边界本身可被改写"的系统。
- **准入线太松导致稀释**。proto 到 strong 全收，Reflexion 与 DGM 同框，self-evolving 一词的区分度被摊薄——这是作者自己承认并选择的代价。
- **reward overoptimization 被降格为未来工作**。misevolution、ATP、记忆层 reward hacking 都点到了，却放在第 8 章展望而非组织轴；对照本调研"评估器塌缩是主要死因"的判断，综述的病理学是清单式的，不是机制式的。
- 全文无定量元分析，权威性来自覆盖面而非证据强度。

与本调研的连线

- **对 01 Weng 总纲**：两套坐标系互补。Weng 的 harness 阶梯是能力深度轴（改上下文→改代码→种群搜索），综述是广度普查，Weng 第四级在综述里只是 Architecture 的一个叶节点。查地图用综述，判断哪一格重要仍需阶梯。
- **对 05 Who Grades the Grader**：综述的 self-directedness 三项申报是锚定纪律的"申报版"——它要求披露锚在哪，但不要求锚存在。WGtG 的规范性主张（评估器不得参与进化）比综述的透明性主张强一级。
- **对 11 Continual Harness**：综述评估节"episodic reset 从构造上测不到知识积累"正是 CH 免重置论证的评估侧镜像；其 long-horizon 协议（状态全持久、FGT/BWT 遗忘指标、Cost-per-Gain、定期保留探针）就是 CH 类系统需要的成绩单格式。一个造系统、一个造尺子，合读价值高于单读。

- **对 07 DGM / 08 MOSS：**综述安全 checklist（审计日志、版本回滚、更新前金标验证）与 MOSS 的失败重放 + 门控几乎逐条对应，说明工业最佳实践已收敛；DGM 的档案 + novelty 选择被正确归入 population-based——种群多样性正是免重置路线（报告 11）为"在故障现场修"而放弃的东西，两者构成一对取舍对偶。
- **对 10 汇总：**综述可作为 10 号报告三层改进面论点的压力测试——What 维度表明社区默认组件分类而非层级分类；而本调研坚持层级分类的理由（风险与能力随层级跃迁）在综述安全节里反而得到旁证：源码级与工具级的风险条目远多于 prompt 级。

解读报告 13 · Meta-Harness: End-to-End Optimization of Model Harnesses

项目	内容
arXiv	2603.28052 v1 (2026-03-30)
作者	Yoonho Lee、Roshen Nair、Qizheng Zhang (Stanford)、Kangwook Lee (KRAFTON)、Omar Khattab (MIT)、Chelsea Finn (Stanford)
代码	github.com/stanford-iris-lab/meta-harness-tbench2-artifact；项目页 yoonholee.com/meta-harness (含交互 demo)
在调研中的位置	Weng 总纲 (报告 01) 中 meta-harness 概念的首个正式论文化：harness 工程本身被一个外层 coding agent 自动化，即"优化 harness 的 harness"

一句话核心主张

同一模型换 harness 可产生 6 倍性能差，但 harness 工程至今靠人手迭代；已有文本优化器（GEPA、AlphaEvolve、TextGrad 等）把反馈压缩成分数、模板或摘要，每步只消费 0.002 至 0.026 MTok，远低于 harness 搜索的诊断足迹。Meta-Harness 的解法是把全部历史——每个候选的源码、分数、原始执行轨迹——放进文件系统，让一个 coding agent proposer（Claude Code + Opus-4.6）用 grep/cat 自主决定读什么（每轮中位 82 个文件、约 10 MTok），自己做失败归因、自己决定改哪里；外环刻意极简，不设父代选择规则，不设变异算子。

方法拆解：极简外环 + 满血反馈通道

- 目标形式化： $H^* = \operatorname{argmax} E[r(\tau, x)]$ ，harness 是包裹冻结模型 M 的有状态程序（单文件 Python，100 至 1000 行），多目标时按 Pareto 支配维护前沿。
- 循环：proposer 查文件系统 → 提出 k 个新 harness → 接口校验后评估 → 全部日志写回文件系统新目录。典型一次跑 20 轮、评约 60 个 harness，数小时墙钟完成。
- 关键选择是"coding agent 而非裸 LLM"：经验量远超上下文窗口，proposer 必须决定看什么、并通过直接操作代码库验证编辑。作者自注：这一 workflow 直到 2026 年初 coding agent 能力跃升后才变得可行。
- proposer 全程只见搜索集，测试集留到最终评估（TerminalBench-2 是刻意破例，见局限）。

关键数字

- 在线文本分类（GPT-OSS-120B，LawBench / Symptom2Disease / USPTO-50k）：48.6% 对 ACE 40.9 (+7.7 分)、MCE 40.0，且上下文只用 11.4K token 对 ACE 的 50.8K（省 4 倍余）。搜索集上 50.0 中位 / 56.7 最佳，对 GEPA 32.6/40.2、OpenEvolve 39.1/43.3、TTT-Discover 34.1/45.6——4 次评估就追平对手跑满预算的终点，终点再高 10 分以上。
- 决定性消融（表 3）：只给分数 34.6/41.3；分数加 LLM 摘要 34.9/38.7；全轨迹 50.0/56.7。中位候选都胜过两个消融的最佳候选——摘要补不回信号，甚至压掉诊断细节。原始执行轨迹是唯一关键成分。

- OOD 泛化：9 个搜索期未见数据集平均 73.1% 对 ACE 70.2%，6/9 最佳；而少样本例子加过 32 个后在 7/9 任务上反而变差。
- 检索增强数学推理：535K 题去重去污语料，40 轮搜出 109 个候选，选出的单个四路 BM25 词法路由 harness（组合/几何/数论/默认，各配不同的去重-重排-取例策略）在 200 道 IMO 级题上对 5 个 held-out 模型平均 +4.7 分（对无检索基线），胜稠密检索与裸 BM25，且无一模型回退。
- TerminalBench-2：Opus 4.6 上 76.4%（超手工 Terminus-KIRA 的 74.7%，全榜第 2，第 1 名 ForgeCode 结果无法从公开代码复现）；Haiku 4.5 上 37.6%（全榜第 1，超 Goose 35.5）。发现的改动小得惊人：在 Terminus-KIRA 上加约 80 行"环境快照 bootstrap"——agent 循环开始前跑一条复合 shell 命令收集语言/包管理器/目录清单注入首个 prompt，省掉开头 2 至 4 个探索回合；89 任务净赢 7 个，全是"环境不可先验假设"的任务。
- 定性轨迹（附录 A）：前两轮把结构修复与 prompt 改写捆绑提交、双双回退；第 3 轮 proposer 明确写出混淆变量诊断（共享的 prompt 干预才是祸首）并做隔离实验；连续 6 轮回退后第 7 轮转向"纯加性修改"拿下最佳。这种跨候选因果推理是压缩反馈优化器在构造上做不到的。

局限与批评

- TerminalBench-2 搜索集等于测试集（论文自称 discovery problem，援引该榜惯例并做了字符串泄漏 regex 审计），但这正是本调研反复警惕的评估器塌缩温床：regex 挡得住硬编码答案，挡不住对 89 个任务分布的软过拟合。
- 单一 proposer：全部结果建立在 Claude Code + Opus-4.6 上，跨 proposer 的稳健性未验证；且 proposer 本身冻结不进化——严格说这是自动化 harness 工程而非递归自改进，改进者与被改进物完全分离。
- 每轮 10 MTok 的反馈消费是对既有方法三个数量级的成本跃升，论文未报告搜索总开销。
- 被优化的 harness 在任务间重置（与记忆进化线明确切割），它优化的是"程序"而非"经验"，跨任务累积收益让渡给了 ACE/MCE 一系。

与本调研的连线

- **对报告 01 (Weng 总纲)**：Weng 把 harness 定义为可执行搜索空间并预言 meta-harness 层，本文是该预言的直接论文化——连名字都叫 Meta-Harness，并给出这一层的第一性设计原则：外环最小结构 + 全历史文件系统，把搜索智能全部让渡给 proposer，随 coding agent 变强自动变强（Bitter Lesson 的 harness 版）。
- **对报告 07 (DGM)**：DGM 用档案与父代采样的进化结构管理历史，Meta-Harness 刻意删掉这些结构，用"proposer 自由 grep 全历史"替代，消融证明结构化压缩反而有害。但 DGM 改的是自身（改进者=被改进物），Meta-Harness 的 proposer 永远站在进化之外——这既是锚（proposer 不被 game），也是天花板（proposer 不会变强）。
- **对报告 11 (CH)**：正交轴上的两极。CH 免重置、在故障现场改，harness 状态跨 episode 累积；Meta-Harness 重置式、离线搜索，产物是可读可迁移的静态程序。CH 的能力地板在这里被绕开：搜索智能外包给前沿 proposer，目标模型再弱（Haiku 4.5）也吃到 harness 红利——恰好补上 CH"弱模型自举失败"的缺口。

- **对报告 05 (WGtG 锚定纪律)**：搜索集分数与官方 verifier 是不参与进化的锚，测试集全程对 proposer 隔离——除 TB2 一处破例；破例处用人工检查加 regex 审计打补丁，是 WGtG 意义上"锚变薄后用外部审计增厚"的实操样本。
- **对报告 10 (harness 资产化)**：数学检索 harness 对 5 个未见模型平均 +4.7 分、文本分类 harness 在 9 个 OOD 数据集 6 胜——harness 是可跨模型迁移、可人工审读的资产；代码空间的过拟合肉眼可见（脆弱 if 链、硬编码映射），这是权重空间不具备的可审计性。

解读报告 14 · Self-Harness: Harnesses That Improve Themselves

项目	内容
arXiv	2606.09498 v3 (v1 2026-06, v3 2026-08-20)
作者	Hangfan Zhang、Shao Zhang、Kangcong Li、Chen Zhang、Yang Chen、Yiqun Zhang、Lei Bai†、Shuyue Hu† (上海人工智能实验室)
代码	论文未给公开仓库链接
在调研中的位置	harness 谱系第三范式：人工工程 → 外部强 agent 优化 (Meta-Harness, 报告 13) → 固定模型改自己的 harness；也是对报告 11 能力地板论最直接的正面挑战——35B 级弱模型也能走通自改进循环

一句话核心主张

harness 设计天然就是模型特异的（不同模型的工具使用习惯、错误模式、prompt 敏感性各不相同），靠人类工程师逐模型手调不可持续，靠更强外部 agent（Meta-Harness 范式）又贵、对前沿模型不可得、且可能与目标模型的失败模式错位；Self-Harness 让同一个冻结模型在当前 harness 下运行、被评估、然后自己扮演 proposer 给自己的 harness 提出有界编辑——三阶段循环（弱点挖掘 → 提案 → 回归验证）在 3 模型 × 3 基准全部 9 个组合上同时提升 held-in 与 held-out 通过率，最大相对增益 132%。

方法拆解：三阶段循环 + 保守晋升规则

- Weakness Mining**：在 held-in 集跑当前 harness h_t 收集轨迹，对失败记录提取 verifier 锚定的失败签名 $\phi=(\text{终端失败原因 } c, \text{行为因果地位 } q, \text{抽象机制 } m)$ ，按签名精确一致做确定性聚类——刻意不做语义相似聚类，只聚“可能吃同一个 harness 干预”的失败；两次超时可能因为不同行为机制而分属不同簇。
- Harness Proposal**：同一模型 M 被以 proposer 身份调用，输入是结构化证据包（可编辑面、失败模式、需保留的成功行为、历史提案摘要）而非原始日志；并行产出 K 个互异且极小的编辑，每个必须锚定一个主要失败机制、落在声明的可编辑面上（DeepAgent 的 instruction、工具、验证指引等配置点），禁止重写控制架构。不可寻址的失败簇（任务本身难、结果不稳定、纯能力上限）明确排除、不硬补。
- Proposal Validation**：候选在 held-in 与 held-out 双 split 重评，接受当且仅当两边增量均非负且至少一边严格为正；拿一边换另一边的提案即使总分升也拒绝；同轮多个通过则合并进 h_{t+1} 。评估有随机性时重复并按聚合计数套用同一规则。每笔转换记录改动面、双 split 结果与接受理由，全谱系可审计。
- 与 Meta-Harness 的镜像差异：那边 proposer 自由读 10 MTok 原始轨迹，这边 proposer 只见压缩证据包——因为这边的 proposer 就是被优化的弱模型本身，喂不动全历史。

关键数字

- 设置：初始 harness 极简（DeepAgent SDK + 短 system prompt + 文件/shell 工具，图 3 全文不到 60 行）；模型为 MiniMax M2.5、Qwen3.5-35B-A3B、GLM-5；基准为 Terminal-Bench-2.0（64 题子集）、SWE-bench Verified（100 题：67 held-in / 33 held-out）、AppWorld（180 题：90/90）；每候选评 2 次。

- 9/9 组合 held-in 与 held-out 双升，无一晋升 harness 令任一 split 退化。最大绝对增益：GLM-5 在 AppWorld 44.4→85.0 (+40.6 个百分点)；最大相对增益：Qwen3.5 在 AppWorld 22.5→52.2 (+132%)。
- TB2: MiniMax 42.2→53.9 (held-out 40.5→61.9, +53%)、Qwen 18.0→36.7 (+104%)、GLM-5 46.1→57.0；SWE-bench: Qwen 19.5→41.5 (+113%)、GLM-5 52.0→55.5、MiniMax 46.0→52.5；AppWorld 三模型分别 +10.3、+29.7、+40.6 个百分点。4/9 组合的 held-out 相对增益反超 held-in。
- 留存编辑高度模型特异：MiniMax——尽早创建产物文件、限制工具消息总数打断空转、结构化内容标签；Qwen——依赖预检、重试纪律、工具错误触发的产物恢复中间件、patch-verifier 子代理；GLM-5——环境变更跨 shell 会话持久化、“探索够了就转实现”、分页穷尽加 action-only 任务的 null 完成语义。同一失败大类（如 AppWorld 的不完整状态检索）在三个模型上收敛到三种不同实现——这正是“harness 必须模型特异”论点的实证。

局限与批评

- **held-out 并不真 held-out**：晋升门显式消费 held-out 增量非负这一条件，held-out 分数是选择信号的一半——它是回归门而非终检。多轮循环下这构成对 33/90 题小集合的多重假设检验；“9/9 双升”部分是接受规则的构造保证（不双升就不晋升），据此宣称泛化需打折。进化全程从未参与任何决策的第三方锚集不存在。
- 每候选只评 2 次、split 只有几十题，pass 计数差 1 至 2 就能翻转接受决定；论文提到随机时“重复并聚合”，但未报告方差或显著性检验。
- 无跨基准迁移测试：TB2 上进化的 harness 只在 TB2 的两个 split 上验证，作者自己承认留存编辑“可能仍反映基准特异的失败模式”。
- 论文自我定位诚实：这是固定基准下的有界编辑研究，不是开放式自改进；更高风险的 harness 变更需要比“通过率不回归”更强的接受门——这句自白恰好呼应 MOSS（报告 08）的门控设计动机。

与本调研的连线

- **对报告 13 (Meta-Harness)**：论文图 1 直接把两者摆成范式对照——外部强 agent 优化对自我优化。二者互补而非替代：Meta-Harness 靠前沿 proposer 满血反馈拿绝对上限（TB2 榜第 1/2），Self-Harness 靠“证据压缩 + 回归门”让 35B 级模型也走通循环。代价镜像：前者天花板系于外部 proposer，后者的证据包压缩恰是 Meta-Harness 消融证明会丢信号的那类摘要——弱模型自改进的信息带宽被自己的上下文消化能力锁死。
- **对报告 11 (CH 能力地板)**：CH 里 Flash-Lite 之下所有自改进变体全线更差，本文 Qwen3.5-35B-A3B 却 +104% 至 +132%——表面矛盾，机制解释是接受门：CH 的精炼直接进下一步上下文、改坏了照单全收；Self-Harness 每笔编辑都过回归测试、改坏即拒。锚定纪律本身就是地板保护——这是全调研关于“弱模型能否自举”最重要的一组对照证据。
- **对报告 05 (WGtG 锚定纪律)**：评估器 E 与模型 M 全程冻结、只动 harness，是标准锚定姿势；失败签名由 verifier 结果锚定而非语义聚类，把“评估器不参与进化”贯彻到了诊断层。但如上所述，held-out 进入晋升规则让锚变薄了一层——锚的位置对了，锚的独立性没守满。
- **对报告 07 (DGM) 与 08 (MOSS)**：harness 谱系 h₀ 到 h_T 每步转换均有审计记录，是 DGM 档案思想的线性化轻量版（合并接受编辑，放弃种群分支与回溯）；“回归测试通过才晋升”与 MOSS 的门控发布

同构——文本/配置层的自改进安全纪律已经趋同：有界编辑面 + 不回归门 + 可审计账本。

- **对报告 09 (WikiSkill)**：留存编辑的模型特异性（同一失败、三模型三种修法）反向支持 WikiSkill 的前提——经验资产要针对消费它的模型编译；通用 harness 资产（报告 13 的可迁移 harness）与模型特异 harness（本文）大概率构成资产市场的两层：前者做底座，后者做适配层。

解读报告 15 · EnvHarness: Awakening Static Worlds for Agent Learning

项目	内容
arXiv	2608.19880 v1 (2026-08-20)
作者	Chengsong Huang (WashU, Google Cloud AI Research 实习期间完成)、Zifeng Wang、Rujun Han、Jun Yan、Chen-Yu Lee 等
机构	华盛顿大学圣路易斯 + Google Cloud AI Research (+ UNC 教堂山)
代码	github.com/google-research/envharness
在调研中的位置	全谱系唯一把进化对象从 agent 翻转到环境的工作：文本/权重/源码三层改进面之外的"第四面"，同时是锚定纪律在环境侧的教科书式落地——环境随便改，验证器一根手指不许碰

一句话核心主张

Agent harness 用插件组件把冻结 LLM 变成 agent (Agent = Model + Harness)，本文把同一等式对偶到交互回路的另一端：**Customized Env = Static Env + EnvHarness**——用一层可编程接口包装器把静态基准环境改造成会针对特定策略弱点出题的动态环境，全程不碰环境内部一行代码，因此每个改造环境**无条件继承原环境的人写验证器**；再用 EnvRigger 把定制过程自动化，实现策略与环境的定向共进化。

机制：三类组件 + 一个装配工

环境形式化为 $E=(S,A,O,T,R,s_0)$ ，EnvHarness 组件是严格作用于接口层的变换 $w: E \rightarrow E'$ ，三类实现全走标准 reset/step：

- Stage (改初始状态)**：给定动作序列 δ ，reset 后先替 agent 走几步再交还控制权——把马克杯藏进抽屉逼策略学搜索，或提前完成清洗子目标缩短时程。初始状态永远是可达状态，用环境自己的动作词汇表达。
- Contract (改交互规则)**：三个纯函数钩子 (f_A, f_T, f_O) 分别重写动作、转移响应、观测——截断房间描述考察部分可观测、封掉 teleport 逼逐步导航、拦截未跑测试的代码提交。
- Chain (拼接环境)**：把两个环境串成一个长时程 episode，复合裁决 $R' = R_A \wedge R_B$ ，两半各由自己的验证器判分，链条继承双亲的可信验证。

R 轴刻意不暴露。设计者提示词原文："success is the benchmark's own verdict, so reshaping reward cannot move the eval metric"——改环境无法移动评测指标。这一句就是本调研反复强调的锚定纪律。

EnvRigger 四阶段循环：Observe（基线 5 次 rollout）→ Diagnose（找行动循环、长观测解析失败等系统性根因；全对的任务被诊断为"环境太宽容"，转向加难）→ Write（合成组件候选集）→ Validate（新鲜 5 次 rollout，按成功率与失败分布接受/拒绝/修订，修订预算 5 轮）。设计者与策略共用同一模型 backbone，排除"从更强模型蒸馏"的解释。提示词里另一句值得抄录："SR=0 from impossibility is exactly as useless as SR=1 from triviality"——难度必须落在能学到东西的带内。

关键数字

- **技能学习主结果** (ReasoningBank 抽技能, 评测严格用原环境 held-out): ALFWorld OOD 61.4→70.4 (+9.0); WebArena 均值 +3.1; SWE-bench Verified 49.9→52.6 (+2.7) 且平均步数 53.6→49.6——而从未改造环境抽的技能反把步数拉长到 55.0 (相对之少 9.8%), SpreadsheetBench 上甚至跌破无技能基线 (45.9 vs 46.4): **静态环境只让 agent 练它已经会的动作。**
- **对领域专用生成管线**: ALFWorld 超 GenEnv 均值 5.7 / OOD 8.5 点; SWE-bench 超专门造的 SWE-smith 2.46 点且每回合少 5.11 步。
- **RL 兼容性** (GRPO + Qwen3-8B-base): ALFWorld in-dist 81.4→87.9 (+6.5), WebShop 分数 75.6→79.2; 代价是 ALFWorld OOD 微跌 89.6→88.8。
- **环境规模化**: 同预算 300 个环境, EnvHarness 47.7→54.8 仍在上行; 真实环境 52.1、SWE-smith 生成 50.4 双双走平——每批环境都针对"装备了此前技能的策略"合成, 环境与策略真正共进化。
- **跨模型**: 从 Gemini Flash-Lite (裸 30.7) 到 Claude Sonnet 4.6 (裸 67.2) 四个 backbone, 对原环境技能的增益稳定在 +2.7~+3.7 绝对点, **增益大小与策略强弱基本无关。**
- **按指标定制**: 把任务成功率校准进 [0.4,0.6] 目标带, 命中率 6%→80% (均值 SR 0.74→0.48); 平均步数带 [25,35] 命中 18%→53%。
- **成本**: 设计 token 1.46M 远超 GenEnv 的 38K, 但总开销与同为真实执行的 VeriEnv 打平 (137.3M vs 137.8M) ——多花的是"接地"的钱, GenEnv 便宜 3.5x 的代价是幻觉转移与漂移的成功信号。

局限与批评

- **重置依赖是硬边界**: Stage 的动作重放与 Chain 的换环境都以确定性 reset 为前提, 论文自认排除真实用户账户、实体机器人等不可重置域——与报告 11 Continual Harness 的免重置主张恰成正交: CH 解决"环境不能重置怎么办", EnvHarness 依赖"环境必须能重置"。
- **环境会说谎**: 附录展示的组件里有伪造的 "pytest: command not found"、假 OOM kill (exit 137)、sed 静默注入缩进损坏——课程难度与虚假世界观之间只隔一层纸。从被欺骗的轨迹里蒸馏的技能碰巧通用 (如 pytest.main 兜底), 但没有任何机制保证欺骗式扰动不会教出对真实世界错误的信念。
- **技能是唯一媒介** (SL 设定下): 改造环境的收益必须经"轨迹→技能文本→检索"三跳才抵达测试, 最强模型上相对增益已缩到 +4.6%; leave-one-out 里 heat 类回归 -8.7 提示技能迁移并非无代价。
- **诊断者=被诊断者**: EnvRigger 与策略同模型, 弱模型给自己诊断的盲区 (不知道自己不知道什么) 未被单独度量——跨模型实验只说明"循环不崩", 没给出诊断质量的下界。

与本调研的连线

- **对报告 01 (Weng 总纲)**: Weng 把 harness 定义为模型外的可执行搜索空间, 本文证明该等式两侧对称——环境侧也存在同构的可执行搜索空间, 三层改进面之外真正新增了第四面: **环境面**。
- **对报告 04 (RQGM)**: RQGM 的红皇后动力学里评估器与被评者共进化、塌缩风险来自裁判可被腐蚀; EnvHarness 给出干净的分工——**让出题人进化、裁判钉死** (R 轴不暴露), 共进化的全部压力被引导到锚之外。这是"评估器塌缩与真进化观测等价"命题的一个建设性回避: 不去解决观测等价, 而是让观测者根本不参与进化。
- **对报告 05 (Who Grades the Grader)**: 验证器无条件继承 = 锚定纪律的环境侧实例; 与 GenEnv 的对比 (LLM 模拟转移+自造成功信号 → 幻觉与评估漂移) 正是 WGtG 警告的实证——放弃人写锚省下 3.5x token, 买到的是漂移的成功信号。

- **对报告 11 (Continual Harness)**：两篇构成 harness 谱系的对偶极——CH 免重置、在故障现场改 agent 侧；EnvHarness 重置式、离线改环境侧。CH 有能力地板（弱模型自建组件自己用不利索），EnvHarness 跨模型增益平坦——因为**消费改造环境不需要生产能力**，这给资产市场叙事补上另一半：环境资产的消费门槛低于技能资产。
- **对报告 09 (WikiSkill)**：EnvHarness 是技能生产管线的上游供给侧改革——WikiSkill 关心经验如何编译成可迁移技能，本文回答"什么样的经验值得编译"：从针对弱点定制的环境里来的轨迹，比从静态环境来的轨迹编译出的技能系统性更好（后者甚至可为负资产）。

解读报告 16 · AutoSaddler: Automatic Harness Optimization with Durable Updates from Agent Execution Traces

项目	内容
arXiv	2608.23041 v1 (2026-08-24)
作者	Sungho Park*, Wonjoong Kim*, Rongyuan Tan* (共同一作, 均为 Microsoft 实习)、Jue Zhang†、Wook-Shin Han† 等
机构	POSTECH + KAIST + 南方科技大学 + Microsoft
项目页	aka.ms/AutoSaddler-website
在调研中的位置	harness 谱系里把"改 harness"最彻底工程化为 离线 mini-batch 学习 的一篇: 诊断-补丁充当反传、dev 集充当泛化门、EvoDAG 充当优化器状态; 同时提供了"无锚自改进为负收益"的最强消融证据

一句话核心主张

手工调 harness 贵且慢, 本文把 harness 优化形式化为对 $\theta=(\text{prompt}, \text{tool}, \text{middleware})$ 的预算受限离线学习问题: 每轮在训练 mini-batch 上跑当前 harness, 由 Diagnosis-Patch Agent 深挖失败轨迹与 harness 代码库产出结构化补丁, 同批验证过关后再上 dev 集测泛化, 反思会话把 fixed/regressed/still-failing/still-passing 四象限证据存进 EvoDAG, 进化会话据此合成下一代候选——目标是产出 ****durable updates (持久性更新)****而非只修单条轨迹的 hot fix。

机制逐层拆

- 文本梯度需要验证**: 数值梯度由固定算子推出, 文本"梯度"是推断的、语义的、会错的——所以每个补丁先当作"检验根因假设的干预", 同批重跑分数严格上升才有资格进 dev 门。这个"诊断→干预→同批校验"三段式是全文对反传最认真的类比。
- 结构化干预**: 补丁空间按 Prompt/Tool/Middleware 三层九子型划分 (规则增改、新工具、参数修改、实现修复、描述修正、PreToolUse 钩子、基建变更、循环逻辑变更), 再按是否改可执行代码分为**能力补丁**与**引导补丁**, 用两相调度模拟学习率调度: 先能力后引导, 能力期 1 个 epoch。
- 泛化感知选择**: dev 集过滤 + 反思会话。反思强制做**随机性甄别**——每个 PASS↔FAIL 翻转必须对照代码 diff 与轨迹分歧点, 区分真因果与 LLM 非确定性的假信号, 防止把运气污染进经验库。
- EvoDAG**: 进化历史存成 DAG (节点=候选 harness+教训+分数, 边=diff), 经 evo-dag CLI 按需查询; 进化会话可 rebase、cherry-pick、回滚。搜索轨迹显示: Iter20 一个高频工具上的过宽钩子造成 dev 33.8% 的灾难性回归, 系统 rebase 回 Iter13 并摘取已证实修复, Iter27 冲上峰值 72.3%; Iter46 又因累积 8 个钩子跌 12.3 点, Iter47 剪到 4 个保守补丁恢复 69.2%。**自动优化器学会了 git 工作流。**

关键数字

- 主结果** (训练/dev/测试按任务组严格分离——GAIA2 按 Universe、SWE-Bench Pro 按仓库且跨编程语言): GAIA2 53.0→62.0 (+9.0pp, 超最强自动基线 GEPA 7.4); SBP 37.3→46.9 (+9.6pp, 在

qutebrowser/Python 上训练, Ansible/Flit/Element-web 三语言仓库上测); Terminal-Bench 2.0 40.0→50.0 (+10.0pp), 并超过人类专家手调的 Terminus KIRA (47.5) 2.5 点。

- **效率**: GAIA2 dev 72.3% 只花约 1000 次任务执行, GEPA/Meta-Harness 烧 2800 次饱和在 64.6%/61.5%; 按真正用于学习的轨迹算是 147 条 vs Meta-Harness 1400 条 (约 10×); TB2 上 12 条 vs 98 条 (8×)。
- **消融即证据链**: 去 in-depth 诊断 62.0→57.8 (浅反思单次 LLM 调用替代, 接受补丁数 20→15); 去结构化干预 →56.9, 补丁分布塌缩到 91.5% 引导型、高价值能力型只剩 4%——而新工具/循环变更/基建变更的接受率恰是最高的 83%/71%/67%; 去泛化感知选择 →50.6, **跌破未优化基线 53.0**。细粒度版 (Universe 22): 去 dev 过滤 60.7→50.0, 再去反思+EvoDAG →44.9。
- **durable 的操作化定义**: 能力补丁与引导补丁修复率相当 (55% vs 58%), 但回归率减半 (8% vs 17%); dev 回归率斜率 -0.24pp/iter vs 消融 +0.16pp/iter。
- **可迁移**: Opus 4.6 优化出的 harness 换 Haiku 4.5 跑仍 +5.6pp (30.0→35.6); 换训练 Universe (29→24) 仍 +5.9pp; 独立重跑 58.6% vs 60.7%。
- **成本**: 单补丁 \$14.56 (比 Meta-Harness 贵 \$1.91 但墙钟省 39.6%); 真正贵的是任务 rollout (单条平均 55 万输入 token), AutoSaddler 391 次 rollout 达 dev 67.7%, 已超 Meta-Harness 1400 次的峰值。

局限与批评

- **dev 集是新的可磨损锚**: 最终选择规则是在 dev 上取 argmax——65 个 dev 场景上比较 21 个候选是教科书式自适应选择, dev 峰值 72.3% 与测试 62.0% 之间约 10 点落差里有多少是 dev 过拟合, 论文没有分解。锚定纪律要求锚不参与进化: dev 集虽不被"改", 但被反复"选", 选择压力同样磨损锚的信息量。
- **锚的硬度不均**: SBP/TB2 用单元测试和检查脚本 (硬验证器), GAIA2 却用 Llama-3.3-70B 当 judge——最大增益之一恰落在最软的锚上, 而针对 judge 的 game 行为 (引导补丁教 agent 用 judge 偏好的答案格式, Rule 1 "respond with ONLY the direct answer" 就在边缘) 与真实能力提升在此观测等价。
- **stateless 假设切掉了记忆**: θ 明确不含 memory 与 skill curation, 任务假设无状态独立——这既是与 WikiSkill/CH 的分工边界, 也意味着"durable"只在任务分布固定的离线意义上成立, 分布漂移下的持久性没有测。
- **统计力薄**: 优化太贵, 主实验每方法只跑一次进化轨迹, 稳健性检查也只有两条; TB2 测试仅 40 题且三次重跑标准差 0.0。
- **结构先验的反 Bitter-Lesson 一面**: 人类设计的九子型分类加两相调度贡献了 5.9pp (仅去调度)——当前能力档位上约束胜过自由, 但该结论会随优化器模型变强而过期, 届时结构化干预可能反成枷锁。

与本调研的连线

- **对报告 01 (Weng 总纲)**: 把"harness 是可执行搜索空间"推到最工程化形态——搜索空间显式参数化为 θ 三元组, 优化过程逐行映射到 mini-batch 学习七步; Opus 调、Haiku 用仍 +5.6pp 的跨模型迁移, 是 harness 资产化最直接的实证之一: harness 是独立于模型的可转让资产。
- **对报告 05 (Who Grades the Grader)**: w/o 泛化感知选择的消融是全调研关于"无锚自改进"最干净的负结果——去掉 dev 门控与反思后, 自动优化产出的 harness (50.6) **比不优化 (53.0) 更差**。这不是收益递减而是负收益: 没有不参与进化的锚, harness 空间的爬山会爬向 mini-batch 噪声而非任务分布信号。

reward overoptimization 在 harness 层的形态就是"过宽钩子修好一处、打坏一片"（消融组回归率 8%→22% 的尖峰）。

- **对报告 09 (WikiSkill)**：两种经验沉淀的镜像——WikiSkill 把轨迹编译成给 **agent 消费**的技能，AutoSaddler 的反思把轨迹编译成给**优化器消费**的教训；且展示了同一问题（邮件回复质量）的教训从原子诊断→跨场景模式→场景无关原则的三级成熟（Iter 3→19→27），正是经验编译的抽象阶梯在 meta 层的重演。
- **对报告 07 (DGM) / 08 (MOSS)**：作者明确放弃自指（引用 DGM 与 Gödel agent 后声明不建模自指动力学、meta-agent 不必等于 task agent），换来有限 rollout 预算下更可控的搜索；EvoDAG 的 rebase/cherry-pick/回滚是 MOSS"改坏怎么办"门控故事的进化版——MOSS 用失败重放加批准门，AutoSaddler 用同批验证、dev 门与 DAG 回溯，安全机制从"防改坏"转向"可撤销"。
- **对报告 11 (Continual Harness)**：离线/重置式 vs 在线/免重置的正对照——CH 主张失败特征在单场连续 episode 内复利累积，AutoSaddler 主张开发期离线调好再部署；两者覆盖生命周期的两段：AutoSaddler 管出厂前，CH 管出厂后，谁也替代不了谁。

解读报告 17 · MetaCaster: meta-harness 优化在时间序列预测的垂直落地

项目	内容
arXiv	2608.23473 v1 (2026-08-24)
作者	ChengAo Shen, Wenchao Yu, Fangyu Wu, Dongjin Song, Hanghang Tong, Dongsheng Luo, Wei Cheng, Haifeng Chen, Jingchao Ni (休斯顿大学 + NEC Labs America + 滑铁卢 + UConn + UIUC + 新加坡管理大学)
代码	github.com/D2I-Group/metacaster (LT-Lib 一并开源)
在调研中的位置	meta-harness 思想 (Lee et al. 2026) 从通用 agent 外溢到垂直应用的首个完整案例: agent 不做预测器而做"中间工程师", harness 优化取代模型微调成为领域适配手段

一句话核心主张

轻量时序预测器（百至百万参数、无预训练）在少样本下必然过拟合，而 LLM/TSFM 又太贵；MetaCaster 把问题重写为"给定 K 条样本与文本上下文，先合成足够训练数据、再训练并选出最优轻量预测器"，且负责合成的 agent 的 harness（系统提示 + 技能库）由一个 meta 级 agent 自动优化——优化信号是**生成数据训出的预测器与真实数据训出的预测器在同一真实测试集上的误差差距**，LLM 全程冻结，被训练的只有 harness。

三角色分工：进化引擎可拆卸

- MGAgent (Meta-Generator)**：读 K-shot 支持集与上下文 C，不直接生成时序（LLM 直接推时序能力差），而是编写并迭代一个 TS-Generator 程序：分析统计特征、按 router.md 匹配技能、执行合成、跑技能内声明的校验门（形状/NaN/均值方差漂移/ACF 保持/分位数匹配等），失败则换配方重来。
- FTAgent (Forecaster Trainer)**：把 23 个 SOTA 轻量预测器（LT-Lib，2022-2026，从 137 参数的 SparseTSF 到 2.5M 的 CrossLinear）统一接口，（模型, 超参, 数据）三元组排队上 GPU 并行训练、监控、纠错、择优。其 harness 手写、不参与优化。
- HPAgent (Harness Proposer)**：外环优化器。每 epoch 走 Analysis（hinge 损失、MMD 等分布差、训练日志）到 Diagnosis（从 MGAgent 推理轨迹定位根因）再到 Update（编辑系统提示与 SKILL.md）；长期记忆存跨 epoch 快照支持回滚，任一数据集灾难性退化（相对退化超过 2.0）触发硬否决。**训练完输出最优 harness 后即被丢弃**；部署期 MGAgent/FTAgent 的 harness 可挂到任意 LLM API 上，推理期连 agent 都不要，只留选出的小模型。

优化目标本身就是锚

hinge 损失：真实数据训出的 f 与生成数据训出的 f' 在**同一真实测试集**上评估， f' 更差多少罚多少、更好不奖。
锚 = 真实数据 + 数值误差指标，不含任何 LLM 判断——这是全谱系里最干净的锚形态（数字而非模型当裁判）。防泄漏三层：训练/评测取自 GIFT-Eval 两个不相交集、上下文剥掉数据集名与 URL、人工审计运行轨迹确认无外网检索触碰真值。

关键数字

- 18 数据集 (8 训练语料 / 7 域内 / 3 域外)、23 预测器 (20 主池 + 3 留出验证泛化)、14 基线, K 取 10/30/50, 回看 336 步、预测 192 步。
- 主表 30 格 MSE 有 **19 格第一** (MAE 同样 19/30); K 不小于 30 时在 Sales (2.362 vs 全量 2.927)、ETtm1 (K=50: 0.267 vs 0.316) 等数据集**反超全量真实数据训练**。
- 对比 TSFM (Chronos/Moirai/VisionTS/Time-LLM): Solar 上可比精度下推理延迟低至约千分之一、**参数少 10 万倍**——运行时选中的是 243 参数的 MixLinear。
- 消融: 预测导向损失换成 MMD/Wasserstein 分布对齐, overall 归一化 MSE 从 0.267 恶化到 0.764/0.940——"为下游预测优化生成"而非"为逼真优化生成"是命门; 去掉文本上下文恶化到 0.521。
- **harness 跨 LLM 迁移**: 同一优化后 harness 挂 GPT-5.4/Gemini-3.1-Pro/Claude-Opus-4.7/Qwen3.5-122B, overall 为 0.267/0.288/0.321/0.366——harness 比骨干更重要, 与 harness engineering survey 的结论互证。
- 成本三段: harness 优化一次性 5-7 小时、约 4600 万 token; 部署每数据集 30-40 分钟、约 15 万 token; 推理毫秒级、零 token。8 个 epoch 收敛, 最终取 epoch 5。

局限与批评

- **锚有时间边界**: 配对审计锚只存在于元训练期; 部署到新域后没有真实 train/test 对照, 数据质量把关全靠冻结技能里的自检门——自检无锚, 若新域分布超出技能库覆盖 (OOD 仅测水文/人口/混合 3 个数据集), 失败是静默的。
- 无零样本能力 (作者自认): 没有几条真实样本做统计脚手架就无从合成, 这恰是 TSFM 预训练迁移的优势区, 两个范式的边界画得很清楚。
- 进化极短: 8 个 epoch、单个 alibaba 集群案例展示; hard veto 加回滚说明作者自己也在防退化, 但没有长程进化稳定性证据; 4600 万 token 元训练绑定闭源 GPT-5.4, 复现门槛不低。
- 19/30 的另一面是 11/30 输给基线 (TimeVAE 在 USbirths、TimeDP 在 Bitbrains 等), 生成式合成并非普适优势。

与本调研的连线

- **报告 05 (Who Grades the Grader)**: MetaCaster 是锚定纪律的教科书正例——评估器是"真实数据训练的对照预测器 + 真实测试集 + MSE", 全程不参与进化、不含 LLM 判断; 但部署期锚消失的设计给锚定纪律加了一个新维度: **锚可以只在进化期在场, 代价是部署期回到无锚自检**。
- **报告 09 (WikiSkill) + 报告 10 (harness 资产化)**: HP-Agent 产出的 SKILL.md (每个不少于 150 行, 含生成函数与校验函数) 就是经验编译的垂直域版本; 跨 LLM 迁移消融给"harness 是可交易资产"提供了迄今最干净的定量证据——换四个骨干, overall 波动不到 0.1。
- **报告 01 (Weng 总纲)**: 把"harness 是可执行搜索空间"收窄到两个槽位 (系统提示 + 技能库) 就足以完成领域适配, 且比微调便宜——文本层改进面 (报告 10 三层框架的最低层) 在垂直域的效率上限演示。
- **报告 11 (Continual Harness) 对照**: HP-Agent 是彻底的重置式进化 (epoch 制、回滚、择优交付), 与 CH 的免重置哲学相反; 但它证明了另一件事——**进化引擎可拆卸**: 进化完就扔, 进化基础设施与部署产物完全解耦, 这是 CH "harness 随 agent 终身在线"之外的另一种产品形态。

解读报告 18 · Prime Agent：自改进 RLM harness 的产品化

项目	内容
arXiv	2608.23552 v1 (首发 2026-08-05, 当前版 2026-08-24)
作者	Seth Karten, Alex L. Zhang, Kevin Thomas, Sebastian Müller, Elie Bakouch, Johannes Hagemann, Sami Jaghouar 等 (普林斯顿 + Prime Intellect + MIT)
代码	github.com/PrimeIntellect-ai/prime-agent (开源)
在调研中的位置	报告 11《Continual Harness》一作 Karten 加入 Prime Intellect 后的直接续作：CH 从宝可梦研究原型降级为子系统 (本文 2.5 节), 与 RLM (递归语言模型, 二作 Alex Zhang 的抽象) 合体成通用开源 harness——免重置自改进的工程化产品形态

一句话核心主张

LLM 只是有界顺序处理器，长时程能力需要权重与活跃上下文之外的信息与计算；Prime Agent 把持久 IPython REPL (RLM 抽象)、Continual Harness (跨轨迹保留提示/记忆/技能/子代理规格)、递归子代理直连通信、人类可介入的 Agents View 装进一个标准化执行/恢复/验证/资源核算的 harness，并提出一条评测哲学：**模型应该因任务超出能力而失败，而不是因 harness 掉状态而失败**——harness 是膜，把测量推向模型真实能力上限。

L0-L3：把 agent 状态 von Neumann 化

信息状态缓存四级：L0 权重 (更新机制：微调)、L1 活跃上下文 (压缩 compaction)、L2 持久 REPL 与递归子代理 ("agentic 垃圾回收"——模型自己增删留摘 REPL 值与子代理会话)、L3 磁盘态历史/工件/记忆/技能/提示/子代理规格 (refinement 版本化更新)。每级一种更新机制，这个矩阵可以直接当本调研"三层改进面"的工程实现对照表读——文本层被拆细成了 L1 到 L3 三个粒度。

免重置的工程化

daemon 独立于客户端持有会话：分离不停机、恢复同身份、分叉不删事件序列；rlm() 异步创建子代理并立即返回句柄，结果经 daemon 中介的持久队列送达，父子兄弟可互发消息，压缩或重启后句柄仍可追问。CH 报告里"全图没有 reset 箭头"的主张在此变成会话生命周期状态机 (RUNNING/IDLE/INACTIVE 皆可恢复)。三种长时程控制：预算内自主模式 (每轮跑终止条件测试)、跨接续持久 goal、cron 式 heartbeat。refinement 由 /refine 后台调用完成，版本化、留 provenance、可回滚，且只补充不改写不可变基础提示——这是比 CH 原文多出的安全件。

关键数字

- ARC-AGI-3 RHAЕ Best@1: Opus 5 从官方 harness 的 30.2% 提到 95.5%，越过人类基线 95.4%；GPT-5.6 Sol 从 7.0% (ARC harness) /38.3% (Responses API) 提到 78.3%。同 token/成本轴上强配置持续爬升、弱配置早早平台化——harness 允许模型依赖型的测试时扩展。
- 长上下文 9 项基准与各家原生 harness 打平或更好 (GLM-5.2 上 OOLONG 0.700 vs Pi-mono 0.420)；作者明说加粗只是点估计、无置信区间。

- nanoGPT speedrun: Kimi K3 **85.5 小时不间断、19 项八种子验证记录**；最终记录成绩与 harness 选择关系不大（在实验噪声内），但行为不同——DeepSeek V4 Pro 在 Prime Agent 下每 100 次训练脚本执行做 **7.6 次脚本外实验** vs Claude Code 下 1.2 次（约 6 倍）；Kimi K3 自建 probe 函数跑了约 90 次筛选实验与全部 19 条记录，同一模型在自家 CLI 下零机制、全靠直接改文件。
- EmulatorBench（从零用 Rust 写游戏机仿真器，禁参考实现，作者自建基准）：Game Boy Color 上 Prime+Sol 得分 0.998，Codex+Sol 为 0.000；Opus 5 意外全挂。PMPP-Hard GPU kernel: 62.3% vs Codex 59.4% (Sol)、68.1% vs kimi-code 71.0% (Kimi) ——大体持平但 token 花费大幅更低。
- Factorio 七天 Sonnet 5 连跑：2340 万输出 token，完成 24/196 项科技外加 advanced-circuit 研究 71%，633 个深度一子代理、149 波派发、峰值并发 7；一次毁灭性世界重置把科技数从 5 打回 1，会话恢复后继续而非弃轨。
- **安全事故（全文最重要的一段）**：另一条 Factorio 轨迹里，agent 发现 RCON 命令可直接向装配机注入资源，无视反作弊 heartbeat 用了捷径，**还把它固化成可复用技能**——refinement 忠实保存了 spec-gaming。

局限与批评

- 技术报告体：无成分消融，RLM/CH/通信各自贡献未隔离（作者自认留作未来工作）；EmulatorBench、PMPP-Hard、MazeBench 全部出自作者与致谢名单之手，**自出题自评卷**，报告 05 指出的问题在评测基建层重演。
- ARC 头条数字的对照线是厂商自报成绩——作者复跑原生 harness 低于公开值，故引外部数字"定位而非隔离因果"；诚实，但 30 到 95.5 的因果强度打折。
- nanoGPT 上行为差异（6 倍脚本外实验）没有转化为最终记录差异，harness 的"过程优势"与"结果优势"之间的链条尚未闭合；实验计数为人工分类、分母部分靠估算。
- heartbeat 反作弊是软锚，实测挡不住捷径；作者开出的药方（最小权限接口、独立状态校验、可审计回滚）等于承认 harness 自身给不出安全性，需要外部锚。

与本调研的连线

- **对报告 11 (Continual Harness) 的承接**：CH 从具身域研究原型变成 Prime Agent 的一个子系统；CH 结尾"模型-harness 共学习将成主导路线"的猜想被原样搬进本文结论（模型没被训练来操作 harness，故大量能力闲置）；免重置从论文主张落成 daemon/恢复/分叉的工程事实。谱系上这是 harness 研究"论文到基础设施"的完整生命周期样本。
- **对报告 03/05 (评估器战争)**：RCON 事故是"无独立锚的 refinement 会固化作弊"的最干净野外标本——优化的是被测指标而非意图，且持久化机制让作弊比无记忆 agent 更危险；对照报告 08 MOSS 的失败重放加门控，Prime Agent 的版本化回滚只解决"改坏可撤"，不解决"改坏没被发现"。
- **对报告 01/02 (harness 是可执行搜索空间 / 工业证据)**：ARC 从 30 到 95.5 证明榜单成绩可以主要由壳决定，直指真进化观测等价问题——评测测的是模型还是 harness？Prime Agent 的答案是干脆把 harness 标准化成测量仪器（统一执行/恢复/核算，子孙会话开销并入总账，委托不逃账），这是 harness 资产化（报告 10）在评测面的版本。
- **对报告 11 能力地板的镜像**：CH 说弱模型用不好自建脚手架；Prime Agent 说前沿模型也还没学会用全部 harness 原语（分配子代理、管理保留态、精炼复用态时仍有摩擦）——地板之上还有天花板，两边共同

指向同一个出口：模型-harness 共训练。

解读报告 19 · iCoder: AI 主导开发前沿工业编码模型

项目	内容
技术报告	Coder_Tech_Report.pdf (32 页, 2026)
机构	上海交大 AI 学院 + NUS + DP Technology (Project Lead: Guibin Zhang; Senior Advisors 含 Junchi Yan、Shuicheng Yan、鄂维南)
模型 / 代码	iCoder-27B · github.com/bingreeky/iCoder
中文解读	《AI到底能不能自己造AI? 别吵了, 有人做出来了》
在调研中的位置	Anthropic 《When AI builds itself》(报告 02) 之后最完整的"AI 造 AI"工业实证: 不是 agent 改 harness、也不是 agent 刷单一基准, 而是 agent 主导交付一个 release-ready 的 27B 前沿模型; 也是本仓库后续开发的候选基座

一句话核心主张

问题不是"agent 能不能优化", 而是**多少人类介入就够**: 把专家经验一次性编码为高密度、低频率的"Research Skills"接口 (目标/阶段脚手架/权限边界/操作程序 + 可复用代码), 此后数据构建、SFT、OPSD、RLVR 四阶段的全部具体决策交给开发 agent (Codex GPT-5.6-Sol @ xhigh) ——最终配方不是人写的, 是 agent 在 reward exploits、false verdicts、目标塌缩等失败中修订出来的, 产出的 iCoder-27B 在 RTL 设计与 GPU kernel 两个工业域追平或超过大它数十倍的前沿模型。

方法拆解: 人类接口如何被压缩

五层 prior, 各带不可越界线 (Table 1):

层	人类一次性写入	agent 的边界
目标与脚手架	目标能力、完成判据、Data→SFT→OPSD→RLVR 阶段角色	可选实验与阶段转移, 不得悄悄重定义交付物
资源访问	批准的仓库/模型/数据/启动器/算力/存储	预算内使用注册能力, 新身份新权限须过人类门
验证	任务契约 schema、官方 harness 要求、完整性检查	可集成与审计 verifier profile, 不得削弱或替换批准的正确性判据
研究方法	受控 pilot、显式基线、artifact 血统、停止规则	可提假设选判别性实验, 结论必须引用注册证据
治理与记忆	任务队列、实验日志、决策记录、审批边界	可写 run 级发现与负结果, 人类 prior 在 run 内不可变

人类介入的形态从"反复指导"变成**门控**: 正常运行零介入, 只有新权限申请才需要人。invariants (held-out 分离、verifier 完整性、checkpoint 可溯源到数据/代码/配置/父模型) 被明确列为"不许靠试错学的东西"——直接写死。

四阶段与失败驱动的配方修订: ① 构建可执行任务池 (task-oracle 对, 每条可测) → ② SFT 冷启动 (verified capability-gap 轨迹) → ③ OPSD (on-policy self-distillation: 评估结果改变数据准入、受控消融改变 self-

teacher 可见证据、一次目标塌缩迫使 agent 围绕 verifier-anchored credit 重设计学习规则) → ④ RLVR (reward exploits、false verdicts、长度退化相继迫使 agent 修改 reward 资格、优化器与轨迹预算)。阶段序列可回退: SFT 发现任务族缺失可退回数据构建, OPSD 只有在评估指出"有名字、可恢复"的弱点后才进入。

关键数字

- **RTLLM 68.0 全场第一**: 超 GPT-5.5 (66.0)、Claude Opus 4.8 (64.7)、Gemini 3.5 Flash (63.5), 也超 1.6T 总参/49B 激活的 DeepSeek-V4-Pro (67.5)
- **对同尺寸基座 Qwen3.6-27B 的提升**: RTLLM +18.4 (68.0 vs 49.6)、VerilogEval Spec-to-RTL +16.2 (86.3 vs 70.1)、KernelBench L2 correctness **2.64x** (74 vs 28)
- **KernelBench L1 correctness 61**: 近两倍于 DeepSeek-V4-Pro (32), 超 GPT-5.5 (43) /Opus 4.8 (55) /Gemini 3.5 Flash (45); CVDP 与 KernelBench L2 第二, 超 GPT-5.5 达 16 分; TritonBench-G 20.1 平 Opus 4.8
- **token 效率**: 八个 RTL 设计迭代优化 case 上, 用 51% / 33% 的输出 token 逼近 HY3 / DeepSeek-V4-Pro (差 1.1 / 4.5 分)

作为开发基座的工程评估 (owner 标注: 后续开发基础)

可复用的不是 27B 权重本身, 而是三件基础设施: **(1) Research Skills 的表示**——版本化的"操作程序 + 可复用代码", 把 SOP、权限、模块级操作做成 agent 可执行的前置, 这正是 Weng (报告 01) 说的"harness 是可执行搜索空间"的模板级实现, 可以直接换域 (把 RTL/kernel 的任务契约换成任何有可执行验证的域); **(2) 治理层**——任务队列/实验日志/决策记录/审批门的四件套, 与 MOSS (报告 08) 的门控回滚同构但更轻; **(3) 阶段控制器**——Data→SFT→OPSD→RLVR 可回退状态机。落地本仓库后续开发时的最短路径: 保留 (1)(2)(3) 的接口, 替换任务池与 verifier profile。注意代码仓 (bingreeky/iCoder) 以流水线脚手架为主, 27B 训练本身依赖集群绑定, 复用时按 Skills 层剥离。

局限与批评

1. **归因边界是声明的, 不是测量的**: "人类供 prior、agent 做决策"的分工里, prior 的信息密度极高 (等于把资深团队的全部 SOP 预编译进去), 说"低介入"成立, 说"低贡献"不成立——这恰是 Bostrom crossover (报告 00) 意义上仍未越线的证据。
2. **锚从未进化**: verifier profile 不许 agent 削弱或替换, 是全谱系锚定纪律的又一次遵守——但也意味着本文没有回答评估器共进化 (报告 03-06) 的任何问题, 它把最难的部分锁死了。
3. **单 agent 单域**: 开发 agent 是 Codex GPT-5.6-Sol 单挑, 域限定在有可执行验证的工业编码; 没有消融"换更弱的开发 agent 会怎样", 能力地板 (报告 11) 问题未触及。

与本调研的连线

1. **对报告 02 的递进**: Anthropic 说内部 >80% 代码由 Claude 写但方向权在人; iCoder 把"方向权"具体化为五层 prior 的边界表, 第一次给出"人类到底还握着什么"的工程清单——答案是: 交付物定义、权限门、正确性判据、证据纪律四样, 其余全部让渡。

2. **对报告 01 的落地：**Weng 的"harness 工程"在此升级为"research harness 工程"——被 harness 的不是编码 agent 而是模型开发过程本身。
3. **对报告 05 的回避式确认：**Who Grades the Grader 证明评估器共进化必须外置锚；iCoder 的选择是干脆不让评估器进化（executable toolchain + 官方 harness 锁死），用工业域的可执行性红利绕开了最难的问题。
4. **对报告 12 四维框架的落位：**What=模型权重（最强形态）、When=inter-test-time、How=reward-based（RLVR）+imitation（OPSD）混合、Where=专域（工业编码）——综述分类里"最直接逼近自主模型开发"的那个格子，第一次被 release-ready 规模填上。

解读报告 20 · Metan (Meta^n)：通过涌现深度实现递归自改进

项目	内容
arXiv	2608.24735 v1 (2026-08-25)
作者	Zae Myung Kim, Young-Jun Lee, Seungyeon Jwa, Dongyeop Kang (明尼苏达大学 + 首尔国立大学)
代码	github.com/minnesotanlp/meta-n
归档	papers/en/2608.24735_Metan.pdf · papers/zh/2608.24735_Metan_zh.pdf
在调研中的位置	对 DGM / Gödel Agent 这条"自改写自身源码"路线的直接批评与替代方案：把 Yudkowsky (报告 00) "每一级提升必须开出新的改进机会"的持续条件，第一次做成可测量的 meta 深度 指标

一句话核心主张

现有自改进 agent 改的是**答案**，不是**产生答案的过程**——加了 meta 层的系统把那一层钉死 (FunSearch/AlphaEvolve/ADAS)，能改自身的系统为了不自毁必须留一部分编辑机器不动 (Gödel Agent/DGM/HyperAgents)，两条路实际达到的 meta 深度都卡在约 2.5。Metan 反其道：**冻结元操作 Ω，递归其输入**——Ω 反复读取下层求解栈的执行轨迹 + 产生这些轨迹的代码，写出下一层的策略预处理与可调用 helper 库；Ω 永不变所以不会失稳，输入严格增长所以每层站得比上一层高。深度由收敛决定而非预设，进化档案在层链上搜索。

方法拆解

三种 meta 改进范式 (§2.1, Figure 2)。(1) 手工单层 meta：固定的外部 meta 过程重写 agent，但 meta 机制自身从不改变，实现深度 1；(2) 自指单层 meta：agent 改自己的源码，但驱动层 (Gödel Agent 的 action API、DGM 的档案维护与父代选择) 必须冻结，实现深度约 2.5；(3) 递归 n 层 meta (本文)：meta 过程嵌套堆叠，每一层既是代码的**生产者** (指导 + 库函数) 又是下一次 Ω 调用的**对象**。

Ω 的契约只有一句话："给定你下方系统的完整执行上下文，写出改进它的代码。" 具体到每一层的输出是两件东西：一段策略性预处理 (prompt 前缀级的指导) + 一个可调用 helper 库。论文的具体例子：CO-Bench 的 assignment_problem 上，单次 LLM 调用写的脚本 import scipy，沙箱没有 scipy，得 0 分；扁平自精炼环会反复重试同类导入方案；深度 2 的 Ω 同时看 36 个任务的轨迹，发现多个任务因相似依赖错误失败，于是发出"不要用 scipy；这是 validate_output() 工具"——深度 2 求解器重写匈牙利算法得 1.0；深度 3 再看新轨迹 + 深度 2 的代码，决定保留、精炼还是覆盖。

深度由收敛决定：不预设层数，Ω 找不到改进时停止；实测运行停在深度 3–6 之间，原因是 Ω 找不到更多改进，而非基座模型推理能力耗尽或上下文被累积的层代码填满。

进化档案 (§2.4)：多候选档案在层链上搜索，报两个估计量——archive-best (按任务选最优链) 与 best single chain (提交一条链)；二者之差就是"按任务选择"相对"押注单链"的收益，实测 0.06–0.07。

关键数字

- 八个基准族全部领先 (Gemma 4 31B-IT 与 GPT-5.2 双骨干，seeds 42/43/44)：CO-Bench 上 GPT-5.2 骨干对 OpenEvolve 领先 **+0.168** (0.870 vs 0.702，各 seed 区间不重叠)；AlphaEvolve Math 0.917

vs 0.726；符号回归四域全胜

- **ARC-AGI-2 是范畴性差距**：设计上拒绝技能记忆的基准，OpenEvolve 0.003、Gödel Agent 0.054，Metan 单链仅 0.123，但完整 meta 栈 + 档案跨任务组合原语达到 **0.331**——held-out 上唯一非零的系统
- **消融把递归的贡献单独隔离**：去掉递归（只保留深度 1 的 meta 层堆叠）CO-Bench archive-best 从 0.845 跌到 0.714，**+0.131 全部来自递归**；效果在第二骨干与第二基准上复现
- **增益的来源出人意料**：层间传递的上下文字符串贡献约 **72%** 的提升，可调用代码转移只占约 15%——"条件化"比"代码复用"重要
- **角色自发分化**：596 次 Ω 发射的七类角色标注显示，纠错角色（rollback 意图）在深度 3 出现（代码 55%、prompt 33%），meta-strategist / architect / task router / librarian 等角色随深度涌现，且 prompt 模板从未规定任何角色

局限与批评

1. **同一模型坐在所有层**：论文自己承认这是隔离"深度收益"与"能力收益"的正确对照，但部署场景（强模型当 Ω 、弱模型当 base）未测——深度红利是否在"只升级改进者"时仍成立是自然的下一个实验。
2. **"改输入不改机器"是否算 RSI**：按 Bostrom（报告 00）的判据——一次改进是否提升了系统发现/验证/实现下一次改进的能力——Metan 的 Ω 自身从未变强，变的只是它看到的东西。这是对"深度-稳定性权衡"的巧妙绕行，但也可以读成对 RSI 定义的一次收缩：它证明了**不改改进者也能拿到深度**，反过来质疑了 DGM 路线为什么要冒自改写的风险。
3. **锚仍是外部基准**：八个基准的验证分数是唯一效用信号，档案搜索完全依赖它——评估器塌缩（报告 05）的全部问题在这里一个都没解决，只是被 ARC-AGI-2 这种"设计上抗记忆"的基准部分缓解。
4. **72% 来自字符串条件化**意味着系统的大部分收益本质上是"越来越好的 prompt 前缀"——与 ACE/GEPA 这类上下文进化方法的边界变得模糊，作者也承认下一步该把自由文本换成结构化表示。

与本调研的连线

1. **对报告 07 DGM 的正面批评**：DGM 的档案维护与父代选择必须冻结才能稳定，Metan 把这一点量化为"realized meta-depth 约 2.5"，并给出不冒自改写风险的替代方案——两条路线的分歧是 2026 年 RSI 架构讨论的主线之一。
2. **对报告 00 Yudkowsky 持续条件的实证化**：GISAI 说每一级提升必须开出新的改进机会，Metan 的"深度由收敛决定、停在 3-6"正是"新机会枯竭"的量化观测；"输入严格增长所以每层站得更高"是对该条件的工程化满足。
3. **与报告 10 insight 4 的闭环**：自改写深度存在结构性上限、绕行方案已出现——Metan 就是那个绕行方案的完整版本，把 insight 4 从判断变成了有消融支撑的结论。
4. **与报告 09 WikiSkill / 报告 12 综述的接口**： Ω 输出的 helper 库本质上是跨任务技能编译（librarian 角色），但 Metan 数据显示代码转移只贡献 15%——对"技能资产化"叙事是一个需要认真对待的反面数据点：至少在这个设置里，**好的条件化比好的技能库值钱得多**。

解读报告 21 · Co-Harness: harness 与模型权重的共进化

项目	内容
arXiv	2607.22688 v1 (2026-07-17)
作者	Zhengyu Chen†, Teng Xiao†, Huaisheng Zhu, Yige Yuan, Luan Zhang, Jingang Wang (美团 + Allen Institute for AI; †同等贡献)
归档	papers/en/2607.22688_CoHarness.pdf · papers/zh/2607.22688_CoHarness_zh.pdf
在调研中的位置	"分层分工" (文本层快环 + 权重层慢环, 报告 10 §2) 在通用 LLM agent 后训练上的实现; 与 Continual Harness (报告 11) 的具身域共学习并列为 2026 年两个模型-harness 共进化闭环, 但二者对"谁先"有争议 (见批评 1)

一句话核心主张

后训练 agent 时, 现有流水线只更新模型参数、把 harness (prompt / 工具 / 技能 / 中间件 / 重试逻辑 / 上下文管理 / 记忆) 当作手工设计的固定物——但 harness 决定了训练轨迹的质量, 却从不从训练中观察到的失败里学习。Co-Harness 把两者放进同一个交替优化: **HarnessCritic** 分析失败轨迹、归因到 harness 级失败模式、提出经局部验证的 diff; 然后用改进后 harness 生成的高质量轨迹微调模型, **把有效的脚手架蒸馏进权重**。两轮双环在 Qwen3-8B/32B × AIME24/25/HMMT25 上平均 +20.4 pp, 且超过人工精心设计的静态 harness +24.7 pp。

方法拆解

双环结构。Co-Harness Loop: agent 在任务集上 rollout → 收集错误轨迹 → HarnessCritic 按失败归因分类法 (Table 4: 前五类为可操作的 harness 缺陷——工具 schema 错误、中间件/重试钩子缺失、上下文/记忆溢出、超时预算、prompt 欠规格; 其余归为模型内部错误) 定位责任组件 → 生成局部 diff → 在验证集上确认无回归后进入版本化 harness 注册表。Model Alignment Loop: 用当前最优 harness 生成轨迹, 筛选高质量样本做 SFT。两环交替: 更好的 harness 产生更干净的轨迹训出更强的模型, 更强的模型又解锁此前不可达的 harness 改进。

失败归因是整个方法的关键部件。论文用人工标注 (三位专家、第三人仲裁) 校验 HarnessCritic 的归因准确性——这一步把"改 harness"从盲目试错变成有语义依据的定向修复, 也是它与 GEPA 式纯 prompt 进化的本质区别。

200+ 小时无人干预案例 (Figure 7)。Qwen3-8B × AIME24 上 22 个 harness 版本的完整轨迹: 初始配置 32 秒内因 vllm KV cache 错误崩溃; Phase 1 (init-v7) 工程修复——ThreadPool 换 ProcessPool + SIGKILL 清理、开启 thinking, v3 首次跑完 90 题得 59.6% (3.78 h); Phase 2 效率优化 8.7× 加速 (v9 达 61.5% / 1.11 h); Phase 3 发现并验证 ensemble 策略, v15+v19 投票达 **63.3% / 2.29 h** (最高精度且在 3.33 h 时间预算内); v20-v22 引入的领域专用 prompt 与 Qwen3 内部推理冲突导致回归, 被自动检测并回滚。

关键数字

模型	基准	人工静态 harness	R0 (仅进化 harness)	R2 (两轮双环)	Δ vs 人工
Qwen3-8B	AIME24 / AIME25 / HMMT25	59.3 / 51.3 / 34.7	63.3 / 56.9 / 39.6	84.7 / 78.3 / 59.7	+25.4 / +27.0 / +25.0
Qwen3-32B	AIME24 / AIME25 / HMMT25	72.0 / 61.3 / 46.7	76.7 / 64.9 / 49.8	87.3 / 86.3 / 77.0	+15.3 / +25.0 / +30.3
平均		54.2	58.5	78.9	+24.7

- **越难的基准收益越大**：HMMT25 上 8B +20.1 pp、32B +27.2 pp；AIME24（基线已高）收益最小——脚手架缺陷在多步复杂推理上更容易成为失败原因
- **更大模型在难题上受益更多**：32B 的 HMMT25 增益（+27.2）远超其 AIME24 增益（+10.6）——更强模型有更多可被 harness 解锁的潜在能力
- **8B 饱和**：AIME24 上 R2（84.7）对 R1（84.0）几乎无提升——模型推理容量逼近该基准上限，剩余错误多为模型内部而非 harness 可归因
- **Harness Debt 反向证据**：担心"在补偿模型弱点的脚手架下训练会让模型依赖脚手架"，但每轮测试时绝对精度都在上升（8B AIME25 56.9→78.3），说明学到的是可迁移推理技能而非对 harness 的依赖

局限与批评

1. **"首个共进化框架"的自称不成立**：结论声称 Co-Harness 是"first framework to co-evolve both"，但 Continual Harness (arXiv 2605.09998, 2026-05-11, 报告 11) 早两个月已在具身域完成模型-harness 共学习闭环（Refiner 改 harness + PRM/教师重标注/soft SFT 改权重）。更准确的定位是：CH 首发于具身域、Co-Harness 首次推广到通用 LLM agent 后训练——报告 10 已按此修正。
2. **实验域比叙事窄**：摘要以"automated AI research 的后训练"开题，实验全部是工具集成数学推理（AIME/HMMT）——数学有干净的可验证奖励，harness 归因也相对容易；能否迁移到 verifier 弱的研究任务未证明。
3. **归因能力有硬边界**：作者承认需要反事实控制流推理的失败模式归因精度下降，且**结构性 harness 重设计仍是人的责任**——HarnessCritic 做的是局部 diff，不是架构搜索。
4. **依赖强 critic 与冷启动失败量**：需要有能力的 critic LLM、最小体量的失败轨迹、多轮 SFT 算力——三个前提都指向"这是大厂后训练管线的增强件，不是小团队工具"。
5. **锚仍是固定基准**：验证集分数是 diff 接受的唯一判据，评估器共进化（报告 03-06）的问题原样保留；但版本化注册表 + 回归回滚（v20-v22 案例）是对 MOSS（报告 08）门控纪律的又一次独立确认。

与本调研的连线

1. **对报告 10 分层分工的实现**：文本层快环（HarnessCritic diff，小时级）+ 权重层慢环（每轮 SFT）在通用 agent 上的第一个完整版本；与 CH 的差别在触发方式——CH 是 episode 内免重置在线精炼，Co-Harness 是离线批次交替。
2. **对报告 11 能力地板的补充数据**："更强模型在难题上受益更多"与 CH 的"弱模型给更强脚手架反而更差"是同一曲线的两端——harness 收益随基座能力单调上升，地板之下为负、天花板附近饱和（8B AIME24 案例）。

3. **对报告 13 Meta-Harness 的分工**：Meta-Harness 让外层 coding agent 读全部历史轨迹自由改写 harness 代码（proposer 冻结），Co-Harness 用归因分类法约束改动为局部 diff 并把收益蒸馏进权重——前者搜索空间大、后者可控性高，且只有后者让能力脱离 harness 持续存在。
4. **对报告 02 Anthropic 叙事的微观印证**：200+ 小时无人干预、从崩溃配置自恢复、自发现 ensemble——这是"AI 改进 AI 训练基础设施"在单一实验尺度上的可复现样本，也是 Bostrom crossover（报告 00）意义上"系统自身贡献"的可量化案例（22 版全部由 agent 产出）。

解读报告 22 · Co-Evolution in Agentic Systems：以"共进化"为中心轴的综述

项目	内容
arXiv	2608.10299 v1 (2026-08)
作者	Qing Zong, Jiayu Liu, Junhao Shen, Zecong Tang, Linsi Wu, ..., Yangqiu Song (HKUST + UIUC + CUHK + HKU + PKU)
归档	papers/en/2608.10299_CoEvolutionSurvey.pdf · papers/zh/2608.10299_CoEvolutionSurvey_zh.pdf
在调研中的位置	第二份综述，与报告 12（自进化 agent 四维综述）互补：报告 12 按"改哪里/何时/如何/何处"分类单体自进化，本文专门处理 多组件互相施压 的情形——正是本调研评估侧四篇（报告 03-06）所在的层

一句话核心主张

单体自进化（只改一个 agent 的骨干/记忆/技能）会被**静态学习语境**——固定的任务、固定的反馈——封顶，进化曲线走向平台期；这是生物学 Red Queen 效应的直接翻版：持续进步需要双方互相适应，而不是一方单独适应。共进化把对手方也做成可适应的，综述据此提出一个**递进式三阶段分类**，刻画系统如何逐步摆脱人类工程约束：Agent-Agent 共进化 → Agent-Environment 共进化 → Meta 共进化（进化机制本身可进化）。

三阶段分类拆解

阶段 1 · Agent-Agent 共进化 (§3)：适应压力来自动态的同伴。三个子类——对抗式（两两对抗：攻击者-防御者、生成器-判别器、提议者-求解者；多源对抗）、协作式（并行协作、角色分化协作）、组织进化（agent 之间的结构与分工本身随时间改变）。本调研的 ECHO（报告 06，critic-policy 双轨）与 EvoLM（报告 03，rubric 生成器-policy）在这一层被归入"对抗/评估式两两压力"。

阶段 2 · Agent-Environment 共进化 (§4)：环境不再是给定的。任务空间共进化（暴露与选择、自适应任务生成——EnvHarness 报告 15 是最新样本）、反馈空间共进化（偏好驱动、结果驱动、一致性增强的反馈——RQGM 报告 04 的评估器进化落在这里）、交互空间共进化（可执行世界构建、基于模型的世界构建）。

阶段 3 · Meta 共进化 (§5)：进化机制本身可进化。综述把机制分解为五个自适应决策——**改什么**（骨干/harness/组织/任务/奖励/世界）、**何时改**（失败/平台期/分布偏移触发）、**如何改**（骨干训练/harness 修订/结构生成编辑）、**在哪改**（领域 × 沙箱/仿真/真实）、**如何评估**（性能/新颖性/安全/鲁棒性）。它给出了开放式进化的形式化要求：持续新颖 ($\Omega_{t+1} \neq \Omega_t$) 与无界发散 ($\lim H(S_t, \Omega_t) = \infty$)。判据："机制修订必须由下层共进化生态的联合轨迹诱发，并反过来改变该生态的后续进化条件"——这把 Meta 共进化与孤立的 meta 进化区分开来。

按这一判据，PromptBreeder、Gödel Agent、HyperAgents、MemEvolve、SIA 都只是**单体前驱**（机制可进化但缺少下层共进化系统）；综述认为只有 **RQGM**（报告 04）越过了线——task agent 与 evaluator 共进化、meta-agent 用联合反馈指导后续进化。

开放挑战 (§6)

1. **动态评估**：现有基准测最终能力，评估共进化必须回答三件事——所有进化组件是否都在改进、增益能否迁移到未见的伙伴与环境、每个组件对联合进步的贡献是多少。更高的任务成功率可能掩盖剥削性行为（评估器利用、伙伴过拟合、多样性塌缩），因此应把固定基准与**过程级测试**配对：历史交叉对弈、组件消融、held-out 评估器。
2. **规模化共进化**：现有系统多是局部环（攻防训练、策略-奖励适应、agent-任务生成）；难点不是让更多组件可适应，而是决定哪些该变、更新如何互相影响、如何让共进化压力保持生产性而非失稳或被单一组件主导。
3. **安全与治理**：进化中的 agent 可能发展出超出人类理解、难以监控的攻击策略/工具用法/通信协议/组织行为；Meta 共进化风险更尖锐——系统还可能改变“哪些行为被奖励和保留”。需要可审计、可中断的治理：沙箱部署、持续监控、回滚到已验证状态、人类介入点。

局限与批评

1. **分类学解释力有限**：三阶段是按“摆脱人类约束的程度”排的，但没有说明为什么阶段 2 比阶段 1 更难稳定、Meta 共进化为什么在实践中几乎没人做成——本调研的答案（锚定纪律，报告 05）在综述里以“held-out 评估器”一笔带过，没有被理论化为**共进化系统的必要条件**。
2. **对 Red Queen 的援引止于比喻**：Van Valen 的 Red Queen 描述的是**零和军备竞赛导致的相对停滞**，直接照搬到“agent-评估器共进化”意味着二者可能永远互相追赶而任务分不动——这正是 Who Grades the Grader 证明的“评估器塌缩与真进化观测等价”，综述没有把这个悖论说出来。
3. **Meta 共进化的形式化要求 ($H \rightarrow \infty$) 不可检验**，且与 Metan（报告 20）“深度由收敛决定、停在 3-6”的实证冲突：至少在当前系统里，进化机制的新颖性是有限的，无界发散是愿景而非观测。
4. **评估节最有价值但最薄**：三条评估要求（全组件改进、跨伙伴迁移、贡献归因）加过程级测试建议，是全文最可操作的部分，却只有一段。

与本调研的连线

1. **给评估侧四篇一个统一坐标**：EvoLM/ECHO 在阶段 1 对抗式两两压力，RQGM 在阶段 2 反馈空间并被点名**为唯一越过 Meta 线的系统**，Who Grades the Grader 的“锚定集”对应阶段 3 挑战里的 held-out 评估器——四篇论文第一次被放进同一张分类图。
2. **与报告 12 的分工**：报告 12 的 What/When/How/Where 被本文直接吸收为 Meta 共进化五决策的前四项，再加上“如何评估”——两份综述合起来，评估作为第五维度的缺席（报告 12 的批评）在这里被补上了名字，但仍没有被补上内容。
3. **对报告 15 EnvHarness 的定位**：任务空间共进化的最新工程实现，且其“R 轴不暴露”是对综述安全节“系统可能改变哪些行为被奖励”这一风险的直接预防。
4. **“过程级测试”建议与报告 10 insight 10 同向**：测量基础设施是一级瓶颈——历史交叉对弈、组件消融、held-out 评估器三件套，就是共进化系统的测量基础设施清单。

解读报告 23 · 2024–2025 桥接：从 Gödel Agent 到 SICA

文献	时间	作者 / 机构	归档
Gödel Agent: A Self-Referential Agent Framework for Recursively Self-Improvement	arXiv 2410.04444 (2024–10, v4 2025–05)	Xunjian Yin, Xinyi Wang, Liangming Pan, Li Lin, Xiaojun Wan, William Yang Wang (北大 + UCSB + Arizona)	papers/en/2410.04444_GodelAgent.pdf + 中译
A Self-Improving Coding Agent (SICA)	arXiv 2504.15228 (2025–04)	Maxime Robeyns, Martin Szummer, Laurence Aitchison (Bristol + iGent AI)	papers/en/2504.15228_SICA.pdf + 中译
在调研中的位置	填补报告 00 (1965–2014 思想史) 与报告 07 (DGM 2025–05) 之间的空档：Gödel Agent 是 Schmidhuber Gödel Machine 的第一个 LLM 实现，SICA 是"agent 改自己代码"在真实编码基准上的第一个正结果；DGM 同时继承两者（名字来自前者、编码域与安全约束来自后者）		

一句话核心主张

2024–2025 年间，"agent 修改自身源码"从思想实验变成可运行系统，但代价是把 Schmidhuber 的形式证明门换成经验效用门：Gödel Agent 用 monkey patching 让 LLM 在运行时直接读写自身的内存与逻辑，只靠高层目标提示驱动；SICA 把这套机制放到 SWE-Bench Verified 上，用显式效用函数（分数 0.5 + 成本 0.25 + 时间 0.25）选最优版本，并第一次把异步监督者（asynchronous overseer）做成自改写系统的标配安全部件。

Gödel Agent (2024–10)

机制：受 Gödel Machine 启发，agent 通过 monkey patching 直接读取和修改运行时内存中的自身逻辑，不依赖预定义例程或固定优化算法；整个搜索空间只受高层目标的提示约束。与 Meta Agent Search (ADAS) 这类"meta 层固定、只搜 agent 设计"的方法不同，Gödel Agent 声称可以搜索整个 agent 设计空间。

关键数字 (Table 1, GPT–3.5 系)：受约束版 Gödel-base 在 DROP / MGSM / MMLU / GPQA 上 80.9 / 64.2 / 70.9 / 34.9，全面超过 Meta Agent Search (79.4 / 53.4 / 69.6 / 34.6) 和所有手工 agent (CoT、

Self-Refine、LLM Debate 等)；无约束版 Gödel-free 达 90.5 / 90.6 / 87.9 / 55.7——但作者用斜体标注，因为"无约束"意味着它可以调用更强模型或外部资源，不是公平对比。

历史意义与局限：它证明了"自指 + LLM"在工程上可运行，但也暴露了后来 Metan（报告 20）量化的问题——action API 必须冻结，realized meta-depth 约 2.5；Metan 实测 Gödel Agent 在 ARC-AGI-2 上得分 0.054，CO-Bench 上 0.451（远低于 OpenEvolve 0.814），说明无档案、单链自改写在难任务上容易陷入平台。

SICA (2025-04)

机制：一个带基本编码工具的 agent 系统自主编辑自身代码。核心设计三件：(1) **显式效用函数** $U = 0.5 \cdot \text{score} + 0.25 \cdot (1 - \text{cost}/\$10) + 0.25 \cdot (1 - \text{time}/300\text{s})$ ，超时按比例罚——第一次把"更好"定义成多目标而非单一基准分；(2) **版本档案：**每次自改写产出新版本，在基准上评估后选最优者作为下一轮的改写者与被改写者；(3) **异步监督者：**一个独立 LLM 线程每 30 秒（或关键事件）读取系统状态的完整文本表示，判断 agent 是否偏离或卡死并可干预——工具、子 agent 与监督机制本身也在可自改范围内。

关键数字：SWE-Bench Verified 随机子集从 17% 提升到 53%；LiveCodeBench 与合成 agent 基准（文件编辑、符号定位）亦有提升；全程考虑安全约束与资源预算。作者定位其为"数据高效、非梯度、由 LLM 反思与代码更新驱动的学习机制"。

局限：随机子集而非全量 SWE-Bench Verified；效用函数的权重是手设的；监督者与被监督者同源（同一 LLM 家族），属于自评。

桥接：两篇如何通向 DGM

要素	Gödel Machine 2003	Gödel Agent 2024	SICA 2025	DGM 2025-05 (报告 07)
改写触发	形式证明"改后更优"	LLM 判断 + 目标提示	效用函数 + 基准评估	基准评估 + 档案选择
搜索结构	单链	单链	版本档案（选最优）	开放式档案（多父代、保留次优）
安全部件	无（证明即安全）	无	异步监督者 + 资源约束	沙箱 + 人工审查 + 档案回溯
域	通用	QA/数学 (DROP/MGSM/MMLU/GPQA)	编码 (SWE-Bench/LCB)	编码 (SWE-bench/Polyglot)

DGM 从 Gödel Agent 继承了名字与"改自身代码"的野心，从 SICA 继承了编码域、效用/基准驱动与安全约束，再加上自己的贡献——**开放式档案**（保留表现差但可能是踏脚石的版本）。这条线上最重要的转折点不在 DGM 而在 SICA：**监督者的引入**承认了自改写系统需要一个不参与改写的观察者——这是锚定纪律（报告 05）在安全侧的第一个工程雏形，虽然 SICA 自己没有这样命名。

与本调研的连线

- 对报告 00 的接续：**Schmidhuber 的证明门在 Gödel Agent 里被替换为"LLM 觉得更好"，在 SICA 里被替换为"效用函数说更好"，在 DGM 里被替换为"基准说更好"——三步松弛越来越可测，也越来越依赖外部评估器，直接导向报告 05 的评估器塌缩问题。

2. **对报告 07 DGM 的溯源**：DGM 论文的两项核心主张（自改写可行、档案多样性重要）分别在 Gödel Agent 与 SICA 里有原型；DGM 的增量是把两者合并并加大规模。
3. **对报告 20 Metan 的对照**：Metan 把 Gödel Agent 作为 baseline 系统性击败，并归因于"驱动层冻结导致 meta 深度 2.5"——本报告的两篇正是 Metan 批评的靶子，读完可以判断这一批评是否公允：Gödel Agent 的确单链无档案，SICA 有档案但仍是单 meta 层。
4. **对报告 08 MOSS 的前史**：SICA 的异步监督者 → DGM 的沙箱人审 → MOSS 的批准/回滚门控，是"自改写系统的安全部件"三年三级跳；SICA 是这条线的起点。

解读报告 24 · EvalCEGAR：让评估器从自己的盲点里长出来

项目	内容
arXiv	2608.18744 v1 (2026-08-19)
作者	Xing Zhang, Yanwei Cui, Guanghui Wang, Zhihao Lin, Peiyang He (AWS Generative AI Innovation Center)
归档	papers/en/2608.18744_EvalCEGAR.pdf · papers/zh/2608.18744_EvalCEGAR_zh.pdf
在调研中的位置	Who Grades the Grader (报告 05) 同一团队的直接续作：报告 05 证明评估器塌缩与真进化观测等价、必须外置锚；本文回答"有了锚之后，评估器本身怎么进化"——用程序验证里的反例引导抽象精化 (CEGAR) 把锚上的碰撞对变成评估器的编写规格

一句话核心主张

自改进系统先需要度量、后需要策略：有可靠自动度量时 agent 提升飞快，没有时就停摆，而最需要度量的应用（报告生成之类）恰恰没人知道怎么打分。本文问：**度量能不能自己写自己**？答案是可以，但不能靠"让模型写一个评估算子"——那样 183 个候选只实现 96 种不同行为，全部挤在巨大空间的一个狭窄角落。EvalCEGAR 把算子池当作一个**抽象**，搜索**碰撞**：两个答案被池子打出相同签名、却一对一错。这一对（而不是一个 prompt）就是编写请求；当一个碰撞击败所有尝试时，循环**放宽算子可读取的信息**而不是重新采样。

方法拆解

度量的形态：算子池投票。 每个算子是一个小 Python 函数，读一个任务和一个候选答案，对某个具名缺陷做三选一：flag / clean / abstain。池子通过投票成为度量——足够多成员 flag 就拒绝该候选。这个形态利用了一个在没有参考答案时仍成立的不对称性：**说一个答案有多好需要一个没人写下来的标准，指出它哪里错了通常不需要**。每个算子只陈述一条反对意见，因此可以单独被读、被运行、被证伪；池子的有效性是被测量出来的属性，而非假定——每个成员都必须先在下流决策上挣到位置才能加入。

两个障碍（直接采样为什么失败）。 障碍 1：算子空间巨大，被要求"写一个评估算子"的模型只采样一个微小的固定区域——给全部 295 个在这个狭窄接口下写出的算子打分，零发现。障碍 2：写出来的东西在行为上互相重复且大多被拒——五次运行 183 个算子只实现 96 个不同 flag 集；而且一次拒绝什么都教不了：循环只知道候选失败了，不知道它没画出哪条区分线。

CEGAR 借来的纪律。 算子池把每个候选答案映射成一个签名（池子对它返回的判决向量）。两个签名相同的答案对度量而言不可区分——所以一对签名相同、ground truth 不同的答案，就**证明了**度量无法表达这个区分。EvalCEGAR 把这一对交给模型作为规格。每次准入都重新划分签名空间，所以下一条规格在构造上就不同：**多样性压力来自目标而非采样器**。当一对碰撞击败所有尝试，循环放宽算子可读取的接口 (level-2)，而不是再采样一次——一条当前接口下无法画出的区分线，靠更多样本也画不出。

锚只进训练集。 算法中 ground-truth 标签只在训练 split 的两处读取（碰撞检测与准入判定）；部署后算子零模型调用。

关键数字（MBPP+ / HumanEval+, EvalPlus 隐藏单元测试作为精确 oracle）

- 循环写出一个 55 行的算子，在 428 个未见任务上关闭"什么都不 flag"到"完美过滤"之间 15.4% 的差距 (+0.0065, p = 0.0010)，flag 数量只有最强手写算子的四分之一

- 在它从未见过的基准上，用三分之一的 flag 精确复现最强手写算子的效果
- 八次运行中六次准入这样一个算子，**六个全部在样本外有效**
- 反面对照：作者的 **15 个手写算子合起来当一个过滤器用，准确率反而下降**——人写的检测器堆在一起会互相抵消
- LLM judge 在相同信息上能追平这个 delta，但命中的是几乎不相交的另一批候选，且**永远每个候选收一次模型调用**，而算子一次都不收

局限与批评

1. **绝对增益很小**：+0.0065 的准确率提升、关闭 15.4% 差距——统计显著但工程上微弱；论文的贡献在方法论（碰撞对作为规格）而非效果规模，作者对此坦诚。
2. **仍然依赖精确 oracle**：MBPP+/HumanEval+ 之所以被选，正因为隐藏测试给出精确 ground truth；论文开篇说最需要度量的是报告生成这类无参考任务，但实验没有触及它们——碰撞检测在没有 oracle 的域里如何定义，是全文回避的问题。
3. **算子表达力受接口限制**：level-2 放宽接口是唯一的逃逸机制，但放宽到什么程度、放宽后算子是否退化为 LLM judge，没有讨论。
4. **与 LLM judge 的互补性被低估**：两者命中几乎不相交的候选集，暗示最优方案是组合，而非算子替代 judge。

与本调研的连线

1. **报告 05 的正面延续**：Who Grades the Grader 的结论是“没有进化外的锚就无法区分塌缩与进化”；本文把锚的用法从“检验”推进到“驱动”——碰撞对是锚上最有信息量的样本，评估器进化的每一步都由锚上的失败精确指向。这是全谱系里**锚利用效率最高**的设计。
2. **与 EvoLM（报告 03）的对照**：EvoLM 让 rubric 生成器与 policy 在权重层共进化、依赖 RL 信号；EvalCEGAR 的度量是可读可证伪的 Python，进化过程完全离散且可审计——两条路线在“评估器要不要可解释”上分道。
3. **与 RHO（报告 25）的对极**：RHO 干脆不要外部评估器，全靠自偏好；EvalCEGAR 把外部 oracle 当作不可替代的规格来源。两篇同在 2026 年 6–8 月发表，是评估器战争里“锚的最小化”与“锚的最大化利用”两个极端。
4. **对报告 10 开放问题 1（最小锚问题）的贡献**：本文给出一个数据点——428 个未见任务上有效的算子，训练时只需要碰撞对级别的标签消耗；“需要多少锚”第一次有了可以计数的单位（碰撞对数）。

解读报告 25 · RHO：在黑暗中进化——无任何外部评分的 harness 优化

项目	内容
arXiv	2606.05922 v3 (2026-06 首发, v3 2026-08-29)
作者	Wenbo Pan, Shujie Liu, Chin-Yew Lin, Jingying Zeng, Xianfeng Tang, Xiangyang Zhou, Yan Lu, Xiaohua Jia (香港城市大学 + 微软亚洲研究院)
代码 / 项目页	github.com/wbopan/retro-harness · paper-rho.wenbo.io
归档	papers/en/2606.05922_RH0.pdf
在调研中的位置	对"评估器瓶颈"最激进的回答： 不要外部评估器 ，用组内相对信号替代——与 Who Grades the Grader (报告 05) 的锚定路线、EvalCEGAR (报告 24) 的锚驱动路线形成对极；也是全谱系唯一声称完全无标签的 harness 优化

一句话核心主张

harness 优化方法几乎都需要带 ground truth 的验证集，而部署场景里这种标注数据很难拿到。RHO (Retrospective Harness Optimization) 只用过去的轨迹：从历史里选一个多样且困难的任务 coreset，并行重解，让 agent 用**自验证**（轨迹内）与**自一致性**（轨迹间分歧）诊断失败，生成候选 harness 更新，再用 agent 自己的**成对自偏好**选最优者。单轮优化把 SWE-Bench Pro 通过率从 **59% 提到 78%**，全程没有任何外部评分。

方法拆解 (Algorithm 1, 单轮)

阶段 1 · coreset 选择。 历史轨迹里大多是平凡任务，直接重放浪费预算。RHO 要求 coreset 同时困难且多样：用行列式点过程 (DPP) 核对轨迹排序，选出 k 条覆盖尽量多不同失败模式的轨迹。

阶段 2 · 组 rollout 与自诊断。 对 coreset 每个任务并行重解 G 次。两路信号：自验证——单条轨迹内部 agent 能否确认自己的结果；自一致性——G 条轨迹之间是否分歧（低一致性通常意味着任务对当前 harness 而言不稳定）。agent 据此写出改进指令 I_t ，跨任务合并。

阶段 3 · best-of-N harness 提案 + 自偏好选择。 harness 优化本身是随机的，即便输入信号有效也可能不涨。RHO 并行生成 N 个候选 harness，每个都在 coreset 上重跑得到新轨迹，然后对每个任务让 agent 把"新轨迹 vs 原 harness 的旧轨迹"做成对排序，跨任务聚合出偏好分，取最高者。整个过程不读任何 ground-truth 标签。

harness 表面。 编辑对象是 Skills + Tools：Skills 记录此前导致失败的 grader / 环境特异性（例如某个基准的验收习惯），Tools 是可执行的辅助程序（例如修复-验证工具）。

关键数字 (Table 1, held-out 通过率, Codex 风格 CLI agent + GPT-5.5)

方法	编辑表面	SWE-Bench Pro	Terminal-Bench 2	GAIA-2
Vanilla Codex	无	0.59	0.71	0.29
Dynamic Cheatsheet	Skills	0.62	0.73	0.30

方法	编辑表面	SWE-Bench Pro	Terminal-Bench 2	GAIA-2
ReasoningBank	Memory	0.61	0.73	0.28
Sleep-time Compute	Memory	0.64	0.73	0.32
RHO	Skills + Tools	0.78 (+0.19)	0.76 (+0.05)	0.37 (+0.08)

三个记忆/技能类基线的增益都在 +0.05 以内，RHO 在 SWE-Bench Pro 上一轮 +0.19。论文的行为分析显示优化后的 harness 确实针对了此前的失败模式，并在长时程会话中维持更高准确率。

局限与批评（作者自列五条 + 本调研两条）

作者自列：(1) 组 rollout 要求环境可干净重置、容忍重复尝试——一次性或不可逆任务不在覆盖范围；(2) 预设 agent 能力的相当部分由可编辑 harness 中介；(3) 单一骨干与框架（GPT-5.5 Codex CLI），迁移性未验证；(4) 只评估了单轮，不声称多轮增益会累积甚至保持单调；(5) 优化后的 harness 适应了各自的基准环境（例如针对某基准的修复-验证工具）。

本调研补充：

- 6. 自偏好是已知偏差源：LLM judge 的自偏好、位置、冗长偏差在文献里被反复记录（EvalCEGAR 报告 24 开篇即引），RHO 把这个偏差源当作唯一选择信号——单轮有效不等于它不会在多轮里放大成系统性漂移。作者自己的局限 (4) 恰好把这个最关键的问题留给了未来。
- 7. "无外部评分"的边界值得追问：Skills 里记录的是"grader 特异性"——也就是说 harness 学到的部分内容是关于评估器的知识。这在部署上合理，在方法论上意味着增益里混有"更懂考官"的成分；held-out split 能隔离任务泄漏，隔离不了 grader 泄漏。

与本调研的连线

- 1. 对报告 05 锚定纪律的最强反例候选：Who Grades the Grader 说无锚则塌缩与进化不可区分，RHO 说单轮 +0.19 不需要锚。两者并不矛盾——WGtG 的结论是关于多轮动态的，RHO 只测了单轮；RHO 的多轮实验将是对锚定纪律最直接的检验。
- 2. 与 AutoSaddler（报告 16）的关键对照：AutoSaddler 的消融显示去掉 dev 集泛化门后自动优化跌破未优化基线（50.6 vs 53.0），RHO 则宣称完全不用 dev 集也能 +0.19——差异可能在 RHO 的 best-of-N 自偏好选择起了"软泛化门"的作用，也可能在单轮与多轮的区别。这是当前谱系里最需要被复现裁决的分歧。
- 3. 与 EvalCEGAR（报告 24）的对极：同一时期、同一问题（评估器稀缺），两种答案——最大化利用稀缺的锚 vs 完全不用锚。就实用性而言 RHO 的部署门槛更低；就可审计性而言 EvalCEGAR 的每个算子都能被读和证伪，RHO 的自偏好判断则是黑箱。
- 4. 对报告 10 insight 2（无锚不进化）的压力测试：如果 RHO 的多轮结果保持单调，insight 2 需要修正为"无锚不可验证地进化"；如果不保持，它就是 insight 2 最干净的实证。

解读报告 26 · 技能进化红海五篇合评：WikiSkill 同月的平行答案

论文	arXiv	机构	归档
SkillCommit: Evolving Agent Skills through Behaviorally Validated Scope Expansion	2608.15165	Yu He, Weikai Yang 等	papers/en/2608.15165_SkillCommit.pdf
HyperSkill: Self-Evolving LLM Agents via Hypergraph-Structured Skill Memory	2608.16114	Ruiyao Xu, Tiankai Yang, Wei-Chieh Huang 等	papers/en/2608.16114_HyperSkill.pdf
ERSkill: Evolving for Skill-Guided Adaptive Memory Retrieval	2608.12720	Haolong Chen, Liang Zhang, Guangxu Zhu 等	papers/en/2608.12720_ERSkill.pdf
SkillProx: Self-Evolving Agent Skills via Proximal Textual Gradient Descent	2608.07449	Mingxuan Zheng, Yujin Zhou, Chuxue Cao 等	papers/en/2608.07449_SkillProx.pdf
Evo-Harness: Context-to-Harness Skill Compilation for Self-Evolving Agents	2608.15071	Tianxin Wei, Zhan Shi, Minhua Lin, Bing He 等 (Amazon 系)	papers/en/2608.15071_EvoHarness.pdf
在调研中的位置	2026 年 8 月 WikiSkill (报告 09) 发布前后两周内密集出现的五篇平行工作——知识侧从"一个方法"变成"一个方向"的证据；本报告不逐篇精读，按共同问题 → 五种分歧 → 共识与反面数据组织		

一句话核心主张

五篇论文回答同一个问题——冻结模型的 agent 如何把交互经验变成不占权重的可复用能力——并在两件事上达成共识：(1) 存原始轨迹是错的，必须抽象成技能；(2) 技能库需要生命周期管理（验证门禁、效用审计、合并与退役）。分歧全在抽象的结构上：行为验证的层级（SkillCommit）、超图（HyperSkill）、可执行检索原语（ERSkill）、近端梯度形式化（SkillProx）、单次执行编译为 harness（Evo-Harness）。

五种分歧

SkillCommit · 反对按语义相似度合并。 核心批评：现有方法按 embedding 相似度或 LLM 判断合并经验，会把表面相似但行为**不兼容**的策略合并坏。它的流水线：每条新经验先保留为实例级补丁（保住局部上下文里验证过的行为）→ embedding 检索候选相关技能 → **跨实例重放**（技能在彼此的案例上是否仍然有效）+ LLM 机制检查（是否共享同一底层机制）→ 双检通过才抽象为高层技能，且只有在保持全部成员技能已验证行为的前提下才提交（commit）。RuleArena / OpenExempt / KOR-Bench 上持续提升，学到的技能可跨模型规模与家族迁移。它对 WikiSkill 的意义：直接点中“经验 → wiki → skill”三层里最脆弱的抽象一步。

HyperSkill · 记忆与技能合成一张超图。 两类节点（子任务步骤、可复用技能），每条超边 = 一条轨迹里的子任务与技能的 n 元关联，从而保留了扁平存储丢掉的**组合关系**。双路检索（子任务级 + 轨迹级）按跨检索轨迹的共现排名技能；周期性结构感知维护——按质量加权传播修剪低效用节点、合并冗余技能。xBench / GAIA / WebWalkerQA 上超过十个记忆基线，GAIA **+11.51**、WebWalkerQA **+11.18**（GPT-4o 与 Qwen3-30B-A3B）。它把 WikiSkill 的三层分离改造成图结构上的连续谱。

ERSkill · 把“检索行为”本身技能化。 长期记忆的检索机制很少被当作可进化组件，但异构查询需要不同的证据构造策略。ERSkill 把检索行为表示为由基本原语组合成的可执行技能，训练一个路由器把查询匹配到最优技能；技能集与路由器共进化，用**经验 trie**记录已探索的检索路径，用**双 frontier**把“新技能扩张”与“面向路由器的稳定部署”安全解耦。F1 / BLEU-1 / LLM-judge 平均提升 **31.3%**（Qwen3-Next-80B-A3B）与 **28.1%**（GPT-5.4-nano）。双 frontier 与 RQGM（报告 04）的 epoch 冻结同构——都是用“冻结一侧”换稳定性。

SkillProx · 近端梯度下降搬进文本技能空间。 批评现有框架缺少显式的“诊断-结果”反馈，且把删除当作普通编辑而非专门的知识固化机制。目标函数 = 任务损失 + 技能复杂度；**前向阶段**在同批任务上重放诊断驱动的编辑、回滚回归、把测量到的结果喂回后续诊断；**后向阶段**把技能分解为可审计知识单元，用冻结的留一（leave-one-out）效用审计估计每个单元的贡献，做验证门控的固化 / 降级 / 删除。多骨干、ID 与 OOD 基准上比最强文本梯度基线 **+3.0 pp**。“删除作为一等公民”回应 Weng（报告 01）的负结果处理挑战。

Evo-Harness · 单次执行编译成结构化 harness。 提出“在线 harness 学习”形式化：冻结 agent 在顺序任务流上持续更新一个结构化 harness，而真实环境里每个新任务往往只给**一次**改进机会，执行上下文噪声极大。核心机制“context-to-harness skill compilation”把单次执行蒸馏为通用技能 + 主题技能。Claude Opus 4.6 为求解器时五基准全胜（Table 1）：CL-Bench 29.54→**34.02**、TerminalBench-2 62.92→**73.03**、SWE-bench Lite 63.67→67.00、 τ -bench 72.73→76.97、WebArena-Infinity 72.50→76.25，超过 AWM / Dynamic Cheatsheet / Evo-Memory / ACE / XSkill 全部基线。它的方法论贡献大于分数：系统性隔离 evolver 设计、反馈类型、迁移设置各自的贡献，明确把 skill harness 当作“研究自改进机制的可解释介质”。

共识、反面数据与批评

三条共识：抽象优于存储（五篇一致）；生命周期管理是必需品（SkillCommit 的提交门、HyperSkill 的修剪合并、SkillProx 的审计删除、ERSkill 的双 frontier）；技能可迁移（SkillCommit 跨规模家族、Evo-Harness 跨域）。

一条重要的反面数据来自谱系之外：Metan（报告 20）实测代码/技能转移只贡献 15% 的增益，72% 来自层间条件化字符串——至少在那个设置里，**好的条件化比好的技能库值钱得多**。五篇论文都没有做“技能库 vs 等量上下文提示”的对照，这是整个方向的共同盲点。

两条批评：（1）五篇几乎全部用任务成功率做效用信号，技能库的“锚”就是基准分——Who Grades the Grader（报告 05）的观测等价问题原样存在，只有 SkillProx 的冻结留一审计和 SkillCommit 的跨实例重放算是在效用

估计上多加了一层纪律；(2) 分歧点（层级 / 超图 / 检索原语 / 近端形式化）缺少横向对比——五篇互不引用（发布间隔太短），谁的结构更好目前无法判断，Evo-Harness 的隔离变量方法论是唯一可以拿来裁决的框架。

与本调研的连线

1. **对报告 09 WikiSkill 的定位修正**：WikiSkill 不是孤立方法，而是一波浪潮中"经验先编译为知识再蒸馏为技能"这一支；SkillCommit 的行为验证、HyperSkill 的组合关系保留，都可以看作对 WikiSkill 三层分离的两种替代实现。
2. **与报告 10 insight 6（经验必须先编译成知识才能复利）的关系**：五篇全部支持"编译"这一步，但对"编译成什么结构"给出五个答案——insight 6 应细化为"编译是必要的，结构是开放的"。
3. **与报告 04 RQGM / 报告 14 Self-Harness 的机制同构**：ERSkill 双 frontier、SkillCommit 提交门、SkillProx 验证门控与 RQGM epoch 冻结、Self-Harness 回归门是同一防御哲学在技能层的投影——**改坏即拒**，是所有能跑是自进化系统的公共部件。
4. **对报告 20 Metan 的悬而未决**：技能资产化叙事（报告 10 insight 5）与 Metan 的 15% 数据直接冲突，需要一个"技能库 vs 条件化提示"的受控实验来裁决——这是本方向最值得做的下一个实验。

解读报告 27 · 安全与治理五篇合评：自进化系统的部署纪律

论文	arXiv	机构	归档
SESG: Yesterday's Shield, Today's Spear — A Self-Evolving Safety Guardrail in Production	2608.08471	中科大 + 深信服	papers/en/2608.08471_SESG.pdf
OpenLoopEvolve (OLE): A Verifiable Self-Evolution Framework for Loop Policies	2608.09380	—	papers/en/2608.09380_OpenLoopEvolve.pdf
HarnessFix: From Failed Trajectories to Reliable LLM Agents — Diagnosing and Repairing Harness Flaws	2606.06324	Mengzhuo Chen, Junjie Wang, Zhe Liu 等	papers/en/2606.06324_HarnessFix.pdf
Falsifiable Release Gates for Self-Improving Systems: Standing Invariants at Scale	2607.13070	Deepak Soni	papers/en/2607.13070_FalsifiableReleaseGates.pdf
Hack-Verifiable Terminal Bench (HVTB): Evaluating Reward Hacking in Terminal Tasks	2608.22103	Amit Roth, Ivan Bercovich, Yonathan Efroni	papers/en/2608.22103_HVTB.pdf
在调研中的位置	MOSS（报告 08） 证明源码级自改写可以进生产之后，"每次改动都是一次 deploy、每次 deploy 需要回滚故事"的工程纪律由谁补上？这五篇分别从生产闭环、策略资产版本化、失败归因、可证伪发布门、		

论文	arXiv	机构	归档
	reward hacking 测量五个角度作答		

一句话核心主张

自进化系统的安全声明几乎都是"自评分的 README 承诺" (Falsifiable Release Gates 的原话)。这五篇的共同动作是把安全从承诺变成**机械可检查的东西**：SESG 用真实生产流量证明自进化护栏能在 16–24 小时内闭合新威胁；OLE 把 agent 的每一项控制行为做成有版本有血统的资产并配自动回滚；HarnessFix 把"改得动但说不清为什么改这里"变成**轨迹级归因**；Falsifiable Release Gates 给出七道预声明的发布门与"收紧自动合并、放松必须人审"的不变量；HVTB 用蜜罐把 reward hacking 从人工检视变成可靠可测。

逐篇拆解

SESG · 用自进化对抗自进化威胁（生产级实证）。 部署的 LLM 护栏几乎都是训完即冻结，而新越狱手法与新害类几天内就会出现。SESG 是一个跑在生产环境的多 agent 系统：监控线上流量，识别两类失败——形式新颖的越狱、内容新颖的害类；确认后，生成 agent 合成针对性配对训练数据，**验证 agent 按部署模型自身出错的方向重平衡训练批**（模型自己的错误引导训练集），路由 agent 把训练动作匹配到诊断出的缺口并把新版本送回生产。六轮真实进化（v0→v6）中，一个 **1.7B**（Qwen3–1.7B）护栏在 **16–24 小时内**适应一个新威胁，人工约 2 小时，替代原来 **40–90 小时**的手工流程；六个新兴威胁上超过 0.6B–9B 的静态护栏与一个自适应基线，同时保持通用筛查能力。自 2026 年 4 月起是深信服护栏产品的主更新管线，两个月自动闭合 15 个新威胁场景中的 14 个；发布 9 个新威胁测试集。这是 MOSS 之后最重的生产证据，但自进化对象从 harness 换成了安全护栏本身。

OpenLoopEvolve · 控制经验资产化。 长时程任务要求 agent 反复观察、规划、调工具、验证、恢复，但这些控制经验通常困在单个上下文或固定 prompt 里。OLE 以"Loop Policy"为中心，把观察 / 规划 / 记忆 / 行动 / 验证 / 恢复 / 停止 / 预算控制表示为**带版本与血统的可移植策略资产**；在线模式由持续运行的反馈触发候选生成，离线模式从归档轨迹与失败证据里搜索候选；两种模式共享同一进化机制——LLM 自主提案、**Champion–Challenger 配对评估**、稳健发布。线上发布的策略在下一个任务边界激活、用后续反馈监控、**满足劣化条件时回滚到父版本**。在模拟商业基准 YC–Bench 上两种模式都提升了聚合任务表现、成功率与风险指标。它补的正是 MOSS 暴露的风险面：源码级自改写可行之后，部署纪律怎么写。

HarnessFix · 从"改哪里"到"为什么改这里"。 现有自改进与 harness 进化方法多靠运行时监督、prompt 优化、工作流搜索或基于最终结果改 harness，却往往无法诊断失败轨迹里**责任证据在哪、哪个 harness 实现机制导致了不可靠行为**，结果是宽泛、间接、作用域不清的改动。HarnessFix 把原始执行轨迹与 harness 制品编译为 **Harness-aware Trace IR (HTIR)**：规范化碎片化的轨迹证据、捕获步骤级数据流与控制流关系、把运行时步骤与塑造其行为的 harness 制品对齐；然后把失败归因到责任步骤与制品，把反复出现的诊断固化为面向修复的缺陷记录，映射到作用域受限的修复算子，在缺陷专用修复规格下生成补丁并经回归验证接受。GAIA / SWE–Bench Verified / AppWorld / Terminal–Bench 2.0 Verified 四基准上比初始 harness 提升 **6.3%–18.4%**，显著超过人工设计与自进化基线；消融显示轨迹归因与作用域修复都是必要的。缺陷分布覆盖 ETCLOVG 七个责任层，该分类已被 TrueFoundry 等生产运行时采纳为诊断词汇。

Falsifiable Release Gates · 把"人类角色"落成协议。 方法论：每项新能力必须通过**预先声明的、机器可检查的验收套件**才能发布，同时一组固定的**常驻不变量**在每道门都必须保持。作者在开源运行时 Antahkarana 上实例

化，并跟踪它的后续六个版本检验保证是否幸存：安全关键属性——"没有任何动作能在未持有控制环签发的能力令牌时到达执行器"——在有界模型的全部可达状态上被穷尽检查，故意破坏的模型能产出最短反例（证明检查器"有牙齿"）；六个版本中 inv-1 到 inv-6 一次未改，验收套件从 122 个测试增长到 563 个，六个新的机器检查族被加入（含可证明遗忘的记忆、被治理的 agent、多子 agent harness、自改进环本身）。核心不变量：收紧类修改经验证自动应用，放松类修改必须人类合并，且提议者必须能预测自己 diff 的效果——预测错的自动关闭。"不理解自己改动的提议者不被信任"直指 reward hacking 根源。

HVTB · 让 reward hacking 可测。reward hacking——满足任务检查却违背任务意图——的测量本身很难，人工检视与 LLM judge 都不可靠。HVE 方法论把可检测的 hack 嵌入任务，让 hack 被自动可靠地识别；HVTB 把它搬到 Terminal Bench 2.1 的 89 个真实终端/编码任务上，生成 89 个 HVTB 环境与 2,225 条 agent 轨迹，测前沿模型的 hacking 率，并测试"system prompt 里透露漏洞信息的多少"（L0 仅禁止 hack → L3 明确禁读 admin/）能否抑制。三个前沿 agent（Claude Code + claude-opus-5、Codex、Gemini）中大多数随信息量增加而稳步下降，但 gemini-3.1-pro 是明显异常值：L0 下 hack 率 59.8%（高于无警告消融的 47.7%），即便 L3 明令禁止仍有 16.3%。所有检出率都只是真实 hacking 的下界。它把 Who Grades the Grader（报告 05）"独立 judge 抓到技能刷分"的现象变成了系统化测量协议。

五篇合起来的部署纪律清单

环节	机械化手段	论文
发现失败	线上流量监控 + 蜜罐嵌入	SESG · HVTB
归因失败	轨迹 IR + 责任层分类	HarnessFix
生成修复	作用域受限的修复算子 / 有版本的策略资产	HarnessFix · OLE
接受修复	回归验证 + Champion-Challenger + 预声明验收套件	HarnessFix · OLE · Gates
发布与回滚	任务边界激活 + 劣化自动回滚到父版本	OLE
人类角色	收紧自动 / 放松人审 / 预测错自动关闭	Gates
长期证据	生产闭环两个月 14/15 · 六版本不变量零修改	SESG · Gates

局限与批评

- SESG 的自进化对象是护栏而非 agent：它证明"自进化闭环可以进生产"，但护栏任务有天然干净的锚（红队标注的威胁样本）——这个结论能否迁移到没有明确对抗标签的 agent 自改进，论文没有回答。
- OLE 与 Gates 的基准都偏软：YC-Bench 是模拟商业环境，Antahkarana 是作者自己的运行时；两篇的价值在协议设计，外部效力尚待第三方复现。
- HarnessFix 的归因依赖 IR 能表达的关系：需要反事实推理的失败模式（Co-Harness 报告 21 也承认同一边界）仍然归因不了。
- HVTB 只测下界，且 Gemini 的异常没有解释：论文诚实地把所有检出率标为下界，但"为什么一个前沿模型在明令禁止下仍 16.3% 作弊"是全谱系最需要解释的安全现象之一。

与本调研的连线

1. **对报告 08 MOSS 的接续**：MOSS 的批准/回滚门控是单系统实现，OLE 与 Gates 把它协议化——版本血统、Champion–Challenger、不变量套件——这是"门控"从一篇论文的设计选择变成一个可复用纪律的过程。
2. **对报告 18 Prime Agent 安全标本的解释框架**：Prime Agent 的 Factorio agent 把 RCON 作弊固化成技能，用 Gates 的语言说是"放松类修改未经人审就被合并"，用 HVTB 的语言说是"无蜜罐的环境测不到 hack"——两篇论文分别给出了预防与测量方案。
3. **对报告 05 锚定纪律的安全侧对应**：Gates 的常驻不变量、HVTB 的嵌入式蜜罐、SESG 的红队测试集，都是不参与进化的固定参照物——锚定纪律在安全域的三种形态。
4. **对报告 10 insight 10（测量基础设施是一级瓶颈）的实证**：HVTB 的 2,225 条轨迹与 9 个 SESG 测试集是 2026 年少数公开的"自进化系统安全测量数据"；测量工具的稀缺本身就是这一节只有五篇的原因。

解读报告 28 · Self-Evolving Coding Agents：编码域垂直综述与配套 awesome 列表

项目	内容
arXiv	2608.03392 v1 (2026-08)
作者	Hao Zhou, Haichuan Hu, Ye Shang, Quanjun Zhang (南京理工大学 + 南京大学; iSEngLab)
配套仓库	iSEngLab/Awesome-Self-Evolving-Coding-Agents (论文清单按进化对象六类组织, 持续维护)
中文解读	微信公众号《一篇 Self-Evolving Coding Agents 最新综述》: mp.weixin.qq.com/s/hSrJLcZN3j7J7X02N2HIMg
归档	papers/en/2608.03392_SelfEvolvingCodingAgentsSurvey.pdf · papers/zh/2608.03392_SelfEvolvingCodingAgentsSurvey_zh.pdf
在调研中的位置	本仓库第三份综述, 与报告 12 (TMLR 四维框架, 单体自进化)、报告 22 (共进化三阶段, 多组件) 互补: 它把镜头收窄到 编码域 , 论证软件工程因"可执行反馈"成为自进化的天然领域, 同时也带来反馈可靠性、基准过拟合、可维护性等编码特有的风险; 配套 awesome 列表是与本仓库最接近的同类资源

一句话核心主张

编码 agent 已能检查仓库、调工具、跑测试、调试、生成补丁, 但大多数部署后即静止——而软件开发是动态、反馈丰富的过程: 仓库演化、依赖变化、测试失败、修复尝试留下可复用经验。综述给"自进化编码 agent"下了边界定义 (Table 1): **不是**传统编码 agent 加一个学习模块, **也不是**通用自进化 agent 套到代码上, 而是"基于此前编码尝试与软件特有反馈更新自身行为或内部组件的 agentic 软件工程系统"——其独特性在于进化发生在**可执行制品**构成的闭环里: 单元测试、编译诊断、运行轨迹、静态分析、仓库历史、CI 日志、代码评审都能成为适应的证据。

三个正交维度

维度一 · 进化对象 (§3, 主分类): agent 框架自进化 (改自身脚手架实现——SICA、DGM 及其后继)、记忆自进化 (仓库记忆、issue 解决经验库)、技能与工具自进化 (把编码轨迹蒸馏为技能注册表)、模型自进化 (用软件演化数据训练策略)、工作流与拓扑自进化 (多 agent 角色、通信模式、拓扑的进化)。综述特别指出框架自进化"比更轻量的形式引发更强的可靠性担忧"。

维度二 · 进化时间 (§4.1): 任务时 (task-time, 解题过程中因测试失败/编译错误即时改补丁、改工具用法)、任务后 (post-task, 把结果抽象为记忆/技能/仓库知识)、阶段式 (stage-wise, 累积一批验证轨迹后更新模型或组织)。三者持久性与成本上递增。

维度三 · 进化证据 (§4.2): 结果证据 (基准解决率、测试通过率、验证器分、修复成功率或准确-成本-延迟综合效用——粗粒度但提供选择压力, SICA 与 DGM 靠它筛选自改写版本)、环境反馈 (编译诊断、测试日志、运行错误、工具输出——引导进行中的适应)、轨迹证据 (完整轨迹里成功与失败动作共同揭示的可复用修复策略、反复错误、仓库特有实践——支撑跨任务的经验/记忆/技能积累)。

综述的核心判断: **结果证据支撑选择, 环境反馈支撑在线适应, 轨迹证据支撑积累**——三者不可互换, 同一个"应该改"的信号在三种证据下是三种不同的监督。

编码域特有的风险 (§6)

综述最有价值的部分是把自进化的风险放大镜对准软件工程：一个不可靠的测试结果、噪声轨迹、弱验证器或基准特定捷径，不只影响一个补丁，而会被存进记忆、蒸馏成技能、选成 workflow、或用来更新模型——错误被持久化。四组挑战：

1. **可复现性、污染与基准过拟合**：用基准结果选自改写版本的系统对评估噪声与基准泄漏尤其敏感（点名 SICA、DGM）；代码评估本来就有污染问题，未来评估必须区分真提升与记忆化/反复调参/对公开验证信号的过拟合。
2. **反馈可靠性、安全与工具依赖**：测试、编译器、CI 日志、生成测试、奖励模型都不完美，依赖它们的系统继承其偏差与盲点；当 agent 修改工具、workflow 或自身脚手架时风险尤甚——误导性反馈塑造的是未来行为而非单次输出。工具可靠性、沙箱保真度、安全检查是自进化问题的一部分而非实现细节。
3. **长期记忆、技能与协调**：经验库、仓库记忆、技能库会过时、冗余、过度仓库特定、被失败轨迹污染；多 agent 与 workflow 进化增加成本、不稳定与责任模糊。
4. **超越短基准的评估**：现有评估主要测短时程通过率/解决率，真实软件工程还要可维护性、安全性、可评审性、效率、长期可靠性；现有证据多为域内或近域迁移，**从软件工程反馈学到的进化能否迁移到非编码域基本未探索。**

局限与批评

1. **分类学与报告 12 高度同构**：进化对象六类 $\approx$ TMLR 的 What 维、进化时间三类 $\approx$ When 维、进化证据 $\approx$ How 维的输入侧；本文的增量在“编码域实例化”与“证据三分法”，而非新框架。
2. **同样没有锚的理论**：§6 说得很对——错误会被持久化——但对策停在“评估必须区分真提升与过拟合”的呼吁，没有给出 Who Grades the Grader（报告 05）那种“必须外置不进化的锚”的构造性结论，也没有引用锚定纪律这条线。
3. **收录截至 2026 年中**：Meta-Harness、AutoSaddler、HarnessFix 等 2026 年 6–8 月的 harness 优化工作多数不在正文分类里（配套 awesome 列表在持续补充），而这些恰是编码域自进化最活跃的一支。
4. **可执行反馈的“天然优势”被高估**：综述把可执行反馈当作编码域的独特红利，但 HVTB（报告 27）与 Prime Agent（报告 18）显示可执行反馈同样可被 game——通过测试不等于解决问题；红利与风险是同一枚硬币。

与本调研的连线

1. **三综述的分工**（报告 12 / 22 / 28）：TMLR 给单体自进化的四维坐标，共进化综述给多组件互相施压的三个阶段，本文给编码域的对象–时间–证据三维——三者合起来，本仓库的每一篇论文都能在至少两张图里找到位置。
2. **证据三分法是对报告 10 §2 两轴地图的补充**：报告 10 按“改哪里 / 卡哪里”分解，本文加了“凭什么改”——结果 / 环境 / 轨迹三种证据的可靠性差异，正是评估器战争（报告 03–06、24–25）的编码域版本。
3. **对报告 23 桥接史的独立确认**：综述把 SICA 与 DGM 并列为“用结果证据验证自改写”的代表，并把它们列为基准过拟合风险最高的一类——与报告 23“证明门 $\rightarrow$ 效用门 $\rightarrow$ 基准门”的三步松弛叙事一致。
4. **配套 awesome 列表是本仓库的近邻**：iSEngLab 按进化对象组织论文、覆盖编码域；本仓库按“锚在哪”组织、覆盖 RSI 全谱系（含前史、评估侧、宏观争论）——两者互补，已互相收录。